

Università degli Studi di Napoli
Federico II

A.A. 2026-2027

Metodi Statistici per l'Informazione

Indice

0 Prefazione 7
Organizzazione del corso 8
Come è fatta questa dispensa 8
I simboli che incontreremo 8
Convenzioni tipografiche 10

I Probabilità e variabili aleatorie discrete 12

1 Esperimenti, eventi e insiemi 13
Esperimenti aleatori e spazio campione 13
Spazi discreti e spazi continui 14
Eventi 14
Quattro esperimenti da tenere a mente 15
Il lancio di una moneta 15
Il lancio di un dado 16
I pacchetti in coda a un router 16
Operazioni fra eventi 17
Le leggi dell'algebra degli eventi 18
Le leggi di De Morgan 18
Le proprietà associativa e distributiva 19
Un po' di nomenclatura 21

2 Contare: il calcolo combinatorio 23
Quando tutti i risultati si equivalgono 23
Due lanci consecutivi 24
La regola generale 24
Il principio fondamentale: moltiplicare le scelte 25
Disposizioni: quando l'ordine conta 27
Disposizioni semplici 27
Disposizioni con ripetizione 28
Permutazioni 28
Combinazioni: quando l'ordine non conta 29
Un problema con le carte 32
L'insieme delle parti e il binomio di Newton 33
Prove ripetute e conteggio dei successi 34
Riepilogo delle formule 35

3 Dalla frequenza alla probabilità 36
La probabilità come limite della frequenza 36
Spazi finiti con eventi equiprobabili 37
Un esempio completo: i punteggi del poker 38
Coppia d'assi e coppia qualsiasi 38
Almeno tre assi, tris, colore 39
Quando i risultati non sono equiprobabili 40
Le proprietà della probabilità 41

Probabilità condizionata 43
La legge della probabilità composta 44
La legge della probabilità totale 45
Eventi indipendenti 46

4 L'APPROCCIO ASSIOMATICO 49
Algebre di eventi 49
Le proprietà delle algebre 50
Gli assiomi di Kolmogorov 51
Le proprietà che seguono dagli assiomi 53
Probabilità condizionata e teorema di Bayes 55
Il teorema di Bayes 56
Perché una probabilità sta fra 0 e 1 57

5 VARIABILI ALEATORIE DISCRETE 59
Dai risultati ai numeri 59
La funzione di probabilità 60
Un'avvertenza sulle notazioni 61
La media 62
La media campionaria 62
Dalla media campionaria alla media statistica 62
Il conteggio bernoulliano: la variabile binomiale 63
La probabilità di una sequenza 63
La pmf binomiale 64
La media della binomiale 65
La variabile uniforme 66
La variabile di Poisson 67
Da dove viene la formula di Poisson 69

6 PMF CONDIZIONATE E FUNZIONI DI VARIABILI ALEATORIE 71
La pmf condizionata a un evento 71
La probabilità totale per le pmf 72
Le medie condizionate 74
Funzioni di variabili aleatorie 75
La media di una funzione di variabile aleatoria 76
Un esempio completo 77
Il quadrato 77
Il seno 77

7 VARIANZA E DISUGUAGLIANZE 79
Misurare la dispersione 79
Valore quadratico medio e varianza 79
La varianza della binomiale 81
La variabile di Bernoulli 81
Il caso generale 81
La varianza dell'uniforme 84
La varianza della Poisson 85
Le proprietà della media e della varianza 86
La disuguaglianza di Markov 88
La disuguaglianza di Chebyshev 89
Il significato della varianza e della deviazione standard 89

8 VARIABILI ALEATORIE MULTIPLE 91
Coppie di variabili aleatorie 91
La pmf congiunta 92
Proprietà della pmf congiunta 92
Le pmf marginali 93
Variabili indipendenti 94
Le pmf condizionate 95
Più di due variabili: la regola della catena 96
Esempio: tre bit da una sorgente binaria 97
La legge p 98

La legge q 98

9 Funzioni di più variabili, covarianza e correlazione 100
Funzioni di una coppia di variabili 100
La media di una funzione di due variabili 101
Il teorema della media condizionata 103
Correlazione e covarianza 104
Il coefficiente di correlazione 106
La varianza di una combinazione lineare 107
Quale coppia è più correlata? 108

II Variabili aleatorie continue, vettori e processi aleatori 109

10 Variabili aleatorie continue: densità e distribuzione 110
Spazi campione continui 110
Perché un singolo valore ha probabilità zero 110
La frequenza di un intervallo 111
La densità di probabilità 112
Dalla densità alla probabilità: l'integrale 112
Le proprietà della densità 114
La funzione di distribuzione cumulativa 115
La CDF delle variabili discrete 117
La media di una variabile continua 118

11 Le variabili aleatorie continue notevoli 120
Due funzioni utili: il gradino e il rettangolo 120
La variabile uniforme 121
La variabile esponenziale 122
La variabile di Laplace 124
La variabile di Cauchy 125
La variabile di Cauchy non ha media 127

12 PDF condizionate e funzioni di variabili continue 130
PDF e CDF condizionate a un evento 130
La probabilità totale per le densità 131
Funzioni di variabili aleatorie continue 133
Primo caso: g è invertibile 133
Secondo caso: g non è invertibile 135
Due trasformazioni speciali 137
Terzo caso: la conversione A/D 139

13 Media di funzioni e varianza nel continuo 141
La media di una funzione di variabile continua 141
Valore quadratico medio e varianza 142
Le varianze delle variabili notevoli 143
La variabile uniforme 143
La variabile esponenziale 143
La variabile di Laplace 144
La variabile di Cauchy 144
Il dizionario fra discreto e continuo 145

14 Variabili aleatorie continue multiple 147
Coppie e m-ple di variabili continue 147
La densità congiunta 147
Marginali, indipendenza e densità condizionate 149
Le densità condizionate 150
Medie, media condizionata e covarianza 151
La funzione di distribuzione congiunta 153

15 La variabile gaussiana e la funzione Q 155
La gaussiana standard 155
La gaussiana generica 157
La funzione Q 158
Le proprietà della funzione Q 159
La regola delle tre sigma 160
Un'applicazione: bit sbagliati per colpa del rumore 161

16 Vettori aleatori e vettori gaussiani 162
Vettori e matrici: il minimo indispensabile 162
Vettori aleatori: medie, correlazioni e covarianze 164
La caratterizzazione sintetica 166
La matrice di covarianza è sempre definita non negativa 166
Vettori gaussiani 167
Si parte da n gaussiane indipendenti 167
La definizione generale 168
Il caso di due variabili 169
Incorrelazione e indipendenza 170
Marginali e condizionate: si completa il quadrato 170
Le proprietà dei vettori gaussiani 171
Trasformazioni lineari di vettori gaussiani 172

17 Processi aleatori 176
Richiami: la caratterizzazione completa 176
La regola della catena per i vettori aleatori 177
Processi aleatori a tempo discreto 178
Caratterizzazione completa e stazionarietà in senso stretto 179
Processi a valori discreti 180
Processi stazionari in senso lato 181
Il vettore dei campioni di un processo SSL 182
Quattro processi a confronto 183

III Statistica inferenziale e misura dell'informazione 187

18 La legge dei grandi numeri e il teorema centrale del limite 188
Dalla probabilità alla statistica 188
La media campione e la legge dei grandi numeri 189
Le frequenze tendono alle probabilità 190
Modi diversi di convergere 191
Il teorema centrale del limite 192

19 Decisioni bayesiane e classificazione binaria 196
Regole di decisione e rischio bayesiano 196
La classificazione binaria a minima probabilità di errore 198
Esempio: da quale sorgente vengono i bit? 199
Dati continui 200
Esempio: la media di una popolazione gaussiana 201

20 Test di ipotesi: il test di Neyman-Pearson 204
Ipotesi nulla, falsi allarmi e mancate rivelazioni 204
Il test di Neyman-Pearson 205
Esempio: test sulla media di una popolazione gaussiana 206

21 Stima bayesiana: MMSE e MAP 210
Il problema della stima 210
Costo quadratico: lo stimatore MMSE 211
Costo «tutto o niente»: lo stimatore MAP 212
Esempio: la moneta misteriosa 213

Le prestazioni dei due stimatori 215

22 Stima classica e limite di Cramér-Rao 217
La verosimiglianza e lo stimatore a massima verosimiglianza 217
Le qualità di uno stimatore 218
Il limite di Cramér-Rao 219
Esempi 222

23 Stima lineare MMSE e gradiente 223
Il gradiente 223
Lo stimatore lineare MMSE 224
L'algoritmo del gradiente 226

24 Minimi quadrati e stima ricorsiva 229
Il modello lineare e la stima ai minimi quadrati 229
Un dato in più: la stima ricorsiva 231

25 Informazione ed entropia 235
Un esempio: comprimere una sorgente quaternaria 235
L'informazione di un evento 236
L'entropia 237
La disuguaglianza di Jensen 238
L'entropia non supera il logaritmo dell'alfabeto 239

26 La codifica di sorgente 241
Sorgenti e codici 241
La disuguaglianza di Kraft 242
Il codice di Shannon e il limite entropico 243
I codici di Huffman 245

Prefazione

Estratto

Il seguente documento rappresenta una raccolta di appunti, riorganizzata e migliorata nelle vesti grafiche, del corso di Metodi Statistici per l'Informazione del professor Mario Tanda, per il corso di laurea in Informatica A.A. 2026-2027, della Federico II di Napoli.

Il corso fornisce gli strumenti della teoria della probabilità e della statistica che servono a descrivere, elaborare e misurare l'informazione: dal calcolo combinatorio alle variabili aleatorie, discrete e continue, e ai processi aleatori; dall'inferenza statistica alla teoria della decisione e della stima; fino alla misura dell'informazione, con l'entropia e la compressione dei dati.

Si tiene a specificare che questo documento non ha lo scopo di **sostituire libri di testo**, note del professore o lezioni frontali, nonostante siano tutte fonti utilizzate per la stesura, ma quello di integrare al materiale più complesso una rilettura degli argomenti da un punto di vista meno tecnico e quindi più lento nel soffermarsi nei passaggi critici.

Si ringraziano **Valentino Bocchetti** e **Pasquale Miranda** ideatori e gestori del progetto *Unina Docs*,

Si ringraziano inoltre tutti i revisori che hanno contribuito al documento con consigli e proposte di modifica, invitando a dare feedback in caso di errori.

Si ringraziano in fine i lettori nella speranza che questo lavoro sia stato utile.

Redazione a cura di **Fabio Rosiello**

Organizzazione del corso

Il corso vale 6 CFU (48 ore di lezione), tutte in presenza: circa tre quarti di teoria e un quarto di esercitazioni. L'esame è una prova scritta integrata da una prova orale. Gli argomenti si dividono in tre blocchi:

- **Teoria della probabilità**: analisi combinatoria, probabilità su spazi finiti, variabili aleatorie discrete, variabili aleatorie continue, variabili aleatorie multiple, processi aleatori.
- **Statistica**: statistica inferenziale, teoria della decisione, inferenza bayesiana e non bayesiana, stima ricorsiva.
- **Informazione e sua misura** (cenni): entropia, compressione dei dati, mutua informazione, divergenza.

Il testo di riferimento, da affiancare alle lezioni, è Sheldon M. Ross, *Probabilità e statistica per l'ingegneria e le scienze*, Maggioli Editore, IV edizione.

Come è fatta questa dispensa

Questa dispensa segue le slide del corso, una lezione dopo l'altra: ogni parte corrisponde a un pacchetto di slide. La prima, *Probabilità e variabili aleatorie discrete*, copre il primo; la seconda, *Variabili aleatorie continue, vettori e processi aleatori*, copre il secondo, fino ai vettori gaussiani e ai processi stazionari; la terza, *Statistica inferenziale e misura dell'informazione*, copre il terzo: legge dei grandi numeri e teorema centrale del limite, decisioni e test di ipotesi, stima bayesiana e classica, minimi quadrati, entropia e codifica di sorgente. L'obiettivo è che ogni formula si possa **capire**, non solo ricordare: per questo ogni risultato è accompagnato dal suo perché, da un disegno quando aiuta, e da una dimostrazione scritta passo per passo quando la dimostrazione esiste. Gli strumenti di matematica che servono (insiemi, sommatorie, limiti, derivate, serie e, nella seconda e nella terza parte, integrali, integrali doppi, derivate parziali, vettori e matrici, gradienti, autovalori, funzioni convesse) sono spiegati da zero, nel punto esatto in cui servono, dentro i riquadri viola dei **richiami di matematica**: chi li conosce già li può saltare, chi non li ricorda li trova lì, senza dover aprire un altro libro.

I simboli che incontreremo

La matematica usa molti simboli: sono abbreviazioni, e ognuno si legge con parole semplici. Queste tabelle li raccolgono tutti, divisi per parte; il capitolo indicato è quello in cui il simbolo viene spiegato con calma.

Simbolo	Si legge	Significato	Cap.
$x \in A$, $x \notin A$	x appartiene (non appartiene) ad A	x è (non è) un elemento dell'insieme A	1
$A \subseteq B$	A è contenuto in B	ogni elemento di A sta anche in B	1
$\varnothing$, $\lvert A\rvert$	insieme vuoto, cardinalità di A	l'insieme senza elementi; il numero di elementi di A	1
$A \cup B$, $A \cap B$	A unione B, A intersezione B	si verifica almeno uno dei due; si verificano entrambi	1
$\overline{A}$, $A \setminus B$	complementare di A, A meno B	non si verifica A; si verifica A ma non B	1
$A \times B$	A per B (prodotto cartesiano)	l'insieme delle coppie ordinate (a, b)	1
$\sum_{i=1}^{n}$, $\prod_{i=1}^{n}$	sommatoria, produttoria per i da 1 a n	somma, prodotto di n termini	2
$n!$, $\binom{n}{k}$	n fattoriale, n su k	$1 \cdot 2 \cdots n$; i sottoinsiemi di k elementi fra n	2
$\simeq$	circa uguale	i due numeri sono vicini	2
$a_n \to L$, $\lim_{n\to\infty}$	a_n tende a L, limite per n che tende a infinito	i termini si avvicinano a L quanto si vuole	3
$P(A)$, $P(A \mid B)$	probabilità di A, di A dato B	quanto è facile che si verifichi A (sapendo che si è verificato B)	3
$\Longrightarrow$, $\Longleftrightarrow$	implica, se e solo se	dalla prima affermazione segue la seconda; le due sono equivalenti	1
$\forall$	per ogni	la frase vale per tutti gli elementi indicati	4
$X \sim \ldots$	X si distribuisce come…	X ha la legge indicata a destra, per esempio $\mathcal{B}(N, p)$	5
$f'(x)$, $\mathrm{d}f/\mathrm{d}x$	derivata di f	la pendenza del grafico di f nel punto x	7

Tabella 1: *I simboli della prima parte.*

Simbolo	Si legge	Significato	Cap.
$\int_a^b f(x)\,\mathrm{d}x$	integrale di f da a a b	l'area sotto il grafico di f fra a e b	10
$f_X(x)$, $F_X(x)$	densità, CDF di X	probabilità per unità di lunghezza; $P(X \leq x)$	10
$u(x)$, $\mathrm{rect}(x)$	gradino, rettangolo	1 per $x \geq 0$ (0 altrove); 1 per $\lvert x\rvert < \frac{1}{2}$ (0 altrove)	11
$\iint_C f\,\mathrm{d}x\,\mathrm{d}y$	integrale doppio di f su C	il volume sotto la superficie f, sopra la regione C	14
$\partial F/\partial x$	derivata parziale rispetto a x	la derivata fatta tenendo fisse le altre variabili	14
$\mathcal{N}(\mu,\sigma^2)$, $Q(x)$	gaussiana, funzione Q	la campana di media μ e varianza σ^2; la sua coda $P(X_0 > x)$	15
$\underline{x}$, $\underline{\underline{A}}$	vettore x, matrice A	una colonna di numeri; una tabella di numeri	16
$\underline{\underline{A}}^T$, $\underline{\underline{A}}^{-1}$, $\det \underline{\underline{A}}$	trasposta, inversa, determinante	righe e colonne scambiate; la matrice che disfa $\underline{\underline{A}}$; il fattore per cui $\underline{\underline{A}}$ moltiplica le aree	16
$X(n)$	X di n	un processo aleatorio: un valore aleatorio per ogni istante n	17

Tabella 2: *I simboli della seconda parte.*

Simbolo	Si legge	Significato	Cap.
$\overline{X}_n$	media campione	la media dei dati $X_1, \ldots, X_n$	18
i.i.d.	indipendenti e identicamente distribuite	dati che sono prove ripetute dello stesso esperimento	18
$\Phi(x)$	fi di x	la CDF della gaussiana standard, $1 - Q(x)$	18
$\overset{H_1}{\gtrless}_{H_2}$	maggiore: H_1; minore: H_2	se vale > si decide H_1, se vale < si decide H_2	19
$L(\underline{x})$	rapporto di verosimiglianza	quanto i dati sono più probabili sotto un'ipotesi che sotto l'altra	19
$\lfloor a \rfloor$, $\lceil a \rceil$	parte intera inferiore, superiore	a arrotondato per difetto, per eccesso all'intero	19, 26
α, β	falso allarme, mancata rivelazione	le probabilità di errore di prima e di seconda specie; $1 - \beta$ è la potenza	20
$Q^{-1}(\alpha)$	Q inversa di alfa	il numero x per cui $Q(x) = \alpha$	20
$\hat{\theta}$, $\hat{\Theta}$	theta stimato	una stima; uno stimatore	21
$\arg\min$, $\arg\max$	argomento del minimo, del massimo	il punto in cui una funzione è minima, massima	21
$\Gamma(x)$	gamma di x	il fattoriale esteso: $\Gamma(n+1) = n!$	21
$b_n(\theta)$, $I_n(\theta)$	polarizzazione, informazione di Fisher	l'errore medio di uno stimatore; quanto i dati dicono sul parametro	22
$\nabla_{\underline{w}}\, g$	gradiente di g	il vettore delle derivate parziali	23
$\lVert \underline{v} \rVert$	norma di $\underline{v}$	la lunghezza del vettore, $\sqrt{\underline{v}^T \underline{v}}$	24
$i(A)$, $H(X)$	informazione, entropia	$\log \frac{1}{P(A)}$; l'informazione media di X	25

Tabella 3: *I simboli della terza parte.*

Convenzioni tipografiche

Nel testo si usano alcuni riquadri ricorrenti, ognuno con un colore e un compito precisi.

Definizione

I riquadri rossi contengono le **definizioni**: il significato esatto di una parola nuova. Sono da saper ripetere con precisione.

Teorema 0.1 — Teorema

I riquadri blu contengono i **teoremi**: affermazioni che si possono dimostrare a partire dalle definizioni. Sono numerati capitolo per capitolo (Teorema 3.2 è il secondo teorema del capitolo 3), così si possono citare.

Dimostrazione

Passo 1 — Che cosa contiene. Sotto un teorema, quando la dimostrazione esiste, c'è questo riquadro grigio: la dimostrazione scritta **un passaggio alla volta**, ciascuno con il suo motivo.

Passo 2 — Come finisce. Il quadratino nero in fondo a destra vuol dire «come volevasi dimostrare»: da lì in poi il teorema si può usare senza dubbi.

■

Richiamo di matematica: il titolo dice di che cosa

I riquadri viola spiegano **da zero** gli strumenti di matematica che servono in quel punto: che cos'è un limite, una derivata, un integrale, una sommatoria. Sono scritti per chi non li ha mai visti o li ha dimenticati.

Da ricordare: nome della formula

le formule da tenere a mente, in evidenza

Nota

I riquadri verdi contengono **intuizioni**, analogie e osservazioni che aiutano a capire, ma non sono indispensabili.

Attenzione

I riquadri gialli segnalano gli **errori tipici** e i punti in cui è facile confondersi.

Esempio 0.1 — Struttura di un esempio

Gli esempi sono racchiusi fra due righe sottili e numerati all'interno di ogni capitolo.

Esercizio 0.1 — Struttura di un esercizio

Gli esercizi sono racchiusi fra righe doppie.

Svolgimento

Lo svolgimento viene subito dopo il testo: conviene provarci da soli prima di leggerlo.

Parte I

Probabilità e variabili aleatorie discrete

Esperimenti, eventi e insiemi

Chi lavora con l'informazione lavora con l'incertezza. Un bit trasmesso su un canale rumoroso può arrivare sbagliato, un pacchetto può trovare la coda del router piena, una misura è sempre sporcata da un po' di rumore. Non sappiamo **che cosa** succederà, ma possiamo dire **quanto è facile** che succeda: è il mestiere della **teoria della probabilità**.

Prima di calcolare una qualsiasi probabilità serve però un linguaggio preciso per dire *che cosa può succedere*. Questo capitolo lo costruisce, e lo costruisce con uno strumento che probabilmente si conosce già: gli **insiemi**. Alla fine del capitolo «si verificano A e B» diventerà $A \cap B$, «non si verifica A» diventerà $\overline{A}$, e potremo fare i conti sugli eventi con la stessa sicurezza con cui si fanno sui numeri.

Esperimenti aleatori e spazio campione

Tutto comincia da un esperimento il cui esito non si può prevedere.

Esperimento aleatorio

Un **esperimento aleatorio** è un'operazione, o un insieme di operazioni, il cui esito è **uno fra tanti risultati possibili**, nessuno dei quali si può prevedere con certezza prima di eseguirla.

La parola viene dal latino *alea*, «dado» (è l'*alea* di «*alea iacta est*», il dado è tratto): lanciare un dado è l'esperimento aleatorio per eccellenza. Ma sono esperimenti aleatori anche lanciare una moneta, estrarre una carta da un mazzo, contare i pacchetti in coda in un router in un certo istante, misurare il rumore su un cavo. La prima cosa da fare, davanti a un esperimento, è elencare **tutto** quello che può succedere.

Spazio campione

Lo **spazio campione** (o spazio dei campioni) Ω è l'insieme di **tutti i risultati possibili** di un esperimento aleatorio. Non deve essere per forza un insieme di numeri: per una moneta è $\{\text{Testa}, \text{Croce}\}$.

Ω è la lettera greca *omega* maiuscola; la minuscola ω indica invece **un singolo risultato**, cioè un elemento di Ω. Visto che tutto il discorso si regge sugli insiemi, conviene rinfrescare subito le parole di base.

Richiamo di matematica: gli insiemi, le parole di base

Un **insieme** è una collezione di oggetti, detti **elementi**. Lo si può descrivere in due modi:

- **elencando** gli elementi fra parentesi graffe: $A = \{1, 3, 5\}$;
- dando una **proprietà** che li caratterizza: $A = \{x \in \mathbb{N} : x \text{ è dispari e } x < 6\}$, che si legge «l'insieme degli x naturali *tali che* x è dispari e minore di 6». I due punti si leggono «tali che».

I simboli che useremo continuamente sono questi.

Simbolo	Si legge	Significato ed esempio
$x \in A$	x appartiene ad A	x è uno degli elementi di A: $3 \in \{1,3,5\}$
$x \notin A$	x non appartiene ad A	$2 \notin \{1,3,5\}$
$A \subseteq B$	A è contenuto in B	ogni elemento di A è anche in B: $\{1,3\} \subseteq \{1,2,3\}$
$\varnothing$	insieme vuoto	l'insieme che non ha nessun elemento
$\lvert A \rvert$	cardinalità di A	il numero di elementi di A: $\lvert\{1,3,5\}\rvert = 3$

In un insieme **conta solo chi c'è**: non conta l'ordine in cui gli elementi sono scritti e non conta se un elemento è scritto due volte. Quindi $\{1,2\} = \{2,1\} = \{1,1,2\}$: sono tutti lo stesso insieme, con due elementi. Due insiemi sono **uguali** quando hanno esattamente gli stessi elementi.
L'insieme vuoto è contenuto in qualsiasi insieme ($\varnothing \subseteq A$): non ha elementi, quindi non ne ha nessuno che manchi in A. Anche $A \subseteq A$ è sempre vero.

Spazi discreti e spazi continui

Lo spazio campione può essere di due tipi molto diversi.

- È **discreto** se i suoi elementi si possono **mettere in fila e contare** uno dopo l'altro: il primo, il secondo, il terzo… Questo accade se è **finito** (come le sei facce di un dado) oppure se è **infinito numerabile** (come i numeri naturali $0, 1, 2, 3, \ldots$: la fila non finisce mai, ma ogni elemento ha la sua posizione nella fila).
- È **continuo** se i suoi elementi sono «troppi» per essere messi in fila, come i punti di un segmento: il tempo, in secondi, che un pacchetto impiega ad arrivare può essere 0,1, 0,11, 0,101… e fra due valori qualsiasi ce ne sono sempre infiniti altri.

Richiamo di matematica: finito, numerabile, non numerabile

Un insieme è **finito** se i suoi elementi si contano e il conteggio finisce: $|A|$ è un numero naturale.
Un insieme infinito è **numerabile** se si può fare un **elenco** che contenga tutti i suoi elementi, ognuno in una posizione precisa. I naturali $\mathbb{N}_0 = \{0, 1, 2, \ldots\}$ sono numerabili per definizione. Lo sono anche i numeri pari $(0, 2, 4, \ldots)$ e persino gli interi relativi $\mathbb{Z}$, se li si elenca così:

$$0,\ 1,\ -1,\ 2,\ -2,\ 3,\ -3,\ \ldots$$

In questo elenco ogni intero compare prima o poi: il numero -5, per esempio, è all'undicesimo posto.
Invece i numeri reali di un intervallo, come $[0, 1]$, **non** sono numerabili: si può dimostrare (è un celebre risultato di Georg Cantor) che qualunque elenco si provi a scrivere ne lascia fuori qualcuno.

Per tutta la prima parte del corso, fino alle variabili aleatorie continue, lo spazio campione sarà **discreto**: finito oppure numerabile.

Eventi

Spesso non interessa il risultato preciso, ma una sua caratteristica: «è uscito un numero pari», «ci sono meno di sei pacchetti in coda». Ognuna di queste frasi individua un gruppo di risultati, cioè un sottoinsieme di Ω.

Evento

Un **evento** è un sottoinsieme di Ω, definito con una formula matematica oppure a parole. Si dice che l'evento A **si verifica** quando il risultato ω dell'esperimento appartiene ad A.

Evento elementare

Un **evento elementare** è uno dei $|\Omega|$ risultati possibili, cioè un singolo elemento $\omega \in \Omega$ (o, se si preferisce vederlo come insieme, il sottoinsieme $\{\omega\}$ che contiene solo lui).

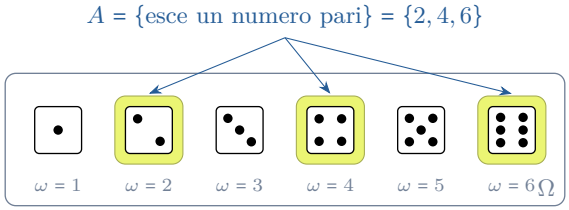


Figura 1.1: *Lo spazio campione del lancio di un dado ha sei eventi elementari; l'evento «esce un numero pari» è il sottoinsieme formato dai tre risultati evidenziati.*

Una cosa da tenere a mente fin da subito: un evento è determinato **solo dagli elementi che contiene**, mentre la frase che lo descrive non è unica. Sul dado, «esce un numero pari», «esce un multiplo di 2» e «non esce un numero dispari» sono tre frasi diverse per **lo stesso** evento $\{2, 4, 6\}$.

Quattro esperimenti da tenere a mente

Gli esempi che seguono torneranno per tutto il corso: conviene guardarli bene.

Il lancio di una moneta

Con un **solo lancio** i risultati possibili sono due:

$$\Omega = \{\text{Testa}, \text{Croce}\} = \{T, C\}, \qquad |\Omega| = 2.$$

Eventi possibili sono $A = \{T\}$ («esce testa»), $B = \{C\}$ («esce croce») e «esce testa o croce», che è $\{T, C\} = \Omega$: un evento che si verifica sempre.

Se la moneta si lancia **due volte**, un risultato è la coppia formata dall'esito del primo lancio e da quello del secondo:

$$\Omega = \{TT, TC, CT, CC\} = \{T, C\} \times \{T, C\} = \{T, C\}^2, \qquad |\Omega| = 4.$$

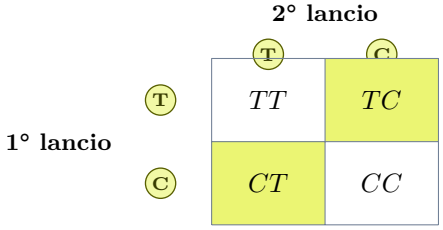
Il simbolo $\times$ fra due insiemi è il **prodotto cartesiano**, e merita un richiamo.

Richiamo di matematica: il prodotto cartesiano

Il **prodotto cartesiano** $A \times B$ è l'insieme di tutte le **coppie ordinate** (a, b) con il primo elemento preso da A e il secondo da B:

$$A \times B = \{(a, b) : a \in A,\ b \in B\}.$$

«Ordinate» vuol dire che **conta l'ordine**: (T, C) e (C, T) sono due coppie diverse. Questa è la grande differenza con gli insiemi, dove $\{T, C\} = \{C, T\}$. Quando un insieme si moltiplica per sé stesso si scrive una potenza: $A \times A = A^2$, $A \times A \times A = A^3$ (le terne ordinate), e così via.
Il nome viene da Cartesio: le coppie ordinate di numeri reali, $\mathbb{R} \times \mathbb{R} = \mathbb{R}^2$, sono proprio i punti del piano cartesiano, e $(2, 3)$ non è lo stesso punto di $(3, 2)$.



Le caselle gialle sono l'evento A = {numero dispari di croci} = $\{TC, CT\}$. L'evento B = {nessuna croce} è la sola casella TT.

Figura 1.2: *I quattro risultati del lancio doppio: righe per il primo lancio, colonne per il secondo.*

Perché TC e CT sono risultati diversi

Lo si capisce immaginando di lanciare due monete diverse, una da un euro e una da due euro: «testa sulla moneta da uno e croce su quella da due» è chiaramente un'altra cosa rispetto a «croce sulla moneta da uno e testa su quella da due». Lanciare due volte la stessa moneta è la stessa situazione, con il primo e il secondo lancio al posto delle due monete. Contare TC e CT come un unico risultato sarebbe un errore, e nel Capitolo 3 vedremo che porta a probabilità sbagliate.

Il lancio di un dado

Lanciando un dado una volta:

$$\Omega = \{1, 2, 3, 4, 5, 6\}, \qquad |\Omega| = 6.$$

Ecco alcuni eventi, prima a parole e poi come insiemi:

- A = «il risultato è dispari» = $\{1, 3, 5\}$;
- B = «il risultato è pari» = $\{2, 4, 6\}$;
- C = «il risultato è dispari e non supera 4» = $\{1, 3\}$;
- D = «il risultato è 6» = $\{6\}$, un evento elementare.

I pacchetti in coda a un router

Un router riceve pacchetti e li inoltra uno alla volta; quelli che arrivano mentre è occupato aspettano in una **coda**. L'esperimento consiste nel guardare la coda in un certo istante e contare quanti pacchetti ci sono.



Figura 1.3: *Il numero di pacchetti in coda in un istante è il risultato di un esperimento aleatorio.*

I valori possibili sono $0, 1, 2, \ldots$ e non c'è un massimo che si possa fissare a priori (o, se c'è, è così grande che conviene ignorarlo). Lo spazio campione è allora l'insieme dei numeri naturali:

$$\Omega = \{0, 1, 2, 3, 4, 5, 6, \ldots\} = \mathbb{N}_0, \qquad |\Omega| = \infty.$$

È uno spazio **infinito ma numerabile**, quindi discreto. Alcuni eventi:

- A = «in coda ci sono meno di 6 pacchetti» = $\{0, 1, 2, 3, 4, 5\}$;
- B = «il numero di pacchetti è dispari» = $\{1, 3, 5, \ldots, 2k + 1, \ldots\}$;
- C = «il numero di pacchetti è dispari e non supera 6» = $\{1, 3, 5\}$: sono i numeri che stanno sia in A sia in B, cioè (lo vedremo fra un attimo) $C = A \cap B$;
- D = «il numero di pacchetti è pari oppure non supera 4» = $\{0, 1, 2, 3, 4, 6, 8, 10, \ldots, 2k, \ldots\}$.

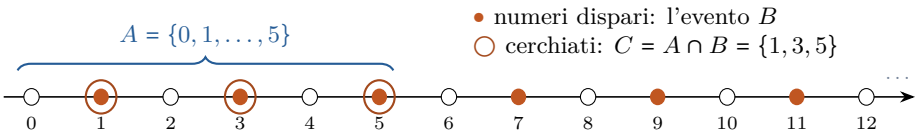


Figura 1.4: *Gli eventi del router sulla retta dei numeri naturali.*

Operazioni fra eventi

Gli eventi sono insiemi, quindi si combinano con le operazioni degli insiemi. Ognuna ha un significato preciso a parole, ed è il significato che conta. Nelle definizioni A e B sono due sottoinsiemi di Ω (più in generale $\{A_i\}_{i=1}^{M}$ indica M sottoinsiemi $A_1, A_2, \ldots, A_M$ di Ω).

Unione

L'**unione** $A \cup B$ è l'insieme degli elementi che stanno in A **oppure** in B (o in entrambi: gli elementi comuni si prendono una volta sola). L'evento $A \cup B$ si verifica quando si verifica **almeno uno** fra A e B.

Intersezione

L'**intersezione** $A \cap B$ è l'insieme di tutti e soli gli elementi comuni ad A **e** a B. L'evento $A \cap B$ si verifica quando si verificano **entrambi**.

Complementare

Il **complementare** di A (in Ω) è l'insieme $\overline{A}$ degli elementi di Ω che **non** appartengono ad A. L'evento $\overline{A}$ si verifica quando A **non** si verifica.

Differenza

La **differenza** $A \setminus B$ («A meno B») è l'insieme degli elementi di A che non appartengono a B: da A si tolgono gli elementi in comune con B. L'evento $A \setminus B$ si verifica quando si verifica A **ma non** B.



$A \cup B$ almeno uno dei due — $A \cap B$ tutti e due — $\overline{A}$ non A — $A \setminus B$ A ma non B

Figura 1.5: *Le quattro operazioni con i **diagrammi di Venn**: il rettangolo è Ω, i cerchi sono gli eventi, la parte gialla è il risultato.*

Dalla definizione di complementare seguono alcune proprietà che si usano di continuo:

$$\overline{\Omega} = \varnothing, \qquad \overline{\varnothing} = \Omega, \qquad \overline{\overline{A}} = A, \qquad A \cup \overline{A} = \Omega, \qquad A \cap \overline{A} = \varnothing.$$

Ognuna si legge facilmente a parole: fuori da Ω non c'è niente; ciò che non sta nel «non A» sta in A; ogni elemento sta in A oppure fuori da A, e non può stare in entrambi.

Esempio 1.1 — Una differenza

Siano $A_1 = \{1, 2, 3, 4, 5, 6, 7, 8\}$ e $A_2 = \{1, 4, 6\}$, dentro lo spazio $\Omega = \mathbb{N}$. Il complementare di A_2 è l'insieme di tutti i naturali diversi da 1, 4 e 6. Togliendo da A_1 gli elementi che ha in comune con A_2 resta

$$A_1 \setminus A_2 = \{2, 3, 5, 7, 8\}.$$

Si noti che è anche l'insieme degli elementi di A_1 che stanno nel complementare di A_2: è $A_1 \cap \overline{A_2}$. Non è un caso, come mostra la proprietà seguente.

Teorema 1.1 — La differenza come intersezione

Per due eventi qualsiasi A e B vale

$$A \setminus B = A \cap \overline{B}.$$

Dimostrazione

Passo 1 — Che cosa significa «uguali». Due insiemi sono uguali se hanno gli stessi elementi. Basta quindi mostrare che un elemento qualsiasi x sta nel primo insieme se e solo se sta nel secondo.

Passo 2 — Si traduce la definizione. $x \in A \setminus B$ vuol dire, per definizione di differenza: $x \in A$ e $x \notin B$.

Passo 3 — Si riconosce il complementare. «$x \notin B$» è proprio la definizione di $x \in \overline{B}$. Quindi la frase diventa: $x \in A$ e $x \in \overline{B}$.

Passo 4 — Si riconosce l'intersezione. «x sta in A e in $\overline{B}$» è la definizione di $x \in A \cap \overline{B}$. Tutti i passaggi si possono percorrere anche all'indietro, quindi i due insiemi hanno gli stessi elementi.

■

LE LEGGI DELL'ALGEBRA DEGLI EVENTI

Con i numeri sappiamo che $a \cdot (b + c) = a \cdot b + a \cdot c$ e che $(a + b) + c = a + (b + c)$. Anche le operazioni sugli eventi obbediscono a delle leggi, e queste leggi permettono di trasformare un evento complicato in uno più semplice da calcolare. Per dimostrarle useremo sempre la stessa tecnica, quella appena vista: tradurre ogni operazione nelle parole «e», «o», «non».

Richiamo di matematica: «e», «o», «non» e come si dimostra che due insiemi sono uguali

Le operazioni sugli insiemi corrispondono esattamente ai connettivi della logica:

Insiemi	Logica	Vale quando...
$x \in A \cap B$	$x \in A$ **e** $x \in B$	sono vere tutte e due le affermazioni
$x \in A \cup B$	$x \in A$ **o** $x \in B$	è vera almeno una delle due
$x \in \overline{A}$	**non** $x \in A$	l'affermazione $x \in A$ è falsa

La «o» della matematica è **inclusiva**: «P o Q» è vera anche quando sono vere tutte e due (come nell'unione, che contiene anche gli elementi comuni). Non è la «o» esclusiva di «o mangi la minestra o salti dalla finestra».
Per dimostrare che due insiemi X e Y sono uguali si mostra che, per un elemento x qualsiasi,

$$x \in X \iff x \in Y,$$

dove il simbolo $\iff$ si legge «se e solo se» e significa che le due affermazioni sono o entrambe vere o entrambe false. In pratica si scrive una **catena** di affermazioni equivalenti che parte da $x \in X$ e arriva a $x \in Y$, giustificando ogni anello.

Le leggi di De Morgan

Teorema 1.2 — Leggi di De Morgan

Per due eventi qualsiasi A_1 e A_2:

$$\overline{A_1 \cup A_2} = \overline{A_1} \cap \overline{A_2} \qquad \overline{A_1 \cap A_2} = \overline{A_1} \cup \overline{A_2}.$$

Il complementare di un'unione è l'intersezione dei complementari, e il complementare di un'intersezione è l'unione dei complementari.

A parole la prima legge dice una cosa ovvia: «non (piove o nevica)» è la stessa cosa di «non piove e non nevica», cioè «né piove né nevica». La seconda: «non (sono stanco e ho fame)» vuol dire che almeno una delle due cose manca, cioè «non sono stanco o non ho fame».

Dimostrazione

Passo 1 — Prima legge, si parte dal primo membro. Sia x un elemento qualsiasi di Ω:

$$x \in \overline{A_1 \cup A_2} \iff x \notin A_1 \cup A_2$$

per definizione di complementare.

Passo 2 — Si nega la «o». x non sta nell'unione quando non è vero che sta in almeno uno dei due insiemi, cioè quando **non sta in nessuno** dei due:

$$x \notin A_1 \cup A_2 \iff x \notin A_1 \text{ e } x \notin A_2.$$

Passo 3 — Si arriva al secondo membro. Per definizione di complementare e poi di intersezione:

$$x \notin A_1 \text{ e } x \notin A_2 \iff x \in \overline{A_1} \text{ e } x \in \overline{A_2} \iff x \in \overline{A_1} \cap \overline{A_2}.$$

La catena è fatta di equivalenze, quindi i due insiemi coincidono.

Passo 4 — La seconda legge si ricava dalla prima. La prima legge vale per due eventi qualsiasi, quindi anche per i due eventi $\overline{A_1}$ e $\overline{A_2}$:

$$\overline{\overline{A_1} \cup \overline{A_2}} = \overline{\overline{A_1}} \cap \overline{\overline{A_2}} = A_1 \cap A_2,$$

perché il complementare del complementare è l'insieme di partenza.

Passo 5 — Si fa il complementare di entrambi i membri. Due insiemi uguali hanno complementari uguali:

$$\overline{\overline{\overline{A_1} \cup \overline{A_2}}} = \overline{A_1 \cap A_2} \quad \Longrightarrow \quad \overline{A_1} \cup \overline{A_2} = \overline{A_1 \cap A_2},$$

che è la seconda legge.

■



$\overline{A}$ | $\overline{B}$ | $\overline{A} \cap \overline{B}$ (giallo in entrambe) | $\overline{A \cup B}$ (fuori dall'unione)

Figura 1.6: *La prima legge di De Morgan vista con i diagrammi: la parte gialla in comune ai primi due disegni è proprio ciò che resta fuori dall'unione.*

Le proprietà associativa e distributiva

Teorema 1.3 — Proprietà associativa

Per tre eventi qualsiasi A_1, A_2, A_3:

$$(A_1 \cup A_2) \cup A_3 = A_1 \cup (A_2 \cup A_3) \qquad (A_1 \cap A_2) \cap A_3 = A_1 \cap (A_2 \cap A_3).$$

Dimostrazione

Passo 1 — Unione. Un elemento sta in $(A_1 \cup A_2) \cup A_3$ se sta in $A_1 \cup A_2$ oppure in A_3, cioè se sta in **almeno uno** dei tre insiemi. Lo stesso ragionamento, fatto sul secondo membro, porta alla stessa frase.

Passo 2 — Intersezione. Un elemento sta in $(A_1 \cap A_2) \cap A_3$ se sta in $A_1 \cap A_2$ e in A_3, cioè se sta in **tutti e tre** gli insiemi; e di nuovo il secondo membro dice lo stesso.

■

Grazie a questa proprietà le parentesi non servono più: si scrive semplicemente $A_1 \cup A_2 \cup A_3$ («almeno uno dei tre») e $A_1 \cap A_2 \cap A_3$ («tutti e tre»). Per molti insiemi si usa una notazione compatta, la stessa idea della sommatoria che vedremo nel prossimo capitolo.

Richiamo di matematica: unione e intersezione di molti insiemi

Dati M insiemi $A_1, A_2, \ldots, A_M$ si scrive

$$\bigcup_{i=1}^{M} A_i = A_1 \cup A_2 \cup \cdots \cup A_M, \qquad \bigcap_{i=1}^{M} A_i = A_1 \cap A_2 \cap \cdots \cap A_M.$$

Si legge «unione (intersezione) per i che va da 1 a M degli A_i». La lettera i è un **indice**: prende uno dopo l'altro i valori $1, 2, \ldots, M$, e per ciascuno si prende l'insieme A_i. Il primo insieme contiene gli elementi che stanno in **almeno uno** degli A_i; il secondo quelli che stanno in **tutti**. L'indice può partire da un altro numero: $\bigcap_{i=2}^{M} A_i = A_2 \cap A_3 \cap \cdots \cap A_M$.

Teorema 1.4 — Proprietà distributive

Per eventi qualsiasi $A_1, A_2, \ldots, A_M$ valgono la distributiva dell'unione rispetto all'intersezione e quella dell'intersezione rispetto all'unione:

$$A_1 \cup \left(\bigcap_{i=2}^{M} A_i \right) = \bigcap_{i=2}^{M} (A_1 \cup A_i) \qquad A_1 \cap \left(\bigcup_{i=2}^{M} A_i \right) = \bigcup_{i=2}^{M} (A_1 \cap A_i)\,.$$

Con tre soli eventi A, B, C si leggono meglio:

$$A \cup (B \cap C) = (A \cup B) \cap (A \cup C) \qquad A \cap (B \cup C) = (A \cap B) \cup (A \cap C).$$

Dimostrazione

Passo 1 — Seconda legge, primo membro. $x \in A_1 \cap \left(\bigcup_{i=2}^{M} A_i \right)$ vuol dire che $x \in A_1$ **e** che x sta in almeno uno fra $A_2, \ldots, A_M$: diciamo in A_k.

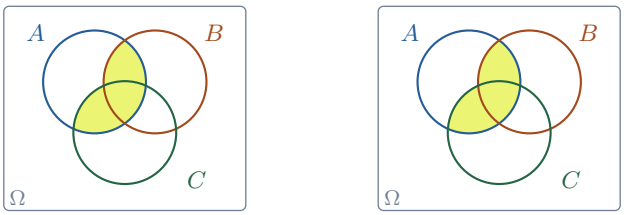
Passo 2 — Seconda legge, secondo membro. Allora x sta sia in A_1 sia in A_k, cioè in $A_1 \cap A_k$: sta in almeno una delle intersezioni $A_1 \cap A_i$, quindi nella loro unione. Viceversa, se x sta in una delle $A_1 \cap A_k$, sta in A_1 e in A_k, quindi in A_1 e nell'unione degli A_i. I due insiemi coincidono.

Passo 3 — Prima legge, primo membro. $x \in A_1 \cup \left(\bigcap_{i=2}^{M} A_i \right)$ vuol dire che $x \in A_1$ **oppure** che x sta in tutti gli $A_2, \ldots, A_M$.

Passo 4 — Prima legge, secondo membro. Se $x \in A_1$, allora x sta in ogni $A_1 \cup A_i$ (che contiene A_1); se invece x sta in tutti gli A_i, sta di nuovo in ogni $A_1 \cup A_i$. In entrambi i casi x sta nell'intersezione di tutti gli $A_1 \cup A_i$.

Passo 5 — Prima legge, il viceversa. Sia ora x in tutti gli $A_1 \cup A_i$. Se $x \in A_1$ abbiamo finito. Se $x \notin A_1$, allora da $x \in A_1 \cup A_i$ segue che $x \in A_i$, e questo per ogni i da 2 a M: x sta nell'intersezione degli A_i. Anche qui i due insiemi coincidono.

■



$A \cap (B \cup C)$ $\qquad$ $(A \cap B) \cup (A \cap C)$

Figura 1.7: *La seconda proprietà distributiva: in entrambi i casi si colora la parte di A che sta anche in B o in C.*

Insiemi e numeri: somiglianze e differenze

Se si sostituisce l'unione con la somma e l'intersezione con il prodotto, la seconda legge distributiva diventa quella che si usa da sempre con i numeri: $a \cdot (b + c) = a \cdot b + a \cdot c$. La **prima** invece diventerebbe $a + b \cdot c = (a + b) \cdot (a + c)$, che con i numeri è **falsa**: con $a = 1$, $b = 2$, $c = 3$ il primo membro vale $1 + 6 = 7$ e il secondo $3 \cdot 4 = 12$. Con gli insiemi l'unione e l'intersezione sono perfettamente simmetriche, e ogni legge vale anche scambiando i due simboli.

UN PO' DI NOMENCLATURA

Alcuni eventi e alcune relazioni fra eventi hanno un nome proprio.

Evento certo, evento impossibile

Ω è detto **evento certo**: contiene tutti i risultati, quindi si verifica sempre. $\varnothing$ è detto **evento impossibile**: non contiene nessun risultato, quindi non si verifica mai.

Eventi complementari, incompatibili, implicazione

- A e $\overline{A}$ sono detti **eventi complementari**.
- Due eventi A e B con $A \cap B = \varnothing$ sono detti **incompatibili** (o **mutuamente esclusivi**): non si possono verificare insieme.
- Se $A \subseteq B$ si dice che A **implica** B: ogni volta che si verifica A, si verifica necessariamente anche B.



incompatibili: $A \cap B = \varnothing$ A implica B: $A \subseteq B$

Figura 1.8: *Due eventi incompatibili non hanno risultati in comune; se $A \subseteq B$, chi sta in A sta anche in B.*

Esempio 1.2 — Testa e croce sono complementari

Nel lancio singolo di una moneta, T e C sono eventi complementari ($\overline{T} = C$), quindi anche incompatibili:

$$T \cap C = \overline{C} \cap C = \varnothing.$$

Applicando le leggi di De Morgan si ritrovano le proprietà di Ω e di $\varnothing$:

$$\overline{T \cap C} = \overline{T} \cup \overline{C} = C \cup T = \Omega = \overline{\varnothing}, \qquad \overline{T \cup C} = \overline{T} \cap \overline{C} = C \cap T = \varnothing = \overline{\Omega}.$$

Esempio 1.3 — Lo stesso evento, tante frasi

Nel lancio doppio della moneta, l'evento $D =$ «esce almeno una croce» è incompatibile con $\{TT\}$ e si può scrivere in molti modi:

$$D = \{CC, TC, CT\} = \overline{\{TT\}} = \Omega \setminus \{TT\} = \{CC\} \cup \{TC\} \cup \{CT\}.$$

Matematicamente l'evento è individuato in modo unico dai suoi elementi; a parole lo si può descrivere con frasi diverse: «almeno una croce», «non due teste», «non è uscito TT».

Per finire, ecco il «vocabolario» che traduce le frasi sugli eventi nelle operazioni sugli insiemi. Conviene impararlo bene: negli esercizi il primo passo è sempre tradurre il testo in questa lingua.

A parole	**Con gli insiemi**
si verifica A	il risultato ω sta in A: $\omega \in A$
si verifica A **oppure** B (almeno uno)	$A \cup B$
si verificano A **e** B (entrambi)	$A \cap B$
non si verifica A	$\overline{A}$
si verifica A **ma non** B	$A \setminus B = A \cap \overline{B}$
né A **né** B	$\overline{A} \cap \overline{B} = \overline{A \cup B}$
A e B non possono verificarsi insieme	$A \cap B = \varnothing$
se si verifica A, si verifica anche B	$A \subseteq B$
qualcosa succede sempre / non succede mai	Ω / $\varnothing$

Tabella 1.1: *Dal linguaggio degli eventi a quello degli insiemi.*

In sintesi

- Un **esperimento aleatorio** ha un esito imprevedibile; lo **spazio campione** Ω raccoglie tutti i risultati possibili. Per ora Ω è **discreto**: finito o numerabile.
- Un **evento** è un sottoinsieme di Ω; si verifica quando il risultato gli appartiene. È determinato dai suoi elementi, non dalla frase che lo descrive.
- Unione («o»), intersezione («e»), complementare («non») e differenza («ma non») costruiscono nuovi eventi, e $A \setminus B = A \cap \overline{B}$.
- Leggi di **De Morgan**: $\overline{A \cup B} = \overline{A} \cap \overline{B}$ e $\overline{A \cap B} = \overline{A} \cup \overline{B}$. Valgono anche le proprietà associativa e le due distributive.
- Ω è l'evento certo, $\varnothing$ l'impossibile; A e B sono incompatibili se $A \cap B = \varnothing$; A implica B se $A \subseteq B$.

Contare: il calcolo combinatorio

In molti esperimenti i risultati possibili sono tutti «alla pari»: un dado non truccato non preferisce nessuna faccia, una moneta non preferisce testa a croce, un mazzo ben mescolato non preferisce nessuna carta. In questi casi, come vedremo fra poco, la probabilità di un evento si ottiene **contando**: quanti risultati fanno verificare l'evento, su quanti risultati possibili. Contare sembra facile, ma i numeri crescono in fretta: le mani possibili di cinque carte da un mazzo di 52 sono più di due milioni e mezzo, e nessuno le vuole elencare una per una. Il **calcolo combinatorio** è l'insieme delle tecniche per contare **senza elencare**.

Quando tutti i risultati si equivalgono

Prendiamo un dado non truccato, che d'ora in poi chiameremo **onesto**, e lanciamolo n volte. Ogni lancio dà uno dei sei risultati di $\Omega = \{1, 2, 3, 4, 5, 6\}$. Contiamo quante volte esce ciascuna faccia.

Numero di occorrenze e frequenza relativa

Se un esperimento si ripete n volte, il **numero di occorrenze** n_A di un evento A è il numero di prove in cui A si è verificato. La **frequenza relativa** di A è la frazione di prove in cui si è verificato:

$$f_n(A) = \frac{n_A}{n}.$$

È sempre un numero fra 0 (non si è mai verificato) e 1 (si è verificato sempre).

Detto n_i il numero di volte in cui esce la faccia i, per un dado onesto ci aspettiamo che, se n è abbastanza grande, i sei numeri $n_1, \ldots, n_6$ siano **all'incirca uguali** fra loro, cioè ognuno vicino a $n/|\Omega| = n/6$. La figura mostra che cosa succede davvero in tre serie di lanci simulati al computer.

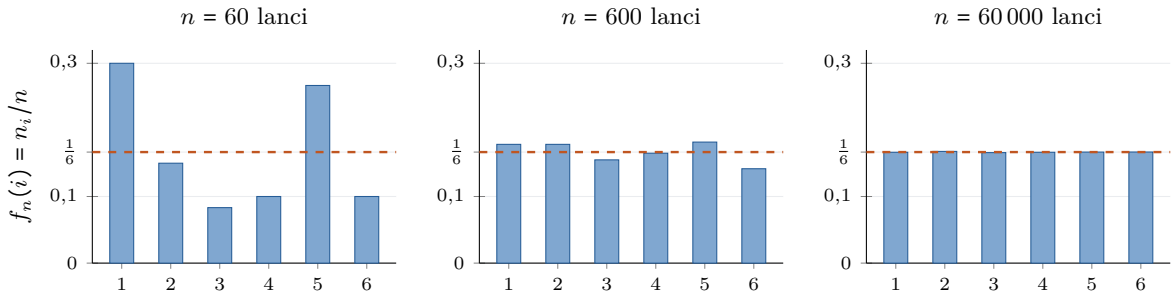


Figura 2.1: *Frequenze relative delle sei facce in tre serie di lanci di un dado onesto (simulate). Con pochi lanci sono molto irregolari; al crescere di n si schiacciano tutte sulla linea tratteggiata* $1/6$.

Consideriamo ora i due eventi $A = \{1, 3, 5\}$ («esce un dispari») e $B = \{2, 4, 6\}$ («esce un pari»). L'evento A si verifica ogni volta che esce l'1, il 3 o il 5, quindi il suo numero di occorrenze è la somma di quelli delle tre facce; e siccome ognuna esce circa $n/|\Omega|$ volte:

$$n_A = n_1 + n_3 + n_5 \simeq \frac{n}{|\Omega|} + \frac{n}{|\Omega|} + \frac{n}{|\Omega|} = \frac{n}{|\Omega|}\,|A|\,, \qquad n_B = n_2 + n_4 + n_6 \simeq \frac{n}{|\Omega|}\,|B|\,.$$

Il simbolo $\simeq$ si legge «circa uguale». Dividendo per n si ottengono le frequenze relative:

$$\frac{n_A}{n} \simeq \frac{|A|}{|\Omega|} = \frac{3}{6} = \frac{1}{2}, \qquad \frac{n_B}{n} \simeq \frac{|B|}{|\Omega|} = \frac{3}{6} = \frac{1}{2}.$$

La frazione di volte in cui si verifica un evento è (circa) il numero dei suoi elementi diviso il numero di tutti i risultati possibili.

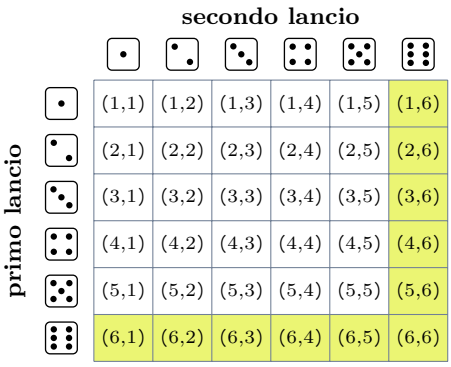
Due lanci consecutivi

Ora l'esperimento consiste nel lanciare il dado **due volte di seguito**, annotando il primo e il secondo risultato. Lo spazio campione è l'insieme delle coppie ordinate:

$$\Omega = \{(1,1),(1,2),\dots,(1,6),(2,1),\dots,(6,1),(6,2),\dots,(6,6)\} = \{1,\dots,6\}^2,$$

che ha $6 \cdot 6 = 36$ elementi. Se il dado è onesto, in un gran numero n di prove ogni coppia esce circa $n/|\Omega| = n/36$ volte. Sia A l'evento «esce almeno un 6»:

$$A = \{(1,6),(2,6),\dots,(5,6),(6,1),(6,2),\dots,(6,6)\}.$$



Le 11 caselle gialle sono l'evento «almeno un 6»: le 6 della riga in basso (il primo lancio è un 6) più le 6 della colonna a destra (il secondo lancio è un 6), meno la casella (6,6), che sta in entrambe e non va contata due volte: $6 + 6 - 1 = 11$.

Figura 2.2: *I 36 risultati del lancio doppio di un dado.*

Anche qui ci aspettiamo che, per n abbastanza grande, la frequenza dell'evento sia

$$\frac{n_A}{n} \simeq \frac{|A|}{|\Omega|} = \frac{11}{36} \approx 0{,}306.$$

La regola generale

Gli esempi suggeriscono una regola che vale ogni volta che i risultati sono «alla pari».

Eventi elementari equivalenti

In uno spazio campione finito Ω gli eventi elementari sono **equivalenti** se nessuno è privilegiato rispetto agli altri: ripetendo l'esperimento un numero molto grande di volte, ciascun risultato si verifica all'incirca lo stesso numero di volte di qualsiasi altro.

In questo caso, per qualsiasi evento $A \subseteq \Omega$, la frequenza relativa gode della proprietà

$$f_n(A) = \frac{n_A}{n} \longrightarrow \frac{|A|}{|\Omega|} \qquad \text{per } n \to \infty.$$

La freccia si legge «tende a»: al crescere del numero n di prove la frequenza si avvicina quanto si vuole al numero $|A| \,/\, |\Omega|$. (La definizione precisa di questo «avvicinarsi», il *limite*, è nel prossimo capitolo.) La conseguenza pratica è importantissima: quando gli eventi elementari sono equivalenti, **tutto si riduce a contare** quanti elementi hanno gli insiemi che ci interessano. Il resto del capitolo insegna a farlo.

Il principio fondamentale: moltiplicare le scelte

Quasi tutte le formule di conteggio discendono da un'unica idea. Prima però serve una notazione, perché di prodotti lunghi ne scriveremo parecchi.

Richiamo di matematica: sommatorie e produttorie

Quando si devono sommare molti termini che seguono una regola, invece dei puntini si usa la lettera greca Σ (*sigma* maiuscola, la «S» di somma):

$$\sum_{i=1}^{n} a_i = a_1 + a_2 + \cdots + a_n.$$

Si legge «sommatoria per i che va da 1 a n di a_i». L'**indice** i parte dal valore scritto sotto, cresce di uno alla volta e si ferma al valore scritto sopra; per ogni valore si calcola il termine e alla fine si somma tutto:

$$\sum_{i=1}^{4} i = 1+2+3+4 = 10, \qquad \sum_{k=0}^{3} 2^k = 1+2+4+8 = 15, \qquad \sum_{i=1}^{3} 5 = 5+5+5 = 15.$$

Nell'ultimo esempio il termine non dipende da i: si somma tre volte lo stesso numero, e in generale $\sum_{i=1}^{n} c = n \cdot c$. Il nome dell'indice non conta: $\sum_{i=1}^{4} i$ e $\sum_{k=1}^{4} k$ sono la stessa somma.
Allo stesso modo la lettera Π (*pi* maiuscola, la «P» di prodotto) indica un prodotto:

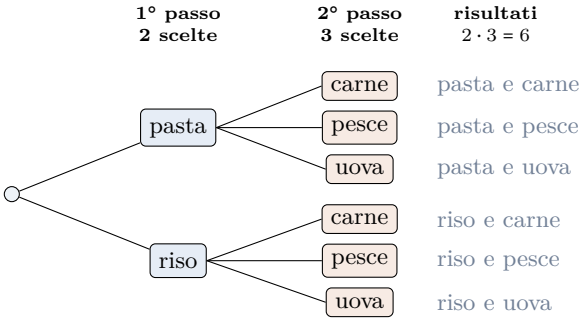
$$\prod_{i=1}^{n} a_i = a_1 \cdot a_2 \cdots a_n, \qquad \prod_{i=1}^{4} i = 1\cdot 2\cdot 3\cdot 4 = 24, \qquad \prod_{i=0}^{2} (5-i) = 5\cdot 4\cdot 3 = 60.$$

Due proprietà delle sommatorie si usano di continuo. Una costante che moltiplica tutti i termini si può portare fuori (è la proprietà distributiva: $c\,a_1 + \cdots + c\,a_n = c\,(a_1 + \cdots + a_n)$), e la somma di due successioni si può spezzare in due somme (basta riordinare i termini):

$$\sum_{i=1}^{n} c\,a_i = c \sum_{i=1}^{n} a_i, \qquad \sum_{i=1}^{n} (a_i + b_i) = \sum_{i=1}^{n} a_i + \sum_{i=1}^{n} b_i.$$

Esempio 2.1 — Quanti pranzi diversi?

Un menù offre 2 primi (pasta, riso) e 3 secondi (carne, pesce, uova). Un pranzo è formato da un primo e un secondo. Per ognuno dei 2 primi si può scegliere uno qualsiasi dei 3 secondi: i pranzi diversi sono $2 \cdot 3 = 6$.



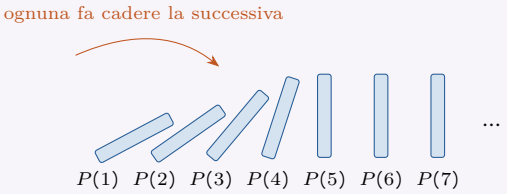
Il disegno si chiama **diagramma ad albero**: ogni ramo è una scelta, ogni foglia (a destra) è un risultato completo. Le foglie sono tante quanti i rami del primo livello moltiplicati per i rami che partono da ciascuno di essi.

L'esempio contiene già tutta l'idea. Per dimostrarla in generale serve uno strumento che useremo più volte.

Richiamo di matematica: il principio di induzione

Per dimostrare che un'affermazione $P(n)$ è vera **per ogni** numero naturale $n \geq 1$ non serve verificarla su infiniti numeri. Bastano due cose:

1. la **base**: si verifica che $P(1)$ è vera;
2. il **passo induttivo**: si dimostra che, *se* $P(n-1)$ è vera (è l'**ipotesi induttiva**), *allora* è vera anche $P(n)$.



È come una fila di tessere del domino: la base fa cadere la prima tessera; il passo induttivo garantisce che ogni tessera, cadendo, fa cadere la successiva. Allora cadono tutte: $P(1)$ fa cadere $P(2)$, che fa cadere $P(3)$, e così via senza fine.

Teorema 2.1 — Principio fondamentale del calcolo combinatorio

Se una scelta si compie in k passi successivi e al passo i-esimo ci sono m_i possibilità, **qualunque** siano state le scelte fatte ai passi precedenti, allora i modi di compiere l'intera scelta sono

$$m_1 \cdot m_2 \cdots m_k = \prod_{i=1}^{k} m_i.$$

In particolare, dati k insiemi finiti $A_1, A_2, \ldots, A_k$ (non necessariamente distinti), il loro **prodotto cartesiano** $A^{(k)} = A_1 \times A_2 \times \cdots \times A_k$, cioè l'insieme delle k-ple ordinate con il primo elemento in A_1, il secondo in A_2 e così via, ha come numero di elementi il prodotto dei numeri di elementi dei singoli insiemi:

$$\left|A^{(k)}\right| = \prod_{i=1}^{k} |A_i|\,. \qquad (\bullet)$$

Dimostrazione

Passo 1 — Base. Con un solo passo ($k = 1$) i modi sono m_1, e la formula dà proprio m_1.

Passo 2 — Ipotesi induttiva. Supponiamo che i primi $k-1$ passi si possano compiere in $m_1 \cdot m_2 \cdots m_{k-1}$ modi.

Passo 3 — Passo induttivo. Ognuno di questi modi si può completare con una qualsiasi delle m_k possibilità del passo k-esimo, e completamenti diversi danno scelte complete diverse. Come nell'albero dei pranzi, ogni foglia del livello $k-1$ si apre in m_k rami: le scelte complete sono $(m_1 \cdots m_{k-1}) \cdot m_k$.

Passo 4 — Il prodotto cartesiano. Costruire una k-pla di $A^{(k)}$ vuol dire scegliere il primo elemento in A_1 ($m_1 = |A_1|$ modi), poi il secondo in A_2 ($m_2 = |A_2|$ modi, qualunque sia il primo), e così via. La formula $(\bullet)$ è il caso particolare con $m_i = |A_i|$.

■

Il numero di elementi del prodotto cartesiano è il **prodotto** del numero di elementi dei singoli insiemi: è la relazione fondamentale del calcolo combinatorio, da cui derivano tutte le formule del capitolo. La forma con i «passi» è un po' più generale ed è quella che serve quando l'insieme delle scelte disponibili cambia da un passo all'altro: conta solo che ne cambi il *contenuto*, non il *numero*.

Esempio 2.2 — Targhe e lanci

- Il lancio doppio di una moneta ha $\left|\{T,C\}^2\right| = 2 \cdot 2 = 4$ risultati; il lancio doppio di un dado $6 \cdot 6 = 36$; tre lanci di un dado $6^3 = 216$.
- Una targa automobilistica italiana ha la forma `AB 123 CD`: due lettere, tre cifre, due lettere. Le lettere ammesse sono 22 (sono escluse I, O, Q e U, che si confondono con altri simboli). Le targhe possibili sono $22 \cdot 22 \cdot 10 \cdot 10 \cdot 10 \cdot 22 \cdot 22 = 22^4 \cdot 10^3 = 234\,256\,000$.

Disposizioni: quando l'ordine conta

Disposizioni semplici

Disposizioni semplici

Dato un insieme $A = \{a_1, a_2, \ldots, a_n\}$ di n elementi, le **disposizioni semplici di n oggetti di classe k** (k-ple ordinate senza ripetizione) sono le sequenze ordinate di k elementi **distinti** di A: le «stringhe» di lunghezza k in cui ogni elemento di A compare al più una volta.

Teorema 2.2 — Numero di disposizioni semplici

Per $k \le n$ il numero di disposizioni semplici di n oggetti di classe k è

$$K_{o,nr} = n\,(n-1)\,(n-2)\cdots(n-k+1) = \prod_{i=0}^{k-1}(n-i).$$

I pedici ricordano che l'ordine conta (o) e che non sono ammesse ripetizioni (nr).

Dimostrazione

Passo 1 — I passi. Si costruisce la sequenza una posizione alla volta: k passi.

Passo 2 — Le scelte a ogni passo. Al primo passo si può scegliere uno qualsiasi degli n elementi. Al secondo passo un elemento è già stato usato e non si può ripetere: restano $n-1$ scelte, *qualunque* sia l'elemento usato. Al terzo ne restano $n-2$, e in generale al passo i-esimo ne restano $n-(i-1)$. All'ultimo passo, il k-esimo, le scelte sono $n-k+1$.

Passo 3 — Si moltiplica. Per il principio fondamentale (Teorema 2.1) il totale è $n\,(n-1)\cdots(n-k+1)$. Nella formula $(\bullet)$ è come avere $|A_1| = n$, $|A_2| = n-1$, …, $|A_k| = n-k+1$.

■

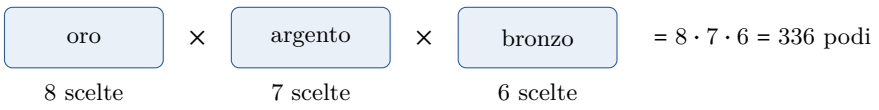


Figura 2.3: *Otto atleti in finale: chi vince l'oro si sceglie fra 8, l'argento fra i 7 rimasti, il bronzo fra i 6 rimasti. Contano l'ordine (oro e argento non sono la stessa cosa) e l'assenza di ripetizioni (nessuno vince due medaglie).*

Si noti che la formula funziona anche se si prova a esagerare: per $k > n$ il prodotto contiene il fattore $n - n = 0$ e dà zero, come deve essere (non si possono mettere in fila k oggetti distinti se se ne hanno meno di k).

Disposizioni con ripetizione

Disposizioni con ripetizione

Le **disposizioni con ripetizione di n oggetti di classe k** (o k-ple ordinate con ripetizione) sono le sequenze ordinate di k elementi di $A = \{a_1, \dots, a_n\}$ in cui ogni elemento **può ripetersi**.

Teorema 2.3 — Numero di disposizioni con ripetizione

Il numero di disposizioni con ripetizione di n oggetti di classe k è

$$K_{o,r} = \prod_{i=0}^{k-1} n = n^k.$$

Dimostrazione

Passo 1 — Le scelte non diminuiscono. Questa volta a ogni posizione si può rimettere qualsiasi elemento, anche se è già stato usato: a ognuno dei k passi le scelte sono sempre n.

Passo 2 — Si moltiplica. Per il principio fondamentale il totale è $n \cdot n \cdots n$ (k volte), cioè n^k. Nella (•) è il caso $|A_1| = |A_2| = \cdots = |A_k| = n$: le disposizioni con ripetizione sono proprio gli elementi del prodotto cartesiano A^k. ■

Esempio 2.3 — Stringhe binarie, byte e codici PIN

- Le stringhe binarie di lunghezza k sono le k-ple ordinate con ripetizione dell'insieme $\{0, 1\}$, che ha 2 elementi: sono 2^k. Un byte ($k = 8$) può quindi assumere $2^8 = 256$ valori diversi.
- Un PIN di 4 cifre è una disposizione con ripetizione delle 10 cifre: i PIN possibili sono $10^4 = 10\,000$. Chi prova a indovinarlo a caso ha una sola possibilità su diecimila.

Permutazioni

Un caso particolare, ma importantissimo, delle disposizioni semplici è quello in cui si usano **tutti** gli elementi: $k = n$. La domanda è: in quanti modi si possono mettere in fila n oggetti distinti?

Permutazioni

Una **permutazione** di n oggetti distinti è un modo di metterli in fila, cioè una disposizione semplice di classe $k = n$.

Teorema 2.4 — Numero di permutazioni

Il numero di permutazioni di n oggetti distinti è

$$n\,(n-1)\,(n-2)\cdots 2 \cdot 1 = n!$$

(si legge «n fattoriale»).

Dimostrazione

Passo 1. È la formula delle disposizioni semplici con $k = n$: l'ultimo fattore diventa $n - n + 1 = 1$, e il prodotto comprende tutti gli interi da n fino a 1.

■

Richiamo di matematica: il fattoriale

Il **fattoriale** di un intero $n \geq 1$ è il prodotto di tutti gli interi da 1 a n:

$$n! = \prod_{i=1}^{n} i = 1 \cdot 2 \cdot 3 \cdots n, \qquad \text{e per convenzione} \quad 0! = 1.$$

n	0	1	2	3	4	5	6	7	8	9	10
$n!$	1	1	2	6	24	120	720	5 040	40 320	362 880	3 628 800

Il fattoriale cresce in modo vertiginoso: 52!, il numero di modi di mescolare un mazzo di carte francesi, vale circa $8 \cdot 10^{67}$, un numero con 68 cifre. Ogni volta che si mescola bene un mazzo, quasi certamente si ottiene un ordine che non è mai esistito prima nella storia.

Due proprietà si usano di continuo:

- $n! = n \cdot (n-1)!$: il fattoriale di n è n volte il fattoriale del numero precedente (per esempio $5! = 5 \cdot 4! = 5 \cdot 24 = 120$);
- un rapporto di fattoriali si semplifica cancellando i fattori comuni: $\frac{7!}{4!} = \frac{7 \cdot 6 \cdot 5 \cdot \cancel{4!}}{\cancel{4!}} = 7 \cdot 6 \cdot 5 = 210$.

Perché $0! = 1$**?** Perché è l'unico valore che rende vera la regola $n! = n \cdot (n-1)!$ anche per $n = 1$: $1! = 1 \cdot 0!$ richiede $0! = 1$. C'è anche una lettura «combinatoria»: c'è esattamente **un** modo di mettere in fila zero oggetti, cioè non fare niente.

Con il fattoriale la formula delle disposizioni semplici si scrive in forma compatta. Basta moltiplicare e dividere per $(n-k)!$, che «completa» il prodotto fino a 1:

$$K_{o,nr} = n\,(n-1)\cdots(n-k+1) = \frac{n\,(n-1)\cdots(n-k+1)\cdot(n-k)!}{(n-k)!} = \frac{n!}{(n-k)!}.$$

Per esempio, i podi della figura sono $\frac{8!}{5!} = 8 \cdot 7 \cdot 6 = 336$.

Esempio 2.4 — Anagrammi

Gli anagrammi della parola ROMA (anche senza senso) sono le permutazioni delle sue 4 lettere distinte: $4! = 24$. Si possono ottenere dall'albero: 4 scelte per la prima lettera, 3 per la seconda, 2 per la terza, 1 per l'ultima. Fra questi ci sono AMOR, MORA, RAMO, ORMA e MARO.

Combinazioni: quando l'ordine non conta

Spesso l'ordine non interessa: in una mano di carte conta *quali* carte si hanno, non in che ordine sono arrivate; in una schedina del lotto conta *quali* numeri si giocano.

Combinazioni

Le **combinazioni di n elementi su k posti**, indicate con $C_{n,k}$, sono le k-ple **non ordinate** e senza ripetizioni che si possono formare con n elementi. In altre parole, $C_{n,k}$ è il numero di **sottoinsiemi di k elementi** di un insieme di n elementi.

In un sottoinsieme contano solo gli elementi, non il loro ordine: $\{a_1, a_2\}$ e $\{a_2, a_1\}$ sono lo stesso insieme e vanno contati una volta sola. Il trucco per contarli è partire dalle disposizioni, in cui l'ordine conta, e accorgersi che ogni sottoinsieme viene contato più volte.

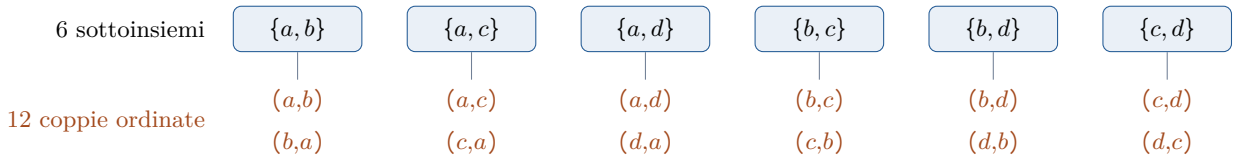


Figura 2.4: *Con $n = 4$ elementi $\{a, b, c, d\}$ e $k = 2$: le $4 \cdot 3 = 12$ disposizioni si raggruppano a due a due (le $2! = 2$ permutazioni di ciascuna coppia), e i gruppi sono i $12/2 = 6$ sottoinsiemi.*

Teorema 2.5 — Numero di combinazioni

Il numero di sottoinsiemi di k elementi di un insieme di n elementi ($0 \le k \le n$) è

$$C_{n,k} = \frac{n\,(n-1)\,(n-2)\cdots(n-k+1)}{k!} = \frac{n!}{k!\,(n-k)!} = \binom{n}{k}.$$

Il numero $\binom{n}{k}$ si chiama **coefficiente binomiale** e si legge «n su k».

Dimostrazione — contare due volte la stessa cosa

Passo 1 — L'idea. Contiamo le k-ple ordinate senza ripetizione in due modi diversi. Siccome contiamo la stessa cosa, i due risultati devono essere uguali.

Passo 2 — Primo modo. Sono le disposizioni semplici: $K_{o,nr} = n\,(n-1)\cdots(n-k+1)$.

Passo 3 — Secondo modo. Una k-pla ordinata si può costruire in due passi: prima si sceglie *quali* k elementi usare (un sottoinsieme: $C_{n,k}$ modi), poi si sceglie *in che ordine* metterli (le permutazioni di k oggetti: $k!$ modi, qualunque sia il sottoinsieme). Per il principio fondamentale le k-ple ordinate sono $C_{n,k} \cdot k!$.

Passo 4 — Si uguaglia. $C_{n,k} \cdot k! = n\,(n-1)\cdots(n-k+1)$, quindi

$$C_{n,k} = \frac{n\,(n-1)\cdots(n-k+1)}{k!}.$$

In altre parole: tutte le $k!$ permutazioni di una stessa k-pla ordinata *collassano* in un'unica combinazione.

Passo 5 — La forma con i fattoriali. Moltiplicando numeratore e denominatore per $(n-k)!$, il numeratore diventa $n!$ (come per le disposizioni):

$$C_{n,k} = \frac{n\,(n-1)\cdots(n-k+1)\cdot(n-k)!}{k!\,(n-k)!} = \frac{n!}{k!\,(n-k)!}.$$

■

Esempio 2.5 — Il SuperEnalotto

Una giocata del SuperEnalotto consiste nello scegliere 6 numeri diversi fra 1 e 90, senza che l'ordine conti. Le giocate possibili sono

$$\binom{90}{6} = \frac{90 \cdot 89 \cdot 88 \cdot 87 \cdot 86 \cdot 85}{6!} = 622\,614\,630.$$

Con una sola giocata, le probabilità di fare «sei» sono una su più di seicento milioni.

Richiamo di matematica: il coefficiente binomiale e il triangolo di Tartaglia

Il coefficiente binomiale $\binom{n}{k} = \dfrac{n!}{k!\,(n-k)!}$ ha alcune proprietà che conviene conoscere.

- **Casi estremi**: $\binom{n}{0} = \binom{n}{n} = 1$ (un solo sottoinsieme vuoto, un solo sottoinsieme «tutto») e $\binom{n}{1} = n$ (i sottoinsiemi con un elemento sono tanti quanti gli elementi).
- **Simmetria**: $\binom{n}{k} = \binom{n}{n-k}$. Nella formula basta scambiare k con $n-k$: il denominatore $k!\,(n-k)!$ non cambia. A parole: scegliere i k elementi che *entrano* equivale a scegliere gli $n-k$ che *restano fuori*. Per esempio $\binom{90}{84} = \binom{90}{6}$.
- **Regola di Stifel**: $\binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k}$ per $1 \le k \le n-1$. Si fissa un elemento x dell'insieme. I sottoinsiemi di k elementi o contengono x, e allora gli altri $k-1$ si scelgono fra i rimanenti $n-1$ ($\binom{n-1}{k-1}$ modi), oppure non lo contengono, e allora tutti i k elementi si scelgono fra gli altri $n-1$ ($\binom{n-1}{k}$ modi). I due gruppi non hanno elementi in comune, quindi i totali si sommano.

La regola di Stifel permette di costruire tutti i coefficienti binomiali senza fattoriali, riga dopo riga: è il **triangolo di Tartaglia**. La riga n contiene $\binom{n}{0}, \binom{n}{1}, \ldots, \binom{n}{n}$; ai lati ci sono degli 1 e ogni numero interno è la somma dei due che ha sopra.

$n=0$				1			
$n=1$			1		1		
$n=2$		1		2		1	
$n=3$	1		3		3		1
$n=4$	1		4		6		4		1
$n=5$	1		5		10		10		5		1
$n=6$	1		6		15		20		15		6		1

$\binom{4}{1} + \binom{4}{2} = 4 + 6 = 10 = \binom{5}{2}$

UN PROBLEMA CON LE CARTE

Esercizio 2.1 — Estrazioni da un mazzo di carte francesi

Un mazzo di carte francesi ha 52 carte, 13 per ognuno dei quattro semi: Cuori (C), Fiori (F), Picche (P) e Quadri (Q). Si estraggono delle carte **senza reinserimento** (una carta estratta non torna nel mazzo). Si calcolino:

a) il numero di possibili quaterne ordinate;

b) il numero di quaterne non ordinate;

c) il numero di quaterne ordinate con semi (C, F, P, Q), cioè con la prima carta di cuori, la seconda di fiori, la terza di picche e la quarta di quadri;

d) il numero di cinquine non ordinate in cui compaiono esattamente due assi.

Svolgimento

a) Contano l'ordine e l'assenza di ripetizioni (una carta estratta non può riuscire): sono disposizioni semplici di 52 oggetti di classe 4,

$$52 \cdot 51 \cdot 50 \cdot 49 = 6\,497\,400.$$

b) Ora l'ordine non conta: le $4! = 24$ permutazioni di ogni quaterna collassano in un'unica quaterna non ordinata,

$$\frac{52 \cdot 51 \cdot 50 \cdot 49}{4!} = \frac{6\,497\,400}{24} = 270\,725 = \binom{52}{4}.$$

c) La prima carta si sceglie fra le 13 di cuori, la seconda fra le 13 di fiori, la terza fra le 13 di picche, la quarta fra le 13 di quadri: è il prodotto cartesiano di quattro insiemi con $|A_i| = 13$ ($k = 4$),

$$13 \cdot 13 \cdot 13 \cdot 13 = 13^4 = 28\,561.$$

Le ripetizioni sono impossibili da sole, perché le quattro carte hanno semi diversi.

d) Si costruisce la cinquina in due passi. Prima si scelgono i due assi fra i 4 del mazzo: i sottoinsiemi di 2 assi sono $\binom{4}{2}$ (4 assi su 2 posti). Poi si scelgono le altre 3 carte fra le $52 - 4 = 48$ che non sono assi (altrimenti gli assi sarebbero più di due): sono $\binom{48}{3}$. Per il principio fondamentale:

$$\binom{4}{2}\binom{48}{3} = \frac{4!}{2!\,2!} \cdot \frac{48!}{3!\,45!} = \frac{4 \cdot 3}{2} \cdot \frac{48 \cdot 47 \cdot 46}{3 \cdot 2} = 6 \cdot 17\,296 = 103\,776.$$

Una curiosità sul punto c)

Se nel punto c) l'ordine non contasse (cioè si volessero le quaterne non ordinate con una carta per seme), il risultato sarebbe ancora 13^4: ogni mano con una carta per seme corrisponde a una e una sola quaterna ordinata nell'ordine C, F, P, Q. Se invece si volessero le quaterne *ordinate* con una carta per seme in un ordine qualsiasi, bisognerebbe moltiplicare per le $4!$ disposizioni dei semi: $4! \cdot 13^4 = 685\,464$.

L'insieme delle parti e il binomio di Newton

Insieme delle parti

L'**insieme delle parti** $\mathcal{P}(A)$ di un insieme A è l'insieme di **tutti** i sottoinsiemi di A, compresi l'insieme vuoto $\varnothing$ e A stesso.

Quanti sono i sottoinsiemi di un insieme A con n elementi? Quelli con esattamente k elementi sono $\binom{n}{k}$, e k può andare da 0 (l'insieme vuoto) a n (A stesso). Sommando su tutte le dimensioni possibili:

$$|\mathcal{P}(A)| = \sum_{k=0}^{n} \binom{n}{k} = \binom{n}{0} + \binom{n}{1} + \cdots + \binom{n}{n}.$$

Questa somma ha un valore molto semplice, che si scopre con una delle formule più famose della matematica.

Teorema 2.6 — Binomio di Newton

Per qualsiasi coppia di numeri a, b e per ogni naturale n:

$$(a+b)^n = \sum_{k=0}^{n} \binom{n}{k} a^k\, b^{n-k}.$$

Prima della dimostrazione, i casi piccoli. Per $n = 2$ si ritrova il quadrato di un binomio, $(a+b)^2 = b^2 + 2ab + a^2$, con i coefficienti $1, 2, 1$ della riga 2 del triangolo di Tartaglia. Per $n = 3$: $(a+b)^3 = b^3 + 3ab^2 + 3a^2b + a^3$, con i coefficienti $1, 3, 3, 1$ della riga 3. Non è una coincidenza.

Dimostrazione

Passo 1 — Si scrive la potenza come prodotto. $(a+b)^n = (a+b)(a+b)\cdots(a+b)$, con n fattori.

Passo 2 — Come si sviluppa un prodotto. Moltiplicando tutto (proprietà distributiva) si ottiene una somma di termini, e ogni termine si forma scegliendo **da ciascun fattore** o la a o la b e moltiplicando le scelte. Per esempio con $n = 3$ la scelta «a dal primo fattore, b dal secondo, a dal terzo» produce il termine $a \cdot b \cdot a = a^2 b$.

Passo 3 — Che termini si ottengono. Se la a è stata scelta da k fattori, la b è stata scelta dagli altri $n-k$: il termine vale $a^k b^{n-k}$. Quindi i termini possibili sono $a^0 b^n, a^1 b^{n-1}, \ldots, a^n b^0$.

Passo 4 — Quante volte compare ciascuno. Il termine $a^k b^{n-k}$ compare una volta per ogni modo di scegliere *quali* k fattori (fra gli n) danno la a. Sono i sottoinsiemi di k elementi di un insieme di n: $\binom{n}{k}$. Raccogliendo i termini uguali si ottiene $\binom{n}{k} a^k b^{n-k}$, e sommando su k da 0 a n si ha la tesi. ∎

Teorema 2.7 — Numero dei sottoinsiemi

Un insieme A con n elementi ha 2^n sottoinsiemi:

$$|\mathcal{P}(A)| = \sum_{k=0}^{n} \binom{n}{k} = 2^n.$$

Dimostrazione — due modi

Passo 1 — Con il binomio di Newton. Ponendo $a = b = 1$ nella formula di Newton, ogni potenza di 1 vale 1:

$$2^n = (1+1)^n = \sum_{k=0}^{n} \binom{n}{k} 1^k \, 1^{n-k} = \sum_{k=0}^{n} \binom{n}{k} = |\mathcal{P}(A)| \, .$$

Passo 2 — Con una stringa binaria. Si mettono in fila gli n elementi di A. Un sottoinsieme si descrive dicendo, per ogni elemento, se c'è (1) o non c'è (0): è una stringa binaria di lunghezza n, e sottoinsiemi diversi danno stringhe diverse. Le stringhe binarie di lunghezza n sono 2^n (disposizioni con ripetizione, Teorema 2.3), quindi anche i sottoinsiemi. ■

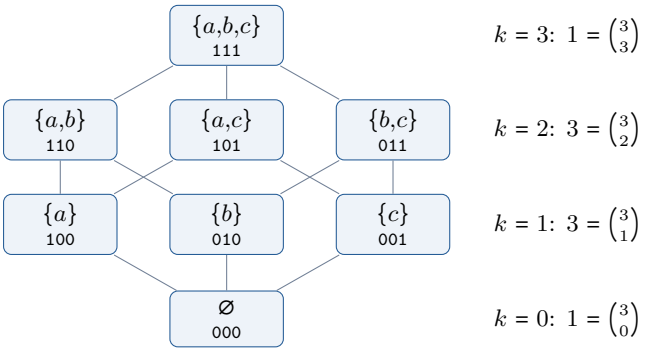


Figura 2.5: *Gli $2^3 = 8$ sottoinsiemi di $\{a, b, c\}$, ordinati per numero di elementi k, ognuno con la sua stringa binaria (1 = l'elemento c'è). Le righe ne contengono $1, 3, 3, 1$: la riga 3 del triangolo di Tartaglia.*

PROVE RIPETUTE E CONTEGGIO DEI SUCCESSI

Un ultimo conteggio, che sarà la chiave della distribuzione binomiale (Capitolo 5). Si considerino le stringhe binarie di lunghezza n che contengono esattamente k valori «1» e $n - k$ valori «0». Quante sono?

Teorema 2.8 — Stringhe con k uni

Le stringhe binarie di lunghezza n con esattamente k valori «1» (e $n - k$ valori «0») sono

$$\frac{n!}{k!\,(n-k)!} = \binom{n}{k}.$$

Dimostrazione — permutazioni inefficaci

Passo 1 — Si parte da una stringa qualsiasi. Si prende una stringa con k «1» e $n - k$ «0», per esempio 1 1 0 0 0 ($n = 5$, $k = 2$), e si immagina di aver dato un nome diverso a ogni simbolo, come se fossero n oggetti distinti. Le loro permutazioni sono $n!$.

Passo 2 — Molte permutazioni non cambiano nulla. Scambiare fra loro due «1» lascia la stringa identica: le $k!$ permutazioni degli «1» sulle posizioni che già occupano sono *inefficaci*. Lo stesso vale per le $(n-k)!$ permutazioni degli «0» sulle loro posizioni.

Passo 3 — Si divide. Ogni stringa diversa viene quindi prodotta da $k!\,(n-k)!$ permutazioni. Dividendo le $n!$ permutazioni iniziali per $k!$ e per $(n-k)!$ si ottiene il numero di stringhe diverse: $\dfrac{n!}{k!\,(n-k)!} = \binom{n}{k}$.

Passo 4 — Un modo più breve. Una stringa con k uni è individuata da *quali* k posizioni, fra le n, contengono un 1: un sottoinsieme di k elementi dell'insieme delle posizioni $\{1, \ldots, n\}$. Sono $\binom{n}{k}$. ■

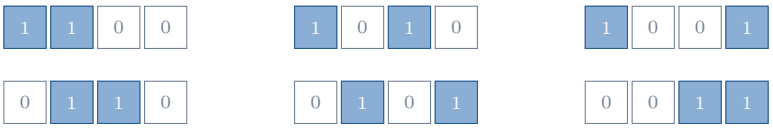


Figura 2.6: *Le* $\binom{4}{2} = \frac{4!}{2!\,2!} = 6$ *stringhe di lunghezza 4 con due «1»: tante quante le coppie di posizioni in cui mettere gli uni.*

Il nome del paragrafo viene dall'interpretazione più importante: se si ripete n volte una prova che può riuscire (1, un *successo*) o fallire (0, un *insuccesso*), le sequenze di risultati con esattamente k successi sono $\binom{n}{k}$. Per esempio, nei 10 lanci di una moneta le sequenze con esattamente 3 teste sono $\binom{10}{3} = 120$.

Riepilogo delle formule

Davanti a un problema di conteggio le domande da farsi sono due: **l'ordine conta?** e **sono ammesse ripetizioni?**

Che cosa si conta	Ordine	Ripetizioni	Quante sono
disposizioni con ripetizione	sì	sì	n^k
disposizioni semplici	sì	no	$n\,(n-1)\cdots(n-k+1) = \dfrac{n!}{(n-k)!}$
permutazioni ($k = n$)	sì	no	$n!$
combinazioni (sottoinsiemi)	no	no	$\binom{n}{k} = \dfrac{n!}{k!\,(n-k)!}$
tutti i sottoinsiemi	—	—	2^n

Tabella 2.1: *Le formule del calcolo combinatorio per k scelte da n elementi.*

Il caso che manca: combinazioni con ripetizione

Nella tabella manca la casella «ordine no, ripetizioni sì», che nel corso non serve ma completa il quadro. Per esempio: in quanti modi si possono scegliere 3 palline di gelato fra 5 gusti, potendo ripetere un gusto? La risposta è $\binom{n+k-1}{k} = \binom{7}{3} = 35$. Il motivo: una scelta si può disegnare con k pallini (le palline) e $n-1$ stanghette che separano i gusti; per esempio $\bullet\bullet\,|\,|\,\bullet\,|\,|$ vuol dire due palline del primo gusto e una del terzo. Ogni scelta è una stringa di $n+k-1$ simboli in cui si decide dove stanno i k pallini: $\binom{n+k-1}{k}$ modi.

In sintesi

- Se gli eventi elementari sono **equivalenti**, la frequenza di un evento tende a $|A| \,/\, |\Omega|$: la probabilità si calcola **contando**.
- **Principio fondamentale**: se una scelta si fa in k passi con m_i possibilità al passo i, i modi sono $\prod m_i$; in particolare $|A_1 \times \cdots \times A_k| = \prod |A_i|$.
- Disposizioni con ripetizione: n^k. Disposizioni semplici: $n!/(n-k)!$. Permutazioni: $n!$.
- Combinazioni (sottoinsiemi di k elementi): $\binom{n}{k} = \frac{n!}{k!\,(n-k)!}$, perché le $k!$ permutazioni di ogni k-pla collassano in un'unica combinazione.
- Binomio di Newton: $(a+b)^n = \sum_k \binom{n}{k} a^k b^{n-k}$; di conseguenza un insieme di n elementi ha 2^n sottoinsiemi.
- Le stringhe binarie lunghe n con k uni (le sequenze di n prove con k successi) sono $\binom{n}{k}$.

Dalla frequenza alla probabilità

Nel capitolo precedente abbiamo visto che, quando i risultati di un esperimento sono «alla pari», la frequenza relativa di un evento si avvicina sempre di più al numero $|A| \,/\, |\Omega|$. È il momento di dare un nome a questo numero: la **probabilità**. In questo capitolo la definiamo come il valore a cui tende la frequenza, la calcoliamo in alcuni casi interessanti (le mani del poker, un dado truccato) e ne ricaviamo le regole di calcolo: la probabilità del complementare, dell'unione, della differenza, la **probabilità condizionata**, la legge della **probabilità totale** e l'**indipendenza**.

La probabilità come limite della frequenza

La frase «la frequenza si avvicina sempre di più a un numero» ha un nome preciso in matematica: *limite*. Prima di usarla, vediamo che cosa significa esattamente.

Richiamo di matematica: il limite di una successione

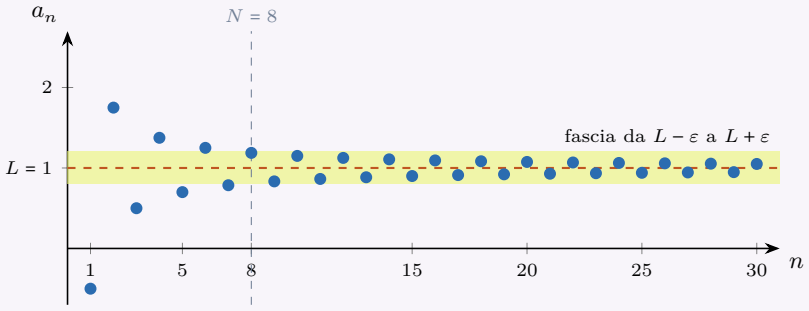
Una **successione** è un elenco infinito di numeri, uno per ogni naturale n: $a_1, a_2, a_3, \dots$ Per esempio $a_n = 1/n$ è la successione $1, \frac{1}{2}, \frac{1}{3}, \frac{1}{4}, \dots$, e la frequenza $f_n(A)$ di un evento, calcolata dopo n prove, è una successione.
Si dice che la successione **tende** al numero L (o che ha **limite** L), e si scrive

$$\lim_{n\to\infty} a_n = L \qquad \text{oppure} \qquad a_n \to L \text{ per } n \to \infty,$$

se i suoi termini si avvicinano a L **quanto si vuole** e **per sempre**. In modo preciso: per quanto stretta si scelga una fascia attorno a L, cioè per qualsiasi tolleranza $\varepsilon > 0$, da un certo indice N in poi *tutti* i termini stanno nella fascia:

$$|a_n - L| < \varepsilon \qquad \text{per ogni } n \geq N.$$

Il simbolo $|a_n - L|$ è la distanza fra a_n e L (il valore assoluto della differenza). Più stretta è la fascia, più avanti bisogna andare per trovare N, ma un N esiste sempre.



Nel disegno $a_n = 1 + (-1)^n \cdot 1{,}5/n$: i termini saltano sopra e sotto il valore $L = 1$, ma sempre più vicino. Con la tolleranza $\varepsilon = 0{,}2$ (la fascia gialla) basta prendere $N = 8$: da lì in poi nessun termine esce più. Con una fascia più stretta servirebbe un N più grande, ma lo si troverebbe comunque.
Altri esempi: $1/n \to 0$; $(n+1)/n = 1 + 1/n \to 1$. Invece la successione $(-1)^n = -1, 1, -1, 1, \dots$ **non** ha limite: salta per sempre fra due valori e non si avvicina a nessun numero.

Ora possiamo dare la definizione che regge tutta la prima parte del corso.

Probabilità (definizione frequentista)

Dato uno spazio campione discreto Ω e un suo sottoinsieme (evento) A, la **probabilità** che si verifichi A è il limite della frequenza relativa di A quando il numero di prove tende all'infinito:

$$P(A) = \lim_{n\to\infty} \frac{n_A}{n}.$$

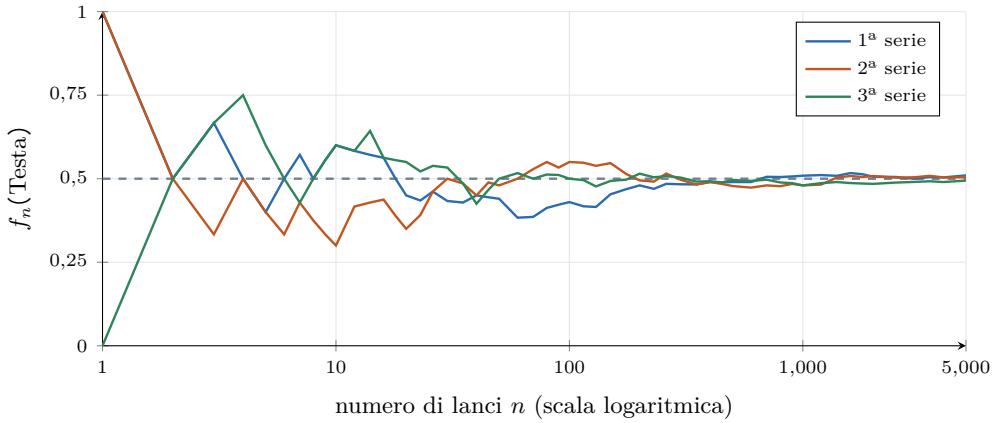


Figura 3.1: *Frequenza di «testa» in tre serie di 5000 lanci di una moneta onesta (simulate). All'inizio le tre curve oscillano moltissimo e sono diverse fra loro; al crescere di n si stringono tutte attorno a $1/2$.*

Un limite un po' speciale

La frequenza non è una successione come $1/n$, scritta una volta per tutte: ogni serie di lanci produce numeri diversi (nella figura le tre curve non coincidono mai). Il limite va quindi inteso in senso «fisico»: è il valore attorno a cui **tutte** le serie finiscono per stringersi. Rendere preciso questo discorso è il compito della *legge dei grandi numeri*, che vedremo nella terza parte del corso; il capitolo seguente aggira il problema con l'approccio assiomatico. Per ora la definizione frequentista basta per capire da dove vengono tutte le regole.

Spazi finiti con eventi equiprobabili

Se gli eventi elementari sono equivalenti, nel senso del capitolo precedente, ora possiamo dire che sono **equiprobabili**: hanno tutti la stessa probabilità $1/|\Omega|$. Per uno spazio finito con eventi elementari equiprobabili vale allora la relazione generale

$$P(A) = \frac{|\Omega_A|}{|\Omega|},$$

dove Ω_A è l'insieme di tutti gli esiti che comportano il verificarsi di A (cioè l'insieme A stesso).

Da ricordare: spazi equiprobabili

$$P(A) = \frac{|A|}{|\Omega|} = \frac{\text{numero dei casi favorevoli}}{\text{numero dei casi possibili}}$$

Con questa formula si rileggono tutti gli esempi già visti: la probabilità che un dado onesto dia un numero pari è $3/6 = 1/2$; quella di ottenere almeno un 6 in due lanci è $11/36$; quella di indovinare un PIN a caso è $1/10\,000$. Il punto delicato è sempre lo stesso: i risultati che si contano devono essere **davvero** equiprobabili.

Esempio 3.1 — L'errore di d'Alembert

Si lanciano due monete. Qual è la probabilità di ottenere una testa e una croce?

Ragionamento sbagliato: i risultati sono tre, «due teste», «due croci», «una testa e una croce», quindi la probabilità è $1/3$. Lo sostenne nel Settecento il matematico Jean-Baptiste d'Alembert.

Ragionamento giusto: i risultati equiprobabili sono le quattro coppie ordinate TT, TC, CT, CC (lo si vede pensando alle due monete come diverse, Capitolo 1). L'evento «una testa e una croce» è $\{TC, CT\}$ e contiene **due** di esse:

$$P(\{TC, CT\}) = \frac{2}{4} = \frac{1}{2}.$$

I tre risultati di d'Alembert esistono, ma non sono equiprobabili: «una testa e una croce» si può ottenere in due modi, gli altri in uno solo. Basta lanciare due monete qualche centinaio di volte per vedere che la frequenza si avvicina a $1/2$, non a $1/3$.

Un esempio completo: i punteggi del poker

Il poker «all'italiana» si gioca con un mazzo ridotto: le carte dal 7 all'asso, cioè 8 valori (7, 8, 9, 10, J, Q, K, A) per 4 semi, per un totale di $8 \times 4 = 32$ carte. Un giocatore riceve 5 carte, estratte senza reinserimento.

7	8	9	10	J	Q	K	A
7♡	8♡	9♡	10♡	J♡	Q♡	K♡	A♡
7♢	8♢	9♢	10♢	J♢	Q♢	K♢	A♢
7♣	8♣	9♣	10♣	J♣	Q♣	K♣	A♣
7♠	8♠	9♠	10♠	J♠	Q♠	K♠	A♠

In giallo una mano con una **coppia d'assi**: $A♡$, $A♠$, $7♢$, $9♣$, $K♡$.

Figura 3.2: *Il mazzo da 32 carte: 8 valori per 4 semi (cuori, quadri, fiori, picche).*

In tutti i calcoli lo spazio campione è l'insieme delle **cinquine** di carte distinte, in cui l'ordine non conta: sono i sottoinsiemi di 5 carte di un insieme di 32. Se il mazzo è ben mescolato, sono tutti equiprobabili, e

$$|\Omega| = \binom{32}{5} = \frac{32!}{5!\,27!} = \frac{32 \cdot 31 \cdot 30 \cdot 29 \cdot 28}{5 \cdot 4 \cdot 3 \cdot 2} = 201\,376.$$

Ogni probabilità sarà quindi un rapporto con denominatore 201 376: tutto il lavoro sta nel contare il numeratore.

Coppia d'assi e coppia qualsiasi

Esempio 3.2 — Due assi (anche con punteggi più alti)

Sia C_2 l'evento «nella mano ci sono esattamente due assi». Una cinquina di C_2 si costruisce in due passi: si mettono i 4 assi del mazzo su 2 posti ($\binom{4}{2}$ modi) e si sceglie una terna fra le $32 - 4 = 28$ carte che non sono assi ($\binom{28}{3}$ modi). Per il principio fondamentale:

$$|C_2| = \binom{4}{2}\binom{28}{3} = \frac{4!}{2!\,2!} \cdot \frac{28!}{3!\,25!} = 6 \cdot 3\,276 = 19\,656, \qquad P(C_2) = \frac{|C_2|}{|\Omega|} = \frac{19\,656}{201\,376} \approx 0{,}0976.$$

Così però si contano anche mani migliori di una semplice coppia d'assi: il *full* (due assi e tre carte uguali fra loro) e la *doppia coppia* (due assi e un'altra coppia), perché nella terna le carte possono avere lo stesso valore.

Esempio 3.3 — Solo una coppia d'assi

Per escludere i punteggi più alti, le tre carte che non sono assi devono avere tre valori **diversi**. Restano ferme le posizioni dei due assi ($\binom{4}{2}$ modi); poi:

- la terza carta può essere una qualsiasi delle 28 che non sono assi;
- la quarta può essere solo una delle 24 che hanno un valore diverso dalla terza: delle 27 carte non-asso rimaste si tolgono le 3 dello stesso valore della terza;
- la quinta, per lo stesso motivo, solo una delle 20 con valore diverso dalle due precedenti.

In questo modo le tre carte vengono scelte *in ordine*, mentre nella mano l'ordine non conta: ogni terna è stata contata 3! = 6 volte, e bisogna dividere.

$$\left|C_2'\right| = \binom{4}{2} \cdot \frac{28 \cdot 24 \cdot 20}{3!} = \frac{4 \cdot 3}{2} \cdot \frac{28 \cdot 24 \cdot 20}{6} = 28 \cdot 24 \cdot 20 = 13\,440, \qquad P(C_2') = \frac{13\,440}{201\,376} \approx 0{,}067.$$

Verifica con un altro conteggio. Le tre carte non-asso si possono scegliere anche così: prima i tre valori diversi fra i 7 valori che non sono l'asso ($\binom{7}{3} = 35$ modi), poi il seme di ciascuna ($4^3 = 64$ modi). Si ottiene $35 \cdot 64 = 2\,240$ terne, e $6 \cdot 2\,240 = 13\,440$: lo stesso numero.

Se la coppia può essere di qualsiasi valore, la probabilità precedente va moltiplicata per 8: le coppie di 7 (quattro sette su due posti), di 8, …, di re si contano esattamente come quella d'assi, e i valori sono otto. La probabilità di avere una coppia (e niente di meglio) è circa $8 \cdot 0{,}067 \approx 0{,}53$: più di una mano su due.

Almeno tre assi, tris, colore

Esempio 3.4 — Almeno tre assi

L'evento C_3 = «almeno tre assi» è l'unione di due eventi incompatibili: «esattamente tre assi» (i 4 assi su 3 posti, le altre 2 carte fra le 28 non-asso) ed «esattamente quattro assi» (i 4 assi su 4 posti, l'ultima carta fra le 28). Siccome non hanno mani in comune, si sommano:

$$|C_3| = \binom{4}{3}\binom{28}{2} + \binom{4}{4}\binom{28}{1} = 4 \cdot 378 + 1 \cdot 28 = 1\,540, \qquad P(C_3) = \frac{1\,540}{201\,376} \approx 0{,}0076.$$

Esempio 3.5 — Un tris qualsiasi

Sia C_3' l'evento «un tris, con le altre due carte diverse» (quindi non un full e non un poker). Indichiamo con $C_3'(7)$ le mani con esattamente un tris di 7. I tris di 8, 9, …, assi si contano allo stesso modo, quindi $\left|C_3'\right| = 8\ \left|C_3'(7)\right|$.

Per $C_3'(7)$: tre posizioni sono occupate da un 7, e i tre 7 si scelgono fra i quattro in $\binom{4}{3} = \frac{4!}{3!\,1!} = 4$ modi; la quarta carta si sceglie fra le 28 che non sono 7, la quinta fra le 24 di valore diverso dai 7 e dalla quarta. Le ultime due sono state scelte in ordine, quindi si divide per 2! = 2:

$$\left|C_3'(7)\right| = 4 \cdot \frac{28 \cdot 24}{2} = 1\,344, \qquad P(C_3') = 8 \cdot \frac{1\,344}{201\,376} = 8 \cdot 0{,}006674 \approx 0{,}0534.$$

Esempio 3.6 — Colore

Sia C_p l'evento «colore di picche», cioè cinque carte di picche. Ci sono 8 carte di picche da distribuire su 5 posti, con ordine inessenziale:

$$|C_p| = \binom{8}{5} = \frac{8 \cdot 7 \cdot 6}{3!} = 56, \qquad P(C_p) = \frac{56}{201\,376} \approx 0{,}00028.$$

(Si è usata la simmetria $\binom{8}{5} = \binom{8}{3}$.) La probabilità di un colore qualsiasi è $4 \cdot P(C_p) \approx 0{,}0011$. Questo conteggio include però le **scale reali**, cioè le cinque carte consecutive dello stesso seme, che valgono di più. Per ogni seme ce ne sono 5, dalla minima $(A, 7, 8, 9, 10$, con l'asso che vale come carta più bassa) alla massima $(10, J, Q, K, A)$. Togliendole:

$$|C_p| = 56 - 5 = 51, \qquad P(C_p) = \frac{51}{201\,376} \approx 0{,}00025,$$

e la probabilità di un colore qualsiasi senza scale reali è $4 \cdot 0{,}00025 \approx 0{,}001$.

Mano	Casi favorevoli	Probabilità
una coppia (e niente di meglio)	$8 \cdot 13\,440 = 107\,520$	0,534
tris (non full né poker)	$8 \cdot 1\,344 = 10\,752$	0,053
almeno tre assi	1 540	0,0076
colore (senza scale reali)	$4 \cdot 51 = 204$	0,001

Tabella 3.1: *Alcune mani del poker con 32 carte, su* $|\Omega| = 201\,376$ *mani possibili. Nel poker vale di più la mano più rara: un colore è circa cinquanta volte più raro di un tris.*

Quando i risultati non sono equiprobabili

Togliamo ora l'ipotesi che gli eventi elementari siano equiprobabili. Sia Ω uno spazio campione discreto (finito o numerabile). La definizione di probabilità data prima vale ancora:

a) $A \subseteq \Omega$ è un evento e si conducono n esperimenti;

b) $n_A = n_A(n)$ è il numero di volte in cui A si verifica;

c) frequenza relativa e probabilità sono

$$f_n(A) = \frac{n_A}{n}, \qquad P(A) = \lim_{n\to\infty} f_n(A) = \lim_{n\to\infty} \frac{n_A}{n}.$$

La differenza con il caso precedente è che ora **non** è più vero, in generale, che $n_A \simeq n\,|A| \,/\, |\Omega|$. Quando gli eventi elementari non sono equiprobabili, un evento ha una «misura» diversa da quella ordinaria, data dal numero dei suoi elementi: due eventi con lo stesso numero di elementi ($|A| = |B|$) possono avere pesi diversi, e le tecniche di conteggio non bastano più a calcolare le probabilità.

Esempio 3.7 — Un dado truccato

Un dado è truccato in modo che il risultato 1 esca **5 volte su 6**; le altre cinque facce sono ugualmente probabili fra loro. Si lancia una volta, quindi $\Omega = \{1,2,3,4,5,6\}$. Siano $A = \{2,4,6\}$ (pari) e $B = \{1,3,5\}$ (dispari): hanno entrambi 3 elementi.

Se n_i è il numero di volte (su n prove) in cui esce la faccia i, il trucco dice che l'1 esce cinque volte più spesso di tutte le altre facce messe insieme:

$$\sum_{i=1}^{6} n_i = n, \qquad n_1 \simeq 5 \sum_{i=2}^{6} n_i \quad \Longrightarrow \quad f_n(1) = \frac{n_1}{n} \simeq 5 \sum_{i=2}^{6} f_n(i).$$

Le frequenze di tutte le facce sommano a 1 (dividendo la prima uguaglianza per n), quindi

$$f_n(1) + \sum_{i=2}^{6} f_n(i) = 1 \quad \Longrightarrow \quad f_n(1) + \frac{1}{5} f_n(1) = f_n(1)\left(1 + \frac{1}{5}\right) = 1 \quad \Longrightarrow \quad f_n(1) \simeq \frac{5}{6}.$$

Il restante $1 - \frac{5}{6} = \frac{1}{6}$ si divide in parti uguali fra le altre cinque facce: $f_n(2) = f_n(3) = \cdots = f_n(6) \simeq \dfrac{1 - 5/6}{5} = \dfrac{1}{30}$. Passando al limite:

$$P(1) = \frac{5}{6}, \qquad P(i) = \frac{1}{30} \quad i = 2,3,4,5,6.$$

Gli eventi A e B si verificano quando esce una delle loro facce, quindi le frequenze si sommano:

$$f_n(A) = \frac{n_2 + n_4 + n_6}{n} = f_n(2) + f_n(4) + f_n(6) \longrightarrow \frac{3}{30} = \frac{1}{10},$$

$$f_n(B) = \frac{n_1 + n_3 + n_5}{n} = f_n(1) + f_n(3) + f_n(5) \longrightarrow \frac{5}{6} + \frac{2}{30} = \frac{9}{10}.$$

In questo caso $P(B)$ ha una misura molto maggiore di $P(A)$, nove volte superiore, anche se i due eventi hanno lo stesso numero di elementi.

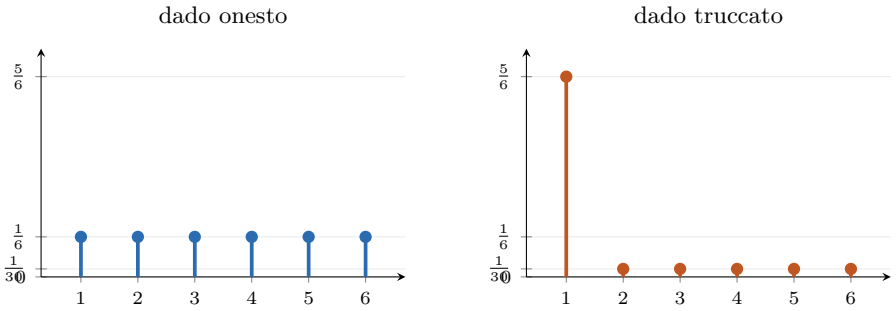


Figura 3.3: *Le probabilità delle sei facce. Nel dado onesto si distribuiscono in parti uguali; in quello truccato quasi tutta la probabilità sta sull'1.*

LE PROPRIETÀ DELLA PROBABILITÀ

Le frequenze relative obbediscono a regole semplicissime, che si ricavano contando. Passando al limite, le stesse regole valgono per le probabilità. Per «passare al limite» serve sapere come si comportano i limiti con le operazioni.

Richiamo di matematica: le regole dei limiti

Se due successioni hanno limite, $a_n \to a$ e $b_n \to b$, allora:

$$a_n + b_n \to a + b, \qquad a_n - b_n \to a - b, \qquad c \cdot a_n \to c \cdot a \ \ (c \text{ costante}), \qquad a_n \cdot b_n \to a \cdot b,$$

e, se $b \neq 0$, anche $a_n / b_n \to a/b$. In parole: il limite di una somma è la somma dei limiti, e così via. Inoltre una successione costante ($a_n = c$ per ogni n) tende a c. Infine, se due successioni sono sempre uguali, hanno lo stesso limite: un'uguaglianza fra frequenze, vera per ogni n, diventa un'uguaglianza fra probabilità.

Siano A e B due eventi, n_A e n_B i loro numeri di occorrenze su n prove e $f_n(A)$, $f_n(B)$ le frequenze relative (entrambe ≥ 0, chiaramente).

Teorema 3.1 — Proprietà della frequenza e della probabilità

Per due eventi qualsiasi A e B:

a) **eventi complementari**: $P(\overline{A}) = 1 - P(A)$;
b) **unione**: $P(A \cup B) = P(A) + P(B) - P(A \cap B)$;
c) **differenza**: $P(A \setminus B) = P(A) - P(A \cap B)$;
d) **evento certo e impossibile**: $P(\Omega) = 1$ e $P(\varnothing) = 0$.

Inoltre $0 \leq P(A) \leq 1$ per ogni evento A.

Dimostrazione

Passo 1 — Complementare. In ogni prova o si verifica A o si verifica $\overline{A}$, mai entrambi: le prove in cui si verifica $\overline{A}$ sono tutte le altre, $n - n_A$. Quindi

$$f_n(\overline{A}) = \frac{n - n_A}{n} = 1 - f_n(A) \quad \Longrightarrow \quad P(\overline{A}) = 1 - P(A).$$

Passo 2 — Unione. Se si sommano n_A e n_B, le prove in cui si sono verificati *entrambi* gli eventi (quelle di $A \cap B$) vengono contate due volte, una in n_A e una in n_B. Per contarle una volta sola bisogna toglierle una volta:

$$f_n(A \cup B) = \frac{n_{A\cup B}}{n} = \frac{n_A + n_B - n_{A\cap B}}{n} = f_n(A) + f_n(B) - f_n(A \cap B)$$

e, passando al limite, $P(A \cup B) = P(A) + P(B) - P(A \cap B)$.

Passo 3 — Differenza. Perché si verifichi A ma non B, dalle n_A prove in cui si verifica A vanno tolte quelle in cui si verificano entrambi:

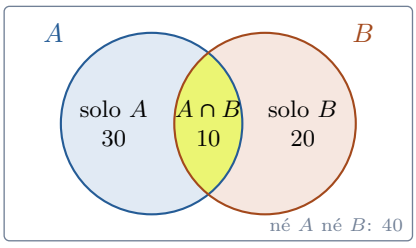
$$f_n(A \setminus B) = f_n(A \cap \overline{B}) = \frac{n_A - n_{A\cap B}}{n} = f_n(A) - f_n(A \cap B) \quad \Longrightarrow \quad P(A \setminus B) = P(A) - P(A \cap B).$$

Passo 4 — Certo e impossibile. Ω si verifica in tutte le prove, $\varnothing$ in nessuna:

$$f_n(\Omega) = \frac{n}{n} = 1 \implies P(\Omega) = 1, \qquad f_n(\varnothing) = \frac{0}{n} = 0 \implies P(\varnothing) = 0.$$

Passo 5 — Fra 0 e 1. Per ogni n vale $0 \leq n_A \leq n$, quindi $0 \leq f_n(A) \leq 1$, e il limite di numeri compresi fra 0 e 1 è ancora compreso fra 0 e 1.

■



Su $n = 100$ prove: A si è verificato $n_A = 30 + 10 = 40$ volte, B si è verificato $n_B = 10 + 20 = 30$ volte. Ma $A \cup B$ si è verificato $30+10+20 = 60$ volte, non $40 + 30 = 70$: le 10 prove di $A \cap B$ sono state contate due volte. Infatti $60 = 40 + 30 - 10$.

Figura 3.4: *Perché nell'unione si sottrae l'intersezione. In ogni regione è scritto quante volte si è verificata.*

La proprietà b) è nota anche come **sub-additività**: siccome $P(A \cap B) \geq 0$, ne segue $P(A \cup B) \leq P(A) + P(B)$, con il segno di uguale esattamente quando $P(A \cap B) = 0$, per esempio se A e B sono **incompatibili**. Per gli eventi incompatibili, quindi, **le probabilità si sommano**.

Esempio 3.8 — L'unione e il complementare al lavoro

- Un dado onesto: la probabilità di ottenere un numero pari *oppure* almeno 5 è

$$P(\{2,4,6\} \cup \{5,6\}) = \frac{3}{6} + \frac{2}{6} - \frac{1}{6} = \frac{4}{6} = \frac{2}{3},$$

  dove si toglie $P(\{6\}) = 1/6$ perché il 6 è sia pari sia almeno 5. In effetti l'unione è $\{2,4,5,6\}$.

- Due lanci di un dado: «almeno un 6» è l'unione di «6 al primo lancio» e «6 al secondo», che si verificano insieme solo con (6,6):

$$P(\text{almeno un 6}) = \frac{6}{36} + \frac{6}{36} - \frac{1}{36} = \frac{11}{36},$$

  lo stesso numero trovato contando le caselle nel capitolo precedente. Ancora più rapido è passare al complementare: «nessun 6» vuol dire 5 possibilità per ogni lancio, $5 \cdot 5 = 25$ coppie, e $P(\text{almeno un 6}) = 1 - \frac{25}{36} = \frac{11}{36}$.

Il trucco del complementare

Quando un evento contiene la parola «almeno», spesso conviene calcolare la probabilità del suo complementare, che contiene la parola «nessuno», e sottrarla da 1. Con dieci lanci di un dado, per esempio, «almeno un 6» richiederebbe di considerare un 6, due 6, …, dieci 6; «nessun 6» invece è un solo conto: 5^{10} sequenze su 6^{10}, e $P(\text{almeno un 6}) = 1 - (5/6)^{10} \approx 0{,}84$.

Probabilità condizionata

Spesso si ha un'informazione parziale sul risultato: «è uscito un numero pari», «il pacchetto è arrivato in ritardo». Come cambia la probabilità degli altri eventi, sapendo questo?

Siano A e B due eventi che, in n esperimenti, si verificano n_A e n_B volte ($n_B > 0$). Definiamo la **frequenza di A condizionata a B**, $f_n(A \mid B)$, come il rapporto fra il numero di volte in cui si verificano *entrambi* ($n_{A\cap B}$) e il numero di volte in cui si verifica B:

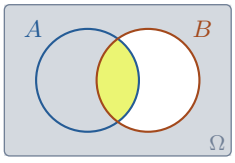
$$f_n(A \mid B) = \frac{n_{A\cap B}}{n_B} = \frac{n_{A\cap B}}{n} \cdot \frac{n}{n_B} = \frac{f_n(A \cap B)}{f_n(B)}.$$

In altre parole, **restringiamo il nostro campione** (il nostro «mondo») ai soli n_B esperimenti in cui si è verificato B, e fra questi guardiamo in quanti si è verificato anche A. Passando al limite (il rapporto dei limiti si può fare perché $P(B) > 0$):

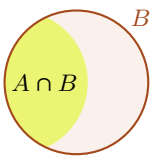
Probabilità condizionata

Se $P(B) > 0$, la **probabilità di A condizionata a B** (o «di A dato B») è

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}.$$



si scarta tutto ciò che sta fuori da B



sapendo che è successo B: il nuovo mondo è B, e di A resta solo $A \cap B$

Figura 3.5: *La probabilità condizionata: si scarta tutto ciò che sta fuori da B (in grigio) e si misura quanta parte di B è occupata da A.*

Esempio 3.9 — Condizionare un dado

Si lancia un dado onesto.

- Sapendo che è uscito un numero pari, qual è la probabilità che sia il 6?

$$P(\{6\} \mid \text{pari}) = \frac{P(\{6\} \cap \{2,4,6\})}{P(\{2,4,6\})} = \frac{1/6}{3/6} = \frac{1}{3}.$$

  Ha senso: fra i tre pari, il 6 è uno.

- Sapendo che è uscito un numero non superiore a 3, qual è la probabilità che sia dispari?

$$P(\text{dispari} \mid \{1,2,3\}) = \frac{P(\{1,3\})}{P(\{1,2,3\})} = \frac{2/6}{3/6} = \frac{2}{3}.$$

- Viceversa $P(\text{pari} \mid \{6\}) = 1$: se è uscito 6, è certamente uscito un pari. Il condizionamento **non è simmetrico**: $P(A \mid B)$ e $P(B \mid A)$ sono, in generale, numeri diversi.

La legge della probabilità composta

Scambiando i ruoli di A e B, la stessa definizione dà

$$P(B \mid A) = \frac{P(A \cap B)}{P(A)}, \qquad P(A) > 0.$$

Moltiplicando ciascuna delle due definizioni per il suo denominatore si ottiene una formula per l'intersezione.

Da ricordare: legge della probabilità composta

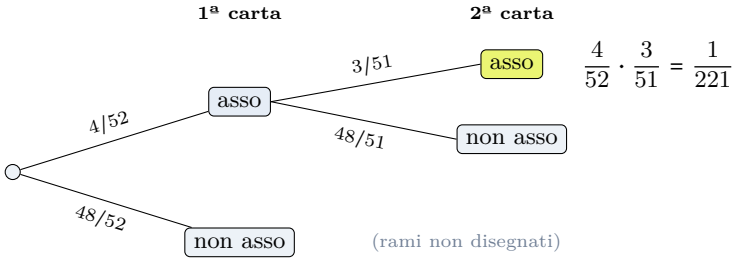
$$P(A \cap B) = P(B \mid A)\,P(A) = P(A \mid B)\,P(B)$$

È utilissima quando un esperimento avviene **in due tempi**: la probabilità che succedano entrambe le cose è la probabilità della prima, moltiplicata per la probabilità della seconda *sapendo* che la prima è successa.

Esempio 3.10 — Due assi di fila

Da un mazzo di 52 carte se ne estraggono due, senza reinserimento. Qual è la probabilità che siano due assi? Siano A_1 = «la prima è un asso» e A_2 = «la seconda è un asso». Alla prima estrazione gli assi sono 4 su 52; se la prima è stata un asso, alla seconda restano 3 assi su 51 carte:

$$P(A_1 \cap A_2) = P(A_1)\,P(A_2 \mid A_1) = \frac{4}{52} \cdot \frac{3}{51} = \frac{12}{2\,652} = \frac{1}{221} \approx 0{,}0045.$$



Lo stesso risultato si ottiene contando: le coppie di assi sono $\binom{4}{2} = 6$ su $\binom{52}{2} = 1\,326$ coppie possibili, e $6/1\,326 = 1/221$. Nell'albero la probabilità di un percorso è il prodotto delle probabilità dei suoi rami: è la legge della probabilità composta disegnata.

La legge della probabilità totale

Un'importante conseguenza della probabilità condizionata permette di calcolare la probabilità di un evento «spezzandolo» in casi.

Partizione

Gli eventi $E_1, E_2, \ldots, E_M$, cioè $\{E_i\}_{i=1}^{M}$, formano una **partizione** di Ω se **coprono** tutto Ω e sono **a due a due incompatibili**:

$$\bigcup_{i=1}^{M} E_i = \Omega, \qquad E_i \cap E_j = \varnothing \quad \text{per } i \neq j.$$

In ogni prova si verifica uno e un solo E_i: sono i «casi» in cui si divide il mondo.

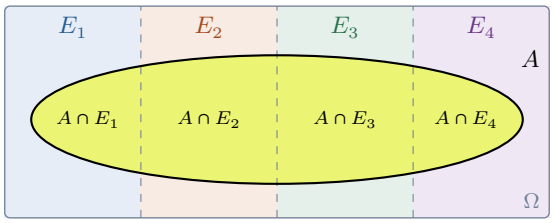


Figura 3.6: *Una partizione di Ω in quattro casi. L'evento A viene tagliato in quattro pezzi $A \cap E_i$, che non si sovrappongono: la probabilità di A è la somma delle probabilità dei pezzi.*

Teorema 3.2 — Legge della probabilità totale

Se $\{E_i\}_{i=1}^{M}$ è una partizione di Ω e $A \subseteq \Omega$ è un evento qualsiasi, allora

$$P(A) = \sum_{i=1}^{M} P(A \cap E_i) = \sum_{i=1}^{M} P(A \mid E_i)\, P(E_i).$$

Dimostrazione

Passo 1 — Si «ritaglia» A con la partizione. A è contenuto in Ω, quindi $A = A \cap \Omega$; e Ω è l'unione degli E_i. Per la proprietà distributiva (Teorema 1.4):

$$P(A) = P(A \cap \Omega) = P\left(A \cap \bigcup_{i=1}^{M} E_i\right) = P\left(\bigcup_{i=1}^{M} (A \cap E_i)\right).$$

Passo 2 — I pezzi non si sovrappongono. Siccome $E_i \cap E_j = \varnothing$ per $i \neq j$, anche i pezzi di A sono incompatibili: $(A \cap E_i) \cap (A \cap E_j) \subseteq E_i \cap E_j = \varnothing$.

Passo 3 — Si sommano le probabilità. Per eventi incompatibili la probabilità dell'unione è la somma delle probabilità (proprietà b) con $P(A \cap B) = 0$, applicata un pezzo alla volta):

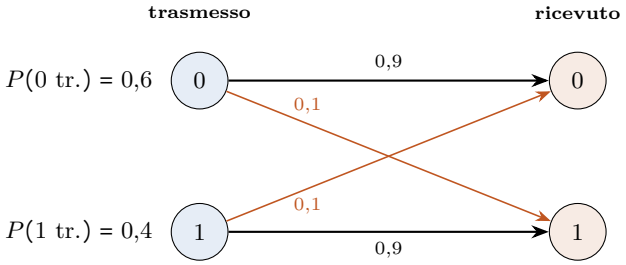
$$P(A) = \sum_{i=1}^{M} P(A \cap E_i).$$

Passo 4 — Si usa la probabilità composta. Ogni pezzo si riscrive come $P(A \cap E_i) = P(A \mid E_i)\, P(E_i)$, e si ottiene la seconda forma.

■

Esempio 3.11 — Un canale binario

Una sorgente trasmette il bit 0 con probabilità 0,6 e il bit 1 con probabilità 0,4. Il canale è rumoroso: qualunque bit venga trasmesso, con probabilità 0,1 arriva invertito. Qual è la probabilità di ricevere un 1?



I due casi «è stato trasmesso 0» ed «è stato trasmesso 1» formano una partizione. Per la legge della probabilità totale:

$$P(1\text{ ric.}) = P(1\text{ ric.} \mid 0\text{ tr.})\,P(0\text{ tr.}) + P(1\text{ ric.} \mid 1\text{ tr.})\,P(1\text{ tr.}) = 0{,}1 \cdot 0{,}6 + 0{,}9 \cdot 0{,}4 = 0{,}06 + 0{,}36 = 0{,}42.$$

Un 1 si può ricevere in due modi: perché è stato trasmesso 1 ed è arrivato giusto, oppure perché è stato trasmesso 0 ed è stato invertito. La legge somma i due modi, ciascuno pesato con la probabilità del suo caso. Nel prossimo capitolo ci chiederemo il contrario: *ricevuto* un 1, qual è la probabilità che sia stato *trasmesso* un 1?

Eventi indipendenti

Due eventi A e B si dicono **indipendenti** quando il verificarsi di uno non ha alcuna influenza sul verificarsi o meno dell'altro. Con le frequenze: sapere che si è verificato B non cambia la frequenza di A, e viceversa,

$$f_n(A \mid B) \simeq f_n(A) \qquad \text{e} \qquad f_n(B \mid A) \simeq f_n(B).$$

Usando la legge della probabilità composta, in questo caso

$$f_n(A \cap B) = f_n(A)\,f_n(B \mid A) = f_n(B)\,f_n(A \mid B) \simeq f_n(A)\,f_n(B),$$

e passando al limite si arriva alla definizione.

Eventi indipendenti

Due eventi A e B sono **indipendenti** se (e solo se)

$$P(A \cap B) = P(A)\,P(B).$$

Teorema 3.3 — Indipendenza e probabilità condizionata

Se $P(B) > 0$, gli eventi A e B sono indipendenti se e solo se $P(A \mid B) = P(A)$. Allo stesso modo, se $P(A) > 0$, sono indipendenti se e solo se $P(B \mid A) = P(B)$.

Dimostrazione

Passo 1 — Da indipendenti a condizionata. Se $P(A \cap B) = P(A)\,P(B)$, allora

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} = \frac{P(A)\,P(B)}{P(B)} = P(A).$$

Passo 2 — Da condizionata a indipendenti. Se $P(A \mid B) = P(A)$, per la probabilità composta $P(A \cap B) = P(A \mid B)\,P(B) = P(A)\,P(B)$.

Passo 3 — Scambiando i ruoli. Lo stesso ragionamento, con A e B scambiati, vale per $P(B \mid A)$.

■

La forma con il prodotto è preferibile come definizione perché è simmetrica e funziona anche quando una delle due probabilità è nulla (la probabilità condizionata a un evento di probabilità zero non è definita).

Esempio 3.12 — Due lanci di un dado

I due lanci di un dado onesto sono indipendenti: il primo non può influenzare il secondo. Per ogni coppia (i, j):

$$P(\{(i,j)\}) = P(\text{primo} = i)\,P(\text{secondo} = j) = \frac{1}{6} \cdot \frac{1}{6} = \frac{1}{36},$$

che è proprio la probabilità di ciascuna delle 36 coppie equiprobabili del capitolo precedente. Allo stesso modo

$$P(\text{primo pari e secondo} = 6) = \frac{1}{2} \cdot \frac{1}{6} = \frac{1}{12},$$

e in effetti le coppie favorevoli sono (2,6), (4,6), (6,6), cioè 3 su 36.

Esempio 3.13 — Indipendenti anche senza «separazione fisica»

In un **solo** lancio di un dado onesto, siano $A = \{2, 4, 6\}$ (pari) e $B = \{1, 2\}$ (non più di 2). Allora $A \cap B = \{2\}$ e

$$P(A \cap B) = \frac{1}{6} = \frac{1}{2} \cdot \frac{1}{3} = P(A)\,P(B)\,:$$

i due eventi sono indipendenti. Sapere che è uscito 1 o 2 non cambia la probabilità che sia uscito un pari: è $1/2$ prima ed è $1/2$ dopo (uno dei due casi rimasti è pari). L'indipendenza è una proprietà dei *numeri*, non solo della «fisica» dell'esperimento.

Indipendenti non vuol dire incompatibili

È un errore molto comune confondere le due parole, che dicono quasi il contrario. Se A e B sono **incompatibili** ($A \cap B = \varnothing$) e hanno entrambi probabilità positiva, allora $P(A \cap B) = 0 \neq P(A)\,P(B)$: sono **dipendenti**, e in modo fortissimo, perché se si verifica uno sicuramente l'altro non si verifica. Testa e croce nello stesso lancio sono incompatibili; testa al primo lancio e testa al secondo sono indipendenti.

In sintesi

- La **probabilità** di un evento è il limite della sua frequenza relativa: $P(A) = \lim_{n\to\infty} n_A/n$. Se gli eventi elementari sono equiprobabili, $P(A) = |A| \,/\, |\Omega|$ (casi favorevoli su casi possibili), purché i casi contati siano davvero equiprobabili.
- Se non lo sono, eventi con lo stesso numero di elementi possono avere probabilità diverse (dado truccato).
- Regole: $P(\overline{A}) = 1 - P(A)$; $P(A \cup B) = P(A) + P(B) - P(A \cap B)$; $P(A \setminus B) = P(A) - P(A \cap B)$; $P(\Omega) = 1$, $P(\varnothing) = 0$; per eventi incompatibili le probabilità si sommano.
- Probabilità condizionata: $P(A \mid B) = P(A \cap B)/P(B)$, cioè si restringe il mondo a B. Probabilità composta: $P(A \cap B) = P(B \mid A)\, P(A) = P(A \mid B)\, P(B)$.
- Probabilità totale: se gli E_i formano una partizione, $P(A) = \sum_i P(A \mid E_i)\, P(E_i)$.
- A e B sono indipendenti se $P(A \cap B) = P(A)\, P(B)$, cioè se sapere che uno si è verificato non cambia la probabilità dell'altro. Indipendenti non vuol dire incompatibili.

L'APPROCCIO ASSIOMATICO

La definizione frequentista ha un grande pregio: dice che cosa *significa* una probabilità, e da lì abbiamo ricavato tutte le regole di calcolo. Ha però anche dei limiti. Richiede di ripetere l'esperimento infinite volte, cosa che nessuno può fare; la frequenza non è una successione fissata, ma cambia da una serie di prove all'altra; e ci sono eventi che non si possono ripetere affatto («domani pioverà», «questo disco si guasterà entro un anno»).

Nel 1933 il matematico russo Andrej Kolmogorov propose una strada diversa, che è quella usata ancora oggi. Invece di dire che cosa *è* la probabilità, si elencano poche **regole** (gli **assiomi**) che una probabilità deve rispettare, scelte in modo che le frequenze le rispettino. Tutto il resto si **dimostra** a partire da quelle regole. Le formule sono le stesse del capitolo precedente, ma ora poggiano su basi solide. Prima degli assiomi, però, bisogna stabilire con precisione **quali** sottoinsiemi di Ω hanno diritto a una probabilità.

ALGEBRE DI EVENTI

Le operazioni fra eventi (unione, complementare, intersezione) devono produrre ancora eventi: se sappiamo calcolare la probabilità di A e di B, vogliamo poter calcolare anche quella di «A oppure B» e di «non A». La famiglia degli eventi deve quindi essere **chiusa** rispetto a queste operazioni: applicandole, non se ne deve uscire.

Algebra di eventi

Si consideri una famiglia $\mathcal{E}$ di sottoinsiemi di Ω (non vuota). $\mathcal{E}$ si chiama **algebra** di sottoinsiemi di Ω, o **algebra di eventi**, se gode di due proprietà:

a) è **chiusa rispetto all'unione**: se $A_1, A_2 \in \mathcal{E}$, allora $A_1 \cup A_2 \in \mathcal{E}$;
b) è **chiusa rispetto alla complementazione**: se $A_1 \in \mathcal{E}$, allora $\overline{A_1} \in \mathcal{E}$.

Quando lo spazio è infinito (come i pacchetti in coda al router, $\Omega = \mathbb{N}_0$) ci servono anche unioni di **infiniti** eventi. Per esempio «il numero di pacchetti è pari» è l'unione degli infiniti eventi elementari $\{0\}, \{2\}, \{4\}, \ldots$

Richiamo di matematica: l'unione di infiniti insiemi

Data una successione di insiemi $B_1, B_2, B_3, \ldots$ (una famiglia *numerabile*: uno per ogni naturale), la loro unione

$$\bigcup_{n=1}^{\infty} B_n = B_1 \cup B_2 \cup B_3 \cup \cdots$$

è l'insieme degli elementi che stanno in **almeno uno** dei B_n. Il simbolo ∞ in alto non è un numero: dice solo che l'indice non si ferma mai. Per esempio, con $B_n = \{2n\}$:

$$\bigcup_{n=0}^{\infty} \{2n\} = \{0\} \cup \{2\} \cup \{4\} \cup \cdots = \{0, 2, 4, 6, \ldots\},$$

l'insieme dei numeri pari. Allo stesso modo $\bigcap_{n=1}^{\infty} B_n$ contiene gli elementi che stanno in **tutti** i B_n.

Sigma-algebra

Un'algebra $\mathcal{E}$ è una **σ-algebra** se, oltre a essere chiusa rispetto alla complementazione e all'unione, è chiusa anche rispetto all'unione di una infinità numerabile di suoi elementi:

$$B_1, B_2, B_3, \ldots \in \mathcal{E} \quad \Longrightarrow \quad \bigcup_{n=1}^{\infty} B_n \in \mathcal{E}.$$

La lettera greca σ (*sigma* minuscola) ricorda la «S» di somma: nella tradizione matematica segnala che l'operazione si può ripetere un'infinità numerabile di volte. Negli spazi finiti la distinzione non conta (le unioni di infiniti eventi si riducono a unioni di un numero finito di eventi diversi), quindi ogni algebra è anche una σ-algebra.

LE PROPRIETÀ DELLE ALGEBRE

Dalle due sole proprietà della definizione seguono tutte le altre: un'algebra è chiusa anche rispetto all'intersezione e alla differenza, e contiene sempre Ω e $\varnothing$.

Teorema 4.1 — Proprietà delle algebre

Sia $\mathcal{E}$ un'algebra di eventi e siano $A, B \in \mathcal{E}$. Allora:

a) $A \cap B \in \mathcal{E}$ (chiusura rispetto all'intersezione);
b) $A \setminus B \in \mathcal{E}$ (chiusura rispetto alla differenza);
c) $\Omega \in \mathcal{E}$ e $\varnothing \in \mathcal{E}$.

Dimostrazione

Passo 1 — Intersezione, con De Morgan. Per la seconda legge di De Morgan $\overline{A \cap B} = \overline{A} \cup \overline{B}$; facendo il complementare di entrambi i membri:

$$A \cap B = \overline{\overline{A} \cup \overline{B}}.$$

Ora si costruisce il secondo membro un passo alla volta, restando sempre dentro $\mathcal{E}$: A e B stanno in $\mathcal{E}$, quindi anche $\overline{A}$ e $\overline{B}$ (chiusura rispetto al complementare); allora anche la loro unione $\overline{A} \cup \overline{B}$ (chiusura rispetto all'unione); e infine anche il complementare dell'unione, che è $A \cap B$.

Passo 2 — Differenza. Per il Teorema 1.1, $A \setminus B = A \cap \overline{B}$. Siccome $B \in \mathcal{E}$, anche $\overline{B} \in \mathcal{E}$; e l'intersezione di due elementi di $\mathcal{E}$ sta in $\mathcal{E}$ per il passo precedente.

Passo 3 — Ω e $\varnothing$. $\mathcal{E}$ non è vuota, quindi contiene almeno un evento A, e con esso $\overline{A}$. Allora contiene $A \cup \overline{A} = \Omega$ e il suo complementare $\overline{\Omega} = \varnothing$.

■

Teorema 4.2 — La più piccola algebra che contiene un evento

Se A è un evento qualsiasi, la più piccola algebra che contiene A è

$$\mathcal{E} = \left\{A, \overline{A}, \Omega, \varnothing\right\}.$$

Dimostrazione

Passo 1 — Quei quattro insiemi devono esserci. Un'algebra che contiene A contiene $\overline{A}$, per la chiusura rispetto al complementare; contiene $A \cup \overline{A} = \Omega$, per la chiusura rispetto all'unione; e contiene $\varnothing = \overline{\Omega}$, di nuovo per la chiusura rispetto al complementare. Quindi ogni algebra che contiene A contiene almeno i quattro insiemi.

Passo 2 — E bastano. Resta da verificare che i quattro insiemi formano già un'algebra, senza bisogno di aggiungerne altri. I complementari restano dentro: $A \leftrightarrow \overline{A}$ e $\Omega \leftrightarrow \varnothing$. Le unioni pure:

$\cup$	A	$\overline{A}$	Ω	$\varnothing$
A	A	Ω	Ω	A
$\overline{A}$	Ω	$\overline{A}$	Ω	$\overline{A}$
Ω	Ω	Ω	Ω	Ω
$\varnothing$	A	$\overline{A}$	Ω	$\varnothing$

Ogni casella della tabella è uno dei quattro insiemi: la famiglia è chiusa rispetto all'unione e al complementare, cioè è un'algebra.

■

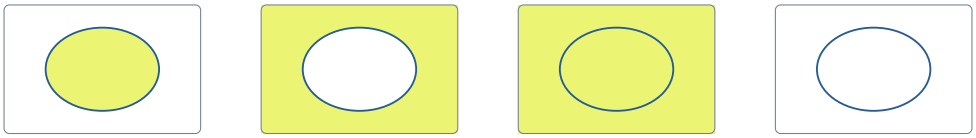


Figura 4.1: *I quattro elementi della più piccola algebra che contiene A (in giallo l'insieme indicato sotto).*

Un'algebra è un «livello di informazione»

Si lancia un dado e un amico ci dice soltanto se il risultato è pari o dispari. Con questa informazione possiamo decidere se si è verificato {2,4,6}, {1,3,5}, Ω o $\varnothing$, ma non se si è verificato {6}: gli eventi che riusciamo a «vedere» sono proprio i quattro dell'algebra generata da $A = \{2, 4, 6\}$. Chi invece vede il dado può decidere su qualsiasi sottoinsieme di Ω: la sua algebra è l'insieme delle parti $\mathcal{P}(\Omega)$, con $2^6 = 64$ eventi. Più informazione vuol dire un'algebra più ricca.

Gli assiomi di Kolmogorov

Ora possiamo dire che cos'è una probabilità: una funzione che a ogni evento dell'algebra associa un numero fra 0 e 1, e che rispetta tre regole.

Legge di probabilità

Si definisce **legge di probabilità** una funzione con dominio $\mathcal{E}$ e codominio $[0, 1]$,

$$P : A \in \mathcal{E} \longmapsto P(A) \in [0, 1],$$

che soddisfi gli **assiomi di Kolmogorov**:

1) **non negatività**: $P(A) \geq 0$ per ogni $A \in \mathcal{E}$, in simboli $\forall A \in \mathcal{E}$;
2) **normalizzazione**: $P(\Omega) = 1$;
3) **additività**: se A e B sono incompatibili ($A \cap B = \varnothing$), allora $P(A \cup B) = P(A) + P(B)$;

3a) **numerabile additività**: se $\{B_n\}_{n\in\mathbb{N}}$ è una collezione numerabile di eventi a due a due incompatibili ($B_i \cap B_j = \varnothing$ per $i \neq j$), allora

$$P\left(\bigcup_{n=1}^{\infty} B_n\right) = \sum_{n=1}^{\infty} P(B_n).$$

Spazio di probabilità

La terna $(\Omega, \mathcal{E}, P)$, formata dallo spazio campione, da una σ-algebra di eventi e da una legge di probabilità, si chiama **spazio di probabilità**.

Il simbolo $\forall$ (una «A» capovolta, da *All*) si legge «per ogni»: «$P(A) \geq 0 \ \forall A \in \mathcal{E}$» vuol dire che la probabilità di qualsiasi evento è non negativa. L'assioma 3a parla di una somma di infiniti termini, che merita un richiamo.

Richiamo di matematica: le somme infinite (serie)

Che senso ha sommare infiniti numeri $a_1 + a_2 + a_3 + \cdots$? Si sommano i primi N termini, ottenendo le **somme parziali**

$$S_N = \sum_{n=1}^{N} a_n,$$

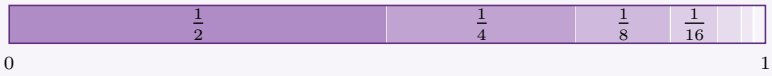
e si guarda dove va S_N quando N cresce. Se le somme parziali hanno un limite S, si dice che la **serie** converge e si scrive $\sum_{n=1}^{\infty} a_n = S$:

$$\sum_{n=1}^{\infty} a_n = \lim_{N \to \infty} \sum_{n=1}^{N} a_n.$$

L'esempio più famoso è la **serie geometrica** di ragione $\frac{1}{2}$:

$$\frac{1}{2} + \frac{1}{4} + \frac{1}{8} + \frac{1}{16} + \cdots = \sum_{n=1}^{\infty} \left(\frac{1}{2}\right)^n = 1.$$

Si vede con un disegno: si prende un segmento lungo 1, se ne colora la metà, poi la metà di quel che resta, poi ancora la metà di quel che resta… La parte colorata non supera mai il segmento, e quella che manca si dimezza a ogni passo: dopo N passi è colorato $S_N = 1 - (1/2)^N$, che tende a 1.



Una serie può anche *non* convergere: $1 + 1 + 1 + \cdots$ cresce senza limite. Quando tutti i termini sono ≥ 0, come le probabilità, la somma infinita o è un numero o è $+\infty$; l'assioma 3a dice in particolare che, per eventi incompatibili, è sempre un numero (non più grande di 1).

Esempio 4.1 — Aspettare la prima testa

Si lancia una moneta onesta finché non esce testa. Sia B_n l'evento «la prima testa esce al lancio n-esimo», cioè $n-1$ croci seguite da una testa. I lanci sono indipendenti, quindi

$$P(B_n) = \underbrace{\frac{1}{2} \cdot \frac{1}{2} \cdots \frac{1}{2}}_{n-1 \text{ croci}} \cdot \frac{1}{2} = \left(\frac{1}{2}\right)^n.$$

Gli eventi $B_1, B_2, \ldots$ sono incompatibili (la prima testa esce a un solo lancio) e la loro unione è «prima o poi esce testa». Per la numerabile additività:

$$P(\text{prima o poi esce testa}) = \sum_{n=1}^{\infty} P(B_n) = \sum_{n=1}^{\infty} \left(\frac{1}{2}\right)^n = 1.$$

Senza l'assioma 3a non potremmo fare questo conto: l'evento è l'unione di *infiniti* eventi, e l'additività semplice (assioma 3) parla solo di due alla volta.

Gli assiomi e le frequenze vanno d'accordo

Gli assiomi non sono stati scelti a caso: sono proprio le proprietà che abbiamo trovato per le frequenze nel capitolo precedente. La frequenza di un evento è ≥ 0, quella di Ω è 1, e se due eventi sono incompatibili il numero di prove in cui si verifica uno dei due è la somma dei due conteggi. Per questo la probabilità frequentista è una legge di probabilità nel senso di Kolmogorov, e tutto ciò che dimostreremo dagli assiomi vale anche per lei.

Come si costruisce una probabilità su uno spazio discreto

Su uno spazio discreto basta assegnare a ogni risultato ω un numero $p(\omega) \geq 0$, con la sola condizione che la somma di tutti sia 1. Per un evento qualsiasi si pone poi $P(A) = \sum_{\omega \in A} p(\omega)$, la somma dei pesi dei suoi risultati. Questa P rispetta gli assiomi: è ≥ 0, vale 1 su Ω e, se due eventi non hanno risultati in comune, i loro pesi si sommano. È esattamente quello che abbiamo fatto con il dado truccato, assegnando 5/6 all'1 e 1/30 alle altre facce.

LE PROPRIETÀ CHE SEGUONO DAGLI ASSIOMI

Ritroviamo ora, **dimostrandole** dagli assiomi, le regole del capitolo precedente. Lo schema è sempre lo stesso: si scrive l'evento come unione di pezzi **incompatibili** e si applica l'additività.

Teorema 4.3 — Eventi complementari ed evento impossibile

Per ogni evento A: $P(\overline{A}) = 1 - P(A)$. In particolare $P(\varnothing) = 0$.

Dimostrazione

Passo 1 — A e $\overline{A}$ si spartiscono Ω. $\Omega = A \cup \overline{A}$, e i due eventi sono incompatibili.

Passo 2 — Si applicano gli assiomi. Per la normalizzazione e l'additività:

$$1 = P(\Omega) = P(A \cup \overline{A}) = P(A) + P(\overline{A}) \quad \Longrightarrow \quad P(\overline{A}) = 1 - P(A).$$

Passo 3 — L'evento impossibile. Con $A = \Omega$: $P(\varnothing) = P(\overline{\Omega}) = 1 - P(\Omega) = 1 - 1 = 0$.

■

Teorema 4.4 — Sottrazione fra eventi

Per due eventi qualsiasi A e B:

$$P(A \setminus B) = P(A \cap \overline{B}) = P(A) - P(A \cap B).$$

È la probabilità che si verifichi A e non B (cioè A meno B).

Dimostrazione

Passo 1 — Si taglia A in due pezzi. $A = A \cap \Omega = A \cap (B \cup \overline{B})$ e, per la proprietà distributiva,

$$A = (A \cap B) \cup (A \cap \overline{B}).$$

Passo 2 — I pezzi sono incompatibili. Uno sta dentro B, l'altro fuori: $(A \cap B) \cap (A \cap \overline{B}) \subseteq B \cap \overline{B} = \varnothing$.

Passo 3 — Additività. $P(A) = P(A \cap B) + P(A \cap \overline{B})$, e portando $P(A \cap B)$ dall'altra parte si ottiene la tesi. ■

Teorema 4.5 — Unione di eventi non incompatibili

Per due eventi qualsiasi A e B:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

Dimostrazione

Passo 1 — Si scrive l'unione con pezzi incompatibili. Osserviamo preliminarmente che

$$A \cup B = A \cup (B \cap \overline{A}) :$$

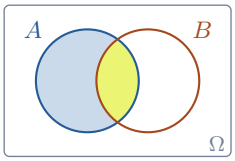
l'unione è fatta da tutto A, più la parte di B che sta fuori da A. I due eventi a secondo membro sono incompatibili (uno sta in A, l'altro fuori).

Passo 2 — Additività. Quindi $P(A \cup B) = P(A) + P(B \cap \overline{A})$.

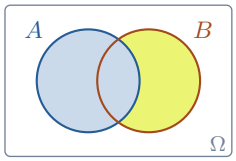
Passo 3 — Si usa la sottrazione. $P(B \cap \overline{A})$ è la probabilità che si verifichi B e non A (cioè B meno A): per il teorema precedente, con i ruoli di A e B scambiati, vale $P(B) - P(B \cap A)$. Sostituendo:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

■



$A = (A \cap B) \cup (A \cap \overline{B})$
due pezzi incompatibili



$A \cup B = A \cup (B \cap \overline{A})$
tutto A più il giallo

Figura 4.2: *Le due scomposizioni usate nelle dimostrazioni: a sinistra A è tagliato da B; a destra all'evento A (azzurro) si aggiunge la parte di B che sta fuori da A (giallo).*

Esercizio 4.1 — Indipendenza dei complementari

Dimostrare che se due eventi A e B sono indipendenti, lo sono anche i loro complementari:

$$P(A \cap B) = P(A)\,P(B) \quad \Longrightarrow \quad P(\overline{A} \cap \overline{B}) = P(\overline{A})\,P(\overline{B}).$$

Svolgimento

Per la legge di De Morgan $\overline{A} \cap \overline{B} = \overline{A \cup B}$: «né A né B» è il contrario di «almeno uno dei due». Quindi, usando il complementare, poi l'unione e infine l'indipendenza:

$$\begin{aligned} P(\overline{A} \cap \overline{B}) &= P(\overline{A \cup B}) = 1 - P(A \cup B) = 1 - [P(A) + P(B) - P(A \cap B)] \\ &= 1 - P(A) - P(B) + P(A)\,P(B). \end{aligned}$$

Ora si raccoglie con pazienza. I primi due termini danno $1 - P(A) = P(\overline{A})$; gli ultimi due hanno in comune $P(B)$:

$$P(\overline{A}) - P(B)\,(1 - P(A)) = P(\overline{A}) - P(B)\,P(\overline{A}) = P(\overline{A})\,(1 - P(B)) = P(\overline{A})\,P(\overline{B}).$$

Con lo stesso metodo si vede che sono indipendenti anche A e $\overline{B}$: per la sottrazione, $P(A \cap \overline{B}) = P(A) - P(A \cap B) = P(A) - P(A)\,P(B) = P(A)\,(1 - P(B)) = P(A)\,P(\overline{B})$. Se sapere che è successo B non dice nulla su A, nemmeno sapere che *non* è successo dice qualcosa.

Probabilità condizionata e teorema di Bayes

Nell'approccio assiomatico la probabilità condizionata e l'indipendenza diventano **definizioni**: si pone

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} \quad (P(B) > 0), \qquad A, B \text{ indipendenti} \iff P(A \cap B) = P(A)\,P(B),$$

cioè esattamente le formule che le frequenze ci avevano suggerito. Ne seguono, come prima, la legge della probabilità composta e quella della probabilità totale. Un fatto in più, che useremo spesso, è che *condizionare non fa uscire dalla teoria*.

Teorema 4.6 — La probabilità condizionata è una probabilità

Fissato un evento B con $P(B) > 0$, la funzione che a ogni evento A associa $P(A \mid B)$ è una legge di probabilità: soddisfa tutti gli assiomi di Kolmogorov.

Dimostrazione

Passo 1 — Non negatività. $P(A \mid B) = P(A \cap B)/P(B)$ è il rapporto fra un numero ≥ 0 e un numero > 0.

Passo 2 — Normalizzazione. $P(\Omega \mid B) = P(\Omega \cap B)/P(B) = P(B)/P(B) = 1$.

Passo 3 — Additività. Se $A_1 \cap A_2 = \varnothing$, i pezzi $A_1 \cap B$ e $A_2 \cap B$ sono ancora incompatibili e, per la distributiva, $(A_1 \cup A_2) \cap B = (A_1 \cap B) \cup (A_2 \cap B)$. Quindi

$$P(A_1 \cup A_2 \mid B) = \frac{P(A_1 \cap B) + P(A_2 \cap B)}{P(B)} = P(A_1 \mid B) + P(A_2 \mid B).$$

Lo stesso ragionamento vale per una famiglia numerabile di eventi incompatibili. ∎

Di conseguenza tutte le regole valgono anche «dentro» un condizionamento: per esempio $P(\overline{A} \mid B) = 1 - P(A \mid B)$.

Partiamo dalla legge della probabilità composta, che scrive la stessa intersezione in due modi:

$$P(A \cap B) = P(B \mid A)\,P(A) = P(A \mid B)\,P(B).$$

Dividendo per $P(A)$ si ottiene una formula che **rovescia** il condizionamento.

Teorema 4.7 — Teorema (o legge) di Bayes

Se $P(A) > 0$ e $P(B) > 0$:

$$P(B \mid A) = P(A \mid B)\,\frac{P(B)}{P(A)}.$$

Se poi $\{E_i\}_{i=1}^{M}$ è una partizione di Ω, per ogni i:

$$P(E_i \mid A) = \frac{P(A \mid E_i)\,P(E_i)}{\sum_{j=1}^{M} P(A \mid E_j)\,P(E_j)}.$$

Dimostrazione

Passo 1 — Prima forma. Dalla probabilità composta $P(B \mid A)\,P(A) = P(A \mid B)\,P(B)$; si dividono i due membri per $P(A) > 0$.

Passo 2 — Seconda forma. Si applica la prima con $B = E_i$: $P(E_i \mid A) = P(A \mid E_i)\,P(E_i)/P(A)$. Il denominatore $P(A)$ si scrive con la legge della probabilità totale (Teorema 3.2) rispetto alla partizione degli E_j: $P(A) = \sum_j P(A \mid E_j)\,P(E_j)$.

■

Il teorema di Bayes serve quando si conosce la probabilità di un *effetto* data la *causa*, $P(A \mid E_i)$, e si vuole risalire alla probabilità della causa dato l'effetto osservato, $P(E_i \mid A)$. I tre ingredienti hanno nomi che ritroveremo nella parte di statistica del corso:

- $P(E_i)$ è la probabilità **a priori** della causa: quanto la si riteneva probabile *prima* di osservare A;
- $P(A \mid E_i)$ è la **verosimiglianza**: quanto la causa E_i rende probabile ciò che si è osservato;
- $P(E_i \mid A)$ è la probabilità **a posteriori**: quanto è probabile la causa *dopo* aver osservato A.

Esempio 4.2 — Il canale binario, al contrario

Riprendiamo il canale binario del capitolo precedente: si trasmette 0 con probabilità 0,6 e 1 con probabilità 0,4, e ogni bit viene invertito con probabilità 0,1. Avevamo trovato $P(\text{1 ric.}) = 0{,}42$. Se si *riceve* un 1, qual è la probabilità che sia stato *trasmesso* un 1? Per Bayes:

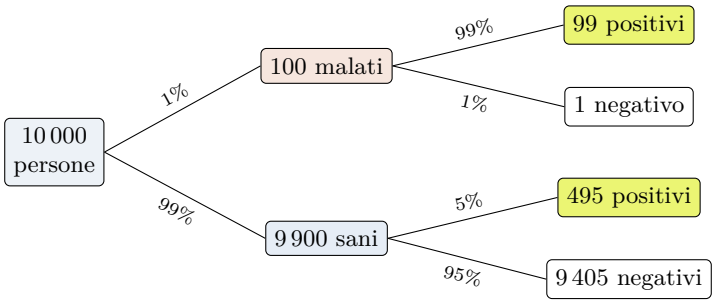
$$P(\text{1 tr.} \mid \text{1 ric.}) = \frac{P(\text{1 ric.} \mid \text{1 tr.})\,P(\text{1 tr.})}{P(\text{1 ric.})} = \frac{0{,}9 \cdot 0{,}4}{0{,}42} = \frac{0{,}36}{0{,}42} = \frac{6}{7} \approx 0{,}857.$$

Quindi, ricevuto un 1, c'è ancora una probabilità $1/7 \approx 0{,}14$ che sia stato trasmesso uno 0: più del 10% di inversione del canale, perché gli 0 trasmessi sono più numerosi degli 1. Decidere quale bit è stato trasmesso, dato quello ricevuto, è un problema di *decisione* che affronteremo nella parte di statistica.

Esempio 4.3 — Il test diagnostico

Una malattia colpisce l'1% della popolazione. Un test la rileva nel 99% dei malati, ma dà un falso allarme nel 5% dei sani. Una persona fa il test e risulta **positiva**: qual è la probabilità che sia malata?

Molti rispondono «99%». Ragioniamo con 10 000 persone, ognuna rappresentativa:



I positivi sono 99 + 495 = 594, e di questi solo 99 sono malati: $99/594 = 1/6 \approx 0{,}17$. Con il teorema di Bayes, rispetto alla partizione malato, sano:

$$P(M \mid +) = \frac{P(+ \mid M)\,P(M)}{P(+ \mid M)\,P(M) + P(+ \mid S)\,P(S)} = \frac{0{,}99 \cdot 0{,}01}{0{,}99 \cdot 0{,}01 + 0{,}05 \cdot 0{,}99} = \frac{0{,}0099}{0{,}0594} \approx 0{,}167.$$

Il test è ottimo, eppure un positivo è malato solo una volta su sei: i sani sono così tanti che i loro falsi allarmi superano di gran lunga i veri positivi. È l'effetto della probabilità a priori, $P(M) = 0{,}01$, che è piccola.

Non scambiare $P(A \mid B)$ con $P(B \mid A)$

$P(+ \mid M) = 0{,}99$ e $P(M \mid +) \approx 0{,}17$ sono due numeri molto diversi. Confonderli è uno degli errori più comuni (e più pericolosi) del ragionamento probabilistico; il teorema di Bayes dice come passare dall'uno all'altro, e mostra che serve anche la probabilità a priori.

Perché una probabilità sta fra 0 e 1

Nella definizione di legge di probabilità abbiamo scritto che il codominio è $[0, 1]$. In realtà non era necessario dirlo: lo si può dimostrare dagli assiomi. Il primo passo è un risultato utile anche da solo.

Teorema 4.8 — Monotonia della probabilità

Se l'evento A è contenuto nell'evento B ($A \subseteq B$), allora $P(A) \le P(B)$.

Dimostrazione

Passo 1 — Si scrive B con pezzi incompatibili. Se $A \subseteq B$ possiamo scrivere

$$B = A \cup (\overline{A} \cap B),$$

cioè B è fatto da A più la parte di B che sta fuori da A. I due eventi non si intersecano: $A \cap (\overline{A} \cap B) = \varnothing$.

Passo 2 — Additività. Per il terzo assioma $P(B) = P(A) + P(\overline{A} \cap B)$.

Passo 3 — Non negatività. Per il primo assioma $P(\overline{A} \cap B) \ge 0$, quindi $P(B) \ge P(A)$. ∎

Teorema 4.9 — La probabilità sta fra 0 e 1

Per ogni evento A: $0 \le P(A) \le 1$.

Dimostrazione

Passo 1. Ogni evento sta fra l'evento impossibile e quello certo: $\varnothing \subseteq A \subseteq \Omega$. Per la monotonia, e ricordando $P(\varnothing) = 0$ e $P(\Omega) = 1$:

$$0 = P(\varnothing) \le P(A) \le P(\Omega) = 1.$$

■

La monotonia ha anche un significato intuitivo: se ogni volta che succede A succede anche B, allora B succede *almeno* altrettanto spesso. Per esempio, «esce un 6» implica «esce un numero pari», e infatti $P(\{6\}) = 1/6 \le P(\{2,4,6\}) = 1/2$.

In sintesi

- Gli eventi formano un'**algebra**: una famiglia chiusa rispetto all'unione e al complementare (e quindi anche all'intersezione e alla differenza, e contenente Ω e $\varnothing$). Una **σ-algebra** è chiusa anche rispetto alle unioni numerabili. La più piccola algebra che contiene A è $\{A, \overline{A}, \Omega, \varnothing\}$.
- **Assiomi di Kolmogorov**: $P(A) \ge 0$; $P(\Omega) = 1$; additività (anche numerabile) per eventi incompatibili. $(\Omega, \mathcal{E}, P)$ è uno **spazio di probabilità**.
- Dagli assiomi: $P(\overline{A}) = 1 - P(A)$, $P(\varnothing) = 0$, $P(A \setminus B) = P(A) - P(A \cap B)$, $P(A \cup B) = P(A) + P(B) - P(A \cap B)$, monotonia e $0 \le P(A) \le 1$.
- Se A e B sono indipendenti, lo sono anche i complementari. La probabilità condizionata a B è a sua volta una probabilità.
- **Bayes**: $P(B \mid A) = P(A \mid B)\,P(B)/P(A)$; con una partizione, $P(E_i \mid A) = P(A \mid E_i)P(E_i)/\sum_j P(A \mid E_j)P(E_j)$. A priori, verosimiglianza, a posteriori.

Variabili aleatorie discrete

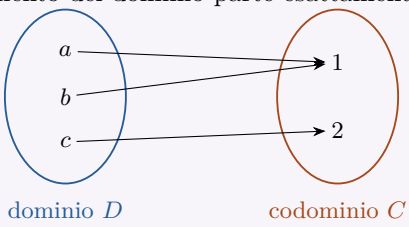
Finora i risultati di un esperimento erano oggetti qualsiasi: testa e croce, coppie di dadi, mani di carte. Ma molto spesso ciò che interessa è un **numero**: quante teste sono uscite, quanti pacchetti ci sono in coda, quanti bit sono arrivati sbagliati. Le **variabili aleatorie** trasformano i risultati in numeri, e con i numeri si possono fare cose che con le teste e le croci non si possono fare: per esempio la **media**. In questo capitolo introduciamo le variabili aleatorie discrete, la loro funzione di probabilità e la loro media, e studiamo le tre famiglie più importanti: la **binomiale**, l'**uniforme** e quella di **Poisson**.

Dai risultati ai numeri

Se Ω è un insieme di numeri, il risultato dell'esperimento è già un numero. In molti casi interessanti, come il lancio di una moneta o l'estrazione di una carta, Ω non è un insieme numerico; però lo si può sempre mettere in corrispondenza con un insieme discreto di numeri. Lo strumento per farlo è una funzione.

Richiamo di matematica: che cos'è una funzione

Una **funzione** $f : D \to C$ è una regola che associa a **ogni** elemento x dell'insieme D (il **dominio**) **uno e un solo** elemento $f(x)$ dell'insieme C (il **codominio**). Si scrive anche $x \mapsto f(x)$, «x va in $f(x)$». Si può disegnare con delle frecce: da ogni elemento del dominio parte esattamente una freccia.



Da ogni elemento di D parte una sola freccia. Più frecce possono arrivare allo stesso elemento di C (qui a e b vanno entrambi in 1): è permesso.

Variabile aleatoria

Una **variabile aleatoria** è una funzione che associa a ogni risultato ω di un esperimento un numero reale:

$$X : \omega \in \Omega \longmapsto X(\omega) \in \mathcal{X} \subseteq \mathbb{R}.$$

L'insieme $\mathcal{X}$ dei valori che può assumere (il suo codominio, necessariamente discreto se Ω è discreto) si chiama **alfabeto** di X.

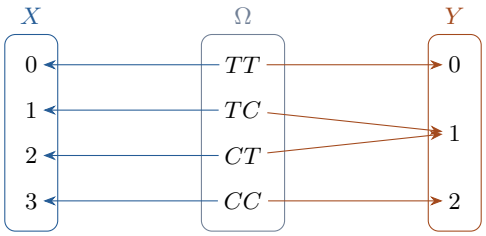
Gli eventi elementari diventano allora gli eventi $\{X = x\}$, con $x \in \mathcal{X}$: «la variabile ha assunto il valore x». Le loro frequenze relative e le loro probabilità si indicano con $f_n(x)$ e $P(X = x)$.

Che cosa c'è di aleatorio

Il nome inganna: la *funzione* X non ha niente di casuale, è una regola fissata una volta per tutte (per esempio «conta le teste»). Aleatorio è il suo *argomento* ω, il risultato dell'esperimento: siccome non sappiamo quale ω uscirà, non sappiamo nemmeno quale valore assumerà $X(\omega)$.

Esempio 5.1 — Monete trasformate in numeri

- **Lancio singolo**: $X : \omega \in \{T, C\} \mapsto X(\omega) \in \{0, 1\}$, con $X(T) = 0$ e $X(C) = 1$. Allora $P(X = 0) = P(X = 1) = \frac{1}{2}$.
- **Lancio doppio**: $X : \omega \in \{T, C\}^2 \mapsto X(\omega) \in \{0, 1, 2, 3\}$, numerando i quattro risultati: $TT \mapsto 0$, $TC \mapsto 1$, $CT \mapsto 2$, $CC \mapsto 3$. Allora $P(X = i) = \frac{1}{4}$ per $i = 0, 1, 2, 3$.
- **Lancio doppio, contando le croci**: $Y(\omega) =$ numero di croci in ω, con alfabeto $\{0, 1, 2\}$. Questa volta due risultati vanno nello stesso numero, e le probabilità si sommano: $P(Y = 0) = P(\{TT\}) = \frac{1}{4}$, $P(Y = 1) = P(\{TC, CT\}) = \frac{1}{2}$, $P(Y = 2) = P(\{CC\}) = \frac{1}{4}$.



LA FUNZIONE DI PROBABILITÀ

Per descrivere una variabile aleatoria discreta basta dire con che probabilità assume ciascuno dei suoi valori.

Funzione di probabilità (pmf)

La sequenza di numeri

$$p_X(x) = P(X = x), \qquad x \in \mathcal{X},$$

si chiama **funzione di probabilità**, in inglese *probability mass function* (**pmf**) o *Distribution Function* (DF), della variabile aleatoria X. Una variabile aleatoria si dice **caratterizzata** quando è assegnata la sequenza dei $|\mathcal{X}|$ valori della sua pmf.

Il nome inglese viene da un'immagine utile: si pensi alla probabilità come a un chilo di sabbia da distribuire sui punti dell'alfabeto. La pmf dice quanta *massa* di probabilità sta su ciascun punto.

Teorema 5.1 — Proprietà della pmf

Per ogni variabile aleatoria discreta X:

$$p_X(x) \geq 0 \quad \forall x \in \mathcal{X} \qquad \text{e} \qquad \sum_{x \in \mathcal{X}} p_X(x) = 1.$$

Dimostrazione

Passo 1 — Con le frequenze. Se $n_x = n_{\{X=x\}}$ è il numero di occorrenze dell'evento $\{X = x\}$ su n prove, $p_X(x) = \lim_{n\to\infty} n_x/n$, limite di numeri ≥ 0: quindi $p_X(x) \geq 0$.

Passo 2 — La somma. In ogni prova la variabile assume uno e un solo valore, quindi $\sum_x n_x = n$ e $\sum_x f_n(x) = 1$ per ogni n. Passando al limite, $\sum_x p_X(x) = 1$.

Passo 3 — Con gli assiomi. Gli eventi $\{X = x\}$, al variare di $x \in \mathcal{X}$, sono incompatibili (la variabile non può assumere due valori insieme) e la loro unione è Ω (qualche valore lo assume sempre): formano una partizione. Per la (numerabile) additività, $\sum_x P(X = x) = P(\Omega) = 1$; e ogni $P(X = x) \geq 0$ per il primo assioma.

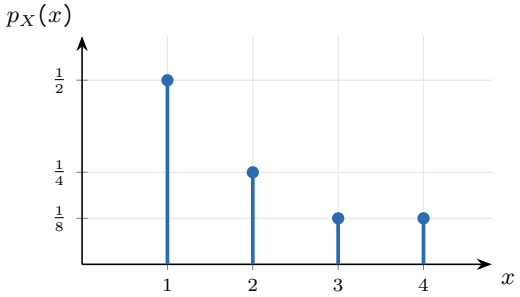
■

Esempio 5.2 — È una pmf?

Sia $\mathcal{X} = \{1, 2, 3, 4\}$. La sequenza $\left(\frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \frac{1}{8}\right)$ può essere la pmf di una variabile aleatoria? Tutti i valori sono ≥ 0 e

$$\sum_{x\in\mathcal{X}} p_X(x) = \frac{1}{2} + \frac{1}{4} + \frac{1}{8} + \frac{1}{8} = \frac{4+2+1+1}{8} = 1,$$

quindi la risposta è sì. Invece $\left(\frac{1}{2}, \frac{1}{2}, \frac{1}{4}, 0\right)$ non lo è (la somma vale $\frac{5}{4} > 1$), e nemmeno $(0{,}6;\ 0{,}6;\ -0{,}2;\ 0)$, che somma a 1 ma contiene un valore negativo.



Il grafico di una pmf si disegna così, con un «bastoncino» su ogni valore dell'alfabeto, alto quanto la sua probabilità.

Un'avvertenza sulle notazioni

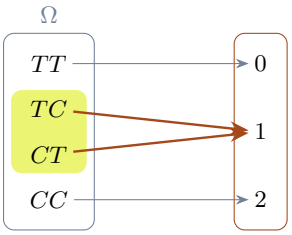
Per come è stata definita, la probabilità è una funzione definita su sottoinsiemi di Ω, a valori in $[0, 1]$:

$$P : A \subseteq \Omega \longmapsto P(A) \in [0, 1].$$

(A rigore bisognerebbe strutturare Ω con un'algebra di eventi, ma sorvoliamo.) Quando si passa alle variabili aleatorie, la notazione corretta sarebbe quindi

$$P\left(\{\omega \in \Omega : X(\omega) = x\}\right),$$

cioè la probabilità dell'insieme dei risultati che la variabile manda nel valore x. Useremo la notazione semplificata $P(X = x)$, o a volte $P(\{X = x\})$ per ricordare che ci riferiamo a un insieme di elementi di Ω, al posto di quella più precisa ma più lunga.



$\{Y = 1\}$ è un modo breve per scrivere l'insieme giallo $\{\omega \in \Omega : Y(\omega) = 1\} = \{TC, CT\}$: i risultati da cui parte una freccia verso 1. Quindi $P(Y = 1) = P(\{TC, CT\}) = \frac{1}{2}$.

Figura 5.1: *L'evento $\{Y = 1\}$ è un sottoinsieme di Ω.*

La media

La pmf descrive tutto, ma è una tabella di numeri. Spesso basta una caratterizzazione meno precisa, riassunta in un solo numero: il valore «attorno a cui» la variabile si distribuisce.

La media campionaria

Si abbia una variabile aleatoria $X(\omega)$ e si compiano n esperimenti. La collezione dei risultati sarà

$$[X(\tilde{\omega}_1) \;\; X(\tilde{\omega}_2) \;\; \dots \;\; X(\tilde{\omega}_n)],$$

dove $\tilde{\omega}_i$ è il risultato dell'esperimento i-esimo e $X(\tilde{\omega}_i)$ il valore assunto dalla variabile in quell'esperimento. La loro media aritmetica si chiama **media campionaria**:

$$\overline{X}_n = \frac{1}{n}\sum_{i=1}^{n} X(\tilde{\omega}_i).$$

Esempio 5.3 — La media di venti lanci

Venti lanci di un dado onesto (simulati) hanno dato:

$$5,\ 3,\ 6,\ 3,\ 6,\ 6,\ 6,\ 5,\ 1,\ 4,\ 2,\ 6,\ 1,\ 2,\ 1,\ 3,\ 4,\ 2,\ 4,\ 5.$$

La media campionaria è la somma divisa per 20: $\overline{X}_{20} = 75/20 = 3{,}75$. Ma la somma si può fare in modo più furbo, **raggruppando i valori uguali**: ogni faccia è uscita un certo numero di volte n_i.

valore x_i	1	2	3	4	5	6	
volte n_i	3	3	3	3	3	5	totale 20
frequenza $f_{20}(x_i)$	0,15	0,15	0,15	0,15	0,15	0,25	totale 1

$$\overline{X}_{20} = \frac{1\cdot 3 + 2\cdot 3 + 3\cdot 3 + 4\cdot 3 + 5\cdot 3 + 6\cdot 5}{20} = 1\cdot 0{,}15 + 2\cdot 0{,}15 + \cdots + 6\cdot 0{,}25 = 3{,}75.$$

La media è la somma dei valori, ciascuno moltiplicato per la sua frequenza relativa.

Dalla media campionaria alla media statistica

Il raggruppamento dell'esempio funziona sempre. Siccome $X(\tilde{\omega}_i) \in \mathcal{X} = \{x_1, x_2, \dots, x_M\}$, al crescere di n la variabile assumerà n_1 volte il valore x_1, n_2 volte il valore x_2, e così via (il caso $M = \infty$ si tratta come caso limite). Quindi, per $n \to \infty$,

$$\overline{X}_n = \frac{1}{n}\sum_{i=1}^{M} n_i\, x_i = \sum_{i=1}^{M} x_i\, f_n(x_i) \longrightarrow \sum_{i=1}^{M} x_i\, P(X = x_i) = \sum_{i=1}^{M} x_i\, p_X(x_i) \triangleq E[X],$$

dove $f_n(x_i) = n_{\{X=x_i\}}/n$ e il simbolo $\triangleq$ si legge «è uguale per definizione». Le frequenze tendono alle probabilità, quindi la media campionaria tende a un numero che dipende solo dalla pmf.

Media statistica

La **media statistica** (o **valore atteso**) di una variabile aleatoria discreta X è

$$E[X] = \sum_{x\in\mathcal{X}} x\, p_X(x) :$$

la somma dei valori assunti, ciascuno moltiplicato per la probabilità con cui è assunto. Si indica anche con μ_X.

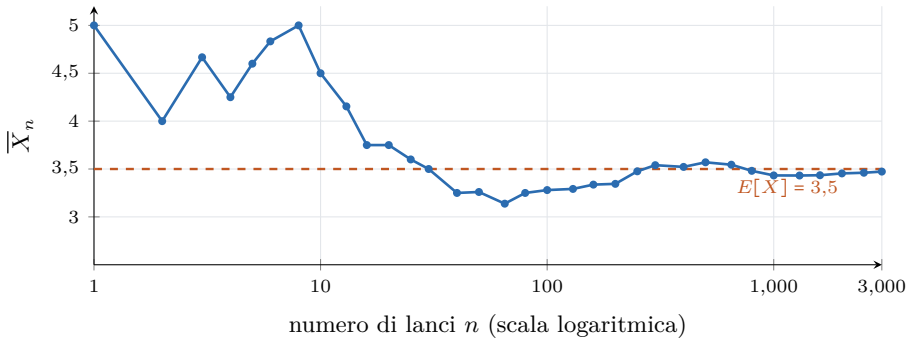


Figura 5.2: *La media campionaria dei lanci di un dado onesto (simulati), al crescere del numero di lanci: oscilla molto all'inizio e poi si avvicina alla media statistica* $E[X] = 3{,}5$.

Esempio 5.4 — Due medie

- Un dado onesto: $E[X] = 1 \cdot \frac{1}{6} + 2 \cdot \frac{1}{6} + \cdots + 6 \cdot \frac{1}{6} = \frac{21}{6} = 3{,}5$. La media **non** è per forza un valore che la variabile può assumere: nessun dado mostra 3,5.
- Il dado truccato del Capitolo 3 ($P(1) = \frac{5}{6}$, $P(i) = \frac{1}{30}$ per le altre facce): $E[X] = 1 \cdot \frac{5}{6} + (2+3+4+5+6) \cdot \frac{1}{30} = \frac{5}{6} + \frac{20}{30} = \frac{25+20}{30} = 1{,}5$. Il trucco sposta la media verso l'1.

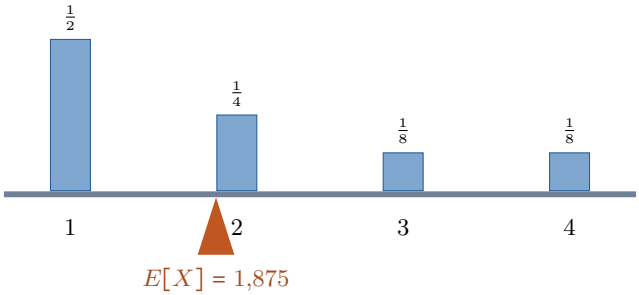


Figura 5.3: *La media come baricentro. Se si appoggiano su un'asta dei pesi proporzionali alle probabilità della pmf* $\left(\frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \frac{1}{8}\right)$, *l'asta sta in equilibrio esattamente sul punto* $E[X] = 1 \cdot \frac{1}{2} + 2 \cdot \frac{1}{4} + 3 \cdot \frac{1}{8} + 4 \cdot \frac{1}{8} = 1{,}875$.

Il conteggio bernoulliano: la variabile binomiale

Consideriamo N lanci di una moneta. Ogni lancio dà testa (T) con probabilità p e croce (C) con probabilità $q = 1-p$ (la moneta non deve essere per forza onesta). I lanci sono **indipendenti**: l'esito di ognuno non dipende da quelli precedenti o successivi. Lo spazio campione è l'insieme delle N-ple del tipo

$$\underbrace{(C, C, T, T, C, \ldots, C, T, T)}_{N}, \qquad \Omega = \{T, C\}^N.$$

Sia $X_N(\omega)$ la variabile aleatoria che **conta** il numero di teste in N lanci:

$$X_N : \omega \in \{T, C\}^N \longmapsto X_N(\omega) \in \mathcal{X} = \{0, 1, 2, \ldots, N\},$$

dove $X_N(\omega) = k$ se ω contiene k teste. Vogliamo la sua pmf.

La probabilità di una sequenza

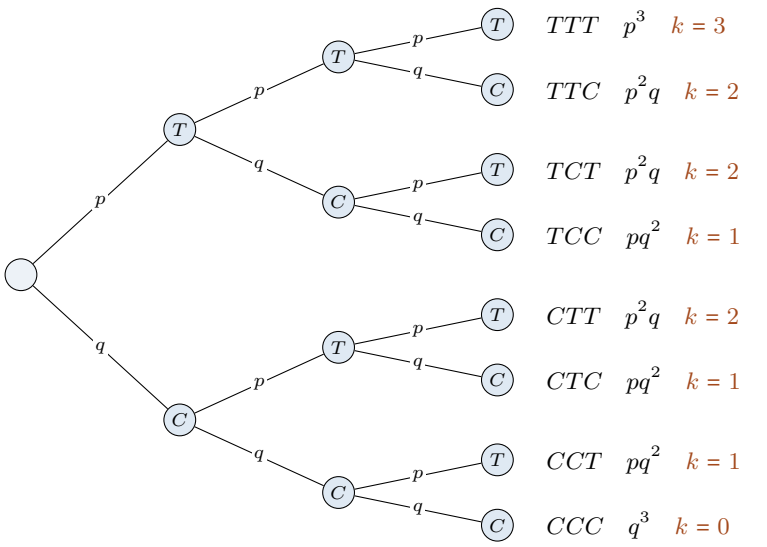
Prendiamo una sequenza particolare con k teste, per esempio quella con tutte le teste all'inizio:

$$\omega = (\underbrace{T, T, \ldots, T}_{k \text{ volte}}, \underbrace{C, C, \ldots, C}_{N-k \text{ volte}}).$$

Per l'indipendenza dei lanci la probabilità che si verifichino insieme tutti questi esiti è il prodotto delle probabilità dei singoli esiti:

$$P(\omega) = \underbrace{p \cdot p \cdots p}_{k \text{ volte}} \cdot \underbrace{q \cdot q \cdots q}_{N-k \text{ volte}} = p^k \, q^{N-k}.$$

L'ordine delle teste e delle croci non conta nel prodotto: **tutte** le sequenze con k teste e $N-k$ croci hanno la stessa probabilità $p^k q^{N-k}$. E quante sono? Sono le stringhe di lunghezza N con k «uni» (Teorema 2.8): $C_{N,k} = \binom{N}{k}$.



Con $N = 3$ lanci: una sequenza con k teste ha probabilità $p^k q^{3-k}$. Le sequenze con $k = 0,1,2,3$ teste sono $1,3,3,1 = \binom{3}{k}$, quindi $P(X_3 = 2) = 3p^2q$, $P(X_3 = 1) = 3pq^2$, …

Figura 5.4: *L'albero di tre lanci. La probabilità di un percorso è il prodotto delle probabilità dei suoi rami.*

La pmf binomiale

Sia $\Omega_{N,k} = \bigcup_{i=1}^{C_{N,k}} \{\omega_i\}$ l'insieme di tutte le sequenze con k teste. L'evento $\{X_N = k\}$ è proprio $\Omega_{N,k}$, quindi

$$P(X_N = k) = p_{X_N}(k) = P(\Omega_{N,k}) = P\left(\bigcup_{i=1}^{C_{N,k}} \{\omega_i\}\right).$$

Gli eventi elementari ω_i sono mutuamente esclusivi ($P(\omega_i \cap \omega_j) = 0$ per $i \neq j$), quindi le probabilità si sommano, e sono tutte uguali a $p^k q^{N-k}$:

$$P(X_N = k) = \sum_{i=1}^{C_{N,k}} P(\{\omega_i\}) = \binom{N}{k} p^k q^{N-k}.$$

Variabile binomiale

Una variabile aleatoria X con alfabeto $\{0,1,\dots,N\}$ e pmf

$$p_X(k) = \binom{N}{k} p^k (1-p)^{N-k}, \qquad k = 0,1,\dots,N,$$

si dice **binomiale** di parametri N e p; in breve $X \sim \mathcal{B}(N,p)$. Conta i successi in N prove indipendenti, ognuna con probabilità di successo p. Per $N = 1$ si chiama **variabile di Bernoulli**: vale 1 con probabilità p e 0 con probabilità $1-p$.

Teorema 5.2 — La binomiale è una pmf

Per ogni N e ogni $p \in [0,1]$: $p_{X_N}(k) \geq 0$ per $k \in \{0,1,\dots,N\}$ e $\sum_{k=0}^{N} p_{X_N}(k) = 1$.

Dimostrazione

Passo 1 — Non negatività. È il prodotto di un coefficiente binomiale (positivo) e di potenze di p e q, che sono ≥ 0.

Passo 2 — Somma, con il binomio di Newton. La somma è proprio lo sviluppo di Newton (Teorema 2.6) con $a = p$ e $b = q$:

$$\sum_{k=0}^{N} \binom{N}{k} p^k \, q^{N-k} = (p+q)^N = (p+1-p)^N = 1^N = 1.$$

Ecco da dove viene il nome «binomiale»: i suoi valori sono i termini dello sviluppo del binomio $(p+q)^N$.

■

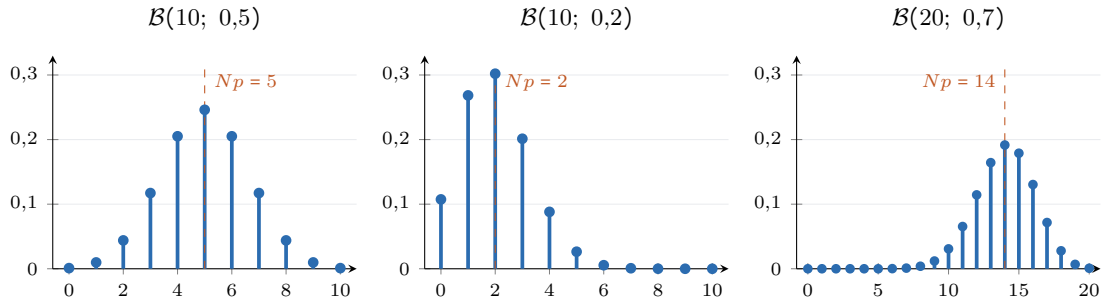


Figura 5.5: *Tre pmf binomiali. Con $p = 0{,}5$ la pmf è simmetrica; con p piccolo è spostata verso sinistra, con p grande verso destra. La linea tratteggiata è la media Np, che calcoliamo fra poco.*

La media della binomiale

Il calcolo della media usa un trucco che ritroveremo spesso: spostare l'indice di una sommatoria.

Richiamo di matematica: cambiare l'indice di una sommatoria

In una sommatoria si può cambiare il nome dell'indice e anche *spostarlo*, purché si spostino di conseguenza gli estremi. Per esempio, ponendo $l = k - 1$: quando k va da 1 a N, l va da 0 a $N - 1$, e

$$\sum_{k=1}^{N} a_{k-1} = \sum_{l=0}^{N-1} a_l.$$

I termini sommati sono esattamente gli stessi $(a_0, a_1, \ldots, a_{N-1})$; cambia solo il nome con cui li si conta. Esempio: $\sum_{k=1}^{3} 2^{k-1} = 2^0 + 2^1 + 2^2 = \sum_{l=0}^{2} 2^l = 7$.
Un'altra cosa utile: se il termine con $k = 0$ vale zero, lo si può togliere senza cambiare la somma, e la sommatoria parte da $k = 1$.

Teorema 5.3 — Media della binomiale

Se $X_N \sim \mathcal{B}(N, p)$, allora

$$E[X_N] = N\,p.$$

Dimostrazione

Passo 1 — Si scrive la definizione. Per definizione di media, con la pmf binomiale e la formula del coefficiente binomiale:

$$E[X_N] = \sum_{k=0}^{N} k\, p_{X_N}(k) = \sum_{k=0}^{N} k \binom{N}{k} p^k q^{N-k} = \sum_{k=0}^{N} k\, \frac{N!}{k!\,(N-k)!}\, p^k q^{N-k}.$$

Passo 2 — Si toglie il termine nullo. Per $k = 0$ il termine contiene il fattore $k = 0$ e vale zero: la somma può partire da $k = 1$.

Passo 3 — Si semplifica $k/k!$. Per $k \geq 1$ vale $k! = k \cdot (k-1)!$, quindi $\dfrac{k}{k!} = \dfrac{1}{(k-1)!}$:

$$E[X_N] = \sum_{k=1}^{N} \frac{N!}{(k-1)!\,(N-k)!}\, p^k q^{N-k}.$$

Passo 4 — Si fa comparire $N-1$. Si scrive $N! = N \cdot (N-1)!$ e si nota che $N - k = (N-1) - (k-1)$, sia nel fattoriale sia nell'esponente di q:

$$E[X_N] = \sum_{k=1}^{N} \frac{N\,(N-1)!}{(k-1)!\,[(N-1)-(k-1)]!}\, p^k q^{N-1-(k-1)}.$$

Passo 5 — Si porta fuori Np. N non dipende da k, e da p^k si può staccare un fattore p: $p^k = p \cdot p^{k-1}$. Portando fuori entrambi:

$$E[X_N] = Np \sum_{k=1}^{N} \frac{(N-1)!}{(k-1)!\,[(N-1)-(k-1)]!}\, p^{k-1} q^{N-1-(k-1)}.$$

Passo 6 — Si cambia indice. Si pone $l = k-1$ e $M = N-1$. Quando k va da 1 a N, l va da 0 a M:

$$E[X_N] = Np \sum_{l=0}^{M} \frac{M!}{l!\,(M-l)!}\, p^l q^{M-l} = Np\,(p+q)^M = Np.$$

La somma rimasta è la somma di tutti i valori di una pmf binomiale $\mathcal{B}(M,p)$, cioè (binomio di Newton) $(p+q)^M = 1$. ■

Il risultato è quello che l'intuito suggerisce: se in ogni lancio esce testa con probabilità p, in N lanci ci si aspettano in media Np teste (con 10 lanci di una moneta onesta, 5 teste). Nel Capitolo 9 ritroveremo questo risultato in una riga, con la linearità della media.

LA VARIABILE UNIFORME

Variabile uniforme

Una variabile aleatoria X che assume valori in un alfabeto finito $\mathcal{X}$ di cardinalità $|\mathcal{X}| = M$ si dice **uniformemente distribuita** su $\mathcal{X}$, in breve $X \sim \mathcal{U}(\mathcal{X})$, se tutti i valori hanno la stessa probabilità:

$$p_X(x) = P(X = x) = \frac{1}{M} \qquad \forall x \in \mathcal{X}.$$

Ovviamente $p_X(x)$ soddisfa le condizioni per essere una pmf: è positiva e M termini uguali a $1/M$ sommano a 1. Il calcolo della media è immediato:

$$E[X] = \sum_{x \in \mathcal{X}} x\, p_X(x) = \frac{1}{M} \sum_{x \in \mathcal{X}} x :$$

è la **media aritmetica** dei valori dell'alfabeto. Il dado onesto è una variabile uniforme su $\{1, \ldots, 6\}$, e infatti la sua media è $(1 + 2 + \cdots + 6)/6 = 3{,}5$.

Un caso interessante è $\mathcal{X} = \{0, 1, 2, \ldots, M-1\}$ (per esempio un numero casuale di k bit, con $M = 2^k$). Per calcolarne la media serve la somma dei primi numeri naturali.

Teorema 5.4 — Somma dei primi n naturali

Per ogni naturale $n \geq 1$:

$$\sum_{i=1}^{n} i = 1 + 2 + \cdots + n = \frac{n\,(n+1)}{2}.$$

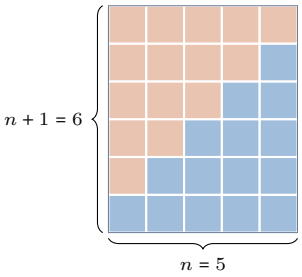
Dimostrazione — il trucco di Gauss

Passo 1 — Si scrive la somma due volte. Sia $S = 1 + 2 + \cdots + n$. La si scrive una volta in avanti e una volta all'indietro, e si sommano le due righe colonna per colonna:

$$\begin{array}{rcccccccc} S & = & 1 & + & 2 & + & \cdots & + & n \\ S & = & n & + & (n-1) & + & \cdots & + & 1 \\ \hline 2S & = & (n+1) & + & (n+1) & + & \cdots & + & (n+1) \end{array}$$

Passo 2 — Ogni colonna vale $n+1$. In ogni colonna, mentre il numero in alto cresce di 1, quello in basso cala di 1: la somma resta sempre $n+1$. Le colonne sono n, quindi $2S = n\,(n+1)$ e $S = n\,(n+1)/2$.

■



La «scala» blu ha $1 + 2 + 3 + 4 + 5$ quadretti. Una seconda scala uguale (arancione), capovolta, la completa in un rettangolo di $5 \times 6 = 30$ quadretti. Quindi una scala sola ne ha la metà: $\frac{5 \cdot 6}{2} = 15$.

Figura 5.6: *La dimostrazione di Gauss, disegnata.*

Esempio 5.5 — La media di un'uniforme su $\{0, 1, \ldots, M-1\}$

Se $X \sim \mathcal{U}(\{0, 1, \ldots, M-1\})$, il termine con 0 non contribuisce e si applica il Teorema 5.4 con $n = M - 1$:

$$E[X] = \sum_{x \in \mathcal{X}} x\, p_X(x) = \frac{1}{M} \sum_{i=0}^{M-1} i = \frac{1}{M} \cdot \frac{(M-1)\,M}{2} = \frac{M-1}{2}.$$

È il punto di mezzo fra il valore più piccolo (0) e il più grande ($M-1$), come ci si aspetta da una distribuzione che non preferisce nessun valore. Per un byte casuale ($M = 256$) la media è 127,5.

La variabile di Poisson

La terza variabile notevole ha un alfabeto infinito e una pmf in cui compare il numero e. Prima di definirla, conviene ricordare da dove viene quel numero.

Richiamo di matematica: il numero e e la serie esponenziale

Si depositi 1 euro in una banca che paga il 100% di interesse all'anno. Se l'interesse viene pagato una volta sola, a fine anno si hanno 2 euro. Se viene pagato ogni sei mesi, metà alla volta, si hanno $\left(1+\frac{1}{2}\right)^2 = 2{,}25$ euro. Se viene pagato n volte all'anno, ogni volta l'$\frac{1}{n}$ del capitale, a fine anno si hanno $\left(1+\frac{1}{n}\right)^n$ euro:

n	1	2	4	12	52	365	1 000 000
$\left(1+\frac{1}{n}\right)^n$	2	2,25	2,4414	2,6130	2,6926	2,7146	2,71828

Il guadagno cresce, ma sempre più lentamente: la successione ha un limite, che si chiama e, il **numero di Nepero**:

$$e = \lim_{n\to\infty}\left(1+\frac{1}{n}\right)^n = 2{,}718281828\ldots$$

Più in generale, per qualsiasi numero reale x vale $\left(1+\frac{x}{n}\right)^n \to e^x$; per esempio $\left(1-\frac{\lambda}{n}\right)^n \to e^{-\lambda}$. La funzione $x \mapsto e^x$ si chiama **esponenziale**.
L'esponenziale si può scrivere anche come una somma infinita (la **serie esponenziale**):

$$e^x = \sum_{k=0}^{\infty}\frac{x^k}{k!} = 1 + x + \frac{x^2}{2} + \frac{x^3}{6} + \frac{x^4}{24} + \cdots$$

Con $x = 1$ le somme parziali sono 1, 2, 2,5, 2,6667, 2,7083, 2,7167, 2,7181, 2,71825, … e si avvicinano a e molto in fretta, perché i fattoriali al denominatore crescono vertiginosamente. Il *perché* di questa formula si capisce con le derivate: lo vedremo nel Capitolo 7, dove le introdurremo.

Variabile di Poisson

Una variabile aleatoria X si dice **di Poisson** (o poissoniana) di parametro $\lambda > 0$, in breve $X \sim \mathcal{P}(\lambda)$, se:

1. il suo alfabeto è $\mathcal{X} = \{0, 1, 2, 3, \ldots\} = \mathbb{N}_0$;
2. la sua pmf è

$$p_X(k) = P(X = k) = \frac{\lambda^k}{k!}\,e^{-\lambda}, \qquad k \in \mathbb{N}_0.$$

Teorema 5.5 — La Poisson è una pmf

Per ogni $\lambda > 0$: $p_X(k) \geq 0$ per ogni $k \in \mathbb{N}_0$ e $\sum_{k=0}^{\infty} p_X(k) = 1$.

Dimostrazione

Passo 1 — Non negatività. $\lambda^k > 0$, $k! > 0$ ed $e^{-\lambda} > 0$.

Passo 2 — Somma. Il fattore $e^{-\lambda}$ non dipende da k e si porta fuori; quello che resta è la serie esponenziale con $x = \lambda$:

$$\sum_{x\in\mathcal{X}} p_X(x) = \sum_{k=0}^{\infty}\frac{\lambda^k}{k!}\,e^{-\lambda} = e^{-\lambda}\sum_{k=0}^{\infty}\frac{\lambda^k}{k!} = e^{-\lambda}\,e^{\lambda} = 1.$$

■

Teorema 5.6 — Media della Poisson

Se $X \sim \mathcal{P}(\lambda)$, allora $E[X] = \lambda$.

Dimostrazione

Passo 1 — La definizione.

$$E[X] = \sum_{x \in \mathcal{X}} x\, p_X(x) = \sum_{k=0}^{\infty} k\, \frac{\lambda^k}{k!}\, e^{-\lambda}.$$

Passo 2 — Si toglie il termine nullo e si semplifica. Il termine con $k = 0$ è nullo e si può togliere; per $k \geq 1$, $k/k! = 1/(k-1)!$. Si porta fuori $e^{-\lambda}$ e un fattore λ (da $\lambda^k = \lambda \cdot \lambda^{k-1}$):

$$E[X] = \sum_{k=1}^{\infty} \frac{\lambda^k}{(k-1)!}\, e^{-\lambda} = e^{-\lambda}\, \lambda \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!}.$$

Passo 3 — Si cambia indice. Posto $j = k - 1$, quando k va da 1 a ∞, j va da 0 a ∞, e si riconosce la serie esponenziale:

$$E[X] = e^{-\lambda}\, \lambda \sum_{j=0}^{\infty} \frac{\lambda^j}{j!} = e^{-\lambda}\, \lambda\, e^{\lambda} = \lambda.$$

■

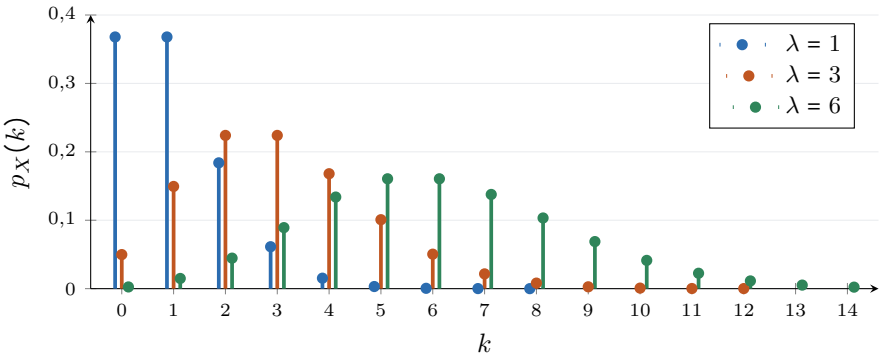


Figura 5.7: *Tre pmf di Poisson (i bastoncini dei tre colori sono leggermente sfalsati per non sovrapporsi). La massa si concentra attorno a λ, che è la media; al crescere di λ si sposta a destra e si allarga.*

Da dove viene la formula di Poisson

La pmf di Poisson non è stata inventata a caso: è quello che diventa la binomiale quando le prove sono **moltissime** e il successo in ciascuna è **rarissimo**. Si pensi ai pacchetti che arrivano a un router in un millisecondo: molti utenti potrebbero spedirne uno (N grande), ma ognuno lo fa con probabilità piccola (p piccolo), e il numero medio di arrivi è $\lambda = Np$.

Teorema 5.7 — La Poisson come limite della binomiale

Sia $\lambda > 0$ fissato e sia $X_N \sim \mathcal{B}(N, \lambda/N)$, una binomiale con media $N \cdot \lambda/N = \lambda$. Allora, per ogni $k \in \mathbb{N}_0$,

$$\lim_{N \to \infty} P(X_N = k) = \frac{\lambda^k}{k!}\, e^{-\lambda}.$$

Dimostrazione

Passo 1 — Si scrive la binomiale con $p = \lambda/N$.

$$P(X_N = k) = \binom{N}{k}\left(\frac{\lambda}{N}\right)^k\left(1-\frac{\lambda}{N}\right)^{N-k} = \frac{N\,(N-1)\cdots(N-k+1)}{k!}\cdot\frac{\lambda^k}{N^k}\cdot\left(1-\frac{\lambda}{N}\right)^N\left(1-\frac{\lambda}{N}\right)^{-k}.$$

Passo 2 — Si raggruppano i fattori. Il numeratore $N\,(N-1)\cdots(N-k+1)$ ha k fattori, come N^k: li si divide uno per uno.

$$P(X_N = k) = \frac{\lambda^k}{k!}\cdot\underbrace{\frac{N}{N}\cdot\frac{N-1}{N}\cdots\frac{N-k+1}{N}}_{(1)}\cdot\underbrace{\left(1-\frac{\lambda}{N}\right)^N}_{(2)}\cdot\underbrace{\left(1-\frac{\lambda}{N}\right)^{-k}}_{(3)}.$$

Passo 3 — Il limite di ogni pezzo. Con k fissato e $N \to \infty$:

- (1): ogni fattore è $1 - i/N$ con i fra 0 e $k-1$, e tende a 1; i fattori sono k, un numero fissato, quindi il prodotto tende a 1;
- (2): è il limite del richiamo sul numero e, con $x = -\lambda$: tende a $e^{-\lambda}$;
- (3): la base $1 - \lambda/N$ tende a 1 e l'esponente $-k$ è fisso, quindi tende a $1^{-k} = 1$.

Passo 4 — Si mette insieme. Il limite di un prodotto è il prodotto dei limiti: $P(X_N = k) \to \dfrac{\lambda^k}{k!}\cdot 1\cdot e^{-\lambda}\cdot 1$.

■

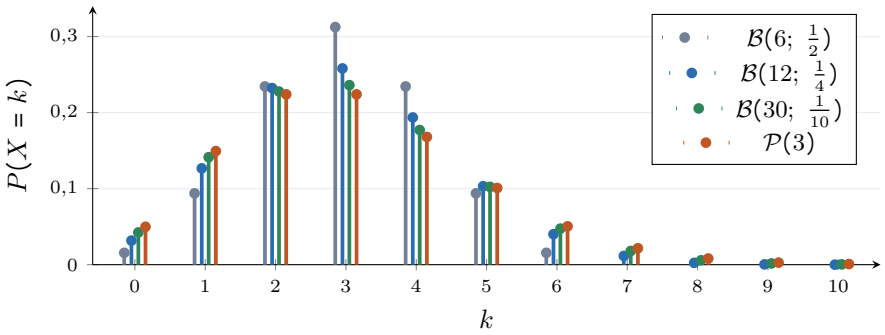


Figura 5.8: *Binomiali con media $Np = 3$ e N sempre più grande: al crescere di N i bastoncini si avvicinano a quelli della Poisson con $\lambda = 3$ (in arancione).*

In sintesi

- Una **variabile aleatoria** è una funzione $X : \Omega \to \mathcal{X} \subseteq \mathbb{R}$ che trasforma i risultati in numeri; $\mathcal{X}$ è il suo **alfabeto**. $P(X = x)$ abbrevia $P(\{\omega : X(\omega) = x\})$.
- La **pmf** $p_X(x) = P(X = x)$ è ≥ 0 e somma a 1.
- La **media statistica** $E[X] = \sum_x x\,p_X(x)$ è il limite della media campionaria: la somma dei valori pesati con le loro probabilità, il baricentro della pmf.
- **Binomiale** $\mathcal{B}(N,p)$: $p_X(k) = \binom{N}{k}p^k(1-p)^{N-k}$, $k = 0,\dots,N$; conta i successi in N prove indipendenti; $E[X] = Np$.
- **Uniforme** su M valori: $p_X(x) = 1/M$; la media è la media aritmetica dei valori, e su $\{0,\dots,M-1\}$ vale $(M-1)/2$.
- **Poisson** $\mathcal{P}(\lambda)$: $p_X(k) = \frac{\lambda^k}{k!}e^{-\lambda}$, $k \in \mathbb{N}_0$; $E[X] = \lambda$. È il limite della binomiale con $N \to \infty$ e $Np = \lambda$: conta gli eventi rari.

PMF CONDIZIONATE E FUNZIONI DI VARIABILI ALEATORIE

Nel Capitolo 3 abbiamo visto come cambia la probabilità di un evento quando si sa che ne è accaduto un altro. Lo stesso si può fare con le variabili aleatorie: sapendo qualcosa sul risultato, la pmf e la media cambiano, e si parla di **pmf condizionata** e di **media condizionata**. Nella seconda metà del capitolo applichiamo una funzione a una variabile aleatoria (la eleviamo al quadrato, ne prendiamo il seno…) e ci chiediamo come si calcolano la pmf e la media della nuova variabile.

LA PMF CONDIZIONATA A UN EVENTO

Introduciamo l'argomento con un esempio. Sia $X \sim \mathcal{B}\left(16, \frac{1}{3}\right)$, cioè

$$\mathcal{X} = \{0, 1, 2, \dots, 16\}, \qquad p_X(k) = \binom{16}{k}\left(\frac{1}{3}\right)^k\left(\frac{2}{3}\right)^{16-k}, \qquad E[X] = 16 \cdot \frac{1}{3} = \frac{16}{3} \approx 5{,}33.$$

Supponiamo ora di sapere che si è verificata la condizione $X > 4$. Come si distribuisce X sotto questa condizione? Dal punto di vista «fisico» significa considerare un insieme di n esperimenti, **scartare** quelli in cui X ha dato un valore inferiore a 5 e valutare la frequenza dei 12 valori residui (da 5 a 16) nel campione così ridotto. È esattamente la probabilità condizionata del Capitolo 3, applicata agli eventi $\{X = k\}$:

$$p_{X|X>4}(k) = P(X = k \mid X > 4) = \frac{P(\{X = k\} \cap \{X > 4\})}{P(\{X > 4\})}.$$

L'intersezione al numeratore è facile: se $k > 4$, l'evento $\{X = k\}$ è contenuto in $\{X > 4\}$ e l'intersezione è $\{X = k\}$ stesso; se $k \le 4$, i due eventi sono incompatibili e l'intersezione è vuota. Quindi

$$p_{X|X>4}(k) = \begin{cases} \dfrac{P(X = k)}{P(X > 4)} = \dfrac{P(X = k)}{\sum_{j=5}^{16} P(X = j)} & k = 5, 6, \dots, 16 \\ 0 & k < 5 \end{cases}$$

Con i numeri: $P(X > 4) = \sum_{j=5}^{16} P(X = j) \approx 0{,}661$, quindi le probabilità dei valori rimasti vengono divise per 0,661, cioè moltiplicate per circa 1,51.

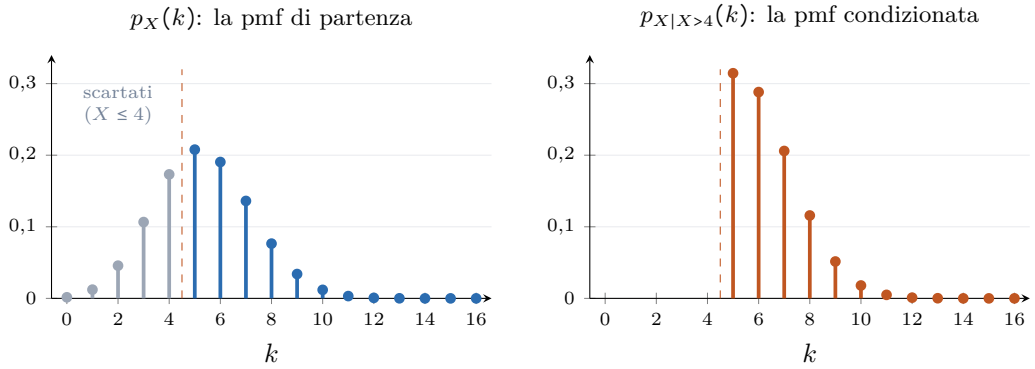


Figura 6.1: *Condizionare a $X > 4$: i valori da 0 a 4 vengono scartati e quelli rimasti vengono «rialzati» tutti nella stessa proporzione (divisi per $P(X > 4) \approx 0{,}661$), in modo che la loro somma torni a 1.*

La pmf condizionata trovata è davvero una pmf: è ≥ 0 e

$$\sum_{k\in\mathcal{X}} p_{X|X>4}(k) = \sum_{k=5}^{16} \frac{P(X=k)}{\sum_{j=5}^{16} P(X=j)} = \frac{\sum_{k=5}^{16} P(X=k)}{\sum_{j=5}^{16} P(X=j)} = 1,$$

perché il denominatore è lo stesso per tutti i termini e si può portare fuori dalla somma.

Siamo ora in grado di dare la definizione generale: si può condizionare una variabile aleatoria a un **qualsiasi** evento A di probabilità non nulla, non necessariamente definito tramite X stessa.

Pmf condizionata

Sia X una variabile aleatoria e $A \subseteq \Omega$ un evento con $P(A) \neq 0$. La **pmf di X condizionata ad A** è

$$p_{X|A}(x) = P(X = x \mid A) = \frac{P(\{X=x\} \cap A)}{P(A)}, \qquad x \in \mathcal{X}.$$

Teorema 6.1 — La pmf condizionata è una pmf

Fissato l'evento A (con $P(A) \neq 0$), al variare di $x \in \mathcal{X}$ la funzione $p_{X|A}(x)$ è una pmf:

$$p_{X|A}(x) \geq 0 \qquad \text{e} \qquad \sum_{x\in\mathcal{X}} p_{X|A}(x) = 1.$$

Dimostrazione

Passo 1 — Una probabilità condizionata è una probabilità. Per il Teorema 4.6, $P(\cdot \mid A)$ rispetta tutti gli assiomi; in particolare è ≥ 0.

Passo 2 — La somma. Gli eventi $\{X = x\}$, al variare di x, formano una partizione di Ω. Per l'additività della probabilità condizionata:

$$\sum_{x\in\mathcal{X}} P(X=x \mid A) = P\left(\bigcup_{x\in\mathcal{X}} \{X=x\} \,\middle|\, A\right) = P(\Omega \mid A) = 1.$$

■

LA PROBABILITÀ TOTALE PER LE PMF

Ricordiamo la legge della probabilità totale: per un qualunque evento C e una qualunque partizione $\{E_i\}_{i=1}^M$ di Ω,

$$P(C) = \sum_{i=1}^{M} P(C \mid E_i)\, P(E_i).$$

Specializzandola all'evento $C = \{X = x\}$ si ottiene una formula per la pmf.

Teorema 6.2 — Probabilità totale per le pmf

Se $\{E_i\}_{i=1}^M$ è una partizione di Ω con $P(E_i) > 0$, allora per ogni $x \in \mathcal{X}$:

$$p_X(x) = P(X=x) = \sum_{i=1}^{M} P(\{X=x\} \mid E_i)\, P(E_i) = \sum_{i=1}^{M} p_{X|E_i}(x)\, P(E_i).$$

La pmf di X è una **media pesata** delle pmf condizionate, con pesi le probabilità dei casi.

Dimostrazione

Passo 1. È la legge della probabilità totale (Teorema 3.2) applicata all'evento $C = \{X = x\}$, con $P(\{X = x\} \mid E_i) = p_{X|E_i}(x)$ per definizione di pmf condizionata.

■

Esempio 6.1 — Spezzare una binomiale

Con riferimento all'esempio precedente, $X \sim \mathcal{B}(16, \frac{1}{3})$, si può usare la partizione in due casi $E_1 = \{X > 4\}$, $E_2 = \{X \le 4\}$, che coprono Ω e sono incompatibili:

$$p_X(k) = p_{X|X>4}(k)\, P(X > 4) + p_{X|X\le 4}(k)\, P(X \le 4).$$

Oppure la partizione in tre casi $\{X \le 1\}$, $\{2 \le X \le 6\}$, $\{X \ge 7\}$, che sono a due a due incompatibili e la cui unione è tutto Ω:

$$p_X(k) = p_{X|X\le 1}(k)\, P(X \le 1) + p_{X|2\le X\le 6}(k)\, P(2 \le X \le 6) + p_{X|X\ge 7}(k)\, P(X \ge 7).$$

In questi due casi la formula è quasi ovvia: per ogni k solo uno dei termini è diverso da zero (quello del caso che contiene k), e per quel termine $p_{X|E_i}(k)\, P(E_i) = P(X = k)$. Attenzione però a scegliere bene gli intervalli: una partizione deve contenere ogni valore una e una sola volta.

La formula diventa davvero utile quando i casi E_i **non** sono definiti tramite X, ma descrivono qualcosa che influenza X e che non si conosce.

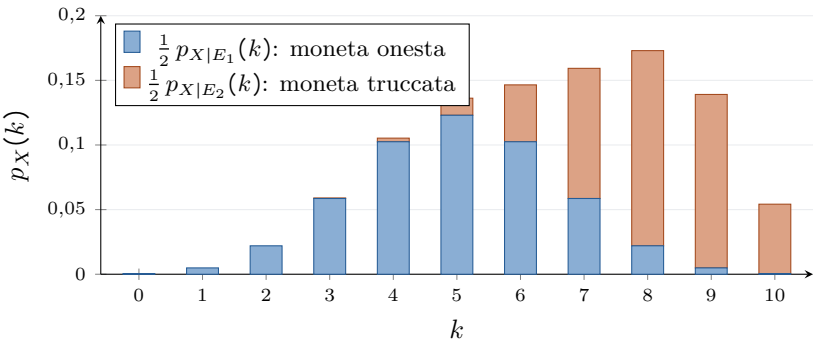
Esempio 6.2 — Due monete in un cassetto

In un cassetto ci sono due monete identiche all'aspetto: una è onesta ($p = 0{,}5$), l'altra è truccata e dà testa con probabilità $p = 0{,}8$. Se ne prende una a caso e la si lancia 10 volte; sia X il numero di teste. I due casi E_1 = «è la moneta onesta» ed E_2 = «è la moneta truccata» hanno probabilità $\frac{1}{2}$ ciascuno, e *sapendo* quale moneta è stata presa X è binomiale:

$$p_{X|E_1} = \mathcal{B}(10;\ 0{,}5), \qquad p_{X|E_2} = \mathcal{B}(10;\ 0{,}8).$$

Per la probabilità totale:

$$p_X(k) = \frac{1}{2}\binom{10}{k} 0{,}5^{10} + \frac{1}{2}\binom{10}{k} 0{,}8^k\, 0{,}2^{10-k}.$$



Ogni barra è la somma di due pezzi: il contributo della moneta onesta (blu) e quello della moneta truccata (arancione). Si può anche andare al contrario, con Bayes: se sono uscite 9 teste, la probabilità che la moneta sia quella truccata è

$$P(E_2 \mid X = 9) = \frac{p_{X|E_2}(9)\, P(E_2)}{p_X(9)} = \frac{0{,}2684 \cdot \frac{1}{2}}{0{,}2684 \cdot \frac{1}{2} + 0{,}0098 \cdot \frac{1}{2}} \approx 0{,}965.$$

LE MEDIE CONDIZIONATE

Un analogo sviluppo è possibile sulle medie. Si calcola la pmf condizionata e poi la sua media.

Media condizionata

La **media di X condizionata all'evento** E (con $P(E) > 0$) è la media della pmf condizionata:

$$E[X \mid E] = \sum_{x \in \mathcal{X}} x\, p_{X|E}(x).$$

Per dimostrare il risultato principale serve scambiare l'ordine di due sommatorie.

Richiamo di matematica: scambiare l'ordine di due sommatorie

Una **somma doppia** $\sum_i \sum_j a_{ij}$ somma tutti i numeri a_{ij} di una tabella, con i che indica la riga e j la colonna. Il totale non dipende dall'ordine: si può sommare prima ogni riga e poi i totali delle righe, oppure prima ogni colonna e poi i totali delle colonne.

	$j=1$	$j=2$	$j=3$	riga
$i=1$	1	2	3	6
$i=2$	4	5	6	15
colonna	5	7	9	**21**

$$\sum_{i=1}^{2}\sum_{j=1}^{3} a_{ij} = 6 + 15 = 21 = 5 + 7 + 9 = \sum_{j=1}^{3}\sum_{i=1}^{2} a_{ij}$$

Inoltre, un fattore che dipende solo dall'indice esterno si può portare dentro o fuori dalla somma interna: $\sum_i \sum_j b_i\, c_j = \sum_i b_i \sum_j c_j$. Con infiniti termini lo scambio resta lecito quando i termini sono tutti ≥ 0, o più in generale quando le serie convergono «bene» (assolutamente): sarà sempre il nostro caso.

Teorema 6.3 — Media e medie condizionate

Se $\{E_m\}_{m=1}^{M}$ è una partizione di Ω con $P(E_m) > 0$, allora

$$E[X] = \sum_{m=1}^{M} P(E_m)\, E[X \mid E_m].$$

La media è la media pesata delle medie condizionate.

Dimostrazione

Passo 1 — Si usa la probabilità totale per la pmf. Nella definizione di media si sostituisce $p_X(x)$ con la formula del Teorema 6.2:

$$E[X] = \sum_{x \in \mathcal{X}} x\, p_X(x) = \sum_{x \in \mathcal{X}} x \sum_{m=1}^{M} p_{X|E_m}(x)\, P(E_m).$$

Passo 2 — Si scambiano le somme. Si porta la x dentro, si scambia l'ordine delle due somme e si porta fuori $P(E_m)$, che non dipende da x:

$$E[X] = \sum_{m=1}^{M} P(E_m) \underbrace{\sum_{x \in \mathcal{X}} x\, p_{X|E_m}(x)}_{E[X|E_m]}.$$

Passo 3 — Si riconosce la media condizionata. La somma interna è, per definizione, $E[X \mid E_m]$.

■

Esempio 6.3 — Le medie condizionate al lavoro

- Per $X \sim \mathcal{B}(16, \frac{1}{3})$ e la partizione $\{X \le 4\}$, $\{X > 4\}$:

$$E[X] = P(X \le 4)\, E[X \mid X \le 4] + P(X > 4)\, E[X \mid X > 4].$$

  Con i numeri: $P(X \le 4) \approx 0{,}339$, $E[X \mid X \le 4] \approx 3{,}29$ (la media dei soli valori da 0 a 4, con la pmf condizionata), $P(X > 4) \approx 0{,}661$, $E[X \mid X > 4] \approx 6{,}38$. Infatti $0{,}339 \cdot 3{,}29 + 0{,}661 \cdot 6{,}38 \approx 1{,}116 + 4{,}217 = 5{,}333 = 16/3$.

- Per le due monete: sapendo quale moneta è stata presa, la media è quella di una binomiale, Np. Quindi

$$E[X] = \frac{1}{2} \cdot (10 \cdot 0{,}5) + \frac{1}{2} \cdot (10 \cdot 0{,}8) = \frac{1}{2} \cdot 5 + \frac{1}{2} \cdot 8 = 6{,}5,$$

  senza bisogno di calcolare la pmf di X.

Funzioni di variabili aleatorie

Si assuma che $X = X(\omega)$ sia una variabile aleatoria con alfabeto $\mathcal{X}$ e pmf $\{p_X(x)\}_{x \in \mathcal{X}}$, e sia $g(x)$ una funzione definita (almeno) sui valori di $\mathcal{X}$. Si forma la nuova variabile aleatoria

$$Y = g(X) = g[X(\omega)] \in \mathcal{Y}, \qquad \text{dove } \mathcal{Y} = g(\mathcal{X})$$

è l'insieme dei valori che g assume sui punti di $\mathcal{X}$. Per esempio, se X è la tensione misurata su un resistore, $Y = X^2/R$ è la potenza dissipata. Il problema è ricavare una caratterizzazione di Y da quella di X:

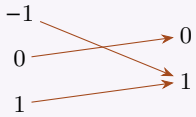
1. la pmf $\{p_Y(y)\}_{y \in \mathcal{Y}}$;
2. la media statistica $E[Y] = \sum_{y \in \mathcal{Y}} y\, p_Y(y)$.

Richiamo di matematica: funzioni iniettive, biunivoche e controimmagine

Una funzione g è **iniettiva** se manda elementi diversi in elementi diversi: $x_1 \neq x_2 \Rightarrow g(x_1) \neq g(x_2)$. Nel disegno a frecce: a ogni punto di arrivo arriva *al massimo una* freccia. Se inoltre ogni elemento del codominio viene raggiunto, la funzione è **biunivoca** (o *biiettiva*): fra i due insiemi c'è una corrispondenza uno a uno, e la funzione si può invertire, $x = g^{-1}(y)$.
La **controimmagine** di un valore y è l'insieme dei punti che vanno in y: $g^{-1}(y) = \{x : g(x) = y\}$. Per una funzione biunivoca contiene un solo punto; in generale può contenerne più d'uno.



$g(x) = 3x$: biunivoca
(una freccia per punto)



$g(x) = x^2$: non iniettiva
$g^{-1}(1) = \{-1, 1\}$

Distinguiamo due casi.

Primo caso: g è biunivoca su $\mathcal{X}$, cioè $|\mathcal{Y}| = |\mathcal{X}|$ e per ogni $y \in \mathcal{Y}$ è definito un solo $x = g^{-1}(y)$. Si tratta solo di una **ridenominazione** dell'alfabeto: i valori cambiano nome, le probabilità restano le stesse.

$$p_Y(y_i) = P(Y = y_i) = P\left(X = g^{-1}(y_i)\right) = P(X = x_i) = p_X(x_i).$$

Secondo caso: g non è iniettiva, cioè associa a più valori di $\mathcal{X}$ un solo valore di $\mathcal{Y}$: $\mathcal{X} = \{x_1, \ldots, x_n\}$, $\mathcal{Y} = \{y_1, \ldots, y_m\}$, con $n > m$. Nei punti di $\mathcal{Y}$ in cui g è invertibile vale la relazione precedente. Per un punto y_k raggiunto da L_k valori diversi,

$$g\left(x_1^{(k)}\right) = g\left(x_2^{(k)}\right) = \cdots = g\left(x_{L_k}^{(k)}\right) = y_k,$$

l'evento $\{Y = y_k\}$ si verifica quando X assume *uno qualsiasi* di quei valori, e le probabilità si sommano (gli eventi $\{X = x_i^{(k)}\}$ sono incompatibili):

$$p_Y(y_k) = P\left(\bigcup_{i=1}^{L_k} \left\{X = x_i^{(k)}\right\}\right) = \sum_{i=1}^{L_k} P\left(X = x_i^{(k)}\right) = \sum_{i=1}^{L_k} p_X\left(x_i^{(k)}\right).$$

Le probabilità «collassano»: tutta la massa dei punti che vanno nello stesso valore si accumula lì. Le due formule si riassumono in una sola.

Da ricordare: pmf di una funzione di variabile aleatoria

$$p_Y(y) = \sum_{x\,:\,g(x)=y} p_X(x) \qquad \text{(si sommano le probabilità della controimmagine di } y\text{)}$$

La media di una funzione di variabile aleatoria

Per la media seguiamo la stessa suddivisione. Se g è biunivoca c'è solo una ridenominazione dell'alfabeto, quindi

$$E[Y] = \sum_{y\in\mathcal{Y}} y\, p_Y(y) = \sum_{x\in\mathcal{X}} g(x)\, p_X(x).$$

La cosa notevole è che la stessa formula vale **sempre**, anche quando g non è iniettiva.

Teorema 6.4 — Teorema fondamentale per il calcolo della media

Se $Y = g(X)$, allora

$$E[Y] = E[g(X)] = \sum_{x\in\mathcal{X}} g(x)\, p_X(x).$$

Per calcolare la media di $g(X)$ non serve conoscere la pmf di Y: basta quella di X.

Dimostrazione

Passo 1 — Si parte dalla definizione per Y. Usando la formula della pmf di Y:

$$E[Y] = \sum_{y\in\mathcal{Y}} y\, p_Y(y) = \sum_{y\in\mathcal{Y}} y \sum_{x\,:\,g(x)=y} p_X(x).$$

Passo 2 — Si porta y dentro. Nella somma interna ogni x soddisfa $g(x) = y$, quindi si può scrivere $g(x)$ al posto di y:

$$E[Y] = \sum_{y\in\mathcal{Y}} \sum_{x\,:\,g(x)=y} g(x)\, p_X(x).$$

Passo 3 — I gruppi coprono tutto $\mathcal{X}$. Ogni $x \in \mathcal{X}$ va in uno e un solo valore $y = g(x)$: le controimmagini dei diversi y dividono $\mathcal{X}$ in gruppi disgiunti che lo coprono tutto. Sommare gruppo per gruppo e poi sommare i gruppi equivale a sommare su tutti gli x:

$$E[Y] = \sum_{x\in\mathcal{X}} g(x)\, p_X(x).$$

■

Il teorema si chiama anche **teorema del valore medio**. È comodissimo: per esempio $E[X^2] = \sum_x x^2\, p_X(x)$, senza dover prima trovare la pmf di X^2.

La media di $g(X)$ non è g della media

In generale $E[g(X)] \neq g(E[X])$. Se X vale -1 o $+1$ con probabilità $\frac{1}{2}$ ciascuno, allora $E[X] = 0$ e quindi $(E[X])^2 = 0$, ma X^2 vale sempre 1 e $E[X^2] = 1$. Si può portare la funzione «fuori» dalla media solo in casi speciali, come le funzioni lineari che vedremo nel prossimo capitolo.

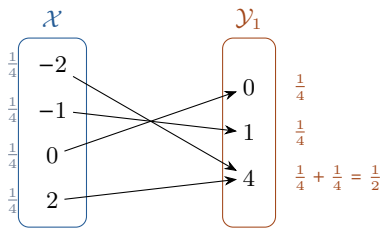
Un esempio completo

Sia $X \sim \mathcal{U}(\{-2,-1,0,2\})$: ognuno dei quattro valori ha probabilità $\frac{1}{4}$. Troviamo la pmf delle due variabili aleatorie

$$Y_1 = X^2 \quad \left(g(x) = x^2\right), \qquad Y_2 = 3\sin\left(\frac{2\pi}{5}X\right) \quad \left(g(x) = 3\sin\left(\frac{2\pi}{5}x\right)\right).$$

Il quadrato

I valori di Y_1 sono $(-2)^2 = 4$, $(-1)^2 = 1$, $0^2 = 0$ e $2^2 = 4$: l'alfabeto è $\mathcal{Y}_1 = \{0,1,4\}$, con $|\mathcal{Y}_1| = 3 < |\mathcal{X}| = 4$. La funzione non è iniettiva: -2 e 2 vanno entrambi in 4.



$$p_{Y_1}(0) = P(X=0) = \frac{1}{4}, \qquad p_{Y_1}(1) = P(X=-1) = \frac{1}{4}, \qquad p_{Y_1}(4) = P(\{X=-2\} \cup \{X=2\}) = P(X=-2) + P(X=2) = \frac{1}{2}.$$

La media si può calcolare in due modi, e il teorema fondamentale garantisce che danno lo stesso risultato:

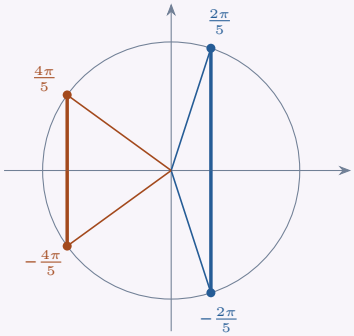
$$E[Y_1] = 0\cdot\frac{1}{4} + 1\cdot\frac{1}{4} + 4\cdot\frac{1}{2} = \frac{9}{4}, \qquad E[Y_1] = \sum_x x^2\, p_X(x) = \frac{4+1+0+4}{4} = \frac{9}{4}.$$

Il seno

Per Y_2 serve ricordare la funzione seno.

Richiamo di matematica: il seno e i radianti

Si disegni una circonferenza di raggio 1 centrata nell'origine. Un angolo θ si misura in **radianti**: è la lunghezza dell'arco che l'angolo stacca sulla circonferenza, partendo dal punto $(1,0)$ e girando in senso antiorario. Il giro completo, la lunghezza della circonferenza, è 2π radianti, cioè 360°; quindi π radianti sono 180° e $\frac{2\pi}{5}$ radianti sono 72°. Angoli negativi si misurano in senso orario.
Il **seno** $\sin\theta$ è l'altezza (la coordinata verticale) del punto della circonferenza raggiunto dopo l'angolo θ.



I tratti spessi verticali sono i seni. Si vede che $\sin\frac{2\pi}{5} \approx 0{,}951$ (72°) è più alto di $\sin\frac{4\pi}{5} \approx 0{,}588$ (144°), e che il seno di un angolo negativo è l'opposto: $\sin(-\theta) = -\sin\theta$ (il punto si riflette sotto l'asse orizzontale).

Calcoliamo i quattro valori di Y_2, usando $\sin(-\theta) = -\sin\theta$:

$$X=-2: \quad 3\sin\left(-\tfrac{4\pi}{5}\right) = -3\sin\tfrac{4\pi}{5} \approx -1{,}763 = \alpha_1, \qquad X=-1: \quad 3\sin\left(-\tfrac{2\pi}{5}\right) = -3\sin\tfrac{2\pi}{5} \approx -2{,}853 = \alpha_2,$$
$$X=0: \quad 3\sin 0 = 0 = \alpha_3, \qquad X=2: \quad 3\sin\tfrac{4\pi}{5} \approx 1{,}763 = \alpha_4.$$

I quattro valori sono tutti diversi: $|\mathcal{Y}_2| = 4 = |\mathcal{X}|$, la funzione è biunivoca su $\mathcal{X}$, e c'è solo una ridenominazione:

$$p_{Y_2}(\alpha_i) = \frac{1}{4}, \qquad i = 1,2,3,4.$$

La variabile aleatoria Y_2 assume uniformemente i quattro valori di $\mathcal{Y}_2$. La sua media, con il teorema fondamentale, è $E[Y_2] = \frac{1}{4}(-1{,}763 - 2{,}853 + 0 + 1{,}763) = -\frac{2{,}853}{4} \approx -0{,}713$: i due valori $\pm 1{,}763$ si cancellano.

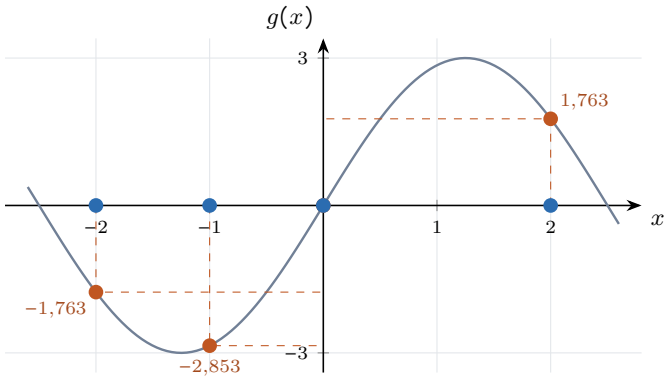


Figura 6.2: *La funzione* $g(x) = 3\sin\left(\frac{2\pi}{5}x\right)$*: i quattro valori dell'alfabeto di* X *(in blu sull'asse orizzontale) vanno in quattro valori diversi (in arancione), quindi* Y_2 *è ancora uniforme.*

In sintesi

- La **pmf condizionata** a un evento A è $p_{X|A}(x) = P(\{X = x\} \cap A)/P(A)$: si scartano i risultati fuori da A e si «rialzano» gli altri in proporzione. È ancora una pmf.
- **Probabilità totale per le pmf**: $p_X(x) = \sum_i p_{X|E_i}(x)\, P(E_i)$; utilissima quando i casi E_i descrivono qualcosa di ignoto che influenza X (le due monete).
- **Media condizionata**: $E[X \mid E] = \sum_x x\, p_{X|E}(x)$, e $E[X] = \sum_m P(E_m)\, E[X \mid E_m]$.
- Se $Y = g(X)$: $p_Y(y) = \sum_{x:g(x)=y} p_X(x)$. Se g è biunivoca è una ridenominazione, altrimenti le probabilità dei punti che vanno nello stesso valore si sommano.
- **Teorema fondamentale**: $E[g(X)] = \sum_x g(x)\, p_X(x)$, senza bisogno della pmf di Y. In generale $E[g(X)] \neq g(E[X])$.

Varianza e disuguaglianze

La media dice *dove* si trova una variabile aleatoria, ma non *quanto* è sparpagliata attorno a quel punto. Due variabili possono avere la stessa media ed essere diversissime: una sempre vicina alla media, l'altra capace di allontanarsene molto. In questo capitolo introduciamo le misure della dispersione, il **valore quadratico medio**, la **varianza** e la **deviazione standard**; le calcoliamo per la binomiale, l'uniforme e la Poisson (e per farlo ci serviranno le **derivate**, spiegate da zero); infine, con le disuguaglianze di **Markov** e di **Chebyshev**, scopriamo che cosa ci dice davvero la deviazione standard.

Misurare la dispersione

Si considerino due variabili aleatorie:

$$X: \quad P(X=4)=\tfrac{1}{4},\ P(X=5)=\tfrac{1}{2},\ P(X=6)=\tfrac{1}{4}; \qquad Y: \quad P(Y=1)=\tfrac{1}{4},\ P(Y=5)=\tfrac{1}{2},\ P(Y=9)=\tfrac{1}{4}.$$

Entrambe hanno media 5 (le pmf sono simmetriche attorno a 5), ma Y si allontana dalla media molto più di X.

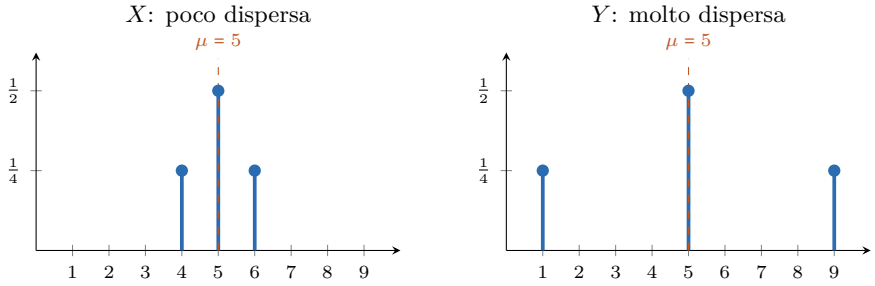


Figura 7.1: *Stessa media, dispersione molto diversa.*

L'idea naturale è misurare, in media, quanto la variabile si allontana dalla sua media μ_X. Ma la media dello scarto $X-\mu_X$ non funziona: gli scarti positivi e quelli negativi si compensano, e il risultato è sempre zero, $E[X-\mu_X]=E[X]-\mu_X=0$ (lo dimostreremo fra poco, con la linearità della media). Per evitare le compensazioni si rendono positivi tutti gli scarti **elevandoli al quadrato**.

Valore quadratico medio e varianza

Data una variabile aleatoria $X\sim p_X(x)$, $x\in\mathcal{X}$, con media $\mu_X=E[X]$, definiamo quattro grandezze. Tutte si calcolano con il teorema fondamentale (Teorema 6.4), cioè come medie di una funzione di X.

Valore quadratico medio e valore efficace

Il **valore quadratico medio** (*mean square*) di X è la media del suo quadrato:

$$X_{rms}^2=E[X^2]=\sum_{x\in\mathcal{X}}x^2\,p_X(x).$$

Il **valore efficace** (*root mean square*) è la sua radice: $X_{rms}=\sqrt{E[X^2]}=\sqrt{\sum_{x\in\mathcal{X}}x^2\,p_X(x)}$.

Varianza e deviazione standard

La **varianza** di X è la media del quadrato dello scarto dalla media:

$$\sigma_X^2 = E\left[(X-\mu_X)^2\right] = \sum_{x\in\mathcal{X}} (x-\mu_X)^2\, p_X(x).$$

La **deviazione standard** è la sua radice: $\sigma_X = \sqrt{E[(X-\mu_X)^2]} = \sqrt{\sum_x (x-\mu_X)^2\, p_X(x)}$.

La deviazione standard ha la stessa unità di misura di X (se X è in metri, σ_X è in metri, mentre σ_X^2 è in metri quadrati): per questo è la misura di dispersione che si usa per «leggere» i risultati.

Teorema 7.1 — Varianza, valore quadratico medio e media

$$\sigma_X^2 = X_{rms}^2 - \mu_X^2 = E[X^2] - E^2[X], \qquad \sigma_X = \sqrt{X_{rms}^2 - \mu_X^2} = \sqrt{E[X^2] - E^2[X]},$$

dove $E^2[X]$ indica $(E[X])^2$.

Dimostrazione

Passo 1 — Si sviluppa il quadrato. $(x-\mu_X)^2 = x^2 - 2x\mu_X + \mu_X^2$, quindi

$$\sigma_X^2 = \sum_{x\in\mathcal{X}} \left(x^2 - 2x\mu_X + \mu_X^2\right) p_X(x).$$

Passo 2 — Si spezza la somma in tre. Le costanti $2\mu_X$ e μ_X^2 escono dalle sommatorie:

$$\sigma_X^2 = \sum_x x^2\, p_X(x) - 2\mu_X \sum_x x\, p_X(x) + \mu_X^2 \sum_x p_X(x).$$

Passo 3 — Si riconoscono i pezzi. La prima somma è $E[X^2] = X_{rms}^2$, la seconda è $E[X] = \mu_X$, la terza è 1 (la pmf somma a 1):

$$\sigma_X^2 = X_{rms}^2 - 2\mu_X^2 + \mu_X^2 = X_{rms}^2 - \mu_X^2.$$

■

Da ricordare: varianza

$$\sigma_X^2 = E\left[(X-\mu_X)^2\right] = E[X^2] - \mu_X^2 \qquad \sigma_X = \sqrt{\sigma_X^2}$$

Esempio 7.1 — Le due variabili dell'inizio

Per X: $\sigma_X^2 = (4-5)^2 \cdot \frac{1}{4} + (5-5)^2 \cdot \frac{1}{2} + (6-5)^2 \cdot \frac{1}{4} = \frac{1}{2}$, quindi $\sigma_X \approx 0{,}71$. Per Y: $\sigma_Y^2 = (1-5)^2 \cdot \frac{1}{4} + 0 + (9-5)^2 \cdot \frac{1}{4} = 8$, quindi $\sigma_Y \approx 2{,}83$. La varianza ha colto esattamente la differenza che si vedeva nei grafici.

Con la seconda formula: $E[X^2] = 16 \cdot \frac{1}{4} + 25 \cdot \frac{1}{2} + 36 \cdot \frac{1}{4} = 25{,}5$ e $\sigma_X^2 = 25{,}5 - 5^2 = 0{,}5$. Stesso risultato.

Perché si chiama «valore efficace»

Il nome viene dall'elettrotecnica. La potenza dissipata da un resistore R con tensione v è v^2/R: dipende dal *quadrato* della tensione. Se la tensione varia nel tempo, la potenza media dipende dalla media di v^2, cioè dal valore quadratico medio. Il valore efficace è la tensione costante che dissiperebbe la stessa potenza media: i 230 volt della presa di casa sono il valore efficace di una tensione alternata che oscilla fra circa -325 e $+325$ volt.

La varianza della binomiale

La variabile di Bernoulli

Cominciamo dal caso $N = 1$, $X \sim \mathcal{B}(1, p)$: la variabile vale 1 con probabilità p e 0 con probabilità $1 - p$.

$$E[X] = 1 \cdot p + 0 \cdot (1-p) = p, \qquad E[X^2] = 1^2 \cdot p + 0^2 \cdot (1-p) = p,$$

$$\sigma_X^2 = E[X^2] - E^2[X] = p - p^2 = p(1-p), \qquad \sigma_X = \sqrt{p(1-p)}.$$

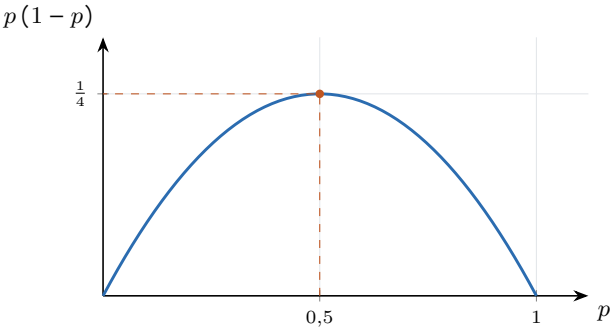


Figura 7.2: *La varianza di una Bernoulli in funzione di p. È nulla per $p = 0$ e $p = 1$ (il risultato è certo) ed è massima, $\frac{1}{4}$, per $p = \frac{1}{2}$: la moneta onesta è la più imprevedibile.*

Il caso generale

Per $X \sim \mathcal{B}(N, p)$ serve $E[X^2]$:

$$E[X^2] = \sum_{x \in \mathcal{X}} x^2 \, p_X(x) = \sum_{k=0}^{N} k^2 \binom{N}{k} p^k q^{N-k} = \sum_{k=1}^{N} k^2 \, \frac{N!}{k!\,(N-k)!} \, p^k q^{N-k} = Np \sum_{k=1}^{N} k \, \frac{(N-1)!}{(k-1)!\,(N-k)!} \, p^{k-1} q^{N-k},$$

dove, come per la media, si è tolto il termine $k = 0$ (che è nullo), si è semplificato un k con il fattoriale ($k^2/k! = k/(k-1)!$) e si sono portati fuori N (da $N! = N\,(N-1)!$) e un p. A differenza della media, però, resta un fattore k davanti, e la somma non è più un binomio di Newton. Il trucco per toglierlo è usare una **derivata**.

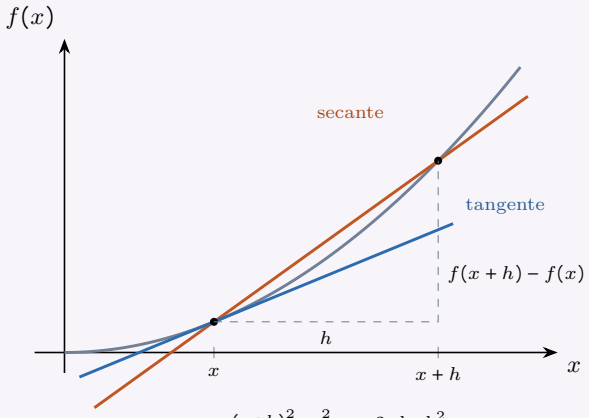
Richiamo di matematica: la derivata

Si disegni il grafico di una funzione $f(x)$. La **derivata** $f'(x)$ dice quanto è **ripida** la curva nel punto x: è la pendenza della retta tangente, cioè di quanto sale la curva per ogni passo verso destra.
Per calcolarla si prende un secondo punto vicino, $x + h$. La retta che passa per i due punti (la *secante*) ha pendenza «salita diviso spostamento», il **rapporto incrementale**:

$$\frac{f(x+h) - f(x)}{h}.$$

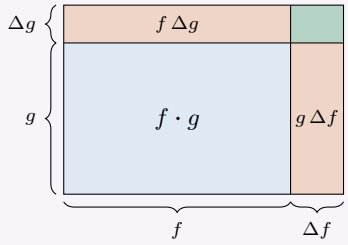
Quando h si avvicina a zero, il secondo punto scivola sul primo e la secante diventa la tangente. La derivata è il limite del rapporto incrementale:

$$f'(x) = \frac{\mathrm{d}f}{\mathrm{d}x} = \lim_{h \to 0} \frac{f(x+h) - f(x)}{h}.$$



Esempio: per $f(x) = x^2$ il rapporto incrementale è $\frac{(x+h)^2 - x^2}{h} = \frac{2xh + h^2}{h} = 2x + h$, che per $h \to 0$ tende a $2x$. Quindi $(x^2)' = 2x$: la parabola è piatta in $x = 0$ e sempre più ripida allontanandosi.
Le regole che ci servono:

- una costante ha derivata nulla: $(c)' = 0$ (il suo grafico è piatto);
- $(x^n)' = n\,x^{n-1}$. Per il binomio di Newton $(x+h)^n = x^n + n\,x^{n-1}h +$ (termini con h^2, h^3, …); togliendo x^n e dividendo per h resta $n\,x^{n-1} +$ (termini con h), che tendono a zero;
- **linearità**: $(af + bg)' = af' + bg'$; in particolare la derivata di una somma (anche di molti termini) è la somma delle derivate;
- **regola del prodotto**: $(fg)' = f'g + fg'$ (spiegata dal disegno qui sotto);
- $\big((x+c)^m\big)' = m\,(x+c)^{m-1}$: spostare il grafico in orizzontale non cambia le pendenze.



Il prodotto $f \cdot g$ è l'area di un rettangolo. Quando x cresce di h, i lati crescono di Δf e Δg, e l'area cresce di $f\,\Delta g + g\,\Delta f + \Delta f\,\Delta g$ (le strisce arancioni e il quadratino verde). Dividendo per h e mandando h a zero, $\Delta f/h \to f'$, $\Delta g/h \to g'$, mentre il quadratino, che è piccolo «due volte», sparisce: resta $f'g + fg'$.

Derivare rispetto a una lettera tenendo ferme le altre. Se un'espressione contiene due lettere, per esempio p e q, si può derivare rispetto a p trattando q come un numero fisso: $\frac{\mathrm{d}}{\mathrm{d}p}\left(p^2 q^3\right) = 2p\,q^3$. Lo useremo con q, che solo alla fine sostituiremo con $1 - p$.

Teorema 7.2 — Varianza della binomiale

Se $X \sim \mathcal{B}(N, p)$, allora

$$E[X^2] = Np\,(1-p) + N^2p^2, \qquad \sigma_X^2 = Np\,(1-p), \qquad \sigma_X = \sqrt{Np\,(1-p)}.$$

Dimostrazione — il trucco della derivata

Passo 1 — L'idea. Un fattore k davanti a p^{k-1} è proprio quello che produce la derivata: $k\,p^{k-1} = \frac{\mathrm{d}}{\mathrm{d}p}\,p^k$. Trattando q come una lettera indipendente da p (e sostituendo $q = 1-p$ solo alla fine), ogni termine della somma è la derivata rispetto a p di un termine senza il fattore k:

$$E[X^2] = Np \sum_{k=1}^{N} \frac{(N-1)!}{(k-1)!\,(N-k)!}\,\frac{\mathrm{d}}{\mathrm{d}p}\left(p^k\right) q^{N-k} = Np\,\frac{\mathrm{d}}{\mathrm{d}p}\left[\sum_{k=1}^{N} \frac{(N-1)!}{(k-1)!\,[(N-1)-(k-1)]!}\,p^k q^{N-k}\right]_{q=1-p}$$

(la derivata di una somma è la somma delle derivate, e i fattori che non contengono p restano fuori dalla derivata).

Passo 2 — Si riconosce un binomio di Newton. Posto $l = k-1$, e staccando un fattore p da $p^k = p \cdot p^l$:

$$\sum_{k=1}^{N} \frac{(N-1)!}{(k-1)!\,[(N-1)-(k-1)]!}\,p^k q^{N-k} = p \sum_{l=0}^{N-1} \frac{(N-1)!}{l!\,[(N-1)-l]!}\,p^l q^{N-1-l} = p\,(p+q)^{N-1}.$$

Passo 3 — Si deriva. Con la regola del prodotto, e ricordando che q è fisso:

$$\frac{\mathrm{d}}{\mathrm{d}p}\left[p\,(p+q)^{N-1}\right] = (p+q)^{N-1} + p\,(N-1)\,(p+q)^{N-2}.$$

Passo 4 — Si sostituisce $q = 1-p$. Ora $p+q=1$, e le sue potenze valgono 1:

$$E[X^2] = Np\,[1 + p\,(N-1)] = Np\,[1 + Np - p] = Np\,(1-p) + N^2p^2.$$

Passo 5 — La varianza. Siccome $\mu_X = Np$ (Teorema 5.3), il secondo addendo è proprio μ_X^2:

$$\sigma_X^2 = E[X^2] - \mu_X^2 = Np\,(1-p) + N^2p^2 - N^2p^2 = Np\,(1-p).$$

■

Lo stesso risultato si ottiene in un modo più semplice, che evita le derivate: invece di $E[X^2]$ si calcola $E[X(X-1)]$, perché il fattore $k(k-1)$ si semplifica con il fattoriale ancora meglio di k^2.

Dimostrazione — secondo modo: il momento fattoriale

Passo 1 — Si calcola $E[X(X-1)]$. Per il teorema fondamentale, con $g(x) = x(x-1)$. I termini con $k=0$ e $k=1$ sono nulli; per $k \geq 2$, $\frac{k(k-1)}{k!} = \frac{1}{(k-2)!}$:

$$E[X(X-1)] = \sum_{k=2}^{N} k(k-1)\,\frac{N!}{k!\,(N-k)!}\,p^k(1-p)^{N-k} = N(N-1)\,p^2 \sum_{k=2}^{N} \frac{(N-2)!}{(k-2)!\,[N-2-(k-2)]!}\,p^{k-2}(1-p)^{N-2-(k-2)}.$$

Passo 2 — Newton ancora una volta. Con $l = k-2$ e $M = N-2$ la somma diventa $\sum_{l=0}^{M} \frac{M!}{l!\,(M-l)!}\,p^l(1-p)^{M-l} = 1$, quindi $E[X(X-1)] = N(N-1)\,p^2$.

Passo 3 — Si torna a $E[X^2]$. Sempre per il teorema fondamentale, la media di una differenza si spezza: $E[X(X-1)] = \sum_x (x^2 - x)\,p_X(x) = E[X^2] - E[X]$. Quindi

$$E[X^2] = E[X(X-1)] + E[X] = N(N-1)\,p^2 + Np = N^2p^2 - Np^2 + Np = Np\,(1-p) + N^2p^2.$$

■

Da ricordare: binomiale $\mathcal{B}(N,p)$

$$\mu_X = Np \qquad X^2_{rms} = Np\,(1-p) + N^2p^2 \qquad \sigma_X^2 = Np\,(1-p) \qquad \sigma_X = \sqrt{Np\,(1-p)}$$

LA VARIANZA DELL'UNIFORME

Sia $X \sim \mathcal{U}(\{0, 1, \ldots, M-1\})$, per cui $\mu_X = \frac{M-1}{2}$ (Capitolo 5). Il valore quadratico medio è

$$X_{rms}^2 = \frac{1}{M}\sum_{k=0}^{M-1} k^2 = \frac{1}{M}\sum_{k=1}^{M-1} k^2,$$

e serve la somma dei primi quadrati. Invece di cercarla per tentativi, la ricaviamo con un trucco che spiega da dove viene la formula.

Richiamo di matematica: le somme telescopiche

Una somma in cui ogni termine è una differenza fra due valori consecutivi, $a_{l+1} - a_l$, si semplifica quasi tutta:

$$\sum_{l=1}^{n}(a_{l+1} - a_l) = (a_2 - a_1) + (a_3 - a_2) + (a_4 - a_3) + \cdots + (a_{n+1} - a_n) = a_{n+1} - a_1.$$

Ogni a_l intermedio compare una volta con il più e una volta con il meno, e si cancella: restano solo l'ultimo e il primo. Il nome viene dal cannocchiale (telescopio) che si chiude, con i tubi che rientrano uno nell'altro.

Teorema 7.3 — Somma dei primi quadrati

Per ogni naturale $n \geq 1$:

$$\sum_{l=1}^{n} l^2 = 1^2 + 2^2 + \cdots + n^2 = \frac{n\,(n+1)\,(2n+1)}{6}.$$

Dimostrazione — con una somma telescopica

Passo 1 — Il cubo di un binomio. Per ogni l: $(l+1)^3 = l^3 + 3l^2 + 3l + 1$, quindi

$$(l+1)^3 - l^3 = 3l^2 + 3l + 1.$$

Passo 2 — Si somma da 1 a n. A sinistra c'è una somma telescopica, che vale $(n+1)^3 - 1^3$. A destra si spezza la somma in tre, chiamando S la somma dei quadrati che cerchiamo e usando la somma di Gauss (Teorema 5.4):

$$(n+1)^3 - 1 = 3S + 3\,\frac{n\,(n+1)}{2} + n.$$

Passo 3 — Si ricava S. Si porta tutto il resto a sinistra e si raccoglie $(n+1)$:

$$3S = (n+1)^3 - 1 - n - \frac{3n\,(n+1)}{2} = (n+1)^3 - (n+1) - \frac{3n\,(n+1)}{2} = (n+1)\left[(n+1)^2 - 1 - \frac{3n}{2}\right].$$

Dentro la parentesi: $(n+1)^2 - 1 - \frac{3n}{2} = n^2 + 2n - \frac{3n}{2} = n^2 + \frac{n}{2} = \frac{n\,(2n+1)}{2}$. Quindi $3S = \frac{n\,(n+1)\,(2n+1)}{2}$ e $S = \frac{n\,(n+1)\,(2n+1)}{6}$.

Passo 4 — Una verifica. Con $n = 3$: $1 + 4 + 9 = 14$ e $\frac{3 \cdot 4 \cdot 7}{6} = 14$.

■

Teorema 7.4 — Varianza dell'uniforme

Se $X \sim \mathcal{U}(\{0, 1, \ldots, M-1\})$:

$$\mu_X = \frac{M-1}{2}, \qquad X_{rms}^2 = \frac{(M-1)(2M-1)}{6}, \qquad \sigma_X^2 = \frac{M^2-1}{12}.$$

Dimostrazione

Passo 1 — Il valore quadratico medio. Con la somma dei quadrati, $n = M - 1$:

$$X_{rms}^2 = \frac{1}{M} \cdot \frac{(M-1)\,M\,(2M-1)}{6} = \frac{(M-1)(2M-1)}{6}.$$

Passo 2 — La varianza. Si sottrae $\mu_X^2 = (M-1)^2/4$ e si porta tutto al denominatore comune 12:

$$\sigma_X^2 = \frac{(M-1)(2M-1)}{6} - \frac{(M-1)^2}{4} = \frac{2(M-1)(2M-1) - 3(M-1)^2}{12}.$$

Passo 3 — Si sviluppano i prodotti.

$$\sigma_X^2 = \frac{2\,(2M^2 - M - 2M + 1) - 3\,(M^2 - 2M + 1)}{12} = \frac{4M^2 - 6M + 2 - 3M^2 + 6M - 3}{12} = \frac{M^2 - 1}{12}.$$

■

Esempio 7.2 — Dado e byte

- Un byte casuale ($M = 256$): $\sigma_X^2 = \frac{65\,536-1}{12} \approx 5\,461$ e $\sigma_X \approx 73{,}9$.
- Un dado onesto ha valori $1, \dots, 6$: sono i valori $0, \dots, 5$ ($M = 6$) aumentati di 1. Vedremo fra poco che aggiungere una costante non cambia la varianza, quindi $\sigma_X^2 = \frac{36-1}{12} = \frac{35}{12} \approx 2{,}92$ e $\sigma_X \approx 1{,}71$.

La varianza della Poisson

Per la Poisson useremo lo stesso trucco della derivata, questa volta su una serie. Serve sapere come si deriva l'esponenziale; è anche l'occasione per capire, finalmente, da dove viene la serie esponenziale.

Richiamo di matematica: la derivata dell'esponenziale e la serie esponenziale

La derivata di e^x è e^x. Il rapporto incrementale è

$$\frac{e^{x+h} - e^x}{h} = e^x\,\frac{e^h - 1}{h},$$

e il secondo fattore tende a 1: è la proprietà che distingue il numero e da tutte le altre basi.

h	0,1	0,01	0,001	0,0001
$\frac{e^h - 1}{h}$	1,0517	1,0050	1,0005	1,00005

Quindi $(e^x)' = e^x$: la curva e^x è ripida esattamente quanto è alta (con la base 2 la pendenza in 0 sarebbe circa 0,69, con la base 3 circa 1,10; con e è esattamente 1).

La derivata di e^{-x}. Siccome $e^{-x} \cdot e^x = 1$, derivando con la regola del prodotto si ottiene $(e^{-x})'\,e^x + e^{-x}\,e^x = 0$, cioè $(e^{-x})' = -e^{-x}$.

Da dove viene la serie. Sia $S(x) = \sum_{k=0}^{\infty} \frac{x^k}{k!} = 1 + x + \frac{x^2}{2} + \cdots$. Una serie di potenze come questa si può derivare termine a termine, e $\left(\frac{x^k}{k!}\right)' = \frac{k\,x^{k-1}}{k!} = \frac{x^{k-1}}{(k-1)!}$: ogni termine diventa il precedente, quindi $S'(x) = S(x)$. Inoltre $S(0) = 1$. Anche e^x ha queste due proprietà, e le due funzioni coincidono: la funzione $D(x) = S(x)\,e^{-x}$ ha derivata

$$D'(x) = S'(x)\,e^{-x} + S(x)\,(e^{-x})' = S(x)\,e^{-x} - S(x)\,e^{-x} = 0,$$

quindi è costante (una curva con pendenza sempre nulla è piatta) e vale $D(0) = 1$. Allora $S(x)\,e^{-x} = 1$, cioè $S(x) = e^x$.

Teorema 7.5 — Varianza della Poisson

Se $X \sim \mathcal{P}(\lambda)$:

$$\mu_X = \lambda, \qquad X_{rms}^2 = \lambda + \lambda^2, \qquad \sigma_X^2 = \lambda, \qquad \sigma_X = \sqrt{\lambda}.$$

Per una variabile di Poisson la media e la varianza coincidono.

Dimostrazione — il trucco della derivata

Passo 1 — Si prepara la somma. Si toglie il termine $k = 0$ (nullo), si semplifica $k^2/k! = k/(k-1)!$ e si porta fuori $e^{-\lambda}$ e un λ:

$$X_{rms}^2 = e^{-\lambda} \sum_{k=0}^{\infty} k^2 \frac{\lambda^k}{k!} = e^{-\lambda} \sum_{k=1}^{\infty} k \frac{\lambda^k}{(k-1)!} = e^{-\lambda}\, \lambda \sum_{k=1}^{\infty} k \frac{\lambda^{k-1}}{(k-1)!}.$$

Passo 2 — Il fattore k diventa una derivata. $k\,\lambda^{k-1} = \frac{\mathrm{d}}{\mathrm{d}\lambda}\lambda^k$, e la serie si deriva termine a termine:

$$X_{rms}^2 = e^{-\lambda}\, \lambda \frac{\mathrm{d}}{\mathrm{d}\lambda}\left(\sum_{k=1}^{\infty} \frac{\lambda^k}{(k-1)!}\right) = e^{-\lambda}\, \lambda \frac{\mathrm{d}}{\mathrm{d}\lambda}\left(\lambda \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!}\right).$$

Passo 3 — Si riconosce l'esponenziale. Posto $l = k - 1$, la serie è $\sum_{l=0}^{\infty} \frac{\lambda^l}{l!} = e^{\lambda}$:

$$X_{rms}^2 = e^{-\lambda}\, \lambda \frac{\mathrm{d}}{\mathrm{d}\lambda}\left(\lambda\, e^{\lambda}\right).$$

Passo 4 — Si deriva con la regola del prodotto. $\frac{\mathrm{d}}{\mathrm{d}\lambda}\left(\lambda\, e^{\lambda}\right) = e^{\lambda} + \lambda\, e^{\lambda}$, quindi

$$X_{rms}^2 = e^{-\lambda}\, \lambda \left(e^{\lambda} + \lambda\, e^{\lambda}\right) = \lambda + \lambda^2.$$

Passo 5 — La varianza. $\sigma_X^2 = X_{rms}^2 - \mu_X^2 = \lambda + \lambda^2 - \lambda^2 = \lambda$.

■

Dimostrazione — secondo modo: il momento fattoriale

Passo 1. I termini con $k = 0$ e $k = 1$ sono nulli; per $k \geq 2$ si semplifica $k(k-1)/k! = 1/(k-2)!$ e, posto $l = k - 2$:

$$E[X(X-1)] = \sum_{k=2}^{\infty} k\,(k-1)\, e^{-\lambda} \frac{\lambda^k}{k!} = e^{-\lambda}\, \lambda^2 \sum_{k=2}^{\infty} \frac{\lambda^{k-2}}{(k-2)!} = e^{-\lambda}\, \lambda^2 \sum_{l=0}^{\infty} \frac{\lambda^l}{l!} = e^{-\lambda}\, \lambda^2\, e^{\lambda} = \lambda^2.$$

Passo 2. Quindi $E[X^2] = E[X(X-1)] + E[X] = \lambda^2 + \lambda$.

■

LE PROPRIETÀ DELLA MEDIA E DELLA VARIANZA

Teorema 7.6 — Media e varianza di una trasformazione lineare

Siano a e b costanti reali e $Y = aX + b$. Allora:

a) $E[aX + b] = a\,E[X] + b$ (in particolare $E[b] = b$: la media di una costante è la costante);
b) $\sigma_Y^2 = a^2 \sigma_X^2$: la costante b non modifica la varianza, e la costante a va elevata al quadrato (quindi $\sigma_Y = |a|\,\sigma_X$);
c) $E[Y^2] = Y_{rms}^2 = a^2 X_{rms}^2 + b^2 + 2ab\,\mu_X$.

Dimostrazione

Passo 1 — La media. Per il teorema fondamentale, con $g(x) = ax + b$:

$$E[aX + b] = \sum_x (ax + b)\, p_X(x) = a \sum_x x\, p_X(x) + b \sum_x p_X(x) = a\, E[X] + b.$$

Passo 2 — La varianza. Per il passo precedente $\mu_Y = a\mu_X + b$, quindi lo scarto di Y dalla sua media è $Y - \mu_Y = aX + b - a\mu_X - b = a\,(X - \mu_X)$: la b si cancella. Allora

$$\sigma_Y^2 = E\left[(Y - \mu_Y)^2\right] = E\left[a^2 (X - \mu_X)^2\right] = a^2\, E\left[(X - \mu_X)^2\right] = a^2 \sigma_X^2,$$

dove si è usato il passo 1 per portare fuori la costante a^2.

Passo 3 — Il valore quadratico medio. Per il Teorema 7.1, $E[Y^2] = \sigma_Y^2 + \mu_Y^2$:

$$E[Y^2] = a^2\sigma_X^2 + (a\mu_X + b)^2 = a^2\sigma_X^2 + a^2\mu_X^2 + b^2 + 2ab\,\mu_X = a^2\left(\sigma_X^2 + \mu_X^2\right) + b^2 + 2ab\,\mu_X = a^2 X_{rms}^2 + b^2 + 2ab\,\mu_X.$$

■

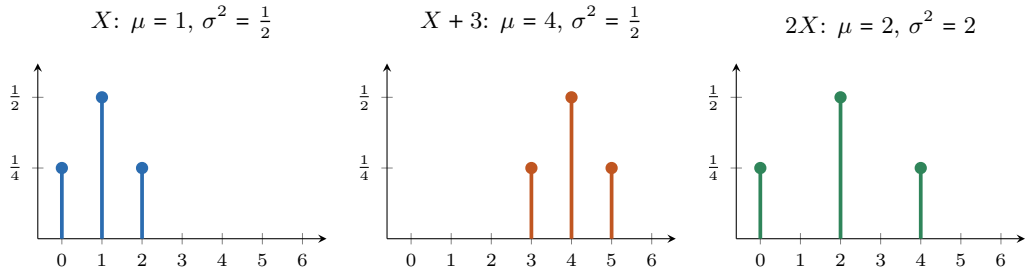


Figura 7.3: *Aggiungere una costante sposta la pmf ma non la allarga: la varianza resta la stessa. Moltiplicare per 2 allarga le distanze di 2 volte, quindi la varianza (che è una media di distanze al quadrato) di 4 volte.*

Altre tre proprietà discendono direttamente dalle definizioni:

- se $X(\omega) \geq 0$ per ogni $\omega \in \Omega$ (una variabile aleatoria **non negativa**), allora $E[X] = \sum_x x\, p_X(x) \geq 0$, perché è una somma di prodotti di quantità non negative;
- $\sigma_X^2 \geq 0$ sempre, perché $\sigma_X^2 = \sum_x (x - \mu_X)^2 p_X(x)$ è una somma di prodotti di quantità non negative (o, se si preferisce, la media della variabile non negativa $(X - \mu_X)^2$);
- per le variabili a **media nulla** ($\mu_X = 0$) varianza e valore quadratico medio coincidono: $\sigma_X^2 = X_{rms}^2$.

In particolare, ponendo $a = 1$ e $b = -\mu_X$ nella proprietà a): $E[X - \mu_X] = \mu_X - \mu_X = 0$, come avevamo anticipato all'inizio del capitolo.

Variabile	**Alfabeto**	**pmf**	**Media**	**Varianza**
Bernoulli $\mathcal{B}(1,p)$	$\{0,1\}$	$p_X(1) = p$, $p_X(0) = 1-p$	p	$p(1-p)$
binomiale $\mathcal{B}(N,p)$	$\{0,\dots,N\}$	$\binom{N}{k} p^k (1-p)^{N-k}$	Np	$Np(1-p)$
uniforme $\mathcal{U}(\{0,\dots,M-1\})$	$\{0,\dots,M-1\}$	$\frac{1}{M}$	$\frac{M-1}{2}$	$\frac{M^2-1}{12}$
Poisson $\mathcal{P}(\lambda)$	$\mathbb{N}_0$	$\frac{\lambda^k}{k!} e^{-\lambda}$	λ	λ

Tabella 7.1: *Le variabili aleatorie discrete notevoli.*

La disuguaglianza di Markov

Media e varianza sono «riassunti» della pmf. Quanto si può dire su una variabile aleatoria conoscendo solo quelli? Sorprendentemente molto, grazie a due disuguaglianze che valgono per **qualsiasi** pmf.

Teorema 7.7 — Disuguaglianza di Markov

Sia Z una variabile aleatoria **non negativa**, con alfabeto discreto $\mathcal{Z} \subseteq [0, +\infty[$ e pmf $p_Z(z)$. Allora, per qualunque $\delta > 0$:

$$P(Z \geq \delta) \leq \frac{E[Z]}{\delta}.$$

Dimostrazione

Passo 1 — La probabilità della coda. L'evento $\{Z \geq \delta\}$ si verifica quando Z assume uno dei valori $z \geq \delta$:

$$P(Z \geq \delta) = \sum_{z\,:\,z \geq \delta} p_Z(z).$$

Passo 2 — (a) Si moltiplica per un numero ≥ 1. Per i valori $z \geq \delta$ della somma vale $\frac{z}{\delta} \geq 1$; moltiplicando ogni termine per $\frac{z}{\delta}$, la somma non può diminuire:

$$\sum_{z\,:\,z \geq \delta} p_Z(z) \leq \sum_{z\,:\,z \geq \delta} \frac{z}{\delta}\, p_Z(z).$$

Passo 3 — (b) Si estende la somma a tutto l'alfabeto. Aggiungendo anche i valori $z < \delta$ si aggiungono termini $\frac{z}{\delta} p_Z(z) \geq 0$ (perché Z è non negativa): la somma non può diminuire.

$$\sum_{z\,:\,z \geq \delta} \frac{z}{\delta}\, p_Z(z) \leq \sum_{z \in \mathcal{Z}} \frac{z}{\delta}\, p_Z(z).$$

Passo 4 — (c) Si riconosce la media. $\sum_{z \in \mathcal{Z}} \frac{z}{\delta}\, p_Z(z) = \frac{1}{\delta} \sum_z z\, p_Z(z) = \frac{E[Z]}{\delta}$, per la definizione di media. Mettendo in fila i tre passaggi:

$$P(Z \geq \delta) \underset{(a)}{\leq} \sum_{z \geq \delta} \frac{z}{\delta}\, p_Z(z) \underset{(b)}{\leq} \sum_{z \in \mathcal{Z}} \frac{z}{\delta}\, p_Z(z) \underset{(c)}{=} \frac{E[Z]}{\delta}.$$

■

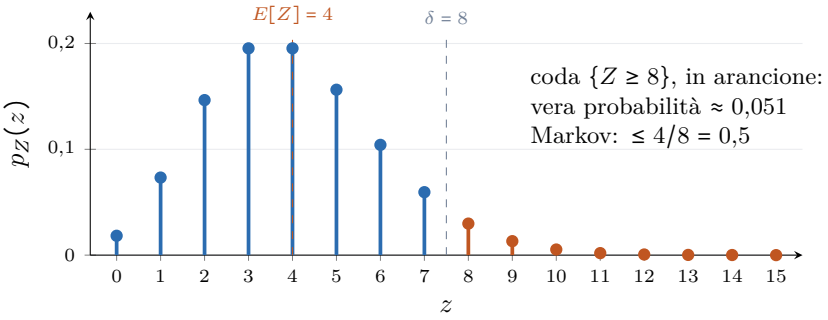


Figura 7.4: *Una Poisson con $\lambda = 4$. Markov garantisce che la coda oltre $\delta = 8$ abbia probabilità al più 0,5; quella vera è molto più piccola. La disuguaglianza è grossolana, ma vale per qualsiasi variabile non negativa di cui si conosca solo la media.*

Esempio 7.3 — La coda del router

Si sa soltanto che il numero medio di pacchetti in coda in un router è 2. Qual è, al massimo, la probabilità di trovarne 10 o più? Il numero di pacchetti è una variabile non negativa, quindi per Markov $P(Z \geq 10) \leq \frac{2}{10} = 0{,}2$. Senza sapere nient'altro della pmf, non si può dire di più; se poi si sapesse che Z è di Poisson, il conto esatto darebbe circa 0,00005.

La disuguaglianza di Chebyshev

La disuguaglianza di Markov vale per variabili non negative. Applicandola alla variabile non negativa $(X-\mu_X)^2$, che misura la distanza al quadrato dalla media, si ottiene un risultato che vale per **qualsiasi** variabile e che coinvolge la deviazione standard.

Teorema 7.8 — Disuguaglianza di Chebyshev

Sia X una variabile aleatoria con media μ_X e deviazione standard $\sigma_X > 0$. Per ogni $k > 0$:

$$P\left(|X-\mu_X| \geq k\,\sigma_X\right) \leq \frac{1}{k^2}.$$

Dimostrazione

Passo 1 — Le scelte. Si applica Markov con $Z = |X-\mu_X|^2$, che è non negativa, e $\delta = (k\,\sigma_X)^2 > 0$.

Passo 2 — La media di Z. Per variabili reali $|X-\mu_X|^2 = (X-\mu_X)^2$, quindi

$$E[Z] = E\left[|X-\mu_X|^2\right] = E\left[(X-\mu_X)^2\right] = \sigma_X^2.$$

Passo 3 — L'evento. Due numeri non negativi stanno nello stesso ordine dei loro quadrati, quindi $|X-\mu_X|^2 \geq (k\,\sigma_X)^2$ esattamente quando $|X-\mu_X| \geq k\,\sigma_X$.

Passo 4 — Markov. Mettendo insieme:

$$P\left(|X-\mu_X|^2 \geq (k\,\sigma_X)^2\right) = P\left(|X-\mu_X| \geq k\,\sigma_X\right) \leq \frac{\sigma_X^2}{k^2\sigma_X^2} = \frac{1}{k^2}.$$

■

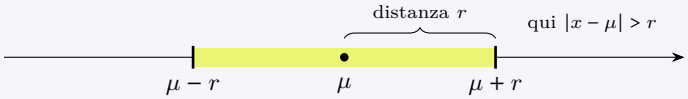
Il significato della varianza e della deviazione standard

La disuguaglianza di Chebyshev si può leggere «al contrario», guardando la probabilità di restare *vicini* alla media. Serve un richiamo sul valore assoluto.

Richiamo di matematica: valore assoluto e intervalli

Il **valore assoluto** $|a|$ è il numero a senza segno: $|3| = |-3| = 3$. La quantità $|x-\mu|$ è la **distanza** fra x e μ sulla retta dei numeri. Dire che la distanza non supera r vuol dire che x sta nell'intervallo centrato in μ di raggio r:

$$|x-\mu| \leq r \iff -r \leq x-\mu \leq r \iff \mu - r \leq x \leq \mu + r.$$



Teorema 7.9 — Quanto si resta vicini alla media

Per ogni variabile aleatoria e ogni $k > 0$:

$$P\left(\mu_X - k\,\sigma_X \leq X \leq \mu_X + k\,\sigma_X\right) \geq 1 - \frac{1}{k^2}.$$

Dimostrazione

Passo 1 — Si passa al complementare. L'evento «distanza minore di $k\sigma_X$» è il complementare di «distanza almeno $k\sigma_X$»:

$$P\left(|X-\mu_X| < k\,\sigma_X\right) = 1 - P\left(|X-\mu_X| \geq k\,\sigma_X\right) \geq 1 - \frac{1}{k^2},$$

perché togliendo da 1 un numero che è al più $1/k^2$ si ottiene almeno $1 - 1/k^2$.

Passo 2 — Si aggiunge l'uguaglianza. Se nella disuguaglianza a sinistra si ammette anche l'uguaglianza ($|X-\mu_X| \leq k\,\sigma_X$) si aggiunge una quantità non negativa (che può anche essere nulla), e la disuguaglianza resta vera a maggior ragione.

Passo 3 — Si toglie il valore assoluto. Per il richiamo, $|X-\mu_X| \leq k\,\sigma_X$ equivale a $-k\sigma_X \leq X - \mu_X \leq k\sigma_X$, cioè a $\mu_X - k\sigma_X \leq X \leq \mu_X + k\sigma_X$.

■

Il teorema dice che la deviazione standard è il **righello naturale** della variabile: qualunque sia la pmf, almeno il 75% della probabilità sta entro 2 deviazioni standard dalla media, almeno l'89% entro 3, almeno il 99% entro 10.

k	1	1,5	2	3	4	10
$1 - 1/k^2$	0	0,56	0,75	0,89	0,94	0,99

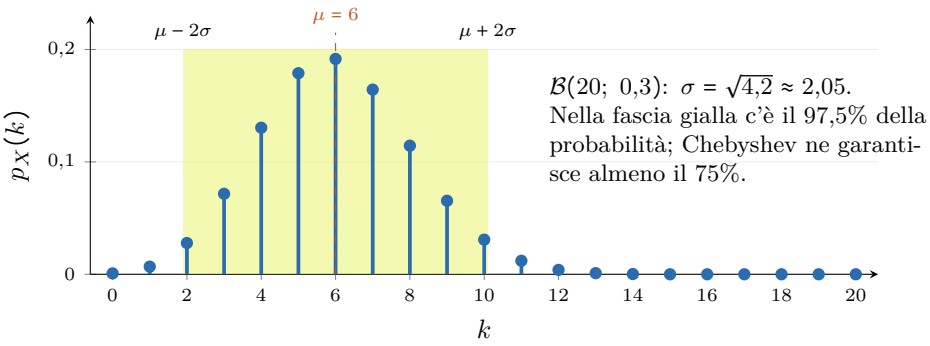


Figura 7.5: *La fascia $\mu \pm 2\sigma$ per una binomiale. Come Markov, anche Chebyshev è prudente: vale per tutte le pmf, quindi per una pmf particolare la probabilità vera è di solito molto più alta del limite garantito.*

Riscrivendo il teorema in termini relativi, il parametro fondamentale risulta il rapporto μ_X/σ_X. Valori elevati di questo rapporto indicano una pmf molto concentrata intorno alla media rispetto alla sua posizione (una variabile «poco aleatoria»), mentre valori bassi indicano un'elevata aleatorietà. (Una funzione è molto concentrata se è sostanzialmente diversa da zero in un intervallo piccolo rispetto al suo valore centrale.)

Esempio 7.4 — Poisson grandi e piccole

Per una Poisson $\mu_X/\sigma_X = \lambda/\sqrt{\lambda} = \sqrt{\lambda}$. Con $\lambda = 1$ il rapporto vale 1: la variabile vale spesso 0, 1, 2, 3, cioè fluttua quanto è grande. Con $\lambda = 100$ il rapporto vale 10: la variabile vale circa 100 ± 10, fluttuazioni del 10%. Con $\lambda = 10\,000$, circa $10\,000 \pm 100$: l'1%. Più eventi rari si contano, più il loro numero diventa prevedibile in proporzione.

In sintesi

- Valore quadratico medio $E[X^2]$, valore efficace $\sqrt{E[X^2]}$, varianza $\sigma_X^2 = E[(X-\mu_X)^2] = E[X^2] - \mu_X^2$, deviazione standard σ_X.
- Bernoulli: $p(1-p)$. Binomiale: $Np(1-p)$. Uniforme su $\{0,\dots,M-1\}$: $(M^2-1)/12$. Poisson: λ (uguale alla media). Si calcolano con il trucco della derivata o con $E[X(X-1)]$.
- La **derivata** è la pendenza della tangente: $(x^n)' = nx^{n-1}$, $(fg)' = f'g + fg'$, $(e^x)' = e^x$; da qui la serie $e^x = \sum x^k/k!$.
- $E[aX+b] = aE[X] + b$; $\sigma^2_{aX+b} = a^2\sigma_X^2$; $E[X] \geq 0$ se $X \geq 0$; $\sigma^2 \geq 0$.
- **Markov**: $P(Z \geq \delta) \leq E[Z]/\delta$ per $Z \geq 0$. **Chebyshev**: $P(|X-\mu_X| \geq k\sigma_X) \leq 1/k^2$, cioè $P(\mu_X - k\sigma_X \leq X \leq \mu_X + k\sigma_X) \geq 1 - 1/k^2$: la deviazione standard è il righello della dispersione, e μ/σ misura la concentrazione.

VARIABILI ALEATORIE MULTIPLE

Molti esperimenti producono più numeri insieme: di una persona scelta a caso si possono misurare l'altezza, il peso e l'età; da un canale di comunicazione esce un bit, ma interessa anche quale bit era entrato; una sorgente emette parole di più bit. Questi numeri vanno descritti **insieme**, perché spesso sono legati fra loro: le persone alte tendono a pesare di più, il bit ricevuto dipende da quello trasmesso. In questo capitolo introduciamo le coppie (e le terne, e le m-ple) di variabili aleatorie, la loro **pmf congiunta**, le **marginali**, le **condizionate** e l'**indipendenza**.

COPPIE DI VARIABILI ALEATORIE

Coppia di variabili aleatorie

Una **coppia di variabili aleatorie** (o **variabile doppia**) associa a ogni risultato ω di un esperimento una coppia ordinata di numeri:

$$(X, Y) : \omega \in \Omega \longmapsto (X(\omega), Y(\omega)) \in \mathcal{X} \times \mathcal{Y} \subseteq \mathbb{R}^2,$$

dove $\mathcal{X}$ e $\mathcal{Y}$ sono gli alfabeti di X e di Y.

In altre parole, il risultato di un esperimento non è più un unico valore $X(\omega) = x \in \mathcal{X}$, ma una coppia ordinata $(X(\omega), Y(\omega)) = (x, y)$ che varia nel prodotto cartesiano $\mathcal{X} \times \mathcal{Y}$: un punto del piano invece che un punto della retta.

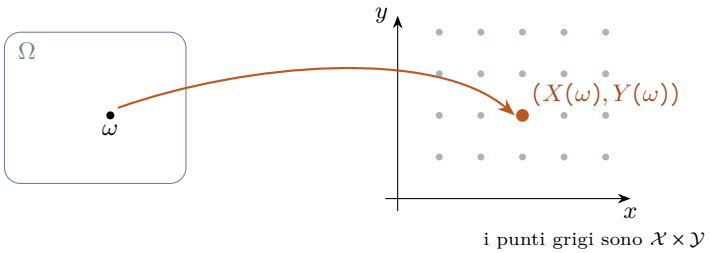


Figura 8.1: *Una coppia di variabili aleatorie manda ogni risultato in un punto del piano.*

Esempio 8.1 — Altezza, peso ed età

Si consideri l'elenco di tutti i residenti in Italia a una certa data, con altezza (X), peso (Y) ed età (Z). Si sceglie un residente a caso e se ne leggono l'altezza in centimetri, $X(\omega) \in \{30, 31, \ldots, 210\}$, il peso in chilogrammi, $Y(\omega) \in \{0{,}5;\ 0{,}6;\ \ldots;\ 170\}$, e l'età in anni, $Z(\omega) \in \{0, 1, \ldots, 110\}$. Possibili coppie sono $(X, Y) \in \mathcal{X} \times \mathcal{Y}$, $(X, Z) \in \mathcal{X} \times \mathcal{Z}$, $(Y, Z) \in \mathcal{Y} \times \mathcal{Z}$; e $(X, Y, Z) \in \mathcal{X} \times \mathcal{Y} \times \mathcal{Z}$ è una **terna** di variabili aleatorie.

La pmf congiunta

Come per una variabile sola, la descrizione completa si ottiene dalle frequenze.

- Si considera la coppia (X, Y) (nell'esempio: altezza e peso di un residente scelto a caso).
- Si eseguono n esperimenti (si sceglie n volte a caso un nome dall'elenco).
- Si registrano i valori $(X(\tilde{\omega}_i), Y(\tilde{\omega}_i))$ (altezza e peso del residente scelto di volta in volta).
- Si indica con $n_{X=x,\,Y=y}$ il numero di volte in cui è uscito $X = x$ *e* $Y = y$ (il residente aveva altezza x e peso y): è il numero di occorrenze dell'evento $\{X = x\} \cap \{Y = y\}$.

Pmf congiunta

La **pmf congiunta** (o DF congiunta) delle due variabili aleatorie X e Y è

$$p_{X,Y}(x, y) = P(\{X = x\} \cap \{Y = y\}) = \lim_{n\to\infty} \frac{n_{X=x,\,Y=y}}{n}, \qquad (x, y) \in \mathcal{X} \times \mathcal{Y}.$$

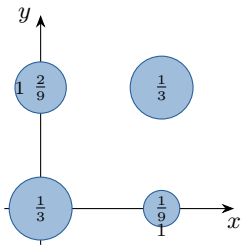
Si scrive anche $P(X = x, Y = y)$, dove la virgola si legge «e».

La pmf congiunta è quindi una **tabella** di $|\mathcal{X}| \cdot |\mathcal{Y}|$ numeri, una casella per ogni coppia di valori, che gode di certe proprietà.

Esempio 8.2 — Una pmf congiunta su due bit

Due variabili X e Y con alfabeto $\{0, 1\}$ hanno la pmf congiunta della tabella (la ritroveremo nel prossimo capitolo):

$p_{X,Y}(x,y)$	$y = 0$	$y = 1$
$x = 0$	$\frac{1}{3}$	$\frac{2}{9}$
$x = 1$	$\frac{1}{9}$	$\frac{1}{3}$



A destra la stessa pmf disegnata come «bolle»: ogni punto (x, y) ha un cerchio di area proporzionale alla sua probabilità. I quattro numeri sono positivi e sommano a $\frac{3+2+1+3}{9} = 1$.

Proprietà della pmf congiunta

Teorema 8.1 — Proprietà della pmf congiunta

$$p_{X,Y}(x, y) \geq 0 \qquad \text{e} \qquad \sum_{x\in\mathcal{X},\, y\in\mathcal{Y}} p_{X,Y}(x, y) = 1.$$

Dimostrazione

Passo 1 — Non negatività. È una probabilità.

Passo 2 — La somma. In ogni prova la coppia assume esattamente un valore (x, y): gli eventi elementari $\{X = x, Y = y\}$ sono a due a due incompatibili (un evento $\{X = x, Y = y\}$ è incompatibile con ogni altro evento $\{X = x', Y = y'\}$ con $(x', y') \neq (x, y)$) e la loro unione è Ω. Per l'additività:

$$1 = P(\Omega) = P\left(\bigcup_{x\in\mathcal{X},\, y\in\mathcal{Y}} \{X = x, Y = y\}\right) = \sum_{x\in\mathcal{X},\, y\in\mathcal{Y}} P(\{X = x, Y = y\}) = \sum_{x,\,y} p_{X,Y}(x, y).$$

■

Le pmf marginali

Dalla pmf congiunta si ricavano le pmf delle singole variabili. Si noti che

$$\bigcup_{x\in\mathcal{X}} \{X = x\} = \Omega, \qquad \bigcup_{y\in\mathcal{Y}} \{Y = y\} = \Omega :$$

qualche valore X lo assume sempre, e anche Y.

Teorema 8.2 — Marginalizzazione della pmf congiunta

$$p_X(x) = \sum_{y\in\mathcal{Y}} p_{X,Y}(x, y), \qquad p_Y(y) = \sum_{x\in\mathcal{X}} p_{X,Y}(x, y).$$

Le pmf p_X e p_Y ottenute così si chiamano **pmf marginali**.

Dimostrazione

Passo 1 — Si «affetta» l'evento $\{X = x\}$. Intersecando con $\Omega = \bigcup_y \{Y = y\}$ e usando la proprietà distributiva:

$$\{X = x\} = \{X = x\} \cap \Omega = \{X = x\} \cap \bigcup_{y\in\mathcal{Y}} \{Y = y\} = \bigcup_{y\in\mathcal{Y}} (\{X = x\} \cap \{Y = y\}) .$$

Passo 2 — Le fette sono incompatibili. Per $y \neq y'$ gli eventi $\{X = x\} \cap \{Y = y\}$ e $\{X = x\} \cap \{Y = y'\}$ non possono verificarsi insieme (Y non assume due valori). Quindi le probabilità si sommano:

$$p_X(x) = P(\{X = x\}) = \sum_{y\in\mathcal{Y}} P(\{X = x\} \cap \{Y = y\}) = \sum_{y\in\mathcal{Y}} p_{X,Y}(x, y).$$

Passo 3 — Per Y. Lo stesso ragionamento, scambiando i ruoli, dà $p_Y(y) = \sum_x p_{X,Y}(x, y)$.

■

Il nome viene da come si fanno i conti a mano: si sommano le righe e le colonne della tabella e si scrivono i totali **a margine**.

	$y = 0$	$y = 1$	$p_X(x)$
$x = 0$	$\frac{1}{3}$	$\frac{2}{9}$	$\frac{1}{3} + \frac{2}{9} = \frac{5}{9}$
$x = 1$	$\frac{1}{9}$	$\frac{1}{3}$	$\frac{1}{9} + \frac{1}{3} = \frac{4}{9}$
$p_Y(y)$	$\frac{1}{3} + \frac{1}{9} = \frac{4}{9}$	$\frac{2}{9} + \frac{1}{3} = \frac{5}{9}$	1

Figura 8.2: *Le pmf marginali sono le somme delle righe (in arancione, la pmf di X) e delle colonne (in blu, la pmf di Y), scritte ai margini della tabella della pmf congiunta.*

Quindi caratterizzare congiuntamente la coppia (X, Y) significa caratterizzare anche ciascuna variabile marginalmente. Il viceversa **non** è vero in generale: le marginali non bastano a ricostruire la congiunta.

Esempio 8.3 — Stesse marginali, congiunte diverse

Due bit X e Y, ognuno uguale a 0 o a 1 con probabilità $\frac{1}{2}$. Le due pmf congiunte qui sotto hanno entrambe queste marginali (si sommino righe e colonne), ma descrivono situazioni opposte: a sinistra i due bit non hanno nulla a che fare l'uno con l'altro; a destra sono sempre uguali (per esempio, il secondo è una copia del primo).

	$y=0$	$y=1$
$x=0$	$\frac{1}{4}$	$\frac{1}{4}$
$x=1$	$\frac{1}{4}$	$\frac{1}{4}$

	$y=0$	$y=1$
$x=0$	$\frac{1}{2}$	0
$x=1$	0	$\frac{1}{2}$

VARIABILI INDIPENDENTI

Variabili aleatorie indipendenti

Due variabili aleatorie X e Y sono **indipendenti** se (e solo se) gli eventi $\{X=x\}$ e $\{Y=y\}$ sono indipendenti per ogni coppia di valori (x,y). Per due variabili indipendenti la pmf congiunta **si fattorizza** nel prodotto delle marginali:

$$p_{X,Y}(x,y) = P(\{X=x\} \cap \{Y=y\}) = P(\{X=x\})\,P(\{Y=y\}) = p_X(x)\,p_Y(y).$$

Questo è l'unico caso in cui assegnare le due pmf marginali $p_X(x)$ e $p_Y(y)$ equivale ad assegnare la pmf congiunta. Nell'ultimo esempio la tabella di sinistra è quella di due bit indipendenti (ogni casella vale $\frac{1}{2}\cdot\frac{1}{2}$); quella di destra no ($p_{X,Y}(0,0) = \frac{1}{2} \neq \frac{1}{4}$).

Esempio 8.4 — Verificare l'indipendenza

- Due lanci di un dado onesto: $p_{X,Y}(i,j) = \frac{1}{36} = \frac{1}{6}\cdot\frac{1}{6} = p_X(i)\,p_Y(j)$ per ogni coppia: i due lanci sono indipendenti.
- La coppia dei due bit di prima, con marginali $p_X(0) = \frac{5}{9}$ e $p_Y(0) = \frac{4}{9}$: $p_{X,Y}(0,0) = \frac{1}{3} = \frac{27}{81}$, mentre $p_X(0)\,p_Y(0) = \frac{5}{9}\cdot\frac{4}{9} = \frac{20}{81}$. Basta una sola casella che non si fattorizza: le due variabili **non** sono indipendenti.

Il concetto di pmf congiunta si generalizza a una m-pla di variabili aleatorie $(X_1, X_2, \ldots, X_m) \in \mathcal{X}_1 \times \mathcal{X}_2 \times \cdots \times \mathcal{X}_m \subseteq \mathbb{R}^m$ mediante la pmf congiunta

$$p_{X_1,X_2,\ldots,X_m}(x_1,x_2,\ldots,x_m) = P\left(\{X_1=x_1\} \cap \{X_2=x_2\} \cap \cdots \cap \{X_m=x_m\}\right),$$

e il concetto di indipendenza si generalizza nel modo seguente: le m variabili sono indipendenti se

$$p_{X_1,\ldots,X_m}(x_1,\ldots,x_m) = \prod_{i=1}^{m} P(\{X_i=x_i\}) = \prod_{i=1}^{m} p_{X_i}(x_i)$$

per ogni scelta dei valori.

LE PMF CONDIZIONATE

Si considerino le variabili aleatorie $X \in \mathcal{X}$ e $Y \in \mathcal{Y}$ con assegnata pmf congiunta $p_{X,Y}(x,y)$. Applichiamo all'evento $\{X = x, Y = y\} = \{X = x\} \cap \{Y = y\}$ la legge della probabilità composta:

$$p_{X,Y}(x,y) = P(\{X = x\} \cap \{Y = y\}) = P(\{Y = y\} \mid \{X = x\})\, P(\{X = x\}) = p_{Y|X}(y \mid x)\, p_X(x).$$

Pmf condizionate

La **pmf condizionata di Y dato X** è, per $p_X(x) > 0$,

$$p_{Y|X}(y \mid x) = P(Y = y \mid X = x) = \frac{p_{X,Y}(x,y)}{p_X(x)},$$

e allo stesso modo $p_{X|Y}(x \mid y) = p_{X,Y}(x,y)/p_Y(y)$ per $p_Y(y) > 0$.

Come la legge congiunta, la legge condizionata $p_{Y|X}(y \mid x)$ è una tabella di $|\mathcal{X}| \cdot |\mathcal{Y}|$ numeri che soddisfa alcune proprietà. Siccome la congiunta si può scrivere condizionando in entrambi i modi,

$$p_{Y|X}(y \mid x)\, p_X(x) = p_{X,Y}(x,y) = p_{X|Y}(x \mid y)\, p_Y(y),$$

si ottiene subito la versione per le pmf del teorema di Bayes.

Da ricordare: legge di Bayes per le pmf

$$p_{X|Y}(x \mid y) = \frac{p_{Y|X}(y \mid x)\, p_X(x)}{p_Y(y)}$$

Teorema 8.3 — Proprietà delle pmf condizionate

a) Fissato y (con $p_Y(y) > 0$), al variare di x la funzione $p_{X|Y}(x \mid y)$ è una pmf: $p_{X|Y}(x \mid y) \geq 0$ e $\sum_{x \in \mathcal{X}} p_{X|Y}(x \mid y) = 1$.

b) Marginalizzazione con le condizionate:

$$p_X(x) = \sum_{y \in \mathcal{Y}} p_{X|Y}(x \mid y)\, p_Y(y), \qquad p_Y(y) = \sum_{x \in \mathcal{X}} p_{Y|X}(y \mid x)\, p_X(x).$$

c) Se X e Y sono indipendenti: $p_{Y|X}(y \mid x) = p_Y(y)$ e $p_{X|Y}(x \mid y) = p_X(x)$.

Dimostrazione

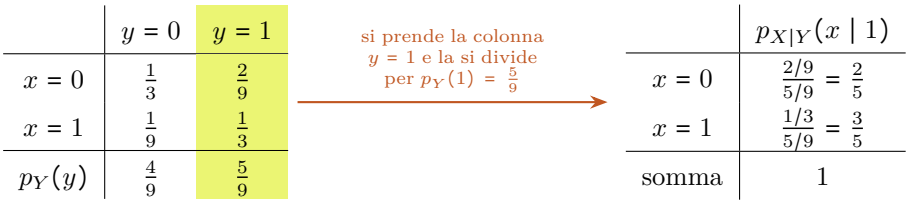
Passo 1 — a) È una pmf. È ≥ 0 perché è una probabilità condizionata. Per la somma, gli eventi $\{X = x\}$ formano una partizione di Ω e la probabilità condizionata è una probabilità (Teorema 4.6):

$$\sum_{x \in \mathcal{X}} p_{X|Y}(x \mid y) = P\left(\bigcup_{x \in \mathcal{X}} \{X = x\} \,\middle|\, \{Y = y\} \right) = P(\Omega \mid \{Y = y\}) = 1.$$

Passo 2 — b) Marginalizzazione. Nella formula delle marginali si scrive la congiunta come condizionata per marginale: $p_X(x) = \sum_y p_{X,Y}(x,y) = \sum_y p_{X|Y}(x \mid y)\, p_Y(y)$. Non è altro che la legge della probabilità totale per l'evento $\{X = x\}$ rispetto alla partizione $\Omega = \bigcup_y \{Y = y\}$. Lo stesso per p_Y, rispetto alla partizione $\Omega = \bigcup_x \{X = x\}$.

Passo 3 — c) Indipendenza. Se $p_{X,Y}(x,y) = p_X(x)\, p_Y(y)$, allora $p_{Y|X}(y \mid x) = \frac{p_X(x)\, p_Y(y)}{p_X(x)} = p_Y(y)$, e allo stesso modo per l'altra.

■



	$y = 0$	$y = 1$
$x = 0$	$\frac{1}{3}$	$\frac{2}{9}$
$x = 1$	$\frac{1}{9}$	$\frac{1}{3}$
$p_Y(y)$	$\frac{4}{9}$	$\frac{5}{9}$

	$p_{X\mid Y}(x \mid 1)$
$x = 0$	$\frac{2/9}{5/9} = \frac{2}{5}$
$x = 1$	$\frac{1/3}{5/9} = \frac{3}{5}$
somma	1

Figura 8.3: *La pmf condizionata a $Y = 1$: si guarda solo la colonna $y = 1$ della congiunta e la si «rialza» dividendola per il suo totale, così che sommi a 1. È la stessa operazione della pmf condizionata a un evento (Capitolo 6).*

Esempio 8.5 — Il canale binario con le pmf congiunte

Riprendiamo il canale binario dei capitoli 3 e 4: X è il bit trasmesso, con $p_X(0) = 0{,}6$ e $p_X(1) = 0{,}4$; Y è il bit ricevuto. Il canale è descritto dalla pmf condizionata $p_{Y\mid X}$: il bit arriva giusto con probabilità 0,9 e invertito con probabilità 0,1. La congiunta si ottiene moltiplicando: $p_{X,Y}(x, y) = p_{Y\mid X}(y \mid x)\, p_X(x)$.

$p_{X,Y}(x,y)$	$y = 0$	$y = 1$	$p_X(x)$
$x = 0$	$0{,}9 \cdot 0{,}6 = 0{,}54$	$0{,}1 \cdot 0{,}6 = 0{,}06$	0,6
$x = 1$	$0{,}1 \cdot 0{,}4 = 0{,}04$	$0{,}9 \cdot 0{,}4 = 0{,}36$	0,4
$p_Y(y)$	0,58	0,42	1

Tutto quello che avevamo calcolato è in questa tabella: la marginale $p_Y(1) = 0{,}42$ è la probabilità totale del Capitolo 3, e la condizionata $p_{X\mid Y}(1 \mid 1) = \frac{0{,}36}{0{,}42} = \frac{6}{7}$ è il risultato del teorema di Bayes del Capitolo 4. La pmf congiunta è il modo più ordinato di tenere insieme tutte queste informazioni.

Più di due variabili: la regola della catena

Si consideri una terna di variabili aleatorie (X, Y, Z), distribuite secondo $p_{X,Y,Z}(x, y, z)$, $(x, y, z) \in \mathcal{X} \times \mathcal{Y} \times \mathcal{Z}$. Le pmf condizionate si definiscono come per le coppie, e anche condizionando a più variabili insieme; per esempio

$$p_{X\mid Y,Z}(x \mid y, z) = \frac{p_{X,Y\mid Z}(x, y \mid z)}{p_{Y\mid Z}(y \mid z)}$$

è la pmf di X sapendo che $Y = y$ e $Z = z$.

Teorema 8.4 — Regola della catena

$$p_{X,Y,Z}(x, y, z) = p_Z(z)\, p_{Y\mid Z}(y \mid z)\, p_{X\mid Y,Z}(x \mid y, z).$$

Ogni permutazione dei pedici e degli argomenti è ovviamente possibile, e la regola si estende a qualsiasi numero di variabili.

Dimostrazione

Passo 1 — Prima applicazione della probabilità composta. Si considera l'evento $\{X = x, Y = y\}$ come un unico evento e lo si condiziona a $\{Z = z\}$:

$$P(X = x, Y = y, Z = z) = P(X = x, Y = y \mid Z = z)\, P(Z = z).$$

Passo 2 — Seconda applicazione, dentro il condizionamento. La probabilità condizionata a $\{Z = z\}$ è una probabilità (Teorema 4.6), quindi anche per lei vale la probabilità composta:

$$P(X = x, Y = y \mid Z = z) = P(X = x \mid Y = y, Z = z)\, P(Y = y \mid Z = z).$$

Passo 3 — Si mette insieme.

$$P(X = x, Y = y, Z = z) = P(X = x \mid Y = y, Z = z)\, P(Y = y \mid Z = z)\, P(Z = z).$$

■

La regola della catena dice che una congiunta si può sempre costruire «un pezzo alla volta»: prima si sceglie z, poi y sapendo z, poi x sapendo entrambi. È esattamente il diagramma ad albero, con un livello per ogni variabile.

Indipendenza di più variabili

Una terna di variabili aleatorie (e allo stesso modo un gruppo di $n > 3$ variabili) è **indipendente** se la pmf congiunta di un qualunque sottogruppo di esse, condizionata a un qualunque altro sottogruppo (costituito da variabili distinte dalle prime), è pari alla relativa pmf congiunta non condizionata.

In questo caso, chiaramente, la pmf congiunta si fattorizza nel prodotto delle pmf marginali: nella regola della catena ogni condizionata diventa una marginale, e $p_{X,Y,Z}(x, y, z) = p_X(x)\, p_Y(y)\, p_Z(z)$. Attenzione: non basta che le variabili siano indipendenti *a coppie*, come mostra l'esempio che segue.

ESEMPIO: TRE BIT DA UNA SORGENTE BINARIA

Si consideri una sorgente binaria che emette tre bit, (B_1, B_2, B_3), con $B_i \in \{0, 1\}$. Si assegnano due possibili leggi congiunte, p_{B_1,B_2,B_3} e q_{B_1,B_2,B_3}, riportate nella tabella ($0 < \alpha < 1$ è un parametro). Ci chiediamo se le coppie (B_1, B_2), (B_1, B_3), (B_2, B_3) e la terna (B_1, B_2, B_3) siano o meno indipendenti, secondo l'una e l'altra legge.

$b_1 b_2 b_3$	$p_{B_1,B_2,B_3}(b_1, b_2, b_3)$	$q_{B_1,B_2,B_3}(b_1, b_2, b_3)$
000	$(1-\alpha)^3$	$(1-\alpha)^2$
001	$\alpha(1-\alpha)^2$	0
010	$\alpha(1-\alpha)^2$	0
011	$\alpha^2(1-\alpha)$	$\alpha(1-\alpha)$
100	$\alpha(1-\alpha)^2$	0
101	$\alpha^2(1-\alpha)$	$\alpha(1-\alpha)$
110	$\alpha^2(1-\alpha)$	α^2
111	α^3	0

Tabella 8.1: *Le due leggi congiunte della sorgente di tre bit.*

La legge p

Cominciamo con il trovare la congiunta di tutte le possibili coppie secondo p. Per la marginalizzazione si somma sul bit che non interessa; per esempio

$$p_{B_1,B_2}(b_1,b_2) = p_{B_1,B_2,B_3}(b_1,b_2,0) + p_{B_1,B_2,B_3}(b_1,b_2,1).$$

Nelle somme compare sempre il fattore $(1-\alpha+\alpha) = 1$:

b_1b_2	$p_{B_1,B_2}(b_1,b_2)$
00	$(1-\alpha)^3 + \alpha(1-\alpha)^2 = (1-\alpha)^2(1-\alpha+\alpha) = (1-\alpha)^2$
01	$\alpha(1-\alpha)^2 + \alpha^2(1-\alpha) = \alpha(1-\alpha)(1-\alpha+\alpha) = \alpha(1-\alpha)$
10	$\alpha(1-\alpha)^2 + \alpha^2(1-\alpha) = \alpha(1-\alpha)$
11	$\alpha^2(1-\alpha) + \alpha^3 = \alpha^2(1-\alpha+\alpha) = \alpha^2$

Sommando sul bit 2 o sul bit 1 si trovano, allo stesso modo, p_{B_1,B_3} e p_{B_2,B_3}: hanno esattamente gli stessi quattro valori, $(1-\alpha)^2$, $\alpha(1-\alpha)$, $\alpha(1-\alpha)$, α^2. Marginalizzando ancora, $p_{B_1}(b_1) = p_{B_1,B_2}(b_1,0) + p_{B_1,B_2}(b_1,1)$:

$$p_{B_1}(0) = (1-\alpha)^2 + \alpha(1-\alpha) = (1-\alpha)(1-\alpha+\alpha) = 1-\alpha, \qquad p_{B_1}(1) = \alpha(1-\alpha) + \alpha^2 = \alpha,$$

e lo stesso vale per B_2 e B_3: ogni bit è 1 con probabilità α. Ora si vede che la legge p **si fattorizza nel prodotto delle marginali**: ogni riga della tabella è un prodotto di tre fattori, α per ogni 1 e $1-\alpha$ per ogni 0 (per esempio $p(0,1,1) = (1-\alpha)\cdot\alpha\cdot\alpha$). Questo implica che anche le congiunte a coppie si fattorizzano: secondo p l'intera terna è statisticamente indipendente.

La legge q

Procedendo allo stesso modo con q:

coppia di valori	q_{B_1,B_2}	q_{B_2,B_3}	q_{B_1,B_3}
00	$(1-\alpha)^2$	$(1-\alpha)^2$	$(1-\alpha)^2$
01	$\alpha(1-\alpha)$	$\alpha(1-\alpha)$	$\alpha(1-\alpha)$
10	$\alpha(1-\alpha)$	α^2	α^2
11	α^2	$\alpha(1-\alpha)$	$\alpha(1-\alpha)$

(Per esempio $q_{B_2,B_3}(1,0) = q(0,1,0) + q(1,1,0) = 0 + \alpha^2$.) Le marginali sono

$$q_{B_1}(1) = q_{B_2}(1) = \alpha, \qquad q_{B_3}(0) = (1-\alpha)^2 + \alpha^2, \qquad q_{B_3}(1) = 2\alpha(1-\alpha).$$

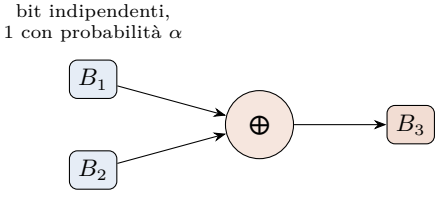
B_1 e B_2 sono indipendenti: q_{B_1,B_2} è la stessa di prima, il prodotto delle marginali. Non lo sono invece B_1 e B_3, né B_2 e B_3: per esempio $q_{B_1,B_3}(1,0) = \alpha^2$, mentre $q_{B_1}(1)\,q_{B_3}(0) = \alpha\left[(1-\alpha)^2 + \alpha^2\right]$, e i due numeri sono diversi (salvo il caso speciale $\alpha = \frac{1}{2}$, di cui diremo fra poco). Non lo è, quindi, nemmeno la terna.

Lo si vede bene con le condizionate. Sapendo che i primi due bit sono 1:

$$p_{B_3|B_1=1,B_2=1}(1) = \frac{p_{B_1,B_2,B_3}(1,1,1)}{p_{B_1,B_2}(1,1)} = \frac{\alpha^3}{\alpha^2} = \alpha = p_{B_3}(1),$$

$$q_{B_3|B_1=1,B_2=1}(1) = \frac{q_{B_1,B_2,B_3}(1,1,1)}{q_{B_1,B_2}(1,1)} = \frac{0}{\alpha^2} = 0 \neq q_{B_3}(1).$$

Secondo p, conoscere i primi due bit non dice nulla sul terzo; secondo q, lo dice con certezza. Guardando la tabella si capisce perché: nelle righe con probabilità non nulla, B_3 vale 1 esattamente quando B_1 e B_2 sono diversi. Si vede facilmente che $B_3 = B_1 \oplus B_2$ è un **bit di parità**.



b_1	b_2	$b_1 \oplus b_2$
0	0	0
0	1	1
1	0	1
1	1	0

Figura 8.4: *La sorgente secondo la legge q: due bit indipendenti e un terzo bit calcolato come loro XOR (somma modulo 2), che vale 1 quando i due bit sono diversi. Il numero totale di uni nella parola è sempre pari: è il principio dei codici di controllo di parità usati per rilevare gli errori di trasmissione.*

Indipendenti a coppie ma non tutti insieme

Con $\alpha = \frac{1}{2}$ succede una cosa curiosa. Tutte e tre le congiunte a coppie di q valgono $\frac{1}{4}$ in ogni casella, e le marginali valgono $\frac{1}{2}$: **ogni coppia** di bit è indipendente. Eppure la terna non lo è affatto, perché il terzo bit è determinato dai primi due ($q(1,1,1) = 0 \neq \frac{1}{8}$). Guardare i bit due alla volta non basta: per l'indipendenza di più variabili serve la fattorizzazione dell'intera pmf congiunta, come dice la definizione.

In sintesi

- Una **coppia di variabili aleatorie** manda ogni ω in un punto (x, y) di $\mathcal{X} \times \mathcal{Y}$; la **pmf congiunta** $p_{X,Y}(x, y) = P(X = x, Y = y)$ è una tabella di numeri ≥ 0 che somma a 1.
- **Marginali**: $p_X(x) = \sum_y p_{X,Y}(x, y)$, $p_Y(y) = \sum_x p_{X,Y}(x, y)$ (le somme «a margine»). La congiunta determina le marginali, non il viceversa.
- X e Y sono **indipendenti** se $p_{X,Y}(x, y) = p_X(x)\, p_Y(y)$ per ogni coppia: è l'unico caso in cui le marginali bastano.
- **Condizionate**: $p_{Y|X}(y \mid x) = p_{X,Y}(x, y)/p_X(x)$, una pmf in y per ogni x; Bayes: $p_{X|Y} = p_{Y|X}\, p_X/p_Y$; marginalizzare con le condizionate è la probabilità totale.
- **Regola della catena**: $p_{X,Y,Z} = p_Z\, p_{Y|Z}\, p_{X|Y,Z}$. Più variabili sono indipendenti se la congiunta si fattorizza tutta; l'indipendenza a coppie non basta (bit di parità).

Funzioni di più variabili, covarianza e correlazione

Nel capitolo precedente abbiamo descritto una coppia di variabili aleatorie con la sua pmf congiunta. Ora le usiamo: combiniamo X e Y in una nuova variabile $Z = g(X,Y)$ (una somma, un prodotto, una formula qualsiasi) e ne calcoliamo pmf e media; scopriamo che la media di una somma è sempre la somma delle medie; e introduciamo due numeri, la **covarianza** e il **coefficiente di correlazione**, che riassumono in modo semplice quanto due variabili «si muovono insieme».

Funzioni di una coppia di variabili

Sia $(X,Y) \sim p_{X,Y}(x,y)$, $(x,y) \in \mathcal{X} \times \mathcal{Y}$, una variabile doppia, e sia $g(x,y)$ una funzione di due variabili il cui dominio include $\mathcal{X} \times \mathcal{Y}$. Si vuole caratterizzare $Z = g(X,Y)$ in termini di pmf e di media statistica. Per prima cosa si determina l'alfabeto $\mathcal{Z}$, l'insieme dei valori $g(x,y)$. Poi si ragiona esattamente come nel Capitolo 6 per le funzioni di una variabile.

- Se $|\mathcal{Z}| = |\mathcal{X}|\,|\mathcal{Y}|$, la funzione è biunivoca sulle coppie: per ogni z esiste un unico punto $(x(z), y(z))$ con $z = g(x,y)$, e

$$P(Z = z) = p_Z(z) = p_{X,Y}\left[x(z), y(z)\right].$$

- Se $|\mathcal{Z}| < |\mathcal{X}|\,|\mathcal{Y}|$, la relazione precedente vale nei punti in cui l'inversa è unica, mentre negli altri le probabilità «collassano»: se $z = g(x,y)$ per tutte le coppie di un insieme $A(z) \subseteq \mathcal{X} \times \mathcal{Y}$, allora

$$p_Z(z) = \sum_{(x,y) \in A(z)} p_{X,Y}(x,y).$$

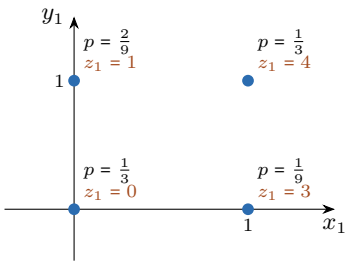
Da ricordare: pmf di una funzione di due variabili

$$p_Z(z) = \sum_{(x,y)\,:\,g(x,y)=z} p_{X,Y}(x,y)$$

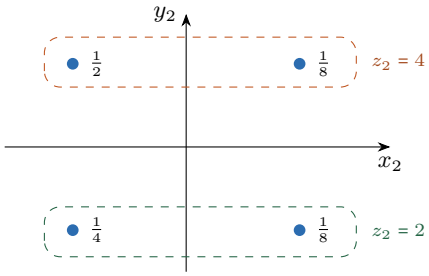
Esempio 9.1 — Due coppie e la stessa formula

Si considerino due variabili doppie, $(X_1, Y_1) \in \{0,1\}^2$ e $(X_2, Y_2) \in \{-1,1\}^2$, con le pmf congiunte riportate qui sotto (la prima è quella del capitolo precedente), e le due variabili

$$Z_1 = 3X_1^2 + Y_1, \qquad Z_2 = 3X_2^2 + Y_2.$$



$Z_1 = 3X_1^2 + Y_1$: quattro valori diversi



$Z_2 = 3X_2^2 + Y_2$: due valori soli

Prima coppia. I valori possibili di Z_1 sono $3 \cdot 0 + 0 = 0$, $3 \cdot 0 + 1 = 1$, $3 \cdot 1 + 0 = 3$, $3 \cdot 1 + 1 = 4$: quindi $|\mathcal{Z}_1| = |\{0,1,3,4\}| = 4 = |\{0,1\}|^2 = |\mathcal{X}| \cdot |\mathcal{Y}|$, e la corrispondenza è biunivoca:

$$p_{Z_1}(0) = p_{X_1,Y_1}(0,0) = \tfrac{1}{3}, \quad p_{Z_1}(1) = p_{X_1,Y_1}(0,1) = \tfrac{2}{9}, \quad p_{Z_1}(3) = p_{X_1,Y_1}(1,0) = \tfrac{1}{9}, \quad p_{Z_1}(4) = p_{X_1,Y_1}(1,1) = \tfrac{1}{3}.$$

Seconda coppia. Qui $X_2 = \pm 1$, quindi $X_2^2 = 1$ sempre e $Z_2 = 3 + Y_2$: i valori possibili sono solo $\{2,4\}$, e $|\mathcal{Z}_2| = 2 < |\{-1,1\}|^2 = 4$. La corrispondenza non è biunivoca e le probabilità collassano:

$$p_{Z_2}(2) = p_{X_2,Y_2}(1,-1) + p_{X_2,Y_2}(-1,-1) = \tfrac{1}{8} + \tfrac{1}{4} = \tfrac{3}{8}, \qquad p_{Z_2}(4) = p_{X_2,Y_2}(-1,1) + p_{X_2,Y_2}(1,1) = \tfrac{1}{2} + \tfrac{1}{8} = \tfrac{5}{8}.$$

La media di una funzione di due variabili

Con riferimento alla trasformazione generica $Z = g(X,Y)$, il teorema fondamentale per il calcolo della media (Teorema 6.4) si traduce in modo immediato.

Teorema 9.1 — Teorema fondamentale per due variabili

$$E[Z] = E[g(X,Y)] = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} g(x,y)\, p_{X,Y}(x,y) = \sum_{(x,y) \in \mathcal{X} \times \mathcal{Y}} g(x,y)\, p_{X,Y}(x,y).$$

Dimostrazione

Passo 1. È la stessa dimostrazione del caso di una variabile, con le coppie (x,y) al posto dei valori x. Si scrive $E[Z] = \sum_z z\, p_Z(z) = \sum_z \sum_{(x,y) \in A(z)} g(x,y)\, p_{X,Y}(x,y)$; gli insiemi $A(z)$ dividono $\mathcal{X} \times \mathcal{Y}$ in gruppi disgiunti che lo coprono tutto, quindi sommare gruppo per gruppo equivale a sommare su tutte le coppie. ∎

La conseguenza più importante riguarda le combinazioni lineari.

Teorema 9.2 — Linearità della media

Se a e b sono costanti, per qualsiasi coppia di variabili aleatorie X e Y:

$$E[aX + bY] = a\,E[X] + b\,E[Y].$$

Più in generale, se $X_1, X_2, \ldots, X_m$ sono m variabili aleatorie con pmf congiunta $p_{X_1,\ldots,X_m}(x_1, \ldots, x_m)$ e $a_1, \ldots, a_m$ sono costanti:

$$E\left[\sum_{i=1}^{m} a_i X_i\right] = \sum_{i=1}^{m} a_i\,E[X_i].$$

Dimostrazione

Passo 1 — Il teorema fondamentale con $g(x, y) = ax + by$.

$$E[aX + bY] = \sum_{x\in\mathcal{X}}\sum_{y\in\mathcal{Y}} (ax + by)\,p_{X,Y}(x, y) = a\sum_x\sum_y x\,p_{X,Y}(x, y) + b\sum_x\sum_y y\,p_{X,Y}(x, y).$$

Passo 2 — Si raccoglie e si marginalizza. Nella prima somma x non dipende da y e si porta fuori dalla somma interna; nella seconda si scambia l'ordine delle somme e si porta fuori y:

$$E[aX + bY] = a\sum_{x\in\mathcal{X}} x\underbrace{\sum_{y\in\mathcal{Y}} p_{X,Y}(x, y)}_{p_X(x)} + b\sum_{y\in\mathcal{Y}} y\underbrace{\sum_{x\in\mathcal{X}} p_{X,Y}(x, y)}_{p_Y(y)}.$$

Le somme interne sono le marginali (Teorema 8.2).

Passo 3 — Si riconoscono le medie.

$$E[aX + bY] = a\sum_x x\,p_X(x) + b\sum_y y\,p_Y(y) = a\,E[X] + b\,E[Y].$$

Passo 4 — Con m variabili. Si applica il risultato ripetutamente (è un'induzione): $\sum_{i=1}^{m} a_i X_i$ è la somma di $\sum_{i=1}^{m-1} a_i X_i$ e di $a_m X_m$, e la media di una somma di due variabili è la somma delle medie. ■

La linearità non chiede l'indipendenza

La media di una somma è la somma delle medie **sempre**, qualunque sia la pmf congiunta: le variabili possono essere dipendenti quanto si vuole. È questo che la rende così utile. (Vedremo invece che per la varianza di una somma la dipendenza conta, eccome.)

Esempio 9.2 — La media della binomiale, in una riga

Nel Capitolo 5 abbiamo dimostrato $E[X_N] = Np$ con una lunga catena di passaggi. Con la linearità basta osservare che il numero di teste in N lanci è la somma di N variabili di Bernoulli:

$$X_N = B_1 + B_2 + \cdots + B_N, \qquad B_i = \begin{cases} 1 & \text{se l'}i\text{-esimo lancio dà testa} \\ 0 & \text{altrimenti} \end{cases}$$

Ogni B_i vale 1 con probabilità p, quindi $E[B_i] = p$, e

$$E[X_N] = E[B_1] + E[B_2] + \cdots + E[B_N] = Np.$$

Esempio 9.3 — Le medie di Z_1 e Z_2

Con le pmf trovate nell'esempio precedente:

$$E[Z_1] = 0 \cdot \tfrac{1}{3} + 1 \cdot \tfrac{2}{9} + 3 \cdot \tfrac{1}{9} + 4 \cdot \tfrac{1}{3} = \frac{2+3+12}{9} = \frac{17}{9}, \qquad E[Z_2] = 2 \cdot \tfrac{3}{8} + 4 \cdot \tfrac{5}{8} = \frac{6+20}{8} = \frac{26}{8} = \frac{13}{4}.$$

Il teorema della media condizionata

Il teorema fondamentale si può riorganizzare in un modo molto utile. Con riferimento a $Z = g(X,Y)$, scriviamo la congiunta come condizionata per marginale, $p_{X,Y}(x,y) = p_{X|Y}(x \mid y)\, p_Y(y)$:

$$E[Z] = \sum_{x\in\mathcal{X}} \sum_{y\in\mathcal{Y}} g(x,y)\, p_{X|Y}(x \mid y)\, p_Y(y) = \sum_{y\in\mathcal{Y}} p_Y(y) \underbrace{\sum_{x\in\mathcal{X}} g(x,y)\, p_{X|Y}(x \mid y)}_{h(y)} = \sum_{y\in\mathcal{Y}} p_Y(y)\, h(y),$$

dove

$$h(y) = \sum_{x\in\mathcal{X}} g(x,y)\, p_{X|Y}(x \mid y) = E[g(X,Y) \mid Y = y]$$

è la media di $g(X,Y)$ eseguita rispetto alla pmf condizionata $p_{X|Y}(x \mid y)$: la media di g sapendo che $Y = y$. Al variare di y è una funzione di y, quindi $h(Y) = E[g(X,Y) \mid Y]$ è a sua volta una variabile aleatoria (una funzione di Y), e l'ultima somma è la sua media.

Teorema 9.3 — Teorema della media condizionata

$$E[g(X,Y)] = E[h(Y)] = E\big[\, E[g(X,Y) \mid Y]\,\big].$$

La media si può calcolare in due tempi: prima la media condizionata a ogni valore di Y, poi la media di questi numeri, pesati con p_Y. Ovviamente i ruoli di X e Y si possono scambiare.

È lo stesso principio del Teorema 6.3 (la media è la media pesata delle medie condizionate), con la partizione $\Omega = \bigcup_y \{Y = y\}$.

Esempio 9.4 — La media di Z_1, in due tempi

Calcoliamo di nuovo $E[Z_1] = E[E[Z_1 \mid Y_1]]$, dove $Z_1 = g(X_1, Y_1) = 3X_1^2 + Y_1$. Serve la pmf condizionata $p_{X_1|Y_1}(x_1 \mid y_1) = p_{X_1,Y_1}(x_1, y_1)/p_{Y_1}(y_1)$, e per questa la marginale di Y_1:

$$p_{Y_1}(0) = p_{X_1,Y_1}(0,0) + p_{X_1,Y_1}(1,0) = \tfrac{1}{3} + \tfrac{1}{9} = \tfrac{4}{9}, \qquad p_{Y_1}(1) = p_{X_1,Y_1}(0,1) + p_{X_1,Y_1}(1,1) = \tfrac{2}{9} + \tfrac{1}{3} = \tfrac{5}{9}.$$

$x_1 y_1$	$p_{X_1\|Y_1}(x_1 \mid y_1) = \dfrac{p_{X_1,Y_1}(x_1,y_1)}{p_{Y_1}(y_1)}$
00	$\frac{1}{3} \cdot \frac{9}{4} = \frac{3}{4}$
01	$\frac{2}{9} \cdot \frac{9}{5} = \frac{2}{5}$
10	$\frac{1}{9} \cdot \frac{9}{4} = \frac{1}{4}$
11	$\frac{1}{3} \cdot \frac{9}{5} = \frac{3}{5}$

Ora le medie condizionate. Sapendo che $Y_1 = 0$, la Y_1 nella formula vale 0; e siccome X_1 vale 0 o 1, il termine $3X_1^2$ vale 3 solo quando $X_1 = 1$:

$$E[Z_1 \mid Y_1 = 0] = E[3X_1^2 + Y_1 \mid Y_1 = 0] = E[3X_1^2 \mid Y_1 = 0] = 3 \cdot 1^2 \cdot p_{X_1|Y_1}(1 \mid 0) = 3 \cdot \tfrac{1}{4} = \tfrac{3}{4}.$$

Sapendo che $Y_1 = 1$, invece, la Y_1 vale 1:

$$E[Z_1 \mid Y_1 = 1] = E[3X_1^2 + 1 \mid Y_1 = 1] = 3 \cdot 1^2 \cdot p_{X_1|Y_1}(1 \mid 1) + 1 = 3 \cdot \tfrac{3}{5} + 1 = \tfrac{9}{5} + 1 = \tfrac{14}{5}.$$

Infine la media delle medie condizionate:

$$E[Z_1] = E[Z_1 \mid Y_1 = 0]\, p_{Y_1}(0) + E[Z_1 \mid Y_1 = 1]\, p_{Y_1}(1) = \tfrac{3}{4} \cdot \tfrac{4}{9} + \tfrac{14}{5} \cdot \tfrac{5}{9} = \tfrac{3}{9} + \tfrac{14}{9} = \tfrac{17}{9},$$

lo stesso valore trovato prima.

Correlazione e covarianza

Le coppie (μ_X, σ_X^2) e (μ_Y, σ_Y^2) contengono informazioni globali, anche se sommarie, sulle due pmf marginali. L'equivalente per la pmf congiunta è la **covarianza**, che dà un'idea, ancora abbastanza sommaria, del grado di «dipendenza» fra X e Y.

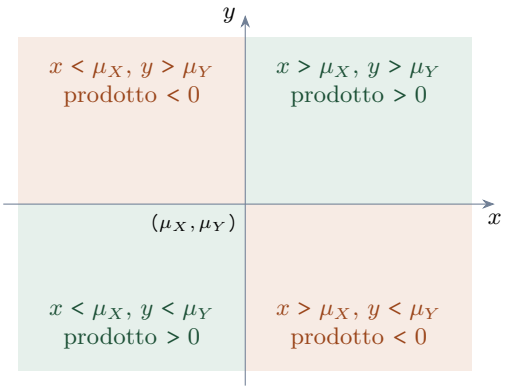
Correlazione e covarianza

La **correlazione** fra X e Y è la media del loro prodotto:

$$R_{XY} = E[XY] = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} x\, y\, p_{X,Y}(x,y).$$

La **covarianza** fra X e Y è la media del prodotto degli scarti dalle rispettive medie:

$$\sigma_{XY}^2 = COV(X,Y) = E\left[(X - \mu_X)(Y - \mu_Y)\right] = \sum_x \sum_y (x - \mu_X)(y - \mu_Y)\, p_{X,Y}(x,y).$$



Gli assi sono centrati sulle medie. Il prodotto degli scarti $(x - \mu_X)(y - \mu_Y)$ è positivo nei quadranti verdi (le due variabili sono entrambe sopra o entrambe sotto la media) e negativo in quelli arancioni (una sopra, l'altra sotto). La covarianza è la media di questo prodotto: è positiva se la probabilità sta soprattutto nei quadranti verdi, negativa se sta soprattutto in quelli arancioni.

Figura 9.1: *Il segno della covarianza.*

Teorema 9.4 — Covarianza e correlazione

$$COV(X,Y) = R_{XY} - \mu_X\,\mu_Y = E[XY] - E[X]\,E[Y].$$

In particolare, se almeno una delle due variabili ha media nulla, $COV(X,Y) = R_{XY}$.

Dimostrazione

Passo 1 — Si sviluppa il prodotto. $(X - \mu_X)(Y - \mu_Y) = XY - \mu_X Y - \mu_Y X + \mu_X\mu_Y$.

Passo 2 — Linearità della media. Le medie μ_X e μ_Y sono costanti, quindi

$$COV(X,Y) = E[XY] - \mu_X\,E[Y] - \mu_Y\,E[X] + \mu_X\mu_Y = R_{XY} - \mu_X\mu_Y - \mu_X\mu_Y + \mu_X\mu_Y = R_{XY} - \mu_X\mu_Y.$$

■

Variabili incorrelate

Due variabili aleatorie che abbiano covarianza nulla, $COV(X,Y) = 0$, si dicono **incorrelate**.

Teorema 9.5 — Indipendenti implica incorrelate

Se X e Y sono indipendenti, allora sono incorrelate: $COV(X,Y) = 0$, e quindi $E[XY] = E[X]\,E[Y]$.

Dimostrazione

Passo 1 — La congiunta si fattorizza. Se $p_{X,Y}(x,y) = p_X(x)\,p_Y(y)$:

$$COV(X,Y) = \sum_x \sum_y (x - \mu_X)(y - \mu_Y)\,p_X(x)\,p_Y(y).$$

Passo 2 — La somma doppia si spezza. Il termine si fattorizza in una parte che dipende solo da x e una che dipende solo da y, quindi la somma doppia è il prodotto di due somme:

$$COV(X,Y) = \sum_x (x - \mu_X)\,p_X(x) \sum_y (y - \mu_Y)\,p_Y(y) = E[X - \mu_X]\,E[Y - \mu_Y] = 0 \cdot 0 = 0,$$

perché la media dello scarto dalla media è sempre nulla.

■

La proposizione **non si inverte**: l'incorrelazione non implica, in generale, l'indipendenza.

Esempio 9.5 — Incorrelate ma dipendenti

Sia X uniforme su $\{-1, 0, 1\}$ e sia $Y = X^2$. Le due variabili sono fortissimamente dipendenti: conoscendo X si conosce Y con certezza (per esempio $P(Y = 0 \mid X = 0) = 1$, mentre $P(Y = 0) = \frac{1}{3}$). Eppure

$$E[X] = \tfrac{1}{3}(-1 + 0 + 1) = 0, \qquad E[XY] = E[X^3] = \tfrac{1}{3}\left((-1)^3 + 0^3 + 1^3\right) = 0,$$

quindi $COV(X, Y) = E[XY] - E[X]\,E[Y] = 0 - 0 = 0$: sono incorrelate. La covarianza vede solo la tendenza a crescere o calare *insieme*; qui Y è grande sia quando X è molto negativa sia quando è molto positiva, e i due effetti si compensano.

Il coefficiente di correlazione

La covarianza ha un difetto: dipende dalle unità di misura (se X si misura in centimetri invece che in metri, la covarianza diventa cento volte più grande). Per avere un numero «puro» la si divide per le deviazioni standard; il risultato sta sempre fra -1 e 1.

Teorema 9.6 — Limite della covarianza

Per due variabili aleatorie qualsiasi (con $\sigma_X, \sigma_Y > 0$):

$$|COV(X, Y)| \le \sigma_X\, \sigma_Y.$$

Dimostrazione

Passo 1 — Un quadrato ha media non negativa. Per entrambe le scelte del segno, la variabile $\left(\frac{X-\mu_X}{\sigma_X} \pm \frac{Y-\mu_Y}{\sigma_Y}\right)^2$ è non negativa, quindi lo è la sua media:

$$0 \le E\left[\left(\frac{X - \mu_X}{\sigma_X} \pm \frac{Y - \mu_Y}{\sigma_Y}\right)^2\right].$$

Passo 2 — Si sviluppa il quadrato. Con $(a \pm b)^2 = a^2 + b^2 \pm 2ab$ e la linearità della media:

$$0 \le E\left[\left(\frac{X - \mu_X}{\sigma_X}\right)^2\right] + E\left[\left(\frac{Y - \mu_Y}{\sigma_Y}\right)^2\right] \pm 2\,E\left[\frac{X - \mu_X}{\sigma_X} \cdot \frac{Y - \mu_Y}{\sigma_Y}\right].$$

Passo 3 — Si riconoscono i pezzi. Il primo termine è $\frac{E[(X-\mu_X)^2]}{\sigma_X^2} = \frac{\sigma_X^2}{\sigma_X^2} = 1$, il secondo allo stesso modo vale 1, il terzo è $\pm 2\,\frac{COV(X,Y)}{\sigma_X \sigma_Y}$:

$$0 \le 1 + 1 \pm 2\,\frac{COV(X, Y)}{\sigma_X\, \sigma_Y} \quad \Longleftrightarrow \quad -2 \le \pm 2\,\frac{COV(X, Y)}{\sigma_X\, \sigma_Y} \quad \Longleftrightarrow \quad -\sigma_X \sigma_Y \le \pm\, COV(X, Y).$$

Passo 4 — I due segni insieme. Con il segno $+$: $COV(X, Y) \ge -\sigma_X \sigma_Y$. Con il segno $-$: $-COV(X, Y) \ge -\sigma_X \sigma_Y$, cioè $COV(X, Y) \le \sigma_X \sigma_Y$. Insieme:

$$-\sigma_X \sigma_Y \le COV(X, Y) \le \sigma_X \sigma_Y \quad \Longleftrightarrow \quad |COV(X, Y)| \le \sigma_X\, \sigma_Y.$$

■

Coefficiente di correlazione

Il **coefficiente di correlazione** fra X e Y è

$$\rho_{XY} = \frac{COV(X, Y)}{\sigma_X\, \sigma_Y} \in [-1, 1].$$

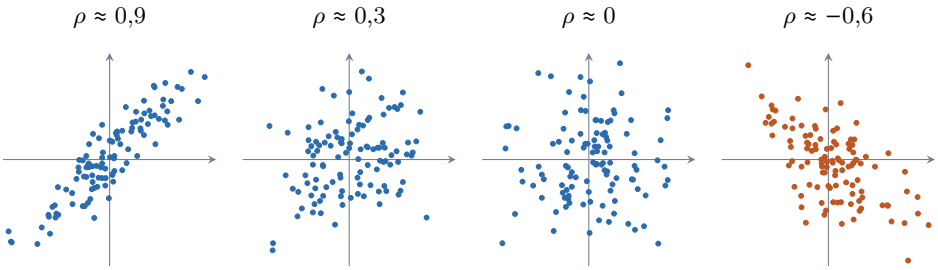


Figura 9.2: *Ogni punto è una coppia (x, y) estratta da quattro coppie di variabili con coefficienti di correlazione diversi (simulazione). Con ρ vicino a 1 i punti si allineano lungo una retta crescente; con ρ vicino a 0 non c'è una tendenza; con ρ negativo la tendenza è decrescente.*

Che cosa misura ρ

Il coefficiente di correlazione misura la dipendenza **lineare**: quanto i punti (x, y) tendono a disporsi lungo una retta. Dalla dimostrazione si vede che $\rho_{XY} = \pm 1$ esattamente quando la media del quadrato è zero, cioè quando $\frac{X-\mu_X}{\sigma_X} = \mp\frac{Y-\mu_Y}{\sigma_Y}$ con certezza: Y è una funzione lineare di X, $Y = aX + b$. Un ρ vicino a zero, invece, non esclude affatto una dipendenza non lineare, come nell'esempio $Y = X^2$.

La varianza di una combinazione lineare

Teorema 9.7 — Varianza di una combinazione lineare

Sia $Z = aX + bY$, con a e b costanti. Allora $\mu_Z = a\mu_X + b\mu_Y$ e

$$\sigma_Z^2 = a^2\sigma_X^2 + b^2\sigma_Y^2 + 2ab\,COV(X, Y).$$

In particolare, se X e Y sono incorrelate (per esempio indipendenti), $\sigma_{X+Y}^2 = \sigma_X^2 + \sigma_Y^2$.

Dimostrazione

Passo 1 — Lo scarto di Z. La media segue dalla linearità; lo scarto dalla media è

$$Z - \mu_Z = aX + bY - a\mu_X - b\mu_Y = a\,(X - \mu_X) + b\,(Y - \mu_Y).$$

Passo 2 — Il quadrato. Sviluppando $(au + bv)^2 = a^2u^2 + b^2v^2 + 2ab\,uv$:

$$\sigma_Z^2 = E\left[(Z - \mu_Z)^2\right] = E\left[(a(X - \mu_X) + b(Y - \mu_Y))^2\right]$$

$$= a^2\,E[(X - \mu_X)^2] + b^2\,E[(Y - \mu_Y)^2] + 2ab\,E[(X - \mu_X)(Y - \mu_Y)] = a^2\sigma_X^2 + b^2\sigma_Y^2 + 2ab\,COV(X, Y).$$

■

Esempio 9.6 — La varianza della binomiale, in poche righe

Riprendiamo $X_N = B_1 + \cdots + B_N$, con le B_i di Bernoulli **indipendenti** (i lanci lo sono). Ogni B_i ha varianza $p(1-p)$. Per due lanci, $\sigma_{B_1+B_2}^2 = p(1-p)+p(1-p)$, perché la covarianza di due variabili indipendenti è nulla. Aggiungendo un lancio alla volta: la somma dei primi $n-1$ lanci è una funzione di quei lanci, che sono indipendenti dall'n-esimo, e la covarianza di una somma si spezza nella somma delle covarianze (dalla definizione e dalla linearità della media: $COV(U + V, W) = COV(U, W) + COV(V, W)$), tutte nulle. Così ogni lancio aggiunge $p(1-p)$, e

$$\sigma_{X_N}^2 = N\,p\,(1-p),$$

lo stesso risultato ottenuto nel Capitolo 7 con il trucco della derivata.

QUALE COPPIA È PIÙ CORRELATA?

Esercizio 9.1 — Confrontare due coefficienti di correlazione

Date le due pmf congiunte introdotte all'inizio del capitolo, per $(X_1, Y_1) \in \{0,1\}^2$ e $(X_2, Y_2) \in \{-1,1\}^2$, trovare quale delle due dà luogo a un coefficiente di correlazione maggiore (in valore assoluto).

Svolgimento

Prima coppia. Le marginali, sommando righe e colonne della tabella: $p_{X_1}(0) = \frac{5}{9}$, $p_{X_1}(1) = \frac{4}{9}$; $p_{Y_1}(0) = \frac{4}{9}$, $p_{Y_1}(1) = \frac{5}{9}$. Quindi

$$E[X_1] = 0 \cdot \tfrac{5}{9} + 1 \cdot \tfrac{4}{9} = \tfrac{4}{9}, \qquad E[Y_1] = 0 \cdot \tfrac{4}{9} + 1 \cdot \tfrac{5}{9} = \tfrac{5}{9},$$

$$E[X_1^2] = 0^2 \cdot \tfrac{5}{9} + 1^2 \cdot \tfrac{4}{9} = \tfrac{4}{9}, \qquad E[Y_1^2] = \tfrac{5}{9},$$

$$\sigma^2_{X_1} = E[X_1^2] - E^2[X_1] = \tfrac{4}{9} - \tfrac{16}{81} = \tfrac{36-16}{81} = \tfrac{20}{81} \approx 0{,}247, \qquad \sigma^2_{Y_1} = \tfrac{5}{9} - \tfrac{25}{81} = \tfrac{45-25}{81} = \tfrac{20}{81} \approx 0{,}247.$$

Per $E[X_1Y_1]$ si considera l'unico prodotto di valori diverso da zero, quello con $x_1 = y_1 = 1$:

$$E[X_1Y_1] = 1 \cdot 1 \cdot p_{X_1,Y_1}(1,1) = \tfrac{1}{3}, \qquad COV(X_1, Y_1) = E[X_1Y_1] - E[X_1]\,E[Y_1] = \tfrac{1}{3} - \tfrac{4}{9} \cdot \tfrac{5}{9} = \tfrac{27-20}{81} = \tfrac{7}{81} \approx 0{,}086.$$

$$\rho_{X_1Y_1} = \frac{COV(X_1, Y_1)}{\sigma_{X_1}\sigma_{Y_1}} = \frac{7/81}{\sqrt{\frac{20}{81} \cdot \frac{20}{81}}} = \frac{7/81}{20/81} = \frac{7}{20} = 0{,}35.$$

Seconda coppia. Le marginali: $p_{X_2}(-1) = \frac{1}{4} + \frac{1}{2} = \frac{3}{4}$, $p_{X_2}(1) = \frac{1}{8} + \frac{1}{8} = \frac{1}{4}$; $p_{Y_2}(-1) = \frac{1}{4} + \frac{1}{8} = \frac{3}{8}$, $p_{Y_2}(1) = \frac{1}{2} + \frac{1}{8} = \frac{5}{8}$. Quindi

$$E[X_2] = -1 \cdot \tfrac{3}{4} + 1 \cdot \tfrac{1}{4} = -\tfrac{1}{2}, \qquad E[Y_2] = -1 \cdot \tfrac{3}{8} + 1 \cdot \tfrac{5}{8} = \tfrac{1}{4},$$

e, siccome $(\pm 1)^2 = 1$, $E[X_2^2] = E[Y_2^2] = 1$:

$$\sigma^2_{X_2} = 1 - \tfrac{1}{4} = \tfrac{3}{4}, \qquad \sigma^2_{Y_2} = 1 - \tfrac{1}{16} = \tfrac{15}{16}.$$

Per $E[X_2Y_2]$ servono tutti e quattro i punti (il prodotto vale $+1$ se i segni sono uguali, -1 se sono diversi):

$$E[X_2Y_2] = (-1 \cdot 1)\,\tfrac{1}{2} + (-1 \cdot -1)\,\tfrac{1}{4} + (1 \cdot 1)\,\tfrac{1}{8} + (1 \cdot -1)\,\tfrac{1}{8} = -\tfrac{1}{2} + \tfrac{1}{4} + \tfrac{1}{8} - \tfrac{1}{8} = -\tfrac{1}{4},$$

$$COV(X_2, Y_2) = -\tfrac{1}{4} - \left(-\tfrac{1}{2}\right) \cdot \tfrac{1}{4} = -\tfrac{1}{4} + \tfrac{1}{8} = -\tfrac{1}{8},$$

$$\rho_{X_2Y_2} = \frac{-1/8}{\sqrt{\frac{3}{4} \cdot \frac{15}{16}}} = \frac{-1/8}{\sqrt{45/64}} = \frac{-1/8}{\sqrt{45}/8} = -\frac{1}{\sqrt{45}} \approx -0{,}149.$$

Conclusione. Essendo $|\rho_{X_1Y_1}| = 0{,}35 > |\rho_{X_2Y_2}| \approx 0{,}149$, la coppia (X_1, Y_1) risulta a correlazione assoluta maggiore. Il segno negativo della seconda ha un significato preciso: ci si aspetta che X_2 e Y_2 tendano a discostarsi dalle rispettive medie in direzioni opposte (se una è superiore alla media, l'altra tipicamente è inferiore, e viceversa).

In sintesi

- Se $Z = g(X,Y)$: $p_Z(z) = \sum_{g(x,y)=z} p_{X,Y}(x,y)$ (le probabilità collassano se g non è biunivoca sulle coppie), e $E[g(X,Y)] = \sum_x \sum_y g(x,y)\,p_{X,Y}(x,y)$.
- **Linearità**: $E[\sum a_i X_i] = \sum a_i E[X_i]$, sempre, anche per variabili dipendenti.
- **Media condizionata**: $E[g(X,Y)] = E\big[E[g(X,Y) \mid Y]\big]$: prima la media sapendo Y, poi la media su Y.
- Correlazione $R_{XY} = E[XY]$; **covarianza** $COV(X,Y) = E[(X-\mu_X)(Y-\mu_Y)] = R_{XY} - \mu_X\mu_Y$. Indipendenti $\Rightarrow$ incorrelate, non il viceversa.
- $|COV(X,Y)| \le \sigma_X\sigma_Y$; **coefficiente di correlazione** $\rho_{XY} = COV/(\sigma_X\sigma_Y) \in [-1,1]$, misura della dipendenza lineare.
- $\sigma^2_{aX+bY} = a^2\sigma_X^2 + b^2\sigma_Y^2 + 2ab\,COV(X,Y)$: per variabili incorrelate le varianze si sommano.

Parte II

Variabili aleatorie continue, vettori e processi aleatori

Variabili aleatorie continue: densità e distribuzione

Finora i risultati possibili si potevano mettere in fila e contare: le facce di un dado, le mani di carte, i pacchetti in coda. Molte grandezze fisiche però variano con continuità: una tensione, un tempo di attesa, la posizione di un oggetto. Una tensione può valere 0,31 volt, o 0,312, o 0,3127… e fra due valori qualsiasi ce ne sono infiniti altri. In questo capitolo scopriamo che in questi casi la probabilità di un singolo valore è sempre **zero**, e che serve un oggetto nuovo per descrivere la variabile: la **densità di probabilità**. Per lavorarci useremo lo strumento matematico che fa per le grandezze continue quello che la sommatoria fa per quelle discrete: l'**integrale**, spiegato da zero.

Spazi campione continui

Rimuoviamo ora l'ipotesi che lo spazio campione sia discreto. Supponiamo d'ora in poi che $\Omega \subseteq \mathbb{R}$ sia un sottoinsieme **continuo** dei numeri reali (per esempio un intervallo). Ω può essere esso stesso lo spazio delle misure osservabili, oppure il dominio di una variabile aleatoria

$$X : \omega \in \Omega \longmapsto X(\omega) \in \mathcal{X},$$

e ora l'alfabeto $\mathcal{X}$ non potrà più essere un insieme discreto. Spesso accade che $X(\omega) = \omega$ e $\mathcal{X} = \Omega$: il risultato dell'esperimento è già il numero che interessa.

Esempio 10.1 — Il rumore termico

La tensione misurata a vuoto ai capi di un resistore non è mai esattamente zero: gli elettroni del materiale si agitano a causa della temperatura (è il *rumore termico*), e la tensione oscilla attorno allo zero in modo imprevedibile.

a) Si misura n volte questa tensione. Il risultato è già un numero reale: $X(\omega) = \omega = x \in \mathbb{R}$, e le misure sono n numeri $\{x_i\}_{i=1}^{n}$.

b) Si misura invece la potenza che la tensione trasferisce a un carico di resistenza R. Lo spazio campione è ancora lo stesso, ma la variabile aleatoria ora è $X(\omega) = \omega^2/R$: una funzione del risultato.

Perché un singolo valore ha probabilità zero

In entrambi i casi gli eventi elementari sono del tipo $\{X(\omega_i) = x_i\}$. Si potrebbe essere tentati di definire, come nel caso discreto,

$$P(X = x_i) = \lim_{n\to\infty} \frac{n_{X=x_i}}{n},$$

dove $n_{X=x_i}$ è il numero di volte in cui si è osservato esattamente il valore x_i. La definizione non è sbagliata, ma è inutile. Due realizzazioni distinte $X(\omega_i)$ e $X(\omega_j)$ di una variabile aleatoria reale non si possono mai misurare con esattezza: servirebbe uno strumento di precisione infinita, e anche così l'evento $X(\omega_i) = X(\omega_j)$, che i due valori coincidano fino all'ultima delle infinite cifre decimali, sarebbe impossibile. Quello che possiamo dire è se la misura $X(\omega_j)$ cade o meno **in un intorno** di $X(\omega_i)$, cioè abbastanza vicino. Quindi, se X è una variabile aleatoria continua, gli eventi elementari $\{X = x\}$ hanno (a meno di casi degeneri) probabilità nulla.

C'è anche una ragione matematica: i valori possibili sono troppi perché ognuno possa avere una probabilità positiva. Prima di vederla, un richiamo che chiarisce quando una somma di infiniti termini positivi può dare un numero finito.

Richiamo di matematica: la serie geometrica

Per un numero q con $|q| < 1$ (per esempio $q = \frac{1}{2}$, oppure $q = -0{,}3$):

$$\sum_{k=0}^{\infty} q^k = 1 + q + q^2 + q^3 + \cdots = \frac{1}{1-q}.$$

Dimostrazione. Sia $S_N = 1+q+q^2+\cdots+q^N$ la somma parziale. Moltiplicandola per q si ottiene $q\,S_N = q+q^2+\cdots+q^{N+1}$: gli stessi termini, spostati di un posto. Sottraendo, quasi tutto si cancella (è una somma telescopica):

$$S_N - q\,S_N = 1 - q^{N+1} \quad\Longrightarrow\quad S_N = \frac{1-q^{N+1}}{1-q}.$$

Se $|q| < 1$, le potenze q^{N+1} diventano piccolissime al crescere di N (ogni volta si moltiplica per un numero più piccolo di 1 in valore assoluto), cioè $q^{N+1} \to 0$, e quindi $S_N \to \frac{1}{1-q}$.
Con $q = \frac{1}{2}$ si ritrova $1 + \frac{1}{2} + \frac{1}{4} + \cdots = 2$ (la serie del Capitolo 4 partiva da $\frac{1}{2}$ e valeva 1). Una somma di *infiniti* termini positivi, quindi, può essere finita, purché i termini diventino piccoli abbastanza in fretta. Questo però succede per un'infinità **numerabile** di termini, quelli che si possono mettere in fila.

Teorema 10.1 — Pochi valori possono avere probabilità positiva

Per qualsiasi variabile aleatoria, l'insieme dei valori x con $P(X = x) > 0$ è al più numerabile. In particolare, se l'alfabeto è un intervallo di numeri reali, non tutti i suoi valori possono avere probabilità positiva: quasi tutti devono avere probabilità zero.

Dimostrazione

Passo 1 — Pochi valori «grossi». Fissato un intero $k \geq 1$, i valori con $P(X = x) \geq \frac{1}{k}$ sono al massimo k: se fossero $k+1$, gli eventi $\{X = x\}$ corrispondenti, che sono incompatibili, avrebbero probabilità totale $\geq \frac{k+1}{k} > 1$. Per esempio, al massimo 2 valori possono avere probabilità $\geq \frac{1}{2}$, al massimo 10 valori probabilità $\geq \frac{1}{10}$.

Passo 2 — Li si mette in fila. Un valore con probabilità positiva ha probabilità $\geq \frac{1}{k}$ per qualche k (basta prendere k abbastanza grande). Quindi i valori con probabilità positiva si possono elencare: prima quelli (al più uno) con probabilità ≥ 1, poi quelli (al più due) con probabilità $\geq \frac{1}{2}$, poi quelli $\geq \frac{1}{3}$, e così via. L'elenco può essere infinito, ma è un elenco: l'insieme è al più numerabile.

Passo 3 — L'intervallo è troppo grande. I numeri reali di un intervallo non sono numerabili (Capitolo 1): non si possono mettere tutti in un elenco. Quindi non tutti possono avere probabilità positiva.

■

In una variabile continua «onesta» nessun valore è privilegiato rispetto ai suoi vicini, e allora tutti hanno probabilità zero. Ma attenzione: probabilità zero **non** vuol dire impossibile. Ogni volta che si misura una tensione si osserva *qualche* valore, e quel valore aveva probabilità zero di uscire.

La frequenza di un intervallo

Se la probabilità dei singoli valori è nulla, ha senso solo chiedersi con che frequenza la variabile cade in un **intervallo**. Supponiamo di compiere n esperimenti e di disporre delle osservazioni $X(\omega_i)$. Fissato un valore x, contiamo quante volte X è caduta in un intorno di x di ampiezza Δx, cioè fra $x - \frac{\Delta x}{2}$ e $x + \frac{\Delta x}{2}$:

$$f_n(x;\Delta x) = \frac{n\left\{x - \frac{\Delta x}{2} \leq X \leq x + \frac{\Delta x}{2}\right\}}{n}.$$

Possiamo allora definire nel modo consueto la probabilità dell'evento «X cade nell'intervallo»:

$$P\left(\left\{\omega \in \Omega : x - \tfrac{\Delta x}{2} \leq X \leq x + \tfrac{\Delta x}{2}\right\}\right) = P\left(X \in \left[x - \tfrac{\Delta x}{2},\, x + \tfrac{\Delta x}{2}\right]\right) = P_X(x;\Delta x) = \lim_{n\to\infty} f_n(x;\Delta x).$$

La densità di probabilità

La probabilità di un intervallo dipende dalla sua ampiezza: un intervallo largo il doppio raccoglie, più o meno, il doppio della probabilità. Per avere una grandezza che descriva la variabile *in un punto* si divide la probabilità per l'ampiezza, ottenendo una probabilità *per unità di lunghezza*, e poi si stringe l'intervallo.

Densità di probabilità (PDF)

La **funzione densità di probabilità** (*probability density function*, **PDF**) della variabile aleatoria continua X è

$$f_X(x) = \lim_{\Delta x \to 0} \frac{P\left(x - \frac{\Delta x}{2} \le X \le x + \frac{\Delta x}{2}\right)}{\Delta x} = \lim_{\Delta x \to 0} \frac{P_X(x; \Delta x)}{\Delta x}.$$

Il nome viene dalla fisica. La densità di una sbarra di metallo è la sua massa per unità di lunghezza: una sbarra più densa in un punto pesa di più in quel tratto. Allo stesso modo $f_X(x)$ dice quanta probabilità c'è «per ogni centimetro» attorno a x. Nel caso discreto la probabilità era concentrata in mucchietti (i bastoncini della pmf); ora è spalmata con continuità, come uno strato di sabbia più spesso in certi punti e più sottile in altri.

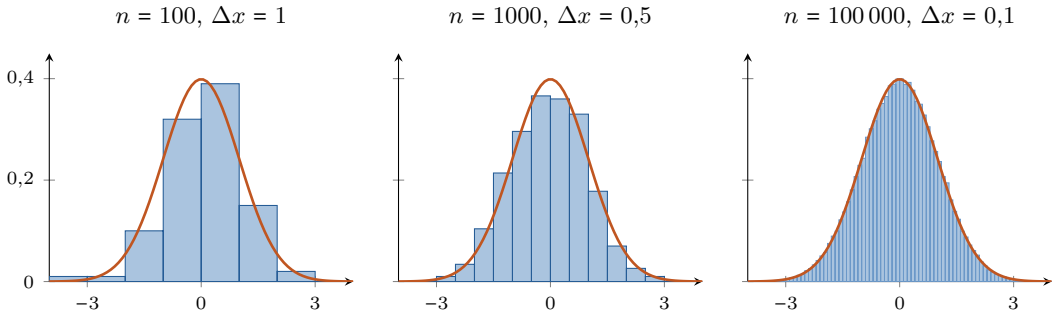


Figura 10.1: *Istogrammi di misure di rumore (simulate): ogni barra è alta $f_n(x; \Delta x)/\Delta x$, la frequenza dell'intervallo divisa per la sua ampiezza. Con più misure e intervalli più stretti l'istogramma si avvicina a una curva liscia (in arancione): la densità di probabilità. Questa curva è la gaussiana, che studieremo nel Capitolo 15.*

Dalla densità alla probabilità: l'integrale

La definizione dice che, per un intervallo piccolo, la probabilità è circa la densità per l'ampiezza:

$$P\left(x - \tfrac{\Delta x}{2} \le X \le x + \tfrac{\Delta x}{2}\right) \approx f_X(x)\,\Delta x.$$

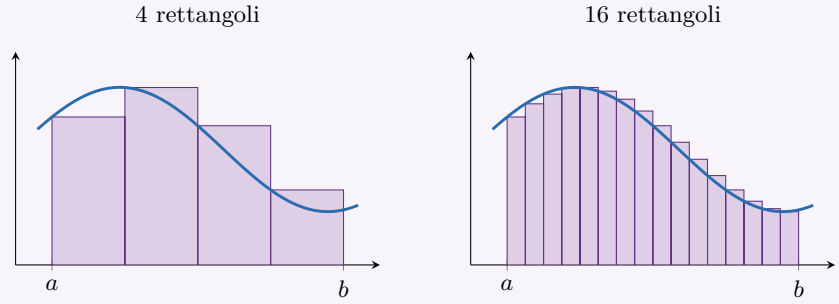
Per un intervallo grande $[a_1, a_2]$ lo si spezza in tanti intervalli piccoli, si calcola la probabilità di ciascuno così e si somma: in un grafico, è la somma delle aree di tanti rettangoli sottili sotto la curva f_X. Quando i rettangoli diventano infinitamente sottili, la somma diventa l'**area sotto la curva**, che si chiama integrale.

Richiamo di matematica: l'integrale come area

Sia $f(x) \geq 0$ una funzione definita sull'intervallo $[a, b]$. Si vuole calcolare l'area della regione compresa fra il grafico di f e l'asse x, fra a e b. Si divide $[a, b]$ in n pezzi uguali di larghezza $\Delta = \frac{b-a}{n}$, con estremi $x_0 = a, x_1, \ldots, x_n = b$, e su ogni pezzo si costruisce un rettangolo alto quanto la funzione in un punto del pezzo. La somma delle aree dei rettangoli,

$$\sum_{i=0}^{n-1} f(x_i)\,\Delta,$$

si chiama **somma di Riemann**. Più i rettangoli sono sottili, meglio approssimano l'area:



Il limite delle somme di Riemann per $n \to \infty$ (cioè per $\Delta \to 0$) è l'**integrale definito**:

$$\int_a^b f(x)\,\mathrm{d}x = \lim_{\Delta \to 0} \sum_i f(x_i)\,\Delta.$$

La notazione racconta la costruzione: il simbolo $\int$ è una «S» allungata (di somma), $f(x)$ è l'altezza di un rettangolo e $\mathrm{d}x$ è la sua larghezza infinitamente piccola. La lettera x è una variabile muta, come l'indice di una sommatoria: $\int_a^b f(x)\,\mathrm{d}x = \int_a^b f(t)\,\mathrm{d}t$.
Proprietà che seguono subito dalla costruzione con i rettangoli:

- **linearità**: $\int_a^b (c\,f(x) + d\,g(x))\,\mathrm{d}x = c\int_a^b f(x)\,\mathrm{d}x + d\int_a^b g(x)\,\mathrm{d}x$;
- **additività**: se $a < c < b$, $\int_a^b f = \int_a^c f + \int_c^b f$ (l'area si può tagliare in due);
- **positività**: se $f(x) \geq 0$ su $[a, b]$, allora $\int_a^b f(x)\,\mathrm{d}x \geq 0$;
- un singolo punto non ha area: $\int_a^a f(x)\,\mathrm{d}x = 0$.

Se la funzione è negativa in qualche tratto, le aree sotto l'asse x contano con il segno meno.

Con l'integrale, la probabilità di qualsiasi intervallo si ottiene dalla densità.

Da ricordare: probabilità di un intervallo

$$P(a_1 \leq X \leq a_2) = \int_{a_1}^{a_2} f_X(t)\,\mathrm{d}t \qquad P\left(x - \tfrac{\Delta x}{2} \leq X \leq x + \tfrac{\Delta x}{2}\right) = \int_{x-\frac{\Delta x}{2}}^{x+\frac{\Delta x}{2}} f_X(t)\,\mathrm{d}t$$

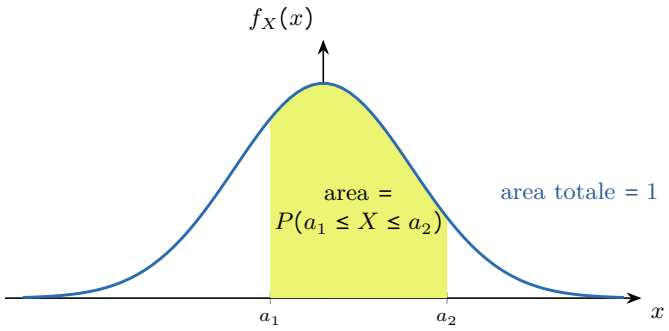


Figura 10.2: *La probabilità che X cada fra a_1 e a_2 è l'area sotto la densità, fra a_1 e a_2.*

Le proprietà della densità

Per l'area «totale», da $-\infty$ a $+\infty$, serve un'estensione dell'integrale.

Richiamo di matematica: gli integrali impropri

Un integrale su un intervallo infinito si definisce come limite:

$$\int_a^{\infty} f(x)\,dx = \lim_{H\to\infty}\int_a^{H} f(x)\,dx, \qquad \int_{-\infty}^{\infty} f(x)\,dx = \lim_{H\to\infty}\int_{-H}^{0} f(x)\,dx + \lim_{K\to\infty}\int_0^{K} f(x)\,dx.$$

Se i limiti esistono e sono finiti, l'integrale si dice **convergente** (la funzione è **sommabile**). Una regione infinitamente lunga può avere area finita, se la funzione si abbassa abbastanza in fretta: è la stessa idea della serie geometrica. Per esempio (lo calcoleremo con il teorema del prossimo richiamo) $\int_1^H \frac{1}{x^2}\,dx = 1 - \frac{1}{H}$, che tende a 1: l'area sotto $\frac{1}{x^2}$ da 1 a infinito vale 1. Invece $\int_0^H 1\,dx = H$ cresce senza limite: un rettangolo alto 1 e infinitamente lungo ha area infinita.
Nel secondo caso le due metà devono convergere *ciascuna per conto suo*: non basta che si compensino. È un punto che diventerà importante con la variabile di Cauchy, nel prossimo capitolo.

Teorema 10.2 — Proprietà della densità

Ogni densità di probabilità soddisfa:

a) $f_X(x) \geq 0$ per ogni $x \in \mathbb{R}$;

b) f_X è sommabile su $\mathbb{R}$ e il suo integrale vale 1: $\int_{-\infty}^{\infty} f_X(t)\,dt = P(X \in \mathbb{R}) = P(\Omega) = 1$.

Inoltre $P(X = x) = 0$ per ogni x, quindi gli estremi di un intervallo non contano: $P(a_1 \leq X \leq a_2) = P(a_1 < X < a_2) = P(a_1 \leq X < a_2)$.

Dimostrazione

Passo 1 — Non negatività. $f_X(x)$ è il limite di rapporti fra una probabilità (≥ 0) e un'ampiezza (> 0). In altre parole: se la densità fosse negativa in un tratto, il suo integrale su quel tratto, cioè la probabilità di quell'intervallo, sarebbe negativo.

Passo 2 — Area totale. L'evento «X è un numero reale qualsiasi» è certo, quindi ha probabilità 1, ed è l'area sotto tutta la curva.

Passo 3 — Un punto. $P(X = x) \leq P\left(x - \frac{\Delta x}{2} \leq X \leq x + \frac{\Delta x}{2}\right) \simeq f_X(x)\,\Delta x$, che tende a zero quando $\Delta x \to 0$. Quindi aggiungere o togliere gli estremi a un intervallo non cambia la sua probabilità.

■

Una densità non è una probabilità

$f_X(x)$ può benissimo essere **maggiore di 1**. Una variabile uniformemente distribuita fra 0 e $\frac{1}{2}$ ha densità 2 su quell'intervallo: l'area è $2 \cdot \frac{1}{2} = 1$, come deve. Ad avere un significato di probabilità è l'area, non l'altezza: $f_X(x)\,\Delta x$, per Δx piccolo. Ed è $P(X = x) = 0$, non $f_X(x)$.

La funzione di distribuzione cumulativa

La densità $f_X(x)$, $x \in \mathbb{R}$, è perfettamente adeguata a caratterizzare la variabile aleatoria X. I punti in cui è diversa da zero formano il suo **supporto**, $\text{supp}[f_X(x)] = \mathcal{X}$: sono i valori che la variabile può assumere. E la probabilità di qualsiasi intervallo è l'integrale della densità. Tuttavia è molto usata anche una caratterizzazione alternativa, che parla direttamente di probabilità.

Funzione di distribuzione cumulativa (CDF)

La **funzione di distribuzione cumulativa** (*Cumulative Distribution Function*, **CDF**) di X è la probabilità che X non superi il valore x:

$$F_X(x) = P(-\infty < X \le x) = \int_{-\infty}^{x} f_X(t)\,\mathrm{d}t.$$

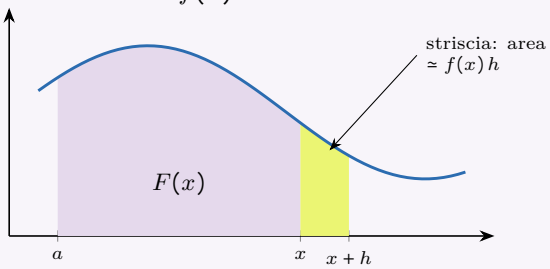
$F_X(x)$ è l'area sotto la densità *a sinistra* di x: la probabilità «accumulata» da $-\infty$ fino a x. Quando x si sposta verso destra, l'area cresce. Il legame fra F_X e f_X è uno dei risultati più importanti della matematica.

Richiamo di matematica: il teorema fondamentale del calcolo integrale

Sia f una funzione continua e sia $F(x) = \int_a^x f(t)\,\mathrm{d}t$ la **funzione integrale**: l'area sotto f da a fino a x, vista come funzione dell'estremo destro. Allora

$$F'(x) = f(x)\,:$$

la derivata dell'area è l'altezza della curva. Il motivo si vede nel disegno: quando l'estremo passa da x a $x + h$, l'area cresce di una strisciolina larga h e alta circa $f(x)$.



Quindi $F(x+h) - F(x) \simeq f(x)\,h$, il rapporto incrementale $\frac{F(x+h)-F(x)}{h}$ è circa $f(x)$, e diventa esattamente $f(x)$ quando $h \to 0$ (la striscia diventa un rettangolo perfetto).

Come si calcola un integrale. Una funzione G con $G'(x) = f(x)$ si chiama **primitiva** di f. Due primitive della stessa funzione differiscono per una costante (la loro differenza ha derivata nulla, quindi è piatta). Siccome anche F è una primitiva, $F(x) = G(x) + c$, e da $F(a) = 0$ si ricava $c = -G(a)$. Quindi

$$\int_a^b f(x)\,\mathrm{d}x = G(b) - G(a) = \Big[G(x)\Big]_a^b\,:$$

per calcolare un integrale basta trovare una primitiva e fare la differenza dei suoi valori agli estremi. Le primitive si trovano leggendo al contrario la tabella delle derivate. Da $(x^{n+1})' = (n+1)\,x^n$:

$$\int_a^b x^n\,\mathrm{d}x = \left[\frac{x^{n+1}}{n+1}\right]_a^b = \frac{b^{n+1} - a^{n+1}}{n+1} \qquad (n \neq -1).$$

Per esempio $\int_0^1 x\,\mathrm{d}x = \frac{1}{2}$ (l'area del triangolo con base e altezza 1) e $\int_1^H x^{-2}\,\mathrm{d}x = \Big[-x^{-1}\Big]_1^H = 1 - \frac{1}{H}$.

Applicando il teorema fondamentale alla CDF si ottiene subito il legame con la densità.

Da ricordare: CDF e PDF

$$F_X(x) = \int_{-\infty}^{x} f_X(t)\,\mathrm{d}t \qquad \Longleftrightarrow \qquad f_X(x) = \frac{\mathrm{d}}{\mathrm{d}x} F_X(x)$$

Talvolta si fa riferimento alla funzione complementare, la **CCDF** (*Complementary Cumulative Distribution Function*): la probabilità che X superi x, cioè l'area a destra di x,

$$\overline{F}_X(x) = P(X > x) = \int_x^{\infty} f_X(t)\,\mathrm{d}t = 1 - F_X(x) \quad \Longrightarrow \quad f_X(x) = -\frac{\mathrm{d}}{\mathrm{d}x}\overline{F}_X(x).$$

Teorema 10.3 — Proprietà della CDF

a) $F_X(x) \in [0,1]$;
b) $F_X(-\infty) = 0$ e $F_X(+\infty) = 1$ (intesi come limiti);
c) F_X è continua;
d) F_X è crescente (non decrescente): se $x_1 < x_2$ allora $F_X(x_1) \le F_X(x_2)$;
e) $P(a_1 \le X \le a_2) = \int_{a_1}^{a_2} f_X(t)\,\mathrm{d}t = F_X(a_2) - F_X(a_1)$.

Dimostrazione

Passo 1 — Fra 0 e 1. $F_X(x)$ è una probabilità.

Passo 2 — Ai due estremi. Per $x \to -\infty$ l'area a sinistra di x si riduce a nulla; per $x \to +\infty$ diventa tutta l'area sotto la densità, che vale 1.

Passo 3 — Continuità. Spostando x di poco, l'area cambia di poco: di una striscia stretta, larga quanto lo spostamento. (È la funzione integrale di una funzione sommabile.)

Passo 4 — Crescenza. Se $x_1 < x_2$, l'area fino a x_2 è quella fino a x_1 più l'area fra x_1 e x_2, che non è negativa perché l'integrando $f_X \ge 0$.

Passo 5 — Un intervallo. Per l'additività dell'integrale, $\int_{-\infty}^{a_2} f_X = \int_{-\infty}^{a_1} f_X + \int_{a_1}^{a_2} f_X$, cioè $F_X(a_2) = F_X(a_1) + P(a_1 \le X \le a_2)$.

■

Esempio 10.2 — La densità triangolare

Sia X con densità a forma di triangolo:

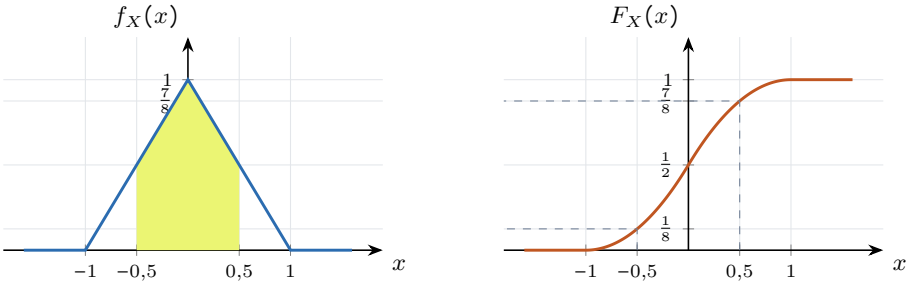
$$f_X(x) = \begin{cases} 1 - |x| & -1 \le x \le 1 \\ 0 & \text{altrove} \end{cases}$$

È una densità: è ≥ 0, e l'area sotto il triangolo (base 2, altezza 1) vale $\frac{2 \cdot 1}{2} = 1$. Calcoliamo la CDF integrando un pezzo alla volta.

- Per $x < -1$ a sinistra non c'è area: $F_X(x) = 0$.
- Per $-1 \le x \le 0$ la densità vale $1 + t$, con primitiva $t + \frac{t^2}{2}$:

$$F_X(x) = \int_{-1}^{x} (1+t)\,\mathrm{d}t = \left[t + \tfrac{t^2}{2}\right]_{-1}^{x} = x + \tfrac{x^2}{2} - \left(-1 + \tfrac{1}{2}\right) = \frac{(1+x)^2}{2}.$$

- Per $0 \le x \le 1$ all'area di sinistra, $F_X(0) = \frac{1}{2}$, si aggiunge quella fra 0 e x, dove la densità vale $1 - t$: $\int_0^x (1-t)\,\mathrm{d}t = x - \frac{x^2}{2}$. Quindi $F_X(x) = \frac{1}{2} + x - \frac{x^2}{2} = 1 - \frac{(1-x)^2}{2}$.
- Per $x > 1$ tutta l'area è a sinistra: $F_X(x) = 1$.



La probabilità che X cada fra $-\frac{1}{2}$ e $\frac{1}{2}$ è l'area gialla a sinistra, oppure la differenza dei valori della CDF a destra:

$$P\left(-\tfrac{1}{2} \le X \le \tfrac{1}{2}\right) = F_X\left(\tfrac{1}{2}\right) - F_X\left(-\tfrac{1}{2}\right) = \left(1 - \tfrac{1}{8}\right) - \tfrac{1}{8} = \tfrac{3}{4}.$$

Verifica geometrica: fuori dalla zona gialla restano due triangolini con base e altezza $\frac{1}{2}$, di area $\frac{1}{8}$ ciascuno, e $1 - \frac{1}{8} - \frac{1}{8} = \frac{3}{4}$. Si noti anche che la CDF cresce più in fretta dove la densità è più alta (attorno a 0): la sua pendenza è proprio la densità.

La CDF delle variabili discrete

La CDF si può definire anche per le variabili discrete (e per quelle «miste», di cui non parliamo): $F_X(x) = P(X \le x)$ ha senso per qualsiasi variabile aleatoria. In questo caso, però, la proprietà di continuità va «rimodulata»: la CDF di una variabile discreta è una **scala**, piatta fra un valore dell'alfabeto e il successivo, con un **salto** in ogni valore x alto esattamente $p_X(x)$.

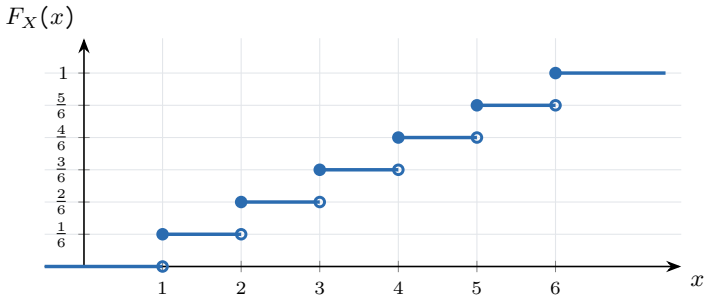


Figura 10.3: *La CDF del lancio di un dado: in ogni faccia sale di un gradino alto $\frac{1}{6}$. Il pallino pieno indica il valore nel punto di salto: $F_X(3) = P(X \le 3) = \frac{3}{6}$, perché il 3 è compreso.*

La media di una variabile continua

Media statistica di una variabile continua

La **media statistica** di una variabile aleatoria continua con densità $f_X(x)$ è

$$E[X] = \mu_X = \int_{-\infty}^{\infty} x\, f_X(x)\, \mathrm{d}x,$$

purché l'integrale converga.

La definizione è la stessa del caso discreto, $\sum_x x\, p_X(x)$, con l'integrale al posto della somma e $f_X(x)\,\mathrm{d}x$ al posto di $p_X(x)$. Per giustificarla in modo convincente si può approssimare la variabile continua con una discreta.

Dimostrazione — la media come limite di una variabile quantizzata

Passo 1 — Si quantizza X. Si divide l'asse reale in intervalli di ampiezza Δ e si definisce la versione «quantizzata» di X: se X cade nell'intervallo $[i\Delta, (i+1)\Delta)$, la si sostituisce con un valore x_i di quell'intervallo,

$$X^\Delta = x_i \in [i\Delta, (i+1)\Delta) \qquad \text{se} \quad i\Delta \le X < (i+1)\Delta.$$

È una variabile discreta, con probabilità

$$P(X^\Delta = x_i) = \int_{i\Delta}^{(i+1)\Delta} f_X(x)\,\mathrm{d}x.$$

Passo 2 — La media della variabile discreta. Con la definizione del Capitolo 5:

$$E[X^\Delta] = \sum_{i=-\infty}^{\infty} x_i\, P(X^\Delta = x_i) = \sum_{i=-\infty}^{\infty} x_i \int_{i\Delta}^{(i+1)\Delta} f_X(x)\,\mathrm{d}x.$$

Passo 3 — Si stringono gli intervalli. Quando Δ è piccolo, l'area sotto f_X su un intervallo è circa l'altezza per la base, $f_X(x_i)\,\Delta$, e la quantizzazione diventa sempre più fine. Se $x f_X(x)$ è integrabile (secondo Riemann), la somma diventa una somma di Riemann della funzione $x f_X(x)$:

$$E[X] = \lim_{\Delta\to 0} E[X^\Delta] = \lim_{\Delta\to 0} \sum_{i=-\infty}^{\infty} x_i\, f_X(x_i)\,\Delta = \int_{-\infty}^{\infty} x\, f_X(x)\,\mathrm{d}x.$$

■

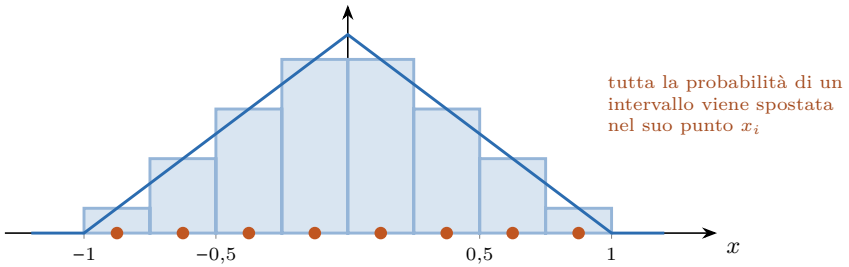


Figura 10.4: *La quantizzazione della densità triangolare con $\Delta = \frac{1}{4}$: ogni rettangolo azzurro ha area circa uguale alla probabilità del suo intervallo, che la variabile quantizzata X^Δ concentra nel punto arancione.*

Esempio 10.3 — Due medie

- La densità triangolare è simmetrica attorno a 0, e la sua media è 0: i contributi $x f_X(x)$ a destra (positivi) e a sinistra (negativi) sono uguali e opposti.
- Sia $f_X(x) = 2x$ per $0 \le x \le 1$ (e 0 altrove): una densità che cresce, quindi i valori grandi sono più probabili. È una densità perché $\int_0^1 2x\,\mathrm{d}x = \left[x^2\right]_0^1 = 1$. La media è

$$E[X] = \int_0^1 x \cdot 2x\,\mathrm{d}x = \int_0^1 2x^2\,\mathrm{d}x = \left[\tfrac{2x^3}{3}\right]_0^1 = \tfrac{2}{3},$$

  spostata verso destra rispetto al punto di mezzo $\frac{1}{2}$, come ci si aspetta.

Anche nel continuo la media è il **baricentro**: una sbarra con densità di massa $f_X(x)$ starebbe in equilibrio appoggiata nel punto $E[X]$.

In sintesi

- Per una variabile continua ogni singolo valore ha probabilità zero: gli intervalli, non i punti, hanno probabilità. Solo un'infinità al più numerabile di valori può avere probabilità positiva.
- La **densità** $f_X(x) = \lim P(x - \frac{\Delta x}{2} \le X \le x + \frac{\Delta x}{2})/\Delta x$ è una probabilità per unità di lunghezza: $f_X \ge 0$, $\int f_X = 1$, e può superare 1.
- $P(a_1 \le X \le a_2) = \int_{a_1}^{a_2} f_X$: l'**integrale** è l'area sotto la curva, limite delle somme di Riemann; si calcola con una primitiva, $\int_a^b f = G(b) - G(a)$.
- La **CDF** $F_X(x) = P(X \le x) = \int_{-\infty}^{x} f_X$ è continua, crescente, va da 0 a 1, e $f_X = F_X'$ (teorema fondamentale del calcolo integrale). La CCDF è $1 - F_X$. Per le variabili discrete la CDF è una scala.
- **Media**: $E[X] = \int x\, f_X(x)\,\mathrm{d}x$, limite della media di una versione quantizzata di X.

Le variabili aleatorie continue notevoli

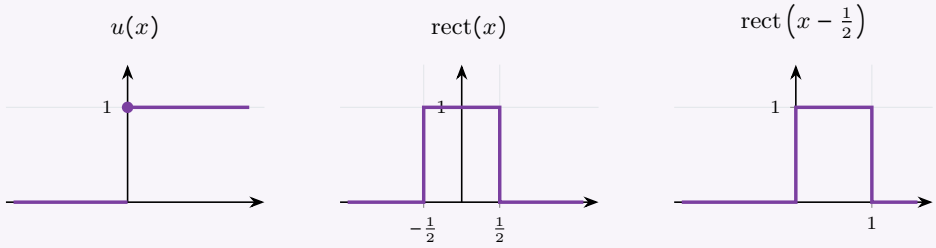
Come nel discreto avevamo la binomiale, l'uniforme e la Poisson, anche nel continuo ci sono alcune variabili che compaiono di continuo. In questo capitolo ne studiamo quattro: l'**uniforme**, l'**esponenziale**, quella di **Laplace** e quella di **Cauchy**. Per ognuna calcoliamo la densità, la CDF e la media; per farlo ci servono alcuni strumenti nuovi per gli integrali (l'integrazione per parti, il cambio di variabile) e due funzioni nuove (il logaritmo e l'arcotangente), tutti spiegati da zero. La variabile di Cauchy ci riserverà una sorpresa: non ha media. La quinta variabile continua notevole, la gaussiana, è così importante che avrà un capitolo tutto per sé.

Due funzioni utili: il gradino e il rettangolo

Le densità che vedremo sono spesso diverse da zero solo su una parte della retta. Per scriverle in una sola formula si usano due funzioni «interruttore».

Richiamo di matematica: il gradino unitario e la funzione rettangolo

Il **gradino unitario** $u(x)$ vale 0 per $x < 0$ e 1 per $x \geq 0$: moltiplicare una funzione per $u(x)$ la «spegne» a sinistra dello zero. La **funzione rettangolo** $\text{rect}(x)$ vale 1 per $|x| < \frac{1}{2}$ e 0 altrove: è un impulso largo 1 centrato in 0, e $\text{rect}\left(x - \frac{1}{2}\right)$ è lo stesso impulso spostato sull'intervallo $(0, 1)$.



Per esempio, $e^{-x}u(x)$ vale e^{-x} per $x \geq 0$ e zero per $x < 0$. Quanto valga la funzione esattamente nel punto di salto non conta: un singolo punto non ha area, quindi non cambia nessun integrale.

LA VARIABILE UNIFORME

Variabile uniforme continua

Una variabile aleatoria X si dice **uniformemente distribuita** nell'intervallo $[a, b]$ (con $b > a$), in breve $X \sim \mathcal{U}(a, b)$, se

$$f_X(x) = \begin{cases} \dfrac{1}{b-a} & x \in (a, b) \\ 0 & \text{altrove} \end{cases}$$

La densità è costante sull'intervallo: nessun punto è privilegiato. L'altezza $\frac{1}{b-a}$ è l'unica che rende l'area del rettangolo (base $b - a$) uguale a 1. Il supporto è $\text{supp}[f_X(x)] = [a, b]$, e tale è anche l'alfabeto: X non assume valori fuori dall'intervallo. Con la funzione rettangolo, $\mathcal{U}(0, 1)$ ha densità $\text{rect}\left(x - \frac{1}{2}\right)$.

Teorema 11.1 — CDF e media dell'uniforme

Se $X \sim \mathcal{U}(a, b)$:

$$F_X(x) = \begin{cases} 0 & x < a \\ \dfrac{x-a}{b-a} & a \le x \le b \\ 1 & x > b \end{cases} \qquad E[X] = \frac{a+b}{2}.$$

Dimostrazione

Passo 1 — La CDF. A sinistra di a non c'è area. Fra a e x la densità vale $\frac{1}{b-a}$, costante, quindi l'area è quella di un rettangolo: base $x - a$, altezza $\frac{1}{b-a}$. Oltre b l'area è tutta, cioè 1.

$$F_X(x) = \int_{-\infty}^{x} f_X(t)\,\mathrm{d}t = \int_a^x \frac{1}{b-a}\,\mathrm{d}t = \frac{x-a}{b-a} \qquad (a \le x \le b).$$

Passo 2 — La media. Con la primitiva di x, che è $\frac{x^2}{2}$:

$$E[X] = \int_a^b x\,\frac{1}{b-a}\,\mathrm{d}x = \frac{1}{b-a}\left[\frac{x^2}{2}\right]_a^b = \frac{b^2-a^2}{2(b-a)} = \frac{(b-a)(b+a)}{2(b-a)} = \frac{b+a}{2},$$

dove si è usato il prodotto notevole $b^2 - a^2 = (b - a)(b + a)$.

■

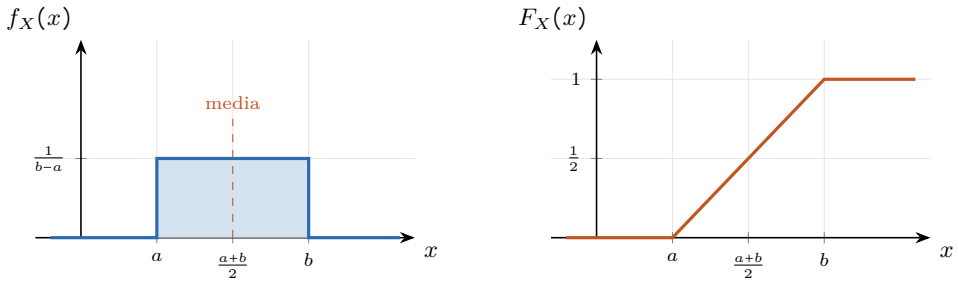


Figura 11.1: *La variabile uniforme: densità costante sull'intervallo, CDF che sale in linea retta da 0 a 1.*

La variabile esponenziale

Variabile esponenziale

Una variabile aleatoria X si dice **esponenziale** (unilatera) di parametro $\lambda > 0$, in breve $X \sim \mathcal{E}(\lambda)$, se ha densità

$$f_X(x) = \lambda\, e^{-\lambda x}\, u(x).$$

Il supporto è $\operatorname{supp}[f_X(x)] = [0, \infty)$: la variabile è sempre non negativa, $X \geq 0$. È la variabile tipica dei **tempi di attesa**: il tempo fino al prossimo pacchetto che arriva a un router, fino al guasto di un componente, fino al decadimento di un atomo. La densità è massima in 0 e cala esponenzialmente: le attese brevi sono le più probabili, quelle lunghe sono rare. Prima di calcolare la CDF serve sapere come si integra un esponenziale.

Richiamo di matematica: la derivata e la primitiva di e^{ax}

Per una costante a: $\left(e^{ax}\right)' = a\, e^{ax}$. Infatti il rapporto incrementale è

$$\frac{e^{a(x+h)} - e^{ax}}{h} = e^{ax}\,\frac{e^{ah} - 1}{h} = a\, e^{ax}\,\frac{e^{ah} - 1}{ah},$$

e l'ultima frazione tende a 1 quando $h \to 0$ (è il limite $\frac{e^k - 1}{k} \to 1$ del Capitolo 7, con $k = ah$ che tende anch'esso a zero). Di conseguenza una primitiva di e^{ax} è $\frac{e^{ax}}{a}$, e in particolare

$$\int e^{-\lambda t}\, \mathrm{d}t \quad \text{ha primitiva} \quad \frac{e^{-\lambda t}}{-\lambda}.$$

Serve anche sapere che l'esponenziale «batte» qualsiasi potenza: per $\lambda > 0$, $x^n e^{-\lambda x} \to 0$ quando $x \to \infty$. Per $n = 1$: dalla serie esponenziale, che ha tutti i termini positivi, $e^{\lambda x} \geq \frac{(\lambda x)^2}{2}$, quindi $x\, e^{-\lambda x} \leq \frac{2x}{\lambda^2 x^2} = \frac{2}{\lambda^2 x} \to 0$. Per n qualsiasi si ragiona allo stesso modo con il termine $\frac{(\lambda x)^{n+1}}{(n+1)!}$ della serie.

Teorema 11.2 — CDF dell'esponenziale

Se $X \sim \mathcal{E}(\lambda)$: $\quad F_X(x) = \left(1 - e^{-\lambda x}\right) u(x), \quad \overline{F}_X(x) = P(X > x) = e^{-\lambda x}$ per $x \geq 0$.

Dimostrazione

Passo 1. Per $x < 0$ non c'è area. Per $x \geq 0$, con la primitiva del richiamo:

$$F_X(x) = \int_0^x \lambda\, e^{-\lambda t}\, \mathrm{d}t = \lambda \left[\frac{e^{-\lambda t}}{-\lambda}\right]_0^x = \left[-e^{-\lambda t}\right]_0^x = -e^{-\lambda x} - (-e^0) = 1 - e^{-\lambda x}.$$

La CCDF è il complemento a 1: $e^{-\lambda x}$.

■

Per la media serve una tecnica nuova, perché l'integrando $x\, \lambda e^{-\lambda x}$ è un prodotto.

Richiamo di matematica: l'integrazione per parti

La regola del prodotto (Capitolo 7) dice che $(fg)' = f'g + fg'$. Integrando entrambi i membri fra a e b, e ricordando che l'integrale di una derivata è la differenza dei valori agli estremi (teorema fondamentale):

$$\Big[fg\Big]_a^b = \int_a^b f'(x)\,g(x)\,\mathrm{d}x + \int_a^b f(x)\,g'(x)\,\mathrm{d}x.$$

Portando un integrale dall'altra parte si ottiene la formula di **integrazione per parti**:

$$\int_a^b f(x)\,g'(x)\,\mathrm{d}x = \Big[f(x)\,g(x)\Big]_a^b - \int_a^b f'(x)\,g(x)\,\mathrm{d}x.$$

Serve quando l'integrando è un prodotto di due fattori, uno facile da derivare (f, che derivato si semplifica) e uno facile da integrare (g', di cui si conosce una primitiva g). Esempio:

$$\int_0^1 x\,e^x\,\mathrm{d}x = \Big[x\,e^x\Big]_0^1 - \int_0^1 1\cdot e^x\,\mathrm{d}x = e - (e-1) = 1,$$

con $f = x$ (derivata 1) e $g' = e^x$ (primitiva e^x).

Teorema 11.3 — Media dell'esponenziale

Se $X \sim \mathcal{E}(\lambda)$: $\quad E[X] = \dfrac{1}{\lambda}$.

Dimostrazione

Passo 1 — Si toglie il gradino. Il gradino annulla la parte negativa dell'asse:

$$E[X] = \int_{-\infty}^{\infty} x\,f_X(x)\,\mathrm{d}x = \int_{-\infty}^{\infty} x\,\lambda e^{-\lambda x}u(x)\,\mathrm{d}x = \int_0^{\infty} x\,\lambda e^{-\lambda x}\,\mathrm{d}x.$$

Passo 2 — Per parti. Con $f(x) = x$ (derivata 1) e $g'(x) = \lambda e^{-\lambda x}$ (primitiva $g(x) = -e^{-\lambda x}$):

$$\int_0^{\infty} x\,\lambda e^{-\lambda x}\,\mathrm{d}x = \Big[x\left(-e^{-\lambda x}\right)\Big]_0^{\infty} - \int_0^{\infty}\left(-e^{-\lambda x}\right)\mathrm{d}x.$$

Passo 3 — Il termine di bordo è nullo. In $x = 0$ vale 0; per $x \to \infty$, $x\,e^{-\lambda x} \to 0$ (l'esponenziale batte la potenza).

Passo 4 — L'integrale rimasto.

$$E[X] = \int_0^{\infty} e^{-\lambda x}\,\mathrm{d}x = \left[\frac{e^{-\lambda x}}{-\lambda}\right]_0^{\infty} = 0 - \frac{1}{-\lambda} = \frac{1}{\lambda}.$$

■

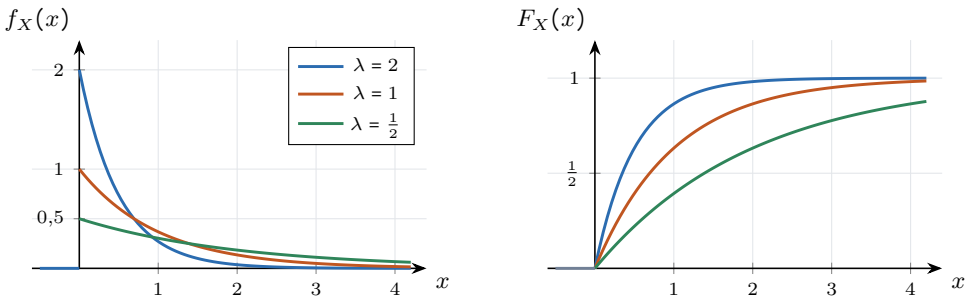


Figura 11.2: *Densità e CDF esponenziali. Con λ grande la densità parte alta e scende in fretta (attese brevi, media $\frac{1}{\lambda}$ piccola); con λ piccolo è bassa e lunga (attese lunghe).*

Esempio 11.1 — L'esponenziale non ha memoria

Il tempo di vita di un componente elettronico è $X \sim \mathcal{E}(\lambda)$. Il componente funziona da s ore: qual è la probabilità che funzioni per almeno altre t ore? Con la probabilità condizionata e la CCDF:

$$P(X > s+t \mid X > s) = \frac{P(\{X > s+t\} \cap \{X > s\})}{P(X > s)} = \frac{P(X > s+t)}{P(X > s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = P(X > t).$$

(L'intersezione è $\{X > s+t\}$ perché chi supera $s+t$ supera anche s.) Il risultato non dipende da s: il componente «non ricorda» quanto ha già lavorato, e la sua vita residua ha la stessa distribuzione di quella di un componente nuovo. È la proprietà di **assenza di memoria**, che rende l'esponenziale il modello naturale dei guasti casuali (non dovuti all'usura) e degli arrivi «a caso» di pacchetti o chiamate.

La variabile di Laplace

Variabile di Laplace

Una variabile aleatoria X si dice **di Laplace** di parametro $\lambda > 0$, in breve $X \sim \mathcal{L}(\lambda)$, se ha densità

$$f_X(x) = \frac{\lambda}{2} e^{-\lambda|x|}.$$

In questo caso $\text{supp}[f_X(x)] = \mathbb{R}$: la variabile può assumere qualunque valore reale. La densità è fatta da due esponenziali «schiena contro schiena», ciascuno dimezzato (così l'area totale è 1): è simmetrica attorno a 0, con una punta nell'origine.

Teorema 11.4 — CDF della variabile di Laplace

Se $X \sim \mathcal{L}(\lambda)$:

$$F_X(x) = \begin{cases} \frac{1}{2} e^{\lambda x} & x \le 0 \\ 1 - \frac{1}{2} e^{-\lambda x} & x \ge 0 \end{cases}$$

Dimostrazione

Passo 1 — Il valore assoluto. $|t| = -t$ per $t \le 0$ e $|t| = t$ per $t \ge 0$: a sinistra dello zero la densità è $\frac{\lambda}{2}e^{\lambda t}$, a destra $\frac{\lambda}{2}e^{-\lambda t}$.

Passo 2 — Per $x \le 0$. Si integra solo la parte sinistra. La primitiva di $e^{\lambda t}$ è $\frac{e^{\lambda t}}{\lambda}$, che tende a 0 per $t \to -\infty$:

$$F_X(x) = \int_{-\infty}^{x} \frac{\lambda}{2} e^{\lambda t}\, dt = \frac{\lambda}{2}\left[\frac{e^{\lambda t}}{\lambda}\right]_{-\infty}^{x} = \frac{1}{2} e^{\lambda x}.$$

Passo 3 — Per $x \ge 0$. Si spezza l'integrale in zero, perché le due metà hanno formule diverse:

$$F_X(x) = \int_{-\infty}^{0} \frac{\lambda}{2} e^{\lambda t}\, dt + \int_{0}^{x} \frac{\lambda}{2} e^{-\lambda t}\, dt = \frac{\lambda}{2}\left(\left[\frac{e^{\lambda t}}{\lambda}\right]_{-\infty}^{0} + \left[\frac{e^{-\lambda t}}{-\lambda}\right]_{0}^{x}\right) = \frac{\lambda}{2}\left(\frac{1}{\lambda} + \frac{1 - e^{-\lambda x}}{\lambda}\right).$$

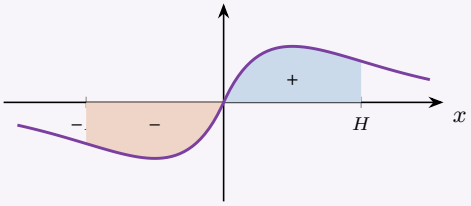
Raccogliendo: $\frac{\lambda}{2} \cdot \frac{2 - e^{-\lambda x}}{\lambda} = 1 - \frac{1}{2} e^{-\lambda x}$. Si noti che le due formule danno lo stesso valore, $\frac{1}{2}$, in $x = 0$: metà della probabilità sta a sinistra dello zero e metà a destra.

■

Per la media non serve nessun calcolo, grazie a un'osservazione sulla simmetria.

Richiamo di matematica: funzioni pari e dispari

Una funzione è **pari** se $g(-x) = g(x)$: il grafico è simmetrico rispetto all'asse verticale (esempi: x^2, $|x|$, $e^{-|x|}$). È **dispari** se $g(-x) = -g(x)$: il grafico è simmetrico rispetto all'origine (esempi: x, x^3, $\sin x$). Il prodotto di una funzione dispari per una pari è dispari: in particolare, se f è pari, $x\,f(x)$ è dispari.



L'integrale di una funzione dispari su un intervallo simmetrico $[-H, H]$ è nullo: l'area a destra (positiva) e quella a sinistra (negativa) sono uguali e opposte. Su tutta la retta, $\int_{-\infty}^{\infty}$, vale lo stesso **purché** le due metà $\int_0^{\infty}$ e $\int_{-\infty}^{0}$ siano finite: se sono infinite, «$+\infty - \infty$» non ha senso, e l'integrale non esiste.

Teorema 11.5 — Media della variabile di Laplace

Se $X \sim \mathcal{L}(\lambda)$: $\quad E[X] = \displaystyle\int_{-\infty}^{\infty} x\,\frac{\lambda}{2}\,e^{-\lambda|x|}\,\mathrm{d}x = 0.$

Dimostrazione

Passo 1 — L'integrando è dispari. La densità è pari, quindi $x\,f_X(x)$ è dispari.

Passo 2 — Le due metà sono finite. $\int_0^{\infty} x\,\frac{\lambda}{2}e^{-\lambda x}\,\mathrm{d}x = \frac{1}{2}\cdot\frac{1}{\lambda}$, perché è metà dell'integrale calcolato per la media dell'esponenziale. Allo stesso modo la metà sinistra vale $-\frac{1}{2\lambda}$. La somma è zero. ∎

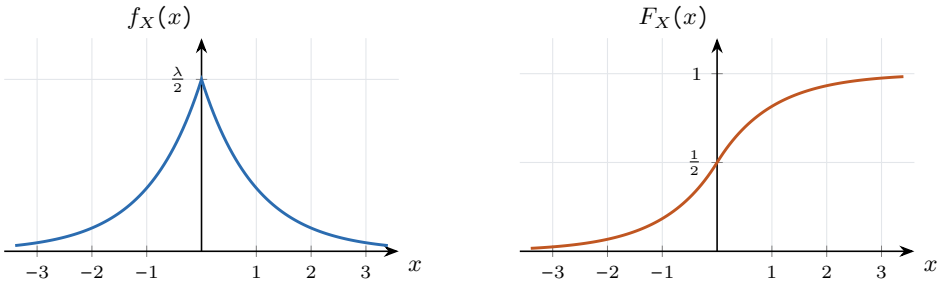


Figura 11.3: *La variabile di Laplace con $\lambda = 1$: due esponenziali dimezzati, simmetrici attorno a 0.*

La variabile di Cauchy

Variabile di Cauchy

Una variabile aleatoria X si dice **di Cauchy** di parametri (a, b), con $b > 0$, in breve $X \sim \mathcal{C}(a, b)$, se ha densità

$$f_X(x) = \frac{1}{b\pi}\,\frac{1}{1 + \left(\dfrac{x-a}{b}\right)^2}.$$

Anche qui $\mathrm{supp}[f_X(x)] = \mathbb{R}$. La densità è una campana simmetrica attorno ad a, che è quindi il *parametro di posizione*; b ne regola la larghezza (a distanza b dal centro la densità è scesa a metà del massimo). Per calcolare la CDF servono due strumenti: il cambio di variabile e l'arcotangente.

Richiamo di matematica: la regola della catena e il cambio di variabile

La derivata di una funzione composta. Se $y = g(x)$ e poi $z = f(y)$, la funzione composta è $z = f(g(x))$. Quando x cresce di un poco h, y cresce di circa $g'(x)\,h$; e quando y cresce di $g'(x)\,h$, z cresce di circa $f'(y)\cdot g'(x)\,h$. Le pendenze si moltiplicano:

$$\frac{\mathrm{d}}{\mathrm{d}x} f(g(x)) = f'(g(x))\, g'(x).$$

È la **regola della catena**. Esempi: $\big((1+x^2)^3\big)' = 3(1+x^2)^2 \cdot 2x$; $\big(e^{-x^2/2}\big)' = e^{-x^2/2}\cdot(-x)$.

Il cambio di variabile negli integrali. Leggendo la regola della catena al contrario: se G è una primitiva di f, allora $G(g(x))$ ha derivata $f(g(x))\,g'(x)$, quindi

$$\int_a^b f(g(x))\,g'(x)\,\mathrm{d}x = \int_{g(a)}^{g(b)} f(u)\,\mathrm{d}u.$$

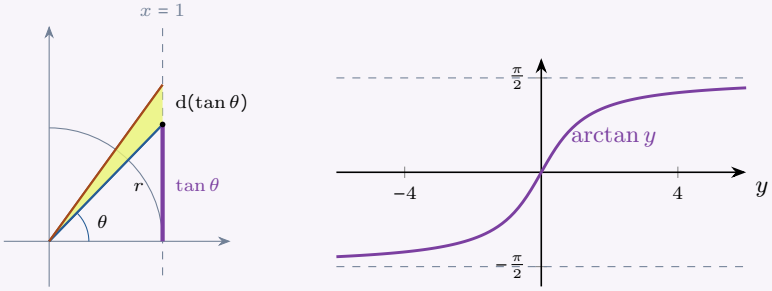
In pratica si pone $u = g(x)$, si sostituisce $\mathrm{d}u = g'(x)\,\mathrm{d}x$ e si cambiano gli estremi. Il caso che ci serve è quello lineare, $u = \frac{t-a}{b}$, con $\mathrm{d}u = \frac{\mathrm{d}t}{b}$, cioè $\mathrm{d}t = b\,\mathrm{d}u$:

$$\int_{-\infty}^{x} \phi\left(\frac{t-a}{b}\right)\mathrm{d}t = b\int_{-\infty}^{\frac{x-a}{b}} \phi(u)\,\mathrm{d}u.$$

Ha un significato geometrico semplice: spostare un grafico non cambia l'area, allargarlo di un fattore b in orizzontale la moltiplica per b.

Richiamo di matematica: l'arcotangente

La **tangente** di un angolo θ (in radianti) è $\tan\theta = \frac{\sin\theta}{\cos\theta}$. Sulla circonferenza di raggio 1, è l'altezza a cui la semiretta inclinata di θ incontra la retta verticale $x = 1$. Quando θ va da $-\frac{\pi}{2}$ a $\frac{\pi}{2}$ (da -90° a 90°, esclusi), la tangente assume una e una sola volta ogni valore reale, da $-\infty$ a $+\infty$. Si può quindi invertire: l'**arcotangente** $\arctan y$ è l'angolo, compreso fra $-\frac{\pi}{2}$ e $\frac{\pi}{2}$, la cui tangente vale y. Per esempio $\arctan 0 = 0$, $\arctan 1 = \frac{\pi}{4}$, e $\arctan y \to \pm\frac{\pi}{2}$ per $y \to \pm\infty$.



La sua derivata è $\frac{1}{1+y^2}$. Nel disegno a sinistra, la semiretta inclinata di θ incontra la retta $x = 1$ a distanza $r = \frac{1}{\cos\theta}$ dall'origine, cioè $r^2 = 1 + \tan^2\theta$ (per Pitagora). Ruotando la semiretta di un angolo piccolo $\mathrm{d}\theta$, il punto d'incontro sale di $\mathrm{d}(\tan\theta)$. L'arco percorso a distanza r è lungo $r\,\mathrm{d}\theta$ ed è perpendicolare alla semiretta; la retta verticale forma con esso l'angolo θ, quindi il tratto verticale è più lungo: $\mathrm{d}(\tan\theta) = \frac{r\,\mathrm{d}\theta}{\cos\theta} = r^2\,\mathrm{d}\theta = (1+\tan^2\theta)\,\mathrm{d}\theta$. Posto $y = \tan\theta$, cioè $\theta = \arctan y$:

$$\frac{\mathrm{d}\theta}{\mathrm{d}y} = \frac{1}{1+y^2} \qquad\Longrightarrow\qquad (\arctan y)' = \frac{1}{1+y^2}.$$

Quindi arctan è una primitiva di $\frac{1}{1+y^2}$, che è proprio la forma della densità di Cauchy.

Teorema 11.6 — CDF della variabile di Cauchy

Se $X \sim \mathcal{C}(a,b)$: $\qquad F_X(x) = \frac{1}{2} + \frac{1}{\pi}\arctan\left(\frac{x-a}{b}\right)$.

Dimostrazione

Passo 1 — Il cambio di variabile. Con $u = \frac{t-a}{b}$ si ha $\mathrm{d}t = b\,\mathrm{d}u$, e l'estremo $t = x$ diventa $u = \frac{x-a}{b}$:

$$F_X(x) = \frac{1}{b\pi}\int_{-\infty}^{x} \frac{1}{1+\left(\frac{t-a}{b}\right)^2}\,\mathrm{d}t = \frac{1}{b\pi}\int_{-\infty}^{\frac{x-a}{b}} \frac{1}{1+u^2}\,b\,\mathrm{d}u = \frac{1}{\pi}\int_{-\infty}^{\frac{x-a}{b}} \frac{1}{1+u^2}\,\mathrm{d}u.$$

Passo 2 — L'arcotangente. La primitiva è $\arctan u$, e $\arctan(-\infty) = -\frac{\pi}{2}$:

$$F_X(x) = \frac{1}{\pi}\left[\arctan\left(\frac{x-a}{b}\right) - \arctan(-\infty)\right] = \frac{1}{\pi}\left[\arctan\left(\frac{x-a}{b}\right) + \frac{\pi}{2}\right] = \frac{1}{2} + \frac{1}{\pi}\arctan\left(\frac{x-a}{b}\right).$$

Passo 3 — Una verifica. Per $x \to +\infty$, $\arctan \to \frac{\pi}{2}$ e $F_X \to \frac{1}{2} + \frac{1}{2} = 1$: l'area totale è 1, quindi f_X è davvero una densità.

■

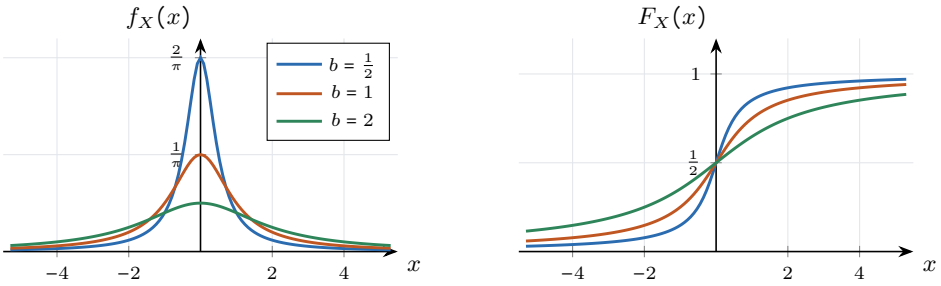


Figura 11.4: *Densità e CDF di Cauchy con $a = 0$. Le code scendono come $\frac{1}{x^2}$, molto più lentamente di un esponenziale: valori lontanissimi dal centro sono rari, ma non abbastanza rari.*

La variabile di Cauchy non ha media

La densità è simmetrica attorno ad a, e verrebbe da dire che la media è a. Invece la media **non è definita**, perché la funzione $x\,f_X(x)$ non è integrabile. Per vederlo serve una funzione che crescesse senza limite, ma molto lentamente.

Richiamo di matematica: il logaritmo

Il **logaritmo naturale** $\ln x$ (per $x > 0$) è l'inversa dell'esponenziale: $\ln x$ è il numero y tale che $e^y = x$. Quindi $\ln 1 = 0$, $\ln e = 1$, $\ln(e^{10}) = 10$, e trasforma i prodotti in somme: $\ln(xy) = \ln x + \ln y$, $\ln \frac{x}{y} = \ln x - \ln y$ (perché $e^a e^b = e^{a+b}$). Cresce senza limite, ma lentissimamente: per arrivare a 10 serve $x = e^{10} \approx 22\,026$.
La sua derivata è $\frac{1}{x}$. Se $y = \ln x$, allora $x = e^y$. Quando y cresce di $\mathrm{d}y$, x cresce di $e^y\,\mathrm{d}y = x\,\mathrm{d}y$; quindi $\frac{\mathrm{d}y}{\mathrm{d}x} = \frac{1}{x}$. Ecco la primitiva che mancava alla tabella del Capitolo 10, il caso $n = -1$: $\int_1^H \frac{1}{x}\,\mathrm{d}x = \ln H$, che tende a infinito. L'area sotto $\frac{1}{x}$ è infinita, mentre quella sotto $\frac{1}{x^2}$ è finita.
Con la regola della catena: $\frac{\mathrm{d}}{\mathrm{d}x}\ln(1+x^2) = \frac{2x}{1+x^2}$.

Teorema 11.7 — La variabile di Cauchy non ha media

Se $X \sim \mathcal{C}(a,b)$, l'integrale $\int_{-\infty}^{\infty} x\,f_X(x)\,\mathrm{d}x$ non esiste: le sue due metà valgono $+\infty$ e $-\infty$.

Dimostrazione — con $a = 0$ e $b = 1$

Passo 1 — La metà destra. Con la primitiva del richiamo:

$$\int_0^H x\,\frac{1}{\pi}\,\frac{1}{1+x^2}\,\mathrm{d}x = \frac{1}{\pi}\left[\frac{1}{2}\ln(1+x^2)\right]_0^H = \frac{1}{2\pi}\ln(1+H^2) \longrightarrow +\infty \qquad (H \to \infty).$$

Passo 2 — La metà sinistra. Per simmetria vale $-\infty$.

Passo 3 — Conclusione. Le due metà non sono finite, e «$+\infty - \infty$» non è un numero. Il motivo è che per x grande $x\,f_X(x) \simeq \frac{1}{\pi x}$, che ha area infinita come $\frac{1}{x}$. Per a e b qualsiasi, il cambio di variabile $u = \frac{x-a}{b}$ riporta a questo caso. ■

Si può però definire un **punto di simmetria**, con un **integrale a valor principale**: invece di mandare a infinito i due estremi in modo indipendente, li si allarga *insieme*, simmetricamente.

Teorema 11.8 — Il valor principale

Se $X \sim \mathcal{C}(a, b)$:

$$\frac{1}{b\pi}\lim_{H\to\infty}\int_{-H}^{H}\frac{x}{1+\left(\frac{x-a}{b}\right)^2}\,\mathrm{d}x = a.$$

Dimostrazione

Passo 1 — Il cambio di variabile. Con $u = \frac{x-a}{b}$, cioè $x = ub + a$ e $\mathrm{d}x = b\,\mathrm{d}u$; gli estremi $\mp H$ diventano $\frac{\mp H - a}{b}$:

$$\frac{1}{b\pi}\lim_{H\to\infty}\int_{\frac{-H-a}{b}}^{\frac{H-a}{b}}\frac{ub+a}{1+u^2}\,b\,\mathrm{d}u = \frac{b}{\pi}\lim_{H\to\infty}\int_{\frac{-H-a}{b}}^{\frac{H-a}{b}}\frac{u}{1+u^2}\,\mathrm{d}u + \frac{a}{\pi}\lim_{H\to\infty}\int_{\frac{-H-a}{b}}^{\frac{H-a}{b}}\frac{1}{1+u^2}\,\mathrm{d}u.$$

Passo 2 — Il primo limite è zero. Con la primitiva $\frac{1}{2}\ln(1+u^2)$ e la proprietà dei logaritmi:

$$\int_{\frac{-H-a}{b}}^{\frac{H-a}{b}}\frac{u}{1+u^2}\,\mathrm{d}u = \frac{1}{2}\ln\frac{1+\left(\frac{H-a}{b}\right)^2}{1+\left(\frac{H+a}{b}\right)^2} \longrightarrow \frac{1}{2}\ln 1 = 0,$$

perché per H grandissimo numeratore e denominatore della frazione sono quasi uguali (entrambi circa $\frac{H^2}{b^2}$), e il loro rapporto tende a 1.

Passo 3 — Il secondo limite. Gli estremi tendono a $-\infty$ e $+\infty$, e l'integrale diventa $\int_{-\infty}^{\infty}\frac{1}{1+u^2}\,\mathrm{d}u = \left[\arctan u\right]_{-\infty}^{\infty} = \pi$. Quindi il totale è $0 + \frac{a}{\pi}\cdot\pi = a$. ■

Che cosa vuol dire, in pratica, «non ha media»

Per una variabile con media, la media campionaria di tante osservazioni si stabilizza attorno alla media statistica (Capitolo 5). Per la Cauchy questo non succede: ogni tanto esce un valore così enorme da spostare da solo la media di migliaia di osservazioni. La figura confronta la media campionaria di osservazioni di Laplace e di Cauchy, entrambe simmetriche attorno a 0.

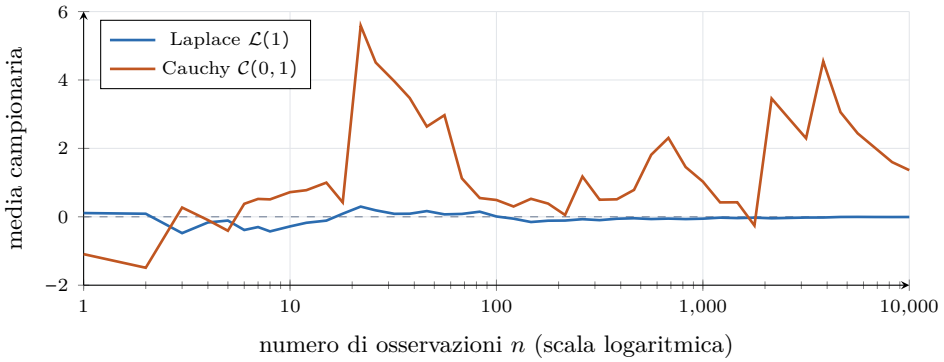


Figura 11.5: *Media campionaria di osservazioni simulate. Quella di Laplace converge a 0; quella di Cauchy continua a fare salti improvvisi anche dopo migliaia di osservazioni, ognuno causato da un singolo valore enorme.*

Variabile	**Densità**	**CDF**	**Supporto**	**Media**
uniforme $\mathcal{U}(a,b)$	$\frac{1}{b-a}$ su (a,b)	$\frac{x-a}{b-a}$ su $[a,b]$	$[a,b]$	$\frac{a+b}{2}$
esponenziale $\mathcal{E}(\lambda)$	$\lambda e^{-\lambda x}u(x)$	$(1-e^{-\lambda x})u(x)$	$[0,\infty)$	$\frac{1}{\lambda}$
Laplace $\mathcal{L}(\lambda)$	$\frac{\lambda}{2}e^{-\lambda\lvert x\rvert}$	$\frac{1}{2}e^{\lambda x}$ $(x\le 0)$, $1-\frac{1}{2}e^{-\lambda x}$ $(x\ge 0)$	$\mathbb{R}$	0
Cauchy $\mathcal{C}(a,b)$	$\frac{1}{b\pi}\frac{1}{1+((x-a)/b)^2}$	$\frac{1}{2}+\frac{1}{\pi}\arctan\frac{x-a}{b}$	$\mathbb{R}$	non esiste

Tabella 11.1: *Le variabili continue notevoli di questo capitolo (le varianze sono nel Capitolo 13).*

In sintesi

- **Uniforme** $\mathcal{U}(a,b)$: densità costante $\frac{1}{b-a}$, CDF lineare, media $\frac{a+b}{2}$.
- **Esponenziale** $\mathcal{E}(\lambda)$: $\lambda e^{-\lambda x}u(x)$, CDF $1-e^{-\lambda x}$, media $\frac{1}{\lambda}$ (per parti); non ha memoria: è il modello dei tempi di attesa.
- **Laplace** $\mathcal{L}(\lambda)$: $\frac{\lambda}{2}e^{-\lambda|x|}$, due esponenziali simmetrici; media 0 perché $xf_X(x)$ è dispari e le due metà sono finite.
- **Cauchy** $\mathcal{C}(a,b)$: CDF $\frac{1}{2}+\frac{1}{\pi}\arctan\frac{x-a}{b}$ (cambio di variabile e arcotangente). Non ha media: $xf_X(x)\sim\frac{1}{\pi x}$ e $\int\frac{1}{x}=\ln$ diverge; il valor principale vale a.
- Strumenti: $(e^{ax})'=ae^{ax}$, integrazione per parti, regola della catena e cambio di variabile, $(\arctan y)'=\frac{1}{1+y^2}$, $(\ln x)'=\frac{1}{x}$, integrali di funzioni dispari.

PDF CONDIZIONATE E FUNZIONI DI VARIABILI CONTINUE

Questo capitolo porta nel continuo due strumenti che conosciamo già dal discreto (Capitolo 6). Il primo è il **condizionamento**: come cambia la densità di X quando si sa che si è verificato un evento. Il secondo sono le **funzioni di variabili aleatorie**: se X ha una certa densità, che densità ha $Y = g(X)$? La risposta è una formula che nel discreto non c'era, perché trasformare una variabile continua non sposta soltanto la probabilità, ma la *stira* e la *comprime*. Vedremo anche due applicazioni importantissime: come un computer genera numeri casuali con qualsiasi densità, e come un convertitore analogico-digitale trasforma una variabile continua in una discreta.

PDF E CDF CONDIZIONATE A UN EVENTO

In modo del tutto analogo a quanto fatto per le variabili discrete, se A è un evento con $P(A) > 0$ possiamo considerare la probabilità che X cada in un intervallino attorno a x *sapendo* che si è verificato A:

$$P\left(X \in \left[x - \tfrac{\Delta x}{2}, x + \tfrac{\Delta x}{2}\right] \,\middle|\, A\right) = P_X(x, \Delta x \mid A).$$

PDF e CDF condizionate

La **densità di X condizionata all'evento A** è

$$f_{X|A}(x) = \lim_{\Delta x \to 0} \frac{P_X(x, \Delta x \mid A)}{\Delta x}.$$

La **CDF condizionata** è

$$F_{X|A}(x) = P(X \le x \mid A) = \frac{P(\{X \le x\} \cap A)}{P(A)}, \qquad \text{e} \qquad f_{X|A}(x) = \frac{\mathrm{d}}{\mathrm{d}x} F_{X|A}(x).$$

Siccome la probabilità condizionata è a sua volta una probabilità (Teorema 4.6), $f_{X|A}$ è una densità a tutti gli effetti: non negativa e con area 1. Il caso più frequente è quello in cui A dice che X è caduta in un certo intervallo.

Esempio 12.1 — Una Laplace ristretta a un intervallo

Sia $X \sim \mathcal{L}(\lambda)$ e sia $A = \{-1 \le X \le 2\}$. Allora

$$F_{X|A}(x) = P(X \le x \mid A) = \frac{P(\{X \le x\} \cap \{-1 \le X \le 2\})}{P(-1 \le X \le 2)},$$

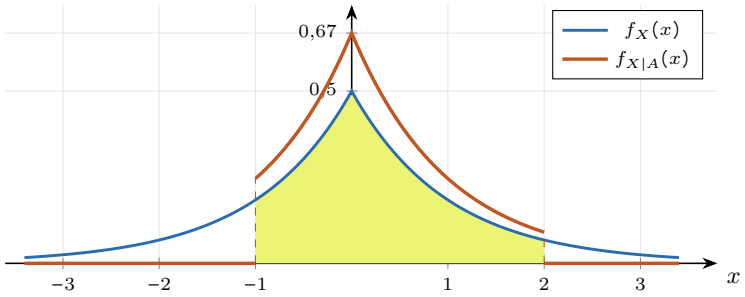
e il denominatore è $P(A) = F_X(2) - F_X(-1)$. Per il numeratore si guarda dove si trova x:

- se $x < -1$, i due eventi sono incompatibili (non si può essere sotto -1 e fra -1 e 2): l'intersezione è vuota;
- se $-1 \le x < 2$, l'intersezione è $\{-1 \le X \le x\}$, con probabilità $F_X(x) - F_X(-1)$;
- se $x \ge 2$, l'intersezione è tutto A.

Quindi

$$F_{X|A}(x) = \begin{cases} 0 & x < -1 \\ \dfrac{F_X(x) - F_X(-1)}{F_X(2) - F_X(-1)} & -1 \le x < 2 \\ \dfrac{F_X(2) - F_X(-1)}{F_X(2) - F_X(-1)} = 1 & x \ge 2 \end{cases} \qquad f_{X|A}(x) = \begin{cases} \dfrac{f_X(x)}{F_X(2) - F_X(-1)} & -1 \le x < 2 \\ 0 & \text{altrove} \end{cases}$$

La densità condizionata si ottiene derivando: il denominatore è una costante. Con $\lambda = 1$: $F_X(2) = 1 - \frac{1}{2}e^{-2} \approx 0{,}932$, $F_X(-1) = \frac{1}{2}e^{-1} \approx 0{,}184$, e $P(A) \approx 0{,}748$.



L'area gialla vale $P(A) \approx 0{,}748$. La densità condizionata (in arancione) è la stessa curva, tagliata fuori dall'intervallo e «rialzata» dividendola per 0,748: così la sua area torna a essere 1. È esattamente quello che succedeva con le pmf nel Capitolo 6.

La probabilità totale per le densità

Teorema 12.1 — Probabilità totale per le PDF e per le medie

Se $\{E_m\}_{m=1}^{M}$ è una partizione di Ω con $P(E_m) > 0$, allora

$$F_X(x) = \sum_{m=1}^{M} F_{X|E_m}(x)\, P(E_m), \qquad f_X(x) = \sum_{m=1}^{M} f_{X|E_m}(x)\, P(E_m),$$

$$E[X] = \sum_{m=1}^{M} E[X \mid E_m]\, P(E_m) = \sum_{m=1}^{M} P(E_m) \int_{-\infty}^{\infty} x\, f_{X|E_m}(x)\, \mathrm{d}x.$$

Dimostrazione

Passo 1 — La CDF. Come nel Capitolo 3, si ritaglia l'evento con la partizione:

$$F_X(x) = P(\{X \le x\} \cap \Omega) = P\left(\{X \le x\} \cap \bigcup_{m=1}^{M} E_m\right) = P\left(\bigcup_{m=1}^{M} (\{X \le x\} \cap E_m)\right),$$

e i pezzi sono incompatibili, quindi le probabilità si sommano:

$$F_X(x) = \sum_{m=1}^{M} P(\{X \le x\} \cap E_m) = \sum_{m=1}^{M} F_{X|E_m}(x)\, P(E_m).$$

Passo 2 — La densità. Si deriva rispetto a x: la derivata di una somma è la somma delle derivate, e i $P(E_m)$ sono costanti.

Passo 3 — La media. Si moltiplica la densità per x e si integra: per la linearità dell'integrale

$$E[X] = \int x \sum_m f_{X|E_m}(x)\, P(E_m)\, \mathrm{d}x = \sum_m P(E_m) \int x\, f_{X|E_m}(x)\, \mathrm{d}x = \sum_m P(E_m)\, E[X \mid E_m].$$

■

Esempio 12.2 — La Laplace spezzata in due

Con riferimento all'esempio precedente ($\lambda = 1$), gli eventi A e $\overline{A}$ formano una partizione:

$$E[X] = E[X \mid A]\, P(A) + E[X \mid \overline{A}]\, P(\overline{A}).$$

Ogni pezzo ha un significato semplice: $E[X \mid A]\, P(A) = \frac{1}{P(A)} \int_{-1}^{2} x\, f_X(x)\, \mathrm{d}x \cdot P(A) = \int_{-1}^{2} x\, f_X(x)\, \mathrm{d}x$, cioè l'integrale di $x f_X(x)$ ristretto ai valori per cui A è vero; e lo stesso per $\overline{A}$, con i valori per cui A è falso. Sommando i due pezzi si integra su tutta la retta, e si ritrova $E[X] = \int x\, f_X(x)\, \mathrm{d}x = 0$.

Con i numeri: usando $\int_0^c x\, e^{-x}\, \mathrm{d}x = 1 - (1 + c)\, e^{-c}$ (per parti),

$$\int_{-1}^{2} x\, \tfrac{1}{2} e^{-|x|}\, \mathrm{d}x = \tfrac{1}{2}\left[\int_0^2 x\, e^{-x}\, \mathrm{d}x - \int_0^1 x\, e^{-x}\, \mathrm{d}x\right] = \tfrac{1}{2}\left[(1 - 3e^{-2}) - (1 - 2e^{-1})\right] \approx 0{,}165,$$

quindi $E[X \mid A] \approx \frac{0{,}165}{0{,}748} \approx 0{,}22$: sapendo che X è fra -1 e 2, la media si sposta verso destra, perché l'intervallo è più lungo da quella parte. Il pezzo di $\overline{A}$ vale $-0{,}165$, e il totale è zero.

Esempio 12.3 — Due tipi di componenti

Un magazzino contiene componenti di due fornitori, in parti uguali. Quelli del primo durano un tempo esponenziale di media 1 anno ($\lambda = 1$), quelli del secondo di media 3 anni ($\lambda = \frac{1}{3}$). Si prende un componente a caso: la sua durata ha densità

$$f_X(x) = \tfrac{1}{2} \cdot 1 \cdot e^{-x} u(x) + \tfrac{1}{2} \cdot \tfrac{1}{3} e^{-x/3} u(x),$$

una «miscela» di due esponenziali, e media $E[X] = \frac{1}{2} \cdot 1 + \frac{1}{2} \cdot 3 = 2$ anni, senza calcolare nessun integrale.

Funzioni di variabili aleatorie continue

Il problema è simile a quello già affrontato per le variabili discrete. Si assuma che $X = X(\omega)$ sia una variabile aleatoria continua con alfabeto $\mathcal{X}$, densità $f_X(x)$ e CDF $F_X(x)$, e sia g una funzione definita sui punti di $\mathcal{X}$ (tranne, al più, un insieme di probabilità nulla). Si forma la nuova variabile aleatoria

$$Y = g(X) = g[X(\omega)] \in \mathcal{Y}, \qquad \mathcal{Y} = g(\mathcal{X}).$$

Vogliamo ricavare la caratterizzazione di Y da quella di X: la densità (o la CDF) e, nel prossimo capitolo, la media. A differenza del caso discreto, qui si distinguono tre casi:

a) g è **biunivoca**, cioè invertibile, continua e derivabile;

b) g non è invertibile, ma è continua e derivabile, e $\mathcal{Y}$ è continuo;

c) g non è invertibile e $\mathcal{Y}$ è **discreto**: è una **conversione A/D** della variabile continua (una quantizzazione, cioè una compressione con perdite), come quella che si fa sui segnali analogici.

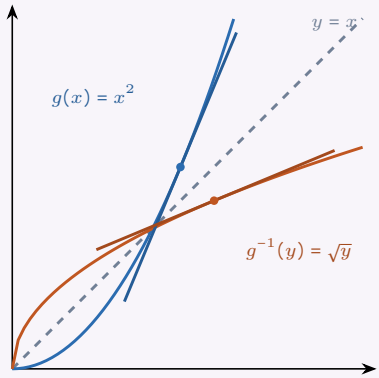
Richiamo di matematica: funzioni monotone e derivata della funzione inversa

Una funzione è **strettamente crescente** se a x più grandi corrispondono valori più grandi, **strettamente decrescente** se corrispondono valori più piccoli; in entrambi i casi si dice **strettamente monotona**. Una funzione continua su un intervallo è invertibile esattamente quando è strettamente monotona: se tornasse indietro, qualche valore verrebbe raggiunto due volte. L'inversa $x = g^{-1}(y)$ risponde alla domanda «quale x dà y?», e il suo grafico è quello di g riflesso rispetto alla bisettrice $y = x$.

Derivata dell'inversa. Per definizione $g\big(g^{-1}(y)\big) = y$. Derivando entrambi i membri rispetto a y con la regola della catena: $\dot{g}\big(g^{-1}(y)\big) \cdot \frac{\mathrm{d}}{\mathrm{d}y} g^{-1}(y) = 1$, cioè

$$\dot{x}(y) = \frac{\mathrm{d}}{\mathrm{d}y}\, g^{-1}(y) = \frac{1}{\dot{g}\big(g^{-1}(y)\big)} :$$

la derivata della funzione inversa in un punto è l'inverso della derivata della funzione originaria, valutata nel punto corrispondente. (Il puntino, $\dot{g}$, è un altro modo di indicare la derivata, usato nelle slide.) Nel disegno: le due tangenti sono una il riflesso dell'altra, e scambiare x con y trasforma la pendenza m in $\frac{1}{m}$.



In $x = 1{,}2$ la parabola ha pendenza $2x = 2{,}4$. Nel punto corrispondente $y = 1{,}44$ la radice ha pendenza $\frac{1}{2\sqrt{y}} = \frac{1}{2{,}4}$. Le pendenze sono una l'inversa dell'altra.

Primo caso: g è invertibile

Se g è invertibile è strettamente monotona su $\mathcal{X}$.

Teorema 12.2 — Densità di una funzione monotona

Se g è strettamente monotona e derivabile, la densità di $Y = g(X)$ è

$$f_Y(y) = \frac{f_X\big(g^{-1}(y)\big)}{\big|\dot{g}\big(g^{-1}(y)\big)\big|} = \frac{f_X\big(x(y)\big)}{\big|\dot{g}\big(x(y)\big)\big|},$$

dove $x(y) = g^{-1}(y)$ è la soluzione dell'equazione $y = g(x)$, che naturalmente dipende da y.

Dimostrazione

Passo 1 — g crescente ($\dot g > 0$): la CDF. Se g è crescente, $g(X) \le y$ succede esattamente quando $X \le g^{-1}(y)$:

$$F_Y(y) = P(Y \le y) = P(g(X) \le y) = P\big(X \le g^{-1}(y)\big) = F_X\big(g^{-1}(y)\big) = F_X\big(x(y)\big).$$

Passo 2 — g crescente: la densità. Si deriva con la regola della catena e la derivata dell'inversa:

$$f_Y(y) = \frac{\mathrm{d}}{\mathrm{d}y} F_Y(y) = f_X\big(g^{-1}(y)\big)\,\frac{\mathrm{d}}{\mathrm{d}y} g^{-1}(y) = \frac{f_X\big(g^{-1}(y)\big)}{\dot g\big(g^{-1}(y)\big)}.$$

Passo 3 — g decrescente ($\dot g < 0$): la CDF. Ora la disuguaglianza si rovescia, perché una funzione decrescente scambia l'ordine: $g(X) \le y$ succede esattamente quando $X \ge g^{-1}(y)$:

$$F_Y(y) = P(g(X) \le y) = P\big(X \ge g^{-1}(y)\big) = 1 - F_X\big(g^{-1}(y)\big).$$

Passo 4 — g decrescente: la densità.

$$f_Y(y) = -f_X\big(g^{-1}(y)\big)\,\frac{\mathrm{d}}{\mathrm{d}y} g^{-1}(y) = -\frac{f_X\big(g^{-1}(y)\big)}{\dot g\big(g^{-1}(y)\big)}.$$

Passo 5 — Una formula sola. Nel secondo caso $\dot g < 0$, quindi $-\dot g = |\dot g|$; nel primo $\dot g = |\dot g|$. In entrambi i casi il denominatore è $|\dot g|$.

■

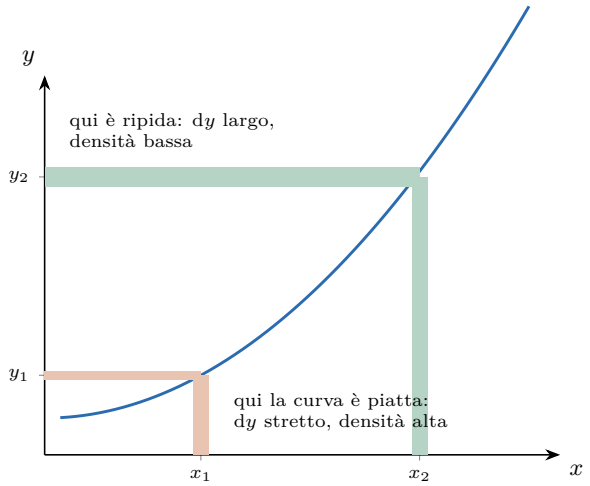


Figura 12.1: *Perché si divide per $|\dot g|$. La probabilità contenuta in una striscia larga $\mathrm{d}x$ attorno a x, cioè $f_X(x)\,\mathrm{d}x$, finisce in una striscia larga $\mathrm{d}y = |\dot g(x)|\,\mathrm{d}x$ attorno a $y = g(x)$. La probabilità si conserva, $f_Y(y)\,\mathrm{d}y = f_X(x)\,\mathrm{d}x$, quindi $f_Y = f_X/|\dot g|$: dove g è ripida la probabilità si «spalma» su un intervallo più largo e la densità si abbassa.*

Esempio 12.4 — Una trasformazione lineare

Sia $Y = aX + b$ con $a \neq 0$. Allora $g(x) = ax + b$, $x(y) = \frac{y-b}{a}$ e $\dot g = a$:

$$f_Y(y) = \frac{1}{|a|}\, f_X\left(\frac{y-b}{a}\right).$$

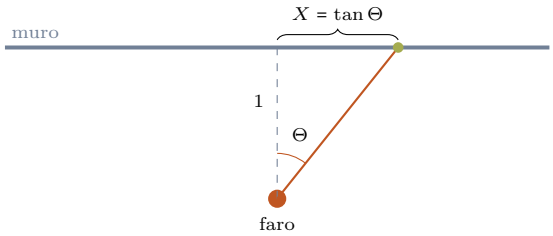
Il grafico di f_Y è quello di f_X spostato di b, allargato di un fattore $|a|$ in orizzontale e abbassato dello stesso fattore, così che l'area resti 1. Per esempio, se $X \sim \mathcal{C}(0,1)$, allora $bX + a \sim \mathcal{C}(a,b)$: i parametri della Cauchy sono proprio una traslazione e un cambio di scala. Useremo questa formula nel Capitolo 15 per costruire tutte le gaussiane a partire da una sola.

Esempio 12.5 — Il faro e la variabile di Cauchy

Un faro ruota e si ferma puntando in una direzione a caso, con un angolo $\Theta \sim \mathcal{U}\left(-\frac{\pi}{2}, \frac{\pi}{2}\right)$ rispetto alla perpendicolare a un muro lungo e diritto che si trova a distanza 1. Il punto illuminato sul muro è $X = \tan\Theta$. La funzione $g(\theta) = \tan\theta$ è crescente su $\left(-\frac{\pi}{2}, \frac{\pi}{2}\right)$, con inversa $\theta(x) = \arctan x$ e derivata $\dot{g} = 1 + \tan^2\theta = 1 + x^2$ (Capitolo 11). La densità di Θ è $\frac{1}{\pi}$ sull'intervallo, quindi

$$f_X(x) = \frac{f_\Theta(\arctan x)}{1 + x^2} = \frac{1}{\pi}\,\frac{1}{1 + x^2}\,:$$

il punto illuminato è una variabile di Cauchy $\mathcal{C}(0, 1)$. Quando il faro punta quasi parallelo al muro, il punto illuminato schizza lontanissimo: sono i valori enormi che impediscono alla Cauchy di avere una media.



Secondo caso: g non è invertibile

Se g non è invertibile, per un valore y l'equazione $g(x) = y$ può avere più soluzioni:

$$\forall y \in \mathcal{Y} \quad \exists\, \{x_i(y)\}_{i=1}^{M(y)} : \quad g[x_i(y)] = y.$$

Per fissare le idee supponiamo $M(y) = 4$, come nella figura, con $\dot{g}(x_1) < 0$. Allora $g(x) \le y$ per $x_1(y) \le x \le x_2(y)$; ovviamente sarà $\dot{g}(x_2) > 0$ e $g(x) \ge y$ per $x_2(y) \le x \le x_3(y)$. La funzione ripassa per il valore $g(x_3) = y$ (con derivata negativa) e si mantiene al di sotto di y fino a $x_4(y)$.

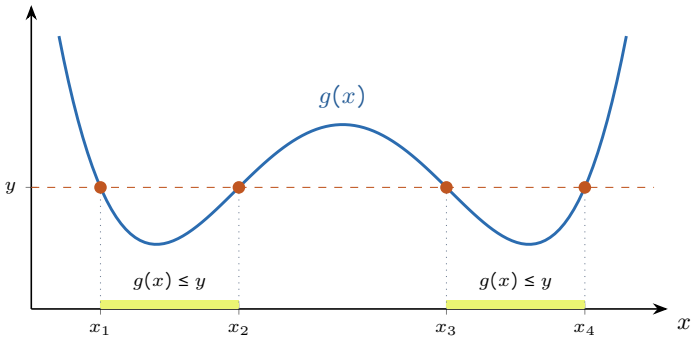


Figura 12.2: *Una funzione non invertibile: il livello y viene raggiunto in quattro punti. L'evento $\{Y \le y\}$ è l'unione dei due intervalli gialli dell'asse x.*

Quindi

$$F_Y(y) = P(Y \le y) = P\big(\{x_1(y) \le X \le x_2(y)\} \cup \{x_3(y) \le X \le x_4(y)\}\big),$$

e sfruttando il fatto che gli intervalli sono disgiunti

$$F_Y(y) = F_X\big(x_2(y)\big) - F_X\big(x_1(y)\big) + F_X\big(x_4(y)\big) - F_X\big(x_3(y)\big).$$

Teorema 12.3 — Densità di una funzione non invertibile

Se $y = g(x)$ ha le soluzioni $x_1(y), \ldots, x_M(y)$, tutte con $\dot{g} \neq 0$:

$$f_Y(y) = \sum_{i=1}^{M(y)} \frac{f_X\big(x_i(y)\big)}{\big|\dot{g}\big(x_i(y)\big)\big|}.$$

Dimostrazione — nel caso della figura

Passo 1 — Si deriva la CDF. Ogni soluzione $x_i(y)$ è, vicino a y, l'inversa del tratto monotono di g che passa per x_i; per la derivata dell'inversa $\dot{x}_i(y) = \frac{1}{\dot{g}(x_i(y))}$. Derivando la CDF termine per termine con la regola della catena:

$$f_Y(y) = \frac{f_X(x_2)}{\dot{g}(x_2)} - \frac{f_X(x_1)}{\dot{g}(x_1)} + \frac{f_X(x_4)}{\dot{g}(x_4)} - \frac{f_X(x_3)}{\dot{g}(x_3)}.$$

Passo 2 — I segni. Nel secondo e nel quarto termine la derivata a denominatore è negativa (g scende in x_1 e in x_3), quindi $-\frac{1}{\dot{g}} = \frac{1}{|\dot{g}|}$; nel primo e nel terzo è positiva. Tutti i termini diventano $\frac{f_X(x_i)}{|\dot{g}(x_i)|}$.

■

Da ricordare: densità di una funzione di variabile aleatoria

$$f_Y(y) = \sum_{i\,:\,g(x_i)=y} \frac{f_X(x_i)}{|\dot{g}(x_i)|} \qquad \text{(si somma su tutte le soluzioni di } y = g(x))$$

È lo stesso principio del discreto, dove le probabilità dei punti con la stessa immagine si sommavano; in più, ogni contributo è diviso per la «velocità» $|\dot{g}|$ con cui g attraversa il livello y.

Esempio 12.6 — Il quadrato di due variabili diverse

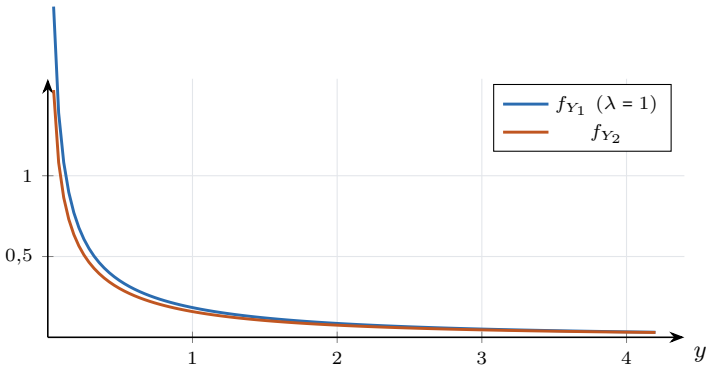
Sia $g(x) = x^2$, e si considerino $X_1 \sim \mathcal{E}(\lambda)$ e $X_2 \sim \mathcal{C}(0,1)$.

Esponenziale. Nel caso $Y_1 = X_1^2$, la variabile X_1 è non negativa ($\mathcal{X}_1 = [0,\infty[$), e su $x \geq 0$ la trasformazione $g(x) = x^2$ è biunivoca: l'equazione $x^2 = y$ ammette solo la soluzione $x(y) = \sqrt{y}$. Quindi

$$\dot{x}(y) = \frac{1}{\dot{g}(x)}\bigg|_{x=\sqrt{y}} = \frac{1}{2x}\bigg|_{x=\sqrt{y}} = \frac{1}{2\sqrt{y}}, \qquad f_{Y_1}(y) = \lambda e^{-\lambda x}u(x)\Big|_{x=\sqrt{y}}\dot{x}(y) = \frac{\lambda e^{-\lambda\sqrt{y}}}{2\sqrt{y}}\,u(y).$$

Cauchy. Nel caso $Y_2 = X_2^2$ invece $\mathcal{X}_2 = \mathbb{R}$, la trasformazione non è biunivoca e per $y > 0$ l'equazione $x^2 = y$ ha due soluzioni, $x_{1,2}(y) = \pm\sqrt{y}$, in cui $|\dot{g}| = 2\sqrt{y}$. Con $f_{X_2}(x) = \frac{1}{\pi}\frac{1}{1+x^2}$, che vale lo stesso in $\pm\sqrt{y}$:

$$f_{Y_2}(y) = \left[\frac{f_{X_2}(\sqrt{y})}{2\sqrt{y}} + \frac{f_{X_2}(-\sqrt{y})}{2\sqrt{y}}\right]u(y) = \frac{1}{\pi}\,\frac{1}{2\sqrt{y}}\,\frac{1}{1+y}\cdot 2\,u(y) = \frac{1}{\pi\sqrt{y}\,(1+y)}\,u(y).$$



Una densità può valere infinito

Entrambe le densità dell'esempio tendono a infinito per $y \to 0$, a causa del fattore $\frac{1}{\sqrt{y}}$: vicino a $x = 0$ la parabola x^2 è piattissima ($\dot{g} = 2x \to 0$), e schiaccia tanta probabilità in un intervallino di y. Non c'è nessuna contraddizione: l'area resta finita, perché $\int_0^1 \frac{1}{\sqrt{y}}\,dy = \left[2\sqrt{y}\right]_0^1 = 2$. Ancora una volta: conta l'area, non l'altezza.

Esempio 12.7 — Ogni variabile, passata nella propria CDF, diventa uniforme

Sia $X \sim f_X(x)$, e consideriamo $Y = F_X(X)$, cioè $g(x) = F_X(x)$. Qualunque sia la densità, $Y \in [0,1]$, perché la CDF assume valori fra 0 e 1. Inoltre g è crescente; potrebbe non essere strettamente crescente (avere tratti in cui è costante, dove $f_X = 0$), ma escludiamo questo caso. Allora

$$g(x) = F_X(x) \implies x(y) = F_X^{-1}(y), \qquad \dot{g}(x) = f_X(x),$$

e con la formula del primo caso

$$f_Y(y) = \frac{f_X\big(F_X^{-1}(y)\big)}{f_X\big(F_X^{-1}(y)\big)} = 1, \quad y \in [0,1], \qquad \text{cioè} \quad f_Y(y) = \operatorname{rect}\left(y - \tfrac{1}{2}\right):$$

Y è una variabile aleatoria uniforme in $(0,1)$, $Y \sim \mathcal{U}(0,1)$. Il motivo intuitivo: $F_X(X)$ è «la frazione di probabilità che sta a sinistra del valore osservato», e questa frazione può essere un numero qualsiasi fra 0 e 1 con uguale probabilità.

Il risultato si può usare al contrario, ed è così che si simula al computer una variabile con qualsiasi densità.

Teorema 12.4 — Il metodo dell'inversione

Se $U \sim \mathcal{U}(0,1)$ e F_X è una CDF strettamente crescente, la variabile $Z = F_X^{-1}(U)$ ha CDF F_X.

Dimostrazione

Passo 1. Per ogni z:

$$F_Z(z) = P(Z \le z) = P\big(F_X^{-1}(U) \le z\big) \underset{(a)}{=} P\big(U \le F_X(z)\big) = F_U\big(F_X(z)\big) \underset{(b)}{=} F_X(z).$$

Passo 2 — (a). F_X è per ipotesi strettamente crescente, e quindi lo è anche la sua inversa: applicando F_X ai due membri di $F_X^{-1}(U) \le z$ la disuguaglianza non cambia verso.

Passo 3 — (b). La CDF di una variabile uniforme in $(0,1)$ è la funzione identica nell'intervallo $(0,1)$: $U \sim \mathcal{U}(0,1) \iff f_U(u) = \operatorname{rect}\left(u - \frac{1}{2}\right) \iff F_U(u) = u$ per $0 \le u \le 1$. Quindi $F_U(F_X(z)) = F_X(z)$.

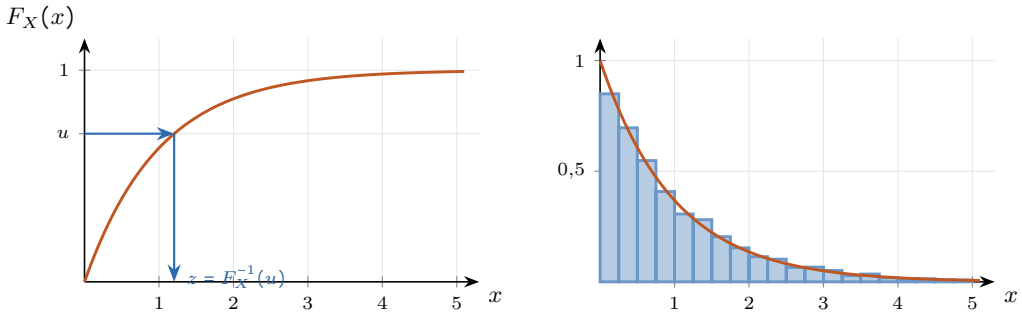
■

I generatori di numeri casuali dei computer producono numeri uniformi in $(0,1)$; con il metodo dell'inversione si trasformano in numeri con la densità voluta. Questo ha notevoli conseguenze nelle procedure di simulazione dei sistemi numerici (tutte le simulazioni di questa dispensa sono state fatte così).

Esempio 12.8 — Generare tempi di attesa esponenziali

Per $X \sim \mathcal{E}(\lambda)$, $F_X(x) = 1 - e^{-\lambda x}$. Risolvendo $u = 1 - e^{-\lambda x}$ rispetto a x: $e^{-\lambda x} = 1 - u$, cioè $x = -\frac{1}{\lambda}\ln(1-u)$. Quindi

$$Z = -\frac{1}{\lambda}\ln(1-U) \sim \mathcal{E}(\lambda).$$



A sinistra: si estrae u uniforme sull'asse verticale, si va orizzontalmente fino alla CDF e si scende: il punto d'arrivo è z. A destra: l'istogramma di 5000 numeri ottenuti così (con $\lambda = 1$) segue la densità esponenziale. Dove la CDF è ripida (vicino a 0) molti valori di u finiscono in un intervallo stretto di x: lì la densità è alta.

Esempio 12.9 — La sinusoide con fase a caso

Siano $X \sim \mathcal{U}\left(-\frac{1}{2}, \frac{1}{2}\right)$ e $g(x) = A\cos(2\pi x + \varphi)$, con $A > 0$. Cerchiamo la densità di $Y = A\cos(2\pi X + \varphi)$: il valore di una sinusoide osservata in un istante a caso.

Si noti che $\mathcal{Y} = [-A, A]$ (il coseno sta fra -1 e 1) e che la trasformazione non è biunivoca. Poiché $\mathcal{X} = \left[-\frac{1}{2}, \frac{1}{2}\right]$, l'argomento del coseno varia in un intervallo di ampiezza 2π, un periodo intero, e in questo intervallo l'equazione $y = A\cos(2\pi x + \varphi)$ ha due soluzioni x_1, x_2 (una mentre il coseno scende e una mentre sale). Quindi

$$f_Y(y) = \frac{f_X(x_1(y))}{|\dot{g}(x_1(y))|} + \frac{f_X(x_2(y))}{|\dot{g}(x_2(y))|} \underset{(a)}{=} \frac{1}{|\dot{g}(x_1(y))|} + \frac{1}{|\dot{g}(x_2(y))|},$$

dove (a) vale perché $f_X = 1$ sull'intervallo. La derivata del coseno è meno il seno (con la regola della catena il fattore 2π esce dall'argomento):

$$\dot{g}(x) = -A\sin(2\pi x + \varphi)\cdot 2\pi, \qquad |\dot{g}(x)| = 2\pi A|\sin(2\pi x + \varphi)|.$$

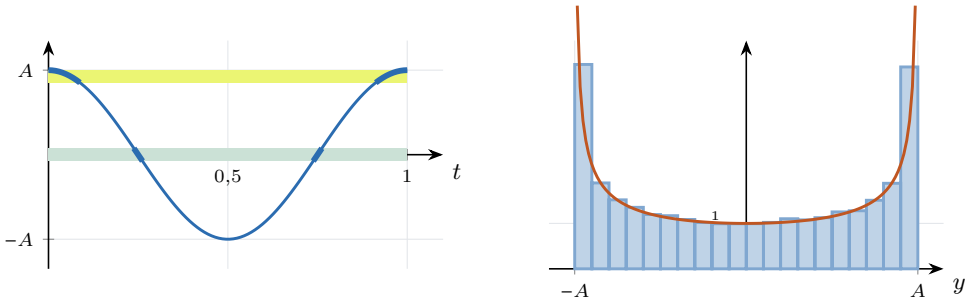
Va scritta in funzione di y: per Pitagora $\sin^2\alpha + \cos^2\alpha = 1$ (seno e coseno sono i cateti di un triangolo rettangolo con ipotenusa 1), quindi $|\sin\alpha| = \sqrt{1-\cos^2\alpha}$, e $\cos(2\pi x + \varphi) = \frac{y}{A}$ nei punti $x_i(y)$:

$$|\dot{g}(x_i(y))| = 2\pi A\sqrt{1-\cos^2(2\pi x_i + \varphi)} = 2\pi A\sqrt{1-\left(\frac{y}{A}\right)^2}.$$

I due termini sono uguali, e

$$f_Y(y) = \frac{2}{2\pi A\sqrt{1-\left(\frac{y}{A}\right)^2}} = \frac{1}{\pi A\sqrt{1-\left(\frac{y}{A}\right)^2}} = \frac{1}{\pi\sqrt{A^2-y^2}}, \qquad y \in (-A, A).$$

È la **distribuzione dell'arcoseno**, a forma di «U»: la sinusoide passa più tempo vicino ai massimi e ai minimi, dove rallenta per invertire il moto, che vicino allo zero, dove corre.



A sinistra: in un periodo, la sinusoide resta nella fascia gialla vicino al massimo (le parti spesse a sinistra e a destra) molto più a lungo che nella fascia verde, alta uguale, attorno allo zero (le due parti spesse in mezzo). A destra: l'istogramma di 20 000 valori simulati con $A = 1$ e la densità dell'arcoseno.

Terzo caso: la conversione A/D

Quando X è continua e Y è discreta si ha una **conversione analogico-digitale** (A/D) della variabile aleatoria. Supponiamo di voler rappresentare X (con perdite) con R bit, cioè con $M = 2^R$ livelli.

- Si scelgono gli M valori di rappresentazione $\mathcal{Y} = \{y_1, y_2, \ldots, y_M\}$, i valori che Y può assumere.
- Si divide l'alfabeto $\mathcal{X}$ in M intervalli, definiti dalle $M+1$ soglie $\{x_i\}_{i=1}^{M+1}$.

Rappresentazione a R bit

Si definisce **rappresentazione a R bit** di X la variabile aleatoria discreta

$$Y = y_i \qquad \text{se} \quad x_i \le X < x_{i+1}, \qquad i = 1, 2, \ldots, M.$$

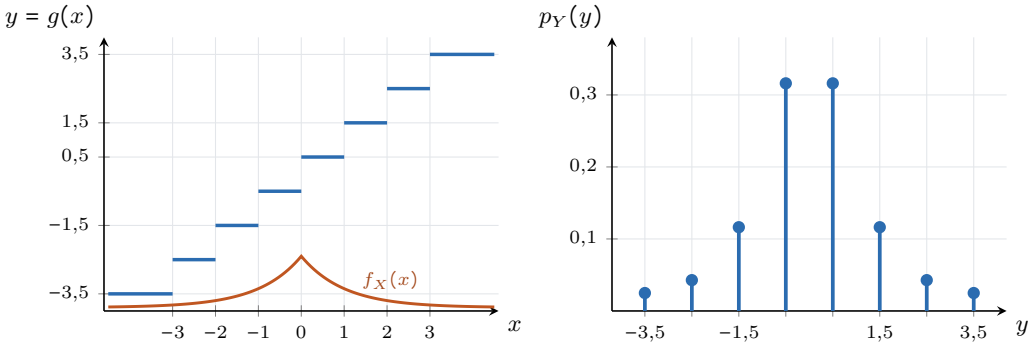
La pmf di Y si scrive facilmente: Y vale y_i quando X cade nell'i-esimo intervallo, quindi

$$p_Y(y_i) = P(x_i \le X < x_{i+1}) = F_X(x_{i+1}) - F_X(x_i), \qquad i = 1, 2, \ldots, M.$$

Ovviamente tanto la partizione quanto i livelli di rappresentazione sono gradi di libertà a disposizione del progettista: scegliendoli bene si riduce l'errore commesso rappresentando X con Y.

Esempio 12.10 — Un convertitore a 3 bit

I campioni di un segnale vocale si modellano bene con una variabile di Laplace (valori piccoli frequentissimi, valori grandi rari). Sia $X \sim \mathcal{L}(1)$, quantizzata con $R = 3$ bit, cioè $M = 8$ livelli: soglie $-\infty, -3, -2, -1, 0, 1, 2, 3, +\infty$ e livelli $-3{,}5$; $-2{,}5$; …; $3{,}5$ (il centro di ogni intervallo, e per i due intervalli estremi il punto a distanza $\frac{1}{2}$ dall'ultima soglia).



A sinistra la caratteristica «a scalini» del convertitore (in basso, per riferimento, la densità di X); a destra la pmf di Y. Per esempio

$$p_Y(0{,}5) = F_X(1) - F_X(0) = \left(1 - \tfrac{1}{2}e^{-1}\right) - \tfrac{1}{2} \approx 0{,}316, \qquad p_Y(3{,}5) = F_X(+\infty) - F_X(3) = \tfrac{1}{2}e^{-3} \approx 0{,}025.$$

Più del 63% delle volte il convertitore usa uno dei due livelli centrali, e solo il 5% delle volte uno dei due estremi. Nella parte del corso sull'informazione vedremo che questa disuguaglianza si può sfruttare per comprimere i dati.

In sintesi

- **Condizionamento**: $F_{X|A}(x) = P(\{X \le x\} \cap A)/P(A)$ e $f_{X|A} = F'_{X|A}$; se A è un intervallo, la densità viene tagliata e rialzata dividendo per $P(A)$.
- **Probabilità totale**: $f_X = \sum_m f_{X|E_m} P(E_m)$ e $E[X] = \sum_m E[X \mid E_m] P(E_m)$.
- Se $Y = g(X)$: $f_Y(y) = \sum_i \frac{f_X(x_i)}{|\dot{g}(x_i)|}$, sommando sulle soluzioni di $g(x) = y$. La probabilità si conserva, $f_Y \mathrm{d}y = f_X \mathrm{d}x$: dove g è ripida la densità si abbassa. Lineare: $f_{aX+b}(y) = f_X\left(\frac{y-b}{a}\right)/|a|$.
- $F_X(X) \sim \mathcal{U}(0,1)$, e viceversa $F_X^{-1}(U)$ ha CDF F_X: è il metodo dell'inversione per simulare qualsiasi densità.
- $A\cos(2\pi X + \varphi)$ con X uniforme su un periodo ha la densità dell'arcoseno $\frac{1}{\pi\sqrt{A^2 - y^2}}$.
- **Conversione A/D** a R bit: $M = 2^R$ livelli, $p_Y(y_i) = F_X(x_{i+1}) - F_X(x_i)$.

Media di funzioni e varianza nel continuo

Nel Capitolo 7 avevamo misurato la dispersione delle variabili discrete con il valore quadratico medio e la varianza, e per calcolarli ci era servito il teorema fondamentale per la media di una funzione, $E[g(X)] = \sum_x g(x)\, p_X(x)$. In questo capitolo portiamo tutto nel continuo: prima il teorema fondamentale, con le somme che diventano integrali; poi il valore quadratico medio e la varianza delle variabili continue notevoli. Alla fine raccogliamo in un «dizionario» le corrispondenze fra il mondo discreto e quello continuo.

La media di una funzione di variabile continua

Sia $X \sim f_X(x)$ e sia $Y = g(X)$, con $\mathcal{Y} = g(\mathcal{X})$. Per calcolare $E[Y]$ si potrebbe ricavare la densità f_Y con i metodi del capitolo precedente e poi integrare $y\, f_Y(y)$. Ma, come nel discreto, non serve.

Teorema 13.1 — Teorema fondamentale per il calcolo della media

Qualunque sia la funzione g (purché l'integrale converga):

$$E[Y] = E[g(X)] = \int_{\mathbb{R}} g(x)\, f_X(x)\, \mathrm{d}x.$$

Dimostrazione — con la quantizzazione

Passo 1 — Si quantizza X. Come per giustificare la media (Capitolo 10), si definisce una versione quantizzata di X:

$$X^{\Delta} = x_i \in [i\Delta, (i+1)\Delta[\qquad \text{se} \quad i\Delta \le X < (i+1)\Delta.$$

Passo 2 — Si applica g. La variabile $Y^{\Delta} = g(X^{\Delta})$ è discreta: vale $g(x_i)$ quando X cade nell'i-esimo intervallo. Per il teorema fondamentale del caso discreto (Teorema 6.4):

$$E[Y^{\Delta}] = \sum_i g(x_i)\, P(X^{\Delta} = x_i) = \sum_i g(x_i)\, P(x_i \le X < x_{i+1}).$$

Passo 3 — Si stringono gli intervalli. Per Δ piccolo $P(x_i \le X < x_{i+1}) \simeq f_X(x_i)\,\Delta$, e Y^{Δ} si avvicina a Y. Se $g(x) f_X(x)$ è integrabile secondo Riemann, la somma diventa un integrale:

$$E[Y] = \lim_{\Delta \to 0} E[Y^{\Delta}] = \lim_{\Delta \to 0} \sum_i g(x_i) \underbrace{f_X(x_i)\,\Delta}_{\simeq P(x_i \le X < x_{i+1})} = \int_{\mathbb{R}} g(x)\, f_X(x)\, \mathrm{d}x.$$

■

Esempio 13.1 — Due strade per la stessa media

Sia $X \sim \mathcal{U}(0,1)$ e $Y = X^2$.

- **Con il teorema fondamentale**: $E[Y] = \int_0^1 x^2 \cdot 1 \, dx = \left[\frac{x^3}{3}\right]_0^1 = \frac{1}{3}$.
- **Passando per la densità di** Y: su $(0,1)$ la funzione x^2 è crescente, con $x(y) = \sqrt{y}$ e $\dot{g}(x(y)) = 2\sqrt{y}$; quindi $f_Y(y) = \frac{1}{2\sqrt{y}}$ per $0 < y < 1$, e
$$E[Y] = \int_0^1 y \, \frac{1}{2\sqrt{y}} \, dy = \int_0^1 \frac{\sqrt{y}}{2} \, dy = \frac{1}{2}\left[\frac{y^{3/2}}{3/2}\right]_0^1 = \frac{1}{2} \cdot \frac{2}{3} = \frac{1}{3}.$$

Stesso risultato, ma la prima strada è molto più breve. (Si è usata la regola delle potenze anche con l'esponente non intero $\frac{1}{2}$: la formula $(x^n)' = n\,x^{n-1}$ vale per qualsiasi esponente reale.)

Dal teorema e dalla linearità dell'integrale seguono subito le proprietà della media già viste nel discreto:
$$E[aX + b] = \int (ax + b)\, f_X(x)\, dx = a \int x\, f_X(x)\, dx + b \int f_X(x)\, dx = a\, E[X] + b,$$
e più in generale $E[g_1(X) + g_2(X)] = E[g_1(X)] + E[g_2(X)]$.

Valore quadratico medio e varianza

A questo punto la generalizzazione dei concetti introdotti per le variabili discrete è immediata. Data una variabile aleatoria $X \sim f_X(x)$, con media $\mu_X = E[X]$, si definiscono:

- il **valore quadratico medio** (*mean square*): $X^2_{rms} = E[X^2] = \int_{\mathbb{R}} x^2 \, f_X(x)\, dx$;
- il **valore efficace** (*root mean square*): $X_{rms} = \sqrt{E[X^2]} = \sqrt{\int_{\mathbb{R}} x^2 \, f_X(x)\, dx}$;
- la **varianza**: $\sigma_X^2 = E\left[(X - \mu_X)^2\right] = \int_{\mathbb{R}} (x - \mu_X)^2 \, f_X(x)\, dx$;
- la **deviazione standard**: $\sigma_X = \sqrt{\sigma_X^2}$.

Teorema 13.2 — Varianza e valore quadratico medio

$$\sigma_X^2 = E[X^2] - \mu_X^2 = X^2_{rms} - \mu_X^2, \qquad \sigma_X = \sqrt{E[X^2] - \mu_X^2}.$$

Dimostrazione

Passo 1. Si sviluppa il quadrato e si usa la linearità della media (le costanti μ_X e μ_X^2 escono):
$$\sigma_X^2 = E\left[X^2 + \mu_X^2 - 2\mu_X X\right] = E[X^2] + \mu_X^2 - 2\mu_X\, E[X] = E[X^2] + \mu_X^2 - 2\mu_X^2 = E[X^2] - \mu_X^2.$$

■

Tutte le proprietà della media e della varianza viste per le variabili aleatorie discrete valgono, ovviamente, anche per quelle continue: le dimostrazioni sono le stesse, con gli integrali al posto delle somme. In particolare $\sigma^2_{aX+b} = a^2\sigma_X^2$, e valgono le disuguaglianze di Markov e di Chebyshev. Per esempio, per una variabile $Z \geq 0$ con densità f_Z la dimostrazione di Markov diventa
$$P(Z \geq \delta) = \int_\delta^\infty f_Z(z)\, dz \leq \int_\delta^\infty \frac{z}{\delta}\, f_Z(z)\, dz \leq \int_0^\infty \frac{z}{\delta}\, f_Z(z)\, dz = \frac{E[Z]}{\delta},$$
con gli stessi tre passaggi del Capitolo 7: si moltiplica per $\frac{z}{\delta} \geq 1$, si estende l'integrale aggiungendo una parte non negativa, si riconosce la media.

LE VARIANZE DELLE VARIABILI NOTEVOLI

La variabile uniforme

Teorema 13.3 — Varianza dell'uniforme

Se $X \sim \mathcal{U}(a,b)$:

$$E[X] = \frac{a+b}{2}, \qquad E[X^2] = \frac{a^2+ab+b^2}{3}, \qquad \sigma_X^2 = \frac{(b-a)^2}{12}, \qquad \sigma_X = \frac{b-a}{\sqrt{12}}.$$

Dimostrazione

Passo 1 — La media. È già stata calcolata nel Capitolo 11.

Passo 2 — Il valore quadratico medio. Con la primitiva $\frac{x^3}{3}$:

$$E[X^2] = \frac{1}{b-a}\int_a^b x^2\,\mathrm{d}x = \frac{1}{b-a}\left[\frac{x^3}{3}\right]_a^b = \frac{b^3-a^3}{3(b-a)} = \frac{(b-a)(b^2+ab+a^2)}{3(b-a)} = \frac{b^2+ab+a^2}{3},$$

dove si è usato il prodotto notevole $b^3-a^3 = (b-a)(b^2+ab+a^2)$ (basta moltiplicare a destra per verificarlo: $b^3+ab^2+a^2b-ab^2-a^2b-a^3 = b^3-a^3$).

Passo 3 — La varianza. Al denominatore comune 12:

$$\sigma_X^2 = \frac{b^2+ab+a^2}{3} - \frac{(b+a)^2}{4} = \frac{4b^2+4ab+4a^2-3b^2-3a^2-6ab}{12} = \frac{b^2-2ab+a^2}{12} = \frac{(b-a)^2}{12}.$$

■

La varianza dipende solo dalla **larghezza** dell'intervallo, non dalla sua posizione: spostare l'intervallo sposta la media ma non la dispersione. Si confronti con l'uniforme discreta su M valori (Capitolo 7), che ha varianza $\frac{M^2-1}{12}$: per M grande è circa $\frac{M^2}{12}$, cioè (larghezza)$^2/12$, lo stesso risultato.

Esempio 13.2 — L'errore di quantizzazione

In un convertitore A/D con passo Δ (Capitolo 12), l'errore che si commette sostituendo X con il centro del suo intervallo sta fra $-\frac{\Delta}{2}$ e $\frac{\Delta}{2}$; se gli intervalli sono stretti rispetto alle variazioni della densità, l'errore è circa uniforme su quell'intervallo. La sua potenza (il valore quadratico medio, che coincide con la varianza perché la media è 0) è allora

$$\sigma^2 = \frac{\Delta^2}{12}.$$

È la celebre formula del **rumore di quantizzazione**: ogni bit in più dimezza Δ e divide la potenza dell'errore per 4.

La variabile esponenziale

Teorema 13.4 — Varianza dell'esponenziale

Se $X \sim \mathcal{E}(\lambda)$:

$$E[X] = \frac{1}{\lambda}, \qquad E[X^2] = \frac{2}{\lambda^2}, \qquad \sigma_X^2 = \frac{1}{\lambda^2}, \qquad \sigma_X = \frac{1}{\lambda}.$$

Dimostrazione

Passo 1 — Il valore quadratico medio, per parti. Il gradino riduce l'integrale a $[0, \infty)$. Con $f(x) = x^2$ (derivata $2x$) e $g'(x) = \lambda e^{-\lambda x}$ (primitiva $-e^{-\lambda x}$):

$$E[X^2] = \int_0^\infty x^2 \lambda e^{-\lambda x}\, dx = \Big[x^2 \left(-e^{-\lambda x}\right)\Big]_0^\infty - \int_0^\infty 2x \left(-e^{-\lambda x}\right) dx.$$

Passo 2 — Il bordo è nullo. In 0 vale 0, e $x^2 e^{-\lambda x} \to 0$ per $x \to \infty$ (l'esponenziale batte la potenza).

Passo 3 — Si riconosce la media. Moltiplicando e dividendo per λ:

$$E[X^2] = 2\int_0^\infty x\, e^{-\lambda x}\, dx = \frac{2}{\lambda} \underbrace{\int_0^\infty x\, \lambda e^{-\lambda x}\, dx}_{E[X] = \frac{1}{\lambda}} = \frac{2}{\lambda^2}.$$

Passo 4 — La varianza. $\sigma_X^2 = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}$.

■

Per l'esponenziale la deviazione standard è uguale alla media: un tempo di attesa medio di 10 minuti fluttua, tipicamente, di altri 10 minuti. È una variabile molto «aleatoria», con rapporto $\mu_X / \sigma_X = 1$.

La variabile di Laplace

Teorema 13.5 — Varianza della variabile di Laplace

Se $X \sim \mathcal{L}(\lambda)$:

$$E[X] = 0, \qquad E[X^2] = \sigma_X^2 = \frac{2}{\lambda^2}, \qquad \sigma_X = \frac{\sqrt{2}}{\lambda}.$$

Dimostrazione

Passo 1 — La parità. $x^2 \frac{\lambda}{2} e^{-\lambda|x|}$ è pari: l'area a sinistra dello zero è uguale a quella a destra, e l'integrale su $\mathbb{R}$ è il doppio di quello su $[0, \infty)$:

$$E[X^2] = \int_{-\infty}^\infty x^2 \frac{\lambda}{2} e^{-\lambda|x|}\, dx = 2 \cdot \frac{\lambda}{2} \int_0^\infty x^2 e^{-\lambda x}\, dx = \int_0^\infty x^2\, \lambda e^{-\lambda x}\, dx = \frac{2}{\lambda^2}.$$

L'ultimo integrale è il valore quadratico medio dell'esponenziale unilatera, calcolato sopra.

Passo 2 — La varianza. La media è nulla, quindi $\sigma_X^2 = E[X^2] - 0 = \frac{2}{\lambda^2}$.

■

La variabile di Cauchy

Per la variabile di Cauchy $\mathcal{C}(a, b)$ non esistono né la media né la varianza, e quindi nemmeno il valore efficace e la deviazione standard. Per la media lo abbiamo visto nel Capitolo 11. Il valore quadratico medio è infinito: con $a = 0$ e $b = 1$, l'integrando $\frac{x^2}{\pi(1+x^2)}$ tende a $\frac{1}{\pi}$ per $x \to \pm\infty$, e una funzione che non scende sotto un valore positivo ha area infinita su una semiretta (come il rettangolo infinito del Capitolo 10). Senza media, poi, la varianza non si può nemmeno definire.

Che cosa ci dice la deviazione standard, nel continuo

La disuguaglianza di Chebyshev garantisce che la probabilità di allontanarsi dalla media di almeno k deviazioni standard sia al più $\frac{1}{k^2}$, per qualsiasi densità. La tabella confronta il limite con i valori veri per tre variabili notevoli (per la gaussiana, la colonna verrà spiegata nel Capitolo 15).

k	uniforme	esponenziale	Laplace	gaussiana	Chebyshev $\frac{1}{k^2}$
1	0,423	0,135	0,243	0,317	1
1,5	0,134	0,082	0,120	0,134	0,444
2	0	0,050	0,059	0,046	0,25
3	0	0,018	0,014	0,003	0,111

Per esempio, per l'esponenziale con $\lambda = 1$ ($\mu = \sigma = 1$) e $k = 2$: $P(|X - 1| \geq 2) = P(X \geq 3) = e^{-3} \approx 0{,}050$. L'uniforme non esce mai oltre $1{,}73\,\sigma$ dal centro (la semilarghezza dell'intervallo è $\frac{b-a}{2} = \sqrt{3}\,\sigma$).

Il dizionario fra discreto e continuo

Ora che abbiamo visto entrambi i mondi, conviene metterli uno accanto all'altro: quasi tutte le formule si traducono con poche regole.

Concetto	**Variabile discreta**	**Variabile continua**
descrizione completa	pmf $p_X(x) = P(X = x)$	densità $f_X(x)$, con $P(X = x) = 0$
probabilità di un insieme	$\sum_{x \in A} p_X(x)$	$\int_A f_X(x)\,\mathrm{d}x$
normalizzazione	$\sum_x p_X(x) = 1$	$\int_{\mathbb{R}} f_X(x)\,\mathrm{d}x = 1$
CDF $F_X(x) = P(X \leq x)$	a scala, salti alti $p_X(x)$	continua, $F_X' = f_X$
media	$\sum_x x\,p_X(x)$	$\int x\,f_X(x)\,\mathrm{d}x$
media di $g(X)$	$\sum_x g(x)\,p_X(x)$	$\int g(x)\,f_X(x)\,\mathrm{d}x$
funzione $Y = g(X)$	$p_Y(y) = \sum_{g(x)=y} p_X(x)$	$f_Y(y) = \sum_{g(x_i)=y} \frac{f_X(x_i)}{\lvert \dot{g}(x_i) \rvert}$
condizionamento a A	$p_{X\mid A}(x) = \frac{P(\{X=x\} \cap A)}{P(A)}$	$F_{X\mid A}(x) = \frac{P(\{X \leq x\} \cap A)}{P(A)}$
varianza	$E[X^2] - \mu_X^2$	$E[X^2] - \mu_X^2$

Tabella 13.1: *Le regole di traduzione: le somme diventano integrali, $p_X(x)$ diventa $f_X(x)\,\mathrm{d}x$; l'unica formula davvero nuova è quella delle funzioni di variabile aleatoria, con la divisione per $|\dot{g}|$.*

Variabile	**Densità**	**Media**	**Valore quadratico medio**	**Varianza**
uniforme $\mathcal{U}(a,b)$	$\frac{1}{b-a}$ su (a,b)	$\frac{a+b}{2}$	$\frac{a^2+ab+b^2}{3}$	$\frac{(b-a)^2}{12}$
esponenziale $\mathcal{E}(\lambda)$	$\lambda e^{-\lambda x} u(x)$	$\frac{1}{\lambda}$	$\frac{2}{\lambda^2}$	$\frac{1}{\lambda^2}$
Laplace $\mathcal{L}(\lambda)$	$\frac{\lambda}{2} e^{-\lambda \lvert x \rvert}$	0	$\frac{2}{\lambda^2}$	$\frac{2}{\lambda^2}$
Cauchy $\mathcal{C}(a,b)$	$\frac{1}{b\pi} \frac{1}{1+((x-a)/b)^2}$	non esiste	$+\infty$	non esiste

Tabella 13.2: *Medie e varianze delle variabili continue notevoli.*

In sintesi

- **Teorema fondamentale**: $E[g(X)] = \int g(x)\, f_X(x)\, \mathrm{d}x$, senza bisogno della densità di $g(X)$; si dimostra quantizzando X e usando il caso discreto.
- Valore quadratico medio $\int x^2 f_X$, valore efficace, varianza $\int (x-\mu_X)^2 f_X = E[X^2] - \mu_X^2$, deviazione standard: le definizioni e le proprietà sono quelle del discreto, con gli integrali.
- Uniforme: $\sigma^2 = \frac{(b-a)^2}{12}$ (errore di quantizzazione $\frac{\Delta^2}{12}$). Esponenziale: $\sigma^2 = \frac{1}{\lambda^2}$, $\sigma = \mu$. Laplace: $\sigma^2 = \frac{2}{\lambda^2}$. Cauchy: né media né varianza.
- Markov e Chebyshev valgono anche nel continuo; per le densità notevoli le probabilità vere sono molto più piccole del limite $\frac{1}{k^2}$.

Variabili aleatorie continue multiple

Nel Capitolo 8 abbiamo descritto coppie di variabili discrete con una tabella, la pmf congiunta. Qui facciamo lo stesso con le variabili continue: la tabella diventa una **superficie**, la densità congiunta, e le probabilità diventano **volumi** sotto la superficie. Per calcolarli ci serve l'integrale doppio, che spieghiamo da zero. Tutto il resto (marginali, indipendenza, densità condizionate, media condizionata, covarianza) si traduce dal discreto con le regole del dizionario del capitolo precedente.

Coppie e m-ple di variabili continue

In perfetta analogia con quanto fatto per le variabili discrete, una coppia di variabili continue è definita nella forma

$$(X, Y) : \omega \in \Omega \longmapsto (X(\omega), Y(\omega)) \in \mathcal{X} \times \mathcal{Y} \subseteq \mathbb{R}^2,$$

dove $\mathcal{X}$ e $\mathcal{Y}$ sono gli alfabeti di X e di Y. Analogamente, date tre variabili aleatorie (a questo punto non importa più se tutte continue o meno) $X(\omega) \in \mathcal{X}$, $Y(\omega) \in \mathcal{Y}$, $Z(\omega) \in \mathcal{Z}$, si ha la terna

$$(X, Y, Z) : \omega \in \Omega \longmapsto (X(\omega), Y(\omega), Z(\omega)) \in \mathcal{X} \times \mathcal{Y} \times \mathcal{Z} \subseteq \mathbb{R}^3,$$

e, date m variabili aleatorie $X_i \in \mathcal{X}_i \subseteq \mathbb{R}$, la m-pla aleatoria

$$(X_1, X_2, \ldots, X_m) : \omega \in \Omega \longmapsto (X_1(\omega), \ldots, X_m(\omega)) \in \mathcal{X}_1 \times \mathcal{X}_2 \times \cdots \times \mathcal{X}_m \subseteq \mathbb{R}^m.$$

Perché servono? Si pensi ad altezza e peso di una persona scelta a caso in una popolazione. Le funzioni $F_X(x)$ e $F_Y(y)$ caratterizzano il comportamento statistico delle singole variabili, ma non quello **congiunto**: ci aspettiamo che una persona molto alta sia anche abbastanza pesante, e questa influenza reciproca non può essere descritta da due funzioni che riguardano ciascuna una sola delle due grandezze. Serve una caratterizzazione congiunta.

La densità congiunta

Densità congiunta

La **densità di probabilità congiunta** della coppia di variabili continue (X, Y) è

$$f_{X,Y}(x, y) = \lim_{\Delta x \to 0} \lim_{\Delta y \to 0} \frac{P\left(\left\{x - \frac{\Delta x}{2} \leq X \leq x + \frac{\Delta x}{2}\right\} \cap \left\{y - \frac{\Delta y}{2} \leq Y \leq y + \frac{\Delta y}{2}\right\}\right)}{\Delta x \, \Delta y} = \lim_{\Delta x \to 0} \lim_{\Delta y \to 0} \frac{P_{X,Y}(x, y; \Delta x, \Delta y)}{\Delta x \, \Delta y},$$

per $(x, y) \in \mathcal{X} \times \mathcal{Y}$.

È la probabilità che il punto (X, Y) cada in un rettangolino attorno a (x, y), divisa per l'**area** del rettangolino: una probabilità per unità di superficie. Se nel caso di una variabile la probabilità era uno strato di sabbia lungo una retta, ora è uno strato di sabbia steso su un tavolo, più alto in certi punti e più basso in altri. La densità congiunta è l'altezza dello strato, e la probabilità che il punto cada in una regione C del tavolo è il **volume** di sabbia sopra quella regione:

$$P((X, Y) \in C) = \iint_C f_{X,Y}(x, y) \, \mathrm{d}x \, \mathrm{d}y.$$

Richiamo di matematica: l'integrale doppio

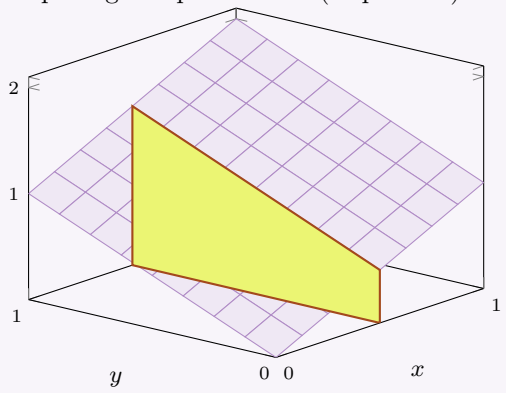
Sia $f(x,y) \geq 0$ una funzione di due variabili: il suo grafico è una superficie sopra il piano (x,y). Il **volume** compreso fra la superficie e una regione C del piano si calcola come l'area nel caso di una variabile: si divide il piano in tanti quadratini di lati Δx e Δy, sopra ogni quadratino si costruisce una colonna alta quanto la funzione, $f(x_i, y_j)$, e si sommano i volumi delle colonne. Quando i quadratini diventano infinitamente piccoli, la somma diventa l'**integrale doppio**:

$$\iint_C f(x,y)\,\mathrm{d}x\,\mathrm{d}y = \lim_{\Delta x, \Delta y \to 0} \sum_{(x_i,y_j)\in C} f(x_i,y_j)\,\Delta x\,\Delta y.$$

Come si calcola: a fette. Sopra un rettangolo $[a,b]\times[c,d]$ si può prima tagliare il volume a fette sottili perpendicolari all'asse x: per x fissato, la fetta ha area $\int_c^d f(x,y)\,\mathrm{d}y$ (un integrale semplice, in cui x è una costante). Poi si sommano le fette, integrando lungo x:

$$\iint_{[a,b]\times[c,d]} f(x,y)\,\mathrm{d}x\,\mathrm{d}y = \int_a^b \left(\int_c^d f(x,y)\,\mathrm{d}y \right) \mathrm{d}x = \int_c^d \left(\int_a^b f(x,y)\,\mathrm{d}x \right) \mathrm{d}y.$$

L'ordine non conta (è il **teorema di Fubini**): si possono tagliare le fette in un verso o nell'altro, come una somma doppia si può fare per righe o per colonne (Capitolo 6).



La superficie $z = x + y$ sopra il quadrato $[0,1]^2$. La fetta gialla, a $x = \frac{1}{2}$ fissato, ha area $\int_0^1 \left(\frac{1}{2} + y\right) \mathrm{d}y = 1$. In generale la fetta in x ha area $\int_0^1 (x+y)\,\mathrm{d}y = x + \frac{1}{2}$, e sommando le fette

$$\int_0^1 \left(x + \tfrac{1}{2}\right) \mathrm{d}x = \tfrac{1}{2} + \tfrac{1}{2} = 1.$$

Due casi utili. Se la funzione è un prodotto, $f(x,y) = g(x)\,h(y)$, sopra un rettangolo l'integrale doppio è il prodotto di due integrali semplici: $\iint g(x)h(y)\,\mathrm{d}x\,\mathrm{d}y = \int g(x)\,\mathrm{d}x \cdot \int h(y)\,\mathrm{d}y$ (nella fetta, $g(x)$ è una costante che esce dall'integrale in y). Se invece la regione non è un rettangolo, gli estremi dell'integrale interno dipendono dalla variabile esterna: per il triangolo $x \geq 0$, $y \geq 0$, $x + y \leq 1$, la fetta in x va da $y = 0$ a $y = 1 - x$, e $\iint_{\text{triangolo}} f\,\mathrm{d}x\,\mathrm{d}y = \int_0^1 \left(\int_0^{1-x} f(x,y)\,\mathrm{d}y \right) \mathrm{d}x$.

Teorema 14.1 — Proprietà della densità congiunta

Le densità congiunte devono soddisfare vincoli simili a quelli delle densità di una sola variabile:

a) $f_{X,Y}(x,y) \geq 0$ per ogni (x,y);

b) $f_{X,Y}$ è sommabile su $\mathbb{R}^2$ con integrale unitario: $\displaystyle\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f_{X,Y}(x,y)\,\mathrm{d}x\,\mathrm{d}y = P\big((X,Y)\in\mathbb{R}^2\big) = 1.$

Dimostrazione

Passo 1. La densità è il limite di rapporti fra una probabilità e un'area, quindi non è negativa; il volume totale è la probabilità dell'evento certo «il punto cade da qualche parte nel piano».

■

Esempio 14.1 — Due tempi di attesa indipendenti

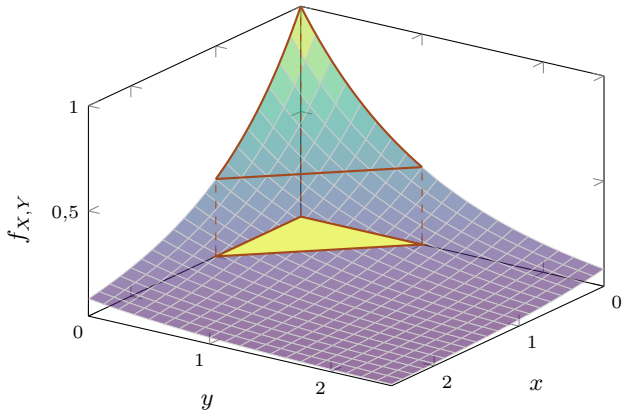
Due componenti si guastano dopo tempi X e Y indipendenti, entrambi esponenziali di parametro 1. Come vedremo fra poco, per variabili indipendenti la densità congiunta è il prodotto delle densità:

$$f_{X,Y}(x,y) = e^{-x}\, e^{-y} = e^{-(x+y)} \qquad x, y \geq 0.$$

Qual è la probabilità che il tempo totale $X + Y$ non superi 1? È il volume sopra il triangolo $x, y \geq 0$, $x + y \leq 1$:

$$P(X+Y \leq 1) = \int_0^1 \left(\int_0^{1-x} e^{-x} e^{-y}\, \mathrm{d}y \right) \mathrm{d}x = \int_0^1 e^{-x} \left(1 - e^{-(1-x)}\right) \mathrm{d}x = \int_0^1 \left(e^{-x} - e^{-1}\right) \mathrm{d}x = \left(1 - e^{-1}\right) - e^{-1} = 1 - \frac{2}{e} \approx 0{,}264.$$

Nella fetta in x il fattore e^{-x} è costante ed esce dall'integrale; poi $e^{-x} e^{-(1-x)} = e^{-1}$.



La probabilità è il volume del «solido» che sta sopra il triangolo giallo e sotto la superficie $e^{-(x+y)}$.

Marginali, indipendenza e densità condizionate

La densità congiunta $f_{X,Y}$ condivide con la pmf congiunta $p_{X,Y}$ le stesse proprietà fondamentali.

Teorema 14.2 — Marginalizzazione e indipendenza

a) **Marginalizzazione**:

$$f_X(x) = \int_{\mathbb{R}} f_{X,Y}(x,y)\, \mathrm{d}y, \qquad f_Y(y) = \int_{\mathbb{R}} f_{X,Y}(x,y)\, \mathrm{d}x,$$

per cui caratterizzare congiuntamente (X, Y) significa anche caratterizzarle marginalmente, mentre il viceversa non è necessariamente vero.

b) **Indipendenza statistica**: due variabili aleatorie sono indipendenti se e solo se

$$f_{X,Y}(x,y) = f_X(x)\, f_Y(y) \quad \Longleftrightarrow \quad F_{X,Y}(x,y) = F_X(x)\, F_Y(y).$$

c) Più in generale, $X_1, \ldots, X_m$ con densità f_{X_i} sono indipendenti se e solo se

$$f_{X_1,\ldots,X_m}(x_1,\ldots,x_m) = \prod_{i=1}^{m} f_{X_i}(x_i) \qquad \forall (x_1,\ldots,x_m) \in \mathbb{R}^m.$$

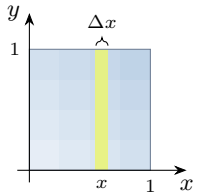
Dimostrazione — della marginalizzazione

Passo 1 — Una striscia. L'evento $\left\{x - \frac{\Delta x}{2} \le X \le x + \frac{\Delta x}{2}\right\}$ non pone condizioni su Y: nel piano è una **striscia verticale** larga Δx, illimitata in alto e in basso.

Passo 2 — Il volume della striscia. La sua probabilità è il volume sopra la striscia. Per Δx piccolo, ogni fetta della striscia ha circa la stessa sezione, quella in x, cioè $\int_{\mathbb{R}} f_{X,Y}(x,y)\,dy$; quindi il volume è circa

$$P\left(x - \tfrac{\Delta x}{2} \le X \le x + \tfrac{\Delta x}{2}\right) \simeq \Delta x \int_{\mathbb{R}} f_{X,Y}(x,y)\,dy.$$

Passo 3 — La densità. Dividendo per Δx e mandandolo a zero si ottiene $f_X(x)$. Per f_Y si usa una striscia orizzontale. ■



La densità $x + y$ sul quadrato (più scura dove è più alta). La striscia gialla è l'evento «X cade vicino a x», qualunque sia Y: il suo volume diviso Δx è la densità marginale $f_X(x) = \int_0^1 (x+y)\,dy = x + \frac{1}{2}$.

Figura 14.1: *Marginalizzare vuol dire «schiacciare» la densità congiunta su un asse, sommando lungo l'altro.*

Le densità condizionate

Vorremmo la densità di X sapendo che $Y = y$. Ma l'evento $\{Y = y\}$ ha probabilità zero, e non ci si può dividere per zero. Si condiziona allora all'evento $\left\{y - \frac{\Delta y}{2} \le Y \le y + \frac{\Delta y}{2}\right\}$, che ha probabilità positiva, e solo alla fine si stringe l'intervallo:

$$P\left(x - \tfrac{\Delta x}{2} \le X \le x + \tfrac{\Delta x}{2} \;\middle|\; y - \tfrac{\Delta y}{2} \le Y \le y + \tfrac{\Delta y}{2}\right) = \frac{P_{X,Y}(x,y;\Delta x,\Delta y)}{P_Y(y;\Delta y)}.$$

Dividendo per Δx e mandando $\Delta x \to 0$ si ottiene la densità di X condizionata all'evento «Y vicino a y». Facendo poi tendere anche Δy a zero, e moltiplicando e dividendo per Δy:

$$f_{X|Y}(x \mid y) = \lim_{\Delta y\to 0}\lim_{\Delta x\to 0} \frac{P_{X,Y}(x,y;\Delta x,\Delta y)}{\Delta x\, P_Y(y;\Delta y)} = \frac{\lim\limits_{\Delta y\to 0}\lim\limits_{\Delta x\to 0} \dfrac{P_{X,Y}(x,y;\Delta x,\Delta y)}{\Delta x\,\Delta y}}{\lim\limits_{\Delta y\to 0} \dfrac{P_Y(y;\Delta y)}{\Delta y}} = \frac{f_{X,Y}(x,y)}{f_Y(y)}.$$

Densità condizionata

La **densità di X condizionata a $Y = y$** (per $f_Y(y) > 0$) è

$$f_{X|Y}(x \mid y) = \frac{f_{X,Y}(x,y)}{f_Y(y)}.$$

Come c'era da attendersi, l'espressione riproduce l'analoga definizione per la pmf condizionata, che d'altronde è essa stessa una densità (discreta). Di conseguenza tutte le proprietà delle pmf condizionate si estendono alle densità condizionate.

Teorema 14.3 — Proprietà delle densità condizionate

a) Per y fissato, al variare di x, $f_{X|Y}(x \mid y)$ è una densità: $f_{X|Y}(x \mid y) \ge 0$ e $\int_{\mathbb{R}} f_{X|Y}(x \mid y)\,dx = 1$.
b) **Probabilità totale per le densità**:

$$f_X(x) = \int_{\mathbb{R}} f_{X,Y}(x,y)\,dy = \int_{\mathbb{R}} f_{X|Y}(x \mid y)\, f_Y(y)\,dy, \qquad f_Y(y) = \int_{\mathbb{R}} f_{Y|X}(y \mid x)\, f_X(x)\,dx.$$

c) **Probabilità composta e Bayes**:

$$f_{X,Y}(x,y) = f_Y(y)\, f_{X|Y}(x \mid y) = f_X(x)\, f_{Y|X}(y \mid x), \qquad f_{X|Y}(x \mid y) = \frac{f_X(x)\, f_{Y|X}(y \mid x)}{f_Y(y)}.$$

Dimostrazione

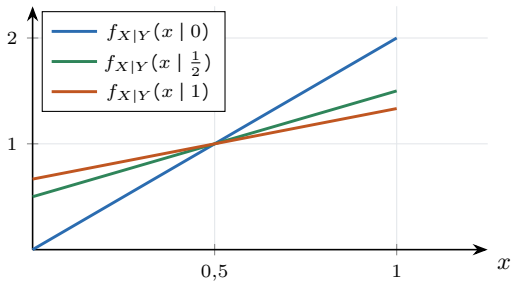
Passo 1 — a). È un rapporto di quantità non negative; integrando in x, il numeratore dà la marginale $f_Y(y)$, che si semplifica con il denominatore.

Passo 2 — b) e c). Dalla definizione, $f_{X,Y} = f_{X|Y}\, f_Y$ (e, scambiando i ruoli, $= f_{Y|X}\, f_X$); sostituendo nella marginalizzazione si ottiene b), uguagliando le due scritture e dividendo per f_Y si ottiene Bayes. ■

Esempio 14.2 — Una densità congiunta calcolata fino in fondo

Sia $f_{X,Y}(x,y) = x + y$ sul quadrato $[0,1]^2$ (e 0 fuori). È una densità: è positiva e il suo integrale vale 1 (lo abbiamo calcolato nel richiamo).

- **Marginali**: $f_X(x) = \int_0^1 (x+y)\,\mathrm{d}y = x + \frac{1}{2}$ e, per simmetria, $f_Y(y) = y + \frac{1}{2}$, per $x, y \in [0,1]$.
- **Indipendenza**: $f_X(x)\, f_Y(y) = \left(x + \frac{1}{2}\right)\left(y + \frac{1}{2}\right) \neq x + y$ (in $(0,0)$ vale $\frac{1}{4}$ contro 0): le variabili non sono indipendenti.
- **Condizionata**: $f_{X|Y}(x \mid y) = \dfrac{x+y}{y+\frac{1}{2}}$, per $x \in [0,1]$. Per esempio con $y = 0$ è $2x$ (sapendo che Y è piccola, X tende a essere grande), con $y = 1$ è $\frac{x+1}{1{,}5}$, quasi piatta.



Ogni curva è una «fetta» della densità congiunta a y fissato, divisa per la sua area $f_Y(y)$ in modo da avere area 1.

Medie, media condizionata e covarianza

Come nel caso discreto valgono le seguenti estensioni.

- Se $Z = g(X,Y)$, allora
$$E[Z] = \iint_{\mathbb{R}^2} g(x,y)\, f_{X,Y}(x,y)\,\mathrm{d}x\,\mathrm{d}y.$$
- **Linearità della media**: $E\left[\sum_{i=1}^m a_i X_i\right] = \sum_{i=1}^m a_i\, E[X_i]$.

Teorema 14.4 — Teorema della media condizionata

$$E[g(X,Y)] = E_Y\Big[E_{X|Y}[g(X,Y) \mid Y]\Big], \qquad \text{dove} \qquad E[g(X,Y) \mid Y = y] = \int_{\mathbb{R}} g(x,y)\, f_{X|Y}(x \mid y)\,\mathrm{d}x.$$

Dimostrazione

Passo 1 — Una funzione di y. $E[g(X,Y) \mid Y = y]$ è una funzione di y, chiamiamola $h(y)$. Se consideriamo la variabile aleatoria $h(Y)$ e ne calcoliamo la media statistica:

$$E[h(Y)] = \int_{\mathbb{R}} h(y)\, f_Y(y)\, \mathrm{d}y = \int_{\mathbb{R}} \left(\int_{\mathbb{R}} g(x,y)\, f_{X|Y}(x \mid y)\, \mathrm{d}x \right) f_Y(y)\, \mathrm{d}y.$$

Passo 2 — Si riconosce la congiunta. $f_Y(y)$ non dipende da x e si può portare dentro l'integrale interno, dove $f_{X|Y}(x \mid y)\, f_Y(y) = f_{X,Y}(x,y)$:

$$E[h(Y)] = \iint_{\mathbb{R}^2} g(x,y)\, f_{X,Y}(x,y)\, \mathrm{d}x\, \mathrm{d}y = E[g(X,Y)].$$

■

Esempio 14.3 — La media in due tempi

Con la densità $x + y$ sul quadrato: la media di X sapendo $Y = y$ è

$$E[X \mid Y = y] = \int_0^1 x\, \frac{x + y}{y + \frac{1}{2}}\, \mathrm{d}x = \frac{\frac{1}{3} + \frac{y}{2}}{y + \frac{1}{2}},$$

che vale $\frac{2}{3}$ per $y = 0$ e $\frac{5}{9}$ per $y = 1$: più Y è grande, più la media di X si abbassa. Mediando rispetto a Y, il denominatore si semplifica con $f_Y(y) = y + \frac{1}{2}$:

$$E[X] = \int_0^1 E[X \mid Y = y]\, f_Y(y)\, \mathrm{d}y = \int_0^1 \left(\tfrac{1}{3} + \tfrac{y}{2} \right) \mathrm{d}y = \tfrac{1}{3} + \tfrac{1}{4} = \tfrac{7}{12},$$

lo stesso valore che si ottiene direttamente: $\int_0^1 x \left(x + \frac{1}{2} \right) \mathrm{d}x = \frac{1}{3} + \frac{1}{4} = \frac{7}{12}$.

Siano $(X,Y) \sim f_{X,Y}(x,y)$, con medie (μ_X, μ_Y) e varianze σ_X^2, σ_Y^2. In analogia con il caso discreto:

- **covarianza**: $COV(X,Y) = E[(X - \mu_X)(Y - \mu_Y)] = E[XY] - \mu_X \mu_Y$;
- **coefficiente di correlazione**: $\rho_{XY} = \dfrac{COV(X,Y)}{\sigma_X\, \sigma_Y}$, con $|\rho_{XY}| \le 1$;
- **incorrelazione**: $COV(X,Y) = 0$;
- l'indipendenza statistica implica l'incorrelazione ma, in generale, non vale il viceversa.

Le dimostrazioni sono quelle del Capitolo 9, con gli integrali al posto delle somme.

Esempio 14.4 — La covarianza della densità $x + y$

Servono $E[XY]$ e le varianze. Con l'integrale doppio, a fette:

$$E[XY] = \int_0^1 \int_0^1 xy(x + y)\, \mathrm{d}y\, \mathrm{d}x = \int_0^1 \int_0^1 \left(x^2 y + x y^2 \right) \mathrm{d}y\, \mathrm{d}x = \frac{1}{3} \cdot \frac{1}{2} + \frac{1}{2} \cdot \frac{1}{3} = \frac{1}{3},$$

dove ogni termine è un prodotto di due integrali semplici. Quindi $COV(X,Y) = \frac{1}{3} - \frac{7}{12} \cdot \frac{7}{12} = \frac{48-49}{144} = -\frac{1}{144}$. Con $E[X^2] = \int_0^1 x^2 \left(x + \frac{1}{2} \right) \mathrm{d}x = \frac{1}{4} + \frac{1}{6} = \frac{5}{12}$ si ha $\sigma_X^2 = \frac{5}{12} - \frac{49}{144} = \frac{11}{144}$, e lo stesso per Y:

$$\rho_{XY} = \frac{-1/144}{11/144} = -\frac{1}{11} \approx -0{,}09.$$

Una correlazione negativa ma debole, coerente con le densità condizionate: quando Y cresce, X tende un poco a calare.

La funzione di distribuzione congiunta

Come per una sola variabile, oltre alla densità si può usare una funzione che dà direttamente delle probabilità.

CDF congiunta

Data una coppia di variabili aleatorie (X, Y), la **funzione di distribuzione di probabilità congiunta** è

$$F_{X,Y}(x, y) = P(X \le x, Y \le y), \qquad (x, y) \in \mathbb{R}^2.$$

Descrive in modo completo il comportamento statistico congiunto delle due variabili.

$F_{X,Y}(x, y)$ è la probabilità che il punto (X, Y) cada nel «quadrante» in basso a sinistra del punto (x, y).

Richiamo di matematica: le derivate parziali

Per una funzione di due variabili $F(x, y)$, la **derivata parziale** rispetto a x, $\frac{\partial F}{\partial x}$, è la derivata fatta trattando y come una costante (lo abbiamo già fatto nel Capitolo 7, derivando rispetto a p con q fisso). Il simbolo ∂ (una «d» arrotondata) ricorda che le variabili sono più di una. La derivata **mista** $\frac{\partial^2 F}{\partial x\, \partial y}$ si ottiene derivando prima rispetto a y e poi il risultato rispetto a x; per le funzioni regolari l'ordine non conta. Esempio: per $F = \frac{x^2 y + x y^2}{2}$, $\frac{\partial F}{\partial y} = \frac{x^2 + 2xy}{2}$ e poi $\frac{\partial^2 F}{\partial x\, \partial y} = \frac{2x + 2y}{2} = x + y$.

Il legame con la densità è lo stesso del caso di una variabile, con una derivata per ogni variabile:

$$F_{X,Y}(x, y) = \int_{-\infty}^{x} \int_{-\infty}^{y} f_{X,Y}(s, t)\, \mathrm{d}t\, \mathrm{d}s \qquad \Longleftrightarrow \qquad f_{X,Y}(x, y) = \frac{\partial^2}{\partial x\, \partial y} F_{X,Y}(x, y).$$

Per esempio, per la densità $x + y$ sul quadrato, nei punti del quadrato $F_{X,Y}(x, y) = \int_0^x \int_0^y (s + t)\, \mathrm{d}t\, \mathrm{d}s = \frac{x^2 y + x y^2}{2}$, e la sua derivata mista, calcolata nel richiamo, ridà proprio $x + y$.

Teorema 14.5 — Proprietà della CDF congiunta

a) $0 \le F_{X,Y}(x, y) \le 1$;
b) fissato comunque y_0, $F_{X,Y}(x, y_0)$ è monotona non decrescente in x (e continua da destra); fissato comunque x_0, $F_{X,Y}(x_0, y)$ è monotona non decrescente in y (e continua da destra);
c) $F_{X,Y}(-\infty, y) = F_{X,Y}(x, -\infty) = F_{X,Y}(-\infty, -\infty) = 0$ e $\lim_{x \to \infty, y \to \infty} F_{X,Y}(x, y) = 1$;
d) le CDF marginali si ricavano dalla congiunta: $F_X(x) = F_{X,Y}(x, +\infty)$, $F_Y(y) = F_{X,Y}(+\infty, y)$;
e) la probabilità dell'evento rettangolare $R = \{x_1 < X \le x_2,\ y_1 < Y \le y_2\}$ è

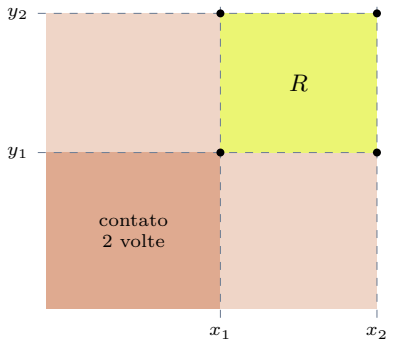
$$P(R) = F_{X,Y}(x_2, y_2) - F_{X,Y}(x_2, y_1) - F_{X,Y}(x_1, y_2) + F_{X,Y}(x_1, y_1).$$

Dimostrazione

Passo 1 — a), b), c). $F_{X,Y}$ è una probabilità; allargando il quadrante (aumentando x o y) l'evento si allarga e la probabilità non diminuisce. Con $x = -\infty$ il quadrante è vuoto ($X \le -\infty$ è impossibile); con entrambe le coordinate a $+\infty$ è tutto il piano.

Passo 2 — d). $\{X \le x, Y \le +\infty\} = \{X \le x\}$: la condizione su Y è sempre vera.

Passo 3 — e) Si toglie e si rimette. Il rettangolo si ottiene dal quadrante di (x_2, y_2) togliendo il quadrante di (x_2, y_1) (la parte sotto) e quello di (x_1, y_2) (la parte a sinistra). Così però il quadrante di (x_1, y_1), che sta in entrambi, è stato tolto due volte, e va rimesso una volta. È lo stesso ragionamento della probabilità dell'unione (Capitolo 3). ∎



Il quadrante di (x_2, y_2) contiene tutto il disegno. Togliendo il quadrante di (x_2, y_1) (la fascia in basso) e quello di (x_1, y_2) (la fascia a sinistra) resta il rettangolo giallo R, ma l'angolo in basso a sinistra, il quadrante di (x_1, y_1), è stato tolto due volte: lo si riaggiunge una volta.

Figura 14.2: *La probabilità di un rettangolo dalla CDF congiunta.*

In sintesi

- La **densità congiunta** $f_{X,Y}(x, y)$ è una probabilità per unità di area: $P((X, Y) \in C) = \iint_C f_{X,Y}$, il volume sotto la superficie. È ≥ 0 e ha volume totale 1.
- L'**integrale doppio** si calcola a fette (Fubini): prima un integrale con l'altra variabile fissa, poi l'altro; per un prodotto $g(x)h(y)$ è il prodotto degli integrali.
- Marginali: $f_X = \int f_{X,Y}\,dy$. Indipendenza: $f_{X,Y} = f_X f_Y$ ($\iff F_{X,Y} = F_X F_Y$).
- Condizionata: $f_{X|Y}(x \mid y) = f_{X,Y}/f_Y$, ottenuta condizionando a Y «vicino a y»; valgono probabilità totale, composta e Bayes per le densità.
- $E[g(X, Y)] = \iint g f_{X,Y}$, linearità, media condizionata $E[g] = E_Y[E_{X|Y}[g \mid Y]]$, covarianza e ρ come nel discreto.
- **CDF congiunta** $F_{X,Y}(x, y) = P(X \leq x, Y \leq y)$, con $f_{X,Y} = \frac{\partial^2 F_{X,Y}}{\partial x \partial y}$; marginali $F_X(x) = F_{X,Y}(x, +\infty)$; un rettangolo si calcola con quattro valori della CDF.

La variabile gaussiana e la funzione Q

Fra tutte le variabili continue ce n'è una che compare ovunque: il rumore termico di un resistore, gli errori di misura, le altezze delle persone, il rumore che disturba un segnale radio. È la **gaussiana** (o **normale**), con la sua densità a forma di campana. Il motivo della sua onnipresenza lo vedremo nel terzo pacchetto di slide, con il teorema centrale del limite: quando una grandezza è la somma di tantissimi piccoli contributi indipendenti (come il rumore termico, somma degli effetti di miliardi di elettroni), la sua densità diventa gaussiana. In questo capitolo ne studiamo la densità, la media e la varianza, e la funzione Q, che serve a calcolarne le probabilità. Alla fine useremo tutto per calcolare quanti bit sbaglia un ricevitore disturbato dal rumore.

La gaussiana standard

Gaussiana standard

Una variabile aleatoria X_0, con alfabeto $\mathcal{X} = \mathbb{R}$, si dice **gaussiana** (o **normale**) **standard**, in breve $X_0 \sim \mathcal{N}(0,1)$, se ha densità

$$f_{X_0}(x_0) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x_0^2}{2}}, \qquad x_0 \in \mathbb{R}.$$

La densità è una campana simmetrica attorno a 0, con il massimo $\frac{1}{\sqrt{2\pi}} \approx 0{,}399$ nell'origine. Le code scendono velocissime: l'esponente $-\frac{x^2}{2}$ cresce in valore assoluto con il quadrato di x, e già a $x = 4$ la densità è circa tremila volte più bassa del massimo ($e^{-8} \approx \frac{1}{3000}$). Il fattore $\frac{1}{\sqrt{2\pi}}$ non è scelto a caso: è l'unico che rende l'area uguale a 1. Per dimostrarlo serve uno dei calcoli più belli della matematica, che passa per il piano e per le coordinate polari.

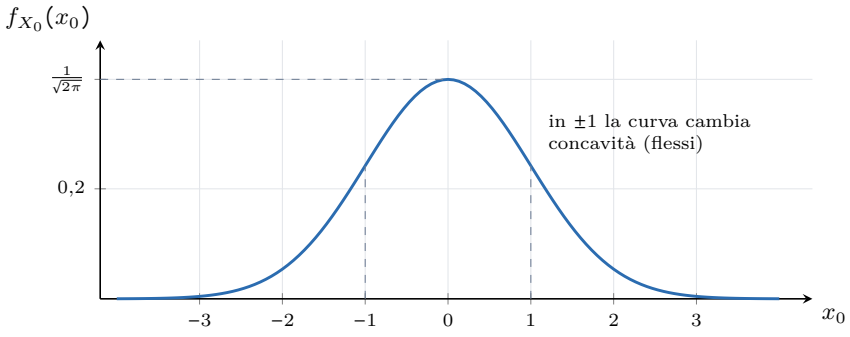


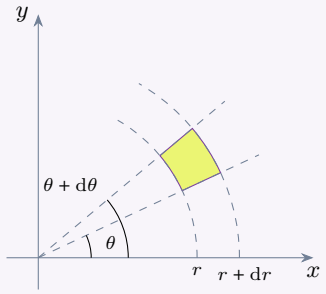
Figura 15.1: *La densità gaussiana standard: la «curva a campana».*

Richiamo di matematica: le coordinate polari

Un punto del piano si può individuare con le coordinate cartesiane (x, y) oppure con le **coordinate polari** (r, θ): la distanza r dall'origine e l'angolo θ che il segmento dall'origine al punto forma con l'asse x. Il legame è $x = r\cos\theta$, $y = r\sin\theta$, e per Pitagora $x^2 + y^2 = r^2$.
Per calcolare un integrale doppio in coordinate polari si divide il piano in «rettangolini polari»: le zone fra due circonferenze di raggi r e $r + \mathrm{d}r$ e fra due semirette di angoli θ e $\theta + \mathrm{d}\theta$. Un rettangolino polare è quasi un rettangolo con un lato lungo $\mathrm{d}r$ (in direzione radiale) e l'altro lungo $r\,\mathrm{d}\theta$ (un arco di circonferenza di raggio r: la lunghezza di un arco è raggio per angolo, in radianti). La sua area è quindi

$$\mathrm{d}A = r\,\mathrm{d}r\,\mathrm{d}\theta,$$

con quel fattore r in più: i rettangolini lontani dall'origine sono più larghi.



Il rettangolino polare giallo ha i lati circa $\mathrm{d}r$ e $r\,\mathrm{d}\theta$: area $r\,\mathrm{d}r\,\mathrm{d}\theta$. Coprendo tutto il piano, r va da 0 a ∞ e θ da 0 a 2π.

Teorema 15.1 — L'integrale di Gauss

$$\int_{-\infty}^{\infty} e^{-\frac{x^2}{2}}\,\mathrm{d}x = \sqrt{2\pi}, \qquad \text{quindi} \qquad \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}}\, e^{-\frac{x^2}{2}}\,\mathrm{d}x = 1.$$

Dimostrazione — passando al quadrato e nel piano

Passo 1 — Il problema. La funzione $e^{-x^2/2}$ non ha una primitiva che si possa scrivere con le funzioni elementari (polinomi, esponenziali, logaritmi, seni…): l'integrale non si può calcolare direttamente. Il trucco è calcolarne il quadrato. Sia $I = \int_{-\infty}^{\infty} e^{-x^2/2}\,\mathrm{d}x$.

Passo 2 — Il quadrato è un integrale doppio. Il nome della variabile di integrazione non conta, quindi

$$I^2 = \int_{-\infty}^{\infty} e^{-\frac{x^2}{2}}\,\mathrm{d}x \cdot \int_{-\infty}^{\infty} e^{-\frac{y^2}{2}}\,\mathrm{d}y = \iint_{\mathbb{R}^2} e^{-\frac{x^2+y^2}{2}}\,\mathrm{d}x\,\mathrm{d}y,$$

perché il prodotto di due integrali in variabili diverse è l'integrale doppio del prodotto (Capitolo 14), ed $e^{-x^2/2}\,e^{-y^2/2} = e^{-(x^2+y^2)/2}$.

Passo 3 — Coordinate polari. La funzione dipende solo da $x^2 + y^2 = r^2$, la distanza dall'origine: è una campana a simmetria circolare. In coordinate polari:

$$I^2 = \int_0^{2\pi} \int_0^{\infty} e^{-\frac{r^2}{2}}\, r\,\mathrm{d}r\,\mathrm{d}\theta.$$

Passo 4 — Ora l'integrale si fa. Grazie al fattore r la primitiva c'è: per la regola della catena $\frac{\mathrm{d}}{\mathrm{d}r}\left(-e^{-r^2/2}\right) = r\,e^{-r^2/2}$. Quindi

$$\int_0^{\infty} e^{-\frac{r^2}{2}}\, r\,\mathrm{d}r = \left[-e^{-\frac{r^2}{2}}\right]_0^{\infty} = 0 - (-1) = 1, \qquad I^2 = \int_0^{2\pi} 1\,\mathrm{d}\theta = 2\pi.$$

Passo 5 — Conclusione. $I > 0$ (è l'integrale di una funzione positiva), quindi $I = \sqrt{2\pi}$.

■

Teorema 15.2 — Media e varianza della gaussiana standard

Se $X_0 \sim \mathcal{N}(0,1)$: $\quad E[X_0] = \mu_{X_0} = 0, \quad \sigma^2_{X_0} = E[X_0^2] = 1.$

Dimostrazione

Passo 1 — La media. L'integrando $x\,\frac{1}{\sqrt{2\pi}}e^{-x^2/2}$ è dispari, e le due metà sono finite: $\int_0^\infty x\,e^{-x^2/2}\,\mathrm{d}x = \left[-e^{-x^2/2}\right]_0^\infty = 1$. Quindi la media è 0.

Passo 2 — Il valore quadratico medio, per parti. Si scrive $x^2e^{-x^2/2} = x\cdot\left(x\,e^{-x^2/2}\right)$, con $f(x) = x$ (derivata 1) e $g'(x) = x\,e^{-x^2/2}$ (primitiva $g(x) = -e^{-x^2/2}$):

$$E[X_0^2] = \frac{1}{\sqrt{2\pi}}\int_{-\infty}^{\infty} x^2 e^{-\frac{x^2}{2}}\,\mathrm{d}x = \frac{1}{\sqrt{2\pi}}\left\{\left[-x\,e^{-\frac{x^2}{2}}\right]_{-\infty}^{\infty} + \int_{-\infty}^{\infty} e^{-\frac{x^2}{2}}\,\mathrm{d}x\right\}.$$

Passo 3 — Si conclude. Il termine di bordo è nullo (l'esponenziale batte la potenza), e l'integrale rimasto è $\sqrt{2\pi}$: $E[X_0^2] = \frac{\sqrt{2\pi}}{\sqrt{2\pi}} = 1$. Siccome la media è 0, la varianza coincide con il valore quadratico medio.

■

LA GAUSSIANA GENERICA

Tutte le altre gaussiane si ottengono dalla standard spostandola e allargandola.

Teorema 15.3 — Densità della gaussiana generica

Sia $X_0 \sim \mathcal{N}(0,1)$ e sia $X = \sigma_X X_0 + \mu_X$, con $\sigma_X > 0$ e $\mu_X \in \mathbb{R}$. Allora

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma_X^2}}\,e^{-\frac{(x-\mu_X)^2}{2\sigma_X^2}}, \qquad x \in \mathbb{R},$$

e $E[X] = \mu_X$, $\mathrm{VAR}(X) = \sigma_X^2$. Si scrive $X \sim \mathcal{N}(\mu_X, \sigma_X^2)$.

Dimostrazione

Passo 1 — La densità. È la trasformazione lineare $g(x) = \sigma_X x + \mu_X$, crescente. Con la formula del Capitolo 12, $f_X(x) = \frac{1}{\sigma_X} f_{X_0}\left(\frac{x-\mu_X}{\sigma_X}\right)$:

$$f_X(x) = \frac{1}{\sigma_X}\,\frac{1}{\sqrt{2\pi}}\,e^{-\frac{1}{2}\left(\frac{x-\mu_X}{\sigma_X}\right)^2} = \frac{1}{\sqrt{2\pi\sigma_X^2}}\,e^{-\frac{(x-\mu_X)^2}{2\sigma_X^2}}.$$

Passo 2 — La media. Per la linearità: $E[X] = E[\sigma_X X_0 + \mu_X] = \sigma_X E[X_0] + \mu_X = 0\cdot\sigma_X + \mu_X = \mu_X$.

Passo 3 — La varianza.

$$\mathrm{VAR}(X) = E[(X-\mu_X)^2] = E[(\sigma_X X_0 + \mu_X - \mu_X)^2] = E[(\sigma_X X_0)^2] = \sigma_X^2\,E[X_0^2] = \sigma_X^2.$$

■

I due parametri hanno quindi un significato diretto: μ_X è il centro della campana (e la sua media), σ_X la sua larghezza (e la sua deviazione standard). Una gaussiana è completamente determinata dalla coppia (μ_X, σ_X^2). Il procedimento si può anche rovesciare: se $X \sim \mathcal{N}(\mu_X, \sigma_X^2)$, la variabile **standardizzata** $X_0 = \frac{X-\mu_X}{\sigma_X}$ è una gaussiana standard.

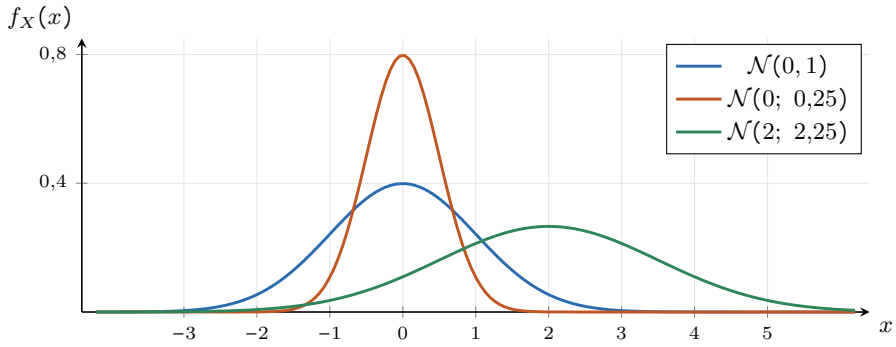


Figura 15.2: *Tre gaussiane. Con $\sigma = 0{,}5$ la campana è stretta e alta, con $\sigma = 1{,}5$ larga e bassa: l'area resta sempre 1. La media μ sposta il centro.*

La funzione Q

Per calcolare la probabilità che una gaussiana cada in un intervallo servirebbe la sua CDF. Ma né la CDF né la CCDF di $X_0 \sim \mathcal{N}(0,1)$ sono note in forma esplicita, perché $e^{-\gamma x^2}$ non ammette primitive elementari (è lo stesso ostacolo incontrato con l'integrale di Gauss, ma ora l'integrale non è su tutta la retta, e il trucco del quadrato non funziona). Si dà allora un nome alla funzione che serve, e se ne tabulano i valori.

Funzione Q

La **funzione** Q è la CCDF della gaussiana standard, cioè la probabilità che $X_0 \sim \mathcal{N}(0,1)$ superi il valore x:

$$Q(x) \triangleq P(X_0 > x) = 1 - F_{X_0}(x) = \frac{1}{\sqrt{2\pi}} \int_x^{+\infty} e^{-\frac{t^2}{2}}\, \mathrm{d}t.$$

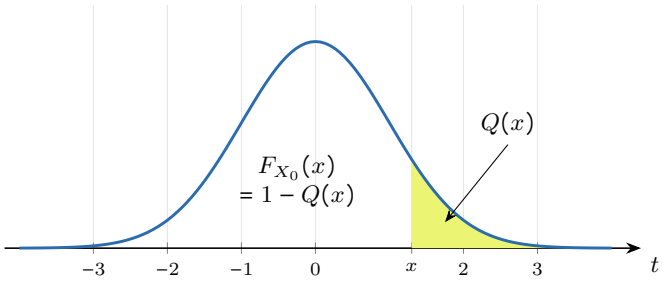


Figura 15.3: *$Q(x)$ è l'area della coda destra della gaussiana standard, oltre x.*

Con la funzione Q si calcola qualsiasi probabilità gaussiana. Per la standard, $F_{X_0}(x) = 1 - Q(x)$ e la probabilità di un intervallino è

$$P_{X_0}(x; \Delta x) = Q\left(x - \frac{\Delta x}{2}\right) - Q\left(x + \frac{\Delta x}{2}\right).$$

Per una gaussiana qualsiasi si standardizza.

Teorema 15.4 — Le code di una gaussiana qualsiasi

Se $X \sim \mathcal{N}(\mu_X, \sigma_X^2)$:

$$P(X > x) = 1 - F_X(x) = Q\left(\frac{x - \mu_X}{\sigma_X}\right).$$

Dimostrazione

Passo 1. Si scrive $X = X_0\sigma_X + \mu_X$ e si isola X_0 (dividere per $\sigma_X > 0$ non cambia il verso della disuguaglianza):

$$P(X > x) = P(X_0\sigma_X + \mu_X > x) = P\left(X_0 > \frac{x-\mu_X}{\sigma_X}\right) = \int_{\frac{x-\mu_X}{\sigma_X}}^{+\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}\,\mathrm{d}t = Q\left(\frac{x-\mu_X}{\sigma_X}\right).$$

■

La quantità $\frac{x-\mu_X}{\sigma_X}$ dice **di quante deviazioni standard** il valore x si trova sopra la media: è tutto quello che conta.

Le proprietà della funzione Q

Teorema 15.5 — Proprietà della funzione Q

a) $Q(-\infty) = 1, \quad Q(0) = \frac{1}{2}, \quad Q(+\infty) = 0;$

b) $\dfrac{\mathrm{d}Q(x)}{\mathrm{d}x} = -\dfrac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} < 0$ per ogni x: Q è decrescente;

c) simmetria: $Q(-x) = 1 - Q(x)$;

d) se $X \sim \mathcal{N}(\mu_X, \sigma_X^2)$: $P(X \geq \eta) = Q\left(\frac{\eta-\mu_X}{\sigma_X}\right)$.

Dimostrazione

Passo 1 — a). $Q(-\infty)$ è l'area sotto tutta la campana, cioè 1; $Q(0)$ è metà dell'area, per la simmetria; $Q(+\infty)$ è l'area di una coda vuota.

Passo 2 — b). Si scrive $Q(x) = 1 - \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}} e^{-t^2/2}\,\mathrm{d}t$ e si deriva con il teorema fondamentale del calcolo integrale: la derivata della funzione integrale è l'integrando calcolato in x, con il segno meno. Spostando x a destra, la coda si accorcia.

Passo 3 — c). Per la parità della funzione integranda, la coda sinistra oltre $-x$ è uguale alla coda destra oltre x: $\int_{-\infty}^{-x} \frac{1}{\sqrt{2\pi}} e^{-t^2/2}\,\mathrm{d}t = \int_{x}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-t^2/2}\,\mathrm{d}t = Q(x)$. Quindi

$$Q(-x) = \int_{-x}^{+\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}\,\mathrm{d}t = 1 - \underbrace{\int_{-\infty}^{-x} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}\,\mathrm{d}t}_{Q(x)} = 1 - Q(x).$$

Passo 4 — d). È il teorema precedente: per una variabile continua $P(X \geq \eta) = P(X > \eta)$.

■

Grazie alla simmetria basta tabulare $Q(x)$ per $x \geq 0$. Ecco alcuni valori:

x	0	0,5	1	1,5	2	2,5	3	4
$Q(x)$	0,5	0,309	0,159	0,0668	0,0228	0,00621	0,00135	$3{,}17 \cdot 10^{-5}$

Teorema 15.6 — Una maggiorazione della funzione Q

Per ogni $x > 0$:

$$Q(x) < \frac{1}{x\sqrt{2\pi}} e^{-\frac{x^2}{2}},$$

e per x grande il secondo membro è anche una buona approssimazione: $Q(x) \simeq \frac{1}{x\sqrt{2\pi}} e^{-\frac{x^2}{2}}$. In particolare, per $x > \frac{1}{\sqrt{2\pi}} \approx 0{,}4$, $Q(x) < e^{-\frac{x^2}{2}}$.

Dimostrazione — lo stesso trucco della disuguaglianza di Markov

Passo 1 — Si moltiplica per un numero maggiore di 1. Nella coda $t > x > 0$, quindi $\frac{t}{x} > 1$:

$$Q(x) = \frac{1}{\sqrt{2\pi}} \int_x^\infty e^{-\frac{t^2}{2}}\, \mathrm{d}t < \frac{1}{\sqrt{2\pi}} \int_x^\infty \frac{t}{x}\, e^{-\frac{t^2}{2}}\, \mathrm{d}t.$$

Passo 2 — Ora la primitiva c'è. Come nell'integrale di Gauss, $t\, e^{-t^2/2}$ ha primitiva $-e^{-t^2/2}$:

$$\frac{1}{x\sqrt{2\pi}} \int_x^\infty t\, e^{-\frac{t^2}{2}}\, \mathrm{d}t = \frac{1}{x\sqrt{2\pi}} \left[-e^{-\frac{t^2}{2}} \right]_x^\infty = \frac{1}{x\sqrt{2\pi}}\, e^{-\frac{x^2}{2}}.$$

Passo 3 — Perché per x grande è anche un'approssimazione. Il fattore $\frac{t}{x}$ è vicino a 1 nella parte della coda che conta, appena oltre x; più in là la densità è trascurabile. Quindi la maggiorazione esagera di poco. Infine, se $x\sqrt{2\pi} > 1$, il fattore $\frac{1}{x\sqrt{2\pi}}$ è minore di 1.

■

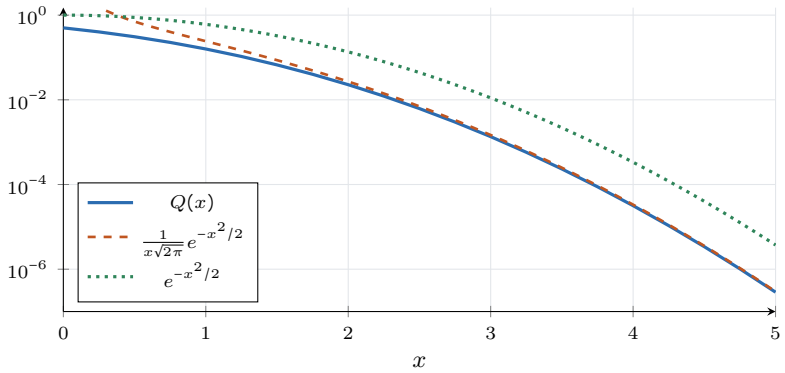


Figura 15.4: *La funzione Q in scala logaritmica (ogni tacca verticale è un fattore 10) e le due maggiorazioni. Da $x \approx 2$ in poi la prima è quasi indistinguibile da $Q(x)$; la seconda è più grossolana ma più semplice.*

La regola delle tre sigma

Quanto spesso una gaussiana si allontana dalla sua media di più di k deviazioni standard? Standardizzando e usando la simmetria (le due code sono uguali):

$$P(|X - \mu_X| > k\,\sigma_X) = P(|X_0| > k) = 2\,Q(k), \qquad P(|X - \mu_X| \le k\,\sigma_X) = 1 - 2\,Q(k).$$

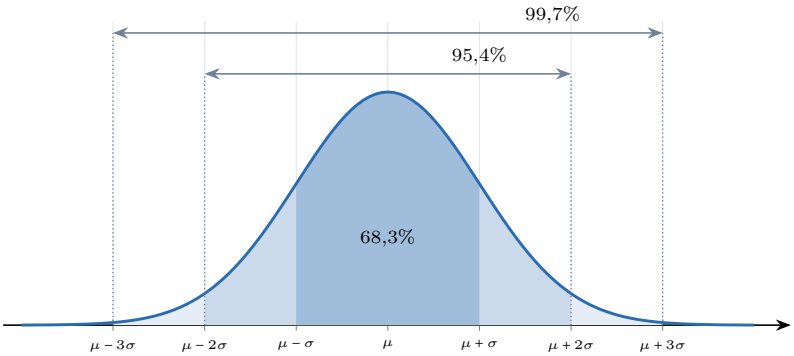


Figura 15.5: *La regola 68–95–99,7: le probabilità che una gaussiana cada entro una, due e tre deviazioni standard dalla media.*

k	1	2	3
$P(\lvert X - \mu_X\rvert \le k\sigma_X)$ per la gaussiana: $1 - 2Q(k)$	0,683	0,954	0,997
minimo garantito per qualsiasi densità (Chebyshev): $1 - \frac{1}{k^2}$	0	0,75	0,889

Una gaussiana esce dalla fascia $\mu \pm 3\sigma$ solo 3 volte su mille: in pratica, un valore a più di tre deviazioni standard dalla media è un evento eccezionale. Ma attenzione: vale per la gaussiana, non per ogni variabile (per una densità qualsiasi, Chebyshev garantisce solo l'89%).

UN'APPLICAZIONE: BIT SBAGLIATI PER COLPA DEL RUMORE

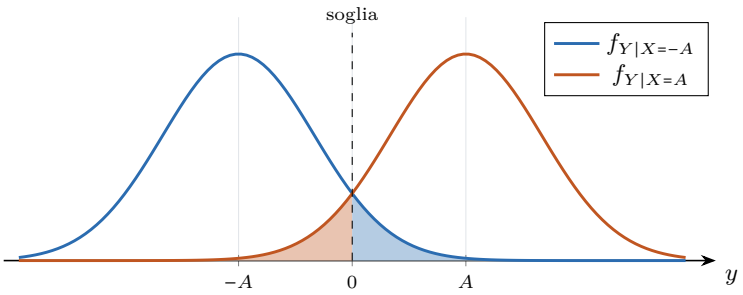
Esempio 15.1 — La probabilità di errore di una trasmissione binaria

Un trasmettitore invia un bit codificandolo come una tensione: $+A$ per l'1, $-A$ per lo 0, con i due bit equiprobabili. Il canale aggiunge un rumore gaussiano $N \sim \mathcal{N}(0, \sigma^2)$, indipendente dal bit, e il ricevitore osserva $Y = X + N$. Decide «1» se $Y > 0$ e «0» se $Y \le 0$. Con che probabilità sbaglia?

- Se è stato trasmesso l'1, $Y = A + N$: per la trasformazione lineare $Y \sim \mathcal{N}(A, \sigma^2)$. Il ricevitore sbaglia se $Y \le 0$:

$$P(\text{errore} \mid X = A) = P(A + N \le 0) = P(N \le -A) = P(N \ge A) = Q\left(\frac{A}{\sigma}\right),$$

  dove si è usata la simmetria del rumore (le code sono uguali) e la proprietà d) della funzione Q.
- Se è stato trasmesso lo 0, per simmetria l'errore ($Y > 0$) ha la stessa probabilità.
- Per la probabilità totale: $P_e = \frac{1}{2}Q\left(\frac{A}{\sigma}\right) + \frac{1}{2}Q\left(\frac{A}{\sigma}\right) = Q\left(\frac{A}{\sigma}\right)$.



Le due campane sono le densità di Y sapendo quale bit è stato trasmesso; le code colorate che oltrepassano la soglia sono gli errori. Più le campane sono lontane in rapporto alla loro larghezza, cioè più è grande $\frac{A}{\sigma}$, meno si sbaglia:

A/σ	1	2	3	4	5
$P_e = Q(A/\sigma)$	0,16	0,023	0,0013	$3{,}2 \cdot 10^{-5}$	$2{,}9 \cdot 10^{-7}$

Raddoppiare l'ampiezza da σ a 2σ divide gli errori per 7; passare da 2σ a 4σ li divide per 700: la coda gaussiana crolla come $e^{-x^2/2}$. Il rapporto A/σ è legato al *rapporto segnale-rumore*, e decidere nel modo migliore che cosa è stato trasmesso è il problema della teoria della decisione, che affronteremo nel terzo pacchetto di slide.

In sintesi

- **Gaussiana standard** $\mathcal{N}(0,1)$: $f(x) = \frac{1}{\sqrt{2\pi}}e^{-x^2/2}$; l'area 1 segue dall'integrale di Gauss $\int e^{-x^2/2} = \sqrt{2\pi}$ (in coordinate polari); media 0, varianza 1.
- **Gaussiana generica** $X = \sigma_X X_0 + \mu_X \sim \mathcal{N}(\mu_X, \sigma_X^2)$: $f_X(x) = \frac{1}{\sqrt{2\pi\sigma_X^2}}e^{-(x-\mu_X)^2/(2\sigma_X^2)}$, determinata da media e varianza; standardizzando, $\frac{X-\mu_X}{\sigma_X} \sim \mathcal{N}(0,1)$.
- **Funzione** Q: $Q(x) = P(X_0 > x)$, la coda della standard; $P(X > x) = Q\left(\frac{x-\mu_X}{\sigma_X}\right)$. È decrescente, $Q(0) = \frac{1}{2}$, $Q(-x) = 1 - Q(x)$, e $Q(x) < \frac{1}{x\sqrt{2\pi}}e^{-x^2/2}$ per $x > 0$.
- Regola 68–95–99,7: $P(|X - \mu| \le k\sigma) = 1 - 2Q(k)$.
- Trasmissione binaria $\pm A$ con rumore gaussiano: $P_e = Q(A/\sigma)$.

VETTORI ALEATORI E VETTORI GAUSSIANI

Nel Capitolo 14 abbiamo studiato coppie e m-ple di variabili continue. Quando le variabili diventano molte (i campioni di un segnale in istanti successivi, le tensioni su n antenne, i pixel di un'immagine) scrivere ogni media e ogni covarianza con i suoi indici diventa pesantissimo. L'algebra lineare offre un modo compatto per farlo: si raccolgono le variabili in un **vettore**, le loro medie in un altro vettore e le covarianze di tutte le coppie in una **matrice**, e le formule tornano corte come quelle di una sola variabile. Con questa notazione studieremo la famiglia più importante di tutte, i **vettori gaussiani**: n variabili gaussiane legate fra loro, descritte da una sola formula e con una proprietà preziosa: restano gaussiane quando passano attraverso un sistema lineare.

Come nelle slide, i vettori si indicano con una sottolineatura ($\underline{X}$, $\underline{x}$, $\underline{\mu}$) e le matrici con due ($\underline{\underline{A}}$, $\underline{\underline{C}}$).

VETTORI E MATRICI: IL MINIMO INDISPENSABILE

Per leggere questo capitolo bastano poche operazioni fra vettori e matrici. Le raccogliamo qui, partendo da zero; chi le conosce già può passare direttamente ai vettori aleatori.

Richiamo di matematica: vettori, matrici e trasposti

Un **vettore** di n numeri si scrive come una **colonna**:

$$\underline{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \qquad (n \times 1 : \ n \text{ righe e una colonna}).$$

Il suo **trasposto** $\underline{x}^T = [x_1, x_2, \ldots, x_n]$ contiene gli stessi numeri disposti in riga ($1 \times n$). Per risparmiare spazio, un vettore colonna si scrive spesso come il trasposto di una riga: $\underline{x} = [x_1, x_2, \ldots, x_n]^T$.
Una **matrice** $m \times n$ è una tabella di numeri con m righe e n colonne; l'elemento a_{ij} sta nella riga i e nella colonna j. La **trasposta** $\underline{\underline{A}}^T$ si ottiene scambiando le righe con le colonne: l'elemento di posto (i, j) di $\underline{\underline{A}}^T$ è a_{ji}. Per esempio

$$\underline{\underline{A}} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} (2 \times 3), \qquad \underline{\underline{A}}^T = \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix} (3 \times 2).$$

Una matrice quadrata ($n \times n$) è **simmetrica** se $\underline{\underline{A}}^T = \underline{\underline{A}}$, cioè se $a_{ij} = a_{ji}$: è uguale alla sua immagine allo specchio rispetto alla **diagonale principale**, quella che va dall'angolo in alto a sinistra all'angolo in basso a destra. È **diagonale** se tutti gli elementi fuori dalla diagonale principale sono nulli.

Richiamo di matematica: i prodotti «riga per colonna»

Tutti i prodotti fra matrici e vettori seguono una sola regola, **riga per colonna**: si prende una riga del primo fattore e una colonna del secondo, si moltiplicano gli elementi a due a due e si sommano i risultati.

- **Riga per colonna** (prodotto scalare): $\underline{x}^T \underline{y} = x_1 y_1 + x_2 y_2 + \cdots + x_n y_n$. Il risultato è un **numero** ($1 \times n$ per $n \times 1$ dà 1×1). Per esempio $\underline{x}^T \underline{x} = \sum_i x_i^2$ è il quadrato della lunghezza del vettore (per Pitagora).
- **Matrice per vettore**: $\underline{\underline{A}}\,\underline{x}$ è il vettore che ha per elemento i-esimo il prodotto della riga i di $\underline{\underline{A}}$ per $\underline{x}$: $(\underline{\underline{A}}\,\underline{x})_i = \sum_j a_{ij} x_j$. Ogni elemento del risultato è una **combinazione lineare** delle x_j (figura qui sotto).
- **Matrice per matrice**: l'elemento (i, j) di $\underline{\underline{A}}\,\underline{\underline{B}}$ è la riga i di $\underline{\underline{A}}$ per la colonna j di $\underline{\underline{B}}$. Le dimensioni «interne» devono coincidere e spariscono: $(m \times n)(n \times p) = m \times p$. Attenzione: in generale $\underline{\underline{A}}\,\underline{\underline{B}} \neq \underline{\underline{B}}\,\underline{\underline{A}}$, l'ordine dei fattori conta.
- **Colonna per riga**: $\underline{x}\,\underline{y}^T$ ($n \times 1$ per $1 \times n$) è una **matrice** $n \times n$, con elemento (i, j) uguale a $x_i y_j$. In particolare $\underline{x}\,\underline{x}^T$ contiene **tutti i prodotti a due a due** $x_i x_j$:

$$\underline{x}\,\underline{x}^T = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \begin{bmatrix} x_1, x_2 \end{bmatrix} = \begin{bmatrix} x_1^2 & x_1 x_2 \\ x_2 x_1 & x_2^2 \end{bmatrix}.$$

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} a_{11}x_1 + a_{12}x_2 + a_{13}x_3 \\ a_{21}x_1 + a_{22}x_2 + a_{23}x_3 \end{bmatrix}$$

$\underline{\underline{A}}$ (2×3) $\quad$ $\underline{x}$ (3×1) $\quad$ $\underline{\underline{A}}\,\underline{x}$ (2×1)

La seconda riga di $\underline{\underline{A}}$ per la colonna $\underline{x}$ dà il secondo elemento del risultato.

Il trasposto di un prodotto si ottiene trasponendo i fattori e **invertendone l'ordine**: $(\underline{\underline{A}}\,\underline{\underline{B}})^T = \underline{\underline{B}}^T \underline{\underline{A}}^T$. Il perché: l'elemento (i, j) di $(\underline{\underline{A}}\,\underline{\underline{B}})^T$ è l'elemento (j, i) di $\underline{\underline{A}}\,\underline{\underline{B}}$, cioè la riga j di $\underline{\underline{A}}$ per la colonna i di $\underline{\underline{B}}$; ma la colonna i di $\underline{\underline{B}}$ è la riga i di $\underline{\underline{B}}^T$, e la riga j di $\underline{\underline{A}}$ è la colonna j di $\underline{\underline{A}}^T$. Per esempio $(\underline{\underline{A}}\,\underline{x})^T = \underline{x}^T \underline{\underline{A}}^T$. Infine, un numero è uguale al suo trasposto, quindi $\underline{x}^T \underline{y} = (\underline{x}^T \underline{y})^T = \underline{y}^T \underline{x}$.

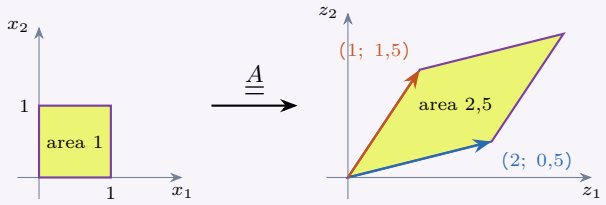
Richiamo di matematica: identità, inversa, determinante e forme quadratiche

Identità e inversa. La matrice **identità** $\underline{\underline{I}}$ ha 1 sulla diagonale principale e 0 altrove: per ogni vettore $\underline{\underline{I}}\,\underline{x} = \underline{x}$, come moltiplicare un numero per 1. L'**inversa** di una matrice quadrata $\underline{\underline{A}}$ è la matrice $\underline{\underline{A}}^{-1}$ tale che $\underline{\underline{A}}^{-1}\underline{\underline{A}} = \underline{\underline{A}}\,\underline{\underline{A}}^{-1} = \underline{\underline{I}}$: disfa quello che fa $\underline{\underline{A}}$, come $\frac{1}{a}$ disfa la moltiplicazione per a. Se $\underline{z} = \underline{\underline{A}}\,\underline{x}$, allora $\underline{x} = \underline{\underline{A}}^{-1}\underline{z}$. Per un prodotto l'ordine si inverte, come per il trasposto: $(\underline{\underline{A}}\,\underline{\underline{B}})^{-1} = \underline{\underline{B}}^{-1}\underline{\underline{A}}^{-1}$ (per disfare due operazioni si disfa prima l'ultima, come quando ci si toglie prima le scarpe e poi i calzini). Inoltre $(\underline{\underline{A}}^{T})^{-1} = (\underline{\underline{A}}^{-1})^{T}$.

Determinante. A ogni matrice quadrata si associa un numero, il **determinante**. Per una matrice 2×2:

$$\det \begin{bmatrix} a & b \\ c & d \end{bmatrix} = ad - bc, \qquad \begin{bmatrix} a & b \\ c & d \end{bmatrix}^{-1} = \frac{1}{ad-bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}$$

(per verificare la formula dell'inversa basta moltiplicare: si ottiene $\underline{\underline{I}}$). Il significato geometrico: $|\det \underline{\underline{A}}|$ è il **fattore per cui $\underline{\underline{A}}$ moltiplica le aree** (i volumi, in n dimensioni). La matrice è invertibile esattamente quando $\det \underline{\underline{A}} \neq 0$: se il determinante è nullo, $\underline{\underline{A}}$ schiaccia il piano su una retta e non si può più tornare indietro. Valgono $\det(\underline{\underline{A}}\,\underline{\underline{B}}) = \det \underline{\underline{A}} \cdot \det \underline{\underline{B}}$ (le due dilatazioni si susseguono) e $\det \underline{\underline{A}}^{T} = \det \underline{\underline{A}}$. Per una matrice diagonale tutto è facile: il determinante è il prodotto degli elementi della diagonale, e l'inversa si ottiene invertendoli uno per uno.



Con $\underline{\underline{A}} = \begin{bmatrix} 2 & 1 \\ 0{,}5 & 1{,}5 \end{bmatrix}$ il quadrato di lato 1 diventa il parallelogramma che ha per lati le colonne di $\underline{\underline{A}}$; la sua area è $\det \underline{\underline{A}} = 2 \cdot 1{,}5 - 1 \cdot 0{,}5 = 2{,}5$.

Forme quadratiche. Data una matrice quadrata $\underline{\underline{C}}$, il numero $\underline{q}^{T}\underline{\underline{C}}\,\underline{q} = \sum_i \sum_j q_i\, c_{ij}\, q_j$ si chiama **forma quadratica**: è un polinomio di secondo grado nelle q_i. Se $\underline{\underline{C}}$ è diagonale, $\underline{q}^{T}\underline{\underline{C}}\,\underline{q} = c_{11}q_1^2 + c_{22}q_2^2 + \cdots + c_{nn}q_n^2$: una somma di quadrati pesati.

VETTORI ALEATORI: MEDIE, CORRELAZIONI E COVARIANZE

Vettore aleatorio

Un **vettore aleatorio** n-dimensionale è la colonna di n variabili aleatorie

$$\underline{X} = [X_1, X_2, \ldots, X_n]^{T}.$$

La sua CDF e la sua PDF sono la CDF e la PDF congiunte delle n variabili, scritte in forma vettoriale: $F_{\underline{X}}(\underline{x}) = P(X_1 \leq x_1, \ldots, X_n \leq x_n)$ e $f_{\underline{X}}(\underline{x}) = f_{X_1 \cdots X_n}(x_1, \ldots, x_n)$, con $\underline{x} = [x_1, \ldots, x_n]^{T}$.

Niente di nuovo, quindi: $f_{\underline{X}}(\underline{x})$ è la densità congiunta del Capitolo 14 con n variabili, scritta in modo compatto. La novità è la caratterizzazione sintetica. La media di un vettore (o di una matrice) di variabili aleatorie si calcola **elemento per elemento**.

Vettore delle medie

Il **vettore valore medio** di $\underline{X}$ è il vettore colonna dei valori attesi delle n variabili:

$$\underline{\mu}_{\underline{X}} \triangleq E[\underline{X}] = [\mu_{X_1}, \mu_{X_2}, \ldots, \mu_{X_n}]^{T}.$$

Le medie da sole non dicono come le variabili sono legate fra loro. Per questo si considerano anche la correlazione e la covarianza di tutte le coppie (X_i, X_j) che si possono estrarre dal vettore, raccolte in una tabella $n \times n$, cioè in una matrice. Il modo per costruirla in un colpo solo è il prodotto colonna per riga $\underline{X}\,\underline{X}^{T}$, che contiene tutti i prodotti $X_i X_j$.

Matrice di correlazione

La **matrice di correlazione** del vettore $\underline{X}$ è la matrice $n \times n$

$$\underline{\underline{R}}_{\underline{X}} \triangleq E\left[\underline{X}\,\underline{X}^T\right] = \begin{bmatrix} R_{X_1X_1} & R_{X_1X_2} & \cdots & R_{X_1X_n} \\ R_{X_2X_1} & R_{X_2X_2} & \cdots & R_{X_2X_n} \\ \vdots & \vdots & \ddots & \vdots \\ R_{X_nX_1} & R_{X_nX_2} & \cdots & R_{X_nX_n} \end{bmatrix}, \qquad R_{X_iX_j} = E[X_iX_j].$$

È **simmetrica**, perché $E[X_iX_j] = E[X_jX_i]$, e sulla diagonale principale ci sono i **valori quadratici medi** delle variabili, perché $E[X_iX_i] = E[X_i^2]$.

Matrice di covarianza

La **matrice di covarianza** del vettore $\underline{X}$ è la matrice $n \times n$

$$\underline{\underline{C}}_{\underline{X}} \triangleq E\left[\left(\underline{X} - \underline{\mu}_{\underline{X}}\right)\left(\underline{X} - \underline{\mu}_{\underline{X}}\right)^T\right] = \begin{bmatrix} C_{X_1X_1} & C_{X_1X_2} & \cdots & C_{X_1X_n} \\ C_{X_2X_1} & C_{X_2X_2} & \cdots & C_{X_2X_n} \\ \vdots & \vdots & \ddots & \vdots \\ C_{X_nX_1} & C_{X_nX_2} & \cdots & C_{X_nX_n} \end{bmatrix}, \qquad C_{X_iX_j} = COV(X_i, X_j).$$

Anche questa è simmetrica, e l'elemento i-esimo della diagonale principale è $C_{X_iX_i} = E[(X_i - \mu_{X_i})(X_i - \mu_{X_i})] = \sigma^2_{X_i}$, la **varianza** di X_i. Fuori dalla diagonale ci sono le covarianze, che si possono scrivere con i coefficienti di correlazione: $C_{X_iX_j} = \rho_{X_iX_j}\,\sigma_{X_i}\sigma_{X_j}$. Per $n = 2$, scrivendo in breve $\sigma_i = \sigma_{X_i}$ e $\rho = \rho_{X_1X_2}$:

$$\underline{\underline{C}}_{\underline{X}} = \begin{bmatrix} \sigma_1^2 & \rho\,\sigma_1\sigma_2 \\ \rho\,\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix}.$$

Teorema 16.1 — Covarianza e correlazione

$$\underline{\underline{C}}_{\underline{X}} = \underline{\underline{R}}_{\underline{X}} - \underline{\mu}_{\underline{X}}\,\underline{\mu}_{\underline{X}}^T.$$

Dimostrazione — come nel Capitolo 9, ma tutto insieme

Passo 1 — Si sviluppa il prodotto. Scriviamo in breve $\underline{\mu}$ per $\underline{\mu}_{\underline{X}}$. Il prodotto fra matrici si sviluppa come quello fra numeri, facendo attenzione a non scambiare l'ordine dei fattori; inoltre $(\underline{X} - \underline{\mu})^T = \underline{X}^T - \underline{\mu}^T$:

$$(\underline{X} - \underline{\mu})(\underline{X} - \underline{\mu})^T = \underline{X}\,\underline{X}^T - \underline{X}\,\underline{\mu}^T - \underline{\mu}\,\underline{X}^T + \underline{\mu}\,\underline{\mu}^T.$$

Passo 2 — Si fa la media. La media è lineare e si fa elemento per elemento; $\underline{\mu}$ è costante ed esce dalla media: $E[\underline{X}\,\underline{\mu}^T] = E[\underline{X}]\,\underline{\mu}^T = \underline{\mu}\,\underline{\mu}^T$, e allo stesso modo $E[\underline{\mu}\,\underline{X}^T] = \underline{\mu}\,\underline{\mu}^T$. Quindi

$$\underline{\underline{C}}_{\underline{X}} = \underline{\underline{R}}_{\underline{X}} - \underline{\mu}\,\underline{\mu}^T - \underline{\mu}\,\underline{\mu}^T + \underline{\mu}\,\underline{\mu}^T = \underline{\underline{R}}_{\underline{X}} - \underline{\mu}\,\underline{\mu}^T.$$

Elemento per elemento è proprio la formula $COV(X_i, X_j) = E[X_iX_j] - \mu_{X_i}\mu_{X_j}$ del Capitolo 9. ■

Per una sola variabile la coppia media-varianza (μ_X, σ_X^2) riassume spesso le informazioni più importanti; per una coppia, la «cinquina» $(\mu_X, \sigma_X^2, \mu_Y, \sigma_Y^2, COV(X,Y))$. Per un vettore aleatorio lo stesso ruolo è svolto dal vettore delle medie $\underline{\mu}_{\underline{X}}$ insieme alla matrice di covarianza $\underline{\underline{C}}_{\underline{X}}$ (o a quella di correlazione $\underline{\underline{R}}_{\underline{X}}$, che per il Teorema 16.1 contiene la stessa informazione, noto $\underline{\mu}_{\underline{X}}$): è la **caratterizzazione statistica sintetica** del vettore. Per $n = 2$ si ritrova proprio la cinquina: due medie e, nella matrice 2×2 simmetrica, due varianze e una covarianza. In generale servono n medie e $\frac{n(n+1)}{2}$ elementi della matrice (la diagonale e il triangolo sopra di essa; quello sotto è uguale per simmetria).

La caratterizzazione sintetica è molto più povera di quella completa, la densità congiunta $f_{\underline{X}}$: dalla densità si calcolano medie e covarianze, ma in generale non si può tornare indietro, perché vettori con densità molto diverse possono avere le stesse medie e covarianze. Vedremo che per i vettori gaussiani, invece, si può.

Esempio 16.1 — Il vettore della densità $x + y$

Riprendiamo la coppia del Capitolo 14 (là si chiamavano X e Y), con densità $f_{\underline{X}}(\underline{x}) = x_1 + x_2$ sul quadrato $[0,1]^2$. Avevamo trovato $E[X_1] = E[X_2] = \frac{7}{12}$, $E[X_1^2] = E[X_2^2] = \frac{5}{12}$ e $E[X_1 X_2] = \frac{1}{3}$. Quindi

$$\underline{\mu}_{\underline{X}} = \begin{bmatrix} 7/12 \\ 7/12 \end{bmatrix}, \qquad \underline{\underline{R}}_{\underline{X}} = \begin{bmatrix} 5/12 & 1/3 \\ 1/3 & 5/12 \end{bmatrix} = \frac{1}{144}\begin{bmatrix} 60 & 48 \\ 48 & 60 \end{bmatrix}, \qquad \underline{\mu}_{\underline{X}}\underline{\mu}_{\underline{X}}^T = \frac{1}{144}\begin{bmatrix} 49 & 49 \\ 49 & 49 \end{bmatrix},$$

dove $\underline{\mu}_{\underline{X}}\underline{\mu}_{\underline{X}}^T$ è il prodotto colonna per riga, con tutti gli elementi uguali a $\frac{7}{12} \cdot \frac{7}{12} = \frac{49}{144}$. Per il Teorema 16.1

$$\underline{\underline{C}}_{\underline{X}} = \underline{\underline{R}}_{\underline{X}} - \underline{\mu}_{\underline{X}}\underline{\mu}_{\underline{X}}^T = \frac{1}{144}\begin{bmatrix} 11 & -1 \\ -1 & 11 \end{bmatrix}.$$

Sulla diagonale ci sono le varianze $\frac{11}{144}$, fuori la covarianza $-\frac{1}{144}$: gli stessi valori del Capitolo 14, ottenuti tutti insieme.

LA MATRICE DI COVARIANZA È SEMPRE DEFINITA NON NEGATIVA

Una varianza non può essere negativa. Per una matrice di covarianza vale qualcosa di più forte, che riguarda tutte le combinazioni lineari delle variabili del vettore.

Matrice definita non negativa

Una matrice quadrata $\underline{\underline{C}}$ di dimensioni $M \times M$ si dice **definita non negativa** se, per qualunque vettore $\underline{q} \in \mathbb{R}^M$ (cioè $M \times 1$),

$$\underline{q}^T \underline{\underline{C}}\, \underline{q} \geq 0.$$

Teorema 16.2 — La matrice di covarianza è definita non negativa

La matrice di covarianza $\underline{\underline{C}}_{\underline{X}}$ di qualunque vettore aleatorio $\underline{X}$ di dimensione M è definita non negativa: $\underline{q}^T \underline{\underline{C}}_{\underline{X}}\, \underline{q} \geq 0$ per ogni $\underline{q} \in \mathbb{R}^M$.

Dimostrazione — la forma quadratica è una varianza

Passo 1 — Una combinazione lineare. Fissato $\underline{q}$, la quantità $\underline{q}^T \underline{X} = q_1 X_1 + \cdots + q_M X_M$ è una variabile aleatoria scalare (riga per colonna dà un numero). Per la linearità della media, $E[\underline{q}^T \underline{X}] = \underline{q}^T \underline{\mu}_{\underline{X}}$.

Passo 2 — Il suo valore quadratico medio. Un numero è uguale al suo trasposto, quindi $\underline{q}^T \underline{X} = (\underline{q}^T \underline{X})^T = \underline{X}^T \underline{q}$ (trasposto di un prodotto, con l'ordine invertito). Allora

$$E[(\underline{q}^T \underline{X})^2] = E[(\underline{q}^T \underline{X})(\underline{X}^T \underline{q})] = E[\underline{q}^T \underline{X}\,\underline{X}^T \underline{q}] = \underline{q}^T E[\underline{X}\,\underline{X}^T]\,\underline{q},$$

dove $\underline{q}$, che è costante, esce dalla media.

Passo 3 — La varianza non è negativa.

$$0 \le \mathrm{VAR}(\underline{q}^T \underline{X}) = E[(\underline{q}^T \underline{X})^2] - \left(E[\underline{q}^T \underline{X}]\right)^2 = \underline{q}^T E[\underline{X}\,\underline{X}^T]\,\underline{q} - (\underline{q}^T \underline{\mu}_{\underline{X}})^2.$$

(Nella slide 77 manca il quadrato su $E[\underline{q}^T \underline{X}]$: la varianza è il valore quadratico medio meno il *quadrato* della media.)

Passo 4 — Anche il quadrato della media è una forma quadratica. Con lo stesso trucco del passo 2, $(\underline{q}^T \underline{\mu}_{\underline{X}})^2 = (\underline{q}^T \underline{\mu}_{\underline{X}})(\underline{\mu}_{\underline{X}}^T \underline{q}) = \underline{q}^T \underline{\mu}_{\underline{X}} \underline{\mu}_{\underline{X}}^T \underline{q}$. Raccogliendo $\underline{q}^T$ a sinistra e $\underline{q}$ a destra:

$$0 \le \underline{q}^T \left(E[\underline{X}\,\underline{X}^T] - \underline{\mu}_{\underline{X}} \underline{\mu}_{\underline{X}}^T \right) \underline{q} = \underline{q}^T \underline{\underline{C}}_{\underline{X}}\, \underline{q},$$

per il Teorema 16.1. E questo vale qualunque sia $\underline{q} \in \mathbb{R}^M$. ■

Il significato è semplice: $\underline{q}^T \underline{\underline{C}}_{\underline{X}} \underline{q}$ **è la varianza della combinazione lineare** $\underline{q}^T \underline{X}$, e una varianza non può essere negativa. Con $M = 2$, svolgendo i prodotti riga per colonna:

$$\underline{q}^T \underline{\underline{C}}_{\underline{X}} \underline{q} = [q_1, q_2] \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix} \begin{bmatrix} q_1 \\ q_2 \end{bmatrix} = [q_1, q_2] \begin{bmatrix} \sigma_1^2 q_1 + \rho\sigma_1\sigma_2 q_2 \\ \rho\sigma_1\sigma_2 q_1 + \sigma_2^2 q_2 \end{bmatrix} = q_1^2\sigma_1^2 + q_2^2\sigma_2^2 + 2q_1q_2\,\rho\,\sigma_1\sigma_2,$$

che è la formula della varianza di $q_1 X_1 + q_2 X_2$ del Capitolo 9 (Teorema 9.7).

Un vecchio risultato in veste nuova

Scegliendo $\underline{q} = [1/\sigma_1, \pm 1/\sigma_2]^T$ la forma quadratica vale $1 + 1 \pm 2\rho$, e la condizione ≥ 0 diventa $\rho \ge -1$ (con il segno $+$) e $\rho \le 1$ (con il segno $-$): è la dimostrazione di $|\rho| \le 1$ del Capitolo 9. La non negatività della matrice di covarianza generalizza quel risultato a M variabili: nessuna combinazione delle variabili può avere varianza negativa.

VETTORI GAUSSIANI

Si parte da n gaussiane indipendenti

Il punto di partenza è il caso più semplice: n variabili gaussiane statisticamente indipendenti, $X_i \sim \mathcal{N}(\mu_{X_i}, \sigma^2_{X_i})$. La loro densità congiunta si può scrivere in una forma che usa solo il vettore delle medie e la matrice di covarianza.

Teorema 16.3 — Densità di n gaussiane indipendenti

Se $X_1, \ldots, X_n$ sono gaussiane indipendenti, la densità congiunta del vettore $\underline{X} = [X_1, \ldots, X_n]^T$ è

$$f_{\underline{X}}(\underline{x}) = \frac{1}{\sqrt{(2\pi)^n \det \underline{\underline{C}}_{\underline{X}}}}\, e^{-\frac{1}{2}\left(\underline{x} - \underline{\mu}_{\underline{X}}\right)^T \underline{\underline{C}}_{\underline{X}}^{-1} \left(\underline{x} - \underline{\mu}_{\underline{X}}\right)}.$$

Dimostrazione

Passo 1 — Il prodotto delle marginali. Per l'indipendenza la densità congiunta è il prodotto delle densità:

$$f_{\underline{X}}(\underline{x}) = \prod_{i=1}^{n} f_{X_i}(x_i) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2_{X_i}}} e^{-\frac{(x_i-\mu_{X_i})^2}{2\sigma^2_{X_i}}} = \frac{1}{\sqrt{(2\pi)^n \prod_{i=1}^{n} \sigma^2_{X_i}}} e^{-\frac{1}{2}\sum_{i=1}^{n} \frac{(x_i-\mu_{X_i})^2}{\sigma^2_{X_i}}}.$$

Si sono usate due regole: il prodotto delle radici è la radice del prodotto ($\sqrt{a}\sqrt{b} = \sqrt{ab}$), e il prodotto di esponenziali è l'esponenziale della somma ($e^a e^b = e^{a+b}$).

Passo 2 — La matrice di covarianza è diagonale. Le variabili sono indipendenti, quindi incorrelate a due a due: tutte le covarianze fuori dalla diagonale sono nulle. Per una matrice diagonale determinante e inversa sono immediati:

$$\underline{\underline{C}}_{\underline{X}} = \begin{bmatrix} \sigma^2_{X_1} & 0 & \cdots & 0 \\ 0 & \sigma^2_{X_2} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma^2_{X_n} \end{bmatrix} \implies \det \underline{\underline{C}}_{\underline{X}} = \prod_{i=1}^{n} \sigma^2_{X_i}, \qquad \underline{\underline{C}}^{-1}_{\underline{X}} = \begin{bmatrix} 1/\sigma^2_{X_1} & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 1/\sigma^2_{X_n} \end{bmatrix}.$$

Il prodotto delle varianze sotto la radice è quindi $\det \underline{\underline{C}}_{\underline{X}}$.

Passo 3 — L'esponente è una forma quadratica. La somma all'esponente è una somma di quadrati pesati con i pesi $\frac{1}{\sigma^2_{X_i}}$, cioè la forma quadratica della matrice diagonale $\underline{\underline{C}}^{-1}_{\underline{X}}$ calcolata nel vettore $\underline{x} - \underline{\mu}_{\underline{X}}$:

$$\sum_{i=1}^{n} \frac{(x_i - \mu_{X_i})^2}{\sigma^2_{X_i}} = \left(\underline{x} - \underline{\mu}_{\underline{X}}\right)^T \underline{\underline{C}}^{-1}_{\underline{X}} \left(\underline{x} - \underline{\mu}_{\underline{X}}\right).$$

■

La definizione generale

La formula appena trovata non contiene più le singole variabili: solo $\underline{\mu}_{\underline{X}}$ e $\underline{\underline{C}}_{\underline{X}}$. L'idea è usarla anche quando la matrice di covarianza **non** è diagonale.

Vettore gaussiano

Un vettore aleatorio $\underline{X}$ si dice **gaussiano**, e si scrive $\underline{X} \sim \mathcal{N}(\underline{\mu}_{\underline{X}}, \underline{\underline{C}}_{\underline{X}})$, quando la sua densità congiunta ha la forma

$$f_{\underline{X}}(\underline{x}) = \frac{1}{\sqrt{(2\pi)^n \det \underline{\underline{C}}_{\underline{X}}}} e^{-\frac{1}{2}\left(\underline{x}-\underline{\mu}_{\underline{X}}\right)^T \underline{\underline{C}}^{-1}_{\underline{X}} \left(\underline{x}-\underline{\mu}_{\underline{X}}\right)},$$

anche se le componenti non sono indipendenti, cioè anche se $\underline{\underline{C}}_{\underline{X}}$ non è diagonale. Equivalentemente, n variabili aleatorie con una densità congiunta di questa forma si dicono **congiuntamente gaussiane**.

Perché la formula abbia senso, $\underline{\underline{C}}_{\underline{X}}$ deve essere invertibile ($\det \underline{\underline{C}}_{\underline{X}} \neq 0$; per il Teorema 16.2, anzi, $\det \underline{\underline{C}}_{\underline{X}} > 0$). È la naturale generalizzazione della densità di una gaussiana: con $n = 1$ la matrice di covarianza è il numero σ^2_X, il suo determinante è σ^2_X e la sua inversa è $\frac{1}{\sigma^2_X}$, e la formula ridà $\frac{1}{\sqrt{2\pi\sigma^2_X}} e^{-\frac{(x-\mu_X)^2}{2\sigma^2_X}}$.

	una variabile, $\mathcal{N}(\mu_X, \sigma^2_X)$	vettore di n variabili, $\mathcal{N}(\underline{\mu}_{\underline{X}}, \underline{\underline{C}}_{\underline{X}})$
centro	μ_X	$\underline{\mu}_{\underline{X}}$
larghezza	σ^2_X	$\underline{\underline{C}}_{\underline{X}}$
costante davanti	$\frac{1}{\sqrt{2\pi\,\sigma^2_X}}$	$\frac{1}{\sqrt{(2\pi)^n \det \underline{\underline{C}}_{\underline{X}}}}$
esponente	$-\frac{1}{2}(x-\mu_X)\frac{1}{\sigma^2_X}(x-\mu_X)$	$-\frac{1}{2}(\underline{x}-\underline{\mu}_{\underline{X}})^T \underline{\underline{C}}^{-1}_{\underline{X}} (\underline{x}-\underline{\mu}_{\underline{X}})$

La forma quadratica all'esponente misura quanto $\underline{x}$ è lontano dal centro $\underline{\mu}_{\underline{X}}$, tenendo conto delle larghezze e delle correlazioni: è il quadrato di una «distanza», e la densità è tanto più alta quanto più $\underline{x}$ è vicino al centro. I punti alla stessa distanza, cioè con la stessa densità, formano delle **ellissi** (in tre dimensioni, degli ellissoidi).

Il caso di due variabili

Con $n = 2$, $\underline{\mu}_{\underline{X}} = [\mu_1, \mu_2]^T$ e la matrice di covarianza scritta con il coefficiente di correlazione, la formula dell'inversa 2×2 del richiamo dà

$$\underline{\underline{C}}_{\underline{X}} = \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix}, \quad \det \underline{\underline{C}}_{\underline{X}} = \sigma_1^2\sigma_2^2(1-\rho^2), \quad \underline{\underline{C}}_{\underline{X}}^{-1} = \frac{1}{\sigma_1^2\sigma_2^2(1-\rho^2)} \begin{bmatrix} \sigma_2^2 & -\rho\sigma_1\sigma_2 \\ -\rho\sigma_1\sigma_2 & \sigma_1^2 \end{bmatrix}.$$

Svolgendo i prodotti all'esponente (come per la forma quadratica della sezione precedente) si ottiene la **gaussiana bivariata**:

$$f_{X_1X_2}(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left\{ -\frac{1}{2(1-\rho^2)} \left[\frac{(x_1-\mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2} \right] \right\},$$

dove $\exp\{a\}$ è un altro modo di scrivere e^a, comodo quando l'esponente è lungo. Serve $|\rho| < 1$: con $\rho = \pm 1$ il determinante si annulla, la matrice non è invertibile e le due variabili sono legate da una relazione lineare esatta (tutta la probabilità sta su una retta, e una densità nel piano non esiste).

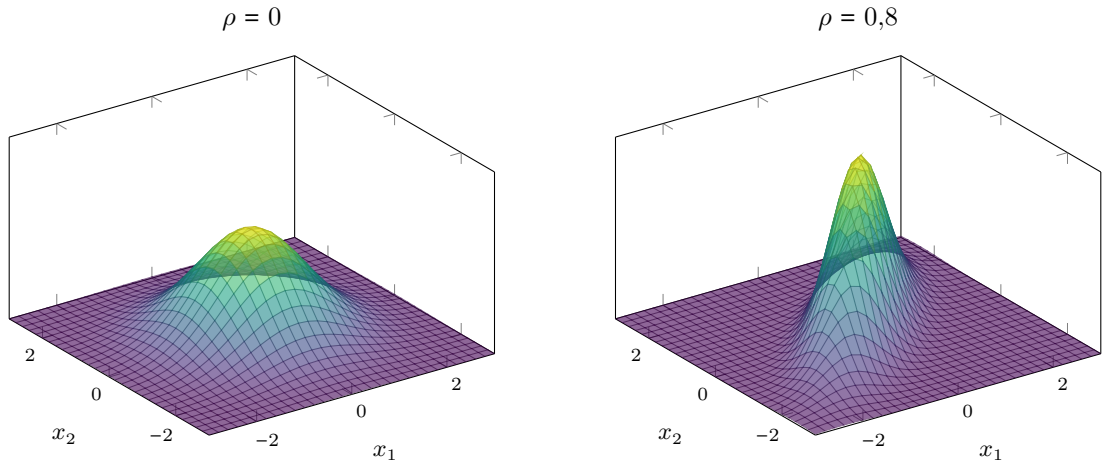


Figura 16.1: *La gaussiana bivariata con $\mu_1 = \mu_2 = 0$ e $\sigma_1 = \sigma_2 = 1$. Con $\rho = 0$ la campana è rotonda; con $\rho = 0{,}8$ è allungata lungo la bisettrice $x_2 = x_1$, e più alta, perché il volume sotto la superficie resta 1.*

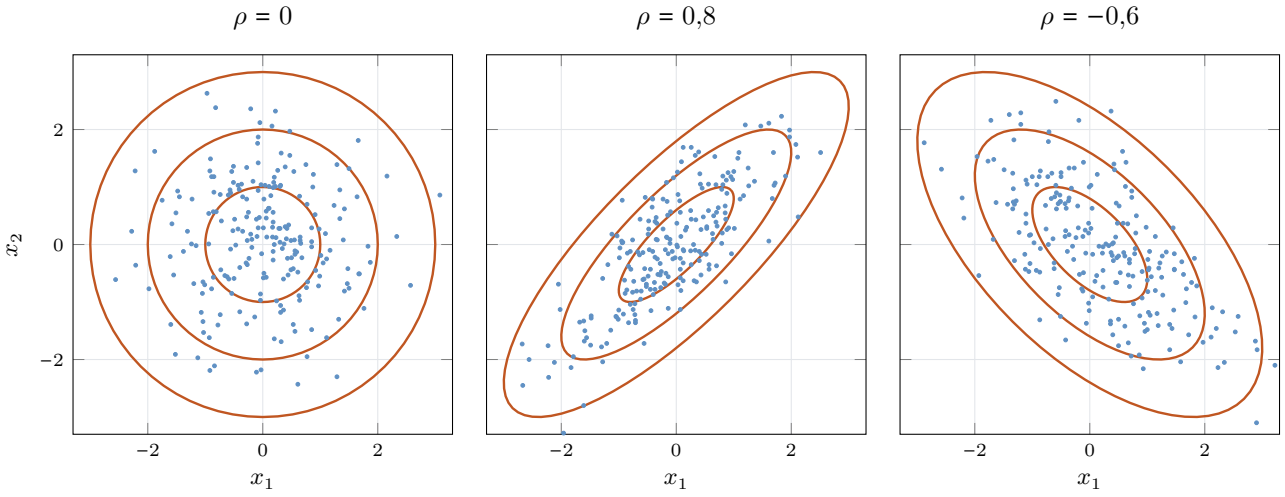


Figura 16.2: *220 punti estratti da tre gaussiane bivariate con medie nulle e varianze unitarie (simulazione), e le ellissi di uguale densità su cui la forma quadratica vale 1, 4 e 9. Con $\rho = 0$ sono circonferenze; con $\rho > 0$ si allungano lungo $x_2 = x_1$, con $\rho < 0$ lungo $x_2 = -x_1$.*

Qualunque sia ρ, le tre ellissi racchiudono una probabilità del 39%, dell'86% e del 99%: con soli 220 punti le percentuali dei pannelli si avvicinano a questi valori, senza coincidere. Per $\rho = 0$ lo si verifica con le coordinate polari, come nell'integrale di Gauss del Capitolo 15: la probabilità di cadere nel cerchio di raggio k è $\int_0^{2\pi}\int_0^k \frac{1}{2\pi} e^{-r^2/2}\, r\, \mathrm{d}r\, \mathrm{d}\theta = 1 - e^{-k^2/2}$, che per $k = 1, 2, 3$ vale 0,39, 0,86 e 0,99.

Incorrelazione e indipendenza

Nel Capitolo 9 abbiamo visto che due variabili indipendenti sono sempre incorrelate, ma che il viceversa in generale è falso. Per le variabili congiuntamente gaussiane, invece, le due cose coincidono.

Teorema 16.4 — Per le congiuntamente gaussiane, incorrelate vuol dire indipendenti

Se $X_1, \dots, X_n$ sono congiuntamente gaussiane e incorrelate a due a due, allora sono statisticamente indipendenti.

Dimostrazione

Passo 1 — La matrice è diagonale. Se le variabili sono incorrelate, tutte le covarianze fuori dalla diagonale sono nulle e $\underline{\underline{C}}_{\underline{X}}$ è diagonale.

Passo 2 — Si legge al contrario il Teorema 16.3. Con una matrice diagonale la forma quadratica è una somma di quadrati e il determinante è un prodotto di varianze; ripercorrendo all'indietro i passaggi di quella dimostrazione, la densità si spezza in un prodotto:

$$f_{\underline{X}}(\underline{x}) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma_{X_i}^2}}\, e^{-\frac{(x_i-\mu_{X_i})^2}{2\sigma_{X_i}^2}}.$$

Passo 3 — I fattori sono le marginali. Integrando rispetto a tutte le variabili tranne x_i, ogni altro fattore (una densità gaussiana, con area 1) dà 1: resta $f_{X_i}(x_i)$, che è quindi proprio l'i-esimo fattore. La densità congiunta è il prodotto delle marginali, cioè le variabili sono indipendenti.

■

Gaussiane una per una non basta

Il teorema richiede che le variabili siano *congiuntamente* gaussiane, non solo gaussiane una per una. Sia $X_1 \sim \mathcal{N}(0,1)$ e sia $X_2 = S\,X_1$, dove S vale $+1$ o -1 con probabilità $\frac{1}{2}$, indipendente da X_1. Anche X_2 è $\mathcal{N}(0,1)$: cambiare segno a caso a una campana simmetrica la lascia com'è. Le due variabili sono incorrelate, perché $E[X_1X_2] = E[S]\,E[X_1^2] = 0 \cdot 1 = 0$; eppure sono fortemente dipendenti, perché $|X_2| = |X_1|$ sempre. Il vettore $[X_1, X_2]^T$ non è gaussiano: i suoi punti stanno tutti sulle due bisettrici $x_2 = \pm x_1$, mentre la densità di un vettore gaussiano con $|\rho| < 1$ è positiva in tutto il piano.

Marginali e condizionate: si completa il quadrato

Le slide affermano che le marginali e le condizionate di un vettore gaussiano sono ancora gaussiane. Per due variabili lo si può verificare con un calcolo elementare. Prendiamo il caso standardizzato, $\mu_1 = \mu_2 = 0$ e $\sigma_1 = \sigma_2 = 1$ (quello generale si riconduce a questo standardizzando le due variabili), in cui

$$f_{X_1X_2}(x_1, x_2) = \frac{1}{2\pi\sqrt{1-\rho^2}}\, e^{-\frac{x_1^2 - 2\rho x_1 x_2 + x_2^2}{2(1-\rho^2)}}.$$

Teorema 16.5 — Marginale e condizionata della gaussiana bivariata

Nel caso standardizzato:

a) la marginale è una gaussiana standard: $X_1 \sim \mathcal{N}(0,1)$, e lo stesso vale per X_2;
b) la condizionata è gaussiana: sapendo che $X_1 = x_1$, si ha $X_2 \sim \mathcal{N}(\rho x_1,\, 1-\rho^2)$, cioè

$$f_{X_2|X_1}(x_2 \mid x_1) = \frac{1}{\sqrt{2\pi(1-\rho^2)}}\, e^{-\frac{(x_2-\rho x_1)^2}{2(1-\rho^2)}}.$$

Dimostrazione — completando il quadrato

Passo 1 — Il quadrato. Come quando si risolve un'equazione di secondo grado, si raccolgono i termini che contengono x_2 in un quadrato perfetto. Siccome $(x_2 - \rho x_1)^2 = x_2^2 - 2\rho x_1 x_2 + \rho^2 x_1^2$, basta aggiungere e togliere $\rho^2 x_1^2$:

$$x_1^2 - 2\rho x_1 x_2 + x_2^2 = (x_2 - \rho x_1)^2 + x_1^2 - \rho^2 x_1^2 = (x_2 - \rho x_1)^2 + (1 - \rho^2)\, x_1^2.$$

Passo 2 — La densità si spezza in due fattori. Dividendo per $2(1-\rho^2)$, l'esponente diventa $-\frac{(x_2-\rho x_1)^2}{2(1-\rho^2)} - \frac{x_1^2}{2}$; inoltre $2\pi\sqrt{1-\rho^2} = \sqrt{2\pi}\cdot\sqrt{2\pi(1-\rho^2)}$. Quindi

$$f_{X_1X_2}(x_1,x_2) = \underbrace{\frac{1}{\sqrt{2\pi}}\, e^{-\frac{x_1^2}{2}}}_{\mathcal{N}(0,1)\text{ in } x_1} \cdot \underbrace{\frac{1}{\sqrt{2\pi(1-\rho^2)}}\, e^{-\frac{(x_2-\rho x_1)^2}{2(1-\rho^2)}}}_{\mathcal{N}(\rho x_1,\, 1-\rho^2)\text{ in } x_2}.$$

Passo 3 — La marginale. Per marginalizzare si integra rispetto a x_2. Il primo fattore non dipende da x_2 ed esce dall'integrale; il secondo, come funzione di x_2, è una densità gaussiana (di media ρx_1), quindi ha area 1:

$$f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1X_2}(x_1,x_2)\,\mathrm{d}x_2 = \frac{1}{\sqrt{2\pi}}\, e^{-\frac{x_1^2}{2}} \cdot 1.$$

Per X_2 si ripete il calcolo scambiando i ruoli: l'espressione è simmetrica in x_1 e x_2.

Passo 4 — La condizionata. Per definizione $f_{X_2|X_1}(x_2 \mid x_1) = \frac{f_{X_1X_2}(x_1,x_2)}{f_{X_1}(x_1)}$: dividendo per il primo fattore resta il secondo.

■

La densità condizionata dice due cose. La **media condizionata** $E[X_2 \mid X_1 = x_1] = \rho x_1$ è una retta: sapendo che X_1 è grande, ci si aspetta che anche X_2 lo sia (se $\rho > 0$), ma un po' meno, perché $|\rho| < 1$. La **varianza condizionata** $1 - \rho^2$ è più piccola della varianza 1 di X_2 e non dipende da x_1: conoscere X_1 riduce l'incertezza su X_2, tanto più quanto più $|\rho|$ è vicino a 1. Con $\rho = 0$ la condizionata coincide con la marginale: conoscere X_1 non serve a niente, come deve essere per variabili indipendenti.

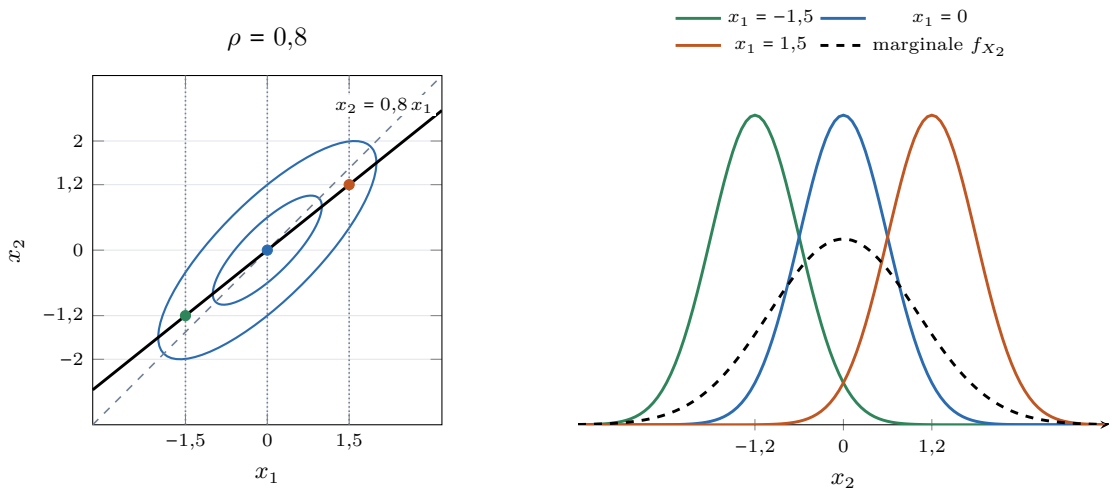


Figura 16.3: *A sinistra: le ellissi della gaussiana bivariata con $\rho = 0{,}8$ e la retta delle medie condizionate $x_2 = 0{,}8\,x_1$ (tratteggiata la bisettrice). A destra: le densità condizionate $f_{X_2|X_1}(x_2 \mid x_1)$ per tre valori di x_1, tutte con varianza $1 - 0{,}8^2 = 0{,}36$ e centrate sulla retta, e la marginale $\mathcal{N}(0,1)$, più larga.*

Le proprietà dei vettori gaussiani

Le slide elencano le proprietà che rendono i vettori gaussiani così comodi.

1. **Bastano medie e covarianze.** Un vettore gaussiano è completamente caratterizzato dal vettore delle medie e dalla matrice di covarianza: nella formula della densità non compare nient'altro. Per i vettori gaussiani, quindi, la caratterizzazione sintetica implica quella completa; in generale è vero solo il contrario (dalla densità si ricavano medie e covarianze, ma non viceversa).
2. **Chiusura rispetto alle trasformazioni lineari.** Qualsiasi trasformazione lineare di un vettore gaussiano è ancora un vettore gaussiano, con opportuno vettore delle medie e opportuna matrice di covarianza.

3. **Calcoli facili.** Le medie e le covarianze dell'uscita di una trasformazione lineare si calcolano con due formule semplici (le vediamo nella prossima sezione); grazie alla proprietà 2, per un vettore gaussiano questo dà la caratterizzazione completa dell'uscita. Per vettori non gaussiani si ottiene con la stessa facilità solo la caratterizzazione sintetica, mentre quella completa è spesso enormemente complicata.
4. **Sottoinsiemi.** Un qualsiasi sottoinsieme di variabili congiuntamente gaussiane è ancora un vettore gaussiano. In particolare ogni singola componente X_i è gaussiana, con media μ_{X_i} e varianza $\sigma^2_{X_i}$ (per due variabili lo abbiamo appena dimostrato).
5. **Condizionamenti.** La densità di un sottoinsieme di variabili congiuntamente gaussiane, condizionata a un qualsiasi sottoinsieme delle rimanenti, è ancora gaussiana, con opportune medie e covarianze condizionate (per due variabili: $\mathcal{N}(\rho x_1, 1-\rho^2)$).
6. **Incorrelazione e indipendenza coincidono** (Teorema 16.4).

TRASFORMAZIONI LINEARI DI VETTORI GAUSSIANI

Cominciamo dal caso più semplice: una combinazione lineare di due variabili.

Teorema 16.6 — Combinazione lineare di due variabili congiuntamente gaussiane

Siano X_1 e X_2 congiuntamente gaussiane, con medie μ_1 e μ_2, varianze σ_1^2 e σ_2^2 e coefficiente di correlazione ρ_{12}, e sia $Z = a_1X_1 + a_2X_2$. Allora $Z \sim \mathcal{N}(\mu_Z, \sigma_Z^2)$, con

$$\mu_Z = a_1\mu_1 + a_2\mu_2, \qquad \sigma_Z^2 = a_1^2\sigma_1^2 + a_2^2\sigma_2^2 + 2a_1a_2\,\sigma_1\sigma_2\,\rho_{12}.$$

Dimostrazione

Passo 1 — La media. Per la linearità della media: $\mu_Z = E[a_1X_1 + a_2X_2] = a_1\mu_1 + a_2\mu_2$.

Passo 2 — La varianza. Si raccolgono gli scarti dalla media e si sviluppa il quadrato del binomio:

$$\begin{aligned}\sigma_Z^2 &= E[(Z-\mu_Z)^2] = E\left[(a_1X_1 + a_2X_2 - a_1\mu_1 - a_2\mu_2)^2\right] = E\left[(a_1(X_1-\mu_1) + a_2(X_2-\mu_2))^2\right] \\ &= E\left[a_1^2(X_1-\mu_1)^2 + a_2^2(X_2-\mu_2)^2 + 2a_1a_2(X_1-\mu_1)(X_2-\mu_2)\right] \\ &= a_1^2\sigma_1^2 + a_2^2\sigma_2^2 + 2a_1a_2\,COV(X_1,X_2) = a_1^2\sigma_1^2 + a_2^2\sigma_2^2 + 2a_1a_2\,\sigma_1\sigma_2\,\rho_{12}.\end{aligned}$$

Fin qui non si è usato nulla di gaussiano: sono le formule del Capitolo 9, valide per qualsiasi coppia.

Passo 3 — La gaussianità. Che Z sia gaussiana è la proprietà di chiusura; la dimostriamo alla fine della sezione, come conseguenza del teorema seguente.

■

Il caso generale è una trasformazione lineare qualsiasi: m combinazioni lineari delle n variabili, più delle costanti.

Teorema 16.7 — Trasformazione lineare di un vettore gaussiano

Sia $\underline{X} \sim \mathcal{N}(\underline{\mu}_{\underline{X}}, \underline{\underline{C}}_{\underline{X}})$ un vettore gaussiano $n \times 1$, e sia

$$\underbrace{\underline{Z}}_{m\times 1} = \underbrace{\underline{\underline{A}}}_{m\times n}\,\underbrace{\underline{X}}_{n\times 1} + \underbrace{\underline{b}}_{m\times 1},$$

con $\underline{\underline{A}}$ e $\underline{b}$ costanti. Allora $\underline{Z} \sim \mathcal{N}(\underline{\mu}_{\underline{Z}}, \underline{\underline{C}}_{\underline{Z}})$, con

$$\underbrace{\underline{\mu}_{\underline{Z}}}_{m\times 1} = \underbrace{\underline{\underline{A}}}_{m\times n}\,\underbrace{\underline{\mu}_{\underline{X}}}_{n\times 1} + \underbrace{\underline{b}}_{m\times 1}, \qquad \underbrace{\underline{\underline{C}}_{\underline{Z}}}_{m\times m} = \underbrace{\underline{\underline{A}}}_{m\times n}\,\underbrace{\underline{\underline{C}}_{\underline{X}}}_{n\times n}\,\underbrace{\underline{\underline{A}}^T}_{n\times m}.$$

Le formule per $\underline{\mu}_{\underline{Z}}$ e $\underline{\underline{C}}_{\underline{Z}}$ valgono per qualsiasi vettore aleatorio $\underline{X}$, gaussiano o no.

Dimostrazione

Passo 1 — La media. Ogni componente di $\underline{Z}$ è una combinazione lineare delle X_j più una costante, $Z_i = \sum_j a_{ij} X_j + b_i$. Per la linearità della media $E[Z_i] = \sum_j a_{ij}\mu_{X_j} + b_i$, cioè $\underline{\mu}_{\underline{Z}} = \underline{\underline{A}}\,\underline{\mu}_{\underline{X}} + \underline{b}$.

Passo 2 — Lo scarto dalla media. La costante $\underline{b}$ si cancella: $\underline{Z} - \underline{\mu}_{\underline{Z}} = \underline{\underline{A}}\,\underline{X} + \underline{b} - \underline{\underline{A}}\,\underline{\mu}_{\underline{X}} - \underline{b} = \underline{\underline{A}}(\underline{X} - \underline{\mu}_{\underline{X}})$.

Passo 3 — La covarianza. Per il trasposto di un prodotto, $\left(\underline{\underline{A}}(\underline{X} - \underline{\mu}_{\underline{X}})\right)^T = (\underline{X} - \underline{\mu}_{\underline{X}})^T \underline{\underline{A}}^T$, e le matrici costanti escono dalla media (una a sinistra e una a destra):

$$\underline{\underline{C}}_{\underline{Z}} = E\left[(\underline{Z} - \underline{\mu}_{\underline{Z}})(\underline{Z} - \underline{\mu}_{\underline{Z}})^T\right] = E\left[\underline{\underline{A}}(\underline{X} - \underline{\mu}_{\underline{X}})(\underline{X} - \underline{\mu}_{\underline{X}})^T \underline{\underline{A}}^T\right] = \underline{\underline{A}}\, E\left[(\underline{X} - \underline{\mu}_{\underline{X}})(\underline{X} - \underline{\mu}_{\underline{X}})^T\right] \underline{\underline{A}}^T = \underline{\underline{A}}\,\underline{\underline{C}}_{\underline{X}}\,\underline{\underline{A}}^T.$$

Passo 4 — La gaussianità, con $m = n$ e $\underline{\underline{A}}$ invertibile. Si ragiona come per $Y = aX + b$ nel Capitolo 12. Ogni $\underline{z}$ viene da un solo $\underline{x} = \underline{\underline{A}}^{-1}(\underline{z} - \underline{b})$. Una scatolina attorno a $\underline{x}$ viene trasformata in una scatolina attorno a $\underline{z}$ con volume $|\det \underline{\underline{A}}|$ volte più grande (richiamo), che contiene la stessa probabilità; quindi la densità, che è una probabilità per unità di volume, si divide per $|\det \underline{\underline{A}}|$:

$$f_{\underline{Z}}(\underline{z}) = \frac{1}{|\det \underline{\underline{A}}|}\, f_{\underline{X}}\left(\underline{\underline{A}}^{-1}(\underline{z} - \underline{b})\right).$$

Nell'esponente compare $\underline{x} - \underline{\mu}_{\underline{X}} = \underline{\underline{A}}^{-1}(\underline{z} - \underline{b}) - \underline{\underline{A}}^{-1}\underline{\underline{A}}\,\underline{\mu}_{\underline{X}} = \underline{\underline{A}}^{-1}(\underline{z} - \underline{\mu}_{\underline{Z}})$, e la forma quadratica diventa

$$(\underline{z} - \underline{\mu}_{\underline{Z}})^T (\underline{\underline{A}}^{-1})^T \underline{\underline{C}}_{\underline{X}}^{-1} \underline{\underline{A}}^{-1}(\underline{z} - \underline{\mu}_{\underline{Z}}) = (\underline{z} - \underline{\mu}_{\underline{Z}})^T \left(\underline{\underline{A}}\,\underline{\underline{C}}_{\underline{X}}\,\underline{\underline{A}}^T\right)^{-1} (\underline{z} - \underline{\mu}_{\underline{Z}}) = (\underline{z} - \underline{\mu}_{\underline{Z}})^T \underline{\underline{C}}_{\underline{Z}}^{-1}(\underline{z} - \underline{\mu}_{\underline{Z}}),$$

perché l'inversa di un prodotto è il prodotto delle inverse in ordine inverso: $(\underline{\underline{A}}\,\underline{\underline{C}}_{\underline{X}}\,\underline{\underline{A}}^T)^{-1} = (\underline{\underline{A}}^T)^{-1}\underline{\underline{C}}_{\underline{X}}^{-1}\underline{\underline{A}}^{-1}$. Infine $\det \underline{\underline{C}}_{\underline{Z}} = \det \underline{\underline{A}} \cdot \det \underline{\underline{C}}_{\underline{X}} \cdot \det \underline{\underline{A}}^T = (\det \underline{\underline{A}})^2 \det \underline{\underline{C}}_{\underline{X}}$, quindi $|\det \underline{\underline{A}}|\sqrt{(2\pi)^n \det \underline{\underline{C}}_{\underline{X}}} = \sqrt{(2\pi)^n \det \underline{\underline{C}}_{\underline{Z}}}$. Mettendo insieme, $f_{\underline{Z}}$ ha proprio la forma gaussiana, con media $\underline{\mu}_{\underline{Z}}$ e covarianza $\underline{\underline{C}}_{\underline{Z}}$.

Passo 5 — Meno uscite che ingressi ($m < n$). Si aggiungono ad $\underline{\underline{A}}$ delle righe in modo da renderla quadrata e invertibile: il vettore allungato è gaussiano per il passo precedente, e $\underline{Z}$, che ne è un sottoinsieme, è gaussiano per la proprietà dei sottoinsiemi. (Se invece $m > n$, o $\underline{\underline{A}}$ non è invertibile, si trova $\det \underline{\underline{C}}_{\underline{Z}} = 0$: il vettore $\underline{Z}$ sta tutto su una retta o su un piano e una densità non si può scrivere. È un caso «degenere» che non ci servirà.)

■

Ora possiamo completare la dimostrazione del Teorema 16.6. La combinazione $Z = a_1 X_1 + a_2 X_2$ è il caso $m = 1$, $n = 2$, $\underline{\underline{A}} = [a_1, a_2]$, $\underline{b} = 0$, e la formula della covarianza ridà la varianza (è la forma quadratica della sezione precedente):

$$\sigma_Z^2 = [a_1, a_2] \begin{bmatrix} \sigma_1^2 & \rho_{12}\sigma_1\sigma_2 \\ \rho_{12}\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix} \begin{bmatrix} a_1 \\ a_2 \end{bmatrix} = a_1^2\sigma_1^2 + a_2^2\sigma_2^2 + 2a_1a_2\,\sigma_1\sigma_2\,\rho_{12}.$$

Per la gaussianità, se $a_1 \neq 0$ si aggiunge la riga $[0, 1]$, che rende la matrice quadrata e invertibile:

$$\begin{bmatrix} Z \\ X_2 \end{bmatrix} = \begin{bmatrix} a_1 & a_2 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}, \qquad \det \begin{bmatrix} a_1 & a_2 \\ 0 & 1 \end{bmatrix} = a_1 \cdot 1 - a_2 \cdot 0 = a_1 \neq 0.$$

Il vettore $[Z, X_2]^T$ è gaussiano (passo 4) e quindi Z, che ne è una componente, è gaussiana (lo garantisce il Teorema 16.5, dopo aver standardizzato). Se $a_1 = 0$, $Z = a_2 X_2$ è una gaussiana moltiplicata per una costante, che è gaussiana per il Capitolo 15.

Esempio 16.2 — Somma e differenza di due rumori indipendenti

Due campioni di rumore X_1 e X_2 sono gaussiani indipendenti, entrambi $\mathcal{N}(0, \sigma^2)$: il vettore $\underline{X}$ è gaussiano con $\underline{\mu}_{\underline{X}} = \underline{0}$ e $\underline{\underline{C}}_{\underline{X}} = \sigma^2 \underline{\underline{I}}$. Calcoliamo somma e differenza:

$$\underline{Z} = \begin{bmatrix} X_1 + X_2 \\ X_1 - X_2 \end{bmatrix} = \underbrace{\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}}_{\underline{\underline{A}}} \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}, \qquad \underline{\underline{C}}_{\underline{Z}} = \underline{\underline{A}} \, (\sigma^2 \underline{\underline{I}}) \, \underline{\underline{A}}^T = \sigma^2 \underline{\underline{A}} \, \underline{\underline{A}}^T = \sigma^2 \begin{bmatrix} 1 \cdot 1 + 1 \cdot 1 & 1 \cdot 1 + 1 \cdot (-1) \\ 1 \cdot 1 + (-1) \cdot 1 & 1 \cdot 1 + (-1)(-1) \end{bmatrix} = \begin{bmatrix} 2\sigma^2 & 0 \\ 0 & 2\sigma^2 \end{bmatrix}.$$

La somma e la differenza sono gaussiane con varianza $2\sigma^2$ e sono **incorrelate**; essendo congiuntamente gaussiane (Teorema 16.7), sono anche **indipendenti** (Teorema 16.4). Conoscere la somma dei due rumori non dice nulla sulla loro differenza! Geometricamente, $\underline{\underline{A}}$ non deforma le figure: le ribalta come uno specchio (attorno a una retta inclinata) e le ingrandisce di $\sqrt{2}$. Una campana rotonda, ribaltata e ingrandita, resta rotonda. Con altre distribuzioni non succede: se X_1 e X_2 sono uniformi su $[0, 1]$, somma e differenza sono ancora incorrelate (la covarianza è $\sigma^2_{X_1} - \sigma^2_{X_2} = 0$), ma non indipendenti: se la somma è vicina a 0, entrambe le variabili sono vicine a 0, e anche la differenza lo è.

Esempio 16.3 — Come si costruisce un vettore gaussiano correlato

Un calcolatore sa generare numeri gaussiani standard indipendenti, W_1 e W_2. Come si ottiene una coppia gaussiana con varianze unitarie e correlazione ρ assegnata? Si prende

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} = \underbrace{\begin{bmatrix} 1 & 0 \\ \rho & \sqrt{1-\rho^2} \end{bmatrix}}_{\underline{\underline{A}}} \begin{bmatrix} W_1 \\ W_2 \end{bmatrix}, \qquad \text{cioè} \qquad X_1 = W_1, \quad X_2 = \rho W_1 + \sqrt{1-\rho^2} \, W_2.$$

Il vettore $\underline{X}$ è gaussiano (trasformazione lineare di un vettore gaussiano), con media nulla e

$$\underline{\underline{C}}_{\underline{X}} = \underline{\underline{A}} \, \underline{\underline{I}} \, \underline{\underline{A}}^T = \begin{bmatrix} 1 & 0 \\ \rho & \sqrt{1-\rho^2} \end{bmatrix} \begin{bmatrix} 1 & \rho \\ 0 & \sqrt{1-\rho^2} \end{bmatrix} = \begin{bmatrix} 1 & \rho \\ \rho & \rho^2 + 1 - \rho^2 \end{bmatrix} = \begin{bmatrix} 1 & \rho \\ \rho & 1 \end{bmatrix},$$

proprio la matrice voluta. È così che sono stati generati i punti delle figure di questo capitolo. Si ritrova anche la condizionata del Teorema 16.5: sapendo che $X_1 = W_1 = x_1$, si ha $X_2 = \rho x_1 + \sqrt{1-\rho^2} \, W_2$, una gaussiana di media ρx_1 e varianza $1 - \rho^2$ (W_2 è indipendente da W_1).

Esempio 16.4 — La media di n campioni di rumore

Siano $X_1, \ldots, X_n$ gaussiane indipendenti, tutte $\mathcal{N}(\mu, \sigma^2)$ (per esempio n misure della stessa grandezza, disturbate da rumore). La loro media aritmetica è una trasformazione lineare con $m = 1$:

$$\bar{X} = \frac{X_1 + \cdots + X_n}{n} = \underbrace{\left[\tfrac{1}{n}, \tfrac{1}{n}, \ldots, \tfrac{1}{n}\right]}_{\underline{\underline{A}} \ (1 \times n)} \underline{X}.$$

Quindi $\bar{X}$ è gaussiana, con media $\underline{\underline{A}} \underline{\mu}_{\underline{X}} = n \cdot \frac{\mu}{n} = \mu$ e varianza

$$\underline{\underline{A}} \, (\sigma^2 \underline{\underline{I}}) \, \underline{\underline{A}}^T = \sigma^2 \sum_{i=1}^{n} \frac{1}{n^2} = \frac{\sigma^2}{n}.$$

Mediando n misure la deviazione standard del rumore si divide per $\sqrt{n}$: con 100 misure l'errore tipico diventa dieci volte più piccolo. Ritroveremo questa media, la *media campione*, all'inizio del terzo pacchetto di slide.

In sintesi

- Un **vettore aleatorio** $\underline{X} = [X_1, \ldots, X_n]^T$ ha vettore delle medie $\underline{\mu}_{\underline{X}} = E[\underline{X}]$, matrice di correlazione $\underline{\underline{R}}_{\underline{X}} = E[\underline{X}\,\underline{X}^T]$ e matrice di covarianza $\underline{\underline{C}}_{\underline{X}} = E[(\underline{X} - \underline{\mu}_{\underline{X}})(\underline{X} - \underline{\mu}_{\underline{X}})^T] = \underline{\underline{R}}_{\underline{X}} - \underline{\mu}_{\underline{X}}\underline{\mu}_{\underline{X}}^T$, entrambe simmetriche; sulla diagonale di $\underline{\underline{C}}_{\underline{X}}$ ci sono le varianze. $(\underline{\mu}_{\underline{X}}, \underline{\underline{C}}_{\underline{X}})$ è la caratterizzazione sintetica.
- $\underline{\underline{C}}_{\underline{X}}$ è **definita non negativa**: $\underline{q}^T \underline{\underline{C}}_{\underline{X}} \underline{q} = \mathrm{VAR}(\underline{q}^T \underline{X}) \geq 0$.
- **Vettore gaussiano**, $\underline{X} \sim \mathcal{N}(\underline{\mu}_{\underline{X}}, \underline{\underline{C}}_{\underline{X}})$:

$$f_{\underline{X}}(\underline{x}) = \frac{1}{\sqrt{(2\pi)^n \det \underline{\underline{C}}_{\underline{X}}}}\, e^{-\frac{1}{2}(\underline{x}-\underline{\mu}_{\underline{X}})^T \underline{\underline{C}}_{\underline{X}}^{-1} (\underline{x}-\underline{\mu}_{\underline{X}})};$$

  con componenti indipendenti $\underline{\underline{C}}_{\underline{X}}$ è diagonale. Le curve di uguale densità sono ellissi.
- Per le congiuntamente gaussiane **incorrelate $\Leftrightarrow$ indipendenti**; marginali e condizionate sono gaussiane (bivariata standard: $X_2 \mid X_1 = x_1 \sim \mathcal{N}(\rho x_1, 1 - \rho^2)$).
- **Trasformazioni lineari**: $\underline{Z} = \underline{\underline{A}}\,\underline{X} + \underline{b}$ ha $\underline{\mu}_{\underline{Z}} = \underline{\underline{A}}\,\underline{\mu}_{\underline{X}} + \underline{b}$ e $\underline{\underline{C}}_{\underline{Z}} = \underline{\underline{A}}\,\underline{\underline{C}}_{\underline{X}}\,\underline{\underline{A}}^T$, ed è gaussiano se $\underline{X}$ lo è. Per due variabili: $\sigma_Z^2 = a_1^2\sigma_1^2 + a_2^2\sigma_2^2 + 2a_1a_2\sigma_1\sigma_2\rho_{12}$.

Processi aleatori

Un segnale che arriva a un ricevitore non è un singolo numero, e nemmeno un vettore di pochi numeri: è una successione di valori che continua nel tempo. Il rumore in un circuito, la sequenza di bit trasmessa da un modem, la temperatura misurata ogni giorno, il prezzo di un'azione ogni minuto sono tutte **successioni aleatorie**: non si possono prevedere esattamente, ma hanno delle regolarità statistiche. Lo strumento per descriverle è il **processo aleatorio**, un esperimento il cui risultato non è un numero ma un'intera successione. In questo capitolo, l'ultimo del secondo pacchetto di slide, ne diamo la definizione nel caso del tempo discreto, vediamo come si caratterizza e introduciamo la nozione più importante, la **stazionarietà**: l'idea che le proprietà statistiche del processo non cambino nel tempo.

Richiami: la caratterizzazione completa

Si consideri uno spazio di probabilità arbitrario (Ω, S, P): Ω è lo spazio campione, S è una σ-algebra di eventi di Ω (Capitolo 4) e $P : S \to [0,1]$ è una legge di probabilità. Ricordiamo che una variabile aleatoria è una funzione

$$X : \omega \in \Omega \longmapsto X(\omega) \in \mathcal{X} \subseteq \mathbb{R},$$

discreta se tale è l'alfabeto $\mathcal{X}$, continua se tale è $\mathcal{X}$. Una coppia di variabili aleatorie è l'applicazione $(X, Y) : \omega \in \Omega \longmapsto (X(\omega), Y(\omega)) \in \mathcal{X} \times \mathcal{Y} \subseteq \mathbb{R}^2$, e una m-pla, ovvia generalizzazione della coppia, si scrive come vettore aleatorio (Capitolo 16):

$$\underline{X}(\omega) = [X_1(\omega), X_2(\omega), \ldots, X_m(\omega)]^T \in \mathcal{X}_1 \times \mathcal{X}_2 \times \cdots \times \mathcal{X}_m \subseteq \mathbb{R}^m.$$

Una variabile, una coppia o un vettore si dicono **completamente caratterizzati** (statisticamente) quando se ne conosce la legge, in una delle forme equivalenti della tabella: la CDF, che esiste sempre, oppure la pmf nel caso discreto o la PDF nel caso continuo. La PDF si ottiene derivando la CDF una volta rispetto a ciascuna variabile.

	CDF (sempre)	pmf (caso discreto)	PDF (caso continuo)
X	$F_X(x) = P(X \le x)$	$p_X(x) = P(X = x)$	$f_X(x) = \dfrac{\mathrm{d}}{\mathrm{d}x} F_X(x)$
(X, Y)	$F_{X,Y}(x,y) = P(X \le x, Y \le y)$	$p_{X,Y}(x,y) = P(X = x, Y = y)$	$f_{X,Y}(x,y) = \dfrac{\partial^2 F_{X,Y}(x,y)}{\partial x \, \partial y}$
$\underline{X}$	$F_{\underline{X}}(\underline{x}) = P(X_1 \le x_1, \ldots, X_m \le x_m)$	$p_{\underline{X}}(\underline{x}) = P(X_1 = x_1, \ldots, X_m = x_m)$	$f_{\underline{X}}(\underline{x}) = \dfrac{\partial^m F_{\underline{X}}(\underline{x})}{\partial x_1 \cdots \partial x_m}$

La regola della catena per i vettori aleatori

Nel Capitolo 8 abbiamo visto la regola della catena per tre variabili discrete. Per i processi ci servirà con un numero qualsiasi di variabili.

Teorema 17.1 — Regola della catena per i vettori aleatori

Per un vettore aleatorio discreto $\underline{X} = [X_1, \dots, X_m]^T$:

$$p_{\underline{X}}(\underline{x}) = P(X_1 = x_1)\, P(X_2 = x_2 \mid X_1 = x_1)\, P(X_3 = x_3 \mid X_1 = x_1, X_2 = x_2) \times \cdots \times P(X_m = x_m \mid X_1 = x_1, \dots, X_{m-1} = x_{m-1}),$$

cioè, in forma compatta,

$$p_{\underline{X}}(\underline{x}) = \prod_{i=1}^{m} p_{X_i \mid X_1, \dots, X_{i-1}}(x_i \mid x_1, \dots, x_{i-1}),$$

dove per $i = 1$ si conviene che $p_{X_1 \mid X_0}(x_1 \mid x_0) = p_{X_1}(x_1)$ (non c'è nessuna condizione). Per i vettori continui vale lo stesso con le densità: $f_{\underline{X}}(\underline{x}) = \prod_{i=1}^{m} f_{X_i \mid X_1, \dots, X_{i-1}}(x_i \mid x_1, \dots, x_{i-1})$, con $f_{X_1 \mid X_0}(x_1 \mid x_0) = f_{X_1}(x_1)$.

Dimostrazione — si stacca una variabile alla volta

Passo 1 — La probabilità composta. Si parte da $P(A \cap B) = P(A \mid B)\, P(B)$, la legge della probabilità composta del Capitolo 4 (che le slide chiamano qui legge di Bayes). Con $A = \{X_2 = x_2, \dots, X_m = x_m\}$ e $B = \{X_1 = x_1\}$:

$$p_{\underline{X}}(\underline{x}) = P(X_2 = x_2, \dots, X_m = x_m \mid X_1 = x_1)\, P(X_1 = x_1).$$

Passo 2 — Si ripete dentro il condizionamento. La probabilità condizionata a $\{X_1 = x_1\}$ è una probabilità (Teorema 4.6), quindi si può staccare allo stesso modo la variabile X_2:

$$p_{\underline{X}}(\underline{x}) = P(X_3 = x_3, \dots, X_m = x_m \mid X_1 = x_1, X_2 = x_2)\, P(X_2 = x_2 \mid X_1 = x_1)\, P(X_1 = x_1).$$

Passo 3 — Si itera. Ogni volta una variabile passa dal gruppo «da calcolare» al gruppo «condizionante»; dopo $m - 1$ passi il gruppo da calcolare contiene solo X_m, e si ottiene il prodotto dell'enunciato.

Passo 4 — Il caso continuo. Si ripete lo stesso ragionamento con la definizione di densità condizionata del Capitolo 14, «congiunta uguale condizionata per marginale», applicata ogni volta a un gruppo di variabili.

■

La regola della catena descrive il vettore **un pezzo alla volta**, nell'ordine in cui le variabili «escono»: prima X_1, poi X_2 sapendo X_1, poi X_3 sapendo le prime due, e così via. È il modo naturale di descrivere un segnale che si svolge nel tempo, campione dopo campione. Due casi particolari li conosciamo già.

- Se le variabili sono **indipendenti**, ogni condizionata coincide con la marginale e la regola diventa il prodotto delle marginali, $p_{\underline{X}}(\underline{x}) = \prod_i p_{X_i}(x_i)$.
- Nella gaussiana bivariata del Capitolo 16 abbiamo trovato $f_{X_1 X_2}(x_1, x_2) = f_{X_1}(x_1)\, f_{X_2 \mid X_1}(x_2 \mid x_1)$, con la marginale $\mathcal{N}(0, 1)$ e la condizionata $\mathcal{N}(\rho x_1, 1 - \rho^2)$: è la regola della catena con $m = 2$.

Esempio 17.1 — Tre assi di fila

Da un mazzo di 52 carte se ne estraggono tre, senza reinserimento; sia $X_i = 1$ se la i-esima carta è un asso e $X_i = 0$ altrimenti. Qual è la probabilità di estrarre tre assi? Le variabili non sono indipendenti (ogni asso estratto rende meno probabile il successivo), ma con la regola della catena ogni fattore è facile:

$$P(X_1 = 1, X_2 = 1, X_3 = 1) = \underbrace{\frac{4}{52}}_{P(X_1=1)} \cdot \underbrace{\frac{3}{51}}_{P(X_2=1 \mid X_1=1)} \cdot \underbrace{\frac{2}{50}}_{P(X_3=1 \mid X_1=1, X_2=1)} = \frac{24}{132\,600} \approx 1{,}8 \cdot 10^{-4}.$$

Ogni condizionata si calcola guardando il mazzo rimasto: dopo un asso restano 3 assi su 51 carte, dopo due assi 2 su 50.

PROCESSI ALEATORI A TEMPO DISCRETO

Processo aleatorio a tempo discreto

Si definisce **processo aleatorio tempo-discreto** un'applicazione che a ogni elemento dello spazio campione fa corrispondere una successione:

$$X : \omega \in \Omega \longmapsto \{X(n,\omega)\}_{n\in\mathbb{Z}},$$

dove $\mathbb{Z}$ è l'insieme dei numeri interi relativi (positivi, negativi e zero), che fanno da istanti di tempo.

Una variabile aleatoria associa a ogni risultato dell'esperimento un numero; un processo aleatorio gli associa un'**intera successione** di numeri, uno per ogni istante. È quindi una funzione di due variabili, n e ω, e la si può guardare in due modi.

- **Fissato il risultato** ω (in orizzontale nella figura): $X(n,\omega)$ è una successione di numeri ben precisi, non più aleatoria, che si chiama **realizzazione** del processo. È il segnale che si osserva davvero in una prova, per esempio quello che compare sullo schermo di un oscilloscopio. Per ogni ω il processo si realizza in una sequenza di valori che stanno in un certo intervallo (anche infinito).
- **Fissato l'istante** $n = n_0$ (in verticale): al variare di ω, $X(n_0,\omega)$ assume valori diversi, uno per ogni elemento dello spazio campione: è una **variabile aleatoria**. È come «campionare verticalmente» il processo: si guarda il valore all'istante n_0 in tutte le realizzazioni possibili.

Come per le variabili aleatorie, d'ora in poi si omette ω e si scrive semplicemente $X(n)$.

Per fissare le idee useremo spesso la **sinusoide con fase a caso**, $X(n) = A\cos(2\pi f_0 n + \Phi)$, dove la fase Φ è scelta a caso, uniformemente su un periodo. Ogni realizzazione è una sinusoide perfetta: il caso decide soltanto da dove parte. È il modello di un oscillatore che si accende in un istante qualsiasi.

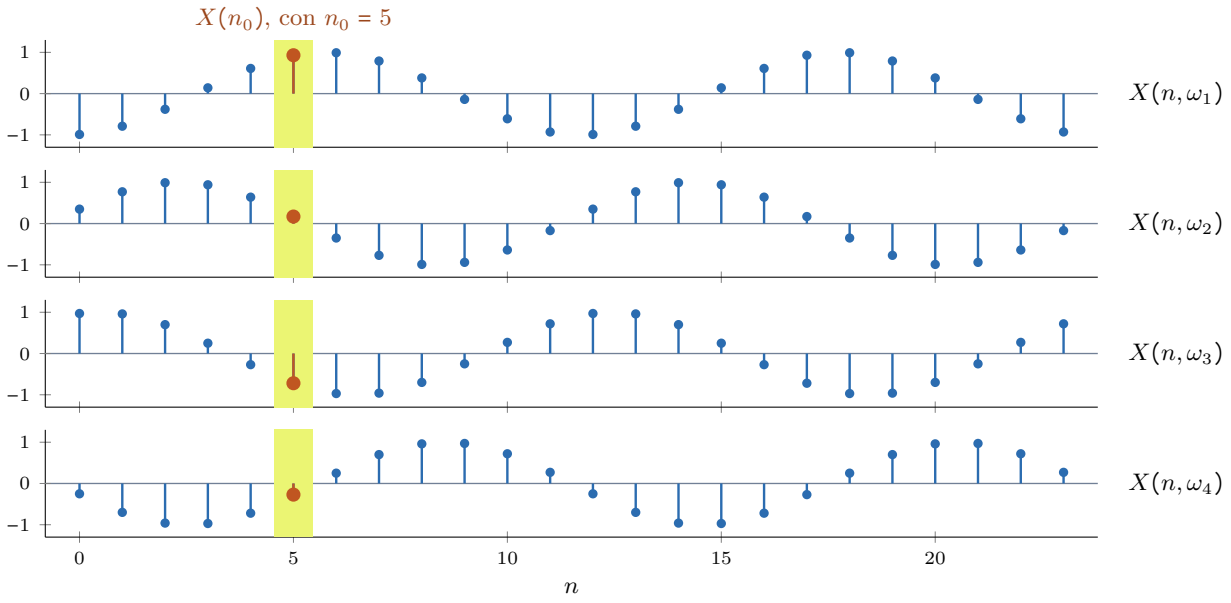


Figura 17.1: *Quattro realizzazioni della sinusoide con fase a caso, con $A = 1$ e $f_0 = \frac{1}{12}$ (un periodo ogni 12 campioni). In orizzontale, ogni riga è una realizzazione: una successione di numeri. In verticale, i valori all'istante $n_0 = 5$ (in rosso, nella fascia gialla) sono quattro determinazioni della variabile aleatoria $X(5)$.*

La variabile aleatoria $X(n_0)$ ha una sua densità, che in generale dipende dall'istante n_0. La si indica con $f_{X(n)}(x;n)$, dove il punto e virgola separa la variabile x dall'istante n, che fa da parametro.

Stazionarietà del primo ordine

Un processo aleatorio si dice **caratterizzato al primo ordine** se ne è nota la PDF $f_{X(n)}(x;n)$ per ogni n. Se questa PDF non dipende dall'istante considerato, $f_{X(n)}(x;n) = f_X(x)$ per ogni n, il processo si dice **stazionario del primo ordine**: in tal caso basta assegnare un'unica PDF del primo ordine.

Esempio 17.2 — La sinusoide con fase a caso è stazionaria del primo ordine

Scriviamo la fase come $\Phi = 2\pi U$, con $U \sim \mathcal{U}\left(-\frac{1}{2}, \frac{1}{2}\right)$: così Φ è uniforme su un periodo intero. Fissato n, $X(n) = A\cos(2\pi U + \varphi_n)$ con $\varphi_n = 2\pi f_0 n$: è esattamente la variabile della sinusoide con fase a caso del Capitolo 12, con la fase $\varphi = \varphi_n$. Là avevamo trovato la densità dell'arcoseno, $\frac{1}{\pi\sqrt{A^2-x^2}}$ per $|x| < A$, che **non dipende da** φ. Quindi

$$f_{X(n)}(x;n) = \frac{1}{\pi\sqrt{A^2 - x^2}} \qquad \text{per ogni } n:$$

il processo è stazionario del primo ordine. In parole: se non si sa da dove parte la sinusoide, nessun istante è diverso dagli altri.

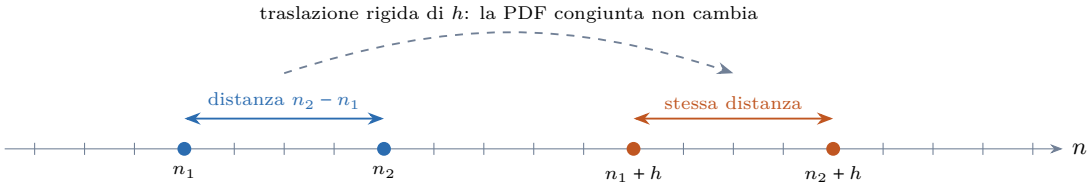
Il primo ordine descrive ogni istante da solo, ma non dice nulla dei legami fra istanti diversi: se il segnale in un istante è alto, sarà alto anche all'istante dopo? Per rispondere serve la descrizione congiunta delle coppie di campioni.

Stazionarietà del secondo ordine

Un processo aleatorio si dice **caratterizzato al secondo ordine** se è nota la PDF congiunta $f_{X(n_1),X(n_2)}(x_1, x_2; n_1, n_2)$ per ogni coppia di istanti n_1, n_2. Si dice **stazionario al secondo ordine** se, per qualsiasi intero h,

$$f_{X(n_1),X(n_2)}(x_1, x_2; n_1, n_2) = f_{X(n_1+h),X(n_2+h)}(x_1, x_2; n_1 + h, n_2 + h).$$

In altre parole, in un processo stazionario al secondo ordine la caratterizzazione congiunta di due campioni dipende solo dalla loro **distanza temporale**, non dalla loro posizione: la PDF congiunta non cambia se i due istanti vengono spostati «rigidamente», insieme, in anticipo o in ritardo.



Un processo stazionario al secondo ordine lo è anche al primo: la densità di un solo campione si ottiene integrando la congiunta rispetto all'altro (Capitolo 14), e se la congiunta non cambia con la traslazione non cambia nemmeno il suo integrale. Il viceversa, invece, non è vero: due processi con le stesse densità del primo ordine possono legare in modo molto diverso i campioni vicini.

Caratterizzazione completa e stazionarietà in senso stretto

Il primo e il secondo ordine guardano uno o due istanti alla volta. La descrizione completa li guarda tutti insieme, in qualsiasi numero.

Caratterizzazione completa di un processo

Un processo aleatorio $X(n)$ si dice **completamente caratterizzato** (statisticamente) se, detto M un intero arbitrario e detti $n_1, n_2, \ldots, n_M$ M istanti di tempo arbitrari, il vettore aleatorio

$$\underline{X} = [X(n_1), X(n_2), \ldots, X(n_M)]^T$$

ha una densità di probabilità $f_{\underline{X}}(x_1, x_2, \ldots, x_M; n_1, n_2, \ldots, n_M)$ nota.

Stazionarietà in senso stretto

Un processo aleatorio si dice **stazionario in senso stretto di ordine** M se la sua densità di ordine M è invariante per traslazione:

$$f_{\underline{X}}(x_1, \ldots, x_M; n_1, \ldots, n_M) = f_{\underline{X}}(x_1, \ldots, x_M; n_1 + h, \ldots, n_M + h) \qquad \forall\, h.$$

Si dice **stazionario in senso stretto** se lo è per ogni ordine M.

Teorema 17.2 — La stazionarietà passa agli ordini più bassi

Un processo stazionario di ordine M lo è anche di qualunque ordine $i \le M$.

Dimostrazione

Passo 1. Si fissano i istanti $n_1, \dots, n_i$ e se ne aggiungono altri $M - i$ qualsiasi, $n_{i+1}, \dots, n_M$. La densità di ordine i si ottiene da quella di ordine M integrando rispetto alle $M - i$ variabili in più (marginalizzazione). Spostando tutti gli istanti di h, la funzione da integrare non cambia (stazionarietà di ordine M), e quindi non cambia nemmeno il risultato dell'integrale, la densità di ordine i.

■

Processo indipendente

Un processo si dice **indipendente** (o **a campioni indipendenti**) se, comunque si scelgano un intero M e gli istanti $n_1, \dots, n_M$, il vettore $\underline{X} = [X(n_1), \dots, X(n_M)]^T$ è costituito da variabili aleatorie indipendenti, cioè

$$f_{\underline{X}}(x_1, \dots, x_M; n_1, \dots, n_M) = f_{X(n_1),\dots,X(n_M)}(x_1, \dots, x_M; n_1, \dots, n_M) = \prod_{i=1}^{M} f_{X(n_i)}(x_i; n_i).$$

Per un processo indipendente, quindi, la caratterizzazione completa si riduce a quella del primo ordine: basta conoscere la densità di ogni singolo campione.

Processi a valori discreti

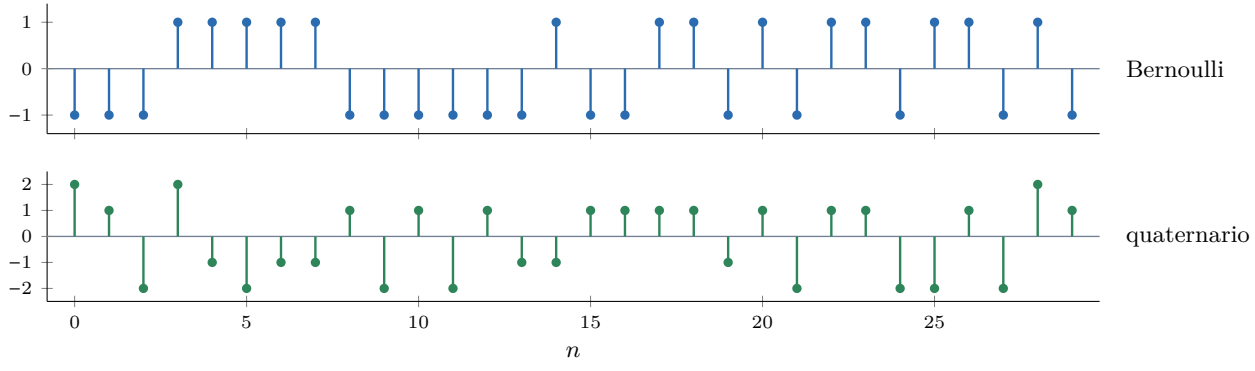
Si chiama **processo ad ampiezza discreta** (o, per brevità, **processo discreto**) un processo le cui realizzazioni sono sequenze di numeri che possono assumere valori in un alfabeto discreto. Tutte le definizioni viste per i processi a valori continui si estendono a questi processi, con la sola differenza che al posto delle densità si usano le pmf. Per esempio, un processo discreto è stazionario in senso stretto se, comunque si scelgano M, gli istanti $n_1, \dots, n_M$ e uno spostamento h,

$$P(X(n_1) = x_1, \dots, X(n_M) = x_M) = P(X(n_1 + h) = x_1, \dots, X(n_M + h) = x_M).$$

Ovviamente anche qui la stazionarietà di ordine M implica quella di ogni ordine $i \le M$; in particolare un processo stazionario ha una pmf marginale indipendente dal tempo.

Esempio 17.3 — Il processo di Bernoulli e il processo quaternario

Un caso di notevole importanza è il **processo indipendente binario**, con $X(n) \in \{-1, 1\}$ e $P(X(n) = -1) = P(X(n) = 1) = \frac{1}{2}$, detto anche **processo di Bernoulli** (in generale le probabilità possono essere p e $1 - p$): è il modello di una sequenza di bit trasmessi con i livelli ± 1, come quella del Capitolo 15. Un altro esempio è il processo **quaternario** indipendente, con $X(n) \in \{-2, -1, 1, 2\}$ e livelli equiprobabili, $P(X(n) = i) = \frac{1}{4}$ per $i \in \{-2, -1, 1, 2\}$: ogni simbolo trasporta due bit.



Una realizzazione di ciascuno dei due processi (simulazione).

Teorema 17.3 — Processi discreti indipendenti e stazionari

Se un processo discreto è stazionario e indipendente, per ogni scelta di M, degli istanti $n_1, \dots, n_M$ e dei valori $x_1, \dots, x_M$:

$$P(X(n_1) = x_1, X(n_2) = x_2, \dots, X(n_M) = x_M) = \prod_{i=1}^{M} P(X(n_i) = x_i) = \prod_{i=1}^{M} p_X(x_i),$$

dove $p_X(x)$ è la pmf marginale, che non dipende dal tempo. Viceversa, un processo indipendente che ha la stessa pmf marginale in ogni istante è stazionario in senso stretto.

Dimostrazione

Passo 1 — La formula. La prima uguaglianza è l'indipendenza; la seconda la stazionarietà, per cui la marginale di ogni campione è la stessa pmf p_X.

Passo 2 — Il viceversa. Se il processo è indipendente e ha sempre la stessa marginale, vale la stessa formula, e il prodotto $\prod_i p_X(x_i)$ non contiene gli istanti n_i: spostandoli tutti di h non cambia nulla.

■

Per un processo discreto indipendente e stazionario, dunque, l'intera caratterizzazione completa si riassume in **una sola pmf**. Per esempio, nel processo di Bernoulli la probabilità di osservare la sequenza $+1, +1, -1$ in tre istanti qualsiasi è $\left(\frac{1}{2}\right)^3 = \frac{1}{8}$, e nel processo quaternario la probabilità che due campioni valgano entrambi 2 è $\frac{1}{4} \cdot \frac{1}{4} = \frac{1}{16}$, dovunque si trovino.

Processi stazionari in senso lato

Conoscere la caratterizzazione completa di un processo è quasi sempre troppo: servirebbero le densità congiunte di un numero qualsiasi di campioni. Come per le variabili e i vettori, ci si accontenta spesso di una caratterizzazione sintetica, fatta di medie e correlazioni. Ci concentriamo sui processi a tempo discreto, ma quanto diremo vale anche per quelli a tempo continuo.

Teorema 17.4 — Medie di un processo stazionario del secondo ordine

Se $X(n)$ è stazionario del secondo ordine:

a) la media $E[X(n)] = \mu_X(n) = \mu_X$ non dipende da n;
b) la media del prodotto $E[X(n_1)X(n_2)]$ dipende solo da $|n_2 - n_1|$, e non separatamente da n_1 e n_2.

Dimostrazione — nel caso discreto; nel continuo si usano le densità

Passo 1 — a). Per la stazionarietà $P(X(n) = x) = p_X(x)$ per ogni n, quindi

$$E[X(n)] = \sum_{x \in \mathcal{X}} x\, P(X(n) = x) = \sum_{x \in \mathcal{X}} x\, p_X(x) = \mu_X,$$

che non contiene n.

Passo 2 — b) Dipende solo dalla differenza. Per ogni h, la stazionarietà del secondo ordine dice che le due pmf congiunte sono uguali, e quindi anche le medie calcolate con esse:

$$\begin{aligned} E[X(n_1)X(n_2)] &= \sum_{x_1 \in \mathcal{X}} \sum_{x_2 \in \mathcal{X}} x_1 x_2\, P(X(n_1) = x_1, X(n_2) = x_2) \\ &= \sum_{x_1 \in \mathcal{X}} \sum_{x_2 \in \mathcal{X}} x_1 x_2\, P(X(n_1 + h) = x_1, X(n_2 + h) = x_2) = E[X(n_1 + h)\, X(n_2 + h)]. \end{aligned}$$

Scegliendo $h = -n_1$: $E[X(n_1)X(n_2)] = E[X(0)\, X(n_2 - n_1)]$, che è una funzione della sola differenza $n_2 - n_1$.

Passo 3 — b) Anzi, del valore assoluto. Per la proprietà commutativa del prodotto, $E[X(n_1)X(n_2)] = E[X(n_2)X(n_1)]$: la stessa funzione dà lo stesso valore in $n_2 - n_1$ e in $n_1 - n_2$. Dipende quindi solo da $|n_2 - n_1|$.

■

Queste due proprietà sono così utili che si prendono come definizione di una stazionarietà più debole, che riguarda solo medie e correlazioni.

Autocorrelazione

L'**autocorrelazione** di un processo $X(n)$ è la correlazione fra i suoi campioni in due istanti:

$$R_X(n_1, n_2) = E[X(n_1)\, X(n_2)].$$

Processo stazionario in senso lato

Un processo, continuo o discreto, non necessariamente stazionario al secondo ordine, si dice **stazionario in senso lato** (**SSL**; in inglese *wide-sense stationary*, WSS) se:

- la sua media non dipende dal tempo: $E[X(n)] = \mu_X$;
- la sua autocorrelazione dipende solo dalla differenza fra gli istanti: $R_X(n_1, n_2) = E[X(n_1)X(n_2)] = R_X(n_2 - n_1)$.

Per il Teorema 17.4 ogni processo stazionario del secondo ordine è SSL. Si scrive spesso $R_X(k) = E[X(n)X(n+k)]$, con k la distanza fra i campioni: per la commutatività del prodotto è una funzione pari, $R_X(-k) = R_X(k)$, e $R_X(0) = E[X^2(n)]$ è il valore quadratico medio, cioè la **potenza media** del processo.

SSL non vuol dire stazionario

La stazionarietà in senso lato riguarda solo medie e correlazioni, non le densità. Si prenda un processo a campioni indipendenti con $X(n) \sim \mathcal{N}(0,1)$ negli istanti pari e $X(n) \sim \mathcal{U}(-\sqrt{3}, \sqrt{3})$ in quelli dispari. La media è sempre 0, la varianza è sempre 1 (per l'uniforme su $(-a, a)$ vale $\frac{(2a)^2}{12} = \frac{a^2}{3} = 1$), e $R_X(n_1, n_2) = 0$ per $n_1 \neq n_2$: il processo è SSL. Ma la densità del primo ordine cambia da un istante all'altro (una campana, poi un rettangolo): il processo non è stazionario nemmeno del primo ordine.

Il vettore dei campioni di un processo SSL

Cosa succede se si prelevano M campioni da un processo SSL e li si mette in un vettore? La struttura della stazionarietà si riflette in quella della matrice di covarianza.

Teorema 17.5 — Il vettore dei campioni di un processo SSL

Sia $X(n)$ un processo SSL e sia $\underline{X} = [X_1, X_2, \ldots, X_M]^T$ il vettore dei suoi campioni negli istanti $n_1, n_2, \ldots, n_M$, cioè $X_i = X(n_i)$. Allora:

a) il vettore delle medie ha tutti gli elementi uguali: $\underline{\mu}_{\underline{X}} = [\mu, \mu, \ldots, \mu]^T = \mu\, \underline{1}$, dove μ è uno scalare e $\underline{1} = [1, 1, \ldots, 1]^T$ è il vettore $M \times 1$ di tutti «1»;

b) $E[X_i X_j] = f(|n_i - n_j|)$ per un'opportuna funzione f; in particolare il valore quadratico medio $E[X_i^2] = f(0)$ e la varianza $\sigma_X^2 = f(0) - \mu^2$ non dipendono da i;

c) il coefficiente di correlazione dipende solo dalla distanza fra gli istanti, $\rho_{i,j} = \rho_{|n_i - n_j|}$, e la matrice di covarianza è simmetrica, della forma

$$\underline{\underline{C}}_{\underline{X}} = \sigma_X^2 \begin{bmatrix} 1 & \rho_{1,2} & \cdots & \rho_{1,M} \\ \rho_{2,1} & 1 & \cdots & \rho_{2,M} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{M,1} & \rho_{M,2} & \cdots & 1 \end{bmatrix};$$

d) se il passo di campionamento è costante ($n_{i+1} - n_i$ uguale per ogni i), $\underline{\underline{C}}_{\underline{X}}$ è una **matrice di Toeplitz**: gli elementi di ciascuna diagonale sono tutti uguali.

Dimostrazione

Passo 1 — a). Per la prima condizione SSL, $E[X_i] = E[X(n_i)] = \mu$ per ogni i.

Passo 2 — b). Per la seconda condizione, $E[X_i X_j] = R_X(n_j - n_i)$. Siccome $E[X_i X_j] = E[X_j X_i] = R_X(n_i - n_j)$, la funzione dà lo stesso valore in $n_j - n_i$ e nel suo opposto: dipende solo da $|n_i - n_j|$. Con $i = j$ la distanza è zero, quindi $E[X_i^2] = f(0)$, e $\sigma^2_{X_i} = E[X_i^2] - E^2[X_i] = f(0) - \mu^2$.

Passo 3 — c). Tutte le deviazioni standard sono uguali a σ_X, e $COV(X_i, X_j) = E[X_i X_j] - \mu^2$ (Capitolo 9):

$$\rho_{i,j} = \frac{COV(X_i, X_j)}{\sigma_{X_i}\,\sigma_{X_j}} = \frac{E[X_i X_j] - \mu^2}{\sigma_X^2} = \frac{E[X(n_i)\,X(n_j)] - \mu^2}{\sigma_X^2} = \rho_{|n_i - n_j|}.$$

Ogni elemento della matrice di covarianza è $C_{X_i X_j} = \rho_{i,j}\,\sigma_X^2$; sulla diagonale $\rho_{i,i} = 1$, e $\rho_{i,j} = \rho_{j,i}$ perché la distanza fra n_i e n_j è la stessa nei due versi.

Passo 4 — d). Con passo costante Δ, $n_j - n_i = (j - i)\Delta$: l'elemento di posto (i, j) dipende solo da $|j - i|$, cioè dalla diagonale su cui si trova.

■

$$\underline{\underline{C}}_{\underline{X}} = \sigma_X^2 \begin{bmatrix} 1 & \rho_1 & \rho_2 & \rho_3 & \rho_4 \\ \rho_1 & 1 & \rho_1 & \rho_2 & \rho_3 \\ \rho_2 & \rho_1 & 1 & \rho_1 & \rho_2 \\ \rho_3 & \rho_2 & \rho_1 & 1 & \rho_1 \\ \rho_4 & \rho_3 & \rho_2 & \rho_1 & 1 \end{bmatrix}$$

Cinque campioni consecutivi di un processo SSL. L'elemento (i, j) dipende solo dalla distanza $|i - j|$: la diagonale principale (distanza 0) contiene tutti 1, le diagonali vicine (distanza 1) tutti ρ_1, e così via. La matrice è simmetrica e **di Toeplitz**: bastano i numeri della prima riga, $1, \rho_1, \ldots, \rho_4$, per scriverla tutta.

Figura 17.2: *La matrice di covarianza di campioni equispaziati di un processo SSL: ogni colore è una diagonale.*

Si osservi che la matrice di covarianza $\underline{\underline{C}}_{\underline{X}}$ è simmetrica anche se il vettore viene estratto da un processo non SSL, perché la media del prodotto di due variabili aleatorie non dipende dall'ordine dei fattori. La struttura, però, non sarà quella precedente: per esempio sulla diagonale principale potrebbero esserci valori diversi, perché la varianza può dipendere dal tempo.

QUATTRO PROCESSI A CONFRONTO

Per rendere concrete le definizioni, studiamo quattro processi: tre stazionari in senso lato, con memorie diverse, e uno che non lo è.

Esempio 17.4 — Il processo di Bernoulli: nessuna memoria

Per il processo di Bernoulli a valori ± 1: $\mu = \frac{1}{2}(-1) + \frac{1}{2}(+1) = 0$, e $X^2(n) = 1$ sempre, quindi $R_X(0) = 1$. Per $k \neq 0$ i due campioni sono indipendenti, e $R_X(k) = E[X(n)]\,E[X(n+k)] = 0$. Quindi

$$R_X(k) = \begin{cases} 1 & k = 0 \\ 0 & k \neq 0 \end{cases} \qquad \text{e} \qquad \underline{\underline{C}}_{\underline{X}} = \underline{\underline{I}}$$

per qualsiasi vettore di campioni: un campione non dice nulla sugli altri. Il processo è SSL (anzi stazionario in senso stretto, per il Teorema 17.3).

Esempio 17.5 — La media mobile: un processo SSL con memoria

Sia $X(n)$ il processo di Bernoulli a valori ± 1 e sia $Y(n) = \frac{1}{2}[X(n) + X(n-1)]$ la media di due campioni consecutivi. $Y(n)$ vale -1 se entrambi i campioni valgono -1, $+1$ se valgono entrambi $+1$, e 0 se sono diversi: con probabilità $\frac{1}{4}$, $\frac{1}{4}$ e $\frac{1}{2}$.

- **Media**: $E[Y(n)] = \frac{1}{2}\left(E[X(n)] + E[X(n-1)]\right) = 0$.
- **Autocorrelazione**: si sviluppa il prodotto e si usa $E[X(i)\,X(j)] = 1$ se $i = j$ e 0 se $i \neq j$ (esempio precedente):

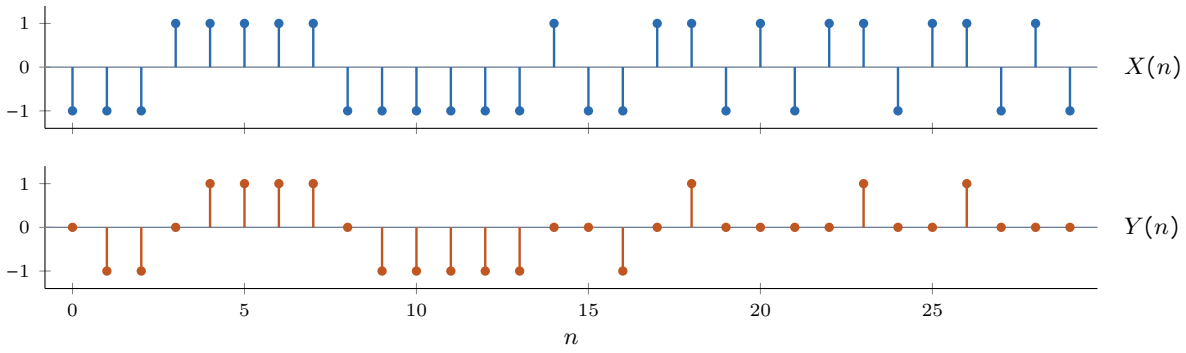
$$R_Y(n, n+k) = \frac{1}{4}E\Big[\,(X(n) + X(n-1))\,(X(n+k) + X(n+k-1))\,\Big] = \begin{cases} \frac{1}{4}(1+1) = \frac{1}{2} & k = 0, \\ \frac{1}{4} & k = \pm 1, \\ 0 & |k| \geq 2. \end{cases}$$

  Con $k = 0$ sopravvivono i due quadrati; con $k = 1$ solo il prodotto $X(n) \cdot X(n)$, perché $X(n)$ è l'unico campione in comune fra $Y(n)$ e $Y(n+1)$ (con $k = -1$ è $X(n-1)$); con $|k| \geq 2$ le due medie non hanno campioni in comune.

R_Y dipende solo da k: il processo è SSL, con $\sigma_Y^2 = \frac{1}{2}$, $\rho_1 = \frac{1/4}{1/2} = \frac{1}{2}$ e $\rho_k = 0$ per $|k| \geq 2$. Per quattro campioni consecutivi la matrice di covarianza è di Toeplitz:

$$\underline{\underline{C}}_{\underline{Y}} = \frac{1}{2}\begin{bmatrix} 1 & \frac{1}{2} & 0 & 0 \\ \frac{1}{2} & 1 & \frac{1}{2} & 0 \\ 0 & \frac{1}{2} & 1 & \frac{1}{2} \\ 0 & 0 & \frac{1}{2} & 1 \end{bmatrix}.$$

A differenza di $X(n)$, i campioni vicini di $Y(n)$ sono correlati: la media mobile «ricorda» il campione precedente e rende la sequenza più lenta e meno frastagliata.



In alto la stessa realizzazione del processo di Bernoulli dell'esempio precedente; in basso la sua media mobile.

Richiamo di matematica: il prodotto di due coseni

Dalle formule di addizione della trigonometria (che si studiano alle superiori)

$$\cos(a-b) = \cos a \cos b + \sin a \sin b, \qquad \cos(a+b) = \cos a \cos b - \sin a \sin b.$$

Sommandole membro a membro, i termini con i seni si cancellano: $\cos(a-b) + \cos(a+b) = 2\cos a \cos b$, cioè

$$\cos a \cos b = \frac{1}{2}\cos(a-b) + \frac{1}{2}\cos(a+b).$$

Il prodotto di due coseni è la media di due coseni: uno con la *differenza* degli argomenti e uno con la *somma*. Serve anche un secondo fatto: la media di un coseno su un numero intero di periodi è zero, perché le parti sopra e sotto l'asse hanno la stessa area. Per esempio

$$\int_{-1/2}^{1/2} \cos(4\pi u + c)\,du = \left[\frac{\sin(4\pi u + c)}{4\pi}\right]_{-1/2}^{1/2} = \frac{\sin(2\pi + c) - \sin(-2\pi + c)}{4\pi} = 0,$$

perché il seno ha periodo 2π (con la regola della catena, la derivata di $\sin(4\pi u + c)$ è $4\pi\cos(4\pi u + c)$, da cui la primitiva).

Esempio 17.6 — La sinusoide con fase a caso è SSL

Riprendiamo $X(n) = A\cos(2\pi U + \varphi_n)$, con $U \sim \mathcal{U}\left(-\frac{1}{2}, \frac{1}{2}\right)$ e $\varphi_n = 2\pi f_0 n$.

- **Media**: $E[X(n)] = \int_{-1/2}^{1/2} A\cos(2\pi u + \varphi_n)\,\mathrm{d}u = 0$ (un periodo intero di coseno), qualunque sia n.
- **Autocorrelazione**: con la formula del richiamo,

$$X(n_1)\,X(n_2) = A^2\cos(2\pi U + \varphi_{n_1})\cos(2\pi U + \varphi_{n_2}) = \frac{A^2}{2}\cos(\varphi_{n_2} - \varphi_{n_1}) + \frac{A^2}{2}\cos(4\pi U + \varphi_{n_1} + \varphi_{n_2}).$$

  Il primo termine non contiene U: è una costante. Il secondo, mediato su U, dà zero (due periodi interi di coseno, come nel richiamo). Quindi

$$R_X(n_1, n_2) = \frac{A^2}{2}\cos(\varphi_{n_2} - \varphi_{n_1}) = \frac{A^2}{2}\cos\left(2\pi f_0(n_2 - n_1)\right),$$

  che dipende solo da $n_2 - n_1$ (e, essendo il coseno pari, solo da $|n_2 - n_1|$).

Il processo è SSL, con $\mu = 0$ e $R_X(k) = \frac{A^2}{2}\cos(2\pi f_0 k)$. La potenza media $R_X(0) = \frac{A^2}{2}$ è il valore quadratico medio di una sinusoide di ampiezza A; e due campioni distanti un periodo ($k = 1/f_0$) hanno di nuovo correlazione massima, perché la sinusoide si ripete. A differenza della media mobile, la memoria di questo processo non si esaurisce mai: conoscendo due campioni si ricostruisce tutta la sinusoide.

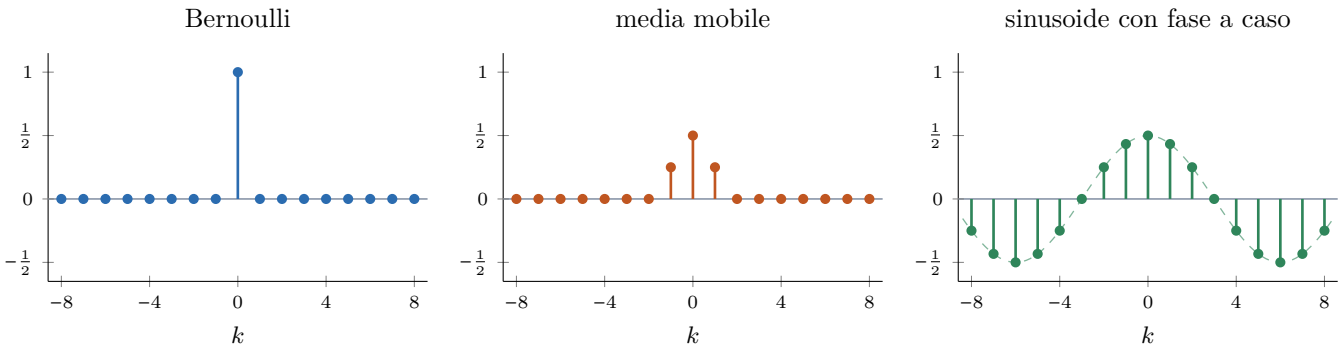


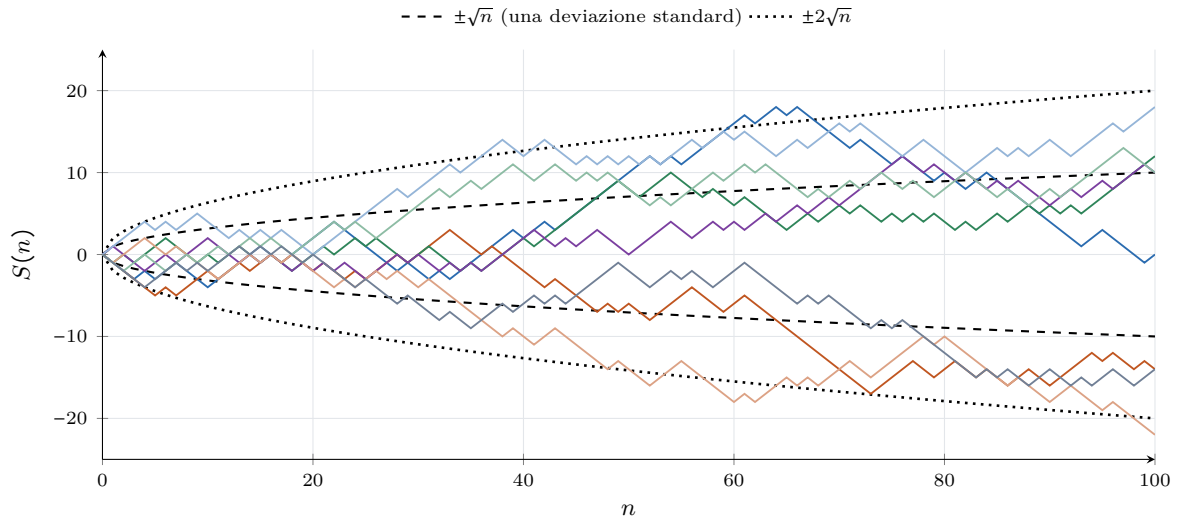
Figura 17.3: *Le autocorrelazioni $R(k)$ dei tre processi SSL degli esempi (con $A = 1$ e $f_0 = \frac{1}{12}$ per la sinusoide). Sono tutte pari e hanno il massimo in $k = 0$, la potenza media. La memoria del processo si legge nella larghezza: nulla per Bernoulli, un passo per la media mobile, infinita per la sinusoide.*

Esempio 17.7 — La passeggiata aleatoria non è stazionaria

Una pedina parte dalla casella 0 e a ogni istante si sposta di una casella avanti o indietro, a seconda dell'esito di una moneta: la sua posizione dopo n passi è $S(n) = X(1) + X(2) + \cdots + X(n)$, con $S(0) = 0$, dove $X(n)$ è il processo di Bernoulli a valori ± 1. È la **passeggiata aleatoria**.

- **Media**: $E[S(n)] = \sum_{i=1}^{n} E[X(i)] = 0$, costante.
- **Varianza**: i passi sono indipendenti, quindi le varianze si sommano (Capitolo 9): $\sigma^2_{S(n)} = \sum_{i=1}^{n} \sigma^2_{X(i)} = n$. Cresce con il tempo.
- **Autocorrelazione**: per $n_1 \le n_2$, $E[S(n_1)\,S(n_2)] = \sum_{i=1}^{n_1} \sum_{j=1}^{n_2} E[X(i)\,X(j)]$, e sopravvivono solo i termini con $i = j$, che sono n_1: $R_S(n_1, n_2) = \min(n_1, n_2)$.

La media non dipende dal tempo, ma l'autocorrelazione non dipende solo dalla differenza $n_2 - n_1$: per esempio $R_S(1, 2) = 1$ e $R_S(10, 11) = 10$. Il processo **non** è SSL, e quindi nemmeno stazionario del secondo ordine; anzi, non lo è neppure del primo ordine, perché la pmf di $S(n)$ si allarga con n. Nella figura le realizzazioni si allontanano dall'origine come $\sqrt{n}$, la deviazione standard dopo n passi.



Otto realizzazioni della passeggiata aleatoria (simulazione): partono tutte da 0 e si sparpagliano sempre di più.

In sintesi

- **Regola della catena**: $p_{\underline{X}}(\underline{x}) = \prod_i p_{X_i|X_1,\ldots,X_{i-1}}(x_i \mid x_1, \ldots, x_{i-1})$ (lo stesso con le densità): la congiunta si costruisce una variabile alla volta.
- Un **processo aleatorio a tempo discreto** associa a ogni ω una successione $\{X(n, \omega)\}_{n \in \mathbb{Z}}$: fissato ω si ha una realizzazione, fissato n una variabile aleatoria.
- **Caratterizzazione**: al primo ordine $f_{X(n)}(x; n)$, al secondo $f_{X(n_1),X(n_2)}(x_1, x_2; n_1, n_2)$, completa con le densità di ogni vettore di M campioni. **Stazionarietà** (di ordine M): le densità non cambiano traslando rigidamente gli istanti; l'ordine M implica gli ordini più bassi.
- **Processo indipendente**: la densità di M campioni è il prodotto delle marginali; se è anche stazionario basta una sola pmf (o PDF). Esempi: Bernoulli ± 1, quaternario.
- **SSL**: media costante e autocorrelazione $R_X(n_1, n_2) = E[X(n_1)X(n_2)] = R_X(n_2 - n_1)$, pari in $k = n_2 - n_1$. Stazionario del secondo ordine $\Rightarrow$ SSL, non viceversa. I campioni equispaziati di un processo SSL hanno $\underline{\mu}_{\underline{X}} = \mu \underline{1}$ e una matrice di covarianza simmetrica e di Toeplitz, $\sigma^2_X[\rho_{|i-j|}]$.

Parte III

Statistica inferenziale e misura dell'informazione

La legge dei grandi numeri e il teorema centrale del limite

Fin qui abbiamo sempre fatto lo stesso tipo di conto: **nota la legge** di probabilità, calcolare la probabilità di un evento, una media, una varianza. La statistica fa il cammino inverso: **osservati dei dati**, risalire alla legge che li ha prodotti. Con questo capitolo comincia il terzo pacchetto di slide, dedicato alla statistica e alla misura dell'informazione. Prima di tutto servono due teoremi che spiegano perché fare la media di tanti dati funziona: la **legge dei grandi numeri**, che dice che la media dei dati si avvicina alla media vera, e il **teorema centrale del limite**, che dice con quale forma (gaussiana) se ne discosta.

Dalla probabilità alla statistica

Supponiamo di avere un **campione** di dimensione n, cioè n numeri $\underline{x} = [x_1, \ldots, x_n]^T \in \mathbb{R}^n$: le altezze di n persone, n misure di una tensione, i bit ricevuti in un secondo. Il campione è il risultato di un esperimento aleatorio: se lo si rifacesse (un *ricampionamento*), si otterrebbero numeri diversi.

Inferenza statistica

L'**inferenza statistica** è il processo che usa l'analisi dei dati per dedurre le proprietà della distribuzione di probabilità sottostante, cioè per definire una legge che un qualsiasi campione, scelto a caso, rispetta.

L'inferenza si contrappone alla **statistica descrittiva**, che si occupa solo delle proprietà dei dati che si hanno davanti (la loro media, la loro dispersione, una retta che li approssima) senza supporre che provengano da una popolazione più ampia. Gli obiettivi fondamentali dell'inferenza statistica sono due: i **test di ipotesi** (decidere fra due o più spiegazioni dei dati, Capitoli 19 e 20) e la **stima dei parametri** (trovare il valore più plausibile di una grandezza non nota, Capitoli 21–23). Alla statistica descrittiva è dedicato il Capitolo 24; gli ultimi due capitoli misurano l'informazione.

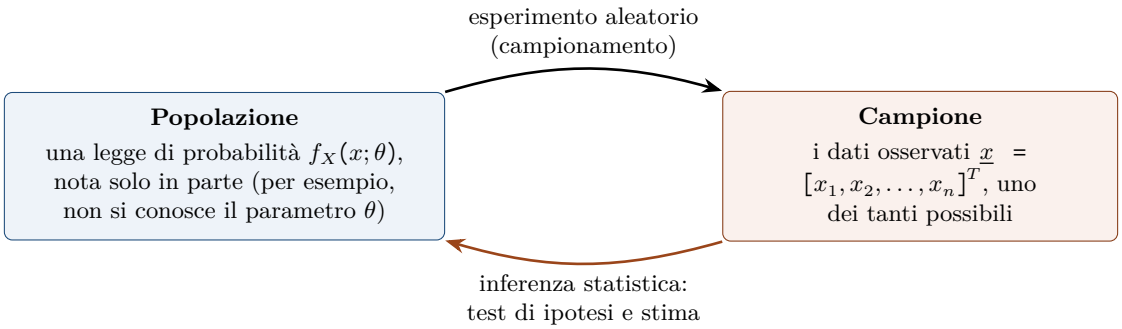


Figura 18.1: *La probabilità va dalla legge ai dati; l'inferenza statistica torna indietro, dai dati alla legge.*

La media campione e la legge dei grandi numeri

Il primo esempio di inferenza è il più naturale: per conoscere la media di una popolazione si fa la media dei dati.

Media campione

Dato un insieme di dati $\underline{x} \in \mathcal{X}^n \subseteq \mathbb{R}^n$, la **media campione** è

$$\overline{x}_n = \frac{1}{n}\sum_{i=1}^{n} x_i.$$

Se i dati sono visti come variabili aleatorie, $\underline{X} = [X_1, \ldots, X_n]^T$, la media campione $\overline{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$ è a sua volta una variabile aleatoria.

La convenzione delle lettere è importante: $\overline{x}_n$, con le lettere piccole, è un numero, la media di *questi* dati (una realizzazione); $\overline{X}_n$, con le lettere grandi, è la media di un campione *aleatorio*, che cambia da un ricampionamento all'altro. È la media campionaria del Capitolo 5, dove avevamo visto in una simulazione che, lanciando tante volte un dado, si avvicina a $E[X] = 3{,}5$. Ora lo dimostriamo. Serve un'ipotesi sul modo in cui sono stati raccolti i dati.

Variabili indipendenti e identicamente distribuite

Le variabili $X_1, X_2, \ldots, X_n$ si dicono **indipendenti e identicamente distribuite**, in breve **i.i.d.**, se sono statisticamente indipendenti e hanno tutte la stessa legge (la stessa pmf o la stessa PDF).

È il modello delle prove ripetute: ogni dato è prodotto dallo stesso esperimento, rifatto da capo senza che un risultato influenzi gli altri. In particolare dati i.i.d. hanno tutti la stessa media $\mu = E[X_i]$ e la stessa varianza $\sigma^2 = E[(X_i - \mu)^2]$.

Teorema 18.1 — Media e varianza della media campione

Se $X_1, \ldots, X_n$ sono i.i.d. con media μ e varianza σ^2:

$$E\left[\overline{X}_n\right] = E\left[\frac{X_1 + X_2 + \cdots + X_n}{n}\right] = \mu, \qquad \mathrm{VAR}\left[\overline{X}_n\right] = \mathrm{VAR}\left[\frac{X_1 + X_2 + \cdots + X_n}{n}\right] = \frac{\sigma^2}{n}.$$

Dimostrazione

Passo 1 — La media. Per la linearità della media, $E[\overline{X}_n] = \frac{1}{n}\left(E[X_1] + \cdots + E[X_n]\right) = \frac{1}{n}\, n\mu = \mu$.

Passo 2 — La varianza. Una costante moltiplicativa esce dalla varianza al quadrato ($\mathrm{VAR}[cY] = c^2\,\mathrm{VAR}[Y]$, perché la varianza è la media di un quadrato). Le X_i sono indipendenti, quindi incorrelate, e la varianza della somma è la somma delle varianze (Capitolo 9):

$$\mathrm{VAR}\left[\overline{X}_n\right] = \frac{1}{n^2}\,\mathrm{VAR}[X_1 + X_2 + \cdots + X_n] = \frac{1}{n^2}\left(\sigma^2 + \sigma^2 + \cdots + \sigma^2\right) = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}.$$

■

La media campione ha la stessa media dei singoli dati, ma una varianza n volte più piccola: la sua deviazione standard è $\frac{\sigma}{\sqrt{n}}$. Mediando, gli scarti in su e quelli in giù si compensano in parte. È proprio questo che fa funzionare il teorema seguente.

Teorema 18.2 — Legge debole dei grandi numeri

Sia $X_1, X_2, \ldots, X_n, \ldots$ una successione di variabili aleatorie i.i.d., con media $E[X_i] = \mu$ e varianza $E[(X_i - \mu)^2] = \sigma^2$. Allora, per ogni $\epsilon > 0$,

$$\lim_{n\to\infty} P\left(\left|\frac{X_1 + X_2 + \cdots + X_n}{n} - \mu\right| > \epsilon\right) = 0.$$

Dimostrazione — con la disuguaglianza di Chebyshev

Passo 1 — Chebyshev per la media campione. La disuguaglianza di Chebyshev (Capitolo 7) dice che una variabile si allontana dalla sua media di almeno k deviazioni standard con probabilità al più $\frac{1}{k^2}$. Per $\overline{X}_n$ la media è μ e la deviazione standard è $\frac{\sigma}{\sqrt{n}}$ (teorema precedente); scegliendo k in modo che la distanza $k\frac{\sigma}{\sqrt{n}}$ sia proprio ϵ, cioè $k = \frac{\epsilon\sqrt{n}}{\sigma}$:

$$P\left(\left|\overline{X}_n - \mu\right| > \epsilon\right) \le P\left(\left|\overline{X}_n - \mu\right| \ge \epsilon\right) \le \frac{1}{k^2} = \frac{\sigma^2}{n\,\epsilon^2}.$$

Passo 2 — Il limite. Il secondo membro tende a 0 per $n \to \infty$ (σ ed ϵ sono fissati), e una probabilità non può essere negativa: la probabilità, schiacciata fra 0 e una quantità che tende a 0, tende a 0.

■

In parole: comunque si fissi una tolleranza ϵ, piccola quanto si vuole, con abbastanza dati la media campione cade a meno di ϵ dalla media vera con probabilità vicina quanto si vuole a 1. La figura mostra sei campioni diversi di lanci di un dado: ogni media campione segue una strada sua, ma tutte entrano nell'«imbuto» che si stringe come $\frac{1}{\sqrt{n}}$.

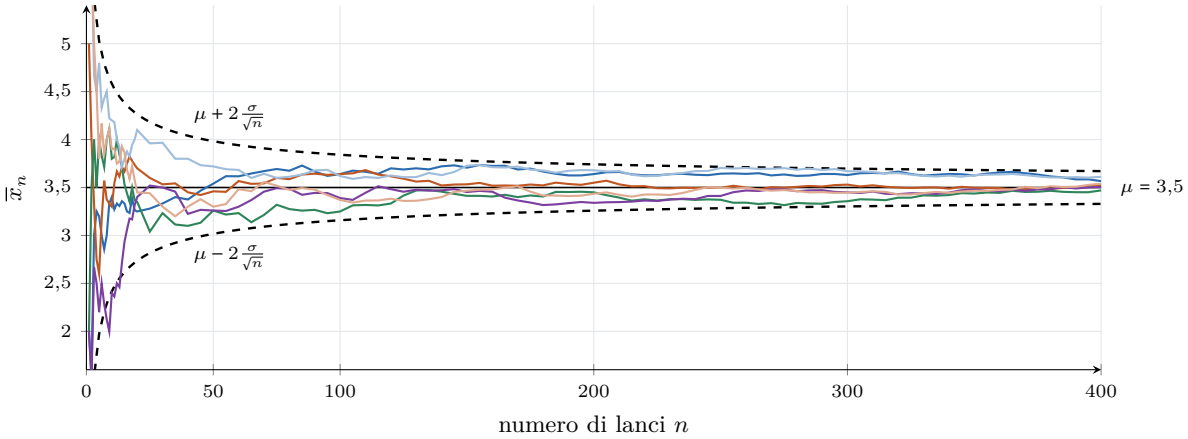


Figura 18.2: *Sei campioni di lanci di un dado onesto (simulazione) e le loro medie campione $\overline{x}_n$ al crescere di n. Le curve tratteggiate distano due deviazioni standard della media campione, $2\frac{\sigma}{\sqrt{n}}$ con $\sigma = \sqrt{35/12} \approx 1{,}71$, dalla media vera: l'imbuto si stringe e le medie vi restano dentro quasi sempre.*

Esempio 18.1 — Quanti lanci servono?

Si vuole stimare la probabilità di «testa» di una moneta onesta con la frequenza relativa, e si vuole che l'errore superi 0,05 con probabilità al più del 5%. Con $X_i = 1$ se esce testa e 0 altrimenti, $\mu = \frac{1}{2}$ e $\sigma^2 = E[X^2] - \mu^2 = \frac{1}{2} - \frac{1}{4} = \frac{1}{4}$. Per la dimostrazione della legge dei grandi numeri

$$P\left(\left|\overline{X}_n - \tfrac{1}{2}\right| > 0{,}05\right) \le \frac{\sigma^2}{n\,\epsilon^2} = \frac{1/4}{n \cdot 0{,}0025} = \frac{100}{n},$$

che è al più 0,05 se $n \ge 2000$. Duemila lanci bastano di sicuro, qualunque cosa succeda. Vedremo alla fine del capitolo che, grazie al teorema centrale del limite, ne bastano in realtà circa 400: Chebyshev vale per qualsiasi legge, e per questo è prudente.

Le frequenze tendono alle probabilità

La legge dei grandi numeri giustifica l'interpretazione frequentista della probabilità da cui eravamo partiti nel Capitolo 3.

Teorema 18.3 — La frequenza relativa tende alla probabilità

Si ripetano n copie indipendenti di un esperimento, in ciascuna delle quali può verificarsi un evento E. La frazione $f_n(E)$ delle n prove in cui E si è verificato tende alla probabilità $P(E)$, nel senso della legge debole dei grandi numeri: per ogni $\epsilon > 0$, $\lim_{n\to\infty} P\left(|f_n(E) - P(E)| > \epsilon\right) = 0$.

Dimostrazione — con le variabili indicatrici

Passo 1 — Una variabile che conta. Si pone

$$X_i = \begin{cases} 1 & \text{se } E \text{ si realizza nell'esperimento } i\text{-esimo,} \\ 0 & \text{se } E \text{ non si realizza nell'esperimento } i\text{-esimo.} \end{cases}$$

La somma $X_1 + X_2 + \cdots + X_n$ conta le prove, fra le prime n, in cui si è verificato E; divisa per n è proprio la frequenza relativa: $f_n(E) = \overline{X}_n$.

Passo 2 — Media e varianza. Le X_i sono i.i.d. (le prove sono copie indipendenti dello stesso esperimento), con $E[X_i] = 1 \cdot P(E) + 0 \cdot P(\overline{E}) = P(E)$ e varianza finita $P(E)\,(1 - P(E))$ (come per la Bernoulli del Capitolo 7).

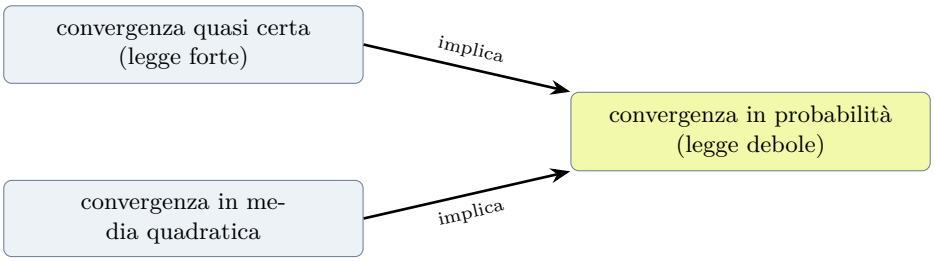
Passo 3 — Si applica la legge dei grandi numeri. con $\mu = P(E)$.

■

Modi diversi di convergere

Per una successione di numeri «tendere a un limite» ha un solo significato (Capitolo 3). Per una successione di *variabili aleatorie*, come le medie campione $\overline{X}_1, \overline{X}_2, \ldots$, ce ne sono diversi.

- **Convergenza in probabilità** (o *convergenza debole*): per ogni $\epsilon > 0$, $\lim_{n\to\infty} P\left(\left|\overline{X}_n - E[X]\right| > \epsilon\right) = 0$. È quella della legge debole dei grandi numeri. Si noti che è il limite di una successione di **numeri**, le probabilità: una successione deterministica.
- **Convergenza quasi certa** (o *forte*, o *con probabilità uno*): la probabilità che la successione aleatoria delle medie campione converga a $E[X]$ vale 1, $P\left(\lim_{n\to\infty} \overline{X}_n = E[X]\right) = 1$. Al limite, la probabilità di allontanarsi dalla media statistica è zero. È la **legge forte dei grandi numeri**, che vale anch'essa per variabili i.i.d. (non la dimostriamo). Qui l'ordine è rovesciato: è la probabilità di un limite, cioè la probabilità che la singola realizzazione della successione, la singola curva della figura, converga.
- **Convergenza in media quadratica**: $\lim_{n\to\infty} E\left[\left(\overline{X}_n - E[X]\right)^2\right] = 0$. Per la media campione è immediata: quella media è proprio la varianza di $\overline{X}_n$, cioè $\frac{\sigma^2}{n} \to 0$.



Le due convergenze di sinistra sono più forti e implicano quella di destra. Per la media quadratica lo si vede con la disuguaglianza di Markov, come nella legge dei grandi numeri: se Y_n è una successione di variabili e c un numero,

$$P\left(|Y_n - c| > \epsilon\right) = P\left((Y_n - c)^2 > \epsilon^2\right) \leq \frac{E\left[(Y_n - c)^2\right]}{\epsilon^2},$$

e se il numeratore tende a zero anche la probabilità tende a zero.

Esempio 18.2 — Le frequenze di un alfabeto finito

I dati $\underline{x} \in \mathcal{X}^n$ abbiano un alfabeto discreto e finito, $\mathcal{X} = \{a_1, \ldots, a_M\}$, e le X_k siano i.i.d. con pmf p_X. Sia N_i il numero di volte in cui $X_k = a_i$ nel campione. Ogni dato vale a_i con probabilità $p_X(a_i)$, indipendentemente dagli altri, quindi N_i conta i successi in n prove ed è binomiale (Capitolo 5):

$$P(N_i = k) = \binom{n}{k} p_X(a_i)^k \left[1 - p_X(a_i)\right]^{n-k}.$$

La frequenza relativa $\frac{N_i}{n}$ è anch'essa una variabile aleatoria. Con la media $n\,p_X(a_i)$ e la varianza $n\,p_X(a_i)(1 - p_X(a_i))$ della binomiale (Capitolo 7):

$$E\left[\frac{N_i}{n}\right] = p_X(a_i), \qquad \mathrm{VAR}\left[\frac{N_i}{n}\right] = \frac{p_X(a_i)\,(1 - p_X(a_i))}{n}.$$

Siccome la media di $\frac{N_i}{n}$ è proprio $p_X(a_i)$, la varianza è la media dello scarto quadratico dalla probabilità, e quindi

$$\lim_{n\to\infty} E\left[\left(\frac{N_i}{n} - p_X(a_i)\right)^2\right] = \lim_{n\to\infty} \frac{p_X(a_i)\,(1 - p_X(a_i))}{n} = 0 :$$

la frequenza relativa converge alla probabilità in media quadratica (e quindi anche in probabilità).

Il teorema centrale del limite

La legge dei grandi numeri dice *dove* va a finire la media campione. Il teorema centrale del limite dice qualcosa di più sorprendente: *con quale forma* si distribuiscono le somme di tante variabili.

Si consideri la somma $Z_n = \sum_{i=1}^n X_i$ di n variabili i.i.d., con densità $f_{X_i}(x) = f_X(x)$, media μ_X e varianza σ_X^2. Per la linearità della media e per l'indipendenza

$$\mu_{Z_n} = n\,\mu_X, \qquad \sigma_{Z_n}^2 = n\,\sigma_X^2 :$$

la somma ha un centro che si sposta e una larghezza che cresce. Per confrontare somme con n diversi conviene standardizzarle (Capitolo 15): la variabile

$$S_n = \frac{Z_n - \mu_{Z_n}}{\sigma_{Z_n}} = \frac{Z_n - n\,\mu_X}{\sqrt{n}\,\sigma_X}$$

ha sempre, indipendentemente da n, valore atteso nullo e varianza unitaria: è una variabile standard.

Teorema 18.4 — Teorema centrale del limite

Sotto ipotesi poco restrittive sulla densità $f_X(x)$ delle X_i (per esempio, varianza finita), al tendere di n all'infinito la CDF di S_n tende alla CDF di una gaussiana standard:

$$\lim_{n\to\infty} F_{S_n}(x) = \lim_{n\to\infty} P(S_n \le x) = \Phi(x) = \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}\,\mathrm{d}t = 1 - Q(x).$$

In sostanza, la somma di un gran numero di variabili aleatorie statisticamente indipendenti segue con buona approssimazione una legge gaussiana, **a prescindere dalla particolare distribuzione di ciascuna di esse**.

Le slide osservano che l'ipotesi di equidistribuzione permette una dimostrazione particolarmente semplice, e che il teorema vale anche sotto ipotesi meno restrittive (variabili non identiche), con una dimostrazione più complessa. Qui ne diamo l'idea, con uno strumento nuovo; due fatti tecnici vanno accettati senza dimostrazione.

Dimostrazione — l'idea, con la funzione generatrice dei momenti

Passo 1 — Uno strumento: la funzione generatrice dei momenti. Per una variabile Y si definisce $M_Y(t) = E\left[e^{tY}\right]$, una funzione del numero t. Si accettano due fatti: se due variabili hanno la stessa M (per t vicino a 0) hanno la stessa legge; e se $M_{Y_n}(t) \to M_Y(t)$, allora le CDF di Y_n tendono a quella di Y.

Passo 2 — La M della gaussiana standard. Completando il quadrato, $tx - \frac{x^2}{2} = -\frac{(x-t)^2}{2} + \frac{t^2}{2}$, quindi

$$M(t) = \int_{-\infty}^{\infty} e^{tx}\,\frac{1}{\sqrt{2\pi}}e^{-\frac{x^2}{2}}\,\mathrm{d}x = e^{\frac{t^2}{2}}\int_{-\infty}^{\infty}\frac{1}{\sqrt{2\pi}}e^{-\frac{(x-t)^2}{2}}\,\mathrm{d}x = e^{\frac{t^2}{2}},$$

perché l'ultimo integrale è l'area di una gaussiana di media t, cioè 1.

Passo 3 — La M di S_n. Siano $Y_i = \frac{X_i-\mu_X}{\sigma_X}$ i dati standardizzati: sono i.i.d., con media 0 e varianza 1, e $S_n = \frac{1}{\sqrt{n}}\sum_i Y_i$. L'esponenziale di una somma è il prodotto degli esponenziali, e la media di un prodotto di variabili indipendenti è il prodotto delle medie (Capitolo 9):

$$M_{S_n}(t) = E\left[e^{\frac{t}{\sqrt{n}}Y_1}\cdots e^{\frac{t}{\sqrt{n}}Y_n}\right] = E\left[e^{\frac{t}{\sqrt{n}}Y_1}\right]\cdots E\left[e^{\frac{t}{\sqrt{n}}Y_n}\right] = \left[M_Y\left(\frac{t}{\sqrt{n}}\right)\right]^n.$$

Passo 4 — Per n grande l'argomento è piccolo. Con la serie esponenziale $e^u = 1 + u + \frac{u^2}{2} + \cdots$ (Capitolo 5) e la linearità della media, ricordando $E[Y] = 0$ ed $E[Y^2] = 1$:

$$M_Y\left(\frac{t}{\sqrt{n}}\right) = 1 + \frac{t}{\sqrt{n}}\,E[Y] + \frac{t^2}{2n}\,E[Y^2] + \cdots = 1 + \frac{t^2}{2n} + (\text{termini che vanno a zero più in fretta di } \tfrac{1}{n}).$$

Tutte le informazioni sulla legge di Y oltre a media e varianza finiscono nei termini trascurabili: per questo il risultato non dipende dalla legge di partenza.

Passo 5 — Il limite. Per il limite $\left(1 + \frac{x}{n}\right)^n \to e^x$ (Capitolo 5, con $x = \frac{t^2}{2}$),

$$M_{S_n}(t) = \left[1 + \frac{t^2}{2n} + \cdots\right]^n \longrightarrow e^{\frac{t^2}{2}},$$

che è la M della gaussiana standard: per il secondo fatto del passo 1, $F_{S_n}(x) \to \Phi(x)$.

■

Perché solo un'idea

La funzione generatrice dei momenti non esiste per tutte le variabili (per la Cauchy, per esempio, la media di e^{tY} è infinita). La dimostrazione completa usa la *funzione caratteristica* $E\left[e^{jtY}\right]$, con l'unità immaginaria j, che esiste sempre: i passaggi sono gli stessi. I due fatti accettati nel passo 1 sono teoremi di analisi che richiedono strumenti oltre questo corso.

Le slide aggiungono un'osservazione pratica: sommando N variabili uniformi i.i.d., già per $N = 15$ si è vicini a una densità normale, ma la convergenza è rapida attorno alla media e lenta sulle code. La figura lo mostra: a sinistra le densità di S_N per $N = 1, 2, 3$ (la somma di due uniformi ha densità triangolare, di tre è fatta di archi di parabola), a destra il confronto sulle code per $N = 15$, in scala logaritmica.

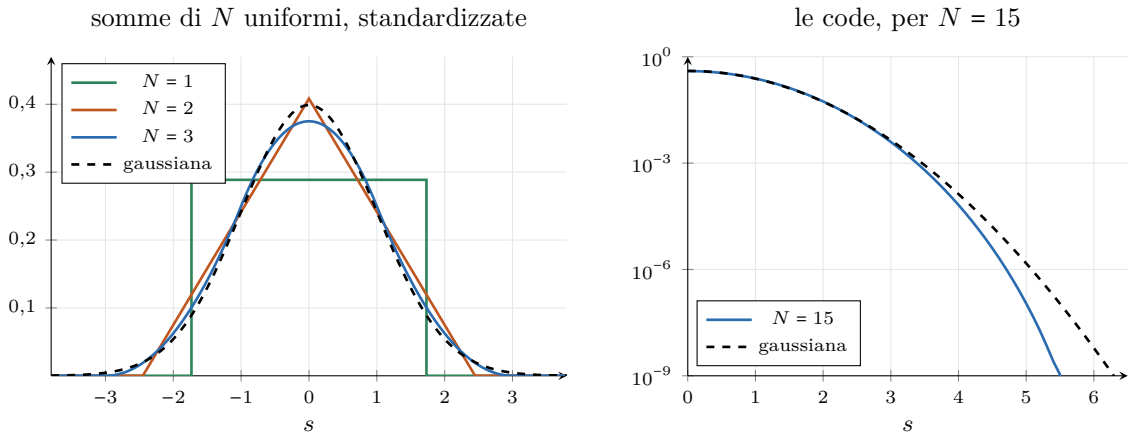
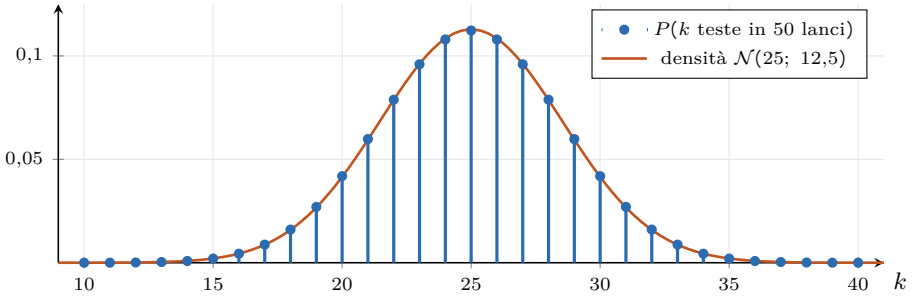


Figura 18.3: *Il teorema centrale del limite in azione. A sinistra: la densità della somma standardizzata di N uniformi diventa una campana già con $N = 3$. A destra, in scala logaritmica: con $N = 15$ le due curve coincidono vicino al centro, ma a $s = 5$ differiscono di un fattore 13, e oltre $s = \sqrt{45} \approx 6{,}7$ la somma di 15 uniformi non arriva proprio, mentre la gaussiana sì.*

Esempio 18.3 — La binomiale diventa gaussiana

Il numero di teste in n lanci di una moneta è una somma di n variabili di Bernoulli i.i.d.: per il teorema centrale del limite, per n grande è circa gaussiano, con la stessa media np e la stessa varianza $np(1-p)$ della binomiale. Per $n = 50$ e $p = \frac{1}{2}$, la pmf binomiale e la densità $\mathcal{N}(25;\ 12{,}5)$ sono quasi indistinguibili.



Torniamo all'esempio dei lanci di una moneta. Per il teorema centrale del limite $\overline{X}_n$ è circa gaussiana, con media $\frac{1}{2}$ e deviazione standard $\frac{\sigma}{\sqrt{n}} = \frac{1}{2\sqrt{n}}$; con la regola delle code del Capitolo 15 (due code uguali):

$$P\left(\left|\overline{X}_n - \tfrac{1}{2}\right| > 0{,}05\right) \approx 2\,Q\left(\frac{0{,}05}{1/(2\sqrt{n})}\right) = 2\,Q\left(0{,}1\,\sqrt{n}\right).$$

Questo vale 0,05 quando $Q(0{,}1\sqrt{n}) = 0{,}025$, cioè $0{,}1\sqrt{n} \approx 1{,}96$ (dalle tavole della funzione Q): $n \approx 385$, contro i 2000 garantiti da Chebyshev.

Quando il teorema non vale

Servono la media e la varianza finite. Per la variabile di Cauchy (Capitoli 11 e 13), che non ha né l'una né l'altra, la media di n dati i.i.d. è di nuovo una Cauchy, larga come un dato singolo: né la legge dei grandi numeri né il teorema centrale del limite funzionano, come si vedeva nella figura delle medie progressive del Capitolo 11.

Perché la gaussiana è ovunque

Il teorema centrale del limite spiega l'onnipresenza della gaussiana annunciata nel Capitolo 15. Il rumore termico di un resistore è la somma degli effetti di moltissimi elettroni; un errore di misura è la somma di tante piccole cause indipendenti; l'altezza di una persona dipende da molti geni e da molti fattori ambientali. Quale che sia la legge dei singoli contributi, la somma è gaussiana.

In sintesi

- L'**inferenza statistica** risale dai dati alla legge che li ha prodotti; gli obiettivi sono i test di ipotesi e la stima. La **statistica descrittiva** guarda solo i dati.
- Per dati i.i.d., la **media campione** $\overline{X}_n$ ha media μ e varianza $\frac{\sigma^2}{n}$.
- **Legge debole dei grandi numeri**: $P(\left|\overline{X}_n - \mu\right| > \epsilon) \leq \frac{\sigma^2}{n\epsilon^2} \to 0$ (Chebyshev). Le frequenze relative tendono alle probabilità.
- Convergenza in probabilità (legge debole), quasi certa (legge forte), in media quadratica; le ultime due implicano la prima.
- **Teorema centrale del limite**: la somma standardizzata $S_n = \frac{Z_n - n\mu_X}{\sqrt{n}\,\sigma_X}$ di n variabili i.i.d. ha CDF che tende a $\Phi(x) = 1 - Q(x)$, qualunque sia la legge di partenza (con varianza finita). La convergenza è rapida al centro e lenta sulle code.

Decisioni bayesiane e classificazione binaria

L'idea principale della statistica inferenziale è che, osservato un campione sufficientemente ampio di una popolazione, si possono dedurre alcune caratteristiche che devono essere rispettate da qualsiasi altro campione. Spesso si ha anche una certa conoscenza a priori: per esempio si sa che il campione proviene da una popolazione la cui distribuzione è nota a meno di un insieme di parametri, cioè da una **famiglia di distribuzioni** indicizzate da un parametro θ. La domanda diventa: come si elaborano i dati per dedurre il valore del parametro?

Se il parametro può assumere solo un numero finito di valori, la domanda è una **decisione**: quale fra M spiegazioni dei dati è quella vera? È il problema di un ricevitore che deve capire quale simbolo è stato trasmesso, di un filtro che deve classificare un messaggio come posta indesiderata o no, di un test medico. In questo capitolo lo risolviamo nel caso **bayesiano**, in cui si conoscono le probabilità a priori delle varie spiegazioni.

Regole di decisione e rischio bayesiano

Si abbia un insieme di dati $\underline{x} \in \mathcal{X}^n$, realizzazione di un vettore aleatorio $\underline{X}$. I dati possono seguire una fra M diverse leggi di probabilità: c'è un insieme di M **ipotesi** mutuamente esclusive $\{H_i\}_{i=1}^M$, ciascuna delle quali definisce una diversa legge condizionata per i dati,

$$p_{\underline{X}}(\underline{x} \mid H_i), \qquad i = 1, 2, \ldots, M.$$

In altre parole $\underline{X}$ ha una distribuzione che appartiene a una famiglia di pmf $p_{\underline{X}}(\underline{x} \mid \theta)$, dove il valore del parametro θ (qui, l'indice i dell'ipotesi) non è noto. Si suppone inoltre di conoscere le **probabilità a priori** $\{P(H_i)\}_{i=1}^M$ di questi «stati della natura».

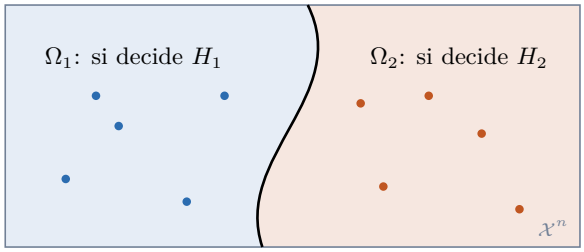
Regola di decisione

Una **regola di decisione** è una corrispondenza

$$D : \underline{x} \in \mathcal{X}^n \longmapsto D(\underline{x}) \in \{1, 2, \ldots, M\}$$

che, osservati i dati, decide quale dei possibili stati della natura è quello effettivamente attivo.

Dare una regola di decisione equivale a dividere l'insieme di tutti i dati possibili in M **regioni di decisione** $\Omega_i = \{\underline{x} : D(\underline{x}) = i\}$: se i dati cadono in Ω_i si decide per l'ipotesi H_i. Le regioni sono una partizione di $\mathcal{X}^n$ (Capitolo 1): non si sovrappongono e lo ricoprono tutto, perché per ogni dato si prende una e una sola decisione.



L'insieme $\mathcal{X}^n$ di tutti i dati possibili è diviso in due regioni. Progettare la regola di decisione vuol dire scegliere da che parte mettere ogni possibile $\underline{x}$, cioè dove tracciare il confine.

Figura 19.1: *Una regola di decisione fra due ipotesi è una partizione dei dati in due regioni.*

Per scegliere la regola migliore bisogna dire quanto costano gli errori. Non tutti gli errori sono uguali: scambiare un messaggio importante per posta indesiderata è peggio del contrario.

Matrice dei costi

La **matrice dei costi** è la matrice $M \times M$

$$\underline{\underline{C}} = \begin{bmatrix} C_{11} & C_{12} & \cdots & C_{1M} \\ C_{21} & C_{22} & \cdots & C_{2M} \\ \vdots & \vdots & \ddots & \vdots \\ C_{M1} & C_{M2} & \cdots & C_{MM} \end{bmatrix},$$

dove C_{ij} è il costo associato all'evento «si prende la decisione per l'ipotesi i, $D(\underline{x}) = i$, e lo stato della natura è H_j», cioè l'ipotesi vera è la j.

Rischio medio bayesiano

Il **rischio medio bayesiano** di una regola di decisione D è il costo medio:

$$R = \sum_{i=1}^{M} \sum_{j=1}^{M} C_{ij}\, P\{D(\underline{X}) = i,\, H = H_j\}.$$

Data una matrice dei costi $\underline{\underline{C}}$, una **regola di decisione ottima** è una corrispondenza $D(\underline{x})$ che minimizza il rischio bayesiano.

Il rischio è la media di una variabile aleatoria, il costo: il costo C_{ij} si paga con la probabilità che si decida i quando è vera j. Il caso più comune è quello in cui le decisioni giuste non costano nulla e quelle sbagliate costano tutte allo stesso modo.

Teorema 19.1 — Costi uniformi: il rischio è la probabilità di errore

Se $C_{ii} = 0$ per $i = 1, 2, \ldots, M$ e $C_{ij} = 1$ per ogni $i \neq j$, allora il rischio medio bayesiano coincide con la probabilità di commettere un errore nella classificazione:

$$R = \sum_{i=1}^{M} \sum_{\substack{j=1 \\ j \neq i}}^{M} P\{D(\underline{X}) = i,\, H = H_j\} = P(e).$$

Dimostrazione

Passo 1. I termini con $i = j$ hanno costo zero e spariscono; gli altri hanno costo 1 e restano con la loro probabilità. Gli eventi $\{D(\underline{X}) = i, H = H_j\}$ con $i \neq j$ sono incompatibili (in ogni prova si prende una sola decisione ed è vera una sola ipotesi), e la loro unione è l'evento «la decisione è sbagliata»: per l'additività la somma delle loro probabilità è $P(e)$. ■

La classificazione binaria a minima probabilità di errore

Supponiamo ora $M = 2$, $C_{11} = C_{22} = 0$ e $C_{12} = C_{21} = 1$. Per il teorema precedente

$$R = P\{D(\underline{X}) = 2,\, H_1\} + P\{D(\underline{X}) = 1,\, H_2\} = P(e).$$

Progettare una regola di decisione vuol dire determinare una partizione di $\mathcal{X}^n$ in due sottoinsiemi Ω_1 e Ω_2, con

$$D(\underline{x}) = \begin{cases} 1 & \text{se } \underline{x} \in \Omega_1, \\ 2 & \text{se } \underline{x} \in \Omega_2, \end{cases} \qquad \text{e quindi} \qquad P(e) = P\{\underline{X} \in \Omega_1,\, H_2\} + P\{\underline{X} \in \Omega_2,\, H_1\}.$$

Cerchiamo la regola ottima, cioè quella con la minima probabilità di errore. Supponiamo prima che le osservazioni siano un vettore aleatorio **discreto**, con pmf condizionate $p_{\underline{X}}(\underline{x} \mid H_i)$ note.

Teorema 19.2 — Regola a minima probabilità di errore

La regola di decisione che minimizza la probabilità di errore è

$$\underline{x} \in \Omega_1 \iff p_{\underline{X}}(\underline{x} \mid H_1)\, P(H_1) > p_{\underline{X}}(\underline{x} \mid H_2)\, P(H_2),$$

o, in modo equivalente,

$$L(\underline{x}) = \frac{p_{\underline{X}}(\underline{x} \mid H_1)}{p_{\underline{X}}(\underline{x} \mid H_2)} \underset{H_2}{\overset{H_1}{\gtrless}} \frac{P(H_2)}{P(H_1)} = \eta,$$

dove il simbolo $\overset{H_1}{\underset{H_2}{\gtrless}}$ si legge: «se vale $>$ si decide H_1, se vale $<$ si decide H_2». La quantità $L(\underline{x})$ si chiama **rapporto di verosimiglianza** (*likelihood ratio*) fra le due ipotesi.

Dimostrazione — la probabilità di errore è il complemento di quella di decisione corretta

Passo 1 — Si scrivono le due probabilità congiunte. Per la probabilità composta,

$$P\{\underline{X} \in \Omega_1,\, H_2\} = \sum_{\underline{x} \in \Omega_1} P\{\underline{X} = \underline{x} \mid H_2\}\, P(H_2), \qquad P\{\underline{X} \in \Omega_2,\, H_1\} = \sum_{\underline{x} \in \Omega_2} P\{\underline{X} = \underline{x} \mid H_1\}\, P(H_1).$$

Passo 2 — Si passa al complemento. Le due regioni si spartiscono tutti i dati, e la somma di una pmf su tutti i dati vale 1: quindi $\sum_{\underline{x} \in \Omega_1} p_{\underline{X}}(\underline{x} \mid H_2) = 1 - \sum_{\underline{x} \in \Omega_2} p_{\underline{X}}(\underline{x} \mid H_2)$, e lo stesso per H_1. Sostituendo e usando $P(H_1) + P(H_2) = 1$:

$$P(e) = 1 - \left[\sum_{\underline{x} \in \Omega_1} p_{\underline{X}}(\underline{x} \mid H_1)\, P(H_1) + \sum_{\underline{x} \in \Omega_2} p_{\underline{X}}(\underline{x} \mid H_2)\, P(H_2) \right].$$

La quantità fra parentesi quadre è la probabilità di una decisione corretta.

Passo 3 — Si massimizza un dato alla volta. $P(e)$ è minima quando la parentesi quadra è massima. Ogni vettore $\underline{x}$ va messo o in Ω_1 o in Ω_2, non in entrambe: se va in Ω_1 contribuisce alla parentesi con $p_{\underline{X}}(\underline{x} \mid H_1)P(H_1)$, se va in Ω_2 con $p_{\underline{X}}(\underline{x} \mid H_2)P(H_2)$. La scelta migliore è metterlo dove il suo contributo è più grande: è la regola dell'enunciato.

Passo 4 — Il rapporto. Dividendo i due membri della disuguaglianza per le quantità positive $p_{\underline{X}}(\underline{x} \mid H_2)$ e $P(H_1)$ si ottiene la forma con il rapporto di verosimiglianza. (Se i due membri sono uguali, le due decisioni danno lo stesso contributo e si può scegliere a piacere.)

■

La stessa regola si legge anche in un altro modo, che le dà il nome. Per la legge di Bayes

$$P\{H_i \mid \underline{X} = \underline{x}\} = \frac{P\{\underline{X} = \underline{x} \mid H_i\}\, P(H_i)}{P\{\underline{X} = \underline{x}\}} = \frac{p_{\underline{X}}(\underline{x} \mid H_i)\, P(H_i)}{p_{\underline{X}}(\underline{x})},$$

e il denominatore è lo stesso per le due ipotesi: confrontare $p_{\underline{X}}(\underline{x} \mid H_i)P(H_i)$ equivale a confrontare le probabilità a posteriori.

Regola MAP e regola ML

La regola a minima probabilità di errore si chiama anche **regola MAP** (*Massima probabilità A Posteriori*): decide per l'ipotesi la cui probabilità a posteriori, dati i dati osservati, è massima. Se le due ipotesi sono a priori equiprobabili, la soglia vale $\eta = 1$ e la regola diventa la **regola a massima verosimiglianza**, o **regola ML** (*Maximum Likelihood*): decide per l'ipotesi che rende più probabili i dati osservati.

Le probabilità a priori spostano la soglia: se H_2 è a priori molto più probabile di H_1, la soglia η è grande, e per decidere H_1 servono dati che la favoriscano nettamente. Le **probabilità di errore condizionate** sono

$$P(e \mid H_1) = P\{L(\underline{X}) < \eta \mid H_1\}, \qquad P(e \mid H_2) = P\{L(\underline{X}) > \eta \mid H_2\},$$

e per la legge della probabilità totale

$$P(e) = P(H_1)\, P(e \mid H_1) + P(H_2)\, P(e \mid H_2).$$

Esempio: da quale sorgente vengono i bit?

Le osservazioni sono n variabili binarie i.i.d., estratte con la stessa probabilità da una sorgente con $P\{X_i = 1\} = p_1$ (ipotesi H_1) o da una sorgente con $P\{X_i = 1\} = p_2$ (ipotesi H_2), con $p_1 > p_2$. Una sequenza precisa con w uni e $n - w$ zeri ha probabilità $p_i^{w}(1-p_i)^{n-w}$ (i bit sono indipendenti), quindi

$$p_{\underline{X}}(\underline{x} \mid H_i) = p_i^{w_H(\underline{x})}\,(1-p_i)^{n-w_H(\underline{x})},$$

dove $w_H(\underline{x})$ è il **peso di Hamming** della sequenza binaria osservata, cioè il numero dei suoi «1».

Teorema 19.3 — Il test sul peso di Hamming

Con ipotesi equiprobabili, il test a minima probabilità di errore fra le due sorgenti è

$$w_H(\underline{x}) \underset{H_2}{\overset{H_1}{\gtrless}} \eta_1 = n\,\frac{\ln\dfrac{1-p_2}{1-p_1}}{\ln\dfrac{p_1(1-p_2)}{p_2(1-p_1)}}\,:$$

si decide per la sorgente con più uni se la sequenza ha abbastanza uni.

Dimostrazione

Passo 1 — Il rapporto di verosimiglianza. Con $P(H_1) = P(H_2) = \frac{1}{2}$ la soglia è $\eta = 1$, e raccogliendo le potenze con lo stesso esponente:

$$L(\underline{x}) = \frac{p_1^{w_H(\underline{x})}(1-p_1)^{n-w_H(\underline{x})}}{p_2^{w_H(\underline{x})}(1-p_2)^{n-w_H(\underline{x})}} = \left(\frac{p_1}{p_2}\right)^{w_H(\underline{x})}\left(\frac{1-p_1}{1-p_2}\right)^{n-w_H(\underline{x})} \underset{H_2}{\overset{H_1}{\gtrless}} 1.$$

Passo 2 — Il logaritmo. Il logaritmo è una funzione crescente: applicato a entrambi i membri non cambia il verso della disuguaglianza, e trasforma le potenze in prodotti ($\ln a^b = b \ln a$) e il prodotto in somma. Con $w = w_H(\underline{x})$:

$$w \ln\frac{p_1}{p_2} + (n-w)\ln\frac{1-p_1}{1-p_2} \underset{H_2}{\overset{H_1}{\gtrless}} 0 \quad\Longleftrightarrow\quad w\left[\ln\frac{p_1}{p_2} - \ln\frac{1-p_1}{1-p_2}\right] \underset{H_2}{\overset{H_1}{\gtrless}} n\ln\frac{1-p_2}{1-p_1},$$

dove si è usato $-\ln\frac{1-p_1}{1-p_2} = \ln\frac{1-p_2}{1-p_1}$.

Passo 3 — Si isola il peso. La differenza di logaritmi è il logaritmo del quoziente: $w \ln\frac{p_1(1-p_2)}{p_2(1-p_1)} \underset{H_2}{\overset{H_1}{\gtrless}} n \ln\frac{1-p_2}{1-p_1}$. Siccome $p_1 > p_2$, si ha $\frac{p_1}{p_2} > 1$ e $\frac{1-p_2}{1-p_1} > 1$: tutti i logaritmi sono positivi, e dividendo per il coefficiente di w il verso non cambia. ∎

Si noti una cosa importante: per decidere non serve conoscere tutta la sequenza, ma solo quanti uni contiene. Una quantità calcolata dai dati che contiene tutto ciò che serve per la decisione si chiama, nel gergo della statistica inferenziale, **statistica sufficiente**: qui è $w_H(\underline{x})$.

Per le prestazioni, si osservi che sotto l'ipotesi H_i il peso $w_H(\underline{X})$ conta i successi in n prove indipendenti con probabilità p_i: è **binomiale** $\mathcal{B}(n, p_i)$ (Capitolo 5). Se η_1 non è intero,

$$P(e \mid H_1) = P\{w_H(\underline{X}) < \eta_1 \mid H_1\} = \sum_{i=0}^{\lfloor \eta_1 \rfloor} \binom{n}{i} p_1^i (1-p_1)^{n-i}, \qquad P(e \mid H_2) = P\{w_H(\underline{X}) > \eta_1 \mid H_2\} = \sum_{i=\lfloor \eta_1 \rfloor + 1}^{n} \binom{n}{i} p_2^i (1-p_2)^{n-i},$$

dove $\lfloor \eta_1 \rfloor$ è la **parte intera** di η_1 (il più grande intero che non la supera), e

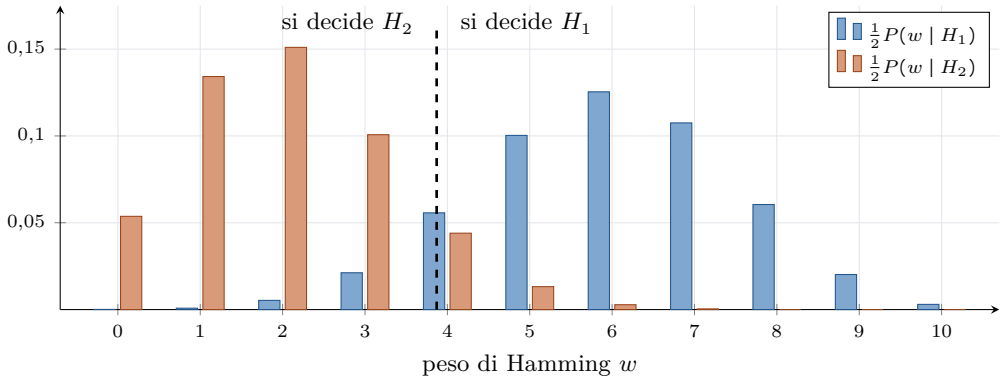
$$P(e) = P(e \mid H_1)\,P(H_1) + P(e \mid H_2)\,P(H_2) = \frac{1}{2}P(e \mid H_1) + \frac{1}{2}P(e \mid H_2).$$

Esempio 19.1 — Dieci bit, sorgenti con $p_1 = 0{,}6$ e $p_2 = 0{,}2$

La soglia è

$$\eta_1 = 10\,\frac{\ln(0{,}8/0{,}4)}{\ln\frac{0{,}6\cdot 0{,}8}{0{,}2\cdot 0{,}4}} = 10\,\frac{\ln 2}{\ln 6} = 10 \cdot \frac{0{,}693}{1{,}792} \approx 3{,}87 :$$

si decide H_1 se la sequenza contiene almeno 4 uni. Le probabilità di errore sono $P(e \mid H_1) = P\{w \le 3 \mid p = 0{,}6\} \approx 0{,}055$ e $P(e \mid H_2) = P\{w \ge 4 \mid p = 0{,}2\} \approx 0{,}121$, quindi $P(e) \approx 0{,}088$. Nella figura, per ogni peso w, le due barre sono $\frac{1}{2}P(w \mid H_1)$ e $\frac{1}{2}P(w \mid H_2)$: la regola ottima sceglie, per ogni w, la barra più alta, e l'errore è la somma delle barre più basse.



Che la soglia 4 sia la migliore si può verificare provando tutte le soglie possibili («si decide H_1 se $w \ge t$»):

soglia t	1	2	3	**4**	5	6	7
$P(e)$	0,446	0,313	0,167	**0,088**	0,100	0,187	0,309

Dati continui

Se i dati sono estratti da una fra M leggi continue, con densità condizionate $\{f_{\underline{X}|H_i}(\underline{x} \mid H_i)\}_{i=1}^{M}$, l'unica differenza è che le somme sulle regioni diventano integrali; per esempio, con $M = 2$,

$$P\{\underline{X} \in \Omega_1 \mid H_1\} = \int_{\Omega_1} f_{\underline{X}|H_1}(\underline{x} \mid H_1)\,\mathrm{d}\underline{x}, \qquad P\{\underline{X} \in \Omega_2 \mid H_2\} = \int_{\Omega_2} f_{\underline{X}|H_2}(\underline{x} \mid H_2)\,\mathrm{d}\underline{x},$$

dove $\mathrm{d}\underline{x}$ indica un integrale multiplo, su tutte le n componenti.

Teorema 19.4 — Regola a minima probabilità di errore per dati continui

$$\underline{x} \in \Omega_1 \iff f_{\underline{X}|H_1}(\underline{x} \mid H_1)\,P(H_1) > f_{\underline{X}|H_2}(\underline{x} \mid H_2)\,P(H_2), \qquad \text{cioè} \qquad L(\underline{x}) = \frac{f_{\underline{X}|H_1}(\underline{x} \mid H_1)}{f_{\underline{X}|H_2}(\underline{x} \mid H_2)} \underset{H_2}{\overset{H_1}{\gtrless}} \frac{P(H_2)}{P(H_1)}.$$

La quantità $L(\underline{x})$ è ancora il rapporto di verosimiglianza fra le due ipotesi.

Dimostrazione

Passo 1. È lo stesso ragionamento del caso discreto, con gli integrali al posto delle somme:

$$P(e) = 1 - \left[\int_{\Omega_1} f_{\underline{X}|H_1}(\underline{x} \mid H_1)\, P(H_1)\, \mathrm{d}\underline{x} + \int_{\Omega_2} f_{\underline{X}|H_2}(\underline{x} \mid H_2)\, P(H_2)\, \mathrm{d}\underline{x} \right],$$

e la parentesi è massima se ogni $\underline{x}$ viene messo nella regione in cui la funzione integranda è più grande.

■

ESEMPIO: LA MEDIA DI UNA POPOLAZIONE GAUSSIANA

I dati, con la stessa probabilità, sono la realizzazione di un vettore gaussiano con componenti indipendenti, tutte con la stessa varianza σ^2, e medie μ_1 (ipotesi H_1) oppure $\mu_2 < \mu_1$ (ipotesi H_2). Per esempio, n misure rumorose di una tensione che può valere μ_1 o μ_2. La densità dei dati (Capitolo 16) è

$$f_{\underline{X}|H_i}(\underline{x} \mid H_i) = \prod_{k=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}}\, e^{-\frac{(x_k - \mu_i)^2}{2\sigma^2}}.$$

Teorema 19.5 — Il test sulla media

Il test a minima probabilità di errore confronta la media campione con il punto di mezzo fra le due medie:

$$\frac{1}{n}\sum_{k=1}^{n} x_k \underset{H_2}{\overset{H_1}{\gtrless}} \frac{\mu_1 + \mu_2}{2},$$

e la sua probabilità di errore è

$$P(e) = Q\left(\sqrt{n}\,\frac{\mu_1 - \mu_2}{2\sigma}\right) \xrightarrow{n\to\infty} 0.$$

Dimostrazione

Passo 1 — Il rapporto di verosimiglianza. Con ipotesi equiprobabili la soglia è 1. Il prodotto delle costanti si semplifica, e il quoziente di esponenziali è l'esponenziale della differenza:

$$L(\underline{x}) = \frac{f_{\underline{X}|H_1}(\underline{x} \mid H_1)}{f_{\underline{X}|H_2}(\underline{x} \mid H_2)} = e^{\sum_{k=1}^{n} \frac{(x_k-\mu_2)^2-(x_k-\mu_1)^2}{2\sigma^2}} \underset{H_2}{\overset{H_1}{\gtrless}} 1.$$

Passo 2 — Il logaritmo. Prendendo il logaritmo naturale e moltiplicando per $2\sigma^2 > 0$ (il verso non cambia):

$$\sum_{k=1}^{n} \left[(x_k - \mu_2)^2 - (x_k - \mu_1)^2 \right] \underset{H_2}{\overset{H_1}{\gtrless}} 0.$$

Passo 3 — Si sviluppano i quadrati. I termini x_k^2 si cancellano:

$$\sum_{k=1}^{n} \left[x_k^2 + \mu_2^2 - 2x_k\mu_2 - x_k^2 - \mu_1^2 + 2x_k\mu_1 \right] = 2(\mu_1 - \mu_2) \sum_{k=1}^{n} x_k + n(\mu_2^2 - \mu_1^2) \underset{H_2}{\overset{H_1}{\gtrless}} 0.$$

Passo 4 — Si isola la somma. Con $\mu_1^2 - \mu_2^2 = (\mu_1 + \mu_2)(\mu_1 - \mu_2)$: $2(\mu_1 - \mu_2) \sum_k x_k \underset{H_2}{\overset{H_1}{\gtrless}} n(\mu_1 + \mu_2)(\mu_1 - \mu_2)$. Siccome $\mu_1 - \mu_2 > 0$, si può dividere per $2n(\mu_1 - \mu_2)$ senza cambiare il verso: è il test dell'enunciato.

Passo 5 — La statistica del test. Sotto H_i, $Z_n = \frac{1}{n} \sum_k X_k$ è una combinazione lineare di gaussiane indipendenti, quindi gaussiana (Capitolo 16), con media e varianza (Capitolo 18)

$$E[Z_n \mid H_i] = \frac{1}{n} \sum_{k=1}^{n} \mu_i = \mu_i, \qquad \mathrm{VAR}[Z_n \mid H_i] = \frac{1}{n^2} \sum_{k=1}^{n} \sigma^2 = \frac{\sigma^2}{n}.$$

Passo 6 — L'errore sotto H_1. Con la soglia $\eta = \frac{\mu_1+\mu_2}{2}$, si standardizza e si usa la funzione Q (Capitolo 15):

$$P(e \mid H_1) = P\{Z_n < \eta \mid H_1\} = 1 - Q\left(\frac{\eta - \mu_1}{\sigma/\sqrt{n}} \right) = 1 - Q\left(\sqrt{n}\, \frac{\mu_2 - \mu_1}{2\sigma} \right) = Q\left(\sqrt{n}\, \frac{\mu_1 - \mu_2}{2\sigma} \right),$$

perché $\eta - \mu_1 = \frac{\mu_2-\mu_1}{2} < 0$ e $Q(-x) = 1 - Q(x)$.

Passo 7 — L'errore sotto H_2.

$$P(e \mid H_2) = P\{Z_n > \eta \mid H_2\} = Q\left(\frac{\eta - \mu_2}{\sigma/\sqrt{n}} \right) = Q\left(\sqrt{n}\, \frac{\mu_1 - \mu_2}{2\sigma} \right).$$

Passo 8 — L'errore totale. Le due probabilità condizionate sono uguali, quindi anche la loro media pesata, $P(e) = P(H_1)P(e \mid H_1) + P(H_2)P(e \mid H_2)$, vale $Q\left(\sqrt{n}\frac{\mu_1-\mu_2}{2\sigma}\right)$. Per $n \to \infty$ l'argomento di Q diverge, perché $\mu_1 - \mu_2 > 0$ e $\sigma > 0$, e $Q(+\infty) = 0$.

■

Il risultato è molto intuitivo: si fa la media delle misure e si guarda se è più vicina a μ_1 o a μ_2. Anche qui la statistica sufficiente è una sola, $\sum_k x_k$ (o la media campione): delle n misure conta solo la somma. Le slide indicano con η_{Z_n} la media di Z_n; qui la chiamiamo μ_i per non confonderla con la soglia η. Con $n = 1$, $\mu_1 = A$ e $\mu_2 = -A$ si ritrova la trasmissione binaria del Capitolo 15: soglia 0 e $P_e = Q\left(\frac{A}{\sigma}\right)$. Ripetere la misura n volte equivale a moltiplicare per $\sqrt{n}$ il rapporto fra la distanza delle medie e la deviazione standard.

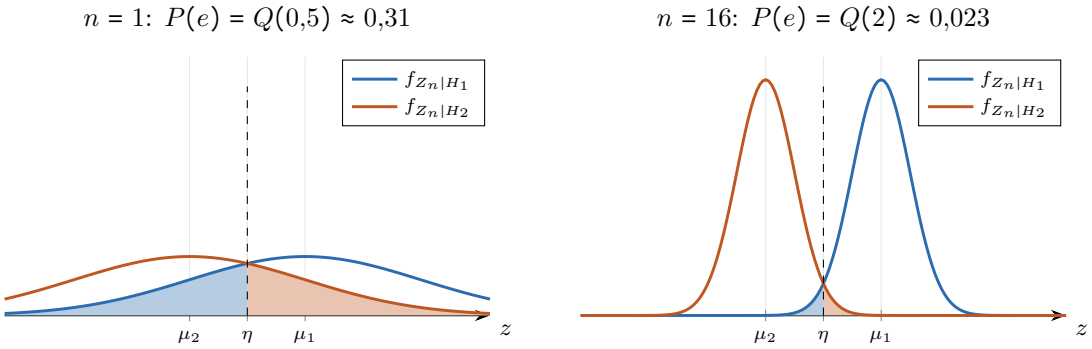


Figura 19.2: *Le densità della media campione Z_n sotto le due ipotesi, con $\mu_1 = 1$, $\mu_2 = 0$ e $\sigma = 1$; le code colorate oltre la soglia $\eta = \frac{1}{2}$ sono gli errori. Con 16 misure le campane sono quattro volte più strette (la deviazione standard è $\frac{\sigma}{\sqrt{n}}$) e si sovrappongono molto meno.*

In sintesi

- Una **regola di decisione** $D(\underline{x}) \in \{1, \ldots, M\}$ è una partizione dei dati in regioni Ω_i. Il **rischio bayesiano** $R = \sum_{i,j} C_{ij} P\{D = i, H_j\}$ pesa le decisioni con i costi; con costi 0 (giusto) e 1 (sbagliato) è la probabilità di errore.
- **Regola MAP** (minima $P(e)$): $L(\underline{x}) = \frac{p(\underline{x}|H_1)}{p(\underline{x}|H_2)} \underset{H_2}{\overset{H_1}{\gtrless}} \frac{P(H_2)}{P(H_1)}$, cioè si decide per la massima probabilità a posteriori. Con ipotesi equiprobabili è la **regola ML**. Per dati continui si usano le densità.
- $P(e) = P(H_1)P(e \mid H_1) + P(H_2)P(e \mid H_2)$.
- Due sorgenti binarie: si confronta il **peso di Hamming** con una soglia; le probabilità di errore sono code di binomiali.
- Media gaussiana: si confronta la **media campione** con $\frac{\mu_1+\mu_2}{2}$; $P(e) = Q\left(\sqrt{n}\frac{\mu_1-\mu_2}{2\sigma}\right) \to 0$. Peso di Hamming e somma dei dati sono **statistiche sufficienti**.

Test di ipotesi: il test di Neyman-Pearson

La regola MAP del capitolo precedente ha bisogno di due ingredienti: i costi delle decisioni sbagliate e le probabilità a priori delle ipotesi. Ci sono però molte situazioni in cui bisogna scegliere fra due ipotesi senza avere né l'uno né l'altro. Le slide ne elencano alcune:

- la rivelazione precoce delle minacce alla sicurezza di un'area pattugliata;
- la rivelazione di un'intrusione in server o domini protetti in Internet;
- la rivelazione (e la localizzazione) di un ostacolo nei sistemi avanzati di assistenza alla guida;
- il controllo del traffico aereo;
- un innumerevole insieme di applicazioni militari.

In tutti questi casi è praticamente impossibile assegnare un costo a un'interpretazione sbagliata dello «stato della natura», cioè a una decisione errata fra le due ipotesi «tutto normale» e «sta succedendo qualcosa». E ha poco senso assegnare delle probabilità a priori quando nei dati possono comparire delle «anomalie statistiche» mai viste prima. Serve un criterio diverso: è quello dei **test di ipotesi**.

Ipotesi nulla, falsi allarmi e mancate rivelazioni

Ipotesi nulla e ipotesi alternativa

L'**ipotesi nulla**, tradizionalmente indicata con H_0, afferma che i dati osservati $\underline{x}$ sono la realizzazione di un vettore aleatorio con una distribuzione condizionata nota, con pmf $p_{\underline{X}|H_0}(\underline{x} \mid H_0)$ o PDF $f_{\underline{X}|H_0}(\underline{x} \mid H_0)$. Il **test di ipotesi** decide se, dati i dati osservati, l'ipotesi nulla deve essere rifiutata in favore di una legge diversa, l'**ipotesi alternativa** H_1, con pmf $p_{\underline{X}|H_1}(\underline{x} \mid H_1)$ o PDF $f_{\underline{X}|H_1}(\underline{x} \mid H_1)$.

L'ipotesi nulla è lo stato «normale», quello che si dà per buono finché i dati non lo smentiscono. Come nella classificazione binaria bisogna dividere i dati in due regioni di decisione, Ω_0 (si accetta H_0) e Ω_1 (si rifiuta H_0 e si decide H_1), ma la struttura bayesiana non si può più usare, per mancanza di informazione a priori. Si guarda invece separatamente ai due modi di sbagliare.

Errori di prima e di seconda specie

- L'**errore di prima specie** (*type I*) consiste nel rifiutare H_0 quando H_0 è vera. La sua probabilità, detta **probabilità di falso allarme** e indicata con α, è

$$\alpha = P\{D(\underline{X}) = 1 \mid H_0\} = \begin{cases} \displaystyle\int_{\Omega_1} f_{\underline{X}|H_0}(\underline{x} \mid H_0)\,\mathrm{d}\underline{x} & \text{dati continui,} \\ \displaystyle\sum_{\underline{x}\in\Omega_1} p_{\underline{X}|H_0}(\underline{x} \mid H_0) & \text{dati discreti.} \end{cases}$$

- L'**errore di seconda specie** (*type II*) consiste nel rifiutare H_1 quando H_1 è vera. La sua probabilità, detta **probabilità di mancata rivelazione**, si indica con β. Il suo complemento a uno, detto **potenza del test** (o probabilità di corretta rivelazione), è

$$1-\beta = P\{D(\underline{X}) = 1 \mid H_1\} = \begin{cases} \displaystyle\int_{\Omega_1} f_{\underline{X}|H_1}(\underline{x} \mid H_1)\,\mathrm{d}\underline{x} & \text{dati continui,} \\ \displaystyle\sum_{\underline{x}\in\Omega_1} p_{\underline{X}|H_1}(\underline{x} \mid H_1) & \text{dati discreti.} \end{cases}$$

I quattro casi possibili si riassumono in una tabella. Si pensi a un allarme antifurto: H_0 è «nessun ladro», H_1 è «c'è un ladro».

	è vera H_0 (nessun ladro)	**è vera** H_1 (c'è un ladro)
si decide H_0 (silenzio)	decisione giusta, prob. $1-\alpha$	mancata rivelazione (II specie), prob. β
si decide H_1 (allarme)	falso allarme (I specie), prob. α	rivelazione, prob. $1-\beta$ (potenza)

Le due colonne sono due mondi separati: in ciascuna le probabilità sommano a 1. Non si possono rendere piccoli entrambi gli errori a piacere: allargando la regione Ω_1 (un allarme più sensibile) la potenza cresce, ma crescono anche i falsi allarmi; restringendola succede il contrario.

Il test di Neyman-Pearson

Test di Neyman-Pearson

Un **test di Neyman-Pearson** è il risultato della seguente ottimizzazione vincolata: si determina Ω_1 in modo che

$$\begin{cases} 1-\beta \text{ (potenza del test)}: & \text{massimizzata,} \\ \text{vincolo:} & \text{probabilità di errore di prima specie} \le \alpha. \end{cases}$$

Si fissa dunque quanti falsi allarmi si è disposti a tollerare (per esempio $\alpha = 0{,}01$: un falso allarme ogni cento prove in condizioni normali) e, fra tutti i test che rispettano questo vincolo, si sceglie il più potente. L'esistenza della soluzione è la sostanza del lemma di Neyman-Pearson, che dice anche quale forma ha.

Teorema 20.1 — Lemma di Neyman-Pearson

Il test più potente fra quelli con probabilità di falso allarme non superiore ad α è basato sul rapporto di verosimiglianza:

$$L(\underline{x}) \underset{H_0}{\overset{H_1}{\gtrless}} \eta, \qquad \text{dove} \qquad L(\underline{x}) = \begin{cases} \dfrac{f_{\underline{X}|H_1}(\underline{x} \mid H_1)}{f_{\underline{X}|H_0}(\underline{x} \mid H_0)} & \text{dati continui,} \\ \dfrac{p_{\underline{X}|H_1}(\underline{x} \mid H_1)}{p_{\underline{X}|H_0}(\underline{x} \mid H_0)} & \text{dati discreti,} \end{cases}$$

e la soglia η si sceglie come soluzione dell'equazione $P\{L(\underline{X}) > \eta \mid H_0\} = \alpha$.

Dimostrazione — nel caso continuo; nel discreto gli integrali diventano somme

Passo 1 — La funzione indicatrice. Per una regione Ω si indica con $\mathbf{1}_\Omega(\underline{x})$ la funzione che vale 1 se $\underline{x} \in \Omega$ e 0 altrimenti (è la variabile indicatrice del Capitolo 18, vista come funzione dei dati). Così $\int \mathbf{1}_\Omega \, f_{\underline{X}|H_i} \, \mathrm{d}\underline{x}$ è la probabilità della regione Ω sotto H_i. Scriviamo in breve f_0 e f_1 per le due densità.

Passo 2 — I due test a confronto. Sia $\Omega^\star = \{\underline{x} : f_1(\underline{x}) > \eta f_0(\underline{x})\}$ la regione del test di Neyman-Pearson, con falso allarme esattamente α, e sia Ω la regione di un test qualsiasi con falso allarme $\alpha_\Omega \le \alpha$.

Passo 3 — Un integrale che non può essere negativo. Si consideri

$$I = \int \big[\mathbf{1}_{\Omega^\star}(\underline{x}) - \mathbf{1}_\Omega(\underline{x})\big]\big[f_1(\underline{x}) - \eta f_0(\underline{x})\big] \, \mathrm{d}\underline{x}.$$

Dove la prima parentesi è positiva ($\underline{x}$ sta in $\Omega^\star$ ma non in Ω), anche la seconda lo è, per come è definita $\Omega^\star$; dove la prima è negativa ($\underline{x}$ sta in Ω ma non in $\Omega^\star$), la seconda è negativa o nulla. Il prodotto non è mai negativo, quindi $I \ge 0$.

Passo 4 — Si svolge l'integrale. Moltiplicando, ogni pezzo è una probabilità:

$$I = \underbrace{\big[(1-\beta_{\Omega^\star}) - (1-\beta_\Omega)\big]}_{\text{differenza di potenza}} - \eta \underbrace{\big[\alpha - \alpha_\Omega\big]}_{\ge 0} \ge 0.$$

Passo 5 — Conclusione. Quindi la differenza di potenza è almeno $\eta(\alpha - \alpha_\Omega)$, che non è negativo ($\eta \ge 0$ e $\alpha_\Omega \le \alpha$): nessun test che rispetti il vincolo è più potente di quello di Neyman-Pearson.

■

Il test ha la stessa forma della regola MAP del capitolo precedente: si confronta il rapporto di verosimiglianza con una soglia. Cambia il modo di scegliere la soglia: nella regola MAP è fissata dalle probabilità a priori, $\eta = \frac{P(H_0)}{P(H_1)}$; qui è fissata dal livello di falsi allarmi α che si è disposti a tollerare. Con dati discreti può non esistere una soglia che dia esattamente α (la probabilità sale a gradini); si sceglie allora la soglia che dà il più grande falso allarme non superiore ad α.

Le trasformazioni crescenti non cambiano il test

Se si applica una qualsiasi funzione strettamente crescente a entrambi i membri della disuguaglianza, l'ottimalità del test non cambia: le stesse $\underline{x}$ finiscono nella stessa regione. Per esempio si può usare il rapporto di verosimiglianza logaritmico $\Lambda(\underline{x}) = \ln L(\underline{x})$ e confrontarlo con la soglia $\ln\eta$: con le densità gaussiane il logaritmo trasforma gli esponenziali in polinomi e i conti si semplificano molto.

Esempio: test sulla media di una popolazione gaussiana

L'ipotesi nulla è che le osservazioni siano variabili gaussiane i.i.d. con media nulla e varianza σ^2, $X_i \sim \mathcal{N}(0, \sigma^2)$ (solo rumore); l'ipotesi alternativa è $X_i \sim \mathcal{N}(\mu, \sigma^2)$ con $\mu > 0$ (un segnale di ampiezza μ immerso nel rumore). È il problema di un radar che deve capire se c'è un bersaglio.

Teorema 20.2 — Il test di Neyman-Pearson sulla media

Con un livello di falso allarme α assegnato, il test di Neyman-Pearson è

$$\frac{1}{n}\sum_{k=1}^{n} x_k \underset{H_0}{\overset{H_1}{\gtrless}} \eta' = Q^{-1}(\alpha)\,\frac{\sigma}{\sqrt{n}},$$

e la sua potenza è

$$1 - \beta = Q\left(Q^{-1}(\alpha) - \mu\,\frac{\sqrt{n}}{\sigma}\right) \xrightarrow{n\to\infty} 1.$$

Qui Q^{-1} è la **funzione inversa** della funzione Q: siccome Q è strettamente decrescente (Capitolo 15), per ogni $\alpha \in (0,1)$ c'è un solo numero x con $Q(x) = \alpha$, e lo si chiama $Q^{-1}(\alpha)$. Si legge sulla tabella dei valori di Q «al contrario», cercando α fra i risultati:

α	0,1	0,05	0,01	0,001
$Q^{-1}(\alpha)$	1,282	1,645	2,326	3,090

Dimostrazione

Passo 1 — Il rapporto di verosimiglianza. Come nel capitolo precedente, le costanti si semplificano:

$$L(\underline{x}) = \frac{\prod_{k=1}^{n} e^{-\frac{(x_k-\mu)^2}{2\sigma^2}}}{\prod_{k=1}^{n} e^{-\frac{x_k^2}{2\sigma^2}}} = e^{\frac{1}{2\sigma^2}\sum_{k=1}^{n}\left[x_k^2-(x_k-\mu)^2\right]} = e^{\frac{1}{2\sigma^2}\sum_{k=1}^{n}\left[2\mu x_k-\mu^2\right]},$$

perché $x_k^2 - (x_k-\mu)^2 = x_k^2 - x_k^2 - \mu^2 + 2\mu x_k$.

Passo 2 — Il logaritmo. Prendendo il logaritmo di entrambi i lati e assorbendo in una nuova soglia $\eta'' = \ln\eta$ tutto ciò che non dipende dai dati:

$$\Lambda(\underline{x}) = \frac{1}{2\sigma^2}\left[2\mu\sum_{k=1}^{n} x_k - n\mu^2\right] \underset{H_0}{\overset{H_1}{\gtrless}} \eta'' \quad\Longleftrightarrow\quad \mu\sum_{k=1}^{n} x_k \underset{H_0}{\overset{H_1}{\gtrless}} \eta''\sigma^2 + \frac{n\mu^2}{2}.$$

(Nelle slide 44–45 l'ipotesi sotto il simbolo è scritta H_2: va letta H_0.)

Passo 3 — La media campione. Dividendo per $\mu n > 0$ il verso non cambia: $\frac{1}{n}\sum_k x_k \underset{H_0}{\overset{H_1}{\gtrless}} \eta'$, con $\eta' = \frac{1}{\mu n}\left(\eta''\sigma^2 + \frac{n\mu^2}{2}\right)$.

Invece di calcolare η' da η, conviene sceglierlo direttamente in modo che il falso allarme valga α.

Passo 4 — La soglia. Sotto H_0, $Z_n = \frac{1}{n}\sum_k X_k$ è gaussiana con media nulla e varianza $\frac{\sigma^2}{n}$ (Capitolo 18). Standardizzando,

$$P\{Z_n > \eta' \mid H_0\} = Q\left(\frac{\eta'}{\sigma/\sqrt{n}}\right) = \alpha \quad\Longleftrightarrow\quad \frac{\eta'}{\sigma/\sqrt{n}} = Q^{-1}(\alpha) \quad\Longleftrightarrow\quad \eta' = Q^{-1}(\alpha)\,\frac{\sigma}{\sqrt{n}}.$$

Passo 5 — La potenza. Sotto H_1, Z_n è gaussiana con media μ e varianza $\frac{\sigma^2}{n}$, quindi

$$1-\beta = P\{Z_n > \eta' \mid H_1\} = Q\left(\frac{\eta'-\mu}{\sigma/\sqrt{n}}\right) = Q\left(\eta'\frac{\sqrt{n}}{\sigma} - \mu\frac{\sqrt{n}}{\sigma}\right) = Q\left(Q^{-1}(\alpha) - \mu\frac{\sqrt{n}}{\sigma}\right).$$

Passo 6 — Il limite. Comunque si fissi un valore di α piccolo ma non nullo, $Q^{-1}(\alpha)$ è un numero grande ma finito; per $n \to \infty$ l'argomento di Q tende a $-\infty$ e $Q(-\infty) = 1$.

■

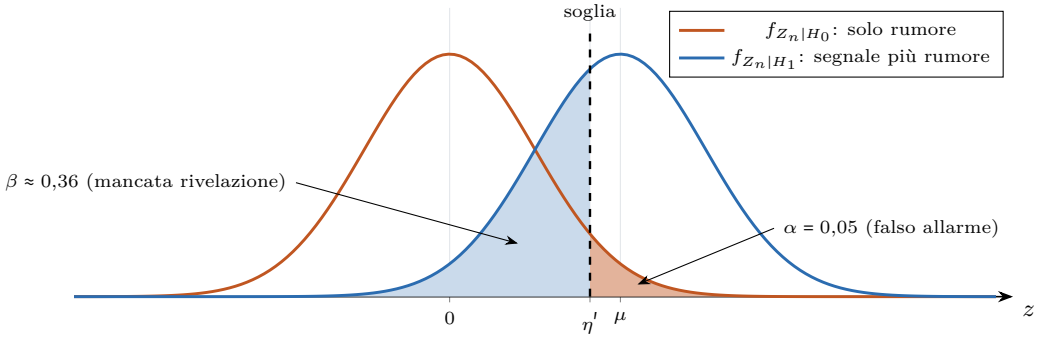


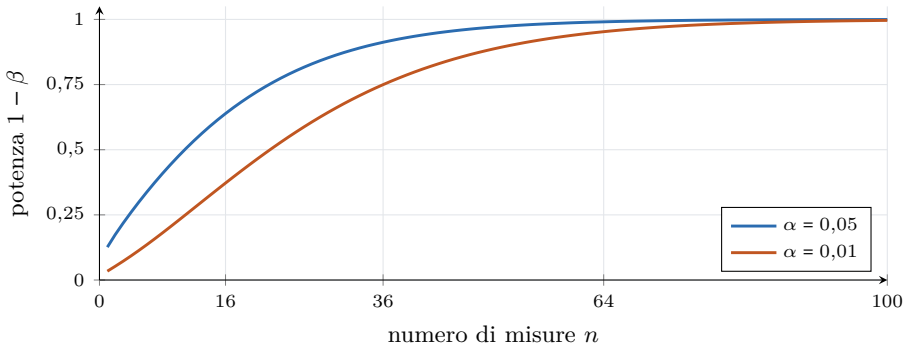
Figura 20.1: *Il test di Neyman-Pearson con $\sigma = 1$, $\mu = 0{,}5$, $n = 16$ e $\alpha = 0{,}05$: la soglia $\eta' = 1{,}645 \cdot \frac{1}{4} \approx 0{,}41$ lascia a destra il 5% della campana di H_0. La potenza è l'area della campana di H_1 a destra della soglia, $1-\beta = Q(1{,}645-2) \approx 0{,}64$.*

Esempio 20.1 — Quante misure servono per un radar affidabile?

Con $\sigma = 1$ e $\mu = 0{,}5$ (il segnale è metà del rumore) e $\alpha = 0{,}05$, la potenza vale

$$1 - \beta = Q\left(1{,}645 - 0{,}5\sqrt{n}\right):$$

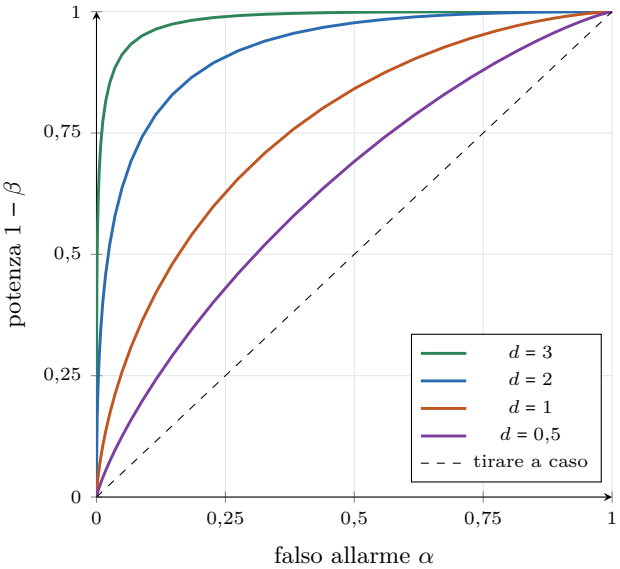
con $n = 16$ misure $Q(-0{,}355) \approx 0{,}64$, con $n = 36$ $Q(-1{,}355) \approx 0{,}91$, con $n = 64$ $Q(-2{,}355) \approx 0{,}99$. Pretendere meno falsi allarmi costa potenza: con $\alpha = 0{,}01$ la soglia sale a $Q^{-1}(0{,}01) = 2{,}326$ e, a parità di n, la potenza scende (curva più in basso nella figura).



Una soglia che non dipende da μ

La soglia $\eta' = Q^{-1}(\alpha)\frac{\sigma}{\sqrt{n}}$ dipende solo dal rumore e dal livello di falso allarme, non dall'ampiezza μ del segnale. Quindi lo stesso test (confrontare la media delle misure con η') è il migliore per *qualunque* $\mu > 0$, anche se l'ampiezza del bersaglio non è nota. Da μ dipende solo la potenza: bersagli deboli si vedono peggio.

Le prestazioni di un test si riassumono nella **curva ROC** (*Receiver Operating Characteristic*): al variare della soglia, si disegna la potenza $1 - \beta$ in funzione del falso allarme α. Per il test sulla media la curva dipende solo da $d = \mu\frac{\sqrt{n}}{\sigma}$, la distanza fra le due campane misurata in deviazioni standard della media campione: $1 - \beta = Q\left(Q^{-1}(\alpha) - d\right)$.



Ogni punto di una curva corrisponde a una soglia: abbassandola si sale lungo la curva, con più rivelazioni ma anche più falsi allarmi. Più la curva si avvicina all'angolo in alto a sinistra ($\alpha = 0$, $1 - \beta = 1$), migliore è il test. La diagonale tratteggiata è un test che decide tirando una moneta truccata: rivela con la stessa probabilità con cui dà falsi allarmi. Aumentando il numero di misure n cresce d, e la curva sale.

Figura 20.2: *Le curve ROC del test sulla media gaussiana per diversi valori di* $d = \mu\sqrt{n}/\sigma$.

In sintesi

- Senza costi e senza probabilità a priori si usa un **test di ipotesi**: ipotesi nulla H_0 contro ipotesi alternativa H_1.
- **Errore di prima specie** (falso allarme): si rifiuta H_0 vera, probabilità α. **Errore di seconda specie** (mancata rivelazione): si rifiuta H_1 vera, probabilità β. **Potenza**: $1-\beta$.
- **Neyman-Pearson**: si massimizza la potenza con il vincolo falso allarme $\leq \alpha$. Il test ottimo è $L(\underline{x}) \underset{H_0}{\overset{H_1}{\gtrless}} \eta$, con η tale che $P\{L(\underline{X}) > \eta \mid H_0\} = \alpha$; si può usare $\ln L$.
- Media gaussiana: $\frac{1}{n}\sum_k x_k \underset{H_0}{\overset{H_1}{\gtrless}} Q^{-1}(\alpha)\frac{\sigma}{\sqrt{n}}$, con potenza $Q\left(Q^{-1}(\alpha) - \mu\frac{\sqrt{n}}{\sigma}\right) \to 1$. La curva ROC riassume il compromesso fra α e $1-\beta$.

Stima bayesiana: MMSE e MAP

Nei due capitoli precedenti il parametro da scoprire poteva assumere pochi valori, uno per ipotesi, e il problema era **decidere**. Spesso invece il parametro è una grandezza continua (la probabilità che una moneta dia testa, la distanza di un bersaglio, la temperatura di un forno) e il problema è **stimarlo**: dare un numero il più vicino possibile a quello vero. Ci sono due approcci. In quello **bayesiano**, di questo capitolo, il parametro è a sua volta una variabile aleatoria, di cui si conosce la densità a priori. In quello **classico**, del prossimo capitolo, è una quantità non nota ma deterministica.

Il problema della stima

Si abbia un insieme di dati $\underline{x} \in \mathcal{X}^n$, realizzazione di un vettore aleatorio $\underline{X}$ la cui distribuzione appartiene a una famiglia di pmf $p_{\underline{X}|\Theta}(\underline{x} \mid \theta)$ o di PDF $f_{\underline{X}|\Theta}(\underline{x} \mid \theta)$, dove il valore di θ non è noto. Tipicamente θ è un parametro continuo, che può essere

- la realizzazione di una variabile aleatoria continua Θ, con una densità marginale $f_\Theta(\theta)$ nota (**approccio bayesiano**): la densità **a priori**, che descrive che cosa si sa del parametro prima di guardare i dati;
- una quantità non nota e deterministica, che assume valori in un insieme continuo (**approccio classico**).

Domanda: come si stima θ sulla base del campione osservato?

Nell'approccio bayesiano i dati aggiornano quello che si sa del parametro. Per la legge di Bayes (con le densità del Capitolo 14), la densità **a posteriori** del parametro, sapendo i dati, è

$$f_{\Theta|\underline{X}}(\theta \mid \underline{x}) = \begin{cases} \dfrac{p_{\underline{X}|\Theta}(\underline{x} \mid \theta)\, f_\Theta(\theta)}{\int p_{\underline{X}|\Theta}(\underline{x} \mid \theta)\, f_\Theta(\theta)\, \mathrm{d}\theta} & \text{dati discreti,} \\ \dfrac{f_{\underline{X}|\Theta}(\underline{x} \mid \theta)\, f_\Theta(\theta)}{\int f_{\underline{X}|\Theta}(\underline{x} \mid \theta)\, f_\Theta(\theta)\, \mathrm{d}\theta} & \text{dati continui,} \end{cases}$$

dove i denominatori sono la legge non condizionata dei dati, per la probabilità totale:

$$p_{\underline{X}}(\underline{x}) = \int p_{\underline{X}|\Theta}(\underline{x} \mid \theta)\, f_\Theta(\theta)\, \mathrm{d}\theta, \qquad f_{\underline{X}}(\underline{x}) = \int f_{\underline{X}|\Theta}(\underline{x} \mid \theta)\, f_\Theta(\theta)\, \mathrm{d}\theta.$$

(Se Θ fosse una variabile discreta, si ricadrebbe in un problema di classificazione come quelli del Capitolo 19.)

Stimatore

Uno **stimatore** del parametro θ è una variabile aleatoria $\hat{\Theta}(\underline{X})$, funzione dei dati, le cui realizzazioni $\hat{\theta}(\underline{x})$ provano a «indovinare» il valore di θ sulla base di un'osservazione $\underline{x} \in \mathcal{X}^n$. Il numero $\hat{\theta}(\underline{x})$ si chiama **stima**.

Il cappello $\hat{}$ si legge «stimato»: $\hat{\theta}$ è «theta stimato». Per progettare uno stimatore bisogna dire quanto costano gli errori, come per le decisioni.

Rischio bayesiano di uno stimatore

Data una **funzione di costo** $C(\cdot)$ dell'errore di stima, il **rischio medio bayesiano** dello stimatore $\hat{\Theta}$ è il costo medio:

$$R = E\left[C\left(\hat{\Theta}(\underline{X}) - \Theta\right)\right] = E_{\underline{X}}\left[E\left[C\left(\hat{\Theta}(\underline{X}) - \Theta\right) \,\middle|\, \underline{X}\right]\right].$$

Uno **stimatore ottimo** è uno stimatore che minimizza il rischio bayesiano.

La seconda forma del rischio è il teorema della media condizionata (Capitoli 9 e 14): prima si fa la media sul parametro sapendo i dati, poi sui dati.

Richiamo di matematica: arg min e arg max

Per una funzione $g(t)$, $\min_t g(t)$ è il **valore** minimo della funzione, mentre $\arg\min_t g(t)$ («l'argomento del minimo») è il **punto** t in cui il minimo viene raggiunto. Per esempio, per $g(t) = (t-3)^2 + 5$ si ha $\min_t g(t) = 5$ ma $\arg\min_t g(t) = 3$. Allo stesso modo $\arg\max$ è il punto di massimo. Due osservazioni utili: moltiplicare g per una costante positiva o sommarle una costante non sposta il punto di minimo (cambia solo il valore); e applicare a g una funzione strettamente crescente, come il logaritmo, non sposta né il minimo né il massimo.

Teorema 21.1 — Lo stimatore bayesiano ottimo

Lo stimatore ottimo bayesiano che opera sul campione osservato $\underline{x}$ è

$$\hat{\theta}(\underline{x})_{\text{opt}} = \arg\min_{\hat{\theta}} \int C\left(\hat{\theta} - \theta\right) f_{\Theta|\underline{X}}(\theta \mid \underline{x})\, \mathrm{d}\theta :$$

per ogni $\underline{x}$ si sceglie il valore che rende minimo il costo medio *a posteriori*.

Dimostrazione

Passo 1 — Il rischio come somma sui dati. Con dati discreti, scrivendo la media esterna sui dati:

$$E\left[C\left(\hat{\Theta}(\underline{X}) - \Theta\right)\right] = \sum_{\underline{x} \in \mathcal{X}^n} p_{\underline{X}}(\underline{x}) \int C\left(\hat{\theta}(\underline{x}) - \theta\right) f_{\Theta|\underline{X}}(\theta \mid \underline{x})\, \mathrm{d}\theta.$$

Passo 2 — Si minimizza un addendo alla volta. La stima $\hat{\theta}(\underline{x})$ si può scegliere separatamente per ogni $\underline{x}$, e compare solo nel proprio addendo. Se per ogni $\underline{x}$ si prende il minimo dell'integrale, pesando con le quantità non negative $p_{\underline{X}}(\underline{x})$ e sommando si ottiene il minimo globale. (Con dati continui la somma è un integrale in $\mathrm{d}\underline{x}$, e il ragionamento è lo stesso.)

■

Costo quadratico: lo stimatore MMSE

La scelta più comune è un costo **quadratico**, $C\left(\hat{\Theta}(\underline{X}) - \Theta\right) = \left(\hat{\Theta}(\underline{X}) - \Theta\right)^2$: gli errori piccoli costano poco, quelli grandi moltissimo. Il rischio è allora l'errore quadratico medio, e lo stimatore ottimo si chiama **stimatore MMSE** (*Minimum Mean Square Error*, a minimo errore quadratico medio).

Richiamo di matematica: derivare sotto il segno di integrale

Se una funzione integranda dipende, oltre che dalla variabile di integrazione θ, da un parametro a, anche l'integrale è una funzione di a: $F(a) = \int g(a,\theta)\,\mathrm{d}\theta$. Per le funzioni regolari che incontreremo, la derivata dell'integrale è l'integrale della derivata parziale:

$$\frac{\mathrm{d}F}{\mathrm{d}a} = \int \frac{\partial g(a,\theta)}{\partial a}\,\mathrm{d}\theta.$$

Il motivo è che l'integrale è un limite di somme (Capitolo 10), e la derivata di una somma è la somma delle derivate. Per esempio, con $g = (a-\theta)^2$ su $[0,1]$: $F(a) = a^2 - a + \frac{1}{3}$, e infatti $F'(a) = 2a - 1 = \int_0^1 2(a-\theta)\,\mathrm{d}\theta$.

Teorema 21.2 — Lo stimatore MMSE è la media condizionata

Con il costo quadratico, lo stimatore bayesiano ottimo è la media a posteriori del parametro:

$$\hat{\theta}_{\mathrm{MMSE}}(\underline{x}) = \int \theta\, f_{\Theta|\underline{X}}(\theta \mid \underline{x})\,\mathrm{d}\theta = E\left[\Theta \mid \underline{X} = \underline{x}\right].$$

Dimostrazione — si annulla la derivata

Passo 1 — La condizione di minimo. Per il Teorema 21.1 bisogna rendere minima, rispetto a $\hat{\theta}(\underline{x})$, la funzione $\int \left(\hat{\theta}(\underline{x}) - \theta\right)^2 f_{\Theta|\underline{X}}(\theta \mid \underline{x})\,\mathrm{d}\theta$. Si annulla la sua derivata, portandola sotto il segno di integrale:

$$\frac{\partial}{\partial \hat{\theta}(\underline{x})} \int \left(\hat{\theta}(\underline{x}) - \theta\right)^2 f_{\Theta|\underline{X}}(\theta \mid \underline{x})\,\mathrm{d}\theta = 2\int \left(\hat{\theta}(\underline{x}) - \theta\right) f_{\Theta|\underline{X}}(\theta \mid \underline{x})\,\mathrm{d}\theta = 0.$$

Passo 2 — Si separano i due termini.

$$\int \hat{\theta}(\underline{x})\, f_{\Theta|\underline{X}}(\theta \mid \underline{x})\,\mathrm{d}\theta = \int \theta\, f_{\Theta|\underline{X}}(\theta \mid \underline{x})\,\mathrm{d}\theta.$$

Passo 3 — Si conclude. $\hat{\theta}(\underline{x})$ non dipende da θ ed esce dall'integrale, e l'integrale della densità condizionata vale 1: resta $\hat{\theta}(\underline{x}) = \int \theta f_{\Theta|\underline{X}}(\theta \mid \underline{x})\,\mathrm{d}\theta = E[\Theta \mid \underline{X} = \underline{x}]$, la media condizionata di Θ all'evento $\{\underline{X} = \underline{x}\}$.

Passo 4 — È proprio un minimo. Sviluppando il quadrato, la funzione da minimizzare è $\hat{\theta}^2 - 2\hat{\theta}\,E[\Theta \mid \underline{x}] + E[\Theta^2 \mid \underline{x}]$: una parabola in $\hat{\theta}$ con la concavità verso l'alto (il costo quadratico è convesso), il cui unico punto a derivata nulla è il vertice, cioè il minimo. ∎

Costo «tutto o niente»: lo stimatore MAP

Si consideri ora un costo che non distingue fra errori grandi e piccoli: un errore è gratis se è minore di una tolleranza piccolissima, e costa 1 altrimenti. Con la funzione rettangolo del Capitolo 11,

$$C\left(\hat{\Theta}(\underline{X}) - \Theta\right) = \overline{\Pi}\left(\frac{\hat{\Theta}(\underline{X}) - \Theta}{\epsilon}\right) = \begin{cases} 0 & |\hat{\Theta}(\underline{X}) - \Theta| < \frac{\epsilon}{2}, \\ 1 & \text{altrove}, \end{cases}$$

dove $\overline{\Pi} = 1 - \mathrm{rect}$ è il complemento del rettangolo: una «tacca» larga ϵ attorno allo zero.

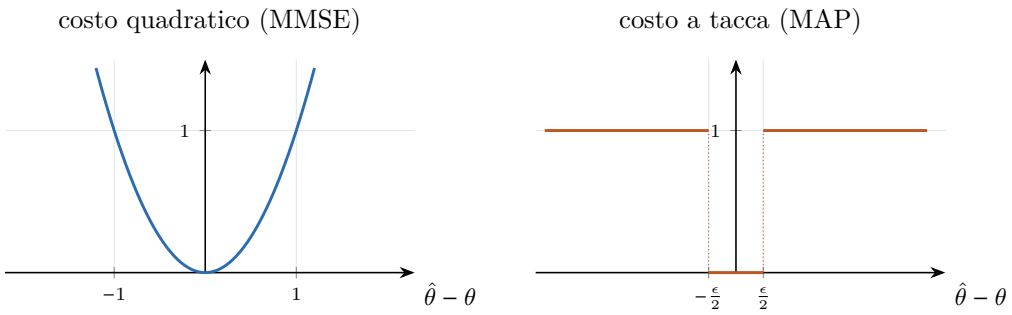


Figura 21.1: *Le due funzioni di costo dell'errore di stima. Quella quadratica punisce molto gli errori grandi; quella a tacca considera giusta una stima entro $\frac{\epsilon}{2}$ da θ e sbagliata ogni altra, comunque lontana.*

Teorema 21.3 — Lo stimatore MAP

Con il costo a tacca, per ϵ arbitrariamente piccolo, lo stimatore bayesiano ottimo è il punto di massimo della densità a posteriori:

$$\hat{\theta}_{\text{MAP}}(\underline{x}) = \arg\max_{\theta} f_{\Theta|\underline{X}}(\theta \mid \underline{x}).$$

Si chiama **stima del massimo a posteriori** (MAP).

Dimostrazione

Passo 1 — Il costo medio a posteriori. Il costo vale 1 dappertutto tranne che nella tacca, dove vale 0; quindi il suo integrale contro la densità a posteriori è 1 meno l'area della densità sulla tacca:

$$\int C\left(\hat{\theta} - \theta\right) f_{\Theta|\underline{X}}(\theta \mid \underline{x})\,\mathrm{d}\theta = 1 - \int_{\hat{\theta}-\epsilon/2}^{\hat{\theta}+\epsilon/2} f_{\Theta|\underline{X}}(\theta \mid \underline{x})\,\mathrm{d}\theta \simeq 1 - \epsilon\, f_{\Theta|\underline{X}}(\hat{\theta} \mid \underline{x}),$$

perché per ϵ piccolissimo l'area su un intervallino è base per altezza (Capitolo 10).

Passo 2 — Il minimo. Il costo è minimo quando $f_{\Theta|\underline{X}}(\hat{\theta} \mid \underline{x})$ è massima: si sceglie $\hat{\theta}$ nel punto più alto della densità a posteriori.

■

Il rischio bayesiano corrispondente è

$$R = \sum_{\underline{x} \in \mathcal{X}^n} p_{\underline{X}}(\underline{x}) \int C\left(\hat{\theta}(\underline{x}) - \theta\right) f_{\Theta|\underline{X}}(\theta \mid \underline{x})\,\mathrm{d}\theta \qquad \text{o, nel caso continuo,} \qquad R = \iint f_{\underline{X}}(\underline{x})\, C\left(\hat{\theta}(\underline{x}) - \theta\right) f_{\Theta|\underline{X}}(\theta \mid \underline{x})\,\mathrm{d}\theta\,\mathrm{d}\underline{x}.$$

I due stimatori guardano la stessa densità a posteriori in due modi diversi: l'MMSE ne prende il **baricentro** (la media), il MAP il **picco** (la moda). Se la densità a posteriori è simmetrica e con un solo picco, come una gaussiana, i due coincidono.

ESEMPIO: LA MONETA MISTERIOSA

Una moneta dà testa con una probabilità β che non conosciamo affatto: la modelliamo come la realizzazione di una variabile aleatoria $B \sim \mathcal{U}(0,1)$, uniforme (nessun valore è a priori più plausibile di un altro). Si lancia la moneta n volte: i risultati $\underline{X} \in \{0,1\}^n$ (1 per testa) sono, *sapendo* che $B = \beta$, variabili di Bernoulli i.i.d. con parametro β. È il modello **Bernoulli composito**. Come nel Capitolo 19, con il peso di Hamming $w(\underline{x})$ (il numero di «1»):

$$p_{\underline{X}|B}(\underline{x} \mid \beta) = \beta^{w(\underline{x})}\,(1-\beta)^{n-w(\underline{x})}.$$

Per trovare la densità a posteriori serve l'integrale di questa espressione in β.

Richiamo di matematica: l'integrale di Eulero e la funzione Gamma

Per a e b interi non negativi vale

$$\int_0^1 t^a (1-t)^b \,\mathrm{d}t = \frac{a!\,b!}{(a+b+1)!}.$$

Perché. Si chiama $I(a,b)$ l'integrale e lo si calcola per parti (Capitolo 11), derivando $(1-t)^b$ e integrando t^a:

$$I(a,b) = \left[(1-t)^b \frac{t^{a+1}}{a+1}\right]_0^1 + \frac{b}{a+1}\int_0^1 t^{a+1}(1-t)^{b-1}\,\mathrm{d}t = \frac{b}{a+1}\,I(a+1,b-1),$$

perché il termine fra parentesi quadre vale 0 in entrambi gli estremi (se $b \geq 1$). Ogni passo sposta un'unità da b ad a; dopo b passi

$$I(a,b) = \frac{b}{a+1}\cdot\frac{b-1}{a+2}\cdots\frac{1}{a+b}\,I(a+b,0) = \frac{b!\,a!}{(a+b)!}\cdot\frac{1}{a+b+1} = \frac{a!\,b!}{(a+b+1)!},$$

dove si è usato $I(a+b,0) = \int_0^1 t^{a+b}\,\mathrm{d}t = \frac{1}{a+b+1}$. Per esempio $\int_0^1 t(1-t)\,\mathrm{d}t = \frac{1}{2}-\frac{1}{3} = \frac{1}{6} = \frac{1!\,1!}{3!}$.

La funzione Gamma. Le slide scrivono la stessa formula con la **funzione Gamma di Eulero** $\Gamma(x)$, che estende il fattoriale ai numeri non interi: per gli interi $\Gamma(m) = (m-1)!$, e in generale $\Gamma(x+1) = x\,\Gamma(x)$ (come $m! = m\cdot(m-1)!$). La **funzione Beta** di Eulero è

$$B(m,k) = \int_0^1 t^{m-1}(1-t)^{k-1}\,\mathrm{d}t = \frac{\Gamma(m)\,\Gamma(k)}{\Gamma(m+k)},$$

che con $m = a+1$ e $k = b+1$ è proprio la formula di sopra.

Teorema 21.4 — Le stime della moneta misteriosa

Con $B \sim \mathcal{U}(0,1)$ e $w = w(\underline{x})$ teste in n lanci:

a) la densità a posteriori è $f_{B|\underline{X}}(\beta \mid \underline{x}) = \dfrac{(n+1)!}{w!\,(n-w)!}\,\beta^w(1-\beta)^{n-w}$, per $0 \leq \beta \leq 1$;

b) la stima MMSE è $\hat{\beta}_{\mathrm{MMSE}}(\underline{x}) = \dfrac{w+1}{n+2}$;

c) la stima MAP è $\hat{\beta}_{\mathrm{MAP}}(\underline{x}) = \dfrac{w}{n}$.

Dimostrazione

Passo 1 — La legge dei dati. Mediando sulla variabile B, che ha densità 1 su $[0,1]$, e usando il richiamo con $a = w$ e $b = n-w$:

$$p_{\underline{X}}(\underline{x}) = \int_0^1 \beta^w(1-\beta)^{n-w}\,f_B(\beta)\,\mathrm{d}\beta = \frac{w!\,(n-w)!}{(n+1)!} = \frac{\Gamma(w+1)\,\Gamma(n-w+1)}{\Gamma(n+2)}.$$

Passo 2 — a) La densità a posteriori. Per la legge di Bayes, $f_{B|\underline{X}}(\beta \mid \underline{x}) = \frac{p_{\underline{X}|B}(\underline{x}|\beta)\,f_B(\beta)}{p_{\underline{X}}(\underline{x})}$, con $f_B = 1$.

Passo 3 — b) La media a posteriori. Per il Teorema 21.2, usando di nuovo il richiamo, ora con $a = w+1$:

$$\hat{\beta}_{\mathrm{MMSE}}(\underline{x}) = \int_0^1 \beta\,f_{B|\underline{X}}(\beta \mid \underline{x})\,\mathrm{d}\beta = \frac{(n+1)!}{w!\,(n-w)!}\int_0^1 \beta^{w+1}(1-\beta)^{n-w}\,\mathrm{d}\beta = \frac{(n+1)!}{w!\,(n-w)!}\cdot\frac{(w+1)!\,(n-w)!}{(n+2)!} = \frac{w+1}{n+2},$$

perché $\frac{(w+1)!}{w!} = w+1$ e $\frac{(n+1)!}{(n+2)!} = \frac{1}{n+2}$ (sono le proprietà $\Gamma(x+1) = x\,\Gamma(x)$ usate nelle slide).

Passo 4 — c) Il massimo a posteriori. Il fattore costante $\frac{(n+1)!}{w!(n-w)!}$ è positivo e non dipende da β: non sposta il punto di massimo, che è lo stesso di $\beta^w(1-\beta)^{n-w}$, e anche del suo logaritmo (richiamo su $\arg\max$). Si annulla la derivata:

$$\frac{\mathrm{d}}{\mathrm{d}\beta}\left[w\ln\beta + (n-w)\ln(1-\beta)\right] = \frac{w}{\beta} - \frac{n-w}{1-\beta} = 0 \quad\Longleftrightarrow\quad (1-\beta)\,w = \beta\,(n-w) \quad\Longleftrightarrow\quad w = \beta n,$$

nell'ipotesi $\beta \neq 0,1$ (se $w = 0$ o $w = n$ il massimo è in un estremo, e vale ancora $\beta = \frac{w}{n}$).

■

La stima MAP è la frequenza delle teste: la risposta più spontanea. La stima MMSE è leggermente diversa: è come se ai lanci veri si aggiungessero una testa e una croce immaginarie, che rappresentano la densità a priori uniforme (centrata in $\frac{1}{2}$). Con

pochi dati la differenza conta: dopo 3 teste in 3 lanci il MAP dice $\hat{\beta} = 1$, cioè «la moneta dà sempre testa», mentre l'MMSE dice, più prudente, $\frac{4}{5}$. È la **regola di successione di Laplace**, che il matematico usò per il famoso problema dell'alba: avendo visto sorgere il sole n giorni di fila, la probabilità che sorga domani è $\frac{n+1}{n+2}$.

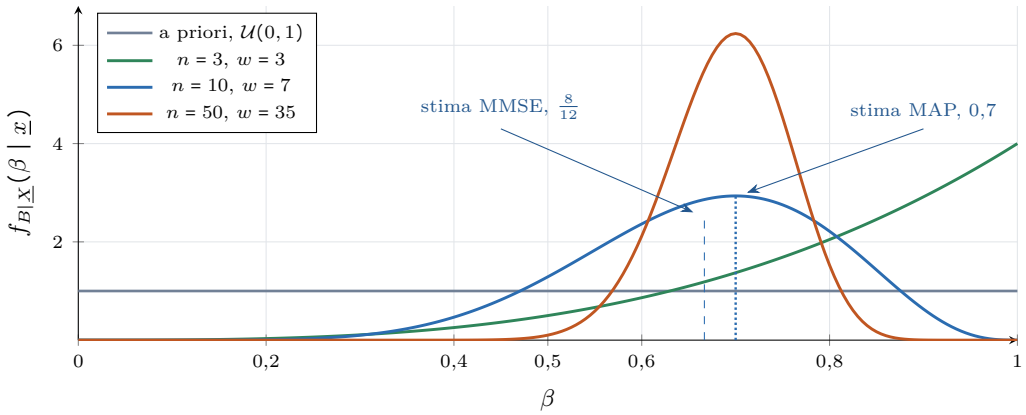


Figura 21.2: *Le densità a posteriori della probabilità di testa. Partendo dalla densità uniforme, i dati la spostano e la stringono: con 35 teste su 50 lanci il parametro è quasi certamente fra* 0,55 *e* 0,85. *Per* $n = 10$ *e* $w = 7$ *sono segnate la media (stima MMSE,* $\frac{8}{12} \approx 0{,}667$*) e il picco (stima MAP,* 0,7*).*

LE PRESTAZIONI DEI DUE STIMATORI

Quale dei due stimatori sbaglia meno, in media? Calcoliamo media ed errore quadratico medio di entrambi, mediando sia sui dati sia sul parametro. Servono alcuni momenti, che si calcolano tutti con il teorema della media condizionata: prima si media sapendo $B = \beta$ (e allora $w(\underline{X})$ è binomiale con parametri n e β), poi su B.

- Per la variabile uniforme: $E[B] = \int_0^1 \beta \, \mathrm{d}\beta = \frac{1}{2}$, $E[B^2] = \int_0^1 \beta^2 \, \mathrm{d}\beta = \left[\frac{\beta^3}{3}\right]_0^1 = \frac{1}{3}$, e $\sigma_B^2 = \frac{1}{3} - \frac{1}{4} = \frac{1}{12}$.
- La media del peso: $E[w(\underline{X})] = E_B\left[E[w(\underline{X}) \mid B]\right] = E_B[nB] = \frac{n}{2}$.
- Il valore quadratico medio del peso: sapendo B, la binomiale ha varianza $nB(1-B)$ e media nB, e il valore quadratico medio è varianza più quadrato della media:

$$E\left[w^2(\underline{X})\right] = E_B\left[nB(1-B) + n^2B^2\right] = n\left(\frac{1}{2} - \frac{1}{3}\right) + \frac{n^2}{3} = \frac{n}{6} + \frac{n^2}{3},$$

  e quindi la varianza (non condizionata) del peso è $\sigma_w^2 = \frac{n}{6} + \frac{n^2}{3} - \frac{n^2}{4} = \frac{n}{6} + \frac{n^2}{12}$.
- Il prodotto: $E[w(\underline{X})\, B] = E_B\left[B\, E[w(\underline{X}) \mid B]\right] = E_B[nB^2] = \frac{n}{3}$.

Teorema 21.5 — Media ed errore quadratico medio dei due stimatori

Entrambi gli stimatori hanno media $\frac{1}{2}$, come il parametro: $E\left[\hat{\beta}_{\text{MMSE}}(\underline{X})\right] = E\left[\hat{\beta}_{\text{MAP}}(\underline{X})\right] = \frac{1}{2}$. I loro errori quadratici medi sono

$$E\left[\left(\hat{\beta}_{\text{MMSE}}(\underline{X}) - B\right)^2\right] = \frac{1}{6(n+2)}, \qquad E\left[\left(\hat{\beta}_{\text{MAP}}(\underline{X}) - B\right)^2\right] = \frac{1}{6n}.$$

Dimostrazione

Passo 1 — Le medie. Per la linearità: $E\left[\frac{w+1}{n+2}\right] = \frac{n/2+1}{n+2} = \frac{(n+2)/2}{n+2} = \frac{1}{2}$ e $E\left[\frac{w}{n}\right] = \frac{n/2}{n} = \frac{1}{2}$.

Passo 2 — L'errore quadratico in tre pezzi. Per entrambi gli stimatori, sviluppando il quadrato, $E[(\hat{\beta} - B)^2] = E[\hat{\beta}^2] + E[B^2] - 2E[\hat{\beta}B]$, con $E[B^2] = \frac{1}{3}$.

Passo 3 — MMSE. Con i momenti calcolati sopra:

$$E\left[\hat{\beta}^2_{\text{MMSE}}\right] = \frac{E[w^2] + 2E[w] + 1}{(n+2)^2} = \frac{\frac{n}{6} + \frac{n^2}{3} + n + 1}{(n+2)^2} = \frac{2n^2 + 7n + 6}{6(n+2)^2} = \frac{(2n+3)(n+2)}{6(n+2)^2} = \frac{2n+3}{6(n+2)},$$

$$E\left[\hat{\beta}_{\text{MMSE}}\, B\right] = \frac{E[wB] + E[B]}{n+2} = \frac{\frac{n}{3} + \frac{1}{2}}{n+2} = \frac{2n+3}{6(n+2)}.$$

Quindi l'errore è $\frac{2n+3}{6(n+2)} + \frac{1}{3} - 2 \cdot \frac{2n+3}{6(n+2)} = \frac{1}{3} - \frac{2n+3}{6(n+2)} = \frac{2(n+2)-(2n+3)}{6(n+2)} = \frac{1}{6(n+2)}$.

Passo 4 — MAP.

$$E\left[\hat{\beta}^2_{\text{MAP}}\right] = \frac{E[w^2]}{n^2} = \frac{1}{6n} + \frac{1}{3}, \qquad E\left[\hat{\beta}_{\text{MAP}}\, B\right] = \frac{E[wB]}{n} = \frac{1}{3},$$

e l'errore è $\frac{1}{6n} + \frac{1}{3} + \frac{1}{3} - \frac{2}{3} = \frac{1}{6n}$.

■

Le slide arrivano agli stessi risultati con passaggi più lunghi (slide 64–73), sviluppando $(n+2)^2$ e i prodotti. Come c'era da aspettarsi, per ogni valore di n l'errore quadratico medio dello stimatore MMSE è minore di quello del MAP: è il migliore possibile, per costruzione. La differenza è grande con pochi dati e sparisce quando i dati sono tanti:

n	1	2	5	10	100
errore MMSE, $\frac{1}{6(n+2)}$	0,056	0,042	0,024	0,0139	0,00163
errore MAP, $\frac{1}{6n}$	0,167	0,083	0,033	0,0167	0,00167

Consistenza di uno stimatore

Uno stimatore $\hat{B}_n(\underline{X})$, calcolato da n dati, si dice

- **consistente in media quadratica** (*MS-consistent*) se il suo errore quadratico medio tende a zero per $n \to \infty$;
- **consistente** (in senso debole) se tende al parametro in probabilità: per ogni $\epsilon > 0$, $\lim_{n\to\infty} P\left\{|\hat{B}_n(\underline{X}) - B| > \epsilon\right\} = 0$.

Entrambi gli stimatori della moneta sono consistenti in media quadratica, perché $\frac{1}{6(n+2)}$ e $\frac{1}{6n}$ tendono a zero. E quindi sono anche consistenti in senso debole: per la disuguaglianza di Markov, come nel Capitolo 18,

$$P\left\{|\hat{B}_n(\underline{X}) - B| > \epsilon\right\} = P\left\{\left(\hat{B}_n(\underline{X}) - B\right)^2 > \epsilon^2\right\} \le \frac{E\left[\left(\hat{B}_n(\underline{X}) - B\right)^2\right]}{\epsilon^2} = \frac{\text{MSE}\left(\hat{B}_n\right)}{\epsilon^2} \xrightarrow{n\to\infty} 0,$$

dove MSE (*Mean Square Error*) indica l'errore quadratico medio: al crescere di n il secondo membro tende a zero, e il primo, che è una probabilità, non è negativo.

In sintesi

- **Stima bayesiana**: il parametro è una variabile Θ con densità a priori f_Θ; i dati la trasformano nella densità a posteriori $f_{\Theta|\underline{X}}$ (legge di Bayes).
- Lo **stimatore ottimo** minimizza il costo medio a posteriori, per ogni $\underline{x}$: $\hat{\theta} = \arg\min \int C(\hat{\theta} - \theta) f_{\Theta|\underline{X}}(\theta \mid \underline{x})\, \mathrm{d}\theta$.
- Costo quadratico: **MMSE** $= E[\Theta \mid \underline{X} = \underline{x}]$, il baricentro della densità a posteriori. Costo a tacca: **MAP** $= \arg\max f_{\Theta|\underline{X}}(\theta \mid \underline{x})$, il suo picco.
- Moneta con $B \sim \mathcal{U}(0,1)$ e w teste in n lanci: $\hat{\beta}_{\text{MMSE}} = \frac{w+1}{n+2}$, $\hat{\beta}_{\text{MAP}} = \frac{w}{n}$; errori quadratici $\frac{1}{6(n+2)} < \frac{1}{6n}$, entrambi $\to 0$: stimatori consistenti.
- $\int_0^1 t^a (1-t)^b\, \mathrm{d}t = \frac{a!\, b!}{(a+b+1)!}$ (funzioni Beta e Gamma di Eulero).

Stima classica e limite di Cramér-Rao

Nella stima bayesiana il parametro era una variabile aleatoria con una densità a priori nota. Spesso però non si ha abbastanza informazione per assegnare una densità $f_\Theta(\theta)$: la massa di un elettrone, la distanza di una stella, la probabilità di testa di una moneta mai vista non sono «estratte a caso» da nessuna parte. In questo capitolo il parametro θ è una quantità **deterministica e non nota**: è l'inferenza **non bayesiana**, o classica. Vedremo come costruire uno stimatore, come giudicarne la qualità e, soprattutto, che esiste un limite inferiore all'errore che *qualunque* stimatore può commettere: il limite di Cramér-Rao.

La verosimiglianza e lo stimatore a massima verosimiglianza

Le osservazioni $\underline{x} \in \mathcal{X}^n$ sono realizzazioni di un vettore aleatorio la cui PDF appartiene a una famiglia $f_{\underline{X}}(\underline{x};\theta)$, dove θ è deterministico e non noto e appartiene a un insieme S, lo **spazio dei parametri**. Il punto e virgola, al posto della barra verticale del condizionamento, ricorda che θ non è una variabile aleatoria: è solo un parametro da cui la densità dipende.

Verosimiglianza

La **verosimiglianza** (*likelihood*) del parametro θ, date le osservazioni disponibili, è la funzione

$$L(\theta;\underline{x}) = f_{\underline{X}}(\underline{x};\theta),$$

o, equivalentemente, la **funzione di verosimiglianza logaritmica** $\Lambda(\theta;\underline{x}) = \log f_{\underline{X}}(\underline{x};\theta)$.

È la stessa formula della densità, guardata al contrario: la densità è una funzione dei dati $\underline{x}$ per θ fissato (e ha area 1); la verosimiglianza è una funzione del parametro θ per i dati fissati, quelli che si sono osservati (e in generale non ha area 1). Dice quanto ciascun valore del parametro rende plausibili i dati osservati.

Stimatore a massima verosimiglianza

La **stima a massima verosimiglianza** di θ è

$$\hat{\theta}(\underline{x}) = \arg\max_{\theta\in S} \log f_{\underline{X}}(\underline{x};\theta),$$

ed è una realizzazione dello **stimatore a massima verosimiglianza** (MLE, *Maximum Likelihood Estimator*) $\hat{\Theta}(\underline{X}) = \arg\max_{\theta\in S} \log f_{\underline{X}}(\underline{X};\theta)$.

Si sceglie il valore del parametro che rende più probabili i dati osservati. Il logaritmo non sposta il punto di massimo (Capitolo 21) e trasforma i prodotti delle densità di dati indipendenti in somme, molto più facili da derivare. Si noti il legame con la stima bayesiana: con una densità a priori uniforme, la densità a posteriori è proporzionale alla verosimiglianza, e la stima MAP coincide con quella a massima verosimiglianza.

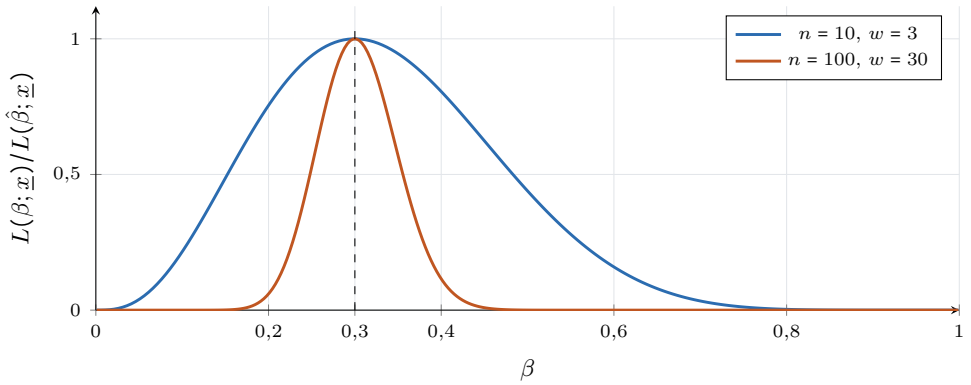


Figura 22.1: *La verosimiglianza della probabilità di testa β di una moneta, divisa per il suo massimo, dopo n lanci con w teste. In entrambi i casi il massimo è in $\hat{\beta} = \frac{w}{n} = 0{,}3$, ma con 100 lanci il picco è molto più stretto: i dati escludono molti più valori del parametro.*

LE QUALITÀ DI UNO STIMATORE

Polarizzazione di uno stimatore

Dato uno stimatore $\hat{\Theta}_n(\underline{X})$ del parametro non aleatorio θ, calcolato da n dati, si scrive

$$E\left[\hat{\Theta}_n(\underline{X})\right] = \theta + b_n(\theta),$$

dove $b_n(\theta)$ è la **polarizzazione** (*bias*) dello stimatore. Lo stimatore è **non polarizzato** (o corretto) se $b_n(\theta) = 0$, e **asintoticamente non polarizzato** se $b_n(\theta) \to 0$ per $n \to \infty$.

Uno stimatore non polarizzato non sbaglia «in media»: se si potesse ripetere l'esperimento tante volte, la media delle stime sarebbe il valore vero. Ma ogni singola stima può comunque essere lontana: serve anche misurare quanto le stime sono sparpagliate. L'errore aleatorio dello stimatore si quantifica di solito con il suo valore quadratico medio, l'**errore quadratico medio**

$$e_n^2 = E\left[\left(\hat{\Theta}_n(\underline{X}) - \theta\right)^2\right].$$

Teorema 22.1 — L'errore quadratico medio si divide in varianza e polarizzazione

$$\mathrm{MSE}\left[\hat{\Theta}(\underline{X})\right] = E\left[\left(\hat{\Theta}(\underline{X}) - \theta\right)^2\right] = \mathrm{VAR}\left[\hat{\Theta}(\underline{X})\right] + b_n^2(\theta).$$

In particolare, se l'errore quadratico medio tende a zero, tendono a zero sia la varianza sia la polarizzazione.

Dimostrazione

Passo 1 — Si aggiunge e si toglie la media. $\hat{\Theta} - \theta = \left(\hat{\Theta} - E[\hat{\Theta}]\right) + \left(E[\hat{\Theta}] - \theta\right)$, e la seconda parentesi è il numero $b_n(\theta)$.

Passo 2 — Si sviluppa il quadrato.

$$E\left[\left(\hat{\Theta} - \theta\right)^2\right] = E\left[\left(\hat{\Theta} - E[\hat{\Theta}]\right)^2\right] + 2\,b_n(\theta)\,E\left[\hat{\Theta} - E[\hat{\Theta}]\right] + b_n^2(\theta).$$

Il termine misto ha media nulla, perché lo scarto dalla media ha media zero; il primo termine è la varianza.

Passo 3 — La conseguenza. I due addendi $\mathrm{VAR}[\hat{\Theta}] \geq 0$ e $b_n^2(\theta) \geq 0$ non sono negativi: se la loro somma tende a zero, tende a zero ciascuno dei due.

■

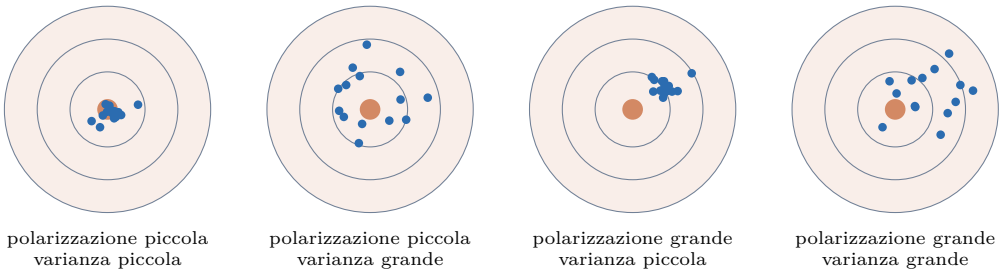


Figura 22.2: *Polarizzazione e varianza come tiri al bersaglio: il centro è il valore vero θ, ogni punto blu una stima ottenuta da un diverso campione. La polarizzazione è la distanza fra il centro dei colpi e il centro del bersaglio, la varianza è quanto i colpi sono sparpagliati. Solo il primo stimatore ha un errore quadratico medio piccolo.*

Per uno stimatore non polarizzato l'errore quadratico medio coincide con la varianza,

$$\mathrm{VAR}\left[\hat{\Theta}_n(\underline{X})\right] = E\left[\left(\hat{\Theta}_n(\underline{X}) - \theta\right)^2\right] = E\left[\hat{\Theta}_n^2(\underline{X})\right] - \theta^2,$$

e lo stimatore non polarizzato a minimo errore quadratico medio è quello che minimizza la varianza. Come nel caso bayesiano (Capitolo 21), si parla poi di consistenza: uno stimatore è **consistente in senso debole** se $\hat{\Theta}_n(\underline{X}) \to \theta$ in probabilità, **consistente in senso forte** se $\hat{\Theta}_n(\underline{X}) \to \theta$ quasi certamente (con probabilità 1), **consistente in media quadratica** se $e_n^2 \to 0$.

Il limite di Cramér-Rao

Quanto può essere piccola la varianza di uno stimatore non polarizzato? Il risultato di questa sezione dice che non può scendere sotto un certo valore, che dipende solo dalla famiglia di densità e non dallo stimatore. Sia $\underline{x} \in \mathcal{X}^n$ la realizzazione di un vettore aleatorio $\underline{X} \sim f_{\underline{X}}(\underline{x};\theta)$, con θ parametro non aleatorio. Supponiamo che la densità sia abbastanza regolare da poter derivare rispetto a θ sotto il segno di integrale (Capitolo 21).

Richiamo di matematica: la derivata del logaritmo

Per la regola della catena (Capitolo 11), la derivata di $\log g(\theta)$ è $\frac{g'(\theta)}{g(\theta)}$ (qui log è il logaritmo naturale). Rovesciando la formula, $g'(\theta) = \left(\frac{\mathrm{d}}{\mathrm{d}\theta}\log g(\theta)\right) g(\theta)$. Applicata a una densità che dipende da un parametro:

$$\frac{\partial}{\partial\theta} f_{\underline{X}}(\underline{x};\theta) = \left(\frac{\partial}{\partial\theta}\log f_{\underline{X}}(\underline{x};\theta)\right) f_{\underline{X}}(\underline{x};\theta).$$

È il trucco che trasforma un integrale della derivata della densità in una *media*, perché compare il fattore $f_{\underline{X}}$.

Teorema 22.2 — Le due identità della derivata logaritmica

$$E\left[\frac{\partial}{\partial\theta}\log f_{\underline{X}}(\underline{X};\theta)\right] = 0, \qquad E\left[\frac{\partial^2}{\partial\theta^2}\log f_{\underline{X}}(\underline{X};\theta)\right] = -E\left[\left(\frac{\partial}{\partial\theta}\log f_{\underline{X}}(\underline{X};\theta)\right)^2\right] = -\mathrm{VAR}\left[\frac{\partial}{\partial\theta}\log f_{\underline{X}}(\underline{X};\theta)\right].$$

Dimostrazione — derivando due volte l'area della densità

Passo 1 — Prima derivata. Si parte dall'identità $\int_{\mathbb{R}^n} f_{\underline{X}}(\underline{x};\theta)\,\mathrm{d}\underline{x} = 1$, che vale per ogni θ. Derivando rispetto a θ (il secondo membro è costante) e usando il richiamo:

$$\int_{\mathbb{R}^n} \frac{\partial}{\partial\theta} f_{\underline{X}}(\underline{x};\theta)\,\mathrm{d}\underline{x} = \int_{\mathbb{R}^n} \left(\frac{\partial}{\partial\theta}\log f_{\underline{X}}(\underline{x};\theta)\right) f_{\underline{X}}(\underline{x};\theta)\,\mathrm{d}\underline{x} = E\left[\frac{\partial}{\partial\theta}\log f_{\underline{X}}(\underline{X};\theta)\right] = 0.$$

Sotto integrale $\underline{x}$ è una variabile muta di integrazione e si scrive con la lettera minuscola; nella media statistica, che è la media di una funzione di un vettore aleatorio, si scrive con la maiuscola.

Passo 2 — Seconda derivata. Si deriva di nuovo l'integrale del passo 1, con la regola del prodotto:

$$\int_{\mathbb{R}^n} \left(\frac{\partial^2}{\partial\theta^2}\log f_{\underline{X}}\right) f_{\underline{X}}\,\mathrm{d}\underline{x} + \int_{\mathbb{R}^n} \left(\frac{\partial}{\partial\theta}\log f_{\underline{X}}\right) \frac{\partial f_{\underline{X}}}{\partial\theta}\,\mathrm{d}\underline{x} = 0.$$

Nel secondo integrale si usa di nuovo il richiamo, $\frac{\partial f_{\underline{X}}}{\partial\theta} = \left(\frac{\partial}{\partial\theta}\log f_{\underline{X}}\right) f_{\underline{X}}$: diventa la media del quadrato della derivata logaritmica. Portandolo a destra si ottiene la seconda identità.

Passo 3 — Quadrato medio e varianza. La derivata logaritmica ha media nulla (passo 1), quindi il suo valore quadratico medio coincide con la sua varianza.

■

Informazione di Fisher

L'**informazione di Fisher** che i dati contengono sul parametro θ è

$$I_n(\theta) = E\left[\left(\frac{\partial}{\partial\theta}\log f_{\underline{X}}(\underline{X};\theta)\right)^2\right] = -E\left[\frac{\partial^2}{\partial\theta^2}\log f_{\underline{X}}(\underline{X};\theta)\right].$$

La seconda forma ha un'interpretazione geometrica: la derivata seconda della log-verosimiglianza misura quanto è **curva**, quanto è appuntito il suo picco. Un picco stretto, come quello con 100 lanci nella figura della prima sezione, individua bene il parametro: tanta informazione. Un picco piatto lascia molti valori quasi ugualmente plausibili: poca informazione.

Teorema 22.3 — Limite di Cramér-Rao

Sia $\hat{\Theta}(\underline{X})$ uno stimatore del parametro non aleatorio θ, con $E[\hat{\Theta}(\underline{X})] = \theta + b_n(\theta)$. Allora

$$\mathrm{VAR}\left[\hat{\Theta}(\underline{X})\right] \geq \frac{|1 + b_n'(\theta)|^2}{I_n(\theta)}.$$

In particolare, se lo stimatore è non polarizzato,

$$\mathrm{MSE}\left[\hat{\Theta}(\underline{X})\right] = E\left[\left(\hat{\Theta}(\underline{X}) - \theta\right)^2\right] = \mathrm{VAR}\left[\hat{\Theta}(\underline{X})\right] \geq \frac{1}{I_n(\theta)}.$$

Dimostrazione — con la covarianza

Passo 1 — La media dello stimatore, derivata. Per ipotesi $E[\hat{\Theta}(\underline{X})] = \int_{\mathbb{R}^n} \hat{\Theta}(\underline{x})\, f_{\underline{X}}(\underline{x};\theta)\,\mathrm{d}\underline{x} = \theta + b_n(\theta)$. Derivando rispetto a θ (lo stimatore $\hat{\Theta}(\underline{x})$ dipende solo dai dati, non da θ) e usando il richiamo:

$$\int_{\mathbb{R}^n} \hat{\Theta}(\underline{x}) \left(\frac{\partial}{\partial\theta} \log f_{\underline{X}}(\underline{x};\theta) \right) f_{\underline{X}}(\underline{x};\theta)\,\mathrm{d}\underline{x} = E\left[\hat{\Theta}(\underline{X}) \frac{\partial}{\partial\theta} \log f_{\underline{X}}(\underline{X};\theta) \right] = 1 + b_n'(\theta).$$

Passo 2 — È una covarianza. Ricordando che $COV(X,Y) = R_{XY} - \mu_X\mu_Y$ (Capitolo 9), la covarianza coincide con la correlazione se almeno una delle due medie è nulla, come qui per la derivata logaritmica (Teorema 22.2):

$$COV\left(\hat{\Theta}(\underline{X}),\ \frac{\partial}{\partial\theta} \log f_{\underline{X}}(\underline{X};\theta) \right) = E\left[\hat{\Theta}(\underline{X}) \frac{\partial}{\partial\theta} \log f_{\underline{X}}(\underline{X};\theta) \right] = 1 + b_n'(\theta).$$

Passo 3 — Il limite della covarianza. Per il Capitolo 9, $|COV(X,Y)|^2 \le \sigma_X^2 \sigma_Y^2$, quindi

$$|1 + b_n'(\theta)|^2 \le \mathrm{VAR}\left[\hat{\Theta}(\underline{X})\right] \mathrm{VAR}\left[\frac{\partial}{\partial\theta} \log f_{\underline{X}}(\underline{X};\theta) \right] = \mathrm{VAR}\left[\hat{\Theta}(\underline{X})\right] I_n(\theta),$$

dove la varianza della derivata logaritmica è l'informazione di Fisher, per il Teorema 22.2.

Passo 4 — Si divide. Dividendo per $I_n(\theta) > 0$ si ottiene il limite. Se lo stimatore è non polarizzato, $b_n = 0$, la derivata b_n' è nulla e la varianza coincide con l'errore quadratico medio.

■

Mettendo insieme il limite con il Teorema 22.1, per uno stimatore qualsiasi

$$\mathrm{MSE}\left[\hat{\Theta}(\underline{X})\right] = \mathrm{VAR}\left[\hat{\Theta}(\underline{X})\right] + b_n^2(\theta) \ge \frac{|1 + b_n'(\theta)|^2}{I_n(\theta)} + b_n^2(\theta).$$

Il limite di Cramér-Rao (CRB, *Cramér-Rao Bound*) è dunque un limite inferiore per l'errore quadratico medio di qualunque stimatore non polarizzato: nessuno può fare meglio di $\frac{1}{I_n(\theta)}$.

Stimatore efficiente

Uno stimatore non polarizzato il cui errore quadratico medio è uguale al limite di Cramér-Rao, $\frac{1}{I_n(\theta)}$, si dice **efficiente**.

Le slide aggiungono due fatti, che non dimostriamo. Se per un dato problema di stima non bayesiana esiste uno stimatore efficiente, questo coincide necessariamente con lo stimatore a massima verosimiglianza. E lo stimatore a massima verosimiglianza ha un buon comportamento asintotico: sotto opportune condizioni di regolarità è

- asintoticamente corretto (non polarizzato);
- consistente (converge in probabilità al valore vero);
- asintoticamente efficiente (la sua varianza si avvicina al limite di Cramér-Rao);
- asintoticamente normale (per n grande ha densità gaussiana, come nel teorema centrale del limite).

ESEMPI

Esempio 22.1 — La probabilità di testa

Sia $\underline{x} \in \{0,1\}^n$ la realizzazione di n lanci di Bernoulli con parametro β non noto, e sia $w(\underline{x})$ il numero di «1». Come nel Capitolo 21, $p_{\underline{X}}(\underline{x}) = \beta^{w(\underline{x})}(1-\beta)^{n-w(\underline{x})}$; ora però β non è aleatorio.

La stima a massima verosimiglianza. Si annulla la derivata della log-verosimiglianza, che è la stessa del calcolo della stima MAP:

$$\frac{\partial}{\partial\beta}\log p_{\underline{X}}(\underline{x}) = \frac{w(\underline{x})}{\beta} - \frac{n-w(\underline{x})}{1-\beta} = 0 \quad\Longrightarrow\quad (1-\beta)\,w(\underline{x}) = \beta\,(n-w(\underline{x})) \quad\Longrightarrow\quad \hat{\beta} = \frac{w(\underline{x})}{n}.$$

Le prestazioni. $w(\underline{X})$ è binomiale: $E[w(\underline{X})] = n\beta$ ed $E[w^2(\underline{X})] = n\beta(1-\beta) + n^2\beta^2$ (varianza più quadrato della media). Quindi

$$E\left[\hat{\beta}(\underline{X})\right] = \frac{n\beta}{n} = \beta, \qquad E\left[\hat{\beta}^2(\underline{X})\right] = \frac{n\beta - n\beta^2 + n^2\beta^2}{n^2} = \frac{\beta(1-\beta)}{n} + \beta^2, \qquad \mathrm{VAR}\left[\hat{\beta}(\underline{X})\right] = \frac{\beta(1-\beta)}{n}.$$

(Nella slide 92 c'è scritto $\mathrm{VAR}[\hat{\beta}^2(\underline{X})]$: è la varianza di $\hat{\beta}$, non del suo quadrato.) Lo stimatore è non polarizzato e consistente in media quadratica. **È efficiente?** La derivata seconda della log-verosimiglianza è

$$\frac{\partial^2}{\partial\beta^2}\log p_{\underline{X}}(\underline{x}) = -\frac{w(\underline{x})}{\beta^2} - \frac{n-w(\underline{x})}{(1-\beta)^2},$$

e quindi l'informazione di Fisher è

$$I_n(\beta) = E\left[\frac{w(\underline{X})}{\beta^2} + \frac{n-w(\underline{X})}{(1-\beta)^2}\right] = \frac{n\beta}{\beta^2} + \frac{n-n\beta}{(1-\beta)^2} = \frac{n}{\beta} + \frac{n}{1-\beta} = n\,\frac{1-\beta+\beta}{\beta(1-\beta)} = \frac{n}{\beta(1-\beta)}.$$

Il limite di Cramér-Rao è $\frac{1}{I_n(\beta)} = \frac{\beta(1-\beta)}{n}$: la varianza dello stimatore a massima verosimiglianza lo raggiunge, quindi lo stimatore è **efficiente**. Nessuno stimatore non polarizzato può stimare la probabilità di testa meglio della frequenza delle teste.

Esempio 22.2 — La media di dati gaussiani

Siano $X_1, \ldots, X_n$ i.i.d. $\mathcal{N}(\mu, \sigma^2)$, con σ^2 noto e μ da stimare. La log-verosimiglianza è

$$\log f_{\underline{X}}(\underline{x};\mu) = -\frac{n}{2}\log(2\pi\sigma^2) - \sum_{k=1}^{n}\frac{(x_k-\mu)^2}{2\sigma^2}, \qquad \frac{\partial}{\partial\mu}\log f_{\underline{X}} = \sum_{k=1}^{n}\frac{x_k-\mu}{\sigma^2}, \qquad \frac{\partial^2}{\partial\mu^2}\log f_{\underline{X}} = -\frac{n}{\sigma^2}.$$

Annullando la derivata prima si trova $\hat{\mu} = \frac{1}{n}\sum_k x_k$: la stima a massima verosimiglianza è la media campione. L'informazione di Fisher è $I_n(\mu) = \frac{n}{\sigma^2}$ e il limite di Cramér-Rao è $\frac{\sigma^2}{n}$, che è proprio la varianza della media campione (Capitolo 18): anche qui lo stimatore a massima verosimiglianza è efficiente.

In sintesi

- Parametro **non aleatorio**: **verosimiglianza** $L(\theta;\underline{x}) = f_{\underline{X}}(\underline{x};\theta)$; stima a **massima verosimiglianza** $\hat{\theta} = \arg\max_\theta \log f_{\underline{X}}(\underline{x};\theta)$.
- **Polarizzazione** $b_n(\theta) = E[\hat{\Theta}] - \theta$; MSE = VAR + b_n^2; consistenza debole, forte, in media quadratica.
- Derivata logaritmica: media nulla; **informazione di Fisher** $I_n(\theta) = E[(\partial_\theta \log f)^2] = -E[\partial_\theta^2 \log f]$.
- **Limite di Cramér-Rao**: $\mathrm{VAR}[\hat{\Theta}] \geq \frac{|1+b_n'|^2}{I_n(\theta)}$; per uno stimatore non polarizzato MSE $\geq \frac{1}{I_n(\theta)}$. Chi lo raggiunge è **efficiente**.
- Frequenza delle teste e media campione sono stime a massima verosimiglianza efficienti, con varianze $\frac{\beta(1-\beta)}{n}$ e $\frac{\sigma^2}{n}$.

Stima lineare MMSE e gradiente

Lo stimatore MMSE del Capitolo 21, la media condizionata $E[\Theta \mid \underline{X} = \underline{x}]$, è il migliore possibile, ma per calcolarlo serve tutta la densità a posteriori, che spesso non si conosce o è troppo complicata. Una via molto più pratica è accontentarsi del miglior stimatore **lineare**: una combinazione lineare dei dati più una costante. Vedremo che per trovarlo bastano medie e covarianze, cioè la caratterizzazione sintetica del Capitolo 16. Poi risolveremo lo stesso problema in modo iterativo, scendendo «a valle» lungo la superficie dell'errore: è l'algoritmo del gradiente, alla base di moltissimi metodi di apprendimento automatico.

Il gradiente

Richiamo di matematica: il gradiente di forme lineari e quadratiche

Per una funzione di più variabili $g(\underline{w})$, con $\underline{w} = [w_1, \ldots, w_n]^T$, il **gradiente** è il vettore delle derivate parziali (Capitolo 14):

$$\nabla_{\underline{w}}\, g = \left[\frac{\partial g}{\partial w_1}, \frac{\partial g}{\partial w_2}, \ldots, \frac{\partial g}{\partial w_n}\right]^T.$$

Indica la direzione in cui g cresce più rapidamente; nel punto di minimo di una funzione regolare è il vettore nullo, come la derivata nel minimo di una funzione di una variabile. Due formule ci serviranno.

- **Forma lineare**: $\nabla_{\underline{w}} \left(\underline{u}^T \underline{w}\right) = \nabla_{\underline{w}} \left(\underline{w}^T \underline{u}\right) = \underline{u}$. Infatti $\underline{u}^T \underline{w} = u_1 w_1 + \cdots + u_n w_n$, e la derivata rispetto a w_k è u_k: è la versione vettoriale di $\frac{\mathrm{d}}{\mathrm{d}w}(uw) = u$.
- **Forma quadratica**: $\nabla_{\underline{w}} \left(\underline{w}^T \underline{\underline{A}}\, \underline{w}\right) = 2\underline{\underline{A}}\, \underline{w}$, se $\underline{\underline{A}}$ è simmetrica. Infatti $\underline{w}^T \underline{\underline{A}}\, \underline{w} = \sum_i \sum_j w_i\, a_{ij}\, w_j$, e w_k compare nei termini con $i = k$ e in quelli con $j = k$:

$$\frac{\partial}{\partial w_k} \underline{w}^T \underline{\underline{A}}\, \underline{w} = \sum_j a_{kj} w_j + \sum_i w_i a_{ik} = (\underline{\underline{A}}\, \underline{w})_k + (\underline{\underline{A}}^T \underline{w})_k = 2(\underline{\underline{A}}\, \underline{w})_k.$$

  È la versione vettoriale di $\frac{\mathrm{d}}{\mathrm{d}w}(aw^2) = 2aw$.

Lo stimatore lineare MMSE

Il campione osservato $\underline{x}$ è la realizzazione di un vettore aleatorio $\underline{X}$; si vuole stimare un parametro aleatorio Θ, distribuito secondo una legge nota, con uno stimatore della forma

$$\hat{\Theta}(\underline{X}) = \underline{a}^T \underline{X} + b, \qquad \underline{a} \in \mathbb{R}^n, \quad b \in \mathbb{R}.$$

Per alleggerire la notazione, d'ora in poi si omette il pedice $\underline{X}$ nelle matrici di correlazione e di covarianza: $\underline{\underline{R}} = E[\underline{X}\,\underline{X}^T]$ è la matrice di correlazione e $\underline{\underline{M}} = E[(\underline{X} - E[\underline{X}])(\underline{X} - E[\underline{X}])^T]$ la matrice di covarianza dei dati.

Stimatore lineare MMSE

Lo **stimatore lineare MMSE** (LMMSE) usa il vettore $\underline{a}$ e la costante b che rendono minimo l'errore quadratico medio

$$E\left[\left(\hat{\Theta}(\underline{X}) - \Theta\right)^2\right] = E\left[\left(\underline{a}^T \underline{X} + b - \Theta\right)^2\right].$$

Teorema 23.1 — Lo stimatore lineare MMSE

I coefficienti ottimi sono

$$\underline{a}_{\text{LMMSE}} = \underline{\underline{M}}^{-1} \underline{s}, \qquad b_{\text{LMMSE}} = E[\Theta] - \underline{a}_{\text{LMMSE}}^T E[\underline{X}],$$

dove $\underline{s} = E[\Theta \underline{X}] - E[\Theta]\,E[\underline{X}] = E\left[(\underline{X} - E[\underline{X}])(\Theta - E[\Theta])\right]$ è il vettore delle covarianze fra i dati e il parametro. In modo equivalente,

$$\hat{\Theta}_{\text{LMMSE}}(\underline{X}) = E[\Theta] + \underline{s}^T \underline{\underline{M}}^{-1} \left(\underline{X} - E[\underline{X}]\right).$$

Dimostrazione

Passo 1 — Si sviluppa il quadrato. Un numero è uguale al suo trasposto (Capitolo 16), quindi si può scrivere il quadrato come prodotto per il trasposto: $\left(\underline{a}^T \underline{X} + b - \Theta\right)^2 = \left(\underline{a}^T \underline{X} + b - \Theta\right)\left(\underline{X}^T \underline{a} + b - \Theta\right)$. Moltiplicando e facendo la media:

$$E\left[\left(\underline{a}^T \underline{X} + b - \Theta\right)^2\right] = \underline{a}^T \underline{\underline{R}}\, \underline{a} + b^2 + E[\Theta^2] + 2b\, \underline{a}^T E[\underline{X}] - 2b\, E[\Theta] - 2\underline{a}^T E[\Theta \underline{X}],$$

dove $E[\underline{a}^T \underline{X}\, \underline{X}^T \underline{a}] = \underline{a}^T \underline{\underline{R}}\, \underline{a}$, perché $\underline{a}$ è costante.

Passo 2 — Il gradiente rispetto ad $\underline{a}$. Con le due formule del richiamo ($\underline{\underline{R}}$ è simmetrica):

$$\nabla_{\underline{a}} E\left[\left(\underline{a}^T \underline{X} + b - \Theta\right)^2\right] = 2\underline{\underline{R}}\, \underline{a} + 2b\, E[\underline{X}] - 2E[\Theta \underline{X}] = \underline{0}.$$

Passo 3 — La derivata rispetto a b.

$$\frac{\partial}{\partial b} E\left[\left(\underline{a}^T \underline{X} + b - \Theta\right)^2\right] = 2b + 2\underline{a}^T E[\underline{X}] - 2E[\Theta] = 0 \quad \Longrightarrow \quad b = E[\Theta] - \underline{a}^T E[\underline{X}] = E[\Theta] - E[\underline{X}]^T \underline{a}.$$

Passo 4 — Si sostituisce b. Nella prima equazione: $\underline{\underline{R}}\, \underline{a} + \left(E[\Theta] - E[\underline{X}]^T \underline{a}\right) E[\underline{X}] - E[\Theta \underline{X}] = \underline{0}$. Il numero $E[\underline{X}]^T \underline{a}$ può stare a destra o a sinistra del vettore $E[\underline{X}]$, e per la proprietà associativa del prodotto fra matrici $E[\underline{X}]\left(E[\underline{X}]^T \underline{a}\right) = \left(E[\underline{X}] E[\underline{X}]^T\right) \underline{a}$. Quindi

$$\left(\underline{\underline{R}} - E[\underline{X}]\, E[\underline{X}]^T\right) \underline{a} + E[\Theta]\, E[\underline{X}] - E[\Theta \underline{X}] = \underline{0}.$$

Passo 5 — Compaiono le covarianze. La matrice fra parentesi è la matrice di covarianza, $\underline{\underline{M}} = \underline{\underline{R}} - E[\underline{X}] E[\underline{X}]^T$ (Capitolo 16), e $E[\Theta \underline{X}] - E[\Theta] E[\underline{X}] = \underline{s}$ è la covarianza fra dati e parametro, calcolata come nel Capitolo 9 componente per componente. L'equazione diventa $\underline{\underline{M}}\, \underline{a} = \underline{s}$, da cui $\underline{a}_{\text{LMMSE}} = \underline{\underline{M}}^{-1} \underline{s}$.

Passo 6 — La forma equivalente. $\underline{a}^T \underline{X} + b = E[\Theta] + \underline{a}^T (\underline{X} - E[\underline{X}])$, e $\underline{a}^T = \underline{s}^T (\underline{\underline{M}}^{-1})^T = \underline{s}^T \underline{\underline{M}}^{-1}$, perché l'inversa di una matrice simmetrica è simmetrica.

■

La forma equivalente ha un significato chiaro: senza dati la stima migliore sarebbe la media a priori $E[\Theta]$; i dati la correggono, in proporzione a quanto si discostano dalla loro media e a quanto sono correlati con il parametro. L'errore quadratico medio è una funzione di secondo grado dei coefficienti a forma di «scodella», perché la matrice di covarianza è definita non negativa (Capitolo 16): il punto in cui il gradiente si annulla è il fondo della scodella, cioè il minimo. Sostituendo i coefficienti ottimi si trova anche il valore minimo:

$$E\left[\left(\hat{\Theta}_{\text{LMMSE}} - \Theta\right)^2\right] = \sigma_\Theta^2 - \underline{s}^T \underline{\underline{M}}^{-1} \underline{s},$$

cioè la varianza a priori del parametro, diminuita di quanto spiegano i dati. (Basta scrivere l'errore come $\underline{a}^T (\underline{X} - E[\underline{X}]) - (\Theta - E[\Theta])$, calcolarne il quadrato medio, $\underline{a}^T \underline{\underline{M}}\, \underline{a} - 2\underline{a}^T \underline{s} + \sigma_\Theta^2$, e porre $\underline{a} = \underline{\underline{M}}^{-1} \underline{s}$.)

Quando il lineare è anche il migliore in assoluto

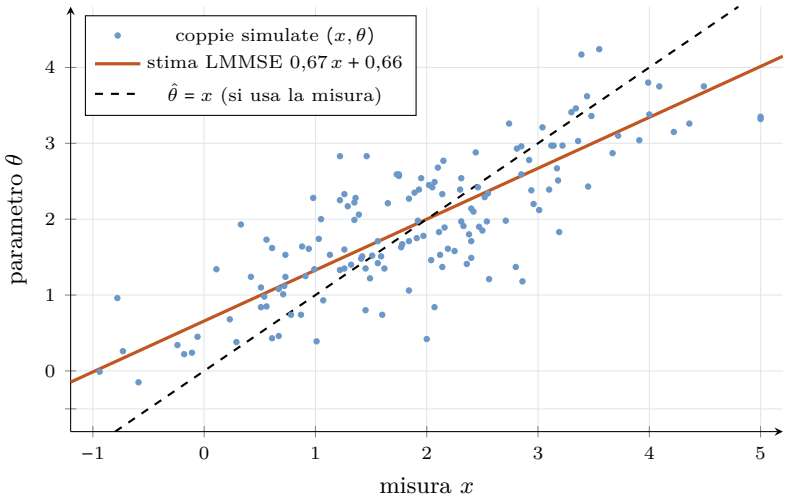
Se $\underline{X}$ e Θ sono congiuntamente gaussiani, la media condizionata $E[\Theta \mid \underline{X} = \underline{x}]$ è una funzione lineare dei dati (nel Capitolo 16, per due variabili standard, era ρx_1): lo stimatore lineare MMSE coincide allora con lo stimatore MMSE, il migliore fra tutti. Per dati non gaussiani lo stimatore lineare è solo il migliore fra quelli lineari.

Esempio 23.1 — Una misura rumorosa

Un parametro Θ ha media μ_Θ e varianza σ^2_Θ, e lo si misura una volta con uno strumento rumoroso: $X = \Theta + N$, con il rumore N indipendente da Θ, a media nulla e varianza σ^2_N. È il caso $n = 1$: la matrice di covarianza è il numero $M = \sigma^2_X = \sigma^2_\Theta + \sigma^2_N$ (le varianze di variabili indipendenti si sommano) e il vettore $\underline{s}$ è il numero $COV(X, \Theta) = COV(\Theta + N, \Theta) = \sigma^2_\Theta$. Quindi

$$a = \frac{\sigma^2_\Theta}{\sigma^2_\Theta + \sigma^2_N}, \qquad b = \mu_\Theta - a\,\mu_X = (1 - a)\,\mu_\Theta, \qquad \hat{\Theta} = a\,X + (1 - a)\,\mu_\Theta.$$

La stima è una **media pesata** fra la misura e la media a priori. Se il rumore è piccolo ($\sigma_N \ll \sigma_\Theta$) il peso a è vicino a 1 e ci si fida della misura; se il rumore è grande ci si fida di più di ciò che si sapeva prima. L'errore quadratico medio è $\sigma^2_\Theta - \frac{\sigma^4_\Theta}{\sigma^2_\Theta + \sigma^2_N} = \frac{\sigma^2_\Theta \sigma^2_N}{\sigma^2_\Theta + \sigma^2_N}$, minore sia di σ^2_N (l'errore che si commette usando la misura così com'è) sia di σ^2_Θ (l'errore che si commette ignorandola).



Nella simulazione $\mu_\Theta = 2$, $\sigma_\Theta = 1$ e $\sigma_N = 0{,}7$: la retta LMMSE ha pendenza $a \approx 0{,}67$ e passa per il centro della nuvola, ed è meno ripida della bisettrice. L'errore quadratico medio scende da $\sigma^2_N = 0{,}49$ a $0{,}33$.

L'ALGORITMO DEL GRADIENTE

Calcolare $\underline{\underline{M}}^{-1}\,\underline{s}$ richiede di invertire una matrice $n \times n$, che per n grande è costoso; inoltre, se le statistiche cambiano nel tempo, bisognerebbe rifare il conto ogni volta. Un'alternativa è risolvere il problema in modo iterativo. Sostituendo l'espressione ottima di b nel gradiente, il gradiente dell'errore quadratico medio rispetto ad $\underline{a}$ risulta

$$2\underline{\underline{M}}\,\underline{a} - 2\underline{s},$$

dove supponiamo noto il vettore $\underline{s}$. Il gradiente indica la direzione in cui l'errore cresce più rapidamente: per scendere verso il minimo basta fare un piccolo passo nella direzione opposta, e ripetere.

Algoritmo del gradiente

L'**algoritmo del gradiente** per lo stimatore lineare MMSE parte da un vettore iniziale $\underline{a}^{(1)}$ e calcola

$$\underline{a}^{(k+1)} = \underline{a}^{(k)} - \gamma\left(\underline{\underline{M}}\,\underline{a}^{(k)} - \underline{s}\right), \qquad k = 1, 2, \ldots$$

dove $\gamma > 0$ è il **passo** (il fattore 2 del gradiente è assorbito in γ).

Le slide indicano l'iterazione con l'apice n; qui usiamo k, per non confonderla con la dimensione n dei dati. Si noti che $\underline{\underline{M}}\,\underline{a}^{(k)} - \underline{s} = \underline{\underline{M}}\left(\underline{a}^{(k)} - \underline{\underline{M}}^{-1}\,\underline{s}\right) = \underline{\underline{M}}\left(\underline{a}^{(k)} - \underline{a}_{\text{LMMSE}}\right)$: il passo è proporzionale alla distanza dalla soluzione, «vista» attraverso la matrice $\underline{\underline{M}}$. Per capire se l'algoritmo converge servono gli autovalori.

Richiamo di matematica: autovalori, autovettori e decomposizione spettrale

Un vettore $\underline{v} \neq \underline{0}$ è un **autovettore** della matrice quadrata $\underline{\underline{S}}$, con **autovalore** λ, se $\underline{\underline{S}}\,\underline{v} = \lambda \underline{v}$: la matrice non lo ruota, lo allunga soltanto (o lo accorcia, o lo ribalta) di un fattore λ. Per esempio $\begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}\begin{bmatrix} 1 \\ 1 \end{bmatrix} = 3\begin{bmatrix} 1 \\ 1 \end{bmatrix}$ e $\begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}\begin{bmatrix} 1 \\ -1 \end{bmatrix} = 1 \cdot \begin{bmatrix} 1 \\ -1 \end{bmatrix}$: autovalori 3 e 1.

Una matrice reale **simmetrica** ha tutti gli autovalori reali, e autovettori (corrispondenti ad autovalori distinti) ortogonali fra loro. Normalizzandoli (lunghezza 1) e mettendoli come colonne di una matrice $\underline{\underline{U}}$, si ottiene una matrice **ortogonale**, con $\underline{\underline{U}}^T\underline{\underline{U}} = \underline{\underline{I}}$, cioè $\underline{\underline{U}}^T = \underline{\underline{U}}^{-1}$, e vale la **decomposizione spettrale**

$$\underline{\underline{S}} = \underline{\underline{U}}\,\underline{\underline{\Lambda}}_S\,\underline{\underline{U}}^T,$$

dove $\underline{\underline{\Lambda}}_S$ è la matrice diagonale degli autovalori. La decomposizione rende facili le potenze: nel prodotto $\underline{\underline{S}}\,\underline{\underline{S}} = \underline{\underline{U}}\,\underline{\underline{\Lambda}}_S\underline{\underline{U}}^T\underline{\underline{U}}\,\underline{\underline{\Lambda}}_S\underline{\underline{U}}^T$ le due $\underline{\underline{U}}$ centrali si annullano ($\underline{\underline{U}}^T\underline{\underline{U}} = \underline{\underline{I}}$), e iterando

$$\underline{\underline{S}}^k = \underline{\underline{U}}\,\underline{\underline{\Lambda}}_S^k\,\underline{\underline{U}}^T,$$

dove la potenza k-esima di una matrice diagonale è la matrice diagonale delle potenze k-esime degli elementi.

Teorema 23.2 — Convergenza dell'algoritmo del gradiente

Sia $\underline{\epsilon}^{(k)} = \underline{a}^{(k)} - \underline{a}_{\text{LMMSE}}$ l'errore al passo k. Allora

$$\underline{\epsilon}^{(k+1)} = \left(\underline{\underline{I}} - \gamma\underline{\underline{M}}\right)^k \underline{\epsilon}^{(1)},$$

e l'errore converge a zero, qualunque sia il punto di partenza, se e solo se

$$0 < \gamma < \frac{2}{\lambda_{\text{MAX}}},$$

dove λ_{MAX} è il più grande autovalore della matrice di covarianza $\underline{\underline{M}}$.

Dimostrazione

Passo 1 — Un passo dell'errore. Sottraendo $\underline{a}_{\text{LMMSE}}$ ai due membri dell'algoritmo e usando $\underline{\underline{M}}\,\underline{a}^{(k)} - \underline{s} = \underline{\underline{M}}\,\underline{\epsilon}^{(k)}$:

$$\underline{\epsilon}^{(k+1)} = \underline{\epsilon}^{(k)} - \gamma\underline{\underline{M}}\,\underline{\epsilon}^{(k)} = \left(\underline{\underline{I}} - \gamma\underline{\underline{M}}\right)\underline{\epsilon}^{(k)}.$$

Passo 2 — Si itera. $\underline{\epsilon}^{(k+1)} = (\underline{\underline{I}} - \gamma\underline{\underline{M}})(\underline{\underline{I}} - \gamma\underline{\underline{M}})\underline{\epsilon}^{(k-1)} = \cdots = (\underline{\underline{I}} - \gamma\underline{\underline{M}})^k\underline{\epsilon}^{(1)}$.

Passo 3 — Gli autovalori di $\underline{\underline{S}} = \underline{\underline{I}} - \gamma\underline{\underline{M}}$. $\underline{\underline{S}}$ è simmetrica, come $\underline{\underline{M}}$. Se $\underline{\underline{M}}\,\underline{v} = \lambda\underline{v}$, allora $\underline{\underline{S}}\,\underline{v} = \underline{v} - \gamma\lambda\underline{v} = (1-\gamma\lambda)\underline{v}$: $\underline{\underline{S}}$ ha gli stessi autovettori di $\underline{\underline{M}}$, e autovalori $1 - \gamma\lambda_i$. Quindi $\underline{\underline{\Lambda}}_S = \underline{\underline{I}} - \gamma\underline{\underline{\Lambda}}_M$, dove $\underline{\underline{\Lambda}}_M$ è la matrice diagonale degli autovalori della matrice di covarianza.

Passo 4 — Le potenze. Con la decomposizione spettrale,

$$\underline{\epsilon}^{(k+1)} = \underline{\underline{U}}\left(\underline{\underline{I}} - \gamma\underline{\underline{\Lambda}}_M\right)^k\underline{\underline{U}}^T\underline{\epsilon}^{(1)},$$

e sulla diagonale di $\left(\underline{\underline{I}} - \gamma\underline{\underline{\Lambda}}_M\right)^k$ ci sono i numeri $(1-\gamma\lambda_i)^k$. Lungo ciascun autovettore l'errore viene moltiplicato, a ogni passo, per $1 - \gamma\lambda_i$.

Passo 5 — La condizione. Le potenze $(1-\gamma\lambda_i)^k$ tendono a zero se e solo se $|1 - \gamma\lambda_i| < 1$, cioè $0 < \gamma\lambda_i < 2$. Gli autovalori di una matrice di covarianza invertibile sono positivi (è definita non negativa, Capitolo 16), quindi la condizione vale per tutti gli autovalori se e solo se vale per il più grande: $0 < \gamma < \frac{2}{\lambda_{\text{MAX}}}$.

■

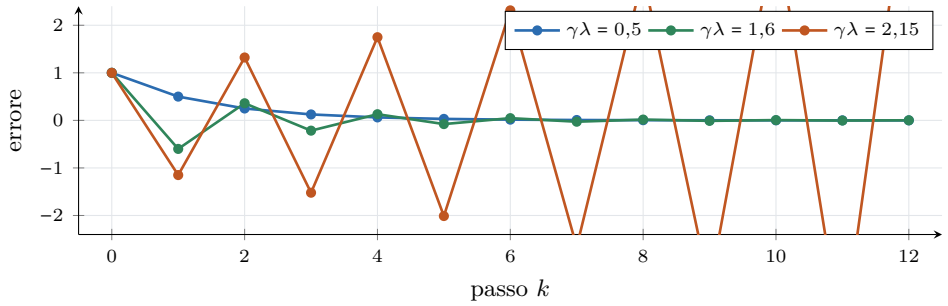
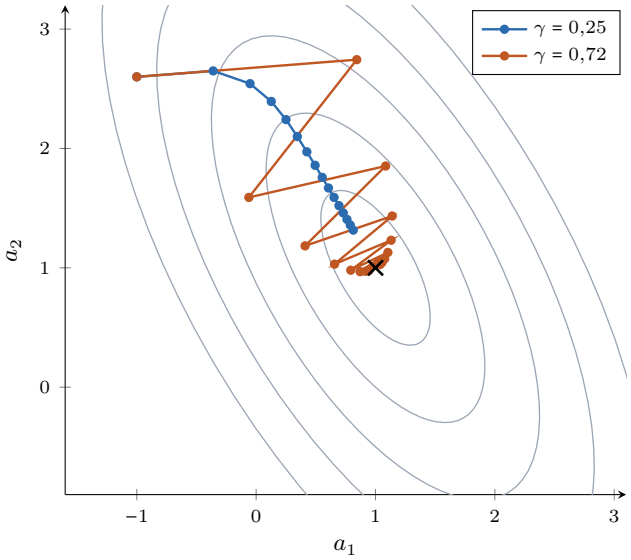


Figura 23.1: *Il caso scalare: a ogni passo l'errore viene moltiplicato per* $1-\gamma\lambda$. *Con* $\gamma\lambda = 0{,}5$ *dimezza a ogni passo; con* $\gamma\lambda = 1{,}6$ *cambia segno e si riduce (il fattore è* $-0{,}6$*); con* $\gamma\lambda = 2{,}15$ *il fattore è* $-1{,}15$*, troppo grande in modulo, e l'algoritmo diverge.*

Esempio 23.2 — Due coefficienti

Con $\underline{\underline{M}} = \begin{bmatrix} 2 & 0{,}9 \\ 0{,}9 & 1 \end{bmatrix}$ e $\underline{s} = [2{,}9;\ 1{,}9]^T$ la soluzione è $\underline{a}_{\text{LMMSE}} = [1,1]^T$ (si verifica moltiplicando). Gli autovalori di $\underline{\underline{M}}$ sono $\lambda_{\text{MAX}} \approx 2{,}53$ e $\lambda_{\min} \approx 0{,}47$ (le radici di $\det(\underline{\underline{M}} - \lambda\underline{\underline{I}}) = (2-\lambda)(1-\lambda) - 0{,}81 = 0$), quindi l'algoritmo converge per $0 < \gamma < \frac{2}{2{,}53} \approx 0{,}79$. La figura mostra le curve di livello dell'errore quadratico medio, ellissi centrate nella soluzione con gli assi lungo gli autovettori, e i primi passi dell'algoritmo per due valori del passo.



Partendo da $[-1;\ 2{,}6]^T$, con il passo piccolo ($\gamma = 0{,}25$) l'algoritmo scende con prudenza, perpendicolare alle curve di livello, ma nella direzione dell'autovalore piccolo avanza lentamente (a ogni passo l'errore si riduce solo del 12%). Con il passo grande ($\gamma = 0{,}72$, vicino al limite 0,79) lungo l'autovalore grande il fattore è $1 - 0{,}72 \cdot 2{,}53 \approx -0{,}82$: l'algoritmo rimbalza da una parte all'altra della valle, a zig-zag, mentre nell'altra direzione arriva più in fretta.

Quando gli autovalori sono molto diversi fra loro, nessun passo va bene per tutte le direzioni: il passo deve essere piccolo per l'autovalore grande, e allora è lentissimo per quello piccolo. È il motivo per cui la convergenza del gradiente è lenta quando le ellissi sono molto schiacciate.

In sintesi

- Gradiente: $\nabla_{\underline{w}}(\underline{u}^T\underline{w}) = \underline{u}$; $\nabla_{\underline{w}}(\underline{w}^T\underline{\underline{A}}\underline{w}) = 2\underline{\underline{A}}\underline{w}$ per $\underline{\underline{A}}$ simmetrica.
- **Stimatore lineare MMSE**: $\hat{\Theta} = \underline{a}^T\underline{X} + b$ con $\underline{a} = \underline{\underline{M}}^{-1}\underline{s}$ e $b = E[\Theta] - \underline{a}^T E[\underline{X}]$, cioè $\hat{\Theta} = E[\Theta] + \underline{s}^T\underline{\underline{M}}^{-1}(\underline{X} - E[\underline{X}])$; servono solo medie e covarianze. Errore minimo $\sigma^2_\Theta - \underline{s}^T\underline{\underline{M}}^{-1}\underline{s}$. Per dati gaussiani coincide con lo stimatore MMSE.
- **Algoritmo del gradiente**: $\underline{a}^{(k+1)} = \underline{a}^{(k)} - \gamma(\underline{\underline{M}}\,\underline{a}^{(k)} - \underline{s})$; l'errore evolve come $(\underline{\underline{I}} - \gamma\underline{\underline{M}})^k$ e, con la decomposizione spettrale, si riduce lungo ogni autovettore del fattore $1 - \gamma\lambda_i$. Converge se e solo se $0 < \gamma < \frac{2}{\lambda_{\text{MAX}}}$.

Minimi quadrati e stima ricorsiva

Dimentichiamoci ora della probabilità. In questo capitolo i vettori contano per quello che sono, e non perché sono considerati realizzazioni di vettori aleatori: è il punto di vista della **statistica descrittiva**. Si hanno dei dati misurati e si cerca il modello lineare che li descrive meglio, nel senso dei **minimi quadrati**. È lo stesso problema dello stimatore lineare MMSE, con le medie sui dati al posto delle medie statistiche. Alla fine vedremo come aggiornare la stima quando arriva un dato nuovo, senza rifare tutti i conti da capo.

Il modello lineare e la stima ai minimi quadrati

Un **insieme di addestramento** (*training set*) è una collezione di p vettori n-dimensionali $\underline{x}(1), \dots, \underline{x}(p)$, che si possono organizzare come colonne di una matrice $n \times p$:

$$\underline{\underline{X}} = \begin{bmatrix} x_1(1) & x_1(2) & \cdots & x_1(p) \\ x_2(1) & x_2(2) & \cdots & x_2(p) \\ \vdots & \vdots & \ddots & \vdots \\ x_n(1) & x_n(2) & \cdots & x_n(p) \end{bmatrix} = \begin{bmatrix} \underline{x}(1) & \underline{x}(2) & \cdots & \underline{x}(p) \end{bmatrix} \in \mathbb{R}^{n \times p}.$$

Si conoscono anche p valori misurati del parametro θ, uno per ciascun vettore dell'insieme di addestramento: $\underline{y} = [\theta(1), \theta(2), \dots, \theta(p)]^T \in \mathbb{R}^p$. Per esempio, ogni $\underline{x}(i)$ può raccogliere n caratteristiche di una casa (superficie, numero di stanze, piano) e $\theta(i)$ il suo prezzo.

Si vuole adattare ai dati un **modello lineare**

$$\theta(i) = \underline{a}^T \underline{x}(i) + \epsilon_i, \qquad i = 1, \dots, p,$$

dove $\underline{a}$ è un vettore n-dimensionale di coefficienti da scegliere ed ϵ_i è l'errore del modello sul dato i. Si sceglie $\underline{a}$ in modo da minimizzare la somma dei quadrati degli errori,

$$\|\underline{\epsilon}\|^2 = \sum_{i=1}^{p} \left(\underline{a}^T \underline{x}(i) - \theta(i) \right)^2, \qquad \underline{\epsilon} = [\epsilon_1, \dots, \epsilon_p]^T,$$

dove $\|\underline{v}\|^2 = \underline{v}^T \underline{v} = \sum_i v_i^2$ è il quadrato della lunghezza del vettore (Capitolo 16).

La somma si scrive in modo compatto con la matrice dei dati. Il prodotto $\underline{\underline{X}}^T \underline{a}$ ($p \times n$ per $n \times 1$) è un vettore $p \times 1$: la riga i di $\underline{\underline{X}}^T$ è $\underline{x}(i)^T$, quindi il suo elemento i-esimo è $\underline{x}(i)^T \underline{a} = \underline{a}^T \underline{x}(i)$ (un numero è uguale al suo trasposto). Allora

$$\underline{\underline{X}}^T \underline{a} - \underline{y} = \begin{bmatrix} \underline{x}(1)^T \underline{a} - \theta(1) \\ \vdots \\ \underline{x}(p)^T \underline{a} - \theta(p) \end{bmatrix} \qquad \text{e} \qquad \sum_{i=1}^{p} \left(\underline{a}^T \underline{x}(i) - \theta(i) \right)^2 = \left\| \underline{\underline{X}}^T \underline{a} - \underline{y} \right\|^2.$$

Teorema 24.1 — La stima ai minimi quadrati

Se la matrice simmetrica $n \times n$ $\underline{\underline{X}}\,\underline{\underline{X}}^T$ è invertibile, il vettore che minimizza $\left\| \underline{\underline{X}}^T \underline{a} - \underline{y} \right\|^2$ è

$$\underline{a}_{\text{LS}} = \left(\underline{\underline{X}}\,\underline{\underline{X}}^T \right)^{-1} \underline{\underline{X}}\,\underline{y},$$

la **stima ai minimi quadrati** (LS, *Least Squares*). È la soluzione delle **equazioni normali** $\underline{\underline{X}}\,\underline{\underline{X}}^T \underline{a} = \underline{\underline{X}}\,\underline{y}$.

Dimostrazione

Passo 1 — Il quadrato di una differenza. Per due vettori $\left\| \underline{\alpha} - \underline{\beta} \right\|^2 = (\underline{\alpha} - \underline{\beta})^T (\underline{\alpha} - \underline{\beta}) = \left\| \underline{\alpha} \right\|^2 + \left\| \underline{\beta} \right\|^2 - 2\underline{\alpha}^T \underline{\beta}$, come $(a-b)^2 = a^2 + b^2 - 2ab$. Con $\underline{\alpha} = \underline{\underline{X}}^T \underline{a}$ e $\underline{\beta} = \underline{y}$, e il trasposto di un prodotto $(\underline{\underline{X}}^T \underline{a})^T = \underline{a}^T \underline{\underline{X}}$:

$$\left\| \underline{\underline{X}}^T \underline{a} - \underline{y} \right\|^2 = \underline{a}^T \underline{\underline{X}}\,\underline{\underline{X}}^T \underline{a} + \left\| \underline{y} \right\|^2 - 2\underline{a}^T \underline{\underline{X}}\,\underline{y}.$$

Passo 2 — Il gradiente. $\underline{\underline{X}}\,\underline{\underline{X}}^T$ è simmetrica (è uguale alla sua trasposta). Con le formule del Capitolo 23 (il secondo termine non dipende da $\underline{a}$):

$$\nabla_{\underline{a}} \left\| \underline{\underline{X}}^T \underline{a} - \underline{y} \right\|^2 = 2\underline{\underline{X}}\,\underline{\underline{X}}^T \underline{a} - 2\underline{\underline{X}}\,\underline{y} = \underline{0} \quad \Longrightarrow \quad \underline{a} = \left(\underline{\underline{X}}\,\underline{\underline{X}}^T \right)^{-1} \underline{\underline{X}}\,\underline{y}.$$

Passo 3 — È un minimo. La somma dei quadrati è una funzione di secondo grado a forma di scodella: $\underline{q}^T \underline{\underline{X}}\,\underline{\underline{X}}^T \underline{q} = \left\| \underline{\underline{X}}^T \underline{q} \right\|^2 \geq 0$ per ogni $\underline{q}$, quindi la matrice è definita non negativa (Capitolo 16), e l'unico punto a gradiente nullo è il fondo della scodella.

■

La formula richiede che la matrice $\underline{\underline{X}}\,\underline{\underline{X}}^T$ sia invertibile. In sostanza servono $p \geq n$ dati (almeno tante equazioni quante sono le incognite) e che le n colonne della matrice $\underline{\underline{X}}^T$, di dimensioni $p \times n$, siano **linearmente indipendenti**: nessuna caratteristica deve essere una combinazione lineare delle altre (se due caratteristiche dicessero la stessa cosa, per esempio la superficie in metri quadri e in centimetri quadri, non si saprebbe come dividere il peso fra loro).

Il legame con lo stimatore lineare MMSE

Dividendo per p, $\frac{1}{p}\underline{\underline{X}}\,\underline{\underline{X}}^T = \frac{1}{p}\sum_i \underline{x}(i)\underline{x}(i)^T$ e $\frac{1}{p}\underline{\underline{X}}\,\underline{y} = \frac{1}{p}\sum_i \theta(i)\,\underline{x}(i)$ sono le medie campione di $\underline{X}\,\underline{X}^T$ e di $\Theta\underline{X}$: per la legge dei grandi numeri tendono a $\underline{\underline{R}} = E[\underline{X}\,\underline{X}^T]$ e a $E[\Theta\underline{X}]$. La stima LS è la versione «con i dati» dello stimatore lineare MMSE del Capitolo 23 (senza la costante b; per averla basta aggiungere a ogni $\underline{x}(i)$ una componente sempre uguale a 1, come nell'esempio che segue).

Esempio 24.1 — La retta che passa più vicina a sei punti

Si cercano i coefficienti della retta $\theta = a_1 + a_2 t$ che approssima meglio sei punti misurati:

t_i	1	2	3	4	5	6
θ_i	2,1	3,9	6,2	7,8	10,1	12,0

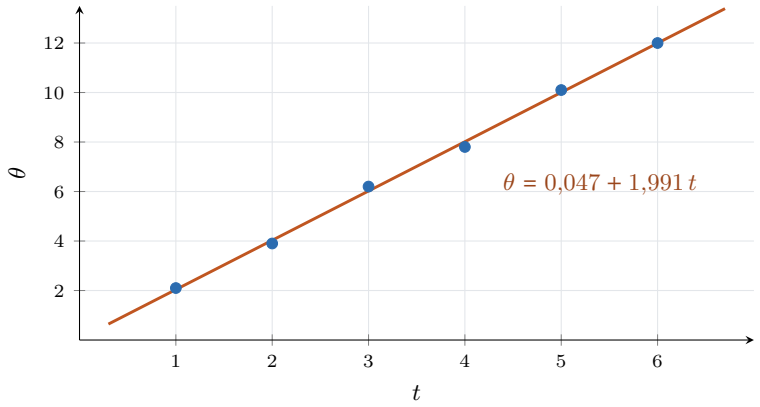
È il modello lineare con $\underline{x}(i) = [1, t_i]^T$ (la componente costante 1 moltiplica a_1). Quindi

$$\underline{\underline{X}}\,\underline{\underline{X}}^T = \sum_i \underline{x}(i)\underline{x}(i)^T = \begin{bmatrix} p & \sum t_i \\ \sum t_i & \sum t_i^2 \end{bmatrix} = \begin{bmatrix} 6 & 21 \\ 21 & 91 \end{bmatrix}, \qquad \underline{\underline{X}}\,\underline{y} = \begin{bmatrix} \sum \theta_i \\ \sum t_i \theta_i \end{bmatrix} = \begin{bmatrix} 42{,}1 \\ 182{,}2 \end{bmatrix}.$$

Con la formula dell'inversa 2×2 (determinante $6 \cdot 91 - 21^2 = 105$):

$$\underline{a}_{\mathrm{LS}} = \frac{1}{105}\begin{bmatrix} 91 & -21 \\ -21 & 6 \end{bmatrix}\begin{bmatrix} 42{,}1 \\ 182{,}2 \end{bmatrix} = \frac{1}{105}\begin{bmatrix} 3831{,}1 - 3826{,}2 \\ -884{,}1 + 1093{,}2 \end{bmatrix} = \begin{bmatrix} 0{,}047 \\ 1{,}991 \end{bmatrix}.$$

La retta è $\theta \approx 0{,}047 + 1{,}991\,t$. Gli errori ϵ_i sono i segmenti verticali della figura; la somma dei loro quadrati, 0,107, è la più piccola possibile fra tutte le rette.



(Gli errori sono così piccoli che nella figura i segmenti verdi si vedono appena: i punti sono quasi allineati.)

UN DATO IN PIÙ: LA STIMA RICORSIVA

Esplicitiamo che la stima è basata su p dati:

$$\underline{a}_{\mathrm{LS}}(p) = \left(\underline{\underline{X}}(p)\,\underline{\underline{X}}^T(p)\right)^{-1} \underline{\underline{X}}(p)\,\underline{y}(p).$$

Consideriamo questo scenario: si vuole migliorare progressivamente la stima aggiungendo nuove osservazioni, man mano che arrivano, e farlo con una complessità limitata. Supponiamo $p \geq n$ e di aver già calcolato $\underline{a}_{\mathrm{LS}}(p)$. Arrivano un nuovo vettore $\underline{x}(p+1)$ e una nuova osservazione $\theta(p+1)$; la nuova stima sarebbe

$$\underline{a}_{\mathrm{LS}}(p+1) = \left(\underline{\underline{X}}(p+1)\,\underline{\underline{X}}^T(p+1)\right)^{-1} \underline{\underline{X}}(p+1)\,\underline{y}(p+1).$$

Dobbiamo ricalcolare tutto da zero? No: la matrice da invertire cambia di poco, e la si può aggiornare.

Teorema 24.2 — Formula di Sherman-Morrison

Sia $\underline{\underline{R}}$ una matrice $n \times n$ invertibile e siano $\underline{u}$ e $\underline{v}$ vettori colonna n-dimensionali, con $1 + \underline{v}^T \underline{\underline{R}}^{-1} \underline{u} \neq 0$. Allora l'inversa della matrice con *aggiornamento di rango 1* $\underline{\underline{R}} + \underline{u}\,\underline{v}^T$ è

$$\left(\underline{\underline{R}} + \underline{u}\,\underline{v}^T\right)^{-1} = \underline{\underline{R}}^{-1} - \frac{\underline{\underline{R}}^{-1}\,\underline{u}\,\underline{v}^T\,\underline{\underline{R}}^{-1}}{1 + \underline{v}^T \underline{\underline{R}}^{-1} \underline{u}}.$$

Dimostrazione — basta moltiplicare

Passo 1 — Si moltiplica. Chiamiamo $c = \underline{v}^T \underline{\underline{R}}^{-1} \underline{u}$: è un numero ($1 \times n$ per $n \times n$ per $n \times 1$). Moltiplicando $\underline{\underline{R}} + \underline{u}\underline{v}^T$ per il secondo membro:

$$\left(\underline{\underline{R}} + \underline{u}\underline{v}^T\right)\left(\underline{\underline{R}}^{-1} - \frac{\underline{\underline{R}}^{-1}\underline{u}\underline{v}^T\underline{\underline{R}}^{-1}}{1+c}\right) = \underline{\underline{I}} + \underline{u}\underline{v}^T\underline{\underline{R}}^{-1} - \frac{\underline{u}\underline{v}^T\underline{\underline{R}}^{-1} + \underline{u}\left(\underline{v}^T\underline{\underline{R}}^{-1}\underline{u}\right)\underline{v}^T\underline{\underline{R}}^{-1}}{1+c}.$$

Passo 2 — Si raccoglie. Il numero c si può spostare dove si vuole: il numeratore della frazione è $(1+c)\,\underline{u}\underline{v}^T\underline{\underline{R}}^{-1}$, e la frazione vale $\underline{u}\underline{v}^T\underline{\underline{R}}^{-1}$. Resta $\underline{\underline{I}}$: il secondo membro è proprio l'inversa. ■

Le slide scrivono il denominatore come $1 + \underline{u}^T\underline{\underline{R}}^{-1}\underline{v}$; nel nostro uso $\underline{u} = \underline{v}$ e $\underline{\underline{R}}$ è simmetrica, quindi le due scritture coincidono.

Teorema 24.3 — La stima ai minimi quadrati ricorsiva

Siano $\underline{\underline{R}}(p) = \underline{\underline{X}}(p)\underline{\underline{X}}^T(p)$ e $K(p+1) = \underline{x}(p+1)^T\underline{\underline{R}}^{-1}(p)\,\underline{x}(p+1)$ (un numero). Allora

$$\underline{\underline{R}}^{-1}(p+1) = \underline{\underline{R}}^{-1}(p) - \frac{\underline{\underline{R}}^{-1}(p)\,\underline{x}(p+1)\,\underline{x}(p+1)^T\underline{\underline{R}}^{-1}(p)}{1+K(p+1)},$$

$$\underline{a}(p+1) = \left[\underline{\underline{I}}_n - \frac{\underline{\underline{R}}^{-1}(p)\,\underline{x}(p+1)\,\underline{x}(p+1)^T}{1+K(p+1)}\right]\left[\underline{a}(p) + \theta(p+1)\,\underline{\underline{R}}^{-1}(p)\,\underline{x}(p+1)\right].$$

Il calcolo comporta $O(n^2)$ operazioni, indipendentemente da p: la complessità non cresce con il numero di dati.

Dimostrazione

Passo 1 — La matrice come somma. Il prodotto $\underline{\underline{X}}(p)\underline{\underline{X}}^T(p)$, fatto «colonne per righe», è la somma dei prodotti colonna per riga dei singoli vettori:

$$\underline{\underline{X}}(p)\underline{\underline{X}}^T(p) = \big[\underline{x}(1) \cdots \underline{x}(p)\big]\begin{bmatrix}\underline{x}^T(1)\\ \vdots \\ \underline{x}^T(p)\end{bmatrix} = \sum_{i=1}^{p} \underline{x}(i)\,\underline{x}^T(i).$$

Passo 2 — Un dato in più è un aggiornamento di rango 1. Aggiungendo il termine $i = p+1$:

$$\underline{\underline{R}}(p+1) = \sum_{i=1}^{p+1} \underline{x}(i)\underline{x}^T(i) = \underline{\underline{R}}(p) + \underbrace{\underline{x}(p+1)}_{\underline{u}}\,\underbrace{\underline{x}^T(p+1)}_{\underline{v}^T},$$

e la formula di Sherman-Morrison dà l'inversa, con $\underline{u} = \underline{v} = \underline{x}(p+1)$.

Passo 3 — Il vettore dei termini noti. La matrice dei dati si allunga di una colonna e il vettore delle osservazioni di un elemento: $\underline{\underline{X}}(p+1) = [\underline{\underline{X}}(p)\ \ \underline{x}(p+1)]$ e $\underline{y}(p+1) = [\underline{y}^T(p),\, \theta(p+1)]^T$. Moltiplicando a blocchi, $\underline{\underline{X}}(p+1)\underline{y}(p+1) = \underline{\underline{X}}(p)\underline{y}(p) + \theta(p+1)\,\underline{x}(p+1)$.

Passo 4 — Si mette insieme. Scriviamo in breve $\underline{x}$ per $\underline{x}(p+1)$, θ per $\theta(p+1)$ e K per $K(p+1)$. Raccogliendo $\underline{\underline{R}}^{-1}(p)$ a destra nella formula dell'inversa (che si può fare perché $\underline{\underline{R}}^{-1}(p) = \underline{\underline{I}}_n\underline{\underline{R}}^{-1}(p)$, inserendo la matrice identità, che non cambia nulla):

$$\underline{a}(p+1) = \left[\underline{\underline{I}}_n - \frac{\underline{\underline{R}}^{-1}(p)\,\underline{x}\underline{x}^T}{1+K}\right]\underline{\underline{R}}^{-1}(p)\Big[\underline{\underline{X}}(p)\underline{y}(p) + \theta\,\underline{x}\Big],$$

e $\underline{\underline{R}}^{-1}(p)\underline{\underline{X}}(p)\underline{y}(p) = \underline{a}(p)$ è la stima precedente: si ottiene la formula dell'enunciato.

Passo 5 — Il costo. Servono solo prodotti matrice per vettore e colonna per riga di dimensione n: ciascuno costa circa n^2 moltiplicazioni, qualunque sia p. Rifare tutto da capo costerebbe invece circa $n^2 p$ operazioni per $\underline{\underline{X}}\,\underline{\underline{X}}^T$ più circa n^3 per l'inversione.

■

La stessa formula, letta come una correzione

Svolgendo il prodotto (con $\underline{x}$, θ, K in breve, $\underline{\underline{R}}^{-1} = \underline{\underline{R}}^{-1}(p)$, e ricordando che $\underline{x}^T\underline{\underline{R}}^{-1}\underline{x} = K$ e $\underline{x}^T\underline{a}(p)$ sono numeri):

$$\underline{a}(p) + \theta\underline{\underline{R}}^{-1}\underline{x} - \frac{\underline{\underline{R}}^{-1}\underline{x}\left(\underline{x}^T\underline{a}(p)\right) + \theta\underline{\underline{R}}^{-1}\underline{x}\,K}{1+K} = \underline{a}(p) + \underline{\underline{R}}^{-1}\underline{x}\left[\theta\left(1 - \frac{K}{1+K}\right) - \frac{\underline{x}^T\underline{a}(p)}{1+K}\right],$$

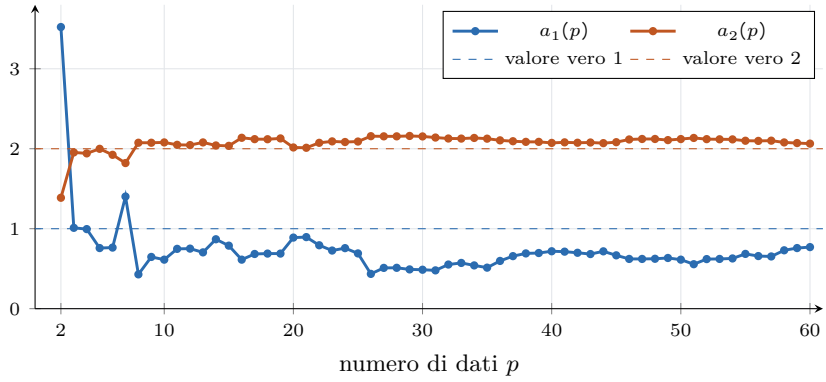
e siccome $1 - \frac{K}{1+K} = \frac{1}{1+K}$ la formula diventa

$$\underline{a}(p+1) = \underline{a}(p) + \frac{\underline{\underline{R}}^{-1}(p)\,\underline{x}(p+1)}{1+K(p+1)}\Big[\theta(p+1) - \underline{x}(p+1)^T\underline{a}(p)\Big].$$

Il termine fra parentesi quadre è l'errore che il vecchio modello commette sul dato nuovo (l'*innovazione*): se il modello aveva già previsto bene $\theta(p+1)$, la stima quasi non cambia; se aveva sbagliato, viene corretta in proporzione all'errore. È la stessa idea del filtro di Kalman.

Esempio 24.2 — La stima che migliora dato dopo dato

Si stimano i coefficienti della retta $\theta = a_1 + a_2 t$ da dati simulati con $a_1 = 1$, $a_2 = 2$ e un rumore gaussiano di deviazione standard 1, che arrivano uno alla volta. La prima stima si calcola con la formula diretta sui primi due dati (servono $p \geq n = 2$); poi si usa la formula ricorsiva.



Con due soli dati la stima è molto lontana dal vero ($a_1 \approx 3{,}5$, $a_2 \approx 1{,}4$), ma bastano pochi dati in più per avvicinarsi. Dopo 60 dati la stima ricorsiva coincide, fino all'ultima cifra, con quella calcolata da capo su tutti i dati.

In sintesi

- Statistica descrittiva: insieme di addestramento $\underline{\underline{X}} = [\underline{x}(1) \cdots \underline{x}(p)]$ e osservazioni $\underline{y}$; modello lineare $\theta(i) = \underline{a}^T \underline{x}(i) + \epsilon_i$.
- **Minimi quadrati**: si minimizza $\left\| \underline{\underline{X}}^T \underline{a} - \underline{y} \right\|^2$; $\underline{a}_{\text{LS}} = (\underline{\underline{X}}\,\underline{\underline{X}}^T)^{-1} \underline{\underline{X}}\,\underline{y}$, se $p \geq n$ e le caratteristiche sono linearmente indipendenti. È lo stimatore lineare MMSE con le medie campione.
- **Sherman-Morrison**: $(\underline{\underline{R}} + \underline{u}\,\underline{v}^T)^{-1} = \underline{\underline{R}}^{-1} - \frac{\underline{\underline{R}}^{-1}\underline{u}\,\underline{v}^T\underline{\underline{R}}^{-1}}{1+\underline{v}^T\underline{\underline{R}}^{-1}\underline{u}}$.
- **Stima ricorsiva**: $\underline{\underline{R}}(p+1) = \underline{\underline{R}}(p) + \underline{x}(p+1)\underline{x}^T(p+1)$; l'aggiornamento di $\underline{\underline{R}}^{-1}$ e di $\underline{a}$ costa $O(n^2)$ operazioni, indipendentemente da p.

Informazione ed entropia

Che cos'è l'informazione? Come la si misura? Sono domande che sembrano filosofiche, ma nel 1948 Claude Shannon diede loro una risposta precisa, con un numero: l'**entropia**. È il numero che dice di quanti bit c'è davvero bisogno per trasmettere o memorizzare i dati prodotti da una sorgente, e quindi quanto si possono comprimere un file, una foto, una canzone. In questo capitolo definiamo l'informazione di un evento e l'entropia di una variabile aleatoria, e dimostriamo, con la disuguaglianza di Jensen, quanto può valere al massimo. Il capitolo successivo userà l'entropia per progettare i codici.

Un esempio: comprimere una sorgente quaternaria

Una sorgente emette ogni secondo un simbolo quaternario, schematizzato da una variabile $X \in \mathcal{X} = \{0, 1, 2, 3\}$; indichiamo con $X(n)$ l'n-esima emissione. Contando quante volte compare ciascuna cifra, la frequenza di occorrenza tende alla probabilità (Capitolo 18). Sia allora $p_{X(n)}(x) = p_X(x)$ la pmf della generica emissione, e supponiamo

$$p_X(0) = \frac{1}{2}, \qquad p_X(1) = \frac{1}{4}, \qquad p_X(2) = \frac{1}{8}, \qquad p_X(3) = \frac{1}{8}.$$

Ogni simbolo quaternario si può rappresentare con una coppia di bit: indipendentemente dal simbolo emesso, si ha un codice di lunghezza 2 bit/simbolo. Cambiamo però approccio: usiamo un codice a **lunghezza variabile**, con parole più corte per i simboli più frequenti, come quello della terza colonna.

x	$p_X(x)$	codice a lunghezza fissa	codice a lunghezza variabile
0	1/2	`00`	`0`
1	1/4	`01`	`10`
2	1/8	`10`	`110`
3	1/8	`11`	`111`

Supponiamo che la sorgente emetta una lunga stringa di N simboli. Con il codice a lunghezza fissa si usano 2 bit/simbolo. Con quello a lunghezza variabile, indicando con $f_N(i)$ la frequenza con cui il simbolo i compare nella stringa, il numero medio di bit per simbolo è

$$L_N = 1 \cdot f_N(0) + 2 \cdot f_N(1) + 3 \cdot f_N(2) + 3 \cdot f_N(3).$$

Al crescere di N le frequenze tendono alle probabilità, e L_N tende alla **lunghezza media del codice**

$$L = 1 \cdot \frac{1}{2} + 2 \cdot \frac{1}{4} + 3 \cdot \frac{1}{8} + 3 \cdot \frac{1}{8} = \frac{1}{2} + \frac{1}{2} + \frac{3}{8} + \frac{3}{8} = 1 + \frac{3}{4} = \frac{7}{4} = 1{,}75 \text{ bit/simbolo}.$$

Il codice a lunghezza variabile ha anche un'altra caratteristica importante: è **univocamente decifrabile**. Per esempio la sequenza 0, 1, 0, 2, 3, 0 diventa `0 10 0 110 111 0`, cioè la stringa `01001101110`, e chi la riceve la può spezzare in un solo modo, leggendo da sinistra: nessuna parola del codice è l'inizio di un'altra (lo vedremo nel Capitolo 26). Si riesce a usare solo 1,75 bit/simbolo perché la sorgente emette *meno informazione* di quella che corrisponde a 2 bit/simbolo. Ma come si misura questa informazione?

L'INFORMAZIONE DI UN EVENTO

Siano $(A_1, A_2, \ldots, A_N)$ gli eventi di interesse, cioè N sottoinsiemi di uno spazio campione Ω, e si consideri lo spazio di probabilità $(\Omega, \mathcal{T}, P)$, con la σ-algebra $\mathcal{T}$ costruita a partire dagli eventi di interesse. Sia $A \in \mathcal{T}$ un evento del cui verificarsi siamo informati: vogliamo definire $i(A)$, la quantità di informazione che riceviamo sapendo che A si è verificato. Ipotesi sensate sono:

1. $i(A) \geq 0$: l'informazione deve essere una quantità non negativa (l'informazione non può nuocere);
2. l'informazione relativa al verificarsi di eventi rari deve avere maggior valore: $i(A)$ deve essere una funzione **decrescente** di $P(A)$ (la notizia «oggi a Napoli è sorto il sole» non informa nessuno, «oggi a Napoli nevica» sì);
3. **indipendenza**: se A e B sono eventi indipendenti, $i(A \cap B) = i(A) + i(B)$ (sapere che sono successe due cose che non hanno niente a che fare l'una con l'altra informa quanto le due notizie separate).

Informazione di un evento

La **quantità di informazione** associata al verificarsi dell'evento A è

$$i(A) \triangleq \log \frac{1}{P(A)}.$$

Perché proprio il logaritmo? Se l'informazione dipende solo dalla probabilità, $i(A) = g(P(A))$, per due eventi indipendenti $P(A \cap B) = P(A)\,P(B)$, e la terza richiesta diventa $g(xy) = g(x) + g(y)$: serve una funzione che trasformi i prodotti in somme, ed è proprio la proprietà del logaritmo, $\log(xy) = \log x + \log y$. Si può dimostrare che le funzioni continue con questa proprietà sono solo i multipli del logaritmo; per la seconda richiesta il multiplo deve essere negativo, e $-\log x = \log \frac{1}{x}$. La base del logaritmo è una scelta di unità di misura.

Teorema 25.1 — Proprietà dell'informazione

La funzione $i(A) = \log \frac{1}{P(A)}$ soddisfa le tre richieste. Inoltre l'evento certo non dà informazione: $i(\Omega) = \log 1 = 0$.

Dimostrazione

Passo 1 — Non è negativa. $P(A) \leq 1$, quindi $\frac{1}{P(A)} \geq 1$ e il suo logaritmo non è negativo.

Passo 2 — È decrescente. Se $P(A)$ diminuisce, $\frac{1}{P(A)}$ aumenta, e il logaritmo è una funzione crescente.

Passo 3 — È additiva. Per eventi indipendenti $i(A \cap B) = \log \frac{1}{P(A)P(B)} = \log \frac{1}{P(A)} + \log \frac{1}{P(B)} = i(A) + i(B)$. ■

Con il logaritmo in base 2 l'informazione si misura in **bit**: sapere l'esito del lancio di una moneta onesta dà $\log_2 2 = 1$ bit, la faccia di un dado $\log_2 6 \approx 2{,}58$ bit, una carta estratta da un mazzo di 52 carte $\log_2 52 \approx 5{,}7$ bit, e sapere che sono usciti dieci «testa» di fila $\log_2 2^{10} = 10$ bit (uno per lancio, per l'indipendenza).

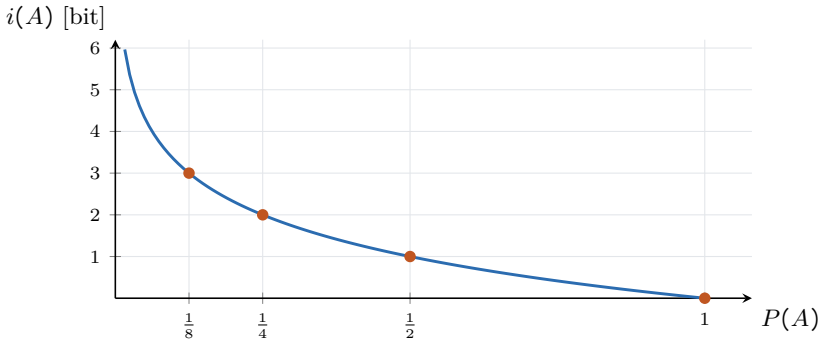


Figura 25.1: *L'informazione $i(A) = \log_2 \frac{1}{P(A)}$: zero per l'evento certo, 1 bit per un evento di probabilità $\frac{1}{2}$, e sempre di più quanto più l'evento è raro. Dimezzare la probabilità aggiunge un bit.*

L'ENTROPIA

Si esegua ripetutamente un esperimento con esiti possibili $(A_1, A_2, \ldots, A_N)$, di probabilità $\{P(A_i)\}_{i=1}^N$. L'informazione che si riceve è una variabile aleatoria, che vale $i(A_k) = \log \frac{1}{P(A_k)}$ quando l'esito è A_k, cioè con probabilità $P(A_k)$. Il suo valore medio è

$$E[i(A)] = \sum_{k=1}^{N} i(A_k)\, P(A_k) = \sum_{k=1}^{N} P(A_k) \log \frac{1}{P(A_k)}.$$

La quantità $H(\mathcal{E}) = E[i(A)]$ si chiama **entropia** dell'esperimento aleatorio $\mathcal{E}$, i cui possibili risultati sono $(A_1, \ldots, A_N)$.

Entropia di una variabile aleatoria discreta

Sia X una variabile aleatoria con alfabeto $\mathcal{X} = \{x_1, x_2, \ldots, x_M\}$, con $|\mathcal{X}| = M$. L'informazione $i(X) = \log \frac{1}{p_X(X)}$ è una variabile aleatoria, e l'**entropia** di X è la sua media:

$$H(X) = E[i(X)] = \sum_{i=1}^{M} p_X(x_i) \log \frac{1}{p_X(x_i)}.$$

La definizione si applica anche al caso $M \to \infty$. La base del logaritmo determina l'unità di misura: l'entropia si misura in **bit** se la base è 2, in **nat** se la base è e.

Se un valore ha probabilità nulla, il suo termine $p \log \frac{1}{p}$ si conta come 0: infatti $p \log \frac{1}{p} \to 0$ per $p \to 0$ (il logaritmo cresce molto più lentamente di quanto p si rimpicciolisce). La quantità di informazione che si riceve osservando le determinazioni di una variabile aleatoria è pari alla quantità di **incertezza a priori** che si aveva sull'esito dell'esperimento: una variabile massimamente informativa è anche una variabile massimamente incerta. E senza incertezza a priori non esiste informazione: se si sapesse già che cosa uscirà, osservarlo non insegnerebbe nulla.

Esempio 25.1 — L'entropia della sorgente quaternaria

Per la sorgente della prima sezione, in bit:

$$H(X) = \frac{1}{2}\log_2 2 + \frac{1}{4}\log_2 4 + \frac{1}{8}\log_2 8 + \frac{1}{8}\log_2 8 = \frac{1}{2} + \frac{2}{4} + \frac{3}{8} + \frac{3}{8} = 1{,}75 \text{ bit}.$$

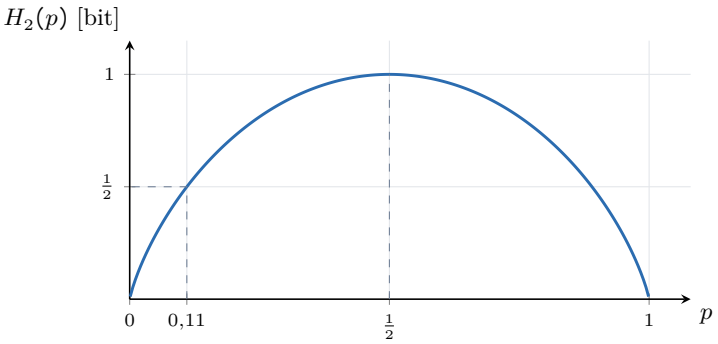
È esattamente la lunghezza media del codice a lunghezza variabile! Non è un caso: in quel codice ogni simbolo x ha una parola lunga proprio $\log_2 \frac{1}{p_X(x)}$ bit (1, 2, 3 e 3), cioè quanto la sua informazione. Nel prossimo capitolo vedremo che nessun codice univocamente decifrabile può fare meglio dell'entropia.

Esempio 25.2 — Il lancio di una moneta

Si consideri una moneta per cui croce (C) esce con probabilità $P(\{C\}) = p$ e testa (T) con probabilità $P(\{T\}) = 1 - p$. Da $\Omega = \{C, T\}$ si forma la σ-algebra $\mathcal{T} = \mathcal{P}(\Omega) = \{\varnothing, \{C\}, \{T\}, \Omega\}$. L'entropia dell'esperimento è

$$H(\mathcal{E}) = p \log \frac{1}{p} + (1-p) \log \frac{1}{1-p} = -p \log p - (1-p) \log(1-p) = H(p, 1-p) = H_2(p).$$

La stessa espressione vale per una sorgente binaria che emette 0 con probabilità p e 1 con probabilità $1 - p$, e in generale per ogni esperimento con esito binario: $H_2(p)$ si chiama **funzione entropia binaria**.



L'entropia è massima, 1 bit, quando la moneta è onesta ($p = \frac{1}{2}$): è il caso più incerto. Vale zero quando $p = 0$ o $p = 1$, perché l'esito è già noto. Una moneta molto truccata, con $p = 0{,}11$, produce solo mezzo bit per lancio: una lunga sequenza dei suoi lanci si può comprimere, in media, a metà.

La disuguaglianza di Jensen

L'entropia di una variabile aleatoria ha la forma generale $H(X) = E[i(X)] = E[g(X)]$, con $g(\alpha) = \log \frac{1}{p_X(\alpha)}$. Viene allora naturale chiedersi: esiste una relazione generale, anche solo una disuguaglianza, che leghi le quantità $E[g(X)]$ e $g(E[X])$? In generale no: c'è solo se $g(\cdot)$ ha la concavità sempre dello stesso verso su tutto l'intervallo $[x_{\text{MIN}}, x_{\text{MAX}}]$, dove x_{MIN} è il più piccolo valore di X e x_{MAX} il più grande.

Richiamo di matematica: funzioni convesse e concave

Una funzione g è **convessa** su un intervallo I se, presi due punti qualsiasi del suo grafico, il segmento che li unisce (la *corda*) sta sopra il grafico: è fatta «a coppa», come x^2 o e^x. È **concava** se la corda sta sotto il grafico (fatta «a cupola», come $\log x$ o $\sqrt{x}$), cioè se $-g$ è convessa. Per le funzioni con derivata seconda c'è un criterio semplice: g è convessa dove $g'' \geq 0$ (la pendenza cresce) e concava dove $g'' \leq 0$. Per esempio

$$\frac{\mathrm{d}^2}{\mathrm{d}y^2} \log y = \frac{\mathrm{d}}{\mathrm{d}y} \frac{1}{y} = -\frac{1}{y^2} < 0 \qquad \forall\, y > 0 :$$

il logaritmo è concavo. Una proprietà ci servirà: una funzione convessa sta sempre **sopra le sue rette tangenti**. Siccome la pendenza cresce, allontanandosi dal punto di tangenza μ la funzione sale (o scende meno) della tangente:

$$g(x) \geq g(\mu) + g'(\mu)\,(x - \mu) \qquad \text{per ogni } x \in I.$$

Per una funzione concava la disuguaglianza è rovesciata: sta sotto le sue tangenti.

Teorema 25.2 — Disuguaglianza di Jensen

Se $g(x)$ è convessa nell'intervallo $I \supseteq \mathcal{X}$ e $X \in \mathcal{X}$ è una variabile aleatoria arbitraria, allora

$$E[g(X)] \geq g\left(E[X]\right).$$

Simmetricamente, se g è concava nell'intervallo $I \supseteq \mathcal{X}$, allora $E[g(X)] \leq g\left(E[X]\right)$. L'uguaglianza vale solo se $g(\cdot)$ è lineare (sui valori assunti da X) o se X non è aleatoria (cioè è costante al variare di $\omega \in \Omega$). Se $g(x)$ non ha concavità costante in I non esiste una relazione generale.

Dimostrazione — con la retta tangente

Passo 1 — La tangente nella media. Sia $\mu = E[X]$: è una media di valori di I, quindi sta in I. Per la proprietà del richiamo, per ogni valore x che la variabile può assumere

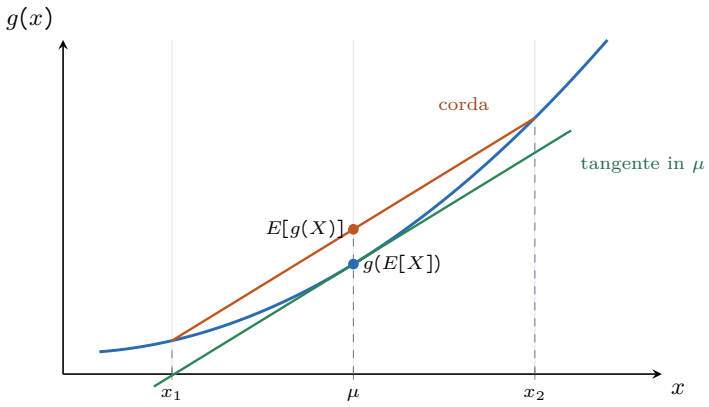
$$g(x) \geq g(\mu) + g'(\mu)\,(x - \mu).$$

Passo 2 — Si fa la media. La disuguaglianza vale per ogni valore di X, quindi anche fra le medie (la media di una quantità più grande è più grande). A destra $g(\mu)$ e $g'(\mu)$ sono numeri, e per la linearità

$$E[g(X)] \geq g(\mu) + g'(\mu)\,(E[X] - \mu) = g(\mu) + g'(\mu) \cdot 0 = g\left(E[X]\right).$$

Passo 3 — Il caso concavo. Se g è concava, $-g$ è convessa: applicando il risultato a $-g$ e cambiando segno si ottiene $E[g(X)] \leq g(E[X])$.

■



Una variabile che vale x_1 o x_2 con probabilità $\frac{1}{2}$ ha media μ nel punto di mezzo. $E[g(X)] = \frac{1}{2}g(x_1) + \frac{1}{2}g(x_2)$ è il punto di mezzo della corda, che per una funzione convessa sta sopra il grafico, cioè sopra $g(E[X])$. La tangente in μ (verde) sta tutta sotto la curva: è l'idea della dimostrazione.

Figura 25.2: *La disuguaglianza di Jensen per una funzione convessa.*

L'entropia non supera il logaritmo dell'alfabeto

Teorema 25.3 — L'entropia massima

Per ogni variabile aleatoria discreta X con alfabeto finito $\mathcal{X}$:

$$0 \leq H(X) \leq \log|\mathcal{X}|.$$

Fra tutte le pmf su $\mathcal{X}$, quella con la massima entropia è l'**uniforme**; l'entropia è nulla solo se X è in realtà una costante.

Dimostrazione — con la disuguaglianza di Jensen

Passo 1 — L'entropia come media di un logaritmo. Si scrive

$$H(X) = E\left[\log \frac{1}{p_X(X)}\right] = E[\log Y], \qquad \text{con} \qquad Y(\omega) = \frac{1}{p_X(X(\omega))},$$

una variabile aleatoria che assume valori positivi (consideriamo nell'alfabeto solo i valori con $p_X(x) > 0$, gli unici che contano).

Passo 2 — La media di Y. Ogni valore $\frac{1}{p_X(x)}$ è assunto con la probabilità $p_X(x)$, quindi

$$E[Y] = \sum_{x \in \mathcal{X}} \underbrace{\frac{1}{p_X(x)}}_{\text{valori assunti}} \cdot \underbrace{p_X(x)}_{\text{prob. dei valori}} = \sum_{x \in \mathcal{X}} 1 = |\mathcal{X}|\,.$$

Passo 3 — Jensen. Il logaritmo è concavo per $y > 0$ (richiamo), quindi $H(X) = E[\log Y] \le \log E[Y] = \log |\mathcal{X}|$.

Passo 4 — Il caso uniforme. Se $p_X(x) = \frac{1}{|\mathcal{X}|}$ per ogni x, tutti i termini sono uguali:

$$H(X) = \sum_{x \in \mathcal{X}} \frac{1}{|\mathcal{X}|} \log |\mathcal{X}| = \log |\mathcal{X}|\,,$$

e il limite superiore è raggiunto.

Passo 5 — Il limite inferiore. Ogni termine $p \log \frac{1}{p}$ è non negativo, perché $p \le 1$; la somma è nulla solo se tutti i termini lo sono, cioè se ogni probabilità vale 0 o 1: un solo valore certo.

■

Per la sorgente quaternaria $\log_2 4 = 2$ bit è il massimo, raggiunto con simboli equiprobabili: in quel caso il codice a lunghezza fissa di 2 bit sarebbe già il migliore possibile. La nostra sorgente ha entropia 1,75 < 2 bit, ed è proprio questa differenza che il codice a lunghezza variabile sfrutta.

In sintesi

- **Informazione** di un evento: $i(A) = \log \frac{1}{P(A)}$; non negativa, grande per eventi rari, additiva per eventi indipendenti. In base 2 si misura in bit.
- **Entropia**: $H(X) = E[i(X)] = \sum_x p_X(x) \log \frac{1}{p_X(x)}$, l'informazione media, cioè l'incertezza a priori. Entropia binaria $H_2(p) = -p \log p - (1-p) \log(1-p)$, massima (1 bit) per $p = \frac{1}{2}$.
- **Jensen**: $E[g(X)] \ge g(E[X])$ per g convessa, $\le$ per g concava (la funzione sta sopra o sotto le sue tangenti).
- $0 \le H(X) \le \log |\mathcal{X}|$, con il massimo per la pmf uniforme.
- La sorgente $(\frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \frac{1}{8})$ ha entropia 1,75 bit, quanto la lunghezza media del suo codice a lunghezza variabile.

La codifica di sorgente

Nel capitolo precedente abbiamo visto che una sorgente con entropia 1,75 bit si può codificare con 1,75 bit per simbolo invece di 2. In quest'ultimo capitolo trasformiamo l'osservazione in teoria: quali codici si possono decifrare senza ambiguità, quanto possono essere corti (mai meno dell'entropia) e come si costruisce il codice migliore, con l'algoritmo di Huffman, lo stesso che ancora oggi lavora dentro i formati ZIP, JPEG e MP3.

Sorgenti e codici

Una **sorgente di informazione** si schematizza come un blocco che in ogni istante n emette una lettera presa da un alfabeto $\mathcal{X}$, detto **alfabeto sorgente**. Una **sorgente discreta senza memoria** (DMS, *Discrete Memoryless Source*) emette una sequenza di lettere senza conservare memoria delle emissioni precedenti: la sua emissione è la stringa aleatoria

$$\dots, X_0, X_1, \dots, X_n, \dots$$

dove le X_i sono variabili aleatorie indipendenti con una pmf comune $p_X(x)$, $x \in \mathcal{X}$ (sorgente stazionaria). È un processo aleatorio indipendente e stazionario come quelli del Capitolo 17. La **codifica di sorgente** rappresenta le emissioni della sorgente con stringhe binarie quanto più brevi possibile.

Nell'esempio del Capitolo 25 c'erano due codici, uno a lunghezza fissa e uno a lunghezza variabile. Con un codice a lunghezza variabile chi riceve i bit non sa dove finisce ogni parola codice (*codeword*), e ci sono due possibilità:

1. si mette un segno di interpunzione fra due parole successive: è uno «spreco», che aumenta il numero medio di bit per lettera;
2. si impone che le concatenazioni di parole codice corrispondano in modo biunivoco alle concatenazioni di lettere dell'alfabeto sorgente.

Formalmente, un codice rappresenta ogni lettera con una stringa binaria di lunghezza $l(x)$:

$$C : x \in \mathcal{X} \longmapsto C(x) \in \{0,1\}^{l(x)},$$

e lo si estende alle sequenze concatenando: $C(x_1 x_2 \cdots x_n) = C(x_1)\, C(x_2) \cdots C(x_n)$.

Codice univocamente decifrabile

Un codice di sorgente si dice **univocamente decifrabile** se, per ogni n, una qualunque concatenazione di parole codice corrisponde a un'unica concatenazione di lettere: dalla stringa binaria $C(x_1)C(x_2)\cdots C(x_n)$ si ricava una e una sola sequenza $(x_1, x_2, \dots, x_n) = \left(C^{-1}[x_1], \dots, C^{-1}[x_n]\right)$.

Codice istantaneo

Un codice si dice **istantaneo** se ogni parola codice può essere decodificata appena si presenta nella stringa binaria, senza guardare i bit successivi. I codici istantanei sono quelli per cui nessuna parola codice è **prefisso** (cioè la parte iniziale) di un'altra parola codice: per questo si chiamano anche **codici a prefisso**.

Un codice a prefisso è univocamente decifrabile: leggendo da sinistra, appena i bit letti formano una parola codice, la si decodifica (non può essere l'inizio di una parola più lunga) e si ricomincia.

Esempio 26.1 — Tre codici a confronto

Si considerino tre codici per una sorgente con otto lettere:

x	$p_X(x)$	$C_1(x)$	$C_2(x)$	$C_3(x)$
1	1/4	000	0	10
2	3/32	001	1001	110
3	1/8	010	100	001
4	1/32	011	1111	1111
5	3/16	100	01	000
6	1/8	101	110	010
7	1/16	110	1100	1110
8	1/8	111	111	011

C_1 è univocamente decifrabile, perché è a lunghezza fissa: si taglia la stringa ogni 3 bit. La sua lunghezza media è $L_1 = E[l_1(X)] = 3$. C_2 e C_3 sono a lunghezza variabile, e le loro lunghezze medie sono

$$L_2 = E[l_2(X)] = 2{,}5 \text{ bit/simbolo}, \qquad L_3 = E[l_3(X)] = 2{,}84375 \text{ bit/simbolo}.$$

Entrambi sono più corti di C_1, ma solo C_3 è univocamente decifrabile. Con C_2, infatti, la stringa `1111000` si può leggere come `111|100|0`, cioè $(x_1, x_2, x_3) = (8, 3, 1)$, ma anche come `1111|0|0|0`, cioè $(x_1, x_2, x_3, x_4) = (4, 1, 1, 1)$: due messaggi diversi danno gli stessi bit. C_3 invece è un codice a prefisso: nessuna parola è l'inizio di un'altra. Vogliamo minimizzare la lunghezza media, ma preservando l'univoca decifrabilità. (L'entropia di questa sorgente è $H(X) \approx 2{,}80$ bit: C_2 scende sotto l'entropia, e vedremo che proprio per questo non può essere decifrabile.)

Un codice a prefisso si visualizza bene con un **albero binario**: si parte dalla radice, a ogni bit si scende a sinistra (0) o a destra (1), e le parole codice sono le **foglie**. La condizione del prefisso dice proprio che nessuna parola codice sta lungo il cammino che porta a un'altra.

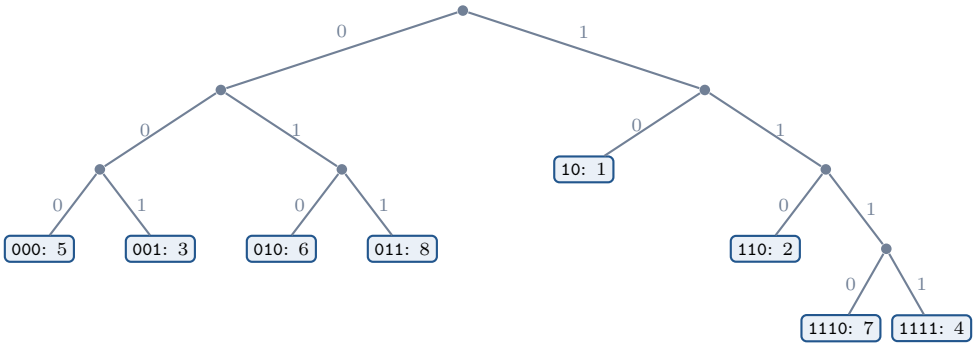


Figura 26.1: *L'albero del codice C_3: ogni parola codice è una foglia (con accanto la lettera che rappresenta), e il cammino dalla radice alla foglia ne dà i bit. Le foglie corte, vicine alla radice, sono per le lettere più frequenti.*

La disuguaglianza di Kraft

Le parole corte sono preziose, ma non se ne possono avere troppe: una parola di lunghezza 1 occupa da sola metà dell'albero. La disuguaglianza di Kraft dice esattamente quali insiemi di lunghezze sono possibili.

Teorema 26.1 — Disuguaglianza di Kraft

Un insieme di lunghezze $\{l(x)\}_{x\in\mathcal{X}}$ è compatibile con la condizione del prefisso (cioè esiste un codice a prefisso con quelle lunghezze) se e solo se

$$\sum_{x\in\mathcal{X}} 2^{-l(x)} \le 1.$$

Dimostrazione — contando le foglie dell'albero

Passo 1 — Le foglie in fondo. Sia $l_{\max}$ la lunghezza più grande. Un albero binario completo profondo $l_{\max}$ ha $2^{l_{\max}}$ nodi all'ultimo livello (a ogni livello raddoppiano). Una parola codice di lunghezza l ha sotto di sé $2^{l_{\max}-l}$ di quei nodi: quelli che si ottengono prolungandola con $l_{\max}-l$ bit qualsiasi.

Passo 2 — Se il codice è a prefisso. Due parole diverse non possono avere nodi in comune sotto di sé (altrimenti una sarebbe prefisso dell'altra), quindi in tutto occupano al più tutti i nodi dell'ultimo livello:

$$\sum_{x} 2^{l_{\max}-l(x)} \le 2^{l_{\max}} \quad\Longrightarrow\quad \sum_{x} 2^{-l(x)} \le 1,$$

dividendo per $2^{l_{\max}}$.

Passo 3 — Viceversa. Se le lunghezze soddisfano la disuguaglianza, si costruisce il codice assegnando le parole in ordine di lunghezza crescente: a ogni passo si prende il primo nodo libero alla profondità richiesta e si «toglie» tutto il sottoalbero sotto di esso. La parola di lunghezza l consuma la frazione 2^{-l} dei nodi dell'ultimo livello: finché la somma delle frazioni non supera 1, c'è sempre un nodo libero, e nessuna parola assegnata è prefisso di un'altra. ∎

Per il codice C_3 dell'esempio: $2^{-2}+5\cdot 2^{-3}+2\cdot 2^{-4} = \frac{1}{4}+\frac{5}{8}+\frac{1}{8} = 1$: l'albero è «pieno». Per C_2, invece, $2^{-1}+2^{-2}+3\cdot 2^{-3}+3\cdot 2^{-4} = 1{,}3125 > 1$: nessun codice a prefisso può avere quelle lunghezze. Si dimostra (teorema di McMillan) che la disuguaglianza di Kraft è necessaria anche per l'univoca decifrabilità: un codice univocamente decifrabile non può avere parole più corte di un codice a prefisso. Per questo d'ora in poi ci concentriamo solo sui codici a prefisso, che non perdono nulla e sono i più comodi da decodificare.

Il codice di Shannon e il limite entropico

Si abbia una sorgente con alfabeto M-ario, $X \in \{x_1, x_2, \dots, x_M\}$, e si supponga nota la legge con cui le lettere vengono emesse, $\{p_X(x_i) = \Pr\{X = x_i\}\}_{i=1}^{M}$. L'idea più naturale, suggerita dall'esempio del Capitolo 25, è dare a ogni lettera una parola lunga quanto la sua informazione. Siccome le lunghezze devono essere intere, si arrotonda per eccesso: $\lceil a \rceil$ indica la **parte intera superiore** di a, il più piccolo intero che non è minore di a (per esempio $\lceil 2{,}3 \rceil = 3$ e $\lceil 3 \rceil = 3$).

Codice di Shannon

Il **codice di Shannon** usa per la lettera x_i una stringa binaria di lunghezza

$$l(x_i) = \left\lceil \log_2 \frac{1}{p_X(x_i)} \right\rceil.$$

Teorema 26.2 — Il codice di Shannon esiste ed è quasi ottimo

Esiste un codice a prefisso con le lunghezze del codice di Shannon, e la sua lunghezza media L soddisfa

$$H(X) \le L < H(X) + 1.$$

Dimostrazione

Passo 1 — L'arrotondamento. Per definizione di parte intera superiore

$$\log_2 \frac{1}{p_X(x_i)} \le l(x_i) < \log_2 \frac{1}{p_X(x_i)} + 1.$$

Passo 2 — Kraft. Dalla prima disuguaglianza, $2^{-l(x_i)} \le 2^{-\log_2 \frac{1}{p_X(x_i)}} = p_X(x_i)$, quindi

$$\sum_{i=1}^{M} 2^{-l(x_i)} \le \sum_{i=1}^{M} p_X(x_i) = 1 :$$

per il teorema di Kraft esiste almeno un codice istantaneo con quelle lunghezze.

Passo 3 — La lunghezza media. Moltiplicando la doppia disuguaglianza del passo 1 per $p_X(x_i)$ e sommando su i:

$$\underbrace{\sum_{i=1}^{M} p_X(x_i) \log_2 \frac{1}{p_X(x_i)}}_{H(X)} \le \underbrace{\sum_{i=1}^{M} p_X(x_i)\, l(x_i)}_{L,\ \text{lunghezza media}} < \sum_{i=1}^{M} p_X(x_i) \log_2 \frac{1}{p_X(x_i)} + 1.$$

■

Il limite inferiore non è una peculiarità del codice di Shannon: vale per qualsiasi codice univocamente decifrabile.

Teorema 26.3 — Il limite entropico

La lunghezza media di qualsiasi codice che soddisfa la disuguaglianza di Kraft (in particolare, di qualsiasi codice a prefisso) è maggiore o uguale all'entropia della sorgente:

$$L = \sum_x p_X(x)\, l(x) \ge H(X),$$

con l'uguaglianza se e solo se $p_X(x) = 2^{-l(x)}$ per ogni x.

Dimostrazione — con la disuguaglianza di Jensen

Passo 1 — La differenza come media di un logaritmo. Scrivendo $l(x) = \log_2 2^{l(x)}$:

$$H(X) - L = \sum_x p_X(x) \left[\log_2 \frac{1}{p_X(x)} - \log_2 2^{l(x)} \right] = \sum_x p_X(x) \log_2 \frac{2^{-l(x)}}{p_X(x)} = E\left[\log_2 \frac{2^{-l(X)}}{p_X(X)} \right].$$

Passo 2 — Jensen. Il logaritmo è concavo, quindi la media del logaritmo non supera il logaritmo della media (Capitolo 25):

$$H(X) - L \le \log_2 E\left[\frac{2^{-l(X)}}{p_X(X)} \right] = \log_2 \sum_x p_X(x) \frac{2^{-l(x)}}{p_X(x)} = \log_2 \sum_x 2^{-l(x)} \le \log_2 1 = 0,$$

dove l'ultima disuguaglianza è quella di Kraft.

Passo 3 — L'uguaglianza. Servono uguaglianze in entrambi i passaggi: in Jensen la quantità $\frac{2^{-l(x)}}{p_X(x)}$ deve essere costante, e in Kraft la somma deve valere 1; insieme danno $p_X(x) = 2^{-l(x)}$.

■

Dalla relazione $L \ge H(X)$ risulta evidente che l'entropia di una sorgente dà una misura della sua **comprimibilità**: nessun codice univocamente decifrabile la può comprimere sotto $H(X)$ bit per simbolo in media, e il codice di Shannon ci arriva a meno di un bit. Il limite si raggiunge esattamente quando tutte le probabilità sono potenze di $\frac{1}{2}$ (probabilità **diadiche**), come per la sorgente quaternaria del Capitolo 25.

I codici di Huffman

Il codice di Shannon può sprecare quasi un bit per simbolo. Il codice migliore, quello con la minima lunghezza media fra tutti i codici a prefisso, si costruisce con un algoritmo molto semplice, dovuto a David Huffman (che lo inventò nel 1952 come esercizio per un corso universitario).

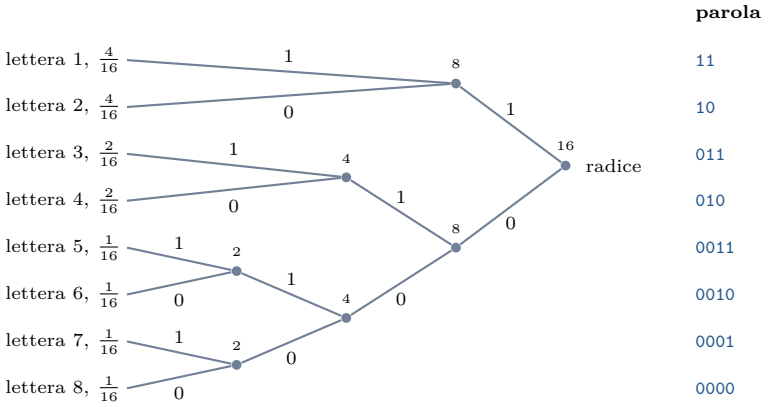
Algoritmo di Huffman

1. Si dispongono verticalmente i simboli in ordine di probabilità decrescente.
2. Si raggruppano i due simboli meno probabili in un «macrosimbolo», a cui si assegna la somma delle probabilità dei due simboli che lo compongono: questo riduce di un'unità la cardinalità dell'alfabeto.
3. Si ripete il passo precedente fino ad arrivare alla **radice** dell'albero, cioè a un unico macrosimbolo con probabilità pari a 1.
4. Si assegnano 1 e 0 ai rami ascendenti e discendenti dell'albero. La parola codice di ogni nodo terminale è la sequenza dei bit che si incontrano per arrivare dalla radice al nodo su cui essa è posta.

L'idea è che i due simboli meno probabili devono avere le parole più lunghe, e conviene che siano «fratelli» nell'albero, cioè che differiscano solo nell'ultimo bit: unendoli in un macrosimbolo si riduce il problema a un alfabeto con una lettera in meno, e si ripete.

Esempio 26.2 — Una sorgente diadica

Alfabeto $\mathcal{X} = \{1, 2, \ldots, 8\}$ con $p_1(x) = \left(\frac{1}{4}, \frac{1}{4}, \frac{1}{8}, \frac{1}{8}, \frac{1}{16}, \frac{1}{16}, \frac{1}{16}, \frac{1}{16}\right)$. Si uniscono prima le coppie di lettere da $\frac{1}{16}$, poi le coppie da $\frac{1}{8}$ (lettere o macrosimboli), poi quelle da $\frac{1}{4}$, e infine le due metà. Nel disegno le probabilità sono scritte in sedicesimi.



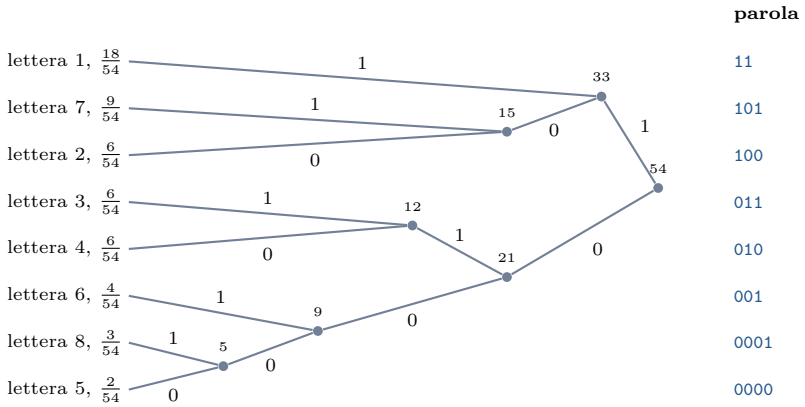
Le lunghezze sono $2, 2, 3, 3, 4, 4, 4, 4$, proprio uguali a $\log_2 \frac{1}{p_1(x)}$, e

$$L_1 = 2 \cdot \frac{1}{4} \cdot 2 + 3 \cdot \frac{1}{8} \cdot 2 + 4 \cdot \frac{1}{16} \cdot 4 = 1 + 0{,}75 + 1 = 2{,}75 \text{ bit/simbolo} = H_1(X).$$

La sorgente è diadica e il codice raggiunge l'entropia. (Nella slide 150 le parole di questo codice sono scritte con i bit in ordine inverso, dalla foglia alla radice: lette così, `00` sarebbe prefisso di `001`; rovesciandole si ottiene un codice a prefisso equivalente a questo.)

Esempio 26.3 — Una sorgente non diadica

Stesso alfabeto, con $p_2(x) = \left(\frac{1}{3}, \frac{1}{9}, \frac{1}{9}, \frac{1}{9}, \frac{1}{27}, \frac{2}{27}, \frac{1}{6}, \frac{1}{18}\right)$. In cinquantaquattresimi le probabilità sono $18, 6, 6, 6, 2, 4, 9, 3$. Ordinate in modo decrescente: lettera 1 (18), lettera 7 (9), lettere 2, 3, 4 (6 ciascuna), lettera 6 (4), lettera 8 (3), lettera 5 (2). Le unioni successive sono: $5 + 8$ ($2 + 3 = 5$); poi questo con la 6 ($5 + 4 = 9$); poi $3 + 4$ ($6 + 6 = 12$); poi $2 + 7$ ($6 + 9 = 15$; in caso di parità si può scegliere); poi i due macrosimboli da 9 e 12 (21); poi la lettera 1 con il macrosimbolo da 15 (33); infine $33 + 21 = 54$.



Le lunghezze sono 2 per la lettera 1, 3 per le lettere 2, 3, 4, 6 e 7, e 4 per le lettere 5 e 8:

$$L_2 = \frac{2 \cdot 18 + 3 \cdot (6 + 6 + 6 + 4 + 9) + 4 \cdot (2 + 3)}{54} = \frac{36 + 93 + 20}{54} = \frac{149}{54} \approx 2{,}759 \text{ bit/simbolo},$$

contro un'entropia $H_2(X) \approx 2{,}7017$ bit: il codice non raggiunge l'entropia, perché le probabilità non sono potenze di $\frac{1}{2}$. Il codice di Shannon, con lunghezze $\lceil \log_2 \frac{1}{p_2(x)} \rceil = 2, 4, 4, 4, 5, 4, 3, 5$, avrebbe $L \approx 3{,}26$: mezzo bit in più. (Nella tabella della slide 150 le parole delle lettere 5 e 7 risultano scambiate rispetto alle probabilità: alla lettera 7, che ha probabilità $\frac{1}{6}$, spetta una parola di 3 bit, alla lettera 5, con probabilità $\frac{1}{27}$, una di 4.)

Le slide concludono con alcune osservazioni.

- Il codice di Huffman **non è unico**: in caso di parità si possono unire i simboli meno probabili in modi diversi, e si possono scambiare gli 0 con gli 1. Tutti i codici ottenuti hanno però la stessa lunghezza media.
- In entrambi gli esempi le due lettere meno probabili **differiscono solo nell'ultimo bit**: è una caratteristica di tutti i codici di Huffman, perché sono state unite per prime.
- Entrambi i codici sono **ottimi**: raggiungono la minima lunghezza media possibile fra i codici a prefisso. Tuttavia solo il primo raggiunge una lunghezza media pari all'entropia della sorgente.
- Se il limite entropico è raggiungibile, allora lo si raggiunge con un codice di Huffman; se, viceversa, il codice di Huffman non raggiunge il limite entropico, il limite non è ottenibile. Il limite entropico è raggiungibile se e solo se $p_X(x) = 2^{-l(x)}$ per ogni $x \in \mathcal{X}$ (Teorema 26.3).

Avvicinarsi all'entropia codificando a blocchi

Anche quando le probabilità non sono diadiche si può arrivare vicino quanto si vuole all'entropia: invece di codificare una lettera alla volta, si codificano blocchi di k lettere, trattandoli come lettere di un alfabeto più grande. Per una sorgente senza memoria l'entropia di un blocco è $k\,H(X)$, e il codice di Shannon per i blocchi ha lunghezza media minore di $k\,H(X) + 1$: per lettera, meno di $H(X) + \frac{1}{k}$. Lo spreco di un bit si divide fra le k lettere del blocco.

In sintesi

- Una **sorgente discreta senza memoria** emette lettere i.i.d.; la **codifica di sorgente** le rappresenta con stringhe binarie il più corte possibile.
- Un codice è **univocamente decifrabile** se ogni stringa si legge in un solo modo; è **a prefisso** (istantaneo) se nessuna parola è l'inizio di un'altra. Un codice a prefisso è un albero binario con le parole sulle foglie.
- **Kraft**: esiste un codice a prefisso con lunghezze $l(x)$ se e solo se $\sum_x 2^{-l(x)} \leq 1$.
- **Limite entropico**: $L \geq H(X)$ per ogni codice univocamente decifrabile, con l'uguaglianza solo se $p_X(x) = 2^{-l(x)}$. Il **codice di Shannon**, $l = \lceil \log_2 \frac{1}{p} \rceil$, ha $H \leq L < H + 1$.
- **Huffman**: si uniscono ripetutamente i due simboli meno probabili; il codice è ottimo fra i codici a prefisso.