

Università degli Studi di Napoli
Federico II

A.A. 2026-2027

Metodi Statistici per l'Informazione

Indice

0 Prefazione 6

Organizzazione del corso 7
Come è fatta questa dispensa 7
I simboli che incontreremo 7
Convenzioni tipografiche 8

I Probabilità e variabili aleatorie discrete 1

1 Esperimenti, eventi e insiemi 11

Esperimenti aleatori e spazio campione 11
Spazi discreti e spazi continui 12
Eventi 12
Quattro esperimenti da tenere a mente 13
Il lancio di una moneta 13
Il lancio di un dado 14
I pacchetti in coda a un router 14
Operazioni fra eventi 15
Le leggi dell'algebra degli eventi 16
Le leggi di De Morgan 16
Le proprietà associativa e distributiva 17
Un po' di nomenclatura 19

2 Contare: il calcolo combinatorio 21

Quando tutti i risultati si equivalgono 21
Due lanci consecutivi 22
La regola generale 22
Il principio fondamentale: moltiplicare le scelte 23
Disposizioni: quando l'ordine conta 25
Disposizioni semplici 25
Disposizioni con ripetizione 26
Permutazioni 26
Combinazioni: quando l'ordine non conta 27
Un problema con le carte 30
L'insieme delle parti e il binomio di Newton 31
Prove ripetute e conteggio dei successi 32
Riepilogo delle formule 33

3 Dalla frequenza alla probabilità 34

La probabilità come limite della frequenza 34
Spazi finiti con eventi equiprobabili 35
Un esempio completo: i punteggi del poker 36
Coppia d'assi e coppia qualsiasi 36
Almeno tre assi, tris, colore 37
Quando i risultati non sono equiprobabili 38
Le proprietà della probabilità 39

Probabilità condizionata 41
La legge della probabilità composta 42
La legge della probabilità totale 43
Eventi indipendenti 44

4 L'APPROCCIO ASSIOMATICO 47
Algebre di eventi 47
Le proprietà delle algebre 48
Gli assiomi di Kolmogorov 49
Le proprietà che seguono dagli assiomi 51
Probabilità condizionata e teorema di Bayes 53
Il teorema di Bayes 54
Perché una probabilità sta fra 0 e 1 55

5 VARIABILI ALEATORIE DISCRETE 57
Dai risultati ai numeri 57
La funzione di probabilità 58
Un'avvertenza sulle notazioni 59
La media 60
La media campionaria 60
Dalla media campionaria alla media statistica 60
Il conteggio bernoulliano: la variabile binomiale 61
La probabilità di una sequenza 61
La pmf binomiale 62
La media della binomiale 63
La variabile uniforme 64
La variabile di Poisson 65
Da dove viene la formula di Poisson 67

6 PMF CONDIZIONATE E FUNZIONI DI VARIABILI ALEATORIE 69
La pmf condizionata a un evento 69
La probabilità totale per le pmf 70
Le medie condizionate 72
Funzioni di variabili aleatorie 73
La media di una funzione di variabile aleatoria 74
Un esempio completo 75
Il quadrato 75
Il seno 75

7 VARIANZA E DISUGUAGLIANZE 77
Misurare la dispersione 77
Valore quadratico medio e varianza 77
La varianza della binomiale 79
La variabile di Bernoulli 79
Il caso generale 79
La varianza dell'uniforme 82
La varianza della Poisson 83
Le proprietà della media e della varianza 84
La disuguaglianza di Markov 86
La disuguaglianza di Chebyshev 87
Il significato della varianza e della deviazione standard 87

8 VARIABILI ALEATORIE MULTIPLE 89
Coppie di variabili aleatorie 89
La pmf congiunta 90
Proprietà della pmf congiunta 90
Le pmf marginali 91
Variabili indipendenti 92
Le pmf condizionate 93
Più di due variabili: la regola della catena 94
Esempio: tre bit da una sorgente binaria 95
La legge p 96

La legge q 96

9 Funzioni di più variabili, covarianza e correlazione 98
Funzioni di una coppia di variabili 98
La media di una funzione di due variabili 99
Il teorema della media condizionata 101
Correlazione e covarianza 102
Il coefficiente di correlazione 104
La varianza di una combinazione lineare 105
Quale coppia è più correlata? 106

II Variabili aleatorie continue, vettori e processi aleatori 10

10 Variabili aleatorie continue: densità e distribuzione 108
Spazi campione continui 108
Perché un singolo valore ha probabilità zero 108
La frequenza di un intervallo 109
La densità di probabilità 110
Dalla densità alla probabilità: l'integrale 110
Le proprietà della densità 112
La funzione di distribuzione cumulativa 113
La CDF delle variabili discrete 115
La media di una variabile continua 116

11 Le variabili aleatorie continue notevoli 118
Due funzioni utili: il gradino e il rettangolo 118
La variabile uniforme 119
La variabile esponenziale 120
La variabile di Laplace 122
La variabile di Cauchy 123
La variabile di Cauchy non ha media 125

12 PDF condizionate e funzioni di variabili continue 128
PDF e CDF condizionate a un evento 128
La probabilità totale per le densità 129
Funzioni di variabili aleatorie continue 131
Primo caso: g è invertibile 131
Secondo caso: g non è invertibile 133
Due trasformazioni speciali 135
Terzo caso: la conversione A/D 137

13 Media di funzioni e varianza nel continuo 139
La media di una funzione di variabile continua 139
Valore quadratico medio e varianza 140
Le varianze delle variabili notevoli 141
La variabile uniforme 141
La variabile esponenziale 141
La variabile di Laplace 142
La variabile di Cauchy 142
Il dizionario fra discreto e continuo 143

14 Variabili aleatorie continue multiple 145
Coppie e m-ple di variabili continue 145
La densità congiunta 145
Marginali, indipendenza e densità condizionate 147
Le densità condizionate 148
Medie, media condizionata e covarianza 149
La funzione di distribuzione congiunta 151

15 La variabile gaussiana e la funzione Q 153

La gaussiana standard 153
La gaussiana generica 155
La funzione Q 156
Le proprietà della funzione Q 157
La regola delle tre sigma 158
Un'applicazione: bit sbagliati per colpa del rumore 159

16 Vettori aleatori e vettori gaussiani 160

Vettori e matrici: il minimo indispensabile 160
Vettori aleatori: medie, correlazioni e covarianze 162
La caratterizzazione sintetica 164
La matrice di covarianza è sempre definita non negativa 164
Vettori gaussiani 165
Si parte da n gaussiane indipendenti 165
La definizione generale 166
Il caso di due variabili 167
Incorrelazione e indipendenza 168
Marginali e condizionate: si completa il quadrato 168
Le proprietà dei vettori gaussiani 169
Trasformazioni lineari di vettori gaussiani 170

17 Processi aleatori 174

Richiami: la caratterizzazione completa 174
La regola della catena per i vettori aleatori 175
Processi aleatori a tempo discreto 176
Caratterizzazione completa e stazionarietà in senso stretto 177
Processi a valori discreti 178
Processi stazionari in senso lato 179
Il vettore dei campioni di un processo SSL 180
Quattro processi a confronto 181

Prefazione

Estratto

Il seguente documento rappresenta una raccolta di appunti, riorganizzata e migliorata nelle vesti grafiche, del corso di Metodi Statistici per l'Informazione del professor Mario Tanda, per il corso di laurea in Informatica A.A. 2026-2027, della Federico II di Napoli.

Il corso fornisce gli strumenti della teoria della probabilità e della statistica che servono a descrivere, elaborare e misurare l'informazione: dal calcolo combinatorio alle variabili aleatorie, discrete e continue, e ai processi aleatori; dall'inferenza statistica alla teoria della decisione e della stima; fino alla misura dell'informazione, con l'entropia e la compressione dei dati.

Si tiene a specificare che questo documento non ha lo scopo di **sostituire libri di testo**, note del professore o lezioni frontali, nonostante siano tutte fonti utilizzate per la stesura, ma quello di integrare al materiale più complesso una rilettura degli argomenti da un punto di vista meno tecnico e quindi più lento nel soffermarsi nei passaggi critici.

Si ringraziano **Valentino Bocchetti** e **Pasquale Miranda** ideatori e gestori del progetto *Unina Docs*,

Si ringraziano inoltre tutti i revisori che hanno contribuito al documento con consigli e proposte di modifica, invitando a dare feedback in caso di errori.

Si ringraziano in fine i lettori nella speranza che questo lavoro sia stato utile.

Redazione a cura di **Fabio Rosiello**

Organizzazione del corso

Il corso vale 6 CFU (48 ore di lezione), tutte in presenza: circa tre quarti di teoria e un quarto di esercitazioni. L'esame è una prova scritta integrata da una prova orale. Gli argomenti si dividono in tre blocchi:

- **Teoria della probabilità**: analisi combinatoria, probabilità su spazi finiti, variabili aleatorie discrete, variabili aleatorie continue, variabili aleatorie multiple, processi aleatori.
- **Statistica**: statistica inferenziale, teoria della decisione, inferenza bayesiana e non bayesiana, stima ricorsiva.
- **Informazione e sua misura** (cenni): entropia, compressione dei dati, mutua informazione, divergenza.

Il testo di riferimento, da affiancare alle lezioni, è Sheldon M. Ross, *Probabilità e statistica per l'ingegneria e le scienze*, Maggioli Editore, IV edizione.

Come è fatta questa dispensa

Questa dispensa segue le slide del corso, una lezione dopo l'altra: ogni parte corrisponde a un pacchetto di slide. La prima, *Probabilità e variabili aleatorie discrete*, copre il primo; la seconda, *Variabili aleatorie continue, vettori e processi aleatori*, copre il secondo, fino ai vettori gaussiani e ai processi stazionari. L'obiettivo è che ogni formula si possa **capire**, non solo ricordare: per questo ogni risultato è accompagnato dal suo perché, da un disegno quando aiuta, e da una dimostrazione scritta passo per passo quando la dimostrazione esiste. Gli strumenti di matematica che servono (insiemi, sommatorie, limiti, derivate, serie e, nella seconda parte, integrali, integrali doppi, derivate parziali, vettori e matrici) sono spiegati da zero, nel punto esatto in cui servono, dentro i riquadri viola dei **richiami di matematica**: chi li conosce già li può saltare, chi non li ricorda li trova lì, senza dover aprire un altro libro.

I simboli che incontreremo

La matematica usa molti simboli: sono abbreviazioni, e ognuno si legge con parole semplici. Queste due tabelle li raccolgono tutti, divisi fra le due parti; il capitolo indicato è quello in cui il simbolo viene spiegato con calma.

Simbolo	Si legge	Significato	Cap.
$x \in A$, $x \notin A$	x appartiene (non appartiene) ad A	x è (non è) un elemento dell'insieme A	1
$A \subseteq B$	A è contenuto in B	ogni elemento di A sta anche in B	1
$\varnothing$, $\lvert A\rvert$	insieme vuoto, cardinalità di A	l'insieme senza elementi; il numero di elementi di A	1
$A \cup B$, $A \cap B$	A unione B, A intersezione B	si verifica almeno uno dei due; si verificano entrambi	1
$\overline{A}$, $A \setminus B$	complementare di A, A meno B	non si verifica A; si verifica A ma non B	1
$A \times B$	A per B (prodotto cartesiano)	l'insieme delle coppie ordinate (a, b)	1
$\sum_{i=1}^{n}$, $\prod_{i=1}^{n}$	sommatoria, produttoria per i da 1 a n	somma, prodotto di n termini	2
$n!$, $\binom{n}{k}$	n fattoriale, n su k	$1 \cdot 2 \cdots n$; i sottoinsiemi di k elementi fra n	2
$\simeq$	circa uguale	i due numeri sono vicini	2
$a_n \to L$, $\lim_{n\to\infty}$	a_n tende a L, limite per n che tende a infinito	i termini si avvicinano a L quanto si vuole	3
$P(A)$, $P(A \mid B)$	probabilità di A, di A dato B	quanto è facile che si verifichi A (sapendo che si è verificato B)	3
$\Longrightarrow$, $\Longleftrightarrow$	implica, se e solo se	dalla prima affermazione segue la seconda; le due sono equivalenti	1
$\forall$	per ogni	la frase vale per tutti gli elementi indicati	4
$X \sim \ldots$	X si distribuisce come…	X ha la legge indicata a destra, per esempio $\mathcal{B}(N, p)$	5
$f'(x)$, $\mathrm{d}f/\mathrm{d}x$	derivata di f	la pendenza del grafico di f nel punto x	7

Tabella 1: *I simboli della prima parte.*

Simbolo	Si legge	Significato	Cap.
$\int_a^b f(x)\,\mathrm{d}x$	integrale di f da a a b	l'area sotto il grafico di f fra a e b	10
$f_X(x)$, $F_X(x)$	densità, CDF di X	probabilità per unità di lunghezza; $P(X \leq x)$	10
$u(x)$, $\mathrm{rect}(x)$	gradino, rettangolo	1 per $x \geq 0$ (0 altrove); 1 per $\lvert x\rvert < \frac{1}{2}$ (0 altrove)	11
$\iint_C f\,\mathrm{d}x\,\mathrm{d}y$	integrale doppio di f su C	il volume sotto la superficie f, sopra la regione C	14
$\partial F/\partial x$	derivata parziale rispetto a x	la derivata fatta tenendo fisse le altre variabili	14
$\mathcal{N}(\mu,\sigma^2)$, $Q(x)$	gaussiana, funzione Q	la campana di media μ e varianza σ^2; la sua coda $P(X_0 > x)$	15
$\underline{x}$, $\underline{\underline{A}}$	vettore x, matrice A	una colonna di numeri; una tabella di numeri	16
$\underline{\underline{A}}^T$, $\underline{\underline{A}}^{-1}$, $\det \underline{\underline{A}}$	trasposta, inversa, determinante	righe e colonne scambiate; la matrice che disfa $\underline{\underline{A}}$; il fattore per cui $\underline{\underline{A}}$ moltiplica le aree	16
$X(n)$	X di n	un processo aleatorio: un valore aleatorio per ogni istante n	17

Tabella 2: *I simboli della seconda parte.*

Convenzioni tipografiche

Nel testo si usano alcuni riquadri ricorrenti, ognuno con un colore e un compito precisi.

Definizione

I riquadri rossi contengono le **definizioni**: il significato esatto di una parola nuova. Sono da saper ripetere con precisione.

Teorema 0.1 — Teorema

I riquadri blu contengono i **teoremi**: affermazioni che si possono dimostrare a partire dalle definizioni. Sono numerati capitolo per capitolo (Teorema 3.2 è il secondo teorema del capitolo 3), così si possono citare.

Dimostrazione

Passo 1 — Che cosa contiene. Sotto un teorema, quando la dimostrazione esiste, c'è questo riquadro grigio: la dimostrazione scritta **un passaggio alla volta**, ciascuno con il suo motivo.

Passo 2 — Come finisce. Il quadratino nero in fondo a destra vuol dire «come volevasi dimostrare»: da lì in poi il teorema si può usare senza dubbi.

■

Richiamo di matematica: il titolo dice di che cosa

I riquadri viola spiegano **da zero** gli strumenti di matematica che servono in quel punto: che cos'è un limite, una derivata, un integrale, una sommatoria. Sono scritti per chi non li ha mai visti o li ha dimenticati.

Da ricordare: nome della formula

le formule da tenere a mente, in evidenza

Nota

I riquadri verdi contengono **intuizioni**, analogie e osservazioni che aiutano a capire, ma non sono indispensabili.

Attenzione

I riquadri gialli segnalano gli **errori tipici** e i punti in cui è facile confondersi.

Esempio 0.1 — Struttura di un esempio

Gli esempi sono racchiusi fra due righe sottili e numerati all'interno di ogni capitolo.

Esercizio 0.1 — Struttura di un esercizio

Gli esercizi sono racchiusi fra righe doppie.

Svolgimento

Lo svolgimento viene subito dopo il testo: conviene provarci da soli prima di leggerlo.

Parte I

Probabilità e variabili aleatorie discrete

Esperimenti, eventi e insiemi

Chi lavora con l'informazione lavora con l'incertezza. Un bit trasmesso su un canale rumoroso può arrivare sbagliato, un pacchetto può trovare la coda del router piena, una misura è sempre sporcata da un po' di rumore. Non sappiamo **che cosa** succederà, ma possiamo dire **quanto è facile** che succeda: è il mestiere della **teoria della probabilità**.

Prima di calcolare una qualsiasi probabilità serve però un linguaggio preciso per dire *che cosa può succedere*. Questo capitolo lo costruisce, e lo costruisce con uno strumento che probabilmente si conosce già: gli **insiemi**. Alla fine del capitolo «si verificano A e B» diventerà $A \cap B$, «non si verifica A» diventerà $\overline{A}$, e potremo fare i conti sugli eventi con la stessa sicurezza con cui si fanno sui numeri.

Esperimenti aleatori e spazio campione

Tutto comincia da un esperimento il cui esito non si può prevedere.

Esperimento aleatorio

Un **esperimento aleatorio** è un'operazione, o un insieme di operazioni, il cui esito è **uno fra tanti risultati possibili**, nessuno dei quali si può prevedere con certezza prima di eseguirla.

La parola viene dal latino *alea*, «dado» (è l'*alea* di «*alea iacta est*», il dado è tratto): lanciare un dado è l'esperimento aleatorio per eccellenza. Ma sono esperimenti aleatori anche lanciare una moneta, estrarre una carta da un mazzo, contare i pacchetti in coda in un router in un certo istante, misurare il rumore su un cavo. La prima cosa da fare, davanti a un esperimento, è elencare **tutto** quello che può succedere.

Spazio campione

Lo **spazio campione** (o spazio dei campioni) Ω è l'insieme di **tutti i risultati possibili** di un esperimento aleatorio. Non deve essere per forza un insieme di numeri: per una moneta è $\{\text{Testa}, \text{Croce}\}$.

Ω è la lettera greca *omega* maiuscola; la minuscola ω indica invece **un singolo risultato**, cioè un elemento di Ω. Visto che tutto il discorso si regge sugli insiemi, conviene rinfrescare subito le parole di base.

Richiamo di matematica: gli insiemi, le parole di base

Un **insieme** è una collezione di oggetti, detti **elementi**. Lo si può descrivere in due modi:

- **elencando** gli elementi fra parentesi graffe: $A = \{1, 3, 5\}$;
- dando una **proprietà** che li caratterizza: $A = \{x \in \mathbb{N} : x \text{ è dispari e } x < 6\}$, che si legge «l'insieme degli x naturali *tali che* x è dispari e minore di 6». I due punti si leggono «tali che».

I simboli che useremo continuamente sono questi.

Simbolo	Si legge	Significato ed esempio
$x \in A$	x appartiene ad A	x è uno degli elementi di A: $3 \in \{1,3,5\}$
$x \notin A$	x non appartiene ad A	$2 \notin \{1,3,5\}$
$A \subseteq B$	A è contenuto in B	ogni elemento di A è anche in B: $\{1,3\} \subseteq \{1,2,3\}$
$\varnothing$	insieme vuoto	l'insieme che non ha nessun elemento
$\lvert A \rvert$	cardinalità di A	il numero di elementi di A: $\lvert\{1,3,5\}\rvert = 3$

In un insieme **conta solo chi c'è**: non conta l'ordine in cui gli elementi sono scritti e non conta se un elemento è scritto due volte. Quindi $\{1,2\} = \{2,1\} = \{1,1,2\}$: sono tutti lo stesso insieme, con due elementi. Due insiemi sono **uguali** quando hanno esattamente gli stessi elementi.
L'insieme vuoto è contenuto in qualsiasi insieme ($\varnothing \subseteq A$): non ha elementi, quindi non ne ha nessuno che manchi in A. Anche $A \subseteq A$ è sempre vero.

Spazi discreti e spazi continui

Lo spazio campione può essere di due tipi molto diversi.

- È **discreto** se i suoi elementi si possono **mettere in fila e contare** uno dopo l'altro: il primo, il secondo, il terzo… Questo accade se è **finito** (come le sei facce di un dado) oppure se è **infinito numerabile** (come i numeri naturali $0, 1, 2, 3, \ldots$: la fila non finisce mai, ma ogni elemento ha la sua posizione nella fila).
- È **continuo** se i suoi elementi sono «troppi» per essere messi in fila, come i punti di un segmento: il tempo, in secondi, che un pacchetto impiega ad arrivare può essere 0,1, 0,11, 0,101… e fra due valori qualsiasi ce ne sono sempre infiniti altri.

Richiamo di matematica: finito, numerabile, non numerabile

Un insieme è **finito** se i suoi elementi si contano e il conteggio finisce: $|A|$ è un numero naturale.
Un insieme infinito è **numerabile** se si può fare un **elenco** che contenga tutti i suoi elementi, ognuno in una posizione precisa. I naturali $\mathbb{N}_0 = \{0, 1, 2, \ldots\}$ sono numerabili per definizione. Lo sono anche i numeri pari $(0, 2, 4, \ldots)$ e persino gli interi relativi $\mathbb{Z}$, se li si elenca così:

$$0,\ 1,\ -1,\ 2,\ -2,\ 3,\ -3,\ \ldots$$

In questo elenco ogni intero compare prima o poi: il numero -5, per esempio, è all'undicesimo posto.
Invece i numeri reali di un intervallo, come $[0, 1]$, **non** sono numerabili: si può dimostrare (è un celebre risultato di Georg Cantor) che qualunque elenco si provi a scrivere ne lascia fuori qualcuno.

Per tutta la prima parte del corso, fino alle variabili aleatorie continue, lo spazio campione sarà **discreto**: finito oppure numerabile.

Eventi

Spesso non interessa il risultato preciso, ma una sua caratteristica: «è uscito un numero pari», «ci sono meno di sei pacchetti in coda». Ognuna di queste frasi individua un gruppo di risultati, cioè un sottoinsieme di Ω.

Evento

Un **evento** è un sottoinsieme di Ω, definito con una formula matematica oppure a parole. Si dice che l'evento A **si verifica** quando il risultato ω dell'esperimento appartiene ad A.

Evento elementare

Un **evento elementare** è uno dei $|\Omega|$ risultati possibili, cioè un singolo elemento $\omega \in \Omega$ (o, se si preferisce vederlo come insieme, il sottoinsieme $\{\omega\}$ che contiene solo lui).

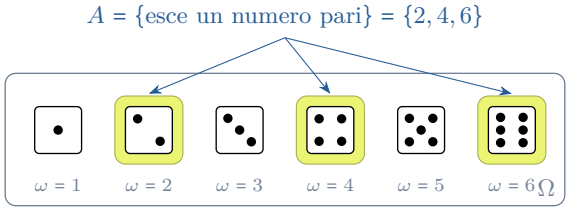


Figura 1.1: *Lo spazio campione del lancio di un dado ha sei eventi elementari; l'evento «esce un numero pari» è il sottoinsieme formato dai tre risultati evidenziati.*

Una cosa da tenere a mente fin da subito: un evento è determinato **solo dagli elementi che contiene**, mentre la frase che lo descrive non è unica. Sul dado, «esce un numero pari», «esce un multiplo di 2» e «non esce un numero dispari» sono tre frasi diverse per **lo stesso** evento $\{2, 4, 6\}$.

Quattro esperimenti da tenere a mente

Gli esempi che seguono torneranno per tutto il corso: conviene guardarli bene.

Il lancio di una moneta

Con un **solo lancio** i risultati possibili sono due:

$$\Omega = \{\text{Testa}, \text{Croce}\} = \{T, C\}, \qquad |\Omega| = 2.$$

Eventi possibili sono $A = \{T\}$ («esce testa»), $B = \{C\}$ («esce croce») e «esce testa o croce», che è $\{T, C\} = \Omega$: un evento che si verifica sempre.

Se la moneta si lancia **due volte**, un risultato è la coppia formata dall'esito del primo lancio e da quello del secondo:

$$\Omega = \{TT, TC, CT, CC\} = \{T, C\} \times \{T, C\} = \{T, C\}^2, \qquad |\Omega| = 4.$$

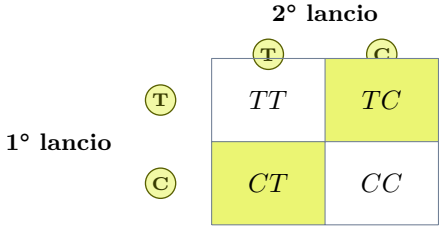
Il simbolo $\times$ fra due insiemi è il **prodotto cartesiano**, e merita un richiamo.

Richiamo di matematica: il prodotto cartesiano

Il **prodotto cartesiano** $A \times B$ è l'insieme di tutte le **coppie ordinate** (a, b) con il primo elemento preso da A e il secondo da B:

$$A \times B = \{(a, b) : a \in A,\ b \in B\}.$$

«Ordinate» vuol dire che **conta l'ordine**: (T, C) e (C, T) sono due coppie diverse. Questa è la grande differenza con gli insiemi, dove $\{T, C\} = \{C, T\}$. Quando un insieme si moltiplica per sé stesso si scrive una potenza: $A \times A = A^2$, $A \times A \times A = A^3$ (le terne ordinate), e così via.
Il nome viene da Cartesio: le coppie ordinate di numeri reali, $\mathbb{R} \times \mathbb{R} = \mathbb{R}^2$, sono proprio i punti del piano cartesiano, e $(2, 3)$ non è lo stesso punto di $(3, 2)$.



Le caselle gialle sono l'evento A = {numero dispari di croci} = $\{TC, CT\}$. L'evento B = {nessuna croce} è la sola casella TT.

Figura 1.2: *I quattro risultati del lancio doppio: righe per il primo lancio, colonne per il secondo.*

Perché TC e CT sono risultati diversi

Lo si capisce immaginando di lanciare due monete diverse, una da un euro e una da due euro: «testa sulla moneta da uno e croce su quella da due» è chiaramente un'altra cosa rispetto a «croce sulla moneta da uno e testa su quella da due». Lanciare due volte la stessa moneta è la stessa situazione, con il primo e il secondo lancio al posto delle due monete. Contare TC e CT come un unico risultato sarebbe un errore, e nel Capitolo 3 vedremo che porta a probabilità sbagliate.

Il lancio di un dado

Lanciando un dado una volta:

$$\Omega = \{1, 2, 3, 4, 5, 6\}, \qquad |\Omega| = 6.$$

Ecco alcuni eventi, prima a parole e poi come insiemi:

- A = «il risultato è dispari» = $\{1, 3, 5\}$;
- B = «il risultato è pari» = $\{2, 4, 6\}$;
- C = «il risultato è dispari e non supera 4» = $\{1, 3\}$;
- D = «il risultato è 6» = $\{6\}$, un evento elementare.

I pacchetti in coda a un router

Un router riceve pacchetti e li inoltra uno alla volta; quelli che arrivano mentre è occupato aspettano in una **coda**. L'esperimento consiste nel guardare la coda in un certo istante e contare quanti pacchetti ci sono.



Figura 1.3: *Il numero di pacchetti in coda in un istante è il risultato di un esperimento aleatorio.*

I valori possibili sono $0, 1, 2, \ldots$ e non c'è un massimo che si possa fissare a priori (o, se c'è, è così grande che conviene ignorarlo). Lo spazio campione è allora l'insieme dei numeri naturali:

$$\Omega = \{0, 1, 2, 3, 4, 5, 6, \ldots\} = \mathbb{N}_0, \qquad |\Omega| = \infty.$$

È uno spazio **infinito ma numerabile**, quindi discreto. Alcuni eventi:

- A = «in coda ci sono meno di 6 pacchetti» = $\{0, 1, 2, 3, 4, 5\}$;
- B = «il numero di pacchetti è dispari» = $\{1, 3, 5, \ldots, 2k + 1, \ldots\}$;
- C = «il numero di pacchetti è dispari e non supera 6» = $\{1, 3, 5\}$: sono i numeri che stanno sia in A sia in B, cioè (lo vedremo fra un attimo) $C = A \cap B$;
- D = «il numero di pacchetti è pari oppure non supera 4» = $\{0, 1, 2, 3, 4, 6, 8, 10, \ldots, 2k, \ldots\}$.

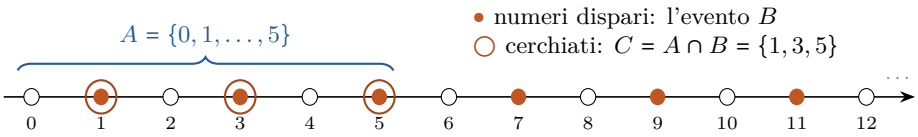


Figura 1.4: *Gli eventi del router sulla retta dei numeri naturali.*

Operazioni fra eventi

Gli eventi sono insiemi, quindi si combinano con le operazioni degli insiemi. Ognuna ha un significato preciso a parole, ed è il significato che conta. Nelle definizioni A e B sono due sottoinsiemi di Ω (più in generale $\{A_i\}_{i=1}^{M}$ indica M sottoinsiemi $A_1, A_2, \ldots, A_M$ di Ω).

Unione

L'**unione** $A \cup B$ è l'insieme degli elementi che stanno in A **oppure** in B (o in entrambi: gli elementi comuni si prendono una volta sola). L'evento $A \cup B$ si verifica quando si verifica **almeno uno** fra A e B.

Intersezione

L'**intersezione** $A \cap B$ è l'insieme di tutti e soli gli elementi comuni ad A **e** a B. L'evento $A \cap B$ si verifica quando si verificano **entrambi**.

Complementare

Il **complementare** di A (in Ω) è l'insieme $\overline{A}$ degli elementi di Ω che **non** appartengono ad A. L'evento $\overline{A}$ si verifica quando A **non** si verifica.

Differenza

La **differenza** $A \setminus B$ («A meno B») è l'insieme degli elementi di A che non appartengono a B: da A si tolgono gli elementi in comune con B. L'evento $A \setminus B$ si verifica quando si verifica A **ma non** B.



$A \cup B$ almeno uno dei due — $A \cap B$ tutti e due — $\overline{A}$ non A — $A \setminus B$ A ma non B

Figura 1.5: *Le quattro operazioni con i **diagrammi di Venn**: il rettangolo è Ω, i cerchi sono gli eventi, la parte gialla è il risultato.*

Dalla definizione di complementare seguono alcune proprietà che si usano di continuo:

$$\overline{\Omega} = \varnothing, \qquad \overline{\varnothing} = \Omega, \qquad \overline{\overline{A}} = A, \qquad A \cup \overline{A} = \Omega, \qquad A \cap \overline{A} = \varnothing.$$

Ognuna si legge facilmente a parole: fuori da Ω non c'è niente; ciò che non sta nel «non A» sta in A; ogni elemento sta in A oppure fuori da A, e non può stare in entrambi.

Esempio 1.1 — Una differenza

Siano $A_1 = \{1, 2, 3, 4, 5, 6, 7, 8\}$ e $A_2 = \{1, 4, 6\}$, dentro lo spazio $\Omega = \mathbb{N}$. Il complementare di A_2 è l'insieme di tutti i naturali diversi da 1, 4 e 6. Togliendo da A_1 gli elementi che ha in comune con A_2 resta

$$A_1 \setminus A_2 = \{2, 3, 5, 7, 8\}.$$

Si noti che è anche l'insieme degli elementi di A_1 che stanno nel complementare di A_2: è $A_1 \cap \overline{A_2}$. Non è un caso, come mostra la proprietà seguente.

Teorema 1.1 — La differenza come intersezione

Per due eventi qualsiasi A e B vale

$$A \setminus B = A \cap \overline{B}.$$

Dimostrazione

Passo 1 — Che cosa significa «uguali». Due insiemi sono uguali se hanno gli stessi elementi. Basta quindi mostrare che un elemento qualsiasi x sta nel primo insieme se e solo se sta nel secondo.

Passo 2 — Si traduce la definizione. $x \in A \setminus B$ vuol dire, per definizione di differenza: $x \in A$ e $x \notin B$.

Passo 3 — Si riconosce il complementare. «$x \notin B$» è proprio la definizione di $x \in \overline{B}$. Quindi la frase diventa: $x \in A$ e $x \in \overline{B}$.

Passo 4 — Si riconosce l'intersezione. «x sta in A e in $\overline{B}$» è la definizione di $x \in A \cap \overline{B}$. Tutti i passaggi si possono percorrere anche all'indietro, quindi i due insiemi hanno gli stessi elementi.

■

LE LEGGI DELL'ALGEBRA DEGLI EVENTI

Con i numeri sappiamo che $a \cdot (b + c) = a \cdot b + a \cdot c$ e che $(a + b) + c = a + (b + c)$. Anche le operazioni sugli eventi obbediscono a delle leggi, e queste leggi permettono di trasformare un evento complicato in uno più semplice da calcolare. Per dimostrarle useremo sempre la stessa tecnica, quella appena vista: tradurre ogni operazione nelle parole «e», «o», «non».

Richiamo di matematica: «e», «o», «non» e come si dimostra che due insiemi sono uguali

Le operazioni sugli insiemi corrispondono esattamente ai connettivi della logica:

Insiemi	Logica	Vale quando...
$x \in A \cap B$	$x \in A$ **e** $x \in B$	sono vere tutte e due le affermazioni
$x \in A \cup B$	$x \in A$ **o** $x \in B$	è vera almeno una delle due
$x \in \overline{A}$	**non** $x \in A$	l'affermazione $x \in A$ è falsa

La «o» della matematica è **inclusiva**: «P o Q» è vera anche quando sono vere tutte e due (come nell'unione, che contiene anche gli elementi comuni). Non è la «o» esclusiva di «o mangi la minestra o salti dalla finestra».
Per dimostrare che due insiemi X e Y sono uguali si mostra che, per un elemento x qualsiasi,

$$x \in X \iff x \in Y,$$

dove il simbolo $\iff$ si legge «se e solo se» e significa che le due affermazioni sono o entrambe vere o entrambe false. In pratica si scrive una **catena** di affermazioni equivalenti che parte da $x \in X$ e arriva a $x \in Y$, giustificando ogni anello.

Le leggi di De Morgan

Teorema 1.2 — Leggi di De Morgan

Per due eventi qualsiasi A_1 e A_2:

$$\overline{A_1 \cup A_2} = \overline{A_1} \cap \overline{A_2} \qquad \overline{A_1 \cap A_2} = \overline{A_1} \cup \overline{A_2}.$$

Il complementare di un'unione è l'intersezione dei complementari, e il complementare di un'intersezione è l'unione dei complementari.

A parole la prima legge dice una cosa ovvia: «non (piove o nevica)» è la stessa cosa di «non piove e non nevica», cioè «né piove né nevica». La seconda: «non (sono stanco e ho fame)» vuol dire che almeno una delle due cose manca, cioè «non sono stanco o non ho fame».

Dimostrazione

Passo 1 — Prima legge, si parte dal primo membro. Sia x un elemento qualsiasi di Ω:

$$x \in \overline{A_1 \cup A_2} \iff x \notin A_1 \cup A_2$$

per definizione di complementare.

Passo 2 — Si nega la «o». x non sta nell'unione quando non è vero che sta in almeno uno dei due insiemi, cioè quando **non sta in nessuno** dei due:

$$x \notin A_1 \cup A_2 \iff x \notin A_1 \text{ e } x \notin A_2.$$

Passo 3 — Si arriva al secondo membro. Per definizione di complementare e poi di intersezione:

$$x \notin A_1 \text{ e } x \notin A_2 \iff x \in \overline{A_1} \text{ e } x \in \overline{A_2} \iff x \in \overline{A_1} \cap \overline{A_2}.$$

La catena è fatta di equivalenze, quindi i due insiemi coincidono.

Passo 4 — La seconda legge si ricava dalla prima. La prima legge vale per due eventi qualsiasi, quindi anche per i due eventi $\overline{A_1}$ e $\overline{A_2}$:

$$\overline{\overline{A_1} \cup \overline{A_2}} = \overline{\overline{A_1}} \cap \overline{\overline{A_2}} = A_1 \cap A_2,$$

perché il complementare del complementare è l'insieme di partenza.

Passo 5 — Si fa il complementare di entrambi i membri. Due insiemi uguali hanno complementari uguali:

$$\overline{\overline{\overline{A_1} \cup \overline{A_2}}} = \overline{A_1 \cap A_2} \quad \Longrightarrow \quad \overline{A_1} \cup \overline{A_2} = \overline{A_1 \cap A_2},$$

che è la seconda legge.

■



$\overline{A}$ | $\overline{B}$ | $\overline{A} \cap \overline{B}$ (giallo in entrambe) | $\overline{A \cup B}$ (fuori dall'unione)

Figura 1.6: *La prima legge di De Morgan vista con i diagrammi: la parte gialla in comune ai primi due disegni è proprio ciò che resta fuori dall'unione.*

Le proprietà associativa e distributiva

Teorema 1.3 — Proprietà associativa

Per tre eventi qualsiasi A_1, A_2, A_3:

$$(A_1 \cup A_2) \cup A_3 = A_1 \cup (A_2 \cup A_3) \qquad (A_1 \cap A_2) \cap A_3 = A_1 \cap (A_2 \cap A_3).$$

Dimostrazione

Passo 1 — Unione. Un elemento sta in $(A_1 \cup A_2) \cup A_3$ se sta in $A_1 \cup A_2$ oppure in A_3, cioè se sta in **almeno uno** dei tre insiemi. Lo stesso ragionamento, fatto sul secondo membro, porta alla stessa frase.

Passo 2 — Intersezione. Un elemento sta in $(A_1 \cap A_2) \cap A_3$ se sta in $A_1 \cap A_2$ e in A_3, cioè se sta in **tutti e tre** gli insiemi; e di nuovo il secondo membro dice lo stesso.

■

Grazie a questa proprietà le parentesi non servono più: si scrive semplicemente $A_1 \cup A_2 \cup A_3$ («almeno uno dei tre») e $A_1 \cap A_2 \cap A_3$ («tutti e tre»). Per molti insiemi si usa una notazione compatta, la stessa idea della sommatoria che vedremo nel prossimo capitolo.

Richiamo di matematica: unione e intersezione di molti insiemi

Dati M insiemi $A_1, A_2, \ldots, A_M$ si scrive

$$\bigcup_{i=1}^{M} A_i = A_1 \cup A_2 \cup \cdots \cup A_M, \qquad \bigcap_{i=1}^{M} A_i = A_1 \cap A_2 \cap \cdots \cap A_M.$$

Si legge «unione (intersezione) per i che va da 1 a M degli A_i». La lettera i è un **indice**: prende uno dopo l'altro i valori $1, 2, \ldots, M$, e per ciascuno si prende l'insieme A_i. Il primo insieme contiene gli elementi che stanno in **almeno uno** degli A_i; il secondo quelli che stanno in **tutti**. L'indice può partire da un altro numero: $\bigcap_{i=2}^{M} A_i = A_2 \cap A_3 \cap \cdots \cap A_M$.

Teorema 1.4 — Proprietà distributive

Per eventi qualsiasi $A_1, A_2, \ldots, A_M$ valgono la distributiva dell'unione rispetto all'intersezione e quella dell'intersezione rispetto all'unione:

$$A_1 \cup \left(\bigcap_{i=2}^{M} A_i \right) = \bigcap_{i=2}^{M} (A_1 \cup A_i) \qquad A_1 \cap \left(\bigcup_{i=2}^{M} A_i \right) = \bigcup_{i=2}^{M} (A_1 \cap A_i)\,.$$

Con tre soli eventi A, B, C si leggono meglio:

$$A \cup (B \cap C) = (A \cup B) \cap (A \cup C) \qquad A \cap (B \cup C) = (A \cap B) \cup (A \cap C).$$

Dimostrazione

Passo 1 — Seconda legge, primo membro. $x \in A_1 \cap \left(\bigcup_{i=2}^{M} A_i \right)$ vuol dire che $x \in A_1$ **e** che x sta in almeno uno fra $A_2, \ldots, A_M$: diciamo in A_k.

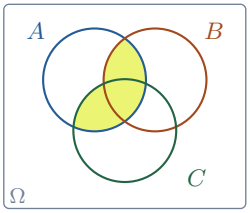
Passo 2 — Seconda legge, secondo membro. Allora x sta sia in A_1 sia in A_k, cioè in $A_1 \cap A_k$: sta in almeno una delle intersezioni $A_1 \cap A_i$, quindi nella loro unione. Viceversa, se x sta in una delle $A_1 \cap A_k$, sta in A_1 e in A_k, quindi in A_1 e nell'unione degli A_i. I due insiemi coincidono.

Passo 3 — Prima legge, primo membro. $x \in A_1 \cup \left(\bigcap_{i=2}^{M} A_i \right)$ vuol dire che $x \in A_1$ **oppure** che x sta in tutti gli $A_2, \ldots, A_M$.

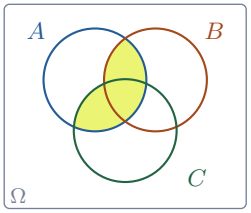
Passo 4 — Prima legge, secondo membro. Se $x \in A_1$, allora x sta in ogni $A_1 \cup A_i$ (che contiene A_1); se invece x sta in tutti gli A_i, sta di nuovo in ogni $A_1 \cup A_i$. In entrambi i casi x sta nell'intersezione di tutti gli $A_1 \cup A_i$.

Passo 5 — Prima legge, il viceversa. Sia ora x in tutti gli $A_1 \cup A_i$. Se $x \in A_1$ abbiamo finito. Se $x \notin A_1$, allora da $x \in A_1 \cup A_i$ segue che $x \in A_i$, e questo per ogni i da 2 a M: x sta nell'intersezione degli A_i. Anche qui i due insiemi coincidono.

■



$A \cap (B \cup C)$



$(A \cap B) \cup (A \cap C)$

Figura 1.7: *La seconda proprietà distributiva: in entrambi i casi si colora la parte di A che sta anche in B o in C.*

Insiemi e numeri: somiglianze e differenze

Se si sostituisce l'unione con la somma e l'intersezione con il prodotto, la seconda legge distributiva diventa quella che si usa da sempre con i numeri: $a \cdot (b + c) = a \cdot b + a \cdot c$. La **prima** invece diventerebbe $a + b \cdot c = (a + b) \cdot (a + c)$, che con i numeri è **falsa**: con $a = 1$, $b = 2$, $c = 3$ il primo membro vale $1 + 6 = 7$ e il secondo $3 \cdot 4 = 12$. Con gli insiemi l'unione e l'intersezione sono perfettamente simmetriche, e ogni legge vale anche scambiando i due simboli.

UN PO' DI NOMENCLATURA

Alcuni eventi e alcune relazioni fra eventi hanno un nome proprio.

Evento certo, evento impossibile

Ω è detto **evento certo**: contiene tutti i risultati, quindi si verifica sempre. $\varnothing$ è detto **evento impossibile**: non contiene nessun risultato, quindi non si verifica mai.

Eventi complementari, incompatibili, implicazione

- A e $\overline{A}$ sono detti **eventi complementari**.
- Due eventi A e B con $A \cap B = \varnothing$ sono detti **incompatibili** (o **mutuamente esclusivi**): non si possono verificare insieme.
- Se $A \subseteq B$ si dice che A **implica** B: ogni volta che si verifica A, si verifica necessariamente anche B.



incompatibili: $A \cap B = \varnothing$ A implica B: $A \subseteq B$

Figura 1.8: *Due eventi incompatibili non hanno risultati in comune; se $A \subseteq B$, chi sta in A sta anche in B.*

Esempio 1.2 — Testa e croce sono complementari

Nel lancio singolo di una moneta, T e C sono eventi complementari ($\overline{T} = C$), quindi anche incompatibili:

$$T \cap C = \overline{C} \cap C = \varnothing.$$

Applicando le leggi di De Morgan si ritrovano le proprietà di Ω e di $\varnothing$:

$$\overline{T \cap C} = \overline{T} \cup \overline{C} = C \cup T = \Omega = \overline{\varnothing}, \qquad \overline{T \cup C} = \overline{T} \cap \overline{C} = C \cap T = \varnothing = \overline{\Omega}.$$

Esempio 1.3 — Lo stesso evento, tante frasi

Nel lancio doppio della moneta, l'evento $D =$ «esce almeno una croce» è incompatibile con $\{TT\}$ e si può scrivere in molti modi:

$$D = \{CC, TC, CT\} = \overline{\{TT\}} = \Omega \setminus \{TT\} = \{CC\} \cup \{TC\} \cup \{CT\}.$$

Matematicamente l'evento è individuato in modo unico dai suoi elementi; a parole lo si può descrivere con frasi diverse: «almeno una croce», «non due teste», «non è uscito TT».

Per finire, ecco il «vocabolario» che traduce le frasi sugli eventi nelle operazioni sugli insiemi. Conviene impararlo bene: negli esercizi il primo passo è sempre tradurre il testo in questa lingua.

A parole	**Con gli insiemi**
si verifica A	il risultato ω sta in A: $\omega \in A$
si verifica A **oppure** B (almeno uno)	$A \cup B$
si verificano A **e** B (entrambi)	$A \cap B$
non si verifica A	$\overline{A}$
si verifica A **ma non** B	$A \setminus B = A \cap \overline{B}$
né A **né** B	$\overline{A} \cap \overline{B} = \overline{A \cup B}$
A e B non possono verificarsi insieme	$A \cap B = \varnothing$
se si verifica A, si verifica anche B	$A \subseteq B$
qualcosa succede sempre / non succede mai	Ω / $\varnothing$

Tabella 1.1: *Dal linguaggio degli eventi a quello degli insiemi.*

In sintesi

- Un **esperimento aleatorio** ha un esito imprevedibile; lo **spazio campione** Ω raccoglie tutti i risultati possibili. Per ora Ω è **discreto**: finito o numerabile.
- Un **evento** è un sottoinsieme di Ω; si verifica quando il risultato gli appartiene. È determinato dai suoi elementi, non dalla frase che lo descrive.
- Unione («o»), intersezione («e»), complementare («non») e differenza («ma non») costruiscono nuovi eventi, e $A \setminus B = A \cap \overline{B}$.
- Leggi di **De Morgan**: $\overline{A \cup B} = \overline{A} \cap \overline{B}$ e $\overline{A \cap B} = \overline{A} \cup \overline{B}$. Valgono anche le proprietà associativa e le due distributive.
- Ω è l'evento certo, $\varnothing$ l'impossibile; A e B sono incompatibili se $A \cap B = \varnothing$; A implica B se $A \subseteq B$.

Contare: il calcolo combinatorio

In molti esperimenti i risultati possibili sono tutti «alla pari»: un dado non truccato non preferisce nessuna faccia, una moneta non preferisce testa a croce, un mazzo ben mescolato non preferisce nessuna carta. In questi casi, come vedremo fra poco, la probabilità di un evento si ottiene **contando**: quanti risultati fanno verificare l'evento, su quanti risultati possibili. Contare sembra facile, ma i numeri crescono in fretta: le mani possibili di cinque carte da un mazzo di 52 sono più di due milioni e mezzo, e nessuno le vuole elencare una per una. Il **calcolo combinatorio** è l'insieme delle tecniche per contare **senza elencare**.

Quando tutti i risultati si equivalgono

Prendiamo un dado non truccato, che d'ora in poi chiameremo **onesto**, e lanciamolo n volte. Ogni lancio dà uno dei sei risultati di $\Omega = \{1, 2, 3, 4, 5, 6\}$. Contiamo quante volte esce ciascuna faccia.

Numero di occorrenze e frequenza relativa

Se un esperimento si ripete n volte, il **numero di occorrenze** n_A di un evento A è il numero di prove in cui A si è verificato. La **frequenza relativa** di A è la frazione di prove in cui si è verificato:

$$f_n(A) = \frac{n_A}{n}.$$

È sempre un numero fra 0 (non si è mai verificato) e 1 (si è verificato sempre).

Detto n_i il numero di volte in cui esce la faccia i, per un dado onesto ci aspettiamo che, se n è abbastanza grande, i sei numeri $n_1, \ldots, n_6$ siano **all'incirca uguali** fra loro, cioè ognuno vicino a $n/|\Omega| = n/6$. La figura mostra che cosa succede davvero in tre serie di lanci simulati al computer.

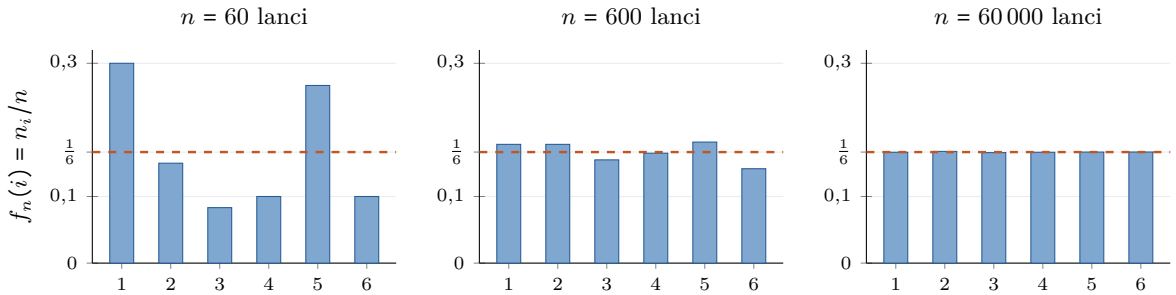


Figura 2.1: *Frequenze relative delle sei facce in tre serie di lanci di un dado onesto (simulate). Con pochi lanci sono molto irregolari; al crescere di n si schiacciano tutte sulla linea tratteggiata* $1/6$.

Consideriamo ora i due eventi $A = \{1, 3, 5\}$ («esce un dispari») e $B = \{2, 4, 6\}$ («esce un pari»). L'evento A si verifica ogni volta che esce l'1, il 3 o il 5, quindi il suo numero di occorrenze è la somma di quelli delle tre facce; e siccome ognuna esce circa $n/|\Omega|$ volte:

$$n_A = n_1 + n_3 + n_5 \simeq \frac{n}{|\Omega|} + \frac{n}{|\Omega|} + \frac{n}{|\Omega|} = \frac{n}{|\Omega|}\,|A|\,, \qquad n_B = n_2 + n_4 + n_6 \simeq \frac{n}{|\Omega|}\,|B|\,.$$

Il simbolo $\simeq$ si legge «circa uguale». Dividendo per n si ottengono le frequenze relative:

$$\frac{n_A}{n} \simeq \frac{|A|}{|\Omega|} = \frac{3}{6} = \frac{1}{2}, \qquad \frac{n_B}{n} \simeq \frac{|B|}{|\Omega|} = \frac{3}{6} = \frac{1}{2}.$$

La frazione di volte in cui si verifica un evento è (circa) il numero dei suoi elementi diviso il numero di tutti i risultati possibili.

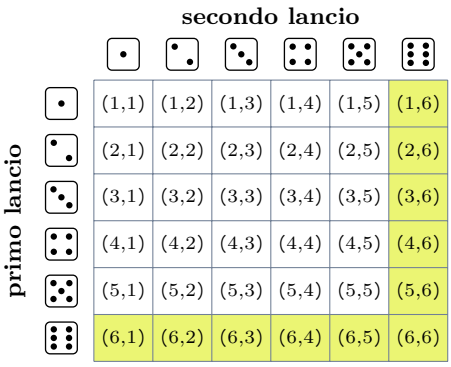
Due lanci consecutivi

Ora l'esperimento consiste nel lanciare il dado **due volte di seguito**, annotando il primo e il secondo risultato. Lo spazio campione è l'insieme delle coppie ordinate:

$$\Omega = \{(1,1),(1,2),\ldots,(1,6),(2,1),\ldots,(6,1),(6,2),\ldots,(6,6)\} = \{1,\ldots,6\}^2,$$

che ha $6 \cdot 6 = 36$ elementi. Se il dado è onesto, in un gran numero n di prove ogni coppia esce circa $n/|\Omega| = n/36$ volte. Sia A l'evento «esce almeno un 6»:

$$A = \{(1,6),(2,6),\ldots,(5,6),(6,1),(6,2),\ldots,(6,6)\}.$$



Le 11 caselle gialle sono l'evento «almeno un 6»: le 6 della riga in basso (il primo lancio è un 6) più le 6 della colonna a destra (il secondo lancio è un 6), meno la casella (6,6), che sta in entrambe e non va contata due volte: $6 + 6 - 1 = 11$.

Figura 2.2: *I 36 risultati del lancio doppio di un dado.*

Anche qui ci aspettiamo che, per n abbastanza grande, la frequenza dell'evento sia

$$\frac{n_A}{n} \simeq \frac{|A|}{|\Omega|} = \frac{11}{36} \approx 0{,}306.$$

La regola generale

Gli esempi suggeriscono una regola che vale ogni volta che i risultati sono «alla pari».

Eventi elementari equivalenti

In uno spazio campione finito Ω gli eventi elementari sono **equivalenti** se nessuno è privilegiato rispetto agli altri: ripetendo l'esperimento un numero molto grande di volte, ciascun risultato si verifica all'incirca lo stesso numero di volte di qualsiasi altro.

In questo caso, per qualsiasi evento $A \subseteq \Omega$, la frequenza relativa gode della proprietà

$$f_n(A) = \frac{n_A}{n} \longrightarrow \frac{|A|}{|\Omega|} \qquad \text{per } n \to \infty.$$

La freccia si legge «tende a»: al crescere del numero n di prove la frequenza si avvicina quanto si vuole al numero $|A| \,/\, |\Omega|$. (La definizione precisa di questo «avvicinarsi», il *limite*, è nel prossimo capitolo.) La conseguenza pratica è importantissima: quando gli eventi elementari sono equivalenti, **tutto si riduce a contare** quanti elementi hanno gli insiemi che ci interessano. Il resto del capitolo insegna a farlo.

Il principio fondamentale: moltiplicare le scelte

Quasi tutte le formule di conteggio discendono da un'unica idea. Prima però serve una notazione, perché di prodotti lunghi ne scriveremo parecchi.

Richiamo di matematica: sommatorie e produttorie

Quando si devono sommare molti termini che seguono una regola, invece dei puntini si usa la lettera greca Σ (*sigma* maiuscola, la «S» di somma):

$$\sum_{i=1}^{n} a_i = a_1 + a_2 + \cdots + a_n.$$

Si legge «sommatoria per i che va da 1 a n di a_i». L'**indice** i parte dal valore scritto sotto, cresce di uno alla volta e si ferma al valore scritto sopra; per ogni valore si calcola il termine e alla fine si somma tutto:

$$\sum_{i=1}^{4} i = 1+2+3+4 = 10, \qquad \sum_{k=0}^{3} 2^k = 1+2+4+8 = 15, \qquad \sum_{i=1}^{3} 5 = 5+5+5 = 15.$$

Nell'ultimo esempio il termine non dipende da i: si somma tre volte lo stesso numero, e in generale $\sum_{i=1}^{n} c = n \cdot c$. Il nome dell'indice non conta: $\sum_{i=1}^{4} i$ e $\sum_{k=1}^{4} k$ sono la stessa somma.
Allo stesso modo la lettera Π (*pi* maiuscola, la «P» di prodotto) indica un prodotto:

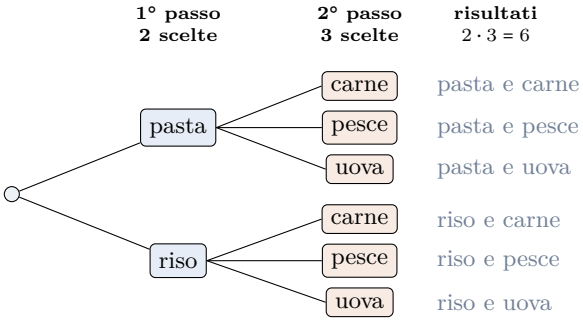
$$\prod_{i=1}^{n} a_i = a_1 \cdot a_2 \cdots a_n, \qquad \prod_{i=1}^{4} i = 1\cdot 2\cdot 3\cdot 4 = 24, \qquad \prod_{i=0}^{2} (5-i) = 5\cdot 4\cdot 3 = 60.$$

Due proprietà delle sommatorie si usano di continuo. Una costante che moltiplica tutti i termini si può portare fuori (è la proprietà distributiva: $c\,a_1 + \cdots + c\,a_n = c\,(a_1 + \cdots + a_n)$), e la somma di due successioni si può spezzare in due somme (basta riordinare i termini):

$$\sum_{i=1}^{n} c\,a_i = c \sum_{i=1}^{n} a_i, \qquad \sum_{i=1}^{n} (a_i + b_i) = \sum_{i=1}^{n} a_i + \sum_{i=1}^{n} b_i.$$

Esempio 2.1 — Quanti pranzi diversi?

Un menù offre 2 primi (pasta, riso) e 3 secondi (carne, pesce, uova). Un pranzo è formato da un primo e un secondo. Per ognuno dei 2 primi si può scegliere uno qualsiasi dei 3 secondi: i pranzi diversi sono $2 \cdot 3 = 6$.



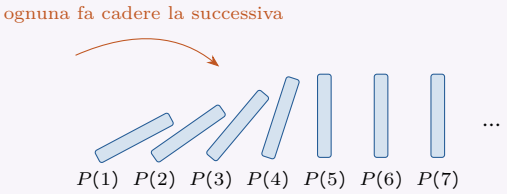
Il disegno si chiama **diagramma ad albero**: ogni ramo è una scelta, ogni foglia (a destra) è un risultato completo. Le foglie sono tante quanti i rami del primo livello moltiplicati per i rami che partono da ciascuno di essi.

L'esempio contiene già tutta l'idea. Per dimostrarla in generale serve uno strumento che useremo più volte.

Richiamo di matematica: il principio di induzione

Per dimostrare che un'affermazione $P(n)$ è vera **per ogni** numero naturale $n \geq 1$ non serve verificarla su infiniti numeri. Bastano due cose:

1. la **base**: si verifica che $P(1)$ è vera;
2. il **passo induttivo**: si dimostra che, *se* $P(n-1)$ è vera (è l'**ipotesi induttiva**), *allora* è vera anche $P(n)$.



È come una fila di tessere del domino: la base fa cadere la prima tessera; il passo induttivo garantisce che ogni tessera, cadendo, fa cadere la successiva. Allora cadono tutte: $P(1)$ fa cadere $P(2)$, che fa cadere $P(3)$, e così via senza fine.

Teorema 2.1 — Principio fondamentale del calcolo combinatorio

Se una scelta si compie in k passi successivi e al passo i-esimo ci sono m_i possibilità, **qualunque** siano state le scelte fatte ai passi precedenti, allora i modi di compiere l'intera scelta sono

$$m_1 \cdot m_2 \cdots m_k = \prod_{i=1}^{k} m_i.$$

In particolare, dati k insiemi finiti $A_1, A_2, \ldots, A_k$ (non necessariamente distinti), il loro **prodotto cartesiano** $A^{(k)} = A_1 \times A_2 \times \cdots \times A_k$, cioè l'insieme delle k-ple ordinate con il primo elemento in A_1, il secondo in A_2 e così via, ha come numero di elementi il prodotto dei numeri di elementi dei singoli insiemi:

$$\left|A^{(k)}\right| = \prod_{i=1}^{k} |A_i|\,. \qquad (\bullet)$$

Dimostrazione

Passo 1 — Base. Con un solo passo ($k = 1$) i modi sono m_1, e la formula dà proprio m_1.

Passo 2 — Ipotesi induttiva. Supponiamo che i primi $k-1$ passi si possano compiere in $m_1 \cdot m_2 \cdots m_{k-1}$ modi.

Passo 3 — Passo induttivo. Ognuno di questi modi si può completare con una qualsiasi delle m_k possibilità del passo k-esimo, e completamenti diversi danno scelte complete diverse. Come nell'albero dei pranzi, ogni foglia del livello $k-1$ si apre in m_k rami: le scelte complete sono $(m_1 \cdots m_{k-1}) \cdot m_k$.

Passo 4 — Il prodotto cartesiano. Costruire una k-pla di $A^{(k)}$ vuol dire scegliere il primo elemento in A_1 ($m_1 = |A_1|$ modi), poi il secondo in A_2 ($m_2 = |A_2|$ modi, qualunque sia il primo), e così via. La formula $(\bullet)$ è il caso particolare con $m_i = |A_i|$.

■

Il numero di elementi del prodotto cartesiano è il **prodotto** del numero di elementi dei singoli insiemi: è la relazione fondamentale del calcolo combinatorio, da cui derivano tutte le formule del capitolo. La forma con i «passi» è un po' più generale ed è quella che serve quando l'insieme delle scelte disponibili cambia da un passo all'altro: conta solo che ne cambi il *contenuto*, non il *numero*.

Esempio 2.2 — Targhe e lanci

- Il lancio doppio di una moneta ha $\left|\{T,C\}^2\right| = 2 \cdot 2 = 4$ risultati; il lancio doppio di un dado $6 \cdot 6 = 36$; tre lanci di un dado $6^3 = 216$.
- Una targa automobilistica italiana ha la forma `AB 123 CD`: due lettere, tre cifre, due lettere. Le lettere ammesse sono 22 (sono escluse I, O, Q e U, che si confondono con altri simboli). Le targhe possibili sono $22 \cdot 22 \cdot 10 \cdot 10 \cdot 10 \cdot 22 \cdot 22 = 22^4 \cdot 10^3 = 234\,256\,000$.

Disposizioni: quando l'ordine conta

Disposizioni semplici

Disposizioni semplici

Dato un insieme $A = \{a_1, a_2, \ldots, a_n\}$ di n elementi, le **disposizioni semplici di n oggetti di classe k** (k-ple ordinate senza ripetizione) sono le sequenze ordinate di k elementi **distinti** di A: le «stringhe» di lunghezza k in cui ogni elemento di A compare al più una volta.

Teorema 2.2 — Numero di disposizioni semplici

Per $k \le n$ il numero di disposizioni semplici di n oggetti di classe k è

$$K_{o,nr} = n\,(n-1)\,(n-2)\cdots(n-k+1) = \prod_{i=0}^{k-1}(n-i).$$

I pedici ricordano che l'ordine conta (o) e che non sono ammesse ripetizioni (nr).

Dimostrazione

Passo 1 — I passi. Si costruisce la sequenza una posizione alla volta: k passi.

Passo 2 — Le scelte a ogni passo. Al primo passo si può scegliere uno qualsiasi degli n elementi. Al secondo passo un elemento è già stato usato e non si può ripetere: restano $n-1$ scelte, *qualunque* sia l'elemento usato. Al terzo ne restano $n-2$, e in generale al passo i-esimo ne restano $n-(i-1)$. All'ultimo passo, il k-esimo, le scelte sono $n-k+1$.

Passo 3 — Si moltiplica. Per il principio fondamentale (Teorema 2.1) il totale è $n\,(n-1)\cdots(n-k+1)$. Nella formula $(\bullet)$ è come avere $|A_1| = n$, $|A_2| = n-1$, …, $|A_k| = n-k+1$.

■

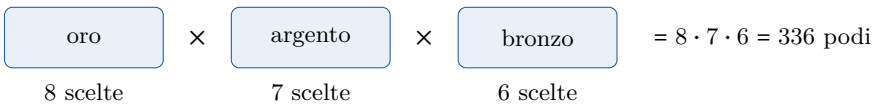


Figura 2.3: *Otto atleti in finale: chi vince l'oro si sceglie fra 8, l'argento fra i 7 rimasti, il bronzo fra i 6 rimasti. Contano l'ordine (oro e argento non sono la stessa cosa) e l'assenza di ripetizioni (nessuno vince due medaglie).*

Si noti che la formula funziona anche se si prova a esagerare: per $k > n$ il prodotto contiene il fattore $n - n = 0$ e dà zero, come deve essere (non si possono mettere in fila k oggetti distinti se se ne hanno meno di k).

Disposizioni con ripetizione

Disposizioni con ripetizione

Le **disposizioni con ripetizione di n oggetti di classe k** (o k-ple ordinate con ripetizione) sono le sequenze ordinate di k elementi di $A = \{a_1, \dots, a_n\}$ in cui ogni elemento **può ripetersi**.

Teorema 2.3 — Numero di disposizioni con ripetizione

Il numero di disposizioni con ripetizione di n oggetti di classe k è

$$K_{o,r} = \prod_{i=0}^{k-1} n = n^k.$$

Dimostrazione

Passo 1 — Le scelte non diminuiscono. Questa volta a ogni posizione si può rimettere qualsiasi elemento, anche se è già stato usato: a ognuno dei k passi le scelte sono sempre n.

Passo 2 — Si moltiplica. Per il principio fondamentale il totale è $n \cdot n \cdots n$ (k volte), cioè n^k. Nella (•) è il caso $|A_1| = |A_2| = \cdots = |A_k| = n$: le disposizioni con ripetizione sono proprio gli elementi del prodotto cartesiano A^k. ■

Esempio 2.3 — Stringhe binarie, byte e codici PIN

- Le stringhe binarie di lunghezza k sono le k-ple ordinate con ripetizione dell'insieme $\{0, 1\}$, che ha 2 elementi: sono 2^k. Un byte ($k = 8$) può quindi assumere $2^8 = 256$ valori diversi.
- Un PIN di 4 cifre è una disposizione con ripetizione delle 10 cifre: i PIN possibili sono $10^4 = 10\,000$. Chi prova a indovinarlo a caso ha una sola possibilità su diecimila.

Permutazioni

Un caso particolare, ma importantissimo, delle disposizioni semplici è quello in cui si usano **tutti** gli elementi: $k = n$. La domanda è: in quanti modi si possono mettere in fila n oggetti distinti?

Permutazioni

Una **permutazione** di n oggetti distinti è un modo di metterli in fila, cioè una disposizione semplice di classe $k = n$.

Teorema 2.4 — Numero di permutazioni

Il numero di permutazioni di n oggetti distinti è

$$n\,(n-1)\,(n-2)\cdots 2 \cdot 1 = n!$$

(si legge «n fattoriale»).

Dimostrazione

Passo 1. È la formula delle disposizioni semplici con $k = n$: l'ultimo fattore diventa $n - n + 1 = 1$, e il prodotto comprende tutti gli interi da n fino a 1.

■

Richiamo di matematica: il fattoriale

Il **fattoriale** di un intero $n \geq 1$ è il prodotto di tutti gli interi da 1 a n:

$$n! = \prod_{i=1}^{n} i = 1 \cdot 2 \cdot 3 \cdots n, \qquad \text{e per convenzione} \quad 0! = 1.$$

n	0	1	2	3	4	5	6	7	8	9	10
$n!$	1	1	2	6	24	120	720	5 040	40 320	362 880	3 628 800

Il fattoriale cresce in modo vertiginoso: 52!, il numero di modi di mescolare un mazzo di carte francesi, vale circa $8 \cdot 10^{67}$, un numero con 68 cifre. Ogni volta che si mescola bene un mazzo, quasi certamente si ottiene un ordine che non è mai esistito prima nella storia.

Due proprietà si usano di continuo:

- $n! = n \cdot (n-1)!$: il fattoriale di n è n volte il fattoriale del numero precedente (per esempio $5! = 5 \cdot 4! = 5 \cdot 24 = 120$);
- un rapporto di fattoriali si semplifica cancellando i fattori comuni: $\frac{7!}{4!} = \frac{7 \cdot 6 \cdot 5 \cdot \cancel{4!}}{\cancel{4!}} = 7 \cdot 6 \cdot 5 = 210$.

Perché $0! = 1$**?** Perché è l'unico valore che rende vera la regola $n! = n \cdot (n-1)!$ anche per $n = 1$: $1! = 1 \cdot 0!$ richiede $0! = 1$. C'è anche una lettura «combinatoria»: c'è esattamente **un** modo di mettere in fila zero oggetti, cioè non fare niente.

Con il fattoriale la formula delle disposizioni semplici si scrive in forma compatta. Basta moltiplicare e dividere per $(n-k)!$, che «completa» il prodotto fino a 1:

$$K_{o,nr} = n\,(n-1)\cdots(n-k+1) = \frac{n\,(n-1)\cdots(n-k+1)\cdot(n-k)!}{(n-k)!} = \frac{n!}{(n-k)!}.$$

Per esempio, i podi della figura sono $\frac{8!}{5!} = 8 \cdot 7 \cdot 6 = 336$.

Esempio 2.4 — Anagrammi

Gli anagrammi della parola ROMA (anche senza senso) sono le permutazioni delle sue 4 lettere distinte: $4! = 24$. Si possono ottenere dall'albero: 4 scelte per la prima lettera, 3 per la seconda, 2 per la terza, 1 per l'ultima. Fra questi ci sono AMOR, MORA, RAMO, ORMA e MARO.

Combinazioni: quando l'ordine non conta

Spesso l'ordine non interessa: in una mano di carte conta *quali* carte si hanno, non in che ordine sono arrivate; in una schedina del lotto conta *quali* numeri si giocano.

Combinazioni

Le **combinazioni di n elementi su k posti**, indicate con $C_{n,k}$, sono le k-ple **non ordinate** e senza ripetizioni che si possono formare con n elementi. In altre parole, $C_{n,k}$ è il numero di **sottoinsiemi di k elementi** di un insieme di n elementi.

In un sottoinsieme contano solo gli elementi, non il loro ordine: $\{a_1, a_2\}$ e $\{a_2, a_1\}$ sono lo stesso insieme e vanno contati una volta sola. Il trucco per contarli è partire dalle disposizioni, in cui l'ordine conta, e accorgersi che ogni sottoinsieme viene contato più volte.

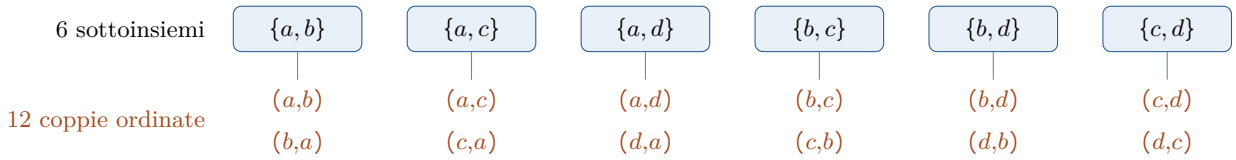


Figura 2.4: *Con $n = 4$ elementi $\{a, b, c, d\}$ e $k = 2$: le $4 \cdot 3 = 12$ disposizioni si raggruppano a due a due (le $2! = 2$ permutazioni di ciascuna coppia), e i gruppi sono i $12/2 = 6$ sottoinsiemi.*

Teorema 2.5 — Numero di combinazioni

Il numero di sottoinsiemi di k elementi di un insieme di n elementi ($0 \le k \le n$) è

$$C_{n,k} = \frac{n\,(n-1)\,(n-2)\cdots(n-k+1)}{k!} = \frac{n!}{k!\,(n-k)!} = \binom{n}{k}.$$

Il numero $\binom{n}{k}$ si chiama **coefficiente binomiale** e si legge «n su k».

Dimostrazione — contare due volte la stessa cosa

Passo 1 — L'idea. Contiamo le k-ple ordinate senza ripetizione in due modi diversi. Siccome contiamo la stessa cosa, i due risultati devono essere uguali.

Passo 2 — Primo modo. Sono le disposizioni semplici: $K_{o,nr} = n\,(n-1)\cdots(n-k+1)$.

Passo 3 — Secondo modo. Una k-pla ordinata si può costruire in due passi: prima si sceglie *quali* k elementi usare (un sottoinsieme: $C_{n,k}$ modi), poi si sceglie *in che ordine* metterli (le permutazioni di k oggetti: $k!$ modi, qualunque sia il sottoinsieme). Per il principio fondamentale le k-ple ordinate sono $C_{n,k} \cdot k!$.

Passo 4 — Si uguaglia. $C_{n,k} \cdot k! = n\,(n-1)\cdots(n-k+1)$, quindi

$$C_{n,k} = \frac{n\,(n-1)\cdots(n-k+1)}{k!}.$$

In altre parole: tutte le $k!$ permutazioni di una stessa k-pla ordinata *collassano* in un'unica combinazione.

Passo 5 — La forma con i fattoriali. Moltiplicando numeratore e denominatore per $(n-k)!$, il numeratore diventa $n!$ (come per le disposizioni):

$$C_{n,k} = \frac{n\,(n-1)\cdots(n-k+1)\cdot(n-k)!}{k!\,(n-k)!} = \frac{n!}{k!\,(n-k)!}.$$

■

Esempio 2.5 — Il SuperEnalotto

Una giocata del SuperEnalotto consiste nello scegliere 6 numeri diversi fra 1 e 90, senza che l'ordine conti. Le giocate possibili sono

$$\binom{90}{6} = \frac{90 \cdot 89 \cdot 88 \cdot 87 \cdot 86 \cdot 85}{6!} = 622\,614\,630.$$

Con una sola giocata, le probabilità di fare «sei» sono una su più di seicento milioni.

Richiamo di matematica: il coefficiente binomiale e il triangolo di Tartaglia

Il coefficiente binomiale $\binom{n}{k} = \dfrac{n!}{k!\,(n-k)!}$ ha alcune proprietà che conviene conoscere.

- **Casi estremi**: $\binom{n}{0} = \binom{n}{n} = 1$ (un solo sottoinsieme vuoto, un solo sottoinsieme «tutto») e $\binom{n}{1} = n$ (i sottoinsiemi con un elemento sono tanti quanti gli elementi).
- **Simmetria**: $\binom{n}{k} = \binom{n}{n-k}$. Nella formula basta scambiare k con $n-k$: il denominatore $k!\,(n-k)!$ non cambia. A parole: scegliere i k elementi che *entrano* equivale a scegliere gli $n-k$ che *restano fuori*. Per esempio $\binom{90}{84} = \binom{90}{6}$.
- **Regola di Stifel**: $\binom{n}{k} = \binom{n-1}{k-1} + \binom{n-1}{k}$ per $1 \le k \le n-1$. Si fissa un elemento x dell'insieme. I sottoinsiemi di k elementi o contengono x, e allora gli altri $k-1$ si scelgono fra i rimanenti $n-1$ ($\binom{n-1}{k-1}$ modi), oppure non lo contengono, e allora tutti i k elementi si scelgono fra gli altri $n-1$ ($\binom{n-1}{k}$ modi). I due gruppi non hanno elementi in comune, quindi i totali si sommano.

La regola di Stifel permette di costruire tutti i coefficienti binomiali senza fattoriali, riga dopo riga: è il **triangolo di Tartaglia**. La riga n contiene $\binom{n}{0}, \binom{n}{1}, \ldots, \binom{n}{n}$; ai lati ci sono degli 1 e ogni numero interno è la somma dei due che ha sopra.

$n = 0$	1
$n = 1$	1 1
$n = 2$	1 2 1
$n = 3$	1 3 3 1
$n = 4$	1 4 6 4 1
$n = 5$	1 5 10 10 5 1
$n = 6$	1 6 15 20 15 6 1

$\binom{4}{1} + \binom{4}{2} = 4 + 6 = 10 = \binom{5}{2}$

UN PROBLEMA CON LE CARTE

Esercizio 2.1 — Estrazioni da un mazzo di carte francesi

Un mazzo di carte francesi ha 52 carte, 13 per ognuno dei quattro semi: Cuori (C), Fiori (F), Picche (P) e Quadri (Q). Si estraggono delle carte **senza reinserimento** (una carta estratta non torna nel mazzo). Si calcolino:

a) il numero di possibili quaterne ordinate;

b) il numero di quaterne non ordinate;

c) il numero di quaterne ordinate con semi (C, F, P, Q), cioè con la prima carta di cuori, la seconda di fiori, la terza di picche e la quarta di quadri;

d) il numero di cinquine non ordinate in cui compaiono esattamente due assi.

Svolgimento

a) Contano l'ordine e l'assenza di ripetizioni (una carta estratta non può riuscire): sono disposizioni semplici di 52 oggetti di classe 4,

$$52 \cdot 51 \cdot 50 \cdot 49 = 6\,497\,400.$$

b) Ora l'ordine non conta: le $4! = 24$ permutazioni di ogni quaterna collassano in un'unica quaterna non ordinata,

$$\frac{52 \cdot 51 \cdot 50 \cdot 49}{4!} = \frac{6\,497\,400}{24} = 270\,725 = \binom{52}{4}.$$

c) La prima carta si sceglie fra le 13 di cuori, la seconda fra le 13 di fiori, la terza fra le 13 di picche, la quarta fra le 13 di quadri: è il prodotto cartesiano di quattro insiemi con $|A_i| = 13$ ($k = 4$),

$$13 \cdot 13 \cdot 13 \cdot 13 = 13^4 = 28\,561.$$

Le ripetizioni sono impossibili da sole, perché le quattro carte hanno semi diversi.

d) Si costruisce la cinquina in due passi. Prima si scelgono i due assi fra i 4 del mazzo: i sottoinsiemi di 2 assi sono $\binom{4}{2}$ (4 assi su 2 posti). Poi si scelgono le altre 3 carte fra le $52 - 4 = 48$ che non sono assi (altrimenti gli assi sarebbero più di due): sono $\binom{48}{3}$. Per il principio fondamentale:

$$\binom{4}{2}\binom{48}{3} = \frac{4!}{2!\,2!} \cdot \frac{48!}{3!\,45!} = \frac{4 \cdot 3}{2} \cdot \frac{48 \cdot 47 \cdot 46}{3 \cdot 2} = 6 \cdot 17\,296 = 103\,776.$$

Una curiosità sul punto c)

Se nel punto c) l'ordine non contasse (cioè si volessero le quaterne non ordinate con una carta per seme), il risultato sarebbe ancora 13^4: ogni mano con una carta per seme corrisponde a una e una sola quaterna ordinata nell'ordine C, F, P, Q. Se invece si volessero le quaterne *ordinate* con una carta per seme in un ordine qualsiasi, bisognerebbe moltiplicare per le 4! disposizioni dei semi: $4! \cdot 13^4 = 685\,464$.

L'insieme delle parti e il binomio di Newton

Insieme delle parti

L'**insieme delle parti** $\mathcal{P}(A)$ di un insieme A è l'insieme di **tutti** i sottoinsiemi di A, compresi l'insieme vuoto $\varnothing$ e A stesso.

Quanti sono i sottoinsiemi di un insieme A con n elementi? Quelli con esattamente k elementi sono $\binom{n}{k}$, e k può andare da 0 (l'insieme vuoto) a n (A stesso). Sommando su tutte le dimensioni possibili:

$$|\mathcal{P}(A)| = \sum_{k=0}^{n} \binom{n}{k} = \binom{n}{0} + \binom{n}{1} + \cdots + \binom{n}{n}.$$

Questa somma ha un valore molto semplice, che si scopre con una delle formule più famose della matematica.

Teorema 2.6 — Binomio di Newton

Per qualsiasi coppia di numeri a, b e per ogni naturale n:

$$(a+b)^n = \sum_{k=0}^{n} \binom{n}{k} a^k\, b^{n-k}.$$

Prima della dimostrazione, i casi piccoli. Per $n = 2$ si ritrova il quadrato di un binomio, $(a+b)^2 = b^2 + 2ab + a^2$, con i coefficienti $1, 2, 1$ della riga 2 del triangolo di Tartaglia. Per $n = 3$: $(a+b)^3 = b^3 + 3ab^2 + 3a^2b + a^3$, con i coefficienti $1, 3, 3, 1$ della riga 3. Non è una coincidenza.

Dimostrazione

Passo 1 — Si scrive la potenza come prodotto. $(a+b)^n = (a+b)(a+b)\cdots(a+b)$, con n fattori.

Passo 2 — Come si sviluppa un prodotto. Moltiplicando tutto (proprietà distributiva) si ottiene una somma di termini, e ogni termine si forma scegliendo **da ciascun fattore** o la a o la b e moltiplicando le scelte. Per esempio con $n = 3$ la scelta «a dal primo fattore, b dal secondo, a dal terzo» produce il termine $a \cdot b \cdot a = a^2 b$.

Passo 3 — Che termini si ottengono. Se la a è stata scelta da k fattori, la b è stata scelta dagli altri $n-k$: il termine vale $a^k b^{n-k}$. Quindi i termini possibili sono $a^0 b^n, a^1 b^{n-1}, \ldots, a^n b^0$.

Passo 4 — Quante volte compare ciascuno. Il termine $a^k b^{n-k}$ compare una volta per ogni modo di scegliere *quali* k fattori (fra gli n) danno la a. Sono i sottoinsiemi di k elementi di un insieme di n: $\binom{n}{k}$. Raccogliendo i termini uguali si ottiene $\binom{n}{k} a^k b^{n-k}$, e sommando su k da 0 a n si ha la tesi. ∎

Teorema 2.7 — Numero dei sottoinsiemi

Un insieme A con n elementi ha 2^n sottoinsiemi:

$$|\mathcal{P}(A)| = \sum_{k=0}^{n} \binom{n}{k} = 2^n.$$

Dimostrazione — due modi

Passo 1 — Con il binomio di Newton. Ponendo $a = b = 1$ nella formula di Newton, ogni potenza di 1 vale 1:

$$2^n = (1+1)^n = \sum_{k=0}^{n} \binom{n}{k} 1^k \, 1^{n-k} = \sum_{k=0}^{n} \binom{n}{k} = |\mathcal{P}(A)| \, .$$

Passo 2 — Con una stringa binaria. Si mettono in fila gli n elementi di A. Un sottoinsieme si descrive dicendo, per ogni elemento, se c'è (1) o non c'è (0): è una stringa binaria di lunghezza n, e sottoinsiemi diversi danno stringhe diverse. Le stringhe binarie di lunghezza n sono 2^n (disposizioni con ripetizione, Teorema 2.3), quindi anche i sottoinsiemi. ■

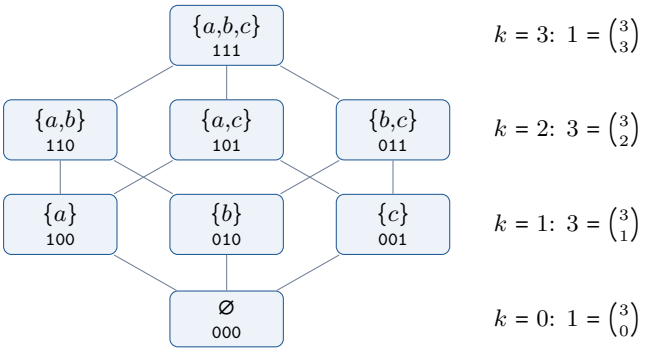


Figura 2.5: *Gli $2^3 = 8$ sottoinsiemi di $\{a, b, c\}$, ordinati per numero di elementi k, ognuno con la sua stringa binaria (1 = l'elemento c'è). Le righe ne contengono $1, 3, 3, 1$: la riga 3 del triangolo di Tartaglia.*

PROVE RIPETUTE E CONTEGGIO DEI SUCCESSI

Un ultimo conteggio, che sarà la chiave della distribuzione binomiale (Capitolo 5). Si considerino le stringhe binarie di lunghezza n che contengono esattamente k valori «1» e $n - k$ valori «0». Quante sono?

Teorema 2.8 — Stringhe con k uni

Le stringhe binarie di lunghezza n con esattamente k valori «1» (e $n - k$ valori «0») sono

$$\frac{n!}{k!\,(n-k)!} = \binom{n}{k}.$$

Dimostrazione — permutazioni inefficaci

Passo 1 — Si parte da una stringa qualsiasi. Si prende una stringa con k «1» e $n - k$ «0», per esempio 1 1 0 0 0 ($n = 5$, $k = 2$), e si immagina di aver dato un nome diverso a ogni simbolo, come se fossero n oggetti distinti. Le loro permutazioni sono $n!$.

Passo 2 — Molte permutazioni non cambiano nulla. Scambiare fra loro due «1» lascia la stringa identica: le $k!$ permutazioni degli «1» sulle posizioni che già occupano sono *inefficaci*. Lo stesso vale per le $(n-k)!$ permutazioni degli «0» sulle loro posizioni.

Passo 3 — Si divide. Ogni stringa diversa viene quindi prodotta da $k!\,(n-k)!$ permutazioni. Dividendo le $n!$ permutazioni iniziali per $k!$ e per $(n-k)!$ si ottiene il numero di stringhe diverse: $\dfrac{n!}{k!\,(n-k)!} = \binom{n}{k}$.

Passo 4 — Un modo più breve. Una stringa con k uni è individuata da *quali* k posizioni, fra le n, contengono un 1: un sottoinsieme di k elementi dell'insieme delle posizioni $\{1, \ldots, n\}$. Sono $\binom{n}{k}$. ■

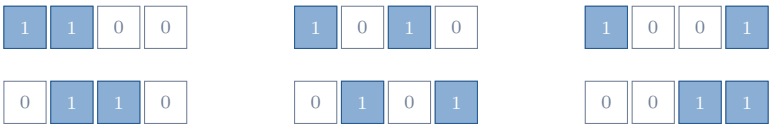


Figura 2.6: *Le* $\binom{4}{2} = \frac{4!}{2!\,2!} = 6$ *stringhe di lunghezza 4 con due «1»: tante quante le coppie di posizioni in cui mettere gli uni.*

Il nome del paragrafo viene dall'interpretazione più importante: se si ripete n volte una prova che può riuscire (1, un *successo*) o fallire (0, un *insuccesso*), le sequenze di risultati con esattamente k successi sono $\binom{n}{k}$. Per esempio, nei 10 lanci di una moneta le sequenze con esattamente 3 teste sono $\binom{10}{3} = 120$.

Riepilogo delle formule

Davanti a un problema di conteggio le domande da farsi sono due: **l'ordine conta?** e **sono ammesse ripetizioni?**

Che cosa si conta	Ordine	Ripetizioni	Quante sono
disposizioni con ripetizione	sì	sì	n^k
disposizioni semplici	sì	no	$n\,(n-1)\cdots(n-k+1) = \dfrac{n!}{(n-k)!}$
permutazioni ($k = n$)	sì	no	$n!$
combinazioni (sottoinsiemi)	no	no	$\binom{n}{k} = \dfrac{n!}{k!\,(n-k)!}$
tutti i sottoinsiemi	—	—	2^n

Tabella 2.1: *Le formule del calcolo combinatorio per k scelte da n elementi.*

Il caso che manca: combinazioni con ripetizione

Nella tabella manca la casella «ordine no, ripetizioni sì», che nel corso non serve ma completa il quadro. Per esempio: in quanti modi si possono scegliere 3 palline di gelato fra 5 gusti, potendo ripetere un gusto? La risposta è $\binom{n+k-1}{k} = \binom{7}{3} = 35$. Il motivo: una scelta si può disegnare con k pallini (le palline) e $n-1$ stanghette che separano i gusti; per esempio $\bullet\bullet\,|\,|\,\bullet\,|\,|$ vuol dire due palline del primo gusto e una del terzo. Ogni scelta è una stringa di $n+k-1$ simboli in cui si decide dove stanno i k pallini: $\binom{n+k-1}{k}$ modi.

In sintesi

- Se gli eventi elementari sono **equivalenti**, la frequenza di un evento tende a $|A| \,/\, |\Omega|$: la probabilità si calcola **contando**.
- **Principio fondamentale**: se una scelta si fa in k passi con m_i possibilità al passo i, i modi sono $\prod m_i$; in particolare $|A_1 \times \cdots \times A_k| = \prod |A_i|$.
- Disposizioni con ripetizione: n^k. Disposizioni semplici: $n!/(n-k)!$. Permutazioni: $n!$.
- Combinazioni (sottoinsiemi di k elementi): $\binom{n}{k} = \frac{n!}{k!\,(n-k)!}$, perché le $k!$ permutazioni di ogni k-pla collassano in un'unica combinazione.
- Binomio di Newton: $(a+b)^n = \sum_k \binom{n}{k} a^k b^{n-k}$; di conseguenza un insieme di n elementi ha 2^n sottoinsiemi.
- Le stringhe binarie lunghe n con k uni (le sequenze di n prove con k successi) sono $\binom{n}{k}$.

Dalla frequenza alla probabilità

Nel capitolo precedente abbiamo visto che, quando i risultati di un esperimento sono «alla pari», la frequenza relativa di un evento si avvicina sempre di più al numero $|A| \,/\, |\Omega|$. È il momento di dare un nome a questo numero: la **probabilità**. In questo capitolo la definiamo come il valore a cui tende la frequenza, la calcoliamo in alcuni casi interessanti (le mani del poker, un dado truccato) e ne ricaviamo le regole di calcolo: la probabilità del complementare, dell'unione, della differenza, la **probabilità condizionata**, la legge della **probabilità totale** e l'**indipendenza**.

La probabilità come limite della frequenza

La frase «la frequenza si avvicina sempre di più a un numero» ha un nome preciso in matematica: *limite*. Prima di usarla, vediamo che cosa significa esattamente.

Richiamo di matematica: il limite di una successione

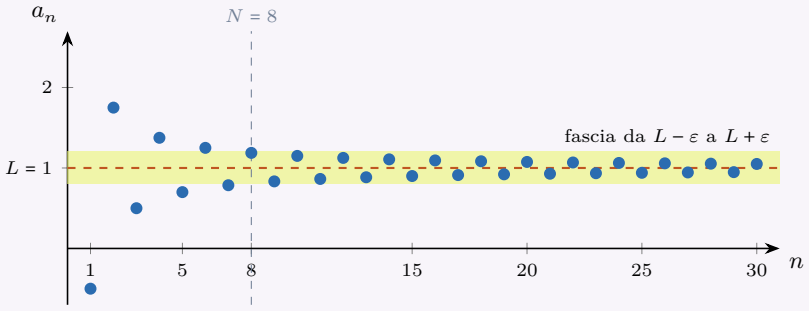
Una **successione** è un elenco infinito di numeri, uno per ogni naturale n: $a_1, a_2, a_3, \dots$ Per esempio $a_n = 1/n$ è la successione $1, \frac{1}{2}, \frac{1}{3}, \frac{1}{4}, \dots$, e la frequenza $f_n(A)$ di un evento, calcolata dopo n prove, è una successione.
Si dice che la successione **tende** al numero L (o che ha **limite** L), e si scrive

$$\lim_{n\to\infty} a_n = L \qquad \text{oppure} \qquad a_n \to L \text{ per } n \to \infty,$$

se i suoi termini si avvicinano a L **quanto si vuole** e **per sempre**. In modo preciso: per quanto stretta si scelga una fascia attorno a L, cioè per qualsiasi tolleranza $\varepsilon > 0$, da un certo indice N in poi *tutti* i termini stanno nella fascia:

$$|a_n - L| < \varepsilon \qquad \text{per ogni } n \geq N.$$

Il simbolo $|a_n - L|$ è la distanza fra a_n e L (il valore assoluto della differenza). Più stretta è la fascia, più avanti bisogna andare per trovare N, ma un N esiste sempre.



Nel disegno $a_n = 1 + (-1)^n \cdot 1{,}5/n$: i termini saltano sopra e sotto il valore $L = 1$, ma sempre più vicino. Con la tolleranza $\varepsilon = 0{,}2$ (la fascia gialla) basta prendere $N = 8$: da lì in poi nessun termine esce più. Con una fascia più stretta servirebbe un N più grande, ma lo si troverebbe comunque.
Altri esempi: $1/n \to 0$; $(n+1)/n = 1 + 1/n \to 1$. Invece la successione $(-1)^n = -1, 1, -1, 1, \dots$ **non** ha limite: salta per sempre fra due valori e non si avvicina a nessun numero.

Ora possiamo dare la definizione che regge tutta la prima parte del corso.

Probabilità (definizione frequentista)

Dato uno spazio campione discreto Ω e un suo sottoinsieme (evento) A, la **probabilità** che si verifichi A è il limite della frequenza relativa di A quando il numero di prove tende all'infinito:

$$P(A) = \lim_{n\to\infty} \frac{n_A}{n}.$$

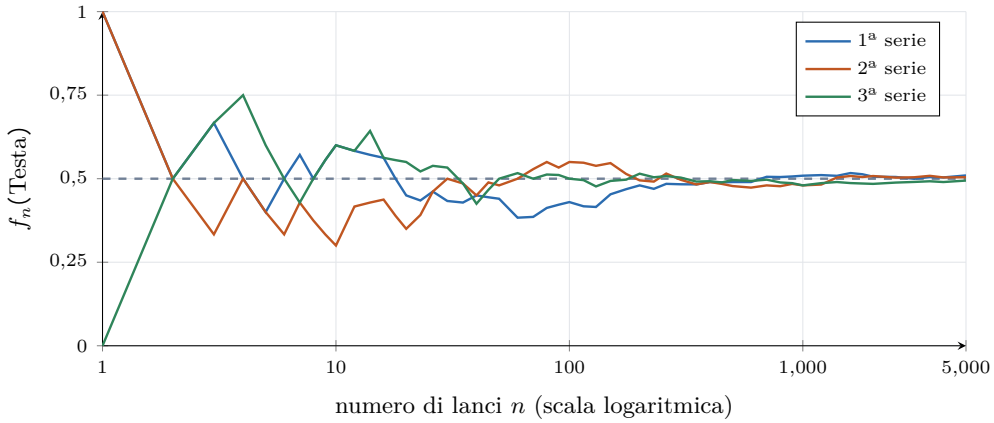


Figura 3.1: *Frequenza di «testa» in tre serie di 5000 lanci di una moneta onesta (simulate). All'inizio le tre curve oscillano moltissimo e sono diverse fra loro; al crescere di n si stringono tutte attorno a $1/2$.*

Un limite un po' speciale

La frequenza non è una successione come $1/n$, scritta una volta per tutte: ogni serie di lanci produce numeri diversi (nella figura le tre curve non coincidono mai). Il limite va quindi inteso in senso «fisico»: è il valore attorno a cui **tutte** le serie finiscono per stringersi. Rendere preciso questo discorso è il compito della *legge dei grandi numeri*, che vedremo nella terza parte del corso; il capitolo seguente aggira il problema con l'approccio assiomatico. Per ora la definizione frequentista basta per capire da dove vengono tutte le regole.

Spazi finiti con eventi equiprobabili

Se gli eventi elementari sono equivalenti, nel senso del capitolo precedente, ora possiamo dire che sono **equiprobabili**: hanno tutti la stessa probabilità $1/|\Omega|$. Per uno spazio finito con eventi elementari equiprobabili vale allora la relazione generale

$$P(A) = \frac{|\Omega_A|}{|\Omega|},$$

dove Ω_A è l'insieme di tutti gli esiti che comportano il verificarsi di A (cioè l'insieme A stesso).

Da ricordare: spazi equiprobabili

$$P(A) = \frac{|A|}{|\Omega|} = \frac{\text{numero dei casi favorevoli}}{\text{numero dei casi possibili}}$$

Con questa formula si rileggono tutti gli esempi già visti: la probabilità che un dado onesto dia un numero pari è $3/6 = 1/2$; quella di ottenere almeno un 6 in due lanci è $11/36$; quella di indovinare un PIN a caso è $1/10\,000$. Il punto delicato è sempre lo stesso: i risultati che si contano devono essere **davvero** equiprobabili.

Esempio 3.1 — L'errore di d'Alembert

Si lanciano due monete. Qual è la probabilità di ottenere una testa e una croce?

Ragionamento sbagliato: i risultati sono tre, «due teste», «due croci», «una testa e una croce», quindi la probabilità è $1/3$. Lo sostenne nel Settecento il matematico Jean-Baptiste d'Alembert.

Ragionamento giusto: i risultati equiprobabili sono le quattro coppie ordinate TT, TC, CT, CC (lo si vede pensando alle due monete come diverse, Capitolo 1). L'evento «una testa e una croce» è $\{TC, CT\}$ e contiene **due** di esse:

$$P(\{TC, CT\}) = \frac{2}{4} = \frac{1}{2}.$$

I tre risultati di d'Alembert esistono, ma non sono equiprobabili: «una testa e una croce» si può ottenere in due modi, gli altri in uno solo. Basta lanciare due monete qualche centinaio di volte per vedere che la frequenza si avvicina a $1/2$, non a $1/3$.

Un esempio completo: i punteggi del poker

Il poker «all'italiana» si gioca con un mazzo ridotto: le carte dal 7 all'asso, cioè 8 valori (7, 8, 9, 10, J, Q, K, A) per 4 semi, per un totale di $8 \times 4 = 32$ carte. Un giocatore riceve 5 carte, estratte senza reinserimento.



In giallo una mano con una **coppia d'assi**: $A\heartsuit$, $A\spadesuit$, $7\diamond$, $9\clubsuit$, $K\heartsuit$.

Figura 3.2: *Il mazzo da 32 carte: 8 valori per 4 semi (cuori, quadri, fiori, picche).*

In tutti i calcoli lo spazio campione è l'insieme delle **cinquine** di carte distinte, in cui l'ordine non conta: sono i sottoinsiemi di 5 carte di un insieme di 32. Se il mazzo è ben mescolato, sono tutti equiprobabili, e

$$|\Omega| = \binom{32}{5} = \frac{32!}{5!\,27!} = \frac{32 \cdot 31 \cdot 30 \cdot 29 \cdot 28}{5 \cdot 4 \cdot 3 \cdot 2} = 201\,376.$$

Ogni probabilità sarà quindi un rapporto con denominatore 201 376: tutto il lavoro sta nel contare il numeratore.

Coppia d'assi e coppia qualsiasi

Esempio 3.2 — Due assi (anche con punteggi più alti)

Sia C_2 l'evento «nella mano ci sono esattamente due assi». Una cinquina di C_2 si costruisce in due passi: si mettono i 4 assi del mazzo su 2 posti ($\binom{4}{2}$ modi) e si sceglie una terna fra le $32 - 4 = 28$ carte che non sono assi ($\binom{28}{3}$ modi). Per il principio fondamentale:

$$|C_2| = \binom{4}{2}\binom{28}{3} = \frac{4!}{2!\,2!} \cdot \frac{28!}{3!\,25!} = 6 \cdot 3\,276 = 19\,656, \qquad P(C_2) = \frac{|C_2|}{|\Omega|} = \frac{19\,656}{201\,376} \approx 0{,}0976.$$

Così però si contano anche mani migliori di una semplice coppia d'assi: il *full* (due assi e tre carte uguali fra loro) e la *doppia coppia* (due assi e un'altra coppia), perché nella terna le carte possono avere lo stesso valore.

Esempio 3.3 — Solo una coppia d'assi

Per escludere i punteggi più alti, le tre carte che non sono assi devono avere tre valori **diversi**. Restano ferme le posizioni dei due assi ($\binom{4}{2}$ modi); poi:

- la terza carta può essere una qualsiasi delle 28 che non sono assi;
- la quarta può essere solo una delle 24 che hanno un valore diverso dalla terza: delle 27 carte non-asso rimaste si tolgono le 3 dello stesso valore della terza;
- la quinta, per lo stesso motivo, solo una delle 20 con valore diverso dalle due precedenti.

In questo modo le tre carte vengono scelte *in ordine*, mentre nella mano l'ordine non conta: ogni terna è stata contata 3! = 6 volte, e bisogna dividere.

$$\left|C_2'\right| = \binom{4}{2} \cdot \frac{28 \cdot 24 \cdot 20}{3!} = \frac{4 \cdot 3}{2} \cdot \frac{28 \cdot 24 \cdot 20}{6} = 28 \cdot 24 \cdot 20 = 13\,440, \qquad P(C_2') = \frac{13\,440}{201\,376} \approx 0{,}067.$$

Verifica con un altro conteggio. Le tre carte non-asso si possono scegliere anche così: prima i tre valori diversi fra i 7 valori che non sono l'asso ($\binom{7}{3} = 35$ modi), poi il seme di ciascuna ($4^3 = 64$ modi). Si ottiene $35 \cdot 64 = 2\,240$ terne, e $6 \cdot 2\,240 = 13\,440$: lo stesso numero.

Se la coppia può essere di qualsiasi valore, la probabilità precedente va moltiplicata per 8: le coppie di 7 (quattro sette su due posti), di 8, …, di re si contano esattamente come quella d'assi, e i valori sono otto. La probabilità di avere una coppia (e niente di meglio) è circa $8 \cdot 0{,}067 \approx 0{,}53$: più di una mano su due.

Almeno tre assi, tris, colore

Esempio 3.4 — Almeno tre assi

L'evento C_3 = «almeno tre assi» è l'unione di due eventi incompatibili: «esattamente tre assi» (i 4 assi su 3 posti, le altre 2 carte fra le 28 non-asso) ed «esattamente quattro assi» (i 4 assi su 4 posti, l'ultima carta fra le 28). Siccome non hanno mani in comune, si sommano:

$$|C_3| = \binom{4}{3}\binom{28}{2} + \binom{4}{4}\binom{28}{1} = 4 \cdot 378 + 1 \cdot 28 = 1\,540, \qquad P(C_3) = \frac{1\,540}{201\,376} \approx 0{,}0076.$$

Esempio 3.5 — Un tris qualsiasi

Sia C_3' l'evento «un tris, con le altre due carte diverse» (quindi non un full e non un poker). Indichiamo con $C_3'(7)$ le mani con esattamente un tris di 7. I tris di 8, 9, …, assi si contano allo stesso modo, quindi $\left|C_3'\right| = 8\ \left|C_3'(7)\right|$.

Per $C_3'(7)$: tre posizioni sono occupate da un 7, e i tre 7 si scelgono fra i quattro in $\binom{4}{3} = \frac{4!}{3!\,1!} = 4$ modi; la quarta carta si sceglie fra le 28 che non sono 7, la quinta fra le 24 di valore diverso dai 7 e dalla quarta. Le ultime due sono state scelte in ordine, quindi si divide per 2! = 2:

$$\left|C_3'(7)\right| = 4 \cdot \frac{28 \cdot 24}{2} = 1\,344, \qquad P(C_3') = 8 \cdot \frac{1\,344}{201\,376} = 8 \cdot 0{,}006674 \approx 0{,}0534.$$

Esempio 3.6 — Colore

Sia C_p l'evento «colore di picche», cioè cinque carte di picche. Ci sono 8 carte di picche da distribuire su 5 posti, con ordine inessenziale:

$$|C_p| = \binom{8}{5} = \frac{8 \cdot 7 \cdot 6}{3!} = 56, \qquad P(C_p) = \frac{56}{201\,376} \approx 0{,}00028.$$

(Si è usata la simmetria $\binom{8}{5} = \binom{8}{3}$.) La probabilità di un colore qualsiasi è $4 \cdot P(C_p) \approx 0{,}0011$. Questo conteggio include però le **scale reali**, cioè le cinque carte consecutive dello stesso seme, che valgono di più. Per ogni seme ce ne sono 5, dalla minima ($A, 7, 8, 9, 10$, con l'asso che vale come carta più bassa) alla massima ($10, J, Q, K, A$). Togliendole:

$$|C_p| = 56 - 5 = 51, \qquad P(C_p) = \frac{51}{201\,376} \approx 0{,}00025,$$

e la probabilità di un colore qualsiasi senza scale reali è $4 \cdot 0{,}00025 \approx 0{,}001$.

Mano	**Casi favorevoli**	**Probabilità**
una coppia (e niente di meglio)	$8 \cdot 13\,440 = 107\,520$	0,534
tris (non full né poker)	$8 \cdot 1\,344 = 10\,752$	0,053
almeno tre assi	1 540	0,0076
colore (senza scale reali)	$4 \cdot 51 = 204$	0,001

Tabella 3.1: *Alcune mani del poker con 32 carte, su* $|\Omega| = 201\,376$ *mani possibili. Nel poker vale di più la mano più rara: un colore è circa cinquanta volte più raro di un tris.*

Quando i risultati non sono equiprobabili

Togliamo ora l'ipotesi che gli eventi elementari siano equiprobabili. Sia Ω uno spazio campione discreto (finito o numerabile). La definizione di probabilità data prima vale ancora:

a) $A \subseteq \Omega$ è un evento e si conducono n esperimenti;

b) $n_A = n_A(n)$ è il numero di volte in cui A si verifica;

c) frequenza relativa e probabilità sono

$$f_n(A) = \frac{n_A}{n}, \qquad P(A) = \lim_{n\to\infty} f_n(A) = \lim_{n\to\infty} \frac{n_A}{n}.$$

La differenza con il caso precedente è che ora **non** è più vero, in generale, che $n_A \simeq n\,|A| \,/\, |\Omega|$. Quando gli eventi elementari non sono equiprobabili, un evento ha una «misura» diversa da quella ordinaria, data dal numero dei suoi elementi: due eventi con lo stesso numero di elementi ($|A| = |B|$) possono avere pesi diversi, e le tecniche di conteggio non bastano più a calcolare le probabilità.

Esempio 3.7 — Un dado truccato

Un dado è truccato in modo che il risultato 1 esca **5 volte su 6**; le altre cinque facce sono ugualmente probabili fra loro. Si lancia una volta, quindi $\Omega = \{1,2,3,4,5,6\}$. Siano $A = \{2,4,6\}$ (pari) e $B = \{1,3,5\}$ (dispari): hanno entrambi 3 elementi.

Se n_i è il numero di volte (su n prove) in cui esce la faccia i, il trucco dice che l'1 esce cinque volte più spesso di tutte le altre facce messe insieme:

$$\sum_{i=1}^{6} n_i = n, \qquad n_1 \simeq 5 \sum_{i=2}^{6} n_i \quad \Longrightarrow \quad f_n(1) = \frac{n_1}{n} \simeq 5 \sum_{i=2}^{6} f_n(i).$$

Le frequenze di tutte le facce sommano a 1 (dividendo la prima uguaglianza per n), quindi

$$f_n(1) + \sum_{i=2}^{6} f_n(i) = 1 \quad \Longrightarrow \quad f_n(1) + \frac{1}{5} f_n(1) = f_n(1)\left(1 + \frac{1}{5}\right) = 1 \quad \Longrightarrow \quad f_n(1) \simeq \frac{5}{6}.$$

Il restante $1 - \frac{5}{6} = \frac{1}{6}$ si divide in parti uguali fra le altre cinque facce: $f_n(2) = f_n(3) = \cdots = f_n(6) \simeq \dfrac{1 - 5/6}{5} = \dfrac{1}{30}$. Passando al limite:

$$P(1) = \frac{5}{6}, \qquad P(i) = \frac{1}{30} \quad i = 2,3,4,5,6.$$

Gli eventi A e B si verificano quando esce una delle loro facce, quindi le frequenze si sommano:

$$f_n(A) = \frac{n_2 + n_4 + n_6}{n} = f_n(2) + f_n(4) + f_n(6) \longrightarrow \frac{3}{30} = \frac{1}{10},$$

$$f_n(B) = \frac{n_1 + n_3 + n_5}{n} = f_n(1) + f_n(3) + f_n(5) \longrightarrow \frac{5}{6} + \frac{2}{30} = \frac{9}{10}.$$

In questo caso $P(B)$ ha una misura molto maggiore di $P(A)$, nove volte superiore, anche se i due eventi hanno lo stesso numero di elementi.

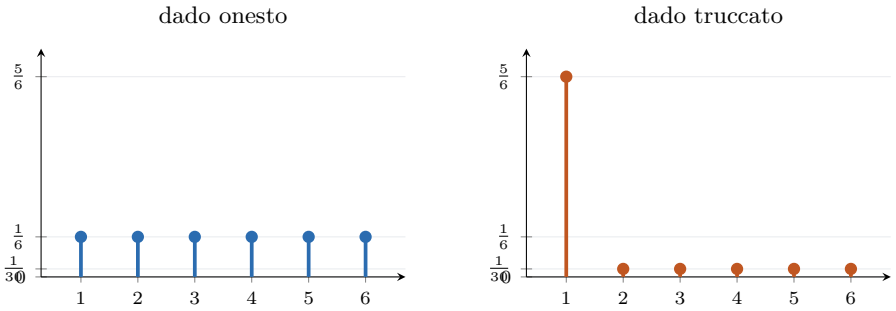


Figura 3.3: *Le probabilità delle sei facce. Nel dado onesto si distribuiscono in parti uguali; in quello truccato quasi tutta la probabilità sta sull'1.*

LE PROPRIETÀ DELLA PROBABILITÀ

Le frequenze relative obbediscono a regole semplicissime, che si ricavano contando. Passando al limite, le stesse regole valgono per le probabilità. Per «passare al limite» serve sapere come si comportano i limiti con le operazioni.

Richiamo di matematica: le regole dei limiti

Se due successioni hanno limite, $a_n \to a$ e $b_n \to b$, allora:

$$a_n + b_n \to a + b, \qquad a_n - b_n \to a - b, \qquad c \cdot a_n \to c \cdot a \ \ (c \text{ costante}), \qquad a_n \cdot b_n \to a \cdot b,$$

e, se $b \neq 0$, anche $a_n / b_n \to a/b$. In parole: il limite di una somma è la somma dei limiti, e così via. Inoltre una successione costante ($a_n = c$ per ogni n) tende a c. Infine, se due successioni sono sempre uguali, hanno lo stesso limite: un'uguaglianza fra frequenze, vera per ogni n, diventa un'uguaglianza fra probabilità.

Siano A e B due eventi, n_A e n_B i loro numeri di occorrenze su n prove e $f_n(A)$, $f_n(B)$ le frequenze relative (entrambe ≥ 0, chiaramente).

Teorema 3.1 — Proprietà della frequenza e della probabilità

Per due eventi qualsiasi A e B:

a) **eventi complementari**: $P(\overline{A}) = 1 - P(A)$;
b) **unione**: $P(A \cup B) = P(A) + P(B) - P(A \cap B)$;
c) **differenza**: $P(A \setminus B) = P(A) - P(A \cap B)$;
d) **evento certo e impossibile**: $P(\Omega) = 1$ e $P(\varnothing) = 0$.

Inoltre $0 \leq P(A) \leq 1$ per ogni evento A.

Dimostrazione

Passo 1 — Complementare. In ogni prova o si verifica A o si verifica $\overline{A}$, mai entrambi: le prove in cui si verifica $\overline{A}$ sono tutte le altre, $n - n_A$. Quindi

$$f_n(\overline{A}) = \frac{n - n_A}{n} = 1 - f_n(A) \quad \Longrightarrow \quad P(\overline{A}) = 1 - P(A).$$

Passo 2 — Unione. Se si sommano n_A e n_B, le prove in cui si sono verificati *entrambi* gli eventi (quelle di $A \cap B$) vengono contate due volte, una in n_A e una in n_B. Per contarle una volta sola bisogna toglierle una volta:

$$f_n(A \cup B) = \frac{n_{A\cup B}}{n} = \frac{n_A + n_B - n_{A\cap B}}{n} = f_n(A) + f_n(B) - f_n(A \cap B)$$

e, passando al limite, $P(A \cup B) = P(A) + P(B) - P(A \cap B)$.

Passo 3 — Differenza. Perché si verifichi A ma non B, dalle n_A prove in cui si verifica A vanno tolte quelle in cui si verificano entrambi:

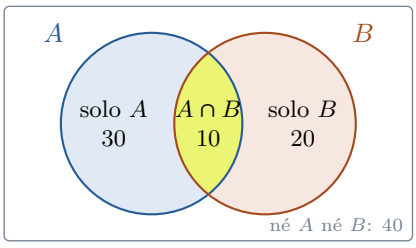
$$f_n(A \setminus B) = f_n(A \cap \overline{B}) = \frac{n_A - n_{A\cap B}}{n} = f_n(A) - f_n(A \cap B) \quad \Longrightarrow \quad P(A \setminus B) = P(A) - P(A \cap B).$$

Passo 4 — Certo e impossibile. Ω si verifica in tutte le prove, $\varnothing$ in nessuna:

$$f_n(\Omega) = \frac{n}{n} = 1 \implies P(\Omega) = 1, \qquad f_n(\varnothing) = \frac{0}{n} = 0 \implies P(\varnothing) = 0.$$

Passo 5 — Fra 0 e 1. Per ogni n vale $0 \leq n_A \leq n$, quindi $0 \leq f_n(A) \leq 1$, e il limite di numeri compresi fra 0 e 1 è ancora compreso fra 0 e 1.

■



Su $n = 100$ prove: A si è verificato $n_A = 30 + 10 = 40$ volte, B si è verificato $n_B = 10 + 20 = 30$ volte. Ma $A \cup B$ si è verificato $30+10+20 = 60$ volte, non $40 + 30 = 70$: le 10 prove di $A \cap B$ sono state contate due volte. Infatti $60 = 40 + 30 - 10$.

Figura 3.4: *Perché nell'unione si sottrae l'intersezione. In ogni regione è scritto quante volte si è verificata.*

La proprietà b) è nota anche come **sub-additività**: siccome $P(A \cap B) \geq 0$, ne segue $P(A \cup B) \leq P(A) + P(B)$, con il segno di uguale esattamente quando $P(A \cap B) = 0$, per esempio se A e B sono **incompatibili**. Per gli eventi incompatibili, quindi, **le probabilità si sommano**.

Esempio 3.8 — L'unione e il complementare al lavoro

- Un dado onesto: la probabilità di ottenere un numero pari *oppure* almeno 5 è

$$P(\{2,4,6\} \cup \{5,6\}) = \frac{3}{6} + \frac{2}{6} - \frac{1}{6} = \frac{4}{6} = \frac{2}{3},$$

  dove si toglie $P(\{6\}) = 1/6$ perché il 6 è sia pari sia almeno 5. In effetti l'unione è $\{2,4,5,6\}$.

- Due lanci di un dado: «almeno un 6» è l'unione di «6 al primo lancio» e «6 al secondo», che si verificano insieme solo con (6,6):

$$P(\text{almeno un 6}) = \frac{6}{36} + \frac{6}{36} - \frac{1}{36} = \frac{11}{36},$$

  lo stesso numero trovato contando le caselle nel capitolo precedente. Ancora più rapido è passare al complementare: «nessun 6» vuol dire 5 possibilità per ogni lancio, $5 \cdot 5 = 25$ coppie, e $P(\text{almeno un 6}) = 1 - \frac{25}{36} = \frac{11}{36}$.

Il trucco del complementare

Quando un evento contiene la parola «almeno», spesso conviene calcolare la probabilità del suo complementare, che contiene la parola «nessuno», e sottrarla da 1. Con dieci lanci di un dado, per esempio, «almeno un 6» richiederebbe di considerare un 6, due 6, …, dieci 6; «nessun 6» invece è un solo conto: 5^{10} sequenze su 6^{10}, e $P(\text{almeno un 6}) = 1 - (5/6)^{10} \approx 0{,}84$.

Probabilità condizionata

Spesso si ha un'informazione parziale sul risultato: «è uscito un numero pari», «il pacchetto è arrivato in ritardo». Come cambia la probabilità degli altri eventi, sapendo questo?

Siano A e B due eventi che, in n esperimenti, si verificano n_A e n_B volte ($n_B > 0$). Definiamo la **frequenza di A condizionata a B**, $f_n(A \mid B)$, come il rapporto fra il numero di volte in cui si verificano *entrambi* ($n_{A\cap B}$) e il numero di volte in cui si verifica B:

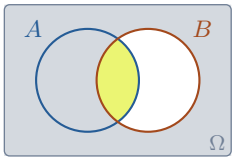
$$f_n(A \mid B) = \frac{n_{A\cap B}}{n_B} = \frac{n_{A\cap B}}{n} \cdot \frac{n}{n_B} = \frac{f_n(A \cap B)}{f_n(B)}.$$

In altre parole, **restringiamo il nostro campione** (il nostro «mondo») ai soli n_B esperimenti in cui si è verificato B, e fra questi guardiamo in quanti si è verificato anche A. Passando al limite (il rapporto dei limiti si può fare perché $P(B) > 0$):

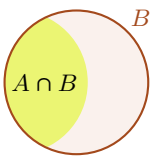
Probabilità condizionata

Se $P(B) > 0$, la **probabilità di A condizionata a B** (o «di A dato B») è

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}.$$



si scarta tutto ciò che sta fuori da B



sapendo che è successo B: il nuovo mondo è B, e di A resta solo $A \cap B$

Figura 3.5: *La probabilità condizionata: si scarta tutto ciò che sta fuori da B (in grigio) e si misura quanta parte di B è occupata da A.*

Esempio 3.9 — Condizionare un dado

Si lancia un dado onesto.

- Sapendo che è uscito un numero pari, qual è la probabilità che sia il 6?

$$P(\{6\} \mid \text{pari}) = \frac{P(\{6\} \cap \{2,4,6\})}{P(\{2,4,6\})} = \frac{1/6}{3/6} = \frac{1}{3}.$$

  Ha senso: fra i tre pari, il 6 è uno.

- Sapendo che è uscito un numero non superiore a 3, qual è la probabilità che sia dispari?

$$P(\text{dispari} \mid \{1,2,3\}) = \frac{P(\{1,3\})}{P(\{1,2,3\})} = \frac{2/6}{3/6} = \frac{2}{3}.$$

- Viceversa $P(\text{pari} \mid \{6\}) = 1$: se è uscito 6, è certamente uscito un pari. Il condizionamento **non è simmetrico**: $P(A \mid B)$ e $P(B \mid A)$ sono, in generale, numeri diversi.

La legge della probabilità composta

Scambiando i ruoli di A e B, la stessa definizione dà

$$P(B \mid A) = \frac{P(A \cap B)}{P(A)}, \qquad P(A) > 0.$$

Moltiplicando ciascuna delle due definizioni per il suo denominatore si ottiene una formula per l'intersezione.

Da ricordare: legge della probabilità composta

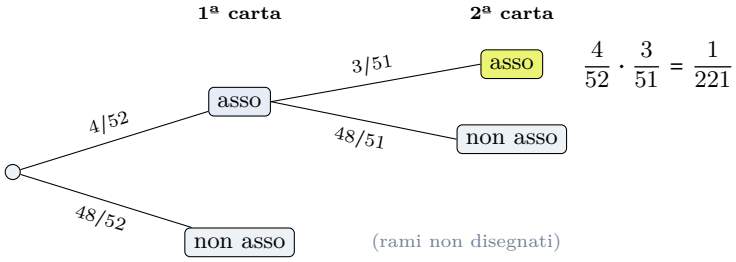
$$P(A \cap B) = P(B \mid A)\,P(A) = P(A \mid B)\,P(B)$$

È utilissima quando un esperimento avviene **in due tempi**: la probabilità che succedano entrambe le cose è la probabilità della prima, moltiplicata per la probabilità della seconda *sapendo* che la prima è successa.

Esempio 3.10 — Due assi di fila

Da un mazzo di 52 carte se ne estraggono due, senza reinserimento. Qual è la probabilità che siano due assi? Siano A_1 = «la prima è un asso» e A_2 = «la seconda è un asso». Alla prima estrazione gli assi sono 4 su 52; se la prima è stata un asso, alla seconda restano 3 assi su 51 carte:

$$P(A_1 \cap A_2) = P(A_1)\,P(A_2 \mid A_1) = \frac{4}{52} \cdot \frac{3}{51} = \frac{12}{2\,652} = \frac{1}{221} \approx 0{,}0045.$$



Lo stesso risultato si ottiene contando: le coppie di assi sono $\binom{4}{2} = 6$ su $\binom{52}{2} = 1\,326$ coppie possibili, e $6/1\,326 = 1/221$. Nell'albero la probabilità di un percorso è il prodotto delle probabilità dei suoi rami: è la legge della probabilità composta disegnata.

La legge della probabilità totale

Un'importante conseguenza della probabilità condizionata permette di calcolare la probabilità di un evento «spezzandolo» in casi.

Partizione

Gli eventi $E_1, E_2, \ldots, E_M$, cioè $\{E_i\}_{i=1}^{M}$, formano una **partizione** di Ω se **coprono** tutto Ω e sono **a due a due incompatibili**:

$$\bigcup_{i=1}^{M} E_i = \Omega, \qquad E_i \cap E_j = \varnothing \quad \text{per } i \neq j.$$

In ogni prova si verifica uno e un solo E_i: sono i «casi» in cui si divide il mondo.

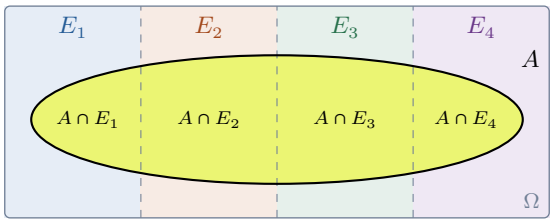


Figura 3.6: *Una partizione di Ω in quattro casi. L'evento A viene tagliato in quattro pezzi $A \cap E_i$, che non si sovrappongono: la probabilità di A è la somma delle probabilità dei pezzi.*

Teorema 3.2 — Legge della probabilità totale

Se $\{E_i\}_{i=1}^{M}$ è una partizione di Ω e $A \subseteq \Omega$ è un evento qualsiasi, allora

$$P(A) = \sum_{i=1}^{M} P(A \cap E_i) = \sum_{i=1}^{M} P(A \mid E_i)\, P(E_i).$$

Dimostrazione

Passo 1 — Si «ritaglia» A con la partizione. A è contenuto in Ω, quindi $A = A \cap \Omega$; e Ω è l'unione degli E_i. Per la proprietà distributiva (Teorema 1.4):

$$P(A) = P(A \cap \Omega) = P\left(A \cap \bigcup_{i=1}^{M} E_i\right) = P\left(\bigcup_{i=1}^{M} (A \cap E_i)\right).$$

Passo 2 — I pezzi non si sovrappongono. Siccome $E_i \cap E_j = \varnothing$ per $i \neq j$, anche i pezzi di A sono incompatibili: $(A \cap E_i) \cap (A \cap E_j) \subseteq E_i \cap E_j = \varnothing$.

Passo 3 — Si sommano le probabilità. Per eventi incompatibili la probabilità dell'unione è la somma delle probabilità (proprietà b) con $P(A \cap B) = 0$, applicata un pezzo alla volta):

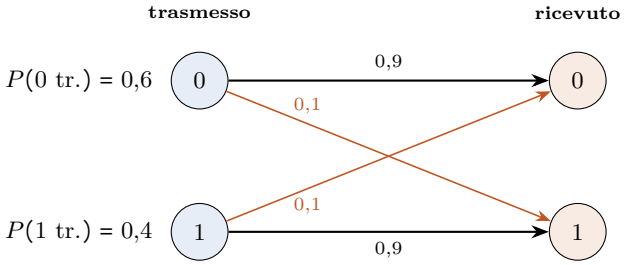
$$P(A) = \sum_{i=1}^{M} P(A \cap E_i).$$

Passo 4 — Si usa la probabilità composta. Ogni pezzo si riscrive come $P(A \cap E_i) = P(A \mid E_i)\, P(E_i)$, e si ottiene la seconda forma.

■

Esempio 3.11 — Un canale binario

Una sorgente trasmette il bit 0 con probabilità 0,6 e il bit 1 con probabilità 0,4. Il canale è rumoroso: qualunque bit venga trasmesso, con probabilità 0,1 arriva invertito. Qual è la probabilità di ricevere un 1?



I due casi «è stato trasmesso 0» ed «è stato trasmesso 1» formano una partizione. Per la legge della probabilità totale:

$$P(1\text{ ric.}) = P(1\text{ ric.} \mid 0\text{ tr.})\,P(0\text{ tr.}) + P(1\text{ ric.} \mid 1\text{ tr.})\,P(1\text{ tr.}) = 0{,}1 \cdot 0{,}6 + 0{,}9 \cdot 0{,}4 = 0{,}06 + 0{,}36 = 0{,}42.$$

Un 1 si può ricevere in due modi: perché è stato trasmesso 1 ed è arrivato giusto, oppure perché è stato trasmesso 0 ed è stato invertito. La legge somma i due modi, ciascuno pesato con la probabilità del suo caso. Nel prossimo capitolo ci chiederemo il contrario: *ricevuto* un 1, qual è la probabilità che sia stato *trasmesso* un 1?

Eventi indipendenti

Due eventi A e B si dicono **indipendenti** quando il verificarsi di uno non ha alcuna influenza sul verificarsi o meno dell'altro. Con le frequenze: sapere che si è verificato B non cambia la frequenza di A, e viceversa,

$$f_n(A \mid B) \simeq f_n(A) \qquad \text{e} \qquad f_n(B \mid A) \simeq f_n(B).$$

Usando la legge della probabilità composta, in questo caso

$$f_n(A \cap B) = f_n(A)\,f_n(B \mid A) = f_n(B)\,f_n(A \mid B) \simeq f_n(A)\,f_n(B),$$

e passando al limite si arriva alla definizione.

Eventi indipendenti

Due eventi A e B sono **indipendenti** se (e solo se)

$$P(A \cap B) = P(A)\,P(B).$$

Teorema 3.3 — Indipendenza e probabilità condizionata

Se $P(B) > 0$, gli eventi A e B sono indipendenti se e solo se $P(A \mid B) = P(A)$. Allo stesso modo, se $P(A) > 0$, sono indipendenti se e solo se $P(B \mid A) = P(B)$.

Dimostrazione

Passo 1 — Da indipendenti a condizionata. Se $P(A \cap B) = P(A)\,P(B)$, allora

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} = \frac{P(A)\,P(B)}{P(B)} = P(A).$$

Passo 2 — Da condizionata a indipendenti. Se $P(A \mid B) = P(A)$, per la probabilità composta $P(A \cap B) = P(A \mid B)\,P(B) = P(A)\,P(B)$.

Passo 3 — Scambiando i ruoli. Lo stesso ragionamento, con A e B scambiati, vale per $P(B \mid A)$.

■

La forma con il prodotto è preferibile come definizione perché è simmetrica e funziona anche quando una delle due probabilità è nulla (la probabilità condizionata a un evento di probabilità zero non è definita).

Esempio 3.12 — Due lanci di un dado

I due lanci di un dado onesto sono indipendenti: il primo non può influenzare il secondo. Per ogni coppia (i, j):

$$P(\{(i,j)\}) = P(\text{primo} = i)\,P(\text{secondo} = j) = \frac{1}{6} \cdot \frac{1}{6} = \frac{1}{36},$$

che è proprio la probabilità di ciascuna delle 36 coppie equiprobabili del capitolo precedente. Allo stesso modo

$$P(\text{primo pari e secondo} = 6) = \frac{1}{2} \cdot \frac{1}{6} = \frac{1}{12},$$

e in effetti le coppie favorevoli sono (2,6), (4,6), (6,6), cioè 3 su 36.

Esempio 3.13 — Indipendenti anche senza «separazione fisica»

In un **solo** lancio di un dado onesto, siano $A = \{2, 4, 6\}$ (pari) e $B = \{1, 2\}$ (non più di 2). Allora $A \cap B = \{2\}$ e

$$P(A \cap B) = \frac{1}{6} = \frac{1}{2} \cdot \frac{1}{3} = P(A)\,P(B)\,:$$

i due eventi sono indipendenti. Sapere che è uscito 1 o 2 non cambia la probabilità che sia uscito un pari: è $1/2$ prima ed è $1/2$ dopo (uno dei due casi rimasti è pari). L'indipendenza è una proprietà dei *numeri*, non solo della «fisica» dell'esperimento.

Indipendenti non vuol dire incompatibili

È un errore molto comune confondere le due parole, che dicono quasi il contrario. Se A e B sono **incompatibili** ($A \cap B = \varnothing$) e hanno entrambi probabilità positiva, allora $P(A \cap B) = 0 \neq P(A)\,P(B)$: sono **dipendenti**, e in modo fortissimo, perché se si verifica uno sicuramente l'altro non si verifica. Testa e croce nello stesso lancio sono incompatibili; testa al primo lancio e testa al secondo sono indipendenti.

In sintesi

- La **probabilità** di un evento è il limite della sua frequenza relativa: $P(A) = \lim_{n\to\infty} n_A/n$. Se gli eventi elementari sono equiprobabili, $P(A) = |A| \,/\, |\Omega|$ (casi favorevoli su casi possibili), purché i casi contati siano davvero equiprobabili.
- Se non lo sono, eventi con lo stesso numero di elementi possono avere probabilità diverse (dado truccato).
- Regole: $P(\overline{A}) = 1 - P(A)$; $P(A \cup B) = P(A) + P(B) - P(A \cap B)$; $P(A \setminus B) = P(A) - P(A \cap B)$; $P(\Omega) = 1$, $P(\varnothing) = 0$; per eventi incompatibili le probabilità si sommano.
- Probabilità condizionata: $P(A \mid B) = P(A \cap B)/P(B)$, cioè si restringe il mondo a B. Probabilità composta: $P(A \cap B) = P(B \mid A)\, P(A) = P(A \mid B)\, P(B)$.
- Probabilità totale: se gli E_i formano una partizione, $P(A) = \sum_i P(A \mid E_i)\, P(E_i)$.
- A e B sono indipendenti se $P(A \cap B) = P(A)\, P(B)$, cioè se sapere che uno si è verificato non cambia la probabilità dell'altro. Indipendenti non vuol dire incompatibili.

L'APPROCCIO ASSIOMATICO

La definizione frequentista ha un grande pregio: dice che cosa *significa* una probabilità, e da lì abbiamo ricavato tutte le regole di calcolo. Ha però anche dei limiti. Richiede di ripetere l'esperimento infinite volte, cosa che nessuno può fare; la frequenza non è una successione fissata, ma cambia da una serie di prove all'altra; e ci sono eventi che non si possono ripetere affatto («domani pioverà», «questo disco si guasterà entro un anno»).

Nel 1933 il matematico russo Andrej Kolmogorov propose una strada diversa, che è quella usata ancora oggi. Invece di dire che cosa *è* la probabilità, si elencano poche **regole** (gli **assiomi**) che una probabilità deve rispettare, scelte in modo che le frequenze le rispettino. Tutto il resto si **dimostra** a partire da quelle regole. Le formule sono le stesse del capitolo precedente, ma ora poggiano su basi solide. Prima degli assiomi, però, bisogna stabilire con precisione **quali** sottoinsiemi di Ω hanno diritto a una probabilità.

ALGEBRE DI EVENTI

Le operazioni fra eventi (unione, complementare, intersezione) devono produrre ancora eventi: se sappiamo calcolare la probabilità di A e di B, vogliamo poter calcolare anche quella di «A oppure B» e di «non A». La famiglia degli eventi deve quindi essere **chiusa** rispetto a queste operazioni: applicandole, non se ne deve uscire.

Algebra di eventi

Si consideri una famiglia $\mathcal{E}$ di sottoinsiemi di Ω (non vuota). $\mathcal{E}$ si chiama **algebra** di sottoinsiemi di Ω, o **algebra di eventi**, se gode di due proprietà:

a) è **chiusa rispetto all'unione**: se $A_1, A_2 \in \mathcal{E}$, allora $A_1 \cup A_2 \in \mathcal{E}$;
b) è **chiusa rispetto alla complementazione**: se $A_1 \in \mathcal{E}$, allora $\overline{A_1} \in \mathcal{E}$.

Quando lo spazio è infinito (come i pacchetti in coda al router, $\Omega = \mathbb{N}_0$) ci servono anche unioni di **infiniti** eventi. Per esempio «il numero di pacchetti è pari» è l'unione degli infiniti eventi elementari $\{0\}, \{2\}, \{4\}, \ldots$

Richiamo di matematica: l'unione di infiniti insiemi

Data una successione di insiemi $B_1, B_2, B_3, \ldots$ (una famiglia *numerabile*: uno per ogni naturale), la loro unione

$$\bigcup_{n=1}^{\infty} B_n = B_1 \cup B_2 \cup B_3 \cup \cdots$$

è l'insieme degli elementi che stanno in **almeno uno** dei B_n. Il simbolo ∞ in alto non è un numero: dice solo che l'indice non si ferma mai. Per esempio, con $B_n = \{2n\}$:

$$\bigcup_{n=0}^{\infty} \{2n\} = \{0\} \cup \{2\} \cup \{4\} \cup \cdots = \{0, 2, 4, 6, \ldots\},$$

l'insieme dei numeri pari. Allo stesso modo $\bigcap_{n=1}^{\infty} B_n$ contiene gli elementi che stanno in **tutti** i B_n.

Sigma-algebra

Un'algebra $\mathcal{E}$ è una **σ-algebra** se, oltre a essere chiusa rispetto alla complementazione e all'unione, è chiusa anche rispetto all'unione di una infinità numerabile di suoi elementi:

$$B_1, B_2, B_3, \ldots \in \mathcal{E} \quad \Longrightarrow \quad \bigcup_{n=1}^{\infty} B_n \in \mathcal{E}.$$

La lettera greca σ (*sigma* minuscola) ricorda la «S» di somma: nella tradizione matematica segnala che l'operazione si può ripetere un'infinità numerabile di volte. Negli spazi finiti la distinzione non conta (le unioni di infiniti eventi si riducono a unioni di un numero finito di eventi diversi), quindi ogni algebra è anche una σ-algebra.

LE PROPRIETÀ DELLE ALGEBRE

Dalle due sole proprietà della definizione seguono tutte le altre: un'algebra è chiusa anche rispetto all'intersezione e alla differenza, e contiene sempre Ω e $\varnothing$.

Teorema 4.1 — Proprietà delle algebre

Sia $\mathcal{E}$ un'algebra di eventi e siano $A, B \in \mathcal{E}$. Allora:

a) $A \cap B \in \mathcal{E}$ (chiusura rispetto all'intersezione);
b) $A \setminus B \in \mathcal{E}$ (chiusura rispetto alla differenza);
c) $\Omega \in \mathcal{E}$ e $\varnothing \in \mathcal{E}$.

Dimostrazione

Passo 1 — Intersezione, con De Morgan. Per la seconda legge di De Morgan $\overline{A \cap B} = \overline{A} \cup \overline{B}$; facendo il complementare di entrambi i membri:

$$A \cap B = \overline{\overline{A} \cup \overline{B}}.$$

Ora si costruisce il secondo membro un passo alla volta, restando sempre dentro $\mathcal{E}$: A e B stanno in $\mathcal{E}$, quindi anche $\overline{A}$ e $\overline{B}$ (chiusura rispetto al complementare); allora anche la loro unione $\overline{A} \cup \overline{B}$ (chiusura rispetto all'unione); e infine anche il complementare dell'unione, che è $A \cap B$.

Passo 2 — Differenza. Per il Teorema 1.1, $A \setminus B = A \cap \overline{B}$. Siccome $B \in \mathcal{E}$, anche $\overline{B} \in \mathcal{E}$; e l'intersezione di due elementi di $\mathcal{E}$ sta in $\mathcal{E}$ per il passo precedente.

Passo 3 — Ω e $\varnothing$. $\mathcal{E}$ non è vuota, quindi contiene almeno un evento A, e con esso $\overline{A}$. Allora contiene $A \cup \overline{A} = \Omega$ e il suo complementare $\overline{\Omega} = \varnothing$.

■

Teorema 4.2 — La più piccola algebra che contiene un evento

Se A è un evento qualsiasi, la più piccola algebra che contiene A è

$$\mathcal{E} = \left\{A, \overline{A}, \Omega, \varnothing\right\}.$$

Dimostrazione

Passo 1 — Quei quattro insiemi devono esserci. Un'algebra che contiene A contiene $\overline{A}$, per la chiusura rispetto al complementare; contiene $A \cup \overline{A} = \Omega$, per la chiusura rispetto all'unione; e contiene $\varnothing = \overline{\Omega}$, di nuovo per la chiusura rispetto al complementare. Quindi ogni algebra che contiene A contiene almeno i quattro insiemi.

Passo 2 — E bastano. Resta da verificare che i quattro insiemi formano già un'algebra, senza bisogno di aggiungerne altri. I complementari restano dentro: $A \leftrightarrow \overline{A}$ e $\Omega \leftrightarrow \varnothing$. Le unioni pure:

$\cup$	A	$\overline{A}$	Ω	$\varnothing$
A	A	Ω	Ω	A
$\overline{A}$	Ω	$\overline{A}$	Ω	$\overline{A}$
Ω	Ω	Ω	Ω	Ω
$\varnothing$	A	$\overline{A}$	Ω	$\varnothing$

Ogni casella della tabella è uno dei quattro insiemi: la famiglia è chiusa rispetto all'unione e al complementare, cioè è un'algebra.

■

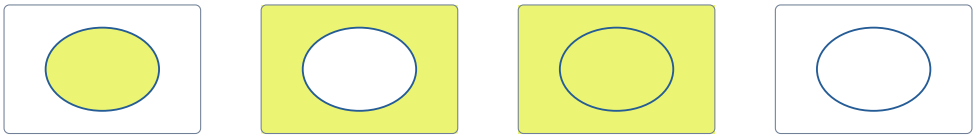


Figura 4.1: *I quattro elementi della più piccola algebra che contiene A (in giallo l'insieme indicato sotto).*

Un'algebra è un «livello di informazione»

Si lancia un dado e un amico ci dice soltanto se il risultato è pari o dispari. Con questa informazione possiamo decidere se si è verificato {2,4,6}, {1,3,5}, Ω o $\varnothing$, ma non se si è verificato {6}: gli eventi che riusciamo a «vedere» sono proprio i quattro dell'algebra generata da $A = \{2, 4, 6\}$. Chi invece vede il dado può decidere su qualsiasi sottoinsieme di Ω: la sua algebra è l'insieme delle parti $\mathcal{P}(\Omega)$, con $2^6 = 64$ eventi. Più informazione vuol dire un'algebra più ricca.

Gli assiomi di Kolmogorov

Ora possiamo dire che cos'è una probabilità: una funzione che a ogni evento dell'algebra associa un numero fra 0 e 1, e che rispetta tre regole.

Legge di probabilità

Si definisce **legge di probabilità** una funzione con dominio $\mathcal{E}$ e codominio $[0, 1]$,

$$P : A \in \mathcal{E} \longmapsto P(A) \in [0, 1],$$

che soddisfi gli **assiomi di Kolmogorov**:

1) **non negatività**: $P(A) \geq 0$ per ogni $A \in \mathcal{E}$, in simboli $\forall A \in \mathcal{E}$;
2) **normalizzazione**: $P(\Omega) = 1$;
3) **additività**: se A e B sono incompatibili ($A \cap B = \varnothing$), allora $P(A \cup B) = P(A) + P(B)$;

3a) **numerabile additività**: se $\{B_n\}_{n\in\mathbb{N}}$ è una collezione numerabile di eventi a due a due incompatibili ($B_i \cap B_j = \varnothing$ per $i \neq j$), allora

$$P\left(\bigcup_{n=1}^{\infty} B_n\right) = \sum_{n=1}^{\infty} P(B_n).$$

Spazio di probabilità

La terna $(\Omega, \mathcal{E}, P)$, formata dallo spazio campione, da una σ-algebra di eventi e da una legge di probabilità, si chiama **spazio di probabilità**.

Il simbolo $\forall$ (una «A» capovolta, da *All*) si legge «per ogni»: «$P(A) \geq 0 \ \forall A \in \mathcal{E}$» vuol dire che la probabilità di qualsiasi evento è non negativa. L'assioma 3a parla di una somma di infiniti termini, che merita un richiamo.

Richiamo di matematica: le somme infinite (serie)

Che senso ha sommare infiniti numeri $a_1 + a_2 + a_3 + \cdots$? Si sommano i primi N termini, ottenendo le **somme parziali**

$$S_N = \sum_{n=1}^{N} a_n,$$

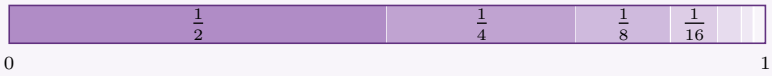
e si guarda dove va S_N quando N cresce. Se le somme parziali hanno un limite S, si dice che la **serie** converge e si scrive $\sum_{n=1}^{\infty} a_n = S$:

$$\sum_{n=1}^{\infty} a_n = \lim_{N \to \infty} \sum_{n=1}^{N} a_n.$$

L'esempio più famoso è la **serie geometrica** di ragione $\frac{1}{2}$:

$$\frac{1}{2} + \frac{1}{4} + \frac{1}{8} + \frac{1}{16} + \cdots = \sum_{n=1}^{\infty} \left(\frac{1}{2}\right)^n = 1.$$

Si vede con un disegno: si prende un segmento lungo 1, se ne colora la metà, poi la metà di quel che resta, poi ancora la metà di quel che resta… La parte colorata non supera mai il segmento, e quella che manca si dimezza a ogni passo: dopo N passi è colorato $S_N = 1 - (1/2)^N$, che tende a 1.



Una serie può anche *non* convergere: $1 + 1 + 1 + \cdots$ cresce senza limite. Quando tutti i termini sono ≥ 0, come le probabilità, la somma infinita o è un numero o è $+\infty$; l'assioma 3a dice in particolare che, per eventi incompatibili, è sempre un numero (non più grande di 1).

Esempio 4.1 — Aspettare la prima testa

Si lancia una moneta onesta finché non esce testa. Sia B_n l'evento «la prima testa esce al lancio n-esimo», cioè $n-1$ croci seguite da una testa. I lanci sono indipendenti, quindi

$$P(B_n) = \underbrace{\frac{1}{2} \cdot \frac{1}{2} \cdots \frac{1}{2}}_{n-1 \text{ croci}} \cdot \frac{1}{2} = \left(\frac{1}{2}\right)^n.$$

Gli eventi $B_1, B_2, \ldots$ sono incompatibili (la prima testa esce a un solo lancio) e la loro unione è «prima o poi esce testa». Per la numerabile additività:

$$P(\text{prima o poi esce testa}) = \sum_{n=1}^{\infty} P(B_n) = \sum_{n=1}^{\infty} \left(\frac{1}{2}\right)^n = 1.$$

Senza l'assioma 3a non potremmo fare questo conto: l'evento è l'unione di *infiniti* eventi, e l'additività semplice (assioma 3) parla solo di due alla volta.

Gli assiomi e le frequenze vanno d'accordo

Gli assiomi non sono stati scelti a caso: sono proprio le proprietà che abbiamo trovato per le frequenze nel capitolo precedente. La frequenza di un evento è ≥ 0, quella di Ω è 1, e se due eventi sono incompatibili il numero di prove in cui si verifica uno dei due è la somma dei due conteggi. Per questo la probabilità frequentista è una legge di probabilità nel senso di Kolmogorov, e tutto ciò che dimostreremo dagli assiomi vale anche per lei.

Come si costruisce una probabilità su uno spazio discreto

Su uno spazio discreto basta assegnare a ogni risultato ω un numero $p(\omega) \geq 0$, con la sola condizione che la somma di tutti sia 1. Per un evento qualsiasi si pone poi $P(A) = \sum_{\omega \in A} p(\omega)$, la somma dei pesi dei suoi risultati. Questa P rispetta gli assiomi: è ≥ 0, vale 1 su Ω e, se due eventi non hanno risultati in comune, i loro pesi si sommano. È esattamente quello che abbiamo fatto con il dado truccato, assegnando 5/6 all'1 e 1/30 alle altre facce.

LE PROPRIETÀ CHE SEGUONO DAGLI ASSIOMI

Ritroviamo ora, **dimostrandole** dagli assiomi, le regole del capitolo precedente. Lo schema è sempre lo stesso: si scrive l'evento come unione di pezzi **incompatibili** e si applica l'additività.

Teorema 4.3 — Eventi complementari ed evento impossibile

Per ogni evento A: $P(\overline{A}) = 1 - P(A)$. In particolare $P(\varnothing) = 0$.

Dimostrazione

Passo 1 — A e $\overline{A}$ si spartiscono Ω. $\Omega = A \cup \overline{A}$, e i due eventi sono incompatibili.

Passo 2 — Si applicano gli assiomi. Per la normalizzazione e l'additività:

$$1 = P(\Omega) = P(A \cup \overline{A}) = P(A) + P(\overline{A}) \quad \Longrightarrow \quad P(\overline{A}) = 1 - P(A).$$

Passo 3 — L'evento impossibile. Con $A = \Omega$: $P(\varnothing) = P(\overline{\Omega}) = 1 - P(\Omega) = 1 - 1 = 0$.

■

Teorema 4.4 — Sottrazione fra eventi

Per due eventi qualsiasi A e B:

$$P(A \setminus B) = P(A \cap \overline{B}) = P(A) - P(A \cap B).$$

È la probabilità che si verifichi A e non B (cioè A meno B).

Dimostrazione

Passo 1 — Si taglia A in due pezzi. $A = A \cap \Omega = A \cap (B \cup \overline{B})$ e, per la proprietà distributiva,

$$A = (A \cap B) \cup (A \cap \overline{B}).$$

Passo 2 — I pezzi sono incompatibili. Uno sta dentro B, l'altro fuori: $(A \cap B) \cap (A \cap \overline{B}) \subseteq B \cap \overline{B} = \varnothing$.

Passo 3 — Additività. $P(A) = P(A \cap B) + P(A \cap \overline{B})$, e portando $P(A \cap B)$ dall'altra parte si ottiene la tesi. ■

Teorema 4.5 — Unione di eventi non incompatibili

Per due eventi qualsiasi A e B:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

Dimostrazione

Passo 1 — Si scrive l'unione con pezzi incompatibili. Osserviamo preliminarmente che

$$A \cup B = A \cup (B \cap \overline{A}) :$$

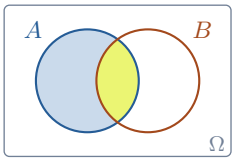
l'unione è fatta da tutto A, più la parte di B che sta fuori da A. I due eventi a secondo membro sono incompatibili (uno sta in A, l'altro fuori).

Passo 2 — Additività. Quindi $P(A \cup B) = P(A) + P(B \cap \overline{A})$.

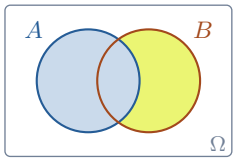
Passo 3 — Si usa la sottrazione. $P(B \cap \overline{A})$ è la probabilità che si verifichi B e non A (cioè B meno A): per il teorema precedente, con i ruoli di A e B scambiati, vale $P(B) - P(B \cap A)$. Sostituendo:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B).$$

■



$A = (A \cap B) \cup (A \cap \overline{B})$
due pezzi incompatibili



$A \cup B = A \cup (B \cap \overline{A})$
tutto A più il giallo

Figura 4.2: *Le due scomposizioni usate nelle dimostrazioni: a sinistra A è tagliato da B; a destra all'evento A (azzurro) si aggiunge la parte di B che sta fuori da A (giallo).*

Esercizio 4.1 — Indipendenza dei complementari

Dimostrare che se due eventi A e B sono indipendenti, lo sono anche i loro complementari:

$$P(A \cap B) = P(A)\,P(B) \quad \Longrightarrow \quad P(\overline{A} \cap \overline{B}) = P(\overline{A})\,P(\overline{B}).$$

Svolgimento

Per la legge di De Morgan $\overline{A} \cap \overline{B} = \overline{A \cup B}$: «né A né B» è il contrario di «almeno uno dei due». Quindi, usando il complementare, poi l'unione e infine l'indipendenza:

$$\begin{aligned} P(\overline{A} \cap \overline{B}) &= P(\overline{A \cup B}) = 1 - P(A \cup B) = 1 - [P(A) + P(B) - P(A \cap B)] \\ &= 1 - P(A) - P(B) + P(A)\,P(B). \end{aligned}$$

Ora si raccoglie con pazienza. I primi due termini danno $1 - P(A) = P(\overline{A})$; gli ultimi due hanno in comune $P(B)$:

$$P(\overline{A}) - P(B)\,(1 - P(A)) = P(\overline{A}) - P(B)\,P(\overline{A}) = P(\overline{A})\,(1 - P(B)) = P(\overline{A})\,P(\overline{B}).$$

Con lo stesso metodo si vede che sono indipendenti anche A e $\overline{B}$: per la sottrazione, $P(A \cap \overline{B}) = P(A) - P(A \cap B) = P(A) - P(A)\,P(B) = P(A)\,(1 - P(B)) = P(A)\,P(\overline{B})$. Se sapere che è successo B non dice nulla su A, nemmeno sapere che *non* è successo dice qualcosa.

Probabilità condizionata e teorema di Bayes

Nell'approccio assiomatico la probabilità condizionata e l'indipendenza diventano **definizioni**: si pone

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} \quad (P(B) > 0), \qquad A, B \text{ indipendenti} \iff P(A \cap B) = P(A)\,P(B),$$

cioè esattamente le formule che le frequenze ci avevano suggerito. Ne seguono, come prima, la legge della probabilità composta e quella della probabilità totale. Un fatto in più, che useremo spesso, è che *condizionare non fa uscire dalla teoria*.

Teorema 4.6 — La probabilità condizionata è una probabilità

Fissato un evento B con $P(B) > 0$, la funzione che a ogni evento A associa $P(A \mid B)$ è una legge di probabilità: soddisfa tutti gli assiomi di Kolmogorov.

Dimostrazione

Passo 1 — Non negatività. $P(A \mid B) = P(A \cap B)/P(B)$ è il rapporto fra un numero ≥ 0 e un numero > 0.

Passo 2 — Normalizzazione. $P(\Omega \mid B) = P(\Omega \cap B)/P(B) = P(B)/P(B) = 1$.

Passo 3 — Additività. Se $A_1 \cap A_2 = \varnothing$, i pezzi $A_1 \cap B$ e $A_2 \cap B$ sono ancora incompatibili e, per la distributiva, $(A_1 \cup A_2) \cap B = (A_1 \cap B) \cup (A_2 \cap B)$. Quindi

$$P(A_1 \cup A_2 \mid B) = \frac{P(A_1 \cap B) + P(A_2 \cap B)}{P(B)} = P(A_1 \mid B) + P(A_2 \mid B).$$

Lo stesso ragionamento vale per una famiglia numerabile di eventi incompatibili. ∎

Di conseguenza tutte le regole valgono anche «dentro» un condizionamento: per esempio $P(\overline{A} \mid B) = 1 - P(A \mid B)$.

Partiamo dalla legge della probabilità composta, che scrive la stessa intersezione in due modi:

$$P(A \cap B) = P(B \mid A)\,P(A) = P(A \mid B)\,P(B).$$

Dividendo per $P(A)$ si ottiene una formula che **rovescia** il condizionamento.

Teorema 4.7 — Teorema (o legge) di Bayes

Se $P(A) > 0$ e $P(B) > 0$:

$$P(B \mid A) = P(A \mid B)\,\frac{P(B)}{P(A)}.$$

Se poi $\{E_i\}_{i=1}^{M}$ è una partizione di Ω, per ogni i:

$$P(E_i \mid A) = \frac{P(A \mid E_i)\,P(E_i)}{\sum_{j=1}^{M} P(A \mid E_j)\,P(E_j)}.$$

Dimostrazione

Passo 1 — Prima forma. Dalla probabilità composta $P(B \mid A)\,P(A) = P(A \mid B)\,P(B)$; si dividono i due membri per $P(A) > 0$.

Passo 2 — Seconda forma. Si applica la prima con $B = E_i$: $P(E_i \mid A) = P(A \mid E_i)\,P(E_i)/P(A)$. Il denominatore $P(A)$ si scrive con la legge della probabilità totale (Teorema 3.2) rispetto alla partizione degli E_j: $P(A) = \sum_j P(A \mid E_j)\,P(E_j)$.

■

Il teorema di Bayes serve quando si conosce la probabilità di un *effetto* data la *causa*, $P(A \mid E_i)$, e si vuole risalire alla probabilità della causa dato l'effetto osservato, $P(E_i \mid A)$. I tre ingredienti hanno nomi che ritroveremo nella parte di statistica del corso:

- $P(E_i)$ è la probabilità **a priori** della causa: quanto la si riteneva probabile *prima* di osservare A;
- $P(A \mid E_i)$ è la **verosimiglianza**: quanto la causa E_i rende probabile ciò che si è osservato;
- $P(E_i \mid A)$ è la probabilità **a posteriori**: quanto è probabile la causa *dopo* aver osservato A.

Esempio 4.2 — Il canale binario, al contrario

Riprendiamo il canale binario del capitolo precedente: si trasmette 0 con probabilità 0,6 e 1 con probabilità 0,4, e ogni bit viene invertito con probabilità 0,1. Avevamo trovato $P(\text{1 ric.}) = 0{,}42$. Se si *riceve* un 1, qual è la probabilità che sia stato *trasmesso* un 1? Per Bayes:

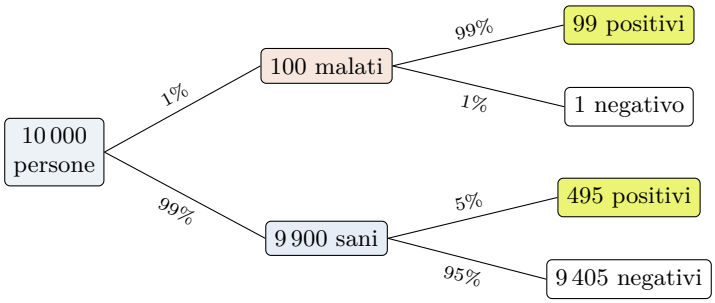
$$P(\text{1 tr.} \mid \text{1 ric.}) = \frac{P(\text{1 ric.} \mid \text{1 tr.})\,P(\text{1 tr.})}{P(\text{1 ric.})} = \frac{0{,}9 \cdot 0{,}4}{0{,}42} = \frac{0{,}36}{0{,}42} = \frac{6}{7} \approx 0{,}857.$$

Quindi, ricevuto un 1, c'è ancora una probabilità $1/7 \approx 0{,}14$ che sia stato trasmesso uno 0: più del 10% di inversione del canale, perché gli 0 trasmessi sono più numerosi degli 1. Decidere quale bit è stato trasmesso, dato quello ricevuto, è un problema di *decisione* che affronteremo nella parte di statistica.

Esempio 4.3 — Il test diagnostico

Una malattia colpisce l'1% della popolazione. Un test la rileva nel 99% dei malati, ma dà un falso allarme nel 5% dei sani. Una persona fa il test e risulta **positiva**: qual è la probabilità che sia malata?

Molti rispondono «99%». Ragioniamo con 10 000 persone, ognuna rappresentativa:



I positivi sono 99 + 495 = 594, e di questi solo 99 sono malati: $99/594 = 1/6 \approx 0{,}17$. Con il teorema di Bayes, rispetto alla partizione malato, sano:

$$P(M \mid +) = \frac{P(+ \mid M)\,P(M)}{P(+ \mid M)\,P(M) + P(+ \mid S)\,P(S)} = \frac{0{,}99 \cdot 0{,}01}{0{,}99 \cdot 0{,}01 + 0{,}05 \cdot 0{,}99} = \frac{0{,}0099}{0{,}0594} \approx 0{,}167.$$

Il test è ottimo, eppure un positivo è malato solo una volta su sei: i sani sono così tanti che i loro falsi allarmi superano di gran lunga i veri positivi. È l'effetto della probabilità a priori, $P(M) = 0{,}01$, che è piccola.

Non scambiare $P(A \mid B)$ con $P(B \mid A)$

$P(+ \mid M) = 0{,}99$ e $P(M \mid +) \approx 0{,}17$ sono due numeri molto diversi. Confonderli è uno degli errori più comuni (e più pericolosi) del ragionamento probabilistico; il teorema di Bayes dice come passare dall'uno all'altro, e mostra che serve anche la probabilità a priori.

Perché una probabilità sta fra 0 e 1

Nella definizione di legge di probabilità abbiamo scritto che il codominio è $[0, 1]$. In realtà non era necessario dirlo: lo si può dimostrare dagli assiomi. Il primo passo è un risultato utile anche da solo.

Teorema 4.8 — Monotonia della probabilità

Se l'evento A è contenuto nell'evento B ($A \subseteq B$), allora $P(A) \le P(B)$.

Dimostrazione

Passo 1 — Si scrive B con pezzi incompatibili. Se $A \subseteq B$ possiamo scrivere

$$B = A \cup (\overline{A} \cap B),$$

cioè B è fatto da A più la parte di B che sta fuori da A. I due eventi non si intersecano: $A \cap (\overline{A} \cap B) = \varnothing$.

Passo 2 — Additività. Per il terzo assioma $P(B) = P(A) + P(\overline{A} \cap B)$.

Passo 3 — Non negatività. Per il primo assioma $P(\overline{A} \cap B) \ge 0$, quindi $P(B) \ge P(A)$. ∎

Teorema 4.9 — La probabilità sta fra 0 e 1

Per ogni evento A: $0 \le P(A) \le 1$.

Dimostrazione

Passo 1. Ogni evento sta fra l'evento impossibile e quello certo: $\varnothing \subseteq A \subseteq \Omega$. Per la monotonia, e ricordando $P(\varnothing) = 0$ e $P(\Omega) = 1$:

$$0 = P(\varnothing) \le P(A) \le P(\Omega) = 1.$$

■

La monotonia ha anche un significato intuitivo: se ogni volta che succede A succede anche B, allora B succede *almeno* altrettanto spesso. Per esempio, «esce un 6» implica «esce un numero pari», e infatti $P(\{6\}) = 1/6 \le P(\{2,4,6\}) = 1/2$.

In sintesi

- Gli eventi formano un'**algebra**: una famiglia chiusa rispetto all'unione e al complementare (e quindi anche all'intersezione e alla differenza, e contenente Ω e $\varnothing$). Una **σ-algebra** è chiusa anche rispetto alle unioni numerabili. La più piccola algebra che contiene A è $\{A, \overline{A}, \Omega, \varnothing\}$.
- **Assiomi di Kolmogorov**: $P(A) \ge 0$; $P(\Omega) = 1$; additività (anche numerabile) per eventi incompatibili. $(\Omega, \mathcal{E}, P)$ è uno **spazio di probabilità**.
- Dagli assiomi: $P(\overline{A}) = 1 - P(A)$, $P(\varnothing) = 0$, $P(A \setminus B) = P(A) - P(A \cap B)$, $P(A \cup B) = P(A) + P(B) - P(A \cap B)$, monotonia e $0 \le P(A) \le 1$.
- Se A e B sono indipendenti, lo sono anche i complementari. La probabilità condizionata a B è a sua volta una probabilità.
- **Bayes**: $P(B \mid A) = P(A \mid B)\,P(B)/P(A)$; con una partizione, $P(E_i \mid A) = P(A \mid E_i)P(E_i)/\sum_j P(A \mid E_j)P(E_j)$. A priori, verosimiglianza, a posteriori.

Variabili aleatorie discrete

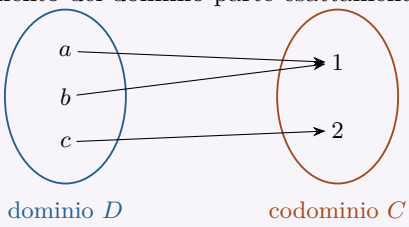
Finora i risultati di un esperimento erano oggetti qualsiasi: testa e croce, coppie di dadi, mani di carte. Ma molto spesso ciò che interessa è un **numero**: quante teste sono uscite, quanti pacchetti ci sono in coda, quanti bit sono arrivati sbagliati. Le **variabili aleatorie** trasformano i risultati in numeri, e con i numeri si possono fare cose che con le teste e le croci non si possono fare: per esempio la **media**. In questo capitolo introduciamo le variabili aleatorie discrete, la loro funzione di probabilità e la loro media, e studiamo le tre famiglie più importanti: la **binomiale**, l'**uniforme** e quella di **Poisson**.

Dai risultati ai numeri

Se Ω è un insieme di numeri, il risultato dell'esperimento è già un numero. In molti casi interessanti, come il lancio di una moneta o l'estrazione di una carta, Ω non è un insieme numerico; però lo si può sempre mettere in corrispondenza con un insieme discreto di numeri. Lo strumento per farlo è una funzione.

Richiamo di matematica: che cos'è una funzione

Una **funzione** $f : D \to C$ è una regola che associa a **ogni** elemento x dell'insieme D (il **dominio**) **uno e un solo** elemento $f(x)$ dell'insieme C (il **codominio**). Si scrive anche $x \mapsto f(x)$, «x va in $f(x)$». Si può disegnare con delle frecce: da ogni elemento del dominio parte esattamente una freccia.



Da ogni elemento di D parte una sola freccia. Più frecce possono arrivare allo stesso elemento di C (qui a e b vanno entrambi in 1): è permesso.

Variabile aleatoria

Una **variabile aleatoria** è una funzione che associa a ogni risultato ω di un esperimento un numero reale:

$$X : \omega \in \Omega \longmapsto X(\omega) \in \mathcal{X} \subseteq \mathbb{R}.$$

L'insieme $\mathcal{X}$ dei valori che può assumere (il suo codominio, necessariamente discreto se Ω è discreto) si chiama **alfabeto** di X.

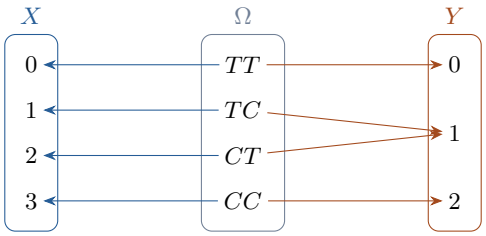
Gli eventi elementari diventano allora gli eventi $\{X = x\}$, con $x \in \mathcal{X}$: «la variabile ha assunto il valore x». Le loro frequenze relative e le loro probabilità si indicano con $f_n(x)$ e $P(X = x)$.

Che cosa c'è di aleatorio

Il nome inganna: la *funzione* X non ha niente di casuale, è una regola fissata una volta per tutte (per esempio «conta le teste»). Aleatorio è il suo *argomento* ω, il risultato dell'esperimento: siccome non sappiamo quale ω uscirà, non sappiamo nemmeno quale valore assumerà $X(\omega)$.

Esempio 5.1 — Monete trasformate in numeri

- **Lancio singolo**: $X : \omega \in \{T, C\} \mapsto X(\omega) \in \{0, 1\}$, con $X(T) = 0$ e $X(C) = 1$. Allora $P(X = 0) = P(X = 1) = \frac{1}{2}$.
- **Lancio doppio**: $X : \omega \in \{T, C\}^2 \mapsto X(\omega) \in \{0, 1, 2, 3\}$, numerando i quattro risultati: $TT \mapsto 0$, $TC \mapsto 1$, $CT \mapsto 2$, $CC \mapsto 3$. Allora $P(X = i) = \frac{1}{4}$ per $i = 0, 1, 2, 3$.
- **Lancio doppio, contando le croci**: $Y(\omega) =$ numero di croci in ω, con alfabeto $\{0, 1, 2\}$. Questa volta due risultati vanno nello stesso numero, e le probabilità si sommano: $P(Y = 0) = P(\{TT\}) = \frac{1}{4}$, $P(Y = 1) = P(\{TC, CT\}) = \frac{1}{2}$, $P(Y = 2) = P(\{CC\}) = \frac{1}{4}$.



numera i risultati: una freccia per valore

conta le croci: TC e CT finiscono entrambi in 1

LA FUNZIONE DI PROBABILITÀ

Per descrivere una variabile aleatoria discreta basta dire con che probabilità assume ciascuno dei suoi valori.

Funzione di probabilità (pmf)

La sequenza di numeri

$$p_X(x) = P(X = x), \qquad x \in \mathcal{X},$$

si chiama **funzione di probabilità**, in inglese *probability mass function* (**pmf**) o *Distribution Function* (DF), della variabile aleatoria X. Una variabile aleatoria si dice **caratterizzata** quando è assegnata la sequenza dei $|\mathcal{X}|$ valori della sua pmf.

Il nome inglese viene da un'immagine utile: si pensi alla probabilità come a un chilo di sabbia da distribuire sui punti dell'alfabeto. La pmf dice quanta *massa* di probabilità sta su ciascun punto.

Teorema 5.1 — Proprietà della pmf

Per ogni variabile aleatoria discreta X:

$$p_X(x) \geq 0 \quad \forall x \in \mathcal{X} \qquad \text{e} \qquad \sum_{x \in \mathcal{X}} p_X(x) = 1.$$

Dimostrazione

Passo 1 — Con le frequenze. Se $n_x = n_{\{X=x\}}$ è il numero di occorrenze dell'evento $\{X = x\}$ su n prove, $p_X(x) = \lim_{n\to\infty} n_x/n$, limite di numeri ≥ 0: quindi $p_X(x) \geq 0$.

Passo 2 — La somma. In ogni prova la variabile assume uno e un solo valore, quindi $\sum_x n_x = n$ e $\sum_x f_n(x) = 1$ per ogni n. Passando al limite, $\sum_x p_X(x) = 1$.

Passo 3 — Con gli assiomi. Gli eventi $\{X = x\}$, al variare di $x \in \mathcal{X}$, sono incompatibili (la variabile non può assumere due valori insieme) e la loro unione è Ω (qualche valore lo assume sempre): formano una partizione. Per la (numerabile) additività, $\sum_x P(X = x) = P(\Omega) = 1$; e ogni $P(X = x) \geq 0$ per il primo assioma.

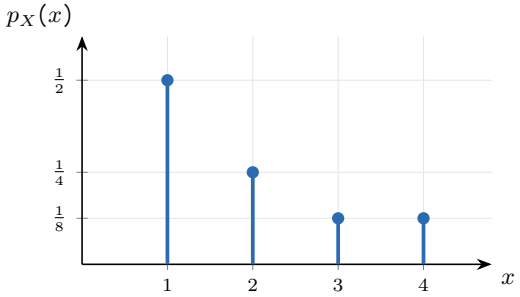
■

Esempio 5.2 — È una pmf?

Sia $\mathcal{X} = \{1, 2, 3, 4\}$. La sequenza $\left(\frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \frac{1}{8}\right)$ può essere la pmf di una variabile aleatoria? Tutti i valori sono ≥ 0 e

$$\sum_{x\in\mathcal{X}} p_X(x) = \frac{1}{2} + \frac{1}{4} + \frac{1}{8} + \frac{1}{8} = \frac{4+2+1+1}{8} = 1,$$

quindi la risposta è sì. Invece $\left(\frac{1}{2}, \frac{1}{2}, \frac{1}{4}, 0\right)$ non lo è (la somma vale $\frac{5}{4} > 1$), e nemmeno $(0{,}6;\ 0{,}6;\ -0{,}2;\ 0)$, che somma a 1 ma contiene un valore negativo.



Il grafico di una pmf si disegna così, con un «bastoncino» su ogni valore dell'alfabeto, alto quanto la sua probabilità.

Un'avvertenza sulle notazioni

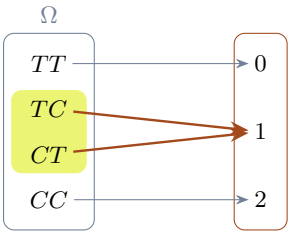
Per come è stata definita, la probabilità è una funzione definita su sottoinsiemi di Ω, a valori in $[0, 1]$:

$$P : A \subseteq \Omega \longmapsto P(A) \in [0, 1].$$

(A rigore bisognerebbe strutturare Ω con un'algebra di eventi, ma sorvoliamo.) Quando si passa alle variabili aleatorie, la notazione corretta sarebbe quindi

$$P\left(\{\omega \in \Omega : X(\omega) = x\}\right),$$

cioè la probabilità dell'insieme dei risultati che la variabile manda nel valore x. Useremo la notazione semplificata $P(X = x)$, o a volte $P(\{X = x\})$ per ricordare che ci riferiamo a un insieme di elementi di Ω, al posto di quella più precisa ma più lunga.



$\{Y = 1\}$ è un modo breve per scrivere l'insieme giallo $\{\omega \in \Omega : Y(\omega) = 1\} = \{TC, CT\}$: i risultati da cui parte una freccia verso 1. Quindi $P(Y = 1) = P(\{TC, CT\}) = \frac{1}{2}$.

Figura 5.1: *L'evento $\{Y = 1\}$ è un sottoinsieme di Ω.*

La media

La pmf descrive tutto, ma è una tabella di numeri. Spesso basta una caratterizzazione meno precisa, riassunta in un solo numero: il valore «attorno a cui» la variabile si distribuisce.

La media campionaria

Si abbia una variabile aleatoria $X(\omega)$ e si compiano n esperimenti. La collezione dei risultati sarà

$$[X(\tilde{\omega}_1) \;\; X(\tilde{\omega}_2) \;\; \dots \;\; X(\tilde{\omega}_n)],$$

dove $\tilde{\omega}_i$ è il risultato dell'esperimento i-esimo e $X(\tilde{\omega}_i)$ il valore assunto dalla variabile in quell'esperimento. La loro media aritmetica si chiama **media campionaria**:

$$\overline{X}_n = \frac{1}{n}\sum_{i=1}^{n} X(\tilde{\omega}_i).$$

Esempio 5.3 — La media di venti lanci

Venti lanci di un dado onesto (simulati) hanno dato:

$$5,\ 3,\ 6,\ 3,\ 6,\ 6,\ 6,\ 5,\ 1,\ 4,\ 2,\ 6,\ 1,\ 2,\ 1,\ 3,\ 4,\ 2,\ 4,\ 5.$$

La media campionaria è la somma divisa per 20: $\overline{X}_{20} = 75/20 = 3{,}75$. Ma la somma si può fare in modo più furbo, **raggruppando i valori uguali**: ogni faccia è uscita un certo numero di volte n_i.

valore x_i	1	2	3	4	5	6	
volte n_i	3	3	3	3	3	5	totale 20
frequenza $f_{20}(x_i)$	0,15	0,15	0,15	0,15	0,15	0,25	totale 1

$$\overline{X}_{20} = \frac{1\cdot 3 + 2\cdot 3 + 3\cdot 3 + 4\cdot 3 + 5\cdot 3 + 6\cdot 5}{20} = 1\cdot 0{,}15 + 2\cdot 0{,}15 + \cdots + 6\cdot 0{,}25 = 3{,}75.$$

La media è la somma dei valori, ciascuno moltiplicato per la sua frequenza relativa.

Dalla media campionaria alla media statistica

Il raggruppamento dell'esempio funziona sempre. Siccome $X(\tilde{\omega}_i) \in \mathcal{X} = \{x_1, x_2, \dots, x_M\}$, al crescere di n la variabile assumerà n_1 volte il valore x_1, n_2 volte il valore x_2, e così via (il caso $M = \infty$ si tratta come caso limite). Quindi, per $n \to \infty$,

$$\overline{X}_n = \frac{1}{n}\sum_{i=1}^{M} n_i\, x_i = \sum_{i=1}^{M} x_i\, f_n(x_i) \longrightarrow \sum_{i=1}^{M} x_i\, P(X = x_i) = \sum_{i=1}^{M} x_i\, p_X(x_i) \triangleq E[X],$$

dove $f_n(x_i) = n_{\{X=x_i\}}/n$ e il simbolo $\triangleq$ si legge «è uguale per definizione». Le frequenze tendono alle probabilità, quindi la media campionaria tende a un numero che dipende solo dalla pmf.

Media statistica

La **media statistica** (o **valore atteso**) di una variabile aleatoria discreta X è

$$E[X] = \sum_{x\in\mathcal{X}} x\, p_X(x) :$$

la somma dei valori assunti, ciascuno moltiplicato per la probabilità con cui è assunto. Si indica anche con μ_X.

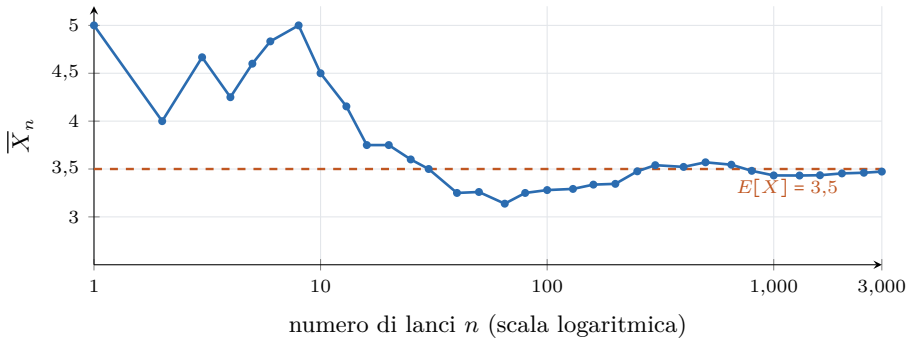


Figura 5.2: *La media campionaria dei lanci di un dado onesto (simulati), al crescere del numero di lanci: oscilla molto all'inizio e poi si avvicina alla media statistica* $E[X] = 3{,}5$.

Esempio 5.4 — Due medie

- Un dado onesto: $E[X] = 1 \cdot \frac{1}{6} + 2 \cdot \frac{1}{6} + \cdots + 6 \cdot \frac{1}{6} = \frac{21}{6} = 3{,}5$. La media **non** è per forza un valore che la variabile può assumere: nessun dado mostra 3,5.
- Il dado truccato del Capitolo 3 ($P(1) = \frac{5}{6}$, $P(i) = \frac{1}{30}$ per le altre facce): $E[X] = 1 \cdot \frac{5}{6} + (2+3+4+5+6) \cdot \frac{1}{30} = \frac{5}{6} + \frac{20}{30} = \frac{25+20}{30} = 1{,}5$. Il trucco sposta la media verso l'1.

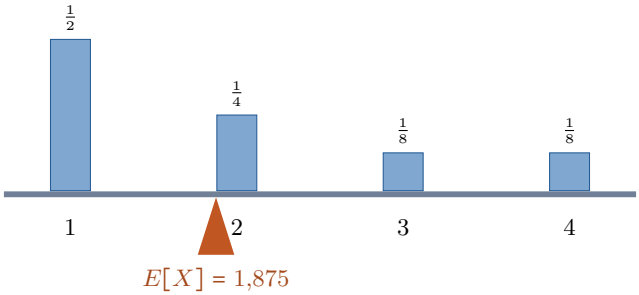


Figura 5.3: *La media come baricentro. Se si appoggiano su un'asta dei pesi proporzionali alle probabilità della pmf* $\left(\frac{1}{2}, \frac{1}{4}, \frac{1}{8}, \frac{1}{8}\right)$, *l'asta sta in equilibrio esattamente sul punto* $E[X] = 1 \cdot \frac{1}{2} + 2 \cdot \frac{1}{4} + 3 \cdot \frac{1}{8} + 4 \cdot \frac{1}{8} = 1{,}875$.

Il conteggio bernoulliano: la variabile binomiale

Consideriamo N lanci di una moneta. Ogni lancio dà testa (T) con probabilità p e croce (C) con probabilità $q = 1-p$ (la moneta non deve essere per forza onesta). I lanci sono **indipendenti**: l'esito di ognuno non dipende da quelli precedenti o successivi. Lo spazio campione è l'insieme delle N-ple del tipo

$$\underbrace{(C, C, T, T, C, \ldots, C, T, T)}_{N}, \qquad \Omega = \{T, C\}^N.$$

Sia $X_N(\omega)$ la variabile aleatoria che **conta** il numero di teste in N lanci:

$$X_N : \omega \in \{T, C\}^N \longmapsto X_N(\omega) \in \mathcal{X} = \{0, 1, 2, \ldots, N\},$$

dove $X_N(\omega) = k$ se ω contiene k teste. Vogliamo la sua pmf.

La probabilità di una sequenza

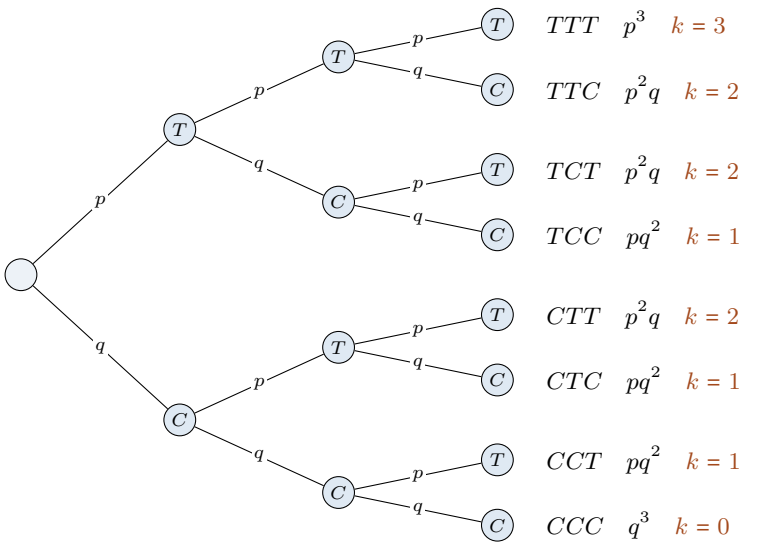
Prendiamo una sequenza particolare con k teste, per esempio quella con tutte le teste all'inizio:

$$\omega = (\underbrace{T, T, \ldots, T}_{k \text{ volte}}, \underbrace{C, C, \ldots, C}_{N-k \text{ volte}}).$$

Per l'indipendenza dei lanci la probabilità che si verifichino insieme tutti questi esiti è il prodotto delle probabilità dei singoli esiti:

$$P(\omega) = \underbrace{p \cdot p \cdots p}_{k \text{ volte}} \cdot \underbrace{q \cdot q \cdots q}_{N-k \text{ volte}} = p^k \, q^{N-k}.$$

L'ordine delle teste e delle croci non conta nel prodotto: **tutte** le sequenze con k teste e $N-k$ croci hanno la stessa probabilità $p^k q^{N-k}$. E quante sono? Sono le stringhe di lunghezza N con k «uni» (Teorema 2.8): $C_{N,k} = \binom{N}{k}$.



Con $N = 3$ lanci: una sequenza con k teste ha probabilità $p^k q^{3-k}$. Le sequenze con $k = 0,1,2,3$ teste sono $1,3,3,1 = \binom{3}{k}$, quindi $P(X_3 = 2) = 3p^2q$, $P(X_3 = 1) = 3pq^2$, …

Figura 5.4: *L'albero di tre lanci. La probabilità di un percorso è il prodotto delle probabilità dei suoi rami.*

La pmf binomiale

Sia $\Omega_{N,k} = \bigcup_{i=1}^{C_{N,k}} \{\omega_i\}$ l'insieme di tutte le sequenze con k teste. L'evento $\{X_N = k\}$ è proprio $\Omega_{N,k}$, quindi

$$P(X_N = k) = p_{X_N}(k) = P(\Omega_{N,k}) = P\left(\bigcup_{i=1}^{C_{N,k}} \{\omega_i\}\right).$$

Gli eventi elementari ω_i sono mutuamente esclusivi ($P(\omega_i \cap \omega_j) = 0$ per $i \neq j$), quindi le probabilità si sommano, e sono tutte uguali a $p^k q^{N-k}$:

$$P(X_N = k) = \sum_{i=1}^{C_{N,k}} P(\{\omega_i\}) = \binom{N}{k} p^k q^{N-k}.$$

Variabile binomiale

Una variabile aleatoria X con alfabeto $\{0,1,\dots,N\}$ e pmf

$$p_X(k) = \binom{N}{k} p^k (1-p)^{N-k}, \qquad k = 0,1,\dots,N,$$

si dice **binomiale** di parametri N e p; in breve $X \sim \mathcal{B}(N,p)$. Conta i successi in N prove indipendenti, ognuna con probabilità di successo p. Per $N = 1$ si chiama **variabile di Bernoulli**: vale 1 con probabilità p e 0 con probabilità $1-p$.

Teorema 5.2 — La binomiale è una pmf

Per ogni N e ogni $p \in [0,1]$: $p_{X_N}(k) \geq 0$ per $k \in \{0,1,\dots,N\}$ e $\sum_{k=0}^{N} p_{X_N}(k) = 1$.

Dimostrazione

Passo 1 — Non negatività. È il prodotto di un coefficiente binomiale (positivo) e di potenze di p e q, che sono ≥ 0.

Passo 2 — Somma, con il binomio di Newton. La somma è proprio lo sviluppo di Newton (Teorema 2.6) con $a = p$ e $b = q$:

$$\sum_{k=0}^{N} \binom{N}{k} p^k \, q^{N-k} = (p+q)^N = (p+1-p)^N = 1^N = 1.$$

Ecco da dove viene il nome «binomiale»: i suoi valori sono i termini dello sviluppo del binomio $(p+q)^N$.

■

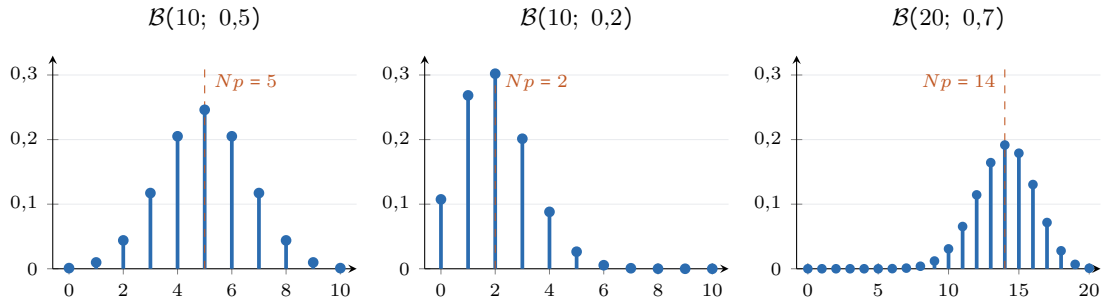


Figura 5.5: *Tre pmf binomiali. Con $p = 0{,}5$ la pmf è simmetrica; con p piccolo è spostata verso sinistra, con p grande verso destra. La linea tratteggiata è la media Np, che calcoliamo fra poco.*

La media della binomiale

Il calcolo della media usa un trucco che ritroveremo spesso: spostare l'indice di una sommatoria.

Richiamo di matematica: cambiare l'indice di una sommatoria

In una sommatoria si può cambiare il nome dell'indice e anche *spostarlo*, purché si spostino di conseguenza gli estremi. Per esempio, ponendo $l = k - 1$: quando k va da 1 a N, l va da 0 a $N - 1$, e

$$\sum_{k=1}^{N} a_{k-1} = \sum_{l=0}^{N-1} a_l.$$

I termini sommati sono esattamente gli stessi $(a_0, a_1, \ldots, a_{N-1})$; cambia solo il nome con cui li si conta. Esempio: $\sum_{k=1}^{3} 2^{k-1} = 2^0 + 2^1 + 2^2 = \sum_{l=0}^{2} 2^l = 7$.
Un'altra cosa utile: se il termine con $k = 0$ vale zero, lo si può togliere senza cambiare la somma, e la sommatoria parte da $k = 1$.

Teorema 5.3 — Media della binomiale

Se $X_N \sim \mathcal{B}(N, p)$, allora

$$E[X_N] = N\,p.$$

Dimostrazione

Passo 1 — Si scrive la definizione. Per definizione di media, con la pmf binomiale e la formula del coefficiente binomiale:

$$E[X_N] = \sum_{k=0}^{N} k\, p_{X_N}(k) = \sum_{k=0}^{N} k \binom{N}{k} p^k q^{N-k} = \sum_{k=0}^{N} k\, \frac{N!}{k!\,(N-k)!}\, p^k q^{N-k}.$$

Passo 2 — Si toglie il termine nullo. Per $k = 0$ il termine contiene il fattore $k = 0$ e vale zero: la somma può partire da $k = 1$.

Passo 3 — Si semplifica $k/k!$. Per $k \geq 1$ vale $k! = k \cdot (k-1)!$, quindi $\dfrac{k}{k!} = \dfrac{1}{(k-1)!}$:

$$E[X_N] = \sum_{k=1}^{N} \frac{N!}{(k-1)!\,(N-k)!}\, p^k q^{N-k}.$$

Passo 4 — Si fa comparire $N-1$. Si scrive $N! = N \cdot (N-1)!$ e si nota che $N - k = (N-1) - (k-1)$, sia nel fattoriale sia nell'esponente di q:

$$E[X_N] = \sum_{k=1}^{N} \frac{N\,(N-1)!}{(k-1)!\,[(N-1)-(k-1)]!}\, p^k q^{N-1-(k-1)}.$$

Passo 5 — Si porta fuori Np. N non dipende da k, e da p^k si può staccare un fattore p: $p^k = p \cdot p^{k-1}$. Portando fuori entrambi:

$$E[X_N] = Np \sum_{k=1}^{N} \frac{(N-1)!}{(k-1)!\,[(N-1)-(k-1)]!}\, p^{k-1} q^{N-1-(k-1)}.$$

Passo 6 — Si cambia indice. Si pone $l = k-1$ e $M = N-1$. Quando k va da 1 a N, l va da 0 a M:

$$E[X_N] = Np \sum_{l=0}^{M} \frac{M!}{l!\,(M-l)!}\, p^l q^{M-l} = Np\,(p+q)^M = Np.$$

La somma rimasta è la somma di tutti i valori di una pmf binomiale $\mathcal{B}(M,p)$, cioè (binomio di Newton) $(p+q)^M = 1$. ■

Il risultato è quello che l'intuito suggerisce: se in ogni lancio esce testa con probabilità p, in N lanci ci si aspettano in media Np teste (con 10 lanci di una moneta onesta, 5 teste). Nel Capitolo 9 ritroveremo questo risultato in una riga, con la linearità della media.

LA VARIABILE UNIFORME

Variabile uniforme

Una variabile aleatoria X che assume valori in un alfabeto finito $\mathcal{X}$ di cardinalità $|\mathcal{X}| = M$ si dice **uniformemente distribuita** su $\mathcal{X}$, in breve $X \sim \mathcal{U}(\mathcal{X})$, se tutti i valori hanno la stessa probabilità:

$$p_X(x) = P(X = x) = \frac{1}{M} \qquad \forall x \in \mathcal{X}.$$

Ovviamente $p_X(x)$ soddisfa le condizioni per essere una pmf: è positiva e M termini uguali a $1/M$ sommano a 1. Il calcolo della media è immediato:

$$E[X] = \sum_{x \in \mathcal{X}} x\, p_X(x) = \frac{1}{M} \sum_{x \in \mathcal{X}} x :$$

è la **media aritmetica** dei valori dell'alfabeto. Il dado onesto è una variabile uniforme su $\{1, \ldots, 6\}$, e infatti la sua media è $(1 + 2 + \cdots + 6)/6 = 3{,}5$.

Un caso interessante è $\mathcal{X} = \{0, 1, 2, \ldots, M-1\}$ (per esempio un numero casuale di k bit, con $M = 2^k$). Per calcolarne la media serve la somma dei primi numeri naturali.

Teorema 5.4 — Somma dei primi n naturali

Per ogni naturale $n \geq 1$:

$$\sum_{i=1}^{n} i = 1 + 2 + \cdots + n = \frac{n\,(n+1)}{2}.$$

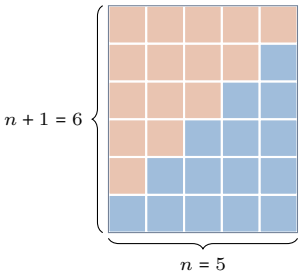
Dimostrazione — il trucco di Gauss

Passo 1 — Si scrive la somma due volte. Sia $S = 1 + 2 + \cdots + n$. La si scrive una volta in avanti e una volta all'indietro, e si sommano le due righe colonna per colonna:

$$\begin{array}{rcccccccc} S &=& 1 &+& 2 &+& \cdots &+& n \\ S &=& n &+& (n-1) &+& \cdots &+& 1 \\ \hline 2S &=& (n+1) &+& (n+1) &+& \cdots &+& (n+1) \end{array}$$

Passo 2 — Ogni colonna vale $n+1$. In ogni colonna, mentre il numero in alto cresce di 1, quello in basso cala di 1: la somma resta sempre $n+1$. Le colonne sono n, quindi $2S = n\,(n+1)$ e $S = n\,(n+1)/2$.

■



La «scala» blu ha $1 + 2 + 3 + 4 + 5$ quadretti. Una seconda scala uguale (arancione), capovolta, la completa in un rettangolo di $5 \times 6 = 30$ quadretti. Quindi una scala sola ne ha la metà: $\frac{5 \cdot 6}{2} = 15$.

Figura 5.6: *La dimostrazione di Gauss, disegnata.*

Esempio 5.5 — La media di un'uniforme su $\{0, 1, \ldots, M-1\}$

Se $X \sim \mathcal{U}(\{0, 1, \ldots, M-1\})$, il termine con 0 non contribuisce e si applica il Teorema 5.4 con $n = M - 1$:

$$E[X] = \sum_{x \in \mathcal{X}} x\, p_X(x) = \frac{1}{M} \sum_{i=0}^{M-1} i = \frac{1}{M} \cdot \frac{(M-1)\,M}{2} = \frac{M-1}{2}.$$

È il punto di mezzo fra il valore più piccolo (0) e il più grande ($M-1$), come ci si aspetta da una distribuzione che non preferisce nessun valore. Per un byte casuale ($M = 256$) la media è 127,5.

La variabile di Poisson

La terza variabile notevole ha un alfabeto infinito e una pmf in cui compare il numero e. Prima di definirla, conviene ricordare da dove viene quel numero.

Richiamo di matematica: il numero e e la serie esponenziale

Si depositi 1 euro in una banca che paga il 100% di interesse all'anno. Se l'interesse viene pagato una volta sola, a fine anno si hanno 2 euro. Se viene pagato ogni sei mesi, metà alla volta, si hanno $\left(1+\frac{1}{2}\right)^2 = 2{,}25$ euro. Se viene pagato n volte all'anno, ogni volta l'$\frac{1}{n}$ del capitale, a fine anno si hanno $\left(1+\frac{1}{n}\right)^n$ euro:

n	1	2	4	12	52	365	1 000 000
$\left(1+\frac{1}{n}\right)^n$	2	2,25	2,4414	2,6130	2,6926	2,7146	2,71828

Il guadagno cresce, ma sempre più lentamente: la successione ha un limite, che si chiama e, il **numero di Nepero**:

$$e = \lim_{n\to\infty}\left(1+\frac{1}{n}\right)^n = 2{,}718281828\ldots$$

Più in generale, per qualsiasi numero reale x vale $\left(1+\frac{x}{n}\right)^n \to e^x$; per esempio $\left(1-\frac{\lambda}{n}\right)^n \to e^{-\lambda}$. La funzione $x \mapsto e^x$ si chiama **esponenziale**.
L'esponenziale si può scrivere anche come una somma infinita (la **serie esponenziale**):

$$e^x = \sum_{k=0}^{\infty}\frac{x^k}{k!} = 1 + x + \frac{x^2}{2} + \frac{x^3}{6} + \frac{x^4}{24} + \cdots$$

Con $x = 1$ le somme parziali sono 1, 2, 2,5, 2,6667, 2,7083, 2,7167, 2,7181, 2,71825, … e si avvicinano a e molto in fretta, perché i fattoriali al denominatore crescono vertiginosamente. Il *perché* di questa formula si capisce con le derivate: lo vedremo nel Capitolo 7, dove le introdurremo.

Variabile di Poisson

Una variabile aleatoria X si dice **di Poisson** (o poissoniana) di parametro $\lambda > 0$, in breve $X \sim \mathcal{P}(\lambda)$, se:

1. il suo alfabeto è $\mathcal{X} = \{0, 1, 2, 3, \ldots\} = \mathbb{N}_0$;
2. la sua pmf è

$$p_X(k) = P(X = k) = \frac{\lambda^k}{k!}\,e^{-\lambda}, \qquad k \in \mathbb{N}_0.$$

Teorema 5.5 — La Poisson è una pmf

Per ogni $\lambda > 0$: $p_X(k) \geq 0$ per ogni $k \in \mathbb{N}_0$ e $\sum_{k=0}^{\infty} p_X(k) = 1$.

Dimostrazione

Passo 1 — Non negatività. $\lambda^k > 0$, $k! > 0$ ed $e^{-\lambda} > 0$.

Passo 2 — Somma. Il fattore $e^{-\lambda}$ non dipende da k e si porta fuori; quello che resta è la serie esponenziale con $x = \lambda$:

$$\sum_{x\in\mathcal{X}} p_X(x) = \sum_{k=0}^{\infty}\frac{\lambda^k}{k!}\,e^{-\lambda} = e^{-\lambda}\sum_{k=0}^{\infty}\frac{\lambda^k}{k!} = e^{-\lambda}\,e^{\lambda} = 1.$$

■

Teorema 5.6 — Media della Poisson

Se $X \sim \mathcal{P}(\lambda)$, allora $E[X] = \lambda$.

Dimostrazione

Passo 1 — La definizione.

$$E[X] = \sum_{x \in \mathcal{X}} x\, p_X(x) = \sum_{k=0}^{\infty} k\, \frac{\lambda^k}{k!}\, e^{-\lambda}.$$

Passo 2 — Si toglie il termine nullo e si semplifica. Il termine con $k = 0$ è nullo e si può togliere; per $k \geq 1$, $k/k! = 1/(k-1)!$. Si porta fuori $e^{-\lambda}$ e un fattore λ (da $\lambda^k = \lambda \cdot \lambda^{k-1}$):

$$E[X] = \sum_{k=1}^{\infty} \frac{\lambda^k}{(k-1)!}\, e^{-\lambda} = e^{-\lambda}\, \lambda \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!}.$$

Passo 3 — Si cambia indice. Posto $j = k - 1$, quando k va da 1 a ∞, j va da 0 a ∞, e si riconosce la serie esponenziale:

$$E[X] = e^{-\lambda}\, \lambda \sum_{j=0}^{\infty} \frac{\lambda^j}{j!} = e^{-\lambda}\, \lambda\, e^{\lambda} = \lambda.$$

■

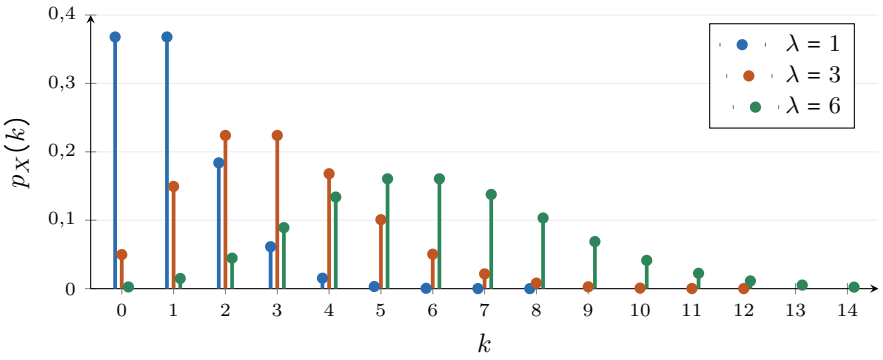


Figura 5.7: *Tre pmf di Poisson (i bastoncini dei tre colori sono leggermente sfalsati per non sovrapporsi). La massa si concentra attorno a λ, che è la media; al crescere di λ si sposta a destra e si allarga.*

Da dove viene la formula di Poisson

La pmf di Poisson non è stata inventata a caso: è quello che diventa la binomiale quando le prove sono **moltissime** e il successo in ciascuna è **rarissimo**. Si pensi ai pacchetti che arrivano a un router in un millisecondo: molti utenti potrebbero spedirne uno (N grande), ma ognuno lo fa con probabilità piccola (p piccolo), e il numero medio di arrivi è $\lambda = Np$.

Teorema 5.7 — La Poisson come limite della binomiale

Sia $\lambda > 0$ fissato e sia $X_N \sim \mathcal{B}(N, \lambda/N)$, una binomiale con media $N \cdot \lambda/N = \lambda$. Allora, per ogni $k \in \mathbb{N}_0$,

$$\lim_{N \to \infty} P(X_N = k) = \frac{\lambda^k}{k!}\, e^{-\lambda}.$$

Dimostrazione

Passo 1 — Si scrive la binomiale con $p = \lambda/N$.

$$P(X_N = k) = \binom{N}{k}\left(\frac{\lambda}{N}\right)^k\left(1-\frac{\lambda}{N}\right)^{N-k} = \frac{N\,(N-1)\cdots(N-k+1)}{k!}\cdot\frac{\lambda^k}{N^k}\cdot\left(1-\frac{\lambda}{N}\right)^N\left(1-\frac{\lambda}{N}\right)^{-k}.$$

Passo 2 — Si raggruppano i fattori. Il numeratore $N\,(N-1)\cdots(N-k+1)$ ha k fattori, come N^k: li si divide uno per uno.

$$P(X_N = k) = \frac{\lambda^k}{k!}\cdot\underbrace{\frac{N}{N}\cdot\frac{N-1}{N}\cdots\frac{N-k+1}{N}}_{(1)}\cdot\underbrace{\left(1-\frac{\lambda}{N}\right)^N}_{(2)}\cdot\underbrace{\left(1-\frac{\lambda}{N}\right)^{-k}}_{(3)}.$$

Passo 3 — Il limite di ogni pezzo. Con k fissato e $N \to \infty$:

- (1): ogni fattore è $1 - i/N$ con i fra 0 e $k-1$, e tende a 1; i fattori sono k, un numero fissato, quindi il prodotto tende a 1;
- (2): è il limite del richiamo sul numero e, con $x = -\lambda$: tende a $e^{-\lambda}$;
- (3): la base $1 - \lambda/N$ tende a 1 e l'esponente $-k$ è fisso, quindi tende a $1^{-k} = 1$.

Passo 4 — Si mette insieme. Il limite di un prodotto è il prodotto dei limiti: $P(X_N = k) \to \dfrac{\lambda^k}{k!}\cdot 1\cdot e^{-\lambda}\cdot 1$.

■

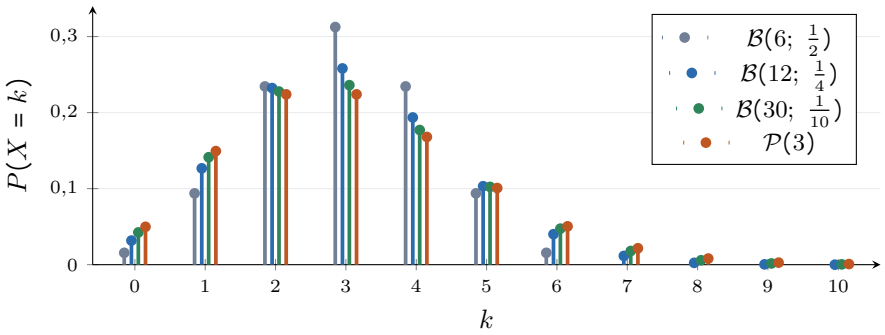


Figura 5.8: *Binomiali con media $Np = 3$ e N sempre più grande: al crescere di N i bastoncini si avvicinano a quelli della Poisson con $\lambda = 3$ (in arancione).*

In sintesi

- Una **variabile aleatoria** è una funzione $X : \Omega \to \mathcal{X} \subseteq \mathbb{R}$ che trasforma i risultati in numeri; $\mathcal{X}$ è il suo **alfabeto**. $P(X = x)$ abbrevia $P(\{\omega : X(\omega) = x\})$.
- La **pmf** $p_X(x) = P(X = x)$ è ≥ 0 e somma a 1.
- La **media statistica** $E[X] = \sum_x x\,p_X(x)$ è il limite della media campionaria: la somma dei valori pesati con le loro probabilità, il baricentro della pmf.
- **Binomiale** $\mathcal{B}(N,p)$: $p_X(k) = \binom{N}{k}p^k(1-p)^{N-k}$, $k = 0,\dots,N$; conta i successi in N prove indipendenti; $E[X] = Np$.
- **Uniforme** su M valori: $p_X(x) = 1/M$; la media è la media aritmetica dei valori, e su $\{0,\dots,M-1\}$ vale $(M-1)/2$.
- **Poisson** $\mathcal{P}(\lambda)$: $p_X(k) = \frac{\lambda^k}{k!}e^{-\lambda}$, $k \in \mathbb{N}_0$; $E[X] = \lambda$. È il limite della binomiale con $N \to \infty$ e $Np = \lambda$: conta gli eventi rari.

PMF CONDIZIONATE E FUNZIONI DI VARIABILI ALEATORIE

Nel Capitolo 3 abbiamo visto come cambia la probabilità di un evento quando si sa che ne è accaduto un altro. Lo stesso si può fare con le variabili aleatorie: sapendo qualcosa sul risultato, la pmf e la media cambiano, e si parla di **pmf condizionata** e di **media condizionata**. Nella seconda metà del capitolo applichiamo una funzione a una variabile aleatoria (la eleviamo al quadrato, ne prendiamo il seno…) e ci chiediamo come si calcolano la pmf e la media della nuova variabile.

LA PMF CONDIZIONATA A UN EVENTO

Introduciamo l'argomento con un esempio. Sia $X \sim \mathcal{B}\left(16, \frac{1}{3}\right)$, cioè

$$\mathcal{X} = \{0, 1, 2, \dots, 16\}, \qquad p_X(k) = \binom{16}{k}\left(\frac{1}{3}\right)^k\left(\frac{2}{3}\right)^{16-k}, \qquad E[X] = 16 \cdot \frac{1}{3} = \frac{16}{3} \approx 5{,}33.$$

Supponiamo ora di sapere che si è verificata la condizione $X > 4$. Come si distribuisce X sotto questa condizione? Dal punto di vista «fisico» significa considerare un insieme di n esperimenti, **scartare** quelli in cui X ha dato un valore inferiore a 5 e valutare la frequenza dei 12 valori residui (da 5 a 16) nel campione così ridotto. È esattamente la probabilità condizionata del Capitolo 3, applicata agli eventi $\{X = k\}$:

$$p_{X|X>4}(k) = P(X = k \mid X > 4) = \frac{P(\{X = k\} \cap \{X > 4\})}{P(\{X > 4\})}.$$

L'intersezione al numeratore è facile: se $k > 4$, l'evento $\{X = k\}$ è contenuto in $\{X > 4\}$ e l'intersezione è $\{X = k\}$ stesso; se $k \le 4$, i due eventi sono incompatibili e l'intersezione è vuota. Quindi

$$p_{X|X>4}(k) = \begin{cases} \dfrac{P(X = k)}{P(X > 4)} = \dfrac{P(X = k)}{\sum_{j=5}^{16} P(X = j)} & k = 5, 6, \dots, 16 \\ 0 & k < 5 \end{cases}$$

Con i numeri: $P(X > 4) = \sum_{j=5}^{16} P(X = j) \approx 0{,}661$, quindi le probabilità dei valori rimasti vengono divise per 0,661, cioè moltiplicate per circa 1,51.

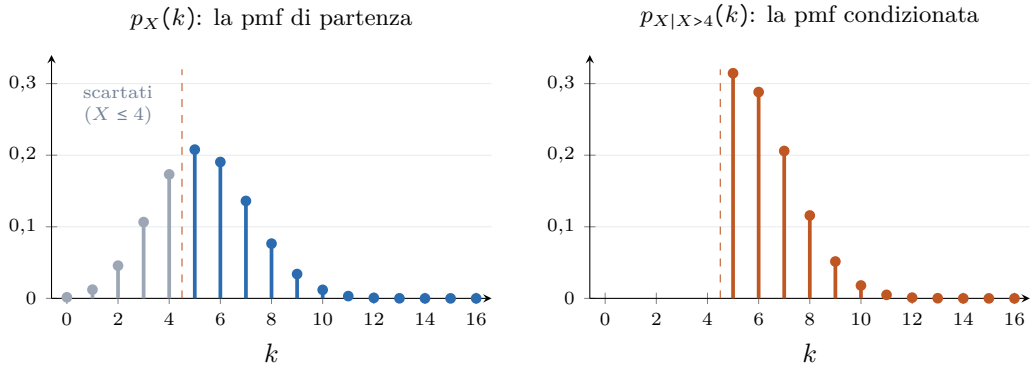


Figura 6.1: *Condizionare a $X > 4$: i valori da 0 a 4 vengono scartati e quelli rimasti vengono «rialzati» tutti nella stessa proporzione (divisi per $P(X > 4) \approx 0{,}661$), in modo che la loro somma torni a 1.*

La pmf condizionata trovata è davvero una pmf: è ≥ 0 e

$$\sum_{k\in\mathcal{X}} p_{X|X>4}(k) = \sum_{k=5}^{16} \frac{P(X=k)}{\sum_{j=5}^{16} P(X=j)} = \frac{\sum_{k=5}^{16} P(X=k)}{\sum_{j=5}^{16} P(X=j)} = 1,$$

perché il denominatore è lo stesso per tutti i termini e si può portare fuori dalla somma.

Siamo ora in grado di dare la definizione generale: si può condizionare una variabile aleatoria a un **qualsiasi** evento A di probabilità non nulla, non necessariamente definito tramite X stessa.

Pmf condizionata

Sia X una variabile aleatoria e $A \subseteq \Omega$ un evento con $P(A) \neq 0$. La **pmf di X condizionata ad A** è

$$p_{X|A}(x) = P(X = x \mid A) = \frac{P(\{X=x\} \cap A)}{P(A)}, \qquad x \in \mathcal{X}.$$

Teorema 6.1 — La pmf condizionata è una pmf

Fissato l'evento A (con $P(A) \neq 0$), al variare di $x \in \mathcal{X}$ la funzione $p_{X|A}(x)$ è una pmf:

$$p_{X|A}(x) \geq 0 \qquad \text{e} \qquad \sum_{x\in\mathcal{X}} p_{X|A}(x) = 1.$$

Dimostrazione

Passo 1 — Una probabilità condizionata è una probabilità. Per il Teorema 4.6, $P(\cdot \mid A)$ rispetta tutti gli assiomi; in particolare è ≥ 0.

Passo 2 — La somma. Gli eventi $\{X = x\}$, al variare di x, formano una partizione di Ω. Per l'additività della probabilità condizionata:

$$\sum_{x\in\mathcal{X}} P(X=x \mid A) = P\left(\bigcup_{x\in\mathcal{X}} \{X=x\} \,\middle|\, A\right) = P(\Omega \mid A) = 1.$$

■

LA PROBABILITÀ TOTALE PER LE PMF

Ricordiamo la legge della probabilità totale: per un qualunque evento C e una qualunque partizione $\{E_i\}_{i=1}^M$ di Ω,

$$P(C) = \sum_{i=1}^{M} P(C \mid E_i)\, P(E_i).$$

Specializzandola all'evento $C = \{X = x\}$ si ottiene una formula per la pmf.

Teorema 6.2 — Probabilità totale per le pmf

Se $\{E_i\}_{i=1}^M$ è una partizione di Ω con $P(E_i) > 0$, allora per ogni $x \in \mathcal{X}$:

$$p_X(x) = P(X=x) = \sum_{i=1}^{M} P(\{X=x\} \mid E_i)\, P(E_i) = \sum_{i=1}^{M} p_{X|E_i}(x)\, P(E_i).$$

La pmf di X è una **media pesata** delle pmf condizionate, con pesi le probabilità dei casi.

Dimostrazione

Passo 1. È la legge della probabilità totale (Teorema 3.2) applicata all'evento $C = \{X = x\}$, con $P(\{X = x\} \mid E_i) = p_{X|E_i}(x)$ per definizione di pmf condizionata.

■

Esempio 6.1 — Spezzare una binomiale

Con riferimento all'esempio precedente, $X \sim \mathcal{B}(16, \frac{1}{3})$, si può usare la partizione in due casi $E_1 = \{X > 4\}$, $E_2 = \{X \le 4\}$, che coprono Ω e sono incompatibili:

$$p_X(k) = p_{X|X>4}(k)\, P(X > 4) + p_{X|X\le 4}(k)\, P(X \le 4).$$

Oppure la partizione in tre casi $\{X \le 1\}$, $\{2 \le X \le 6\}$, $\{X \ge 7\}$, che sono a due a due incompatibili e la cui unione è tutto Ω:

$$p_X(k) = p_{X|X\le 1}(k)\, P(X \le 1) + p_{X|2\le X\le 6}(k)\, P(2 \le X \le 6) + p_{X|X\ge 7}(k)\, P(X \ge 7).$$

In questi due casi la formula è quasi ovvia: per ogni k solo uno dei termini è diverso da zero (quello del caso che contiene k), e per quel termine $p_{X|E_i}(k)\, P(E_i) = P(X = k)$. Attenzione però a scegliere bene gli intervalli: una partizione deve contenere ogni valore una e una sola volta.

La formula diventa davvero utile quando i casi E_i **non** sono definiti tramite X, ma descrivono qualcosa che influenza X e che non si conosce.

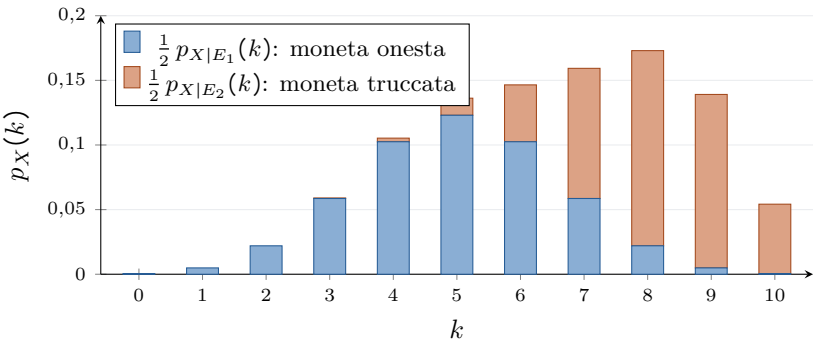
Esempio 6.2 — Due monete in un cassetto

In un cassetto ci sono due monete identiche all'aspetto: una è onesta ($p = 0{,}5$), l'altra è truccata e dà testa con probabilità $p = 0{,}8$. Se ne prende una a caso e la si lancia 10 volte; sia X il numero di teste. I due casi $E_1 =$ «è la moneta onesta» ed $E_2 =$ «è la moneta truccata» hanno probabilità $\frac{1}{2}$ ciascuno, e *sapendo* quale moneta è stata presa X è binomiale:

$$p_{X|E_1} = \mathcal{B}(10;\ 0{,}5), \qquad p_{X|E_2} = \mathcal{B}(10;\ 0{,}8).$$

Per la probabilità totale:

$$p_X(k) = \frac{1}{2}\binom{10}{k} 0{,}5^{10} + \frac{1}{2}\binom{10}{k} 0{,}8^k\, 0{,}2^{10-k}.$$



Ogni barra è la somma di due pezzi: il contributo della moneta onesta (blu) e quello della moneta truccata (arancione). Si può anche andare al contrario, con Bayes: se sono uscite 9 teste, la probabilità che la moneta sia quella truccata è

$$P(E_2 \mid X = 9) = \frac{p_{X|E_2}(9)\, P(E_2)}{p_X(9)} = \frac{0{,}2684 \cdot \frac{1}{2}}{0{,}2684 \cdot \frac{1}{2} + 0{,}0098 \cdot \frac{1}{2}} \approx 0{,}965.$$

LE MEDIE CONDIZIONATE

Un analogo sviluppo è possibile sulle medie. Si calcola la pmf condizionata e poi la sua media.

Media condizionata

La **media di X condizionata all'evento** E (con $P(E) > 0$) è la media della pmf condizionata:

$$E[X \mid E] = \sum_{x \in \mathcal{X}} x\, p_{X|E}(x).$$

Per dimostrare il risultato principale serve scambiare l'ordine di due sommatorie.

Richiamo di matematica: scambiare l'ordine di due sommatorie

Una **somma doppia** $\sum_i \sum_j a_{ij}$ somma tutti i numeri a_{ij} di una tabella, con i che indica la riga e j la colonna. Il totale non dipende dall'ordine: si può sommare prima ogni riga e poi i totali delle righe, oppure prima ogni colonna e poi i totali delle colonne.

	$j=1$	$j=2$	$j=3$	riga
$i=1$	1	2	3	6
$i=2$	4	5	6	15
colonna	5	7	9	**21**

$$\sum_{i=1}^{2}\sum_{j=1}^{3} a_{ij} = 6 + 15 = 21 = 5 + 7 + 9 = \sum_{j=1}^{3}\sum_{i=1}^{2} a_{ij}$$

Inoltre, un fattore che dipende solo dall'indice esterno si può portare dentro o fuori dalla somma interna: $\sum_i \sum_j b_i\, c_j = \sum_i b_i \sum_j c_j$. Con infiniti termini lo scambio resta lecito quando i termini sono tutti ≥ 0, o più in generale quando le serie convergono «bene» (assolutamente): sarà sempre il nostro caso.

Teorema 6.3 — Media e medie condizionate

Se $\{E_m\}_{m=1}^{M}$ è una partizione di Ω con $P(E_m) > 0$, allora

$$E[X] = \sum_{m=1}^{M} P(E_m)\, E[X \mid E_m].$$

La media è la media pesata delle medie condizionate.

Dimostrazione

Passo 1 — Si usa la probabilità totale per la pmf. Nella definizione di media si sostituisce $p_X(x)$ con la formula del Teorema 6.2:

$$E[X] = \sum_{x \in \mathcal{X}} x\, p_X(x) = \sum_{x \in \mathcal{X}} x \sum_{m=1}^{M} p_{X|E_m}(x)\, P(E_m).$$

Passo 2 — Si scambiano le somme. Si porta la x dentro, si scambia l'ordine delle due somme e si porta fuori $P(E_m)$, che non dipende da x:

$$E[X] = \sum_{m=1}^{M} P(E_m) \underbrace{\sum_{x \in \mathcal{X}} x\, p_{X|E_m}(x)}_{E[X|E_m]}.$$

Passo 3 — Si riconosce la media condizionata. La somma interna è, per definizione, $E[X \mid E_m]$.

■

Esempio 6.3 — Le medie condizionate al lavoro

- Per $X \sim \mathcal{B}(16, \frac{1}{3})$ e la partizione $\{X \le 4\}$, $\{X > 4\}$:

$$E[X] = P(X \le 4)\, E[X \mid X \le 4] + P(X > 4)\, E[X \mid X > 4].$$

  Con i numeri: $P(X \le 4) \approx 0{,}339$, $E[X \mid X \le 4] \approx 3{,}29$ (la media dei soli valori da 0 a 4, con la pmf condizionata), $P(X > 4) \approx 0{,}661$, $E[X \mid X > 4] \approx 6{,}38$. Infatti $0{,}339 \cdot 3{,}29 + 0{,}661 \cdot 6{,}38 \approx 1{,}116 + 4{,}217 = 5{,}333 = 16/3$.

- Per le due monete: sapendo quale moneta è stata presa, la media è quella di una binomiale, Np. Quindi

$$E[X] = \frac{1}{2} \cdot (10 \cdot 0{,}5) + \frac{1}{2} \cdot (10 \cdot 0{,}8) = \frac{1}{2} \cdot 5 + \frac{1}{2} \cdot 8 = 6{,}5,$$

  senza bisogno di calcolare la pmf di X.

Funzioni di variabili aleatorie

Si assuma che $X = X(\omega)$ sia una variabile aleatoria con alfabeto $\mathcal{X}$ e pmf $\{p_X(x)\}_{x \in \mathcal{X}}$, e sia $g(x)$ una funzione definita (almeno) sui valori di $\mathcal{X}$. Si forma la nuova variabile aleatoria

$$Y = g(X) = g[X(\omega)] \in \mathcal{Y}, \qquad \text{dove } \mathcal{Y} = g(\mathcal{X})$$

è l'insieme dei valori che g assume sui punti di $\mathcal{X}$. Per esempio, se X è la tensione misurata su un resistore, $Y = X^2/R$ è la potenza dissipata. Il problema è ricavare una caratterizzazione di Y da quella di X:

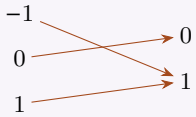
1. la pmf $\{p_Y(y)\}_{y \in \mathcal{Y}}$;
2. la media statistica $E[Y] = \sum_{y \in \mathcal{Y}} y\, p_Y(y)$.

Richiamo di matematica: funzioni iniettive, biunivoche e controimmagine

Una funzione g è **iniettiva** se manda elementi diversi in elementi diversi: $x_1 \neq x_2 \Rightarrow g(x_1) \neq g(x_2)$. Nel disegno a frecce: a ogni punto di arrivo arriva *al massimo una* freccia. Se inoltre ogni elemento del codominio viene raggiunto, la funzione è **biunivoca** (o *biiettiva*): fra i due insiemi c'è una corrispondenza uno a uno, e la funzione si può invertire, $x = g^{-1}(y)$.
La **controimmagine** di un valore y è l'insieme dei punti che vanno in y: $g^{-1}(y) = \{x : g(x) = y\}$. Per una funzione biunivoca contiene un solo punto; in generale può contenerne più d'uno.



$g(x) = 3x$: biunivoca
(una freccia per punto)



$g(x) = x^2$: non iniettiva
$g^{-1}(1) = \{-1, 1\}$

Distinguiamo due casi.

Primo caso: g è biunivoca su $\mathcal{X}$, cioè $|\mathcal{Y}| = |\mathcal{X}|$ e per ogni $y \in \mathcal{Y}$ è definito un solo $x = g^{-1}(y)$. Si tratta solo di una **ridenominazione** dell'alfabeto: i valori cambiano nome, le probabilità restano le stesse.

$$p_Y(y_i) = P(Y = y_i) = P\left(X = g^{-1}(y_i)\right) = P(X = x_i) = p_X(x_i).$$

Secondo caso: g non è iniettiva, cioè associa a più valori di $\mathcal{X}$ un solo valore di $\mathcal{Y}$: $\mathcal{X} = \{x_1, \ldots, x_n\}$, $\mathcal{Y} = \{y_1, \ldots, y_m\}$, con $n > m$. Nei punti di $\mathcal{Y}$ in cui g è invertibile vale la relazione precedente. Per un punto y_k raggiunto da L_k valori diversi,

$$g\left(x_1^{(k)}\right) = g\left(x_2^{(k)}\right) = \cdots = g\left(x_{L_k}^{(k)}\right) = y_k,$$

l'evento $\{Y = y_k\}$ si verifica quando X assume *uno qualsiasi* di quei valori, e le probabilità si sommano (gli eventi $\{X = x_i^{(k)}\}$ sono incompatibili):

$$p_Y(y_k) = P\left(\bigcup_{i=1}^{L_k} \left\{X = x_i^{(k)}\right\}\right) = \sum_{i=1}^{L_k} P\left(X = x_i^{(k)}\right) = \sum_{i=1}^{L_k} p_X\left(x_i^{(k)}\right).$$

Le probabilità «collassano»: tutta la massa dei punti che vanno nello stesso valore si accumula lì. Le due formule si riassumono in una sola.

Da ricordare: pmf di una funzione di variabile aleatoria

$$p_Y(y) = \sum_{x\,:\,g(x)=y} p_X(x) \qquad \text{(si sommano le probabilità della controimmagine di } y\text{)}$$

La media di una funzione di variabile aleatoria

Per la media seguiamo la stessa suddivisione. Se g è biunivoca c'è solo una ridenominazione dell'alfabeto, quindi

$$E[Y] = \sum_{y\in\mathcal{Y}} y\, p_Y(y) = \sum_{x\in\mathcal{X}} g(x)\, p_X(x).$$

La cosa notevole è che la stessa formula vale **sempre**, anche quando g non è iniettiva.

Teorema 6.4 — Teorema fondamentale per il calcolo della media

Se $Y = g(X)$, allora

$$E[Y] = E[g(X)] = \sum_{x\in\mathcal{X}} g(x)\, p_X(x).$$

Per calcolare la media di $g(X)$ non serve conoscere la pmf di Y: basta quella di X.

Dimostrazione

Passo 1 — Si parte dalla definizione per Y. Usando la formula della pmf di Y:

$$E[Y] = \sum_{y\in\mathcal{Y}} y\, p_Y(y) = \sum_{y\in\mathcal{Y}} y \sum_{x\,:\,g(x)=y} p_X(x).$$

Passo 2 — Si porta y dentro. Nella somma interna ogni x soddisfa $g(x) = y$, quindi si può scrivere $g(x)$ al posto di y:

$$E[Y] = \sum_{y\in\mathcal{Y}} \sum_{x\,:\,g(x)=y} g(x)\, p_X(x).$$

Passo 3 — I gruppi coprono tutto $\mathcal{X}$. Ogni $x \in \mathcal{X}$ va in uno e un solo valore $y = g(x)$: le controimmagini dei diversi y dividono $\mathcal{X}$ in gruppi disgiunti che lo coprono tutto. Sommare gruppo per gruppo e poi sommare i gruppi equivale a sommare su tutti gli x:

$$E[Y] = \sum_{x\in\mathcal{X}} g(x)\, p_X(x).$$

■

Il teorema si chiama anche **teorema del valore medio**. È comodissimo: per esempio $E[X^2] = \sum_x x^2\, p_X(x)$, senza dover prima trovare la pmf di X^2.

La media di $g(X)$ non è g della media

In generale $E[g(X)] \neq g(E[X])$. Se X vale -1 o $+1$ con probabilità $\frac{1}{2}$ ciascuno, allora $E[X] = 0$ e quindi $(E[X])^2 = 0$, ma X^2 vale sempre 1 e $E[X^2] = 1$. Si può portare la funzione «fuori» dalla media solo in casi speciali, come le funzioni lineari che vedremo nel prossimo capitolo.

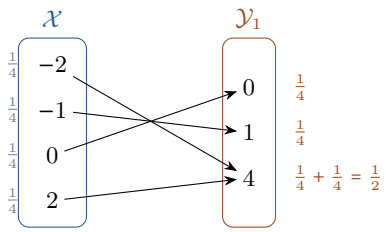
Un esempio completo

Sia $X \sim \mathcal{U}(\{-2,-1,0,2\})$: ognuno dei quattro valori ha probabilità $\frac{1}{4}$. Troviamo la pmf delle due variabili aleatorie

$$Y_1 = X^2 \quad \left(g(x) = x^2\right), \qquad Y_2 = 3\sin\left(\frac{2\pi}{5}X\right) \quad \left(g(x) = 3\sin\left(\frac{2\pi}{5}x\right)\right).$$

Il quadrato

I valori di Y_1 sono $(-2)^2 = 4$, $(-1)^2 = 1$, $0^2 = 0$ e $2^2 = 4$: l'alfabeto è $\mathcal{Y}_1 = \{0,1,4\}$, con $|\mathcal{Y}_1| = 3 < |\mathcal{X}| = 4$. La funzione non è iniettiva: -2 e 2 vanno entrambi in 4.



$$p_{Y_1}(0) = P(X=0) = \frac{1}{4}, \qquad p_{Y_1}(1) = P(X=-1) = \frac{1}{4}, \qquad p_{Y_1}(4) = P(\{X=-2\} \cup \{X=2\}) = P(X=-2) + P(X=2) = \frac{1}{2}.$$

La media si può calcolare in due modi, e il teorema fondamentale garantisce che danno lo stesso risultato:

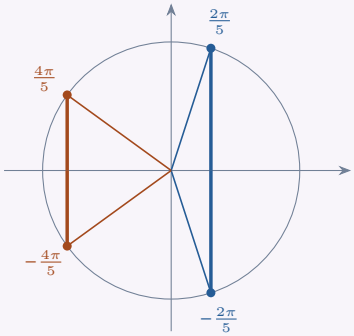
$$E[Y_1] = 0\cdot\frac{1}{4} + 1\cdot\frac{1}{4} + 4\cdot\frac{1}{2} = \frac{9}{4}, \qquad E[Y_1] = \sum_x x^2\, p_X(x) = \frac{4+1+0+4}{4} = \frac{9}{4}.$$

Il seno

Per Y_2 serve ricordare la funzione seno.

Richiamo di matematica: il seno e i radianti

Si disegni una circonferenza di raggio 1 centrata nell'origine. Un angolo θ si misura in **radianti**: è la lunghezza dell'arco che l'angolo stacca sulla circonferenza, partendo dal punto $(1,0)$ e girando in senso antiorario. Il giro completo, la lunghezza della circonferenza, è 2π radianti, cioè 360°; quindi π radianti sono 180° e $\frac{2\pi}{5}$ radianti sono 72°. Angoli negativi si misurano in senso orario.
Il **seno** $\sin\theta$ è l'altezza (la coordinata verticale) del punto della circonferenza raggiunto dopo l'angolo θ.



I tratti spessi verticali sono i seni. Si vede che $\sin\frac{2\pi}{5} \approx 0{,}951$ (72°) è più alto di $\sin\frac{4\pi}{5} \approx 0{,}588$ (144°), e che il seno di un angolo negativo è l'opposto: $\sin(-\theta) = -\sin\theta$ (il punto si riflette sotto l'asse orizzontale).

Calcoliamo i quattro valori di Y_2, usando $\sin(-\theta) = -\sin\theta$:

$$X=-2: \quad 3\sin\left(-\tfrac{4\pi}{5}\right) = -3\sin\tfrac{4\pi}{5} \approx -1{,}763 = \alpha_1, \qquad X=-1: \quad 3\sin\left(-\tfrac{2\pi}{5}\right) = -3\sin\tfrac{2\pi}{5} \approx -2{,}853 = \alpha_2,$$
$$X=0: \quad 3\sin 0 = 0 = \alpha_3, \qquad X=2: \quad 3\sin\tfrac{4\pi}{5} \approx 1{,}763 = \alpha_4.$$

I quattro valori sono tutti diversi: $|\mathcal{Y}_2| = 4 = |\mathcal{X}|$, la funzione è biunivoca su $\mathcal{X}$, e c'è solo una ridenominazione:

$$p_{Y_2}(\alpha_i) = \frac{1}{4}, \qquad i = 1,2,3,4.$$

La variabile aleatoria Y_2 assume uniformemente i quattro valori di $\mathcal{Y}_2$. La sua media, con il teorema fondamentale, è $E[Y_2] = \frac{1}{4}(-1{,}763 - 2{,}853 + 0 + 1{,}763) = -\frac{2{,}853}{4} \approx -0{,}713$: i due valori $\pm 1{,}763$ si cancellano.

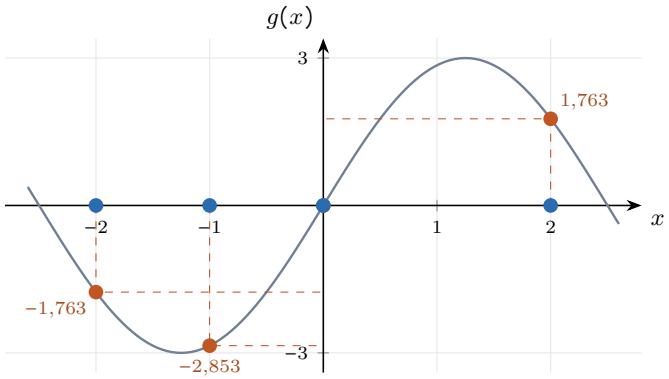


Figura 6.2: *La funzione* $g(x) = 3\sin\left(\frac{2\pi}{5}x\right)$*: i quattro valori dell'alfabeto di* X *(in blu sull'asse orizzontale) vanno in quattro valori diversi (in arancione), quindi* Y_2 *è ancora uniforme.*

In sintesi

- La **pmf condizionata** a un evento A è $p_{X|A}(x) = P(\{X = x\} \cap A)/P(A)$: si scartano i risultati fuori da A e si «rialzano» gli altri in proporzione. È ancora una pmf.
- **Probabilità totale per le pmf**: $p_X(x) = \sum_i p_{X|E_i}(x)\, P(E_i)$; utilissima quando i casi E_i descrivono qualcosa di ignoto che influenza X (le due monete).
- **Media condizionata**: $E[X \mid E] = \sum_x x\, p_{X|E}(x)$, e $E[X] = \sum_m P(E_m)\, E[X \mid E_m]$.
- Se $Y = g(X)$: $p_Y(y) = \sum_{x:g(x)=y} p_X(x)$. Se g è biunivoca è una ridenominazione, altrimenti le probabilità dei punti che vanno nello stesso valore si sommano.
- **Teorema fondamentale**: $E[g(X)] = \sum_x g(x)\, p_X(x)$, senza bisogno della pmf di Y. In generale $E[g(X)] \neq g(E[X])$.

Varianza e disuguaglianze

La media dice *dove* si trova una variabile aleatoria, ma non *quanto* è sparpagliata attorno a quel punto. Due variabili possono avere la stessa media ed essere diversissime: una sempre vicina alla media, l'altra capace di allontanarsene molto. In questo capitolo introduciamo le misure della dispersione, il **valore quadratico medio**, la **varianza** e la **deviazione standard**; le calcoliamo per la binomiale, l'uniforme e la Poisson (e per farlo ci serviranno le **derivate**, spiegate da zero); infine, con le disuguaglianze di **Markov** e di **Chebyshev**, scopriamo che cosa ci dice davvero la deviazione standard.

Misurare la dispersione

Si considerino due variabili aleatorie:

$$X: \quad P(X=4)=\tfrac{1}{4},\ P(X=5)=\tfrac{1}{2},\ P(X=6)=\tfrac{1}{4}; \qquad Y: \quad P(Y=1)=\tfrac{1}{4},\ P(Y=5)=\tfrac{1}{2},\ P(Y=9)=\tfrac{1}{4}.$$

Entrambe hanno media 5 (le pmf sono simmetriche attorno a 5), ma Y si allontana dalla media molto più di X.

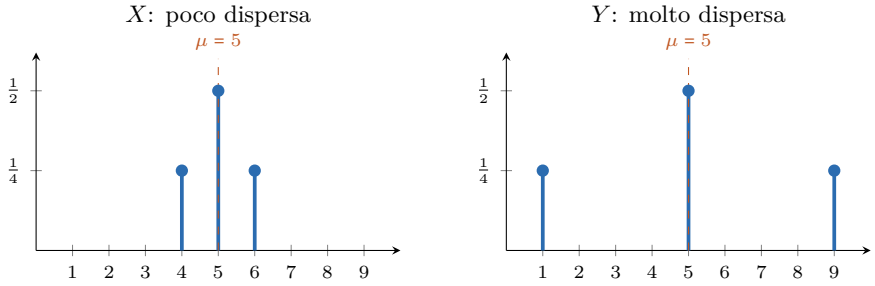


Figura 7.1: *Stessa media, dispersione molto diversa.*

L'idea naturale è misurare, in media, quanto la variabile si allontana dalla sua media μ_X. Ma la media dello scarto $X-\mu_X$ non funziona: gli scarti positivi e quelli negativi si compensano, e il risultato è sempre zero, $E[X-\mu_X]=E[X]-\mu_X=0$ (lo dimostreremo fra poco, con la linearità della media). Per evitare le compensazioni si rendono positivi tutti gli scarti **elevandoli al quadrato**.

Valore quadratico medio e varianza

Data una variabile aleatoria $X\sim p_X(x)$, $x\in\mathcal{X}$, con media $\mu_X=E[X]$, definiamo quattro grandezze. Tutte si calcolano con il teorema fondamentale (Teorema 6.4), cioè come medie di una funzione di X.

Valore quadratico medio e valore efficace

Il **valore quadratico medio** (*mean square*) di X è la media del suo quadrato:

$$X_{rms}^2=E[X^2]=\sum_{x\in\mathcal{X}}x^2\,p_X(x).$$

Il **valore efficace** (*root mean square*) è la sua radice: $X_{rms}=\sqrt{E[X^2]}=\sqrt{\sum_{x\in\mathcal{X}}x^2\,p_X(x)}$.

Varianza e deviazione standard

La **varianza** di X è la media del quadrato dello scarto dalla media:

$$\sigma_X^2 = E\left[(X-\mu_X)^2\right] = \sum_{x\in\mathcal{X}} (x-\mu_X)^2\, p_X(x).$$

La **deviazione standard** è la sua radice: $\sigma_X = \sqrt{E[(X-\mu_X)^2]} = \sqrt{\sum_x (x-\mu_X)^2\, p_X(x)}$.

La deviazione standard ha la stessa unità di misura di X (se X è in metri, σ_X è in metri, mentre σ_X^2 è in metri quadrati): per questo è la misura di dispersione che si usa per «leggere» i risultati.

Teorema 7.1 — Varianza, valore quadratico medio e media

$$\sigma_X^2 = X_{rms}^2 - \mu_X^2 = E[X^2] - E^2[X], \qquad \sigma_X = \sqrt{X_{rms}^2 - \mu_X^2} = \sqrt{E[X^2] - E^2[X]},$$

dove $E^2[X]$ indica $(E[X])^2$.

Dimostrazione

Passo 1 — Si sviluppa il quadrato. $(x-\mu_X)^2 = x^2 - 2x\mu_X + \mu_X^2$, quindi

$$\sigma_X^2 = \sum_{x\in\mathcal{X}} \left(x^2 - 2x\mu_X + \mu_X^2\right) p_X(x).$$

Passo 2 — Si spezza la somma in tre. Le costanti $2\mu_X$ e μ_X^2 escono dalle sommatorie:

$$\sigma_X^2 = \sum_x x^2\, p_X(x) - 2\mu_X \sum_x x\, p_X(x) + \mu_X^2 \sum_x p_X(x).$$

Passo 3 — Si riconoscono i pezzi. La prima somma è $E[X^2] = X_{rms}^2$, la seconda è $E[X] = \mu_X$, la terza è 1 (la pmf somma a 1):

$$\sigma_X^2 = X_{rms}^2 - 2\mu_X^2 + \mu_X^2 = X_{rms}^2 - \mu_X^2.$$

■

Da ricordare: varianza

$$\sigma_X^2 = E\left[(X-\mu_X)^2\right] = E[X^2] - \mu_X^2 \qquad \sigma_X = \sqrt{\sigma_X^2}$$

Esempio 7.1 — Le due variabili dell'inizio

Per X: $\sigma_X^2 = (4-5)^2 \cdot \frac{1}{4} + (5-5)^2 \cdot \frac{1}{2} + (6-5)^2 \cdot \frac{1}{4} = \frac{1}{2}$, quindi $\sigma_X \approx 0{,}71$. Per Y: $\sigma_Y^2 = (1-5)^2 \cdot \frac{1}{4} + 0 + (9-5)^2 \cdot \frac{1}{4} = 8$, quindi $\sigma_Y \approx 2{,}83$. La varianza ha colto esattamente la differenza che si vedeva nei grafici.

Con la seconda formula: $E[X^2] = 16 \cdot \frac{1}{4} + 25 \cdot \frac{1}{2} + 36 \cdot \frac{1}{4} = 25{,}5$ e $\sigma_X^2 = 25{,}5 - 5^2 = 0{,}5$. Stesso risultato.

Perché si chiama «valore efficace»

Il nome viene dall'elettrotecnica. La potenza dissipata da un resistore R con tensione v è v^2/R: dipende dal *quadrato* della tensione. Se la tensione varia nel tempo, la potenza media dipende dalla media di v^2, cioè dal valore quadratico medio. Il valore efficace è la tensione costante che dissiperebbe la stessa potenza media: i 230 volt della presa di casa sono il valore efficace di una tensione alternata che oscilla fra circa -325 e $+325$ volt.

La varianza della binomiale

La variabile di Bernoulli

Cominciamo dal caso $N = 1$, $X \sim \mathcal{B}(1, p)$: la variabile vale 1 con probabilità p e 0 con probabilità $1 - p$.

$$E[X] = 1 \cdot p + 0 \cdot (1-p) = p, \qquad E[X^2] = 1^2 \cdot p + 0^2 \cdot (1-p) = p,$$

$$\sigma_X^2 = E[X^2] - E^2[X] = p - p^2 = p(1-p), \qquad \sigma_X = \sqrt{p(1-p)}.$$

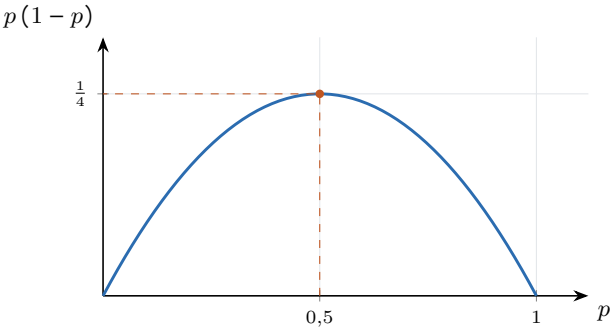


Figura 7.2: *La varianza di una Bernoulli in funzione di p. È nulla per $p = 0$ e $p = 1$ (il risultato è certo) ed è massima, $\frac{1}{4}$, per $p = \frac{1}{2}$: la moneta onesta è la più imprevedibile.*

Il caso generale

Per $X \sim \mathcal{B}(N, p)$ serve $E[X^2]$:

$$E[X^2] = \sum_{x \in \mathcal{X}} x^2 \, p_X(x) = \sum_{k=0}^{N} k^2 \binom{N}{k} p^k q^{N-k} = \sum_{k=1}^{N} k^2 \, \frac{N!}{k!\,(N-k)!} \, p^k q^{N-k} = Np \sum_{k=1}^{N} k \, \frac{(N-1)!}{(k-1)!\,(N-k)!} \, p^{k-1} q^{N-k},$$

dove, come per la media, si è tolto il termine $k = 0$ (che è nullo), si è semplificato un k con il fattoriale ($k^2/k! = k/(k-1)!$) e si sono portati fuori N (da $N! = N\,(N-1)!$) e un p. A differenza della media, però, resta un fattore k davanti, e la somma non è più un binomio di Newton. Il trucco per toglierlo è usare una **derivata**.

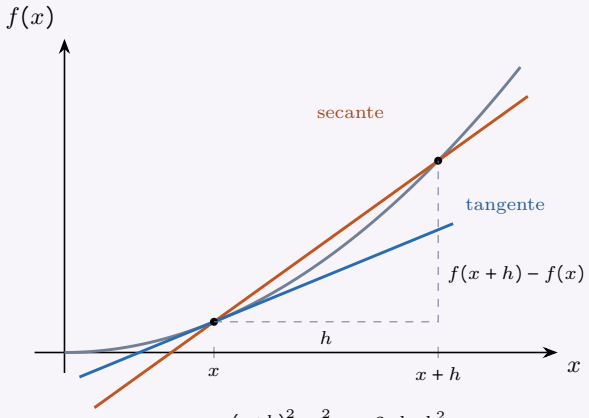
Richiamo di matematica: la derivata

Si disegni il grafico di una funzione $f(x)$. La **derivata** $f'(x)$ dice quanto è **ripida** la curva nel punto x: è la pendenza della retta tangente, cioè di quanto sale la curva per ogni passo verso destra.
Per calcolarla si prende un secondo punto vicino, $x + h$. La retta che passa per i due punti (la *secante*) ha pendenza «salita diviso spostamento», il **rapporto incrementale**:

$$\frac{f(x+h) - f(x)}{h}.$$

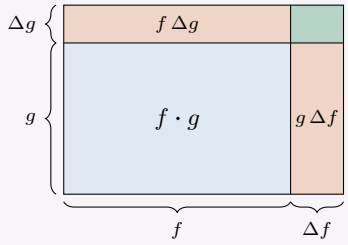
Quando h si avvicina a zero, il secondo punto scivola sul primo e la secante diventa la tangente. La derivata è il limite del rapporto incrementale:

$$f'(x) = \frac{\mathrm{d}f}{\mathrm{d}x} = \lim_{h \to 0} \frac{f(x+h) - f(x)}{h}.$$



Esempio: per $f(x) = x^2$ il rapporto incrementale è $\frac{(x+h)^2 - x^2}{h} = \frac{2xh + h^2}{h} = 2x + h$, che per $h \to 0$ tende a $2x$. Quindi $(x^2)' = 2x$: la parabola è piatta in $x = 0$ e sempre più ripida allontanandosi.
Le regole che ci servono:

- una costante ha derivata nulla: $(c)' = 0$ (il suo grafico è piatto);
- $(x^n)' = n\,x^{n-1}$. Per il binomio di Newton $(x+h)^n = x^n + n\,x^{n-1}h +$ (termini con h^2, h^3, …); togliendo x^n e dividendo per h resta $n\,x^{n-1} +$ (termini con h), che tendono a zero;
- **linearità**: $(af + bg)' = af' + bg'$; in particolare la derivata di una somma (anche di molti termini) è la somma delle derivate;
- **regola del prodotto**: $(fg)' = f'g + fg'$ (spiegata dal disegno qui sotto);
- $\big((x+c)^m\big)' = m\,(x+c)^{m-1}$: spostare il grafico in orizzontale non cambia le pendenze.



Il prodotto $f \cdot g$ è l'area di un rettangolo. Quando x cresce di h, i lati crescono di Δf e Δg, e l'area cresce di $f\,\Delta g + g\,\Delta f + \Delta f\,\Delta g$ (le strisce arancioni e il quadratino verde). Dividendo per h e mandando h a zero, $\Delta f/h \to f'$, $\Delta g/h \to g'$, mentre il quadratino, che è piccolo «due volte», sparisce: resta $f'g + fg'$.

Derivare rispetto a una lettera tenendo ferme le altre. Se un'espressione contiene due lettere, per esempio p e q, si può derivare rispetto a p trattando q come un numero fisso: $\frac{\mathrm{d}}{\mathrm{d}p}\left(p^2 q^3\right) = 2p\,q^3$. Lo useremo con q, che solo alla fine sostituiremo con $1 - p$.

Teorema 7.2 — Varianza della binomiale

Se $X \sim \mathcal{B}(N, p)$, allora

$$E[X^2] = Np\,(1-p) + N^2p^2, \qquad \sigma_X^2 = Np\,(1-p), \qquad \sigma_X = \sqrt{Np\,(1-p)}.$$

Dimostrazione — il trucco della derivata

Passo 1 — L'idea. Un fattore k davanti a p^{k-1} è proprio quello che produce la derivata: $k\,p^{k-1} = \frac{\mathrm{d}}{\mathrm{d}p}\,p^k$. Trattando q come una lettera indipendente da p (e sostituendo $q = 1-p$ solo alla fine), ogni termine della somma è la derivata rispetto a p di un termine senza il fattore k:

$$E[X^2] = Np \sum_{k=1}^{N} \frac{(N-1)!}{(k-1)!\,(N-k)!}\,\frac{\mathrm{d}}{\mathrm{d}p}\left(p^k\right) q^{N-k} = Np\,\frac{\mathrm{d}}{\mathrm{d}p}\left[\sum_{k=1}^{N} \frac{(N-1)!}{(k-1)!\,[(N-1)-(k-1)]!}\,p^k q^{N-k}\right]_{q=1-p}$$

(la derivata di una somma è la somma delle derivate, e i fattori che non contengono p restano fuori dalla derivata).

Passo 2 — Si riconosce un binomio di Newton. Posto $l = k-1$, e staccando un fattore p da $p^k = p \cdot p^l$:

$$\sum_{k=1}^{N} \frac{(N-1)!}{(k-1)!\,[(N-1)-(k-1)]!}\,p^k q^{N-k} = p \sum_{l=0}^{N-1} \frac{(N-1)!}{l!\,[(N-1)-l]!}\,p^l q^{N-1-l} = p\,(p+q)^{N-1}.$$

Passo 3 — Si deriva. Con la regola del prodotto, e ricordando che q è fisso:

$$\frac{\mathrm{d}}{\mathrm{d}p}\left[p\,(p+q)^{N-1}\right] = (p+q)^{N-1} + p\,(N-1)\,(p+q)^{N-2}.$$

Passo 4 — Si sostituisce $q = 1-p$. Ora $p+q=1$, e le sue potenze valgono 1:

$$E[X^2] = Np\,[1 + p\,(N-1)] = Np\,[1 + Np - p] = Np\,(1-p) + N^2p^2.$$

Passo 5 — La varianza. Siccome $\mu_X = Np$ (Teorema 5.3), il secondo addendo è proprio μ_X^2:

$$\sigma_X^2 = E[X^2] - \mu_X^2 = Np\,(1-p) + N^2p^2 - N^2p^2 = Np\,(1-p).$$

■

Lo stesso risultato si ottiene in un modo più semplice, che evita le derivate: invece di $E[X^2]$ si calcola $E[X(X-1)]$, perché il fattore $k(k-1)$ si semplifica con il fattoriale ancora meglio di k^2.

Dimostrazione — secondo modo: il momento fattoriale

Passo 1 — Si calcola $E[X(X-1)]$. Per il teorema fondamentale, con $g(x) = x(x-1)$. I termini con $k=0$ e $k=1$ sono nulli; per $k \geq 2$, $\frac{k(k-1)}{k!} = \frac{1}{(k-2)!}$:

$$E[X(X-1)] = \sum_{k=2}^{N} k(k-1)\,\frac{N!}{k!\,(N-k)!}\,p^k(1-p)^{N-k} = N(N-1)\,p^2 \sum_{k=2}^{N} \frac{(N-2)!}{(k-2)!\,[N-2-(k-2)]!}\,p^{k-2}(1-p)^{N-2-(k-2)}.$$

Passo 2 — Newton ancora una volta. Con $l = k-2$ e $M = N-2$ la somma diventa $\sum_{l=0}^{M} \frac{M!}{l!\,(M-l)!}\,p^l(1-p)^{M-l} = 1$, quindi $E[X(X-1)] = N(N-1)\,p^2$.

Passo 3 — Si torna a $E[X^2]$. Sempre per il teorema fondamentale, la media di una differenza si spezza: $E[X(X-1)] = \sum_x (x^2 - x)\,p_X(x) = E[X^2] - E[X]$. Quindi

$$E[X^2] = E[X(X-1)] + E[X] = N(N-1)\,p^2 + Np = N^2p^2 - Np^2 + Np = Np\,(1-p) + N^2p^2.$$

■

Da ricordare: binomiale $\mathcal{B}(N,p)$

$$\mu_X = Np \qquad X^2_{rms} = Np\,(1-p) + N^2p^2 \qquad \sigma_X^2 = Np\,(1-p) \qquad \sigma_X = \sqrt{Np\,(1-p)}$$

LA VARIANZA DELL'UNIFORME

Sia $X \sim \mathcal{U}(\{0, 1, \ldots, M-1\})$, per cui $\mu_X = \frac{M-1}{2}$ (Capitolo 5). Il valore quadratico medio è

$$X_{rms}^2 = \frac{1}{M}\sum_{k=0}^{M-1} k^2 = \frac{1}{M}\sum_{k=1}^{M-1} k^2,$$

e serve la somma dei primi quadrati. Invece di cercarla per tentativi, la ricaviamo con un trucco che spiega da dove viene la formula.

Richiamo di matematica: le somme telescopiche

Una somma in cui ogni termine è una differenza fra due valori consecutivi, $a_{l+1} - a_l$, si semplifica quasi tutta:

$$\sum_{l=1}^{n}(a_{l+1} - a_l) = (a_2 - a_1) + (a_3 - a_2) + (a_4 - a_3) + \cdots + (a_{n+1} - a_n) = a_{n+1} - a_1.$$

Ogni a_l intermedio compare una volta con il più e una volta con il meno, e si cancella: restano solo l'ultimo e il primo. Il nome viene dal cannocchiale (telescopio) che si chiude, con i tubi che rientrano uno nell'altro.

Teorema 7.3 — Somma dei primi quadrati

Per ogni naturale $n \geq 1$:

$$\sum_{l=1}^{n} l^2 = 1^2 + 2^2 + \cdots + n^2 = \frac{n\,(n+1)\,(2n+1)}{6}.$$

Dimostrazione — con una somma telescopica

Passo 1 — Il cubo di un binomio. Per ogni l: $(l+1)^3 = l^3 + 3l^2 + 3l + 1$, quindi

$$(l+1)^3 - l^3 = 3l^2 + 3l + 1.$$

Passo 2 — Si somma da 1 a n. A sinistra c'è una somma telescopica, che vale $(n+1)^3 - 1^3$. A destra si spezza la somma in tre, chiamando S la somma dei quadrati che cerchiamo e usando la somma di Gauss (Teorema 5.4):

$$(n+1)^3 - 1 = 3S + 3\,\frac{n\,(n+1)}{2} + n.$$

Passo 3 — Si ricava S. Si porta tutto il resto a sinistra e si raccoglie $(n+1)$:

$$3S = (n+1)^3 - 1 - n - \frac{3n\,(n+1)}{2} = (n+1)^3 - (n+1) - \frac{3n\,(n+1)}{2} = (n+1)\left[(n+1)^2 - 1 - \frac{3n}{2}\right].$$

Dentro la parentesi: $(n+1)^2 - 1 - \frac{3n}{2} = n^2 + 2n - \frac{3n}{2} = n^2 + \frac{n}{2} = \frac{n\,(2n+1)}{2}$. Quindi $3S = \frac{n\,(n+1)\,(2n+1)}{2}$ e $S = \frac{n\,(n+1)\,(2n+1)}{6}$.

Passo 4 — Una verifica. Con $n = 3$: $1 + 4 + 9 = 14$ e $\frac{3 \cdot 4 \cdot 7}{6} = 14$.

■

Teorema 7.4 — Varianza dell'uniforme

Se $X \sim \mathcal{U}(\{0, 1, \ldots, M-1\})$:

$$\mu_X = \frac{M-1}{2}, \qquad X_{rms}^2 = \frac{(M-1)(2M-1)}{6}, \qquad \sigma_X^2 = \frac{M^2-1}{12}.$$

Dimostrazione

Passo 1 — Il valore quadratico medio. Con la somma dei quadrati, $n = M - 1$:

$$X_{rms}^2 = \frac{1}{M} \cdot \frac{(M-1)\,M\,(2M-1)}{6} = \frac{(M-1)(2M-1)}{6}.$$

Passo 2 — La varianza. Si sottrae $\mu_X^2 = (M-1)^2/4$ e si porta tutto al denominatore comune 12:

$$\sigma_X^2 = \frac{(M-1)(2M-1)}{6} - \frac{(M-1)^2}{4} = \frac{2(M-1)(2M-1) - 3(M-1)^2}{12}.$$

Passo 3 — Si sviluppano i prodotti.

$$\sigma_X^2 = \frac{2\,(2M^2 - M - 2M + 1) - 3\,(M^2 - 2M + 1)}{12} = \frac{4M^2 - 6M + 2 - 3M^2 + 6M - 3}{12} = \frac{M^2 - 1}{12}.$$

■

Esempio 7.2 — Dado e byte

- Un byte casuale ($M = 256$): $\sigma_X^2 = \frac{65\,536-1}{12} \approx 5\,461$ e $\sigma_X \approx 73{,}9$.
- Un dado onesto ha valori $1, \dots, 6$: sono i valori $0, \dots, 5$ ($M = 6$) aumentati di 1. Vedremo fra poco che aggiungere una costante non cambia la varianza, quindi $\sigma_X^2 = \frac{36-1}{12} = \frac{35}{12} \approx 2{,}92$ e $\sigma_X \approx 1{,}71$.

La varianza della Poisson

Per la Poisson useremo lo stesso trucco della derivata, questa volta su una serie. Serve sapere come si deriva l'esponenziale; è anche l'occasione per capire, finalmente, da dove viene la serie esponenziale.

Richiamo di matematica: la derivata dell'esponenziale e la serie esponenziale

La derivata di e^x è e^x. Il rapporto incrementale è

$$\frac{e^{x+h} - e^x}{h} = e^x\,\frac{e^h - 1}{h},$$

e il secondo fattore tende a 1: è la proprietà che distingue il numero e da tutte le altre basi.

h	0,1	0,01	0,001	0,0001
$\frac{e^h - 1}{h}$	1,0517	1,0050	1,0005	1,00005

Quindi $(e^x)' = e^x$: la curva e^x è ripida esattamente quanto è alta (con la base 2 la pendenza in 0 sarebbe circa 0,69, con la base 3 circa 1,10; con e è esattamente 1).

La derivata di e^{-x}. Siccome $e^{-x} \cdot e^x = 1$, derivando con la regola del prodotto si ottiene $(e^{-x})'\,e^x + e^{-x}\,e^x = 0$, cioè $(e^{-x})' = -e^{-x}$.

Da dove viene la serie. Sia $S(x) = \sum_{k=0}^{\infty} \frac{x^k}{k!} = 1 + x + \frac{x^2}{2} + \cdots$. Una serie di potenze come questa si può derivare termine a termine, e $\left(\frac{x^k}{k!}\right)' = \frac{k\,x^{k-1}}{k!} = \frac{x^{k-1}}{(k-1)!}$: ogni termine diventa il precedente, quindi $S'(x) = S(x)$. Inoltre $S(0) = 1$. Anche e^x ha queste due proprietà, e le due funzioni coincidono: la funzione $D(x) = S(x)\,e^{-x}$ ha derivata

$$D'(x) = S'(x)\,e^{-x} + S(x)\,(e^{-x})' = S(x)\,e^{-x} - S(x)\,e^{-x} = 0,$$

quindi è costante (una curva con pendenza sempre nulla è piatta) e vale $D(0) = 1$. Allora $S(x)\,e^{-x} = 1$, cioè $S(x) = e^x$.

Teorema 7.5 — Varianza della Poisson

Se $X \sim \mathcal{P}(\lambda)$:

$$\mu_X = \lambda, \qquad X_{rms}^2 = \lambda + \lambda^2, \qquad \sigma_X^2 = \lambda, \qquad \sigma_X = \sqrt{\lambda}.$$

Per una variabile di Poisson la media e la varianza coincidono.

Dimostrazione — il trucco della derivata

Passo 1 — Si prepara la somma. Si toglie il termine $k = 0$ (nullo), si semplifica $k^2/k! = k/(k-1)!$ e si porta fuori $e^{-\lambda}$ e un λ:

$$X_{rms}^2 = e^{-\lambda} \sum_{k=0}^{\infty} k^2 \frac{\lambda^k}{k!} = e^{-\lambda} \sum_{k=1}^{\infty} k \frac{\lambda^k}{(k-1)!} = e^{-\lambda}\, \lambda \sum_{k=1}^{\infty} k \frac{\lambda^{k-1}}{(k-1)!}.$$

Passo 2 — Il fattore k diventa una derivata. $k\,\lambda^{k-1} = \frac{\mathrm{d}}{\mathrm{d}\lambda}\lambda^k$, e la serie si deriva termine a termine:

$$X_{rms}^2 = e^{-\lambda}\, \lambda \frac{\mathrm{d}}{\mathrm{d}\lambda}\left(\sum_{k=1}^{\infty} \frac{\lambda^k}{(k-1)!}\right) = e^{-\lambda}\, \lambda \frac{\mathrm{d}}{\mathrm{d}\lambda}\left(\lambda \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!}\right).$$

Passo 3 — Si riconosce l'esponenziale. Posto $l = k - 1$, la serie è $\sum_{l=0}^{\infty} \frac{\lambda^l}{l!} = e^{\lambda}$:

$$X_{rms}^2 = e^{-\lambda}\, \lambda \frac{\mathrm{d}}{\mathrm{d}\lambda}\left(\lambda\, e^{\lambda}\right).$$

Passo 4 — Si deriva con la regola del prodotto. $\frac{\mathrm{d}}{\mathrm{d}\lambda}\left(\lambda\, e^{\lambda}\right) = e^{\lambda} + \lambda\, e^{\lambda}$, quindi

$$X_{rms}^2 = e^{-\lambda}\, \lambda \left(e^{\lambda} + \lambda\, e^{\lambda}\right) = \lambda + \lambda^2.$$

Passo 5 — La varianza. $\sigma_X^2 = X_{rms}^2 - \mu_X^2 = \lambda + \lambda^2 - \lambda^2 = \lambda$.

■

Dimostrazione — secondo modo: il momento fattoriale

Passo 1. I termini con $k = 0$ e $k = 1$ sono nulli; per $k \geq 2$ si semplifica $k(k-1)/k! = 1/(k-2)!$ e, posto $l = k - 2$:

$$E[X(X-1)] = \sum_{k=2}^{\infty} k\,(k-1)\, e^{-\lambda} \frac{\lambda^k}{k!} = e^{-\lambda}\, \lambda^2 \sum_{k=2}^{\infty} \frac{\lambda^{k-2}}{(k-2)!} = e^{-\lambda}\, \lambda^2 \sum_{l=0}^{\infty} \frac{\lambda^l}{l!} = e^{-\lambda}\, \lambda^2\, e^{\lambda} = \lambda^2.$$

Passo 2. Quindi $E[X^2] = E[X(X-1)] + E[X] = \lambda^2 + \lambda$.

■

LE PROPRIETÀ DELLA MEDIA E DELLA VARIANZA

Teorema 7.6 — Media e varianza di una trasformazione lineare

Siano a e b costanti reali e $Y = aX + b$. Allora:

a) $E[aX + b] = a\,E[X] + b$ (in particolare $E[b] = b$: la media di una costante è la costante);
b) $\sigma_Y^2 = a^2 \sigma_X^2$: la costante b non modifica la varianza, e la costante a va elevata al quadrato (quindi $\sigma_Y = |a|\,\sigma_X$);
c) $E[Y^2] = Y_{rms}^2 = a^2 X_{rms}^2 + b^2 + 2ab\,\mu_X$.

Dimostrazione

Passo 1 — La media. Per il teorema fondamentale, con $g(x) = ax + b$:

$$E[aX + b] = \sum_x (ax + b)\, p_X(x) = a \sum_x x\, p_X(x) + b \sum_x p_X(x) = a\, E[X] + b.$$

Passo 2 — La varianza. Per il passo precedente $\mu_Y = a\mu_X + b$, quindi lo scarto di Y dalla sua media è $Y - \mu_Y = aX + b - a\mu_X - b = a\,(X - \mu_X)$: la b si cancella. Allora

$$\sigma_Y^2 = E\left[(Y - \mu_Y)^2\right] = E\left[a^2 (X - \mu_X)^2\right] = a^2\, E\left[(X - \mu_X)^2\right] = a^2 \sigma_X^2,$$

dove si è usato il passo 1 per portare fuori la costante a^2.

Passo 3 — Il valore quadratico medio. Per il Teorema 7.1, $E[Y^2] = \sigma_Y^2 + \mu_Y^2$:

$$E[Y^2] = a^2\sigma_X^2 + (a\mu_X + b)^2 = a^2\sigma_X^2 + a^2\mu_X^2 + b^2 + 2ab\,\mu_X = a^2\left(\sigma_X^2 + \mu_X^2\right) + b^2 + 2ab\,\mu_X = a^2 X_{rms}^2 + b^2 + 2ab\,\mu_X.$$

■

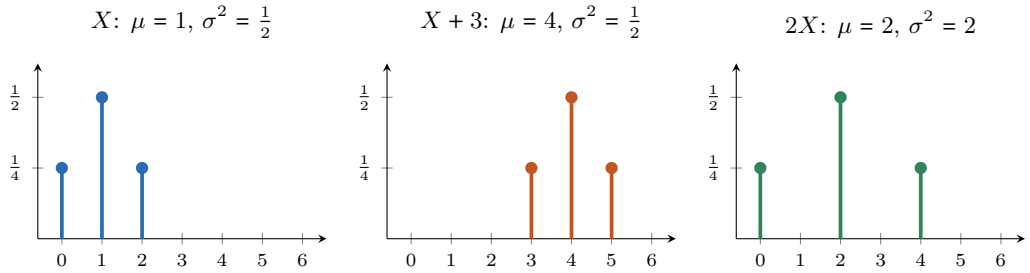


Figura 7.3: *Aggiungere una costante sposta la pmf ma non la allarga: la varianza resta la stessa. Moltiplicare per 2 allarga le distanze di 2 volte, quindi la varianza (che è una media di distanze al quadrato) di 4 volte.*

Altre tre proprietà discendono direttamente dalle definizioni:

- se $X(\omega) \geq 0$ per ogni $\omega \in \Omega$ (una variabile aleatoria **non negativa**), allora $E[X] = \sum_x x\, p_X(x) \geq 0$, perché è una somma di prodotti di quantità non negative;
- $\sigma_X^2 \geq 0$ sempre, perché $\sigma_X^2 = \sum_x (x - \mu_X)^2 p_X(x)$ è una somma di prodotti di quantità non negative (o, se si preferisce, la media della variabile non negativa $(X - \mu_X)^2$);
- per le variabili a **media nulla** ($\mu_X = 0$) varianza e valore quadratico medio coincidono: $\sigma_X^2 = X_{rms}^2$.

In particolare, ponendo $a = 1$ e $b = -\mu_X$ nella proprietà a): $E[X - \mu_X] = \mu_X - \mu_X = 0$, come avevamo anticipato all'inizio del capitolo.

Variabile	**Alfabeto**	**pmf**	**Media**	**Varianza**
Bernoulli $\mathcal{B}(1,p)$	$\{0,1\}$	$p_X(1) = p$, $p_X(0) = 1-p$	p	$p(1-p)$
binomiale $\mathcal{B}(N,p)$	$\{0,\dots,N\}$	$\binom{N}{k} p^k (1-p)^{N-k}$	Np	$Np(1-p)$
uniforme $\mathcal{U}(\{0,\dots,M-1\})$	$\{0,\dots,M-1\}$	$\frac{1}{M}$	$\frac{M-1}{2}$	$\frac{M^2-1}{12}$
Poisson $\mathcal{P}(\lambda)$	$\mathbb{N}_0$	$\frac{\lambda^k}{k!} e^{-\lambda}$	λ	λ

Tabella 7.1: *Le variabili aleatorie discrete notevoli.*

La disuguaglianza di Markov

Media e varianza sono «riassunti» della pmf. Quanto si può dire su una variabile aleatoria conoscendo solo quelli? Sorprendentemente molto, grazie a due disuguaglianze che valgono per **qualsiasi** pmf.

Teorema 7.7 — Disuguaglianza di Markov

Sia Z una variabile aleatoria **non negativa**, con alfabeto discreto $\mathcal{Z} \subseteq [0, +\infty[$ e pmf $p_Z(z)$. Allora, per qualunque $\delta > 0$:

$$P(Z \geq \delta) \leq \frac{E[Z]}{\delta}.$$

Dimostrazione

Passo 1 — La probabilità della coda. L'evento $\{Z \geq \delta\}$ si verifica quando Z assume uno dei valori $z \geq \delta$:

$$P(Z \geq \delta) = \sum_{z\,:\,z \geq \delta} p_Z(z).$$

Passo 2 — (a) Si moltiplica per un numero ≥ 1. Per i valori $z \geq \delta$ della somma vale $\frac{z}{\delta} \geq 1$; moltiplicando ogni termine per $\frac{z}{\delta}$, la somma non può diminuire:

$$\sum_{z\,:\,z \geq \delta} p_Z(z) \leq \sum_{z\,:\,z \geq \delta} \frac{z}{\delta}\, p_Z(z).$$

Passo 3 — (b) Si estende la somma a tutto l'alfabeto. Aggiungendo anche i valori $z < \delta$ si aggiungono termini $\frac{z}{\delta} p_Z(z) \geq 0$ (perché Z è non negativa): la somma non può diminuire.

$$\sum_{z\,:\,z \geq \delta} \frac{z}{\delta}\, p_Z(z) \leq \sum_{z \in \mathcal{Z}} \frac{z}{\delta}\, p_Z(z).$$

Passo 4 — (c) Si riconosce la media. $\sum_{z \in \mathcal{Z}} \frac{z}{\delta}\, p_Z(z) = \frac{1}{\delta} \sum_z z\, p_Z(z) = \frac{E[Z]}{\delta}$, per la definizione di media. Mettendo in fila i tre passaggi:

$$P(Z \geq \delta) \underset{(a)}{\leq} \sum_{z \geq \delta} \frac{z}{\delta}\, p_Z(z) \underset{(b)}{\leq} \sum_{z \in \mathcal{Z}} \frac{z}{\delta}\, p_Z(z) \underset{(c)}{=} \frac{E[Z]}{\delta}.$$

■

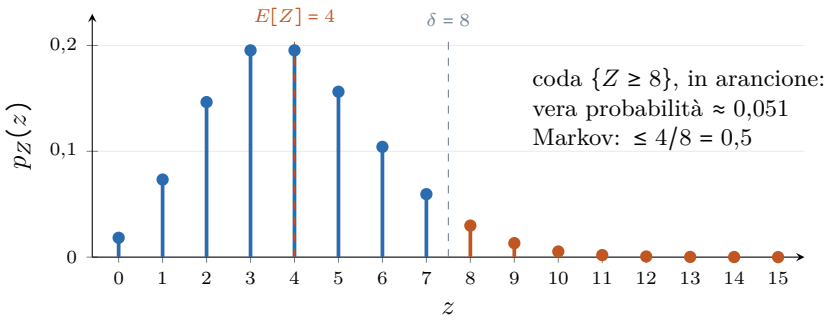


Figura 7.4: *Una Poisson con $\lambda = 4$. Markov garantisce che la coda oltre $\delta = 8$ abbia probabilità al più 0,5; quella vera è molto più piccola. La disuguaglianza è grossolana, ma vale per qualsiasi variabile non negativa di cui si conosca solo la media.*

Esempio 7.3 — La coda del router

Si sa soltanto che il numero medio di pacchetti in coda in un router è 2. Qual è, al massimo, la probabilità di trovarne 10 o più? Il numero di pacchetti è una variabile non negativa, quindi per Markov $P(Z \geq 10) \leq \frac{2}{10} = 0{,}2$. Senza sapere nient'altro della pmf, non si può dire di più; se poi si sapesse che Z è di Poisson, il conto esatto darebbe circa 0,00005.

La disuguaglianza di Chebyshev

La disuguaglianza di Markov vale per variabili non negative. Applicandola alla variabile non negativa $(X-\mu_X)^2$, che misura la distanza al quadrato dalla media, si ottiene un risultato che vale per **qualsiasi** variabile e che coinvolge la deviazione standard.

Teorema 7.8 — Disuguaglianza di Chebyshev

Sia X una variabile aleatoria con media μ_X e deviazione standard $\sigma_X > 0$. Per ogni $k > 0$:

$$P\left(|X-\mu_X| \geq k\,\sigma_X\right) \leq \frac{1}{k^2}.$$

Dimostrazione

Passo 1 — Le scelte. Si applica Markov con $Z = |X-\mu_X|^2$, che è non negativa, e $\delta = (k\,\sigma_X)^2 > 0$.

Passo 2 — La media di Z. Per variabili reali $|X-\mu_X|^2 = (X-\mu_X)^2$, quindi

$$E[Z] = E\left[|X-\mu_X|^2\right] = E\left[(X-\mu_X)^2\right] = \sigma_X^2.$$

Passo 3 — L'evento. Due numeri non negativi stanno nello stesso ordine dei loro quadrati, quindi $|X-\mu_X|^2 \geq (k\,\sigma_X)^2$ esattamente quando $|X-\mu_X| \geq k\,\sigma_X$.

Passo 4 — Markov. Mettendo insieme:

$$P\left(|X-\mu_X|^2 \geq (k\,\sigma_X)^2\right) = P\left(|X-\mu_X| \geq k\,\sigma_X\right) \leq \frac{\sigma_X^2}{k^2\sigma_X^2} = \frac{1}{k^2}.$$

■

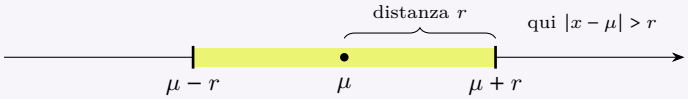
Il significato della varianza e della deviazione standard

La disuguaglianza di Chebyshev si può leggere «al contrario», guardando la probabilità di restare *vicini* alla media. Serve un richiamo sul valore assoluto.

Richiamo di matematica: valore assoluto e intervalli

Il **valore assoluto** $|a|$ è il numero a senza segno: $|3| = |-3| = 3$. La quantità $|x-\mu|$ è la **distanza** fra x e μ sulla retta dei numeri. Dire che la distanza non supera r vuol dire che x sta nell'intervallo centrato in μ di raggio r:

$$|x-\mu| \leq r \iff -r \leq x-\mu \leq r \iff \mu - r \leq x \leq \mu + r.$$



Teorema 7.9 — Quanto si resta vicini alla media

Per ogni variabile aleatoria e ogni $k > 0$:

$$P\left(\mu_X - k\,\sigma_X \leq X \leq \mu_X + k\,\sigma_X\right) \geq 1 - \frac{1}{k^2}.$$

Dimostrazione

Passo 1 — Si passa al complementare. L'evento «distanza minore di $k\sigma_X$» è il complementare di «distanza almeno $k\sigma_X$»:

$$P\left(|X-\mu_X| < k\,\sigma_X\right) = 1 - P\left(|X-\mu_X| \geq k\,\sigma_X\right) \geq 1 - \frac{1}{k^2},$$

perché togliendo da 1 un numero che è al più $1/k^2$ si ottiene almeno $1 - 1/k^2$.

Passo 2 — Si aggiunge l'uguaglianza. Se nella disuguaglianza a sinistra si ammette anche l'uguaglianza ($|X-\mu_X| \leq k\,\sigma_X$) si aggiunge una quantità non negativa (che può anche essere nulla), e la disuguaglianza resta vera a maggior ragione.

Passo 3 — Si toglie il valore assoluto. Per il richiamo, $|X-\mu_X| \leq k\,\sigma_X$ equivale a $-k\sigma_X \leq X - \mu_X \leq k\sigma_X$, cioè a $\mu_X - k\sigma_X \leq X \leq \mu_X + k\sigma_X$.

■

Il teorema dice che la deviazione standard è il **righello naturale** della variabile: qualunque sia la pmf, almeno il 75% della probabilità sta entro 2 deviazioni standard dalla media, almeno l'89% entro 3, almeno il 99% entro 10.

k	1	1,5	2	3	4	10
$1 - 1/k^2$	0	0,56	0,75	0,89	0,94	0,99

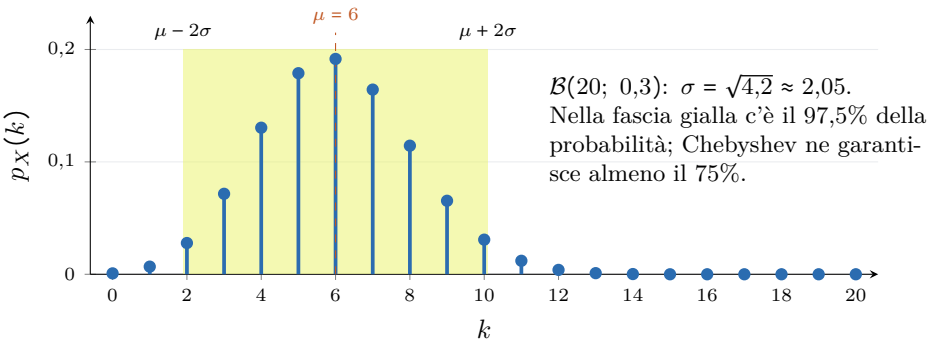


Figura 7.5: *La fascia $\mu \pm 2\sigma$ per una binomiale. Come Markov, anche Chebyshev è prudente: vale per tutte le pmf, quindi per una pmf particolare la probabilità vera è di solito molto più alta del limite garantito.*

Riscrivendo il teorema in termini relativi, il parametro fondamentale risulta il rapporto μ_X/σ_X. Valori elevati di questo rapporto indicano una pmf molto concentrata intorno alla media rispetto alla sua posizione (una variabile «poco aleatoria»), mentre valori bassi indicano un'elevata aleatorietà. (Una funzione è molto concentrata se è sostanzialmente diversa da zero in un intervallo piccolo rispetto al suo valore centrale.)

Esempio 7.4 — Poisson grandi e piccole

Per una Poisson $\mu_X/\sigma_X = \lambda/\sqrt{\lambda} = \sqrt{\lambda}$. Con $\lambda = 1$ il rapporto vale 1: la variabile vale spesso 0, 1, 2, 3, cioè fluttua quanto è grande. Con $\lambda = 100$ il rapporto vale 10: la variabile vale circa 100 ± 10, fluttuazioni del 10%. Con $\lambda = 10\,000$, circa $10\,000 \pm 100$: l'1%. Più eventi rari si contano, più il loro numero diventa prevedibile in proporzione.

In sintesi

- Valore quadratico medio $E[X^2]$, valore efficace $\sqrt{E[X^2]}$, varianza $\sigma_X^2 = E[(X-\mu_X)^2] = E[X^2] - \mu_X^2$, deviazione standard σ_X.
- Bernoulli: $p(1-p)$. Binomiale: $Np(1-p)$. Uniforme su $\{0,\dots,M-1\}$: $(M^2-1)/12$. Poisson: λ (uguale alla media). Si calcolano con il trucco della derivata o con $E[X(X-1)]$.
- La **derivata** è la pendenza della tangente: $(x^n)' = nx^{n-1}$, $(fg)' = f'g + fg'$, $(e^x)' = e^x$; da qui la serie $e^x = \sum x^k/k!$.
- $E[aX+b] = aE[X] + b$; $\sigma^2_{aX+b} = a^2\sigma_X^2$; $E[X] \geq 0$ se $X \geq 0$; $\sigma^2 \geq 0$.
- **Markov**: $P(Z \geq \delta) \leq E[Z]/\delta$ per $Z \geq 0$. **Chebyshev**: $P(|X-\mu_X| \geq k\sigma_X) \leq 1/k^2$, cioè $P(\mu_X - k\sigma_X \leq X \leq \mu_X + k\sigma_X) \geq 1 - 1/k^2$: la deviazione standard è il righello della dispersione, e μ/σ misura la concentrazione.

VARIABILI ALEATORIE MULTIPLE

Molti esperimenti producono più numeri insieme: di una persona scelta a caso si possono misurare l'altezza, il peso e l'età; da un canale di comunicazione esce un bit, ma interessa anche quale bit era entrato; una sorgente emette parole di più bit. Questi numeri vanno descritti **insieme**, perché spesso sono legati fra loro: le persone alte tendono a pesare di più, il bit ricevuto dipende da quello trasmesso. In questo capitolo introduciamo le coppie (e le terne, e le m-ple) di variabili aleatorie, la loro **pmf congiunta**, le **marginali**, le **condizionate** e l'**indipendenza**.

COPPIE DI VARIABILI ALEATORIE

Coppia di variabili aleatorie

Una **coppia di variabili aleatorie** (o **variabile doppia**) associa a ogni risultato ω di un esperimento una coppia ordinata di numeri:

$$(X, Y) : \omega \in \Omega \longmapsto (X(\omega), Y(\omega)) \in \mathcal{X} \times \mathcal{Y} \subseteq \mathbb{R}^2,$$

dove $\mathcal{X}$ e $\mathcal{Y}$ sono gli alfabeti di X e di Y.

In altre parole, il risultato di un esperimento non è più un unico valore $X(\omega) = x \in \mathcal{X}$, ma una coppia ordinata $(X(\omega), Y(\omega)) = (x, y)$ che varia nel prodotto cartesiano $\mathcal{X} \times \mathcal{Y}$: un punto del piano invece che un punto della retta.

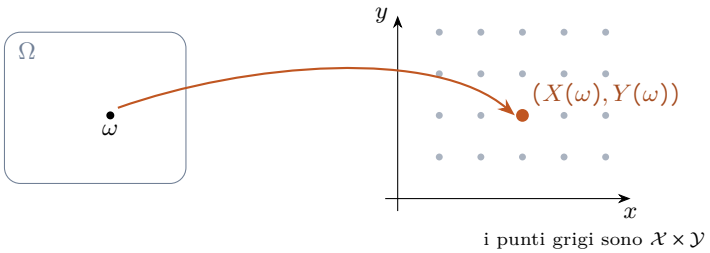


Figura 8.1: *Una coppia di variabili aleatorie manda ogni risultato in un punto del piano.*

Esempio 8.1 — Altezza, peso ed età

Si consideri l'elenco di tutti i residenti in Italia a una certa data, con altezza (X), peso (Y) ed età (Z). Si sceglie un residente a caso e se ne leggono l'altezza in centimetri, $X(\omega) \in \{30, 31, \ldots, 210\}$, il peso in chilogrammi, $Y(\omega) \in \{0{,}5;\ 0{,}6;\ \ldots;\ 170\}$, e l'età in anni, $Z(\omega) \in \{0, 1, \ldots, 110\}$. Possibili coppie sono $(X, Y) \in \mathcal{X} \times \mathcal{Y}$, $(X, Z) \in \mathcal{X} \times \mathcal{Z}$, $(Y, Z) \in \mathcal{Y} \times \mathcal{Z}$; e $(X, Y, Z) \in \mathcal{X} \times \mathcal{Y} \times \mathcal{Z}$ è una **terna** di variabili aleatorie.

La pmf congiunta

Come per una variabile sola, la descrizione completa si ottiene dalle frequenze.

- Si considera la coppia (X, Y) (nell'esempio: altezza e peso di un residente scelto a caso).
- Si eseguono n esperimenti (si sceglie n volte a caso un nome dall'elenco).
- Si registrano i valori $(X(\tilde{\omega}_i), Y(\tilde{\omega}_i))$ (altezza e peso del residente scelto di volta in volta).
- Si indica con $n_{X=x,\,Y=y}$ il numero di volte in cui è uscito $X = x$ *e* $Y = y$ (il residente aveva altezza x e peso y): è il numero di occorrenze dell'evento $\{X = x\} \cap \{Y = y\}$.

Pmf congiunta

La **pmf congiunta** (o DF congiunta) delle due variabili aleatorie X e Y è

$$p_{X,Y}(x, y) = P(\{X = x\} \cap \{Y = y\}) = \lim_{n\to\infty} \frac{n_{X=x,\,Y=y}}{n}, \qquad (x, y) \in \mathcal{X} \times \mathcal{Y}.$$

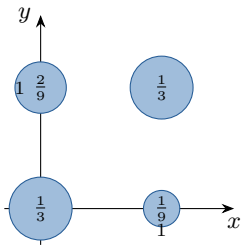
Si scrive anche $P(X = x, Y = y)$, dove la virgola si legge «e».

La pmf congiunta è quindi una **tabella** di $|\mathcal{X}| \cdot |\mathcal{Y}|$ numeri, una casella per ogni coppia di valori, che gode di certe proprietà.

Esempio 8.2 — Una pmf congiunta su due bit

Due variabili X e Y con alfabeto $\{0, 1\}$ hanno la pmf congiunta della tabella (la ritroveremo nel prossimo capitolo):

$p_{X,Y}(x,y)$	$y = 0$	$y = 1$
$x = 0$	$\frac{1}{3}$	$\frac{2}{9}$
$x = 1$	$\frac{1}{9}$	$\frac{1}{3}$



A destra la stessa pmf disegnata come «bolle»: ogni punto (x, y) ha un cerchio di area proporzionale alla sua probabilità. I quattro numeri sono positivi e sommano a $\frac{3+2+1+3}{9} = 1$.

Proprietà della pmf congiunta

Teorema 8.1 — Proprietà della pmf congiunta

$$p_{X,Y}(x, y) \geq 0 \qquad \text{e} \qquad \sum_{x\in\mathcal{X},\, y\in\mathcal{Y}} p_{X,Y}(x, y) = 1.$$

Dimostrazione

Passo 1 — Non negatività. È una probabilità.

Passo 2 — La somma. In ogni prova la coppia assume esattamente un valore (x, y): gli eventi elementari $\{X = x, Y = y\}$ sono a due a due incompatibili (un evento $\{X = x, Y = y\}$ è incompatibile con ogni altro evento $\{X = x', Y = y'\}$ con $(x', y') \neq (x, y)$) e la loro unione è Ω. Per l'additività:

$$1 = P(\Omega) = P\left(\bigcup_{x\in\mathcal{X},\, y\in\mathcal{Y}} \{X = x, Y = y\}\right) = \sum_{x\in\mathcal{X},\, y\in\mathcal{Y}} P(\{X = x, Y = y\}) = \sum_{x,\,y} p_{X,Y}(x, y).$$

■

Le pmf marginali

Dalla pmf congiunta si ricavano le pmf delle singole variabili. Si noti che

$$\bigcup_{x\in\mathcal{X}} \{X = x\} = \Omega, \qquad \bigcup_{y\in\mathcal{Y}} \{Y = y\} = \Omega :$$

qualche valore X lo assume sempre, e anche Y.

Teorema 8.2 — Marginalizzazione della pmf congiunta

$$p_X(x) = \sum_{y\in\mathcal{Y}} p_{X,Y}(x, y), \qquad p_Y(y) = \sum_{x\in\mathcal{X}} p_{X,Y}(x, y).$$

Le pmf p_X e p_Y ottenute così si chiamano **pmf marginali**.

Dimostrazione

Passo 1 — Si «affetta» l'evento $\{X = x\}$. Intersecando con $\Omega = \bigcup_y \{Y = y\}$ e usando la proprietà distributiva:

$$\{X = x\} = \{X = x\} \cap \Omega = \{X = x\} \cap \bigcup_{y\in\mathcal{Y}} \{Y = y\} = \bigcup_{y\in\mathcal{Y}} (\{X = x\} \cap \{Y = y\}) .$$

Passo 2 — Le fette sono incompatibili. Per $y \neq y'$ gli eventi $\{X = x\} \cap \{Y = y\}$ e $\{X = x\} \cap \{Y = y'\}$ non possono verificarsi insieme (Y non assume due valori). Quindi le probabilità si sommano:

$$p_X(x) = P(\{X = x\}) = \sum_{y\in\mathcal{Y}} P(\{X = x\} \cap \{Y = y\}) = \sum_{y\in\mathcal{Y}} p_{X,Y}(x, y).$$

Passo 3 — Per Y. Lo stesso ragionamento, scambiando i ruoli, dà $p_Y(y) = \sum_x p_{X,Y}(x, y)$.

■

Il nome viene da come si fanno i conti a mano: si sommano le righe e le colonne della tabella e si scrivono i totali **a margine**.

	$y = 0$	$y = 1$	$p_X(x)$
$x = 0$	$\frac{1}{3}$	$\frac{2}{9}$	$\frac{1}{3} + \frac{2}{9} = \frac{5}{9}$
$x = 1$	$\frac{1}{9}$	$\frac{1}{3}$	$\frac{1}{9} + \frac{1}{3} = \frac{4}{9}$
$p_Y(y)$	$\frac{1}{3} + \frac{1}{9} = \frac{4}{9}$	$\frac{2}{9} + \frac{1}{3} = \frac{5}{9}$	1

Figura 8.2: *Le pmf marginali sono le somme delle righe (in arancione, la pmf di X) e delle colonne (in blu, la pmf di Y), scritte ai margini della tabella della pmf congiunta.*

Quindi caratterizzare congiuntamente la coppia (X, Y) significa caratterizzare anche ciascuna variabile marginalmente. Il viceversa **non** è vero in generale: le marginali non bastano a ricostruire la congiunta.

Esempio 8.3 — Stesse marginali, congiunte diverse

Due bit X e Y, ognuno uguale a 0 o a 1 con probabilità $\frac{1}{2}$. Le due pmf congiunte qui sotto hanno entrambe queste marginali (si sommino righe e colonne), ma descrivono situazioni opposte: a sinistra i due bit non hanno nulla a che fare l'uno con l'altro; a destra sono sempre uguali (per esempio, il secondo è una copia del primo).

	$y=0$	$y=1$
$x=0$	$\frac{1}{4}$	$\frac{1}{4}$
$x=1$	$\frac{1}{4}$	$\frac{1}{4}$

	$y=0$	$y=1$
$x=0$	$\frac{1}{2}$	0
$x=1$	0	$\frac{1}{2}$

VARIABILI INDIPENDENTI

Variabili aleatorie indipendenti

Due variabili aleatorie X e Y sono **indipendenti** se (e solo se) gli eventi $\{X=x\}$ e $\{Y=y\}$ sono indipendenti per ogni coppia di valori (x,y). Per due variabili indipendenti la pmf congiunta **si fattorizza** nel prodotto delle marginali:

$$p_{X,Y}(x,y) = P(\{X=x\} \cap \{Y=y\}) = P(\{X=x\})\,P(\{Y=y\}) = p_X(x)\,p_Y(y).$$

Questo è l'unico caso in cui assegnare le due pmf marginali $p_X(x)$ e $p_Y(y)$ equivale ad assegnare la pmf congiunta. Nell'ultimo esempio la tabella di sinistra è quella di due bit indipendenti (ogni casella vale $\frac{1}{2}\cdot\frac{1}{2}$); quella di destra no ($p_{X,Y}(0,0) = \frac{1}{2} \neq \frac{1}{4}$).

Esempio 8.4 — Verificare l'indipendenza

- Due lanci di un dado onesto: $p_{X,Y}(i,j) = \frac{1}{36} = \frac{1}{6}\cdot\frac{1}{6} = p_X(i)\,p_Y(j)$ per ogni coppia: i due lanci sono indipendenti.
- La coppia dei due bit di prima, con marginali $p_X(0) = \frac{5}{9}$ e $p_Y(0) = \frac{4}{9}$: $p_{X,Y}(0,0) = \frac{1}{3} = \frac{27}{81}$, mentre $p_X(0)\,p_Y(0) = \frac{5}{9}\cdot\frac{4}{9} = \frac{20}{81}$. Basta una sola casella che non si fattorizza: le due variabili **non** sono indipendenti.

Il concetto di pmf congiunta si generalizza a una m-pla di variabili aleatorie $(X_1, X_2, \ldots, X_m) \in \mathcal{X}_1 \times \mathcal{X}_2 \times \cdots \times \mathcal{X}_m \subseteq \mathbb{R}^m$ mediante la pmf congiunta

$$p_{X_1,X_2,\ldots,X_m}(x_1,x_2,\ldots,x_m) = P\left(\{X_1=x_1\} \cap \{X_2=x_2\} \cap \cdots \cap \{X_m=x_m\}\right),$$

e il concetto di indipendenza si generalizza nel modo seguente: le m variabili sono indipendenti se

$$p_{X_1,\ldots,X_m}(x_1,\ldots,x_m) = \prod_{i=1}^{m} P(\{X_i=x_i\}) = \prod_{i=1}^{m} p_{X_i}(x_i)$$

per ogni scelta dei valori.

LE PMF CONDIZIONATE

Si considerino le variabili aleatorie $X \in \mathcal{X}$ e $Y \in \mathcal{Y}$ con assegnata pmf congiunta $p_{X,Y}(x,y)$. Applichiamo all'evento $\{X = x, Y = y\} = \{X = x\} \cap \{Y = y\}$ la legge della probabilità composta:

$$p_{X,Y}(x,y) = P(\{X = x\} \cap \{Y = y\}) = P(\{Y = y\} \mid \{X = x\})\, P(\{X = x\}) = p_{Y|X}(y \mid x)\, p_X(x).$$

Pmf condizionate

La **pmf condizionata di Y dato X** è, per $p_X(x) > 0$,

$$p_{Y|X}(y \mid x) = P(Y = y \mid X = x) = \frac{p_{X,Y}(x,y)}{p_X(x)},$$

e allo stesso modo $p_{X|Y}(x \mid y) = p_{X,Y}(x,y)/p_Y(y)$ per $p_Y(y) > 0$.

Come la legge congiunta, la legge condizionata $p_{Y|X}(y \mid x)$ è una tabella di $|\mathcal{X}| \cdot |\mathcal{Y}|$ numeri che soddisfa alcune proprietà. Siccome la congiunta si può scrivere condizionando in entrambi i modi,

$$p_{Y|X}(y \mid x)\, p_X(x) = p_{X,Y}(x,y) = p_{X|Y}(x \mid y)\, p_Y(y),$$

si ottiene subito la versione per le pmf del teorema di Bayes.

Da ricordare: legge di Bayes per le pmf

$$p_{X|Y}(x \mid y) = \frac{p_{Y|X}(y \mid x)\, p_X(x)}{p_Y(y)}$$

Teorema 8.3 — Proprietà delle pmf condizionate

a) Fissato y (con $p_Y(y) > 0$), al variare di x la funzione $p_{X|Y}(x \mid y)$ è una pmf: $p_{X|Y}(x \mid y) \geq 0$ e $\sum_{x \in \mathcal{X}} p_{X|Y}(x \mid y) = 1$.

b) Marginalizzazione con le condizionate:

$$p_X(x) = \sum_{y \in \mathcal{Y}} p_{X|Y}(x \mid y)\, p_Y(y), \qquad p_Y(y) = \sum_{x \in \mathcal{X}} p_{Y|X}(y \mid x)\, p_X(x).$$

c) Se X e Y sono indipendenti: $p_{Y|X}(y \mid x) = p_Y(y)$ e $p_{X|Y}(x \mid y) = p_X(x)$.

Dimostrazione

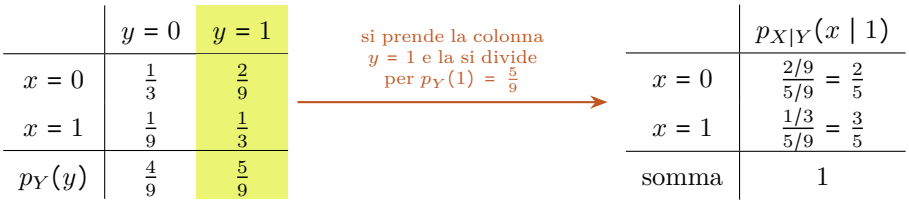
Passo 1 — a) È una pmf. È ≥ 0 perché è una probabilità condizionata. Per la somma, gli eventi $\{X = x\}$ formano una partizione di Ω e la probabilità condizionata è una probabilità (Teorema 4.6):

$$\sum_{x \in \mathcal{X}} p_{X|Y}(x \mid y) = P\left(\bigcup_{x \in \mathcal{X}} \{X = x\} \,\middle|\, \{Y = y\} \right) = P(\Omega \mid \{Y = y\}) = 1.$$

Passo 2 — b) Marginalizzazione. Nella formula delle marginali si scrive la congiunta come condizionata per marginale: $p_X(x) = \sum_y p_{X,Y}(x,y) = \sum_y p_{X|Y}(x \mid y)\, p_Y(y)$. Non è altro che la legge della probabilità totale per l'evento $\{X = x\}$ rispetto alla partizione $\Omega = \bigcup_y \{Y = y\}$. Lo stesso per p_Y, rispetto alla partizione $\Omega = \bigcup_x \{X = x\}$.

Passo 3 — c) Indipendenza. Se $p_{X,Y}(x,y) = p_X(x)\, p_Y(y)$, allora $p_{Y|X}(y \mid x) = \frac{p_X(x)\, p_Y(y)}{p_X(x)} = p_Y(y)$, e allo stesso modo per l'altra.

■



	$y = 0$	$y = 1$
$x = 0$	$\frac{1}{3}$	$\frac{2}{9}$
$x = 1$	$\frac{1}{9}$	$\frac{1}{3}$
$p_Y(y)$	$\frac{4}{9}$	$\frac{5}{9}$

	$p_{X\mid Y}(x \mid 1)$
$x = 0$	$\frac{2/9}{5/9} = \frac{2}{5}$
$x = 1$	$\frac{1/3}{5/9} = \frac{3}{5}$
somma	1

Figura 8.3: *La pmf condizionata a $Y = 1$: si guarda solo la colonna $y = 1$ della congiunta e la si «rialza» dividendola per il suo totale, così che sommi a 1. È la stessa operazione della pmf condizionata a un evento (Capitolo 6).*

Esempio 8.5 — Il canale binario con le pmf congiunte

Riprendiamo il canale binario dei capitoli 3 e 4: X è il bit trasmesso, con $p_X(0) = 0{,}6$ e $p_X(1) = 0{,}4$; Y è il bit ricevuto. Il canale è descritto dalla pmf condizionata $p_{Y\mid X}$: il bit arriva giusto con probabilità 0,9 e invertito con probabilità 0,1. La congiunta si ottiene moltiplicando: $p_{X,Y}(x, y) = p_{Y\mid X}(y \mid x)\, p_X(x)$.

$p_{X,Y}(x,y)$	$y = 0$	$y = 1$	$p_X(x)$
$x = 0$	$0{,}9 \cdot 0{,}6 = 0{,}54$	$0{,}1 \cdot 0{,}6 = 0{,}06$	0,6
$x = 1$	$0{,}1 \cdot 0{,}4 = 0{,}04$	$0{,}9 \cdot 0{,}4 = 0{,}36$	0,4
$p_Y(y)$	0,58	0,42	1

Tutto quello che avevamo calcolato è in questa tabella: la marginale $p_Y(1) = 0{,}42$ è la probabilità totale del Capitolo 3, e la condizionata $p_{X\mid Y}(1 \mid 1) = \frac{0{,}36}{0{,}42} = \frac{6}{7}$ è il risultato del teorema di Bayes del Capitolo 4. La pmf congiunta è il modo più ordinato di tenere insieme tutte queste informazioni.

Più di due variabili: la regola della catena

Si consideri una terna di variabili aleatorie (X, Y, Z), distribuite secondo $p_{X,Y,Z}(x, y, z)$, $(x, y, z) \in \mathcal{X} \times \mathcal{Y} \times \mathcal{Z}$. Le pmf condizionate si definiscono come per le coppie, e anche condizionando a più variabili insieme; per esempio

$$p_{X\mid Y,Z}(x \mid y, z) = \frac{p_{X,Y\mid Z}(x, y \mid z)}{p_{Y\mid Z}(y \mid z)}$$

è la pmf di X sapendo che $Y = y$ e $Z = z$.

Teorema 8.4 — Regola della catena

$$p_{X,Y,Z}(x, y, z) = p_Z(z)\, p_{Y\mid Z}(y \mid z)\, p_{X\mid Y,Z}(x \mid y, z).$$

Ogni permutazione dei pedici e degli argomenti è ovviamente possibile, e la regola si estende a qualsiasi numero di variabili.

Dimostrazione

Passo 1 — Prima applicazione della probabilità composta. Si considera l'evento $\{X = x, Y = y\}$ come un unico evento e lo si condiziona a $\{Z = z\}$:

$$P(X = x, Y = y, Z = z) = P(X = x, Y = y \mid Z = z)\, P(Z = z).$$

Passo 2 — Seconda applicazione, dentro il condizionamento. La probabilità condizionata a $\{Z = z\}$ è una probabilità (Teorema 4.6), quindi anche per lei vale la probabilità composta:

$$P(X = x, Y = y \mid Z = z) = P(X = x \mid Y = y, Z = z)\, P(Y = y \mid Z = z).$$

Passo 3 — Si mette insieme.

$$P(X = x, Y = y, Z = z) = P(X = x \mid Y = y, Z = z)\, P(Y = y \mid Z = z)\, P(Z = z).$$

■

La regola della catena dice che una congiunta si può sempre costruire «un pezzo alla volta»: prima si sceglie z, poi y sapendo z, poi x sapendo entrambi. È esattamente il diagramma ad albero, con un livello per ogni variabile.

Indipendenza di più variabili

Una terna di variabili aleatorie (e allo stesso modo un gruppo di $n > 3$ variabili) è **indipendente** se la pmf congiunta di un qualunque sottogruppo di esse, condizionata a un qualunque altro sottogruppo (costituito da variabili distinte dalle prime), è pari alla relativa pmf congiunta non condizionata.

In questo caso, chiaramente, la pmf congiunta si fattorizza nel prodotto delle pmf marginali: nella regola della catena ogni condizionata diventa una marginale, e $p_{X,Y,Z}(x, y, z) = p_X(x)\, p_Y(y)\, p_Z(z)$. Attenzione: non basta che le variabili siano indipendenti *a coppie*, come mostra l'esempio che segue.

ESEMPIO: TRE BIT DA UNA SORGENTE BINARIA

Si consideri una sorgente binaria che emette tre bit, (B_1, B_2, B_3), con $B_i \in \{0, 1\}$. Si assegnano due possibili leggi congiunte, p_{B_1,B_2,B_3} e q_{B_1,B_2,B_3}, riportate nella tabella ($0 < \alpha < 1$ è un parametro). Ci chiediamo se le coppie (B_1, B_2), (B_1, B_3), (B_2, B_3) e la terna (B_1, B_2, B_3) siano o meno indipendenti, secondo l'una e l'altra legge.

$b_1 b_2 b_3$	$p_{B_1,B_2,B_3}(b_1, b_2, b_3)$	$q_{B_1,B_2,B_3}(b_1, b_2, b_3)$
000	$(1-\alpha)^3$	$(1-\alpha)^2$
001	$\alpha(1-\alpha)^2$	0
010	$\alpha(1-\alpha)^2$	0
011	$\alpha^2(1-\alpha)$	$\alpha(1-\alpha)$
100	$\alpha(1-\alpha)^2$	0
101	$\alpha^2(1-\alpha)$	$\alpha(1-\alpha)$
110	$\alpha^2(1-\alpha)$	α^2
111	α^3	0

Tabella 8.1: *Le due leggi congiunte della sorgente di tre bit.*

La legge p

Cominciamo con il trovare la congiunta di tutte le possibili coppie secondo p. Per la marginalizzazione si somma sul bit che non interessa; per esempio

$$p_{B_1,B_2}(b_1,b_2) = p_{B_1,B_2,B_3}(b_1,b_2,0) + p_{B_1,B_2,B_3}(b_1,b_2,1).$$

Nelle somme compare sempre il fattore $(1-\alpha+\alpha) = 1$:

b_1b_2	$p_{B_1,B_2}(b_1,b_2)$
00	$(1-\alpha)^3 + \alpha(1-\alpha)^2 = (1-\alpha)^2(1-\alpha+\alpha) = (1-\alpha)^2$
01	$\alpha(1-\alpha)^2 + \alpha^2(1-\alpha) = \alpha(1-\alpha)(1-\alpha+\alpha) = \alpha(1-\alpha)$
10	$\alpha(1-\alpha)^2 + \alpha^2(1-\alpha) = \alpha(1-\alpha)$
11	$\alpha^2(1-\alpha) + \alpha^3 = \alpha^2(1-\alpha+\alpha) = \alpha^2$

Sommando sul bit 2 o sul bit 1 si trovano, allo stesso modo, p_{B_1,B_3} e p_{B_2,B_3}: hanno esattamente gli stessi quattro valori, $(1-\alpha)^2$, $\alpha(1-\alpha)$, $\alpha(1-\alpha)$, α^2. Marginalizzando ancora, $p_{B_1}(b_1) = p_{B_1,B_2}(b_1,0) + p_{B_1,B_2}(b_1,1)$:

$$p_{B_1}(0) = (1-\alpha)^2 + \alpha(1-\alpha) = (1-\alpha)(1-\alpha+\alpha) = 1-\alpha, \qquad p_{B_1}(1) = \alpha(1-\alpha) + \alpha^2 = \alpha,$$

e lo stesso vale per B_2 e B_3: ogni bit è 1 con probabilità α. Ora si vede che la legge p **si fattorizza nel prodotto delle marginali**: ogni riga della tabella è un prodotto di tre fattori, α per ogni 1 e $1-\alpha$ per ogni 0 (per esempio $p(0,1,1) = (1-\alpha)\cdot\alpha\cdot\alpha$). Questo implica che anche le congiunte a coppie si fattorizzano: secondo p l'intera terna è statisticamente indipendente.

La legge q

Procedendo allo stesso modo con q:

coppia di valori	q_{B_1,B_2}	q_{B_2,B_3}	q_{B_1,B_3}
00	$(1-\alpha)^2$	$(1-\alpha)^2$	$(1-\alpha)^2$
01	$\alpha(1-\alpha)$	$\alpha(1-\alpha)$	$\alpha(1-\alpha)$
10	$\alpha(1-\alpha)$	α^2	α^2
11	α^2	$\alpha(1-\alpha)$	$\alpha(1-\alpha)$

(Per esempio $q_{B_2,B_3}(1,0) = q(0,1,0) + q(1,1,0) = 0 + \alpha^2$.) Le marginali sono

$$q_{B_1}(1) = q_{B_2}(1) = \alpha, \qquad q_{B_3}(0) = (1-\alpha)^2 + \alpha^2, \qquad q_{B_3}(1) = 2\alpha(1-\alpha).$$

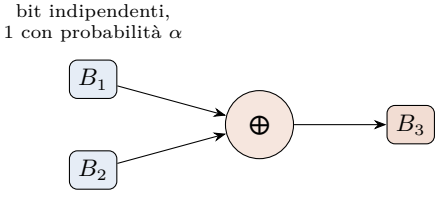
B_1 e B_2 sono indipendenti: q_{B_1,B_2} è la stessa di prima, il prodotto delle marginali. Non lo sono invece B_1 e B_3, né B_2 e B_3: per esempio $q_{B_1,B_3}(1,0) = \alpha^2$, mentre $q_{B_1}(1)\,q_{B_3}(0) = \alpha\left[(1-\alpha)^2 + \alpha^2\right]$, e i due numeri sono diversi (salvo il caso speciale $\alpha = \frac{1}{2}$, di cui diremo fra poco). Non lo è, quindi, nemmeno la terna.

Lo si vede bene con le condizionate. Sapendo che i primi due bit sono 1:

$$p_{B_3|B_1=1,B_2=1}(1) = \frac{p_{B_1,B_2,B_3}(1,1,1)}{p_{B_1,B_2}(1,1)} = \frac{\alpha^3}{\alpha^2} = \alpha = p_{B_3}(1),$$

$$q_{B_3|B_1=1,B_2=1}(1) = \frac{q_{B_1,B_2,B_3}(1,1,1)}{q_{B_1,B_2}(1,1)} = \frac{0}{\alpha^2} = 0 \neq q_{B_3}(1).$$

Secondo p, conoscere i primi due bit non dice nulla sul terzo; secondo q, lo dice con certezza. Guardando la tabella si capisce perché: nelle righe con probabilità non nulla, B_3 vale 1 esattamente quando B_1 e B_2 sono diversi. Si vede facilmente che $B_3 = B_1 \oplus B_2$ è un **bit di parità**.



b_1	b_2	$b_1 \oplus b_2$
0	0	0
0	1	1
1	0	1
1	1	0

Figura 8.4: *La sorgente secondo la legge q: due bit indipendenti e un terzo bit calcolato come loro XOR (somma modulo 2), che vale 1 quando i due bit sono diversi. Il numero totale di uni nella parola è sempre pari: è il principio dei codici di controllo di parità usati per rilevare gli errori di trasmissione.*

Indipendenti a coppie ma non tutti insieme

Con $\alpha = \frac{1}{2}$ succede una cosa curiosa. Tutte e tre le congiunte a coppie di q valgono $\frac{1}{4}$ in ogni casella, e le marginali valgono $\frac{1}{2}$: **ogni coppia** di bit è indipendente. Eppure la terna non lo è affatto, perché il terzo bit è determinato dai primi due ($q(1,1,1) = 0 \neq \frac{1}{8}$). Guardare i bit due alla volta non basta: per l'indipendenza di più variabili serve la fattorizzazione dell'intera pmf congiunta, come dice la definizione.

In sintesi

- Una **coppia di variabili aleatorie** manda ogni ω in un punto (x, y) di $\mathcal{X} \times \mathcal{Y}$; la **pmf congiunta** $p_{X,Y}(x, y) = P(X = x, Y = y)$ è una tabella di numeri ≥ 0 che somma a 1.
- **Marginali**: $p_X(x) = \sum_y p_{X,Y}(x, y)$, $p_Y(y) = \sum_x p_{X,Y}(x, y)$ (le somme «a margine»). La congiunta determina le marginali, non il viceversa.
- X e Y sono **indipendenti** se $p_{X,Y}(x, y) = p_X(x)\, p_Y(y)$ per ogni coppia: è l'unico caso in cui le marginali bastano.
- **Condizionate**: $p_{Y|X}(y \mid x) = p_{X,Y}(x, y)/p_X(x)$, una pmf in y per ogni x; Bayes: $p_{X|Y} = p_{Y|X}\, p_X/p_Y$; marginalizzare con le condizionate è la probabilità totale.
- **Regola della catena**: $p_{X,Y,Z} = p_Z\, p_{Y|Z}\, p_{X|Y,Z}$. Più variabili sono indipendenti se la congiunta si fattorizza tutta; l'indipendenza a coppie non basta (bit di parità).

Funzioni di più variabili, covarianza e correlazione

Nel capitolo precedente abbiamo descritto una coppia di variabili aleatorie con la sua pmf congiunta. Ora le usiamo: combiniamo X e Y in una nuova variabile $Z = g(X,Y)$ (una somma, un prodotto, una formula qualsiasi) e ne calcoliamo pmf e media; scopriamo che la media di una somma è sempre la somma delle medie; e introduciamo due numeri, la **covarianza** e il **coefficiente di correlazione**, che riassumono in modo semplice quanto due variabili «si muovono insieme».

Funzioni di una coppia di variabili

Sia $(X,Y) \sim p_{X,Y}(x,y)$, $(x,y) \in \mathcal{X} \times \mathcal{Y}$, una variabile doppia, e sia $g(x,y)$ una funzione di due variabili il cui dominio include $\mathcal{X} \times \mathcal{Y}$. Si vuole caratterizzare $Z = g(X,Y)$ in termini di pmf e di media statistica. Per prima cosa si determina l'alfabeto $\mathcal{Z}$, l'insieme dei valori $g(x,y)$. Poi si ragiona esattamente come nel Capitolo 6 per le funzioni di una variabile.

- Se $|\mathcal{Z}| = |\mathcal{X}|\,|\mathcal{Y}|$, la funzione è biunivoca sulle coppie: per ogni z esiste un unico punto $(x(z), y(z))$ con $z = g(x,y)$, e

$$P(Z = z) = p_Z(z) = p_{X,Y}\left[x(z), y(z)\right].$$

- Se $|\mathcal{Z}| < |\mathcal{X}|\,|\mathcal{Y}|$, la relazione precedente vale nei punti in cui l'inversa è unica, mentre negli altri le probabilità «collassano»: se $z = g(x,y)$ per tutte le coppie di un insieme $A(z) \subseteq \mathcal{X} \times \mathcal{Y}$, allora

$$p_Z(z) = \sum_{(x,y) \in A(z)} p_{X,Y}(x,y).$$

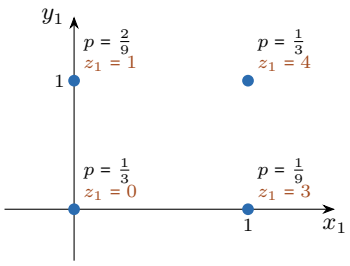
Da ricordare: pmf di una funzione di due variabili

$$p_Z(z) = \sum_{(x,y)\,:\,g(x,y)=z} p_{X,Y}(x,y)$$

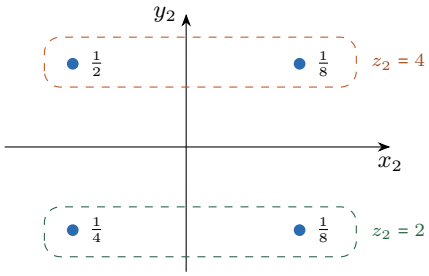
Esempio 9.1 — Due coppie e la stessa formula

Si considerino due variabili doppie, $(X_1, Y_1) \in \{0,1\}^2$ e $(X_2, Y_2) \in \{-1,1\}^2$, con le pmf congiunte riportate qui sotto (la prima è quella del capitolo precedente), e le due variabili

$$Z_1 = 3X_1^2 + Y_1, \qquad Z_2 = 3X_2^2 + Y_2.$$



$Z_1 = 3X_1^2 + Y_1$: quattro valori diversi



$Z_2 = 3X_2^2 + Y_2$: due valori soli

Prima coppia. I valori possibili di Z_1 sono $3 \cdot 0 + 0 = 0$, $3 \cdot 0 + 1 = 1$, $3 \cdot 1 + 0 = 3$, $3 \cdot 1 + 1 = 4$: quindi $|\mathcal{Z}_1| = |\{0,1,3,4\}| = 4 = |\{0,1\}|^2 = |\mathcal{X}| \cdot |\mathcal{Y}|$, e la corrispondenza è biunivoca:

$$p_{Z_1}(0) = p_{X_1,Y_1}(0,0) = \tfrac{1}{3}, \quad p_{Z_1}(1) = p_{X_1,Y_1}(0,1) = \tfrac{2}{9}, \quad p_{Z_1}(3) = p_{X_1,Y_1}(1,0) = \tfrac{1}{9}, \quad p_{Z_1}(4) = p_{X_1,Y_1}(1,1) = \tfrac{1}{3}.$$

Seconda coppia. Qui $X_2 = \pm 1$, quindi $X_2^2 = 1$ sempre e $Z_2 = 3 + Y_2$: i valori possibili sono solo $\{2,4\}$, e $|\mathcal{Z}_2| = 2 < |\{-1,1\}|^2 = 4$. La corrispondenza non è biunivoca e le probabilità collassano:

$$p_{Z_2}(2) = p_{X_2,Y_2}(1,-1) + p_{X_2,Y_2}(-1,-1) = \tfrac{1}{8} + \tfrac{1}{4} = \tfrac{3}{8}, \qquad p_{Z_2}(4) = p_{X_2,Y_2}(-1,1) + p_{X_2,Y_2}(1,1) = \tfrac{1}{2} + \tfrac{1}{8} = \tfrac{5}{8}.$$

La media di una funzione di due variabili

Con riferimento alla trasformazione generica $Z = g(X,Y)$, il teorema fondamentale per il calcolo della media (Teorema 6.4) si traduce in modo immediato.

Teorema 9.1 — Teorema fondamentale per due variabili

$$E[Z] = E[g(X,Y)] = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} g(x,y)\, p_{X,Y}(x,y) = \sum_{(x,y) \in \mathcal{X} \times \mathcal{Y}} g(x,y)\, p_{X,Y}(x,y).$$

Dimostrazione

Passo 1. È la stessa dimostrazione del caso di una variabile, con le coppie (x,y) al posto dei valori x. Si scrive $E[Z] = \sum_z z\, p_Z(z) = \sum_z \sum_{(x,y) \in A(z)} g(x,y)\, p_{X,Y}(x,y)$; gli insiemi $A(z)$ dividono $\mathcal{X} \times \mathcal{Y}$ in gruppi disgiunti che lo coprono tutto, quindi sommare gruppo per gruppo equivale a sommare su tutte le coppie. ∎

La conseguenza più importante riguarda le combinazioni lineari.

Teorema 9.2 — Linearità della media

Se a e b sono costanti, per qualsiasi coppia di variabili aleatorie X e Y:

$$E[aX + bY] = a\,E[X] + b\,E[Y].$$

Più in generale, se $X_1, X_2, \ldots, X_m$ sono m variabili aleatorie con pmf congiunta $p_{X_1,\ldots,X_m}(x_1, \ldots, x_m)$ e $a_1, \ldots, a_m$ sono costanti:

$$E\left[\sum_{i=1}^{m} a_i X_i\right] = \sum_{i=1}^{m} a_i\,E[X_i].$$

Dimostrazione

Passo 1 — Il teorema fondamentale con $g(x, y) = ax + by$.

$$E[aX + bY] = \sum_{x\in\mathcal{X}}\sum_{y\in\mathcal{Y}} (ax + by)\,p_{X,Y}(x, y) = a\sum_x\sum_y x\,p_{X,Y}(x, y) + b\sum_x\sum_y y\,p_{X,Y}(x, y).$$

Passo 2 — Si raccoglie e si marginalizza. Nella prima somma x non dipende da y e si porta fuori dalla somma interna; nella seconda si scambia l'ordine delle somme e si porta fuori y:

$$E[aX + bY] = a\sum_{x\in\mathcal{X}} x\underbrace{\sum_{y\in\mathcal{Y}} p_{X,Y}(x, y)}_{p_X(x)} + b\sum_{y\in\mathcal{Y}} y\underbrace{\sum_{x\in\mathcal{X}} p_{X,Y}(x, y)}_{p_Y(y)}.$$

Le somme interne sono le marginali (Teorema 8.2).

Passo 3 — Si riconoscono le medie.

$$E[aX + bY] = a\sum_x x\,p_X(x) + b\sum_y y\,p_Y(y) = a\,E[X] + b\,E[Y].$$

Passo 4 — Con m variabili. Si applica il risultato ripetutamente (è un'induzione): $\sum_{i=1}^{m} a_i X_i$ è la somma di $\sum_{i=1}^{m-1} a_i X_i$ e di $a_m X_m$, e la media di una somma di due variabili è la somma delle medie. ■

La linearità non chiede l'indipendenza

La media di una somma è la somma delle medie **sempre**, qualunque sia la pmf congiunta: le variabili possono essere dipendenti quanto si vuole. È questo che la rende così utile. (Vedremo invece che per la varianza di una somma la dipendenza conta, eccome.)

Esempio 9.2 — La media della binomiale, in una riga

Nel Capitolo 5 abbiamo dimostrato $E[X_N] = Np$ con una lunga catena di passaggi. Con la linearità basta osservare che il numero di teste in N lanci è la somma di N variabili di Bernoulli:

$$X_N = B_1 + B_2 + \cdots + B_N, \qquad B_i = \begin{cases} 1 & \text{se l'}i\text{-esimo lancio dà testa} \\ 0 & \text{altrimenti} \end{cases}$$

Ogni B_i vale 1 con probabilità p, quindi $E[B_i] = p$, e

$$E[X_N] = E[B_1] + E[B_2] + \cdots + E[B_N] = Np.$$

Esempio 9.3 — Le medie di Z_1 e Z_2

Con le pmf trovate nell'esempio precedente:

$$E[Z_1] = 0 \cdot \tfrac{1}{3} + 1 \cdot \tfrac{2}{9} + 3 \cdot \tfrac{1}{9} + 4 \cdot \tfrac{1}{3} = \frac{2+3+12}{9} = \frac{17}{9}, \qquad E[Z_2] = 2 \cdot \tfrac{3}{8} + 4 \cdot \tfrac{5}{8} = \frac{6+20}{8} = \frac{26}{8} = \frac{13}{4}.$$

Il teorema della media condizionata

Il teorema fondamentale si può riorganizzare in un modo molto utile. Con riferimento a $Z = g(X,Y)$, scriviamo la congiunta come condizionata per marginale, $p_{X,Y}(x,y) = p_{X|Y}(x \mid y)\, p_Y(y)$:

$$E[Z] = \sum_{x\in\mathcal{X}} \sum_{y\in\mathcal{Y}} g(x,y)\, p_{X|Y}(x \mid y)\, p_Y(y) = \sum_{y\in\mathcal{Y}} p_Y(y) \underbrace{\sum_{x\in\mathcal{X}} g(x,y)\, p_{X|Y}(x \mid y)}_{h(y)} = \sum_{y\in\mathcal{Y}} p_Y(y)\, h(y),$$

dove

$$h(y) = \sum_{x\in\mathcal{X}} g(x,y)\, p_{X|Y}(x \mid y) = E[g(X,Y) \mid Y = y]$$

è la media di $g(X,Y)$ eseguita rispetto alla pmf condizionata $p_{X|Y}(x \mid y)$: la media di g sapendo che $Y = y$. Al variare di y è una funzione di y, quindi $h(Y) = E[g(X,Y) \mid Y]$ è a sua volta una variabile aleatoria (una funzione di Y), e l'ultima somma è la sua media.

Teorema 9.3 — Teorema della media condizionata

$$E[g(X,Y)] = E[h(Y)] = E\big[\, E[g(X,Y) \mid Y]\,\big].$$

La media si può calcolare in due tempi: prima la media condizionata a ogni valore di Y, poi la media di questi numeri, pesati con p_Y. Ovviamente i ruoli di X e Y si possono scambiare.

È lo stesso principio del Teorema 6.3 (la media è la media pesata delle medie condizionate), con la partizione $\Omega = \bigcup_y \{Y = y\}$.

Esempio 9.4 — La media di Z_1, in due tempi

Calcoliamo di nuovo $E[Z_1] = E[E[Z_1 \mid Y_1]]$, dove $Z_1 = g(X_1, Y_1) = 3X_1^2 + Y_1$. Serve la pmf condizionata $p_{X_1|Y_1}(x_1 \mid y_1) = p_{X_1,Y_1}(x_1, y_1)/p_{Y_1}(y_1)$, e per questa la marginale di Y_1:

$$p_{Y_1}(0) = p_{X_1,Y_1}(0,0) + p_{X_1,Y_1}(1,0) = \tfrac{1}{3} + \tfrac{1}{9} = \tfrac{4}{9}, \qquad p_{Y_1}(1) = p_{X_1,Y_1}(0,1) + p_{X_1,Y_1}(1,1) = \tfrac{2}{9} + \tfrac{1}{3} = \tfrac{5}{9}.$$

$x_1 y_1$	$p_{X_1\|Y_1}(x_1 \mid y_1) = \dfrac{p_{X_1,Y_1}(x_1,y_1)}{p_{Y_1}(y_1)}$
00	$\frac{1}{3} \cdot \frac{9}{4} = \frac{3}{4}$
01	$\frac{2}{9} \cdot \frac{9}{5} = \frac{2}{5}$
10	$\frac{1}{9} \cdot \frac{9}{4} = \frac{1}{4}$
11	$\frac{1}{3} \cdot \frac{9}{5} = \frac{3}{5}$

Ora le medie condizionate. Sapendo che $Y_1 = 0$, la Y_1 nella formula vale 0; e siccome X_1 vale 0 o 1, il termine $3X_1^2$ vale 3 solo quando $X_1 = 1$:

$$E[Z_1 \mid Y_1 = 0] = E[3X_1^2 + Y_1 \mid Y_1 = 0] = E[3X_1^2 \mid Y_1 = 0] = 3 \cdot 1^2 \cdot p_{X_1|Y_1}(1 \mid 0) = 3 \cdot \tfrac{1}{4} = \tfrac{3}{4}.$$

Sapendo che $Y_1 = 1$, invece, la Y_1 vale 1:

$$E[Z_1 \mid Y_1 = 1] = E[3X_1^2 + 1 \mid Y_1 = 1] = 3 \cdot 1^2 \cdot p_{X_1|Y_1}(1 \mid 1) + 1 = 3 \cdot \tfrac{3}{5} + 1 = \tfrac{9}{5} + 1 = \tfrac{14}{5}.$$

Infine la media delle medie condizionate:

$$E[Z_1] = E[Z_1 \mid Y_1 = 0]\, p_{Y_1}(0) + E[Z_1 \mid Y_1 = 1]\, p_{Y_1}(1) = \tfrac{3}{4} \cdot \tfrac{4}{9} + \tfrac{14}{5} \cdot \tfrac{5}{9} = \tfrac{3}{9} + \tfrac{14}{9} = \tfrac{17}{9},$$

lo stesso valore trovato prima.

Correlazione e covarianza

Le coppie (μ_X, σ_X^2) e (μ_Y, σ_Y^2) contengono informazioni globali, anche se sommarie, sulle due pmf marginali. L'equivalente per la pmf congiunta è la **covarianza**, che dà un'idea, ancora abbastanza sommaria, del grado di «dipendenza» fra X e Y.

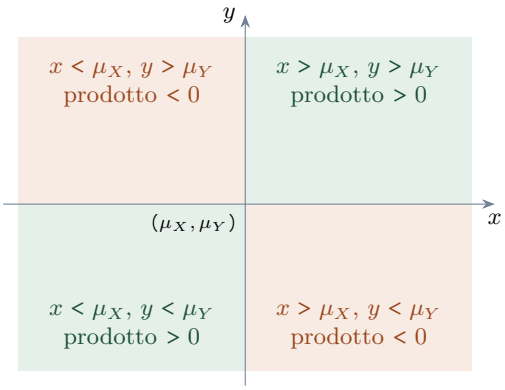
Correlazione e covarianza

La **correlazione** fra X e Y è la media del loro prodotto:

$$R_{XY} = E[XY] = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} x\, y\, p_{X,Y}(x,y).$$

La **covarianza** fra X e Y è la media del prodotto degli scarti dalle rispettive medie:

$$\sigma_{XY}^2 = COV(X,Y) = E\left[(X - \mu_X)(Y - \mu_Y)\right] = \sum_x \sum_y (x - \mu_X)(y - \mu_Y)\, p_{X,Y}(x,y).$$



Gli assi sono centrati sulle medie. Il prodotto degli scarti $(x - \mu_X)(y - \mu_Y)$ è positivo nei quadranti verdi (le due variabili sono entrambe sopra o entrambe sotto la media) e negativo in quelli arancioni (una sopra, l'altra sotto). La covarianza è la media di questo prodotto: è positiva se la probabilità sta soprattutto nei quadranti verdi, negativa se sta soprattutto in quelli arancioni.

Figura 9.1: *Il segno della covarianza.*

Teorema 9.4 — Covarianza e correlazione

$$COV(X,Y) = R_{XY} - \mu_X \mu_Y = E[XY] - E[X]\,E[Y].$$

In particolare, se almeno una delle due variabili ha media nulla, $COV(X,Y) = R_{XY}$.

Dimostrazione

Passo 1 — Si sviluppa il prodotto. $(X - \mu_X)(Y - \mu_Y) = XY - \mu_X Y - \mu_Y X + \mu_X \mu_Y$.

Passo 2 — Linearità della media. Le medie μ_X e μ_Y sono costanti, quindi

$$COV(X,Y) = E[XY] - \mu_X\,E[Y] - \mu_Y\,E[X] + \mu_X \mu_Y = R_{XY} - \mu_X \mu_Y - \mu_X \mu_Y + \mu_X \mu_Y = R_{XY} - \mu_X \mu_Y.$$

■

Variabili incorrelate

Due variabili aleatorie che abbiano covarianza nulla, $COV(X,Y) = 0$, si dicono **incorrelate**.

Teorema 9.5 — Indipendenti implica incorrelate

Se X e Y sono indipendenti, allora sono incorrelate: $COV(X,Y) = 0$, e quindi $E[XY] = E[X]\,E[Y]$.

Dimostrazione

Passo 1 — La congiunta si fattorizza. Se $p_{X,Y}(x,y) = p_X(x)\,p_Y(y)$:

$$COV(X,Y) = \sum_x \sum_y (x - \mu_X)(y - \mu_Y)\,p_X(x)\,p_Y(y).$$

Passo 2 — La somma doppia si spezza. Il termine si fattorizza in una parte che dipende solo da x e una che dipende solo da y, quindi la somma doppia è il prodotto di due somme:

$$COV(X,Y) = \sum_x (x - \mu_X)\,p_X(x) \sum_y (y - \mu_Y)\,p_Y(y) = E[X - \mu_X]\,E[Y - \mu_Y] = 0 \cdot 0 = 0,$$

perché la media dello scarto dalla media è sempre nulla.

■

La proposizione **non si inverte**: l'incorrelazione non implica, in generale, l'indipendenza.

Esempio 9.5 — Incorrelate ma dipendenti

Sia X uniforme su $\{-1, 0, 1\}$ e sia $Y = X^2$. Le due variabili sono fortissimamente dipendenti: conoscendo X si conosce Y con certezza (per esempio $P(Y = 0 \mid X = 0) = 1$, mentre $P(Y = 0) = \frac{1}{3}$). Eppure

$$E[X] = \tfrac{1}{3}(-1 + 0 + 1) = 0, \qquad E[XY] = E[X^3] = \tfrac{1}{3}\left((-1)^3 + 0^3 + 1^3\right) = 0,$$

quindi $COV(X, Y) = E[XY] - E[X]\,E[Y] = 0 - 0 = 0$: sono incorrelate. La covarianza vede solo la tendenza a crescere o calare *insieme*; qui Y è grande sia quando X è molto negativa sia quando è molto positiva, e i due effetti si compensano.

Il coefficiente di correlazione

La covarianza ha un difetto: dipende dalle unità di misura (se X si misura in centimetri invece che in metri, la covarianza diventa cento volte più grande). Per avere un numero «puro» la si divide per le deviazioni standard; il risultato sta sempre fra -1 e 1.

Teorema 9.6 — Limite della covarianza

Per due variabili aleatorie qualsiasi (con $\sigma_X, \sigma_Y > 0$):

$$|COV(X, Y)| \le \sigma_X\, \sigma_Y.$$

Dimostrazione

Passo 1 — Un quadrato ha media non negativa. Per entrambe le scelte del segno, la variabile $\left(\frac{X-\mu_X}{\sigma_X} \pm \frac{Y-\mu_Y}{\sigma_Y}\right)^2$ è non negativa, quindi lo è la sua media:

$$0 \le E\left[\left(\frac{X - \mu_X}{\sigma_X} \pm \frac{Y - \mu_Y}{\sigma_Y}\right)^2\right].$$

Passo 2 — Si sviluppa il quadrato. Con $(a \pm b)^2 = a^2 + b^2 \pm 2ab$ e la linearità della media:

$$0 \le E\left[\left(\frac{X - \mu_X}{\sigma_X}\right)^2\right] + E\left[\left(\frac{Y - \mu_Y}{\sigma_Y}\right)^2\right] \pm 2\,E\left[\frac{X - \mu_X}{\sigma_X} \cdot \frac{Y - \mu_Y}{\sigma_Y}\right].$$

Passo 3 — Si riconoscono i pezzi. Il primo termine è $\frac{E[(X-\mu_X)^2]}{\sigma_X^2} = \frac{\sigma_X^2}{\sigma_X^2} = 1$, il secondo allo stesso modo vale 1, il terzo è $\pm 2\,\frac{COV(X,Y)}{\sigma_X \sigma_Y}$:

$$0 \le 1 + 1 \pm 2\,\frac{COV(X, Y)}{\sigma_X\, \sigma_Y} \quad \Longleftrightarrow \quad -2 \le \pm 2\,\frac{COV(X, Y)}{\sigma_X\, \sigma_Y} \quad \Longleftrightarrow \quad -\sigma_X \sigma_Y \le \pm\, COV(X, Y).$$

Passo 4 — I due segni insieme. Con il segno $+$: $COV(X, Y) \ge -\sigma_X \sigma_Y$. Con il segno $-$: $-COV(X, Y) \ge -\sigma_X \sigma_Y$, cioè $COV(X, Y) \le \sigma_X \sigma_Y$. Insieme:

$$-\sigma_X \sigma_Y \le COV(X, Y) \le \sigma_X \sigma_Y \quad \Longleftrightarrow \quad |COV(X, Y)| \le \sigma_X\, \sigma_Y.$$

■

Coefficiente di correlazione

Il **coefficiente di correlazione** fra X e Y è

$$\rho_{XY} = \frac{COV(X, Y)}{\sigma_X\, \sigma_Y} \in [-1, 1].$$

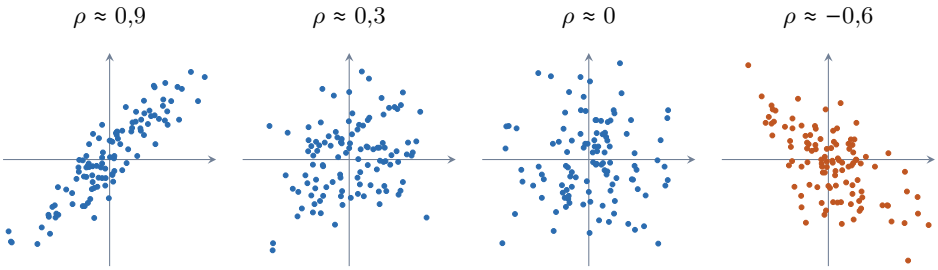


Figura 9.2: *Ogni punto è una coppia (x, y) estratta da quattro coppie di variabili con coefficienti di correlazione diversi (simulazione). Con ρ vicino a 1 i punti si allineano lungo una retta crescente; con ρ vicino a 0 non c'è una tendenza; con ρ negativo la tendenza è decrescente.*

Che cosa misura ρ

Il coefficiente di correlazione misura la dipendenza **lineare**: quanto i punti (x, y) tendono a disporsi lungo una retta. Dalla dimostrazione si vede che $\rho_{XY} = \pm 1$ esattamente quando la media del quadrato è zero, cioè quando $\frac{X-\mu_X}{\sigma_X} = \mp\frac{Y-\mu_Y}{\sigma_Y}$ con certezza: Y è una funzione lineare di X, $Y = aX + b$. Un ρ vicino a zero, invece, non esclude affatto una dipendenza non lineare, come nell'esempio $Y = X^2$.

La varianza di una combinazione lineare

Teorema 9.7 — Varianza di una combinazione lineare

Sia $Z = aX + bY$, con a e b costanti. Allora $\mu_Z = a\mu_X + b\mu_Y$ e

$$\sigma_Z^2 = a^2\sigma_X^2 + b^2\sigma_Y^2 + 2ab\,COV(X, Y).$$

In particolare, se X e Y sono incorrelate (per esempio indipendenti), $\sigma_{X+Y}^2 = \sigma_X^2 + \sigma_Y^2$.

Dimostrazione

Passo 1 — Lo scarto di Z. La media segue dalla linearità; lo scarto dalla media è

$$Z - \mu_Z = aX + bY - a\mu_X - b\mu_Y = a\,(X - \mu_X) + b\,(Y - \mu_Y).$$

Passo 2 — Il quadrato. Sviluppando $(au + bv)^2 = a^2u^2 + b^2v^2 + 2ab\,uv$:

$$\sigma_Z^2 = E\left[(Z - \mu_Z)^2\right] = E\left[(a(X - \mu_X) + b(Y - \mu_Y))^2\right]$$

$$= a^2\,E[(X - \mu_X)^2] + b^2\,E[(Y - \mu_Y)^2] + 2ab\,E[(X - \mu_X)(Y - \mu_Y)] = a^2\sigma_X^2 + b^2\sigma_Y^2 + 2ab\,COV(X, Y).$$

■

Esempio 9.6 — La varianza della binomiale, in poche righe

Riprendiamo $X_N = B_1 + \cdots + B_N$, con le B_i di Bernoulli **indipendenti** (i lanci lo sono). Ogni B_i ha varianza $p(1-p)$. Per due lanci, $\sigma_{B_1+B_2}^2 = p(1-p)+p(1-p)$, perché la covarianza di due variabili indipendenti è nulla. Aggiungendo un lancio alla volta: la somma dei primi $n-1$ lanci è una funzione di quei lanci, che sono indipendenti dall'n-esimo, e la covarianza di una somma si spezza nella somma delle covarianze (dalla definizione e dalla linearità della media: $COV(U + V, W) = COV(U, W) + COV(V, W)$), tutte nulle. Così ogni lancio aggiunge $p(1-p)$, e

$$\sigma_{X_N}^2 = N\,p\,(1-p),$$

lo stesso risultato ottenuto nel Capitolo 7 con il trucco della derivata.

QUALE COPPIA È PIÙ CORRELATA?

Esercizio 9.1 — Confrontare due coefficienti di correlazione

Date le due pmf congiunte introdotte all'inizio del capitolo, per $(X_1, Y_1) \in \{0,1\}^2$ e $(X_2, Y_2) \in \{-1,1\}^2$, trovare quale delle due dà luogo a un coefficiente di correlazione maggiore (in valore assoluto).

Svolgimento

Prima coppia. Le marginali, sommando righe e colonne della tabella: $p_{X_1}(0) = \frac{5}{9}$, $p_{X_1}(1) = \frac{4}{9}$; $p_{Y_1}(0) = \frac{4}{9}$, $p_{Y_1}(1) = \frac{5}{9}$. Quindi

$$E[X_1] = 0 \cdot \tfrac{5}{9} + 1 \cdot \tfrac{4}{9} = \tfrac{4}{9}, \qquad E[Y_1] = 0 \cdot \tfrac{4}{9} + 1 \cdot \tfrac{5}{9} = \tfrac{5}{9},$$

$$E[X_1^2] = 0^2 \cdot \tfrac{5}{9} + 1^2 \cdot \tfrac{4}{9} = \tfrac{4}{9}, \qquad E[Y_1^2] = \tfrac{5}{9},$$

$$\sigma^2_{X_1} = E[X_1^2] - E^2[X_1] = \tfrac{4}{9} - \tfrac{16}{81} = \tfrac{36-16}{81} = \tfrac{20}{81} \approx 0{,}247, \qquad \sigma^2_{Y_1} = \tfrac{5}{9} - \tfrac{25}{81} = \tfrac{45-25}{81} = \tfrac{20}{81} \approx 0{,}247.$$

Per $E[X_1Y_1]$ si considera l'unico prodotto di valori diverso da zero, quello con $x_1 = y_1 = 1$:

$$E[X_1Y_1] = 1 \cdot 1 \cdot p_{X_1,Y_1}(1,1) = \tfrac{1}{3}, \qquad COV(X_1, Y_1) = E[X_1Y_1] - E[X_1]\,E[Y_1] = \tfrac{1}{3} - \tfrac{4}{9} \cdot \tfrac{5}{9} = \tfrac{27-20}{81} = \tfrac{7}{81} \approx 0{,}086.$$

$$\rho_{X_1Y_1} = \frac{COV(X_1, Y_1)}{\sigma_{X_1}\sigma_{Y_1}} = \frac{7/81}{\sqrt{\frac{20}{81} \cdot \frac{20}{81}}} = \frac{7/81}{20/81} = \frac{7}{20} = 0{,}35.$$

Seconda coppia. Le marginali: $p_{X_2}(-1) = \frac{1}{4} + \frac{1}{2} = \frac{3}{4}$, $p_{X_2}(1) = \frac{1}{8} + \frac{1}{8} = \frac{1}{4}$; $p_{Y_2}(-1) = \frac{1}{4} + \frac{1}{8} = \frac{3}{8}$, $p_{Y_2}(1) = \frac{1}{2} + \frac{1}{8} = \frac{5}{8}$. Quindi

$$E[X_2] = -1 \cdot \tfrac{3}{4} + 1 \cdot \tfrac{1}{4} = -\tfrac{1}{2}, \qquad E[Y_2] = -1 \cdot \tfrac{3}{8} + 1 \cdot \tfrac{5}{8} = \tfrac{1}{4},$$

e, siccome $(\pm 1)^2 = 1$, $E[X_2^2] = E[Y_2^2] = 1$:

$$\sigma^2_{X_2} = 1 - \tfrac{1}{4} = \tfrac{3}{4}, \qquad \sigma^2_{Y_2} = 1 - \tfrac{1}{16} = \tfrac{15}{16}.$$

Per $E[X_2Y_2]$ servono tutti e quattro i punti (il prodotto vale $+1$ se i segni sono uguali, -1 se sono diversi):

$$E[X_2Y_2] = (-1 \cdot 1)\,\tfrac{1}{2} + (-1 \cdot -1)\,\tfrac{1}{4} + (1 \cdot 1)\,\tfrac{1}{8} + (1 \cdot -1)\,\tfrac{1}{8} = -\tfrac{1}{2} + \tfrac{1}{4} + \tfrac{1}{8} - \tfrac{1}{8} = -\tfrac{1}{4},$$

$$COV(X_2, Y_2) = -\tfrac{1}{4} - \left(-\tfrac{1}{2}\right) \cdot \tfrac{1}{4} = -\tfrac{1}{4} + \tfrac{1}{8} = -\tfrac{1}{8},$$

$$\rho_{X_2Y_2} = \frac{-1/8}{\sqrt{\frac{3}{4} \cdot \frac{15}{16}}} = \frac{-1/8}{\sqrt{45/64}} = \frac{-1/8}{\sqrt{45}/8} = -\frac{1}{\sqrt{45}} \approx -0{,}149.$$

Conclusione. Essendo $|\rho_{X_1Y_1}| = 0{,}35 > |\rho_{X_2Y_2}| \approx 0{,}149$, la coppia (X_1, Y_1) risulta a correlazione assoluta maggiore. Il segno negativo della seconda ha un significato preciso: ci si aspetta che X_2 e Y_2 tendano a discostarsi dalle rispettive medie in direzioni opposte (se una è superiore alla media, l'altra tipicamente è inferiore, e viceversa).

In sintesi

- Se $Z = g(X,Y)$: $p_Z(z) = \sum_{g(x,y)=z} p_{X,Y}(x,y)$ (le probabilità collassano se g non è biunivoca sulle coppie), e $E[g(X,Y)] = \sum_x \sum_y g(x,y)\,p_{X,Y}(x,y)$.
- **Linearità**: $E[\sum a_i X_i] = \sum a_i E[X_i]$, sempre, anche per variabili dipendenti.
- **Media condizionata**: $E[g(X,Y)] = E\big[E[g(X,Y) \mid Y]\big]$: prima la media sapendo Y, poi la media su Y.
- Correlazione $R_{XY} = E[XY]$; **covarianza** $COV(X,Y) = E[(X-\mu_X)(Y-\mu_Y)] = R_{XY} - \mu_X\mu_Y$. Indipendenti $\Rightarrow$ incorrelate, non il viceversa.
- $|COV(X,Y)| \le \sigma_X\sigma_Y$; **coefficiente di correlazione** $\rho_{XY} = COV/(\sigma_X\sigma_Y) \in [-1,1]$, misura della dipendenza lineare.
- $\sigma^2_{aX+bY} = a^2\sigma_X^2 + b^2\sigma_Y^2 + 2ab\,COV(X,Y)$: per variabili incorrelate le varianze si sommano.

Parte II

Variabili aleatorie continue, vettori e processi aleatori

Variabili aleatorie continue: densità e distribuzione

Finora i risultati possibili si potevano mettere in fila e contare: le facce di un dado, le mani di carte, i pacchetti in coda. Molte grandezze fisiche però variano con continuità: una tensione, un tempo di attesa, la posizione di un oggetto. Una tensione può valere 0,31 volt, o 0,312, o 0,3127… e fra due valori qualsiasi ce ne sono infiniti altri. In questo capitolo scopriamo che in questi casi la probabilità di un singolo valore è sempre **zero**, e che serve un oggetto nuovo per descrivere la variabile: la **densità di probabilità**. Per lavorarci useremo lo strumento matematico che fa per le grandezze continue quello che la sommatoria fa per quelle discrete: l'**integrale**, spiegato da zero.

Spazi campione continui

Rimuoviamo ora l'ipotesi che lo spazio campione sia discreto. Supponiamo d'ora in poi che $\Omega \subseteq \mathbb{R}$ sia un sottoinsieme **continuo** dei numeri reali (per esempio un intervallo). Ω può essere esso stesso lo spazio delle misure osservabili, oppure il dominio di una variabile aleatoria

$$X : \omega \in \Omega \longmapsto X(\omega) \in \mathcal{X},$$

e ora l'alfabeto $\mathcal{X}$ non potrà più essere un insieme discreto. Spesso accade che $X(\omega) = \omega$ e $\mathcal{X} = \Omega$: il risultato dell'esperimento è già il numero che interessa.

Esempio 10.1 — Il rumore termico

La tensione misurata a vuoto ai capi di un resistore non è mai esattamente zero: gli elettroni del materiale si agitano a causa della temperatura (è il *rumore termico*), e la tensione oscilla attorno allo zero in modo imprevedibile.

a) Si misura n volte questa tensione. Il risultato è già un numero reale: $X(\omega) = \omega = x \in \mathbb{R}$, e le misure sono n numeri $\{x_i\}_{i=1}^{n}$.

b) Si misura invece la potenza che la tensione trasferisce a un carico di resistenza R. Lo spazio campione è ancora lo stesso, ma la variabile aleatoria ora è $X(\omega) = \omega^2/R$: una funzione del risultato.

Perché un singolo valore ha probabilità zero

In entrambi i casi gli eventi elementari sono del tipo $\{X(\omega_i) = x_i\}$. Si potrebbe essere tentati di definire, come nel caso discreto,

$$P(X = x_i) = \lim_{n\to\infty} \frac{n_{X=x_i}}{n},$$

dove $n_{X=x_i}$ è il numero di volte in cui si è osservato esattamente il valore x_i. La definizione non è sbagliata, ma è inutile. Due realizzazioni distinte $X(\omega_i)$ e $X(\omega_j)$ di una variabile aleatoria reale non si possono mai misurare con esattezza: servirebbe uno strumento di precisione infinita, e anche così l'evento $X(\omega_i) = X(\omega_j)$, che i due valori coincidano fino all'ultima delle infinite cifre decimali, sarebbe impossibile. Quello che possiamo dire è se la misura $X(\omega_j)$ cade o meno **in un intorno** di $X(\omega_i)$, cioè abbastanza vicino. Quindi, se X è una variabile aleatoria continua, gli eventi elementari $\{X = x\}$ hanno (a meno di casi degeneri) probabilità nulla.

C'è anche una ragione matematica: i valori possibili sono troppi perché ognuno possa avere una probabilità positiva. Prima di vederla, un richiamo che chiarisce quando una somma di infiniti termini positivi può dare un numero finito.

Richiamo di matematica: la serie geometrica

Per un numero q con $|q| < 1$ (per esempio $q = \frac{1}{2}$, oppure $q = -0{,}3$):

$$\sum_{k=0}^{\infty} q^k = 1 + q + q^2 + q^3 + \cdots = \frac{1}{1-q}.$$

Dimostrazione. Sia $S_N = 1+q+q^2+\cdots+q^N$ la somma parziale. Moltiplicandola per q si ottiene $q\,S_N = q+q^2+\cdots+q^{N+1}$: gli stessi termini, spostati di un posto. Sottraendo, quasi tutto si cancella (è una somma telescopica):

$$S_N - q\,S_N = 1 - q^{N+1} \quad \Longrightarrow \quad S_N = \frac{1-q^{N+1}}{1-q}.$$

Se $|q| < 1$, le potenze q^{N+1} diventano piccolissime al crescere di N (ogni volta si moltiplica per un numero più piccolo di 1 in valore assoluto), cioè $q^{N+1} \to 0$, e quindi $S_N \to \frac{1}{1-q}$.
Con $q = \frac{1}{2}$ si ritrova $1 + \frac{1}{2} + \frac{1}{4} + \cdots = 2$ (la serie del Capitolo 4 partiva da $\frac{1}{2}$ e valeva 1). Una somma di *infiniti* termini positivi, quindi, può essere finita, purché i termini diventino piccoli abbastanza in fretta. Questo però succede per un'infinità **numerabile** di termini, quelli che si possono mettere in fila.

Teorema 10.1 — Pochi valori possono avere probabilità positiva

Per qualsiasi variabile aleatoria, l'insieme dei valori x con $P(X = x) > 0$ è al più numerabile. In particolare, se l'alfabeto è un intervallo di numeri reali, non tutti i suoi valori possono avere probabilità positiva: quasi tutti devono avere probabilità zero.

Dimostrazione

Passo 1 — Pochi valori «grossi». Fissato un intero $k \geq 1$, i valori con $P(X = x) \geq \frac{1}{k}$ sono al massimo k: se fossero $k+1$, gli eventi $\{X = x\}$ corrispondenti, che sono incompatibili, avrebbero probabilità totale $\geq \frac{k+1}{k} > 1$. Per esempio, al massimo 2 valori possono avere probabilità $\geq \frac{1}{2}$, al massimo 10 valori probabilità $\geq \frac{1}{10}$.

Passo 2 — Li si mette in fila. Un valore con probabilità positiva ha probabilità $\geq \frac{1}{k}$ per qualche k (basta prendere k abbastanza grande). Quindi i valori con probabilità positiva si possono elencare: prima quelli (al più uno) con probabilità ≥ 1, poi quelli (al più due) con probabilità $\geq \frac{1}{2}$, poi quelli $\geq \frac{1}{3}$, e così via. L'elenco può essere infinito, ma è un elenco: l'insieme è al più numerabile.

Passo 3 — L'intervallo è troppo grande. I numeri reali di un intervallo non sono numerabili (Capitolo 1): non si possono mettere tutti in un elenco. Quindi non tutti possono avere probabilità positiva.

■

In una variabile continua «onesta» nessun valore è privilegiato rispetto ai suoi vicini, e allora tutti hanno probabilità zero. Ma attenzione: probabilità zero **non** vuol dire impossibile. Ogni volta che si misura una tensione si osserva *qualche* valore, e quel valore aveva probabilità zero di uscire.

La frequenza di un intervallo

Se la probabilità dei singoli valori è nulla, ha senso solo chiedersi con che frequenza la variabile cade in un **intervallo**. Supponiamo di compiere n esperimenti e di disporre delle osservazioni $X(\omega_i)$. Fissato un valore x, contiamo quante volte X è caduta in un intorno di x di ampiezza Δx, cioè fra $x - \frac{\Delta x}{2}$ e $x + \frac{\Delta x}{2}$:

$$f_n(x;\Delta x) = \frac{n\left\{x - \frac{\Delta x}{2} \leq X \leq x + \frac{\Delta x}{2}\right\}}{n}.$$

Possiamo allora definire nel modo consueto la probabilità dell'evento «X cade nell'intervallo»:

$$P\left(\left\{\omega \in \Omega : x - \tfrac{\Delta x}{2} \leq X \leq x + \tfrac{\Delta x}{2}\right\}\right) = P\left(X \in \left[x - \tfrac{\Delta x}{2},\, x + \tfrac{\Delta x}{2}\right]\right) = P_X(x;\Delta x) = \lim_{n\to\infty} f_n(x;\Delta x).$$

La densità di probabilità

La probabilità di un intervallo dipende dalla sua ampiezza: un intervallo largo il doppio raccoglie, più o meno, il doppio della probabilità. Per avere una grandezza che descriva la variabile *in un punto* si divide la probabilità per l'ampiezza, ottenendo una probabilità *per unità di lunghezza*, e poi si stringe l'intervallo.

Densità di probabilità (PDF)

La **funzione densità di probabilità** (*probability density function*, **PDF**) della variabile aleatoria continua X è

$$f_X(x) = \lim_{\Delta x \to 0} \frac{P\left(x - \frac{\Delta x}{2} \le X \le x + \frac{\Delta x}{2}\right)}{\Delta x} = \lim_{\Delta x \to 0} \frac{P_X(x; \Delta x)}{\Delta x}.$$

Il nome viene dalla fisica. La densità di una sbarra di metallo è la sua massa per unità di lunghezza: una sbarra più densa in un punto pesa di più in quel tratto. Allo stesso modo $f_X(x)$ dice quanta probabilità c'è «per ogni centimetro» attorno a x. Nel caso discreto la probabilità era concentrata in mucchietti (i bastoncini della pmf); ora è spalmata con continuità, come uno strato di sabbia più spesso in certi punti e più sottile in altri.

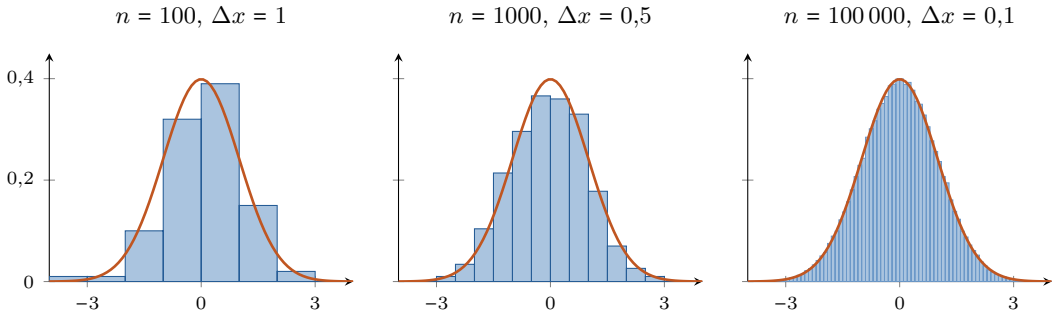


Figura 10.1: *Istogrammi di misure di rumore (simulate): ogni barra è alta $f_n(x; \Delta x)/\Delta x$, la frequenza dell'intervallo divisa per la sua ampiezza. Con più misure e intervalli più stretti l'istogramma si avvicina a una curva liscia (in arancione): la densità di probabilità. Questa curva è la gaussiana, che studieremo nel Capitolo 15.*

Dalla densità alla probabilità: l'integrale

La definizione dice che, per un intervallo piccolo, la probabilità è circa la densità per l'ampiezza:

$$P\left(x - \tfrac{\Delta x}{2} \le X \le x + \tfrac{\Delta x}{2}\right) \simeq f_X(x)\,\Delta x.$$

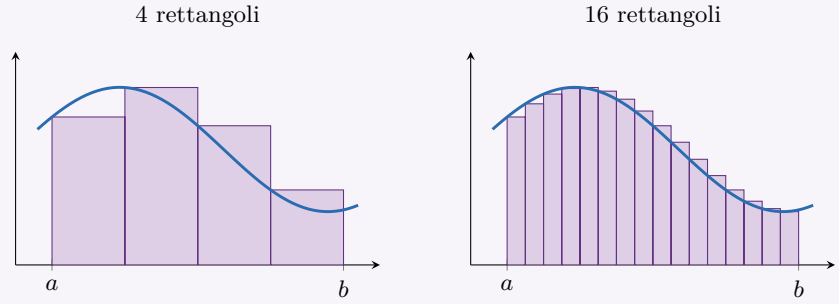
Per un intervallo grande $[a_1, a_2]$ lo si spezza in tanti intervalli piccoli, si calcola la probabilità di ciascuno così e si somma: in un grafico, è la somma delle aree di tanti rettangoli sottili sotto la curva f_X. Quando i rettangoli diventano infinitamente sottili, la somma diventa l'**area sotto la curva**, che si chiama integrale.

Richiamo di matematica: l'integrale come area

Sia $f(x) \geq 0$ una funzione definita sull'intervallo $[a, b]$. Si vuole calcolare l'area della regione compresa fra il grafico di f e l'asse x, fra a e b. Si divide $[a, b]$ in n pezzi uguali di larghezza $\Delta = \frac{b-a}{n}$, con estremi $x_0 = a, x_1, \ldots, x_n = b$, e su ogni pezzo si costruisce un rettangolo alto quanto la funzione in un punto del pezzo. La somma delle aree dei rettangoli,

$$\sum_{i=0}^{n-1} f(x_i)\,\Delta,$$

si chiama **somma di Riemann**. Più i rettangoli sono sottili, meglio approssimano l'area:



Il limite delle somme di Riemann per $n \to \infty$ (cioè per $\Delta \to 0$) è l'**integrale definito**:

$$\int_a^b f(x)\,\mathrm{d}x = \lim_{\Delta \to 0} \sum_i f(x_i)\,\Delta.$$

La notazione racconta la costruzione: il simbolo $\int$ è una «S» allungata (di somma), $f(x)$ è l'altezza di un rettangolo e $\mathrm{d}x$ è la sua larghezza infinitamente piccola. La lettera x è una variabile muta, come l'indice di una sommatoria: $\int_a^b f(x)\,\mathrm{d}x = \int_a^b f(t)\,\mathrm{d}t$.
Proprietà che seguono subito dalla costruzione con i rettangoli:

- **linearità**: $\int_a^b (c\,f(x) + d\,g(x))\,\mathrm{d}x = c\int_a^b f(x)\,\mathrm{d}x + d\int_a^b g(x)\,\mathrm{d}x$;
- **additività**: se $a < c < b$, $\int_a^b f = \int_a^c f + \int_c^b f$ (l'area si può tagliare in due);
- **positività**: se $f(x) \geq 0$ su $[a, b]$, allora $\int_a^b f(x)\,\mathrm{d}x \geq 0$;
- un singolo punto non ha area: $\int_a^a f(x)\,\mathrm{d}x = 0$.

Se la funzione è negativa in qualche tratto, le aree sotto l'asse x contano con il segno meno.

Con l'integrale, la probabilità di qualsiasi intervallo si ottiene dalla densità.

Da ricordare: probabilità di un intervallo

$$P(a_1 \leq X \leq a_2) = \int_{a_1}^{a_2} f_X(t)\,\mathrm{d}t \qquad P\left(x - \tfrac{\Delta x}{2} \leq X \leq x + \tfrac{\Delta x}{2}\right) = \int_{x-\frac{\Delta x}{2}}^{x+\frac{\Delta x}{2}} f_X(t)\,\mathrm{d}t$$

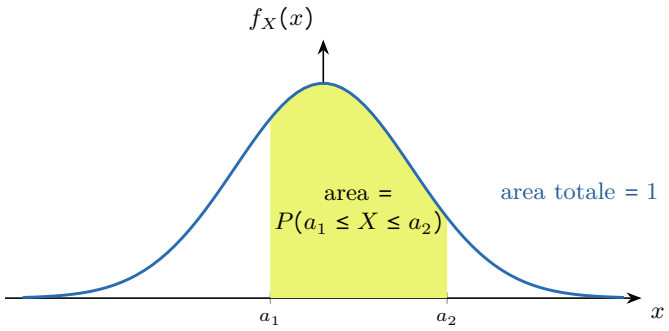


Figura 10.2: *La probabilità che X cada fra a_1 e a_2 è l'area sotto la densità, fra a_1 e a_2.*

Le proprietà della densità

Per l'area «totale», da $-\infty$ a $+\infty$, serve un'estensione dell'integrale.

Richiamo di matematica: gli integrali impropri

Un integrale su un intervallo infinito si definisce come limite:

$$\int_a^{\infty} f(x)\,dx = \lim_{H\to\infty}\int_a^{H} f(x)\,dx, \qquad \int_{-\infty}^{\infty} f(x)\,dx = \lim_{H\to\infty}\int_{-H}^{0} f(x)\,dx + \lim_{K\to\infty}\int_0^{K} f(x)\,dx.$$

Se i limiti esistono e sono finiti, l'integrale si dice **convergente** (la funzione è **sommabile**). Una regione infinitamente lunga può avere area finita, se la funzione si abbassa abbastanza in fretta: è la stessa idea della serie geometrica. Per esempio (lo calcoleremo con il teorema del prossimo richiamo) $\int_1^H \frac{1}{x^2}\,dx = 1 - \frac{1}{H}$, che tende a 1: l'area sotto $\frac{1}{x^2}$ da 1 a infinito vale 1. Invece $\int_0^H 1\,dx = H$ cresce senza limite: un rettangolo alto 1 e infinitamente lungo ha area infinita.
Nel secondo caso le due metà devono convergere *ciascuna per conto suo*: non basta che si compensino. È un punto che diventerà importante con la variabile di Cauchy, nel prossimo capitolo.

Teorema 10.2 — Proprietà della densità

Ogni densità di probabilità soddisfa:

a) $f_X(x) \geq 0$ per ogni $x \in \mathbb{R}$;

b) f_X è sommabile su $\mathbb{R}$ e il suo integrale vale 1: $\int_{-\infty}^{\infty} f_X(t)\,dt = P(X \in \mathbb{R}) = P(\Omega) = 1$.

Inoltre $P(X = x) = 0$ per ogni x, quindi gli estremi di un intervallo non contano: $P(a_1 \leq X \leq a_2) = P(a_1 < X < a_2) = P(a_1 \leq X < a_2)$.

Dimostrazione

Passo 1 — Non negatività. $f_X(x)$ è il limite di rapporti fra una probabilità (≥ 0) e un'ampiezza (> 0). In altre parole: se la densità fosse negativa in un tratto, il suo integrale su quel tratto, cioè la probabilità di quell'intervallo, sarebbe negativo.

Passo 2 — Area totale. L'evento «X è un numero reale qualsiasi» è certo, quindi ha probabilità 1, ed è l'area sotto tutta la curva.

Passo 3 — Un punto. $P(X = x) \leq P\left(x - \frac{\Delta x}{2} \leq X \leq x + \frac{\Delta x}{2}\right) \simeq f_X(x)\,\Delta x$, che tende a zero quando $\Delta x \to 0$. Quindi aggiungere o togliere gli estremi a un intervallo non cambia la sua probabilità.

■

Una densità non è una probabilità

$f_X(x)$ può benissimo essere **maggiore di 1**. Una variabile uniformemente distribuita fra 0 e $\frac{1}{2}$ ha densità 2 su quell'intervallo: l'area è $2 \cdot \frac{1}{2} = 1$, come deve. Ad avere un significato di probabilità è l'area, non l'altezza: $f_X(x)\,\Delta x$, per Δx piccolo. Ed è $P(X = x) = 0$, non $f_X(x)$.

La funzione di distribuzione cumulativa

La densità $f_X(x)$, $x \in \mathbb{R}$, è perfettamente adeguata a caratterizzare la variabile aleatoria X. I punti in cui è diversa da zero formano il suo **supporto**, $\text{supp}[f_X(x)] = \mathcal{X}$: sono i valori che la variabile può assumere. E la probabilità di qualsiasi intervallo è l'integrale della densità. Tuttavia è molto usata anche una caratterizzazione alternativa, che parla direttamente di probabilità.

Funzione di distribuzione cumulativa (CDF)

La **funzione di distribuzione cumulativa** (*Cumulative Distribution Function*, **CDF**) di X è la probabilità che X non superi il valore x:

$$F_X(x) = P(-\infty < X \le x) = \int_{-\infty}^{x} f_X(t)\,\mathrm{d}t.$$

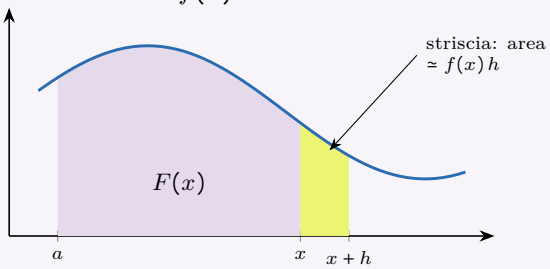
$F_X(x)$ è l'area sotto la densità *a sinistra* di x: la probabilità «accumulata» da $-\infty$ fino a x. Quando x si sposta verso destra, l'area cresce. Il legame fra F_X e f_X è uno dei risultati più importanti della matematica.

Richiamo di matematica: il teorema fondamentale del calcolo integrale

Sia f una funzione continua e sia $F(x) = \int_a^x f(t)\,\mathrm{d}t$ la **funzione integrale**: l'area sotto f da a fino a x, vista come funzione dell'estremo destro. Allora

$$F'(x) = f(x)\,:$$

la derivata dell'area è l'altezza della curva. Il motivo si vede nel disegno: quando l'estremo passa da x a $x + h$, l'area cresce di una strisciolina larga h e alta circa $f(x)$.



Quindi $F(x+h) - F(x) \simeq f(x)\,h$, il rapporto incrementale $\frac{F(x+h)-F(x)}{h}$ è circa $f(x)$, e diventa esattamente $f(x)$ quando $h \to 0$ (la striscia diventa un rettangolo perfetto).

Come si calcola un integrale. Una funzione G con $G'(x) = f(x)$ si chiama **primitiva** di f. Due primitive della stessa funzione differiscono per una costante (la loro differenza ha derivata nulla, quindi è piatta). Siccome anche F è una primitiva, $F(x) = G(x) + c$, e da $F(a) = 0$ si ricava $c = -G(a)$. Quindi

$$\int_a^b f(x)\,\mathrm{d}x = G(b) - G(a) = \Big[G(x)\Big]_a^b\,:$$

per calcolare un integrale basta trovare una primitiva e fare la differenza dei suoi valori agli estremi. Le primitive si trovano leggendo al contrario la tabella delle derivate. Da $(x^{n+1})' = (n+1)\,x^n$:

$$\int_a^b x^n\,\mathrm{d}x = \left[\frac{x^{n+1}}{n+1}\right]_a^b = \frac{b^{n+1} - a^{n+1}}{n+1} \qquad (n \neq -1).$$

Per esempio $\int_0^1 x\,\mathrm{d}x = \frac{1}{2}$ (l'area del triangolo con base e altezza 1) e $\int_1^H x^{-2}\,\mathrm{d}x = \Big[-x^{-1}\Big]_1^H = 1 - \frac{1}{H}$.

Applicando il teorema fondamentale alla CDF si ottiene subito il legame con la densità.

Da ricordare: CDF e PDF

$$F_X(x) = \int_{-\infty}^{x} f_X(t)\,\mathrm{d}t \qquad \Longleftrightarrow \qquad f_X(x) = \frac{\mathrm{d}}{\mathrm{d}x} F_X(x)$$

Talvolta si fa riferimento alla funzione complementare, la **CCDF** (*Complementary Cumulative Distribution Function*): la probabilità che X superi x, cioè l'area a destra di x,

$$\overline{F}_X(x) = P(X > x) = \int_x^{\infty} f_X(t)\,\mathrm{d}t = 1 - F_X(x) \quad \Longrightarrow \quad f_X(x) = -\frac{\mathrm{d}}{\mathrm{d}x}\overline{F}_X(x).$$

Teorema 10.3 — Proprietà della CDF

a) $F_X(x) \in [0,1]$;
b) $F_X(-\infty) = 0$ e $F_X(+\infty) = 1$ (intesi come limiti);
c) F_X è continua;
d) F_X è crescente (non decrescente): se $x_1 < x_2$ allora $F_X(x_1) \le F_X(x_2)$;
e) $P(a_1 \le X \le a_2) = \int_{a_1}^{a_2} f_X(t)\,\mathrm{d}t = F_X(a_2) - F_X(a_1)$.

Dimostrazione

Passo 1 — Fra 0 e 1. $F_X(x)$ è una probabilità.

Passo 2 — Ai due estremi. Per $x \to -\infty$ l'area a sinistra di x si riduce a nulla; per $x \to +\infty$ diventa tutta l'area sotto la densità, che vale 1.

Passo 3 — Continuità. Spostando x di poco, l'area cambia di poco: di una striscia stretta, larga quanto lo spostamento. (È la funzione integrale di una funzione sommabile.)

Passo 4 — Crescenza. Se $x_1 < x_2$, l'area fino a x_2 è quella fino a x_1 più l'area fra x_1 e x_2, che non è negativa perché l'integrando $f_X \ge 0$.

Passo 5 — Un intervallo. Per l'additività dell'integrale, $\int_{-\infty}^{a_2} f_X = \int_{-\infty}^{a_1} f_X + \int_{a_1}^{a_2} f_X$, cioè $F_X(a_2) = F_X(a_1) + P(a_1 \le X \le a_2)$.

■

Esempio 10.2 — La densità triangolare

Sia X con densità a forma di triangolo:

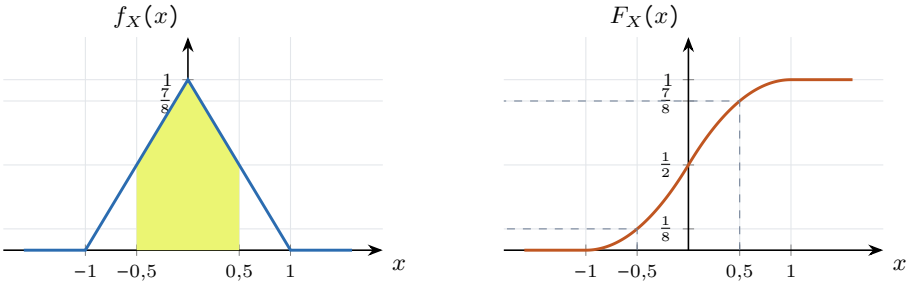
$$f_X(x) = \begin{cases} 1 - |x| & -1 \le x \le 1 \\ 0 & \text{altrove} \end{cases}$$

È una densità: è ≥ 0, e l'area sotto il triangolo (base 2, altezza 1) vale $\frac{2 \cdot 1}{2} = 1$. Calcoliamo la CDF integrando un pezzo alla volta.

- Per $x < -1$ a sinistra non c'è area: $F_X(x) = 0$.
- Per $-1 \le x \le 0$ la densità vale $1 + t$, con primitiva $t + \frac{t^2}{2}$:

$$F_X(x) = \int_{-1}^{x} (1 + t)\,\mathrm{d}t = \left[t + \frac{t^2}{2}\right]_{-1}^{x} = x + \frac{x^2}{2} - \left(-1 + \frac{1}{2}\right) = \frac{(1 + x)^2}{2}.$$

- Per $0 \le x \le 1$ all'area di sinistra, $F_X(0) = \frac{1}{2}$, si aggiunge quella fra 0 e x, dove la densità vale $1 - t$: $\int_0^x (1 - t)\,\mathrm{d}t = x - \frac{x^2}{2}$. Quindi $F_X(x) = \frac{1}{2} + x - \frac{x^2}{2} = 1 - \frac{(1-x)^2}{2}$.
- Per $x > 1$ tutta l'area è a sinistra: $F_X(x) = 1$.



La probabilità che X cada fra $-\frac{1}{2}$ e $\frac{1}{2}$ è l'area gialla a sinistra, oppure la differenza dei valori della CDF a destra:

$$P\left(-\tfrac{1}{2} \le X \le \tfrac{1}{2}\right) = F_X\left(\tfrac{1}{2}\right) - F_X\left(-\tfrac{1}{2}\right) = \left(1 - \tfrac{1}{8}\right) - \tfrac{1}{8} = \tfrac{3}{4}.$$

Verifica geometrica: fuori dalla zona gialla restano due triangolini con base e altezza $\frac{1}{2}$, di area $\frac{1}{8}$ ciascuno, e $1 - \frac{1}{8} - \frac{1}{8} = \frac{3}{4}$. Si noti anche che la CDF cresce più in fretta dove la densità è più alta (attorno a 0): la sua pendenza è proprio la densità.

La CDF delle variabili discrete

La CDF si può definire anche per le variabili discrete (e per quelle «miste», di cui non parliamo): $F_X(x) = P(X \le x)$ ha senso per qualsiasi variabile aleatoria. In questo caso, però, la proprietà di continuità va «rimodulata»: la CDF di una variabile discreta è una **scala**, piatta fra un valore dell'alfabeto e il successivo, con un **salto** in ogni valore x alto esattamente $p_X(x)$.

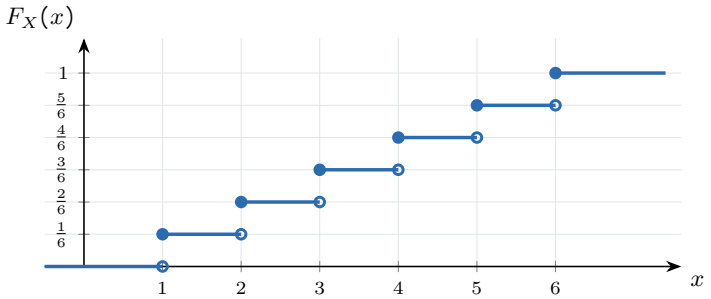


Figura 10.3: *La CDF del lancio di un dado: in ogni faccia sale di un gradino alto $\frac{1}{6}$. Il pallino pieno indica il valore nel punto di salto: $F_X(3) = P(X \le 3) = \frac{3}{6}$, perché il 3 è compreso.*

LA MEDIA DI UNA VARIABILE CONTINUA

Media statistica di una variabile continua

La **media statistica** di una variabile aleatoria continua con densità $f_X(x)$ è

$$E[X] = \mu_X = \int_{-\infty}^{\infty} x\, f_X(x)\, \mathrm{d}x,$$

purché l'integrale converga.

La definizione è la stessa del caso discreto, $\sum_x x\, p_X(x)$, con l'integrale al posto della somma e $f_X(x)\,\mathrm{d}x$ al posto di $p_X(x)$. Per giustificarla in modo convincente si può approssimare la variabile continua con una discreta.

Dimostrazione — la media come limite di una variabile quantizzata

Passo 1 — Si quantizza X. Si divide l'asse reale in intervalli di ampiezza Δ e si definisce la versione «quantizzata» di X: se X cade nell'intervallo $[i\Delta, (i+1)\Delta)$, la si sostituisce con un valore x_i di quell'intervallo,

$$X^{\Delta} = x_i \in [i\Delta, (i+1)\Delta) \qquad \text{se} \quad i\Delta \le X < (i+1)\Delta.$$

È una variabile discreta, con probabilità

$$P(X^{\Delta} = x_i) = \int_{i\Delta}^{(i+1)\Delta} f_X(x)\,\mathrm{d}x.$$

Passo 2 — La media della variabile discreta. Con la definizione del Capitolo 5:

$$E[X^{\Delta}] = \sum_{i=-\infty}^{\infty} x_i\, P(X^{\Delta} = x_i) = \sum_{i=-\infty}^{\infty} x_i \int_{i\Delta}^{(i+1)\Delta} f_X(x)\,\mathrm{d}x.$$

Passo 3 — Si stringono gli intervalli. Quando Δ è piccolo, l'area sotto f_X su un intervallo è circa l'altezza per la base, $f_X(x_i)\,\Delta$, e la quantizzazione diventa sempre più fine. Se $x f_X(x)$ è integrabile (secondo Riemann), la somma diventa una somma di Riemann della funzione $x f_X(x)$:

$$E[X] = \lim_{\Delta\to 0} E[X^{\Delta}] = \lim_{\Delta\to 0} \sum_{i=-\infty}^{\infty} x_i\, f_X(x_i)\,\Delta = \int_{-\infty}^{\infty} x\, f_X(x)\,\mathrm{d}x.$$

■

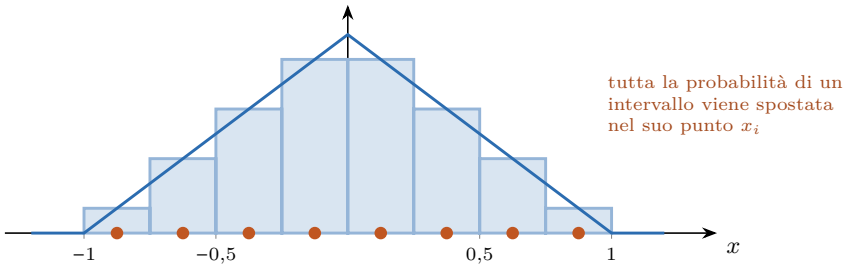


Figura 10.4: *La quantizzazione della densità triangolare con $\Delta = \frac{1}{4}$: ogni rettangolo azzurro ha area circa uguale alla probabilità del suo intervallo, che la variabile quantizzata X^{Δ} concentra nel punto arancione.*

Esempio 10.3 — Due medie

- La densità triangolare è simmetrica attorno a 0, e la sua media è 0: i contributi $x f_X(x)$ a destra (positivi) e a sinistra (negativi) sono uguali e opposti.
- Sia $f_X(x) = 2x$ per $0 \le x \le 1$ (e 0 altrove): una densità che cresce, quindi i valori grandi sono più probabili. È una densità perché $\int_0^1 2x\,\mathrm{d}x = \left[x^2\right]_0^1 = 1$. La media è

$$E[X] = \int_0^1 x \cdot 2x\,\mathrm{d}x = \int_0^1 2x^2\,\mathrm{d}x = \left[\tfrac{2x^3}{3}\right]_0^1 = \tfrac{2}{3},$$

  spostata verso destra rispetto al punto di mezzo $\frac{1}{2}$, come ci si aspetta.

Anche nel continuo la media è il **baricentro**: una sbarra con densità di massa $f_X(x)$ starebbe in equilibrio appoggiata nel punto $E[X]$.

In sintesi

- Per una variabile continua ogni singolo valore ha probabilità zero: gli intervalli, non i punti, hanno probabilità. Solo un'infinità al più numerabile di valori può avere probabilità positiva.
- La **densità** $f_X(x) = \lim P(x - \frac{\Delta x}{2} \le X \le x + \frac{\Delta x}{2})/\Delta x$ è una probabilità per unità di lunghezza: $f_X \ge 0$, $\int f_X = 1$, e può superare 1.
- $P(a_1 \le X \le a_2) = \int_{a_1}^{a_2} f_X$: l'**integrale** è l'area sotto la curva, limite delle somme di Riemann; si calcola con una primitiva, $\int_a^b f = G(b) - G(a)$.
- La **CDF** $F_X(x) = P(X \le x) = \int_{-\infty}^{x} f_X$ è continua, crescente, va da 0 a 1, e $f_X = F_X'$ (teorema fondamentale del calcolo integrale). La CCDF è $1 - F_X$. Per le variabili discrete la CDF è una scala.
- **Media**: $E[X] = \int x\, f_X(x)\,\mathrm{d}x$, limite della media di una versione quantizzata di X.

Le variabili aleatorie continue notevoli

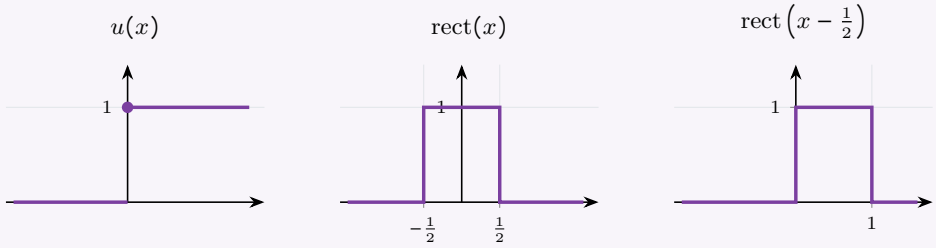
Come nel discreto avevamo la binomiale, l'uniforme e la Poisson, anche nel continuo ci sono alcune variabili che compaiono di continuo. In questo capitolo ne studiamo quattro: l'**uniforme**, l'**esponenziale**, quella di **Laplace** e quella di **Cauchy**. Per ognuna calcoliamo la densità, la CDF e la media; per farlo ci servono alcuni strumenti nuovi per gli integrali (l'integrazione per parti, il cambio di variabile) e due funzioni nuove (il logaritmo e l'arcotangente), tutti spiegati da zero. La variabile di Cauchy ci riserverà una sorpresa: non ha media. La quinta variabile continua notevole, la gaussiana, è così importante che avrà un capitolo tutto per sé.

Due funzioni utili: il gradino e il rettangolo

Le densità che vedremo sono spesso diverse da zero solo su una parte della retta. Per scriverle in una sola formula si usano due funzioni «interruttore».

Richiamo di matematica: il gradino unitario e la funzione rettangolo

Il **gradino unitario** $u(x)$ vale 0 per $x < 0$ e 1 per $x \geq 0$: moltiplicare una funzione per $u(x)$ la «spegne» a sinistra dello zero. La **funzione rettangolo** $\text{rect}(x)$ vale 1 per $|x| < \frac{1}{2}$ e 0 altrove: è un impulso largo 1 centrato in 0, e $\text{rect}\left(x - \frac{1}{2}\right)$ è lo stesso impulso spostato sull'intervallo $(0, 1)$.



Per esempio, $e^{-x}u(x)$ vale e^{-x} per $x \geq 0$ e zero per $x < 0$. Quanto valga la funzione esattamente nel punto di salto non conta: un singolo punto non ha area, quindi non cambia nessun integrale.

LA VARIABILE UNIFORME

Variabile uniforme continua

Una variabile aleatoria X si dice **uniformemente distribuita** nell'intervallo $[a, b]$ (con $b > a$), in breve $X \sim \mathcal{U}(a, b)$, se

$$f_X(x) = \begin{cases} \dfrac{1}{b-a} & x \in (a, b) \\ 0 & \text{altrove} \end{cases}$$

La densità è costante sull'intervallo: nessun punto è privilegiato. L'altezza $\frac{1}{b-a}$ è l'unica che rende l'area del rettangolo (base $b - a$) uguale a 1. Il supporto è $\text{supp}[f_X(x)] = [a, b]$, e tale è anche l'alfabeto: X non assume valori fuori dall'intervallo. Con la funzione rettangolo, $\mathcal{U}(0, 1)$ ha densità $\text{rect}\left(x - \frac{1}{2}\right)$.

Teorema 11.1 — CDF e media dell'uniforme

Se $X \sim \mathcal{U}(a, b)$:

$$F_X(x) = \begin{cases} 0 & x < a \\ \dfrac{x-a}{b-a} & a \le x \le b \\ 1 & x > b \end{cases} \qquad E[X] = \frac{a+b}{2}.$$

Dimostrazione

Passo 1 — La CDF. A sinistra di a non c'è area. Fra a e x la densità vale $\frac{1}{b-a}$, costante, quindi l'area è quella di un rettangolo: base $x - a$, altezza $\frac{1}{b-a}$. Oltre b l'area è tutta, cioè 1.

$$F_X(x) = \int_{-\infty}^{x} f_X(t)\,\mathrm{d}t = \int_a^x \frac{1}{b-a}\,\mathrm{d}t = \frac{x-a}{b-a} \qquad (a \le x \le b).$$

Passo 2 — La media. Con la primitiva di x, che è $\frac{x^2}{2}$:

$$E[X] = \int_a^b x\,\frac{1}{b-a}\,\mathrm{d}x = \frac{1}{b-a}\left[\frac{x^2}{2}\right]_a^b = \frac{b^2-a^2}{2(b-a)} = \frac{(b-a)(b+a)}{2(b-a)} = \frac{b+a}{2},$$

dove si è usato il prodotto notevole $b^2 - a^2 = (b - a)(b + a)$.

■

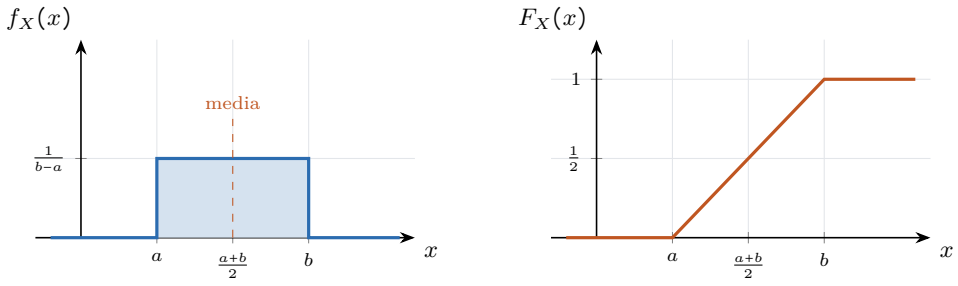


Figura 11.1: *La variabile uniforme: densità costante sull'intervallo, CDF che sale in linea retta da 0 a 1.*

La variabile esponenziale

Variabile esponenziale

Una variabile aleatoria X si dice **esponenziale** (unilatera) di parametro $\lambda > 0$, in breve $X \sim \mathcal{E}(\lambda)$, se ha densità

$$f_X(x) = \lambda\, e^{-\lambda x}\, u(x).$$

Il supporto è $\operatorname{supp}[f_X(x)] = [0, \infty)$: la variabile è sempre non negativa, $X \geq 0$. È la variabile tipica dei **tempi di attesa**: il tempo fino al prossimo pacchetto che arriva a un router, fino al guasto di un componente, fino al decadimento di un atomo. La densità è massima in 0 e cala esponenzialmente: le attese brevi sono le più probabili, quelle lunghe sono rare. Prima di calcolare la CDF serve sapere come si integra un esponenziale.

Richiamo di matematica: la derivata e la primitiva di e^{ax}

Per una costante a: $\left(e^{ax}\right)' = a\, e^{ax}$. Infatti il rapporto incrementale è

$$\frac{e^{a(x+h)} - e^{ax}}{h} = e^{ax}\,\frac{e^{ah} - 1}{h} = a\, e^{ax}\,\frac{e^{ah} - 1}{ah},$$

e l'ultima frazione tende a 1 quando $h \to 0$ (è il limite $\frac{e^k - 1}{k} \to 1$ del Capitolo 7, con $k = ah$ che tende anch'esso a zero). Di conseguenza una primitiva di e^{ax} è $\frac{e^{ax}}{a}$, e in particolare

$$\int e^{-\lambda t}\, \mathrm{d}t \quad \text{ha primitiva} \quad \frac{e^{-\lambda t}}{-\lambda}.$$

Serve anche sapere che l'esponenziale «batte» qualsiasi potenza: per $\lambda > 0$, $x^n e^{-\lambda x} \to 0$ quando $x \to \infty$. Per $n = 1$: dalla serie esponenziale, che ha tutti i termini positivi, $e^{\lambda x} \geq \frac{(\lambda x)^2}{2}$, quindi $x\, e^{-\lambda x} \leq \frac{2x}{\lambda^2 x^2} = \frac{2}{\lambda^2 x} \to 0$. Per n qualsiasi si ragiona allo stesso modo con il termine $\frac{(\lambda x)^{n+1}}{(n+1)!}$ della serie.

Teorema 11.2 — CDF dell'esponenziale

Se $X \sim \mathcal{E}(\lambda)$: $\quad F_X(x) = \left(1 - e^{-\lambda x}\right) u(x), \quad \overline{F}_X(x) = P(X > x) = e^{-\lambda x}$ per $x \geq 0$.

Dimostrazione

Passo 1. Per $x < 0$ non c'è area. Per $x \geq 0$, con la primitiva del richiamo:

$$F_X(x) = \int_0^x \lambda\, e^{-\lambda t}\, \mathrm{d}t = \lambda \left[\frac{e^{-\lambda t}}{-\lambda}\right]_0^x = \left[-e^{-\lambda t}\right]_0^x = -e^{-\lambda x} - \left(-e^{0}\right) = 1 - e^{-\lambda x}.$$

La CCDF è il complemento a 1: $e^{-\lambda x}$.

■

Per la media serve una tecnica nuova, perché l'integrando $x\, \lambda e^{-\lambda x}$ è un prodotto.

Richiamo di matematica: l'integrazione per parti

La regola del prodotto (Capitolo 7) dice che $(fg)' = f'g + fg'$. Integrando entrambi i membri fra a e b, e ricordando che l'integrale di una derivata è la differenza dei valori agli estremi (teorema fondamentale):

$$\Big[fg\Big]_a^b = \int_a^b f'(x)\,g(x)\,\mathrm{d}x + \int_a^b f(x)\,g'(x)\,\mathrm{d}x.$$

Portando un integrale dall'altra parte si ottiene la formula di **integrazione per parti**:

$$\int_a^b f(x)\,g'(x)\,\mathrm{d}x = \Big[f(x)\,g(x)\Big]_a^b - \int_a^b f'(x)\,g(x)\,\mathrm{d}x.$$

Serve quando l'integrando è un prodotto di due fattori, uno facile da derivare (f, che derivato si semplifica) e uno facile da integrare (g', di cui si conosce una primitiva g). Esempio:

$$\int_0^1 x\,e^x\,\mathrm{d}x = \Big[x\,e^x\Big]_0^1 - \int_0^1 1\cdot e^x\,\mathrm{d}x = e - (e-1) = 1,$$

con $f = x$ (derivata 1) e $g' = e^x$ (primitiva e^x).

Teorema 11.3 — Media dell'esponenziale

Se $X \sim \mathcal{E}(\lambda)$: $\quad E[X] = \dfrac{1}{\lambda}$.

Dimostrazione

Passo 1 — Si toglie il gradino. Il gradino annulla la parte negativa dell'asse:

$$E[X] = \int_{-\infty}^{\infty} x\,f_X(x)\,\mathrm{d}x = \int_{-\infty}^{\infty} x\,\lambda e^{-\lambda x}u(x)\,\mathrm{d}x = \int_0^{\infty} x\,\lambda e^{-\lambda x}\,\mathrm{d}x.$$

Passo 2 — Per parti. Con $f(x) = x$ (derivata 1) e $g'(x) = \lambda e^{-\lambda x}$ (primitiva $g(x) = -e^{-\lambda x}$):

$$\int_0^{\infty} x\,\lambda e^{-\lambda x}\,\mathrm{d}x = \Big[x\left(-e^{-\lambda x}\right)\Big]_0^{\infty} - \int_0^{\infty}\left(-e^{-\lambda x}\right)\mathrm{d}x.$$

Passo 3 — Il termine di bordo è nullo. In $x = 0$ vale 0; per $x \to \infty$, $x\,e^{-\lambda x} \to 0$ (l'esponenziale batte la potenza).

Passo 4 — L'integrale rimasto.

$$E[X] = \int_0^{\infty} e^{-\lambda x}\,\mathrm{d}x = \left[\frac{e^{-\lambda x}}{-\lambda}\right]_0^{\infty} = 0 - \frac{1}{-\lambda} = \frac{1}{\lambda}.$$

■

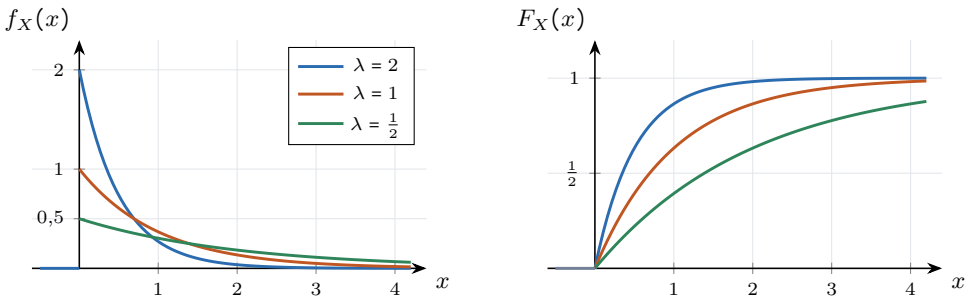


Figura 11.2: *Densità e CDF esponenziali. Con λ grande la densità parte alta e scende in fretta (attese brevi, media $\frac{1}{\lambda}$ piccola); con λ piccolo è bassa e lunga (attese lunghe).*

Esempio 11.1 — L'esponenziale non ha memoria

Il tempo di vita di un componente elettronico è $X \sim \mathcal{E}(\lambda)$. Il componente funziona da s ore: qual è la probabilità che funzioni per almeno altre t ore? Con la probabilità condizionata e la CCDF:

$$P(X > s+t \mid X > s) = \frac{P(\{X > s+t\} \cap \{X > s\})}{P(X > s)} = \frac{P(X > s+t)}{P(X > s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = P(X > t).$$

(L'intersezione è $\{X > s+t\}$ perché chi supera $s+t$ supera anche s.) Il risultato non dipende da s: il componente «non ricorda» quanto ha già lavorato, e la sua vita residua ha la stessa distribuzione di quella di un componente nuovo. È la proprietà di **assenza di memoria**, che rende l'esponenziale il modello naturale dei guasti casuali (non dovuti all'usura) e degli arrivi «a caso» di pacchetti o chiamate.

La variabile di Laplace

Variabile di Laplace

Una variabile aleatoria X si dice **di Laplace** di parametro $\lambda > 0$, in breve $X \sim \mathcal{L}(\lambda)$, se ha densità

$$f_X(x) = \frac{\lambda}{2} e^{-\lambda|x|}.$$

In questo caso $\text{supp}[f_X(x)] = \mathbb{R}$: la variabile può assumere qualunque valore reale. La densità è fatta da due esponenziali «schiena contro schiena», ciascuno dimezzato (così l'area totale è 1): è simmetrica attorno a 0, con una punta nell'origine.

Teorema 11.4 — CDF della variabile di Laplace

Se $X \sim \mathcal{L}(\lambda)$:

$$F_X(x) = \begin{cases} \frac{1}{2} e^{\lambda x} & x \le 0 \\ 1 - \frac{1}{2} e^{-\lambda x} & x \ge 0 \end{cases}$$

Dimostrazione

Passo 1 — Il valore assoluto. $|t| = -t$ per $t \le 0$ e $|t| = t$ per $t \ge 0$: a sinistra dello zero la densità è $\frac{\lambda}{2}e^{\lambda t}$, a destra $\frac{\lambda}{2}e^{-\lambda t}$.

Passo 2 — Per $x \le 0$. Si integra solo la parte sinistra. La primitiva di $e^{\lambda t}$ è $\frac{e^{\lambda t}}{\lambda}$, che tende a 0 per $t \to -\infty$:

$$F_X(x) = \int_{-\infty}^{x} \frac{\lambda}{2} e^{\lambda t}\, dt = \frac{\lambda}{2}\left[\frac{e^{\lambda t}}{\lambda}\right]_{-\infty}^{x} = \frac{1}{2} e^{\lambda x}.$$

Passo 3 — Per $x \ge 0$. Si spezza l'integrale in zero, perché le due metà hanno formule diverse:

$$F_X(x) = \int_{-\infty}^{0} \frac{\lambda}{2} e^{\lambda t}\, dt + \int_{0}^{x} \frac{\lambda}{2} e^{-\lambda t}\, dt = \frac{\lambda}{2}\left(\left[\frac{e^{\lambda t}}{\lambda}\right]_{-\infty}^{0} + \left[\frac{e^{-\lambda t}}{-\lambda}\right]_{0}^{x}\right) = \frac{\lambda}{2}\left(\frac{1}{\lambda} + \frac{1 - e^{-\lambda x}}{\lambda}\right).$$

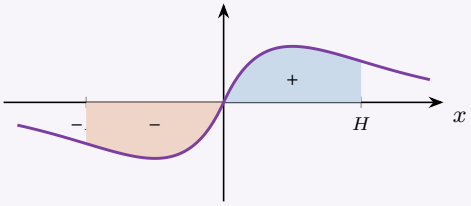
Raccogliendo: $\frac{\lambda}{2} \cdot \frac{2 - e^{-\lambda x}}{\lambda} = 1 - \frac{1}{2} e^{-\lambda x}$. Si noti che le due formule danno lo stesso valore, $\frac{1}{2}$, in $x = 0$: metà della probabilità sta a sinistra dello zero e metà a destra.

■

Per la media non serve nessun calcolo, grazie a un'osservazione sulla simmetria.

Richiamo di matematica: funzioni pari e dispari

Una funzione è **pari** se $g(-x) = g(x)$: il grafico è simmetrico rispetto all'asse verticale (esempi: x^2, $|x|$, $e^{-|x|}$). È **dispari** se $g(-x) = -g(x)$: il grafico è simmetrico rispetto all'origine (esempi: x, x^3, $\sin x$). Il prodotto di una funzione dispari per una pari è dispari: in particolare, se f è pari, $x\,f(x)$ è dispari.



L'integrale di una funzione dispari su un intervallo simmetrico $[-H, H]$ è nullo: l'area a destra (positiva) e quella a sinistra (negativa) sono uguali e opposte. Su tutta la retta, $\int_{-\infty}^{\infty}$, vale lo stesso **purché** le due metà $\int_0^{\infty}$ e $\int_{-\infty}^{0}$ siano finite: se sono infinite, «$+\infty - \infty$» non ha senso, e l'integrale non esiste.

Teorema 11.5 — Media della variabile di Laplace

Se $X \sim \mathcal{L}(\lambda)$: $\quad E[X] = \displaystyle\int_{-\infty}^{\infty} x\,\frac{\lambda}{2}\,e^{-\lambda|x|}\,\mathrm{d}x = 0.$

Dimostrazione

Passo 1 — L'integrando è dispari. La densità è pari, quindi $x\,f_X(x)$ è dispari.

Passo 2 — Le due metà sono finite. $\int_0^{\infty} x\,\frac{\lambda}{2}e^{-\lambda x}\,\mathrm{d}x = \frac{1}{2}\cdot\frac{1}{\lambda}$, perché è metà dell'integrale calcolato per la media dell'esponenziale. Allo stesso modo la metà sinistra vale $-\frac{1}{2\lambda}$. La somma è zero. ∎

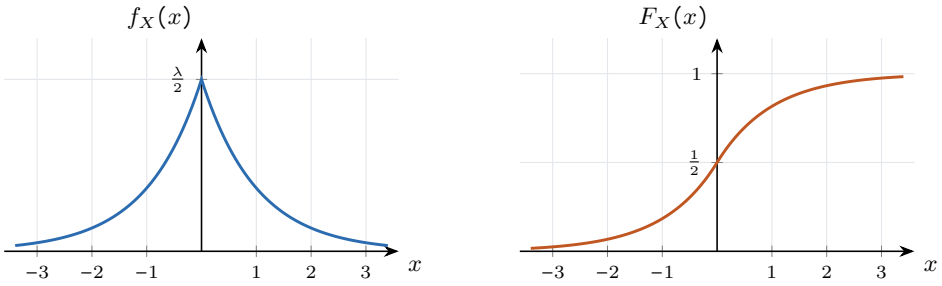


Figura 11.3: *La variabile di Laplace con $\lambda = 1$: due esponenziali dimezzati, simmetrici attorno a 0.*

La variabile di Cauchy

Variabile di Cauchy

Una variabile aleatoria X si dice **di Cauchy** di parametri (a, b), con $b > 0$, in breve $X \sim \mathcal{C}(a, b)$, se ha densità

$$f_X(x) = \frac{1}{b\pi}\,\frac{1}{1 + \left(\dfrac{x-a}{b}\right)^2}.$$

Anche qui $\mathrm{supp}[f_X(x)] = \mathbb{R}$. La densità è una campana simmetrica attorno ad a, che è quindi il *parametro di posizione*; b ne regola la larghezza (a distanza b dal centro la densità è scesa a metà del massimo). Per calcolare la CDF servono due strumenti: il cambio di variabile e l'arcotangente.

Richiamo di matematica: la regola della catena e il cambio di variabile

La derivata di una funzione composta. Se $y = g(x)$ e poi $z = f(y)$, la funzione composta è $z = f(g(x))$. Quando x cresce di un poco h, y cresce di circa $g'(x)\,h$; e quando y cresce di $g'(x)\,h$, z cresce di circa $f'(y)\cdot g'(x)\,h$. Le pendenze si moltiplicano:

$$\frac{\mathrm{d}}{\mathrm{d}x} f(g(x)) = f'(g(x))\, g'(x).$$

È la **regola della catena**. Esempi: $\big((1+x^2)^3\big)' = 3(1+x^2)^2 \cdot 2x$; $\big(e^{-x^2/2}\big)' = e^{-x^2/2}\cdot(-x)$.

Il cambio di variabile negli integrali. Leggendo la regola della catena al contrario: se G è una primitiva di f, allora $G(g(x))$ ha derivata $f(g(x))\,g'(x)$, quindi

$$\int_a^b f(g(x))\,g'(x)\,\mathrm{d}x = \int_{g(a)}^{g(b)} f(u)\,\mathrm{d}u.$$

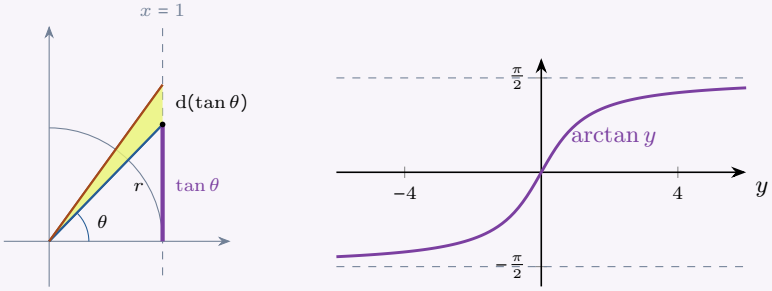
In pratica si pone $u = g(x)$, si sostituisce $\mathrm{d}u = g'(x)\,\mathrm{d}x$ e si cambiano gli estremi. Il caso che ci serve è quello lineare, $u = \frac{t-a}{b}$, con $\mathrm{d}u = \frac{\mathrm{d}t}{b}$, cioè $\mathrm{d}t = b\,\mathrm{d}u$:

$$\int_{-\infty}^{x} \phi\left(\frac{t-a}{b}\right)\mathrm{d}t = b\int_{-\infty}^{\frac{x-a}{b}} \phi(u)\,\mathrm{d}u.$$

Ha un significato geometrico semplice: spostare un grafico non cambia l'area, allargarlo di un fattore b in orizzontale la moltiplica per b.

Richiamo di matematica: l'arcotangente

La **tangente** di un angolo θ (in radianti) è $\tan\theta = \frac{\sin\theta}{\cos\theta}$. Sulla circonferenza di raggio 1, è l'altezza a cui la semiretta inclinata di θ incontra la retta verticale $x = 1$. Quando θ va da $-\frac{\pi}{2}$ a $\frac{\pi}{2}$ (da -90° a 90°, esclusi), la tangente assume una e una sola volta ogni valore reale, da $-\infty$ a $+\infty$. Si può quindi invertire: l'**arcotangente** $\arctan y$ è l'angolo, compreso fra $-\frac{\pi}{2}$ e $\frac{\pi}{2}$, la cui tangente vale y. Per esempio $\arctan 0 = 0$, $\arctan 1 = \frac{\pi}{4}$, e $\arctan y \to \pm\frac{\pi}{2}$ per $y \to \pm\infty$.



La sua derivata è $\frac{1}{1+y^2}$. Nel disegno a sinistra, la semiretta inclinata di θ incontra la retta $x = 1$ a distanza $r = \frac{1}{\cos\theta}$ dall'origine, cioè $r^2 = 1 + \tan^2\theta$ (per Pitagora). Ruotando la semiretta di un angolo piccolo $\mathrm{d}\theta$, il punto d'incontro sale di $\mathrm{d}(\tan\theta)$. L'arco percorso a distanza r è lungo $r\,\mathrm{d}\theta$ ed è perpendicolare alla semiretta; la retta verticale forma con esso l'angolo θ, quindi il tratto verticale è più lungo: $\mathrm{d}(\tan\theta) = \frac{r\,\mathrm{d}\theta}{\cos\theta} = r^2\,\mathrm{d}\theta = (1+\tan^2\theta)\,\mathrm{d}\theta$. Posto $y = \tan\theta$, cioè $\theta = \arctan y$:

$$\frac{\mathrm{d}\theta}{\mathrm{d}y} = \frac{1}{1+y^2} \qquad\Longrightarrow\qquad (\arctan y)' = \frac{1}{1+y^2}.$$

Quindi arctan è una primitiva di $\frac{1}{1+y^2}$, che è proprio la forma della densità di Cauchy.

Teorema 11.6 — CDF della variabile di Cauchy

Se $X \sim \mathcal{C}(a,b)$: $\qquad F_X(x) = \frac{1}{2} + \frac{1}{\pi}\arctan\left(\frac{x-a}{b}\right)$.

Dimostrazione

Passo 1 — Il cambio di variabile. Con $u = \frac{t-a}{b}$ si ha $\mathrm{d}t = b\,\mathrm{d}u$, e l'estremo $t = x$ diventa $u = \frac{x-a}{b}$:

$$F_X(x) = \frac{1}{b\pi}\int_{-\infty}^{x} \frac{1}{1+\left(\frac{t-a}{b}\right)^2}\,\mathrm{d}t = \frac{1}{b\pi}\int_{-\infty}^{\frac{x-a}{b}} \frac{1}{1+u^2}\,b\,\mathrm{d}u = \frac{1}{\pi}\int_{-\infty}^{\frac{x-a}{b}} \frac{1}{1+u^2}\,\mathrm{d}u.$$

Passo 2 — L'arcotangente. La primitiva è $\arctan u$, e $\arctan(-\infty) = -\frac{\pi}{2}$:

$$F_X(x) = \frac{1}{\pi}\left[\arctan\left(\frac{x-a}{b}\right) - \arctan(-\infty)\right] = \frac{1}{\pi}\left[\arctan\left(\frac{x-a}{b}\right) + \frac{\pi}{2}\right] = \frac{1}{2} + \frac{1}{\pi}\arctan\left(\frac{x-a}{b}\right).$$

Passo 3 — Una verifica. Per $x \to +\infty$, $\arctan \to \frac{\pi}{2}$ e $F_X \to \frac{1}{2} + \frac{1}{2} = 1$: l'area totale è 1, quindi f_X è davvero una densità.

■

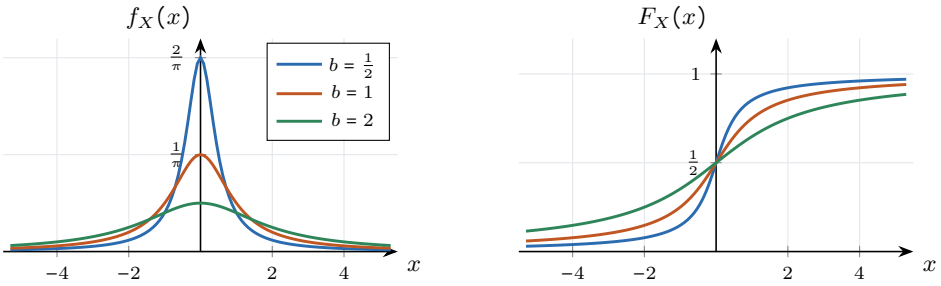


Figura 11.4: *Densità e CDF di Cauchy con $a = 0$. Le code scendono come $\frac{1}{x^2}$, molto più lentamente di un esponenziale: valori lontanissimi dal centro sono rari, ma non abbastanza rari.*

La variabile di Cauchy non ha media

La densità è simmetrica attorno ad a, e verrebbe da dire che la media è a. Invece la media **non è definita**, perché la funzione $x\,f_X(x)$ non è integrabile. Per vederlo serve una funzione che crescesse senza limite, ma molto lentamente.

Richiamo di matematica: il logaritmo

Il **logaritmo naturale** $\ln x$ (per $x > 0$) è l'inversa dell'esponenziale: $\ln x$ è il numero y tale che $e^y = x$. Quindi $\ln 1 = 0$, $\ln e = 1$, $\ln(e^{10}) = 10$, e trasforma i prodotti in somme: $\ln(xy) = \ln x + \ln y$, $\ln \frac{x}{y} = \ln x - \ln y$ (perché $e^a e^b = e^{a+b}$). Cresce senza limite, ma lentissimamente: per arrivare a 10 serve $x = e^{10} \approx 22\,026$.
La sua derivata è $\frac{1}{x}$. Se $y = \ln x$, allora $x = e^y$. Quando y cresce di $\mathrm{d}y$, x cresce di $e^y\,\mathrm{d}y = x\,\mathrm{d}y$; quindi $\frac{\mathrm{d}y}{\mathrm{d}x} = \frac{1}{x}$. Ecco la primitiva che mancava alla tabella del Capitolo 10, il caso $n = -1$: $\int_1^H \frac{1}{x}\,\mathrm{d}x = \ln H$, che tende a infinito. L'area sotto $\frac{1}{x}$ è infinita, mentre quella sotto $\frac{1}{x^2}$ è finita.
Con la regola della catena: $\frac{\mathrm{d}}{\mathrm{d}x}\ln(1+x^2) = \frac{2x}{1+x^2}$.

Teorema 11.7 — La variabile di Cauchy non ha media

Se $X \sim \mathcal{C}(a,b)$, l'integrale $\int_{-\infty}^{\infty} x\,f_X(x)\,\mathrm{d}x$ non esiste: le sue due metà valgono $+\infty$ e $-\infty$.

Dimostrazione — con $a = 0$ e $b = 1$

Passo 1 — La metà destra. Con la primitiva del richiamo:

$$\int_0^H x\,\frac{1}{\pi}\,\frac{1}{1+x^2}\,\mathrm{d}x = \frac{1}{\pi}\left[\frac{1}{2}\ln(1+x^2)\right]_0^H = \frac{1}{2\pi}\ln(1+H^2) \longrightarrow +\infty \qquad (H \to \infty).$$

Passo 2 — La metà sinistra. Per simmetria vale $-\infty$.

Passo 3 — Conclusione. Le due metà non sono finite, e «$+\infty - \infty$» non è un numero. Il motivo è che per x grande $x\,f_X(x) \simeq \frac{1}{\pi x}$, che ha area infinita come $\frac{1}{x}$. Per a e b qualsiasi, il cambio di variabile $u = \frac{x-a}{b}$ riporta a questo caso. ■

Si può però definire un **punto di simmetria**, con un **integrale a valor principale**: invece di mandare a infinito i due estremi in modo indipendente, li si allarga *insieme*, simmetricamente.

Teorema 11.8 — Il valor principale

Se $X \sim \mathcal{C}(a, b)$:

$$\frac{1}{b\pi}\lim_{H\to\infty}\int_{-H}^{H}\frac{x}{1+\left(\frac{x-a}{b}\right)^2}\,\mathrm{d}x = a.$$

Dimostrazione

Passo 1 — Il cambio di variabile. Con $u = \frac{x-a}{b}$, cioè $x = ub + a$ e $\mathrm{d}x = b\,\mathrm{d}u$; gli estremi $\mp H$ diventano $\frac{\mp H - a}{b}$:

$$\frac{1}{b\pi}\lim_{H\to\infty}\int_{\frac{-H-a}{b}}^{\frac{H-a}{b}}\frac{ub+a}{1+u^2}\,b\,\mathrm{d}u = \frac{b}{\pi}\lim_{H\to\infty}\int_{\frac{-H-a}{b}}^{\frac{H-a}{b}}\frac{u}{1+u^2}\,\mathrm{d}u + \frac{a}{\pi}\lim_{H\to\infty}\int_{\frac{-H-a}{b}}^{\frac{H-a}{b}}\frac{1}{1+u^2}\,\mathrm{d}u.$$

Passo 2 — Il primo limite è zero. Con la primitiva $\frac{1}{2}\ln(1+u^2)$ e la proprietà dei logaritmi:

$$\int_{\frac{-H-a}{b}}^{\frac{H-a}{b}}\frac{u}{1+u^2}\,\mathrm{d}u = \frac{1}{2}\ln\frac{1+\left(\frac{H-a}{b}\right)^2}{1+\left(\frac{H+a}{b}\right)^2} \longrightarrow \frac{1}{2}\ln 1 = 0,$$

perché per H grandissimo numeratore e denominatore della frazione sono quasi uguali (entrambi circa $\frac{H^2}{b^2}$), e il loro rapporto tende a 1.

Passo 3 — Il secondo limite. Gli estremi tendono a $-\infty$ e $+\infty$, e l'integrale diventa $\int_{-\infty}^{\infty}\frac{1}{1+u^2}\,\mathrm{d}u = \left[\arctan u\right]_{-\infty}^{\infty} = \pi$. Quindi il totale è $0 + \frac{a}{\pi}\cdot\pi = a$. ■

Che cosa vuol dire, in pratica, «non ha media»

Per una variabile con media, la media campionaria di tante osservazioni si stabilizza attorno alla media statistica (Capitolo 5). Per la Cauchy questo non succede: ogni tanto esce un valore così enorme da spostare da solo la media di migliaia di osservazioni. La figura confronta la media campionaria di osservazioni di Laplace e di Cauchy, entrambe simmetriche attorno a 0.

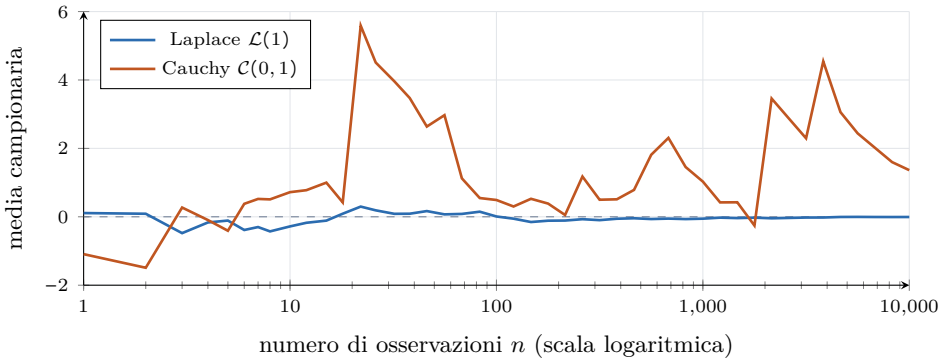


Figura 11.5: *Media campionaria di osservazioni simulate. Quella di Laplace converge a 0; quella di Cauchy continua a fare salti improvvisi anche dopo migliaia di osservazioni, ognuno causato da un singolo valore enorme.*

Variabile	**Densità**	**CDF**	**Supporto**	**Media**
uniforme $\mathcal{U}(a,b)$	$\frac{1}{b-a}$ su (a,b)	$\frac{x-a}{b-a}$ su $[a,b]$	$[a,b]$	$\frac{a+b}{2}$
esponenziale $\mathcal{E}(\lambda)$	$\lambda e^{-\lambda x}u(x)$	$(1-e^{-\lambda x})u(x)$	$[0,\infty)$	$\frac{1}{\lambda}$
Laplace $\mathcal{L}(\lambda)$	$\frac{\lambda}{2}e^{-\lambda\lvert x\rvert}$	$\frac{1}{2}e^{\lambda x}$ $(x\le 0)$, $1-\frac{1}{2}e^{-\lambda x}$ $(x\ge 0)$	$\mathbb{R}$	0
Cauchy $\mathcal{C}(a,b)$	$\frac{1}{b\pi}\frac{1}{1+((x-a)/b)^2}$	$\frac{1}{2}+\frac{1}{\pi}\arctan\frac{x-a}{b}$	$\mathbb{R}$	non esiste

Tabella 11.1: *Le variabili continue notevoli di questo capitolo (le varianze sono nel Capitolo 13).*

In sintesi

- **Uniforme** $\mathcal{U}(a,b)$: densità costante $\frac{1}{b-a}$, CDF lineare, media $\frac{a+b}{2}$.
- **Esponenziale** $\mathcal{E}(\lambda)$: $\lambda e^{-\lambda x}u(x)$, CDF $1-e^{-\lambda x}$, media $\frac{1}{\lambda}$ (per parti); non ha memoria: è il modello dei tempi di attesa.
- **Laplace** $\mathcal{L}(\lambda)$: $\frac{\lambda}{2}e^{-\lambda|x|}$, due esponenziali simmetrici; media 0 perché $xf_X(x)$ è dispari e le due metà sono finite.
- **Cauchy** $\mathcal{C}(a,b)$: CDF $\frac{1}{2}+\frac{1}{\pi}\arctan\frac{x-a}{b}$ (cambio di variabile e arcotangente). Non ha media: $xf_X(x)\sim\frac{1}{\pi x}$ e $\int\frac{1}{x}=\ln$ diverge; il valor principale vale a.
- Strumenti: $(e^{ax})'=ae^{ax}$, integrazione per parti, regola della catena e cambio di variabile, $(\arctan y)'=\frac{1}{1+y^2}$, $(\ln x)'=\frac{1}{x}$, integrali di funzioni dispari.

PDF CONDIZIONATE E FUNZIONI DI VARIABILI CONTINUE

Questo capitolo porta nel continuo due strumenti che conosciamo già dal discreto (Capitolo 6). Il primo è il **condizionamento**: come cambia la densità di X quando si sa che si è verificato un evento. Il secondo sono le **funzioni di variabili aleatorie**: se X ha una certa densità, che densità ha $Y = g(X)$? La risposta è una formula che nel discreto non c'era, perché trasformare una variabile continua non sposta soltanto la probabilità, ma la *stira* e la *comprime*. Vedremo anche due applicazioni importantissime: come un computer genera numeri casuali con qualsiasi densità, e come un convertitore analogico-digitale trasforma una variabile continua in una discreta.

PDF E CDF CONDIZIONATE A UN EVENTO

In modo del tutto analogo a quanto fatto per le variabili discrete, se A è un evento con $P(A) > 0$ possiamo considerare la probabilità che X cada in un intervallino attorno a x *sapendo* che si è verificato A:

$$P\left(X \in \left[x - \tfrac{\Delta x}{2}, x + \tfrac{\Delta x}{2}\right] \,\middle|\, A\right) = P_X(x, \Delta x \mid A).$$

PDF e CDF condizionate

La **densità di X condizionata all'evento A** è

$$f_{X|A}(x) = \lim_{\Delta x \to 0} \frac{P_X(x, \Delta x \mid A)}{\Delta x}.$$

La **CDF condizionata** è

$$F_{X|A}(x) = P(X \le x \mid A) = \frac{P(\{X \le x\} \cap A)}{P(A)}, \qquad \text{e} \qquad f_{X|A}(x) = \frac{\mathrm{d}}{\mathrm{d}x} F_{X|A}(x).$$

Siccome la probabilità condizionata è a sua volta una probabilità (Teorema 4.6), $f_{X|A}$ è una densità a tutti gli effetti: non negativa e con area 1. Il caso più frequente è quello in cui A dice che X è caduta in un certo intervallo.

Esempio 12.1 — Una Laplace ristretta a un intervallo

Sia $X \sim \mathcal{L}(\lambda)$ e sia $A = \{-1 \le X \le 2\}$. Allora

$$F_{X|A}(x) = P(X \le x \mid A) = \frac{P(\{X \le x\} \cap \{-1 \le X \le 2\})}{P(-1 \le X \le 2)},$$

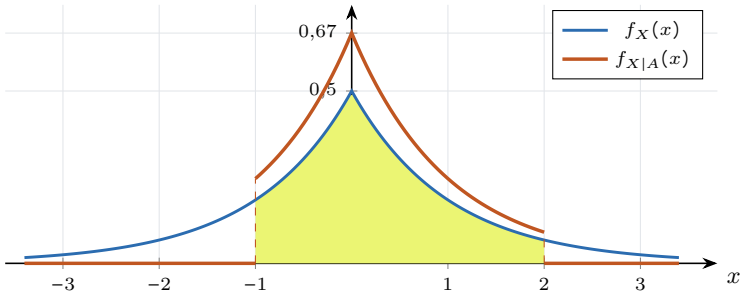
e il denominatore è $P(A) = F_X(2) - F_X(-1)$. Per il numeratore si guarda dove si trova x:

- se $x < -1$, i due eventi sono incompatibili (non si può essere sotto -1 e fra -1 e 2): l'intersezione è vuota;
- se $-1 \le x < 2$, l'intersezione è $\{-1 \le X \le x\}$, con probabilità $F_X(x) - F_X(-1)$;
- se $x \ge 2$, l'intersezione è tutto A.

Quindi

$$F_{X|A}(x) = \begin{cases} 0 & x < -1 \\ \dfrac{F_X(x) - F_X(-1)}{F_X(2) - F_X(-1)} & -1 \le x < 2 \\ \dfrac{F_X(2) - F_X(-1)}{F_X(2) - F_X(-1)} = 1 & x \ge 2 \end{cases} \qquad f_{X|A}(x) = \begin{cases} \dfrac{f_X(x)}{F_X(2) - F_X(-1)} & -1 \le x < 2 \\ 0 & \text{altrove} \end{cases}$$

La densità condizionata si ottiene derivando: il denominatore è una costante. Con $\lambda = 1$: $F_X(2) = 1 - \frac{1}{2}e^{-2} \approx 0{,}932$, $F_X(-1) = \frac{1}{2}e^{-1} \approx 0{,}184$, e $P(A) \approx 0{,}748$.



L'area gialla vale $P(A) \approx 0{,}748$. La densità condizionata (in arancione) è la stessa curva, tagliata fuori dall'intervallo e «rialzata» dividendola per 0,748: così la sua area torna a essere 1. È esattamente quello che succedeva con le pmf nel Capitolo 6.

La probabilità totale per le densità

Teorema 12.1 — Probabilità totale per le PDF e per le medie

Se $\{E_m\}_{m=1}^{M}$ è una partizione di Ω con $P(E_m) > 0$, allora

$$F_X(x) = \sum_{m=1}^{M} F_{X|E_m}(x)\, P(E_m), \qquad f_X(x) = \sum_{m=1}^{M} f_{X|E_m}(x)\, P(E_m),$$

$$E[X] = \sum_{m=1}^{M} E[X \mid E_m]\, P(E_m) = \sum_{m=1}^{M} P(E_m) \int_{-\infty}^{\infty} x\, f_{X|E_m}(x)\, \mathrm{d}x.$$

Dimostrazione

Passo 1 — La CDF. Come nel Capitolo 3, si ritaglia l'evento con la partizione:

$$F_X(x) = P(\{X \le x\} \cap \Omega) = P\left(\{X \le x\} \cap \bigcup_{m=1}^{M} E_m\right) = P\left(\bigcup_{m=1}^{M} (\{X \le x\} \cap E_m)\right),$$

e i pezzi sono incompatibili, quindi le probabilità si sommano:

$$F_X(x) = \sum_{m=1}^{M} P(\{X \le x\} \cap E_m) = \sum_{m=1}^{M} F_{X|E_m}(x)\, P(E_m).$$

Passo 2 — La densità. Si deriva rispetto a x: la derivata di una somma è la somma delle derivate, e i $P(E_m)$ sono costanti.

Passo 3 — La media. Si moltiplica la densità per x e si integra: per la linearità dell'integrale

$$E[X] = \int x \sum_m f_{X|E_m}(x)\, P(E_m)\, \mathrm{d}x = \sum_m P(E_m) \int x\, f_{X|E_m}(x)\, \mathrm{d}x = \sum_m P(E_m)\, E[X \mid E_m].$$

■

Esempio 12.2 — La Laplace spezzata in due

Con riferimento all'esempio precedente ($\lambda = 1$), gli eventi A e $\overline{A}$ formano una partizione:

$$E[X] = E[X \mid A]\, P(A) + E[X \mid \overline{A}]\, P(\overline{A}).$$

Ogni pezzo ha un significato semplice: $E[X \mid A]\, P(A) = \frac{1}{P(A)} \int_{-1}^{2} x\, f_X(x)\, \mathrm{d}x \cdot P(A) = \int_{-1}^{2} x\, f_X(x)\, \mathrm{d}x$, cioè l'integrale di $x f_X(x)$ ristretto ai valori per cui A è vero; e lo stesso per $\overline{A}$, con i valori per cui A è falso. Sommando i due pezzi si integra su tutta la retta, e si ritrova $E[X] = \int x\, f_X(x)\, \mathrm{d}x = 0$.

Con i numeri: usando $\int_0^c x\, e^{-x}\, \mathrm{d}x = 1 - (1 + c)\, e^{-c}$ (per parti),

$$\int_{-1}^{2} x\, \tfrac{1}{2} e^{-|x|}\, \mathrm{d}x = \tfrac{1}{2}\left[\int_0^2 x\, e^{-x}\, \mathrm{d}x - \int_0^1 x\, e^{-x}\, \mathrm{d}x\right] = \tfrac{1}{2}\left[(1 - 3e^{-2}) - (1 - 2e^{-1})\right] \approx 0{,}165,$$

quindi $E[X \mid A] \approx \frac{0{,}165}{0{,}748} \approx 0{,}22$: sapendo che X è fra -1 e 2, la media si sposta verso destra, perché l'intervallo è più lungo da quella parte. Il pezzo di $\overline{A}$ vale $-0{,}165$, e il totale è zero.

Esempio 12.3 — Due tipi di componenti

Un magazzino contiene componenti di due fornitori, in parti uguali. Quelli del primo durano un tempo esponenziale di media 1 anno ($\lambda = 1$), quelli del secondo di media 3 anni ($\lambda = \frac{1}{3}$). Si prende un componente a caso: la sua durata ha densità

$$f_X(x) = \tfrac{1}{2} \cdot 1 \cdot e^{-x} u(x) + \tfrac{1}{2} \cdot \tfrac{1}{3} e^{-x/3} u(x),$$

una «miscela» di due esponenziali, e media $E[X] = \frac{1}{2} \cdot 1 + \frac{1}{2} \cdot 3 = 2$ anni, senza calcolare nessun integrale.

Funzioni di variabili aleatorie continue

Il problema è simile a quello già affrontato per le variabili discrete. Si assuma che $X = X(\omega)$ sia una variabile aleatoria continua con alfabeto $\mathcal{X}$, densità $f_X(x)$ e CDF $F_X(x)$, e sia g una funzione definita sui punti di $\mathcal{X}$ (tranne, al più, un insieme di probabilità nulla). Si forma la nuova variabile aleatoria

$$Y = g(X) = g[X(\omega)] \in \mathcal{Y}, \qquad \mathcal{Y} = g(\mathcal{X}).$$

Vogliamo ricavare la caratterizzazione di Y da quella di X: la densità (o la CDF) e, nel prossimo capitolo, la media. A differenza del caso discreto, qui si distinguono tre casi:

a) g è **biunivoca**, cioè invertibile, continua e derivabile;

b) g non è invertibile, ma è continua e derivabile, e $\mathcal{Y}$ è continuo;

c) g non è invertibile e $\mathcal{Y}$ è **discreto**: è una **conversione A/D** della variabile continua (una quantizzazione, cioè una compressione con perdite), come quella che si fa sui segnali analogici.

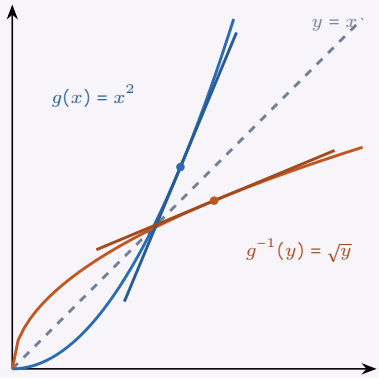
Richiamo di matematica: funzioni monotone e derivata della funzione inversa

Una funzione è **strettamente crescente** se a x più grandi corrispondono valori più grandi, **strettamente decrescente** se corrispondono valori più piccoli; in entrambi i casi si dice **strettamente monotona**. Una funzione continua su un intervallo è invertibile esattamente quando è strettamente monotona: se tornasse indietro, qualche valore verrebbe raggiunto due volte. L'inversa $x = g^{-1}(y)$ risponde alla domanda «quale x dà y?», e il suo grafico è quello di g riflesso rispetto alla bisettrice $y = x$.

Derivata dell'inversa. Per definizione $g\big(g^{-1}(y)\big) = y$. Derivando entrambi i membri rispetto a y con la regola della catena: $\dot{g}\big(g^{-1}(y)\big) \cdot \frac{\mathrm{d}}{\mathrm{d}y} g^{-1}(y) = 1$, cioè

$$\dot{x}(y) = \frac{\mathrm{d}}{\mathrm{d}y}\, g^{-1}(y) = \frac{1}{\dot{g}\big(g^{-1}(y)\big)} :$$

la derivata della funzione inversa in un punto è l'inverso della derivata della funzione originaria, valutata nel punto corrispondente. (Il puntino, $\dot{g}$, è un altro modo di indicare la derivata, usato nelle slide.) Nel disegno: le due tangenti sono una il riflesso dell'altra, e scambiare x con y trasforma la pendenza m in $\frac{1}{m}$.



In $x = 1{,}2$ la parabola ha pendenza $2x = 2{,}4$. Nel punto corrispondente $y = 1{,}44$ la radice ha pendenza $\frac{1}{2\sqrt{y}} = \frac{1}{2{,}4}$. Le pendenze sono una l'inversa dell'altra.

Primo caso: g è invertibile

Se g è invertibile è strettamente monotona su $\mathcal{X}$.

Teorema 12.2 — Densità di una funzione monotona

Se g è strettamente monotona e derivabile, la densità di $Y = g(X)$ è

$$f_Y(y) = \frac{f_X\big(g^{-1}(y)\big)}{\big|\dot{g}\big(g^{-1}(y)\big)\big|} = \frac{f_X\big(x(y)\big)}{\big|\dot{g}\big(x(y)\big)\big|},$$

dove $x(y) = g^{-1}(y)$ è la soluzione dell'equazione $y = g(x)$, che naturalmente dipende da y.

Dimostrazione

Passo 1 — g crescente ($\dot g > 0$): la CDF. Se g è crescente, $g(X) \le y$ succede esattamente quando $X \le g^{-1}(y)$:

$$F_Y(y) = P(Y \le y) = P(g(X) \le y) = P\big(X \le g^{-1}(y)\big) = F_X\big(g^{-1}(y)\big) = F_X\big(x(y)\big).$$

Passo 2 — g crescente: la densità. Si deriva con la regola della catena e la derivata dell'inversa:

$$f_Y(y) = \frac{\mathrm{d}}{\mathrm{d}y} F_Y(y) = f_X\big(g^{-1}(y)\big)\,\frac{\mathrm{d}}{\mathrm{d}y} g^{-1}(y) = \frac{f_X\big(g^{-1}(y)\big)}{\dot g\big(g^{-1}(y)\big)}.$$

Passo 3 — g decrescente ($\dot g < 0$): la CDF. Ora la disuguaglianza si rovescia, perché una funzione decrescente scambia l'ordine: $g(X) \le y$ succede esattamente quando $X \ge g^{-1}(y)$:

$$F_Y(y) = P(g(X) \le y) = P\big(X \ge g^{-1}(y)\big) = 1 - F_X\big(g^{-1}(y)\big).$$

Passo 4 — g decrescente: la densità.

$$f_Y(y) = -f_X\big(g^{-1}(y)\big)\,\frac{\mathrm{d}}{\mathrm{d}y} g^{-1}(y) = -\frac{f_X\big(g^{-1}(y)\big)}{\dot g\big(g^{-1}(y)\big)}.$$

Passo 5 — Una formula sola. Nel secondo caso $\dot g < 0$, quindi $-\dot g = |\dot g|$; nel primo $\dot g = |\dot g|$. In entrambi i casi il denominatore è $|\dot g|$.

■

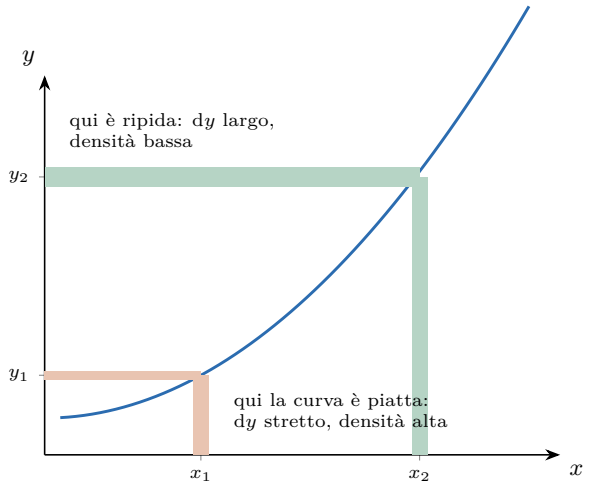


Figura 12.1: *Perché si divide per $|\dot g|$. La probabilità contenuta in una striscia larga $\mathrm{d}x$ attorno a x, cioè $f_X(x)\,\mathrm{d}x$, finisce in una striscia larga $\mathrm{d}y = |\dot g(x)|\,\mathrm{d}x$ attorno a $y = g(x)$. La probabilità si conserva, $f_Y(y)\,\mathrm{d}y = f_X(x)\,\mathrm{d}x$, quindi $f_Y = f_X/|\dot g|$: dove g è ripida la probabilità si «spalma» su un intervallo più largo e la densità si abbassa.*

Esempio 12.4 — Una trasformazione lineare

Sia $Y = aX + b$ con $a \neq 0$. Allora $g(x) = ax + b$, $x(y) = \frac{y-b}{a}$ e $\dot g = a$:

$$f_Y(y) = \frac{1}{|a|}\, f_X\left(\frac{y-b}{a}\right).$$

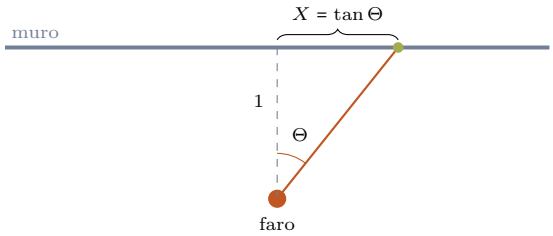
Il grafico di f_Y è quello di f_X spostato di b, allargato di un fattore $|a|$ in orizzontale e abbassato dello stesso fattore, così che l'area resti 1. Per esempio, se $X \sim \mathcal{C}(0,1)$, allora $bX + a \sim \mathcal{C}(a,b)$: i parametri della Cauchy sono proprio una traslazione e un cambio di scala. Useremo questa formula nel Capitolo 15 per costruire tutte le gaussiane a partire da una sola.

Esempio 12.5 — Il faro e la variabile di Cauchy

Un faro ruota e si ferma puntando in una direzione a caso, con un angolo $\Theta \sim \mathcal{U}\left(-\frac{\pi}{2}, \frac{\pi}{2}\right)$ rispetto alla perpendicolare a un muro lungo e diritto che si trova a distanza 1. Il punto illuminato sul muro è $X = \tan\Theta$. La funzione $g(\theta) = \tan\theta$ è crescente su $\left(-\frac{\pi}{2}, \frac{\pi}{2}\right)$, con inversa $\theta(x) = \arctan x$ e derivata $\dot{g} = 1 + \tan^2\theta = 1 + x^2$ (Capitolo 11). La densità di Θ è $\frac{1}{\pi}$ sull'intervallo, quindi

$$f_X(x) = \frac{f_\Theta(\arctan x)}{1 + x^2} = \frac{1}{\pi}\,\frac{1}{1 + x^2}\,:$$

il punto illuminato è una variabile di Cauchy $\mathcal{C}(0, 1)$. Quando il faro punta quasi parallelo al muro, il punto illuminato schizza lontanissimo: sono i valori enormi che impediscono alla Cauchy di avere una media.



Secondo caso: g non è invertibile

Se g non è invertibile, per un valore y l'equazione $g(x) = y$ può avere più soluzioni:

$$\forall y \in \mathcal{Y} \quad \exists\, \{x_i(y)\}_{i=1}^{M(y)} : \quad g[x_i(y)] = y.$$

Per fissare le idee supponiamo $M(y) = 4$, come nella figura, con $\dot{g}(x_1) < 0$. Allora $g(x) \le y$ per $x_1(y) \le x \le x_2(y)$; ovviamente sarà $\dot{g}(x_2) > 0$ e $g(x) \ge y$ per $x_2(y) \le x \le x_3(y)$. La funzione ripassa per il valore $g(x_3) = y$ (con derivata negativa) e si mantiene al di sotto di y fino a $x_4(y)$.

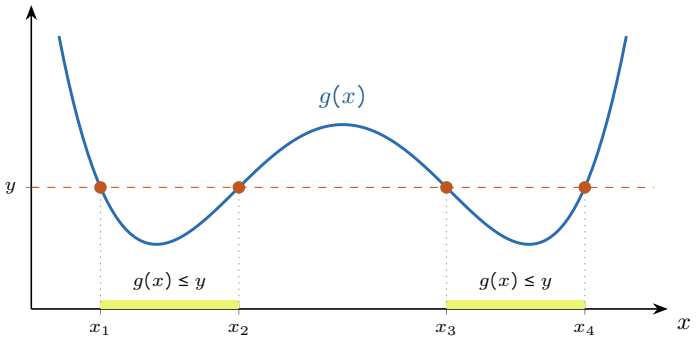


Figura 12.2: *Una funzione non invertibile: il livello y viene raggiunto in quattro punti. L'evento $\{Y \le y\}$ è l'unione dei due intervalli gialli dell'asse x.*

Quindi

$$F_Y(y) = P(Y \le y) = P\big(\{x_1(y) \le X \le x_2(y)\} \cup \{x_3(y) \le X \le x_4(y)\}\big),$$

e sfruttando il fatto che gli intervalli sono disgiunti

$$F_Y(y) = F_X\big(x_2(y)\big) - F_X\big(x_1(y)\big) + F_X\big(x_4(y)\big) - F_X\big(x_3(y)\big).$$

Teorema 12.3 — Densità di una funzione non invertibile

Se $y = g(x)$ ha le soluzioni $x_1(y), \ldots, x_M(y)$, tutte con $\dot{g} \neq 0$:

$$f_Y(y) = \sum_{i=1}^{M(y)} \frac{f_X\big(x_i(y)\big)}{\big|\dot{g}\big(x_i(y)\big)\big|}.$$

Dimostrazione — nel caso della figura

Passo 1 — Si deriva la CDF. Ogni soluzione $x_i(y)$ è, vicino a y, l'inversa del tratto monotono di g che passa per x_i; per la derivata dell'inversa $\dot{x}_i(y) = \frac{1}{\dot{g}(x_i(y))}$. Derivando la CDF termine per termine con la regola della catena:

$$f_Y(y) = \frac{f_X(x_2)}{\dot{g}(x_2)} - \frac{f_X(x_1)}{\dot{g}(x_1)} + \frac{f_X(x_4)}{\dot{g}(x_4)} - \frac{f_X(x_3)}{\dot{g}(x_3)}.$$

Passo 2 — I segni. Nel secondo e nel quarto termine la derivata a denominatore è negativa (g scende in x_1 e in x_3), quindi $-\frac{1}{\dot{g}} = \frac{1}{|\dot{g}|}$; nel primo e nel terzo è positiva. Tutti i termini diventano $\frac{f_X(x_i)}{|\dot{g}(x_i)|}$.

■

Da ricordare: densità di una funzione di variabile aleatoria

$$f_Y(y) = \sum_{i\,:\,g(x_i)=y} \frac{f_X(x_i)}{|\dot{g}(x_i)|} \qquad \text{(si somma su tutte le soluzioni di } y = g(x))$$

È lo stesso principio del discreto, dove le probabilità dei punti con la stessa immagine si sommavano; in più, ogni contributo è diviso per la «velocità» $|\dot{g}|$ con cui g attraversa il livello y.

Esempio 12.6 — Il quadrato di due variabili diverse

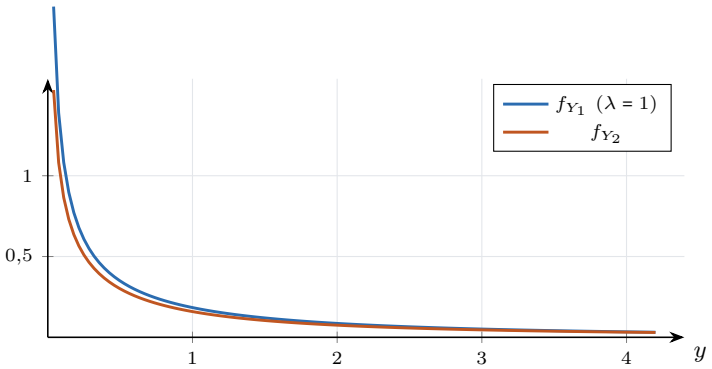
Sia $g(x) = x^2$, e si considerino $X_1 \sim \mathcal{E}(\lambda)$ e $X_2 \sim \mathcal{C}(0,1)$.

Esponenziale. Nel caso $Y_1 = X_1^2$, la variabile X_1 è non negativa ($\mathcal{X}_1 = [0,\infty[$), e su $x \geq 0$ la trasformazione $g(x) = x^2$ è biunivoca: l'equazione $x^2 = y$ ammette solo la soluzione $x(y) = \sqrt{y}$. Quindi

$$\dot{x}(y) = \frac{1}{\dot{g}(x)}\bigg|_{x=\sqrt{y}} = \frac{1}{2x}\bigg|_{x=\sqrt{y}} = \frac{1}{2\sqrt{y}}, \qquad f_{Y_1}(y) = \lambda e^{-\lambda x}u(x)\Big|_{x=\sqrt{y}}\dot{x}(y) = \frac{\lambda e^{-\lambda\sqrt{y}}}{2\sqrt{y}}\,u(y).$$

Cauchy. Nel caso $Y_2 = X_2^2$ invece $\mathcal{X}_2 = \mathbb{R}$, la trasformazione non è biunivoca e per $y > 0$ l'equazione $x^2 = y$ ha due soluzioni, $x_{1,2}(y) = \pm\sqrt{y}$, in cui $|\dot{g}| = 2\sqrt{y}$. Con $f_{X_2}(x) = \frac{1}{\pi}\frac{1}{1+x^2}$, che vale lo stesso in $\pm\sqrt{y}$:

$$f_{Y_2}(y) = \left[\frac{f_{X_2}(\sqrt{y})}{2\sqrt{y}} + \frac{f_{X_2}(-\sqrt{y})}{2\sqrt{y}}\right]u(y) = \frac{1}{\pi}\,\frac{1}{2\sqrt{y}}\,\frac{1}{1+y}\cdot 2\,u(y) = \frac{1}{\pi\sqrt{y}\,(1+y)}\,u(y).$$



Una densità può valere infinito

Entrambe le densità dell'esempio tendono a infinito per $y \to 0$, a causa del fattore $\frac{1}{\sqrt{y}}$: vicino a $x = 0$ la parabola x^2 è piattissima ($\dot{g} = 2x \to 0$), e schiaccia tanta probabilità in un intervallino di y. Non c'è nessuna contraddizione: l'area resta finita, perché $\int_0^1 \frac{1}{\sqrt{y}}\,dy = \left[2\sqrt{y}\right]_0^1 = 2$. Ancora una volta: conta l'area, non l'altezza.

Esempio 12.7 — Ogni variabile, passata nella propria CDF, diventa uniforme

Sia $X \sim f_X(x)$, e consideriamo $Y = F_X(X)$, cioè $g(x) = F_X(x)$. Qualunque sia la densità, $Y \in [0,1]$, perché la CDF assume valori fra 0 e 1. Inoltre g è crescente; potrebbe non essere strettamente crescente (avere tratti in cui è costante, dove $f_X = 0$), ma escludiamo questo caso. Allora

$$g(x) = F_X(x) \implies x(y) = F_X^{-1}(y), \qquad \dot{g}(x) = f_X(x),$$

e con la formula del primo caso

$$f_Y(y) = \frac{f_X\big(F_X^{-1}(y)\big)}{f_X\big(F_X^{-1}(y)\big)} = 1, \quad y \in [0,1], \qquad \text{cioè} \quad f_Y(y) = \operatorname{rect}\left(y - \tfrac{1}{2}\right):$$

Y è una variabile aleatoria uniforme in $(0,1)$, $Y \sim \mathcal{U}(0,1)$. Il motivo intuitivo: $F_X(X)$ è «la frazione di probabilità che sta a sinistra del valore osservato», e questa frazione può essere un numero qualsiasi fra 0 e 1 con uguale probabilità.

Il risultato si può usare al contrario, ed è così che si simula al computer una variabile con qualsiasi densità.

Teorema 12.4 — Il metodo dell'inversione

Se $U \sim \mathcal{U}(0,1)$ e F_X è una CDF strettamente crescente, la variabile $Z = F_X^{-1}(U)$ ha CDF F_X.

Dimostrazione

Passo 1. Per ogni z:

$$F_Z(z) = P(Z \le z) = P\big(F_X^{-1}(U) \le z\big) \underset{(a)}{=} P\big(U \le F_X(z)\big) = F_U\big(F_X(z)\big) \underset{(b)}{=} F_X(z).$$

Passo 2 — (a). F_X è per ipotesi strettamente crescente, e quindi lo è anche la sua inversa: applicando F_X ai due membri di $F_X^{-1}(U) \le z$ la disuguaglianza non cambia verso.

Passo 3 — (b). La CDF di una variabile uniforme in $(0,1)$ è la funzione identica nell'intervallo $(0,1)$: $U \sim \mathcal{U}(0,1) \iff f_U(u) = \operatorname{rect}\left(u - \frac{1}{2}\right) \iff F_U(u) = u$ per $0 \le u \le 1$. Quindi $F_U(F_X(z)) = F_X(z)$.

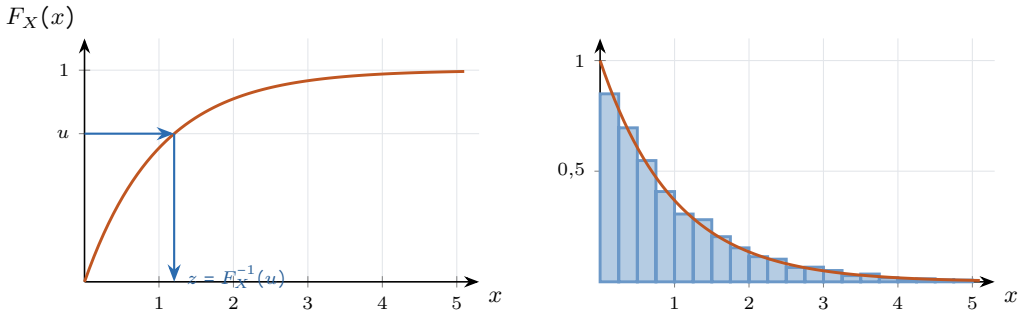
■

I generatori di numeri casuali dei computer producono numeri uniformi in $(0,1)$; con il metodo dell'inversione si trasformano in numeri con la densità voluta. Questo ha notevoli conseguenze nelle procedure di simulazione dei sistemi numerici (tutte le simulazioni di questa dispensa sono state fatte così).

Esempio 12.8 — Generare tempi di attesa esponenziali

Per $X \sim \mathcal{E}(\lambda)$, $F_X(x) = 1 - e^{-\lambda x}$. Risolvendo $u = 1 - e^{-\lambda x}$ rispetto a x: $e^{-\lambda x} = 1 - u$, cioè $x = -\frac{1}{\lambda}\ln(1-u)$. Quindi

$$Z = -\frac{1}{\lambda}\ln(1-U) \sim \mathcal{E}(\lambda).$$



A sinistra: si estrae u uniforme sull'asse verticale, si va orizzontalmente fino alla CDF e si scende: il punto d'arrivo è z. A destra: l'istogramma di 5000 numeri ottenuti così (con $\lambda = 1$) segue la densità esponenziale. Dove la CDF è ripida (vicino a 0) molti valori di u finiscono in un intervallo stretto di x: lì la densità è alta.

Esempio 12.9 — La sinusoide con fase a caso

Siano $X \sim \mathcal{U}\left(-\frac{1}{2}, \frac{1}{2}\right)$ e $g(x) = A\cos(2\pi x + \varphi)$, con $A > 0$. Cerchiamo la densità di $Y = A\cos(2\pi X + \varphi)$: il valore di una sinusoide osservata in un istante a caso.

Si noti che $\mathcal{Y} = [-A, A]$ (il coseno sta fra -1 e 1) e che la trasformazione non è biunivoca. Poiché $\mathcal{X} = \left[-\frac{1}{2}, \frac{1}{2}\right]$, l'argomento del coseno varia in un intervallo di ampiezza 2π, un periodo intero, e in questo intervallo l'equazione $y = A\cos(2\pi x + \varphi)$ ha due soluzioni x_1, x_2 (una mentre il coseno scende e una mentre sale). Quindi

$$f_Y(y) = \frac{f_X(x_1(y))}{|\dot{g}(x_1(y))|} + \frac{f_X(x_2(y))}{|\dot{g}(x_2(y))|} \underset{(a)}{=} \frac{1}{|\dot{g}(x_1(y))|} + \frac{1}{|\dot{g}(x_2(y))|},$$

dove (a) vale perché $f_X = 1$ sull'intervallo. La derivata del coseno è meno il seno (con la regola della catena il fattore 2π esce dall'argomento):

$$\dot{g}(x) = -A\sin(2\pi x + \varphi)\cdot 2\pi, \qquad |\dot{g}(x)| = 2\pi A|\sin(2\pi x + \varphi)|.$$

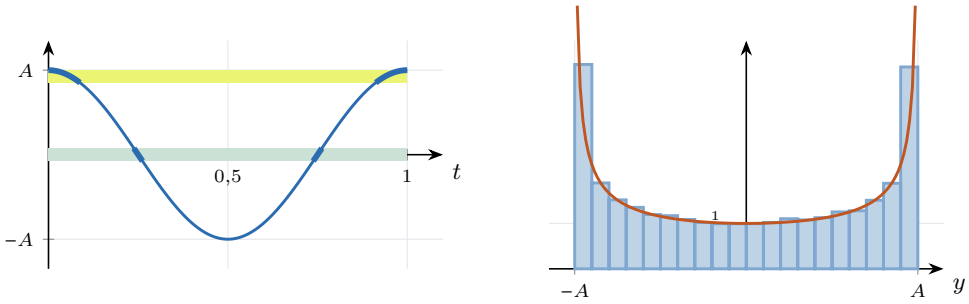
Va scritta in funzione di y: per Pitagora $\sin^2\alpha + \cos^2\alpha = 1$ (seno e coseno sono i cateti di un triangolo rettangolo con ipotenusa 1), quindi $|\sin\alpha| = \sqrt{1-\cos^2\alpha}$, e $\cos(2\pi x + \varphi) = \frac{y}{A}$ nei punti $x_i(y)$:

$$|\dot{g}(x_i(y))| = 2\pi A\sqrt{1-\cos^2(2\pi x_i + \varphi)} = 2\pi A\sqrt{1-\left(\frac{y}{A}\right)^2}.$$

I due termini sono uguali, e

$$f_Y(y) = \frac{2}{2\pi A\sqrt{1-\left(\frac{y}{A}\right)^2}} = \frac{1}{\pi A\sqrt{1-\left(\frac{y}{A}\right)^2}} = \frac{1}{\pi\sqrt{A^2-y^2}}, \qquad y \in (-A, A).$$

È la **distribuzione dell'arcoseno**, a forma di «U»: la sinusoide passa più tempo vicino ai massimi e ai minimi, dove rallenta per invertire il moto, che vicino allo zero, dove corre.



A sinistra: in un periodo, la sinusoide resta nella fascia gialla vicino al massimo (le parti spesse a sinistra e a destra) molto più a lungo che nella fascia verde, alta uguale, attorno allo zero (le due parti spesse in mezzo). A destra: l'istogramma di 20 000 valori simulati con $A = 1$ e la densità dell'arcoseno.

Terzo caso: la conversione A/D

Quando X è continua e Y è discreta si ha una **conversione analogico-digitale** (A/D) della variabile aleatoria. Supponiamo di voler rappresentare X (con perdite) con R bit, cioè con $M = 2^R$ livelli.

- Si scelgono gli M valori di rappresentazione $\mathcal{Y} = \{y_1, y_2, \ldots, y_M\}$, i valori che Y può assumere.
- Si divide l'alfabeto $\mathcal{X}$ in M intervalli, definiti dalle $M+1$ soglie $\{x_i\}_{i=1}^{M+1}$.

Rappresentazione a R bit

Si definisce **rappresentazione a R bit** di X la variabile aleatoria discreta

$$Y = y_i \qquad \text{se} \quad x_i \le X < x_{i+1}, \qquad i = 1, 2, \ldots, M.$$

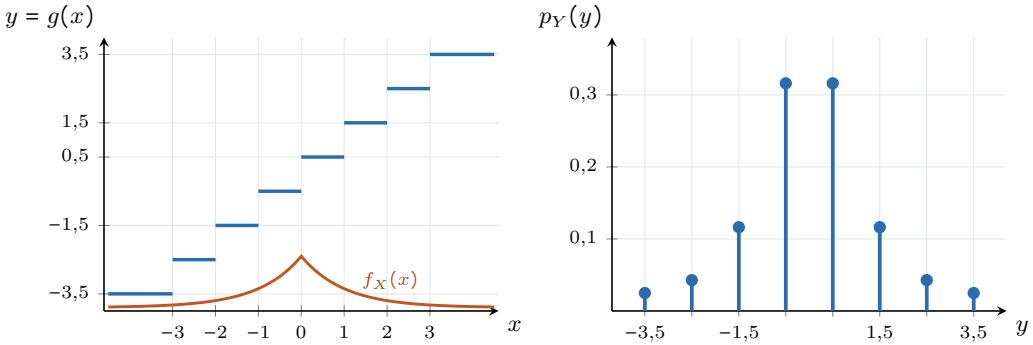
La pmf di Y si scrive facilmente: Y vale y_i quando X cade nell'i-esimo intervallo, quindi

$$p_Y(y_i) = P(x_i \le X < x_{i+1}) = F_X(x_{i+1}) - F_X(x_i), \qquad i = 1, 2, \ldots, M.$$

Ovviamente tanto la partizione quanto i livelli di rappresentazione sono gradi di libertà a disposizione del progettista: scegliendoli bene si riduce l'errore commesso rappresentando X con Y.

Esempio 12.10 — Un convertitore a 3 bit

I campioni di un segnale vocale si modellano bene con una variabile di Laplace (valori piccoli frequentissimi, valori grandi rari). Sia $X \sim \mathcal{L}(1)$, quantizzata con $R = 3$ bit, cioè $M = 8$ livelli: soglie $-\infty, -3, -2, -1, 0, 1, 2, 3, +\infty$ e livelli $-3{,}5$; $-2{,}5$; …; $3{,}5$ (il centro di ogni intervallo, e per i due intervalli estremi il punto a distanza $\frac{1}{2}$ dall'ultima soglia).



A sinistra la caratteristica «a scalini» del convertitore (in basso, per riferimento, la densità di X); a destra la pmf di Y. Per esempio

$$p_Y(0{,}5) = F_X(1) - F_X(0) = \left(1 - \tfrac{1}{2}e^{-1}\right) - \tfrac{1}{2} \approx 0{,}316, \qquad p_Y(3{,}5) = F_X(+\infty) - F_X(3) = \tfrac{1}{2}e^{-3} \approx 0{,}025.$$

Più del 63% delle volte il convertitore usa uno dei due livelli centrali, e solo il 5% delle volte uno dei due estremi. Nella parte del corso sull'informazione vedremo che questa disuguaglianza si può sfruttare per comprimere i dati.

In sintesi

- **Condizionamento**: $F_{X|A}(x) = P(\{X \le x\} \cap A)/P(A)$ e $f_{X|A} = F'_{X|A}$; se A è un intervallo, la densità viene tagliata e rialzata dividendo per $P(A)$.
- **Probabilità totale**: $f_X = \sum_m f_{X|E_m} P(E_m)$ e $E[X] = \sum_m E[X \mid E_m] P(E_m)$.
- Se $Y = g(X)$: $f_Y(y) = \sum_i \frac{f_X(x_i)}{|\dot{g}(x_i)|}$, sommando sulle soluzioni di $g(x) = y$. La probabilità si conserva, $f_Y \mathrm{d}y = f_X \mathrm{d}x$: dove g è ripida la densità si abbassa. Lineare: $f_{aX+b}(y) = f_X\left(\frac{y-b}{a}\right)/|a|$.
- $F_X(X) \sim \mathcal{U}(0,1)$, e viceversa $F_X^{-1}(U)$ ha CDF F_X: è il metodo dell'inversione per simulare qualsiasi densità.
- $A\cos(2\pi X + \varphi)$ con X uniforme su un periodo ha la densità dell'arcoseno $\frac{1}{\pi\sqrt{A^2 - y^2}}$.
- **Conversione A/D** a R bit: $M = 2^R$ livelli, $p_Y(y_i) = F_X(x_{i+1}) - F_X(x_i)$.

Media di funzioni e varianza nel continuo

Nel Capitolo 7 avevamo misurato la dispersione delle variabili discrete con il valore quadratico medio e la varianza, e per calcolarli ci era servito il teorema fondamentale per la media di una funzione, $E[g(X)] = \sum_x g(x)\, p_X(x)$. In questo capitolo portiamo tutto nel continuo: prima il teorema fondamentale, con le somme che diventano integrali; poi il valore quadratico medio e la varianza delle variabili continue notevoli. Alla fine raccogliamo in un «dizionario» le corrispondenze fra il mondo discreto e quello continuo.

La media di una funzione di variabile continua

Sia $X \sim f_X(x)$ e sia $Y = g(X)$, con $\mathcal{Y} = g(\mathcal{X})$. Per calcolare $E[Y]$ si potrebbe ricavare la densità f_Y con i metodi del capitolo precedente e poi integrare $y\, f_Y(y)$. Ma, come nel discreto, non serve.

Teorema 13.1 — Teorema fondamentale per il calcolo della media

Qualunque sia la funzione g (purché l'integrale converga):

$$E[Y] = E[g(X)] = \int_{\mathbb{R}} g(x)\, f_X(x)\, \mathrm{d}x.$$

Dimostrazione — con la quantizzazione

Passo 1 — Si quantizza X. Come per giustificare la media (Capitolo 10), si definisce una versione quantizzata di X:

$$X^{\Delta} = x_i \in [i\Delta, (i+1)\Delta[\qquad \text{se} \quad i\Delta \le X < (i+1)\Delta.$$

Passo 2 — Si applica g. La variabile $Y^{\Delta} = g(X^{\Delta})$ è discreta: vale $g(x_i)$ quando X cade nell'i-esimo intervallo. Per il teorema fondamentale del caso discreto (Teorema 6.4):

$$E[Y^{\Delta}] = \sum_i g(x_i)\, P(X^{\Delta} = x_i) = \sum_i g(x_i)\, P(x_i \le X < x_{i+1}).$$

Passo 3 — Si stringono gli intervalli. Per Δ piccolo $P(x_i \le X < x_{i+1}) \simeq f_X(x_i)\,\Delta$, e Y^{Δ} si avvicina a Y. Se $g(x) f_X(x)$ è integrabile secondo Riemann, la somma diventa un integrale:

$$E[Y] = \lim_{\Delta \to 0} E[Y^{\Delta}] = \lim_{\Delta \to 0} \sum_i g(x_i) \underbrace{f_X(x_i)\,\Delta}_{\simeq P(x_i \le X < x_{i+1})} = \int_{\mathbb{R}} g(x)\, f_X(x)\, \mathrm{d}x.$$

■

Esempio 13.1 — Due strade per la stessa media

Sia $X \sim \mathcal{U}(0,1)$ e $Y = X^2$.

- **Con il teorema fondamentale**: $E[Y] = \int_0^1 x^2 \cdot 1 \, dx = \left[\frac{x^3}{3}\right]_0^1 = \frac{1}{3}$.
- **Passando per la densità di** Y: su $(0,1)$ la funzione x^2 è crescente, con $x(y) = \sqrt{y}$ e $\dot{g}(x(y)) = 2\sqrt{y}$; quindi $f_Y(y) = \frac{1}{2\sqrt{y}}$ per $0 < y < 1$, e

$$E[Y] = \int_0^1 y \, \frac{1}{2\sqrt{y}} \, dy = \int_0^1 \frac{\sqrt{y}}{2} \, dy = \frac{1}{2}\left[\frac{y^{3/2}}{3/2}\right]_0^1 = \frac{1}{2} \cdot \frac{2}{3} = \frac{1}{3}.$$

Stesso risultato, ma la prima strada è molto più breve. (Si è usata la regola delle potenze anche con l'esponente non intero $\frac{1}{2}$: la formula $(x^n)' = n\,x^{n-1}$ vale per qualsiasi esponente reale.)

Dal teorema e dalla linearità dell'integrale seguono subito le proprietà della media già viste nel discreto:

$$E[aX + b] = \int (ax + b)\, f_X(x) \, dx = a \int x \, f_X(x) \, dx + b \int f_X(x) \, dx = a\, E[X] + b,$$

e più in generale $E[g_1(X) + g_2(X)] = E[g_1(X)] + E[g_2(X)]$.

Valore quadratico medio e varianza

A questo punto la generalizzazione dei concetti introdotti per le variabili discrete è immediata. Data una variabile aleatoria $X \sim f_X(x)$, con media $\mu_X = E[X]$, si definiscono:

- il **valore quadratico medio** (*mean square*): $X^2_{rms} = E[X^2] = \int_{\mathbb{R}} x^2 \, f_X(x) \, dx$;
- il **valore efficace** (*root mean square*): $X_{rms} = \sqrt{E[X^2]} = \sqrt{\int_{\mathbb{R}} x^2 \, f_X(x) \, dx}$;
- la **varianza**: $\sigma_X^2 = E\left[(X - \mu_X)^2\right] = \int_{\mathbb{R}} (x - \mu_X)^2 \, f_X(x) \, dx$;
- la **deviazione standard**: $\sigma_X = \sqrt{\sigma_X^2}$.

Teorema 13.2 — Varianza e valore quadratico medio

$$\sigma_X^2 = E[X^2] - \mu_X^2 = X^2_{rms} - \mu_X^2, \qquad \sigma_X = \sqrt{E[X^2] - \mu_X^2}.$$

Dimostrazione

Passo 1. Si sviluppa il quadrato e si usa la linearità della media (le costanti μ_X e μ_X^2 escono):

$$\sigma_X^2 = E\left[X^2 + \mu_X^2 - 2\mu_X X\right] = E[X^2] + \mu_X^2 - 2\mu_X\, E[X] = E[X^2] + \mu_X^2 - 2\mu_X^2 = E[X^2] - \mu_X^2.$$

■

Tutte le proprietà della media e della varianza viste per le variabili aleatorie discrete valgono, ovviamente, anche per quelle continue: le dimostrazioni sono le stesse, con gli integrali al posto delle somme. In particolare $\sigma^2_{aX+b} = a^2\sigma_X^2$, e valgono le disuguaglianze di Markov e di Chebyshev. Per esempio, per una variabile $Z \geq 0$ con densità f_Z la dimostrazione di Markov diventa

$$P(Z \geq \delta) = \int_\delta^\infty f_Z(z) \, dz \leq \int_\delta^\infty \frac{z}{\delta} \, f_Z(z) \, dz \leq \int_0^\infty \frac{z}{\delta} \, f_Z(z) \, dz = \frac{E[Z]}{\delta},$$

con gli stessi tre passaggi del Capitolo 7: si moltiplica per $\frac{z}{\delta} \geq 1$, si estende l'integrale aggiungendo una parte non negativa, si riconosce la media.

LE VARIANZE DELLE VARIABILI NOTEVOLI

La variabile uniforme

Teorema 13.3 — Varianza dell'uniforme

Se $X \sim \mathcal{U}(a, b)$:

$$E[X] = \frac{a+b}{2}, \qquad E[X^2] = \frac{a^2+ab+b^2}{3}, \qquad \sigma_X^2 = \frac{(b-a)^2}{12}, \qquad \sigma_X = \frac{b-a}{\sqrt{12}}.$$

Dimostrazione

Passo 1 — La media. È già stata calcolata nel Capitolo 11.

Passo 2 — Il valore quadratico medio. Con la primitiva $\frac{x^3}{3}$:

$$E[X^2] = \frac{1}{b-a}\int_a^b x^2\,\mathrm{d}x = \frac{1}{b-a}\left[\frac{x^3}{3}\right]_a^b = \frac{b^3-a^3}{3(b-a)} = \frac{(b-a)(b^2+ab+a^2)}{3(b-a)} = \frac{b^2+ab+a^2}{3},$$

dove si è usato il prodotto notevole $b^3 - a^3 = (b-a)(b^2+ab+a^2)$ (basta moltiplicare a destra per verificarlo: $b^3 + ab^2 + a^2b - ab^2 - a^2b - a^3 = b^3 - a^3$).

Passo 3 — La varianza. Al denominatore comune 12:

$$\sigma_X^2 = \frac{b^2+ab+a^2}{3} - \frac{(b+a)^2}{4} = \frac{4b^2+4ab+4a^2-3b^2-3a^2-6ab}{12} = \frac{b^2-2ab+a^2}{12} = \frac{(b-a)^2}{12}.$$

■

La varianza dipende solo dalla **larghezza** dell'intervallo, non dalla sua posizione: spostare l'intervallo sposta la media ma non la dispersione. Si confronti con l'uniforme discreta su M valori (Capitolo 7), che ha varianza $\frac{M^2-1}{12}$: per M grande è circa $\frac{M^2}{12}$, cioè (larghezza)$^2/12$, lo stesso risultato.

Esempio 13.2 — L'errore di quantizzazione

In un convertitore A/D con passo Δ (Capitolo 12), l'errore che si commette sostituendo X con il centro del suo intervallo sta fra $-\frac{\Delta}{2}$ e $\frac{\Delta}{2}$; se gli intervalli sono stretti rispetto alle variazioni della densità, l'errore è circa uniforme su quell'intervallo. La sua potenza (il valore quadratico medio, che coincide con la varianza perché la media è 0) è allora

$$\sigma^2 = \frac{\Delta^2}{12}.$$

È la celebre formula del **rumore di quantizzazione**: ogni bit in più dimezza Δ e divide la potenza dell'errore per 4.

La variabile esponenziale

Teorema 13.4 — Varianza dell'esponenziale

Se $X \sim \mathcal{E}(\lambda)$:

$$E[X] = \frac{1}{\lambda}, \qquad E[X^2] = \frac{2}{\lambda^2}, \qquad \sigma_X^2 = \frac{1}{\lambda^2}, \qquad \sigma_X = \frac{1}{\lambda}.$$

Dimostrazione

Passo 1 — Il valore quadratico medio, per parti. Il gradino riduce l'integrale a $[0, \infty)$. Con $f(x) = x^2$ (derivata $2x$) e $g'(x) = \lambda e^{-\lambda x}$ (primitiva $-e^{-\lambda x}$):

$$E[X^2] = \int_0^\infty x^2 \lambda e^{-\lambda x}\, \mathrm{d}x = \Big[x^2 \left(-e^{-\lambda x}\right)\Big]_0^\infty - \int_0^\infty 2x \left(-e^{-\lambda x}\right) \mathrm{d}x.$$

Passo 2 — Il bordo è nullo. In 0 vale 0, e $x^2 e^{-\lambda x} \to 0$ per $x \to \infty$ (l'esponenziale batte la potenza).

Passo 3 — Si riconosce la media. Moltiplicando e dividendo per λ:

$$E[X^2] = 2 \int_0^\infty x\, e^{-\lambda x}\, \mathrm{d}x = \frac{2}{\lambda} \underbrace{\int_0^\infty x\, \lambda e^{-\lambda x}\, \mathrm{d}x}_{E[X] = \frac{1}{\lambda}} = \frac{2}{\lambda^2}.$$

Passo 4 — La varianza. $\sigma_X^2 = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}$.

■

Per l'esponenziale la deviazione standard è uguale alla media: un tempo di attesa medio di 10 minuti fluttua, tipicamente, di altri 10 minuti. È una variabile molto «aleatoria», con rapporto $\mu_X / \sigma_X = 1$.

La variabile di Laplace

Teorema 13.5 — Varianza della variabile di Laplace

Se $X \sim \mathcal{L}(\lambda)$:

$$E[X] = 0, \qquad E[X^2] = \sigma_X^2 = \frac{2}{\lambda^2}, \qquad \sigma_X = \frac{\sqrt{2}}{\lambda}.$$

Dimostrazione

Passo 1 — La parità. $x^2 \frac{\lambda}{2} e^{-\lambda |x|}$ è pari: l'area a sinistra dello zero è uguale a quella a destra, e l'integrale su $\mathbb{R}$ è il doppio di quello su $[0, \infty)$:

$$E[X^2] = \int_{-\infty}^\infty x^2 \frac{\lambda}{2} e^{-\lambda |x|}\, \mathrm{d}x = 2 \cdot \frac{\lambda}{2} \int_0^\infty x^2 e^{-\lambda x}\, \mathrm{d}x = \int_0^\infty x^2\, \lambda e^{-\lambda x}\, \mathrm{d}x = \frac{2}{\lambda^2}.$$

L'ultimo integrale è il valore quadratico medio dell'esponenziale unilatera, calcolato sopra.

Passo 2 — La varianza. La media è nulla, quindi $\sigma_X^2 = E[X^2] - 0 = \frac{2}{\lambda^2}$.

■

La variabile di Cauchy

Per la variabile di Cauchy $\mathcal{C}(a, b)$ non esistono né la media né la varianza, e quindi nemmeno il valore efficace e la deviazione standard. Per la media lo abbiamo visto nel Capitolo 11. Il valore quadratico medio è infinito: con $a = 0$ e $b = 1$, l'integrando $\frac{x^2}{\pi(1+x^2)}$ tende a $\frac{1}{\pi}$ per $x \to \pm\infty$, e una funzione che non scende sotto un valore positivo ha area infinita su una semiretta (come il rettangolo infinito del Capitolo 10). Senza media, poi, la varianza non si può nemmeno definire.

Che cosa ci dice la deviazione standard, nel continuo

La disuguaglianza di Chebyshev garantisce che la probabilità di allontanarsi dalla media di almeno k deviazioni standard sia al più $\frac{1}{k^2}$, per qualsiasi densità. La tabella confronta il limite con i valori veri per tre variabili notevoli (per la gaussiana, la colonna verrà spiegata nel Capitolo 15).

k	uniforme	esponenziale	Laplace	gaussiana	Chebyshev $\frac{1}{k^2}$
1	0,423	0,135	0,243	0,317	1
1,5	0,134	0,082	0,120	0,134	0,444
2	0	0,050	0,059	0,046	0,25
3	0	0,018	0,014	0,003	0,111

Per esempio, per l'esponenziale con $\lambda = 1$ ($\mu = \sigma = 1$) e $k = 2$: $P(|X - 1| \geq 2) = P(X \geq 3) = e^{-3} \approx 0{,}050$. L'uniforme non esce mai oltre $1{,}73\,\sigma$ dal centro (la semilarghezza dell'intervallo è $\frac{b-a}{2} = \sqrt{3}\,\sigma$).

Il dizionario fra discreto e continuo

Ora che abbiamo visto entrambi i mondi, conviene metterli uno accanto all'altro: quasi tutte le formule si traducono con poche regole.

Concetto	**Variabile discreta**	**Variabile continua**
descrizione completa	pmf $p_X(x) = P(X = x)$	densità $f_X(x)$, con $P(X = x) = 0$
probabilità di un insieme	$\sum_{x \in A} p_X(x)$	$\int_A f_X(x)\,\mathrm{d}x$
normalizzazione	$\sum_x p_X(x) = 1$	$\int_{\mathbb{R}} f_X(x)\,\mathrm{d}x = 1$
CDF $F_X(x) = P(X \leq x)$	a scala, salti alti $p_X(x)$	continua, $F_X' = f_X$
media	$\sum_x x\,p_X(x)$	$\int x\,f_X(x)\,\mathrm{d}x$
media di $g(X)$	$\sum_x g(x)\,p_X(x)$	$\int g(x)\,f_X(x)\,\mathrm{d}x$
funzione $Y = g(X)$	$p_Y(y) = \sum_{g(x)=y} p_X(x)$	$f_Y(y) = \sum_{g(x_i)=y} \frac{f_X(x_i)}{\lvert \dot{g}(x_i) \rvert}$
condizionamento a A	$p_{X\mid A}(x) = \frac{P(\{X=x\} \cap A)}{P(A)}$	$F_{X\mid A}(x) = \frac{P(\{X \leq x\} \cap A)}{P(A)}$
varianza	$E[X^2] - \mu_X^2$	$E[X^2] - \mu_X^2$

Tabella 13.1: *Le regole di traduzione: le somme diventano integrali, $p_X(x)$ diventa $f_X(x)\,\mathrm{d}x$; l'unica formula davvero nuova è quella delle funzioni di variabile aleatoria, con la divisione per $|\dot{g}|$.*

Variabile	**Densità**	**Media**	**Valore quadratico medio**	**Varianza**
uniforme $\mathcal{U}(a,b)$	$\frac{1}{b-a}$ su (a,b)	$\frac{a+b}{2}$	$\frac{a^2+ab+b^2}{3}$	$\frac{(b-a)^2}{12}$
esponenziale $\mathcal{E}(\lambda)$	$\lambda e^{-\lambda x} u(x)$	$\frac{1}{\lambda}$	$\frac{2}{\lambda^2}$	$\frac{1}{\lambda^2}$
Laplace $\mathcal{L}(\lambda)$	$\frac{\lambda}{2} e^{-\lambda \lvert x \rvert}$	0	$\frac{2}{\lambda^2}$	$\frac{2}{\lambda^2}$
Cauchy $\mathcal{C}(a,b)$	$\frac{1}{b\pi} \frac{1}{1+((x-a)/b)^2}$	non esiste	$+\infty$	non esiste

Tabella 13.2: *Medie e varianze delle variabili continue notevoli.*

In sintesi

- **Teorema fondamentale**: $E[g(X)] = \int g(x)\, f_X(x)\, \mathrm{d}x$, senza bisogno della densità di $g(X)$; si dimostra quantizzando X e usando il caso discreto.
- Valore quadratico medio $\int x^2 f_X$, valore efficace, varianza $\int (x-\mu_X)^2 f_X = E[X^2] - \mu_X^2$, deviazione standard: le definizioni e le proprietà sono quelle del discreto, con gli integrali.
- Uniforme: $\sigma^2 = \frac{(b-a)^2}{12}$ (errore di quantizzazione $\frac{\Delta^2}{12}$). Esponenziale: $\sigma^2 = \frac{1}{\lambda^2}$, $\sigma = \mu$. Laplace: $\sigma^2 = \frac{2}{\lambda^2}$. Cauchy: né media né varianza.
- Markov e Chebyshev valgono anche nel continuo; per le densità notevoli le probabilità vere sono molto più piccole del limite $\frac{1}{k^2}$.

Variabili aleatorie continue multiple

Nel Capitolo 8 abbiamo descritto coppie di variabili discrete con una tabella, la pmf congiunta. Qui facciamo lo stesso con le variabili continue: la tabella diventa una **superficie**, la densità congiunta, e le probabilità diventano **volumi** sotto la superficie. Per calcolarli ci serve l'integrale doppio, che spieghiamo da zero. Tutto il resto (marginali, indipendenza, densità condizionate, media condizionata, covarianza) si traduce dal discreto con le regole del dizionario del capitolo precedente.

Coppie e m-ple di variabili continue

In perfetta analogia con quanto fatto per le variabili discrete, una coppia di variabili continue è definita nella forma

$$(X, Y) : \omega \in \Omega \longmapsto (X(\omega), Y(\omega)) \in \mathcal{X} \times \mathcal{Y} \subseteq \mathbb{R}^2,$$

dove $\mathcal{X}$ e $\mathcal{Y}$ sono gli alfabeti di X e di Y. Analogamente, date tre variabili aleatorie (a questo punto non importa più se tutte continue o meno) $X(\omega) \in \mathcal{X}$, $Y(\omega) \in \mathcal{Y}$, $Z(\omega) \in \mathcal{Z}$, si ha la terna

$$(X, Y, Z) : \omega \in \Omega \longmapsto (X(\omega), Y(\omega), Z(\omega)) \in \mathcal{X} \times \mathcal{Y} \times \mathcal{Z} \subseteq \mathbb{R}^3,$$

e, date m variabili aleatorie $X_i \in \mathcal{X}_i \subseteq \mathbb{R}$, la m-pla aleatoria

$$(X_1, X_2, \ldots, X_m) : \omega \in \Omega \longmapsto (X_1(\omega), \ldots, X_m(\omega)) \in \mathcal{X}_1 \times \mathcal{X}_2 \times \cdots \times \mathcal{X}_m \subseteq \mathbb{R}^m.$$

Perché servono? Si pensi ad altezza e peso di una persona scelta a caso in una popolazione. Le funzioni $F_X(x)$ e $F_Y(y)$ caratterizzano il comportamento statistico delle singole variabili, ma non quello **congiunto**: ci aspettiamo che una persona molto alta sia anche abbastanza pesante, e questa influenza reciproca non può essere descritta da due funzioni che riguardano ciascuna una sola delle due grandezze. Serve una caratterizzazione congiunta.

La densità congiunta

Densità congiunta

La **densità di probabilità congiunta** della coppia di variabili continue (X, Y) è

$$f_{X,Y}(x, y) = \lim_{\Delta x \to 0} \lim_{\Delta y \to 0} \frac{P\left(\left\{x - \frac{\Delta x}{2} \leq X \leq x + \frac{\Delta x}{2}\right\} \cap \left\{y - \frac{\Delta y}{2} \leq Y \leq y + \frac{\Delta y}{2}\right\}\right)}{\Delta x \, \Delta y} = \lim_{\Delta x \to 0} \lim_{\Delta y \to 0} \frac{P_{X,Y}(x, y; \Delta x, \Delta y)}{\Delta x \, \Delta y},$$

per $(x, y) \in \mathcal{X} \times \mathcal{Y}$.

È la probabilità che il punto (X, Y) cada in un rettangolino attorno a (x, y), divisa per l'**area** del rettangolino: una probabilità per unità di superficie. Se nel caso di una variabile la probabilità era uno strato di sabbia lungo una retta, ora è uno strato di sabbia steso su un tavolo, più alto in certi punti e più basso in altri. La densità congiunta è l'altezza dello strato, e la probabilità che il punto cada in una regione C del tavolo è il **volume** di sabbia sopra quella regione:

$$P((X, Y) \in C) = \iint_C f_{X,Y}(x, y) \, \mathrm{d}x \, \mathrm{d}y.$$

Richiamo di matematica: l'integrale doppio

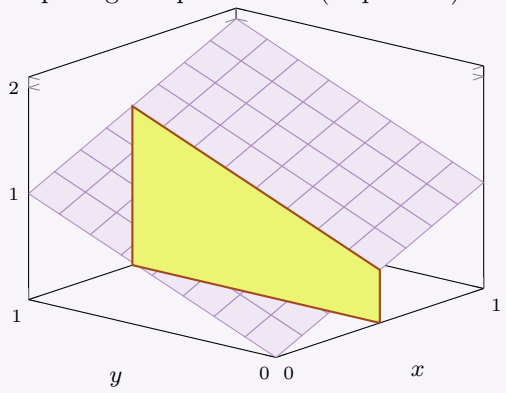
Sia $f(x,y) \geq 0$ una funzione di due variabili: il suo grafico è una superficie sopra il piano (x,y). Il **volume** compreso fra la superficie e una regione C del piano si calcola come l'area nel caso di una variabile: si divide il piano in tanti quadratini di lati Δx e Δy, sopra ogni quadratino si costruisce una colonna alta quanto la funzione, $f(x_i, y_j)$, e si sommano i volumi delle colonne. Quando i quadratini diventano infinitamente piccoli, la somma diventa l'**integrale doppio**:

$$\iint_C f(x,y)\,\mathrm{d}x\,\mathrm{d}y = \lim_{\Delta x, \Delta y \to 0} \sum_{(x_i,y_j)\in C} f(x_i,y_j)\,\Delta x\,\Delta y.$$

Come si calcola: a fette. Sopra un rettangolo $[a,b]\times[c,d]$ si può prima tagliare il volume a fette sottili perpendicolari all'asse x: per x fissato, la fetta ha area $\int_c^d f(x,y)\,\mathrm{d}y$ (un integrale semplice, in cui x è una costante). Poi si sommano le fette, integrando lungo x:

$$\iint_{[a,b]\times[c,d]} f(x,y)\,\mathrm{d}x\,\mathrm{d}y = \int_a^b \left(\int_c^d f(x,y)\,\mathrm{d}y \right) \mathrm{d}x = \int_c^d \left(\int_a^b f(x,y)\,\mathrm{d}x \right) \mathrm{d}y.$$

L'ordine non conta (è il **teorema di Fubini**): si possono tagliare le fette in un verso o nell'altro, come una somma doppia si può fare per righe o per colonne (Capitolo 6).



La superficie $z = x + y$ sopra il quadrato $[0,1]^2$. La fetta gialla, a $x = \frac{1}{2}$ fissato, ha area $\int_0^1 \left(\frac{1}{2} + y\right) \mathrm{d}y = 1$. In generale la fetta in x ha area $\int_0^1 (x+y)\,\mathrm{d}y = x + \frac{1}{2}$, e sommando le fette

$$\int_0^1 \left(x + \tfrac{1}{2}\right) \mathrm{d}x = \tfrac{1}{2} + \tfrac{1}{2} = 1.$$

Due casi utili. Se la funzione è un prodotto, $f(x,y) = g(x)\,h(y)$, sopra un rettangolo l'integrale doppio è il prodotto di due integrali semplici: $\iint g(x)h(y)\,\mathrm{d}x\,\mathrm{d}y = \int g(x)\,\mathrm{d}x \cdot \int h(y)\,\mathrm{d}y$ (nella fetta, $g(x)$ è una costante che esce dall'integrale in y). Se invece la regione non è un rettangolo, gli estremi dell'integrale interno dipendono dalla variabile esterna: per il triangolo $x \geq 0$, $y \geq 0$, $x + y \leq 1$, la fetta in x va da $y = 0$ a $y = 1 - x$, e $\iint_{\text{triangolo}} f\,\mathrm{d}x\,\mathrm{d}y = \int_0^1 \left(\int_0^{1-x} f(x,y)\,\mathrm{d}y \right) \mathrm{d}x$.

Teorema 14.1 — Proprietà della densità congiunta

Le densità congiunte devono soddisfare vincoli simili a quelli delle densità di una sola variabile:

a) $f_{X,Y}(x,y) \geq 0$ per ogni (x,y);

b) $f_{X,Y}$ è sommabile su $\mathbb{R}^2$ con integrale unitario: $\displaystyle\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f_{X,Y}(x,y)\,\mathrm{d}x\,\mathrm{d}y = P\left((X,Y)\in\mathbb{R}^2\right) = 1.$

Dimostrazione

Passo 1. La densità è il limite di rapporti fra una probabilità e un'area, quindi non è negativa; il volume totale è la probabilità dell'evento certo «il punto cade da qualche parte nel piano».

■

Esempio 14.1 — Due tempi di attesa indipendenti

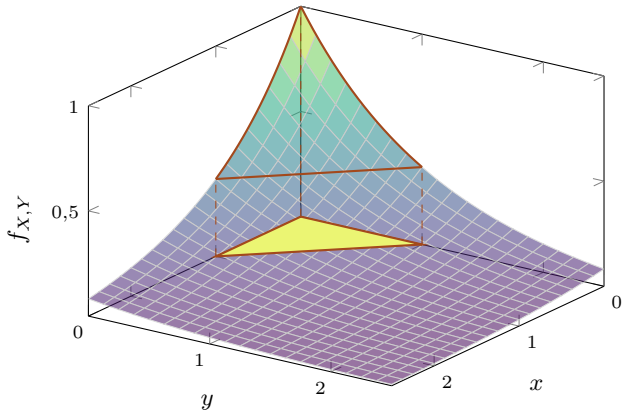
Due componenti si guastano dopo tempi X e Y indipendenti, entrambi esponenziali di parametro 1. Come vedremo fra poco, per variabili indipendenti la densità congiunta è il prodotto delle densità:

$$f_{X,Y}(x,y) = e^{-x}\, e^{-y} = e^{-(x+y)} \qquad x, y \geq 0.$$

Qual è la probabilità che il tempo totale $X + Y$ non superi 1? È il volume sopra il triangolo $x, y \geq 0$, $x + y \leq 1$:

$$P(X+Y \leq 1) = \int_0^1 \left(\int_0^{1-x} e^{-x} e^{-y}\, \mathrm{d}y \right) \mathrm{d}x = \int_0^1 e^{-x} \left(1 - e^{-(1-x)}\right) \mathrm{d}x = \int_0^1 \left(e^{-x} - e^{-1}\right) \mathrm{d}x = \left(1 - e^{-1}\right) - e^{-1} = 1 - \frac{2}{e} \approx 0{,}264.$$

Nella fetta in x il fattore e^{-x} è costante ed esce dall'integrale; poi $e^{-x} e^{-(1-x)} = e^{-1}$.



La probabilità è il volume del «solido» che sta sopra il triangolo giallo e sotto la superficie $e^{-(x+y)}$.

Marginali, indipendenza e densità condizionate

La densità congiunta $f_{X,Y}$ condivide con la pmf congiunta $p_{X,Y}$ le stesse proprietà fondamentali.

Teorema 14.2 — Marginalizzazione e indipendenza

a) **Marginalizzazione**:

$$f_X(x) = \int_{\mathbb{R}} f_{X,Y}(x,y)\, \mathrm{d}y, \qquad f_Y(y) = \int_{\mathbb{R}} f_{X,Y}(x,y)\, \mathrm{d}x,$$

per cui caratterizzare congiuntamente (X, Y) significa anche caratterizzarle marginalmente, mentre il viceversa non è necessariamente vero.

b) **Indipendenza statistica**: due variabili aleatorie sono indipendenti se e solo se

$$f_{X,Y}(x,y) = f_X(x)\, f_Y(y) \quad \Longleftrightarrow \quad F_{X,Y}(x,y) = F_X(x)\, F_Y(y).$$

c) Più in generale, $X_1, \ldots, X_m$ con densità f_{X_i} sono indipendenti se e solo se

$$f_{X_1,\ldots,X_m}(x_1, \ldots, x_m) = \prod_{i=1}^{m} f_{X_i}(x_i) \qquad \forall (x_1, \ldots, x_m) \in \mathbb{R}^m.$$

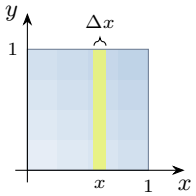
Dimostrazione — della marginalizzazione

Passo 1 — Una striscia. L'evento $\left\{x - \frac{\Delta x}{2} \le X \le x + \frac{\Delta x}{2}\right\}$ non pone condizioni su Y: nel piano è una **striscia verticale** larga Δx, illimitata in alto e in basso.

Passo 2 — Il volume della striscia. La sua probabilità è il volume sopra la striscia. Per Δx piccolo, ogni fetta della striscia ha circa la stessa sezione, quella in x, cioè $\int_{\mathbb{R}} f_{X,Y}(x,y)\,dy$; quindi il volume è circa

$$P\left(x - \tfrac{\Delta x}{2} \le X \le x + \tfrac{\Delta x}{2}\right) \simeq \Delta x \int_{\mathbb{R}} f_{X,Y}(x,y)\,dy.$$

Passo 3 — La densità. Dividendo per Δx e mandandolo a zero si ottiene $f_X(x)$. Per f_Y si usa una striscia orizzontale. ■



La densità $x + y$ sul quadrato (più scura dove è più alta). La striscia gialla è l'evento «X cade vicino a x», qualunque sia Y: il suo volume diviso Δx è la densità marginale $f_X(x) = \int_0^1 (x+y)\,dy = x + \frac{1}{2}$.

Figura 14.1: *Marginalizzare vuol dire «schiacciare» la densità congiunta su un asse, sommando lungo l'altro.*

Le densità condizionate

Vorremmo la densità di X sapendo che $Y = y$. Ma l'evento $\{Y = y\}$ ha probabilità zero, e non ci si può dividere per zero. Si condiziona allora all'evento $\left\{y - \frac{\Delta y}{2} \le Y \le y + \frac{\Delta y}{2}\right\}$, che ha probabilità positiva, e solo alla fine si stringe l'intervallo:

$$P\left(x - \tfrac{\Delta x}{2} \le X \le x + \tfrac{\Delta x}{2} \;\middle|\; y - \tfrac{\Delta y}{2} \le Y \le y + \tfrac{\Delta y}{2}\right) = \frac{P_{X,Y}(x,y;\Delta x,\Delta y)}{P_Y(y;\Delta y)}.$$

Dividendo per Δx e mandando $\Delta x \to 0$ si ottiene la densità di X condizionata all'evento «Y vicino a y». Facendo poi tendere anche Δy a zero, e moltiplicando e dividendo per Δy:

$$f_{X|Y}(x \mid y) = \lim_{\Delta y\to 0}\lim_{\Delta x\to 0} \frac{P_{X,Y}(x,y;\Delta x,\Delta y)}{\Delta x\, P_Y(y;\Delta y)} = \frac{\lim\limits_{\Delta y\to 0}\lim\limits_{\Delta x\to 0} \dfrac{P_{X,Y}(x,y;\Delta x,\Delta y)}{\Delta x\,\Delta y}}{\lim\limits_{\Delta y\to 0} \dfrac{P_Y(y;\Delta y)}{\Delta y}} = \frac{f_{X,Y}(x,y)}{f_Y(y)}.$$

Densità condizionata

La **densità di X condizionata a $Y = y$** (per $f_Y(y) > 0$) è

$$f_{X|Y}(x \mid y) = \frac{f_{X,Y}(x,y)}{f_Y(y)}.$$

Come c'era da attendersi, l'espressione riproduce l'analoga definizione per la pmf condizionata, che d'altronde è essa stessa una densità (discreta). Di conseguenza tutte le proprietà delle pmf condizionate si estendono alle densità condizionate.

Teorema 14.3 — Proprietà delle densità condizionate

a) Per y fissato, al variare di x, $f_{X|Y}(x \mid y)$ è una densità: $f_{X|Y}(x \mid y) \ge 0$ e $\int_{\mathbb{R}} f_{X|Y}(x \mid y)\,dx = 1$.
b) **Probabilità totale per le densità**:

$$f_X(x) = \int_{\mathbb{R}} f_{X,Y}(x,y)\,dy = \int_{\mathbb{R}} f_{X|Y}(x \mid y)\, f_Y(y)\,dy, \qquad f_Y(y) = \int_{\mathbb{R}} f_{Y|X}(y \mid x)\, f_X(x)\,dx.$$

c) **Probabilità composta e Bayes**:

$$f_{X,Y}(x,y) = f_Y(y)\, f_{X|Y}(x \mid y) = f_X(x)\, f_{Y|X}(y \mid x), \qquad f_{X|Y}(x \mid y) = \frac{f_X(x)\, f_{Y|X}(y \mid x)}{f_Y(y)}.$$

Dimostrazione

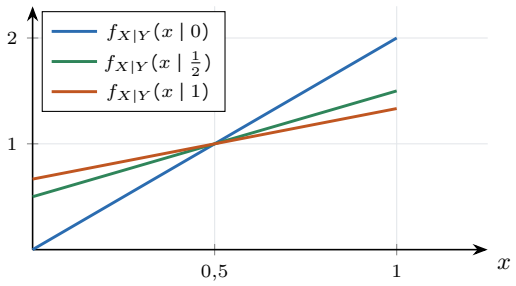
Passo 1 — a). È un rapporto di quantità non negative; integrando in x, il numeratore dà la marginale $f_Y(y)$, che si semplifica con il denominatore.

Passo 2 — b) e c). Dalla definizione, $f_{X,Y} = f_{X|Y}\, f_Y$ (e, scambiando i ruoli, $= f_{Y|X}\, f_X$); sostituendo nella marginalizzazione si ottiene b), uguagliando le due scritture e dividendo per f_Y si ottiene Bayes. ■

Esempio 14.2 — Una densità congiunta calcolata fino in fondo

Sia $f_{X,Y}(x,y) = x + y$ sul quadrato $[0,1]^2$ (e 0 fuori). È una densità: è positiva e il suo integrale vale 1 (lo abbiamo calcolato nel richiamo).

- **Marginali**: $f_X(x) = \int_0^1 (x+y)\,\mathrm{d}y = x + \frac{1}{2}$ e, per simmetria, $f_Y(y) = y + \frac{1}{2}$, per $x, y \in [0,1]$.
- **Indipendenza**: $f_X(x)\, f_Y(y) = \left(x + \frac{1}{2}\right)\left(y + \frac{1}{2}\right) \neq x + y$ (in $(0,0)$ vale $\frac{1}{4}$ contro 0): le variabili non sono indipendenti.
- **Condizionata**: $f_{X|Y}(x \mid y) = \dfrac{x+y}{y+\frac{1}{2}}$, per $x \in [0,1]$. Per esempio con $y = 0$ è $2x$ (sapendo che Y è piccola, X tende a essere grande), con $y = 1$ è $\frac{x+1}{1{,}5}$, quasi piatta.



Ogni curva è una «fetta» della densità congiunta a y fissato, divisa per la sua area $f_Y(y)$ in modo da avere area 1.

Medie, media condizionata e covarianza

Come nel caso discreto valgono le seguenti estensioni.

- Se $Z = g(X,Y)$, allora
$$E[Z] = \iint_{\mathbb{R}^2} g(x,y)\, f_{X,Y}(x,y)\,\mathrm{d}x\,\mathrm{d}y.$$
- **Linearità della media**: $E\left[\sum_{i=1}^m a_i X_i\right] = \sum_{i=1}^m a_i\, E[X_i]$.

Teorema 14.4 — Teorema della media condizionata

$$E[g(X,Y)] = E_Y\Big[E_{X|Y}[g(X,Y) \mid Y]\Big], \qquad \text{dove} \qquad E[g(X,Y) \mid Y = y] = \int_{\mathbb{R}} g(x,y)\, f_{X|Y}(x \mid y)\,\mathrm{d}x.$$

Dimostrazione

Passo 1 — Una funzione di y. $E[g(X,Y) \mid Y = y]$ è una funzione di y, chiamiamola $h(y)$. Se consideriamo la variabile aleatoria $h(Y)$ e ne calcoliamo la media statistica:

$$E[h(Y)] = \int_{\mathbb{R}} h(y)\, f_Y(y)\, \mathrm{d}y = \int_{\mathbb{R}} \left(\int_{\mathbb{R}} g(x,y)\, f_{X|Y}(x \mid y)\, \mathrm{d}x \right) f_Y(y)\, \mathrm{d}y.$$

Passo 2 — Si riconosce la congiunta. $f_Y(y)$ non dipende da x e si può portare dentro l'integrale interno, dove $f_{X|Y}(x \mid y)\, f_Y(y) = f_{X,Y}(x,y)$:

$$E[h(Y)] = \iint_{\mathbb{R}^2} g(x,y)\, f_{X,Y}(x,y)\, \mathrm{d}x\, \mathrm{d}y = E[g(X,Y)].$$

■

Esempio 14.3 — La media in due tempi

Con la densità $x + y$ sul quadrato: la media di X sapendo $Y = y$ è

$$E[X \mid Y = y] = \int_0^1 x\, \frac{x + y}{y + \frac{1}{2}}\, \mathrm{d}x = \frac{\frac{1}{3} + \frac{y}{2}}{y + \frac{1}{2}},$$

che vale $\frac{2}{3}$ per $y = 0$ e $\frac{5}{9}$ per $y = 1$: più Y è grande, più la media di X si abbassa. Mediando rispetto a Y, il denominatore si semplifica con $f_Y(y) = y + \frac{1}{2}$:

$$E[X] = \int_0^1 E[X \mid Y = y]\, f_Y(y)\, \mathrm{d}y = \int_0^1 \left(\tfrac{1}{3} + \tfrac{y}{2} \right) \mathrm{d}y = \tfrac{1}{3} + \tfrac{1}{4} = \tfrac{7}{12},$$

lo stesso valore che si ottiene direttamente: $\int_0^1 x \left(x + \frac{1}{2} \right) \mathrm{d}x = \frac{1}{3} + \frac{1}{4} = \frac{7}{12}$.

Siano $(X,Y) \sim f_{X,Y}(x,y)$, con medie (μ_X, μ_Y) e varianze σ_X^2, σ_Y^2. In analogia con il caso discreto:

- **covarianza**: $COV(X,Y) = E[(X - \mu_X)(Y - \mu_Y)] = E[XY] - \mu_X \mu_Y$;
- **coefficiente di correlazione**: $\rho_{XY} = \dfrac{COV(X,Y)}{\sigma_X\, \sigma_Y}$, con $|\rho_{XY}| \le 1$;
- **incorrelazione**: $COV(X,Y) = 0$;
- l'indipendenza statistica implica l'incorrelazione ma, in generale, non vale il viceversa.

Le dimostrazioni sono quelle del Capitolo 9, con gli integrali al posto delle somme.

Esempio 14.4 — La covarianza della densità $x + y$

Servono $E[XY]$ e le varianze. Con l'integrale doppio, a fette:

$$E[XY] = \int_0^1 \int_0^1 xy(x + y)\, \mathrm{d}y\, \mathrm{d}x = \int_0^1 \int_0^1 \left(x^2 y + x y^2 \right) \mathrm{d}y\, \mathrm{d}x = \frac{1}{3} \cdot \frac{1}{2} + \frac{1}{2} \cdot \frac{1}{3} = \frac{1}{3},$$

dove ogni termine è un prodotto di due integrali semplici. Quindi $COV(X,Y) = \frac{1}{3} - \frac{7}{12} \cdot \frac{7}{12} = \frac{48-49}{144} = -\frac{1}{144}$. Con $E[X^2] = \int_0^1 x^2 \left(x + \frac{1}{2} \right) \mathrm{d}x = \frac{1}{4} + \frac{1}{6} = \frac{5}{12}$ si ha $\sigma_X^2 = \frac{5}{12} - \frac{49}{144} = \frac{11}{144}$, e lo stesso per Y:

$$\rho_{XY} = \frac{-1/144}{11/144} = -\frac{1}{11} \approx -0{,}09.$$

Una correlazione negativa ma debole, coerente con le densità condizionate: quando Y cresce, X tende un poco a calare.

La funzione di distribuzione congiunta

Come per una sola variabile, oltre alla densità si può usare una funzione che dà direttamente delle probabilità.

CDF congiunta

Data una coppia di variabili aleatorie (X, Y), la **funzione di distribuzione di probabilità congiunta** è

$$F_{X,Y}(x, y) = P(X \le x, Y \le y), \qquad (x, y) \in \mathbb{R}^2.$$

Descrive in modo completo il comportamento statistico congiunto delle due variabili.

$F_{X,Y}(x, y)$ è la probabilità che il punto (X, Y) cada nel «quadrante» in basso a sinistra del punto (x, y).

Richiamo di matematica: le derivate parziali

Per una funzione di due variabili $F(x, y)$, la **derivata parziale** rispetto a x, $\frac{\partial F}{\partial x}$, è la derivata fatta trattando y come una costante (lo abbiamo già fatto nel Capitolo 7, derivando rispetto a p con q fisso). Il simbolo ∂ (una «d» arrotondata) ricorda che le variabili sono più di una. La derivata **mista** $\frac{\partial^2 F}{\partial x\, \partial y}$ si ottiene derivando prima rispetto a y e poi il risultato rispetto a x; per le funzioni regolari l'ordine non conta. Esempio: per $F = \frac{x^2 y + x y^2}{2}$, $\frac{\partial F}{\partial y} = \frac{x^2 + 2xy}{2}$ e poi $\frac{\partial^2 F}{\partial x\, \partial y} = \frac{2x + 2y}{2} = x + y$.

Il legame con la densità è lo stesso del caso di una variabile, con una derivata per ogni variabile:

$$F_{X,Y}(x, y) = \int_{-\infty}^{x} \int_{-\infty}^{y} f_{X,Y}(s, t)\, \mathrm{d}t\, \mathrm{d}s \qquad \Longleftrightarrow \qquad f_{X,Y}(x, y) = \frac{\partial^2}{\partial x\, \partial y} F_{X,Y}(x, y).$$

Per esempio, per la densità $x + y$ sul quadrato, nei punti del quadrato $F_{X,Y}(x, y) = \int_0^x \int_0^y (s + t)\, \mathrm{d}t\, \mathrm{d}s = \frac{x^2 y + x y^2}{2}$, e la sua derivata mista, calcolata nel richiamo, ridà proprio $x + y$.

Teorema 14.5 — Proprietà della CDF congiunta

a) $0 \le F_{X,Y}(x, y) \le 1$;
b) fissato comunque y_0, $F_{X,Y}(x, y_0)$ è monotona non decrescente in x (e continua da destra); fissato comunque x_0, $F_{X,Y}(x_0, y)$ è monotona non decrescente in y (e continua da destra);
c) $F_{X,Y}(-\infty, y) = F_{X,Y}(x, -\infty) = F_{X,Y}(-\infty, -\infty) = 0$ e $\lim_{x \to \infty, y \to \infty} F_{X,Y}(x, y) = 1$;
d) le CDF marginali si ricavano dalla congiunta: $F_X(x) = F_{X,Y}(x, +\infty)$, $F_Y(y) = F_{X,Y}(+\infty, y)$;
e) la probabilità dell'evento rettangolare $R = \{x_1 < X \le x_2,\ y_1 < Y \le y_2\}$ è

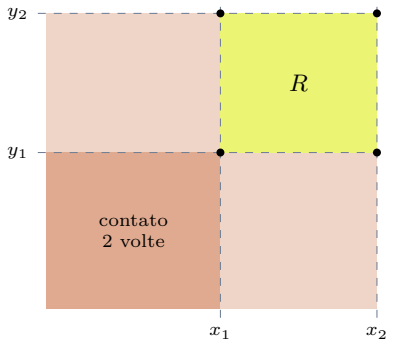
$$P(R) = F_{X,Y}(x_2, y_2) - F_{X,Y}(x_2, y_1) - F_{X,Y}(x_1, y_2) + F_{X,Y}(x_1, y_1).$$

Dimostrazione

Passo 1 — a), b), c). $F_{X,Y}$ è una probabilità; allargando il quadrante (aumentando x o y) l'evento si allarga e la probabilità non diminuisce. Con $x = -\infty$ il quadrante è vuoto ($X \le -\infty$ è impossibile); con entrambe le coordinate a $+\infty$ è tutto il piano.

Passo 2 — d). $\{X \le x, Y \le +\infty\} = \{X \le x\}$: la condizione su Y è sempre vera.

Passo 3 — e) Si toglie e si rimette. Il rettangolo si ottiene dal quadrante di (x_2, y_2) togliendo il quadrante di (x_2, y_1) (la parte sotto) e quello di (x_1, y_2) (la parte a sinistra). Così però il quadrante di (x_1, y_1), che sta in entrambi, è stato tolto due volte, e va rimesso una volta. È lo stesso ragionamento della probabilità dell'unione (Capitolo 3). ∎



Il quadrante di (x_2, y_2) contiene tutto il disegno. Togliendo il quadrante di (x_2, y_1) (la fascia in basso) e quello di (x_1, y_2) (la fascia a sinistra) resta il rettangolo giallo R, ma l'angolo in basso a sinistra, il quadrante di (x_1, y_1), è stato tolto due volte: lo si riaggiunge una volta.

Figura 14.2: *La probabilità di un rettangolo dalla CDF congiunta.*

In sintesi

- La **densità congiunta** $f_{X,Y}(x, y)$ è una probabilità per unità di area: $P((X, Y) \in C) = \iint_C f_{X,Y}$, il volume sotto la superficie. È ≥ 0 e ha volume totale 1.
- L'**integrale doppio** si calcola a fette (Fubini): prima un integrale con l'altra variabile fissa, poi l'altro; per un prodotto $g(x)h(y)$ è il prodotto degli integrali.
- Marginali: $f_X = \int f_{X,Y}\,dy$. Indipendenza: $f_{X,Y} = f_X f_Y$ ($\iff F_{X,Y} = F_X F_Y$).
- Condizionata: $f_{X|Y}(x \mid y) = f_{X,Y}/f_Y$, ottenuta condizionando a Y «vicino a y»; valgono probabilità totale, composta e Bayes per le densità.
- $E[g(X, Y)] = \iint g f_{X,Y}$, linearità, media condizionata $E[g] = E_Y[E_{X|Y}[g \mid Y]]$, covarianza e ρ come nel discreto.
- **CDF congiunta** $F_{X,Y}(x, y) = P(X \leq x, Y \leq y)$, con $f_{X,Y} = \frac{\partial^2 F_{X,Y}}{\partial x \partial y}$; marginali $F_X(x) = F_{X,Y}(x, +\infty)$; un rettangolo si calcola con quattro valori della CDF.

La variabile gaussiana e la funzione Q

Fra tutte le variabili continue ce n'è una che compare ovunque: il rumore termico di un resistore, gli errori di misura, le altezze delle persone, il rumore che disturba un segnale radio. È la **gaussiana** (o **normale**), con la sua densità a forma di campana. Il motivo della sua onnipresenza lo vedremo nel terzo pacchetto di slide, con il teorema centrale del limite: quando una grandezza è la somma di tantissimi piccoli contributi indipendenti (come il rumore termico, somma degli effetti di miliardi di elettroni), la sua densità diventa gaussiana. In questo capitolo ne studiamo la densità, la media e la varianza, e la funzione Q, che serve a calcolarne le probabilità. Alla fine useremo tutto per calcolare quanti bit sbaglia un ricevitore disturbato dal rumore.

La gaussiana standard

Gaussiana standard

Una variabile aleatoria X_0, con alfabeto $\mathcal{X} = \mathbb{R}$, si dice **gaussiana** (o **normale**) **standard**, in breve $X_0 \sim \mathcal{N}(0,1)$, se ha densità

$$f_{X_0}(x_0) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x_0^2}{2}}, \qquad x_0 \in \mathbb{R}.$$

La densità è una campana simmetrica attorno a 0, con il massimo $\frac{1}{\sqrt{2\pi}} \approx 0{,}399$ nell'origine. Le code scendono velocissime: l'esponente $-\frac{x^2}{2}$ cresce in valore assoluto con il quadrato di x, e già a $x = 4$ la densità è circa tremila volte più bassa del massimo ($e^{-8} \approx \frac{1}{3000}$). Il fattore $\frac{1}{\sqrt{2\pi}}$ non è scelto a caso: è l'unico che rende l'area uguale a 1. Per dimostrarlo serve uno dei calcoli più belli della matematica, che passa per il piano e per le coordinate polari.

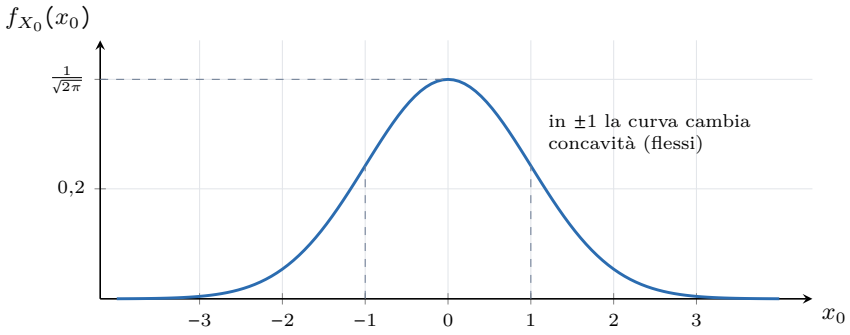


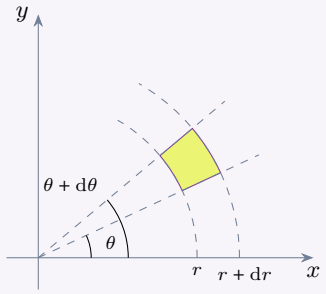
Figura 15.1: *La densità gaussiana standard: la «curva a campana».*

Richiamo di matematica: le coordinate polari

Un punto del piano si può individuare con le coordinate cartesiane (x, y) oppure con le **coordinate polari** (r, θ): la distanza r dall'origine e l'angolo θ che il segmento dall'origine al punto forma con l'asse x. Il legame è $x = r\cos\theta$, $y = r\sin\theta$, e per Pitagora $x^2 + y^2 = r^2$.
Per calcolare un integrale doppio in coordinate polari si divide il piano in «rettangolini polari»: le zone fra due circonferenze di raggi r e $r + \mathrm{d}r$ e fra due semirette di angoli θ e $\theta + \mathrm{d}\theta$. Un rettangolino polare è quasi un rettangolo con un lato lungo $\mathrm{d}r$ (in direzione radiale) e l'altro lungo $r\,\mathrm{d}\theta$ (un arco di circonferenza di raggio r: la lunghezza di un arco è raggio per angolo, in radianti). La sua area è quindi

$$\mathrm{d}A = r\,\mathrm{d}r\,\mathrm{d}\theta,$$

con quel fattore r in più: i rettangolini lontani dall'origine sono più larghi.



Il rettangolino polare giallo ha i lati circa $\mathrm{d}r$ e $r\,\mathrm{d}\theta$: area $r\,\mathrm{d}r\,\mathrm{d}\theta$. Coprendo tutto il piano, r va da 0 a ∞ e θ da 0 a 2π.

Teorema 15.1 — L'integrale di Gauss

$$\int_{-\infty}^{\infty} e^{-\frac{x^2}{2}}\,\mathrm{d}x = \sqrt{2\pi}, \qquad \text{quindi} \qquad \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}}\, e^{-\frac{x^2}{2}}\,\mathrm{d}x = 1.$$

Dimostrazione — passando al quadrato e nel piano

Passo 1 — Il problema. La funzione $e^{-x^2/2}$ non ha una primitiva che si possa scrivere con le funzioni elementari (polinomi, esponenziali, logaritmi, seni…): l'integrale non si può calcolare direttamente. Il trucco è calcolarne il quadrato. Sia $I = \int_{-\infty}^{\infty} e^{-x^2/2}\,\mathrm{d}x$.

Passo 2 — Il quadrato è un integrale doppio. Il nome della variabile di integrazione non conta, quindi

$$I^2 = \int_{-\infty}^{\infty} e^{-\frac{x^2}{2}}\,\mathrm{d}x \cdot \int_{-\infty}^{\infty} e^{-\frac{y^2}{2}}\,\mathrm{d}y = \iint_{\mathbb{R}^2} e^{-\frac{x^2+y^2}{2}}\,\mathrm{d}x\,\mathrm{d}y,$$

perché il prodotto di due integrali in variabili diverse è l'integrale doppio del prodotto (Capitolo 14), ed $e^{-x^2/2}\,e^{-y^2/2} = e^{-(x^2+y^2)/2}$.

Passo 3 — Coordinate polari. La funzione dipende solo da $x^2 + y^2 = r^2$, la distanza dall'origine: è una campana a simmetria circolare. In coordinate polari:

$$I^2 = \int_0^{2\pi} \int_0^{\infty} e^{-\frac{r^2}{2}}\, r\,\mathrm{d}r\,\mathrm{d}\theta.$$

Passo 4 — Ora l'integrale si fa. Grazie al fattore r la primitiva c'è: per la regola della catena $\frac{\mathrm{d}}{\mathrm{d}r}\left(-e^{-r^2/2}\right) = r\,e^{-r^2/2}$. Quindi

$$\int_0^{\infty} e^{-\frac{r^2}{2}}\, r\,\mathrm{d}r = \left[-e^{-\frac{r^2}{2}}\right]_0^{\infty} = 0 - (-1) = 1, \qquad I^2 = \int_0^{2\pi} 1\,\mathrm{d}\theta = 2\pi.$$

Passo 5 — Conclusione. $I > 0$ (è l'integrale di una funzione positiva), quindi $I = \sqrt{2\pi}$.

■

Teorema 15.2 — Media e varianza della gaussiana standard

Se $X_0 \sim \mathcal{N}(0,1)$: $\quad E[X_0] = \mu_{X_0} = 0, \quad \sigma^2_{X_0} = E[X_0^2] = 1.$

Dimostrazione

Passo 1 — La media. L'integrando $x\,\frac{1}{\sqrt{2\pi}}e^{-x^2/2}$ è dispari, e le due metà sono finite: $\int_0^\infty x\,e^{-x^2/2}\,\mathrm{d}x = \left[-e^{-x^2/2}\right]_0^\infty = 1$. Quindi la media è 0.

Passo 2 — Il valore quadratico medio, per parti. Si scrive $x^2e^{-x^2/2} = x\cdot\left(x\,e^{-x^2/2}\right)$, con $f(x) = x$ (derivata 1) e $g'(x) = x\,e^{-x^2/2}$ (primitiva $g(x) = -e^{-x^2/2}$):

$$E[X_0^2] = \frac{1}{\sqrt{2\pi}}\int_{-\infty}^{\infty} x^2 e^{-\frac{x^2}{2}}\,\mathrm{d}x = \frac{1}{\sqrt{2\pi}}\left\{\left[-x\,e^{-\frac{x^2}{2}}\right]_{-\infty}^{\infty} + \int_{-\infty}^{\infty} e^{-\frac{x^2}{2}}\,\mathrm{d}x\right\}.$$

Passo 3 — Si conclude. Il termine di bordo è nullo (l'esponenziale batte la potenza), e l'integrale rimasto è $\sqrt{2\pi}$: $E[X_0^2] = \frac{\sqrt{2\pi}}{\sqrt{2\pi}} = 1$. Siccome la media è 0, la varianza coincide con il valore quadratico medio.

■

LA GAUSSIANA GENERICA

Tutte le altre gaussiane si ottengono dalla standard spostandola e allargandola.

Teorema 15.3 — Densità della gaussiana generica

Sia $X_0 \sim \mathcal{N}(0,1)$ e sia $X = \sigma_X X_0 + \mu_X$, con $\sigma_X > 0$ e $\mu_X \in \mathbb{R}$. Allora

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma_X^2}}\,e^{-\frac{(x-\mu_X)^2}{2\sigma_X^2}}, \qquad x \in \mathbb{R},$$

e $E[X] = \mu_X$, $\mathrm{VAR}(X) = \sigma_X^2$. Si scrive $X \sim \mathcal{N}(\mu_X, \sigma_X^2)$.

Dimostrazione

Passo 1 — La densità. È la trasformazione lineare $g(x) = \sigma_X x + \mu_X$, crescente. Con la formula del Capitolo 12, $f_X(x) = \frac{1}{\sigma_X} f_{X_0}\left(\frac{x-\mu_X}{\sigma_X}\right)$:

$$f_X(x) = \frac{1}{\sigma_X}\,\frac{1}{\sqrt{2\pi}}\,e^{-\frac{1}{2}\left(\frac{x-\mu_X}{\sigma_X}\right)^2} = \frac{1}{\sqrt{2\pi\sigma_X^2}}\,e^{-\frac{(x-\mu_X)^2}{2\sigma_X^2}}.$$

Passo 2 — La media. Per la linearità: $E[X] = E[\sigma_X X_0 + \mu_X] = \sigma_X E[X_0] + \mu_X = 0\cdot\sigma_X + \mu_X = \mu_X$.

Passo 3 — La varianza.

$$\mathrm{VAR}(X) = E[(X-\mu_X)^2] = E[(\sigma_X X_0 + \mu_X - \mu_X)^2] = E[(\sigma_X X_0)^2] = \sigma_X^2\,E[X_0^2] = \sigma_X^2.$$

■

I due parametri hanno quindi un significato diretto: μ_X è il centro della campana (e la sua media), σ_X la sua larghezza (e la sua deviazione standard). Una gaussiana è completamente determinata dalla coppia (μ_X, σ_X^2). Il procedimento si può anche rovesciare: se $X \sim \mathcal{N}(\mu_X, \sigma_X^2)$, la variabile **standardizzata** $X_0 = \frac{X-\mu_X}{\sigma_X}$ è una gaussiana standard.

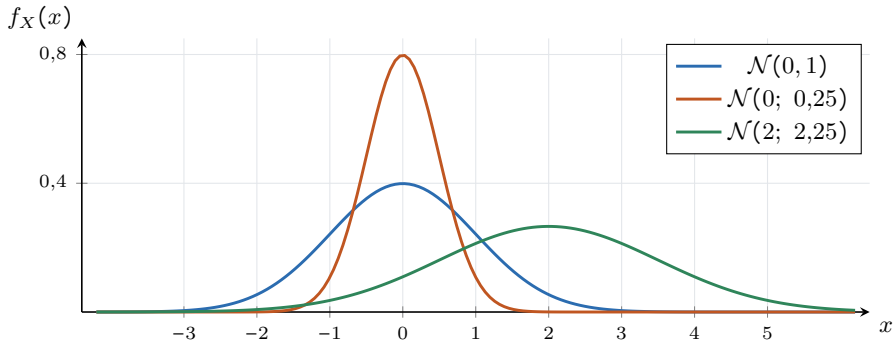


Figura 15.2: *Tre gaussiane. Con $\sigma = 0{,}5$ la campana è stretta e alta, con $\sigma = 1{,}5$ larga e bassa: l'area resta sempre 1. La media μ sposta il centro.*

La funzione Q

Per calcolare la probabilità che una gaussiana cada in un intervallo servirebbe la sua CDF. Ma né la CDF né la CCDF di $X_0 \sim \mathcal{N}(0,1)$ sono note in forma esplicita, perché $e^{-\gamma x^2}$ non ammette primitive elementari (è lo stesso ostacolo incontrato con l'integrale di Gauss, ma ora l'integrale non è su tutta la retta, e il trucco del quadrato non funziona). Si dà allora un nome alla funzione che serve, e se ne tabulano i valori.

Funzione Q

La **funzione** Q è la CCDF della gaussiana standard, cioè la probabilità che $X_0 \sim \mathcal{N}(0,1)$ superi il valore x:

$$Q(x) \triangleq P(X_0 > x) = 1 - F_{X_0}(x) = \frac{1}{\sqrt{2\pi}} \int_x^{+\infty} e^{-\frac{t^2}{2}}\, \mathrm{d}t.$$

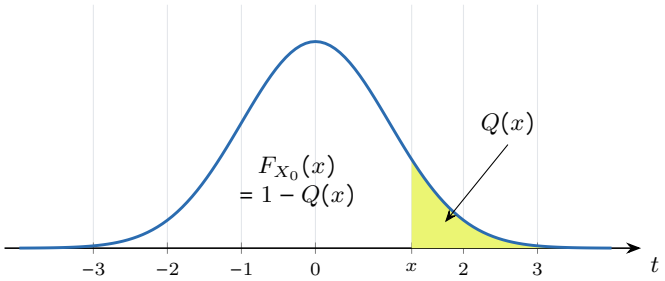


Figura 15.3: *$Q(x)$ è l'area della coda destra della gaussiana standard, oltre x.*

Con la funzione Q si calcola qualsiasi probabilità gaussiana. Per la standard, $F_{X_0}(x) = 1 - Q(x)$ e la probabilità di un intervallino è

$$P_{X_0}(x; \Delta x) = Q\left(x - \frac{\Delta x}{2}\right) - Q\left(x + \frac{\Delta x}{2}\right).$$

Per una gaussiana qualsiasi si standardizza.

Teorema 15.4 — Le code di una gaussiana qualsiasi

Se $X \sim \mathcal{N}(\mu_X, \sigma_X^2)$:

$$P(X > x) = 1 - F_X(x) = Q\left(\frac{x - \mu_X}{\sigma_X}\right).$$

Dimostrazione

Passo 1. Si scrive $X = X_0\sigma_X + \mu_X$ e si isola X_0 (dividere per $\sigma_X > 0$ non cambia il verso della disuguaglianza):

$$P(X > x) = P(X_0\sigma_X + \mu_X > x) = P\left(X_0 > \frac{x-\mu_X}{\sigma_X}\right) = \int_{\frac{x-\mu_X}{\sigma_X}}^{+\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}\,\mathrm{d}t = Q\left(\frac{x-\mu_X}{\sigma_X}\right).$$

■

La quantità $\frac{x-\mu_X}{\sigma_X}$ dice **di quante deviazioni standard** il valore x si trova sopra la media: è tutto quello che conta.

Le proprietà della funzione Q

Teorema 15.5 — Proprietà della funzione Q

a) $Q(-\infty) = 1, \quad Q(0) = \frac{1}{2}, \quad Q(+\infty) = 0;$

b) $\dfrac{\mathrm{d}Q(x)}{\mathrm{d}x} = -\dfrac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} < 0$ per ogni x: Q è decrescente;

c) simmetria: $Q(-x) = 1 - Q(x)$;

d) se $X \sim \mathcal{N}(\mu_X, \sigma_X^2)$: $P(X \geq \eta) = Q\left(\frac{\eta-\mu_X}{\sigma_X}\right)$.

Dimostrazione

Passo 1 — a). $Q(-\infty)$ è l'area sotto tutta la campana, cioè 1; $Q(0)$ è metà dell'area, per la simmetria; $Q(+\infty)$ è l'area di una coda vuota.

Passo 2 — b). Si scrive $Q(x) = 1 - \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}} e^{-t^2/2}\,\mathrm{d}t$ e si deriva con il teorema fondamentale del calcolo integrale: la derivata della funzione integrale è l'integrando calcolato in x, con il segno meno. Spostando x a destra, la coda si accorcia.

Passo 3 — c). Per la parità della funzione integranda, la coda sinistra oltre $-x$ è uguale alla coda destra oltre x: $\int_{-\infty}^{-x} \frac{1}{\sqrt{2\pi}} e^{-t^2/2}\,\mathrm{d}t = \int_{x}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-t^2/2}\,\mathrm{d}t = Q(x)$. Quindi

$$Q(-x) = \int_{-x}^{+\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}\,\mathrm{d}t = 1 - \underbrace{\int_{-\infty}^{-x} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}\,\mathrm{d}t}_{Q(x)} = 1 - Q(x).$$

Passo 4 — d). È il teorema precedente: per una variabile continua $P(X \geq \eta) = P(X > \eta)$.

■

Grazie alla simmetria basta tabulare $Q(x)$ per $x \geq 0$. Ecco alcuni valori:

x	0	0,5	1	1,5	2	2,5	3	4
$Q(x)$	0,5	0,309	0,159	0,0668	0,0228	0,00621	0,00135	$3{,}17 \cdot 10^{-5}$

Teorema 15.6 — Una maggiorazione della funzione Q

Per ogni $x > 0$:

$$Q(x) < \frac{1}{x\sqrt{2\pi}} e^{-\frac{x^2}{2}},$$

e per x grande il secondo membro è anche una buona approssimazione: $Q(x) \simeq \frac{1}{x\sqrt{2\pi}} e^{-\frac{x^2}{2}}$. In particolare, per $x > \frac{1}{\sqrt{2\pi}} \approx 0{,}4$, $Q(x) < e^{-\frac{x^2}{2}}$.

Dimostrazione — lo stesso trucco della disuguaglianza di Markov

Passo 1 — Si moltiplica per un numero maggiore di 1. Nella coda $t > x > 0$, quindi $\frac{t}{x} > 1$:

$$Q(x) = \frac{1}{\sqrt{2\pi}} \int_x^\infty e^{-\frac{t^2}{2}}\, \mathrm{d}t < \frac{1}{\sqrt{2\pi}} \int_x^\infty \frac{t}{x}\, e^{-\frac{t^2}{2}}\, \mathrm{d}t.$$

Passo 2 — Ora la primitiva c'è. Come nell'integrale di Gauss, $t\, e^{-t^2/2}$ ha primitiva $-e^{-t^2/2}$:

$$\frac{1}{x\sqrt{2\pi}} \int_x^\infty t\, e^{-\frac{t^2}{2}}\, \mathrm{d}t = \frac{1}{x\sqrt{2\pi}} \left[-e^{-\frac{t^2}{2}} \right]_x^\infty = \frac{1}{x\sqrt{2\pi}}\, e^{-\frac{x^2}{2}}.$$

Passo 3 — Perché per x grande è anche un'approssimazione. Il fattore $\frac{t}{x}$ è vicino a 1 nella parte della coda che conta, appena oltre x; più in là la densità è trascurabile. Quindi la maggiorazione esagera di poco. Infine, se $x\sqrt{2\pi} > 1$, il fattore $\frac{1}{x\sqrt{2\pi}}$ è minore di 1.

■

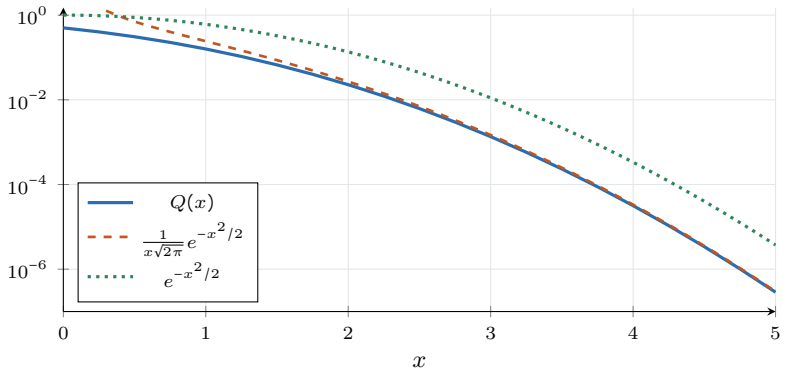


Figura 15.4: *La funzione Q in scala logaritmica (ogni tacca verticale è un fattore 10) e le due maggiorazioni. Da $x \approx 2$ in poi la prima è quasi indistinguibile da $Q(x)$; la seconda è più grossolana ma più semplice.*

La regola delle tre sigma

Quanto spesso una gaussiana si allontana dalla sua media di più di k deviazioni standard? Standardizzando e usando la simmetria (le due code sono uguali):

$$P(|X - \mu_X| > k\,\sigma_X) = P(|X_0| > k) = 2\,Q(k), \qquad P(|X - \mu_X| \le k\,\sigma_X) = 1 - 2\,Q(k).$$

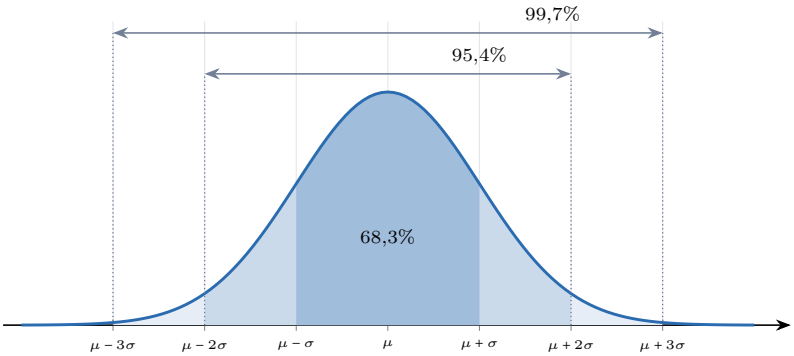


Figura 15.5: *La regola 68–95–99,7: le probabilità che una gaussiana cada entro una, due e tre deviazioni standard dalla media.*

k	1	2	3
$P(\lvert X - \mu_X\rvert \le k\sigma_X)$ per la gaussiana: $1 - 2Q(k)$	0,683	0,954	0,997
minimo garantito per qualsiasi densità (Chebyshev): $1 - \frac{1}{k^2}$	0	0,75	0,889

Una gaussiana esce dalla fascia $\mu \pm 3\sigma$ solo 3 volte su mille: in pratica, un valore a più di tre deviazioni standard dalla media è un evento eccezionale. Ma attenzione: vale per la gaussiana, non per ogni variabile (per una densità qualsiasi, Chebyshev garantisce solo l'89%).

UN'APPLICAZIONE: BIT SBAGLIATI PER COLPA DEL RUMORE

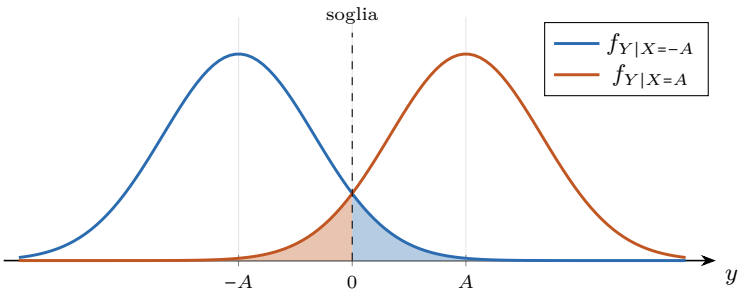
Esempio 15.1 — La probabilità di errore di una trasmissione binaria

Un trasmettitore invia un bit codificandolo come una tensione: $+A$ per l'1, $-A$ per lo 0, con i due bit equiprobabili. Il canale aggiunge un rumore gaussiano $N \sim \mathcal{N}(0, \sigma^2)$, indipendente dal bit, e il ricevitore osserva $Y = X + N$. Decide «1» se $Y > 0$ e «0» se $Y \le 0$. Con che probabilità sbaglia?

- Se è stato trasmesso l'1, $Y = A + N$: per la trasformazione lineare $Y \sim \mathcal{N}(A, \sigma^2)$. Il ricevitore sbaglia se $Y \le 0$:

$$P(\text{errore} \mid X = A) = P(A + N \le 0) = P(N \le -A) = P(N \ge A) = Q\left(\frac{A}{\sigma}\right),$$

  dove si è usata la simmetria del rumore (le code sono uguali) e la proprietà d) della funzione Q.
- Se è stato trasmesso lo 0, per simmetria l'errore ($Y > 0$) ha la stessa probabilità.
- Per la probabilità totale: $P_e = \frac{1}{2}Q\left(\frac{A}{\sigma}\right) + \frac{1}{2}Q\left(\frac{A}{\sigma}\right) = Q\left(\frac{A}{\sigma}\right)$.



Le due campane sono le densità di Y sapendo quale bit è stato trasmesso; le code colorate che oltrepassano la soglia sono gli errori. Più le campane sono lontane in rapporto alla loro larghezza, cioè più è grande $\frac{A}{\sigma}$, meno si sbaglia:

A/σ	1	2	3	4	5
$P_e = Q(A/\sigma)$	0,16	0,023	0,0013	$3{,}2 \cdot 10^{-5}$	$2{,}9 \cdot 10^{-7}$

Raddoppiare l'ampiezza da σ a 2σ divide gli errori per 7; passare da 2σ a 4σ li divide per 700: la coda gaussiana crolla come $e^{-x^2/2}$. Il rapporto A/σ è legato al *rapporto segnale-rumore*, e decidere nel modo migliore che cosa è stato trasmesso è il problema della teoria della decisione, che affronteremo nel terzo pacchetto di slide.

In sintesi

- **Gaussiana standard** $\mathcal{N}(0,1)$: $f(x) = \frac{1}{\sqrt{2\pi}}e^{-x^2/2}$; l'area 1 segue dall'integrale di Gauss $\int e^{-x^2/2} = \sqrt{2\pi}$ (in coordinate polari); media 0, varianza 1.
- **Gaussiana generica** $X = \sigma_X X_0 + \mu_X \sim \mathcal{N}(\mu_X, \sigma_X^2)$: $f_X(x) = \frac{1}{\sqrt{2\pi\sigma_X^2}}e^{-(x-\mu_X)^2/(2\sigma_X^2)}$, determinata da media e varianza; standardizzando, $\frac{X-\mu_X}{\sigma_X} \sim \mathcal{N}(0,1)$.
- **Funzione** Q: $Q(x) = P(X_0 > x)$, la coda della standard; $P(X > x) = Q\left(\frac{x-\mu_X}{\sigma_X}\right)$. È decrescente, $Q(0) = \frac{1}{2}$, $Q(-x) = 1 - Q(x)$, e $Q(x) < \frac{1}{x\sqrt{2\pi}}e^{-x^2/2}$ per $x > 0$.
- Regola 68–95–99,7: $P(|X - \mu| \le k\sigma) = 1 - 2Q(k)$.
- Trasmissione binaria $\pm A$ con rumore gaussiano: $P_e = Q(A/\sigma)$.

VETTORI ALEATORI E VETTORI GAUSSIANI

Nel Capitolo 14 abbiamo studiato coppie e m-ple di variabili continue. Quando le variabili diventano molte (i campioni di un segnale in istanti successivi, le tensioni su n antenne, i pixel di un'immagine) scrivere ogni media e ogni covarianza con i suoi indici diventa pesantissimo. L'algebra lineare offre un modo compatto per farlo: si raccolgono le variabili in un **vettore**, le loro medie in un altro vettore e le covarianze di tutte le coppie in una **matrice**, e le formule tornano corte come quelle di una sola variabile. Con questa notazione studieremo la famiglia più importante di tutte, i **vettori gaussiani**: n variabili gaussiane legate fra loro, descritte da una sola formula e con una proprietà preziosa: restano gaussiane quando passano attraverso un sistema lineare.

Come nelle slide, i vettori si indicano con una sottolineatura ($\underline{X}$, $\underline{x}$, $\underline{\mu}$) e le matrici con due ($\underline{\underline{A}}$, $\underline{\underline{C}}$).

VETTORI E MATRICI: IL MINIMO INDISPENSABILE

Per leggere questo capitolo bastano poche operazioni fra vettori e matrici. Le raccogliamo qui, partendo da zero; chi le conosce già può passare direttamente ai vettori aleatori.

Richiamo di matematica: vettori, matrici e trasposti

Un **vettore** di n numeri si scrive come una **colonna**:

$$\underline{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \qquad (n \times 1 : \ n \text{ righe e una colonna}).$$

Il suo **trasposto** $\underline{x}^T = [x_1, x_2, \ldots, x_n]$ contiene gli stessi numeri disposti in riga ($1 \times n$). Per risparmiare spazio, un vettore colonna si scrive spesso come il trasposto di una riga: $\underline{x} = [x_1, x_2, \ldots, x_n]^T$.
Una **matrice** $m \times n$ è una tabella di numeri con m righe e n colonne; l'elemento a_{ij} sta nella riga i e nella colonna j. La **trasposta** $\underline{\underline{A}}^T$ si ottiene scambiando le righe con le colonne: l'elemento di posto (i, j) di $\underline{\underline{A}}^T$ è a_{ji}. Per esempio

$$\underline{\underline{A}} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} (2 \times 3), \qquad \underline{\underline{A}}^T = \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix} (3 \times 2).$$

Una matrice quadrata ($n \times n$) è **simmetrica** se $\underline{\underline{A}}^T = \underline{\underline{A}}$, cioè se $a_{ij} = a_{ji}$: è uguale alla sua immagine allo specchio rispetto alla **diagonale principale**, quella che va dall'angolo in alto a sinistra all'angolo in basso a destra. È **diagonale** se tutti gli elementi fuori dalla diagonale principale sono nulli.

Richiamo di matematica: i prodotti «riga per colonna»

Tutti i prodotti fra matrici e vettori seguono una sola regola, **riga per colonna**: si prende una riga del primo fattore e una colonna del secondo, si moltiplicano gli elementi a due a due e si sommano i risultati.

- **Riga per colonna** (prodotto scalare): $\underline{x}^T \underline{y} = x_1 y_1 + x_2 y_2 + \cdots + x_n y_n$. Il risultato è un **numero** ($1 \times n$ per $n \times 1$ dà 1×1). Per esempio $\underline{x}^T \underline{x} = \sum_i x_i^2$ è il quadrato della lunghezza del vettore (per Pitagora).
- **Matrice per vettore**: $\underline{\underline{A}}\,\underline{x}$ è il vettore che ha per elemento i-esimo il prodotto della riga i di $\underline{\underline{A}}$ per $\underline{x}$: $(\underline{\underline{A}}\,\underline{x})_i = \sum_j a_{ij} x_j$. Ogni elemento del risultato è una **combinazione lineare** delle x_j (figura qui sotto).
- **Matrice per matrice**: l'elemento (i, j) di $\underline{\underline{A}}\,\underline{\underline{B}}$ è la riga i di $\underline{\underline{A}}$ per la colonna j di $\underline{\underline{B}}$. Le dimensioni «interne» devono coincidere e spariscono: $(m \times n)(n \times p) = m \times p$. Attenzione: in generale $\underline{\underline{A}}\,\underline{\underline{B}} \neq \underline{\underline{B}}\,\underline{\underline{A}}$, l'ordine dei fattori conta.
- **Colonna per riga**: $\underline{x}\,\underline{y}^T$ ($n \times 1$ per $1 \times n$) è una **matrice** $n \times n$, con elemento (i, j) uguale a $x_i y_j$. In particolare $\underline{x}\,\underline{x}^T$ contiene **tutti i prodotti a due a due** $x_i x_j$:

$$\underline{x}\,\underline{x}^T = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \begin{bmatrix} x_1, x_2 \end{bmatrix} = \begin{bmatrix} x_1^2 & x_1 x_2 \\ x_2 x_1 & x_2^2 \end{bmatrix}.$$

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} a_{11}x_1 + a_{12}x_2 + a_{13}x_3 \\ a_{21}x_1 + a_{22}x_2 + a_{23}x_3 \end{bmatrix}$$

$\underline{\underline{A}}$ (2×3) $\quad$ $\underline{x}$ (3×1) $\quad$ $\underline{\underline{A}}\,\underline{x}$ (2×1)

La seconda riga di $\underline{\underline{A}}$ per la colonna $\underline{x}$ dà il secondo elemento del risultato.

Il trasposto di un prodotto si ottiene trasponendo i fattori e **invertendone l'ordine**: $(\underline{\underline{A}}\,\underline{\underline{B}})^T = \underline{\underline{B}}^T \underline{\underline{A}}^T$. Il perché: l'elemento (i, j) di $(\underline{\underline{A}}\,\underline{\underline{B}})^T$ è l'elemento (j, i) di $\underline{\underline{A}}\,\underline{\underline{B}}$, cioè la riga j di $\underline{\underline{A}}$ per la colonna i di $\underline{\underline{B}}$; ma la colonna i di $\underline{\underline{B}}$ è la riga i di $\underline{\underline{B}}^T$, e la riga j di $\underline{\underline{A}}$ è la colonna j di $\underline{\underline{A}}^T$. Per esempio $(\underline{\underline{A}}\,\underline{x})^T = \underline{x}^T \underline{\underline{A}}^T$. Infine, un numero è uguale al suo trasposto, quindi $\underline{x}^T \underline{y} = (\underline{x}^T \underline{y})^T = \underline{y}^T \underline{x}$.

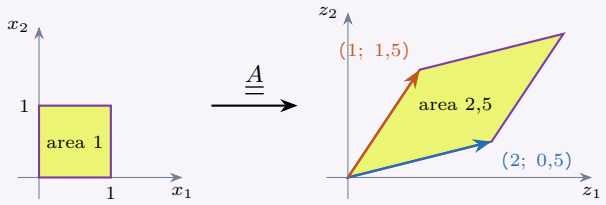
Richiamo di matematica: identità, inversa, determinante e forme quadratiche

Identità e inversa. La matrice **identità** $\underline{\underline{I}}$ ha 1 sulla diagonale principale e 0 altrove: per ogni vettore $\underline{\underline{I}}\,\underline{x} = \underline{x}$, come moltiplicare un numero per 1. L'**inversa** di una matrice quadrata $\underline{\underline{A}}$ è la matrice $\underline{\underline{A}}^{-1}$ tale che $\underline{\underline{A}}^{-1}\underline{\underline{A}} = \underline{\underline{A}}\,\underline{\underline{A}}^{-1} = \underline{\underline{I}}$: disfa quello che fa $\underline{\underline{A}}$, come $\frac{1}{a}$ disfa la moltiplicazione per a. Se $\underline{z} = \underline{\underline{A}}\,\underline{x}$, allora $\underline{x} = \underline{\underline{A}}^{-1}\underline{z}$. Per un prodotto l'ordine si inverte, come per il trasposto: $(\underline{\underline{A}}\,\underline{\underline{B}})^{-1} = \underline{\underline{B}}^{-1}\underline{\underline{A}}^{-1}$ (per disfare due operazioni si disfa prima l'ultima, come quando ci si toglie prima le scarpe e poi i calzini). Inoltre $(\underline{\underline{A}}^{T})^{-1} = (\underline{\underline{A}}^{-1})^{T}$.

Determinante. A ogni matrice quadrata si associa un numero, il **determinante**. Per una matrice 2×2:

$$\det \begin{bmatrix} a & b \\ c & d \end{bmatrix} = ad - bc, \qquad \begin{bmatrix} a & b \\ c & d \end{bmatrix}^{-1} = \frac{1}{ad-bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}$$

(per verificare la formula dell'inversa basta moltiplicare: si ottiene $\underline{\underline{I}}$). Il significato geometrico: $|\det \underline{\underline{A}}|$ è il **fattore per cui $\underline{\underline{A}}$ moltiplica le aree** (i volumi, in n dimensioni). La matrice è invertibile esattamente quando $\det \underline{\underline{A}} \neq 0$: se il determinante è nullo, $\underline{\underline{A}}$ schiaccia il piano su una retta e non si può più tornare indietro. Valgono $\det(\underline{\underline{A}}\,\underline{\underline{B}}) = \det \underline{\underline{A}} \cdot \det \underline{\underline{B}}$ (le due dilatazioni si susseguono) e $\det \underline{\underline{A}}^{T} = \det \underline{\underline{A}}$. Per una matrice diagonale tutto è facile: il determinante è il prodotto degli elementi della diagonale, e l'inversa si ottiene invertendoli uno per uno.



Con $\underline{\underline{A}} = \begin{bmatrix} 2 & 1 \\ 0{,}5 & 1{,}5 \end{bmatrix}$ il quadrato di lato 1 diventa il parallelogramma che ha per lati le colonne di $\underline{\underline{A}}$; la sua area è $\det \underline{\underline{A}} = 2 \cdot 1{,}5 - 1 \cdot 0{,}5 = 2{,}5$.

Forme quadratiche. Data una matrice quadrata $\underline{\underline{C}}$, il numero $\underline{q}^{T}\underline{\underline{C}}\,\underline{q} = \sum_i \sum_j q_i\, c_{ij}\, q_j$ si chiama **forma quadratica**: è un polinomio di secondo grado nelle q_i. Se $\underline{\underline{C}}$ è diagonale, $\underline{q}^{T}\underline{\underline{C}}\,\underline{q} = c_{11}q_1^2 + c_{22}q_2^2 + \cdots + c_{nn}q_n^2$: una somma di quadrati pesati.

VETTORI ALEATORI: MEDIE, CORRELAZIONI E COVARIANZE

Vettore aleatorio

Un **vettore aleatorio** n-dimensionale è la colonna di n variabili aleatorie

$$\underline{X} = [X_1, X_2, \ldots, X_n]^{T}.$$

La sua CDF e la sua PDF sono la CDF e la PDF congiunte delle n variabili, scritte in forma vettoriale: $F_{\underline{X}}(\underline{x}) = P(X_1 \leq x_1, \ldots, X_n \leq x_n)$ e $f_{\underline{X}}(\underline{x}) = f_{X_1 \cdots X_n}(x_1, \ldots, x_n)$, con $\underline{x} = [x_1, \ldots, x_n]^{T}$.

Niente di nuovo, quindi: $f_{\underline{X}}(\underline{x})$ è la densità congiunta del Capitolo 14 con n variabili, scritta in modo compatto. La novità è la caratterizzazione sintetica. La media di un vettore (o di una matrice) di variabili aleatorie si calcola **elemento per elemento**.

Vettore delle medie

Il **vettore valore medio** di $\underline{X}$ è il vettore colonna dei valori attesi delle n variabili:

$$\underline{\mu}_{\underline{X}} \triangleq E[\underline{X}] = [\mu_{X_1}, \mu_{X_2}, \ldots, \mu_{X_n}]^{T}.$$

Le medie da sole non dicono come le variabili sono legate fra loro. Per questo si considerano anche la correlazione e la covarianza di tutte le coppie (X_i, X_j) che si possono estrarre dal vettore, raccolte in una tabella $n \times n$, cioè in una matrice. Il modo per costruirla in un colpo solo è il prodotto colonna per riga $\underline{X}\,\underline{X}^{T}$, che contiene tutti i prodotti $X_i X_j$.

Matrice di correlazione

La **matrice di correlazione** del vettore $\underline{X}$ è la matrice $n \times n$

$$\underline{\underline{R}}_{\underline{X}} \triangleq E\left[\underline{X}\,\underline{X}^T\right] = \begin{bmatrix} R_{X_1X_1} & R_{X_1X_2} & \cdots & R_{X_1X_n} \\ R_{X_2X_1} & R_{X_2X_2} & \cdots & R_{X_2X_n} \\ \vdots & \vdots & \ddots & \vdots \\ R_{X_nX_1} & R_{X_nX_2} & \cdots & R_{X_nX_n} \end{bmatrix}, \qquad R_{X_iX_j} = E[X_iX_j].$$

È **simmetrica**, perché $E[X_iX_j] = E[X_jX_i]$, e sulla diagonale principale ci sono i **valori quadratici medi** delle variabili, perché $E[X_iX_i] = E[X_i^2]$.

Matrice di covarianza

La **matrice di covarianza** del vettore $\underline{X}$ è la matrice $n \times n$

$$\underline{\underline{C}}_{\underline{X}} \triangleq E\left[\left(\underline{X} - \underline{\mu}_{\underline{X}}\right)\left(\underline{X} - \underline{\mu}_{\underline{X}}\right)^T\right] = \begin{bmatrix} C_{X_1X_1} & C_{X_1X_2} & \cdots & C_{X_1X_n} \\ C_{X_2X_1} & C_{X_2X_2} & \cdots & C_{X_2X_n} \\ \vdots & \vdots & \ddots & \vdots \\ C_{X_nX_1} & C_{X_nX_2} & \cdots & C_{X_nX_n} \end{bmatrix}, \qquad C_{X_iX_j} = COV(X_i, X_j).$$

Anche questa è simmetrica, e l'elemento i-esimo della diagonale principale è $C_{X_iX_i} = E[(X_i - \mu_{X_i})(X_i - \mu_{X_i})] = \sigma^2_{X_i}$, la **varianza** di X_i. Fuori dalla diagonale ci sono le covarianze, che si possono scrivere con i coefficienti di correlazione: $C_{X_iX_j} = \rho_{X_iX_j}\,\sigma_{X_i}\sigma_{X_j}$. Per $n = 2$, scrivendo in breve $\sigma_i = \sigma_{X_i}$ e $\rho = \rho_{X_1X_2}$:

$$\underline{\underline{C}}_{\underline{X}} = \begin{bmatrix} \sigma_1^2 & \rho\,\sigma_1\sigma_2 \\ \rho\,\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix}.$$

Teorema 16.1 — Covarianza e correlazione

$$\underline{\underline{C}}_{\underline{X}} = \underline{\underline{R}}_{\underline{X}} - \underline{\mu}_{\underline{X}}\,\underline{\mu}_{\underline{X}}^T.$$

Dimostrazione — come nel Capitolo 9, ma tutto insieme

Passo 1 — Si sviluppa il prodotto. Scriviamo in breve $\underline{\mu}$ per $\underline{\mu}_{\underline{X}}$. Il prodotto fra matrici si sviluppa come quello fra numeri, facendo attenzione a non scambiare l'ordine dei fattori; inoltre $(\underline{X} - \underline{\mu})^T = \underline{X}^T - \underline{\mu}^T$:

$$(\underline{X} - \underline{\mu})(\underline{X} - \underline{\mu})^T = \underline{X}\,\underline{X}^T - \underline{X}\,\underline{\mu}^T - \underline{\mu}\,\underline{X}^T + \underline{\mu}\,\underline{\mu}^T.$$

Passo 2 — Si fa la media. La media è lineare e si fa elemento per elemento; $\underline{\mu}$ è costante ed esce dalla media: $E[\underline{X}\,\underline{\mu}^T] = E[\underline{X}]\,\underline{\mu}^T = \underline{\mu}\,\underline{\mu}^T$, e allo stesso modo $E[\underline{\mu}\,\underline{X}^T] = \underline{\mu}\,\underline{\mu}^T$. Quindi

$$\underline{\underline{C}}_{\underline{X}} = \underline{\underline{R}}_{\underline{X}} - \underline{\mu}\,\underline{\mu}^T - \underline{\mu}\,\underline{\mu}^T + \underline{\mu}\,\underline{\mu}^T = \underline{\underline{R}}_{\underline{X}} - \underline{\mu}\,\underline{\mu}^T.$$

Elemento per elemento è proprio la formula $COV(X_i, X_j) = E[X_iX_j] - \mu_{X_i}\mu_{X_j}$ del Capitolo 9. ■

Per una sola variabile la coppia media-varianza (μ_X, σ_X^2) riassume spesso le informazioni più importanti; per una coppia, la «cinquina» $(\mu_X, \sigma_X^2, \mu_Y, \sigma_Y^2, COV(X,Y))$. Per un vettore aleatorio lo stesso ruolo è svolto dal vettore delle medie $\underline{\mu}_{\underline{X}}$ insieme alla matrice di covarianza $\underline{\underline{C}}_{\underline{X}}$ (o a quella di correlazione $\underline{\underline{R}}_{\underline{X}}$, che per il Teorema 16.1 contiene la stessa informazione, noto $\underline{\mu}_{\underline{X}}$): è la **caratterizzazione statistica sintetica** del vettore. Per $n = 2$ si ritrova proprio la cinquina: due medie e, nella matrice 2×2 simmetrica, due varianze e una covarianza. In generale servono n medie e $\frac{n(n+1)}{2}$ elementi della matrice (la diagonale e il triangolo sopra di essa; quello sotto è uguale per simmetria).

La caratterizzazione sintetica è molto più povera di quella completa, la densità congiunta $f_{\underline{X}}$: dalla densità si calcolano medie e covarianze, ma in generale non si può tornare indietro, perché vettori con densità molto diverse possono avere le stesse medie e covarianze. Vedremo che per i vettori gaussiani, invece, si può.

Esempio 16.1 — Il vettore della densità $x + y$

Riprendiamo la coppia del Capitolo 14 (là si chiamavano X e Y), con densità $f_{\underline{X}}(\underline{x}) = x_1 + x_2$ sul quadrato $[0,1]^2$. Avevamo trovato $E[X_1] = E[X_2] = \frac{7}{12}$, $E[X_1^2] = E[X_2^2] = \frac{5}{12}$ e $E[X_1 X_2] = \frac{1}{3}$. Quindi

$$\underline{\mu}_{\underline{X}} = \begin{bmatrix} 7/12 \\ 7/12 \end{bmatrix}, \qquad \underline{\underline{R}}_{\underline{X}} = \begin{bmatrix} 5/12 & 1/3 \\ 1/3 & 5/12 \end{bmatrix} = \frac{1}{144}\begin{bmatrix} 60 & 48 \\ 48 & 60 \end{bmatrix}, \qquad \underline{\mu}_{\underline{X}}\underline{\mu}_{\underline{X}}^T = \frac{1}{144}\begin{bmatrix} 49 & 49 \\ 49 & 49 \end{bmatrix},$$

dove $\underline{\mu}_{\underline{X}}\underline{\mu}_{\underline{X}}^T$ è il prodotto colonna per riga, con tutti gli elementi uguali a $\frac{7}{12} \cdot \frac{7}{12} = \frac{49}{144}$. Per il Teorema 16.1

$$\underline{\underline{C}}_{\underline{X}} = \underline{\underline{R}}_{\underline{X}} - \underline{\mu}_{\underline{X}}\underline{\mu}_{\underline{X}}^T = \frac{1}{144}\begin{bmatrix} 11 & -1 \\ -1 & 11 \end{bmatrix}.$$

Sulla diagonale ci sono le varianze $\frac{11}{144}$, fuori la covarianza $-\frac{1}{144}$: gli stessi valori del Capitolo 14, ottenuti tutti insieme.

LA MATRICE DI COVARIANZA È SEMPRE DEFINITA NON NEGATIVA

Una varianza non può essere negativa. Per una matrice di covarianza vale qualcosa di più forte, che riguarda tutte le combinazioni lineari delle variabili del vettore.

Matrice definita non negativa

Una matrice quadrata $\underline{\underline{C}}$ di dimensioni $M \times M$ si dice **definita non negativa** se, per qualunque vettore $\underline{q} \in \mathbb{R}^M$ (cioè $M \times 1$),

$$\underline{q}^T \underline{\underline{C}}\, \underline{q} \geq 0.$$

Teorema 16.2 — La matrice di covarianza è definita non negativa

La matrice di covarianza $\underline{\underline{C}}_{\underline{X}}$ di qualunque vettore aleatorio $\underline{X}$ di dimensione M è definita non negativa: $\underline{q}^T \underline{\underline{C}}_{\underline{X}}\, \underline{q} \geq 0$ per ogni $\underline{q} \in \mathbb{R}^M$.

Dimostrazione — la forma quadratica è una varianza

Passo 1 — Una combinazione lineare. Fissato $\underline{q}$, la quantità $\underline{q}^T \underline{X} = q_1 X_1 + \cdots + q_M X_M$ è una variabile aleatoria scalare (riga per colonna dà un numero). Per la linearità della media, $E[\underline{q}^T \underline{X}] = \underline{q}^T \underline{\mu}_{\underline{X}}$.

Passo 2 — Il suo valore quadratico medio. Un numero è uguale al suo trasposto, quindi $\underline{q}^T \underline{X} = (\underline{q}^T \underline{X})^T = \underline{X}^T \underline{q}$ (trasposto di un prodotto, con l'ordine invertito). Allora

$$E[(\underline{q}^T \underline{X})^2] = E[(\underline{q}^T \underline{X})(\underline{X}^T \underline{q})] = E[\underline{q}^T \underline{X}\,\underline{X}^T \underline{q}] = \underline{q}^T E[\underline{X}\,\underline{X}^T]\,\underline{q},$$

dove $\underline{q}$, che è costante, esce dalla media.

Passo 3 — La varianza non è negativa.

$$0 \le \mathrm{VAR}(\underline{q}^T \underline{X}) = E[(\underline{q}^T \underline{X})^2] - \left(E[\underline{q}^T \underline{X}]\right)^2 = \underline{q}^T E[\underline{X}\,\underline{X}^T]\,\underline{q} - (\underline{q}^T \underline{\mu}_{\underline{X}})^2.$$

(Nella slide 77 manca il quadrato su $E[\underline{q}^T \underline{X}]$: la varianza è il valore quadratico medio meno il *quadrato* della media.)

Passo 4 — Anche il quadrato della media è una forma quadratica. Con lo stesso trucco del passo 2, $(\underline{q}^T \underline{\mu}_{\underline{X}})^2 = (\underline{q}^T \underline{\mu}_{\underline{X}})(\underline{\mu}_{\underline{X}}^T \underline{q}) = \underline{q}^T \underline{\mu}_{\underline{X}} \underline{\mu}_{\underline{X}}^T \underline{q}$. Raccogliendo $\underline{q}^T$ a sinistra e $\underline{q}$ a destra:

$$0 \le \underline{q}^T \left(E[\underline{X}\,\underline{X}^T] - \underline{\mu}_{\underline{X}} \underline{\mu}_{\underline{X}}^T \right) \underline{q} = \underline{q}^T \underline{\underline{C}}_{\underline{X}}\, \underline{q},$$

per il Teorema 16.1. E questo vale qualunque sia $\underline{q} \in \mathbb{R}^M$. ■

Il significato è semplice: $\underline{q}^T \underline{\underline{C}}_{\underline{X}}\, \underline{q}$ **è la varianza della combinazione lineare** $\underline{q}^T \underline{X}$, e una varianza non può essere negativa. Con $M = 2$, svolgendo i prodotti riga per colonna:

$$\underline{q}^T \underline{\underline{C}}_{\underline{X}}\, \underline{q} = [q_1, q_2] \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix} \begin{bmatrix} q_1 \\ q_2 \end{bmatrix} = [q_1, q_2] \begin{bmatrix} \sigma_1^2 q_1 + \rho\sigma_1\sigma_2 q_2 \\ \rho\sigma_1\sigma_2 q_1 + \sigma_2^2 q_2 \end{bmatrix} = q_1^2\sigma_1^2 + q_2^2\sigma_2^2 + 2q_1q_2\,\rho\,\sigma_1\sigma_2,$$

che è la formula della varianza di $q_1 X_1 + q_2 X_2$ del Capitolo 9 (Teorema 9.7).

Un vecchio risultato in veste nuova

Scegliendo $\underline{q} = [1/\sigma_1, \pm 1/\sigma_2]^T$ la forma quadratica vale $1 + 1 \pm 2\rho$, e la condizione ≥ 0 diventa $\rho \ge -1$ (con il segno $+$) e $\rho \le 1$ (con il segno $-$): è la dimostrazione di $|\rho| \le 1$ del Capitolo 9. La non negatività della matrice di covarianza generalizza quel risultato a M variabili: nessuna combinazione delle variabili può avere varianza negativa.

VETTORI GAUSSIANI

Si parte da n gaussiane indipendenti

Il punto di partenza è il caso più semplice: n variabili gaussiane statisticamente indipendenti, $X_i \sim \mathcal{N}(\mu_{X_i}, \sigma^2_{X_i})$. La loro densità congiunta si può scrivere in una forma che usa solo il vettore delle medie e la matrice di covarianza.

Teorema 16.3 — Densità di n gaussiane indipendenti

Se $X_1, \ldots, X_n$ sono gaussiane indipendenti, la densità congiunta del vettore $\underline{X} = [X_1, \ldots, X_n]^T$ è

$$f_{\underline{X}}(\underline{x}) = \frac{1}{\sqrt{(2\pi)^n \det \underline{\underline{C}}_{\underline{X}}}}\, e^{-\frac{1}{2}\left(\underline{x} - \underline{\mu}_{\underline{X}}\right)^T \underline{\underline{C}}_{\underline{X}}^{-1} \left(\underline{x} - \underline{\mu}_{\underline{X}}\right)}.$$

Dimostrazione

Passo 1 — Il prodotto delle marginali. Per l'indipendenza la densità congiunta è il prodotto delle densità:

$$f_{\underline{X}}(\underline{x}) = \prod_{i=1}^{n} f_{X_i}(x_i) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2_{X_i}}} e^{-\frac{(x_i-\mu_{X_i})^2}{2\sigma^2_{X_i}}} = \frac{1}{\sqrt{(2\pi)^n \prod_{i=1}^{n} \sigma^2_{X_i}}} e^{-\frac{1}{2}\sum_{i=1}^{n} \frac{(x_i-\mu_{X_i})^2}{\sigma^2_{X_i}}}.$$

Si sono usate due regole: il prodotto delle radici è la radice del prodotto ($\sqrt{a}\sqrt{b} = \sqrt{ab}$), e il prodotto di esponenziali è l'esponenziale della somma ($e^a e^b = e^{a+b}$).

Passo 2 — La matrice di covarianza è diagonale. Le variabili sono indipendenti, quindi incorrelate a due a due: tutte le covarianze fuori dalla diagonale sono nulle. Per una matrice diagonale determinante e inversa sono immediati:

$$\underline{\underline{C}}_{\underline{X}} = \begin{bmatrix} \sigma^2_{X_1} & 0 & \cdots & 0 \\ 0 & \sigma^2_{X_2} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma^2_{X_n} \end{bmatrix} \implies \det \underline{\underline{C}}_{\underline{X}} = \prod_{i=1}^{n} \sigma^2_{X_i}, \qquad \underline{\underline{C}}^{-1}_{\underline{X}} = \begin{bmatrix} 1/\sigma^2_{X_1} & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 1/\sigma^2_{X_n} \end{bmatrix}.$$

Il prodotto delle varianze sotto la radice è quindi $\det \underline{\underline{C}}_{\underline{X}}$.

Passo 3 — L'esponente è una forma quadratica. La somma all'esponente è una somma di quadrati pesati con i pesi $\frac{1}{\sigma^2_{X_i}}$, cioè la forma quadratica della matrice diagonale $\underline{\underline{C}}^{-1}_{\underline{X}}$ calcolata nel vettore $\underline{x} - \underline{\mu}_{\underline{X}}$:

$$\sum_{i=1}^{n} \frac{(x_i - \mu_{X_i})^2}{\sigma^2_{X_i}} = \left(\underline{x} - \underline{\mu}_{\underline{X}}\right)^T \underline{\underline{C}}^{-1}_{\underline{X}} \left(\underline{x} - \underline{\mu}_{\underline{X}}\right).$$

■

La definizione generale

La formula appena trovata non contiene più le singole variabili: solo $\underline{\mu}_{\underline{X}}$ e $\underline{\underline{C}}_{\underline{X}}$. L'idea è usarla anche quando la matrice di covarianza **non** è diagonale.

Vettore gaussiano

Un vettore aleatorio $\underline{X}$ si dice **gaussiano**, e si scrive $\underline{X} \sim \mathcal{N}(\underline{\mu}_{\underline{X}}, \underline{\underline{C}}_{\underline{X}})$, quando la sua densità congiunta ha la forma

$$f_{\underline{X}}(\underline{x}) = \frac{1}{\sqrt{(2\pi)^n \det \underline{\underline{C}}_{\underline{X}}}} e^{-\frac{1}{2}\left(\underline{x}-\underline{\mu}_{\underline{X}}\right)^T \underline{\underline{C}}^{-1}_{\underline{X}} \left(\underline{x}-\underline{\mu}_{\underline{X}}\right)},$$

anche se le componenti non sono indipendenti, cioè anche se $\underline{\underline{C}}_{\underline{X}}$ non è diagonale. Equivalentemente, n variabili aleatorie con una densità congiunta di questa forma si dicono **congiuntamente gaussiane**.

Perché la formula abbia senso, $\underline{\underline{C}}_{\underline{X}}$ deve essere invertibile ($\det \underline{\underline{C}}_{\underline{X}} \neq 0$; per il Teorema 16.2, anzi, $\det \underline{\underline{C}}_{\underline{X}} > 0$). È la naturale generalizzazione della densità di una gaussiana: con $n = 1$ la matrice di covarianza è il numero σ^2_X, il suo determinante è σ^2_X e la sua inversa è $\frac{1}{\sigma^2_X}$, e la formula ridà $\frac{1}{\sqrt{2\pi\sigma^2_X}} e^{-\frac{(x-\mu_X)^2}{2\sigma^2_X}}$.

	una variabile, $\mathcal{N}(\mu_X, \sigma^2_X)$	vettore di n variabili, $\mathcal{N}(\underline{\mu}_{\underline{X}}, \underline{\underline{C}}_{\underline{X}})$
centro	μ_X	$\underline{\mu}_{\underline{X}}$
larghezza	σ^2_X	$\underline{\underline{C}}_{\underline{X}}$
costante davanti	$\frac{1}{\sqrt{2\pi\,\sigma^2_X}}$	$\frac{1}{\sqrt{(2\pi)^n \det \underline{\underline{C}}_{\underline{X}}}}$
esponente	$-\frac{1}{2}(x-\mu_X)\frac{1}{\sigma^2_X}(x-\mu_X)$	$-\frac{1}{2}(\underline{x}-\underline{\mu}_{\underline{X}})^T \underline{\underline{C}}^{-1}_{\underline{X}} (\underline{x}-\underline{\mu}_{\underline{X}})$

La forma quadratica all'esponente misura quanto $\underline{x}$ è lontano dal centro $\underline{\mu}_{\underline{X}}$, tenendo conto delle larghezze e delle correlazioni: è il quadrato di una «distanza», e la densità è tanto più alta quanto più $\underline{x}$ è vicino al centro. I punti alla stessa distanza, cioè con la stessa densità, formano delle **ellissi** (in tre dimensioni, degli ellissoidi).

Il caso di due variabili

Con $n = 2$, $\underline{\mu}_{\underline{X}} = [\mu_1, \mu_2]^T$ e la matrice di covarianza scritta con il coefficiente di correlazione, la formula dell'inversa 2×2 del richiamo dà

$$\underline{\underline{C}}_{\underline{X}} = \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix}, \quad \det \underline{\underline{C}}_{\underline{X}} = \sigma_1^2\sigma_2^2(1-\rho^2), \quad \underline{\underline{C}}_{\underline{X}}^{-1} = \frac{1}{\sigma_1^2\sigma_2^2(1-\rho^2)} \begin{bmatrix} \sigma_2^2 & -\rho\sigma_1\sigma_2 \\ -\rho\sigma_1\sigma_2 & \sigma_1^2 \end{bmatrix}.$$

Svolgendo i prodotti all'esponente (come per la forma quadratica della sezione precedente) si ottiene la **gaussiana bivariata**:

$$f_{X_1X_2}(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left\{ -\frac{1}{2(1-\rho^2)} \left[\frac{(x_1-\mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2} \right] \right\},$$

dove $\exp\{a\}$ è un altro modo di scrivere e^a, comodo quando l'esponente è lungo. Serve $|\rho| < 1$: con $\rho = \pm 1$ il determinante si annulla, la matrice non è invertibile e le due variabili sono legate da una relazione lineare esatta (tutta la probabilità sta su una retta, e una densità nel piano non esiste).

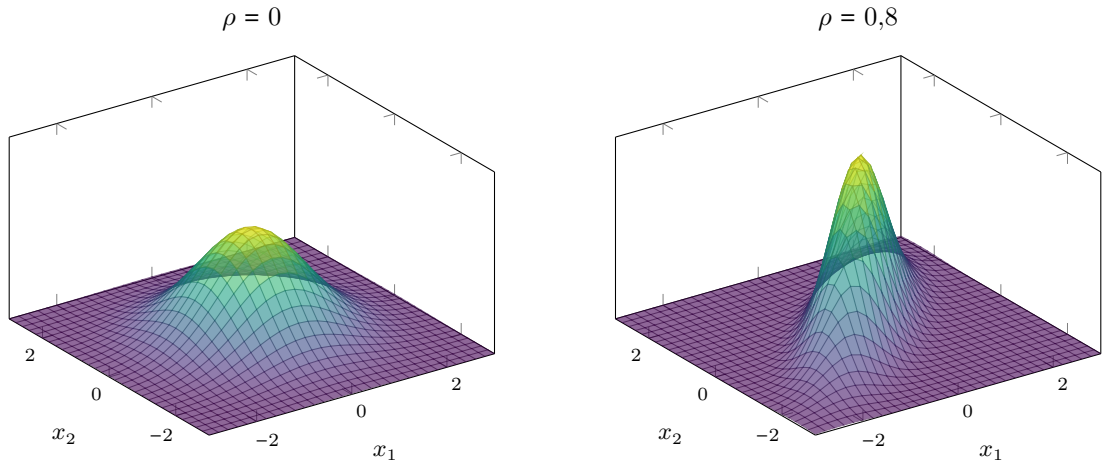


Figura 16.1: *La gaussiana bivariata con $\mu_1 = \mu_2 = 0$ e $\sigma_1 = \sigma_2 = 1$. Con $\rho = 0$ la campana è rotonda; con $\rho = 0{,}8$ è allungata lungo la bisettrice $x_2 = x_1$, e più alta, perché il volume sotto la superficie resta 1.*

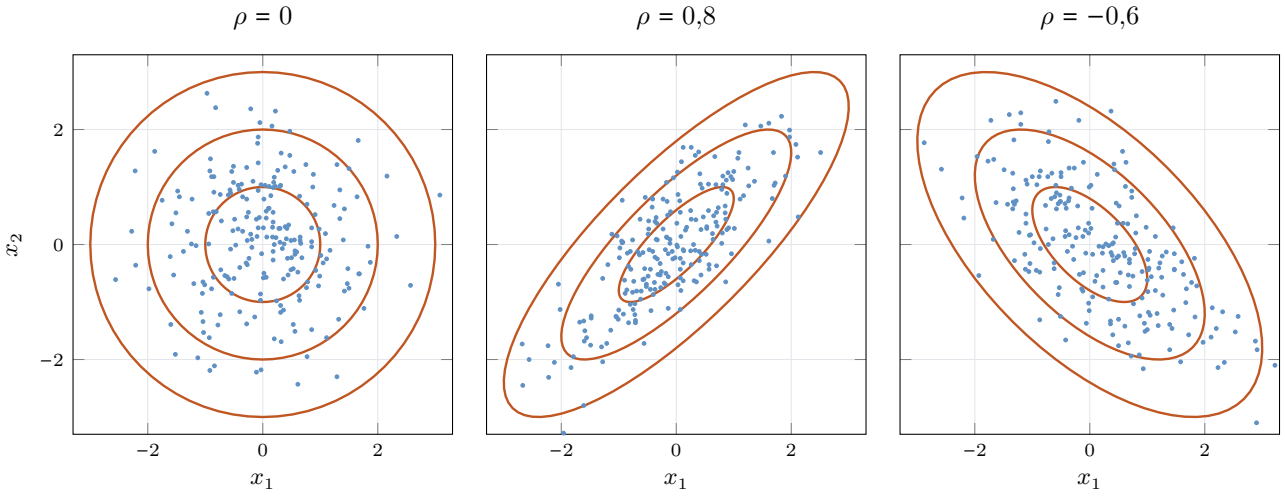


Figura 16.2: *220 punti estratti da tre gaussiane bivariate con medie nulle e varianze unitarie (simulazione), e le ellissi di uguale densità su cui la forma quadratica vale 1, 4 e 9. Con $\rho = 0$ sono circonferenze; con $\rho > 0$ si allungano lungo $x_2 = x_1$, con $\rho < 0$ lungo $x_2 = -x_1$.*

Qualunque sia ρ, le tre ellissi racchiudono una probabilità del 39%, dell'86% e del 99%: con soli 220 punti le percentuali dei pannelli si avvicinano a questi valori, senza coincidere. Per $\rho = 0$ lo si verifica con le coordinate polari, come nell'integrale di Gauss del Capitolo 15: la probabilità di cadere nel cerchio di raggio k è $\int_0^{2\pi}\int_0^k \frac{1}{2\pi} e^{-r^2/2}\, r\, \mathrm{d}r\, \mathrm{d}\theta = 1 - e^{-k^2/2}$, che per $k = 1, 2, 3$ vale 0,39, 0,86 e 0,99.

Incorrelazione e indipendenza

Nel Capitolo 9 abbiamo visto che due variabili indipendenti sono sempre incorrelate, ma che il viceversa in generale è falso. Per le variabili congiuntamente gaussiane, invece, le due cose coincidono.

Teorema 16.4 — Per le congiuntamente gaussiane, incorrelate vuol dire indipendenti

Se $X_1, \dots, X_n$ sono congiuntamente gaussiane e incorrelate a due a due, allora sono statisticamente indipendenti.

Dimostrazione

Passo 1 — La matrice è diagonale. Se le variabili sono incorrelate, tutte le covarianze fuori dalla diagonale sono nulle e $\underline{\underline{C}}_{\underline{X}}$ è diagonale.

Passo 2 — Si legge al contrario il Teorema 16.3. Con una matrice diagonale la forma quadratica è una somma di quadrati e il determinante è un prodotto di varianze; ripercorrendo all'indietro i passaggi di quella dimostrazione, la densità si spezza in un prodotto:

$$f_{\underline{X}}(\underline{x}) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma_{X_i}^2}}\, e^{-\frac{(x_i-\mu_{X_i})^2}{2\sigma_{X_i}^2}}.$$

Passo 3 — I fattori sono le marginali. Integrando rispetto a tutte le variabili tranne x_i, ogni altro fattore (una densità gaussiana, con area 1) dà 1: resta $f_{X_i}(x_i)$, che è quindi proprio l'i-esimo fattore. La densità congiunta è il prodotto delle marginali, cioè le variabili sono indipendenti.

■

Gaussiane una per una non basta

Il teorema richiede che le variabili siano *congiuntamente* gaussiane, non solo gaussiane una per una. Sia $X_1 \sim \mathcal{N}(0,1)$ e sia $X_2 = S\,X_1$, dove S vale $+1$ o -1 con probabilità $\frac{1}{2}$, indipendente da X_1. Anche X_2 è $\mathcal{N}(0,1)$: cambiare segno a caso a una campana simmetrica la lascia com'è. Le due variabili sono incorrelate, perché $E[X_1X_2] = E[S]\,E[X_1^2] = 0 \cdot 1 = 0$; eppure sono fortemente dipendenti, perché $|X_2| = |X_1|$ sempre. Il vettore $[X_1, X_2]^T$ non è gaussiano: i suoi punti stanno tutti sulle due bisettrici $x_2 = \pm x_1$, mentre la densità di un vettore gaussiano con $|\rho| < 1$ è positiva in tutto il piano.

Marginali e condizionate: si completa il quadrato

Le slide affermano che le marginali e le condizionate di un vettore gaussiano sono ancora gaussiane. Per due variabili lo si può verificare con un calcolo elementare. Prendiamo il caso standardizzato, $\mu_1 = \mu_2 = 0$ e $\sigma_1 = \sigma_2 = 1$ (quello generale si riconduce a questo standardizzando le due variabili), in cui

$$f_{X_1X_2}(x_1, x_2) = \frac{1}{2\pi\sqrt{1-\rho^2}}\, e^{-\frac{x_1^2 - 2\rho x_1 x_2 + x_2^2}{2(1-\rho^2)}}.$$

Teorema 16.5 — Marginale e condizionata della gaussiana bivariata

Nel caso standardizzato:

a) la marginale è una gaussiana standard: $X_1 \sim \mathcal{N}(0,1)$, e lo stesso vale per X_2;
b) la condizionata è gaussiana: sapendo che $X_1 = x_1$, si ha $X_2 \sim \mathcal{N}(\rho x_1,\, 1-\rho^2)$, cioè

$$f_{X_2|X_1}(x_2 \mid x_1) = \frac{1}{\sqrt{2\pi(1-\rho^2)}}\, e^{-\frac{(x_2-\rho x_1)^2}{2(1-\rho^2)}}.$$

Dimostrazione — completando il quadrato

Passo 1 — Il quadrato. Come quando si risolve un'equazione di secondo grado, si raccolgono i termini che contengono x_2 in un quadrato perfetto. Siccome $(x_2 - \rho x_1)^2 = x_2^2 - 2\rho x_1 x_2 + \rho^2 x_1^2$, basta aggiungere e togliere $\rho^2 x_1^2$:

$$x_1^2 - 2\rho x_1 x_2 + x_2^2 = (x_2 - \rho x_1)^2 + x_1^2 - \rho^2 x_1^2 = (x_2 - \rho x_1)^2 + (1 - \rho^2)\, x_1^2.$$

Passo 2 — La densità si spezza in due fattori. Dividendo per $2(1-\rho^2)$, l'esponente diventa $-\frac{(x_2-\rho x_1)^2}{2(1-\rho^2)} - \frac{x_1^2}{2}$; inoltre $2\pi\sqrt{1-\rho^2} = \sqrt{2\pi}\cdot\sqrt{2\pi(1-\rho^2)}$. Quindi

$$f_{X_1X_2}(x_1,x_2) = \underbrace{\frac{1}{\sqrt{2\pi}}\, e^{-\frac{x_1^2}{2}}}_{\mathcal{N}(0,1)\text{ in }x_1} \cdot \underbrace{\frac{1}{\sqrt{2\pi(1-\rho^2)}}\, e^{-\frac{(x_2-\rho x_1)^2}{2(1-\rho^2)}}}_{\mathcal{N}(\rho x_1,\,1-\rho^2)\text{ in }x_2}.$$

Passo 3 — La marginale. Per marginalizzare si integra rispetto a x_2. Il primo fattore non dipende da x_2 ed esce dall'integrale; il secondo, come funzione di x_2, è una densità gaussiana (di media ρx_1), quindi ha area 1:

$$f_{X_1}(x_1) = \int_{-\infty}^{\infty} f_{X_1X_2}(x_1,x_2)\,\mathrm{d}x_2 = \frac{1}{\sqrt{2\pi}}\, e^{-\frac{x_1^2}{2}} \cdot 1.$$

Per X_2 si ripete il calcolo scambiando i ruoli: l'espressione è simmetrica in x_1 e x_2.

Passo 4 — La condizionata. Per definizione $f_{X_2|X_1}(x_2 \mid x_1) = \frac{f_{X_1X_2}(x_1,x_2)}{f_{X_1}(x_1)}$: dividendo per il primo fattore resta il secondo.

■

La densità condizionata dice due cose. La **media condizionata** $E[X_2 \mid X_1 = x_1] = \rho x_1$ è una retta: sapendo che X_1 è grande, ci si aspetta che anche X_2 lo sia (se $\rho > 0$), ma un po' meno, perché $|\rho| < 1$. La **varianza condizionata** $1 - \rho^2$ è più piccola della varianza 1 di X_2 e non dipende da x_1: conoscere X_1 riduce l'incertezza su X_2, tanto più quanto più $|\rho|$ è vicino a 1. Con $\rho = 0$ la condizionata coincide con la marginale: conoscere X_1 non serve a niente, come deve essere per variabili indipendenti.

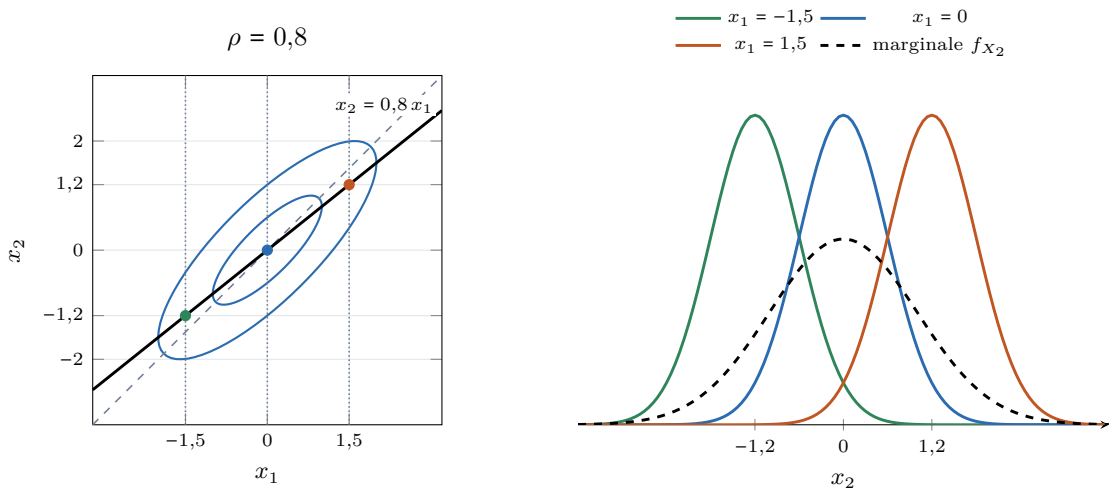


Figura 16.3: *A sinistra: le ellissi della gaussiana bivariata con $\rho = 0{,}8$ e la retta delle medie condizionate $x_2 = 0{,}8\,x_1$ (tratteggiata la bisettrice). A destra: le densità condizionate $f_{X_2|X_1}(x_2 \mid x_1)$ per tre valori di x_1, tutte con varianza $1 - 0{,}8^2 = 0{,}36$ e centrate sulla retta, e la marginale $\mathcal{N}(0,1)$, più larga.*

Le proprietà dei vettori gaussiani

Le slide elencano le proprietà che rendono i vettori gaussiani così comodi.

1. **Bastano medie e covarianze.** Un vettore gaussiano è completamente caratterizzato dal vettore delle medie e dalla matrice di covarianza: nella formula della densità non compare nient'altro. Per i vettori gaussiani, quindi, la caratterizzazione sintetica implica quella completa; in generale è vero solo il contrario (dalla densità si ricavano medie e covarianze, ma non viceversa).
2. **Chiusura rispetto alle trasformazioni lineari.** Qualsiasi trasformazione lineare di un vettore gaussiano è ancora un vettore gaussiano, con opportuno vettore delle medie e opportuna matrice di covarianza.

3. **Calcoli facili.** Le medie e le covarianze dell'uscita di una trasformazione lineare si calcolano con due formule semplici (le vediamo nella prossima sezione); grazie alla proprietà 2, per un vettore gaussiano questo dà la caratterizzazione completa dell'uscita. Per vettori non gaussiani si ottiene con la stessa facilità solo la caratterizzazione sintetica, mentre quella completa è spesso enormemente complicata.
4. **Sottoinsiemi.** Un qualsiasi sottoinsieme di variabili congiuntamente gaussiane è ancora un vettore gaussiano. In particolare ogni singola componente X_i è gaussiana, con media μ_{X_i} e varianza $\sigma^2_{X_i}$ (per due variabili lo abbiamo appena dimostrato).
5. **Condizionamenti.** La densità di un sottoinsieme di variabili congiuntamente gaussiane, condizionata a un qualsiasi sottoinsieme delle rimanenti, è ancora gaussiana, con opportune medie e covarianze condizionate (per due variabili: $\mathcal{N}(\rho x_1, 1-\rho^2)$).
6. **Incorrelazione e indipendenza coincidono** (Teorema 16.4).

Trasformazioni lineari di vettori gaussiani

Cominciamo dal caso più semplice: una combinazione lineare di due variabili.

Teorema 16.6 — Combinazione lineare di due variabili congiuntamente gaussiane

Siano X_1 e X_2 congiuntamente gaussiane, con medie μ_1 e μ_2, varianze σ_1^2 e σ_2^2 e coefficiente di correlazione ρ_{12}, e sia $Z = a_1X_1 + a_2X_2$. Allora $Z \sim \mathcal{N}(\mu_Z, \sigma_Z^2)$, con

$$\mu_Z = a_1\mu_1 + a_2\mu_2, \qquad \sigma_Z^2 = a_1^2\sigma_1^2 + a_2^2\sigma_2^2 + 2a_1a_2\,\sigma_1\sigma_2\,\rho_{12}.$$

Dimostrazione

Passo 1 — La media. Per la linearità della media: $\mu_Z = E[a_1X_1 + a_2X_2] = a_1\mu_1 + a_2\mu_2$.

Passo 2 — La varianza. Si raccolgono gli scarti dalla media e si sviluppa il quadrato del binomio:

$$\begin{aligned}\sigma_Z^2 &= E[(Z-\mu_Z)^2] = E\left[(a_1X_1 + a_2X_2 - a_1\mu_1 - a_2\mu_2)^2\right] = E\left[(a_1(X_1-\mu_1) + a_2(X_2-\mu_2))^2\right] \\ &= E\left[a_1^2(X_1-\mu_1)^2 + a_2^2(X_2-\mu_2)^2 + 2a_1a_2(X_1-\mu_1)(X_2-\mu_2)\right] \\ &= a_1^2\sigma_1^2 + a_2^2\sigma_2^2 + 2a_1a_2\,COV(X_1,X_2) = a_1^2\sigma_1^2 + a_2^2\sigma_2^2 + 2a_1a_2\,\sigma_1\sigma_2\,\rho_{12}.\end{aligned}$$

Fin qui non si è usato nulla di gaussiano: sono le formule del Capitolo 9, valide per qualsiasi coppia.

Passo 3 — La gaussianità. Che Z sia gaussiana è la proprietà di chiusura; la dimostriamo alla fine della sezione, come conseguenza del teorema seguente.

■

Il caso generale è una trasformazione lineare qualsiasi: m combinazioni lineari delle n variabili, più delle costanti.

Teorema 16.7 — Trasformazione lineare di un vettore gaussiano

Sia $\underline{X} \sim \mathcal{N}(\underline{\mu}_{\underline{X}}, \underline{\underline{C}}_{\underline{X}})$ un vettore gaussiano $n \times 1$, e sia

$$\underbrace{\underline{Z}}_{m\times 1} = \underbrace{\underline{\underline{A}}}_{m\times n}\,\underbrace{\underline{X}}_{n\times 1} + \underbrace{\underline{b}}_{m\times 1},$$

con $\underline{\underline{A}}$ e $\underline{b}$ costanti. Allora $\underline{Z} \sim \mathcal{N}(\underline{\mu}_{\underline{Z}}, \underline{\underline{C}}_{\underline{Z}})$, con

$$\underbrace{\underline{\mu}_{\underline{Z}}}_{m\times 1} = \underbrace{\underline{\underline{A}}}_{m\times n}\,\underbrace{\underline{\mu}_{\underline{X}}}_{n\times 1} + \underbrace{\underline{b}}_{m\times 1}, \qquad \underbrace{\underline{\underline{C}}_{\underline{Z}}}_{m\times m} = \underbrace{\underline{\underline{A}}}_{m\times n}\,\underbrace{\underline{\underline{C}}_{\underline{X}}}_{n\times n}\,\underbrace{\underline{\underline{A}}^T}_{n\times m}.$$

Le formule per $\underline{\mu}_{\underline{Z}}$ e $\underline{\underline{C}}_{\underline{Z}}$ valgono per qualsiasi vettore aleatorio $\underline{X}$, gaussiano o no.

Dimostrazione

Passo 1 — La media. Ogni componente di $\underline{Z}$ è una combinazione lineare delle X_j più una costante, $Z_i = \sum_j a_{ij} X_j + b_i$. Per la linearità della media $E[Z_i] = \sum_j a_{ij}\mu_{X_j} + b_i$, cioè $\underline{\mu}_{\underline{Z}} = \underline{\underline{A}}\,\underline{\mu}_{\underline{X}} + \underline{b}$.

Passo 2 — Lo scarto dalla media. La costante $\underline{b}$ si cancella: $\underline{Z} - \underline{\mu}_{\underline{Z}} = \underline{\underline{A}}\,\underline{X} + \underline{b} - \underline{\underline{A}}\,\underline{\mu}_{\underline{X}} - \underline{b} = \underline{\underline{A}}(\underline{X} - \underline{\mu}_{\underline{X}})$.

Passo 3 — La covarianza. Per il trasposto di un prodotto, $\left(\underline{\underline{A}}(\underline{X} - \underline{\mu}_{\underline{X}})\right)^T = (\underline{X} - \underline{\mu}_{\underline{X}})^T \underline{\underline{A}}^T$, e le matrici costanti escono dalla media (una a sinistra e una a destra):

$$\underline{\underline{C}}_{\underline{Z}} = E\left[(\underline{Z} - \underline{\mu}_{\underline{Z}})(\underline{Z} - \underline{\mu}_{\underline{Z}})^T\right] = E\left[\underline{\underline{A}}(\underline{X} - \underline{\mu}_{\underline{X}})(\underline{X} - \underline{\mu}_{\underline{X}})^T \underline{\underline{A}}^T\right] = \underline{\underline{A}}\,E\left[(\underline{X} - \underline{\mu}_{\underline{X}})(\underline{X} - \underline{\mu}_{\underline{X}})^T\right]\underline{\underline{A}}^T = \underline{\underline{A}}\,\underline{\underline{C}}_{\underline{X}}\,\underline{\underline{A}}^T.$$

Passo 4 — La gaussianità, con $m = n$ e $\underline{\underline{A}}$ invertibile. Si ragiona come per $Y = aX + b$ nel Capitolo 12. Ogni $\underline{z}$ viene da un solo $\underline{x} = \underline{\underline{A}}^{-1}(\underline{z} - \underline{b})$. Una scatolina attorno a $\underline{x}$ viene trasformata in una scatolina attorno a $\underline{z}$ con volume $|\det \underline{\underline{A}}|$ volte più grande (richiamo), che contiene la stessa probabilità; quindi la densità, che è una probabilità per unità di volume, si divide per $|\det \underline{\underline{A}}|$:

$$f_{\underline{Z}}(\underline{z}) = \frac{1}{|\det \underline{\underline{A}}|}\, f_{\underline{X}}\left(\underline{\underline{A}}^{-1}(\underline{z} - \underline{b})\right).$$

Nell'esponente compare $\underline{x} - \underline{\mu}_{\underline{X}} = \underline{\underline{A}}^{-1}(\underline{z} - \underline{b}) - \underline{\underline{A}}^{-1}\underline{\underline{A}}\,\underline{\mu}_{\underline{X}} = \underline{\underline{A}}^{-1}(\underline{z} - \underline{\mu}_{\underline{Z}})$, e la forma quadratica diventa

$$(\underline{z} - \underline{\mu}_{\underline{Z}})^T (\underline{\underline{A}}^{-1})^T \underline{\underline{C}}_{\underline{X}}^{-1} \underline{\underline{A}}^{-1}(\underline{z} - \underline{\mu}_{\underline{Z}}) = (\underline{z} - \underline{\mu}_{\underline{Z}})^T \left(\underline{\underline{A}}\,\underline{\underline{C}}_{\underline{X}}\,\underline{\underline{A}}^T\right)^{-1} (\underline{z} - \underline{\mu}_{\underline{Z}}) = (\underline{z} - \underline{\mu}_{\underline{Z}})^T \underline{\underline{C}}_{\underline{Z}}^{-1}(\underline{z} - \underline{\mu}_{\underline{Z}}),$$

perché l'inversa di un prodotto è il prodotto delle inverse in ordine inverso: $(\underline{\underline{A}}\,\underline{\underline{C}}_{\underline{X}}\,\underline{\underline{A}}^T)^{-1} = (\underline{\underline{A}}^T)^{-1}\underline{\underline{C}}_{\underline{X}}^{-1}\underline{\underline{A}}^{-1}$. Infine $\det \underline{\underline{C}}_{\underline{Z}} = \det \underline{\underline{A}} \cdot \det \underline{\underline{C}}_{\underline{X}} \cdot \det \underline{\underline{A}}^T = (\det \underline{\underline{A}})^2 \det \underline{\underline{C}}_{\underline{X}}$, quindi $|\det \underline{\underline{A}}|\sqrt{(2\pi)^n \det \underline{\underline{C}}_{\underline{X}}} = \sqrt{(2\pi)^n \det \underline{\underline{C}}_{\underline{Z}}}$. Mettendo insieme, $f_{\underline{Z}}$ ha proprio la forma gaussiana, con media $\underline{\mu}_{\underline{Z}}$ e covarianza $\underline{\underline{C}}_{\underline{Z}}$.

Passo 5 — Meno uscite che ingressi ($m < n$). Si aggiungono ad $\underline{\underline{A}}$ delle righe in modo da renderla quadrata e invertibile: il vettore allungato è gaussiano per il passo precedente, e $\underline{Z}$, che ne è un sottoinsieme, è gaussiano per la proprietà dei sottoinsiemi. (Se invece $m > n$, o $\underline{\underline{A}}$ non è invertibile, si trova $\det \underline{\underline{C}}_{\underline{Z}} = 0$: il vettore $\underline{Z}$ sta tutto su una retta o su un piano e una densità non si può scrivere. È un caso «degenere» che non ci servirà.)

■

Ora possiamo completare la dimostrazione del Teorema 16.6. La combinazione $Z = a_1 X_1 + a_2 X_2$ è il caso $m = 1$, $n = 2$, $\underline{\underline{A}} = [a_1, a_2]$, $\underline{b} = 0$, e la formula della covarianza ridà la varianza (è la forma quadratica della sezione precedente):

$$\sigma_Z^2 = [a_1, a_2]\begin{bmatrix} \sigma_1^2 & \rho_{12}\sigma_1\sigma_2 \\ \rho_{12}\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix}\begin{bmatrix} a_1 \\ a_2 \end{bmatrix} = a_1^2\sigma_1^2 + a_2^2\sigma_2^2 + 2a_1a_2\,\sigma_1\sigma_2\,\rho_{12}.$$

Per la gaussianità, se $a_1 \neq 0$ si aggiunge la riga $[0, 1]$, che rende la matrice quadrata e invertibile:

$$\begin{bmatrix} Z \\ X_2 \end{bmatrix} = \begin{bmatrix} a_1 & a_2 \\ 0 & 1 \end{bmatrix}\begin{bmatrix} X_1 \\ X_2 \end{bmatrix}, \qquad \det\begin{bmatrix} a_1 & a_2 \\ 0 & 1 \end{bmatrix} = a_1 \cdot 1 - a_2 \cdot 0 = a_1 \neq 0.$$

Il vettore $[Z, X_2]^T$ è gaussiano (passo 4) e quindi Z, che ne è una componente, è gaussiana (lo garantisce il Teorema 16.5, dopo aver standardizzato). Se $a_1 = 0$, $Z = a_2 X_2$ è una gaussiana moltiplicata per una costante, che è gaussiana per il Capitolo 15.

Esempio 16.2 — Somma e differenza di due rumori indipendenti

Due campioni di rumore X_1 e X_2 sono gaussiani indipendenti, entrambi $\mathcal{N}(0, \sigma^2)$: il vettore $\underline{X}$ è gaussiano con $\underline{\mu}_{\underline{X}} = \underline{0}$ e $\underline{\underline{C}}_{\underline{X}} = \sigma^2 \underline{\underline{I}}$. Calcoliamo somma e differenza:

$$\underline{Z} = \begin{bmatrix} X_1 + X_2 \\ X_1 - X_2 \end{bmatrix} = \underbrace{\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}}_{\underline{\underline{A}}} \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}, \qquad \underline{\underline{C}}_{\underline{Z}} = \underline{\underline{A}} \, (\sigma^2 \underline{\underline{I}}) \, \underline{\underline{A}}^T = \sigma^2 \underline{\underline{A}} \, \underline{\underline{A}}^T = \sigma^2 \begin{bmatrix} 1 \cdot 1 + 1 \cdot 1 & 1 \cdot 1 + 1 \cdot (-1) \\ 1 \cdot 1 + (-1) \cdot 1 & 1 \cdot 1 + (-1)(-1) \end{bmatrix} = \begin{bmatrix} 2\sigma^2 & 0 \\ 0 & 2\sigma^2 \end{bmatrix}.$$

La somma e la differenza sono gaussiane con varianza $2\sigma^2$ e sono **incorrelate**; essendo congiuntamente gaussiane (Teorema 16.7), sono anche **indipendenti** (Teorema 16.4). Conoscere la somma dei due rumori non dice nulla sulla loro differenza! Geometricamente, $\underline{\underline{A}}$ non deforma le figure: le ribalta come uno specchio (attorno a una retta inclinata) e le ingrandisce di $\sqrt{2}$. Una campana rotonda, ribaltata e ingrandita, resta rotonda. Con altre distribuzioni non succede: se X_1 e X_2 sono uniformi su $[0, 1]$, somma e differenza sono ancora incorrelate (la covarianza è $\sigma^2_{X_1} - \sigma^2_{X_2} = 0$), ma non indipendenti: se la somma è vicina a 0, entrambe le variabili sono vicine a 0, e anche la differenza lo è.

Esempio 16.3 — Come si costruisce un vettore gaussiano correlato

Un calcolatore sa generare numeri gaussiani standard indipendenti, W_1 e W_2. Come si ottiene una coppia gaussiana con varianze unitarie e correlazione ρ assegnata? Si prende

$$\begin{bmatrix} X_1 \\ X_2 \end{bmatrix} = \underbrace{\begin{bmatrix} 1 & 0 \\ \rho & \sqrt{1-\rho^2} \end{bmatrix}}_{\underline{\underline{A}}} \begin{bmatrix} W_1 \\ W_2 \end{bmatrix}, \qquad \text{cioè} \qquad X_1 = W_1, \quad X_2 = \rho W_1 + \sqrt{1-\rho^2} \, W_2.$$

Il vettore $\underline{X}$ è gaussiano (trasformazione lineare di un vettore gaussiano), con media nulla e

$$\underline{\underline{C}}_{\underline{X}} = \underline{\underline{A}} \, \underline{\underline{I}} \, \underline{\underline{A}}^T = \begin{bmatrix} 1 & 0 \\ \rho & \sqrt{1-\rho^2} \end{bmatrix} \begin{bmatrix} 1 & \rho \\ 0 & \sqrt{1-\rho^2} \end{bmatrix} = \begin{bmatrix} 1 & \rho \\ \rho & \rho^2 + 1 - \rho^2 \end{bmatrix} = \begin{bmatrix} 1 & \rho \\ \rho & 1 \end{bmatrix},$$

proprio la matrice voluta. È così che sono stati generati i punti delle figure di questo capitolo. Si ritrova anche la condizionata del Teorema 16.5: sapendo che $X_1 = W_1 = x_1$, si ha $X_2 = \rho x_1 + \sqrt{1-\rho^2} \, W_2$, una gaussiana di media ρx_1 e varianza $1 - \rho^2$ (W_2 è indipendente da W_1).

Esempio 16.4 — La media di n campioni di rumore

Siano $X_1, \ldots, X_n$ gaussiane indipendenti, tutte $\mathcal{N}(\mu, \sigma^2)$ (per esempio n misure della stessa grandezza, disturbate da rumore). La loro media aritmetica è una trasformazione lineare con $m = 1$:

$$\bar{X} = \frac{X_1 + \cdots + X_n}{n} = \underbrace{\left[\tfrac{1}{n}, \tfrac{1}{n}, \ldots, \tfrac{1}{n}\right]}_{\underline{\underline{A}} \ (1 \times n)} \underline{X}.$$

Quindi $\bar{X}$ è gaussiana, con media $\underline{\underline{A}} \underline{\mu}_{\underline{X}} = n \cdot \frac{\mu}{n} = \mu$ e varianza

$$\underline{\underline{A}} \, (\sigma^2 \underline{\underline{I}}) \, \underline{\underline{A}}^T = \sigma^2 \sum_{i=1}^{n} \frac{1}{n^2} = \frac{\sigma^2}{n}.$$

Mediando n misure la deviazione standard del rumore si divide per $\sqrt{n}$: con 100 misure l'errore tipico diventa dieci volte più piccolo. Ritroveremo questa media, la *media campione*, all'inizio del terzo pacchetto di slide.

In sintesi

- Un **vettore aleatorio** $\underline{X} = [X_1, \ldots, X_n]^T$ ha vettore delle medie $\underline{\mu}_{\underline{X}} = E[\underline{X}]$, matrice di correlazione $\underline{\underline{R}}_{\underline{X}} = E[\underline{X}\,\underline{X}^T]$ e matrice di covarianza $\underline{\underline{C}}_{\underline{X}} = E[(\underline{X} - \underline{\mu}_{\underline{X}})(\underline{X} - \underline{\mu}_{\underline{X}})^T] = \underline{\underline{R}}_{\underline{X}} - \underline{\mu}_{\underline{X}}\underline{\mu}_{\underline{X}}^T$, entrambe simmetriche; sulla diagonale di $\underline{\underline{C}}_{\underline{X}}$ ci sono le varianze. $(\underline{\mu}_{\underline{X}}, \underline{\underline{C}}_{\underline{X}})$ è la caratterizzazione sintetica.
- $\underline{\underline{C}}_{\underline{X}}$ è **definita non negativa**: $\underline{q}^T \underline{\underline{C}}_{\underline{X}} \underline{q} = \mathrm{VAR}(\underline{q}^T \underline{X}) \geq 0$.
- **Vettore gaussiano**, $\underline{X} \sim \mathcal{N}(\underline{\mu}_{\underline{X}}, \underline{\underline{C}}_{\underline{X}})$:

$$f_{\underline{X}}(\underline{x}) = \frac{1}{\sqrt{(2\pi)^n \det \underline{\underline{C}}_{\underline{X}}}}\, e^{-\frac{1}{2}(\underline{x}-\underline{\mu}_{\underline{X}})^T \underline{\underline{C}}_{\underline{X}}^{-1} (\underline{x}-\underline{\mu}_{\underline{X}})};$$

  con componenti indipendenti $\underline{\underline{C}}_{\underline{X}}$ è diagonale. Le curve di uguale densità sono ellissi.
- Per le congiuntamente gaussiane **incorrelate $\Leftrightarrow$ indipendenti**; marginali e condizionate sono gaussiane (bivariata standard: $X_2 \mid X_1 = x_1 \sim \mathcal{N}(\rho x_1, 1 - \rho^2)$).
- **Trasformazioni lineari**: $\underline{Z} = \underline{\underline{A}}\,\underline{X} + \underline{b}$ ha $\underline{\mu}_{\underline{Z}} = \underline{\underline{A}}\,\underline{\mu}_{\underline{X}} + \underline{b}$ e $\underline{\underline{C}}_{\underline{Z}} = \underline{\underline{A}}\,\underline{\underline{C}}_{\underline{X}}\,\underline{\underline{A}}^T$, ed è gaussiano se $\underline{X}$ lo è. Per due variabili: $\sigma_Z^2 = a_1^2\sigma_1^2 + a_2^2\sigma_2^2 + 2a_1a_2\sigma_1\sigma_2\rho_{12}$.

Processi aleatori

Un segnale che arriva a un ricevitore non è un singolo numero, e nemmeno un vettore di pochi numeri: è una successione di valori che continua nel tempo. Il rumore in un circuito, la sequenza di bit trasmessa da un modem, la temperatura misurata ogni giorno, il prezzo di un'azione ogni minuto sono tutte **successioni aleatorie**: non si possono prevedere esattamente, ma hanno delle regolarità statistiche. Lo strumento per descriverle è il **processo aleatorio**, un esperimento il cui risultato non è un numero ma un'intera successione. In questo capitolo, l'ultimo del secondo pacchetto di slide, ne diamo la definizione nel caso del tempo discreto, vediamo come si caratterizza e introduciamo la nozione più importante, la **stazionarietà**: l'idea che le proprietà statistiche del processo non cambino nel tempo.

Richiami: la caratterizzazione completa

Si consideri uno spazio di probabilità arbitrario (Ω, S, P): Ω è lo spazio campione, S è una σ-algebra di eventi di Ω (Capitolo 4) e $P : S \to [0,1]$ è una legge di probabilità. Ricordiamo che una variabile aleatoria è una funzione

$$X : \omega \in \Omega \longmapsto X(\omega) \in \mathcal{X} \subseteq \mathbb{R},$$

discreta se tale è l'alfabeto $\mathcal{X}$, continua se tale è $\mathcal{X}$. Una coppia di variabili aleatorie è l'applicazione $(X, Y) : \omega \in \Omega \longmapsto (X(\omega), Y(\omega)) \in \mathcal{X} \times \mathcal{Y} \subseteq \mathbb{R}^2$, e una m-pla, ovvia generalizzazione della coppia, si scrive come vettore aleatorio (Capitolo 16):

$$\underline{X}(\omega) = [X_1(\omega), X_2(\omega), \ldots, X_m(\omega)]^T \in \mathcal{X}_1 \times \mathcal{X}_2 \times \cdots \times \mathcal{X}_m \subseteq \mathbb{R}^m.$$

Una variabile, una coppia o un vettore si dicono **completamente caratterizzati** (statisticamente) quando se ne conosce la legge, in una delle forme equivalenti della tabella: la CDF, che esiste sempre, oppure la pmf nel caso discreto o la PDF nel caso continuo. La PDF si ottiene derivando la CDF una volta rispetto a ciascuna variabile.

	CDF (sempre)	pmf (caso discreto)	PDF (caso continuo)
X	$F_X(x) = P(X \le x)$	$p_X(x) = P(X = x)$	$f_X(x) = \dfrac{\mathrm{d}}{\mathrm{d}x} F_X(x)$
(X, Y)	$F_{X,Y}(x,y) = P(X \le x, Y \le y)$	$p_{X,Y}(x,y) = P(X = x, Y = y)$	$f_{X,Y}(x,y) = \dfrac{\partial^2 F_{X,Y}(x,y)}{\partial x \, \partial y}$
$\underline{X}$	$F_{\underline{X}}(\underline{x}) = P(X_1 \le x_1, \ldots, X_m \le x_m)$	$p_{\underline{X}}(\underline{x}) = P(X_1 = x_1, \ldots, X_m = x_m)$	$f_{\underline{X}}(\underline{x}) = \dfrac{\partial^m F_{\underline{X}}(\underline{x})}{\partial x_1 \cdots \partial x_m}$

La regola della catena per i vettori aleatori

Nel Capitolo 8 abbiamo visto la regola della catena per tre variabili discrete. Per i processi ci servirà con un numero qualsiasi di variabili.

Teorema 17.1 — Regola della catena per i vettori aleatori

Per un vettore aleatorio discreto $\underline{X} = [X_1, \dots, X_m]^T$:

$$p_{\underline{X}}(\underline{x}) = P(X_1 = x_1)\, P(X_2 = x_2 \mid X_1 = x_1)\, P(X_3 = x_3 \mid X_1 = x_1, X_2 = x_2) \times \cdots \times P(X_m = x_m \mid X_1 = x_1, \dots, X_{m-1} = x_{m-1}),$$

cioè, in forma compatta,

$$p_{\underline{X}}(\underline{x}) = \prod_{i=1}^{m} p_{X_i \mid X_1, \dots, X_{i-1}}(x_i \mid x_1, \dots, x_{i-1}),$$

dove per $i = 1$ si conviene che $p_{X_1 \mid X_0}(x_1 \mid x_0) = p_{X_1}(x_1)$ (non c'è nessuna condizione). Per i vettori continui vale lo stesso con le densità: $f_{\underline{X}}(\underline{x}) = \prod_{i=1}^{m} f_{X_i \mid X_1, \dots, X_{i-1}}(x_i \mid x_1, \dots, x_{i-1})$, con $f_{X_1 \mid X_0}(x_1 \mid x_0) = f_{X_1}(x_1)$.

Dimostrazione — si stacca una variabile alla volta

Passo 1 — La probabilità composta. Si parte da $P(A \cap B) = P(A \mid B)\, P(B)$, la legge della probabilità composta del Capitolo 4 (che le slide chiamano qui legge di Bayes). Con $A = \{X_2 = x_2, \dots, X_m = x_m\}$ e $B = \{X_1 = x_1\}$:

$$p_{\underline{X}}(\underline{x}) = P(X_2 = x_2, \dots, X_m = x_m \mid X_1 = x_1)\, P(X_1 = x_1).$$

Passo 2 — Si ripete dentro il condizionamento. La probabilità condizionata a $\{X_1 = x_1\}$ è una probabilità (Teorema 4.6), quindi si può staccare allo stesso modo la variabile X_2:

$$p_{\underline{X}}(\underline{x}) = P(X_3 = x_3, \dots, X_m = x_m \mid X_1 = x_1, X_2 = x_2)\, P(X_2 = x_2 \mid X_1 = x_1)\, P(X_1 = x_1).$$

Passo 3 — Si itera. Ogni volta una variabile passa dal gruppo «da calcolare» al gruppo «condizionante»; dopo $m - 1$ passi il gruppo da calcolare contiene solo X_m, e si ottiene il prodotto dell'enunciato.

Passo 4 — Il caso continuo. Si ripete lo stesso ragionamento con la definizione di densità condizionata del Capitolo 14, «congiunta uguale condizionata per marginale», applicata ogni volta a un gruppo di variabili.

■

La regola della catena descrive il vettore **un pezzo alla volta**, nell'ordine in cui le variabili «escono»: prima X_1, poi X_2 sapendo X_1, poi X_3 sapendo le prime due, e così via. È il modo naturale di descrivere un segnale che si svolge nel tempo, campione dopo campione. Due casi particolari li conosciamo già.

- Se le variabili sono **indipendenti**, ogni condizionata coincide con la marginale e la regola diventa il prodotto delle marginali, $p_{\underline{X}}(\underline{x}) = \prod_i p_{X_i}(x_i)$.
- Nella gaussiana bivariata del Capitolo 16 abbiamo trovato $f_{X_1 X_2}(x_1, x_2) = f_{X_1}(x_1)\, f_{X_2 \mid X_1}(x_2 \mid x_1)$, con la marginale $\mathcal{N}(0, 1)$ e la condizionata $\mathcal{N}(\rho x_1, 1 - \rho^2)$: è la regola della catena con $m = 2$.

Esempio 17.1 — Tre assi di fila

Da un mazzo di 52 carte se ne estraggono tre, senza reinserimento; sia $X_i = 1$ se la i-esima carta è un asso e $X_i = 0$ altrimenti. Qual è la probabilità di estrarre tre assi? Le variabili non sono indipendenti (ogni asso estratto rende meno probabile il successivo), ma con la regola della catena ogni fattore è facile:

$$P(X_1 = 1, X_2 = 1, X_3 = 1) = \underbrace{\frac{4}{52}}_{P(X_1=1)} \cdot \underbrace{\frac{3}{51}}_{P(X_2=1 \mid X_1=1)} \cdot \underbrace{\frac{2}{50}}_{P(X_3=1 \mid X_1=1, X_2=1)} = \frac{24}{132\,600} \approx 1{,}8 \cdot 10^{-4}.$$

Ogni condizionata si calcola guardando il mazzo rimasto: dopo un asso restano 3 assi su 51 carte, dopo due assi 2 su 50.

PROCESSI ALEATORI A TEMPO DISCRETO

Processo aleatorio a tempo discreto

Si definisce **processo aleatorio tempo-discreto** un'applicazione che a ogni elemento dello spazio campione fa corrispondere una successione:

$$X : \omega \in \Omega \longmapsto \{X(n,\omega)\}_{n\in\mathbb{Z}},$$

dove $\mathbb{Z}$ è l'insieme dei numeri interi relativi (positivi, negativi e zero), che fanno da istanti di tempo.

Una variabile aleatoria associa a ogni risultato dell'esperimento un numero; un processo aleatorio gli associa un'**intera successione** di numeri, uno per ogni istante. È quindi una funzione di due variabili, n e ω, e la si può guardare in due modi.

- **Fissato il risultato** ω (in orizzontale nella figura): $X(n,\omega)$ è una successione di numeri ben precisi, non più aleatoria, che si chiama **realizzazione** del processo. È il segnale che si osserva davvero in una prova, per esempio quello che compare sullo schermo di un oscilloscopio. Per ogni ω il processo si realizza in una sequenza di valori che stanno in un certo intervallo (anche infinito).
- **Fissato l'istante** $n = n_0$ (in verticale): al variare di ω, $X(n_0,\omega)$ assume valori diversi, uno per ogni elemento dello spazio campione: è una **variabile aleatoria**. È come «campionare verticalmente» il processo: si guarda il valore all'istante n_0 in tutte le realizzazioni possibili.

Come per le variabili aleatorie, d'ora in poi si omette ω e si scrive semplicemente $X(n)$.

Per fissare le idee useremo spesso la **sinusoide con fase a caso**, $X(n) = A\cos(2\pi f_0 n + \Phi)$, dove la fase Φ è scelta a caso, uniformemente su un periodo. Ogni realizzazione è una sinusoide perfetta: il caso decide soltanto da dove parte. È il modello di un oscillatore che si accende in un istante qualsiasi.

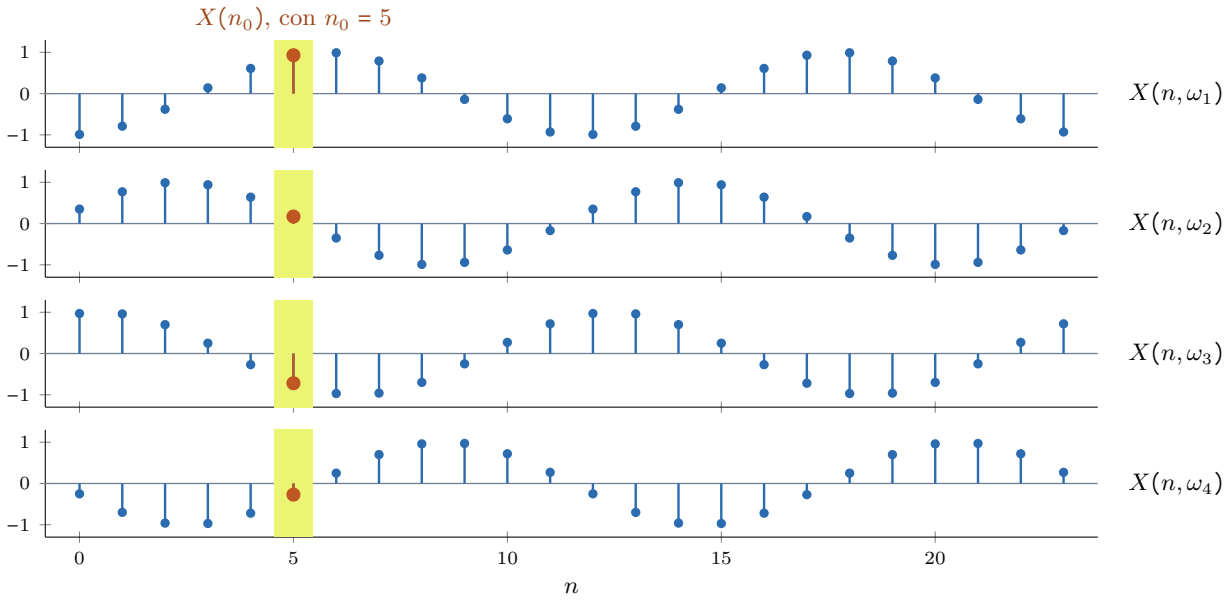


Figura 17.1: *Quattro realizzazioni della sinusoide con fase a caso, con $A = 1$ e $f_0 = \frac{1}{12}$ (un periodo ogni 12 campioni). In orizzontale, ogni riga è una realizzazione: una successione di numeri. In verticale, i valori all'istante $n_0 = 5$ (in rosso, nella fascia gialla) sono quattro determinazioni della variabile aleatoria $X(5)$.*

La variabile aleatoria $X(n_0)$ ha una sua densità, che in generale dipende dall'istante n_0. La si indica con $f_{X(n)}(x;n)$, dove il punto e virgola separa la variabile x dall'istante n, che fa da parametro.

Stazionarietà del primo ordine

Un processo aleatorio si dice **caratterizzato al primo ordine** se ne è nota la PDF $f_{X(n)}(x;n)$ per ogni n. Se questa PDF non dipende dall'istante considerato, $f_{X(n)}(x;n) = f_X(x)$ per ogni n, il processo si dice **stazionario del primo ordine**: in tal caso basta assegnare un'unica PDF del primo ordine.

Esempio 17.2 — La sinusoide con fase a caso è stazionaria del primo ordine

Scriviamo la fase come $\Phi = 2\pi U$, con $U \sim \mathcal{U}\left(-\frac{1}{2}, \frac{1}{2}\right)$: così Φ è uniforme su un periodo intero. Fissato n, $X(n) = A\cos(2\pi U + \varphi_n)$ con $\varphi_n = 2\pi f_0 n$: è esattamente la variabile della sinusoide con fase a caso del Capitolo 12, con la fase $\varphi = \varphi_n$. Là avevamo trovato la densità dell'arcoseno, $\frac{1}{\pi\sqrt{A^2-x^2}}$ per $|x| < A$, che **non dipende da** φ. Quindi

$$f_{X(n)}(x;n) = \frac{1}{\pi\sqrt{A^2 - x^2}} \qquad \text{per ogni } n:$$

il processo è stazionario del primo ordine. In parole: se non si sa da dove parte la sinusoide, nessun istante è diverso dagli altri.

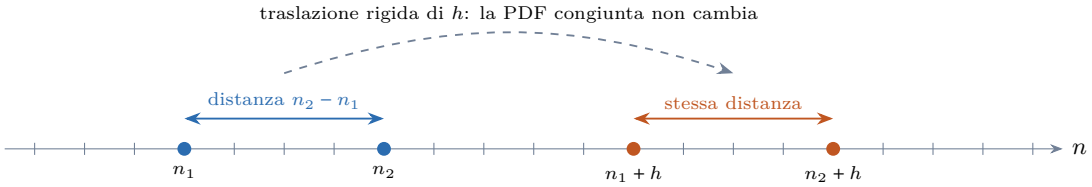
Il primo ordine descrive ogni istante da solo, ma non dice nulla dei legami fra istanti diversi: se il segnale in un istante è alto, sarà alto anche all'istante dopo? Per rispondere serve la descrizione congiunta delle coppie di campioni.

Stazionarietà del secondo ordine

Un processo aleatorio si dice **caratterizzato al secondo ordine** se è nota la PDF congiunta $f_{X(n_1),X(n_2)}(x_1, x_2; n_1, n_2)$ per ogni coppia di istanti n_1, n_2. Si dice **stazionario al secondo ordine** se, per qualsiasi intero h,

$$f_{X(n_1),X(n_2)}(x_1, x_2; n_1, n_2) = f_{X(n_1+h),X(n_2+h)}(x_1, x_2; n_1 + h, n_2 + h).$$

In altre parole, in un processo stazionario al secondo ordine la caratterizzazione congiunta di due campioni dipende solo dalla loro **distanza temporale**, non dalla loro posizione: la PDF congiunta non cambia se i due istanti vengono spostati «rigidamente», insieme, in anticipo o in ritardo.



Un processo stazionario al secondo ordine lo è anche al primo: la densità di un solo campione si ottiene integrando la congiunta rispetto all'altro (Capitolo 14), e se la congiunta non cambia con la traslazione non cambia nemmeno il suo integrale. Il viceversa, invece, non è vero: due processi con le stesse densità del primo ordine possono legare in modo molto diverso i campioni vicini.

Caratterizzazione completa e stazionarietà in senso stretto

Il primo e il secondo ordine guardano uno o due istanti alla volta. La descrizione completa li guarda tutti insieme, in qualsiasi numero.

Caratterizzazione completa di un processo

Un processo aleatorio $X(n)$ si dice **completamente caratterizzato** (statisticamente) se, detto M un intero arbitrario e detti $n_1, n_2, \ldots, n_M$ M istanti di tempo arbitrari, il vettore aleatorio

$$\underline{X} = [X(n_1), X(n_2), \ldots, X(n_M)]^T$$

ha una densità di probabilità $f_{\underline{X}}(x_1, x_2, \ldots, x_M; n_1, n_2, \ldots, n_M)$ nota.

Stazionarietà in senso stretto

Un processo aleatorio si dice **stazionario in senso stretto di ordine** M se la sua densità di ordine M è invariante per traslazione:

$$f_{\underline{X}}(x_1, \ldots, x_M; n_1, \ldots, n_M) = f_{\underline{X}}(x_1, \ldots, x_M; n_1 + h, \ldots, n_M + h) \qquad \forall\, h.$$

Si dice **stazionario in senso stretto** se lo è per ogni ordine M.

Teorema 17.2 — La stazionarietà passa agli ordini più bassi

Un processo stazionario di ordine M lo è anche di qualunque ordine $i \le M$.

Dimostrazione

Passo 1. Si fissano i istanti $n_1, \dots, n_i$ e se ne aggiungono altri $M - i$ qualsiasi, $n_{i+1}, \dots, n_M$. La densità di ordine i si ottiene da quella di ordine M integrando rispetto alle $M - i$ variabili in più (marginalizzazione). Spostando tutti gli istanti di h, la funzione da integrare non cambia (stazionarietà di ordine M), e quindi non cambia nemmeno il risultato dell'integrale, la densità di ordine i.

■

Processo indipendente

Un processo si dice **indipendente** (o **a campioni indipendenti**) se, comunque si scelgano un intero M e gli istanti $n_1, \dots, n_M$, il vettore $\underline{X} = [X(n_1), \dots, X(n_M)]^T$ è costituito da variabili aleatorie indipendenti, cioè

$$f_{\underline{X}}(x_1, \dots, x_M; n_1, \dots, n_M) = f_{X(n_1),\dots,X(n_M)}(x_1, \dots, x_M; n_1, \dots, n_M) = \prod_{i=1}^{M} f_{X(n_i)}(x_i; n_i).$$

Per un processo indipendente, quindi, la caratterizzazione completa si riduce a quella del primo ordine: basta conoscere la densità di ogni singolo campione.

Processi a valori discreti

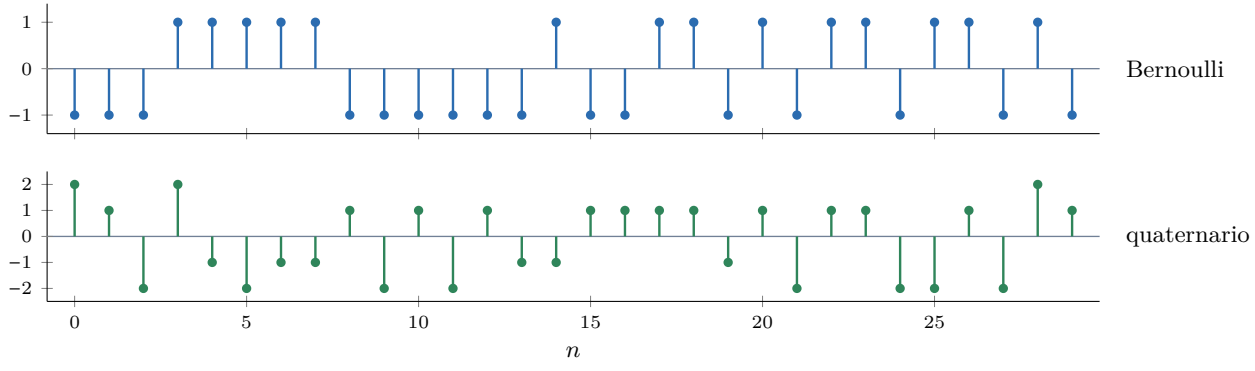
Si chiama **processo ad ampiezza discreta** (o, per brevità, **processo discreto**) un processo le cui realizzazioni sono sequenze di numeri che possono assumere valori in un alfabeto discreto. Tutte le definizioni viste per i processi a valori continui si estendono a questi processi, con la sola differenza che al posto delle densità si usano le pmf. Per esempio, un processo discreto è stazionario in senso stretto se, comunque si scelgano M, gli istanti $n_1, \dots, n_M$ e uno spostamento h,

$$P(X(n_1) = x_1, \dots, X(n_M) = x_M) = P(X(n_1 + h) = x_1, \dots, X(n_M + h) = x_M).$$

Ovviamente anche qui la stazionarietà di ordine M implica quella di ogni ordine $i \le M$; in particolare un processo stazionario ha una pmf marginale indipendente dal tempo.

Esempio 17.3 — Il processo di Bernoulli e il processo quaternario

Un caso di notevole importanza è il **processo indipendente binario**, con $X(n) \in \{-1, 1\}$ e $P(X(n) = -1) = P(X(n) = 1) = \frac{1}{2}$, detto anche **processo di Bernoulli** (in generale le probabilità possono essere p e $1 - p$): è il modello di una sequenza di bit trasmessi con i livelli ± 1, come quella del Capitolo 15. Un altro esempio è il processo **quaternario** indipendente, con $X(n) \in \{-2, -1, 1, 2\}$ e livelli equiprobabili, $P(X(n) = i) = \frac{1}{4}$ per $i \in \{-2, -1, 1, 2\}$: ogni simbolo trasporta due bit.



Una realizzazione di ciascuno dei due processi (simulazione).

Teorema 17.3 — Processi discreti indipendenti e stazionari

Se un processo discreto è stazionario e indipendente, per ogni scelta di M, degli istanti $n_1, \dots, n_M$ e dei valori $x_1, \dots, x_M$:

$$P(X(n_1) = x_1, X(n_2) = x_2, \dots, X(n_M) = x_M) = \prod_{i=1}^{M} P(X(n_i) = x_i) = \prod_{i=1}^{M} p_X(x_i),$$

dove $p_X(x)$ è la pmf marginale, che non dipende dal tempo. Viceversa, un processo indipendente che ha la stessa pmf marginale in ogni istante è stazionario in senso stretto.

Dimostrazione

Passo 1 — La formula. La prima uguaglianza è l'indipendenza; la seconda la stazionarietà, per cui la marginale di ogni campione è la stessa pmf p_X.

Passo 2 — Il viceversa. Se il processo è indipendente e ha sempre la stessa marginale, vale la stessa formula, e il prodotto $\prod_i p_X(x_i)$ non contiene gli istanti n_i: spostandoli tutti di h non cambia nulla.

■

Per un processo discreto indipendente e stazionario, dunque, l'intera caratterizzazione completa si riassume in **una sola pmf**. Per esempio, nel processo di Bernoulli la probabilità di osservare la sequenza $+1, +1, -1$ in tre istanti qualsiasi è $\left(\frac{1}{2}\right)^3 = \frac{1}{8}$, e nel processo quaternario la probabilità che due campioni valgano entrambi 2 è $\frac{1}{4} \cdot \frac{1}{4} = \frac{1}{16}$, dovunque si trovino.

Processi stazionari in senso lato

Conoscere la caratterizzazione completa di un processo è quasi sempre troppo: servirebbero le densità congiunte di un numero qualsiasi di campioni. Come per le variabili e i vettori, ci si accontenta spesso di una caratterizzazione sintetica, fatta di medie e correlazioni. Ci concentriamo sui processi a tempo discreto, ma quanto diremo vale anche per quelli a tempo continuo.

Teorema 17.4 — Medie di un processo stazionario del secondo ordine

Se $X(n)$ è stazionario del secondo ordine:

a) la media $E[X(n)] = \mu_X(n) = \mu_X$ non dipende da n;
b) la media del prodotto $E[X(n_1)X(n_2)]$ dipende solo da $|n_2 - n_1|$, e non separatamente da n_1 e n_2.

Dimostrazione — nel caso discreto; nel continuo si usano le densità

Passo 1 — a). Per la stazionarietà $P(X(n) = x) = p_X(x)$ per ogni n, quindi

$$E[X(n)] = \sum_{x \in \mathcal{X}} x\, P(X(n) = x) = \sum_{x \in \mathcal{X}} x\, p_X(x) = \mu_X,$$

che non contiene n.

Passo 2 — b) Dipende solo dalla differenza. Per ogni h, la stazionarietà del secondo ordine dice che le due pmf congiunte sono uguali, e quindi anche le medie calcolate con esse:

$$\begin{aligned} E[X(n_1)X(n_2)] &= \sum_{x_1 \in \mathcal{X}} \sum_{x_2 \in \mathcal{X}} x_1 x_2\, P(X(n_1) = x_1, X(n_2) = x_2) \\ &= \sum_{x_1 \in \mathcal{X}} \sum_{x_2 \in \mathcal{X}} x_1 x_2\, P(X(n_1 + h) = x_1, X(n_2 + h) = x_2) = E[X(n_1 + h)\, X(n_2 + h)]. \end{aligned}$$

Scegliendo $h = -n_1$: $E[X(n_1)X(n_2)] = E[X(0)\, X(n_2 - n_1)]$, che è una funzione della sola differenza $n_2 - n_1$.

Passo 3 — b) Anzi, del valore assoluto. Per la proprietà commutativa del prodotto, $E[X(n_1)X(n_2)] = E[X(n_2)X(n_1)]$: la stessa funzione dà lo stesso valore in $n_2 - n_1$ e in $n_1 - n_2$. Dipende quindi solo da $|n_2 - n_1|$.

■

Queste due proprietà sono così utili che si prendono come definizione di una stazionarietà più debole, che riguarda solo medie e correlazioni.

Autocorrelazione

L'**autocorrelazione** di un processo $X(n)$ è la correlazione fra i suoi campioni in due istanti:

$$R_X(n_1, n_2) = E[X(n_1)\, X(n_2)].$$

Processo stazionario in senso lato

Un processo, continuo o discreto, non necessariamente stazionario al secondo ordine, si dice **stazionario in senso lato** (**SSL**; in inglese *wide-sense stationary*, WSS) se:

- la sua media non dipende dal tempo: $E[X(n)] = \mu_X$;
- la sua autocorrelazione dipende solo dalla differenza fra gli istanti: $R_X(n_1, n_2) = E[X(n_1)X(n_2)] = R_X(n_2 - n_1)$.

Per il Teorema 17.4 ogni processo stazionario del secondo ordine è SSL. Si scrive spesso $R_X(k) = E[X(n)X(n+k)]$, con k la distanza fra i campioni: per la commutatività del prodotto è una funzione pari, $R_X(-k) = R_X(k)$, e $R_X(0) = E[X^2(n)]$ è il valore quadratico medio, cioè la **potenza media** del processo.

SSL non vuol dire stazionario

La stazionarietà in senso lato riguarda solo medie e correlazioni, non le densità. Si prenda un processo a campioni indipendenti con $X(n) \sim \mathcal{N}(0,1)$ negli istanti pari e $X(n) \sim \mathcal{U}(-\sqrt{3}, \sqrt{3})$ in quelli dispari. La media è sempre 0, la varianza è sempre 1 (per l'uniforme su $(-a, a)$ vale $\frac{(2a)^2}{12} = \frac{a^2}{3} = 1$), e $R_X(n_1, n_2) = 0$ per $n_1 \neq n_2$: il processo è SSL. Ma la densità del primo ordine cambia da un istante all'altro (una campana, poi un rettangolo): il processo non è stazionario nemmeno del primo ordine.

Il vettore dei campioni di un processo SSL

Cosa succede se si prelevano M campioni da un processo SSL e li si mette in un vettore? La struttura della stazionarietà si riflette in quella della matrice di covarianza.

Teorema 17.5 — Il vettore dei campioni di un processo SSL

Sia $X(n)$ un processo SSL e sia $\underline{X} = [X_1, X_2, \ldots, X_M]^T$ il vettore dei suoi campioni negli istanti $n_1, n_2, \ldots, n_M$, cioè $X_i = X(n_i)$. Allora:

a) il vettore delle medie ha tutti gli elementi uguali: $\underline{\mu}_{\underline{X}} = [\mu, \mu, \ldots, \mu]^T = \mu\, \underline{1}$, dove μ è uno scalare e $\underline{1} = [1, 1, \ldots, 1]^T$ è il vettore $M \times 1$ di tutti «1»;

b) $E[X_i X_j] = f(|n_i - n_j|)$ per un'opportuna funzione f; in particolare il valore quadratico medio $E[X_i^2] = f(0)$ e la varianza $\sigma_X^2 = f(0) - \mu^2$ non dipendono da i;

c) il coefficiente di correlazione dipende solo dalla distanza fra gli istanti, $\rho_{i,j} = \rho_{|n_i - n_j|}$, e la matrice di covarianza è simmetrica, della forma

$$\underline{\underline{C}}_{\underline{X}} = \sigma_X^2 \begin{bmatrix} 1 & \rho_{1,2} & \cdots & \rho_{1,M} \\ \rho_{2,1} & 1 & \cdots & \rho_{2,M} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{M,1} & \rho_{M,2} & \cdots & 1 \end{bmatrix};$$

d) se il passo di campionamento è costante ($n_{i+1} - n_i$ uguale per ogni i), $\underline{\underline{C}}_{\underline{X}}$ è una **matrice di Toeplitz**: gli elementi di ciascuna diagonale sono tutti uguali.

Dimostrazione

Passo 1 — a). Per la prima condizione SSL, $E[X_i] = E[X(n_i)] = \mu$ per ogni i.

Passo 2 — b). Per la seconda condizione, $E[X_i X_j] = R_X(n_j - n_i)$. Siccome $E[X_i X_j] = E[X_j X_i] = R_X(n_i - n_j)$, la funzione dà lo stesso valore in $n_j - n_i$ e nel suo opposto: dipende solo da $|n_i - n_j|$. Con $i = j$ la distanza è zero, quindi $E[X_i^2] = f(0)$, e $\sigma^2_{X_i} = E[X_i^2] - E^2[X_i] = f(0) - \mu^2$.

Passo 3 — c). Tutte le deviazioni standard sono uguali a σ_X, e $COV(X_i, X_j) = E[X_i X_j] - \mu^2$ (Capitolo 9):

$$\rho_{i,j} = \frac{COV(X_i, X_j)}{\sigma_{X_i}\,\sigma_{X_j}} = \frac{E[X_i X_j] - \mu^2}{\sigma_X^2} = \frac{E[X(n_i)\,X(n_j)] - \mu^2}{\sigma_X^2} = \rho_{|n_i - n_j|}.$$

Ogni elemento della matrice di covarianza è $C_{X_i X_j} = \rho_{i,j}\,\sigma_X^2$; sulla diagonale $\rho_{i,i} = 1$, e $\rho_{i,j} = \rho_{j,i}$ perché la distanza fra n_i e n_j è la stessa nei due versi.

Passo 4 — d). Con passo costante Δ, $n_j - n_i = (j - i)\Delta$: l'elemento di posto (i, j) dipende solo da $|j - i|$, cioè dalla diagonale su cui si trova.

■

$$\underline{\underline{C}}_{\underline{X}} = \sigma_X^2 \begin{bmatrix} 1 & \rho_1 & \rho_2 & \rho_3 & \rho_4 \\ \rho_1 & 1 & \rho_1 & \rho_2 & \rho_3 \\ \rho_2 & \rho_1 & 1 & \rho_1 & \rho_2 \\ \rho_3 & \rho_2 & \rho_1 & 1 & \rho_1 \\ \rho_4 & \rho_3 & \rho_2 & \rho_1 & 1 \end{bmatrix}$$

Cinque campioni consecutivi di un processo SSL. L'elemento (i, j) dipende solo dalla distanza $|i - j|$: la diagonale principale (distanza 0) contiene tutti 1, le diagonali vicine (distanza 1) tutti ρ_1, e così via. La matrice è simmetrica e **di Toeplitz**: bastano i numeri della prima riga, $1, \rho_1, \ldots, \rho_4$, per scriverla tutta.

Figura 17.2: *La matrice di covarianza di campioni equispaziati di un processo SSL: ogni colore è una diagonale.*

Si osservi che la matrice di covarianza $\underline{\underline{C}}_{\underline{X}}$ è simmetrica anche se il vettore viene estratto da un processo non SSL, perché la media del prodotto di due variabili aleatorie non dipende dall'ordine dei fattori. La struttura, però, non sarà quella precedente: per esempio sulla diagonale principale potrebbero esserci valori diversi, perché la varianza può dipendere dal tempo.

QUATTRO PROCESSI A CONFRONTO

Per rendere concrete le definizioni, studiamo quattro processi: tre stazionari in senso lato, con memorie diverse, e uno che non lo è.

Esempio 17.4 — Il processo di Bernoulli: nessuna memoria

Per il processo di Bernoulli a valori ± 1: $\mu = \frac{1}{2}(-1) + \frac{1}{2}(+1) = 0$, e $X^2(n) = 1$ sempre, quindi $R_X(0) = 1$. Per $k \neq 0$ i due campioni sono indipendenti, e $R_X(k) = E[X(n)]\,E[X(n+k)] = 0$. Quindi

$$R_X(k) = \begin{cases} 1 & k = 0 \\ 0 & k \neq 0 \end{cases} \qquad \text{e} \qquad \underline{\underline{C}}_{\underline{X}} = \underline{\underline{I}}$$

per qualsiasi vettore di campioni: un campione non dice nulla sugli altri. Il processo è SSL (anzi stazionario in senso stretto, per il Teorema 17.3).

Esempio 17.5 — La media mobile: un processo SSL con memoria

Sia $X(n)$ il processo di Bernoulli a valori ± 1 e sia $Y(n) = \frac{1}{2}[X(n) + X(n-1)]$ la media di due campioni consecutivi. $Y(n)$ vale -1 se entrambi i campioni valgono -1, $+1$ se valgono entrambi $+1$, e 0 se sono diversi: con probabilità $\frac{1}{4}$, $\frac{1}{4}$ e $\frac{1}{2}$.

- **Media**: $E[Y(n)] = \frac{1}{2}\left(E[X(n)] + E[X(n-1)]\right) = 0$.
- **Autocorrelazione**: si sviluppa il prodotto e si usa $E[X(i)\,X(j)] = 1$ se $i = j$ e 0 se $i \neq j$ (esempio precedente):

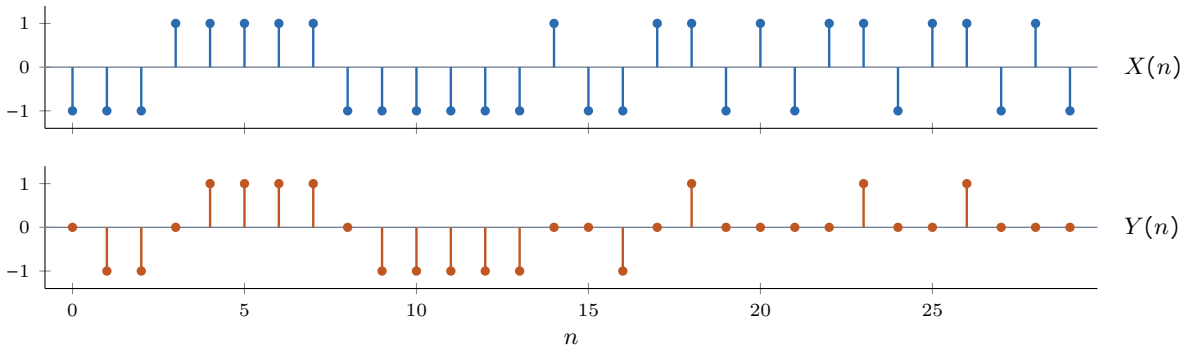
$$R_Y(n, n+k) = \frac{1}{4}E\Big[\,(X(n) + X(n-1))\,(X(n+k) + X(n+k-1))\,\Big] = \begin{cases} \frac{1}{4}(1+1) = \frac{1}{2} & k = 0, \\ \frac{1}{4} & k = \pm 1, \\ 0 & |k| \geq 2. \end{cases}$$

  Con $k = 0$ sopravvivono i due quadrati; con $k = 1$ solo il prodotto $X(n) \cdot X(n)$, perché $X(n)$ è l'unico campione in comune fra $Y(n)$ e $Y(n+1)$ (con $k = -1$ è $X(n-1)$); con $|k| \geq 2$ le due medie non hanno campioni in comune.

R_Y dipende solo da k: il processo è SSL, con $\sigma_Y^2 = \frac{1}{2}$, $\rho_1 = \frac{1/4}{1/2} = \frac{1}{2}$ e $\rho_k = 0$ per $|k| \geq 2$. Per quattro campioni consecutivi la matrice di covarianza è di Toeplitz:

$$\underline{\underline{C}}_{\underline{Y}} = \frac{1}{2}\begin{bmatrix} 1 & \frac{1}{2} & 0 & 0 \\ \frac{1}{2} & 1 & \frac{1}{2} & 0 \\ 0 & \frac{1}{2} & 1 & \frac{1}{2} \\ 0 & 0 & \frac{1}{2} & 1 \end{bmatrix}.$$

A differenza di $X(n)$, i campioni vicini di $Y(n)$ sono correlati: la media mobile «ricorda» il campione precedente e rende la sequenza più lenta e meno frastagliata.



In alto la stessa realizzazione del processo di Bernoulli dell'esempio precedente; in basso la sua media mobile.

Richiamo di matematica: il prodotto di due coseni

Dalle formule di addizione della trigonometria (che si studiano alle superiori)

$$\cos(a-b) = \cos a \cos b + \sin a \sin b, \qquad \cos(a+b) = \cos a \cos b - \sin a \sin b.$$

Sommandole membro a membro, i termini con i seni si cancellano: $\cos(a-b) + \cos(a+b) = 2\cos a \cos b$, cioè

$$\cos a \cos b = \frac{1}{2}\cos(a-b) + \frac{1}{2}\cos(a+b).$$

Il prodotto di due coseni è la media di due coseni: uno con la *differenza* degli argomenti e uno con la *somma*. Serve anche un secondo fatto: la media di un coseno su un numero intero di periodi è zero, perché le parti sopra e sotto l'asse hanno la stessa area. Per esempio

$$\int_{-1/2}^{1/2} \cos(4\pi u + c)\,du = \left[\frac{\sin(4\pi u + c)}{4\pi}\right]_{-1/2}^{1/2} = \frac{\sin(2\pi + c) - \sin(-2\pi + c)}{4\pi} = 0,$$

perché il seno ha periodo 2π (con la regola della catena, la derivata di $\sin(4\pi u + c)$ è $4\pi\cos(4\pi u + c)$, da cui la primitiva).

Esempio 17.6 — La sinusoide con fase a caso è SSL

Riprendiamo $X(n) = A\cos(2\pi U + \varphi_n)$, con $U \sim \mathcal{U}\left(-\frac{1}{2}, \frac{1}{2}\right)$ e $\varphi_n = 2\pi f_0 n$.

- **Media**: $E[X(n)] = \int_{-1/2}^{1/2} A\cos(2\pi u + \varphi_n)\,\mathrm{d}u = 0$ (un periodo intero di coseno), qualunque sia n.
- **Autocorrelazione**: con la formula del richiamo,

$$X(n_1)\,X(n_2) = A^2\cos(2\pi U + \varphi_{n_1})\cos(2\pi U + \varphi_{n_2}) = \frac{A^2}{2}\cos(\varphi_{n_2} - \varphi_{n_1}) + \frac{A^2}{2}\cos(4\pi U + \varphi_{n_1} + \varphi_{n_2}).$$

  Il primo termine non contiene U: è una costante. Il secondo, mediato su U, dà zero (due periodi interi di coseno, come nel richiamo). Quindi

$$R_X(n_1, n_2) = \frac{A^2}{2}\cos(\varphi_{n_2} - \varphi_{n_1}) = \frac{A^2}{2}\cos\left(2\pi f_0(n_2 - n_1)\right),$$

  che dipende solo da $n_2 - n_1$ (e, essendo il coseno pari, solo da $|n_2 - n_1|$).

Il processo è SSL, con $\mu = 0$ e $R_X(k) = \frac{A^2}{2}\cos(2\pi f_0 k)$. La potenza media $R_X(0) = \frac{A^2}{2}$ è il valore quadratico medio di una sinusoide di ampiezza A; e due campioni distanti un periodo ($k = 1/f_0$) hanno di nuovo correlazione massima, perché la sinusoide si ripete. A differenza della media mobile, la memoria di questo processo non si esaurisce mai: conoscendo due campioni si ricostruisce tutta la sinusoide.

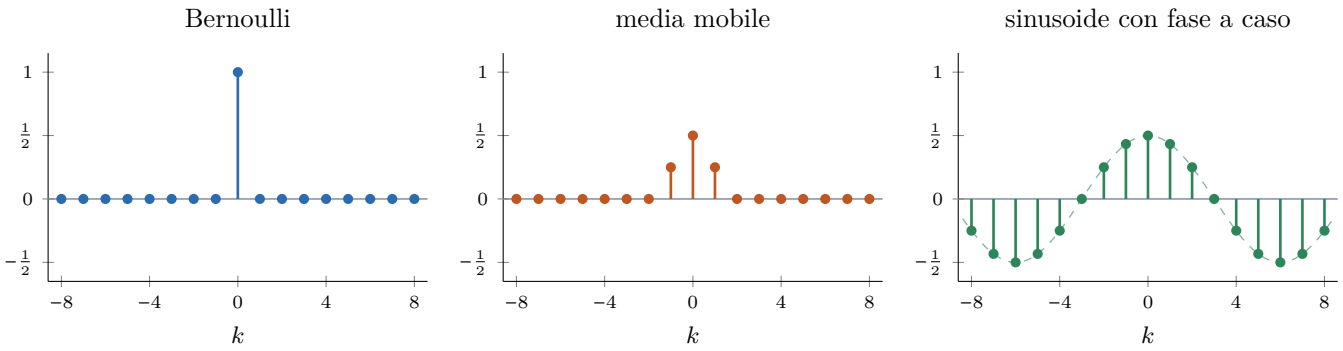


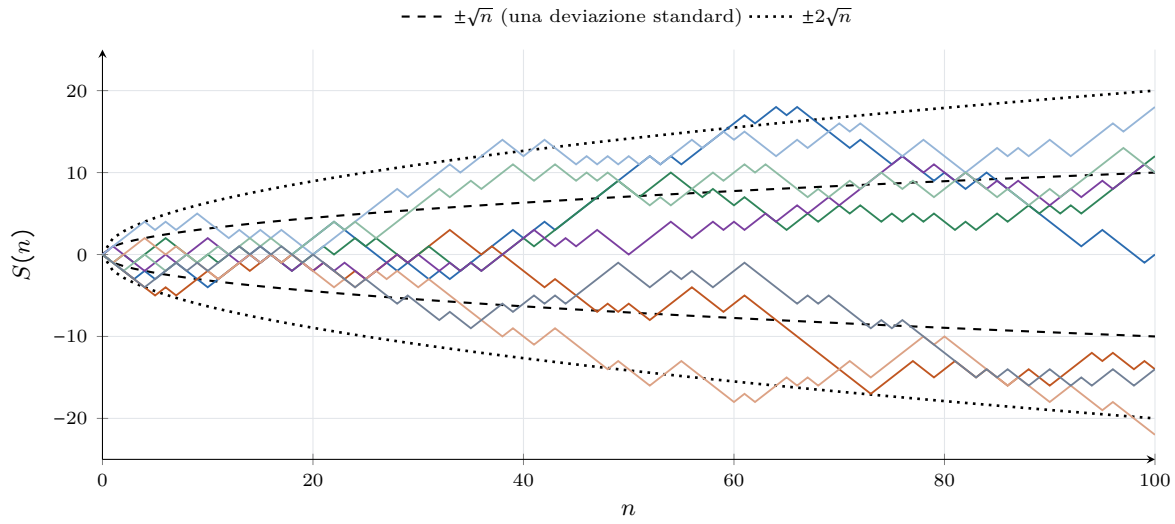
Figura 17.3: *Le autocorrelazioni $R(k)$ dei tre processi SSL degli esempi (con $A = 1$ e $f_0 = \frac{1}{12}$ per la sinusoide). Sono tutte pari e hanno il massimo in $k = 0$, la potenza media. La memoria del processo si legge nella larghezza: nulla per Bernoulli, un passo per la media mobile, infinita per la sinusoide.*

Esempio 17.7 — La passeggiata aleatoria non è stazionaria

Una pedina parte dalla casella 0 e a ogni istante si sposta di una casella avanti o indietro, a seconda dell'esito di una moneta: la sua posizione dopo n passi è $S(n) = X(1) + X(2) + \cdots + X(n)$, con $S(0) = 0$, dove $X(n)$ è il processo di Bernoulli a valori ± 1. È la **passeggiata aleatoria**.

- **Media**: $E[S(n)] = \sum_{i=1}^{n} E[X(i)] = 0$, costante.
- **Varianza**: i passi sono indipendenti, quindi le varianze si sommano (Capitolo 9): $\sigma^2_{S(n)} = \sum_{i=1}^{n} \sigma^2_{X(i)} = n$. Cresce con il tempo.
- **Autocorrelazione**: per $n_1 \le n_2$, $E[S(n_1)\,S(n_2)] = \sum_{i=1}^{n_1} \sum_{j=1}^{n_2} E[X(i)\,X(j)]$, e sopravvivono solo i termini con $i = j$, che sono n_1: $R_S(n_1, n_2) = \min(n_1, n_2)$.

La media non dipende dal tempo, ma l'autocorrelazione non dipende solo dalla differenza $n_2 - n_1$: per esempio $R_S(1, 2) = 1$ e $R_S(10, 11) = 10$. Il processo **non** è SSL, e quindi nemmeno stazionario del secondo ordine; anzi, non lo è neppure del primo ordine, perché la pmf di $S(n)$ si allarga con n. Nella figura le realizzazioni si allontanano dall'origine come $\sqrt{n}$, la deviazione standard dopo n passi.



Otto realizzazioni della passeggiata aleatoria (simulazione): partono tutte da 0 e si sparpagliano sempre di più.

In sintesi

- **Regola della catena**: $p_{\underline{X}}(\underline{x}) = \prod_i p_{X_i|X_1,\ldots,X_{i-1}}(x_i \mid x_1, \ldots, x_{i-1})$ (lo stesso con le densità): la congiunta si costruisce una variabile alla volta.
- Un **processo aleatorio a tempo discreto** associa a ogni ω una successione $\{X(n, \omega)\}_{n \in \mathbb{Z}}$: fissato ω si ha una realizzazione, fissato n una variabile aleatoria.
- **Caratterizzazione**: al primo ordine $f_{X(n)}(x; n)$, al secondo $f_{X(n_1),X(n_2)}(x_1, x_2; n_1, n_2)$, completa con le densità di ogni vettore di M campioni. **Stazionarietà** (di ordine M): le densità non cambiano traslando rigidamente gli istanti; l'ordine M implica gli ordini più bassi.
- **Processo indipendente**: la densità di M campioni è il prodotto delle marginali; se è anche stazionario basta una sola pmf (o PDF). Esempi: Bernoulli ± 1, quaternario.
- **SSL**: media costante e autocorrelazione $R_X(n_1, n_2) = E[X(n_1)X(n_2)] = R_X(n_2 - n_1)$, pari in $k = n_2 - n_1$. Stazionario del secondo ordine $\Rightarrow$ SSL, non viceversa. I campioni equispaziati di un processo SSL hanno $\underline{\mu}_{\underline{X}} = \mu \underline{1}$ e una matrice di covarianza simmetrica e di Toeplitz, $\sigma^2_X[\rho_{|i-j|}]$.