Metodi statistici per l'informazione
Parte III

Mario Tanda

Università degli Studi di Napoli Federico II
Dipartimento di Ingegneria Elettrica e delle Tecnologie dell'Informazione
via Claudio 21 I-80125 Napoli Italy

May 29, 2026

Introduzione

Assumiamo di avere un campione di dimensione n, $\underline{x} \in \mathbb{R}^n$ e assumiamo che questo campione è il risultato di un esperimento aleatorio, il che significa che un ricampionamento porta ad un differente insieme di risultati. L'inferenza statistica è il processo che utilizza l'analisi dei dati per dedurre proprietà della distribuzione di probabilità sottostante, cioè definire una legge che un qualsiasi campione, scelto a caso, rispetta. L'inferenza statistica può essere contrapposta alla statistica descrittiva. La statistica descrittiva si occupa solo delle proprietà dei dati e non si basa sull'assunzione che i dati provengano da una popolazione più ampia. Obiettivi fondamentali dell'inferenza statistica sono i test di ipotesi e la stima dei parametri.

Un esempio: la media campione

Assumiamo di avere un insieme di dati $\underline{x} \in \mathcal{X}^n \subseteq \mathbb{R}^n$. Sappiamo che la media campione è definita come

$$\overline{x}_n = \frac{1}{n} \sum_{i=1}^{n} x_i$$

(Questo campione è una particolare realizzazione e usiamo le lettere piccole.) Sotto opportune ipotesi, la legge dei grandi numeri ci dice che

$$\overline{X}_n = \frac{1}{n} \sum_{i=1}^{n} X_i \to E[X]$$

(Questo è un campione aleatorio e usiamo le lettere grandi.)

Legge debole dei grandi numeri

Sia $X_1, X_2, \ldots, X_n, \ldots$ una successione di variabili aleatorie indipendenti ed identicamente distribuite (i.i.d.), tutte con media $E[X_i] = \mu$ e varianza $E\left[(X-\mu)^2\right] = \sigma^2$. Allora per ogni $\epsilon > 0$,

$$\lim_{n\to\infty} P\left(\left|\frac{X_1 + X_2 + \ldots + X_n}{n} - \mu\right| > \epsilon\right) = 0$$

Dalle proprietà di media e varianza segue che

$$E\left[\frac{X_1 + X_2 + \ldots + X_n}{n}\right] = \mu$$

e

$$VAR\left[\frac{X_1 + X_2 + \ldots + X_n}{n}\right] = \frac{\sigma^2}{n}$$

Legge debole dei grandi numeri

La prima proprietà deriva dalla linearità della media. La seconda si prova nel modo seguente

$$VAR\left[\frac{X_1 + X_2 + \ldots + X_n}{n}\right]$$

$$= \frac{1}{n^2} VAR\left[X_1 + X_2 + \ldots + X_n\right] = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}$$

La seconda uguaglianza vale perché le variabili X_i sono indipendenti e quindi incorrelate (e le varianze si sommano). Dalla diseguaglianza di Chebyshev applicata alla variabile aleatoria $\overline{X}_n = \frac{X_1+X_2+\ldots+X_n}{n}$ segue che

$$P\left(\left|\frac{X_1 + X_2 + \ldots + X_n}{n} - \mu\right| > \epsilon\right) \leq \frac{\sigma^2}{n\,\epsilon^2}$$

Poiché il secondo membro tende a 0 per "n" che tende all'infinito, l'enunciato è provato.

Legge debole dei grandi numeri

Una applicazione di questo teorema è la seguente, che permette anche di giustificare l'interpretazione frequentista della probabilità di un evento. Supponiamo di ripetere in successione molte copie indipendenti di un esperimento, in ciascuna delle quali può verificarsi un certo evento E. Ponendo

$$X_i = \begin{cases} 1 & \text{se } E \text{ si realizza nell'esperimento i-esimo} \\ 0 & \text{se } E \text{ non si realizza nell'esperimento i-esimo} \end{cases}$$

la sommatoria $X_1 + X_2 + \ldots + X_n$ rappresenta il numero di prove - tra le prime n - in cui si è verificato l'evento E.
Poiché

$$E[X_i] = 1 \cdot P(E) + 0 \cdot P(E) = P(E)$$

si deduce che la frazione delle n prove nelle quali si è realizzato l'evento E tende (nel senso della legge debole dei grandi numeri) alla probabilità dell'evento E, $P(E)$.

Un esempio: la media campione

La convergenza debole (cioè la convergenza in probabilità) ci dice che

$$\lim_{n\to\infty} P\left(\left|\overline{X}_n - E[X]\right| > \epsilon\right) = 0 \qquad \epsilon > 0$$

(Legge debole dei grandi numeri.)

La convergenza forte (covergenza quasi certa o con probabilità uno) afferma che al limite la probabilità di allontanarci dalla media statistica $E[X]$ è zero. (Legge forte dei grandi numeri.)

Nota la prima è un limite di valori di probabilità (cioè è il limite di una sequenza deterministica che è la sequenza delle probabilità) mentre la seconda è la probabilità di un limite di una sequenza aleatoria (cioè la probabilità che una sequenza aleatoria, la sequenza delle medie campione, coverga è unitaria).

La convergenza in media quadratica afferma che

$$\lim_{n\to\infty} E\left[\left(\overline{X}_n - E[X]\right)^2\right] = 0$$

Teorema centrale del limite

Consideriamo la variabile aleatoria

$$Z_n = \sum_{i=1}^{n} X_i$$

e supponiamo che le n variabili aleatorie X_i, $i = 1, 2, \ldots, n$, siano indipendenti ed identicamente distribuite, cioè $f_{X_i}(x) = f_X(x)$, $\mu_{X_i} = \mu_X$ e $\sigma^2_{X_i} = \sigma^2_X$, $i = 1, 2, \ldots, n$.

In questo caso

$$\mu_{Z_n} = n\,\mu_X \qquad\qquad \sigma^2_{Z_n} = n\,\sigma^2_X$$

Consideriamo la variabile aleatoria S_n, versione normalizzata di Z_n, data da

$$S_n = \frac{Z_n - \mu_{Z_n}}{\sigma_{Z_n}} = \frac{Z_n - n\,\mu_X}{\sqrt{n}\,\sigma_X}$$

che, indipendentemente da n, ha sempre valore atteso nullo e varianza unitaria, cioè è una variabile standard.

Teorema centrale del limite

Un risultato fondamentale (centrale) della teoria della probabilità è il teorema centrale del limite.

Sotto ipotesi poco restrittive sulla PDF $f_X(x)$ delle variabili aleatorie X_i, si dimostra che, al tendere di n all'infinito, la CDF di S_n, $F_{S_n}(x)$, tende alla CDF di una normale standard

$$\lim_{n\to\infty} F_{S_n}(x) = \lim_{n\to\infty} P\left(S_n \leq x\right) = \phi(x) = \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}\, dt = 1 - Q(x)$$

In sostanza, la somma di un gran numero di variabili aleatorie statisticamente indipendenti segue con buona approssimazione una legge gaussiana a prescindere dalla particolare distribuzione di ciascuna di esse.

Teorema centrale del limite

L'ipotesi di equidistribuzione delle variabili aleatorie X_i permette di condurre una dimostrazione del teorema centrale del limite particolarmente semplice.

Il teorema centrale del limite è vero anche in ipotesi meno restrittive anche se la dimostrazione diventa più complessa.

Se prendiamo N variabili aleatorie uniformi, statisticamente indipendenti ed identicamente distribuire, già per $N = 15$ si è vicini ad una PDF normale (la convergenza è rapida intorno alla media, ma è lenta sulle code).

Un esempio: la media campione

Assumiamo di avere un insieme di dati $\underline{x} \in \mathcal{X}^n$, con $\mathcal{X} = (a_1, \ldots, a_M)$ discreto e finito. Osserviamo che la frequenza di occorrenza dell'evento $X_k = a_i$ è essa stessa una variabile aleatoria. Se N_i è il numero di volte che $X_k = a_i$ nel nostro campione $n-$dimensionale, supponendo che le variabili aleatorie $X_k,\ k = 1, 2, \ldots, n$, siano indipendenti ed identicamente distribuite (i.i.d), abbiamo:

$$P\left(N_i = k\right) = \binom{n}{k} p_X(a_i)^k \left[1 - p_X(a_i)\right]^{n-k}$$

Poiché

$$E\left[\frac{N_i}{n}\right] = p_X(a_i) \qquad VAR\left[\frac{N_i}{n}\right] = \frac{p_X(a_i)\left(1 - p_X(a_i)\right)}{n}$$

abbiamo che $\frac{N_i}{n} \to p_X(a_i)$ in media quadratica, cioè

$$\lim_{n\to\infty} E\left[\left(\frac{N_i}{n} - p_X(a_i)\right)^2\right] = 0$$

Un esempio: la media campione

Infatti

$$VAR\left[\frac{N_i}{n}\right] = E\left[\left(\frac{N_i}{n} - E\left[\frac{N_i}{n}\right]\right)^2\right]$$

$$= E\left[\left(\frac{N_i}{n} - p_X(a_i)\right)^2\right] = \frac{p_X(a_i)\,(1 - p_X(a_i))}{n}$$

Quindi

$$\lim_{n\to\infty} E\left[\left(\frac{N_i}{n} - p_X(a_i)\right)^2\right] = \lim_{n\to\infty} \frac{p_X(a_i)\,(1 - p_X(a_i))}{n} = 0$$

Statistica inferenziale

L'idea principale della statistica inferenziale è che, una volta che osserviamo un campione sufficientemente ampio di una data popolazione, possiamo dedurre un certo numero di caratteristiche che devono essere rispettate da qualsiasi altro campione.

Una certa conoscenza a priori relativa alle statistiche della popolazione dalla quale è estratto il campione può essere disponibile.

Per esempio, noi potremmo assumere che il campione è estratto da una popolazione la cui distribuzione è nota a meno di un insieme di parametri.

Per iniziare assumiamo di sapere che il campione è estratto da una famiglia di distribuzioni, indicizzate da un parametro θ, che deve essere stimato.

Domanda: come elaboriamo i dati per dedurre il valore del parametro?

Bayesian setting: decision rule

Assumiamo di avere un data set $\underline{x} \in \mathcal{X}^n$ che è una realizzazione di un vettore aleatorio $\underline{X}$. Assumiamo che i dati possano avere una tra M diverse leggi di probabilità. Abbiamo quindi un insieme di M differenti ipotesi (mutuamente esclusive) $\{H_i\}_{i=1}^{M}$, ciascuna che definisce una differente legge condizionata per il data set (l'insieme dei dati), cioè:

$$p_{\underline{X}}\left(\underline{x} \mid H_i\right) \qquad i = 1, 2, \ldots, M$$

Assumiamo che il vettore aleatorio $\underline{X}$ ha una distribuzione che appartiene ad una famiglia di distribuzioni con pmf $p_{\underline{X}}\left(\underline{x} \mid \theta\right)$, dove il valore del parametro θ è non noto. Supponiamo, inoltre, che le probabilità a priori $\{p(H_i)\}_{i=1}^{M}$ di questi "stati" della natura siano assegnate. Una regola di decisione è una corrispondenza

$$D: \quad \underline{x} \in \mathcal{X}^n \implies D\left(\underline{x}\right) \in \{1, 2, \ldots, M\}$$

che ci permette di decidere quale di questi possibili stati della natura è quello effettivamente attivo.

Costi bayesiani

Assumiamo di definire la seguente matrice di costi $M \times M$

$$\underline{\underline{C}} = \begin{bmatrix} C_{11} & C_{12} & \dots & C_{1M} \\ C_{21} & C_{22} & \dots & C_{2M} \\ \vdots & \vdots & \vdots & \vdots \\ C_{M1} & C_{M2} & \dots & C_{MM} \end{bmatrix}$$

dove C_{ij} è il costo associato all'evento "prendiamo la decisione per l'ipotesi i, $D(\underline{x}) = i$, e lo stato della natura è H_j, l'ipotesi vera è j". Definiamo rischio medio bayesiano

$$R = \sum_{i=1}^{M} \sum_{j=1}^{M} C_{ij} \, P\{D(\underline{x}) = i, H = H_j\}$$

Costi bayesiani

Data una matrice di costo $\underline{\underline{C}}$, una regola di decisione ottima è una corrispondenza $D(\underline{x})$ che minimizza il rischio bayesiano.

Si noti che, se $C_{ii} = 0$, $i = 1, 2, \ldots, M$ e $C_{ij} = 1$, $\forall i \neq j$ allora

$$R = \sum_{i=1}^{M} \sum_{j=1, j \neq i}^{M} P\{D(\underline{x}) = i, H = H_j\} = P(e)$$

cioè, in questo caso, il rischio medio bayesiano coincide con la probabilità di commettere un errore nella classificazione.

Problema di classificazione binario

Assumiamo per il momento che $M = 2$, che $C_{11} = C_{22} = 0$ e che $C_{12} = C_{21} = 1$. In questo caso

$$R = P\{D(\underline{x}) = 2, H_1\} + P\{D(\underline{x}) = 1, H_2\} = P(e)$$

Progettare una regola di decisione implica determinare una partizione di $\mathcal{X}^n$ in due sottoinsiemi, Ω_1 e Ω_2, tali che

$$D(\underline{x}) = \begin{cases} 1 & \text{se} \quad \underline{x} \in \Omega_1 \\ \\ 2 & \text{se} \quad \underline{x} \in \Omega_2 \end{cases}$$

La corrispondente probabilità di errore è quindi scritta in questo modo

$$P(e) = P\{\underline{X} \in \Omega_1, H_2\} + P\{\underline{X} \in \Omega_2, H_1\}$$

Vogliamo determinare la regola di decisione ottima (cioè a minima probabilità di errore, in questo caso) per questo problema di classificazione binaria.

Classificazione binaria: leggi discrete dei dati

Assumiamo che le osservazioni $\underline{X}$ sono un vettore aleatorio discreto con una data pmf condizionale $p_{\underline{X}}(\underline{x} \mid H_i)$. Noi ovviamente abbiamo

$$P\{\underline{X} \in \Omega_1, H_2\} + P\{\underline{X} \in \Omega_2, H_1\} \quad (\bullet)$$

$$= 1 - \sum_{\underline{x} \in \Omega_1} P\{\underline{X} = \underline{x} \mid H_1\} P(H_1) - \sum_{\underline{x} \in \Omega_2} P\{\underline{X} = \underline{x} \mid H_2\} P(H_2) \quad (\bullet\bullet)$$

In sostanza stiamo scrivendo che la probabilità di errore è il complemento ad uno della probabilità di corretta decisione.

Classificazione binaria: leggi discrete dei dati

Nota che

$$P\{\underline{X} \in \Omega_1, H_2\} = \sum_{\underline{x} \in \Omega_1} P\{\underline{X} = \underline{x} \mid H_2\} P(H_2)$$

$$= \left[1 - \sum_{\underline{x} \in \Omega_2} P\{\underline{X} = \underline{x} \mid H_2\}\right] P(H_2)$$

$$P\{\underline{X} \in \Omega_2, H_1\} = \sum_{\underline{x} \in \Omega_2} P\{\underline{X} = \underline{x} \mid H_1\} P(H_1)$$

$$= \left[1 - \sum_{\underline{x} \in \Omega_1} P\{\underline{X} = \underline{x} \mid H_1\}\right] P(H_1)$$

Usando i due risultati subito sopra, dalla $(\bullet)$ si trova la $(\bullet\bullet)$.

Classificazione binaria: leggi discrete dei dati

Quindi possiamo scrivere

$$P(e) = 1 - \left[\sum_{\underline{x} \in \Omega_1} P\left\{\underline{X} = \underline{x} \mid H_1\right\} P(H_1) + \sum_{\underline{x} \in \Omega_2} P\left\{\underline{X} = \underline{x} \mid H_2\right\} P(H_2) \right]$$

che è minima quando la quantità tra parentesi quadre è massima. Nota che un vettore o lo mettiamo in Ω_1 o lo mettiamo in Ω_2, se lo mettiamo da una parte non lo possiamo mettere nell'altra, quindi con la scelta seguente massimizziamo effettivamente il termine sottrattivo. Pertanto, otteniamo la seguente regola di decisione ottima

$$\underline{x} \in \Omega_1 \iff p_{\underline{X}}(\underline{x} \mid H_1)\, P(H_1) > p_{\underline{X}}(\underline{x} \mid H_2)\, P(H_2)$$

o equivalentemente

$$L\left(\underline{x}\right) = \frac{p_{\underline{X}}(\underline{x} \mid H_1)}{p_{\underline{X}}(\underline{x} \mid H_2)} \underset{H_2}{\overset{H_1}{\gtrless}} \frac{P(H_2)}{P(H_1)} = \eta$$

La quantità $L\left(\underline{x}\right)$ è detta "likelihood ratio", rapporto di verosimiglianza tra le due ipotesi alternative.

Classificazione binaria: leggi discrete dei dati

La precedente regola di decisione è anche nota come regola MAP (Massima Probabilità a-Posteriori), in quanto in base alla legge di Bayes

$$P\left\{H_i \mid \underline{X} = \underline{x}\right\} = \frac{P\left(\underline{X} = \underline{x} \mid H_i\right) P\left(H_i\right)}{P\left\{\underline{X} = \underline{x}\right\}}$$

$$= \frac{p_{\underline{X}}\left(\underline{x} \mid H_i\right) P\left(H_i\right)}{p_{\underline{X}}\left(\underline{x}\right)}$$

La regola quindi decide per l'ipotesi la cui probabilità a-posteriori, dati i dati osservati, è massima. Nel caso particolare in cui le due ipotesi sono (a-priori) egualmente probabili, la soglia η è pari ad 1 e la regola di decisione diventa la regola a massima verosimiglianza (Maximum Likelihood (ML)). Poiché le probabilità di errore condizionate sono

$$P\left(e \mid H_1\right) = P\left\{L\left(\underline{X}\right) < \eta \mid H_1\right\}$$

$$P\left(e \mid H_2\right) = P\left\{L\left(\underline{X}\right) > \eta \mid H_2\right\},$$

la probabilità di errore risulta (legge della probabilità totale)

$$P(e) = P(H_1)\, P\left(e \mid H_1\right) + P(H_2)\, P\left(e \mid H_2\right).$$

Classificazione binaria: leggi discrete dei dati

Assumiamo che le osservazioni sono variabili aleatorie binarie i.i.d che possono essere estratte con la stessa probabilità o da una sorgente con $P\{X_i = 1\} = p_1$ o da una sorgente con $P\{X_i = 1\} = p_2$, con $p_1 > p_2$. In questo caso abbiamo

$$p_{\underline{X}}(\underline{x} \mid H_i) = p_i^{w_H(\underline{x})} (1 - p_i)^{n - w_H(\underline{x})}$$

dove $w_H(\underline{x})$ è il peso di Hamming della sequenza binaria osservata $\underline{x}$, che coindice con il numero dei suoi "1". Il test a minima probabilità di errore è:

$$\frac{p_1^{w_H(\underline{x})} (1 - p_1)^{n - w_H(\underline{x})}}{p_2^{w_H(\underline{x})} (1 - p_2)^{n - w_H(\underline{x})}} \underset{H_2}{\overset{H_1}{\gtrless}} \frac{P(H_2)}{P(H_1)} = \frac{\frac{1}{2}}{\frac{1}{2}} = 1$$

cioè

$$\left(\frac{p_1}{p_2}\right)^{w_H(\underline{x})} \left[\frac{1 - p_1}{1 - p_2}\right]^{n - w_H(\underline{x})} \underset{H_2}{\overset{H_1}{\gtrless}} 1$$

Classificazione binaria: leggi discrete dei dati

o, equivalentemente,

$$w_H(\underline{x}) \ln \frac{p_1}{p_2} + (n - w_H(\underline{x})) \ln \frac{1-p_1}{1-p_2} \underset{H_2}{\overset{H_1}{\gtrless}} 0$$

che diventa

$$w_H(\underline{x}) \left[\ln \frac{p_1}{p_2} - \ln \frac{1-p_1}{1-p_2} \right] \underset{H_2}{\overset{H_1}{\lessgtr}} n \ln \frac{1-p_2}{1-p_1}$$

$$w_H(\underline{x}) \left[\ln \frac{p_1(1-p_2)}{p_2(1-p_1)} \right] \underset{H_2}{\overset{H_1}{\lessgtr}} n \ln \frac{1-p_2}{1-p_1}$$

Si noti che poiché $p_1 > p_2$, tutti i logaritmi sono non-negativi. Il test può quindi essere riscritto nella forma:

$$w_H(\underline{x}) \underset{H_2}{\overset{H_1}{\lessgtr}} n \frac{\ln \frac{1-p_2}{1-p_1}}{\ln \frac{p_1(1-p_2)}{p_2(1-p_1)}} = \eta_1$$

Classificazione binaria: leggi discrete dei dati

Assumendo che η_1 non è un intero, le probabilità di errore condizionate nelle due ipotesi alternative sono scritte come:

$$P(e \mid H_1) = P\{w_H(\underline{x}) < \eta_1 \mid H_1\} = \sum_{i=0}^{\lfloor \eta_1 \rfloor} \binom{n}{i} p_1^i (1-p_1)^{n-i}$$

$$P(e \mid H_2) = P\{w_H(\underline{x}) > \eta_1 \mid H_2\} = \sum_{i=\lfloor \eta_1 \rfloor + 1}^{n} \binom{n}{i} p_2^i (1-p_2)^{n-i}$$

e la probabilità di errore risulta

$$P(e) = P(e \mid H_1) P(H_1) + P(e \mid H_2) P(H_2)$$

$$= \frac{1}{2} P(e \mid H_1) + \frac{1}{2} P(e \mid H_2)$$

Classificazione binaria: leggi dei dati continue

Assumiamo ora che i dati siano estratti da una tra M possibili leggi di probabilità candidate continue e quindi abbiamo in ingresso una di M funzioni densità di probabilità condizionate $\left\{f_{\underline{X}|H_i}\left(\underline{x} \mid H_i\right)\right\}_{i=1}^{M}$. La sola differenza con il caso discreto in questo caso è che ora (assumiamo $M = 2$)

$$P\left\{\underline{X} \in \Omega_1 \mid H_1\right\} = \int_{\Omega_1} f_{\underline{X}|H_1}\left(\underline{x} \mid H_1\right) d\underline{x}$$

$$P\left\{\underline{X} \in \Omega_2 \mid H_2\right\} = \int_{\Omega_2} f_{\underline{X}|H_2}\left(\underline{x} \mid H_2\right) d\underline{x}$$

Quindi, seguendo lo stesso ragionamento fatto nel caso discreto, otteniamo che il test a minima probabilità di errore risulta:

$$\underline{x} \in \Omega_1 \iff f_{\underline{X}|H_1}\left(\underline{x} \mid H_1\right) P\left(H_1\right) > f_{\underline{X}|H_2}\left(\underline{x} \mid H_2\right) P\left(H_2\right)$$

Classificazione binaria: leggi dei dati continue

o, equivalentemente,

$$\frac{f_{\underline{X}|H_1}\left(\underline{x} \mid H_1\right) P\left(H_1\right)}{f_{\underline{X}|H_2}\left(\underline{x} \mid H_2\right) P\left(H_2\right)} \underset{H_2}{\overset{H_1}{\gtrless}} 1$$

e, quindi

$$L\left(\underline{x}\right) = \frac{f_{\underline{X}|H_1}\left(\underline{x} \mid H_1\right)}{f_{\underline{X}|H_2}\left(\underline{x} \mid H_2\right)} \underset{H_2}{\overset{H_1}{\gtrless}} \frac{P\left(H_2\right)}{P\left(H_1\right)}$$

La quantità $L\left(\underline{x}\right)$ sulla sinistra è ancora una volta detta rapporto di verosimiglianza tra le due ipotesi alternative.

Esempio: testare la media di una popolazione gaussiana

Assumiamo che i dati possono, con la stessa probabilità, essere la realizzazione di un vettore aleatorio gaussiano con componenti indipendenti con la stessa varianza e medie μ_1 e $\mu_2 < \mu_1$ differenti. Poiché

$$f_{\underline{X}|H_i}\left(\underline{x} \mid H_i\right) = \prod_{k=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x_k-\mu_i)^2}{2\sigma^2}}$$

il test ottimo si scrive

$$L\left(\underline{x}\right) = \frac{f_{\underline{X}|H_1}\left(\underline{x} \mid H_1\right)}{f_{\underline{X}|H_2}\left(\underline{x} \mid H_2\right)} = e^{\sum_{k=1}^{n} \frac{(x_k-\mu_2)^2-(x_k-\mu_1)^2}{2\sigma^2}} \underset{H_2}{\overset{H_1}{\gtrless}} 1$$

Prendendo il logaritmo naturale di entrambi i membri otteniamo

$$\sum_{k=1}^{n} \frac{(x_k-\mu_2)^2-(x_k-\mu_1)^2}{2\sigma^2} \underset{H_2}{\overset{H_1}{\gtrless}} 0$$

$$\frac{1}{2\sigma^2} \sum_{k=1}^{n} \left[(x_k-\mu_2)^2-(x_k-\mu_1)^2\right] \underset{H_2}{\overset{H_1}{\gtrless}} 0$$

Esempio: testare la media di una popolazione gaussiana

Poiché $\sigma^2 > 0$, possiamo scrivere

$$\sum_{k=1}^{n} \left[x_k^2 + \mu_2^2 - 2x_k\mu_2 - x_k^2 - \mu_1^2 + 2x_k\mu_1 \right] \underset{H_2}{\overset{H_1}{\gtrless}} 0$$

$$2\left(\mu_1 - \mu_2\right) \sum_{k=1}^{n} x_k + n\left(\mu_2^2 - \mu_1^2\right) \underset{H_2}{\overset{H_1}{\gtrless}} 0$$

$$2\left(\mu_1 - \mu_2\right) \sum_{k=1}^{n} x_k + n\left(\mu_2 + \mu_1\right)\left(\mu_2 - \mu_1\right) \underset{H_2}{\overset{H_1}{\gtrless}} 0$$

$$2\left(\mu_1 - \mu_2\right) \sum_{k=1}^{n} x_k \underset{H_2}{\overset{H_1}{\lessgtr}} -n\left(\mu_2 + \mu_1\right)\left(\mu_2 - \mu_1\right)$$

Esempio: testare la media di una popolazione gaussiana

In base all'ipotesi fatta in precedenza sulle medie, $\mu_2 < \mu_1$, abbiamo

$$2 \overbrace{(\mu_1 - \mu_2)}^{>0} \sum_{k=1}^{n} x_k \underset{H_2}{\overset{H_1}{>}} n (\mu_2 + \mu_1) \overbrace{(\mu_1 - \mu_2)}^{>0}$$

e quindi posso dividere a destra e a sinistra per una quantità positiva senza modificare la diseguaglianza

$$\frac{1}{n} \sum_{k=1}^{n} x_k \underset{H_2}{\overset{H_1}{>}} \frac{1}{2} (\mu_2 + \mu_1)$$

La quantità $\sum_{k=1}^{n} x_k$ per questo problema e la quantità $w_H(\underline{x})$ per il problema precedente, sono anche dette statistiche sufficienti nel gergo della statistica inferenziale.

Esempio: testare la media di una popolazione gaussiana

Si noti che nell'ipotesi H_i la statistica del test

$$Z_n = \frac{1}{n} \sum_{k=1}^{n} x_k$$

è gaussiana con media e varianza date da

$$E\left[Z_n \mid H_i\right] = \frac{1}{n} \sum_{k=1}^{n} E\left[x_k \mid H_i\right] = \frac{1}{n} \sum_{k=1}^{n} \mu_i = \mu_i$$

(per la linearità della media) e varianza

$$VAR\left[Z_n \mid H_i\right] = \frac{1}{n^2} \sum_{k=1}^{n} VAR\left[x_k \mid H_i\right] = \frac{1}{n^2} \sum_{k=1}^{n} \sigma^2 = \frac{\sigma^2}{n}$$

per l'indipendenza e per la proprietà che la varianza eleva al quadrato le costanti moltiplicative.

Esempio: testare la media di una popolazione gaussiana

Quindi le probabilità di errore condizionate sono date da

$$P(e \mid H_1) = P\{Z_n < \eta \mid H_1\} = 1 - P\{Z_n > \eta \mid H_1\}$$

$$= 1 - P\left\{\frac{Z_n - \eta_{Z_n}}{\sigma_{Z_n}} > \frac{\eta - \eta_{Z_n}}{\sigma_{Z_n}} \mid H_1\right\}$$

Nota che la variabile aleatoria $W \stackrel{\triangle}{=} \frac{Z_n - \eta_{Z_n}}{\sigma_{Z_n}}$ è una gaussiana standard, quindi

$$P(e \mid H_1) = 1 - Q\left(\frac{\eta - \eta_{Z_n}}{\sigma_{Z_n}} \mid H_1\right) = 1 - Q\left(\frac{\eta - \mu_1}{\frac{\sigma}{\sqrt{n}}}\right)$$

Esempio: testare la media di una popolazione gaussiana

Ricordiamo che

$$\eta = \frac{1}{2}(\mu_1 + \mu_2)$$

e che, per ipotesi, $\mu_1 > \mu_2$, quindi

$$P(e \mid H_1) = 1 - Q\left(\frac{\eta - \mu_1}{\frac{\sigma}{\sqrt{n}}}\right) = 1 - Q\left(\frac{\frac{1}{2}(\mu_1 + \mu_2) - \mu_1}{\frac{\sigma}{\sqrt{n}}}\right)$$

$$= 1 - Q\left(\frac{\frac{\mu_2}{2} - \frac{\mu_1}{2}}{\frac{\sigma}{\sqrt{n}}}\right) = 1 - Q\left(\sqrt{n}\,\frac{\mu_2 - \mu_1}{2\sigma}\right)$$

In questo caso $\mu_2 - \mu_1 < 0$ e ricordando la proprietà della $Q(\cdot)$ function

$$Q(-x) = 1 - Q(x)$$

risulta

$$P(e \mid H_1) = Q\left(\sqrt{n}\,\frac{\mu_1 - \mu_2}{2\sigma}\right)$$

Esempio: testare la media di una popolazione gaussiana

Inoltre,

$$P\left(e \mid H_2\right) = P\left\{Z_n > \eta \mid H_2\right\} = P\left\{\frac{Z_n - \eta_{Z_n}}{\sigma_{Z_n}} > \frac{\eta - \eta_{Z_n}}{\sigma_{Z_n}} \mid H_2\right\}$$

Nota che la variabile aleatoria $W \stackrel{\triangle}{=} \frac{Z_n - \eta_{Z_n}}{\sigma_{Z_n}}$ è una gaussiana standard, quindi

$$P\left(e \mid H_2\right) = Q\left(\frac{\eta - \eta_{Z_n}}{\sigma_{Z_n}} \mid H_2\right) = Q\left(\frac{\eta - \mu_2}{\frac{\sigma}{\sqrt{n}}}\right)$$

Esempio: testare la media di una popolazione gaussiana

Ricordiamo che

$$\eta = \frac{1}{2}\left(\mu_1 + \mu_2\right)$$

e che, per ipotesi, $\mu_1 > \mu_2$, quindi

$$P\left(e \mid H_2\right) = Q\left(\frac{\eta - \mu_2}{\frac{\sigma}{\sqrt{n}}}\right) = Q\left(\frac{\frac{1}{2}\left(\mu_1 + \mu_2\right) - \mu_2}{\frac{\sigma}{\sqrt{n}}}\right)$$

$$= Q\left(\frac{\frac{\mu_1}{2} - \frac{\mu_2}{2}}{\frac{\sigma}{\sqrt{n}}}\right) = Q\left(\sqrt{n}\,\frac{\mu_1 - \mu_2}{2\sigma}\right)$$

In questo caso $\left(\mu_1 - \mu_2 > 0\right)$ risulta

$$P\left(e \mid H_2\right) = Q\left(\sqrt{n}\,\frac{\mu_1 - \mu_2}{2\sigma}\right)$$

Pertanto,

$$P\left(e \mid H_1\right) = P\left(e \mid H_2\right) = Q\left\{\sqrt{n}\,\frac{\mu_1 - \mu_2}{2\sigma}\right\}$$

Esempio: testare la media di una popolazione gaussiana

Quindi

$$P(e) = P\left(e \mid H_1\right) P(H_1) + P\left(e \mid H_2\right) P(H_2) = Q\left\{\sqrt{n}\,\frac{\mu_1 - \mu_2}{2\sigma}\right\}$$

Osserviamo che per ipotesi $\mu_1 - \mu_2 > 0$, inoltre $\sigma^2 > 0$, quindi per $n \to \infty$ l'argomento della $Q-$function diverge e

$$\lim_{n\to\infty} P(e) = \lim_{n\to\infty} Q\left\{\sqrt{n}\,\frac{\mu_1 - \mu_2}{2\sigma}\right\} = 0$$

Elementi di teoria della decisione

Vi sono, inoltre, situazioni nelle quali dobbiamo prendere una decisione tra due ipotesi, ma non abbiamo modi di assegnare la matrice di costo $\underline{\underline{C}}$ e nemmeno le probabilità a priori. Esempi di questi casi includono diverse situazioni di pratico interesse, quali:

- rivelazione precoce delle minacce alla sicurezza di un'area pattugliata;
- rivelazione dell'intrusione in server/domini protetti in internet;
- rivelazione di un ostacolo (e localizzazione) in sistemi avanzati di assistenza alla guida;
- controllo del traffico aereo;
- un innumerevole insieme di applicazioni militari.

In tutte le situazioni precedenti è praticamente impossibile assegnare un costo ad una cattiva (errata) interpretazione dello "stato della natura" (cioè ad una decisione errata tra due ipotesi "tutto normale" o "sta succedendo qualcosa").

È anche poco significativo assegnare delle probabilità a priori se sono presenti nei dati "anomalie statistiche".

Definizioni relative ai test di ipotesi

Definiamo una ipotesi nulla, tradizionalmente denotata con H_0, che i dati osservati $\underline{x}$ sono una realizzazione di un vettore aleatorio con una distribuzione condizionata nota, cioè con pmf/pdf $p_{\underline{X}|H_0}(\underline{x} \mid H_0)/f_{\underline{X}|H_0}(\underline{x} \mid H_0)$.

Vogliamo decidere se o meno, dati i dati osservati $\underline{x}$, l'ipotesi nulla H_0 deve essere rigettata in favore di una legge differente, sia essa $p_{\underline{X}|H_1}(\underline{x} \mid H_1)/f_{\underline{X}|H_1}(\underline{x} \mid H_1)$.

Come nel caso precedente di classificazione binaria dobbiamo partizionare il dominio $\mathcal{X}^n$ in due regioni di decisione, ma la precedente "struttura" bayesiana non è più applicabile qui per la mancanza di una sufficiente informazione a priori.

Definizioni relative ai test di ipotesi

Nel progettare una regola di decisione (cioè un test) dobbiamo definire l'errore di prima specie e l'errore di seconda specie.

In particolare, l'errore di prima specie (type-I) consiste nel rifiutare l'ipotesi H_0 quando l'ipotesi H_0 è vera, la sua probabilità, anche detta probabilità di falso allarme e indicata con α, è data da

$$P\left\{D\left(\underline{X}\right)=1 \mid H_0\right\}=\begin{cases}\displaystyle\int_{\Omega_1} f_{\underline{X}|H_0}\left(\underline{x} \mid H_0\right) d\underline{x} & \text{dati continui} \\ \displaystyle\sum_{\underline{x}\in\Omega_1} p_{\underline{X}|H_0}\left(\underline{x} \mid H_0\right) & \text{dati discreti}\end{cases}$$

Definizioni relative ai test di ipotesi

L'errore di seconda specie (type-II) consiste nel rifiutare l'ipotesi H_1 quando l'ipotesi H_1 è vera, la sua probabilità, anche detta probabilità di mancata rivelazione è indicata con β. Il suo complemento ad uno, $1-\beta$, anche detta potenza del test (o probabilità di corretta rivelazione), è data da

$$1-\beta = P\left\{D\left(\underline{X}\right) = 1 \mid H_1\right\} = \begin{cases} \displaystyle\int_{\Omega_1} f_{\underline{X}|H_1}\left(\underline{x} \mid H_1\right) d\underline{x} & \text{dati continui} \\ \displaystyle\sum_{\underline{x}\in\Omega_1} p_{\underline{X}|H_1}\left(\underline{x} \mid H_1\right) & \text{dati discreti} \end{cases}$$

Test di Neyman-Pearson

Un test di Neyman-Pearson è il risultato della seguente ottimizzazione vincolata: determiniamo Ω_1 in modo tale che

$$\begin{cases} 1-\beta = \text{potenza del test}: & \text{massimizzata} \\ \\ \text{vincolo}: & \text{prob. errore del primo tipo} \leq \alpha \end{cases}$$

L'esistenza della soluzione di questo problema di ottimizzazione vincolata è la sostanza del lemma di Neyman-Pearson.

Test di Neyman-Pearson

Il test risultante è basato sul rapporto di verosimiglianza

$$L(\underline{x}) \underset{H_0}{\overset{H_1}{\gtrless}} \eta$$

dove

$$L(\underline{x}) = \begin{cases} \dfrac{f_{\underline{X}|H_1}(\underline{x}|H_1)}{f_{\underline{X}|H_0}(\underline{x}|H_0)} & \text{dati continui} \\ \dfrac{p_{\underline{X}|H_1}(\underline{x}|H_1)}{p_{\underline{X}|H_0}(\underline{x}|H_0)} & \text{dati discreti} \end{cases}$$

Test di Neyman-Pearson

La soglia η utilizzata deve essere scelta come soluzione dell'equazione

$$P\left\{L\left(\underline{x}\right) > \eta \mid H_0\right\} = \alpha$$

Si noti che se si applica una qualsiasi funzione monotona (strettamente) crescente ad entrambi i lati non si altera l'ottimalità del test.

Per esempio, possiamo introdurre il rapporto di verosimiglianza logaritmico $\ln L\left(\underline{x}\right) = \Lambda\left(\underline{x}\right)$ e confrontarlo con una nuova soglia.

Esempio: test sulla media di una popolazione gaussiana

Supponiamo che l'ipotesi nulla è che le osservazioni sono variabili aleatorie gaussiane i.i.d, con media nulla e varianza σ^2, cioè $X_i \sim \mathcal{N}(0, \sigma^2)$ mentre l'ipotesi alternativa è $X_i \sim \mathcal{N}(\mu, \sigma^2)$ con $\mu > 0$.
In base al precedente esempio il rapporto di verosimiglianza risulta:

$$L(\underline{x}) = \frac{f_{\underline{X}|H_1}(\underline{x} \mid H_1)}{f_{\underline{X}|H_0}(\underline{x} \mid H_0)} = \frac{\prod_{k=1}^{n} e^{-\frac{(x_k-\mu)^2}{2\sigma^2}}}{\prod_{k=1}^{n} e^{-\frac{x_k^2}{2\sigma^2}}}$$

$$= e^{\sum_{k=1}^{n} \frac{x_k^2 - (x_k-\mu)^2}{2\sigma^2}} = e^{\frac{1}{2\sigma^2}\sum_{k=1}^{n}\left[x_k^2 - (x_k-\mu)^2\right]}$$

$$= e^{\frac{1}{2\sigma^2}\sum_{k=1}^{n}\left[x_k^2 - x_k^2 - \mu^2 + 2\mu x_k\right]}$$

$$= e^{\frac{1}{2\sigma^2}\sum_{k=1}^{n}\left[-\mu^2 + 2\mu x_k\right]}$$

Esempio: test sulla media di una popolazione gaussiana

Quindi

$$L(\underline{x}) = e^{\frac{1}{2\sigma^2}\sum_{k=1}^{n}\left[-\mu^2+2\mu x_k\right]} \underset{H_2}{\overset{H_1}{\gtrless}} \overline{\eta}$$

Prendendo il logaritmo di entrambi i lati e assorbendo in una nuova (non nota) soglia η' tutte le quantità non dipendenti dai dati, otteniamo il test

$$\Lambda(\underline{x}) = \frac{1}{2\sigma^2}\left[2\mu\sum_{k=1}^{n}x_k - n\,\mu^2\right] \underset{H_2}{\overset{H_1}{\gtrless}} \eta = \ln(\overline{\eta})$$

$$\left[\mu\sum_{k=1}^{n}x_k - \frac{1}{2}n\,\mu^2\right] \underset{H_2}{\overset{H_1}{\gtrless}} \eta\sigma^2$$

Esempio: test sulla media di una popolazione gaussiana

$$\mu \sum_{k=1}^{n} x_k \underset{H_2}{\overset{H_1}{\gtrless}} \eta\sigma^2 + \frac{1}{2} n\,\mu^2$$

$$\frac{1}{n} \sum_{k=1}^{n} x_k \underset{H_2}{\overset{H_1}{\gtrless}} \frac{1}{\mu\, n} \left[\eta\sigma^2 + \frac{1}{2} n\,\mu^2 \right] = \eta'$$

$$\frac{1}{n} \sum_{k=1}^{n} x_k \underset{H_2}{\overset{H_1}{\gtrless}} \eta'$$

La soglia η' dovrebbe essere scelta in modo tale da assicurare che la probabilità di errore del primo tipo è pari al valore di progetto α.

Prestazione del test

Dobbiamo prima fissare la soglia di rivelazione. Si noti che la statistica del test nell'ipotesi H_0, è gaussiana, con media nulla e varianza $\frac{\sigma^2}{n}$. Di conseguenza

$$P\left\{\frac{1}{n}\sum_{k=1}^{n} x_k > \eta^{'} \mid H_0\right\} = Q\left(\frac{\eta^{'}}{\frac{\sigma}{\sqrt{n}}}\right)$$

deve risultare

$$Q\left(\frac{\eta^{'}}{\frac{\sigma}{\sqrt{n}}}\right) = \alpha \quad \Longleftrightarrow \quad Q^{-1}(\alpha) = \frac{\eta^{'}}{\frac{\sigma}{\sqrt{n}}} \quad \Longleftrightarrow \quad \eta^{'} = Q^{-1}(\alpha)\frac{\sigma}{\sqrt{n}} \quad (\bullet)$$

Per valutare la potenza del test (probabilità di corretta rivelazione), noi notiamo che nell'ipotesi H_1, la statistica del test ha una distribuzione gaussiana con media μ e varianza $\frac{\sigma^2}{n}$. Di conseguenza

$$1-\beta = P\left\{\frac{1}{n}\sum_{k=1}^{n} x_k > \eta^{'} \mid H_1\right\} = Q\left(\frac{\eta^{'}-\mu}{\frac{\sigma}{\sqrt{n}}}\right)$$

Prestazione del test

$$1-\beta = P\left\{\frac{1}{n}\sum_{k=1}^{n} x_k > \eta^{'} \mid H_1\right\} = Q\left(\frac{\eta^{'}-\mu}{\frac{\sigma}{\sqrt{n}}}\right) = Q\left(\left(\eta^{'}-\mu\right)\frac{\sqrt{n}}{\sigma}\right)$$

$$= Q\left(\overbrace{\eta^{'}\frac{\sqrt{n}}{\sigma}}^{Q^{-1}(\alpha)} - \mu\frac{\sqrt{n}}{\sigma}\right) = Q\left(Q^{-1}(\alpha) - \mu\frac{\sqrt{n}}{\sigma}\right)$$

Si noti che

$$\lim_{n\to\infty}(1-\beta) = \lim_{n\to\infty} Q\left(Q^{-1}(\alpha) - \mu\frac{\sqrt{n}}{\sigma}\right) = Q(-\infty) = 1$$

Comunqe fisso un valore di α piccolo, ma finito (quindi $Q^{-1}(\alpha)$ sarà molto grande ma finito)

$$\lim_{n\to\infty}(1-\beta) = 1$$

Elementi di teoria della stima

Supponiamo di avere un data set $\underline{x} \in \mathcal{X}^n$ che è una realizzazione di un vettore aleatorio $\underline{X}$. Supponiamo che il vettore aleatorio $\underline{X}$ abbia una distribuzione appartenente ad una famiglia di pmf/pdf $p_{\underline{X}|\Theta}(\underline{x} \mid \theta)/f_{\underline{X}|\Theta}(\underline{x} \mid \theta)$ dove il valore di θ è non noto. θ tipicamente è un parametro continuo che può essere una realizzazione di una variabile aleatoria Θ continua con una pdf marginale $f_\Theta(\theta)$ nota (approccio bayesiano) o una quantità non nota e deterministica (approccio classico) che assume valori in un insieme continuo.
Domanda: come stimare θ sulla base del campione osservato?

Osserviamo che nell'ambito dell'approccio bayesiano, applicando la legge di Bayes abbiamo:

$$f/p_{\Theta|\underline{X}}(\theta \mid \underline{x}) = \begin{cases} \dfrac{p_{\underline{X}|\Theta}(\underline{x}|\theta)\, f_\Theta(\theta)}{\int p_{\underline{X}|\Theta}(\underline{x}|\theta)\, f_\Theta(\theta) d\theta} & \text{dati discreti} \\ \dfrac{f_{\underline{X}|\Theta}(\underline{x}|\theta)\, f_\Theta(\theta)}{\int f_{\underline{X}|\Theta}(\underline{x}|\theta)\, f_\Theta(\theta) d\theta} & \text{dati continui} \end{cases}$$

Osserviamo che se Θ è una variabile aleatoria discreta, quello sopra diventa un problema di classificazione.

Elementi di teoria della stima

Notiamo, inoltre, che nelle equazioni scritte sopra abbiamo usato il fatto che

$$p_{\underline{X}}\left(\underline{x}\right) = \int p_{\underline{X}|\Theta}\left(\underline{x} \mid \theta\right)\ f_{\Theta}(\theta) d\theta$$

$$f_{\underline{X}}\left(\underline{x}\right) = \int f_{\underline{X}|\Theta}\left(\underline{x} \mid \theta\right)\ f_{\Theta}(\theta) d\theta$$

Uno stimatore del parametro θ è una variabile aleatoria $\hat{\Theta}\left(\underline{X}\right)$ le cui realizzazioni $\hat{\theta}\left(\underline{x}\right)$ provano ad "indovinare" il valore di θ sulla base di una osservazione $\underline{x} \in \mathcal{X}^n$.

Per progettare uno stimatore, noi prima definiamo il rischio medio bayesiano, cioè:

$$R = E\left[C\left(\hat{\Theta}\left(\underline{X}\right) - \Theta\right)\right] = E_{\underline{X}}\left[E\left[C\left(\hat{\Theta}\left(\underline{X}\right) - \Theta\right) \mid \underline{X}\right]\right]$$

dove $C(\cdot)$ è una funzione di costo opportunamente definita.

Elementi di teoria della stima

Uno stimatore ottimo è uno stimatore che minimizza il rischio bayesiano, cioè:

$$\hat{\Theta}\left(\underline{X}\right)_{\text{opt}} = \arg\min E\left[C\left(\hat{\Theta}\left(\underline{X}\right) - \Theta\right)\right]$$

Poiché

$$E\left[C\left(\hat{\Theta}\left(\underline{X}\right) - \Theta\right)\right] = \sum_{\underline{x} \in \mathcal{X}^n} p_{\underline{X}}\left(\underline{x}\right) \int C\left(\hat{\theta}\left(\underline{x}\right) - \theta\right) f_{\Theta|\underline{X}}\left(\theta \mid \underline{x}\right) \, d\theta$$

lo stimatore ottimo bayesiano che opera sul campione osservato $\underline{x}$ è definito come

$$\hat{\theta}\left(\underline{x}\right)_{\text{opt}} = \arg\min \int C\left(\hat{\theta}\left(\underline{x}\right) - \theta\right) f_{\Theta|\underline{X}}\left(\theta \mid \underline{x}\right) \, d\theta$$

Infatti, se per un generico $\underline{x}$ abbiamo il minimo, pesando per ogni $\underline{x}$ con una quantità positiva (non negativa) $p_{\underline{X}}\left(\underline{x}\right)$, si ottiene il minimo globale.

Elementi di teoria della stima

Assumiamo che

$$C\left(\hat{\Theta}\left(\underline{X}\right)-\Theta\right)=\left(\hat{\Theta}\left(\underline{X}\right)-\Theta\right)^{2}$$

cioè, la funzione di costo sia quadratica. Lo stimatore ottimo bayesiano può essere derivato come soluzione dell'equazione:

$$\frac{\partial}{\partial\,\hat{\theta}\left(\underline{x}\right)}\int\left(\hat{\theta}\left(\underline{x}\right)-\theta\right)^{2}f_{\Theta|\underline{X}}\left(\theta\mid\underline{x}\right)\,d\theta=0$$

Portando la derivata parziale sotto segno di integrale abbiamo

$$\int\frac{\partial}{\partial\,\hat{\theta}\left(\underline{x}\right)}\left(\hat{\theta}\left(\underline{x}\right)-\theta\right)^{2}f_{\Theta|\underline{X}}\left(\theta\mid\underline{x}\right)\,d\theta=0$$

$$2\int\left(\hat{\theta}\left(\underline{x}\right)-\theta\right)f_{\Theta|\underline{X}}\left(\theta\mid\underline{x}\right)\,d\theta=0$$

Elementi di teoria della stima

$$2 \int \left(\hat{\theta}\left(\underline{x}\right) - \theta \right) f_{\Theta|\underline{X}}\left(\theta \mid \underline{x}\right) \, d\theta = 0$$

$$\int \left(\hat{\theta}\left(\underline{x}\right) - \theta \right) f_{\Theta|\underline{X}}\left(\theta \mid \underline{x}\right) \, d\theta = 0$$

$$\hat{\theta}\left(\underline{x}\right) \int f_{\Theta|\underline{X}}\left(\theta \mid \underline{x}\right) \, d\theta = \int \theta f_{\Theta|\underline{X}}\left(\theta \mid \underline{x}\right) \, d\theta$$

$$\hat{\theta}\left(\underline{x}\right) = \int \theta f_{\Theta|\underline{X}}\left(\theta \mid \underline{x}\right) \, d\theta$$

Si noti che $\hat{\theta}\left(\underline{x}\right)$ può essere portato fuori dall'integrale in $d\theta$ in quanto non dipende da θ e, inoltre, l'integrale della pdf condizionata vale 1.

$$\hat{\theta}\left(\underline{x}\right) = \int \theta f_{\Theta|\underline{X}}\left(\theta \mid \underline{x}\right) \, d\theta = E\left[\Theta \mid \underline{X} = \underline{x}\right]$$

Si noti che $\hat{\theta}\left(\underline{x}\right)$ è la media condizionata di Θ all'evento $\{\underline{X} = \underline{x}\}$.
Si osservi che la funzione di costo (quadratica) è convessa e, quindi lo stimatore ottenuto (che annulla la derivata prima) corrisponde certamente ad un minimo della funzione di rischio scelta.

Esempio Bernoulli composito

Assumiamo che $\underline{X} \in \{0,1\}^n$ è condizionalmente bernoulliano (le componenti di $\underline{X}$ sono variabili aleatorie i.i.d. condizionalmente bernoulliane) con parametro β, dove $\mathcal{B} \sim \mathcal{U}(0,1)$.

Il peso di Hamming $w(\underline{x})$ di una sequenza binaria è il numero di "1" che contiene. Abbiamo:

$$p_{\underline{X}|\mathcal{B}}(\underline{x} \mid \beta) = \beta^{w(\underline{x})} (1-\beta)^{n-w(\underline{x})}$$

Mediando sulla variabile aleatoria $\mathcal{B} \sim \mathcal{U}(0,1)$ otteniamo la legge non condizionata

$$p_{\underline{X}}(\underline{x}) = \int p_{\underline{X}|\mathcal{B}}(\underline{x} \mid \beta) f_{\mathcal{B}}(\beta) d\beta = \int_0^1 \beta^{w(\underline{x})} (1-\beta)^{n-w(\underline{x})} d\beta$$

$$= \frac{\Gamma(w(\underline{x})+1)\,\Gamma(n-w(\underline{x})+1)}{\Gamma(n+2)}$$

dove abbiamo usato la funzione Beta di Eulero (espressa in termini della funzione Gamma di Eulero)

$$B(m,k) = \int_0^1 t^{m-1}(1-t)^{k-1} dt = \frac{\Gamma(m)\,\Gamma(k)}{\Gamma(m+k)}$$

Esempio Bernoulli composito

La legge condizionata è quindi

$$f_{\mathcal{B}|\underline{X}}\left(\beta \mid \underline{x}\right) = \frac{p_{\underline{X}|\mathcal{B}}\left(\underline{x} \mid \beta\right)\ f_{\mathcal{B}}\left(\beta\right)}{p_{\underline{X}}\left(\underline{x}\right)}$$

Lo stimatore MMSE di β (la media condizionata) è:

$$\hat{\beta}_{\mathrm{MMSE}}\left(\underline{x}\right) = \int_0^1 \beta\ f_{\mathcal{B}|\underline{X}}\left(\beta \mid \underline{x}\right) d\beta = \int_0^1 \beta\ \frac{p_{\underline{X}|\mathcal{B}}\left(\underline{x} \mid \beta\right)\ f_{\mathcal{B}}\left(\beta\right)}{p_{\underline{X}}\left(\underline{x}\right)} d\beta$$

$$= \left(\frac{\Gamma\left(w\left(\underline{x}\right)+1\right)\ \Gamma\left(n-w\left(\underline{x}\right)+1\right)}{\Gamma\left(n+2\right)}\right)^{-1} \int_0^1 \beta^{\,w(\underline{x})+1}\ \left(1-\beta\right)^{n-w(\underline{x})}\, d\beta$$

Esempio Bernoulli composito

Ricordando che

$$\int_0^1 t^{m-1}\,(1-t)^{k-1}\,dt = \frac{\Gamma(m)\,\Gamma(k)}{\Gamma(m+k)}$$

risulta

$$\hat{\beta}_{\mathrm{MMSE}}\,(\underline{x}) = \left(\frac{\Gamma\,(w\,(\underline{x})+1)\;\Gamma\,(n-w\,(\underline{x})+1)}{\Gamma\,(n+2)}\right)^{-1}$$

$$\times\frac{\Gamma\,(w\,(\underline{x})+2)\;\Gamma\,(n-w\,(\underline{x})+1)}{\Gamma\,(n+3)} = \frac{\Gamma\,(n+2)\;\Gamma\,(w\,(\underline{x})+2)}{\Gamma\,(n+3)\;\Gamma\,(w\,(\underline{x})+1)}$$

Esempio Bernoulli composito

Ricordando, inoltre, che

$$\Gamma(x+1) = x\,\Gamma(x)$$

risulta

$$\hat{\beta}_{\mathrm{MMSE}}\left(\underline{x}\right) = \frac{\Gamma\left(n+2\right)\,\Gamma\left(w\left(\underline{x}\right)+2\right)}{\Gamma\left(n+3\right)\,\Gamma\left(w\left(\underline{x}\right)+1\right)} = \frac{w\left(\underline{x}\right)+1}{n+2}$$

Stimatore MAP - Stima del massimo a posteriori

Consideriamo ora la seguente funzione di costo

$$C\left(\hat{\Theta}\left(\underline{X}\right)-\Theta\right)=\Pi\left(\frac{\hat{\Theta}\left(\underline{X}\right)-\Theta}{\epsilon}\right)=\begin{cases}0 & \mid \hat{\Theta}\left(\underline{X}\right)-\Theta \mid < \frac{\epsilon}{2} \\ 1 & \text{altrove}\end{cases}$$

Chiaramente, dato che ϵ è arbitrariamente piccolo, lo stimatore MAP è

$$\hat{\theta}\left(\underline{x}\right)_{\text{opt}}=\arg\min\int C\left(\hat{\theta}\left(\underline{x}\right)-\theta\right)f_{\Theta|\underline{X}}\left(\theta\mid\underline{x}\right)\,d\theta$$

$$=\arg\max f_{\Theta|\underline{X}}\left(\theta\mid\underline{x}\right)$$

Il rischio bayesiano risulta dato da

$$R=E\left[C\left(\hat{\Theta}\left(\underline{X}\right)-\Theta\right)\right]=\sum_{\underline{x}\in\mathcal{X}^n}p_{\underline{X}}\left(\underline{x}\right)\int C\left(\hat{\theta}\left(\underline{x}\right)-\theta\right)f_{\Theta|\underline{X}}\left(\theta\mid\underline{x}\right)\,d\theta$$

oppure, nel caso continuo

$$R=E\left[C\left(\hat{\Theta}\left(\underline{X}\right)-\Theta\right)\right]=\int f_{\underline{X}}\left(\underline{x}\right)\int C\left(\hat{\theta}\left(\underline{x}\right)-\theta\right)f_{\Theta|\underline{X}}\left(\theta\mid\underline{x}\right)\,d\theta\,d\underline{x}$$

Stimatore MAP - Stima del massimo a posteriori

Applicando questo criterio al problema precedente (Bernoulli composito) la stima MAP di β risulta

$$\hat{\beta}_{\mathrm{MAP}}\left(\underline{x}\right) = \arg\max f_{\Theta|\underline{X}}\left(\theta \mid \underline{x}\right)$$

$$= \arg\max f_{\mathcal{B}|\underline{X}}\left(\beta \mid \underline{x}\right) = \arg\max \frac{p_{\underline{X}|\mathcal{B}}\left(\underline{x} \mid \beta\right)\ f_{\mathcal{B}}\left(\beta\right)}{p_{\underline{X}}\left(\underline{x}\right)}$$

$$= \arg\max \left\{ \left(\frac{\Gamma\left(w\left(\underline{x}\right)+1\right)\ \Gamma\left(n-w\left(\underline{x}\right)+1\right)}{\Gamma\left(n+2\right)} \right)^{-1} \beta^{\,w(\underline{x})}\ \left(1-\beta\right)^{n-w(\underline{x})} \right\}$$

$$= \arg\max \left\{ \beta^{\,w(\underline{x})}\ \left(1-\beta\right)^{n-w(\underline{x})} \right\}$$

Si noti che il fattore moltiplicativo è positivo e non dipende da β (quindi, l'arg del max è lo stesso).

Stimatore MAP - Stima del massimo a posteriori

Inoltre, posso massimizzare anche il logaritmo (infatti, l'arg del max è lo stesso)

$$\frac{d}{d\beta}\left[w\left(\underline{x}\right)\log\beta+\left(n-w\left(\underline{x}\right)\right)\log(1-\beta)\right]=0$$

$$\frac{w\left(\underline{x}\right)}{\beta}=\left(n-w\left(\underline{x}\right)\right)\frac{1}{(1-\beta)}$$

Nell'ipotesi $\beta\neq 0,1$, abbiamo

$$(1-\beta)\,w\left(\underline{x}\right)=\beta\left(n-w\left(\underline{x}\right)\right)\quad\rightarrow\quad w\left(\underline{x}\right)=\beta\,n$$

quindi risulta

$$\hat{\beta}_{\mathrm{MAP}}=\frac{w\left(\underline{x}\right)}{n}$$

Prestazione di uno stimatore

Osserviamo preliminarmente che

$$E[\mathcal{B}] = \int_0^1 \beta \, d\beta = \frac{1}{2} \qquad E[\mathcal{B}^2] = \int_0^1 \beta^2 \, d\beta = \left. \frac{\beta^3}{3} \right|_0^1 = \frac{1}{3}$$

$$\sigma^2_{\mathcal{B}} = E[\mathcal{B}^2] - E^2[\mathcal{B}] = \frac{1}{3} - \frac{1}{4} = \frac{4-3}{12} = \frac{1}{12}$$

Quindi

$$E\left[w\left(\underline{X}\right)\right] = E_{\mathcal{B}}\left[\overbrace{E\left[w\left(\underline{X}\right) \mid \mathcal{B}\right]}^{n\mathcal{B}}\right] = nE[\mathcal{B}] = \frac{n}{2}$$

Prestazione di uno stimatore

Inoltre,

$$E\left[w^2\left(\underline{X}\right)\right] = E_{\mathcal{B}}\left[\overbrace{E\left[w^2\left(\underline{X}\right) \mid \mathcal{B}\right]}^{\sigma_w^2 + E^2[w]}\right]$$

dove σ_w^2 e $E^2[w]$ sono, rispettivamente, la varianza e la media di $w\left(\underline{X}\right)$ dato un certo valore di $\mathcal{B}$, cioè per $\mathcal{B} = \beta$. In particolare,

$$\sigma_w^2 = n\mathcal{B}(1-\mathcal{B}) \qquad E^2[w] = n^2\mathcal{B}^2$$

$$\sigma_w^2 + E^2[w] = n\mathcal{B}(1-\mathcal{B}) + n^2\mathcal{B}^2 = n\mathcal{B} - n\mathcal{B}^2 + n^2\mathcal{B}^2$$

quindi

$$E\left[w^2\left(\underline{X}\right)\right] = n\, E_{\mathcal{B}}\left[\mathcal{B} - \mathcal{B}^2 + n\mathcal{B}^2\right]$$

$$= \frac{n}{2} - \frac{n}{3} + \frac{n^2}{3} = \frac{n}{6} + \frac{n^2}{3}$$

Prestazione di uno stimatore

Quindi la varianza incondizionata di $w(\underline{X})$ risulta data

$$\sigma^2_{w(\underline{X})} = E\left[w^2(\underline{X})\right] - E^2\left[w(\underline{X})\right] = \frac{n}{6} + \frac{n^2}{3} - \frac{n^2}{4} = \frac{n}{6} + \frac{n^2}{12}$$

Nel caso dello stimatore MMSE

$$\hat{\beta}_{\text{MMSE}}(\underline{X}) = \frac{w(\underline{X}) + 1}{n+2}$$

$$E\left[\hat{\beta}_{\text{MMSE}}(\underline{X})\right] = E\left[\frac{w(\underline{X}) + 1}{n+2}\right]$$

$$= \frac{1}{n+2} E\left[w(\underline{X}) + 1\right] = \frac{1}{n+2}\left(\frac{n}{2} + 1\right) = \frac{1}{2}$$

$$E\left[\hat{\beta}_{\text{MMSE}}(\underline{X})\right] = \frac{1}{2}$$

Prestazione di uno stimatore

Nel caso dell stimatore MAP

$$\hat{\beta}_{\mathrm{MAP}} = \frac{w\left(\underline{X}\right)}{n}$$

$$E\left[\hat{\beta}_{\mathrm{MAP}}\left(\underline{X}\right)\right] = E\left[\frac{w\left(\underline{X}\right)}{n}\right] = \frac{1}{n} E\left[w\left(\underline{X}\right)\right] = \frac{1}{n}\frac{n}{2}$$

$$E\left[\hat{\beta}_{\mathrm{MAP}}\left(\underline{X}\right)\right] = \frac{1}{2}$$

Prestazione di uno stimatore

Consideriamo ora il valore quadratico medio dell'errore. Nel caso dello stimatore MMSE abbiamo

$$E\left[\hat{\beta}^2_{\mathrm{MMSE}}\left(\underline{X}\right)\right] = E\left[\left(\frac{w\left(\underline{X}\right)+1}{n+2}\right)^2\right] = \frac{1}{(n+2)^2} E\left[\left(w\left(\underline{X}\right)+1\right)^2\right]$$

$$= \frac{1}{(n+2)^2} E\left[w^2\left(\underline{X}\right)+1+2\,w\left(\underline{X}\right)\right]$$

dove

$$E\left[w\left(\underline{X}\right)\right] = \frac{n}{2} \qquad\qquad E\left[w^2\left(\underline{X}\right)\right] = \frac{n}{6}+\frac{n^2}{3}$$

Prestazione di uno stimatore

Quindi

$$E\left[\hat{\beta}^2_{\mathrm{MMSE}}\left(\underline{X}\right)\right] = \frac{1}{(n+2)^2}\left[\frac{n}{6} + \frac{n^2}{3} + 1 + n\right]$$

$$= \frac{1}{(n+2)^2}\left[\frac{2\,n^2 + n + 6 + 6\,n}{6}\right] = \frac{1}{(n+2)^2}\left[\frac{n^2}{3} + \frac{7n}{6} + 1\right]$$

L'errore quadratico medio (MSE) risulta

$$E\left[\left(\hat{\beta}_{\mathrm{MMSE}}\left(\underline{X}\right) - \mathcal{B}\right)^2\right] = E_{\mathcal{B}}\left[E\left[\left(\hat{\beta}_{\mathrm{MMSE}}\left(\underline{X}\right) - \mathcal{B}\right)^2 \mid \mathcal{B} = \beta\right]\right]$$

$$= E_{\mathcal{B}}\left[E\left[\left(\hat{\beta}^2_{\mathrm{MMSE}}\left(\underline{X}\right) + \mathcal{B}^2 - 2\,\hat{\beta}_{\mathrm{MMSE}}\left(\underline{X}\right)\mathcal{B}\right) \mid \mathcal{B} = \beta\right]\right]$$

$$= E_{\mathcal{B}}\left[E\left[\hat{\beta}^2_{\mathrm{MMSE}}\left(\underline{X}\right) \mid \mathcal{B} = \beta\right]\right] + E_{\mathcal{B}}\left[E\left[\mathcal{B}^2 \mid \mathcal{B} = \beta\right]\right]$$

$$-2E_{\mathcal{B}}\left[E\left[\hat{\beta}_{\mathrm{MMSE}}\left(\underline{X}\right)\mathcal{B} \mid \mathcal{B} = \beta\right]\right]$$

dove

Prestazione di uno stimatore

$$E_{\mathcal{B}}\left[E\left[\hat{\beta}^2_{\mathrm{MMSE}}\left(\underline{X}\right) \mid \mathcal{B}=\beta\right]\right] = \frac{1}{(n+2)^2}\left[\frac{n^2}{3}+\frac{7n}{6}+1\right]$$

$$E_{\mathcal{B}}\left[E\left[\mathcal{B}^2 \mid \mathcal{B}=\beta\right]\right] = \frac{1}{3}$$

mentre

$$E_{\mathcal{B}}\left[E\left[\hat{\beta}_{\mathrm{MMSE}}\left(\underline{X}\right)\ \mathcal{B} \mid \mathcal{B}=\beta\right]\right] = E_{\mathcal{B}}\left[E\left[\left(\frac{w\left(\underline{X}\right)+1}{n+2}\right)\ \mathcal{B} \mid \mathcal{B}=\beta\right]\right]$$

$$= \frac{1}{n+2} E_{\mathcal{B}}\left[E\left[\left(w\left(\underline{X}\right)+1\right)\ \mathcal{B} \mid \mathcal{B}=\beta\right]\right]$$

$$= \frac{1}{n+2}\left\{E_{\mathcal{B}}\left[E\left[w\left(\underline{X}\right)\ \mathcal{B} \mid \mathcal{B}=\beta\right]\right] + \overbrace{E_{\mathcal{B}}\left[E\left[\ \mathcal{B} \mid \mathcal{B}=\beta\right]\right]}^{\frac{1}{2}}\right\}$$

Prestazione di uno stimatore

Inoltre,

$$E_{\mathcal{B}}\left[E\left[w\left(\underline{X}\right)\ \mathcal{B} \mid \mathcal{B}=\beta\right]\right] = E_{\mathcal{B}}\left[E\left[n\ \mathcal{B}\ \mathcal{B} \mid \mathcal{B}=\beta\right]\right] = n\,E[\mathcal{B}^2] = \frac{n}{3}$$

Quindi,

$$E_{\mathcal{B}}\left[E\left[\hat{\beta}_{\mathrm{MMSE}}\left(\underline{X}\right)\ \mathcal{B} \mid \mathcal{B}=\beta\right]\right] = E_{\mathcal{B}}\left[E\left[\left(\frac{w\left(\underline{X}\right)+1}{n+2}\right)\ \mathcal{B} \mid \mathcal{B}=\beta\right]\right]$$

$$= \frac{1}{n+2} E_{\mathcal{B}}\left[E\left[\left(w\left(\underline{X}\right)+1\right)\ \mathcal{B} \mid \mathcal{B}=\beta\right]\right]$$

$$= \frac{1}{n+2}\left\{\overbrace{E_{\mathcal{B}}\left[E\left[w\left(\underline{X}\right)\ \mathcal{B} \mid \mathcal{B}=\beta\right]\right]}^{\frac{n}{3}} + \overbrace{E_{\mathcal{B}}\left[E\left[\ \mathcal{B} \mid \mathcal{B}=\beta\right]\right]}^{\frac{1}{2}}\right\}$$

$$= \frac{1}{n+2}\left(\frac{n}{3}+\frac{1}{2}\right)$$

Prestazione di uno stimatore

In definitiva l'errore quadratico medio risulta (vedi slides 61-66-68)

$$E\left[\left(\hat{\beta}_{\mathrm{MMSE}}\left(\underline{X}\right)-\mathcal{B}\right)^{2}\right]=E_{\mathcal{B}}\left[E\left[\hat{\beta}_{\mathrm{MMSE}}^{2}\left(\underline{X}\right)\mid\mathcal{B}=\beta\right]\right]$$

$$+E_{\mathcal{B}}\left[E\left[\mathcal{B}^{2}\mid\mathcal{B}=\beta\right]\right]-2E_{\mathcal{B}}\left[E\left[\hat{\beta}_{\mathrm{MMSE}}\left(\underline{X}\right)\mathcal{B}\mid\mathcal{B}=\beta\right]\right]$$

$$=\frac{1}{(n+2)^{2}}\left[\frac{n^{2}}{3}+\frac{7n}{6}+1\right]+\frac{1}{3}-\frac{2}{n+2}\left(\frac{n}{3}+\frac{1}{2}\right)$$

$$=\frac{2\,n^{2}+7\,n+6}{6\,(n+2)^{2}}+\frac{1}{3}-\frac{2\,(2\,n+3)}{6\,(n+2)}$$

$$=\frac{2\,n^{2}+7\,n+6+2\,(n+2)^{2}-2\,(2\,n+3)\;(n+2)}{6\,(n+2)^{2}}$$

Prestazione di uno stimatore

$$= \frac{2\,n^2 + 7\,n + 6 + 2n^2 + 8n + 8 - 2\,(2\,n + 3)\;(n + 2)}{6\,(n + 2)^2}$$

$$= \frac{4\,n^2 + 15\,n + 14 - 2\,(2\,n + 3)\;(n + 2)}{6\,(n + 2)^2}$$

$$= \frac{4\,n^2 + 15\,n + 14 - 2\left(2\,n^2 + 7n + 6\right)}{6\,(n + 2)^2}$$

$$= \frac{4\,n^2 + 15\,n + 14 - 4\,n^2 - 14n - 12}{6\,(n + 2)^2}$$

$$= \frac{n + 2}{6\,(n + 2)^2} = \frac{1}{6\,(n + 2)}$$

$$E\left[\left(\hat{\beta}_{\mathrm{MMSE}}\left(\underline{X}\right) - \mathcal{B}\right)^2\right] = \frac{1}{6\,(n + 2)}$$

Prestazione di uno stimatore

Nel caso MAP (cioè della stima del massimo a posteriori)

$$E\left[\left(\hat{\beta}_{\mathrm{MAP}}\left(\underline{X}\right)-\mathcal{B}\right)^{2}\right]=E_{\mathcal{B}}\left[E\left[\left(\hat{\beta}_{\mathrm{MAP}}\left(\underline{X}\right)-\mathcal{B}\right)^{2}\mid\mathcal{B}=\beta\right]\right]$$

$$=E_{\mathcal{B}}\left[E\left[\left(\hat{\beta}_{\mathrm{MAP}}^{2}\left(\underline{X}\right)+\mathcal{B}^{2}-2\,\hat{\beta}_{\mathrm{MAP}}\left(\underline{X}\right)\mathcal{B}\right)\mid\mathcal{B}=\beta\right]\right]$$

$$=E_{\mathcal{B}}\left[E\left[\hat{\beta}_{\mathrm{MAP}}^{2}\left(\underline{X}\right)\mid\mathcal{B}=\beta\right]\right]+E_{\mathcal{B}}\left[E\left[\mathcal{B}^{2}\mid\mathcal{B}=\beta\right]\right]$$

$$-2E_{\mathcal{B}}\left[E\left[\hat{\beta}_{\mathrm{MAP}}\left(\underline{X}\right)\mathcal{B}\mid\mathcal{B}=\beta\right]\right]$$

dove (vedi slides 61-62-64)

$$E_{\mathcal{B}}\left[E\left[\hat{\beta}_{\mathrm{MAP}}^{2}\left(\underline{X}\right)\mid\mathcal{B}=\beta\right]\right]=E_{\mathcal{B}}\left[E\left[\left(\frac{w\left(\underline{X}\right)}{n}\right)^{2}\middle|\,\mathcal{B}=\beta\right]\right]$$

$$=\frac{1}{n^{2}}\left[\frac{n^{2}}{3}+\frac{n}{6}\right]$$

$$E_{\mathcal{B}}\left[E\left[\mathcal{B}^{2}\mid\mathcal{B}=\beta\right]\right]=\frac{1}{3}$$

Prestazione di uno stimatore

mentre

$$E_{\mathcal{B}}\left[E\left[\hat{\beta}_{\mathrm{MAP}}\left(\underline{X}\right)\ \mathcal{B} \mid \mathcal{B}=\beta\right]\right]=E_{\mathcal{B}}\left[E\left[\left(\frac{w\left(\underline{X}\right)}{n}\right)\ \mathcal{B} \mid \mathcal{B}=\beta\right]\right]$$

$$=\frac{1}{n}\ E_{\mathcal{B}}\left[E\left[w\left(\underline{X}\right)\ \mathcal{B}\right| \mathcal{B}=\beta]\right]$$

$$=\frac{1}{n}\ E_{\mathcal{B}}\left[n\ \mathcal{B}\,\mathcal{B} \mid \mathcal{B}=\beta\right]=\ E_{\mathcal{B}}\left[\mathcal{B}^2 \mid \mathcal{B}=\beta\right]=\ E\left[\mathcal{B}^2\right]$$

Quindi

$$E_{\mathcal{B}}\left[E\left[\hat{\beta}_{\mathrm{MAP}}\left(\underline{X}\right)\ \mathcal{B} \mid \mathcal{B}=\beta\right]\right]=\frac{1}{3}$$

Prestazione di uno stimatore

Quindi nel caso MAP (cioè della stima del massimo a posteriori)

$$E\left[\left(\hat{\beta}_{\mathrm{MAP}}\left(\underline{X}\right)-\mathcal{B}\right)^{2}\right]=E_{\mathcal{B}}\left[E\left[\hat{\beta}_{\mathrm{MAP}}^{2}\left(\underline{X}\right)\mid\mathcal{B}=\beta\right]\right]$$
$$+E_{\mathcal{B}}\left[E\left[\mathcal{B}^{2}\mid\mathcal{B}=\beta\right]\right]-2E_{\mathcal{B}}\left[E\left[\hat{\beta}_{\mathrm{MAP}}\left(\underline{X}\right)\mathcal{B}\mid\mathcal{B}=\beta\right]\right]$$

dove (vedi slides 61-71-72)

$$E_{\mathcal{B}}\left[E\left[\hat{\beta}_{\mathrm{MAP}}^{2}\left(\underline{X}\right)\mid\mathcal{B}=\beta\right]\right]=\frac{1}{n^{2}}\left[\frac{n^{2}}{3}+\frac{n}{6}\right]$$

$$E_{\mathcal{B}}\left[E\left[\mathcal{B}^{2}\mid\mathcal{B}=\beta\right]\right]=\frac{1}{3}$$

$$E_{\mathcal{B}}\left[E\left[\hat{\beta}_{\mathrm{MAP}}\left(\underline{X}\right)\ \mathcal{B}\mid\mathcal{B}=\beta\right]\right]=\frac{1}{3}$$

Quindi

$$E\left[\left(\hat{\beta}_{\mathrm{MAP}}\left(\underline{X}\right)-\mathcal{B}\right)^{2}\right]=\frac{1}{n^{2}}\left[\frac{n^{2}}{3}+\frac{n}{6}\right]+\frac{1}{3}-2\frac{1}{3}$$

Prestazione di uno stimatore

$$E\left[\left(\hat{\beta}_{\mathrm{MAP}}\left(\underline{X}\right)-\mathcal{B}\right)^2\right]=\frac{1}{n^2}\left[\frac{n^2}{3}+\frac{n}{6}\right]-\frac{1}{3}=\frac{1}{3}+\frac{1}{6n}-\frac{1}{3}=\frac{1}{6\,n}$$

In definitiva,

$$\boxed{E\left[\left(\hat{\beta}_{\mathrm{MAP}}\left(\underline{X}\right)-\mathcal{B}\right)^2\right]=\frac{1}{6\,n}}$$

$$\boxed{E\left[\left(\hat{\beta}_{\mathrm{MMSE}}\left(\underline{X}\right)-\mathcal{B}\right)^2\right]=\frac{1}{6\,(n+2)}}$$

Chiaramente, come era da attendersi, per ogni valore di n, l'errore quadratico medio nel caso MMSE è minore rispetto a quello relativo al caso MAP.

Poiché entrambi i valori di MSE vanno a zero al crescere di n, abbiamo che i due stimatori sono detti MS-consistent (consistenti nel senso MSE) nel senso che l'errore aleatorio ha asintoticamente un valore quadratico medio che si annulla.

Prestazione di uno stimatore

Utilizzando la disuguaglianza di Markov, abbiamo che entrambi gli stimatori tendono a $\mathcal{B}$ in probabilità (consistenza, anche nota come consistenza debole). Se $\hat{\mathcal{B}}_n(\underline{X})$ è uno dei due stimatori, abbiamo

$$\forall \epsilon > 0 \qquad \lim_{n\to\infty} P_r\left\{\left|\hat{\mathcal{B}}_n(\underline{X}) - \mathcal{B}\right| > \epsilon\right\} = 0$$

Infatti

$$\forall \epsilon > 0 \qquad P_r\left\{\left|\hat{\mathcal{B}}_n(\underline{X}) - \mathcal{B}\right| > \epsilon\right\} = P_r\left\{\left|\hat{\mathcal{B}}_n(\underline{X}) - \mathcal{B}\right|^2 > \epsilon^2\right\}$$

$$\leq \frac{E\left[\left(\hat{\mathcal{B}}_n(\underline{X}) - \mathcal{B}\right)^2\right]}{\epsilon^2} = \frac{\mathrm{MSE}\left(\hat{\mathcal{B}}_n(\underline{X})\right)}{\epsilon^2}$$

e dobbiamo tenere presente che se $n \to \infty$ il secondo termine tende a zero e, inoltre, il primo è non negativo.

Inferenza non bayesiana: stima di parametri non aleatori

Assumiamo ora che le osservazioni $\underline{x} \in \mathcal{X}^n$ sono le realizzazioni di un vettore aleatorio la cui pdf appartiene ad una famiglia di pdf $f_{\underline{X}}(\underline{x}; \theta)$.

Assumiamo, inoltre, che θ è deterministico e non noto (non abbiamo abbastanza informazione a priori per assegnare una pdf $f_{\Theta}(\theta)$) e sia S lo spazio dei parametri.

Definiamo la verosimiglianza (likelihood) del parametro θ, date le osservazioni disponibili, la funzione

$$L(\theta; \underline{x}) = f_{\underline{X}}(\underline{x}; \theta)$$

o, equivalentemente, la funzione di verosimiglianza logaritmica

$$\Lambda(\theta; \underline{x}) = \log f_{\underline{X}}(\underline{x}; \theta)$$

Inferenza non bayesiana: stima di parametri non aleatori

La stima a massima verosimiglianza di θ è

$$\hat{\theta}\left(\underline{x}\right) = \arg\max_{\theta \in \mathcal{S}} \log f_{\underline{X}}\left(\underline{x}; \theta\right)$$

ed è una realizzazione dello stimatore a massima verosimiglianza (MLE, maximum likelihood estimator)

$$\widehat{\Theta}\left(\underline{X}\right) = \arg\max_{\theta \in \mathcal{S}} \log f_{\underline{X}}\left(\underline{X}; \theta\right)$$

Dato uno stimatore $\widehat{\Theta}\left(\underline{X}\right)$ del parametro non aleatorio θ, abbiamo:

$$E\left[\widehat{\Theta}_n\left(\underline{X}\right)\right] = \theta + b_n(\theta)$$

dove $b_n(\theta)$ è il bias (polarizzazione) dello stimatore. Lo stimatore è non polarizzato se $b_n(\theta) = 0$, mentre se $b_n(\theta) \to 0$ per $n \to \infty$, è detto asintoticamente non polarizzato.

Inferenza non bayesiana: stima di parametri non aleatori

L'errore aleatorio dello stimatore è generalmente quantificato attraverso il suo valore quadratico medio, cioè:

$$E\left[\left(\widehat{\Theta}_n\left(\underline{X}\right)-\theta\right)^2\right]=\overline{e}_n^2$$

Uno stimatore "non polarizzato" $\left(E\left[\widehat{\Theta}_n\left(\underline{X}\right)\right]=\theta\right)$ a minimo errore quadratico medio MMSE del parametro θ è uno stimatore che minimizza la varianza

$$VAR\left[\widehat{\Theta}_n\left(\underline{X}\right)\right]=E\left[\left(\widehat{\Theta}_n\left(\underline{X}\right)-\theta\right)^2\right]=E\left[\left(\widehat{\Theta}_n\left(\underline{X}\right)\right)^2\right]-\theta^2$$

Uno stimatore è consistente nel senso debole se $\widehat{\Theta}_n\left(\underline{X}\right)\rightarrow\theta$ in probabilità, consistente nel senso forte se $\widehat{\Theta}_n\left(\underline{X}\right)\rightarrow\theta$ quasi certamente (o con probabilità 1), MS consistent (consistente in media quadratica) se $\overline{e}_n^2\rightarrow 0$.

Bound di Cramér-Rao

Sia $\underline{x} \in \mathcal{X}^n$ una realizzazione di un vettore aleatorio la cui pdf appartiene ad una famiglia di pdf $\underline{X} \sim f_{\underline{X}}(\underline{x}; \theta)$ con θ parametro non aleatorio. Consideriamo l'identità

$$\int_{\mathbb{R}^n} f_{\underline{X}}(\underline{x}; \theta)\, d\underline{x} = 1$$

Derivando rispetto a θ abbiamo

$$\int_{\mathbb{R}^n} \frac{\partial}{\partial \theta} f_{\underline{X}}(\underline{x}; \theta)\, d\underline{x} = \int_{\mathbb{R}^n} \left(\frac{\partial}{\partial \theta} \log f_{\underline{X}}(\underline{x}; \theta) \right) f_{\underline{X}}(\underline{x}; \theta)\, d\underline{x}$$

$$= E\left[\frac{\partial}{\partial \theta} \log f_{\underline{X}}(\underline{X}; \theta) \right] = 0$$

Nota che sotto integrale il vettore $\underline{x}$ risulta essere una variabile muta di integrazione e quindi va bene scriverlo piccolo, ma quando scriviamo la media statistica, che risulta essere la media di una funzione di un vettore aleatorio, il vettore aleatorio deve essere scritto con la lettera maiuscola.

Bound di Cramér-Rao

Derivando nuovamente, abbiamo:

$$\int_{\mathbb{R}^n} \frac{\partial}{\partial\theta}\left[\left(\frac{\partial}{\partial\theta}\log f_{\underline{X}}\left(\underline{x};\theta\right)\right) f_{\underline{X}}\left(\underline{x};\theta\right)\right] d\underline{x}$$

$$= \int_{\mathbb{R}^n} \left(\frac{\partial^2}{\partial\theta^2}\log f_{\underline{X}}\left(\underline{x};\theta\right)\right) f_{\underline{X}}\left(\underline{x};\theta\right) d\underline{x}$$

$$+ \int_{\mathbb{R}^n} \left(\frac{\partial}{\partial\theta}\log f_{\underline{X}}\left(\underline{x};\theta\right)\right)\left(\frac{\partial}{\partial\theta} f_{\underline{X}}\left(\underline{x};\theta\right)\right) d\underline{x}$$

$$= \int_{\mathbb{R}^n} \left(\frac{\partial^2}{\partial\theta^2}\log f_{\underline{X}}\left(\underline{x};\theta\right)\right) f_{\underline{X}}\left(\underline{x};\theta\right) d\underline{x}$$

$$+ \int_{\mathbb{R}^n} \left(\frac{\partial}{\partial\theta}\log f_{\underline{X}}\left(\underline{x};\theta\right)\right)\left(\frac{\partial}{\partial\theta}\log f_{\underline{X}}\left(\underline{x};\theta\right)\right) f_{\underline{X}}\left(\underline{x};\theta\right) d\underline{x} = 0$$

Quindi

$$E\left[\frac{\partial^2}{\partial\theta^2}\log f_{\underline{X}}\left(\underline{X};\theta\right)\right] = -E\left[\left(\frac{\partial}{\partial\theta}\log f_{\underline{X}}\left(\underline{X};\theta\right)\right)^2\right]$$

Bound di Cramér-Rao

Inoltre, considerando che

$$E\left[\frac{\partial}{\partial\theta}\log f_{\underline{X}}\left(\underline{X};\theta\right)\right]=0$$

possiamo scrivere

$$E\left[\frac{\partial^2}{\partial\theta^2}\log f_{\underline{X}}\left(\underline{X};\theta\right)\right]=-VAR\left[\frac{\partial}{\partial\theta}\log f_{\underline{X}}\left(\underline{X};\theta\right)\right]$$

Sia $\widehat{\Theta}\left(\underline{X}\right)$ uno stimatore del parametro non aleatorio θ con

$$E\left[\widehat{\Theta}\left(\underline{X}\right)\right]=\int_{\mathbb{R}^n}\widehat{\Theta}\left(\underline{x}\right)f_{\underline{X}}\left(\underline{x};\theta\right)d\underline{x}=\theta+b_n(\theta)$$

$$\frac{\partial}{\partial\,\theta}E\left[\widehat{\Theta}\left(\underline{X}\right)\right]=\int_{\mathbb{R}^n}\widehat{\Theta}\left(\underline{x}\right)\frac{\partial}{\partial\,\theta}f_{\underline{X}}\left(\underline{x};\theta\right)d\underline{x}=1+b_n'(\theta)$$

Bound di Cramér-Rao

$$\frac{\partial}{\partial \theta} E\left[\widehat{\Theta}\left(\underline{X}\right)\right] = \int_{\mathbb{R}^n} \widehat{\Theta}\left(\underline{x}\right) \frac{\partial}{\partial \theta} f_{\underline{X}}\left(\underline{x};\theta\right) d\underline{x} = 1 + b_n'(\theta)$$

$$\frac{\partial}{\partial \theta} E\left[\widehat{\Theta}\left(\underline{X}\right)\right] = \int_{\mathbb{R}^n} \widehat{\Theta}\left(\underline{x}\right) \left(\frac{\partial}{\partial \theta} \log f_{\underline{X}}\left(\underline{x};\theta\right)\right) f_{\underline{X}}\left(\underline{x};\theta\right) d\underline{x} = 1 + b_n'(\theta)$$

Ora

$$COV\left(\widehat{\Theta}\left(\underline{X}\right), \frac{\partial}{\partial \theta} \log f_{\underline{X}}\left(\underline{X};\theta\right)\right)$$

$$= E\left[\left(\widehat{\Theta}\left(\underline{X}\right) - \theta - b_n(\theta)\right)\left(\frac{\partial}{\partial \theta} \log f_{\underline{X}}\left(\underline{X};\theta\right) - 0\right)\right]$$

in quanto

$$E\left[\widehat{\Theta}\left(\underline{X}\right)\right] = \theta + b_n(\theta)$$

e

$$E\left[\frac{\partial}{\partial \theta} \log f_{\underline{X}}\left(\underline{X};\theta\right)\right] = 0$$

Bound di Cramér-Rao

Ricordiamo che

$$COV(X,Y) = R(X,Y) - \mu_X \mu_Y$$

e quindi

$$COV(X,Y) = R(X,Y)$$

se almeno una delle due medie è nulla come accade nel nostro caso. Quindi

$$COV\left(\widehat{\Theta}\left(\underline{X}\right), \frac{\partial}{\partial\,\theta} \log f_{\underline{X}}\left(\underline{X};\theta\right)\right)$$

$$= E\left[\widehat{\Theta}\left(\underline{X}\right)\left(\frac{\partial}{\partial\,\theta} \log f_{\underline{X}}\left(\underline{X};\theta\right)\right)\right] = 1 + b_n'(\theta)$$

in quanto, come visto nella slide precedente,

$$\frac{\partial}{\partial\,\theta} E\left[\widehat{\Theta}\left(\underline{X}\right)\right] = \int_{\mathbb{R}^n} \widehat{\Theta}\left(\underline{x}\right) \frac{\partial}{\partial\,\theta}\left(\log f_{\underline{X}}\left(\underline{x};\theta\right)\right) f_{\underline{X}}\left(\underline{x};\theta\right) d\underline{x} = 1 + b_n'(\theta)$$

Bound di Cramér-Rao

Usando la disuguaglianza

$$| COV(X,Y) |^2 \leq \sigma_X^2 \, \sigma_Y^2$$

possiamo scrivere

$$\left| COV\left(\widehat{\Theta}\left(\underline{X}\right), \frac{\partial}{\partial \theta} \log f_{\underline{X}}\left(\underline{X};\theta\right) \right) \right|^2$$

$$= \left|1 + b_n'(\theta)\right|^2 \leq VAR\left[\widehat{\Theta}\left(\underline{X}\right)\right] VAR\left[\frac{\partial}{\partial \theta} \log f_{\underline{X}}\left(\underline{X};\theta\right)\right]$$

Ricordiamo che

$$E\left[\frac{\partial^2}{\partial \theta^2} \log f_{\underline{X}}\left(\underline{X};\theta\right)\right] = -VAR\left[\frac{\partial}{\partial \theta} \log f_{\underline{X}}\left(\underline{X};\theta\right)\right]$$

e che

$$E\left[\frac{\partial^2}{\partial \theta^2} \log f_{\underline{X}}\left(\underline{X};\theta\right)\right] = -E\left[\left(\frac{\partial}{\partial \theta} \log f_{\underline{X}}\left(\underline{X};\theta\right)\right)^2\right]$$

Bound di Cramér-Rao

Quindi, dalla relazione

$$\left|1+b_n'(\theta)\right|^2 \leq VAR\left[\widehat{\Theta}\left(\underline{X}\right)\right] VAR\left[\frac{\partial}{\partial\,\theta}\log f_{\underline{X}}\left(\underline{X};\theta\right)\right]$$

risulta

$$VAR\left[\widehat{\Theta}\left(\underline{X}\right)\right] \geq \frac{\left|1+b_n'(\theta)\right|^2}{VAR\left[\frac{\partial}{\partial\,\theta}\log f_{\underline{X}}\left(\underline{X};\theta\right)\right]}$$

$$VAR\left[\widehat{\Theta}\left(\underline{X}\right)\right] \geq \frac{\left|1+b_n'(\theta)\right|^2}{E\left[\left(\frac{\partial}{\partial\theta}\log f_{\underline{X}}\left(\underline{X};\theta\right)\right)^2\right]}$$

$$VAR\left[\widehat{\Theta}\left(\underline{X}\right)\right] \geq \frac{\left|1+b_n'(\theta)\right|^2}{-E\left[\frac{\partial^2}{\partial\theta^2}\log f_{\underline{X}}\left(\underline{X};\theta\right)\right]}$$

$$VAR\left[\widehat{\Theta}\left(\underline{X}\right)\right] \geq \frac{\left|1+b_n'(\theta)\right|^2}{I_n\left(\theta\right)}$$

Bound di Cramér-Rao

dove

$$I_n(\theta) = E\left[\left(\frac{\partial}{\partial\theta}\log f_{\underline{X}}(\underline{X};\theta)\right)^2\right] = -E\left[\frac{\partial^2}{\partial\theta^2}\log f_{\underline{X}}(\underline{X};\theta)\right]$$

è detta informazione di Fisher. Se lo stimatore è non polarizzato, cioè se

$$E\left[\widehat{\Theta}(\underline{X})\right] = \theta + \underbrace{b_n(\theta)}_{=0} = \theta$$

abbiamo

$$E\left[\left(\widehat{\Theta}(\underline{X}) - \theta\right)^2\right] = VAR\left[\widehat{\Theta}(\underline{X})\right] \geq \frac{1}{I_n(\theta)}$$

Bound di Cramér-Rao

Il valore MSE di uno stimatore rispetto al parametro stimato θ è dato da (la media del termine misto è nulla)

$$E\left[\left(\widehat{\Theta}\left(\underline{X}\right)-\theta+E\left[\widehat{\Theta}\left(\underline{X}\right)\right]-E\left[\widehat{\Theta}\left(\underline{X}\right)\right]\right)^2\right]$$

$$=E\left[\left(\widehat{\Theta}\left(\underline{X}\right)-E\left[\widehat{\Theta}\left(\underline{X}\right)\right]\right)^2\right]+E\left[\left(\theta-E\left[\widehat{\Theta}\left(\underline{X}\right)\right]\right)^2\right]$$

$$=VAR\left[\widehat{\Theta}\left(\underline{X}\right)\right]+b_n^2(\theta)$$

in quanto abbiamo posto, in generale,

$$E\left[\widehat{\Theta}\left(\underline{X}\right)\right]=\theta+b_n(\theta)$$

Bound di Cramér-Rao

Pertanto,

$$MSE\left[\widehat{\Theta}\left(\underline{X}\right)\right] = VAR\left[\widehat{\Theta}\left(\underline{X}\right)\right] + b_n^2(\theta) \geq \frac{\left|1 + b_n'(\theta)\right|^2}{I_n\left(\theta\right)} + b_n^2(\theta)$$

Se lo stimatore è non polarizzato, $b_n(\theta) = 0$, abbiamo

$$MSE\left[\widehat{\Theta}\left(\underline{X}\right)\right] = VAR\left[\widehat{\Theta}\left(\underline{X}\right)\right] \geq \frac{1}{I_n\left(\theta\right)}$$

Il bound di Cramér-Rao (CRB) è un limite inferiore per l'MSE di qualunque stimatore non polarizzato.

Uno stimatore non polarizzato il cui MSE è uguale al CRB è detto **efficiente**.

Se esiste uno stimatore efficiente per un dato problema di stima non bayesiana, questo necessariamente coincide con lo stimatore ML.

Bound di Cramér-Rao

Attenzione

$$MSE\left[\widehat{\Theta}\left(\underline{X}\right)\right] = \underbrace{VAR\left[\widehat{\Theta}\left(\underline{X}\right)\right]}_{\geq 0} + \underbrace{b_n^2(\theta)}_{\geq 0}$$

quindi se $MSE \to 0$ allora vanno a zero sia la varianza che la polarizzazione.

Inferenza non bayesiana: stima di parametri non aleatori

Lo stimatore a massima verosimiglianza ha un buon comportamento asintotico. Sotto opportune condizioni di regolarità risulta:

- asintoticamente corretto;
- consistente (converge in probabilità al valore vero);
- asintoticamente efficiente;
- asintoticamente normale.

Esempio

Supponiamo che $\underline{x} \in \{0,1\}^n$ sia una realizzazione di $\underline{X}$ bernoulliano con parametro β non noto che vogliamo stimare. Abbiamo visto che se $w(\underline{x})$ è il peso di Hamming della sequenza binaria osservata (il numero di "1" che contiene), allora

$$p_{\underline{X}}(\underline{x}) = \beta^{w(\underline{x})} (1-\beta)^{n-w(\underline{x})}$$

La stima ML si ottiene dalla relazione

$$\frac{\partial}{\partial \beta} \log p_{\underline{X}}(\underline{x}) = 0$$

Abbiamo

$$\frac{\partial}{\partial \beta} \log \left[\beta^{w(\underline{x})} (1-\beta)^{n-w(\underline{x})} \right]$$

$$= \frac{\partial}{\partial \beta} \left[w(\underline{x}) \log \beta + (n - w(\underline{x})) \log (1-\beta) \right]$$

$$= \frac{1}{\beta} w(\underline{x}) + \frac{1}{1-\beta} (n - w(\underline{x})) (-1)$$

Esempio

$$\frac{\partial}{\partial \beta} \log p_{\underline{X}}(\underline{x}) = 0 \implies \frac{1}{\beta} w(\underline{x}) + \frac{1}{1-\beta} (n - w(\underline{x}))(-1) = 0$$

$$\implies \frac{1}{\beta} w(\underline{x}) = \frac{1}{1-\beta} (n - w(\underline{x}))$$

$$\implies (1-\beta) w(\underline{x}) = \beta (n - w(\underline{x})) \qquad \beta \neq 0, 1$$

$$\implies (1-\beta) w(\underline{x}) + \beta w(\underline{x}) = \beta n$$

$$\implies \hat{\beta} = \frac{w(\underline{x})}{n}$$

Esempio

$$\hat{\beta} = \frac{w\left(\underline{x}\right)}{n}$$

Ricordiamo che

$$E\left[w\left(\underline{X}\right)\right] = n\beta, \qquad E\left[w^2\left(\underline{X}\right)\right] = n\beta - n\beta^2 + n^2\beta^2$$

quindi

$$E\left[\hat{\beta}\left(\underline{X}\right)\right] = \beta$$

$$E\left[\hat{\beta}^2\left(\underline{X}\right)\right] = \frac{n\beta - n\beta^2 + n^2\beta^2}{n^2} = \frac{n\beta(1-\beta)}{n^2} + \beta^2$$

e

$$VAR\left[\hat{\beta}^2\left(\underline{X}\right)\right] = E\left[\hat{\beta}^2\left(\underline{X}\right)\right] - \left(E\left[\hat{\beta}\left(\underline{X}\right)\right]\right)^2$$

$$= \frac{\beta(1-\beta)}{n} + \beta^2 - \beta^2 = \frac{\beta(1-\beta)}{n}$$

Lo stimatore ottenuto è non polarizzato e consistente in media quadratica. Questo stimatore è efficiente?

Esempio

Notiamo che

$$\frac{\partial}{\partial \beta} \log p_{\underline{X}}(\underline{x}) = \frac{\partial}{\partial \beta} \log \left[\beta^{w(\underline{x})} \ (1-\beta)^{n-w(\underline{x})} \right]$$

$$= \frac{\partial}{\partial \beta} \left[w(\underline{x}) \log \beta + (n - w(\underline{x})) \log (1-\beta) \right]$$

$$= \frac{1}{\beta} w(\underline{x}) + \frac{1}{1-\beta} (n - w(\underline{x})) (-1)$$

quindi

$$\frac{\partial}{\partial \beta} \log p_{\underline{X}}(\underline{x}) = \frac{1}{\beta} w(\underline{x}) + \frac{1}{1-\beta} (n - w(\underline{x})) (-1)$$

e, inoltre

$$\frac{\partial^2}{\partial \beta^2} \log p_{\underline{X}}(\underline{x}) = -\frac{1}{\beta^2} w(\underline{x}) - \frac{1}{(1-\beta)^2} (n - w(\underline{x}))$$

Esempio

Ricordiamo che

$$I_n(\theta) = E\left[\left(\frac{\partial}{\partial\theta}\log f_{\underline{X}}(\underline{X};\theta)\right)^2\right] = -E\left[\frac{\partial^2}{\partial\theta^2}\log f_{\underline{X}}(\underline{X};\theta)\right]$$

e usando l'ultima uguaglianza, abbiamo,

$$I_n(\theta) = E\left[\frac{1}{\beta^2}w(\underline{X}) + \frac{1}{(1-\beta)^2}(n - w(\underline{X}))\right]$$

$$= \frac{1}{\beta^2}E[w(\underline{X})] + \frac{1}{(1-\beta)^2}[n - E[w(\underline{X})]]$$

$$= \frac{1}{\beta^2}n\beta + \frac{1}{(1-\beta)^2}[n - n\beta]$$

$$= \frac{n}{\beta} + \frac{n}{(1-\beta)^2}(1-\beta) = \frac{n}{\beta} + \frac{n}{(1-\beta)} = n\frac{1-\beta+\beta}{\beta(1-\beta)} = \frac{n}{\beta(1-\beta)}$$

$$I_n(\beta) = \frac{n}{\beta(1-\beta)}$$

Esempio

$$I_n(\beta) = \frac{n}{\beta(1-\beta)}$$

Lo stimatore è non polarizzato, allora

$$CRB = \frac{1}{I_n(\beta)} = \frac{\beta(1-\beta)}{n}$$

La varianza dello stimatore ML attinge il CRB, quindi è efficiente.

Stimatore lineare MMSE

Partiamo con un semplice problema scalare. Assumiamo che $\underline{x}$ è il campione osservato, ottenuto come realizzazione di un vettore aleatorio $\underline{X}$ e assumiamo di voler progettare uno stimatore lineare di un parametro aleatorio Θ, distribuito in accordo ad una legge nota, con la forma:

$$\widehat{\Theta}\left(\underline{X}\right) = \underline{a}^T \underline{X} + b \qquad \underline{a} \in \mathbb{R}^n \quad b \in \mathbb{R}$$

Lo stimatore lineare MMSE (LMMSE) utilizza il vettore $\underline{a}$ e la costante b che permettono di rendere minimo l'errore quadratico medio (MSE)

$$E\left[\left(\widehat{\Theta}\left(\underline{X}\right) - \Theta\right)^2\right] = E\left[\left(\underline{a}^T \underline{X} + b - \Theta\right)^2\right]$$

che è uguale a:

$$E\left[\left(\underline{a}^T \underline{X} + b - \Theta\right)^2\right] = E\left[\left(\underline{a}^T \underline{X} + b - \Theta\right)\left(\underline{a}^T \underline{X} + b - \Theta\right)^T\right]$$

(il trasposto inserito nel secondo fattore nelle parentesi quadre non opera perché l'argomento è uno scalare)

$$= E\left[\left(\underline{a}^T \underline{X} + b - \Theta\right)\left(\underline{X}^T \underline{a} + b - \Theta\right)\right]$$

Stimatore lineare MMSE

$$= E\left[\left(\underline{a}^T\,\underline{X} + b - \Theta\right)\left(\underline{X}^T\,\underline{a} + b - \Theta\right)\right]$$

$$= \underline{a}^T \underbrace{E\left[\underline{X}\,\underline{X}^T\right]}_{\underline{\underline{R}}} \underline{a} + b^2 + E\left[\Theta^2\right] + 2\,b\,\underline{a}^T\,E\left[\underline{X}\right]$$

$$-2\,b\,E\left[\Theta\right] - 2\,\underline{a}^T\,E\left[\Theta\,\underline{X}\right]$$

dove

$$\underline{\underline{R}} = E\left[\underline{X}\,\underline{X}^T\right]$$

è la matrice di correlazione del vettore aleatorio $\underline{X}$. (**D'ora in poi per non appesantire la notazione omettiamo il pedice $\underline{X}$ nelle matrici di correlazione e di covarianza.**)
Quindi

$$E\left[\left(\underline{a}^T\,\underline{X} + b - \Theta\right)^2\right] = \underline{a}^T\,\underline{\underline{R}}\,\underline{a} + b^2 + E\left[\Theta^2\right] + 2\,b\,\underline{a}^T\,E\left[\underline{X}\right]$$

$$-2\,b\,E\left[\Theta\right] - 2\,\underline{a}^T\,E\left[\Theta\,\underline{X}\right]$$

Stimatore lineare MMSE

Ricordiamo che

$$\nabla_{\underline{w}} \left(\underline{u}^T \, \underline{w} \right) = \nabla_{\underline{w}} \left(\underline{w}^T \, \underline{u} \right) = \underline{u}$$

e

$$\nabla_{\underline{w}} \left(\underline{w}^T \, \underline{\underline{A}} \, \underline{w} \right) = 2 \, \underline{\underline{A}} \, \underline{w}$$

dove $\underline{\underline{A}}$ è una matrice simmetrica. Allora possiamo scrivere

$$\nabla_{\underline{a}} E \left[\left(\underline{a}^T \, \underline{X} + b - \Theta \right)^2 \right] = \nabla_{\underline{a}} \left\{ \underline{a}^T \, \underline{\underline{R}} \, \underline{a} + b^2 + E \left[\Theta^2 \right] + 2 \, b \, \underline{a}^T \, E \left[\underline{X} \right] \right.$$

$$\left. - 2 \, b \, E \left[\Theta \right] - 2 \, \underline{a}^T \, E \left[\Theta \, \underline{X} \right] \right\} = 2 \, \underline{\underline{R}} \, \underline{a} + 2 \, b \, E \left[\underline{X} \right] - 2 \, E \left[\Theta \, \underline{X} \right]$$

Pertanto

$$\nabla_{\underline{a}} E \left[\left(\underline{a}^T \, \underline{X} + b - \Theta \right)^2 \right] = 0 \implies 2 \, \underline{\underline{R}} \, \underline{a} + 2 \, b \, E \left[\underline{X} \right] - 2 \, E \left[\Theta \, \underline{X} \right] = 0$$

Stimatore lineare MMSE

Inoltre,

$$\frac{\partial}{\partial b} E\left[\left(\underline{a}^T \underline{X} + b - \Theta\right)^2\right] = \frac{\partial}{\partial b} \left\{\underline{a}^T \underline{\underline{R}} \underline{a} + b^2 + E\left[\Theta^2\right] + 2\, b\, \underline{a}^T E\left[\underline{X}\right]\right.$$

$$\left. - 2\, b\, E\left[\Theta\right] - 2\, \underline{a}^T E\left[\Theta\, \underline{X}^T\right]\right\} = 2\, b + 2\, \underline{a}^T E\left[\underline{X}\right] - 2\, E\left[\Theta\right]$$

$$\frac{\partial}{\partial b} E\left[\left(\underline{a}^T \underline{X} + b - \Theta\right)^2\right] = 0 \quad \Longrightarrow \; 2\, b + 2\, \underline{a}^T E\left[\underline{X}\right] - 2\, E\left[\Theta\right] = 0$$

$$\Longrightarrow \; b = -\, \underline{a}^T E\left[\underline{X}\right] + E\left[\Theta\right] = E\left[\Theta\right] - \underline{a}^T E\left[\underline{X}\right] = E\left[\Theta\right] - E\left[\underline{X}\right]^T \underline{a}$$

$$\boxed{b = E\left[\Theta\right] - E\left[\underline{X}\right]^T \underline{a}}$$

Stimatore lineare MMSE

Le equazioni ottenute sono

$$\nabla_{\underline{a}} E\left[\left(\underline{a}^T \underline{X} + b - \Theta\right)^2\right] = 0 \implies \underline{\underline{R}}\,\underline{a} + b\, E[\underline{X}] - E[\Theta\, \underline{X}] = 0$$

$$\frac{\partial}{\partial b} E\left[\left(\underline{a}^T \underline{X} + b - \Theta\right)^2\right] = 0 \implies b = E[\Theta] - E[\underline{X}]^T \underline{a}$$

Sostituendo l'espressione di b nella prima equazione abbiamo:

$$\underline{\underline{R}}\,\underline{a} + \left(E[\Theta] - E[\underline{X}]^T \underline{a}\right) E[\underline{X}] - E[\Theta\, \underline{X}] = 0$$

Nota che $\left(E[\underline{X}]^T \underline{a}\right)$ è uno scalare (come $E[\Theta]$), quindi se moltiplichiamo il vettore $E[\underline{X}]$ per tale scalare a destra o a sinistra non cambia nulla

$$\left(E[\underline{X}]^T \underline{a}\right) E[\underline{X}] = E[\underline{X}] \left(E[\underline{X}]^T \underline{a}\right).$$

Stimatore lineare MMSE

Nota, inoltre, che nel prodotto matriciale vale la proprietà associativa

$$\left(\underline{\underline{A}}\,\underline{\underline{B}}\right)\,\underline{\underline{C}} = \underline{\underline{A}}\,\left(\underline{\underline{B}}\,\underline{\underline{C}}\right)$$

quindi

$$\underline{\underline{R}}\,\underline{a} + \left(\,E\left[\Theta\right] - \,E\left[\underline{X}\right]^T\,\underline{a}\right)\,E\left[\underline{X}\right] - \,E\left[\Theta\,\underline{X}\right] = 0$$

diventa

$$\left[\underline{\underline{R}} - \,E\left[\underline{X}\right]\,E\left[\underline{X}\right]^T\right]\,\underline{a} + \,E\left[\Theta\right]\,E\left[\underline{X}\right] - \,E\left[\Theta\,\underline{X}\right] = 0$$

Ricordiamo il legame tra la matrice di covarianza $\underline{\underline{M}}$ e la matrice di correlazione $\underline{\underline{R}} = E\left[\underline{X}\,\underline{X}^T\right]$,

$$\underline{\underline{M}} = E\left[\left(\underline{X} - E\left[\underline{X}\right]\right)\left(\underline{X} - E\left[\underline{X}\right]\right)^T\right] = \underline{\underline{R}} - \,E\left[\underline{X}\right]\,E\left[\underline{X}\right]^T$$

Quindi la precedente diventa

$$\underline{\underline{M}}\,\underline{a} + \,E\left[\Theta\right]\,E\left[\underline{X}\right] - \,E\left[\Theta\,\underline{X}\right] = 0$$

Stimatore lineare MMSE

Osserviamo inoltre, che

$$E\left[\Theta\,\underline{X}\right] - E\left[\Theta\right]E\left[\underline{X}\right] = E\left\{\left(\underline{X} - E\left[\underline{X}\right]\right)\left(\Theta - E\left[\Theta\right]\right)\right\} \stackrel{\triangle}{=} \underline{s}$$

quindi il vettore ottimo nel senso MMSE, $\underline{a}_{\mathrm{MMSE}}$, si ottiene dalla soluzione dell'equazione

$$\underline{\underline{M}}\,\underline{a} = \underline{s} \quad \Longrightarrow \quad \underline{a}_{\mathrm{MMSE}} = \underline{\underline{M}}^{-1}\underline{s}$$

Inoltre, lo scalare ottimo nel senso MMSE, b_{MMSE}, è dato da

$$b_{\mathrm{MMSE}} = E\left[\Theta\right] - E\left[\underline{X}\right]^T \underline{a}_{\mathrm{MMSE}} = E\left[\Theta\right] - \underline{a}_{\mathrm{MMSE}}^T E\left[\underline{X}\right]$$

Algoritmo del gradiente

Supponiamo di voler risolvere in modo iterativo il problema LMMSE precedentemente descritto. Abbiamo visto in precedenza, calcolando il gradiente del MSE, che

$$\nabla_{\underline{a}} E\left[\left(\underline{a}^T \underline{X} + b - \Theta\right)^2\right] = 0 \implies \underline{\underline{R}}\,\underline{a} + b\,E\left[\underline{X}\right] - E\left[\Theta\,\underline{X}\right] = 0$$

$$\frac{\partial}{\partial b} E\left[\left(\underline{a}^T \underline{X} + b - \Theta\right)^2\right] = 0 \implies b = E\left[\Theta\right] - E\left[\underline{X}\right]^T \underline{a}$$

Sostituendo l'espressione di b nella prima equazione il gradiente del MSE risulta

$$2\,\underline{\underline{M}}\,\underline{a} - 2\,\underline{s}$$

dove il vettore $\underline{s}$ supponiamo sia noto.

Algoritmo del gradiente

Consideriamo la seguente procedura iterativa per determinare $\underline{a}_{\mathrm{LMMSE}}$

$$\underline{a}^{n+1} = \underline{a}^{n} - \gamma \left(\underline{\underline{M}}\, \underline{a}^{n} - \underline{s} \right)$$

che può essere scritta nel seguente modo

$$\underline{a}^{n+1} = \underline{a}^{n} - \gamma\, \underline{\underline{M}} \left(\underbrace{\underline{a}^{n} - \underbrace{\underline{\underline{M}}^{-1}\, \underline{s}}_{\underline{a}_{\mathrm{LMMSE}}}}_{\text{errore al passo } n} \right)$$

L'errore alla $(n+1)-$esima iterazione risulta

$$\underline{\epsilon}^{(n+1)} = \underline{a}^{(n+1)} - \underline{a}_{\mathrm{LMMSE}}$$

Algoritmo del gradiente

Usando l'epressione precedente di $\underline{a}^{n+1}$, abbiamo

$$\underline{\epsilon}^{(n+1)} = \underline{a}^n - \gamma\,\underline{\underline{M}}\left(\overbrace{\underline{a}^n - \underbrace{\underline{\underline{M}}^{-1}\,\underline{s}}_{\underline{a}_{\mathrm{LMMSE}}}}^{\underline{\epsilon}^{(n)}}\right) - \underline{a}_{\mathrm{LMMSE}}$$

$$= \underline{a}^n - \underline{a}_{\mathrm{LMMSE}} - \gamma\,\underline{\underline{M}}\left(\overbrace{\underline{a}^n - \underbrace{\underline{\underline{M}}^{-1}\,\underline{s}}_{\underline{a}_{\mathrm{LMMSE}}}}^{\underline{\epsilon}^{(n)}}\right)$$

$$= \overbrace{\underline{a}^n - \underline{a}_{\mathrm{LMMSE}}}^{\underline{\epsilon}^{(n)}} - \gamma\,\underline{\underline{M}}\left(\overbrace{\underline{a}^n - \underbrace{\underline{\underline{M}}^{-1}\,\underline{s}}_{\underline{a}_{\mathrm{LMMSE}}}}^{\underline{\epsilon}^{(n)}}\right)$$

$$= \underline{\epsilon}^{(n)} - \gamma\,\underline{\underline{M}}\,\underline{\epsilon}^{(n)} = \left(\underline{\underline{I}} - \gamma\,\underline{\underline{M}}\right)\,\underline{\epsilon}^{(n)}$$

Algoritmo del gradiente

Quindi

$$\underline{\epsilon}^{(n+1)} = \left(\underline{\underline{I}} - \gamma\, \underline{\underline{M}}\right)\, \underline{\epsilon}^{(n)}$$

e, iterando, abbiamo

$$\underline{\epsilon}^{(n+1)} = \left(\underline{\underline{I}} - \gamma\, \underline{\underline{M}}\right)\, \underline{\epsilon}^{(n)} = \left(\underline{\underline{I}} - \gamma\, \underline{\underline{M}}\right)\, \left(\underline{\underline{I}} - \gamma\, \underline{\underline{M}}\right)\, \underline{\epsilon}^{(n-1)}$$

$$= \ldots = \left(\underline{\underline{I}} - \gamma\, \underline{\underline{M}}\right)^n\, \underline{\epsilon}^{(1)}$$

Notiamo che

$$\underline{\underline{S}} \stackrel{\triangle}{=} \underline{\underline{I}} - \gamma\, \underline{\underline{M}}$$

è una matrice (reale) simmetrica (che ha tutti gli autovalori reali e gli autovettori, corrispondenti ad autovalori distinti, ortogonali), quindi ammette la decomposizione (decomposizione spettrale)

$$\underline{\underline{S}} = \underline{\underline{U}}\, \underline{\underline{\Lambda}}_S\, \underline{\underline{U}}^T$$

dove $\underline{\underline{\Lambda}}_S$ è una matrice diagonale i cui elementi sono gli autovalori di $\underline{\underline{S}}$ e $\underline{\underline{U}}$ è una matrice ortogonale ($\underline{\underline{U}}^T = \underline{\underline{U}}^{-1}$) le cui colonne sono gli autovettori normalizzati di $\underline{\underline{S}}$. Consideriamo il prodotto

$$\underline{\underline{S}} \cdot \underline{\underline{S}} = \left(\underline{\underline{U}}\, \underline{\underline{\Lambda}}_S\, \underline{\underline{U}}^T\right) \cdot \left(\underline{\underline{U}}\, \underline{\underline{\Lambda}}_S\, \underline{\underline{U}}^T\right)$$

Algoritmo del gradiente

Essendo gli autovettori ortogonali, abbiamo

$$\underline{\underline{U}}^T \cdot \underline{\underline{U}} = \underline{\underline{I}}$$

quindi

$$\underline{\underline{S}} \cdot \underline{\underline{S}} = \underline{\underline{U}}\ \underline{\underline{\Lambda}}_S^2\ \underline{\underline{U}}^T$$

dove $\underline{\underline{\Lambda}}_S$ è la matrice diagonale degli autovalori della matrice $\underline{\underline{S}}$. Iterando, abbiamo

$$\underline{\underline{S}}^n = \underline{\underline{U}}\ \underline{\underline{\Lambda}}_S^n\ \underline{\underline{U}}^T$$

Nel nostro caso

$$\underline{\underline{S}} \stackrel{\triangle}{=} \underline{\underline{I}} - \gamma\, \underline{\underline{M}}$$

e la matrice (diagonale) degli autovalori di $\underline{\underline{S}} = \underline{\underline{I}} - \gamma\, \underline{\underline{M}}$ sono nella matrice (diagonale) $\underline{\underline{\Lambda}}_S = \underline{\underline{I}} - \gamma\, \underline{\underline{\Lambda}}_M$ dove $\underline{\underline{\Lambda}}_M$ è la matrice (diagonale) degli autovalori della matrice di covarianza $\underline{\underline{M}}$ e $\underline{\underline{U}}$ è la matrice (ortogonale) degli autovettori della matrice $\underline{\underline{S}}$.

Algoritmo del gradiente

Quindi possiamo scrivere

$$\underline{\epsilon}^{(n+1)} = \left(\underline{\underline{I}} - \gamma\,\underline{\underline{M}}\right)^n\,\underline{\epsilon}^{(1)} = \underline{\underline{S}}^n\,\underline{\epsilon}^{(1)}$$

$$= \underline{\underline{U}}\;\underline{\underline{\Lambda}}_S^n\;\underline{\underline{U}}^T\,\underline{\epsilon}^{(1)} = \underline{\underline{U}}\;\left(\underline{\underline{I}} - \gamma\,\underline{\underline{\Lambda}}_M\right)^n\;\underline{\underline{U}}^T\,\underline{\epsilon}^{(1)}$$

Nota, la potenza $n-$esima di una matrice diagonale è una matrice diagonale con ciascuno degli elementi sulla diagonale pari alla potenza $n-$esima dell'elemento nella corrispondente posizione della matrice di partenza. Pertanto, l'errore converge a zero se il massimo modulo degli autovalori di $\underline{\underline{I}} - \gamma\,\underline{\underline{M}}$ è più piccolo di 1, cioè se

$$0 < \gamma < \frac{2}{\lambda_{\mathrm{MAX}}}$$

Un approccio differente: statistica descrittiva

Scordiamoci ora della probabilità. Assumiamo che i vettori contano per quello che sono e non perché sono considerati realizzazioni di vettori aleatori. Definiamo un data set di training come una collezione di p vettori $n-$dimensionali che possono essere organizzati nella matrice $n \times p$:

$$\underline{\underline{X}} = \begin{bmatrix} x_1(1) & x_1(2) & \dots & x_1(p) \\ x_2(1) & x_2(2) & \dots & x_2(p) \\ \vdots & \vdots & \vdots & \vdots \\ x_n(1) & x_n(2) & \dots & x_n(p) \end{bmatrix} \in \mathbb{R}^{n \times p}$$

Assumiamo di conoscere p valori misurati del parametro θ, ciascuno corrispondente ad uno dei p vettori $n-$dimensionali del training set, cioè

$$\underline{y} = [\theta(1), \theta(2), \dots, \theta(p)]^T \quad \in \mathbb{R}^p$$

Un approccio differente: statistica descrittiva

Vogliamo adattare i dati ad un modello lineare nella forma:

$$\theta(i) = \underline{a}^T \, \underline{x}(i) + \epsilon_i$$

dove $\underline{a}$ è un vettore $n-$dimensionale e $\underline{x}(i)$ è lo $i-$esimo vettore $n-$dimensionale dei p vettori $n-$dimensionali che costituiscono il data set. Vogliamo selezionare $\underline{a}$ in modo da minimizzare

$$\|\underline{\epsilon}\|^2 = \sum_{i=1}^{p} \left[\underline{a}^T \, \underline{x}(i) - \theta(i)\right]^2$$

dove

$$\underline{\epsilon} = \left[\epsilon_1, \epsilon_2, \ldots \epsilon_p\right]^T$$

Notiamo preliminarmente che:

$$\sum_{i=1}^{p} \left[\underline{a}^T \, \underline{x}(i) - \theta(i)\right]^2 = \| \underbrace{\underbrace{\underline{\underline{X}}^T}_{p\times n} \cdot \underbrace{\underline{a}}_{n\times 1}}_{p\times 1} - \underbrace{\underline{y}}_{p\times 1} \|^2$$

Un approccio differente: statistica descrittiva

Infatti

$$\underline{\underline{X}}^T \cdot \underline{a} = \begin{bmatrix} x_1(1) & x_1(2) & \dots & x_1(p) \\ x_2(1) & x_2(2) & \dots & x_2(p) \\ \vdots & \vdots & \vdots & \vdots \\ x_n(1) & x_n(2) & \dots & x_n(p) \end{bmatrix}^T \cdot \underline{a}$$

$$= \begin{bmatrix} x_1(1) & x_2(1) & \dots & x_n(1) \\ x_1(2) & x_2(2) & \dots & x_n(2) \\ \vdots & \vdots & \vdots & \vdots \\ x_1(p) & x_2(p) & \dots & x_n(p) \end{bmatrix} \cdot \underline{a} = \begin{bmatrix} \underline{x}(1)^T \cdot \underline{a} \\ \underline{x}(2)^T \cdot \underline{a} \\ \vdots \\ \underline{x}(p)^T \cdot \underline{a} \end{bmatrix}$$

Un approccio differente: statistica descrittiva

Inoltre,

$$\underline{\underline{X}}^T \cdot \underline{a} - \underline{y} = \begin{bmatrix} \underline{x}(1)^T \cdot \underline{a} - \theta(1) \\ \\ \underline{x}(2)^T \cdot \underline{a} - \theta(2) \\ \\ \vdots \\ \\ \underline{x}(p)^T \cdot \underline{a} - \theta(p) \end{bmatrix}$$

e

$$\|\underline{\underline{X}}^T \cdot \underline{a} - \underline{y}\|^2 = \sum_{i=1}^{p} \left[\underline{x}(i)^T \cdot \underline{a} - \theta(i)\right]^2$$

Nota che $\underline{x}(i)^T \cdot \underline{a}$ è uno scalare, quindi uguale al suo trasposto $\underline{a}^T \cdot \underline{x}(i)$.

Un approccio differente: statistica descrittiva

Ricordiamo che

$$\|\underline{\alpha} - \underline{\beta}\|^2 = \|\underline{\alpha}\|^2 + \|\underline{\beta}\|^2 - 2\, \underline{\alpha}^T \cdot \underline{\beta}$$

quindi

$$\|\underline{\underline{X}}^T \cdot \underline{a} - \underline{y}\|^2 = \|\underline{\underline{X}}^T \cdot \underline{a}\|^2 + \|\underline{y}\|^2 - 2\, \left(\underline{\underline{X}}^T \cdot \underline{a}\right)^T \cdot \underline{y}$$

pertanto

$$\|\underline{\underline{X}}^T \cdot \underline{a} - \underline{y}\|^2 = \left(\underline{\underline{X}}^T \cdot \underline{a}\right)^T \left(\underline{\underline{X}}^T \cdot \underline{a}\right) + \|\underline{y}\|^2 - 2\, \underline{a}^T \cdot \underline{\underline{X}} \cdot \underline{y}$$

$$= \underline{a}^T \cdot \underline{\underline{X}} \cdot \underline{\underline{X}}^T \cdot \underline{a} + \|\underline{y}\|^2 - 2\, \underline{a}^T \cdot \underline{\underline{X}} \cdot \underline{y}$$

dove $\underline{\underline{X}} \cdot \underline{\underline{X}}^T$ è una matrice simmetrica di dimensioni $n \times n$.

Un approccio differente: statistica descrittiva

Ricordiamo che

$$\nabla_{\underline{w}} \left(\underline{u}^T \, \underline{w} \right) = \nabla_{\underline{w}} \left(\underline{w}^T \, \underline{u} \right) = \underline{u}$$

e

$$\nabla_{\underline{w}} \left(\underline{w}^T \, \underline{\underline{A}} \, \underline{w} \right) = 2 \, \underline{\underline{A}} \, \underline{w}$$

dove $\underline{\underline{A}}$ è una matrice simmetrica. Quindi calcolando il gradiente rispetto ad $\underline{a}$ abbiamo

$$\nabla_{\underline{a}} \, \| \underline{\underline{X}}^T \cdot \underline{a} - \underline{y} \|^2 = \nabla_{\underline{a}} \left\{ \underline{a}^T \cdot \underline{\underline{X}} \cdot \underline{\underline{X}}^T \cdot \underline{a} + \| \underline{y} \|^2 - 2 \, \underline{a}^T \cdot \underline{\underline{X}} \cdot \underline{y} \right\}$$

$$= 2 \, \underline{\underline{X}} \cdot \underline{\underline{X}}^T \cdot \underline{a} - 2 \, \underline{\underline{X}} \cdot \underline{y}$$

cioè

$$\nabla_{\underline{a}} \, \| \underline{\underline{X}}^T \cdot \underline{a} - \underline{y} \|^2 = 0 \implies 2 \, \underline{\underline{X}} \cdot \underline{\underline{X}}^T \cdot \underline{a} - 2 \, \underline{\underline{X}} \cdot \underline{y} = 0$$

$$\implies \underline{a} = \left(\underline{\underline{X}} \cdot \underline{\underline{X}}^T \right)^{-1} \cdot \underline{\underline{X}} \cdot \underline{y}$$

La precedente relazione richiede l'invertibilità della matrice simmetrica $\underline{\underline{X}} \cdot \underline{\underline{X}}^T$ di dimensioni $n \times n$. (In sostanza si richiede che sia soddisfatta la condizione $p > n$ e che le n colonne della matrice $\underline{\underline{X}}^T$, di dimensioni $p \times n$, siano linearmente indipendenti.)

Un approccio differente: statistica descrittiva

Chiamiamo quella ottenuta la stima LS,

$$\underline{a}_{\mathrm{LS}} = \left(\underbrace{\underline{\underline{X}}}_{n\times p,\ p>n} \cdot \underline{\underline{X}}^T \right)^{-1} \cdot \underline{\underline{X}} \cdot \underline{y}$$

dove $\underline{a}_{\mathrm{LS}}$ è un vettore $n-$dimensionale. Esplicitiamo il fatto che la stima è basata su un campione $p-$dimensionale

$$\underline{a}_{\mathrm{LS}}(p) = \left(\underline{\underline{X}}(p) \cdot \underline{\underline{X}}^T(p)\right)^{-1} \cdot \underline{\underline{X}}(p) \cdot \underline{y}(p)$$

Consideriamo il seguente scenario: vogliamo progressivamente migliorare la nostra stima aggiungendo più osservazioni.

Un approccio differente: statistica descrittiva

Vogliamo "modificare" lo stimatore LS in modo tale da portare in conto la situazione sopra indicata e vogliamo farlo con una complessità limitata. Assumiamo $p \geq n$ e supponiamo di aver valutato

$$\underline{a}_{\mathrm{LS}}(p) = \left(\underline{\underline{X}}(p) \cdot \underline{\underline{X}}^T(p)\right)^{-1} \cdot \underline{\underline{X}}(p) \cdot \underline{y}(p)$$

Supponiamo di avere un nuovo vettore nel data set $\underline{x}(p+1)$ e una nuova osservazione $\theta(p+1)$. La nuova stima sarebbe

$$\underline{a}_{\mathrm{LS}}(p+1) = \left(\underline{\underline{X}}(p+1) \cdot \underline{\underline{X}}^T(p+1)\right)^{-1} \cdot \underline{\underline{X}}(p+1) \cdot \underline{y}(p+1)$$

Domanda: dobbiamo ricalcolare ogni cosa da zero?

Un approccio differente: statistica descrittiva

Sia $\underline{\underline{R}}$ una matrice invertibile di ordine n. Siano $\underline{u}$ e $\underline{v}$ vettori colonna $n-$dimensionali. Vale il seguente lemma sull'inversione di una matrice con aggiornamento di rango 1 (formula di Sherman-Morrison):

$$\left(\underbrace{\underline{\underline{R}}}_{n\times n} + \underbrace{\underbrace{\underline{u}}_{n\times 1} \cdot \underbrace{\underline{v}^T}_{1\times n}}_{n\times n} \right)^{-1} = \underline{\underline{R}}^{-1} - \frac{\underline{\underline{R}}^{-1} \cdot \underline{u} \cdot \underline{v}^T \cdot \underline{\underline{R}}^{-1}}{1 + \underline{u}^T \cdot \underline{\underline{R}}^{-1} \cdot \underline{v}}$$

Un approccio differente: statistica descrittiva

Ricordiamo che

$$\underline{\underline{X}}(p) = \begin{bmatrix} x_1(1) & x_1(2) & \dots & x_1(p) \\ x_2(1) & x_2(2) & \dots & x_2(p) \\ \vdots & \vdots & \vdots & \vdots \\ x_n(1) & x_n(2) & \dots & x_n(p) \end{bmatrix}$$

$$= \begin{bmatrix} \underline{x}(1) & \underline{x}(2) & \dots & \underline{x}(p) \end{bmatrix} \in \mathbb{R}^{n \times p}$$

Quindi

$$\underline{\underline{X}}(p)\underline{\underline{X}}^T(p)$$

$$= \begin{bmatrix} \underline{x}(1) & \underline{x}(2) & \dots & \underline{x}(p) \end{bmatrix} \begin{bmatrix} \underline{x}^T(1) \\ \underline{x}^T(2) \\ \vdots \\ \underline{x}^T(p) \end{bmatrix} = \sum_{i=1}^{p} \underline{x}(i) \cdot \underline{x}^T(i)$$

Un approccio differente: statistica descrittiva

Pertanto,

$$\underline{\underline{X}}(p+1)\cdot\underline{\underline{X}}^T(p+1)=\sum_{i=1}^{p+1}\underline{x}(i)\cdot\underline{x}^T(i)=\sum_{i=1}^{p}\underline{x}(i)\cdot\underline{x}^T(i)+\underline{x}(p+1)\cdot\underline{x}^T(p+1)$$

$$=\underline{\underline{X}}(p)\cdot\underline{\underline{X}}^T(p)+\underline{x}(p+1)\cdot\underline{x}^T(p+1)$$

che possiamo scrivere come segue

$$\underline{\underline{R}}(p+1)=\underline{\underline{R}}(p)+\underbrace{\underline{x}(p+1)}_{\underline{u}}\cdot\underbrace{\underline{x}^T(p+1)}_{\underline{v}^T}$$

Utilizzando la formula di Sherman-Morrison:

$$\left(\underbrace{\underline{\underline{R}}}_{n\times n}+\underbrace{\underbrace{\underline{u}}_{n\times 1}\cdot\underbrace{\underline{v}^T}_{1\times n}}_{n\times n}\right)^{-1}=\underline{\underline{R}}^{-1}-\frac{\underline{\underline{R}}^{-1}\cdot\underline{u}\cdot\underline{v}^T\cdot\underline{\underline{R}}^{-1}}{1+\underline{u}^T\cdot\underline{\underline{R}}^{-1}\cdot\underline{v}}$$

Un approccio differente: statistica descrittiva

possiamo scrivere

$$\underline{\underline{R}}^{-1}(p+1) = \underline{\underline{R}}^{-1}(p) - \frac{\underline{\underline{R}}^{-1}(p) \cdot \underline{x}(p+1) \cdot \underline{x}(p+1)^T \cdot \underline{\underline{R}}^{-1}(p)}{1 + \underbrace{\underline{x}(p+1)^T \cdot \underline{\underline{R}}^{-1}(p) \cdot \underline{x}(p+1)}_{K(p+1)}}$$

Ora

$$\underline{a}(p+1) = \underline{\underline{R}}^{-1}(p+1) \cdot \underline{\underline{X}}(p+1) \cdot \underline{y}(p+1)$$

dove

$$\underline{\underline{X}}(p) = \begin{bmatrix} x_1(1) & x_1(2) & \dots & x_1(p) \\ x_2(1) & x_2(2) & \dots & x_2(p) \\ \vdots & \vdots & \vdots & \vdots \\ x_n(1) & x_n(2) & \dots & x_n(p) \end{bmatrix}$$

$$= \begin{bmatrix} \underline{x}(1) & \underline{x}(2) & \dots & \underline{x}(p) \end{bmatrix} \in \mathbb{R}^{n \times p}$$

Un approccio differente: statistica descrittiva

e quindi

$$\underline{\underline{X}}(p+1) = \left[\begin{array}{cccccc} \underline{x}(1) & \underline{x}(2) & \dots & \underline{x}(p) & \underline{x}(p+1) \end{array} \right]$$

$$\Longrightarrow \underbrace{\underline{\underline{X}}(p+1)}_{n\times(p+1)} = \left[\underbrace{\underline{\underline{X}}(p)}_{n\times p} \quad \underbrace{\underline{x}(p+1)}_{n\times 1} \right]$$

inoltre

$$\underbrace{\underline{y}(p+1)}_{(p+1)\times 1} = \left[\underbrace{\underline{y}^T(p)}_{1\times p} \quad \theta(p+1) \right]^T$$

Un approccio differente: statistica descrittiva

Allora possiamo scrivere

$$\underline{a}(p+1) = \underline{\underline{R}}^{-1}(p+1) \cdot \underline{\underline{X}}(p+1) \cdot \underline{y}(p+1)$$

$$= \left[\underline{\underline{R}}^{-1}(p) - \frac{\underline{\underline{R}}^{-1}(p) \cdot \underline{x}(p+1) \cdot \underline{x}(p+1)^T \cdot \underline{\underline{R}}^{-1}(p)}{1 + \underbrace{\underline{x}(p+1)^T \cdot \underline{\underline{R}}^{-1}(p) \cdot \underline{x}(p+1)}_{K(p+1)}} \right]$$

$$\cdot \left[\underbrace{\underline{\underline{X}}(p)}_{n \times p} \quad \underbrace{\underline{x}(p+1)}_{n \times 1} \right] \cdot \left[\underbrace{\underline{y}^T(p)}_{1 \times p} \quad \theta(p+1) \right]^T$$

Un approccio differente: statistica descrittiva

Quindi

$$\underline{a}(p+1) = \underline{\underline{R}}^{-1}(p+1) \cdot \underline{\underline{X}}(p+1) \cdot \underline{y}(p+1)$$

$$= \left[\underline{\underline{R}}^{-1}(p) - \frac{\underline{\underline{R}}^{-1}(p) \cdot \underline{x}(p+1) \cdot \underline{x}(p+1)^T \cdot \underline{\underline{R}}^{-1}(p)}{1 + K(p+1)} \right]$$

$$\cdot \left[\underbrace{\underbrace{\underline{\underline{X}}(p)}_{n \times p} \cdot \underbrace{\underline{y}(p)}_{p \times 1}}_{n \times 1} + \underbrace{\theta(p+1)\, \underline{x}(p+1)}_{n \times 1} \right]$$

Un approccio differente: statistica descrittiva

Pertanto

$$\underline{a}(p+1) = \underline{\underline{R}}^{-1}(p+1) \cdot \underline{\underline{X}}(p+1) \cdot \underline{y}(p+1)$$

$$= \left[\underline{\underline{R}}^{-1}(p) - \frac{\underline{\underline{R}}^{-1}(p) \cdot \underline{x}(p+1) \cdot \underline{x}(p+1)^T \cdot \underline{\underline{R}}^{-1}(p)}{1 + K(p+1)} \right]$$

$$\cdot \left[\underline{\underline{X}}(p) \cdot \underline{y}(p) + \theta(p+1)\, \underline{x}(p+1) \right]$$

$$= \left[\underline{\underline{R}}^{-1}(p) - \frac{\underline{\underline{R}}^{-1}(p) \cdot \underline{x}(p+1) \cdot \underline{x}(p+1)^T \cdot \underline{\underline{R}}^{-1}(p)}{1 + K(p+1)} \right]$$

$$\cdot \underbrace{\underline{\underline{R}}(p) \cdot \underline{\underline{R}}^{-1}(p)}_{\underline{\underline{I}}_n} \cdot \left[\underline{\underline{X}}(p) \cdot \underline{y}(p) + \theta(p+1)\, \underline{x}(p+1) \right]$$

dove, chiaramente, l'inserimento della matrice identità $n \times n$, $\underline{\underline{I}}_n$, non cambia nulla.

Un approccio differente: statistica descrittiva

Otteniamo

$$\underline{a}(p+1)$$
$$= \left[\underline{\underline{I}}_n(p) - \frac{\underline{\underline{R}}^{-1}(p) \cdot \underline{x}(p+1) \cdot \underline{x}(p+1)^T}{1+K(p+1)}\right]$$
$$\cdot \left[\underbrace{\underline{\underline{R}}^{-1}(p) \cdot \underline{\underline{X}}(p) \cdot \underline{y}(p)}_{\underline{a}(p)} + \theta(p+1)\,\underline{\underline{R}}^{-1}(p) \cdot \underline{x}(p+1)\right]$$

Quindi

$$\underline{a}(p+1) = \left[\underline{\underline{I}}_n(p) - \frac{\underline{\underline{R}}^{-1}(p) \cdot \underline{x}(p+1) \cdot \underline{x}(p+1)^T}{1+K(p+1)}\right]$$
$$\cdot \left[\underline{a}(p) + \theta(p+1)\,\underline{\underline{R}}^{-1}(p) \cdot \underline{x}(p+1)\right]$$

Il calcolo comporta $\mathcal{O}(n^2)$ operazioni indipendentemente da p. La complessità non scala con p.

Informazione e sua misura

Cosa è l'informazione? Come la si misura? A queste domande cercheremo di dare una risposta.

Supponiamo di avere una sorgente quaternaria (la cui emissione sia schematizzata mediante una variabile $X \in \mathcal{X} = \{0, 1, 2, 3\}$). Supponiamo di indicare con $X(n)$ l'n-esima emissione della sorgente. Possiamo valutare la frequenza di occorrenza di ciascuna cifra che, al limite per $n \to \infty$, tende alla probabilità. Sia allora

$$p_{X(n)}(x) = p_X(x), \quad x \in \mathcal{X}$$

la pmf della generica emissione e assumiamo:

$$p_X(x) = \begin{cases} \frac{1}{2} & x = 0 \\ \frac{1}{4} & x = 1 \\ \frac{1}{8} & x = 2 \\ \frac{1}{8} & x = 3 \end{cases}$$

Informazione e sua misura

Ogni simbolo quaternario può essere rappresentato mediante una coppia di bit. Questo significa che, indipendentemente dal simbolo emesso, avremo un codice di lunghezza 2 bit/simbolo.
Cambiamo ora approccio: usiamo cioè un codice a lunghezza variabile quale quello sotto-indicato in terza colonna e confrontiamolo con il codice a lunghezza fissa

x	C_{fissa}	$C_{variabile}$
0	00	0
1	01	10
2	10	110
3	11	111

Informazione e sua misura

Supponiamo ora che la sorgente emetta una (lunga) stringa di N simboli. Con il codice a lunghezza fissa, come detto, useremo 2 bit/simbolo. Con il codice a lunghezza variabile, indicando con $f_N(i)$ la frequenza con cui nella stringa appare il simbolo i, avremo che il numero medio di bit per simbolo è

$$L_N = 1 \cdot f_N(0) + 2 \cdot f_N(1) + 3 \cdot f_N(2) + 3 \cdot f_N(3)$$

Al divergere di N, $L_N \to L$, dove L, lunghezza media del codice, risulta pari a

$$L = 1 \cdot p_X(0) + 2 \cdot p_X(1) + 3 \cdot p_X(2) + 3 \cdot p_X(3)$$

$$= 1 \cdot \frac{1}{2} + 2\frac{1}{4} + 3\frac{1}{8} + 3\frac{1}{8} = \frac{1}{2} + \frac{1}{2} + \frac{3}{8} + \frac{3}{8} = 1 + \frac{3}{4} = \frac{7}{4} = 1.75 \quad bit/simbolo$$

Questo codice a lunghezza variabile ha anche altre caratteristiche per cui risulta univocamente decifrabile. Riusciamo ad utilizzare solo 1.75 bit/simbolo perché la sorgente emette meno informazione di quella che corrisponde ad una lunghezza media del codice di 2 bit/simbolo.
Ma come misuriamo questa informazione?

Informazione e sua misura

Supponiamo che gli eventi di interesse siano $(A_1, A_2, \ldots, A_N)$, cioè N sottoinsiemi di un certo spazio campione Ω. Si consideri lo spazio di probabilità $(\Omega, \mathcal{T}, P)$ con $\mathcal{T}$ costruito a partire dagli eventi di interesse. Sia $A \in \mathcal{T}$ un evento del cui verificarsi siamo informati: vogliamo definire $i(A)$, la quantità di informazione che riceviamo sapendo che A si verifica.

Ipotesi sensate nella definizione di $i(A)$ sono:

1. $i(A) \geq 0$, l'informazione deve essere una quantità non negativa (l'informazione non può nuocere);
2. l'informazione relativa al verificarsi di eventi rari deve avere maggior valore, cioè $i(A)$ deve essere una funzione decrescente di $P(A)$;
3. indipendenza: se A e B sono eventi indipendenti,

$$i\left(A \cap B\right) = i(A) + i(B).$$

La definizione di informazione (soddisfa i precedenti criteri) è

$$i(A) \stackrel{\triangle}{=} \log \frac{1}{P(A)}$$

Informazione e sua misura

Supponiamo di eseguire ripetutamente un esperimento che abbia esiti possibili $(A_1, A_2, \ldots, A_N)$, siano $\{P(A_i)\}_{i=1}^{N}$ le corrispondenti probabilità. Ovviamente $i(A)$ è una variabile aleatoria che associa agli eventi A_k i valori $i(A_k) = \log \frac{1}{P(A_k)}$. Il valore medio di questa variabile aleatoria è:

$$E\left[i(A)\right] = \sum_{k=1}^{N} i(A_k)\, P(A_k) = \sum_{k=1}^{N} \left(\log \frac{1}{P(A_k)}\right)\, P(A_k)$$

La quantità $H\left(\mathcal{E}\right) = E\left[i(A)\right]$ si definisce "entropia" dell'esperimento aleatorio i cui possibili risultati sono $(A_1, A_2, \ldots, A_N)$.

Entropia di una variabile aleatoria discreta

Sia X una variabile aleatoria che assume valori in un alfabeto $\mathcal{X}$. Per il momento supponiamo che $| \mathcal{X} | = M$ e $\mathcal{X} = \{x_1, x_2, \ldots, x_M\}$. Gli eventi di interesse sono $\{X = x_i\}_{i=1}^{M}$. Possiamo definire la variabile aleatoria

$$i(X) = \log \frac{1}{p_X(X)}$$

Si definisce "entropia" di X la quantità

$$H(X) = E[i(X)] = \sum_{i=1}^{M} p_X(x_i) \log \frac{1}{p_X(x_i)}$$

La definizione si applica anche al caso in cui $M \to \infty$. La base del logaritmo determina l'unità di misura dell'entropia. In particolare, l'entropia si misura in

1. "bit", se la base del logaritmo è 2;
2. "nat", se la base del logaritmo è e.

Entropia di una variabile aleatoria discreta

La quantità di informazione che noi riceviamo osservando le determinazioni di una variabile aleatoria è (per forza) pari alla quantità di incertezza a priori che noi abbiamo sull'esito dell'esperimento. Quindi una variabile aleatoria massimamente informativa è anche una variabile massimamente incerta.

Si noti che senza incertezza a priori non esiste informazione.

Esempio: lancio di una moneta

Si consideri una moneta per cui la croce $\{C\}$ esce con probabilità $P(\{C\}) = p$, e la testa $\{T\}$ con probabilità $P(\{T\}) = 1 - p$. Da Ω formiamo la $\sigma-$algebra $\mathcal{T} = P(\Omega) = \{\emptyset, C, T, \Omega\}$. Denotato questo esperimento aleatorio con $\mathcal{E}$, avremo:

$$H(\mathcal{E}) = p \log \frac{1}{p} + (1-p) \log \frac{1}{1-p} = -p \log p - (1-p) \log(1-p)$$

$$= H(p, 1-p) = H_2(p) = H(p)$$

Osserviamo che anche per una sorgente binaria che emetta 0 con probabilità p e 1 con probabilità $1 - p$ avremo la stessa espressione. In generale, l'entropia di ogni esperimento con esito binario ammette l'espressione precedente.

Diseguaglianza di Jensen

Vediamo un utile teorema: la diseguaglianza di Jensen.

Dalle precedenti relazioni si vede che l'entropia di una variabile aleatoria è espressa nella seguente forma generale:

$$H(X) = E\left[i(X)\right] = E[g(X)]$$

con

$$g(\alpha) = \log \frac{1}{p_X(\alpha)}$$

Problema: esiste un relazione generale che leghi (anche sotto forma di diseguaglianza) le quantità: $E[g(X)]$ e $g\left(E[X]\right)$? La risposta in generale è no, a meno che $g(\cdot)$ presenti concavità costante su tutto l'intervallo reale $[x_{MIN}, x_{MAX}]$, dove x_{MIN} è il più piccolo valore di $\mathcal{X}$ e x_{MAX} il più grande.

Diseguaglianza di Jensen

Se $g(x)$ è convessa nell'intervallo $I \supseteq \mathcal{X}$ e $X \in \mathcal{X}$ una variabile aleatoria arbitraria, allora:

$$E[g(X)] \geq g\left(E[X]\right)$$

Simmetricamente se $g(X)$ è concava nell'intervallo $I \supseteq \mathcal{X}$ allora:

$$E[g(X)] \leq g\left(E[X]\right).$$

L'uguaglianza vale solo se $g(\cdot)$ è lineare o se X non è aleatoria (cioè, costante con $\omega \in \Omega$). Se $g(x)$ non presenta concavità costante in I non esiste una relazione generale.

Diseguaglianza di Jensen - Esempi di applicazione: proprietà dell'entropia

Abbiamo visto che

$$H(X) = E\left[\log \frac{1}{p_X(X)}\right] = E\left[\log Y\right]$$

dove

$$Y(\omega) = \frac{1}{p_X(X(\omega))},$$

inoltre, risulta

$$E[Y(\omega)] = \sum_{x \in \mathcal{X}} \overbrace{\frac{1}{p_X(x)}}^{\text{valori assunti}} \cdot \underbrace{p_X(x)}_{\text{prob. dei valori assunti}} = |\,\mathcal{X}\,|$$

Diseguaglianza di Jensen - Esempi di applicazione: proprietà dell'entropia

Osserviamo che

$$\frac{d^2}{dy^2}\log y = -\frac{1}{y^2} < 0 \quad \forall y > 0$$

e che

$$y = \frac{1}{p_X(x)},$$

assume valori non negativi ($p_X(x) > 0 \quad \forall x \in \mathcal{X}$). Se la derivata seconda è negativa la funzione risulta essere concava, quindi

$$H(X) = E\left[\log Y\right] \leq \log E\left[Y\right] = \log \mid \mathcal{X} \mid$$

Diseguaglianza di Jensen - Esempi di applicazione: proprietà dell'entropia

Quindi, in generale, risulta

$$H(X) \leq \log \mid \mathcal{X} \mid$$

Tra tutte le pmf su $\mathcal{X}$ quella che corrisponde alla massima entropia è quella uniforme. Infatti, in questo caso risulta

$$H(X) = E\left[\log \frac{1}{p_X(X)}\right] = \sum_{x \in \mathcal{X}} \overbrace{\log \frac{1}{\frac{1}{|\mathcal{X}|}}}^{\text{valori assunti}} \cdot \underbrace{p_X(x)}_{\text{prob. dei valori assunti}}$$

$$= \sum_{x \in \mathcal{X}} \log \mid \mathcal{X} \mid \, p_X(x) = \log \mid \mathcal{X} \mid$$

Sorgenti di informazione

Una sorgente di informazione è schematizzabile come "un blocco" che in ogni istante n emette una lettera presa da un alfabeto $\mathcal{X}$, detto alfabeto sorgente. Una sorgente discreta senza memoria (Discrete Memoryless Source, DMS) è modellabile come un blocco che emetta una sequenza di lettere senza conservare memoria delle emissioni precedenti. Pertanto, una generica emissione è rappresentata dalla stringa aleatoria

$$\ldots, X_0, X_1, \ldots, X_n$$

dove le X_i sono variabili aleatorie con una pmf comune (sorgente stazionaria), sia essa $p_X(x)$, con $x \in \mathcal{X}$. Si definisce codifica di sorgente la rappresentazione delle emissioni della sorgente con stringhe binarie quanto più brevi possibile. Torniamo all'esempio a pag 3, la differenza tra i due codici è che uno è a lunghezza fissa, l'altro a lunghezza variabile. Noi comunque vogliamo codificare stringhe di lettere dell'alfabeto sorgente.

Sorgenti di informazione

Siccome di un codice a lunghezza variabile non sappiamo la lunghezza di ogni codeword (parola codice), abbiamo due possibilità:

1. poniamo un segno di interpunzione tra due codewords successive: questo darebbe luogo ad uno "spreco" e ad un aumento del numero medio di bit per lettera di sorgente;
2. imponiamo che "concatenazioni" di codewords corrispondono in modo biunivoco a concatenazioni di lettere dell'alfabeto sorgente.

Sia $\{X_n\}_{n=\ldots,-1,0,1,\ldots}$ una sequenza di lettere di una sorgente arbitraria, con $X_n \in \mathcal{X}$ e $|\mathcal{X}| = M$. Vogliamo rappresentare ogni lettera mediante una stringa binaria, cioè istituire la corrispondenza:

$$C : x \in \mathcal{X} \implies C(x) \in \{0,1\}^{l(x)}$$

Vogliamo, inoltre, che una qualunque concatenazione di codewords corrisponda biunivocamente ad un'unica concatenazione di lettere: questa si chiama condizione di univoca decifrabilità.

Sorgenti di informazione

Un codice di sorgente si dice univocamente decifrabile se, $\forall\, n$, valgono le condizioni:

$$C : \underline{x}^n \in \mathcal{X}^n \implies C(\underline{x}^n) = C(X_1)C(x_2)\cdots C(x_n) \in \{0,1\}^{\sum_{i=1}^{n} l(x_i)}$$

$$\underline{x}^n = (x_1, x_2, \ldots, x_n) = C^{-1}\left[C(\underline{x}^n)\right] = \left(C^{-1}\left[x_1\right], \ldots, C^{-1}\left[x_n\right]\right) \in \mathcal{X}^n$$

Un codice si dice istantaneo se ogni parola codice può essere decodificata appena si presenta nella stringa binaria.
I codici istantanei sono per definizione quelli per cui nessuna parola codice può essere prefisso di un'altra parola codice.

Sorgenti di informazione

Esempio - si considerino i tre codici:

x	$p_X(x)$	$C_1(x)$	$C_2(x)$	$C_3(x)$
1	1/4	000	0	10
2	3/32	001	1001	110
3	1/8	010	100	001
4	1/32	011	1111	1111
5	3/16	100	01	000
6	1/8	101	110	010
7	1/16	110	1100	1110
8	1/8	111	111	011

Sorgenti di informazione

$C_1(x)$ è univocamente decifrabile (in quanto a lunghezza fissa). Chiaramente $L_1 = E[l_1(X)] = 3$.

$C_2(x)$ e $C_3(x)$ sono a lunghezza variabile e la lunghezza media dei due codici è:

$$L_2 = E[l_2(X)] = 2.5 \quad bit/symbol$$

$$L_3 = E[l_3(X)] = 2.84375 \quad bit/symbol$$

Entrambi hanno lunghezza media minore di $L_1 = 3$, ma solo $C_3(x)$ è univocamente decifrabile. Infatti, adottando $C_2(x)$, la stringa binaria 1111000 corrisponde alla sequenza $(x_1, x_2, x_3) = (8, 3, 1)$ ma anche alla sequenza $(x_1, x_2, x_3, x_4) = (4, 1, 1, 1)$.

Noi siamo chiaramente interessati sia a minimizzare la lunghezza media ma anche a preservare l'univoca decifrabilità.

Si noti che $C_3(x)$ è un codice a prefisso, in quanto nessuna parola codice è prefisso di un'altra.

Sorgenti di informazione

Una condizione necessaria e sufficiente perché un insieme di lunghezze $\{l(x)\}_{x\in\mathcal{X}}$ sia compatibile con la condizione del prefisso è data dalla disuguaglianza di Kraft:

$$\sum_{x\in\mathcal{X}} 2^{-l(x)} \leq 1$$

D'ora in poi ci focalizzeremo solo sui codici a prefisso (o istantanei).

Codice di Shannon

Si assuma di avere una sorgente con alfabeto $M-$ario,
$X \in \{x_1, x_2, \ldots, x_M\}$.
Si assuma che la legge di probabilità con cui le lettere vengono emesse sia nota, cioè assumiamo di conoscere $\{p_X(x_i) = P_r\{X = x_i\}\}_{i=1}^{M}$.
Si definisce codice di Shannon quello che utilizza per x_i una stringa binaria di lunghezza

$$l(x_i) = \lceil \log \frac{1}{p_X(x_i)} \rceil$$

Si noti che

$$\log \frac{1}{p_X(x_i)} \leq l(x_i) < \log \frac{1}{p_X(x_i)} + 1$$

quindi

$$\sum_{i=1}^{M} 2^{-l(x_i)} \leq \sum_{i=1}^{M} 2^{-\log \frac{1}{p_X(x_i)}} = \sum_{i=1}^{M} p_X(x_i) = 1 \implies \sum_{i=1}^{M} 2^{-l(x_i)} \leq 1$$

Pertanto, esiste almeno un codice istantaneo che abbia le lunghezze del codice di Shannon.

Codice di Shannon

Abbiamo visto che la condizione

$$\log \frac{1}{p_X(x_i)} \leq l(x_i) < \log \frac{1}{p_X(x_i)} + 1$$

dà luogo all'esistenza dei codici a prefisso. Dalla precedente relazione abbiamo

$$\underbrace{\sum_{i=1}^{M} p_X(x_i) \log \frac{1}{p_X(x_i)}}_{H(X)} \leq \underbrace{\sum_{i=1}^{M} p_X(x_i) l(x_i)}_{L \text{ lunghezza media del codice}} < \sum_{i=1}^{M} p_X(x_i) \log \frac{1}{p_X(x_i)} + 1$$

Codice di Shannon

$$H(X) \leq L < H(X) + 1$$

La lunghezza media di un codice che soddisfa la condizione di Kraft (necessaria e sufficiente per la istantaneità e quindi per l'univoca decifrabilità) deve essere maggiore o uguale all'entropia della sorgente.

Dalla relazione $L \geq H(X)$ risulta evidente che l'entropia di una sorgente dà una misura per la sua comprimibilità. La condizione precedente è anche necessaria per l'univoca decifrabilità.

Codici a prefisso ottimi: codici di Huffmann

1. Disporre verticalmente i simboli in ordine di probabilità decrescente.
2. Raggruppare i due simboli meno probabili in un "macrosimbolo" cui si assegna la somma delle probabilità dei due simboli che la compongono: questo riduce di una unità la cardinalità dell'alfabeto.
3. Ripetere il passo precedente fino a quando non si arriva alla radice dell'albero, cioè ad un unico macrosimbolo con probabilità pari a 1.
4. Assegnare $1/0$ ai rami ascendenti/discendenti dell'albero. La parola codice di ogni nodo terminale è la sequenza di bit necessari per arrivare dalla radice al nodo su cui essa è posta.

Codici a prefisso ottimi: codici di Huffmann

Esempio: si consideri un alfabeto con 8 simboli,

$$\mathcal{X} = \{1, 2, 3, 4, 5, 6, 7, 8\}$$

e le due pmf riportate in seguito:

$$p_1(x) = \left\{ \frac{1}{4}, \frac{1}{4}, \frac{1}{8}, \frac{1}{8}, \frac{1}{16}, \frac{1}{16}, \frac{1}{16}, \frac{1}{16} \right\}$$

$$p_2(x) = \left\{ \frac{1}{3}, \frac{1}{9}, \frac{1}{9}, \frac{1}{9}, \frac{1}{27}, \frac{2}{27}, \frac{1}{6}, \frac{1}{18} \right\}$$

Codici a prefisso ottimi: codici di Huffmann

Utilizzando la procedura precedentemente indicata si ottengono i seguenti codici di Huffmann per $p_1(x)$ e $p_2(x)$.

x	$C(p_1(x))$	$C(p_2(x))$
1	00	00
2	10	010
3	001	011
4	101	100
5	0011	101
6	1011	110
7	0111	1110
8	1111	1111

Risulta

$$H_1(x) = 2.75\ bits \qquad L_1 = E[l_1(X)] = 2.75\ bits/simbolo$$

$$H_2(x) = 2.7017\ bits \qquad L_2 = E[l_2(X)] = 2.759\ bits/simbolo$$

Codici a prefisso ottimi: codici di Huffmann

Il codice di Huffmann non è unico: per esempio, in precedenza avremmo potuto unire i simboli meno probabili diversamente.
Si noti che in entrambi i casi le due lettere meno probabili differiscono solo nell'ultimo bit; questa è una caratteristica di tutti i codici di Huffmann.
Entrambi i codici dei due esempi precedenti sono ottimi, nel senso che raggiungono la minima lunghezza media. Tuttavia solo il codice corrispondente a $p_1(x)$ raggiunge una lunghezza media pari all'entropia della sorgente.
Questo suggerisce che se il limite entropico è raggiungibile, allora questo è necessariamente ottenuto con un codice di Huffmann: se, viceversa, il codice di Huffmann non raggiunge il limite entropico, questo significa che il limite entropico non è ottenibile.

Il limite entropico è raggiungibile se e solo se

$$p_X(x) = 2^{-l(x)} \quad x \in \mathcal{X}$$